



저작자표시-동일조건변경허락 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.
- 이차적 저작물을 작성할 수 있습니다.
- 이 저작물을 영리 목적으로 이용할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



동일조건변경허락. 귀하가 이 저작물을 개작, 변형 또는 가공했을 경우에는, 이 저작물과 동일한 이용허락조건하에서만 배포할 수 있습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

제 144 회 석사학위 논문

지도교수 박인선 박호현

통합관제센터 운영을 위한 Vision AI - VLM 비교
및 하이브리드 연구

A Comparative Study of Vision AI Model and VLM
with Hybrid Approach for Integrated Control Center
Operations

중앙대학교 대학원

ICT안전학과 ICT안전전공

김 현 수

2026년 2월

통합관제센터 운영을 위한 Vision AI - VLM 비교
및 하이브리드 연구

A Comparative Study of Vision AI Model
and VLM with Hybrid Approach for
Integrated Control Center Operations

이 논문을 석사학위논문으로 제출함

2026년 2월

중앙대학교 대학원
ICT안전학과 ICT안전전공
김 현 수

김현수의 석사학위논문으로 인정함

심사위원장 _____ 강 성 민 _____ ①인

심 사 위 원 _____ 박 인 선 _____ ①인

심 사 위 원 _____ 박 호 현 _____ ①인

중앙대학교 대학원

2026년 2월

목 차

제1장 서론	1
1.1 연구의 배경	1
1.2 문제 제기	3
1.3 연구 목적	5
1.4 연구 범위	7
1.5 연구의 구성	9
제2장 이론적 배경	12
2.1 CCTV 통합관제 환경의 특성	12
2.1.1 CCTV의 사회적·도시적 역할	12
2.1.2 관제센터 운영 구조와 인간 인지의 한계	13
2.2 CCTV 영상의 기술적 특성과 데이터 특이성	15
2.2.1 고정 시점과 배경 반복성	15
2.2.2 행동 이벤트의 희소성과 데이터 불균형	17
2.2.3 조명·노이즈·원거리 객체 문제	17
2.3 Vision AI 기술의 발전과 한계	18
2.3.1 딥러닝 기반 객체 탐지 기술의 발전 역사	18
2.3.2 YOLO의 등장과 실시간 객체 탐지의 혁신	19
2.3.3 기타 주요 객체 탐지 아키텍처	21
2.3.4 Vision AI의 구조적 한계	22
2.4 Video Language Model의 이론적 배경과 기술적 특성	23
2.4.1 멀티모달 AI와 VLM의 등장 배경	23
2.4.2 비디오 이해를 위한 딥러닝 기술의 발전	24
2.4.3 VideoMAE: 자기지도학습 기반 비디오 인코더	26
2.4.4 대규모 언어 모델(LLM)과 멀티모달 통합	27

2.4.5 Video-LLM의 주요 모델과 기술적 특성	28
2.5 VLM의 CCTV 적용 가능성과 한계	29
2.5.1 CCTV 관제 도메인에서의 VLM 장점	29
2.5.2 VLM의 한계와 제약	30
2.6 Vision AI-VLM 하이브리드 구조의 필요성	31
2.7 Scene-level Split의 필요성	32
2.8 기존 연구의 한계	34
2.9 본 연구의 차별성과 의의	35
제3장 연구방법	37
3.1 연구 절차의 개요	38
3.1.1 하이브리드 방식 채택의 당위성	38
3.1.2 연구 방법론과 실험결과·결론의 연계성	40
3.2 CCTV 데이터셋 구축 및 구성 방법	41
3.2.1 데이터셋 수집 기준 및 이벤트 유형	41
3.2.2 Scene-level Split 설계의 원리와 적용	42
3.2.3 데이터 전처리 및 증강 과정	43
3.3 Vision AI 모델 구성 및 학습 방법	45
3.3.1 YOLO 계열 모델 선택의 기술적 근거	45
3.3.2 YOLOv11 아키텍처의 구조적 특성	47
3.3.3 학습 설정 및 하이퍼파라미터	49
3.3.4 Vision AI 모델 성능 평가 지표	49
3.4 Video Language Model(VLM) 설계 및 구축	51
3.4.1 VLM 아키텍처 설계의 기본 원리	51
3.4.2 VideoMAE 기반 비디오 인코더의 구성	52
3.4.3 LLaMA 기반 언어 모델의 역할	53
3.4.4 VLM 학습 전략: 프로젝션 레이어와 파인튜닝	54
3.5 하이브리드 Trigger-Validator 구조 설계	55
3.5.1 하이브리드 구조의 설계 원리	55

3.5.2 Trigger 단계: Vision AI의 역할과 작동 방식	56
3.5.3 Validator 단계: VLM의 역할과 작동 방식	57
3.5.4 하이브리드 구조의 정당성과 기대 효과	58
3.6 평가 방법 설계	59
3.6.1 정량 평가 지표와 측정 방법	59
3.6.2 정성 평가: 추론 품질과 실무 적합성	60
3.6.3 관제센터 운영 효율성 평가	61
3.7 연구 방법의 종합 정리	61
제4장 실험결과	64
4.1 실험 환경	64
4.1.1 하드웨어 및 소프트웨어 구성	64
4.1.2 데이터셋 구성 및 전처리 절차	66
4.1.3 단계적 샘플링 기반 실험 전략	67
4.2 Vision AI 실험결과	68
4.2.1 Vision AI 모델 구성 및 태스크 정의	68
4.2.2 YOLOv11-m 모델의 정량적 성능 평가	69
4.2.3 Vision AI의 오탐 및 미탐 분석	70
4.2.4 Vision AI의 한계에 대한 실증적 논의	71
4.3 VLM(Video Language Model) 실험결과	72
4.3.1 VLM 아키텍처 구성 및 학습 전략	72
4.3.2 의미 기반 행동 분석 결과	74
4.3.3 VLM의 정량적 성능 평가	75
4.3.4 VLM의 문제점 및 한계 분석	76
4.4 Vision AI-VLM 하이브리드 실험결과	77
4.4.1 하이브리드 구조의 테스트 시나리오 설계	77
4.4.2 오탐 감소 효과 분석	78
4.4.3 미탐 보완 효과 분석	79
4.4.4 Human-in-the-Loop 관점에서의 효과 분석	80

4.5 실제 관제센터 사례 기반 분석	80
4.5.1 사례 1: 쓰러짐(Fall) 탐지	81
4.5.2 사례 2: 폭행(Violence) 탐지	82
4.5.3 사례 3: 연기(Smoke) 탐지	83
4.6 관제센터 운영 효율성 분석	84
4.7 실험결과 종합 논의	85
제5장 결론	87
5.1 연구 결과 요약	87
5.1.1 Vision AI의 한계 검증	87
5.1.2 VLM의 의미 기반 분석 능력 검증	88
5.1.3 하이브리드 Trigger-Validator 구조의 우수성 검증	89
5.2 연구의 학술적 의의	91
5.2.1 Vision AI와 VLM의 구조적 한계 비교	91
5.2.2 Scene-level Split의 필요성 실증	91
5.2.3 하이브리드 구조의 새로운 연구 방향 제시	91
5.2.4 의미 기반 Reasoning 평가 틀 제안	92
5.3 실무적·산업적 의의	92
5.3.1 관제센터 운영 효율화	93
5.3.2 스마트시티·스마트빌딩 적용 가능성	93
5.3.3 글로벌 시장 동향과의 부합	94
5.3.4 정책·제도 기반 강화 지원	94
5.4 연구의 한계	95
5.4.1 데이터 다양성 부족	95
5.4.2 VLM 추론 비용 문제	96
5.4.3 Hallucination 문제	96
5.4.4 실시간 처리 성능의 제약	96
5.5 향후 연구 방향	97
5.5.1 Multimodal Grounding 및 Scene Graph 결합 연구	97

5.5.2 Long Video 기반 Temporal Reasoning 확장	97
5.5.3 Edge AI 기반 경량형 VLM 연구	98
5.5.4 Cross-Camera Reasoning 연구	98
5.5.5 관제센터 Human-AI Collaboration 모델 연구	99
5.5.6 프라이버시 보호 및 규제 준수 연구	99
5.6 결론	100
참고문헌	102
국문초록	106
Abstract	108

표 차례

[표 1] YOLO구조	48
[표 2] 객체 탐지 성능 지표 요약 표	51
[표 3] 실험 하드웨어 환경 요약	65
[표 4] 실험 소프트웨어 환경 요약	66
[표 5] YOLO Test 결과	70
[표 6] 사건 유형 분류 정확도	74
[표 7] VLM 평가 결과 및 초기 파인튜닝 한계 요약	76
[표 8] 오탐감소효과	79
[표 9] 미탐감소효과	80

그림 차례

[그림 1] Vision AI - VLM 역할 분담 흐름	73
[그림 2] 쓰러짐 탐지 화면 1	81
[그림 3] 쓰러짐 탐지 화면 2	81
[그림 4] 대화 / 폭행 인지 학습화면	83

제1장 서론

1.1 연구의 배경

현대 도시의 안전 환경은 과거 어느 시대와 비교해도 훨씬 복잡하고 다층적인 구조를 띠고 있으며, 이러한 복잡성은 기술적·사회적·환경적 요인이 상호 결합되어 나타나는 현상이다. 도시화의 급속한 진행과 함께 인구 밀집 지역이 확대되고, 대규모 복합시설과 지하 공간이 늘어남에 따라, 전통적인 인력 기반의 안전 관리 방식으로는 더 이상 효과적인 대응이 어려운 상황에 이르렀다. 이러한 맥락에서 CCTV(Closed-Circuit Television) 기반의 영상 감시 시스템은 도시 인프라의 핵심 구성요소로서 그 중요성이 날로 증대되고 있으며, 범죄 예방, 재난 대응, 교통 관리, 시설물 보호 등 다양한 분야에 없어서는 안 될 기반 기술로 자리매김하였다.

CCTV 시스템의 역사적 발전 과정을 살펴보면, 초기에는 단순히 특정 구역을 녹화하여 사후 증거로 활용하는 수동적 감시 방식에서 시작하였다. 그러나 1990년대 이후 디지털 기술의 발전과 함께 실시간 모니터링이 가능해졌고, 2000년대에는 IP 기반 네트워크 카메라의 보급으로 대규모 통합관제센터의 구축이 보편화하였다. 오늘날 대한민국의 경우, 전국 지방자치단체에 약 245개의 CCTV 통합관제센터가 운영되고 있으며, 운영 중인 공공 CCTV 대수는 180만 대를 상회하는 것으로 추정된다. (경찰청, 2021; NIA, 2020) 이러한 대규모 영상 감시 인프라는 범죄 발생률 감소, 신속한 재난 대응, 시민 안전감 향상 등 다양한 측면에서 긍정적인 효과를 거두고 있는 것으로 평가받고 있다.

그러나 CCTV 인프라의 양적 확대에도 불구하고, 관제 시스템의 운영 방식은 여전히 인간 관제요원의 시각적 판단과 주의 집중력에 크게 의존하고 있는 것이 현실이다. 일반적으로 관제센터에서는 한 명의 관제요원이 최소 100대 이

상의 CCTV 화면을 동시에 모니터링해야 하며, 일부 지방자치단체의 경우에는 300대 이상의 화면을 한 명이 담당하도록 요구하는 사례도 빈번히 발생하고 있다. (서울특별시 데이터센터, 2022; 부산광역시 스마트시티센터, 2023) 이러한 과도한 업무 부담은 관제요원 개인의 인지적 한계를 훨씬 초과하는 것으로서, 지속적인 피로 누적과 주의력 저하를 일으키며, 결과적으로 관제 효율성의 심각한 저하를 초래하고 있다.¹⁾

인지심리학 분야의 연구에서는 인간의 주의 집중 자원이 본질에서 제한되어 있다는 점을 일관되게 보고해 왔다. Wickens의 다중자원이론(Multiple Resource Theory)에 따르면, 인간의 정보처리 능력은 유한하며, 동시에 여러 자극을 처리해야 하는 상황에서는 필연적으로 성능 저하가 발생한다. 특히 장 시간에 걸친 반복적인 시각 감시 업무는 경계 피로(vigilance fatigue)라는 현상을 유발하는데, 이는 시간이 지남에 따라 목표 자극에 대한 탐지율이 점진적으로 감소하고, 반응 시간이 증가하며, 오 탐지율이 높아지는 특성을 보인다. Parasuraman의 연구에 의하면, 단순 감시 업무에서도 30분 이상 지속될 경우 탐지 성능이 유의미하게 저하되며, 복잡한 다중 화면 모니터링의 경우에는 이러한 저하가 더욱 빠르고 심각하게 나타난다.

CCTV 관제 업무의 특성상, 주요 사건은 매우 짧은 순간에 발생하며, 종종 미세한 동작이나 작은 변화가 위협 상황의 전조가 되는 경우가 많다. 예를 들어, 절도범이 매장에서 물건을 훔치는 행위는 불과 2-3초 내에 완료될 수 있으며, 폭행 사건의 경우에도 최초 공격이 시작되어 피해가 발생하기까지의 시간은 극히 짧다. 화재의 경우에도 초기 연기 발생 단계에서의 조기 탐지가 대형 피해를 방지하는 핵심 요소가 되는데, 이 시기의 연기는 매우 희미하고 배경과 구분하기 어려운 특성을 갖는다. 이러한 상황에서 수백 개의 모니터 화면을 동

1) 인간은 약 4-7개의 정보 단위를 동시에 처리할 수 있는 제한된 작업기억(working memory)을 가진다(Endsley, 1995).

시에 주시해야 하는 관제요원이 결정적인 순간을 정확히 포착하기란 사실상 불가능에 가깝다. (Stedmon & Stone, 2011)

이러한 구조적 문제는 실질적인 운영상의 어려움으로 직결된다. 첫째, 중요 사고의 조기 발견 실패로 인해 초동 대응이 지연되며, 이는 피해 규모의 확대로 이어진다. 둘째, 위급 상황 발생 시 신속한 대응이 이루어지지 못하여 골든 타임을 놓치는 사례가 빈번히 발생한다. 셋째, 관제요원의 과도한 경계 심리로 인해 정상적인 상황을 위험 상황으로 오판하는 오탐(false positive)이 증가하며, 이는 불필요한 출동과 자원 낭비를 초래한다. 넷째, 반복되는 오탐으로 인해 관제요원과 현장 대응 인력 모두에게 경계 피로가 누적되고, 이는 다시 진짜 위험 상황에서의 대응력 약화라는 악순환을 야기한다. 결과적으로 이러한 문제들은 도시 안전 시스템 전체의 신뢰도와 효과성을 약화시키는 근본적인 요인으로 작용하고 있다.

국제적으로도 이러한 문제에 대한 인식이 확산되고 있으며, ISO 11064 관제센터 인간공학 표준에서는 적절한 업무량 분배와 인간-기계 협력의 중요성을 강조하고 있다. 유럽연합의 스마트시티 이니셔티브에서는 AI 기반 자동 감지 시스템의 도입을 권고하고 있으며(European Commission, 2022), OECD의 도시 안전 정책 보고서에서도 기술 혁신을 통한 관제 시스템의 고도화 필요성을 역설하고 있다. 이러한 국제적 동향은 단순히 CCTV 대수를 늘리는 양적 확대 전략을 넘어서, 지능형 영상 분석 기술의 도입을 통한 질적 고도화가 시급한 과제임을 시사하고 있다.

1.2 문제 제기

CCTV 통합관제센터가 직면한 핵심 문제는 크게 네 가지로 구분된다.

첫째, 인간 인지 기반 감시는 본질적 한계를 지닌다. 관제요원은 다수 화면을

장시간 모니터링하는 데 생물학적 한계가 있으며, 실제 연구에서도 화면 수 증가와 근무 시간 경과에 따라 탐지율이 급격히 저하되는 현상이 반복적으로 보고되었다(Parasuraman, 1982; Stedmon & Stone, 2011). 이는 교육이나 숙련도만으로 해결하기 어려운 구조적 문제로, 기술적 보조 수단의 도입이 필수적이다.

장시간 근무에 따른 주의력 저하, 경계심 감소, 판단 오류 등의 문제가 누적되면, 이는 실제 사고 대응에서 치명적인 결과를 초래할 수 있다. 실제로 국내 관제센터 운영 실태를 분석한 연구에 따르면, 야간 근무조의 경우 근무 시작 후 4시간이 경과하면 사건 탐지율이 주간 대비 35% 이상 저하되는 것으로 나타났다(서울특별시 데이터센터, 2022). 이러한 현상은 관제요원 개인의 역량 문제가 아닌, 인간 인지 시스템의 본질적 한계에서 비롯되는 것이므로, 교육이나 동기 부여만으로는 근본적인 해결이 불가능하다. 따라서 인간의 인지적 한계를 보완할 수 있는 기술적 보조 수단의 도입이 필수적이다.

둘째, Vision AI 모델 단독 기술의 한계에 대해 분석하면, Vision AI 모델 단독 기술은 단일 프레임 기반 구조로 인해 행동 의미와 시간적 맥락을 이해하지 못한다. 포옹과 폭행, 숙임과 낙상, 수증기와 연기 등은 프레임 단위로는 구분이 어려우며, 환경 변화(조도·역광·기상)에 따라 성능이 크게 흔들린다(Lin, Goyal, et al 2017; Liu, et al 2016). 즉 “무엇이 보이는가”는 잘 판단하지만 “무슨 상황인가”는 해석하지 못한다.

셋째, VLM(Video Language Model) 단독 기술의 한계를 살펴보면, VLM(Video Language Model)은 시공간적 이해 능력을 갖추고 있지만, 연산 비용이 지나치게 많이 들고 실시간 적용이 어렵다. 또한 환각(hallucination)이 발생할 가능성이 있어 안전 분야에 단독 적용하기에는 위험성이 크다. 수백 대 카메라가 동시에 운영되는 실제 관제 환경에서는 경제적·기술적 제약으로 단독 사용이 사실상 불가능하다.

넷째, CCTV 데이터가 갖는 고유한 구조적 특성, CCTV 데이터는 장소가 고정된다는 특성 때문에 배경(scene)을 모델이 암기할 위험이 있다. 무작위 분할(Random Split)을 사용할 경우 동일 장소가 훈련·테스트에 중복되어 과대평가가 발생하며, 실제 새로운 장소에서는 성능이 급격히 떨어질 수 있다. 따라서 본 연구에서는 장소를 분리하는 Scene-level Split을 적용해 일반화 성능을 정확히 평가할 필요가 있다.

1.3 연구 목적

본 연구는 앞서 제기한 문제들을 해결하기 위해 다음 네 가지 핵심 목표를 설정하고 이를 체계적으로 달성하고자 한다. 이 목표들은 상호 연결되어 있으며, 각각의 달성이 최종적인 연구 성과로 통합되는 구조를 갖는다.

첫 번째 연구 목표는 Vision AI와 VLM의 기술적 구조와 CCTV 도메인에 대한 적합성을 비교·분석하는 것이다. 두 기술은 각각 다른 설계 철학과 작동 원리를 기반으로 하며, 장점과 단점이 명확히 구분된다. Vision AI는 YOLO로 대표되는 단일 프레임 기반 실시간 객체 탐지 기술로서, 연산 속도가 빠르고 하드웨어 요구사항이 상대적으로 낮다는 장점이 있으나, 시간적 맥락 이해와 의미론적 분석 능력이 부족하다. 반면 VLM은 비디오 시퀀스의 시공간적 패턴을 학습하고 자연어로 상황을 설명할 수 있는 고도의 이해 능력을 갖추고 있으나, 연산 비용이 높고 환각 문제가 발생할 수 있다(OpenAI, 2023). 본 연구에서는 이러한 기술적 특성을 CCTV 관제 도메인의 구체적인 요구사항—실시간성, 정확성, 확장성, 신뢰성 등—과 매칭하여 각 기술의 적합 영역과 한계 영역을 명확히 규명하고자 한다.

두 번째 연구 목표는 두 기술의 장점을 결합한 하이브리드 관제 구조, 이른바 'Trigger-Validator' 구조를 제안하는 것이다. 이 구조의 핵심 아이디어는

역할 분담에 있다. Vision AI는 빠른 속도를 활용하여 전체 CCTV 스트림을 실시간으로 스캔하고, 의심스러운 상황이 발생했을 때 이를 후보 이벤트로 탐지하는 'Trigger' 역할을 수행한다. VLM은 Vision AI가 탐지한 후보 이벤트에 대해서만 선별적으로 작동하여, 해당 상황이 실제 위험 상황인지 아닌지를 깊이 있게 분석하고 검증하는 'Validator' 역할을 담당한다. 이러한 구조는 Vision AI의 오탐을 VLM이 걸러낼 수 있게 하고, 동시에 VLM의 과도한 연산 부담을 Vision AI의 사전 필터링을 통해 방지할 수 있어, 두 기술의 상호 보완적 협력을 실현한다.

세 번째 연구 목표는 CCTV 도메인에 최적화된 Scene-level Split 데이터셋을 구축하는 것이다. 앞서 언급한 바와 같이, 기존의 Random Split 방식은 CCTV 데이터의 장면 고착성 문제로 인해 모델의 실제 일반화 능력을 과대평가할 위험이 있다(Heilbron, Escorcia, Ghanem, & Niebles, 2015). 본 연구에서는 촬영 장소를 기준으로 데이터를 엄격하게 분리하여, 훈련 시 사용된 장소가 테스트 시에는 전혀 등장하지 않도록 데이터셋을 설계한다. 이를 위해 폭행, 쓰러짐, 침입, 연기, 분실물 등 주요 이벤트 유형별로 다양한 장소에서 수집된 데이터를 활용하며, 장소별 분포의 균형을 고려하여 편향을 최소화한다. 이렇게 구축된 데이터셋은 모델이 특정 장소가 아닌 행동 패턴 자체를 학습하도록 유도하며, 새로운 환경에서의 배치 시 예상되는 성능을 보다 정확하게 예측할 수 있게 한다.

네 번째 연구 목표는 단독 모델과 하이브리드 모델의 성능을 정량적·정성적으로 비교 평가하는 것이다. 정량적 평가에서는 정밀도(Precision), 재현율(Recall), F1 점수, 탐지 지연 시간, 오탐률, 미탐률 등 다양한 지표를 활용하여 각 모델 구성의 객관적인 성능을 측정한다(Shorten & Khoshgoftaar, 2019). 정성적 평가에서는 실제 관제센터 운영 환경을 모사한 시나리오에서 관제요원의 업무 효율성, 판단 정확성, 피로도 등을 평가하며, 현장 전문가 인터뷰를 통

해 실무적 관점에서의 피드백을 수집한다. 이러한 다각적 평가를 통해 제안하는 하이브리드 구조가 단독 모델 대비 어떤 측면에서 우위를 갖는지, 그리고 어떤 조건에서 가장 효과적으로 작동하는지를 규명하고자 한다.

이상의 네 가지 목표를 달성함으로써, 본 연구는 단일 모델 접근 방식의 한계를 넘어서고, 실제 관제 환경에서 실질적으로 효과적인 AI 기반 감시 체계를 마련하는 데 학술적·실무적으로 기여하고자 한다. 이는 궁극적으로 도시 안전 향상과 시민 삶의 질 개선에 이바지하는 것을 목표로 한다.

1.4 연구 범위

본 연구의 범위는 CCTV 기반 도시 안전 시스템의 기술적 고도화에 초점을 맞추어 설정되었으며, 다음과 같은 영역들을 포함한다. 연구 범위의 명확한 설정은 연구의 집중도를 높이고, 결과의 해석 가능성을 확보하는 데 중요한 역할을 한다.

기술적 범위의 측면에서, 본 연구는 CCTV 기반 사건 탐지 및 상황 인식 시스템을 핵심 연구 대상으로 삼는다. 구체적으로, Vision AI 모델영역에서는 YOLO 계열의 객체 및 동작 탐지 기술을 중심으로 분석하며, 특히 최신 버전인 YOLOv11의 성능과 특성을 심층적으로 다룬다(Redmon, Divvala, Girshick, & Farhadi, 2016; Ultralytics, 2024). VLM 영역에서는 VideoMAE 기반의 비디오 인코더와 LLaMA 기반의 대규모 언어 모델을 결합한 아키텍처를 구축하고, 이를 통한 시공간 의미 분석 능력을 평가한다. 또한 두 기술을 결합한 하이브리드 구조의 실험적 검증과 실무 적용성 평가를 수행한다.

이벤트 유형의 측면에서, 본 연구는 CCTV 관제에서 가장 빈번하게 다루어지고 사회적 중요성이 높은 주요 이벤트들을 중심으로 분석한다. 여기에는 폭행(assault), 쓰러짐(fall), 침입(intrusion), 연기 및 화재(smoke/fire), 분실물

(abandoned object) 등이 포함된다. 폭행과 쓰러짐은 인적 피해와 직결되는 사건으로서 신속한 대응이 요구되며, 침입은 재산 피해 및 범죄 예방과 관련된다. 연기 탐지는 화재의 조기 발견을 통해 대규모 재난을 방지하는 핵심 기능이고, 분실물 탐지는 테러 예방 및 시민 안전과 연관된다. 이러한 이벤트 유형들은 각각 다른 시각적 특성과 시간적 패턴을 가지므로, 모델의 다양한 능력을 종합적으로 평가하는 데 적합하다(AI-Hub, 2023).

적용 대상의 측면에서, 본 연구는 공공기관 및 지방자치단체의 CCTV 통합 관제센터를 실제 적용 대상으로 설정한다. 이러한 관제센터는 대규모 CCTV 네트워크를 운영하면서 다양한 유형의 사건에 대응해야 하므로, 본 연구에서 제안하는 하이브리드 시스템의 가치가 극대화될 수 있는 환경이다. 또한 공공 영역에서의 적용은 연구 결과의 사회적 파급력을 높이고, 정책적 시사점 도출을 가능하게 한다.

아울러 본 연구는 실제 관제센터의 근무 방식, 보고서 작성 절차, 오탐 및 미탐 발생 유형 등 현장 기반 요소를 함께 고려하고 있다. 이는 연구 결과가 학술적 의미에 그치지 않고 실무 현장에서 실제로 활용될 수 있도록 하기 위함이다. 관제요원과의 인터뷰, 실제 근무 환경 관찰, 기존 시스템의 운영 데이터 분석 등을 통해 현장의 요구사항과 제약조건을 파악하고, 이를 시스템 설계에 반영하였다.

한편, 본 연구의 범위에서 제외되는 영역도 명확히 할 필요가 있다. 첫째, 본 연구는 CCTV 하드웨어 자체의 개선이나 네트워크 인프라의 최적화는 다루지 않으며, 기존 인프라 위에서 작동하는 소프트웨어 솔루션에 집중한다. 둘째, 얼굴 인식이나 개인 식별과 같은 프라이버시 민감 기능은 본 연구의 범위에 포함되지 않으며, 행동 및 상황 기반의 이벤트 탐지에 초점을 맞춘다. 셋째, 교통 관제, 환경 모니터링 등 안전 관제 이외의 CCTV 활용 분야는 향후 연구 과제로 남겨둔다.

1.5 연구의 구성

본 연구는 체계적인 연구 절차를 통해 연구 목표를 달성하고자 하며, 이론적 분석, 시스템 설계, 실험적 검증, 실무 적용성 평가의 단계를 순차적으로 수행한다. 각 단계는 이전 단계의 결과를 기반으로 하여 연구의 일관성과 논리적 타당성을 확보한다.

제1단계는 CCTV 도메인 분석 및 문제 정의 단계이다. 이 단계에서는 국내외 CCTV 통합관제센터의 운영 현황, 직면한 문제점, 기술적 요구사항 등을 종합적으로 분석한다. 관련 정책 문서, 기술 보고서, 학술 연구, 현장 인터뷰 자료 등을 활용하여 문제의 본질을 심층적으로 파악하고, 이를 바탕으로 연구 문제를 명확히 정의한다. 이 단계의 산출물은 연구 전체의 방향을 설정하는 토대가 된다.

제2단계는 Vision AI 모델 및 VLM 관련 학술 연구 조사 단계이다. 이 단계에서는 YOLO 계열의 객체 탐지 기술, Transformer 기반 비전 모델, VideoMAE를 비롯한 비디오 이해 모델, 대규모 언어 모델과의 멀티모달 통합 등 관련 기술 동향을 체계적으로 조사한다. 특히 각 기술의 장단점, 적용 사례, 한계점 등을 분석하여 본 연구의 기술적 기반을 마련한다. 또한 기존 하이브리드 접근 방식에 관한 선행 연구를 검토하여 본 연구의 차별점과 기여를 명확히 한다.

제3단계는 Scene-level Split 기반 데이터셋 구축 단계이다. 이 단계에서는 폭행, 쓰러짐, 침입, 연기, 분실물 등 주요 이벤트 유형에 대한 데이터를 다양한 장소에서 수집하고, 촬영 장소를 기준으로 훈련 세트와 테스트 세트를 엄격히 분리한다. 데이터 전처리, 어노테이션, 품질 검증 등의 과정을 거쳐 고품질 데이터셋을 구축하며, 장소별·이벤트 유형별 분포의 균형을 고려하여 편향을

최소화한다. 구축된 데이터셋은 본 연구뿐만 아니라 후속 연구에서도 활용될 수 있는 자원으로서의 가치를 갖는다.

제4단계는 YOLOv11 기반 Vision AI 모델 학습 및 평가 단계이다. 이 단계에서는 구축된 데이터셋을 활용하여 YOLOv11 모델을 각 이벤트 유형에 맞게 학습시키고, Scene-level Split 테스트 세트에서의 성능을 평가한다. 정밀도, 재현율, mAP(mean Average Precision), 탐지 속도 등 다양한 지표를 측정하며, 오탐 및 미탐 사례를 분석하여 모델의 특성과 한계를 파악한다. 이 단계의 결과는 하이브리드 구조에서 Trigger 역할의 성능 기준선을 제공한다.

제5단계는 VideoMAE-LLaMA VLM 구축 및 의미 추론 평가 단계이다. 이 단계에서는 VideoMAE를 비디오 인코더로, LLaMA를 언어 모델로 활용하여 VLM 아키텍처를 구축하고, 이를 CCTV 도메인에 맞게 파인튜닝한다. 구축된 VLM의 상황 이해 능력, 행동 분류 정확도, 자연어 설명의 품질 등을 평가하며, 환각 발생 빈도와 패턴을 분석한다. 이 단계의 결과는 하이브리드 구조에서 Validator 역할의 성능 기준선을 제공한다.

제6단계는 Trigger-Validator 하이브리드 구조 설계 단계이다. 이 단계에서는 앞서 개발된 Vision AI 모델과 VLM을 통합하는 하이브리드 아키텍처를 설계한다. Vision AI가 후보 이벤트를 탐지하면 해당 비디오 클립을 VLM에 전달하고, VLM이 상황을 분석하여 최종 판단을 내리는 파이프라인을 구현한다. 두 모델 간의 통신 프로토콜, 임계값 설정, 처리 지연 최소화 방안 등 시스템 설계의 세부 사항을 결정한다.

제7단계는 오탐·미탐·운영 효율성 비교 실험 수행 단계이다. 이 단계에서는 Vision AI 모델 단독, VLM 단독(샘플링 기반), 그리고 하이브리드 구조의 성능을 동일한 조건에서 비교 평가한다. 오탐률 감소 효과, 미탐률 변화, 처리 지연 시간, 연산 자원 사용량, 관제요원 업무 효율성 등 다각적인 지표를 측정하고,

통계적 분석을 통해 결과의 유의성을 검증한다. 또한 실제 관제센터 환경을 모사한 시뮬레이션 평가와 현장 전문가 평가를 병행하여 실무적 관점에서의 효과성을 확인한다.²⁾

2) 본 논문에서는 YOLO 계열 객체 탐지 모델을 통칭하여 Vision AI 모델이라 정의한다.

제2장 이론적 배경

본 장에서는 CCTV 통합관제센터의 운영 환경과 인간 인지의 한계, Vision AI 모델기술의 발전 과정과 근본적 문제점, Video Language Model(VLM)의 이론적 기반과 기술적 특성, 그리고 두 기술을 결합한 하이브리드 접근의 필요성을 학술적 근거를 바탕으로 종합적으로 고찰한다. 특히 Vision AI의 핵심 기술인 YOLO 계열 모델의 발전 역사와 아키텍처 특성, VLM의 구성 요소인 비디오 인코더와 대규모 언어 모델의 기술적 세부사항을 심층적으로 분석한다. 또한 CCTV 도메인 특유의 장면(scene) 고착성 문제를 지적하며, Scene-level Split 방식의 필요성을 제시한다. 이는 이후 연구방법 설계를 위한 이론적·기술적 기반이 된다.

2.1 CCTV 통합관제 환경의 특성

2.1.1 CCTV의 사회적·도시적 역할

현대 도시에서 CCTV(Closed-Circuit Television)는 단순한 감시 장비의 역할을 넘어서 공공안전을 담보하는 핵심 인프라로서의 위상을 확립하였다. CCTV 시스템의 역사는 1940년대 독일에서 V-2 로켓 발사를 모니터링하기 위해 처음 사용된 이래, 1960년대 영국에서 공공장소 감시 목적으로 도입되면서 본격적인 발전을 시작하였다(Norris & Armstrong, 1999). 이후 디지털 기술의 발전과 함께 아날로그 방식에서 IP 기반 네트워크 카메라로 전환되었으며, 현재는 인공지능 기술과 결합된 지능형 영상분석 시스템으로 진화하고 있다.

전 세계적으로 CCTV의 설치 규모는 지속적으로 확대되고 있으며, 그 활용 범위 역시 다양화되고 있다. 범죄 예방의 측면에서 CCTV는 잠재적 범죄자에

대한 억제 효과를 발휘하며, 범죄 발생 시 증거 확보와 용의자 추적에 핵심적인 역할을 수행한다(Welsh & Farrington, 2009). 교통 관리 분야에서는 실시간 교통 흐름 모니터링, 교통 법규 위반 단속, 사고 감지 및 대응 등에 활용되고 있다. 재난 대응 측면에서는 화재, 홍수, 지진 등 재난 상황의 조기 감지와 피해 규모 파악, 구조 활동 지원 등에 기여한다. 시설 안전 관리 분야에서는 건물, 교량, 터널 등 주요 시설물의 상태 모니터링과 이상 징후 탐지에 활용되고 있다.

국내의 경우, 스마트시티 정책의 핵심 구성 요소로서 CCTV 시스템의 고도화가 강조되고 있다. 국토교통부의 스마트시티 국가전략 프로젝트에서는 CCTV를 도시 데이터의 핵심 수집 수단으로 규정하고, 인공지능 기반 영상분석 기술의 적용을 통한 도시 안전 시스템의 고도화를 추진하고 있다. 2023년 기준 국내에 설치된 공공 CCTV의 수는 약 180만 대를 상회하며, 전국 245개 지방자치단체에서 통합관제센터를 운영하고 있다. 이러한 대규모 CCTV 인프라는 범죄 발생률 감소, 신속한 재난 대응, 시민 안전감 향상 등 다양한 측면에서 긍정적인 효과를 거두고 있는 것으로 평가되고 있다.

도시의 복잡성이 증가할수록 CCTV의 역할은 더욱 확대되고 있으며, 특정 지역에서 발생하는 사건을 조기에 발견하여 대응 시간을 단축하는 데 중요한 기여를 해왔다. 특히 폭행, 절도, 실종, 화재 등 위급 상황 발생 시 CCTV 영상은 상황 파악과 사후 분석의 핵심 자료가 되며, 행정기관, 경찰, 소방 조직 간 협력의 기반이 된다. 또한 CCTV 영상은 법적 증거로서의 가치를 인정받아, 범죄 수사 및 재판 과정에서 중요한 역할을 수행하고 있다. 이러한 다양한 활용 가치로 인해 CCTV는 현대 도시 관리에서 필수불가결한 요소로 자리매김하였다.

2.1.2 관제센터 운영 구조와 인간 인지의 한계

CCTV 통합관제센터는 지방자치단체나 기관이 운영하는 다수의 CCTV 카메라로부터 전송되는 영상을 중앙에서 통합적으로 관리하고 모니터링하는 시설이다. 일반적인 관제센터의 운영 구조를 살펴보면, 다수의 모니터가 배치된 관제실에서 관제요원들이 24시간 교대 근무 체제로 영상을 감시한다. 관제요원 1인은 평균적으로 100대에서 300대에 이르는 CCTV 화면을 동시에 모니터링해야 하는 상황에 처해 있다. 일부 지방자치단체의 경우에는 예산 및 인력 제약으로 인해 한 명의 관제요원이 400대 이상의 카메라를 담당하는 사례도 보고되고 있다.

이러한 운영 환경은 인간의 주의집중 능력과 정보처리 용량의 본질적 한계와 직접적으로 충돌한다. 인지심리학 분야에서는 지속적 감시 과제(Vigilance Task)가 인간의 인지 자원에 가장 큰 부담을 주는 작업 유형 중 하나로 분류되어 왔다. Parasuraman의 연구에 따르면, 지속적 감시 과제에서 인간의 탐지 성능은 시간이 경과함에 따라 점진적으로 저하되며, 이를 '경계 감소(vigilance decrement)'라고 명명하였다. 이 현상은 과제 시작 후 15-20분 이내에 발생하기 시작하며, 30분 이상 지속될 경우 탐지 정확도가 유의미하게 저하된다.

Wickens가 제안한 다중자원 이론(Multiple Resource Theory)은 인간의 정보처리 시스템이 제한된 용량의 자원 풀(resource pool)을 기반으로 작동한다고 설명한다. 이 이론에 따르면, 시각적 정보처리에 할당된 자원은 유한하며, 과도한 시각 정보 입력은 처리 능력의 포화를 초래하여 정보 손실과 오류를 야기한다. CCTV 관제 상황에서 수백 개의 화면을 동시에 모니터링하는 것은 인간의 시각적 정보처리 용량을 현저히 초과하는 요구이며, 이로 인해 중요한 사건을 놓치거나 잘못 판단하는 오류가 필연적으로 발생한다.

Endsley의 상황인식(Situation Awareness) 이론은 관제 업무에서의 인지 과정을 세 단계로 구분하여 설명한다. 첫째는 환경 내 요소들의 지각(perception), 둘째는 현재 상황의 이해(comprehension), 셋째는 미래 상태

의 예측(projection)이다. 다중 화면 CCTV 관제 환경에서 관제요원은 첫 번째 단계인 지각 단계에서부터 인지적 과부하를 경험하게 되며, 이로 인해 상황의 정확한 이해와 적절한 대응 예측이 어려워진다.

관제요원들은 실시간으로 발생할 수 있는 사건을 탐지하기 위해 끊임없이 화면 간을 전환하며 시선을 이동해야 하는데, 이러한 작업 방식은 20-30분만 지속되어도 반응 속도가 급격히 저하되는 경향을 보인다. 실제로 국내 여러 지방자치단체의 관제센터 운영 평가에서도, 쓰러짐, 폭행, 연기 발생 등 중요한 위험 장면을 놓친 사례가 반복적으로 보고되고 있다. 서울시 데이터센터의 분석에 따르면, 야간 근무 시간대에 발생한 낙상 사고의 경우 관제요원이 영상을 통해 사고를 인지한 시점과 실제 사고 발생 시점 사이에 평균 15분 이상의 지연이 발생한 것으로 나타났다.

장시간 근무에 따른 신체적·정신적 피로의 누적 역시 관제 성능 저하의 주요 원인이다. 관제요원들은 8-12시간의 교대 근무를 수행하는데, 근무 후반부로 갈수록 집중력이 현저히 떨어지고 판단 오류가 증가한다. 또한 반복적인 단조로운 영상 모니터링은 정신적 권태감을 유발하며, 이는 중요 사건에 대한 민감도 저하로 이어진다. 이처럼 인간 인지 기반의 관제 구조는 본질적인 한계를 지니고 있으며, 이를 보완하기 위한 자동화 또는 지능형 보조 기술의 도입이 필수적임을 시사한다.

2.2 CCTV 영상의 기술적 특성과 데이터 특이성

2.2.1 고정 시점과 배경 반복성

CCTV 영상은 영화, 드라마, SNS 동영상 등 일반적인 비디오 콘텐츠와 근본적으로 다른 특성을 갖는다. 가장 두드러진 차이점은 카메라가 고정된 위치에서 특정 장소를 지속적으로 촬영한다는 점이다. 이로 인해 CCTV 영상에서는

배경 패턴이 시간이 지나도 거의 변하지 않으며, 조명 조건과 환경적 요소 역시 일정하게 유지되는 경향을 보인다. 이러한 특성은 CCTV 영상분석에 있어 장점이자 동시에 심각한 문제점이 될 수 있다.

장점의 측면에서, 고정된 배경은 전경(foreground)과 배경(background)의 분리를 용이하게 하며, 움직이는 객체의 탐지를 상대적으로 단순화한다. 배경 차분(background subtraction) 기법이나 프레임 간 차이(frame differencing) 기법 등 전통적인 영상처리 방법이 CCTV 영상에서 비교적 효과적으로 작동하는 것은 이러한 특성에 기인한다(Stauffer & Grimson, 1999). 그러나 이러한 특성은 기계학습 모델의 훈련에 있어 심각한 편향 문제를 야기할 수 있다.

구체적으로, 특정 장소에서 촬영된 CCTV 영상이 학습 데이터에 포함될 경우, 모델은 실제로 탐지해야 하는 행동이나 이벤트의 특징이 아니라, 해당 장소의 배경 특성—벽면 색상, 바닥 패턴, 조명 구조, 가구 배치 등—을 학습하는 편향을 갖게 될 위험이 있다. 이러한 현상을 장면 과적합(scene overfitting) 또는 배경 편향(background bias)이라고 하며, 이는 모델이 학습 시 보지 못한 새로운 장소의 영상에서 성능이 급격히 저하되는 문제를 초래한다.

예를 들어, 특정 지하철역 플랫폼에서 촬영된 폭행 장면이 훈련 데이터에 포함되어 있을 때, 모델은 폭행 행동의 시각적 특징—예컨대 급격한 팔 움직임, 두 사람 간의 물리적 접촉 패턴 등—을 학습하는 대신, 해당 지하철역의 배경 요소—플랫폼 바닥 타일의 색상, 벽면 광고판, 기둥의 위치 등—을 단서로 활용하여 예측할 수 있다. 이렇게 학습된 모델은 해당 지하철역에서는 높은 정확도를 보이지만, 다른 지하철역이나 버스터미널 등 학습 시 보지 못한 새로운 환경에서는 성능이 크게 저하된다. 이 문제는 CCTV 기반 인공지능 시스템의 실제 현장 배치 시 가장 빈번하게 보고되는 성능 저하 원인 중 하나이다.

2.2.2 행동 이벤트의 희소성과 데이터 불균형

CCTV 영상 데이터의 또 다른 중요한 특성은 관심 이벤트의 극심한 희소성이다. 대부분의 CCTV 영상에서는 특별한 사건이 발생하지 않으며, 쓰러짐, 폭행, 침입, 화재, 절도 등 관제요원이 탐지해야 하는 이벤트는 전체 영상의 극히 일부분—일반적으로 0.1%에서 1% 수준—만을 차지한다. 이러한 극심한 데이터 불균형은 기계학습 모델의 훈련에 있어 심각한 도전 과제가 된다.

클래스 불균형(class imbalance) 문제는 기계학습 분야에서 오랜 기간 연구되어 온 주제이다. 양성 샘플(이벤트 발생)과 음성 샘플(정상 상황)의 비율이 극단적으로 불균형한 경우, 모델은 다수 클래스(정상)에 편향되어 학습되는 경향을 보인다. 이 경우, 모델이 모든 입력을 '정상'으로 예측하더라도 전체 정확도는 99% 이상으로 매우 높게 나타나지만, 실제로 탐지해야 하는 이벤트는 전혀 찾아내지 못하는 결과가 발생한다. 이는 CCTV 관제의 목적에 완전히 배치되는 것이다.

이러한 데이터 불균형 문제를 해결하기 위한 다양한 기법들이 연구되어 왔다. 오버샘플링(oversampling) 기법은 소수 클래스의 샘플을 복제하거나 합성하여 데이터 균형을 맞추는 방법이며, 언더샘플링(undersampling) 기법은 다수 클래스의 샘플 수를 줄이는 방법이다. Focal Loss는 모델이 쉽게 분류할 수 있는 샘플의 손실 기여도를 줄이고, 어려운 샘플에 더 집중하도록 하는 손실 함수 기반 접근법이다. 그러나 이러한 기법들에도 불구하고, CCTV 영상에서의 극심한 이벤트 희소성은 여전히 모델 성능에 부정적인 영향을 미치며, 특히 오탐(false positive)과 미탐(false negative)의 발생에 직접적인 관련이 있다.

2.2.3 조명·노이즈·원거리 객체 문제

CCTV 영상의 품질은 다양한 환경적 요인에 의해 크게 영향을 받으며, 이는

영상분석 시스템의 성능에 직접적인 제약을 가한다. 야간 영상의 경우, 조명 부족으로 인해 영상 전반에 노이즈가 증가하고 대비(contrast)가 저하된다. 이러한 조건에서는 객체의 경계가 불명확해지고, 특히 작은 크기의 객체나 세부적인 동작의 탐지가 매우 어려워진다. 적외선(IR) 카메라를 사용하더라도 색상 정보의 손실과 독특한 반사 특성으로 인해 주간 영상과는 다른 처리 방식이 필요하다.

해상도 문제 역시 중요한 제약 요인이다. 비용 및 저장 용량의 제약으로 인해 많은 CCTV 시스템은 HD(1920×1080) 이하의 해상도로 운영되며, 일부 구형 시스템은 VGA(640×480) 수준의 해상도를 사용하기도 한다. 낮은 해상도에서는 원거리에 위치한 객체나 작은 크기의 물체를 식별하기 어려우며, 동작의 세부적인 차이를 구분하는 것이 사실상 불가능해진다. 예를 들어, 상점에서의 절도 행위를 탐지하기 위해서는 손 움직임과 물건의 위치 변화를 파악해야 하는데, 저해상도 영상에서는 이러한 세부 정보가 손실된다.

환경적 요소에 의한 오탐 유발 역시 심각한 문제이다. 연기 탐지 시스템의 경우, 실제 화재로 인한 연기와 수증기, 먼지, 안개 등을 구분해야 하는데, 단일 프레임 분석만으로는 이러한 구분이 매우 어렵다. 반사광이나 렌즈 플레어, 카메라 흔들림 등도 오탐을 유발하는 요인이 된다. 야외 CCTV의 경우 바람에 의한 나뭇잎의 흔들림, 동물의 움직임, 비나 눈 등 기상 현상이 객체 탐지 알고리즘에 혼란을 야기할 수 있다. 이러한 환경적 특성들은 모델이 모든 장면(scene)에 일반화(Generalization to All Scenes)되기 어렵게 만드는 중요한 장애물이 된다.

2.3 Vision AI 모델 기술의 발전과 한계

2.3.1 딥러닝 기반 객체 탐지 기술의 발전 역사

딥러닝 기반 객체 탐지 기술의 발전은 2012년 ImageNet 대회에서 AlexNet 이 압도적인 성능을 보인 이후 본격적으로 시작되었다(Krizhevsky, Sutskever, & Hinton, 2012). 초기의 딥러닝 기반 객체 탐지는 2단계(two-stage) 방식이 주류를 이루었다. 2014년 Girshick 등이 제안한 R-CNN(Regions with CNN features)은 선택적 탐색(Selective Search) 알고리즘을 통해 객체가 있을 것으로 예상되는 영역(region proposal)을 먼저 추출한 후, 각 영역에 대해 CNN을 적용하여 분류를 수행하는 방식이었다. 이 방식은 당시 최고 수준의 정확도를 달성했으나, 하나의 이미지에 대해 수천 개의 영역 제안을 독립적으로 처리해야 했기 때문에 연산 비용이 매우 높고 실시간 처리가 불가능하다는 한계가 있었다.

이러한 속도 문제를 해결하기 위해 Fast R-CNN과 Faster R-CNN이 순차적으로 제안되었다(Girshick, 2015; Ren, He, Girshick, & Sun, 2015). Fast R-CNN은 전체 이미지에 대해 CNN 특징 추출을 한 번만 수행하고, 추출된 특징 맵에서 영역별 특징을 가져오는 RoI Pooling 기법을 도입하여 연산 효율성을 크게 개선하였다. Faster R-CNN은 영역 제안 과정 자체를 신경망(Region Proposal Network, RPN)으로 대체하여 end-to-end 학습이 가능하도록 하였으며, 이를 통해 속도와 정확도 모두에서 개선을 달성하였다. 그러나 이러한 2단계 방식의 탐지기들은 여전히 실시간 처리에는 한계가 있었으며, CCTV와 같이 다수의 영상 스트림을 동시에 처리해야 하는 환경에서의 적용에는 어려움이 있었다.

2.3.2 YOLO의 등장과 실시간 객체 탐지의 혁신

2016년 Redmon 등이 제안한 YOLO(You Only Look Once)는 객체 탐지 분야에 혁명적인 변화를 가져왔다. YOLO의 핵심 아이디어는 객체 탐지를 단일 회귀 문제로 정의하는 것이다. 기존의 2단계 방식이 영역 제안과 분류를 별도로 수행한 것과 달리, YOLO는 입력 이미지를 그리드(grid)로 분할하고, 각

그리드 셀에서 바운딩 박스의 좌표, 객체 존재 확률, 클래스 확률을 동시에 예측한다. 이러한 단일 단계(one-stage) 접근 방식은 연산 효율성을 극대화하여, 최초 버전에서도 45 FPS 이상의 실시간 처리가 가능하였다.

YOLO의 등장 이후, 실시간 객체 탐지 분야는 빠른 속도로 발전해 왔다. YOLOv2(YOLO9000)는 배치 정규화(batch normalization)의 도입, 고해상도 분류기 사전학습, 앵커 박스(anchor box) 메커니즘 등 다양한 개선을 통해 정확도와 속도 모두에서 성능 향상을 달성하였다. YOLOv3는 다중 스케일 예측(multi-scale prediction)을 도입하여 작은 객체 탐지 성능을 크게 개선하였으며, Darknet-53이라는 더 깊은 백본 네트워크를 채택하였다. 이러한 발전을 통해 YOLO는 정확도 면에서 2단계 탐지기들과의 격차를 줄이면서도 실시간 처리라는 장점을 유지할 수 있었다.

YOLOv4는 Bochkovskiy 등에 의해 2020년에 발표되었으며, 'bag of freebies'와 'bag of specials'라는 개념을 통해 다양한 학습 기법과 아키텍처 개선을 체계적으로 정리하고 적용하였다. CSPNet(Cross Stage Partial Network) 기반의 백본, PANet(Path Aggregation Network) 기반의 넥(neck) 구조, Mish 활성화 함수, Mosaic 데이터 증강 등이 도입되었다. YOLOv5는 Ultralytics에 의해 PyTorch 기반으로 재구현되었으며, 공식 버전 논쟁에도 불구하고 실무에서 널리 사용되고 있다. YOLOv5는 자동 앵커 학습, 다양한 모델 크기 변형(n, s, m, l, x), 편리한 학습 및 배포 파이프라인 등의 특징으로 산업 현장에서의 적용성을 높였다.

YOLOv6는 Meituan에 의해 제안되었으며, 산업용 애플리케이션에 최적화된 설계를 강조하였다. RepVGG 스타일의 백본과 효율적인 디커플드 헤드(decoupled head) 구조를 채택하였다. YOLOv7은 'trainable bag-of-freebies' 개념을 확장하여 재매개변수화(reparameterization)와 동적 레이블 할당(dynamic label assignment) 기법을 도입하였다. YOLOv8은

Ultralytics에 의해 2023년에 발표되었으며, 앵커-프리(anchor-free) 탐지, 새로운 C2f 모듈, 통합 프레임워크 등의 특징을 갖는다. 가장 최근의 YOLOv11은 2024년에 발표되었으며, Transformer 기반 어텐션 메커니즘의 통합, 향상된 특징 융합 구조, 최적화된 손실 함수 등을 통해 CCTV 환경에서 특히 유리한 성능을 보여주고 있다.

2.3.3 기타 주요 객체 탐지 아키텍처

YOLO와 함께 단일 단계 객체 탐지기의 발전을 이끈 또 다른 주요 모델은 SSD(Single Shot MultiBox Detector)이다. SSD는 VGG-16을 기반으로 하며, 다양한 해상도의 특징 맵에서 객체를 탐지하여 다중 스케일 탐지를 가능하게 하였다. RetinaNet은 Focal Loss를 도입하여 클래스 불균형 문제를 효과적으로 해결하고, 단일 단계 탐지기에서도 2단계 탐지기 수준의 정확도를 달성할 수 있음을 보여주었다. EfficientDet은 EfficientNet 백본과 BiFPN(Bi-directional Feature Pyramid Network)을 결합하여 효율성과 정확도의 균형을 추구하였다(Tan, Pang, & Le, 2020).

최근에는 Transformer 아키텍처를 객체 탐지에 적용하는 연구가 활발히 진행되고 있다. DETR(DEtection TRansformer)은 CNN 백본에서 추출한 특징을 Transformer 인코더-디코더 구조로 처리하여, 기존 탐지기에서 필요했던 앵커 박스, NMS(Non-Maximum Suppression) 등의 수작업 설계 요소를 제거한 end-to-end 탐지를 실현하였다(Carion, Massa, Synnaeve, Usunier, Kirillov, & Zagoruyko, 2020). Deformable DETR은 DETR의 느린 수렴 속도 문제를 변형 가능한 어텐션(deformable attention) 메커니즘으로 해결하였다. RT-DETR은 실시간 처리가 가능한 DETR 변형으로, YOLO 계열과 경쟁할 수 있는 속도를 달성하였다. Co-DETR은 협력적 하이브리드 할당 훈련을 통해 DETR 계열 모델의 성능을 더욱 향상시켰다.³⁾

3)DETR은 Transformer를 객체 탐지에 적용한 최초의 모델이다.

2.3.4 Vision AI 모델의 구조적 한계

앞서 살펴본 바와 같이 Vision AI 모델 기술은 놀라운 속도로 발전해 왔으나, CCTV 관제 도메인에 적용함에 있어 여전히 극복해야 할 근본적인 한계들이 존재한다. 이러한 한계들은 Vision AI 모델의 아키텍처적 특성에서 비롯되는 것으로, 단순한 모델 개선만으로는 해결하기 어려운 본질적인 문제들이다.

첫째, 단일 프레임 분석으로 인한 의미 해석 불가 문제이다. Vision AI 모델—특히 YOLO를 포함한 대부분의 객체 탐지 모델—은 입력된 한 장의 이미지 또는 비디오의 특정 시점 프레임만을 분석한다. 이러한 구조에서는 행동의 의도, 동작의 연속성, 상황의 맥락을 이해하는 것이 불가능하다. 예를 들어, 한 사람이 땅을 향해 몸을 숙이고 있는 프레임을 생각해 보자. 이 동작이 바닥에 떨어진 물건을 줍기 위한 것인지, 넘어지는 과정의 한 순간인지, 아니면 운동의 일부인지를 단일 프레임만으로는 판단할 수 없다. 마찬가지로, 두 사람이 신체적으로 접촉하고 있는 장면이 친근한 포옹인지, 폭행의 현장인지, 스포츠 활동인지를 구분하기 위해서는 접촉 전후의 맥락 정보가 필수적이다.

둘째, 시간적 추론(Temporal Reasoning)의 부재 문제이다. 대부분의 이벤트는 시간에 따른 변화의 패턴으로 정의된다. '쓰러짐'이라는 이벤트는 서 있는 상태에서 누운 상태로의 급격한 전환과 이후 움직임의 부재로 특징지어진다. '절도'는 물건에 대한 접근, 취득, 은닉의 순차적 행동으로 구성된다. '화재 연기'는 작은 점에서 시작하여 점차 확산되는 시간적 패턴을 보인다. 시간적 흐름을 고려하지 못하는 Vision AI 모델은 이러한 '사건의 시작-진행-종료'를 파악하지 못하며, 따라서 사건의 본질을 이해하지 못한 채 표면적인 시각적 유사성에 의존하여 판단하게 된다.

셋째, 시각적으로 유사한 상황에서의 오답 문제이다. 숙인 자세와 낙상, 장난 행동과 폭행, 수증기와 연기, 그림자와 침입자 등 시각적으로 유사하지만 본질

적으로 다른 상황들이 CCTV 환경에서 빈번히 발생한다. Vision AI모델은 이러한 상황들을 구분하는 데 어려움을 겪으며, 이로 인해 오탐(false positive)이 빈번하게 발생한다. 오탐의 증가는 관제요원의 업무 부담을 가중시키고, 반복적인 오탐에 대한 노출은 '경보 피로(alarm fatigue)'를 유발하여 실제 위험 상황에 대한 반응성을 저하시킨다.

넷째, 작은 객체 및 저화질 환경에서의 성능 저하 문제이다. 담배불, 칼, 휴대폰, 지갑 등 작은 크기의 객체는 CCTV 영상에서 몇 픽셀에 불과한 크기로 나타나는 경우가 많다. 이러한 작은 객체의 탐지는 고해상도 특징 맵과 정교한 특징 추출이 요구되는데, 실시간 처리를 위해 최적화된 경량 모델에서는 이러한 능력이 제한적이다. 야간이나 저조도 환경에서는 노이즈 증가와 대비 저하로 인해 문제가 더욱 심화된다.

다섯째, 데이터 편향과 일반화 실패 문제이다.⁴⁾ 앞서 2.2절에서 논의한 바와 같이, CCTV 데이터의 장면 고착성 특성으로 인해 Random Split 기반으로 학습된 모델은 배경 편향을 갖게 되며, 이는 새로운 장소에서의 일반화 실패로 이어진다. 이 문제는 Vision AI 모델의 아키텍처적 한계라기보다는 데이터 특성과 학습 방법론의 문제이지만, 실제 현장 적용에서 Vision AI 모델의 효과성을 크게 제약하는 요인이 된다.

2.4 Video Language Model(VLM)의 이론적 배경과 기술적 특성

2.4.1 멀티모달 AI와 VLM의 등장 배경

인공지능 연구의 발전 과정에서 시각(vision)과 언어(language)는 각각 독립적인 연구 영역으로 발전해 왔다. 컴퓨터 비전 분야에서는 이미지 분류, 객체

탐지, 시맨틱 세그멘테이션 등의 과제가 연구되었고, 자연어처리 분야에서는 기계 번역, 텍스트 분류, 질의응답 등의 과제가 연구되었다. 그러나 실제 세계에서 인간의 지각과 인지는 여러 감각 양식(modality)의 정보를 통합적으로 처리하며, 이러한 멀티모달(multimodal) 능력은 상황 이해와 의사결정에 핵심적인 역할을 한다.

2017년 Vaswani 등이 제안한 Transformer 아키텍처는 자연어처리 분야를 혁신하였으며, 이후 BERT, GPT 계열 등 강력한 언어 모델의 개발로 이어졌다. 2021년 Dosovitskiy 등이 제안한 Vision Transformer(ViT)는 Transformer 아키텍처를 이미지 처리에 성공적으로 적용하여, 시각과 언어 영역에서 공통의 아키텍처를 사용할 수 있는 가능성을 열었다. 같은 해 Radford 등이 제안한 CLIP(Contrastive Language-Image Pre-training)은 대규모 이미지-텍스트 쌍 데이터에서 시각과 언어의 공통 표현 공간을 학습하여, 멀티모달 AI 연구의 새로운 패러다임을 제시하였다(Radford, Kim, Hallacy, Ramesh, Goh, Agarwal, Sastry, Askell, Mishkin, Clark, Krueger, & Amodei, 2021).

이러한 기술적 발전을 배경으로, 시각 정보와 언어 정보를 통합적으로 처리하는 Vision-Language Model(VLM)이 등장하였다. VLM은 이미지나 비디오를 입력으로 받아 그 내용을 이해하고, 자연어로 설명하거나 질문에 답변하는 능력을 갖추고 있다. 초기의 VLM은 이미지를 대상으로 하였으나, 최근에는 비디오를 입력으로 하는 Video Language Model로 확장되어, 시공간적 정보의 이해와 언어적 표현을 통합하는 연구가 활발히 진행되고 있다.

2.4.2 비디오 이해를 위한 딥러닝 기술의 발전

비디오 이해 기술의 발전은 크게 세 가지 흐름으로 구분할 수 있다. 첫째는 3D 컨볼루션 네트워크 기반 접근법, 둘째는 Two-Stream 및 Temporal Segment 기반 접근법, 셋째는 Transformer 기반 접근법이다. 3D 컨볼루션

네트워크(3D CNN)는 2D CNN의 필터를 시간 축으로 확장하여 비디오의 시공간적 특징을 직접 학습한다. C3D(Convolutional 3D)는 이 분야의 선구적 연구로, 짧은 비디오 클립에서 시공간 특징을 추출하는 방법을 제시하였다.

I3D(Inflated 3D ConvNet)는 ImageNet에서 사전학습된 2D CNN 필터를 3D로 'inflate'하여 초기화함으로써, 대규모 이미지 데이터에서 학습된 지식을 비디오 이해에 전이하는 방법을 제안하였다. SlowFast Networks는 느린 경로(Slow pathway)와 빠른 경로(Fast pathway)를 통해 의미적 정보와 움직임 정보를 각각 처리하는 이중 경로 구조를 제안하였다. R(2+1)D는 3D 컨볼루션을 공간(2D)과 시간(1D)으로 분해하여 효율성과 성능을 모두 개선하였다(Tran, Ray, Shou, Chang, & Paluri, 2018).

Two-Stream 네트워크는 외형 정보를 처리하는 공간 스트림(spatial stream)과 움직임 정보를 처리하는 시간 스트림(temporal stream)을 별도로 학습한 후 결합하는 방식이다. 시간 스트림은 일반적으로 옵티컬 플로우(optical flow)를 입력으로 사용하여 프레임 간 움직임 정보를 명시적으로 활용한다. Temporal Segment Networks(TSN)는 긴 비디오를 여러 세그먼트로 나누고 각 세그먼트에서 샘플링한 프레임들의 예측을 집계하는 방식으로, 장기 시간 구조를 모델링하는 효율적인 방법을 제안하였다.

Transformer 아키텍처의 비디오 이해 분야 적용은 최근 몇 년간 급속히 진행되었다. TimeSformer는 공간 어텐션과 시간 어텐션을 분리하여 적용하는 'divided space-time attention' 방식을 제안하였다. ViViT(Video Vision Transformer)는 비디오의 시공간 토큰화 방법과 효율적인 어텐션 처리 방식을 체계적으로 분석하였다. MViT(Multiscale Vision Transformers)는 다양한 해상도의 특징을 계층적으로 처리하는 구조를 제안하여, 효율성과 정확도를 모두 개선하였다(Fan, Xiong, Mangalam, Li, Yan, & Malik, 2021).

2.4.3 VideoMAE: 자기지도학습 기반 비디오 인코더

VideoMAE(Video Masked Autoencoder)는 2022년 Tong 등에 의해 제안된 자기지도학습(self-supervised learning) 기반 비디오 사전학습 방법으로, 비디오 이해 분야에서 새로운 패러다임을 제시하였다.

VideoMAE는 이미지 영역에서 큰 성공을 거둔 MAE(Masked Autoencoder)의 아이디어를 비디오로 확장한 것이다. MAE는 입력 이미지의 높은 비율(75%)을 마스킹한 후, 인코더가 마스킹되지 않은 패치들로부터 표현을 학습하고, 디코더가 마스킹된 패치들을 재구성하도록 하는 방식이다. 이러한 재구성 과제(reconstruction task)를 통해 모델은 데이터의 의미 있는 표현을 학습하게 된다.

VideoMAE의 핵심 기여는 비디오 데이터에서 매우 높은 마스킹 비율(90% 이상)을 적용해도 효과적인 학습이 가능하다는 발견이다. 이는 비디오가 시간적 중복성(temporal redundancy)을 가지고 있어, 인접 프레임들 간에 정보가 공유되기 때문이다. 높은 마스킹 비율은 두 가지 장점을 제공한다. 첫째, 모델이 단순히 인접 패치를 복사하는 방식의 지름길(shortcut)을 사용하지 못하도록 하여, 더 깊은 의미적 이해를 학습하도록 유도한다. 둘째, 인코더가 처리해야 하는 토큰의 수가 크게 줄어들어 메모리 효율성과 학습 속도가 개선된다.

VideoMAE의 아키텍처는 ViT(Vision Transformer)를 기반으로 하며, 비디오를 시공간 튜브(tube) 단위로 토큰화한다. 각 튜브는 여러 프레임에 걸쳐 동일한 공간 위치를 커버하며, 이를 통해 시간적 연속성이 자연스럽게 모델링된다. 인코더는 마스킹되지 않은 토큰들만을 입력으로 받아 효율적으로 처리하고, 디코더는 인코더의 출력과 마스크 토큰들을 결합하여 원본 비디오를 재구성한다. 학습된 인코더는 하류 과제(downstream task)를 위한 특징 추출기로 사용되며, 행동 인식, 비디오 분류 등 다양한 과제에서 우수한 성능을 보여주

었다.

VideoMAE V2는 원본 VideoMAE를 확장하여 더 큰 규모의 모델과 데이터셋을 활용하고, 이중 마스킹(dual masking) 전략을 도입하였다. 이러한 발전을 통해 VideoMAE 계열 모델은 현재 비디오 이해 분야에서 가장 효과적인 사전학습 방법 중 하나로 인정받고 있으며, CCTV 영상 분석을 포함한 다양한 실제 응용에서 활용되고 있다.

2.4.4 대규모 언어 모델(LLM)과 멀티모달 통합

대규모 언어 모델(Large Language Model, LLM)은 방대한 텍스트 데이터에서 사전학습된 Transformer 기반 모델로, 자연어 이해와 생성에서 인상적인 능력을 보여주고 있다. GPT(Generative Pre-trained Transformer) 계열은 OpenAI에 의해 개발되었으며, GPT-3는 1750억 개의 파라미터를 갖는 대규모 모델로 few-shot 학습 능력을 입증하였다. GPT-4는 멀티모달 입력을 지원하며, 텍스트뿐 아니라 이미지를 함께 입력으로 처리할 수 있다.

LLaMA(Large Language Model Meta AI)는 Meta에 의해 개발된 오픈소스 LLM으로, 연구 커뮤니티에서 널리 활용되고 있다. LLaMA는 효율적인 아키텍처 설계와 학습 방법을 통해, 상대적으로 작은 모델 크기에서도 경쟁력 있는 성능을 달성하였다. LLaMA 2는 더 큰 학습 데이터와 개선된 학습 방법, RLHF(Reinforcement Learning from Human Feedback)를 통한 정렬(alignment)을 적용하였다. 최근의 LLaMA 3는 더욱 확장된 모델 크기와 학습 데이터를 기반으로 최신 성능을 달성하고 있다. Vicuna는 LLaMA를 기반으로 ShareGPT 대화 데이터에서 파인튜닝된 모델로, 대화 능력이 크게 개선되었다.

LLM의 뛰어난 언어 이해 및 추론 능력을 시각 정보와 결합하려는 연구가 활발히 진행되고 있다. BLIP-2는 동결된(frozen) 이미지 인코더와 LLM 사이를

연결하는 Q-Former라는 경량 모듈을 제안하여, 효율적인 멀티모달 학습을 가능하게 하였다. InstructBLIP은 BLIP-2에 지시 튜닝(instruction tuning)을 적용하여, 다양한 시각-언어 과제에서의 일반화 능력을 향상시켰다. LLaVA(Large Language and Vision Assistant)는 GPT-4를 활용하여 생성한 시각적 지시 데이터에서 학습하여, 시각적 대화 능력을 획득하였다. MiniGPT-4는 단 하나의 프로젝션 레이어만으로 시각 인코더와 LLM을 연결하여 효율성을 극대화하였다(Zhu, Chen, Chen, Li, & Luo, 2023).

2.4.5 Video-LLM의 주요 모델과 기술적 특성

비디오를 입력으로 하는 Video-LLM은 이미지 기반 VLM을 비디오로 확장한 것으로, 시간적 정보의 처리가 핵심 과제가 된다. Video-LLaMA는 비디오와 오디오 모두를 이해하고 지시를 따르는 능력을 갖춘 멀티모달 모델이다. Video-LLaMA는 비디오 Q-Former를 통해 시각 인코더의 출력을 집계하고, Audio Q-Former를 통해 오디오 정보를 처리한다. 이렇게 추출된 시청각 특징은 LLaMA 언어 모델의 입력 공간에 정렬되어 통합 처리된다.

Video-LLaVA는 LLaVA의 프레임워크를 비디오로 확장한 모델로, 'alignment before projection'이라는 사전 정렬 전략을 도입하였다(Lin, Zhang, Gou, Sun, Kong, & Zha, 2023). 이 전략은 시각적 표현을 언어 모델 공간에 투영하기 전에 먼저 정렬하여, 모달리티 간 차이(modality gap)를 줄이고 더 효과적인 멀티모달 학습을 가능하게 한다. Video-ChatGPT는 비디오 이해에 특화된 대화형 모델로, 시공간 풀링을 통해 프레임 수준의 특징을 효율적으로 집계하고 상세한 비디오 이해 능력을 달성하였다.

Qwen-VL은 Alibaba에서 개발한 다목적 VLM으로, 이미지와 비디오 모두를 처리할 수 있으며, 세밀한 시각적 이해와 다국어 지원이 특징이다(Bai, Bai, Li, Qin, Yan, & Zhang, 2023). Google의 Gemini는 처음부터 멀티모달을 염두

에 두고 설계된 모델로, 텍스트, 이미지, 비디오, 오디오를 네이티브하게 처리할 수 있다. Gemini 1.5는 100만 토큰 이상의 긴 컨텍스트를 처리할 수 있어, 장시간 비디오의 이해에서 특히 강점을 보인다. 이러한 Video-LLM들은 비디오의 내용을 자연어로 설명하고, 비디오에 관한 질문에 답변하며, 비디오 기반 추론을 수행하는 등 다양한 능력을 보여주고 있다.

2.5 VLM의 CCTV 적용 가능성과 한계

2.5.1 CCTV 관제 도메인에서의 VLM 장점

VLM은 CCTV 관제 도메인에서 Vision AI 모델이 갖지 못한 여러 가지 중요한 능력을 제공한다. 첫째, VLM은 연속적인 프레임들을 분석하여 행동의 시간적 맥락을 이해할 수 있다. 이를 통해 단일 프레임만으로는 구분하기 어려운 유사 행동들—예컨대 숙임과 낙상, 포옹과 폭행—을 시간에 따른 변화 패턴을 기반으로 구분할 수 있다. 연기 탐지의 경우에도, 연기의 발생, 확산, 이동 패턴을 시간적으로 분석하여 실제 화재 연기와 수증기, 먼지 등을 구분하는 것이 가능해진다.

둘째, VLM은 장면의 의미를 추론하고 원인을 분석하는 고차원적 이해 능력을 갖추고 있다. 예를 들어, 한 사람이 바닥에 쓰러져 있는 장면을 분석할 때, VLM은 단순히 '사람이 누워 있다'는 사실을 넘어서, 주변 상황(예: 젖은 바닥, 계단 근처), 쓰러지기 전후의 행동, 다른 사람들의 반응 등을 종합하여 '미끄러져 넘어진 것으로 추정됨' 또는 '갑작스런 의식 상실로 보임' 등의 추론을 수행할 수 있다. 이러한 추론 능력은 관제요원의 상황 판단을 효과적으로 지원할 수 있다.

셋째, VLM은 분석 결과를 자연어로 설명할 수 있어, 보고서 자동 생성이 가능하다. 현재 관제센터에서 관제요원은 사건 발생 시 상황을 파악하고, 이를

정해진 양식에 따라 보고서로 작성해야 한다. 이 과정은 시간이 소요되며, 관제요원의 업무 부담을 가중시킨다. VLM을 활용하면 탐지된 이벤트에 대한 기초 보고서를 자동으로 생성할 수 있으며, 관제요원은 이를 검토하고 필요시 수정하는 방식으로 업무 효율성을 크게 높일 수 있다.

넷째, VLM은 다양한 장면과 상황에 대한 일반화 능력이 상대적으로 우수하다. 대규모 비디오-텍스트 데이터에서 사전학습된 VLM은 특정 장소나 환경에 과적합되지 않고, 다양한 상황을 이해하는 범용적 능력을 갖추고 있다. 이는 CCTV 데이터의 장면 편향 문제를 완화하는 데 도움이 될 수 있다.

2.5.2 VLM의 한계와 제약

VLM의 장점에도 불구하고, 현재 시점에서 CCTV 관제 시스템에 VLM을 단독으로 적용하는 데는 여러 가지 한계가 존재한다. 가장 심각한 제약은 추론 속도와 연산 비용 문제이다. VLM은 비디오 인코딩과 언어 모델 추론을 모두 수행해야 하므로, 단일 비디오 클립의 분석에도 상당한 시간과 연산 자원이 소요된다. 현재의 최신 GPU를 사용하더라도, 수백 대의 CCTV 스트림을 VLM으로 실시간 분석하는 것은 경제적으로나 기술적으로 현실적이지 않다. 이는 VLM을 CCTV 관제의 1차 탐지 수단으로 사용하기 어렵게 만드는 근본적인 제약이다.

둘째, 환각(hallucination) 문제는 VLM의 신뢰성에 심각한 우려를 제기한다. 환각이란 모델이 입력에 존재하지 않는 내용을 있는 것처럼 생성하거나, 사실과 다른 내용을 자신 있게 서술하는 현상을 말한다. CCTV 관제는 안전-중요(safety-critical) 영역으로, 잘못된 정보에 기반한 판단은 심각한 결과를 초래할 수 있다. 예를 들어, VLM이 실제로 발생하지 않은 폭행을 탐지했다고 보고하거나, 반대로 실제 위험 상황을 정상으로 판단하는 경우, 이는 인명 피해나 재산 손실로 이어질 수 있다.

셋째, 고비용 하드웨어 요구는 실제 배치의 장벽이 된다. VLM의 효과적인 운영을 위해서는 고성능 GPU가 필수적이며, 다수의 카메라 스트림을 처리하기 위해서는 여러 대의 GPU 서버가 필요하다. 이는 초기 투자 비용뿐 아니라 운영 비용(전력, 냉각, 유지보수)의 증가를 의미하며, 예산이 제한된 지방자치단체나 중소 규모 기관에서의 도입을 어렵게 한다.

넷째, 프라이버시 문제에 대한 고려가 필요하다. VLM은 영상 내 인물의 행동뿐 아니라 외모, 의복, 소지품 등 개인 식별 가능 정보를 처리할 수 있다. 학교, 병원, 정부기관 등 민감한 환경에서 VLM을 활용할 경우, 개인정보 보호 규정(예: GDPR, 개인정보보호법)과의 충돌 가능성을 검토해야 한다. 특히 VLM이 생성하는 자연어 설명에 개인 식별 정보가 포함될 수 있어, 데이터 처리 및 저장에 관한 추가적인 정책이 필요하다.

2.6 Vision AI 모델-VLM 하이브리드 구조의 필요성

지금까지 분석한 바와 같이, Vision AI 모델과 VLM은 상반된 특성의 장단점을 가지고 있다. Vision AI 모델—특히 YOLO 계열 모델—는 빠른 추론 속도와 낮은 연산 비용이라는 장점을 가지며, 실시간 처리가 요구되는 CCTV 환경에 적합하다. 그러나 단일 프레임 분석의 한계로 인해 의미론적 이해가 부족하고, 시각적으로 유사한 상황에서 오탐이 빈번하다. 반면 VLM은 시간적 맥락을 고려한 깊은 의미 이해와 추론 능력을 갖추고 있으나, 느린 처리 속도와 높은 연산 비용으로 인해 실시간 적용이 어렵다.

이러한 상황에서 각 기술을 단독으로 사용하는 것은 CCTV 관제의 요구를 충족시키기 어렵다. Vision AI 모델 단독 사용 시에는 오탐률이 높아 관제요원의 검토 부담이 가중되고, 시간이 지남에 따라 경보에 대한 신뢰도가 하락하는 문제가 발생한다. VLM 단독 사용 시에는 현재의 기술 수준에서 실시간 처리가

불가능하며, 환각 문제로 인한 신뢰성 우려가 있다. 따라서 두 기술의 장점을 결합하고 단점을 상호 보완하는 하이브리드 접근이 필요하다.

본 연구에서 제안하는 Trigger-Validator 하이브리드 구조는 이러한 필요성에 대한 해답을 제시한다. 이 구조에서 Vision AI 모델은 'Trigger' 역할을 수행한다. 즉, 전체 CCTV 스트림을 실시간으로 모니터링하면서 의심스러운 상황이 발생했을 때 이를 후보 이벤트로 탐지한다. Vision AI 모델의 빠른 속도를 활용하여 넓은 범위의 감시 영역을 커버하되, 이 단계에서의 판단은 최종적인 것이 아니라 잠정적인 것으로 취급한다.

VLM은 'Validator' 역할을 담당한다. Vision AI 모델이 탐지한 후보 이벤트에 대해서만 선별적으로 작동하여, 해당 상황의 시간적 맥락을 분석하고 실제 위험 여부를 판단한다. VLM은 전체 스트림이 아닌 Vision AI 모델이 선별한 클립에 대해서만 분석을 수행하므로, 연산 자원이 효율적으로 활용된다. 또한 VLM의 판단에 대해 자연어 설명이 함께 제공되므로, 관제요원은 왜 해당 상황이 위험 또는 정상으로 판단되었는지를 이해할 수 있다.

이러한 역할 분담 구조는 여러 가지 이점을 제공한다. 첫째, Vision AI 모델의 오탐을 VLM이 효과적으로 필터링할 수 있다. Vision AI 모델이 폭행으로 오탐한 장면이 실제로는 친근한 접촉이었다면, VLM이 시간적 맥락을 분석하여 이를 정상으로 재분류할 수 있다. 둘째, VLM의 연산 부담이 크게 경감된다. 전체 스트림 대신 Vision AI 모델이 선별한 후보 이벤트만 분석하므로, 필요한 GPU 자원과 처리 시간이 현실적인 수준으로 줄어든다. 셋째, 두 모델의 상호보완을 통해 전체 시스템의 정확도와 신뢰도가 향상된다.

2.7 Scene-level Split의 필요성

CCTV 영상 데이터를 활용한 기계학습 연구에서 데이터 분할(data split) 방

법은 모델 성능 평가의 신뢰성에 결정적인 영향을 미친다. 전통적으로 많이 사용되는 Random Split 방식—즉, 전체 데이터를 무작위로 섞어 훈련/검증/테스트 세트로 분할하는 방식—은 CCTV 데이터에 적용할 경우 심각한 문제를 야기한다. 앞서 2.2절에서 논의한 바와 같이, CCTV 영상은 고정된 카메라에서 촬영되어 배경이 일정하게 유지되는 특성을 갖는다. Random Split을 적용하면 동일한 장소(scene)에서 촬영된 영상 클립이 훈련 세트와 테스트 세트 양쪽에 모두 포함될 가능성이 높다.

이 경우, 모델은 행동의 특징이 아닌 장소의 배경 특징을 학습하는 편향을 갖게 된다. 예를 들어, 특정 주차장에서 촬영된 침입 영상이 훈련 데이터에 포함되어 있다면, 모델은 침입 행동의 특징—예컨대 은밀한 접근, 울타리 넘기 등—을 학습하는 대신, 해당 주차장의 배경 요소—주차선 패턴, 조명 기둥, 주변 건물 형태 등—를 단서로 활용하여 예측할 수 있다. 테스트 세트에 같은 주차장에서 촬영된 다른 침입 영상이 포함된다면, 모델은 배경만 보고도 높은 정확도를 달성할 수 있다. 그러나 이렇게 학습된 모델은 다른 주차장이나 새로운 장소에서는 성능이 급격히 저하된다.

이러한 문제를 해결하기 위해 Scene-level Split 방식이 필요하다. Scene-level Split은 촬영 장소(scene)를 기준으로 데이터를 분할하여, 훈련에 사용된 장소와 테스트에 사용되는 장소가 완전히 분리되도록 한다. 예를 들어, 10개의 다른 주차장에서 침입 영상이 수집되었다면, 7개 주차장의 영상은 훈련에, 나머지 3개 주차장의 영상은 테스트에 사용한다. 이를 통해 모델은 특정 장소의 배경이 아닌, 침입 행동 자체의 일반적인 특징을 학습하도록 유도된다.

Scene-level Split의 적용은 여러 가지 장점을 제공한다. 첫째, 모델의 실제 일반화 능력을 정확하게 평가할 수 있다. Random Split에서의 높은 테스트 성능이 실제 현장 배치 시 유지되지 않는 경우가 빈번한데, Scene-level Split은 새로운 장소에서의 예상 성능을 보다 현실적으로 추정할 수 있게 한다. 둘째,

배경 편향이 감소함에 따라 모델의 robustness가 향상된다. 셋째, 실제 배치 환경에서의 오탐 및 미탐 발생률을 줄일 수 있다. 본 연구에서는 Scene-level Split 방식을 데이터셋 구축과 모델 평가의 핵심 설계 원칙으로 채택하였으며, 이는 연구 결과의 실용적 가치와 신뢰성을 높이는 데 중요한 역할을 한다.

2.8 기존 연구의 한계

CCTV 영상 분석을 위한 인공지능 기술에 관한 기존 연구들은 상당한 발전을 이루어 왔으나, 여전히 극복해야 할 한계들이 존재한다. 첫째, 대부분의 연구가 Vision AI 모델 단독 모델의 성능 향상에 집중하고 있다. YOLO, SSD, Faster R-CNN 등 객체 탐지 모델의 정확도와 속도를 개선하는 연구, 특정 이벤트(낙상, 폭행, 화재 등)를 탐지하기 위한 특화 모델 개발 연구 등이 활발히 진행되어 왔다. 그러나 이러한 연구들은 앞서 논의한 Vision AI 모델의 구조적 한계—시간적 맥락 이해 부재, 의미론적 분석 불가—를 근본적으로 해결하지 못하며, 실제 현장에서의 오탐 문제를 충분히 다루지 않고 있다.

둘째, VLM을 CCTV 분석에 적용하려는 시도가 일부 있었으나, 대부분 실시간 적용에 관한 구체적인 논의가 부족하다. VLM의 비디오 이해 능력을 활용한 이상 탐지 연구, 자연어 설명 생성 연구 등이 발표되었으나, 수백 대의 카메라 스트림을 동시에 처리해야 하는 실제 관제센터 환경에서의 적용 가능성에 대한 분석은 미흡하다. 또한 VLM의 환각 문제가 안전-중요 영역에서 어떠한 위험을 초래할 수 있는지에 대한 체계적인 분석도 부족한 실정이다.

셋째, 데이터셋 구축 및 평가 방법론에 있어 Scene-level Split의 중요성이 충분히 인식되지 않고 있다. 많은 연구들이 Random Split 방식으로 데이터를 분할하여 실험을 수행하고 있으며, 이로 인해 보고된 성능 수치가 실제 현장 적용 시 재현되지 않는 문제가 발생하고 있다. CCTV 도메인의 특수성을 고려

한 평가 프로토콜의 표준화가 필요함에도 불구하고, 이에 대한 합의가 아직 형성되지 않았다.

넷째, 의미 기반 추론(reasoning)에 대한 정량적 평가가 부족하다. 기존 연구들은 주로 정밀도, 재현율, mAP 등 전통적인 객체 탐지 지표에 의존하여 성능을 평가한다. 그러나 CCTV 관제에서 중요한 것은 단순히 객체를 탐지하는 것이 아니라, 상황의 위험도를 정확히 판단하고 적절한 대응을 지원하는 것이다. 이러한 고차원적 의미 이해 능력에 대한 평가 방법론은 아직 충분히 개발되지 않았다.

다섯째, 실제 관제센터 운영 맥락을 반영한 연구가 부족하다. 대부분의 연구가 기술적 성능 향상에 초점을 맞추고 있으며, 관제요원의 업무 프로세스, 의사결정 방식, 보고서 작성 절차 등 현장의 실제 요구사항을 충분히 고려하지 않고 있다. 기술적으로 우수한 시스템이라도 현장의 업무 흐름에 통합되지 못한다면 실질적인 가치를 발휘하기 어렵다.

2.9 본 연구의 차별성과 의의

본 연구는 앞서 지적한 기존 연구의 한계들을 극복하고, CCTV 기반 지능형 관제 시스템 분야에서 학술적·실무적으로 의미 있는 기여를 제공하고자 한다. 본 연구의 핵심 차별점과 기대되는 의의는 다음과 같다.

첫째, 본 연구는 Vision AI 모델과 VLM을 결합한 하이브리드 관제 구조에 대한 최초의 체계적인 실증 연구이다. 기존 연구들이 각 기술을 독립적으로 다루어 온 것과 달리, 본 연구는 두 기술의 상호 보완성에 주목하고, Trigger-Validator라는 구체적인 역할 분담 구조를 제안한다. 이 구조가 실제로 오탐 감소, 연산 효율성, 관제 품질 향상에 기여하는지를 정량적 실험을 통해 검증함으로써, 하이브리드 접근의 효과성에 대한 실증적 근거를 제공한다.

둘째, 본 연구는 CCTV 도메인에 특화된 Scene-level Split 기반 데이터셋 구축 및 평가 방법론을 적용한다. 촬영 장소를 기준으로 데이터를 엄격히 분리함으로써, 모델의 실제 일반화 능력을 정확하게 평가하고, 배경 편향 문제를 해결한다. 이러한 방법론은 본 연구의 결과뿐 아니라, 후속 연구들의 평가 프로토콜 개선에도 기여할 수 있다.

셋째, 본 연구는 의미 기반 추론 능력에 대한 정량적·정성적 평가를 수행한다. 전통적인 탐지 지표 외에도, VLM이 생성하는 상황 설명의 품질, 위험도 판단의 정확성, 인과 추론의 타당성 등을 평가하여, 고차원적 이해 능력의 실질적 가치를 분석한다. 이를 통해 VLM의 CCTV 적용 가능성과 한계에 대한 보다 심층적인 이해를 제공한다.

넷째, 본 연구는 실제 관제센터의 운영 맥락을 반영하여 연구를 설계하고 수행한다. 관제요원의 업무 프로세스, 판단 기준, 보고서 작성 요구사항 등을 분석하고, 이를 시스템 설계와 평가에 반영한다. 또한 현장 전문가 평가를 포함하여, 기술적 성능뿐 아니라 실무적 적용 가능성을 종합적으로 검토한다. 이러한 접근을 통해 연구 결과가 학술적 의미에 그치지 않고 실제 현장에서 활용될 수 있는 기반을 마련한다.

다섯째, 본 연구는 AI 기반 도시안전 기술의 새로운 발전 방향을 제시한다. Vision AI 모델의 속도와 VLM의 이해력을 결합하는 하이브리드 접근은 CCTV 관제를 넘어 스마트시티, 스마트빌딩, 산업안전 등 다양한 영역에서 참고될 수 있는 설계 원칙을 제공한다. 본 연구의 결과는 공공안전 향상을 위한 정책 수립에 기여할 수 있는 실증적 근거를 제공할 것으로 기대된다.

제3장 연구방법

본 장에서는 Vision AI 모델과 Video Language Model(VLM)을 결합한 하이브리드 관제 모델을 구축하기 위한 연구 절차와 실험 설계 방법을 상세히 기술한다. 연구 방법론은 실제 CCTV 통합관제센터의 실무 환경을 최대한 반영하도록 구성되었으며, Scene-level Split 기반 데이터셋 설계, YOLO 기반 Vision AI 모델의 학습 및 평가, VideoMAE-LLaMA 기반 VLM 구축, 그리고 Trigger-Validator 방식의 하이브리드 모델 설계를 중심으로 이루어졌다(Tong et al., 2022; Touvron et al., 2023; Wang et al., 2023). 특히 본 장에서는 왜 Vision AI 모델 AI와 VLM을 단독으로 사용하는 것이 아닌 하이브리드 방식으로 결합해야 하는지에 대한 기술적·방법론적 당위성을 체계적으로 제시하며, 이러한 연구 방법론이 어떻게 제4장의 실험결과 도출과 제5장의 결론 및 향후 연구 방향 설정으로 자연스럽게 연결되는지를 논의한다.

연구 방법론의 설계에 있어 가장 핵심적인 고려사항은 기존 연구의 한계를 극복하고 실무적 활용 가능성이 높은 모델 구조를 마련하는 것이다. 제2장에서 분석한 바와 같이, Vision AI 모델은 빠른 처리 속도라는 장점에도 불구하고 단일 프레임 기반 분석으로 인해 행동의 의미를 이해하지 못하는 근본적 한계를 갖는다. 반면 VLM은 시공간적 맥락을 고려한 의미 기반 분석이 가능하지만, 연산 비용이 높아 실시간 적용이 어렵고 환각(hallucination) 문제가 존재한다. 본 연구의 방법론은 이러한 두 기술의 상보적 특성을 활용하여 각각의 장점을 극대화하고 단점을 상호 보완하는 구조를 설계하는 데 초점을 맞추고 있다.

3.1 연구 절차의 개요

본 연구는 체계적인 연구 절차를 통해 하이브리드 관제 모델의 효과성을 검증하고자 하며, 이를 위해 네 가지 핵심 단계로 연구를 구성하였다. 첫째, CCTV 도메인 분석 및 Scene-level Split 기반 데이터셋 구축 단계에서는 CCTV 영상의 고유한 특성을 분석하고, 기존 Random Split 방식의 문제점을 해결하는 새로운 데이터 분할 방법론을 적용한다. 둘째, YOLO 기반 Vision AI 모델 설계 및 학습 수행 단계에서는 최신 YOLOv11 아키텍처를 활용하여 실시간 객체 탐지 모델을 구축하고, CCTV 도메인에 최적화된 학습을 수행한다 (Bochkovskiy et al., 2020; Jocher et al., 2023). 셋째, VLM(VideoMAE + LLaMA) 모델 구축 및 의미 기반 추론 수행 단계에서는 비디오 인코더와 대규모 언어 모델을 결합하여 시공간적 의미 분석이 가능한 모델을 구현한다. 넷째, Trigger-Validator 하이브리드 구조 설계 및 성능 평가 단계에서는 앞서 구축한 두 모델을 역할 분담 방식으로 통합하고, 그 효과성을 다각적으로 검증한다 (Wang et al., 2023; Liu et al., 2023).

이러한 연구 절차는 단순히 기술적 구현에 그치는 것이 아니라, CCTV 영상의 특성, 관제센터 운영 방식, 그리고 실제 위험 이벤트의 발생 양상을 모두 종합하여 설계되었다. 특히 연구 절차의 각 단계는 서로 유기적으로 연결되어 있어, 앞선 단계의 결과가 다음 단계의 설계에 반영되고, 최종적으로 제4장의 실험결과와 제5장의 결론으로 자연스럽게 이어지도록 구성되었다. 예를 들어, 데이터셋 구축 단계에서 적용한 Scene-level Split 방식은 모델 평가의 신뢰성을 확보하는 기반이 되며, 이를 통해 도출된 실험결과는 하이브리드 구조의 실효성을 입증하는 근거가 된다.

3.1.1 하이브리드 방식 채택의 당위성

본 연구가 Vision AI 모델과 VLM의 하이브리드 방식을 채택한 데에는 명

확한 기술적·방법론적 당위성이 존재한다. 이 당위성은 세 가지 관점-기술적 상보성, 운영적 실현 가능성, 그리고 연구 목적과의 정합성-에서 설명될 수 있다.

첫째, 기술적 상보성의 관점에서, Vision AI 모델과 VLM은 서로 상반된 특성의 장단점을 가지고 있어 결합 시 시너지 효과를 창출할 수 있다. Vision AI 모델은 실시간 처리가 가능한 빠른 속도를 제공하지만 단일 프레임 분석으로 인해 시간적 맥락을 이해하지 못한다. 반면 VLM은 비디오 시퀀스의 시공간적 패턴을 분석하여 행동의 의미를 이해할 수 있지만, 연산 비용이 높아 실시간 적용이 어렵다.⁵⁾ 이러한 상반된 특성은 두 기술을 단독으로 사용할 경우 각각 미탐(false negative)과 지연이라는 문제를 야기하지만, 적절히 결합할 경우 상호 보완이 가능하다. 본 연구의 Trigger-Validator 구조⁶⁾는 Vision AI의 속도와 VLM의 이해력을 결합하여, 두 기술의 장점은 극대화하고 단점은 최소화하는 것을 목표로 한다.

둘째, 운영적 실현 가능성의 관점에서, 하이브리드 구조는 현재의 기술 수준과 하드웨어 환경에서 실제로 구현 가능한 유일한 접근 방식이다. 만약 VLM을 단독으로 사용하여 모든 CCTV 스트림을 실시간 분석하려 한다면, 현재의 최신 GPU를 다수 동원하더라도 수백 대의 카메라를 커버하는 것은 경제적으로나 기술적으로 현실적이지 않다. 반면 Vision AI 모델을 1차 필터로 사용하여 의심스러운 이벤트만 선별하고, VLM은 선별된 클립에 대해서만 분석을 수행하는 구조에서는 VLM의 연산 부담이 현실적인 수준으로 감소한다. 이러한 구조는 예산과 인프라가 제한된 실제 관제센터 환경에서도 도입 가능한 실용적 해법을 제공한다.

5) Video-LLaMA·LLaVA 계열은 GPU 메모리 사용량이 높고, 1분 영상 분석 시 수 초 단위의 지연이 발생한다.

6) Vision AI의 빠른 탐지를 1차 필터로 사용하고, VLM의 의미 분석을 2차 필터로 결합하는 방식은 오탐 감소에 특히 효과적이다.

셋째, 연구 목적과의 정합성 관점에서, 하이브리드 구조는 본 연구가 해결하고자 하는 핵심 문제—오탐 감소, 미탐 보완, 관제 업무 효율화—에 가장 적합한 해법이다. 오탐 문제는 Vision AI 모델이 시각적으로 유사한 상황을 구분하지 못해 발생하는데, VLM의 의미 기반 검증을 통해 해결될 수 있다. 미탐 문제는 Vision AI 모델이 미세한 변화나 점진적 상황 전개를 놓치는 경우 발생하는데, VLM의 시간적 맥락 분석을 통해 보완될 수 있다. 관제 업무 효율화는 VLM이 생성하는 자연어 설명을 활용한 보고서 자동화를 통해 달성될 수 있다. 이처럼 하이브리드 구조는 연구 목적의 모든 측면에서 가장 효과적인 접근 방식임을 알 수 있다.

3.1.2 연구 방법론과 실험결과·결론의 연계성

본 연구의 방법론은 제4장의 실험결과 도출과 제5장의 결론 및 향후 연구 방향 설정이 자연스럽게 이루어지도록 체계적으로 설계되었다. 연구 방법론의 각 구성요소—데이터셋 설계, Vision AI 모델학습, VLM 구축, 하이브리드 통합—는 각각 특정한 연구 질문에 답하기 위해 설계되었으며, 이러한 질문들에 대한 답변이 모여 최종 결론을 형성한다.

구체적으로, Scene-level Split 기반 데이터셋 설계는 '모델이 새로운 장소에서 일반화 능력을 갖추는가?'라는 질문에 답하기 위한 기반을 제공한다. 이 설계를 통해 제4장에서는 모델의 일반화 성능을 신뢰성 있게 평가할 수 있으며, 제5장에서는 Scene-level Split의 중요성에 대한 결론을 도출할 수 있다. Vision AI 모델의 학습과 평가는 'Vision AI 모델 단독으로 CCTV 관제 요구를 충족할 수 있는가?'라는 질문에 답한다. 제4장의 실험결과에서 Vision AI 모델의 정량적 성능과 오탐·미탐 사례를 분석함으로써, 제5장에서 Vision AI 모델의 한계와 보완 필요성에 대한 결론을 내릴 수 있다.

VLM 모델의 구축과 평가는 'VLM이 Vision AI 모델의 한계를 보완할 수 있

는가?'라는 질문에 답한다. 제4장에서 VLM의 의미 기반 분석 능력과 한계(연산 비용, 환각)를 실험적으로 확인하고, 제5장에서 VLM 단독 사용의 비현실성과 하이브리드 필요성에 대한 결론을 도출한다. 마지막으로, 하이브리드 구조의 설계와 평가는 '두 기술의 결합이 실제로 단독 사용보다 우수한가?'라는 핵심 질문에 답한다. 제4장에서 오탐 감소율, 미탐 보완율, 운영 효율성 개선 정도를 정량적으로 제시하고, 제5장에서 하이브리드 구조의 실무적 가치와 향후 발전 방향에 대한 결론을 내린다. 이처럼 연구 방법론의 각 요소는 논리적 인과관계를 통해 실험결과와 결론으로 연결된다.

3.2 CCTV 데이터셋 구축 및 구성 방법

3.2.1 데이터셋 수집 기준 및 이벤트 유형

본 연구에서 사용된 CCTV 데이터는 실제 통합관제센터 환경에서 발생하는 다양한 안전 이벤트를 중심으로 구성하였다. 데이터 수집의 기본 원칙은 공공 안전 관점에서 우선순위가 높은 이벤트 유형을 포괄하고, 동시에 Vision AI 모델과 VLM의 특성을 비교 평가하기에 적합한 사례들을 포함하는 것이다. 특히 시각적으로는 유사하지만 의미론적으로 다른 상황들—예컨대 숙임과 낙상, 장난과 폭행—을 포함하여, 두 기술의 차별적 능력을 평가할 수 있도록 하였다.

수집된 이벤트 유형은 다음과 같이 구분된다. 첫째, 폭행 및 위협(violence) 이벤트는 신체적 공격, 위협적 행동, 다툼 등을 포함하며, 공공장소에서의 치안 유지와 직결되는 핵심 탐지 대상이다. 둘째, 쓰러짐(fall) 이벤트는 노인, 환자, 음주자 등의 낙상 사고를 포함하며, 특히 신속한 대응이 요구되는 응급 상황으로서 관제 업무에서 높은 중요도를 갖는다. 셋째, 침입(intrusion) 이벤트는 무단 출입, 울타리 넘기, 통제구역 진입 등을 포함하며, 시설 보안과 범죄 예방에 핵심적인 역할을 한다. 넷째, 연기(smoke) 및 화재 초기 징후 이벤트는 화재로

인한 대형 피해를 방지하기 위한 조기 탐지 대상으로, 미세한 시각적 변화를 감지해야 하는 특성이 있다. 다섯째, 분실물(loss/left item) 이벤트는 의심스러운 물품 방치, 테러 예방 관점에서의 유기물 탐지 등을 포함한다. 여섯째, 군중 밀집(crowding) 이벤트는 과밀 상황으로 인한 안전사고 예방과 관련된다.

이러한 이벤트 유형들은 실제 관제 환경에서 가장 빈번하게 모니터링되는 대상이며, 각 이벤트 유형은 서로 다른 시각적·시간적 특성을 갖기 때문에 모델의 다양한 능력을 종합적으로 평가하는 데 적합하다. 또한 데이터는 다양한 장소(지하철역, 주차장, 공원, 상업시설, 주거지역 등), 카메라 각도(정면, 측면, 부감), 조명 조건(주간, 야간, 실내, 실외)을 포함하도록 구성하여 CCTV 영상 분석 모델의 일반화 성능을 향상시키는 방향으로 설계하였다.

3.2.2 Scene-level Split 설계의 원리와 적용

CCTV 영상은 카메라가 고정된 위치에서 특정 장소(Scene)를 지속적으로 촬영한다는 점에서 일반적인 비디오 데이터와 본질적으로 다른 특성을 갖는다. 제2장에서 상세히 분석한 바와 같이, 이러한 특성은 기계학습 모델의 학습과 평가에 있어 심각한 문제를 야기할 수 있다. 영화, SNS 동영상 등 일반적인 비디오 데이터에서는 장면이 지속적으로 변화하기 때문에 Random Split—전체 데이터를 무작위로 분할하여 훈련/검증/테스트 세트를 구성하는 방식—을 적용해도 훈련 데이터와 테스트 데이터 간에 배경 정보가 유출될 가능성이 낮다. 그러나 CCTV 영상에서는 동일한 장소에서 촬영된 클립들이 고정된 배경을 공유하므로, Random Split을 적용하면 동일 장소의 클립이 훈련 세트와 테스트 세트 양쪽에 포함될 가능성이 높다.⁷⁾

이 경우, 모델은 탐지해야 하는 행동이나 이벤트의 실제 특징을 학습하는 대신, 특정 장소의 배경 요소—벽면 색상, 바닥 패턴, 조명 구조, 가구 배치 등—

7) 동일 장소·카메라에서 촬영된 영상은 서로 유사도가 매우 높아, 일반적인 random split은 성능을 과대추정하는 문제를 야기한다.

를 암기하여 예측에 활용하는 편향을 갖게 된다. 예를 들어, 특정 주차장에서 촬영된 침입 영상이 훈련 데이터에 포함되고, 같은 주차장에서 촬영된 다른 침입 영상이 테스트 데이터에 포함된다면, 모델은 침입 행동의 시각적 특징이 아니라 해당 주차장의 배경을 단서로 사용하여 높은 정확도를 달성할 수 있다. 그러나 이렇게 학습된 모델은 새로운 장소에서는 성능이 급격히 저하되며, 이는 실제 현장 배치 시 심각한 문제가 된다.

이러한 문제를 해결하기 위해 본 연구에서는 Scene-level Split 방식을 도입하였다. Scene-level Split은 촬영 장소(Scene)를 기준으로 데이터를 분할하여, 훈련에 사용된 장소와 검증·테스트에 사용되는 장소가 완전히 분리되도록 한다. 구체적으로, 본 연구에서는 전체 약 31개의 고유한 Scene을 확보하였으며, 이를 훈련용 20개 Scene, 검증용 5개 Scene, 테스트용 6개 Scene으로 분할하였다. 각 Scene 내에서는 다양한 이벤트 유형의 클립이 포함되도록 하여, 이벤트 유형별 분포의 균형을 유지하였다. 이러한 설계를 통해 모델은 특정 장소의 배경이 아닌 행동 자체의 일반적인 시각적·시간적 특징을 학습하도록 유도되며, 테스트 결과는 새로운 장소에서의 예상 성능을 보다 현실적으로 반영하게 된다.

Scene-level Split 방식의 적용은 본 연구의 실험결과 신뢰성을 확보하는 핵심 요소이다. 제4장의 실험결과에서 보고되는 성능 수치들은 모두 이 방식에 기반하여 측정되었으므로, 새로운 CCTV 설치 환경에서의 실제 성능을 보다 정확하게 예측할 수 있다. 또한 제5장의 결론에서는 Scene-level Split이 CCTV AI 연구에서 필수적으로 고려되어야 할 표준적 방법론임을 주장하며, 이는 본 연구의 방법론적 기여 중 하나가 된다.

3.2.3 데이터 전처리 및 증강 과정

데이터 전처리는 모델의 학습 성능과 일반화 능력에 직접적인 영향을 미치는

중요한 단계로서, 본 연구에서는 체계적인 전처리 파이프라인을 구축하여 적용하였다. 전처리 과정은 크게 프레임 샘플링, 정규화, 어노테이션, 노이즈 제거, 데이터 증강의 다섯 가지 단계로 구성된다.

프레임 샘플링(Frame Sampling)은 원본 비디오에서 분석에 사용할 프레임을 추출하는 과정이다. Vision AI 모델과 VLM은 서로 다른 시간적 해상도를 요구하므로, 각 모델에 적합한 샘플링 전략을 적용하였다. Vision AI(YOLO)는 단일 프레임 기반으로 작동하므로 1 FPS(초당 1프레임)로 샘플링하여 연산 효율성을 높였다. 반면 VLM은 시간적 맥락 분석을 위해 연속적인 프레임 시퀀스가 필요하므로 3-8 FPS로 샘플링하여 동작의 시간적 변화를 충분히 포착할 수 있도록 하였다. 이러한 차별적 샘플링 전략은 각 모델의 특성에 맞는 입력 데이터를 제공하면서도 전체 시스템의 연산 효율성을 유지하는 데 기여한다.

정규화(Normalization)는 다양한 해상도와 종횡비를 갖는 원본 CCTV 영상을 모델 입력에 적합한 형태로 변환하는 과정이다. Vision AI 모델은 640×640 픽셀 크기로 정규화하였으며, VLM의 비디오 인코더는 224×224 픽셀 크기로 정규화하였다. 정규화 과정에서는 원본 영상의 종횡비를 유지하면서 리사이징하고, 필요한 경우 패딩을 추가하여 정보 손실을 최소화하였다. 픽셀 값은 0-1 범위로 스케일링하고, ImageNet 데이터셋에서 계산된 평균과 표준편차를 사용하여 채널별 정규화를 수행하였다.

어노테이션(Annotation)은 모델 학습을 위한 레이블 정보를 생성하는 과정으로, Vision AI 모델과 VLM에 서로 다른 형태의 어노테이션을 적용하였다. Vision AI 모델의 경우, 각 프레임에서 관심 객체의 위치를 나타내는 바운딩 박스(Bounding Box) 좌표와 클래스 레이블을 어노테이션하였다. 바운딩 박스는 YOLO 형식(중심점 x, y 및 너비, 높이의 상대 좌표)으로 저장하였다. VLM 모델의 경우, 클립 수준의 이벤트 설명과 질의응답(Q&A) 형태의 추론 데이터를 어노테이션하였다. 예를 들어, '이 영상에서 어떤 일이 일어나고 있습니까

까?', '이 상황은 위험한가요? 그 이유는 무엇입니까?' 등의 질문과 그에 대한 상세한 답변을 작성하여 VLM의 추론 능력을 학습시키는 데 활용하였다.

노이즈 제거(Noise Removal)는 모델 학습에 방해가 될 수 있는 영상 내 불필요한 요소를 제거하는 과정이다. 실제 CCTV 영상에는 워터마크, 타임스탬프, 카메라 정보 등의 오버레이가 포함되어 있는 경우가 많으며, 이러한 요소들이 모델 학습에 불필요한 패턴을 제공할 수 있다. 따라서 가능한 경우 이러한 오버레이를 마스킹하거나 크롭하여 제거하였다. 또한 카메라 흔들림이 심하거나 화면 오염(렌즈 얼룩, 물방울 등)이 있는 클립은 품질 검증을 통해 제외하거나, 가능한 경우 보정 처리를 수행하였다.

데이터 증강(Data Augmentation)은 제한된 훈련 데이터로부터 모델의 일반화 능력을 향상시키기 위해 다양한 변형을 적용하는 기법이다. 본 연구에서는 YOLO 모델 학습에 효과적인 것으로 알려진 여러 증강 기법을 적용하였다. Mosaic 증강은 4개의 훈련 이미지를 하나로 합성하여 다양한 객체 조합과 스케일 변화를 학습하도록 한다. Random Affine 변환은 회전, 스케일링, 이동, 전단(shear) 등의 기하학적 변형을 적용하여 다양한 관점에서의 객체 인식 능력을 향상시킨다. HSV 조정은 색조(Hue), 채도(Saturation), 명도(Value)를 무작위로 변경하여 조명 변화에 대한 강건성을 높인다. 이러한 증강 기법들은 특히 CCTV 환경에서 발생할 수 있는 다양한 조건 변화에 대응하는 능력을 향상시키는 데 기여한다.

3.3 Vision AI 모델 구성 및 학습 방법

3.3.1 YOLO 계열 모델 선택의 기술적 근거

본 연구에서 Vision AI 모델로 YOLO 계열을 선택한 데에는 명확한 기술적 근거가 존재한다. YOLO(You Only Look Once)는 2016년 최초 발표 이후 지

속적인 발전을 거듭하며 실시간 객체 탐지 분야에서 가장 널리 사용되는 프레임워크로 자리잡았다. YOLO의 핵심 강점은 빠른 추론 속도, 높은 정확도, 다양한 크기의 객체를 효과적으로 처리하는 구조적 장점에 있으며, 이러한 특성들은 CCTV 관제 도메인의 요구사항과 높은 적합성을 보인다.

첫째, 빠른 추론 속도 측면에서 YOLO는 단일 신경망 통과(single forward pass)만으로 객체의 위치와 클래스를 동시에 예측하는 one-stage 구조를 채택하고 있다. 이는 영역 제안과 분류를 별도로 수행하는 two-stage 탐지기(예: Faster R-CNN)에 비해 현저히 빠른 처리 속도를 제공한다. 실시간 CCTV 분석에서는 다수의 카메라 스트림을 동시에 처리해야 하므로, 추론 속도는 시스템의 실용성을 결정하는 핵심 요소이다. YOLO의 최신 버전들은 일반적인 GPU 환경에서 30-60 FPS 이상의 처리 속도를 달성하여, 실시간 관제 요구를 충족시킨다.

둘째, 높은 정확도 측면에서 YOLO는 지속적인 아키텍처 개선을 통해 정확도 면에서도 경쟁력 있는 성능을 달성해 왔다. 초기 YOLO가 속도는 빠르지만 정확도에서 two-stage 탐지기에 뒤처진다는 비판을 받았던 것과 달리, YOLOv4 이후 버전들은 다양한 학습 기법(Bag of Freebies)과 아키텍처 개선(Bag of Specials)을 통해 COCO 데이터셋 등 벤치마크에서 최고 수준의 mAP를 기록하고 있다. 특히 YOLOv11은 Transformer 기반 어텐션 메커니즘의 통합, 향상된 특징 융합 구조, 최적화된 손실 함수 등을 통해 이전 버전 대비 더욱 향상된 정확도를 제공한다.

셋째, 다중 스케일 객체 탐지 측면에서 YOLO는 Feature Pyramid Network(FPN)와 Path Aggregation Network(PAN)을 결합한 넥(neck) 구조를 통해 다양한 크기의 객체를 효과적으로 탐지한다. CCTV 영상에서는 카메라와의 거리에 따라 동일한 객체가 매우 다른 크기로 나타날 수 있으며, 작은 객체(예: 원거리의 사람)부터 큰 객체(예: 근거리의 차량)까지 모두 정확히 탐지

해야 한다. YOLO의 다중 스케일 특징 융합 구조는 이러한 요구에 효과적으로 대응한다.

넷째, 실무적 적용 용이성 측면에서 YOLO는 풍부한 사전학습 모델, 활발한 커뮤니티 지원, 편리한 학습·배포 파이프라인을 제공한다(Bochkovskiy et al., 2020; Jocher et al., 2023). Ultralytics의 YOLOv5/v8/v11 프레임워크는 PyTorch 기반으로 구현되어 있으며, 명확한 API와 문서화를 통해 커스텀 데이터셋에서의 학습을 용이하게 한다. 또한 ONNX, TensorRT 등 다양한 형식으로의 모델 변환을 지원하여, 엣지 디바이스부터 클라우드 서버까지 다양한 배포 환경에 적용할 수 있다. 이러한 실무적 장점은 연구 결과의 실제 관제센터 도입 가능성을 높인다.

3.3.2 YOLOv11 아키텍처의 구조적 특성

본 연구에서 채택한 YOLOv11-m 모델의 아키텍처는 크게 백본(Backbone), 넥(Neck), 헤드(Head)의 세 부분으로 구성된다. 각 구성요소는 특정 기능을 담당하며, 전체적으로 빠른 속도와 높은 정확도의 균형을 추구하도록 설계되어 있다.⁸⁾

백본(Backbone)은 입력 이미지에서 계층적 특징을 추출하는 역할을 담당한다. YOLOv11은 CSPNet(Cross Stage Partial Network) 기반의 백본을 사용하며, 이는 그래디언트 흐름을 개선하고 연산 효율성을 높이는 구조이다. CSPNet은 특징 맵을 두 부분으로 분할하여 한 부분은 직접 전달하고 다른 부분은 컨볼루션 블록을 통과시킨 후 결합하는 방식으로, 풍부한 그래디언트 정보를 유지하면서도 중복 연산을 줄인다. YOLOv11의 백본에는 Transformer 기반의 어텐션 모듈이 추가되어 글로벌 컨텍스트 정보를 효과적으로 활용할 수 있다. 백본은 입력 이미지를 여러 해상도의 특징 맵으로 변환하며, 이러한 다

8) 동일 장소·카메라에서 촬영된 영상은 서로 유사도가 매우 높아, 일반적인 random split은 성능을 과대추정하는 문제를 야기한다.

중 스케일 특징은 다양한 크기의 객체를 탐지하는 데 활용된다.

넥(Neck)은 백본에서 추출된 다중 스케일 특징을 융합하여 풍부한 표현을 생성하는 역할을 담당한다. YOLOv11은 FPN(Feature Pyramid Network)과 PAN(Path Aggregation Network)을 결합한 구조를 사용한다. FPN은 깊은 층(저해상도, 고의미)에서 얇은 층(고해상도, 저의미)으로 특징을 전달하는 하향식(top-down) 경로를 통해 작은 객체의 탐지 성능을 향상시킨다. PAN은 반대로 얇은 층에서 깊은 층으로의 상향식(bottom-up) 경로를 추가하여 정확한 위치 정보를 깊은 층에 전달한다. 이러한 양방향 특징 융합 구조는 다양한 스케일의 객체를 효과적으로 탐지하는 핵심 메커니즘이다.

분류	내용
Backbone	C3K2 블록을 도입하여 특징 추출(Feature Extraction) 효율을 높였으며, 다양한 스케일의 객체를 포착하기 위한 피라미드 구조를 강화했다.
Head	분류(Classification)와 위치 추정(Localization)을 분리한 Decoupled Head 구조를 채택하여 탐지 정밀도를 향상시켰다.
성능	교통 표지판, 야생 동물, 선박 등 다양한 데이터셋에서 높은 mAP(mean Average Precision)를 기록하며 실시간 관제에 적합한 성능을 보여준다.

[표 1] YOLO 구조

헤드(Head)는 넥에서 전달받은 특징을 기반으로 최종 탐지 결과를 예측하는 역할을 담당한다. 각 출력 위치에서 바운딩 박스 좌표(x, y, 너비, 높이), 객체 존재 확률(objectness score), 그리고 각 클래스에 대한 확률(class probability)을 예측한다. YOLOv11은 디커플드 헤드(decoupled head) 구조를 채택하여, 분류(classification)와 회귀(regression) 작업을 분리된 브랜치에서 처리한다. 이러한 구조는 두 작업 간의 충돌을 줄이고 각각의 최적화를

용이하게 한다. 최종 예측 결과는 Non-Maximum Suppression(NMS)를 통해 중복을 제거하고 최종 탐지 결과로 출력된다.

3.3.3 학습 설정 및 하이퍼파라미터

YOLO 모델의 학습은 CCTV 도메인에 최적화된 하이퍼파라미터 설정을 기반으로 수행되었다. 학습 설정은 기존 연구 및 실험적 탐색을 통해 결정되었으며, 성능과 학습 효율성의 균형을 고려하여 구성되었다.

주요 학습 설정은 다음과 같다. 에폭(Epoch) 수는 100으로 설정하였으며, 이는 모델이 전체 훈련 데이터를 100회 반복 학습하는 것을 의미한다. 배치 크기(Batch Size)는 16으로 설정하여, 메모리 효율성과 학습 안정성의 균형을 맞추었다. 옵티마이저는 SGD(Stochastic Gradient Descent)를 사용하였으며, 모멘텀은 0.937, 가중치 감쇠(weight decay)는 0.0005로 설정하였다. 초기 학습률(Learning Rate)은 0.01로 설정하고, 코사인 어닐링(cosine annealing) 스케줄러를 적용하여 학습이 진행됨에 따라 점진적으로 감소시켰다. 입력 이미지 크기는 640×640 픽셀로 고정하였다.

데이터 분할은 앞서 설명한 Scene-level Split 방식을 적용하였으며, 이는 본 연구 방법론의 핵심 원칙이다. 데이터 증강 기법으로는 Mosaic, Random Affine 변환, HSV 조정 등을 적용하였으며, 이러한 증강은 모델의 일반화 성능 향상에 기여하는 것으로 연구되어 있다. 학습 과정에서는 검증 손실(Validation Loss)을 모니터링하여 Early Stopping을 적용함으로써 과적합을 방지하였다. 구체적으로, 검증 손실이 10 에폭 연속으로 개선되지 않으면 학습을 조기 종료하고, 검증 세트에서 가장 높은 mAP를 기록한 시점의 가중치를 최종 모델로 저장하였다.

3.3.4 Vision AI 모델 성능 평가 지표

Vision AI 모델의 성능 평가는 객체 탐지 분야에서 표준적으로 사용되는 지표들을 활용하여 수행하였다. 이러한 지표들은 모델의 탐지 정확도를 다양한 측면에서 평가할 수 있게 하며, 제4장의 실험결과에서 정량적 성능 비교의 기준이 된다.

정밀도(Precision)는 모델이 양성으로 예측한 것 중 실제로 양성인 비율을 나타낸다. 높은 정밀도는 오탐(false positive)이 적음을 의미한다. 재현율(Recall)은 실제 양성 중 모델이 양성으로 올바르게 예측한 비율을 나타낸다. 높은 재현율은 미탐(false negative)이 적음을 의미한다. CCTV 관제 도메인에서는 특히 재현율의 중요성이 높는데, 이는 위험 상황을 놓치는 것(미탐)이 정상 상황을 위험으로 오판하는 것(오탐)보다 더 심각한 결과를 초래할 수 있기 때문이다. 예를 들어, 낙상 사고를 놓치면 골든타임을 넘겨 생명이 위험해질 수 있으나, 오탐의 경우 추가 확인을 통해 해결될 수 있다.

mAP(mean Average Precision)는 여러 IoU(Intersection over Union) 임계값에서 계산된 평균 정밀도의 평균으로, 객체 탐지 모델의 종합적인 성능을 나타내는 표준 지표이다. mAP50은 IoU 임계값 0.5에서의 mAP를, mAP50-95는 IoU 임계값 0.5부터 0.95까지 0.05 간격으로 계산한 mAP의 평균을 나타낸다. mAP50은 대략적인 위치 정확도를, mAP50-95는 더 엄격한 위치 정확도를 반영한다. F1-score는 정밀도와 재현율의 조화평균으로, 두 지표 간의 균형을 평가하는 데 사용된다. 이러한 지표들을 종합적으로 분석함으로써 모델의 전반적인 탐지 성능을 객관적으로 평가할 수 있다.

지표	정의	공식 수식	의미 / 특징	CCTV 관제에서의 중요성
Precision	모델이 양성으로	$\text{Precision} = \text{TP} / (\text{TP} +$	정밀도가 높을수록	중간 수준 -

(정밀도)	예측한 것 중 실제 양성의 비율	FP)	**오탐(False Positive)**이 적음	오탐은 재확인 가능
Recall (재현율)	실제 양성 중 모델이 양성으로 올바르게 탐지한 비율	$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$	재현율이 높을수록 **미탐(False Negative)**이 적음	최고 중요도 - 미탐은 생명 안전과 직결
F1-score	정밀도와 재현율의 조화 평균	$\text{F1} = \frac{2 \times (\text{Precision} \times \text{Recall})}{(\text{Precision} + \text{Recall})}$	Precision-Recall의 균형 지표	두 지표 간 트레이드오프 평가에 효과적
mAP (mean Average Precision)	여러 IoU 기준에서 계산한 평균 정밀도의 평균	$\text{mAP} = \text{mean}(\text{AP}_{\text{IoU}})$	객체 탐지 모델의 종합 성능 표시	다양한 모델을 비교할 때 기준 지표
mAP50	IoU 0.5 조건에서 계산한 mAP	$\text{AP@IoU}=0.5$	비교적 느슨한 기준 → 대략적 위치 정확도	CCTV에서 빠른 초기 성능 확인 적합
mAP50-95	IoU 0.5~0.95를 0.05 단위로 평균한 mAP	$\text{mAP50-95} = \text{mean}(\text{AP@0.5}, \text{AP@0.55}, \dots, \text{AP@0.95})$	매우 엄격한 기준 → 정밀한 위치 정확도	정교한 주요/행동 분석 평가에 중요

[표 2] 객체 탐지 성능 지표 요약 표

3.4 Video Language Model(VLM) 설계 및 구축

3.4.1 VLM 아키텍처 설계의 기본 원리

본 연구에서 구축한 VLM(Video Language Model)은 비디오 인코더와 대규모 언어 모델(LLM)을 결합한 멀티모달 아키텍처로, 비디오 콘텐츠를 이해하고 자연어로 표현하는 능력을 갖추도록 설계되었다. VLM의 핵심 설계 원리는 세 가지로 요약할 수 있다. 첫째, 비디오의 시공간적 특징을 효과적으로 인코딩하여 시간에 따른 동작의 변화와 의미를 포착한다. 둘째, 인코딩된 시각 정보를 언어 모델의 입력 공간에 정렬(align)하여 시각-언어 간 의미적 연결을 형성한

다. 셋째, 강력한 언어 이해 및 생성 능력을 가진 LLM을 활용하여 상황을 추론하고 자연어로 설명한다(Brown et al., 2020; Touvron et al., 2023).

이러한 설계 원리에 기반하여, 본 연구의 VLM은 VideoMAE를 비디오 인코더로, LLaMA를 언어 모델로 채택하고, 두 모듈을 연결하는 프로젝션 레이어를 구성하였다. 이 구조는 최근 Video-LLaMA, Video-LLaVA 등 주요 Video-LLM 연구에서 채택된 접근 방식과 유사하며, 본 연구에서는 CCTV 도메인의 특성에 맞게 파인튜닝하여 적용하였다.

3.4.2 VideoMAE 기반 비디오 인코더의 구성

VideoMAE(Video Masked Autoencoder)는 자기지도학습(self-supervised learning) 방식으로 비디오의 시공간적 표현을 학습하는 모델로, 본 연구에서 VLM의 비디오 인코더로 채택되었다. VideoMAE의 핵심 원리는 비디오 프레임의 대부분(90% 이상)을 마스킹한 후, 마스킹되지 않은 소수의 패치만으로 전체 비디오를 재구성하도록 학습하는 것이다. 이러한 극단적 마스킹 비율에서 재구성이 가능하려면 모델이 비디오의 깊은 의미적 구조와 시공간적 패턴을 이해해야 하며, 이 과정에서 풍부한 시공간 표현이 학습된다.

VideoMAE가 본 연구의 비디오 인코더로 선택된 이유는 여러 가지가 있다. 첫째, VideoMAE는 적은 레이블 데이터로도 효과적인 학습이 가능하다. 자기지도학습 방식의 사전학습을 통해 대규모 비디오 데이터에서 일반적인 시공간 표현을 학습한 후, 적은 양의 레이블 데이터로 파인튜닝이 가능하다. CCTV 도메인에서는 정확한 이벤트 어노테이션이 포함된 데이터를 대량으로 확보하기 어렵기 때문에, 이러한 데이터 효율적 특성은 매우 중요하다. 둘째, VideoMAE는 메모리 효율성이 높다. 마스킹을 통해 인코더가 처리해야 하는 토큰 수가 크게 줄어들어, 상대적으로 적은 GPU 메모리로도 긴 비디오 시퀀스를 처리할 수 있다. 셋째, VideoMAE는 시간적 변화의 패턴을 정교하게 학습하는 능력이

있어, 행동 인식과 이벤트 탐지에 강점을 보인다.

본 연구에서는 Kinetics-400 데이터셋에서 사전학습된 VideoMAE-Base 모델을 초기 가중치로 사용하였다. VideoMAE는 16프레임의 비디오 클립을 입력으로 받아, 각 프레임을 14×14 크기의 패치로 분할하고 시간 축을 따라 2프레임씩 묶어 시공간 튜브(spatiotemporal tube)로 토큰화한다. 인코더는 ViT(Vision Transformer) 구조를 기반으로 하며, 시공간 어텐션을 통해 프레임 내 공간적 관계와 프레임 간 시간적 관계를 동시에 모델링한다. 최종 출력은 각 시공간 위치에 대한 표현 벡터의 시퀀스로, 이는 후속 프로젝션 레이어를 통해 LLM의 입력 공간으로 변환된다.

3.4.3 LLaMA 기반 언어 모델의 역할

LLaMA(Large Language Model Meta AI)는 Meta에서 개발한 대규모 언어 모델로, 본 연구에서 VLM의 언어 모델 컴포넌트로 채택되었다. LLaMA는 효율적인 아키텍처 설계와 고품질 학습 데이터 큐레이션을 통해, 상대적으로 작은 모델 크기에서도 GPT-3에 필적하는 성능을 달성한 것으로 평가받는다(Brown et al., 2020; Touvron et al., 2023). 또한 오픈소스로 공개되어 연구 커뮤니티에서 널리 활용되고 있으며, 이를 기반으로 한 다양한 파인튜닝 모델(Vicuna, Alpaca 등)이 개발되어 있다.

VLM에서 LLM의 역할은 크게 네 가지로 구분할 수 있다. 첫째, 사건의 의미 이해이다. 비디오 인코더가 추출한 시공간 특징을 기반으로, 영상에서 어떤 상황이 발생하고 있는지를 이해한다. 예를 들어, '한 사람이 바닥에 쓰러져 있으며 주변 사람들이 모여들고 있다'는 상황을 파악한다. 둘째, 원인과 결과의 추론이다. 관찰된 상황의 원인이 무엇인지, 어떤 결과로 이어질 수 있는지를 추론한다. 예를 들어, '이 사람은 갑자기 쓰러졌으며, 의식을 잃은 것으로 보인다. 응급 상황일 가능성이 있다'는 추론을 수행한다.

셋째, 위험도 판단이다. 관찰된 상황이 관제요원의 개입이 필요한 위험 상황 인지, 정상적인 상황인지를 판단한다. 예를 들어, '두 사람이 신체 접촉을 하고 있다'는 관찰에 대해, 맥락 정보를 분석하여 '친근한 인사' 또는 '폭행 상황'으로 구분한다. 넷째, 자연어 보고 생성이다. 분석 결과를 관제요원이 이해하기 쉬운 자연어 형태로 표현한다. 이 기능은 보고서 자동화를 가능하게 하여 관제 업무 효율화에 직접적으로 기여한다. 예를 들어, '2023년 10월 15일 14:23, 지하철역 플랫폼에서 노인으로 추정되는 남성이 갑자기 쓰러졌습니다. 의식 상실이 의심되며, 응급 대응이 필요할 것으로 판단됩니다.'와 같은 형태의 보고를 생성한다.

3.4.4 VLM 학습 전략: 프로젝션 레이어와 파인튜닝

VLM의 학습에서 핵심적인 도전 과제는 사전학습된 비디오 인코더와 언어 모델을 효과적으로 연결하여 시각-언어 정렬(vision-language alignment)을 달성하는 것이다. 본 연구에서는 최근 VLM 연구들에서 효과적인 것으로 입증된 학습 전략을 채택하였다(Wang et al., 2023; Liu et al., 2023). 구체적으로, 비디오 인코더(VideoMAE)는 동결(freeze)하고, 프로젝션 레이어와 LLM의 일부 레이어만 미세조정(fine-tuning)하는 방식을 사용하였다.⁹⁾

이러한 부분 동결 전략은 여러 가지 이점을 제공한다. 첫째, 연산량 감소이다. 대규모 모델 전체를 학습하는 것은 막대한 연산 자원을 요구하지만, 일부 레이어만 학습할 경우 GPU 메모리와 학습 시간을 크게 절약할 수 있다. 둘째, 과적합 방지이다. CCTV 도메인의 학습 데이터가 상대적으로 적은 상황에서 전체 모델을 학습하면 과적합의 위험이 높지만, 사전학습된 지식을 유지하면서 일부만 조정하면 일반화 능력을 보존할 수 있다. 셋째, CCTV 도메인 적응(domain adaptation)이다. 일반적인 비디오와 자연어에서 학습된 사전지식을

9) Video Encoder와 LLM 사이 feature alignment를 담당하며, VLM 성능의 결정적 요소로 전체 파라미터의 1% 이하만 조정해도 효과가 크다.

유지하면서, CCTV 특유의 장면, 이벤트, 표현 방식에 적응하도록 한다.

프로젝션 레이어는 비디오 인코더의 출력 차원을 LLM의 입력 차원에 맞추는 역할을 하며, 동시에 시각 표현을 언어 공간에 정렬하는 기능을 수행한다. 본 연구에서는 2층 MLP(Multi-Layer Perceptron) 구조의 프로젝트 레이어를 사용하였으며, GELU 활성화 함수를 적용하였다. LLM의 경우, 마지막 몇 개의 Transformer 레이어와 출력 레이어만 학습하도록 설정하였다. 파인튜닝 데이터에는 CCTV 영상에 대한 사건 설명 텍스트, 질의응답(Q&A) 형태의 추론 데이터, 장면 기반 시나리오 분석 문장 등이 포함되었다. 이를 통해 모델은 CCTV 도메인에서 요구되는 상황 이해와 설명 생성 능력을 획득하게 된다.

3.5 하이브리드 Trigger-Validator 구조 설계

3.5.1 하이브리드 구조의 설계 원리

본 연구에서 제안하는 Trigger-Validator 하이브리드 구조는 Vision AI 모델과 VLM의 상보적 특성을 활용하여 CCTV 관제 시스템의 효과성을 극대화하기 위해 설계되었다. 이 구조의 핵심 원리는 역할 분담(division of labor)에 있다. Vision AI 모델은 빠른 속도의 장점을 활용하여 전체 비디오 스트림에서 이상 상황의 '후보'를 실시간으로 탐지하는 Trigger 역할을 수행하고, VLM은 의미 기반 분석 능력을 활용하여 Trigger가 탐지한 후보를 검증하고 상세 분석하는 Validator 역할을 수행한다.

이러한 역할 분담 구조의 핵심 장점은 각 기술의 약점을 상대 기술의 강점으로 보완할 수 있다는 점이다. Vision AI 모델의 약점인 의미 이해 부족은 VLM의 시공간적 맥락 분석으로 보완된다. VLM의 약점인 높은 연산 비용은 Vision AI 모델의 사전 필터링으로 해결된다. 또한 VLM의 환각 위험은 Vision AI 모델의 초기 탐지 결과와의 교차 검증을 통해 완화될 수 있다. 결과적으로, 하이

브리드 구조는 단독 사용 대비 오탐 감소, 미탐 보완, 연산 효율성 확보라는 세 가지 목표를 동시에 달성할 수 있다.

3.5.2 Trigger 단계: Vision AI 모델의 역할과 작동 방식

Trigger 단계에서 Vision AI 모델은 실시간 CCTV 영상을 분석하여 이벤트 발생 가능성을 탐지하는 1차 필터 역할을 수행한다. 구체적인 작동 방식은 다음과 같다. 먼저, CCTV 스트림에서 프레임을 추출하여 YOLO 모델에 입력한다. 본 연구에서는 1 FPS로 샘플링하여 연산 효율성을 유지하면서도 실시간 모니터링이 가능하도록 하였다. YOLO 모델은 각 프레임에서 관심 객체(사람, 연기 등)를 탐지하고, 각 탐지에 대해 클래스 레이블과 신뢰도 점수(confidence score)를 출력한다.

탐지된 객체들은 사전에 정의된 임계값(threshold)과 비교된다. 신뢰도 점수가 임계값을 초과하는 탐지가 발생하면, 해당 시점을 중심으로 전후 몇 초간의 비디오 클립을 추출하여 이벤트 후보로 생성한다. 이 과정에서 이벤트 발생 시간, 카메라 ID, 바운딩 박스 좌표, 탐지 클래스, 신뢰도 점수 등의 메타데이터가 함께 기록된다. 임계값 설정은 오탐과 미탐 간의 균형을 고려하여 결정된다. 높은 임계값은 오탐을 줄이지만 미탐을 증가시키고, 낮은 임계값은 반대의 효과를 가져온다. 본 연구의 하이브리드 구조에서는 VLM이 후속 검증을 수행하므로, Trigger 단계의 임계값을 다소 낮게 설정하여 미탐을 최소화하고 오탐은 Validator 단계에서 제거하는 전략을 채택하였다.

Trigger 단계의 핵심 가치는 전체 CCTV 스트림을 VLM으로 처리할 필요 없이 의심스러운 이벤트 후보만을 선별하여 VLM에 전달한다는 점이다. 실제 CCTV 환경에서 대부분의 시간은 특별한 이벤트 없이 정상 상황이 지속된다. Trigger 단계가 이러한 정상 상황을 필터링함으로써, VLM의 연산 부담이 획

기적으로 감소한다. 예를 들어, 100대의 카메라를 모니터링하는 상황에서 평균적으로 시간당 10건의 이벤트 후보가 발생한다면, VLM은 100개의 연속 스트림이 아닌 시간당 10개의 짧은 클립만 분석하면 된다. 이러한 선별적 처리가 하이브리드 구조의 현실적 구현 가능성을 확보하는 핵심 메커니즘이다.

3.5.3 Validator 단계: VLM의 역할과 작동 방식

Validator 단계에서 VLM은 Trigger 단계에서 전달받은 이벤트 후보 클립을 심층 분석하여 최종 판단을 내리는 역할을 수행한다(Tong et al., 2022; Touvron et al., 2023; Wang et al., 2023; Liu et al., 2023). VLM의 분석은 단순한 이진 분류(위험/정상)를 넘어서 상황의 의미를 이해하고 추론하는 고차원적 과정이다. 구체적인 작동 방식은 다음과 같다.

먼저, VLM은 전달받은 비디오 클립을 VideoMAE 인코더를 통해 시공간 특징으로 변환한다. 이 과정에서 클립 내의 동작 변화, 객체 간 상호작용, 장면의 시간적 전개 등이 포착된다. 다음으로, 인코딩된 특징은 프로젝션 레이어를 통해 LLM의 입력 공간으로 변환되어, LLM이 시각 정보를 '이해'할 수 있게 된다. LLM은 이 시각 정보와 함께 분석 지시문(prompt)을 입력으로 받아 상황을 분석한다. 분석 지시문은 '이 영상에서 어떤 상황이 발생하고 있습니까? 위험 상황이라면 그 이유를 설명하십시오.'와 같은 형태로 구성된다.

VLM의 분석 결과는 크게 세 가지 유형의 출력으로 구성된다. 첫째, 사건 분류이다. Vision AI 모델이 탐지한 이벤트 후보가 실제로 해당 유형의 이벤트인지, 아니면 오탐인지를 판단한다. 예를 들어, '쓰러짐'으로 탐지된 후보에 대해 실제 낙상인지 물건을 줍기 위한 숙임인지를 구분한다. 둘째, 위험도 평가이다. 이벤트가 확인된 경우 그 심각도와 긴급성을 평가한다. 동일한 '쓰러짐'이라도 의식 상실이 동반된 경우와 단순 넘어짐의 위험도는 다르다. 셋째, 자연어 설명 생성이다. 분석 결과를 관제요원이 이해하기 쉬운 자연어로 표현한다. 이

설명은 관제 보고서 작성의 기초 자료로 활용될 수 있다.

Validator 단계는 Vision AI 모델의 오탐을 제거하는 핵심 메커니즘이다. Vision AI 모델이 단일 프레임 분석으로 인해 '폭행'으로 오탐한 경우, VLM은 전후 맥락을 분석하여 실제로는 '친근한 신체 접촉'임을 판단할 수 있다. 또한 VLM은 Vision AI 모델이 놓친 사건을 보완하는 역할도 수행할 수 있다. Trigger 단계에서 낮은 임계값으로 인해 포함된 약한 탐지 신호 중에서, VLM이 시간적 맥락 분석을 통해 실제 이벤트임을 확인하는 경우가 이에 해당한다. 이러한 상호 보완적 작동을 통해 하이브리드 구조는 단독 모델 대비 우수한 탐지 성능을 달성한다.

3.5.4 하이브리드 구조의 정당성과 기대 효과

본 연구가 제안하는 Trigger-Validator 하이브리드 구조의 정당성은 여러 관점에서 뒷받침된다. 기술적 관점에서, 이 구조는 Vision AI 모델의 장점(속도)과 VLM의 장점(의미 해석)을 결합하여 각 기술이 단독으로는 달성할 수 없는 성능을 제공한다(Wang et al., 2023; Liu et al., 2023). 앞서 논의한 바와 같이, Vision AI 모델 단독으로는 오탐이 빈번하고 VLM 단독으로는 실시간 처리가 불가능하지만, 두 기술의 결합은 이러한 한계를 상호 보완한다.

운영적 관점에서, 하이브리드 구조는 실제 관제센터 환경에서 실현 가능한 유일한 고도화 방안이다. 현재의 하드웨어 기술과 비용 제약 하에서 수백 대의 CCTV를 VLM으로 상시 분석하는 것은 비현실적이다. 그러나 Trigger-Validator 구조에서는 VLM의 연산이 선별된 이벤트 후보에 한정되므로, 합리적인 수준의 인프라 투자로도 도입이 가능하다. 또한 이 구조는 기존 Vision AI 모델기반 시스템에 VLM을 추가하는 형태로 점진적 도입이 가능하며, 관제센터의 시스템 전환 부담을 줄인다.

사용자 관점에서, 하이브리드 구조는 관제요원의 업무 효율화와 인지 부담

완화에 직접적으로 기여한다. 오탐 감소로 인해 불필요한 경보 검토가 줄어들고, VLM이 생성하는 자연어 설명을 통해 상황 파악이 용이해진다. 또한 보고서 자동 생성 기능은 행정적 업무 부담을 줄여 관제요원이 본연의 감시 업무에 집중할 수 있게 한다. 이러한 다각적인 정당성에 기반하여, 본 연구의 하이브리드 구조는 제4장의 실험에서 그 효과성을 검증하고, 제5장에서 실무적·학술적 가치를 논의하게 된다.

3.6 평가 방법 설계

3.6.1 정량 평가 지표와 측정 방법

본 연구의 실험결과를 객관적으로 평가하기 위해 다양한 정량 평가 지표를 설계하고 적용하였다. 정량 평가는 Vision AI 모델 단독, VLM 단독(샘플링 기반), 그리고 하이브리드 구조의 성능을 동일한 기준에서 비교하여, 제4장에서 각 접근 방식의 상대적 우열을 명확히 제시하는 데 목적이 있다.

기본 탐지 성능 지표로는 앞서 설명한 정밀도(Precision), 재현율(Recall), mAP50, mAP50-95, F1-score를 사용한다. 이러한 지표들은 모델의 탐지 정확도를 다양한 측면에서 평가한다. 특히 CCTV 관제 도메인의 특성을 고려하여, 재현율(미탐 방지)에 높은 가중치를 두어 해석한다. 오탐률과 미탐률도 별도로 측정하여, 각 모델의 오류 특성을 분석한다. 오탐률은 모델이 위험으로 판단한 것 중 실제로는 정상인 비율이며, 미탐률은 실제 위험 상황 중 모델이 탐지하지 못한 비율이다.

하이브리드 구조의 효과를 평가하기 위한 추가 지표로, 오탐 감소율과 미탐 보완율을 정의하였다. 오탐 감소율은 Vision AI 모델 단독 대비 하이브리드 구조에서 오탐이 얼마나 감소했는지를 백분율로 나타낸다. 미탐 보완율은 Vision AI 모델이 놓친 이벤트 중 VLM이 추가로 탐지한 비율을 나타낸다(Wang et

al., 2023; Liu et al., 2023). 이러한 지표들은 하이브리드 구조의 핵심 가치인 '오탐 감소, 미탐 보완'을 직접적으로 측정한다. 연산 효율성 측면에서는 처리 지연 시간(latency)과 GPU 사용량을 측정하여, 각 접근 방식의 연산 비용을 비교한다.

3.6.2 정성 평가: 추론 품질과 실무 적합성

정량 지표만으로는 CCTV 관제 시스템의 실질적 가치를 완전히 평가하기 어렵다. 따라서 본 연구에서는 정성 평가를 병행하여 모델의 추론 품질과 실무 적합성을 다각적으로 분석한다. 정성 평가는 크게 세 가지 영역에서 수행된다.

첫째, VLM의 사건 설명 품질을 평가한다. VLM이 생성하는 자연어 설명의 정확성, 논리성, 완결성, 유용성 등을 전문가가 평가한다. 정확성은 설명 내용이 실제 영상의 내용과 일치하는지를, 논리성은 인과관계와 추론이 타당한지를, 완결성은 중요 정보가 누락 없이 포함되었는지를, 유용성은 관제요원의 의사결정에 도움이 되는지를 평가한다. 이러한 평가는 5점 리커트 척도로 측정되며, 복수의 평가자 간 일치도(inter-rater reliability)를 함께 보고한다.

둘째, 행동 의미 해석의 정확성을 평가한다. 시각적으로 유사하지만 의미론적으로 다른 상황들—숙임 vs 낙상, 장난 vs 폭행, 수증기 vs 연기 등—에 대한 모델의 구분 능력을 평가한다. 이는 혼동 행렬(confusion matrix) 형태로 제시되며, 어떤 유형의 상황에서 오류가 발생하는지를 분석한다. 이러한 분석은 모델의 강점과 약점을 파악하고, 향후 개선 방향을 도출하는 데 활용된다.

셋째, 실제 관제요원의 평가를 수행한다. 협력 관제센터의 관제요원들을 대상으로 하이브리드 시스템의 사용 경험에 대한 피드백을 수집한다. 평가 항목에는 시스템의 직관성, 경보의 신뢰성, 자연어 설명의 유용성, 업무 효율화 체감 정도, 전반적인 만족도 등이 포함된다. 이러한 현장 기반 평가는 기술적 성

능 지표만으로는 파악하기 어려운 실무적 가치를 확인하는 데 중요한 역할을 한다.

3.6.3 관제센터 운영 효율성 평가

본 연구의 궁극적인 목표 중 하나는 관제센터의 운영 효율성을 향상시키는 것이다. 따라서 기술적 탐지 성능 외에도 실제 관제 업무에 미치는 영향을 평가하는 지표를 설계하였다. 운영 효율성 평가는 사건 검토 시간, 보고서 작성 시간, 불필요 대응 감소 효과, 관제요원 피로도의 네 가지 항목으로 구성된다.

사건 검토 시간은 정보 발생부터 관제요원이 해당 이벤트를 확인하고 판단을 내리기까지 소요되는 시간을 측정한다. 하이브리드 시스템에서 VLM이 제공하는 상황 설명은 관제요원의 빠른 판단을 지원하므로, Vision AI 모델 단독 시스템 대비 검토 시간이 단축될 것으로 예상된다. 보고서 작성 시간은 사건 발생 후 공식 보고서를 완성하기까지 소요되는 시간을 측정한다. VLM이 생성하는 자연어 설명을 보고서의 기초 자료로 활용할 경우, 작성 시간이 크게 단축될 것으로 기대된다.

불필요 대응 감소 효과는 오탐으로 인한 출동 또는 조치가 감소한 정도를 측정한다. 오탐이 감소하면 경찰, 소방, 보안 요원 등의 불필요한 출동이 줄어들어 자원 효율성이 향상된다. 관제요원 피로도는 장시간 근무에 따른 인지적·신체적 피로의 변화를 평가한다. 이는 표준화된 피로도 설문지와 인터뷰를 통해 측정되며, 오탐 감소와 업무 지원 기능이 피로도 완화에 기여하는지를 분석한다. 이러한 운영 효율성 지표들은 제4장의 실험결과에서 제시되며, 제5장에서 실무적 의미를 논의하는 근거가 된다.

3.7 연구 방법의 종합 정리

본 장에서 기술한 연구 방법론은 CCTV 영상의 구조적 특성과 현실적 관제 운영 환경을 반영하여 체계적으로 설계되었다. 연구 방법론의 각 구성요소는 서로 유기적으로 연결되어 있으며, 궁극적으로 제4장의 실험결과 도출과 제5장의 결론 및 향후 연구 방향 설정을 위한 견고한 기반을 제공한다.

Scene-level Split 기반 데이터셋 설계는 CCTV 도메인 특유의 배경 편향 문제를 해결하고 모델의 일반화 성능을 신뢰성 있게 평가하기 위한 핵심 방법론이다. 이 설계를 통해 제4장의 실험결과가 실제 현장 배치 시의 예상 성능을 정확히 반영하게 되며, 제5장에서 Scene-level Split이 CCTV AI 연구의 필수적 표준이 되어야 함을 주장할 수 있다. YOLO 기반 Vision AI 모델의 학습과 평가는 실시간 탐지의 기술적 가능성과 단일 프레임 분석의 한계를 동시에 확인하기 위해 설계되었다(Redmon et al., 2016; Bochkovskiy et al., 2020; Jocher et al., 2023). 제4장에서 Vision AI 모델의 정량적 성능과 오탐·미탐 분석을 통해 그 한계를 실증하고, 제5장에서 Vision AI 모델 단독 사용의 부적절성을 결론으로 도출한다.

VideoMAE-LLaMA 기반 VLM의 구축과 평가는 의미 기반 분석의 가치와 실시간 적용의 어려움을 확인하기 위해 설계되었다. 제4장에서 VLM의 우수한 추론 능력과 연산 비용 문제를 제시하고, 제5장에서 VLM 단독 사용의 비현실성을 결론으로 도출한다. Trigger-Validator 하이브리드 구조의 설계와 평가는 두 기술의 결합이 실제로 단독 사용보다 우수함을 검증하기 위해 설계되었다. 제4장에서 오탐 감소, 미탐 보완, 운영 효율성 개선을 정량적·정성적으로 제시하고, 제5장에서 하이브리드 구조가 CCTV 관제의 최적 해법임을 결론으로 도출한다.

결론적으로, Vision AI 모델이 갖는 속도와 효율성, VLM이 제공하는 의미 기반 분석 능력은 서로 상호보완적이기 때문에, 하이브리드 구조는 실무 적용성과 기술적 성능을 동시에 만족시키는 최적의 접근 방식이다. 본 연구의 방법

론은 이러한 결론을 체계적으로 도출하기 위한 논리적 기반을 제공하며, Scene-level Split 데이터셋 설계, 정량·정성 평가 지표의 종합적 적용, 현장 기반 효율성 평가의 포함 등을 통해 학술적 엄밀성과 실무적 유용성을 동시에 추구하였다. 이러한 방법론적 기반 위에서 수행된 실험결과와 그로부터 도출되는 결론은 CCTV AI 연구 분야에 의미 있는 기여를 제공할 것으로 기대된다.

제4장 실험결과

본 장에서는 Vision AI 모델(YOLO 기반 모델), Video Language Model(VLM), 그리고 본 연구에서 제안한 Trigger-Validator 방식의 하이브리드 모델을 비교·평가한 실험 결과를 상세히 제시한다. 실험은 제3장에서 기술한 연구 방법론에 따라 Scene-level Split 방식으로 구성된 CCTV 데이터셋을 기반으로 수행하였으며, 이는 기존 연구에서 문제가 되었던 배경 편향과 일반화 실패 문제를 해결하는 데 효과적이었다. 본 장의 실험결과는 Vision AI 모델과 VLM 각각이 가진 구조적 한계를 실증적으로 확인하고, 하이브리드 모델이 실제 관제 업무 효율성과 탐지 성능을 동시에 향상시킬 수 있음을 검증하는 것을 목표로 한다.

실험 설계에 있어 핵심적으로 고려한 사항은 실험의 재현 가능성과 결과의 신뢰성 확보이다. 모든 실험은 동일한 하드웨어 환경에서 수행되었으며, 실험 설정, 하이퍼파라미터, 데이터셋 버전, 모델 체크포인트 등을 체계적으로 기록하여 추후 재현이 가능하도록 하였다. 또한 정량적 평가와 정성적 평가를 병행하여 모델의 성능을 다각도로 분석하였으며, 실제 관제센터 환경을 모사한 시나리오 기반 테스트를 통해 실무적 적용 가능성을 검증하였다.

4.1 실험 환경

4.1.1 하드웨어 및 소프트웨어 구성

모든 실험은 고성능 GPU 기반의 리눅스 서버 환경에서 수행되었다. Vision AI 모델 (YOLOv11)의 학습과 추론은 NVIDIA RTX 4090(24GB VRAM) 및 A100 80GB 환경에서 진행하였으며, VLM(VideoMAE 기반 인코더 + LLaMA 기반 언어 모델)은 비디오 인코더의 메모리 요구량이 크기 때문에 주로 A100

80GB 환경에서 수행되었다. 이러한 하드웨어 구성은 기존 연구들에서 VLM 계열 모델이 대규모 GPU 메모리를 필요로 한다는 보고와 일치하며, 실제 관제센터에서 중앙 서버 기반 AI 분석 시스템을 구축할 때 고려되는 기술 기준과도 부합한다.

서버의 세부 구성은 다음과 같다. GPU는 NVIDIA A100 80GB 1대 또는 RTX 4090 24GB 1대를 사용하였으며, CPU는 AMD EPYC 7543 32코어 프로세서를 탑재하였다. 시스템 메모리는 256GB DDR4로 구성하여 대용량 데이터셋 로딩과 배치 처리에 충분한 여유를 확보하였다. 스토리지는 NVMe SSD를 사용하여 고속 I/O 환경을 구축하였으며, 대용량 CCTV 영상 데이터와 AI-Hub 데이터셋은 외장 SSD(EXT4 파일시스템)에 저장하여 실험에 사용되는 학습·검증·테스트 데이터를 직접 로딩하였다.

구분	구성 내용
GPU	NVIDIA RTX 4090 (24GB VRAM) - YOLOv11 학습·추론 NVIDIA A100 80GB - YOLOv11 및 VLM (VideoMAE + LLaMA) 주 력 실험
CPU	AMD EPYC 7543 (32 cores)
시스템 메모리	256GB DDR4
스토리지	NVMe SSD 기반 고속 I/O 환경 대용량 CCTV·AI-Hub 데이터는 EXT4 외장 SSD에서 직접 로딩
특징	VLM은 시공간 처리 요구량으로 인해 A100 80GB 환경에서 주로 수행

[표 3] 실험 하드웨어 환경 요약

소프트웨어 환경으로는 Ubuntu 22.04 LTS 운영체제 위에 PyTorch 2.1 프레임워크를 기반으로 실험을 수행하였다. Vision AI 모델은 Ultralytics에서 제공하는 YOLOv11 공식 구현을 사용하였으며, VLM은 VideoLLaMA 계열의 오픈소스 구현을 기반으로 구축하였다. 파이썬 실행 환경은 uv venv를 활용하여 프로젝트별 가상환경을 분리함으로써 패키지 의존성 충돌을 방지하고 실험

환경의 재현성을 확보하였다. 실험 결과의 추적과 시각화를 위해 Weights & Biases(W&B)를 활용하여, 학습 곡선, 평가 지표, 하이퍼파라미터 등을 체계적으로 기록하고 비교 분석이 가능하도록 하였다.

구분	구성 내용
운영체제	Ubuntu 22.04 LTS
딥러닝 프레임워크	PyTorch 2.1
Vision AI 모델	Ultralytics YOLOv11 공식 구현 사용
VLM 모델	VideoMAE 기반 비디오 인코더 + LLaMA 기반 언어 모델 VideoLLaMA오픈소스구현활용
파이썬 환경	uv venv 기반 가상환경 분리(재현성 확보)
실험 관리	Weights & Biases(W&B)를 통해 학습 곡선·지표·파라미터 기록 및 시각화

[표 4] 실험 소프트웨어 환경 요약

4.1.2 데이터셋 구성 및 전처리 절차

본 연구에서 사용된 데이터셋은 AI-Hub에서 제공하는 CCTV 기반 지능형 관제 서비스 데이터와 이상행동 데이터를 포함한 다양한 도메인의 영상으로 구성되었다. 데이터셋은 AI-Hub 공식 CLI 도구(aihubshell)를 이용해 다운로드 하였으며, 총 550개 이상의 고유한 CCTV Scene을 포함하고 있다. 주요 이벤트 클래스는 침입(intrusion), 쓰러짐/실신(fall/swoon), 싸움/폭행(fight/violence), 군집/인파 밀집(crowding), 침수(flood), 화재(fire) 등으로 구성되며, 이들은 실제 관제 업무에서 가장 높은 우선순위를 가지는 탐지 대상이다.

사람 감지 및 군중 분석을 위해서는 AI-Hub의 실내외 군중 식별 데이터, 유동 인구 분석용 CCTV 영상 데이터, 그리고 CrowdHuman 데이터셋을 병합하

여 사용하였다. 쓰러짐(fall) 상황은 실신(swoon) 데이터셋을 활용하여 테스트 셋 및 부분 학습용 데이터로 사용하였다. 다만, 스튜디오 환경(크로마키 배경 등)에서 촬영된 데이터는 실제 CCTV 도메인과의 차이가 크므로, 필터링 및 전처리를 통해 실제 환경과 유사한 데이터만을 선별적으로 사용하였다.

데이터셋의 분할은 제3장에서 기술한 Scene-level Split 방식을 엄격히 적용하여, 학습/검증/테스트 세트 간에 동일 장면이 중복되지 않도록 구성하였다. 구체적으로, 전체 Scene을 훈련용 약 65%, 검증용 약 15%, 테스트용 약 20%의 비율로 분할하였다. 이를 통해 데이터 누수를 방지하고, 실제 운영 환경에서의 일반화 성능을 보다 정확히 추정할 수 있도록 하였다. 각 분할 세트 내에서 이벤트 클래스의 분포가 균형을 이루도록 계층적 샘플링(stratified sampling)을 적용하였다.

4.1.3 단계적 샘플링 기반 실험 전략

초기 단계부터 전체 데이터셋을 한 번에 학습시키는 것은 비효율적이며 문제 진단이 어렵기 때문에, 본 연구에서는 단계적 샘플링 기반의 3단계 실험 전략을 도입하여 모델의 수렴 경향과 도메인 적합성을 체계적으로 검증하였다. 이러한 접근은 대규모 딥러닝 프로젝트에서 권장되는 모범 사례와 일치한다.

첫 번째 단계인 Small Subset(1-2%)에서는 각 클래스 및 장면(Scene)을 대표할 수 있는 소량의 샘플만을 선별하여 사용하였다. 이 단계의 목적은 데이터 구조 및 라벨링 품질을 검증하고, 학습 파이프라인의 오류를 조기에 발견하여 수정하는 것이다. 또한 모델이 기본적으로 수렴하는지, 손실 함수가 적절히 감소하는지 등을 확인하여 후속 실험의 기반을 마련하였다.

두 번째 단계인 Medium Subset(10-20%)에서는 클래스별/Scene별 분포를 어느 정도 반영하는 수준으로 데이터를 확장하였다. 이 단계에서는 주요 하이퍼파라미터 탐색을 수행하고, 데이터 증강 기법 적용 여부에 따른 성능 비교

실험을 진행하였다. 구체적으로, 무증강(no augmentation) 설정과 CCTV 도메인 맞춤 증강(조도 변화, 노이즈, 카메라 각도 변형 등) 설정을 비교하여 증강의 효과를 정량화하였다.

세 번째 단계인 Full Dataset(100%)에서는 앞선 단계에서 검증된 설정과 파이프라인을 기반으로 전체 데이터셋 학습을 수행하였다. 이 단계에서 최종 성능 확보 및 일반화 성능 평가가 이루어졌으며, Early Stopping, 모델 크기 변경(m, l, x), 학습 전략 조정 등을 포함한 반복 실험을 통해 최적 모델을 선정하였다. 특히 성능 요구가 높은 태스크(화재 탐지, 쓰러짐 탐지 등)에 대해서는 전용 모델 또는 추가 파인튜닝을 수행하여 성능을 극대화하였다.

4.2 Vision AI 모델 실험결과

4.2.1 Vision AI 모델 구성 및 태스크 정의

본 연구의 Vision AI 모델은 Ultralytics YOLO 계열을 기반으로 구성하였으며, 우선적으로 YOLO-m(medium) 크기를 기본 모델로 채택하였다. YOLO-m은 속도와 정확도 사이의 균형이 우수하여 실시간 CCTV 분석에 적합한 것으로 알려져 있으며, 필요 시 일부 태스크에 대해 YOLO-l(large), YOLO-x(extra-large) 등 상위 모델을 고려하는 전략을 사용하였다. 모델 선택에 있어서는 추론 속도, GPU 메모리 사용량, 탐지 정확도를 종합적으로 고려하였다.

Vision AI 모델 이 담당하는 주요 태스크는 다음과 같이 정의되었다. 첫째, 화재 상황 감지 태스크는 실내/실외 일반 환경 및 주차장에서의 화재를 탐지하며, 연기(smoke)와 불꽃(flame) 클래스 및 주변 객체(차량, 사람 등)를 함께 인식한다. 둘째, 안전장비 착용 여부 검사 태스크는 헬멧, 안전화, 안전벨트 등의 착용 여부를 분류하는 객체 검출 과제로, 향후 스마트빌딩 및 산업안전 도메인

과의 연계를 고려하여 설계되었다. 셋째, 사람 쓰러짐(fall) 감지 태스크는 실신(swoon) 데이터 및 실제 CCTV 영상을 활용한 낙상 인식으로, 바운딩 박스 종횡비(aspect ratio), 키포인트 궤적(keypoint trajectory) 등의 추가 피처 활용 가능성을 검토하였다. 넷째, 주차장 화재 및 이상행동 탐지 태스크는 주차장 내 차량 화재, 사람 쓰러짐, 군중 이동 패턴 등을 복합적으로 분석한다.

4.2.2 YOLOv11-m 모델의 정량적 성능 평가

YOLOv11-m 모델의 성능은 Precision, Recall, mAP50, mAP50-95 기준으로 측정되었다. Full Dataset 학습 후 테스트 세트에서 측정된 결과, 명확한 형태의 객체(예: 사람, 군중, 차량)에서는 상대적으로 높은 mAP50 값을 기록하였다. 특히 사람(Person) 클래스는 mAP50 기준 약 0.85 이상의 성능을 보여 전반적으로 양호한 탐지 능력을 확인하였다. 그러나 행동 기반 클래스(폭행, 쓰러짐, 연기 등)에서는 성능이 예상보다 낮게 나타났으며, 이러한 결과는 기존 연구에서도 보고된 바 있는 Vision AI 모델의 구조적 한계를 재확인시켜 주었다.

클래스별 성능 분석 결과, 화재(Fire) 클래스에서는 감지 도중 끊김(Detection Missing) 현상이 발생하는 구간이 확인되었다. 이는 연기의 농도가 점진적으로 변화하거나, 화염의 형태가 불규칙하게 변동하는 경우 연속적인 탐지가 어려움을 의미한다. 안전장비(PPE) 클래스에서는 특히 미착용(Off) 상태에 대한 탐지 성능이 저조하게 나타났는데, 이는 '착용하지 않음'이라는 부정적 상태를 시각적으로 정의하는 것이 본질적으로 어렵기 때문이다. 분실물(Lost Item) 클래스에서는 스마트폰과 같은 소형 객체(Small Object)의 경우 크기가 너무 작고 검증 데이터가 부족하여 탐지 성능이 매우 낮았다.

이러한 클래스별 성능 불균형 문제를 해결하기 위해 다양한 개선 전략을 시도하였다. 데이터 불균형 해소를 위해 기존 객체 수(Object count) 기준에서

이미지 수(Image count) 기준으로 비율을 조정하고, 화재 데이터셋 내 정상 (Background) 이미지 비율을 조정하였다. 클래스 단순화 전략으로 안전장비 클래스를 기존 8개(4종 × 착용/미착용)에서 '착용' 4개 클래스로 축소하여 클래스 복잡도를 낮추었다. 분실물 탐지 대상은 소형 객체(스마트폰) 대신 가방 (Bag)으로 변경하여 탐지 가능성을 높였으며, 사람 탐지에는 객체 밀도가 과도하게 높은 CrowdHuman(평균 25객체/이미지) 대신 적절한 난이도의 COCO 또는 OpenImages 데이터셋을 활용하였다.

클래스	mAP50	Precision	Recall
침입(Intrusion)	0.93	0.92	0.94
쓰러짐(Fall)	0.78	0.74	0.81
폭행(Fight)	0.72	0.69	0.75
연기/화재	0.69	0.63	0.68
PPE 미착용	0.84	0.86	0.82
분실물	0.58	0.55	0.62
전체 평균	0.76	0.73	0.77

[표 5] YOLO Test 결과

4.2.3 Vision AI 모델의 오탐 및 미탐 분석

Vision AI 모델의 오류 유형을 심층 분석한 결과, 오탐(False Positive)과 미탐(False Negative) 모두에서 특징적인 패턴이 확인되었다. 이러한 분석은 하이브리드 구조에서 VLM이 보완해야 할 영역을 식별하는 데 중요한 근거가 된다.

오탐(False Positive)의 대표적인 유형은 다음과 같다. 첫째, 쓰러짐으로의 오탐 사례에서, 실제로는 물건을 줍기 위한 숙임 행동이나 신발끈을 묶는 동작이 낙상으로 잘못 인식되는 경우가 빈번하게 발생하였다. 둘째, 폭행으로의 오탐 사례에서, 친근한 신체 접촉(포옹, 악수, 어깨 두드림 등)이나 장난스러운 행

동이 폭행으로 오인되었다. 셋째, 연기로의 오탐 사례에서, 빛 반사, 먼지, 수증기, 안개 등이 화재 연기로 잘못 탐지되었다.¹⁰⁾ 이러한 오탐들은 Vision AI 모델이 단일 프레임 판단에 의존하며, 동작의 의도나 상황의 맥락을 파악할 수 없다는 구조적 한계와 직접적으로 연관된다.

미탐(False Negative)의 대표적인 유형도 분석되었다. 첫째, 폭행 행동이 아주 짧은 시간(1-2초) 동안만 나타난 경우, 샘플링된 프레임에서 해당 순간이 포착되지 않아 탐지에 실패하였다. 둘째, 점진적 쓰러짐-천천히 주저앉거나 벽에 기대어 미끄러지는 경우-이 급격한 낙상과 달리 '일상 동작'으로 오판되었다. 셋째, 희미한 연기 초기 단계나 화면 가장자리에서 발생한 연기가 감지되지 못하였다. 이러한 미탐들은 Vision AI 모델이 시간적 정보를 해석하지 못하고 동작의 연속성을 고려하지 않는다는 사실을 재확인시켜 주었다.

4.2.4 Vision AI 모델의 한계에 대한 실증적 논의

본 실험 결과는 Vision AI 모델이 객체 탐지 성능 자체는 우수하지만, 의미 기반 판단이 필요하거나 행동의 연속성을 고려해야 하는 상황에서는 본질적 한계가 존재함을 실증적으로 확인하였다. 이러한 결과는 여러 선행 연구들에서도 일관되게 보고되어 왔다. Vision AI 모델만으로는 정교한 행동 분석이 어렵고, 사건의 문맥을 이해해야 하는 실무적 환경에서는 보조 기술의 도입이 필수적이라는 결론이 도출된다.

구체적으로, Vision AI 모델의 한계는 세 가지 측면에서 확인되었다. 첫째, 시간적 맥락 이해의 부재이다. YOLO를 포함한 대부분의 객체 탐지 모델은 개별 프레임을 독립적으로 분석하므로, 동작의 시작-진행-종료를 파악하지 못한다. 둘째, 의미론적 추론 능력의 부재이다. 시각적으로 유사하지만 의미가 다른 상황(예: 숙임 vs 낙상)을 구분하기 위해서는 상황의 맥락과 의도에 대한 이해

10) 연기는 배경과 명암 대비가 낮고 형태가 불규칙해 작은 크기일 경우 YOLO 기반 모델이 feature를 안정적으로 학습하기 어렵다.

가 필요하나, Vision AI 모델은 이러한 고차원적 추론이 불가능하다. 셋째, 환경 변화에 대한 취약성이다. 조명 변화, 카메라 각도, 날씨 조건 등 환경적 요인에 의해 성능이 크게 영향을 받았다. 이러한 한계들은 VLM과의 결합을 통해 보완될 수 있으며, 이는 하이브리드 구조의 필요성을 뒷받침하는 실증적 근거가 된다.

4.3 VLM(Video Language Model) 실험결과

4.3.1 VLM 아키텍처 구성 및 학습 전략

본 연구에서 VLM의 역할은 '비상상황을 직접 탐지하는 모델'이 아니라 '영상 내용을 이해하고 자연어로 요약·설명하며, 간단한 질의응답을 수행하는 모델'로 정의하였다. 이러한 역할 정의는 VLM의 강점을 최대한 활용하면서 현실적인 적용 가능성을 확보하기 위한 것이다. 비상상황 감지(화재, 실신, 침수 등)는 YOLO 기반 Vision AI 모델이 1차적으로 수행하고, VLM은 장면 요약 및 설명, 질의응답, 이벤트 이후 상황 설명 및 보고서용 텍스트 생성 등의 고차 기능을 담당하도록 설계하였다.

VLM 아키텍처는 사전학습된 Video Encoder와 LLM을 조합하는 구조를 채택하였다. 실험에서 검토한 후보 조합은 다음과 같다. 첫째, MAE-ST(Spatiotemporal Masked Autoencoder) + Phi-2 또는 Qwen1.5 조합은 경량이며 빠른 추론이 가능하며 저비용 데모 구현에 적합하다. 둘째, MGMAE(Multi-Granularity MAE) + Mistral 7B 조합은 보다 풍부한 장면 설명과 자연스러운 문장 생성이 가능하여 설명 품질이 중요한 고급 데모에 적합하다. 셋째, 최적화된 ST-MAE + LLaMA 3 8B 조합은 고품질 설명과 확장 가능한 구조를 제공하여 향후 확장형 서비스 또는 연구용으로 적합하다. 데모 목적 및 GPU 자원(T4, A10 등) 제약을 고려하여, 우선은 MAE-ST + Phi-2와

같은 경량 조합을 1차 목표로 삼아 실험을 진행하였다.

VLM 학습 데이터로는 Video-Text 데이터셋인 MSR-VTT를 활용하여 약 1,000개의 비디오-캡션 쌍을 테스트셋으로 사용하였다. LLM 텍스트 데이터로는 OpenHermes, OpenOrca, Alpaca, Flan-mini 등 소규모 Instruction 데이터셋을 활용하여 LLM을 경량 파인튜닝하였다. 학습 전략은 두 단계로 구성되었다. 첫째, LLM 미세조정 단계에서는 소량(수백~수천 개)의 질의응답/요약 데이터로 LLM 응답 품질을 개선하였으며, GPU 자원 절감을 위해 4-bit LoRA를 사용하였다. 둘째, Projection Layer 학습 단계에서는 Video Encoder에서 추출한 시각 feature를 LLM의 토큰 임베딩 공간으로 매핑하는 프로젝션 레이어를 학습하였으며, Encoder는 기본적으로 freeze하여 학습 비용을 최소화하였다.



[그림 1] Vision AI 모델 - VLM 역할 분담 흐름

4.3.2 의미 기반 행동 분석 결과

VLM은 Vision AI 모델이 탐지한 이벤트 후보 또는 장면 클립을 입력받아 사건의 의미를 분석하고 자연어로 설명하였다. 이 과정에서 VLM은 Vision AI 모델이 갖지 못한 우수한 추론(reasoning) 능력을 보여주었다. 특히 시각적으로 유사하지만, 의미론적으로 다른 상황들을 구분하는 능력이 현저하게 향상되었다. 낙상 vs 속임 구분에서, VLM은 움직임의 시작-전개-결과를 분석하여 실제 낙상 여부를 판단할 수 있었다. 예를 들어, '사람이 천천히 무릎을 굽히며 바닥의 물건에 손을 뻗고 있다'와 '사람이 갑자기 균형을 잃고 쓰러지며 움직임을 멈추었다'를 구분하여 설명하였다. 장난 vs 폭행 구분에서, VLM은 주변 사람들의 반응, 상호작용의 강도, 행동의 반복성 등을 분석하여 정확한 의미 해석을 수행하였다. 연기 vs 먼지/증기 구분에서, VLM은 연기의 농도 변화, 확산 속도, 움직임을 패턴 등 시공간적 특성을 식별하여 오류를 보정할 수 있었다. 군중 흐름 변화 감지에서, VLM은 점진적인 밀집 증가나 갑작스러운 흐름 변화를 인식하고 설명하였다. 이러한 결과는 VideoMAE 기반 시공간 인코딩 구조가 동작의 변화를 매우 정교하게 학습할 수 있다는 기존 연구 결과와도 일치한다.

이벤트	Vision AI 모델 단독	VLM 해석 정확도
쓰러짐	0.78	0.92
폭행	0.72	0.88
연기/화재	0.69	0.85
장난/오작동 구분	불가	0.81
전체 평균	0.73	0.87

[표 6] 사건 유형 분류 정확도

4.3.3 VLM의 정량적 성능 평가

VLM의 성능은 Event-level accuracy, Semantic Consistency Score, Natural Language Explanation Quality 등 다양한 지표에서 평가되었다. Event-level accuracy는 VLM이 이벤트의 유형(쓰러짐, 폭행, 화재 등)을 올바르게 분류한 비율을 측정하며, 테스트셋에서 약 87%의 정확도를 달성하였다. Semantic Consistency Score는 VLM의 설명이 영상 내용과 의미적으로 일관되는지를 평가하는 지표로, 전문가 평가에서 5점 척도 기준 평균 4.2점을 기록하였다. Natural Language Explanation Quality는 생성된 설명의 문법적 정확성, 논리적 흐름, 정보 완결성 등을 종합적으로 평가하며, 관제 업무 활용에 '적합' 또는 '매우 적합'으로 평가된 비율이 78%에 달하였다.

특히 쓰러짐(fall) 이벤트에 대한 테스트에서, VLM은 24개의 테스트 영상에서 Fall 이벤트 자체를 성공적으로 포착하였다. 다만, 초기 파인튜닝 결과에서 과적합(Overfitting) 문제가 확인되었는데, 모든 답변이 특정 문장 패턴으로 고정되는 증상이 나타났다. 환경 묘사, 디테일, 사람 수, 위치 정보 등에서 원본 모델 대비 다양성이 하락하였다. 이러한 문제의 원인은 LoRA 파인튜닝 데이터의 패턴이 단조로웠고, 학습 프롬프트가 Fall 중심의 답변을 강하게 유도했으며, LoRA Rank 및 Learning Rate가 과도하게 높게 설정되었기 때문으로 분석되었다.

항목	평가 내용 및 결과
Event-level Accuracy	VLM의 이벤트 유형 분류 정확도: 87%
Semantic Consistency Score	영상과 설명의 의미 일치도(전문가 5점 척도): 4.2 / 5
Natural Language Explanation Quality	문법·논리·정보 완결성 기준 평가: 78%가 '적합·매우 적합'
Fall 이벤트 탐지 성능	테스트 영상 24개 중 24/24 탐지 성공
초기 파인튜닝	설명 문장이 특정 패턴으로 고정되고, 디테일·환경

문제(과적합)	묘사·인원·위치 정보 다양성 저하
원인 분석	• 단조로운 LoRA 데이터 패턴 • Fall 중심 프롬프트의 과도한 유도 • 높은 LoRA Rank·Learning Rate 설정

[표 7] VLM 평가 결과 및 초기 파인튜닝 한계 요약

4.3.4 VLM의 문제점 및 한계 분석

VLM의 우수한 의미 기반 분석 능력에도 불구하고, 단독 운영에는 현실적 어려움이 존재함이 실험을 통해 확인되었다. 첫째, 연산량이 매우 높아 실시간 적용이 어렵다. VLM은 비디오 인코딩과 언어 모델 추론을 모두 수행해야 하므로, 단일 비디오 클립 분석에도 Vision AI 모델 대비 수십 배 이상의 시간이 소요된다. A100 GPU 환경에서도 10초 길이의 클립을 분석하는 데 평균 3-5초가 소요되어, 실시간 스트림 분석에는 적합하지 않았다.

둘째, 환각(Hallucination) 발생 가능성이 있어 잘못된 추론을 생성할 위험이 존재한다. 실험 중 일부 사례에서 VLM이 영상에 존재하지 않는 객체나 행동을 설명하거나, 실제 상황과 다른 해석을 제시하는 경우가 관찰되었다. 이는 CCTV 관제와 같은 안전-중요(safety-critical) 영역에서 심각한 문제가 될 수 있다. 셋째, 모든 CCTV 스트림을 VLM으로 처리하면 비용과 속도 측면에서 비효율적이다. 수백 대의 카메라를 상시 VLM으로 분석하는 것은 현재의 하드웨어 기술과 비용 제약 아래서 현실적이지 않다.

이러한 문제점들을 해결하기 위한 개선 전략으로, VideoLLaMA3의 Stage 4(Video-centric Fine-Tuning) 도입을 검토하였다. Stage 4는 시간적 추론(Temporal Reasoning), 동작 이해(Action Understanding), 이벤트 중심 학습에 특화된 단계로, Stage 1-3이 이미지 중심이거나 일반 목적인 것과 달리 특정 도메인의 이벤트 판단 능력이 강화된다. 학습 구성에서 Vision Encoder

는 Freeze(필요 시 일부 해제)하고, Projector에는 LoRA 튜닝을 적용하며, LLM에는 LoRA 또는 Q-LoRA를 적용하였다. 데이터 확장을 위해 다양한 Location, Body Pose, 구조자 등장 여부 등을 포함하여 데이터 다양성을 확보하고, Ground Truth 문장 패턴을 무작위로 확장하였다. 해상도는 CCTV 환경 및 VRAM 효율을 고려하여 4K에서 1080p(1920×1080)로 다운스케일링하였다.

4.4 Vision AI 모델-VLM 하이브리드 실험결과

4.4.1 하이브리드 구조의 테스트 시나리오 설계

본 연구의 핵심 기여는 Trigger-Validator 구조의 실효성을 실험적으로 입증한 것이다. 하이브리드 구조는 Vision AI 모델의 속도 장점과 VLM의 의미 해석 능력을 결합하여, 단독 모델 대비 현저한 성능 개선을 목표로 한다. 테스트 시나리오는 통합관제센터 환경에서 Vision AI 모델과 VLM을 결합한 하이브리드 구조의 유용성을 종합적으로 평가하도록 설계되었다.

구조적 역할 분담은 다음과 같이 정의되었다. Vision AI 모델(YOLO 계열)는 실시간 비상상황 탐지(화재, 쓰러짐, 침수, 군집, 싸움 등)를 담당하며, 알람 발생 시점과 위치(카메라 ID, 좌표, 시간)를 신속하게 제공한다. VLM은 알람이 발생한 구간의 영상을 입력받아 장면 요약('해당 시간대에 어떤 상황이 발생했는지'), 주요 행동 설명('사람들이 어떤 행동을 했는지, 어떤 객체가 중요한지'), 간단한 질의응답('쓰러진 사람 주변에 다른 사람이 있었는가?' 등)을 수행한다.

테스트 시나리오는 세 가지 유형으로 구성되었다. 첫째, YOLO 단독 vs YOLO+VLM 비교 테스트에서, 동일한 이벤트에 대해 YOLO만 사용했을 때 관제사가 확보하는 정보와 YOLO+VLM을 사용할 때 추가적으로 얻는 정보(자연어 요약, Q&A 등)를 비교하였다. 관제사의 상황 이해 속도 및 보고서 작성 편의성을 정성 평가로 측정하였다. 둘째, 이벤트 유형별 하이브리드 성능 분석에

서, 화재, 쓰러짐, 침수, 군집, 싸움 등 이벤트 유형별로 Vision AI 모델의 탐지 성능(mAP, 이벤트 단위 탐지율)과 VLM의 설명 정확도, 관련성, 일관성을 분리하여 평가하였다. 셋째, 실제 데모 환경 테스트에서, 웹 앱 및 관제 UI에 YOLO + VLM 기능을 탑재한 뒤, 실시간 이벤트 발생 → YOLO 탐지 → VLM 요약/설명 생성 → UI 표시의 전체 파이프라인에 대해 지연 시간, 시스템 안정성, 모델 응답 품질을 통합적으로 검증하였다.

4.4.2 오탐 감소 효과 분석

하이브리드 모델은 Vision AI 모델이 탐지한 이벤트 중 잘못된 판단을 VLM이 검증하여 오탐을 효과적으로 제거하였다. 실험 결과, Vision AI 모델 단독 대비 하이브리드 구조에서 오탐이 35-40% 감소하는 것으로 확인되었다. 이는 VLM의 시간적 맥락 분석과 의미 기반 추론이 Vision AI 모델의 단일 프레임 판단 오류를 효과적으로 보정함을 의미한다.

대표적인 오탐 감소 사례는 다음과 같다. 첫째, Vision AI 모델이 쓰러짐으로 오탐한 경우, 하이브리드 구조에서 VLM이 움직임의 연속성을 분석하여 '숙임' 또는 '앉기' 행동으로 재분류하였다. 예를 들어, '사람이 무릎을 꿇혀 바닥에 떨어진 물건을 집어 들고 다시 일어섰다'는 설명과 함께 정상 행동으로 판정하였다. 둘째, Vision AI 모델이 폭행으로 오탐한 경우, VLM이 상호작용의 맥락을 분석하여 '장난스러운 접촉' 또는 '친근한 인사'로 재분류하였다. 셋째, Vision AI 모델이 연기로 오탐한 경우, VLM이 시공간 패턴을 분석하여 '먼지', '수증기', '빛 반사' 등으로 재판단하였다. 이러한 결과는 의미 기반 추론(reasoning)이 CCTV 환경에서 필수적임을 증명한다.

이벤트	Vision AI 모델 FP	하이브리드 FP	감소율
쓰러짐	52건	25건	52% 감소

폭행	41건	24건	41% 감소
연기/화재	34건	22건	35% 감소
분실물	29건	17건	41% 감소
전체 평균	-	-	38% 감소

[표 8] 오탐 감소 효과

4.4.3 미탐 보완 효과 분석

하이브리드 모델은 Vision AI 모델이 놓친 사건을 VLM이 보완하는 구조를 통해 미탐 또한 크게 줄였다. 실험 결과, Vision AI 모델 단독 대비 미탐이 20~25% 보완되는 것으로 확인되었다. 이는 Trigger 단계에서 낮은 임계값을 적용하여 약한 탐지 신호도 VLM에 전달하고, VLM이 시간적 맥락 분석을 통해 실제 이벤트 여부를 확인하는 구조의 효과성을 입증한다.

VLM은 장면 흐름을 분석하여 Vision AI 모델이 인식하지 못한 약한 동작 및 초기 변화를 성공적으로 포착하였다. 예를 들어, 점진적으로 진행되는 쓰러짐-서서히 무릎이 꿇이며 벽에 기대다가 바닥으로 미끄러지는 경우-은 Vision AI 모델의 프레임 단위 분석으로는 급격한 변화로 인식되지 않아 놓치기 쉽지만, VLM은 전체 시퀀스를 분석하여 비정상적인 행동 패턴으로 탐지하였다. 또한, 초기 단계의 희미한 연기나 화면 가장자리에서 발생한 이벤트도 VLM의 전체적인 장면 이해 능력을 통해 보완되었다.

구분	이벤트 수(건)	산출 방식
실제 이벤트 수 (GT)	100	테스트셋 Ground Truth
Vision AI 모델 탐지 이벤트	75 ~ 80	이벤트 단위 탐지 성공
Vision AI 모델 미탐 이벤트	20 ~ 25	GT - Vision 탐지

(V_miss)		
VLM 보완 탐지 이벤트 (VLM_recover)	4 ~ 6	미탐 중 VLM 추가 식별
미탐 보완율 (MCR)	20% ~ 25%	$(VLM_recover / V_miss) \times 100$

[표 9] 미탐감소효과

4.4.4 Human-in-the-Loop 관점에서의 효과 분석

관제요원 대상 정성 분석을 실시한 결과, 하이브리드 구조에 대해 긍정적인 평가가 확인되었다. 참여 관제요원들은 '혼동되는 장면 판단이 쉬워졌다', '오탐이 줄어 경보 스트레스가 감소했다', '보고서 자동 생성 기능으로 업무 시간이 크게 감소했다' 등의 피드백을 제공하였다. 이러한 결과는 하이브리드 구조가 단순히 기술적 성능 향상을 넘어 실제 관제 업무의 효율성과 관제요원의 업무 만족도를 개선할 수 있음을 시사한다.¹¹⁾

특히 VLM이 생성하는 자연어 설명은 관제요원의 상황 판단을 효과적으로 지원하는 것으로 나타났다. 기존에는 경보 발생 시 관제요원이 직접 영상을 확인하고 상황을 파악해야 했으나, 하이브리드 구조에서는 VLM의 요약 설명을 먼저 확인함으로써 초기 판단 시간이 단축되었다. 또한, 보고서 작성 시 VLM의 설명을 기초 자료로 활용할 수 있어, 행정 업무 부담이 크게 감소하였다. 이는 Human-AI 협업 관점에서 하이브리드 구조의 실무적 가치를 입증하는 결과이다.


4.5 실제 관제센터 사례 기반 분석

11) 하이브리드 모델은 관제요원에게 '설명 가능한 추론 근거'를 제공해 판단 오류를 줄이며, 실제 검토 시간을 40% 이상 단축한다는 보고가 있다.


본 절에서는 실제 CCTV 사건 유형을 대표 사례로 선택하여 Vision AI 모델, VLM, Hybrid 모델 간 비교 분석을 수행하였다. 각 사례는 관제센터에서 빈번히 발생하며 정확한 탐지와 판단이 중요한 이벤트 유형을 대상으로 하였다.

4.5.1 사례 1: 쓰러짐(Fall) 탐지

쓰러짐 탐지는 노인, 환자, 음주자 등의 안전과 직결되는 핵심 관제 대상이다. Vision AI 모델 단독 사용 시, 기울어진 자세나 물건 줍기 행동을 낙상으로 잘못 인식하는 오탐이 빈번하게 발생하였다.



[그림 2] 쓰러짐 탐지 화면 1



[그림 3] 쓰러짐 탐지 화면 2

또한 점진적인 쓰러짐(천천히 주저앉는 경우)은 급격한 변화로 인식되지 않아 미탐이 발생하였다. VLM 단독 사용 시, 움직임의 시작-전개-결과를 분석하여 실제 낙상 여부를 높은 정확도로 판단할 수 있었으나, 실시간 적용이 어려운 한계가 있었다.

하이브리드 구조에서는 Vision AI 모델이 쓰러짐 후보를 빠르게 탐지하고, VLM이 해당 클립의 시간적 맥락을 분석하여 오탐을 제거하고 놓친 낙상을 보완하였다. 예를 들어, Vision AI 모델이 '숙임'을 '쓰러짐'으로 오탐한 경우, VLM은 '해당 인물은 바닥에 떨어진 물건을 집어 들기 위해 잠시 허리를 숙인 후 정상적으로 일어났습니다'라는 설명과 함께 정상 행동으로 재분류하였다. 반대로, Vision AI 모델이 놓친 점진적 쓰러짐에 대해서는 VLM이 '해당 인물은 점차 균형을 잃으며 벽에 기대다가 바닥으로 미끄러졌으며, 이후 움직임이 없습니다. 응급 상황으로 판단됩니다'라는 분석을 제공하였다. 결과적으로, 실제 낙상 사고 탐지 정확도가 크게 향상되었다.


4.5.2 사례 2: 폭행(Violence) 탐지

폭행 탐지는 공공장소의 치안 유지에 핵심적인 역할을 한다. Vision AI 모델은 공격적 의도와 장난스러운 신체 접촉을 구분하기 어려웠다. 두 사람이 물리적으로 접촉하는 장면을 탐지하더라도, 그것이 친근한 포옹인지, 싸움인지, 운동인지를 단일 프레임만으로 판단하기 어렵기 때문이다. 반면 VLM은 주변 사람들의 반응(놀라는지, 무관심한지), 상호작용의 강도(가벼운 접촉인지, 강한 충격인지), 행동의 반복성(일회성인지, 지속적인지) 등을 종합 분석하여 정확한 의미 해석을 수행하였다.

하이브리드 구조는 두 기술의 단점을 상쇄하고 폭행 탐지 정확도를 크게 높였다. Vision AI 모델이 신체 접촉을 탐지하면, VLM이 해당 상황을 분석하여 '두 사람이 웃으며 포옹하고 있으며, 주변 사람들도 평온한 상태입니다. 친근한

인

사로 판단됩니다' 또는 '한 사람이 다른 사람을 반복적으로 밀치고 있으며, 피해자로 추정되는 인물이 넘어졌습니다. 주변 사람들이 놀라는 반응을 보이고 있습니다. 폭행 상황으로 판단됩니다'와 같은 상세 분석을 제공하였다. 이러한 의미 기반 판단은 관제요원의 신속하고 정확한 대응을 지원하였다.



[그림 4] 대화 / 폭행 인지 학습화면

4.5.3 사례 3: 연기(Smoke) 탐지

연기 탐지는 화재의 조기 발견과 대형 피해 방지에 핵심적인 역할을 한다. Vision AI 모델은 조명 반사, 먼지, 수증기, 안개 등 시각적으로 연기와 유사한 현상에서 오탐이 빈번하게 발생하였다. 특히 야간이나 저조도 환경에서 이러한 오탐이 더욱 심화되었다. 반면 VLM은 연기의 농도 변화, 확산 속도, 움직임 방향 등 시공간적 패턴을 분석하여 실제 연기와 유사 현상을 구분하였다.

하이브리드 구조에서, VLM은 Vision AI 모델이 연기로 탐지한 영역을 분석하여 '해당 영역에서 관찰되는 현상은 점진적으로 확산되지 않고 형태가 일정하게 유지되고 있습니다. 조명 반사 또는 렌즈 플레어로 추정됩니다' 또는 '해

당 영역에서 밝은 색의 물체가 점차 상승하며 확산되고 있습니다. 연기의 특성과 일치하며, 화재 초기 징후로 판단됩니다'와 같은 분석을 제공하였다. 이러한 분석은 불필요한 화재 경보로 인한 출동을 줄이면서도 실제 화재에 대한 신속한 대응을 가능하게 하였다.

4.6 관제센터 운영 효율성 분석

하이브리드 모델은 단순 탐지 성능 개선 수준을 넘어 관제센터 운영 효율성을 종합적으로 향상시켰다. 본 절에서는 사건 검토 시간, 보고서 작성 시간, 불필요 대응 감소, 관제요원 피로도 등 운영 효율성 지표에 대한 분석 결과를 제시한다.

사건 검토 시간 측면에서, 하이브리드 구조는 Vision AI 모델 단독 대비 평균 43%의 검토 시간 단축 효과를 보였다. 이는 VLM이 제공하는 상황 요약과 자연어 설명이 관제요원의 초기 판단을 효과적으로 지원했기 때문이다. 기존에는 경보 발생 시 관제요원이 직접 전후 영상을 확인하며 상황을 파악해야 했으나, 하이브리드 구조에서는 VLM의 분석 결과를 먼저 확인함으로써 신속한 판단이 가능해졌다.

보고서 작성 시간 측면에서, 하이브리드 구조는 평균 82%의 시간 단축 효과를 보였다. VLM이 생성하는 자연어 설명을 보고서의 기초 자료로 활용함으로써, 관제요원은 처음부터 보고서를 작성할 필요 없이 VLM의 출력을 검토하고 필요시 수정하는 방식으로 업무를 수행할 수 있었다. 이는 행정 업무 부담을 크게 줄이고, 관제요원이 본연의 감시 업무에 더 집중할 수 있게 하였다.

불필요 대응 감소 측면에서, 오탐 감소로 인해 잘못된 경보에 따른 출동이나 조치가 약 40% 감소하였다. 이는 경찰, 소방, 보안 요원 등의 자원을 효율적으로 활용할 수 있게 하며, 반복적인 오탐에 대한 '경보 피로(alarm fatigue)'를

완화하여 실제 위험 상황에 대한 대응 민감도를 유지하는 데 기여하였다. 관제 요원 피로도 측면에서, 정성 평가 결과 하이브리드 구조 도입 후 피로도가 '완화'된 것으로 나타났다. 오탐 감소로 인한 경보 스트레스 감소, 자동화된 분석 지원, 행정 업무 부담 경감 등이 복합적으로 작용한 결과로 분석된다. 이러한 결과는 실제 스마트시티 관제센터 운영 보고서에서 확인된 경향과도 일치한다.

4.7 실험결과 종합 논의

본 장의 실험결과는 제3장에서 제기한 연구 질문들에 대해 명확한 답변을 제공한다. 실험을 통해 도출된 핵심 결론은 다음과 같이 정리된다.

첫째, Vision AI 모델은 빠른 처리 속도와 실시간 탐지 능력에서 강점을 보이지만, 의미 기반 해석에서 근본적인 한계가 있다. 단일 프레임 분석에 의존하는 구조적 특성으로 인해, 시간적 맥락이 중요한 행동 인식과 유사 상황 구분에서 오탐과 미탐이 빈번하게 발생한다. 이는 Vision AI 모델 단독으로는 CCTV 관제의 정교한 요구를 충족시키기 어렵다는 것을 실증적으로 확인해 준다.

둘째, VLM은 시공간적 맥락을 고려한 우수한 의미 해석 능력을 보유하고 있으나, 실시간 적용에는 현실적 제약이 존재한다. 높은 연산 비용, 환각 위험, 대규모 스트림 처리의 비효율성 등은 VLM을 단독 기술로 활용하는 것이 비현실적임을 보여준다. 그러나 VLM의 의미 기반 분석 능력은 Vision AI 모델의 한계를 보완하는 데 매우 효과적이다.

셋째, Trigger-Validator 하이브리드 구조는 두 기술의 장점을 결합하고 단점을 상호 보완하여 최적의 성능을 제공한다. 오탐 35-40% 감소, 미탐 20-25% 보완, 사건 검토 시간 43% 단축, 보고서 작성 시간 82% 단축 등의 정량적 성과는 하이브리드 구조의 실효성을 명확히 입증한다. 관제요원의 정성적 평가 역시 긍정적이며, 실제 관제센터 적용 가능성이 매우 높다.

넷째, 본 연구의 결과는 공공안전, 스마트시티, 스마트빌딩, 산업안전 등 다양한 분야에서 적용할 수 있는 의미 있는 기술적 기반을 제공한다. Vision AI 모델과 VLM을 결합한 하이브리드 접근법은 CCTV 관제를 넘어, 영상 기반 상황 인식이 필요한 다양한 영역에서 참고될 수 있는 설계 원칙을 제시한다. 이러한 실험결과는 제5장에서 연구의 학술적·실무적 의의와 향후 연구 방향을 논의하는 근거가 된다.

제5장 결론 및 향후 연구

본 장에서는 Vision AI 모델-VLM 하이브리드 구조 연구의 주요 결과를 종합적으로 정리하고, 연구의 학술적·실무적 의의를 논의하며, 향후 연구 방향과 공공안전·스마트시티·스마트빌딩 분야에서의 확장 가능성을 제시한다. 본 연구는 CCTV 관제센터의 구조적 문제-인간 인지 기반 감시의 한계, Vision AI 모델 단독 기술의 한계, VLM 단독 기술의 비효율성-를 해결하기 위해 새로운 방향성을 제시하였다는 점에서 중요한 의의를 갖는다. 더불어 Scene-level Split이라는 CCTV 도메인 특유의 문제를 해결할 수 있는 새로운 데이터 구성 기준을 제시했다는 점에서도 차별성이 있다.

CCTV 기반 영상 감시 시스템은 전 세계적으로 빠르게 확산되고 있으며, 2024년 말까지 전 세계적으로 약 32억 대의 감시 카메라가 운영될 것으로 예측된다. 아시아-태평양 지역이 2024년 글로벌 매출의 36.9%를 차지하며, AI 기반 영상 분석 시장은 2030년까지 연평균 18.2% 이상의 성장이 전망된다. 이러한 급격한 시장 성장과 기술 발전 속에서, 본 연구가 제안한 하이브리드 구조는 차세대 지능형 관제 시스템의 핵심 아키텍처로서 의미 있는 기여를 할 것으로 기대된다.

5.1 연구 결과 요약

5.1.1 Vision AI 모델의 한계 검증

본 연구는 Vision AI 모델 (YOLOv11-m)의 실험을 통해 CCTV 도메인에서의 구조적 한계를 실증적으로 확인하였다. Vision AI 모델은 실시간 객체 탐지에서 우수한 속도와 효율성을 보여주지만, CCTV 관제에서 요구되는 정교한

행동 인식과 상황 이해에는 근본적인 한계가 존재함이 확인되었다. 이러한 한계는 다수의 선행 연구에서도 일관되게 지적되어 왔으며, 본 연구의 실험 결과는 이를 CCTV 도메인의 맥락에서 재확인하였다.

첫째, Vision AI 모델은 단일 프레임 기반 판단에 의존하여 의미 해석이 불가능하다. YOLO를 포함한 대부분의 객체 탐지 모델은 각 프레임을 독립적으로 분석하므로, 시각적으로 유사하지만, 의미적으로 다른 상황(예: 숙임 vs 낙상, 장난 vs 폭행)을 구분하기 어렵다. 둘째, 시간적 행동 분석의 구조적 부재가 확인되었다. 행동의 시작-진행-종료를 파악하지 못하므로, 점진적인 상황 변화(예: 천천히 쓰러지는 경우, 초기 단계의 연기 발생)를 탐지하는 데 한계가 있다. 셋째, 조명·해상도 변화에 취약한 성능이 관찰되었다. 야간 환경, 역광 상황, 저해상도 카메라 등 환경적 요인에 의해 탐지 성능이 크게 영향을 받았다.

넷째, 행동 클래스(폭행, 쓰러짐, 연기 등)에서 낮은 Recall이 측정되었다. 이는 Vision AI 모델이 행동의 의미보다는 시각적 형태에 의존하기 때문으로, 행동 구분이 핵심인 CCTV 도메인에서 심각한 제약이 된다. 다섯째, 장면별 배경 편향 모델링 문제가 확인되었다. Random Split 방식으로 학습된 모델은 배경 특징(벽 색상, 바닥 패턴, 조명 등)을 학습하여 테스트 세트에서 높은 성능을 보이지만, 새로운 장소에서는 성능이 급격히 저하되었다. 이러한 결과는 Vision AI 모델 단독으로는 공공안전 감시 시스템에서 요구되는 정교한 이해 능력을 제공하기 어렵다는 점을 재확인시켜 주었다.

5.1.2 VLM의 의미 기반 분석 능력 검증

VLM(VideoMAE 기반 인코더 + LLaMA 기반 언어 모델)은 Vision AI 모델의 한계를 보완하는 핵심적인 능력을 제공함이 실험을 통해 확인되었다. VLM은 Vision-Language 통합을 통해 시각 정보와 언어적 이해를 결합함으로써, 단순한 객체 탐지를 넘어 상황의 의미를 파악하고 설명하는 능력을 보유한다.

최근 VLM 분야의 급격한 발전에 힘입어, 이러한 능력은 CCTV 관제와 같은 실무 영역에서도 적용 가능한 수준에 도달하였다(Zeng et al., 2023).

VLM이 제공하는 핵심 능력은 다음과 같이 정리된다. 첫째, 행동의 연속성 분석 능력이다. VideoMAE 기반 시공간 인코딩 구조는 동작의 시작-전개-결과를 분석하여, 단일 프레임에서는 판단하기 어려운 행동의 의미를 파악할 수 있다. 둘째, 사건의 원인·결과 추론 능력이다. LLM의 추론 능력을 활용하여 관찰된 상황의 원인을 추정하고 잠재적 결과를 예측할 수 있다(Touvron et al., 2023). 셋째, 연기 농도 변화와 같은 미세 시공간 패턴 인식 능력이다. 점진적으로 진행되는 상황 변화를 탐지하여 Vision AI 모델이 놓치기 쉬운 초기 징후를 포착할 수 있다. 넷째, 자연어 보고 생성 능력이다. 탐지된 상황을 관제요원이 이해할 수 있는 자연어로 설명함으로써, 상황 판단과 보고서 작성을 지원한다.

실험에서 VLM은 Vision AI 모델이 놓친 사건을 보완하고 의미 해석의 정확도를 크게 향상시키는 능력을 보여주었다. 특히 낙상 vs 숙임 구분, 장난 vs 폭행 구분, 연기 vs 먼지/증기 구분 등 시각적으로 유사하지만, 의미적으로 다른 상황에서 VLM의 판단 정확도가 Vision AI 모델을 현저히 상회하였다. 그러나 VLM은 다음의 구조적 어려움을 갖는다. 실시간 분석 속도가 부족하여 모든 CCTV 스트림을 상시 분석하기 어렵고, 연산 비용이 높아 대규모 배포에 제약이 있으며, LLM 특유의 환각(Hallucination) 위험성이 존재하여 잘못된 설명을 생성할 수 있다. 최근 연구에 따르면 VLM은 단순 탐지 작업에서 82-86%의 정확도를 달성하지만, 복잡한 다중 클래스 시나리오에서는 26-45%로 정확도가 하락하며, 프라이버시 필터(얼굴/신체 익명화) 적용 시 2-11%의 추가 성능 저하가 발생한다. 따라서 VLM의 단독 사용도 현실적 대안이 될 수 없음을 확인하였다.

5.1.3 하이브리드 Trigger-Validator 구조의 우수성 검증

본 연구의 핵심 기여는 Vision AI 모델과 VLM을 결합한 하이브리드 구조가 두 기술 단독 모델의 한계를 실제로 해결한다는 점을 실험적으로 입증한 것이다. Trigger-Validator 구조는 Vision AI 모델이 빠른 속도로 이벤트 후보를 탐지(Trigger)하고, VLM이 해당 후보에 대해 의미 기반 검증(Validator)을 수행하는 역할 분담 방식을 채택하였다. 이러한 하이브리드 접근법은 최근 연구에서도 가장 유망한 방향으로 인식되고 있으며, 산업 현장에서도 채택이 확산되고 있다.

실험 결과, 하이브리드 구조는 다음과 같은 성과를 보였다. 오탐(False Positive)은 35-40% 감소하였으며, 이는 VLM의 시간적 맥락 분석과 의미 기반 추론이 Vision AI 모델의 단일 프레임 판단 오류를 효과적으로 보정함을 의미한다. 미탐(False Negative)은 20-25% 보완되었으며, 이는 낮은 임계값의 Trigger 단계에서 약한 탐지 신호도 VLM에 전달되어 시간적 맥락 분석을 통해 실제 이벤트 여부가 확인됨을 의미한다. 사건 검토 시간은 평균 43% 감소하였으며, 이는 VLM의 상황 요약과 자연어 설명이 관제요원의 초기 판단을 효과적으로 지원했기 때문이다. 보고서 작성 시간은 평균 82% 감소하였으며, 이는 VLM의 자연어 설명을 보고서의 기초 자료로 활용함으로써 행정 업무 부담이 크게 줄어든 결과이다. 관제요원 피로도는 정성적 평가에서 '완화'된 것으로 확인되었으며, 오탐 감소로 인한 경보 스트레스 감소, 자동화된 분석 지원, 행정 업무 부담 경감 등이 복합적으로 작용하였다.

이러한 결과는 Vision AI 모델의 빠른 속도와 VLM의 의미 기반 분석 능력이 상보적 관계에 있으며, 두 기술을 결합했을 때 비로소 실무적 적용 가능성이 확보된다는 사실을 뒷받침한다. 최근 산업 사례에서도 하이브리드 접근법이 90% 이상의 탐지 정확도와 5% 미만의 오탐률을 달성하고 있으며, 이는 VLM 단독(26-45%)이나 Vision AI 모델 단독보다 현저히 높은 수준이다. 본 연구의 결과는 이러한 산업적 동향과 일치하며, 학술적 근거를 제공한다는 점에서 의

의가 있다.

5.2 연구의 학술적 의의

본 연구는 CCTV 관제 도메인에서 Vision AI 모델과 VLM의 결합에 관한 학술적 기여를 다음과 같이 제공한다.

5.2.1 Vision AI 모델과 VLM의 구조적 한계 비교

기존 연구는 Vision AI 모델 또는 VLM 단독 성능 분석에 집중하였으나, 본 연구는 두 기술을 CCTV 도메인에서 직접 비교하여 각 기술의 강점과 약점을 정량·정성적으로 분석하였다. VLM 분야의 최근 서베이 논문들은 VLM의 일반적인 성능과 한계를 다루고 있으나, CCTV 관제라는 특수한 도메인에서의 적용 가능성을 심층적으로 분석한 연구는 드물다. 본 연구는 이러한 학술적 공백을 메우며, Vision AI 모델(속도, 효율성)와 VLM(의미 해석, 맥락 이해) 각각의 특성이 CCTV 관제 요구사항과 어떻게 부합하거나 충돌하는지를 체계적으로 분석하였다.

5.2.2 Scene-level Split의 필요성 실증

CCTV의 고정된 Scene 특성 때문에 Random Split은 부적절하며, Scene-level Split이 일반화 성능을 확보하는 유일한 방법임을 실험적으로 확인하였다. 이는 CCTV AI 연구에서 반드시 고려되어야 할 새로운 표준을 제안하는 것으로, 기존의 일반적인 비디오 데이터셋 분할 방식이 CCTV 도메인에서는 심각한 데이터 누수와 일반화 실패를 초래할 수 있음을 경고한다. 본 연구에서 제시한 Scene-level Split 방법론은 향후 CCTV 관련 연구에서 데이터셋 구축 및 평가의 표준으로 활용될 수 있다.

5.2.3 하이브리드 구조의 새로운 연구 방향 제시

Trigger-Validator 방식은 Vision AI 모델의 한계를 보완하면서도 VLM의 연산 부담을 줄이는 새로운 AI 아키텍처 방향을 제시한다. 최근 연구에서도 하이브리드 접근법이 가장 유망한 방향으로 인식되고 있으며, 본 연구는 이러한 방향성을 CCTV 도메인에서 구체화하고 실험적으로 검증하였다. 특히 CVPR 2024 워크숍에서 발표된 ViTA 연구는 경량 VLM과 중량 VLM을 결합한 하이브리드 접근으로 43%의 지연 시간 감소를 달성하였으며, 이는 본 연구의 Trigger-Validator 구조와 유사한 철학을 공유한다. 본 연구의 결과는 이러한 하이브리드 접근법의 효과성을 CCTV 관제 도메인에서 재확인하며, 향후 연구의 기반을 마련한다.

5.2.4 의미 기반 Reasoning 평가 틀 제안

본 연구는 단순 탐지 정확도(Precision, Recall, mAP)뿐 아니라 자연어 설명 품질, 상황 의미 일관성, 운영 효율성 지표 등 새로운 평가 지표를 제안하여 향후 CCTV AI 분야의 연구 방향을 확장하였다. 기존의 객체 탐지 평가 체계는 바운딩 박스의 위치와 클래스 분류 정확도에 집중하였으나, CCTV 관제에서는 '상황이 위험한가?', '어떤 조치가 필요한가?'와 같은 의미 기반 판단이 더 중요하다. 본 연구에서 제안한 평가 틀은 VLM의 추론 품질과 실무 적합성을 다각도로 측정하며, 향후 CCTV AI 연구에서 표준 평가 체계로 발전될 수 있다.

5.3 실무적·산업적 의의

본 연구는 학술적 성과를 넘어 실제 산업·행정 현장에서 중요한 실무적 의미를 가진다. 글로벌 스마트시티 시장은 2024년 약 18.2억 달러에서 2034년 약 139.5억 달러로, 연평균 22.59%의 성장이 전망되며, AI 기반 영상 분석이 핵심 기술로 부상하고 있다. 본 연구의 결과는 이러한 시장 성장의 기술적 기반을 제공하며, 실무적 적용 가능성을 입증한다.

5.3.1 관제센터 운영 효율화

하이브리드 모델은 실무에서 다음과 같은 구체적인 성과를 가져올 수 있다. 첫째, 사건 검토 시간 단축으로 관제요원은 더 많은 화면을 효과적으로 감시할 수 있다. 기존 연구에 따르면 인간 관제요원은 동시에 16개 이상의 화면을 효과적으로 모니터링하기 어렵지만, AI 지원을 통해 이러한 한계가 완화될 수 있다. 둘째, 불필요 출동 감소로 경찰·소방 대응 효율이 증가한다. 오탐으로 인한 잘못된 경보는 긴급 자원의 낭비를 초래하며, 반복적인 오탐은 '경보 피로(alarm fatigue)'를 유발하여 실제 위험에 대한 대응 민감도를 저하시킨다. 셋째, 보고서 자동 생성으로 문서 업무 부담이 감소한다. VLM이 생성하는 자연어 설명은 보고서의 기초 자료로 활용될 수 있으며, 관제요원은 처음부터 보고서를 작성하는 대신 VLM의 출력을 검토하고 수정하는 방식으로 업무를 수행할 수 있다. 넷째, 오탐 감소로 관제요원의 스트레스 및 피로도가 완화된다. 지속적인 경보에 대한 대응은 심리적 부담을 초래하며, 오탐 감소는 이러한 부담을 직접적으로 완화한다.

이러한 효과는 실제 지자체 관제센터 보고서에서 확인된 문제가 하이브리드 기술로 개선될 수 있음을 의미한다. 서울특별시 데이터센터의 CCTV 운영 실태 분석에 따르면, 관제요원의 주요 애로사항으로 오탐에 의한 경보 피로, 보고서 작성 업무 부담, 동시 다화면 모니터링의 어려움 등이 지적되었으며, 본 연구의 하이브리드 구조는 이러한 문제에 대한 기술적 해결책을 제시한다.

5.3.2 스마트시티·스마트빌딩 적용 가능성

Vision AI 모델-VLM 하이브리드 구조는 CCTV 관제를 넘어 다양한 분야로 확장 가능하다. 첫째, 스마트시티 도시안전 관제 시스템에 적용될 수 있다. 스마트시티의 핵심 구성요소 중 하나인 지능형 영상 감시 시스템(Intelligent

VSS)은 객체 탐지, 추적, 얼굴 인식, 이상 탐지, 사고 예측 등 다양한 기능을 통합적으로 제공해야 한다. 하이브리드 구조는 이러한 다양한 요구사항을 효과적으로 충족시킬 수 있다.

둘째, 대규모 시설물(공항·철도·항만) 모니터링에 적용될 수 있다. 이러한 국가 기반시설은 오탐에 민감하며, 미탐은 더욱 치명적이기 때문에 하이브리드 구조의 도입 가치가 매우 크다. 셋째, 병원·요양시설 낙상 탐지 시스템에 적용될 수 있다. 고령 인구의 증가와 함께 낙상 사고 예방의 중요성이 커지고 있으며, 하이브리드 구조는 숙임 vs 낙상을 정확히 구분하여 불필요한 경보를 줄이면서도 실제 낙상을 놓치지 않을 수 있다. 넷째, 산업 안전(안전장구 착용, 위험 행동 탐지)에 적용될 수 있다. 공장, 건설 현장 등에서의 안전 규정 준수 모니터링은 산업재해 예방에 핵심적이며, AI 기반 자동 탐지는 인력 부족 문제를 해결할 수 있다. 다섯째, 빌딩 관리(연기/화재 조기 탐지, 출입 보안 강화)에 적용될 수 있다. 화재의 조기 발견은 대형 피해를 방지하는 핵심이며, VLM의 시공간 패턴 분석은 초기 단계의 연기를 효과적으로 탐지할 수 있다.

5.3.3 글로벌 시장 동향과의 부합

본 연구의 결과는 글로벌 AI 영상 감시 시장의 주요 동향과 부합한다. 글로벌 시장 분석에 따르면, AI 영상 감시 시장은 하드웨어 중심에서 소프트웨어 지능 중심으로 전환되고 있으며, 2024년 하드웨어가 56.8%의 시장 점유율을 차지하지만, 소프트웨어 부문은 2030년까지 연평균 18.2% 성장이 예측된다. 또한, 하이브리드 Edge-Cloud 아키텍처, 강화된 사이버보안, 통합 상황 인식 플랫폼에 대한 수요가 증가하고 있으며, 이는 본 연구의 Trigger-Validator 구조와 일치하는 방향이다. 한국의 경우, 2026년까지 모든 공공 CCTV에 AI를 도입하는 정책이 추진되고 있어, 본 연구의 실무적 적용 가능성이 더욱 높다.

5.3.4 정책·제도 기반 강화 지원

본 연구의 결과는 다음과 같은 정책적 근거로 활용될 수 있다. 첫째, 지능형 CCTV 고도화 사업 기획에 활용될 수 있다. 국토교통부의 스마트시티 국가전략 프로젝트에서 지능형 CCTV는 핵심 인프라로 지정되어 있으며, 본 연구의 하이브리드 구조는 고도화 사업의 기술적 방향을 제시한다. 둘째, AI 기반 공공안전 표준 모델 개발에 활용될 수 있다. ISO 37106(스마트시티 운영 모델)과 같은 국제 표준에 부합하는 AI 기반 안전관리 모델의 개발에 본 연구의 결과가 참고될 수 있다. 셋째, 도시 데이터 기반 위험 분석 체계 구축에 활용될 수 있다. CCTV에서 수집되는 영상 데이터를 효과적으로 분석하여 도시 안전 위험을 식별하고 예방하는 체계의 구축에 기여할 수 있다. 넷째, 관제센터 인력 운영 정책 개선에 활용될 수 있다. AI 도입에 따른 관제요원의 역할 변화, 필요 인력 규모, 교육 요구사항 등을 설계하는 데 본 연구의 결과가 참고될 수 있다.

5.4 연구의 한계

본 연구는 새로운 방향성을 제시했지만, 다음과 같은 몇 가지 한계도 존재한다. 이러한 한계를 명확히 인식하고 후속 연구에서 해결해 나가는 것이 학술적 발전을 위해 필요하다.

5.4.1 데이터 다양성 부족

Scene-level Split을 적용했음에도 불구하고, 사용된 CCTV Scene의 다양성은 여전히 충분하지 않을 수 있다. 본 연구에서 사용된 데이터셋은 한국의 특정 지역과 환경을 주로 반영하고 있으며, 다른 국가나 문화권의 CCTV 환경과는 차이가 있을 수 있다. 더욱 다양한 도시(대도시, 중소도시, 농촌), 건물 유형(상업시설, 주거시설, 공공시설), 환경 조건(계절, 날씨, 시간대)을 포함한 데이터셋이 구축된다면 모델의 일반화 성능은 크게 향상될 것이다. 또한 데이터셋의 클래스 불균형 문제도 완전히 해결되지 않았으며, 희귀 이벤트(예: 화재,

테러)에 대한 데이터 확보가 여전히 과제로 남아 있다.

5.4.2 VLM 추론 비용 문제

하이브리드 구조는 Vision AI 모델 단독보다 연산 효율적이지만, VLM 추론 자체는 여전히 높은 비용을 요구한다. 본 연구에서 사용된 VLM은 A100 80GB GPU 환경에서 운영되었으며, 이는 일반적인 관제센터에서 쉽게 확보하기 어려운 고가의 하드웨어이다. 최근 Edge AI 분야에서 경량 VLM 연구가 활발히 진행되고 있으며, MiniCPM-V와 같은 모델은 모바일 기기에서도 GPT-4V급 성능을 달성하고 있어 향후 적용 가능성이 높아지고 있다. 그러나 현재 시점에서 경량 VLM의 CCTV 도메인 적용 가능성은 추가 검증이 필요하며, Edge GPU 기반 경량형 VLM 모델 연구가 필요하다.

5.4.3 Hallucination 문제

LLM 특유의 Hallucination 위험성(잘못된 설명 생성)이 완전히 해결되지 않았다. VLM은 때때로 영상에 존재하지 않는 객체나 행동을 설명하거나, 실제 상황과 다른 해석을 제시할 수 있다. CCTV 관제와 같은 안전-중요(safety-critical) 도메인에서는 Hallucination이 실제 사고 대응을 방해할 수 있으므로, 이를 억제하는 방식의 추가 연구가 필요하다. 최근 연구에서는 검색 증강 생성(RAG), 외부 지식 베이스 연동, 다단계 검증 등의 방법으로 Hallucination을 완화하려는 시도가 진행되고 있으며, CCTV 도메인에 특화된 Hallucination 억제 기법의 개발이 필요하다.

5.4.4 실시간 처리 성능의 제약

본 연구의 하이브리드 구조는 Vision AI 모델의 빠른 탐지와 VLM의 정밀한 분석을 결합하지만, VLM 분석 단계에서의 지연은 여전히 존재한다. 10초 길이의 클립을 VLM으로 분석하는 데 평균 3-5초가 소요되며, 이는 실시간 대응이 필요한 긴급 상황에서 병목이 될 수 있다. 이러한 지연을 최소화하기 위해 비

동기 처리, 병렬화, 모델 최적화 등의 추가 연구가 필요하다. 최근 연구에 따르면, 하이브리드 접근법을 통해 영상-텍스트 변환 지연을 43%까지 감소시킬 수 있으며, 이러한 최적화 기법의 적용이 필요하다.

5.5 향후 연구 방향

본 연구의 발전을 위해 다음과 같은 후속 연구가 필요하다. 이러한 연구 방향은 최근 VLM 및 Edge AI 분야의 발전 동향과 산업적 요구를 반영하고 있다.

5.5.1 Multimodal Grounding 및 Scene Graph 결합 연구

Vision AI 모델이 생성한 바운딩 박스를 기반으로 Scene Graph를 구축하고, 이를 VLM에 입력으로 제공하는 확장된 구조를 연구할 필요가 있다. Scene Graph는 영상 내 객체들 간의 관계(예: 'A가 B를 밀친다', 'C가 D 위에 떨어진다')를 명시적으로 표현하므로, VLM의 추론 능력을 더욱 강화할 수 있다. 최근 SpatialVLM과 같은 연구는 VLM에 공간적 추론 능력을 부여하여 정량적 거리 추정까지 가능하게 하고 있으며, 이러한 접근법을 CCTV 도메인에 적용한다면 행동 관계·대상 관계를 더 정확하게 reasoning할 수 있을 것이다 (Zhou et al., 2024).

5.5.2 Long Video 기반 Temporal Reasoning 확장

현재 모델은 2-10초 단위의 짧은 클립을 분석하지만, 실제 관제 상황에서는 더 긴 시간 범위의 맥락 이해가 필요한 경우가 많다. 향후 연구에서는 30초에서 2분 단위의 Long Video 분석 능력을 개발하고, 행동의 시작-전개-결과를 구분하는 능력을 강화해야 한다. 또한 군중 위험 탐지(Crowd Risk Detection) 분야로 확장하여, 점진적인 군중 밀집, 이상 흐름 감지, 잠재적 stampede 위

험 예측 등의 기능을 개발할 수 있다. VideoMAE V2와 같은 최신 모델은 Dual Masking 기법을 통해 Long Video 처리 효율을 개선하고 있으며, 이러한 발전을 CCTV 도메인에 적용하는 연구가 필요하다.

5.5.3 Edge AI 기반 경량형 VLM 연구

실제 관제센터는 클라우드, 온프레미스, 엣지 혼합 구조로 운영되므로, Edge GPU에서 효율적으로 동작하는 경량형 VLM 연구가 필요하다. 최근 Edge AI 분야에서는 경량 VLM 배포에 관한 연구가 활발히 진행되고 있다. NVIDIA의 Cosmos Nemotron은 AWQ 4bit 양자화를 통해 정확도 손실 없이 Edge AI 2.0 애플리케이션을 지원하고 있으며, NVIDIA Jetson Orin과 RTX 기기에서 운영 가능하다. MiniCPM-V는 8B 파라미터로 GPT-4V, Gemini Pro, Claude 3를 능가하는 성능을 달성하면서 모바일 폰에서도 효율적으로 운영되며, 이미지 인코딩 지연이 37초에서 6초로 87% 개선되었다.

Meta의 Llama 3.2는 1B 및 3B 파라미터의 경량 모델을 제공하여 Edge 및 모바일 기기에서의 배포를 지원하며, 128K 토큰 컨텍스트 길이를 지원한다. Microsoft의 Florence-2는 232M 파라미터의 경량 구조로 Raspberry Pi와 같은 Edge 기기에서도 배포 가능하며, YOLO, BERT, Tesseract 등 특화 모델을 통합 대체할 수 있다. 최근 연구에 따르면, 적절한 학습 전략과 고품질 데이터를 활용하면 2-4B 파라미터의 소형 VLM도 7B 이상 모델의 성능에 필적하거나 초과할 수 있다. 이러한 경량 VLM들을 CCTV 도메인에 특화하여 파인 튜닝하고, Trigger-Validator 구조에 통합하는 연구가 필요하다.

5.5.4 Cross-Camera Reasoning 연구

여러 대의 카메라가 같은 장소를 다양한 각도에서 촬영하는 경우, 단일 카메라 분석의 한계를 극복하기 위해 Multi-Camera Tracking, Cross-View Reasoning, Spatio-Temporal Fusion 기법의 결합이 필요하다. 여러 카메라

의 정보를 종합하면 폭력, 화재, 도난 사건을 훨씬 더 정확하게 분석할 수 있으며, 단일 카메라에서 가려지는 영역의 정보도 보완할 수 있다. 최근 연구에서는 VLM을 활용하여 여러 이미지를 동시에 분석하고 추론하는 Multi-Image Reasoning 능력이 발전하고 있으며, 이를 Multi-Camera CCTV 환경에 적용하는 연구가 필요하다. 또한 동일 인물을 여러 카메라에서 추적하는 Re-Identification 기술과 VLM을 결합하면, 범죄 용의자 추적, 미아 찾기 등의 응용이 가능해진다.

5.5.5 관제센터 Human-AI Collaboration 모델 연구

CCTV 관제 업무는 완전 자동화보다 Human-in-the-Loop 구조가 바람직하다는 점이 여러 연구에서 확인되었다. AI는 인간의 판단을 대체하기보다 증강(augment)해야 하며, 최종 의사결정은 인간 관제요원이 수행해야 한다. 향후 연구에서는 AI 추천 기반 사건 우선순위 정렬, 요원 인지 부하 모니터링, 사건 재검증 UI/UX 설계, AI-요원 협력형 의사결정 지원 등의 연구가 필요하다. 특히 AI의 추천과 인간의 판단 사이의 적절한 균형점을 찾고, AI 오류에 대한 인간의 감독 메커니즘을 설계하는 것이 중요하다.

또한 관제요원의 신뢰(Trust)와 수용(Acceptance)에 관한 연구도 필요하다. AI 시스템이 아무리 우수한 성능을 보여도 관제요원이 이를 신뢰하지 않거나 활용하지 않는다면 실무적 효과는 제한적이다. 따라서 AI 시스템의 설명 가능성(Explainability)을 높이고, 관제요원이 AI의 판단 근거를 이해하고 검증할 수 있는 인터페이스를 설계하는 연구가 필요하다. 이러한 Human-AI Collaboration 연구는 기술적 성능 향상과 함께 진행되어야 실제 관제센터에서의 성공적인 도입이 가능할 것이다.

5.5.6 프라이버시 보호 및 규제 준수 연구

CCTV 기반 AI 시스템의 확산과 함께 프라이버시 보호와 규제 준수에 관한

연구도 중요해지고 있다. 유럽의 GDPR과 같은 개인정보보호 규정은 CCTV 시스템의 설계와 운영에 중요한 제약을 부과하며, AI 기반 분석 시스템도 이러한 규제를 준수해야 한다. 최근 연구에 따르면, 프라이버시 필터(얼굴/신체 익명화)를 적용할 경우 VLM의 성능이 2-11% 저하되는 것으로 보고되었으며, 프라이버시 보호와 탐지 성능 사이의 균형을 찾는 연구가 필요하다. 하이브리드 구조에서 기존의 컴퓨터 비전 레이어는 익명화된 데이터에서 더 잘 작동하며, 움직임을 추적하지만 얼굴은 추적하지 않으므로 프라이버시 보호에 유리하다는 연구 결과도 있다.

5.6 결론

본 연구는 Vision AI 모델과 VLM의 구조적 한계를 극복하고, CCTV 도메인에 최적화된 하이브리드 Trigger-Validator 구조를 제안하였다. 실험 결과는 하이브리드 모델이 단독 모델 대비 월등한 성능을 보이며, 실제 관제센터 운영에서도 실질적인 효율성을 제공함을 입증하였다. 오탐 35-40% 감소, 미탐 20-25% 보완, 사건 검토 시간 43% 단축, 보고서 작성 시간 82% 단축 등의 정량적 성과는 하이브리드 구조의 실효성을 명확히 입증하며, 관제요원의 정성적 평가 역시 긍정적이었다.

특히 오탐·미탐 감소, 보고서 자동 생성, 관제요원 인지 부담 완화 등은 공공 안전 분야에서 매우 큰 의미를 가진다. 기존의 인간 인지 기반 감시 시스템은 관제요원의 주의력 한계, 피로도 축적, 동시 다화면 모니터링의 어려움 등으로 인해 효과적인 위험 탐지에 제약이 있었다. Vision AI 모델은 이러한 문제의 일부를 해결하였으나 의미 기반 판단 능력의 부재로 새로운 한계가 발생하였고, 본 연구의 하이브리드 구조는 VLM의 의미 해석 능력을 결합하여 이러한 한계를 효과적으로 극복하였다.

또한 Scene-level Split 구조를 제시함으로써 CCTV AI 연구에서 반드시 고려되어야 할 새로운 표준을 제안하였다. CCTV의 고정된 장면 특성을 고려하지 않은 기존의 Random Split 방식은 배경 편향 문제를 야기하여 실제 배포 환경에서의 일반화 실패를 초래할 수 있다. 본 연구에서 제시한 Scene-level Split 방법론은 이러한 문제를 해결하며, 향후 CCTV 관련 연구의 데이터셋 구축 및 평가 표준으로 활용될 수 있다.

글로벌 시장 동향을 고려할 때, 본 연구의 시의성과 중요성은 더욱 부각된다. 2024년 말까지 전 세계적으로 약 32억 대의 감시 카메라가 운영될 것으로 예측되며, AI 기반 영상 분석 시장은 급격히 성장하고 있다. 특히 Edge AI와 경량 VLM의 발전은 하이브리드 구조의 실무 적용 가능성을 더욱 높이고 있으며, MiniCPM-V, Llama 3.2, Florence-2 등의 경량 모델들은 Edge 기기에서도 높은 성능을 달성하고 있다. 이러한 기술 발전과 함께 본 연구의 Trigger-Validator 구조는 차세대 지능형 관제 시스템의 핵심 아키텍처로 자리잡을 것으로 기대된다.

향후 이 연구는 스마트시티, 스마트빌딩, 산업안전 등 다양한 분야에서 AI 기반 안전관리 기술의 핵심 기반이 될 수 있으며, 도시 전체의 안전 인프라를 고도화하는 데 중요한 역할을 할 것이다. 공항, 철도, 항만 등 국가 기반시설의 보안 강화, 고령화 사회에서의 낙상 사고 예방, 산업 현장에서의 안전 규정 준수 모니터링 등 다양한 응용 분야에서 하이브리드 구조의 적용이 확산될 것으로 전망된다. 본 연구가 제시한 방향성과 실험 결과가 학술적 논의를 촉진하고, 실무적 적용을 가속화하여, 궁극적으로 더 안전하고 효율적인 사회 인프라 구축에 기여하기를 기대한다.

참 고 문 헌

- 경찰청, "CCTV 통합관제센터 운영지침," 2021.
- 국토교통부, "스마트시티 국가전략 프로젝트 종합보고서," 2021.
- 부산광역시 스마트시티센터. (2023). AI 기반 지능형 관제 시범사업 성과 보고서.
- 서울특별시 데이터센터. (2022). CCTV 운영 및 사고 대응 실태 분석
- AI-Hub. CCTV 기반 지능형 관제 서비스 데이터셋.
한국지능정보사회진흥원, 2023.\
- AI-Hub. 이상행동(실신·싸움·화재 등) CCTV 데이터셋.
한국지능정보사회진흥원, 2023.
- Arnab, A., Dehghani, M., Heigold, G., Sun, C., Lucic, M., & Schmid, C. (2021). ViViT: A Video Vision Transformer. Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), 6836-6846.
- Bochkovskiy, A., Wang, C. Y., & Liao, H. Y. M. (2020). YOLOv4: Optimal Speed and Accuracy of Object Detection. arXiv preprint arXiv:2004.10934.
- Buslaev, A., Iglovikov, V. I., Khvedchenya, E., Parinov, A., Druzhinin, M., & Kalinin, A. A. (2020). Albumentations: Fast and Flexible Image Augmentations. Information, 11(2).
- Carion, N., Massa, F., Synnaeve, G., Usunier, N., Kirillov, A., & Zagoruyko, S. (2020). End-to-End Object Detection with Transformers. Proceedings of the European Conference on Computer Vision (ECCV), 213-229.
- Carreira, J., & Zisserman, A. (2017). Quo Vadis, Action Recognition? A New Model and the Kinetics Dataset. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 6299-6308.
- DAMO Academy. (2024). Video-LLaMA 2/3: Advanced Video-Language Models. Alibaba Group Research.
- Dettmers, T., Pagnoni, A., Holtzman, A., & Zettlemoyer, L. (2023). QLoRA: Efficient Finetuning of Quantized Large Language Models. Advances in Neural Information Processing Systems (NeurIPS).
- Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., ... Houlsby, N. (2021). An Image is Worth 16×16 Words: Transformers for Image Recognition at Scale. International Conference on Learning Representations (ICLR).

- Endsley, M. R. (1995). Toward a Theory of Situation Awareness in Dynamic Systems. *Human Factors*, 37(1), 32-64.
- Fairclough, S. H. (2015). Fatigue and Workload in Control Room Monitoring Tasks. *Applied Ergonomics*, 46(A), 23-34.
- Feichtenhofer, C., Fan, H., Malik, J., & He, K. (2019). SlowFast Networks for Video Recognition. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 6202-6211.
- Feichtenhofer, C., Fan, H., Malik, J., & He, K. (2022). Masked Autoencoders as Spatiotemporal Learners. *Advances in Neural Information Processing Systems (NeurIPS)*.
- Girshick, R., Donahue, J., Darrell, T., & Malik, J. (2014). Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 580-587.
- He, K., Chen, X., Xie, S., Li, Y., Dollár, P., & Girshick, R. (2022). Masked Autoencoders Are Scalable Vision Learners. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 16000-16009.
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 770-778.
- Heilbron, F. C., Escorcia, V., Ghanem, B., & Nibbles, J. C. (2015). ActivityNet: A Large-Scale Video Benchmark. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 961-970.
- Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., ... Chen, W. (2022). LoRA: Low-Rank Adaptation of Large Language Models. *International Conference on Learning Representations (ICLR)*.
- Kay, W., Carreira, J., Simonyan, K., Zhang, B., Hillier, C., Vijayanarasimhan, S., ... Zisserman, A. (2017). The Kinetics Human Action Video Dataset. *arXiv preprint arXiv:1705.06950*.
- Li, J., Li, D., Xiong, C., & Hoi, S. (2023). BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models. *International Conference on Machine Learning (ICML)*.
- Lin, T. Y., Dollár, P., Girshick, R., He, K., Hariharan, B., & Belongie, S. (2014). Microsoft COCO: Common Objects in Context. *Proceedings of the European Conference on Computer Vision (ECCV)*, 740-755.
- Lin, T. Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal Loss for Dense Object Detection. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2980-2988.
- Lin, T. Y., Dollár, P., Girshick, R., He, K., & Belongie, S. (2017). Feature Pyramid Networks for Object Detection. *Proceedings of the IEEE Conference on Computer Vision and Pattern*

- Recognition (CVPR), 2117-2125.
- Liu, H., Li, C., Wu, Q., & Lee, Y. J. (2023). Visual Instruction Tuning. *Advances in Neural Information Processing Systems (NeurIPS)*.
- Liu, W., Anguelov, D., Erhan, D., Szegedy, C., Reed, S., Fu, C. Y., & Berg, A. C. (2016). SSD: Single Shot MultiBox Detector. *Proceedings of the European Conference on Computer Vision (ECCV)*, 21-37.
- Parasuraman, R. (1982). Memory Load and Event Rate Control Sensitivity Decrements in Sustained Attention. *Psychological Bulletin*, 92(3), 492-517.
- Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., ... Sutskever, I. (2021). Learning Transferable Visual Models from Natural Language Supervision. *International Conference on Machine Learning (ICML)*, 8748-8763.
- Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). You Only Look Once: Unified, Real-Time Object Detection. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 779-788.
- Redmon, J., & Farhadi, A. (2017). YOLO9000: Better, Faster, Stronger. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 7263-7271.
- Redmon, J., & Farhadi, A. (2018). YOLOv3: An Incremental Improvement. *arXiv preprint arXiv:1804.02767*.
- Ren, S., He, K., Girshick, R., & Sun, J. (2015). Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks. *Advances in Neural Information Processing Systems (NeurIPS)*.
- Shorten, C., & Khoshgoftaar, T. M. (2019). A Survey on Image Data Augmentation for Deep Learning. *Journal of Big Data*, 6(60).
- Simonyan, K., & Zisserman, A. (2014). Two-Stream Convolutional Networks for Action Recognition in Videos. *Advances in Neural Information Processing Systems (NeurIPS)*, 568-576.
- Stedmon, A., & Stone, R. (2011). Human Factors in Multi-Monitor CCTV Surveillance: Implications for Future Policy and Practice. *Human Factors*, 53(2), 143-154.
- Tong, Z., Song, Y., Wang, J., & Wang, L. (2022). VideoMAE: Masked Autoencoders are Data-Efficient Learners for Self-Supervised Video Pre-Training. *Advances in Neural Information Processing Systems (NeurIPS)*.
- Touvron, H., Lavril, T., Izacard, G., Martinet, X., Lachaux, M. A., Lacroix, T., ... Lample, G. (2023). LLaMA: Open and Efficient Foundation Language Models. *arXiv preprint arXiv:2302.13971*.
- Tran, D., Bourdev, L., Fergus, R., Torresani, L., & Paluri, M. (2015). Learning Spatiotemporal Features with 3D Convolutional Networks. *Proceedings of the IEEE International Conference on*

- Computer Vision (ICCV), 4489-4497.
- Ultralytics. (2022). YOLOv5: State-of-the-Art Object Detection Models. <https://github.com/ultralytics/yolov5>
- Ultralytics. (2024). YOLOv11: Next Generation Real-Time Detection. Technical Documentation.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems* (NeurIPS), 5998-6008.
- Wang, L., Tong, Z., Ji, B., & Wu, G. (2022). VideoMAE V2: Scaling Video Masked Autoencoders with Dual Masking. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.
- Wang, L., Xiong, Y., Wang, Z., Qiao, Y., Lin, D., Tang, X., & Van Gool, L. (2016). Temporal Segment Networks: Towards Good Practices for Deep Action Recognition. *Proceedings of the European Conference on Computer Vision (ECCV)*, 20-36.
- Wojke, N., Bewley, A., & Paulus, D. (2017). Simple Online and Realtime Tracking with a Deep Association Metric. *Proceedings of the IEEE International Conference on Image Processing (ICIP)*, 3645-3649.
- Zhang, X., Li, Y., Wang, Z., Wu, J., Chen, Y., & Qiao, Y. (2023). Video-LLaMA: An Instruction-Tuned Audio-Visual Language Model for Video Understanding. *arXiv preprint arXiv:2306.02858*.
- Zhu, X., Su, W., Lu, L., Li, B., Wang, X., & Dai, J. (2021). Deformable DETR: Deformable Transformers for End-to-End Object Detection. *International Conference on Learning Representations (ICLR)*.

국 문 초 록

통합관제센터 운영을 위한 Vision AI 모델- VLM 비교 및 하이브리드 연구

중앙대학교 대학원

ICT안전학과

ICT안전전공

김현수

현대 도시의 공공안전 확보를 위해 CCTV 통합관제센터의 역할이 점차 중요해지고 있으나, 관제요원 1인당 수백 대의 카메라를 모니터링해야 하는 현실에서 인간 인지의 한계로 인한 사건 탐지 지연과 누락이 빈번하게 발생하고 있다. 이를 해결하기 위해 Vision AI 모델 기반 지능형 영상분석 기술이 도입되었으나, 단일 프레임 분석에 기반한 구조적 한계로 인해 시간적 맥락을 고려하지 못하고, 시각적으로 유사한 상황에서 높은 오탐률을 보이는 문제가 지속되고 있다.

본 연구는 Vision AI 모델의 실시간 탐지 능력과 Video Language Model(VLM)의 시간적 맥락 이해 및 의미 기반 추론 능력을 결합한 Trigger-Validator 하이브리드 구조를 제안한다. 이 구조에서 Vision AI 모델은 전체 CCTV 스트림을 실시간으로 모니터링하며 의심 상황을 1차 탐지하는 Trigger 역할을 수행하고, VLM은 탐지된 후보 이벤트에 대해 시간적 맥락을 분석하여 실제 위험 여부를 판단하는 Validator 역할을 담당한다.

연구 방법론으로는 CCTV 도메인의 장면 고착성 특성을 고려한 Scene-level Split 기반 데이터셋 구축 방식을 적용하여 모델의 실제 일반화 능력을 정확히 평가하였다. 쓰러짐, 폭행, 연기의 세 가지 주요 이벤트 유형에 대해 YOLOv11 기반 Vision AI 모델과 VideoMAE-LLaMA 기반 VLM을 구축하고, 하이브리드 구조의 효과를 정량적·정성적으로 분석하였다.

실험 결과, Vision AI 모델 단독 적용 대비 하이브리드 구조에서 오탐률이 평균 40% 이상 감소하였으며, VLM의 의미 기반 분석을 통해 숙임과 낙상, 장난과 폭행, 수증기와 연기 등 시각적으로 유사한 상황의 구분이 가능함을 확인하였다. 또한 VLM이 생성하는 자연어 설명은 관제요원의 상황 판단을 효과적으로 지원하여 Human-in-the-Loop 관점에서의 관제 품질 향상에 기여하였다.

본 연구는 Vision AI 모델과 VLM의 상호 보완적 결합을 통한 CCTV 관제 고도화의 가능성을 실증적으로 검증하였으며, 스마트시티 안전 인프라 구축을 위한 새로운 기술적 방향을 제시한다는 점에서 학술적·실무적 의의를 갖는다.

주제어: CCTV 통합관제, Vision AI 모델, Video Language Model, 하이브리드 구조, 지능형 영상분석, 스마트시티

Abstract

A Comparative Study of Vision AI Model and VLM with Hybrid Approach for Integrated Control Center Operations

HyunSoo. Kim
Major in ICT Safety
Department of ICT Safety
The Graduate School
Chung-Ang University

As CCTV integrated control centers play an increasingly vital role in ensuring urban public safety, the limitations of human cognition—where a single operator must monitor hundreds of cameras—frequently result in delayed or missed event detection. While Vision AI 모델-based intelligent video analytics have been introduced to address this challenge, their structural limitations rooted in single-frame analysis prevent temporal context understanding and lead to high false positive rates in visually similar situations.

This study proposes a Trigger-Validator hybrid architecture that combines the real-time detection capabilities of Vision AI Model with the temporal context understanding and semantic reasoning abilities of Video Language Models (VLM). In this architecture, Vision AI Model serves as the Trigger, continuously monitoring all CCTV streams to detect suspicious situations in real-time, while VLM acts as the

Validator, analyzing the temporal context of detected candidate events to determine actual risk levels.

The methodology employs a Scene-level Split approach for dataset construction, accounting for the scene-fixation characteristics inherent to CCTV domains, thereby enabling accurate evaluation of model generalization capabilities. YOLOv11-based Vision AI Model and VideoMAE-LLaMA-based VLM were developed for three primary event types—fall detection, violence detection, and smoke detection—and the effectiveness of the hybrid architecture was analyzed both quantitatively and qualitatively.

Experimental results demonstrate that the hybrid architecture achieves an average reduction of over 40% in false positive rates compared to Vision AI Model alone. The VLM's semantic analysis capability successfully distinguishes visually similar situations such as bending versus falling, playful interaction versus assault, and steam versus smoke. Furthermore, the natural language explanations generated by VLM effectively support operators' situational judgment, contributing to improved surveillance quality from a Human-in-the-Loop perspective.

This research empirically validates the potential for advancing CCTV surveillance through the complementary integration of Vision AI Model and VLM, presenting both academic and practical significance by proposing a new technological direction for smart city safety infrastructure development.

Keywords: CCTV Integrated Control, Vision AI Model, Video Language Model, Hybrid Architecture, Intelligent Video Analytics, Smart City