



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.


이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

석사학위청구논문
2024학년도

건설현장 위험요인 식별을 위한
RAG와 Fine-tuning 기반
LLM 성능향상에 관한 연구

Study on improving LLM performance
based on RAG and Fine-tuning
for identifying construction site risk factors



광운대학교 대학원

건축공학과

왕 인 국

건설현장 위험요인 식별을 위한
RAG와 Fine-tuning 기반
LLM 성능향상에 관한 연구

Study on improving LLM performance
based on RAG and Fine-tuning
for identifying construction site risk factors

지 도 교 수 유 정 호

이 논문을 공학 석사학위 청구논문으로 제출함.

2024년 12월

광운대학교 대학원

건축공학과

왕 인 국

왕 인 국의 공학 석사 학위논문을 인준함.

심사위원장 김 재 요



심사위원 유 정 호



심사위원 이 슬 기



광운대학교 대학원

2024년 12월

국문 요약

건설현장 위험요인 식별을 위한 RAG와 Fine-tuning 기반 LLM 성능향상에 관한 연구

왕 인 국

건축공학과

광운대학교 대학원

산업안전보건법 개정안 시행과 중대재해처벌법 시행으로 인해 건설현장의 안전관리 업무가 강화되면서, 현장에서는 인력 부족과 과도한 서류작업 등의 문제에 직면하고 있다. 이러한 문제는 현장에서 유해·위험요인 식별 단계에 투입하는 시간이 감소하고, 위험요인 정보의 누락 가능성이 증대되는 문제로 이어지고 있다. 이에 LLM을 활용한 업무 자동화 기술이 대안으로 주목받고 있으나, 범용 LLM은 건설 안전 분야에 대한 지식 부족으로 전문성의 한계가 존재한다.

본 연구에서는 LLM의 전문성 한계를 극복하고, 위험요인 식별에 적합한 LLM을 구현하기 위해 Fine-tuning과 RAG(Retrieval-Augmented Generation) 기법을 적용한 성능향상에 관한 실험연구를 진행하였다. 실험은 철근·콘크리트 공사와 유해·위험요인 식별 절차를 대상으로 진행하였다. 또한, 실험 시나리오는 Fine-tuning과 RAG를 개별적으로 적용한 경우와 두 방법을 통합하여 구성한 경우(Fine-tuning+RAG, Fine-tuning+MM-RAG)로 구성하여 진행하였으며, 각각의 구성 방식을

적용한 GPT 모델의 답변성능을 정량적(BLEU, ROUGE, BERT Score) 및 정성적 평가를 통해 분석하였다. 실험 결과, Fine-tuning과 MM-RAG 통합 구성방식이 가장 우수한 성능을 보였으며, 특히 BLEU, ROUGE, BERT Score의 정량적 평가에서 높은 점수를 기록하였다.

본 연구는 Fine-tuning과 RAG, MM-RAG(Multi-Modal RAG)와 같은 최신 기법을 적용하여 LLM의 전문성을 향상시키는 효과적인 방법을 도출하였으며, 이를 통해 기존 범용 LLM이 가진 한계를 극복하고 위험요인 식별에 적합한 LLM의 개발 방향성을 제시하였다는 점에서 학술적 의의가 있다. 또한, MM-RAG를 통해 기존 건설 분야의 LLM 연구에서 확장된 접근법을 활용하였으며, 이를 바탕으로 LLM 연구의 새로운 가능성을 열었다는 점에서 학술적 의의가 있다.

그리고 설문 기반의 정성적 평가를 통해 건설현장 위험요인 식별에 LLM을 실질적으로 활용하기 적합하다는 것을 확인하였다. 특히, Fine-tuning과 MM-RAG 통합 구성방식을 적용한 LLM은 전문인력을 가능한 수준임을 확인하였다. 이에 본 연구는 전문인력을 대체하고 보조할 수 있는 LLM을 구현하였으며, 이를 바탕으로 한 도구개발의 기술적 기반을 마련하였다는 점에서 실무적 의의가 있다.

.....

핵심어 : 위험성평가, 위험요인 식별, LLM, RAG, 검색증강생성, Fine-tuning, 미세조정

ABSTRACT

Study on improving LLM performance based on RAG and Fine-tuning for identifying construction site risk factors

Wang In Kuk

Department of Architectural Engineering
Graduate School, KwangWoon University

As safety management work at construction sites is strengthened due to the enforcement of the revised Occupational Safety and Health Act and the Serious Accidents Punishment Act, sites are facing various problems such as a lack of manpower and excessive paperwork. These problems lead to a decrease in the time invested in the identification stage of hazardous and dangerous factors at sites and an increase in the possibility of missing information on hazardous factors. Accordingly, work automation technology using LLM is attracting attention as an alternative, but general-purpose LLM has limitations in expertise due to a lack of knowledge in the field of construction safety. In this study, an experimental study on performance improvement by applying the Fine-tuning and RAG (Retrieval-Augmented Generation) techniques was conducted to overcome the limitations in expertise of LLM and implement an LLM suitable for identifying hazardous factors. The experiment was conducted on reinforced concrete construction and the identification process of hazardous and dangerous factors. In addition, the experimental scenarios were conducted by configuring cases where Fine-Tuning and RAG were applied individually and cases where the two methods were integrated (Fine-tuning+RAG,

Fine-tuning+MM-RAG), and the response performance of the GPT model applied with each configuration method was analyzed through quantitative (BLEU, ROUGE, BERT Score) and qualitative evaluations. The experimental results showed that the integrated configuration method of Fine-Tuning and MM-RAG showed the best performance, and in particular, it recorded high scores in the quantitative evaluation of BLEU, ROUGE, and BERT Score. This study has academic significance in that it derived an effective method to improve the expertise of LLM by applying the latest techniques such as Fine-Tuning, RAG, and MM-RAG (Multi-Modal RAG), and thereby overcoming the limitations of existing general-purpose LLMs and suggesting the development direction of LLMs suitable for risk factor identification. In addition, it has academic significance in that it has utilized an extended approach in the existing LLM research in the construction field through MM-RAG, and opened up new possibilities for LLM research based on this. In addition, it has been confirmed that LLM is suitable for practical use in identifying risk factors in construction sites through a qualitative evaluation based on a questionnaire. In particular, it has been confirmed that LLM that applied the integrated composition method of Fine-tuning and MM-RAG is at a level that allows professional manpower. Accordingly, this study has practical significance in that it has implemented LLM that can replace and assist professional manpower, and has established the technical foundation for tool development based on this.

.....

Keyword : Risk assessment, Risk Factors Identification, LLM, RAG,

Retrieval-Augmented Generation, Fine-tuning

목 차

국문 요약	i
Abstract	iii
목 차	v
그림목차	viii
표 목 차	x

제 1장 서 론 1

1.1. 연구의 배경 및 목적	1
1.1.1 연구의 배경	1
1.1.2 연구의 목적	3
1.2. 연구의 범위	4
1.3 연구의 방법 및 절차	6
1.3.1 연구의 방법	6
1.3.2 연구의 절차	7

제 2장 예비적 고찰 8

2.1 건설 안전 분야 LLM 연구 동향	8
2.2 RAG 및 Fine-tuning 연구 동향	23
2.2.1 RAG(Retrieval Augmented Generation)	23
2.2.2 Fine-tuning	39

2.2.3 Fine tuning과 RAG 통합 연구	49
2.3. LLM 성능 평가지표	52
2.3.1 BLEU	53
2.3.2 ROUGE	54
2.3.3 Bert Score	55
2.4 소결	56
 제 3장 RAG와 Fine-tuning 프로세스 및 시스템 구축	58
3.1 성능향상 전략	58
3.1.1 성능평가를 위한 모범답안 구성(벤치마크 데이터셋)	58
3.1.2 범용 GPT의 한계	60
3.1.3 범용 GPT의 한계 해결전략	62
3.1.4 성능향상 전략 기반 시스템 구축	64
3.2 Fine-tuning(A)	70
3.2.1 데이터 수집 및 생성	70
3.2.2 Fine-tuning Framework 구축	71
3.2.3 하이퍼파라미터 설정	77
3.3 RAG(B)	82
3.3.1 데이터 전처리 및 Chunking	82
3.3.2 Embedding 및 Indexing	86
3.3.3 검색 및 벡터 DB(1)	89

3.4 MM-RAG(C)	92
3.4.1 Table & Image 처리 모듈(i)	93
3.4.2 텍스트 처리 모듈(ii)	96
제 4장 GPT 성능평가	98
4.1 정량적 평가	101
4.1.1 BLEU Score	101
4.1.2 ROUGE Score	102
4.1.3 BERT Score	104
4.2 정성적 평가	109
4.2.1 설문평가	109
4.3 결과분석	111
제 5장 결론	112
5.1 연구의 결과	112
5.2 연구의 의의	114
5.3 연구의 한계 및 향후 연구	115
참 고 문 헌	117
부 록	122

그림 목 차

<그림 1-1> 공종별 사망자 수 및 부상자 수 (국토안전관리원, 2024)	4
<그림 1-2> 연구의 절차	7
<그림 2-1> RAG 개요(Patrick Lewis et al. 2021)	23
<그림 2-2> RAG 프로세스	24
<그림 2-3> Playground 플랫폼 내 Fine-tuning 확인 기능	40
<그림 2-4> Fine-tuning 프로세스	40
<그림 2-5> LLM 정확도(Accuracy) 평가방법	52
<그림 2-6> Bert score 계산 원리(Zhang et al. 2020)	56
<그림 3-1> a. 유해·위험요인 예시 데이터(KRAS)	59
<그림 3-2> b. 핵심위험요인(SIF) 평가표 예시(안전보건공단, 2023)	59
<그림 3-3> 위험요인 정보생성 시스템 개요	62
<그림 3-4> 성능향상 전략(해결전략)	63
<그림 3-5> Fine-tuning 및 RAG 프로세스 기반 통합시스템 구성도	67
<그림 3-6> Fine-tuning 및 MM-RAG 프로세스 기반 통합시스템 구성도	69
<그림 3-7> Fine-tuning(A) 프로세스 세부 모듈 구성도	70
<그림 3-8> d. JSONL 파일 예시	74
<그림 3-9> 작동점검 모듈 활용 예시	76
<그림 3-10> RAG(B) 프로세스 세부 모듈 구성도	82
<그림 3-11> 콘크리트공사의 안전보건작업 지침.pdf	82
<그림 3-12> 전처리 된 Text	82
<그림 3-13> Chunked Text	86
<그림 3-14> Embedding 결과물	87
<그림 3-15> Chroma DB 내부	91

<그림 3-16> MM-RAG(C) 세부 모듈 구성도	92
<그림 3-17> 문서 내 표 인식 결과	93
<그림 3-18> 문서 내 표 이미지 추출 결과	94
<그림 3-19> 표 이미지의 정보추출 결과	95
<그림 3-20> 표 단위별 Chunking 결과	95
<그림 3-21> PDF 문서 내부	97
<그림 3-22> 벡터 데이터베이스 내부	97
<그림 4-1> 구성 방법에 따른 실험 시나리오	98
<그림 4-2> BLEU Score 결과	101
<그림 4-3> ROUGE-1 Score 결과	102
<그림 4-4> ROUGE-L Score 결과	103
<그림 4-5> BERT Score 결과	104
<그림 4-6> 효율성 설문 결과	110
<그림 4-7> 효과성 설문 결과	110

표 목 차

<표 1-1> 연구의 범위	5
<표 2-1> 건설 안전 분야 LLM 활용 연구(국내)	13
<표 2-2> 건설 안전 분야 LLM 활용 연구(국외)	17
<표 2-3> 타 분야 RAG 연구사례	31
<표 2-4> 건설 분야 RAG 기술 활용 연구	36
<표 2-5> 데이터베이스 장·단점	37
<표 2-6> 1단계 데이터 생성 (예시)	41
<표 2-7> 2단계 데이터 형식	41
<표 2-8> 타 분야 Fine-tuning 관련 기존연구	44
<표 2-9> 건설 분야 Fine-tuning 관련 기존연구	48
<표 2-10> RAG와 Fine-tuning 통합 연구	51
<표 2-11> BLUE Score 예시	53
<표 2-12> ROUGE N-gram(N=2) 예시	55
<표 3-1> 모범답안 (콘크리트 공사- 콘크리트 운반 작업예시)	59
<표 3-2> 콘크리트 공사 답변 비교	61
<표 3-3> 거푸집 공사 답변 비교	61
<표 3-4> Fine-tuning 학습용 데이터셋 생성(일부 예시)	70
<표 3-5> Fine-tuning Framework 세부 모듈	71
<표 3-6> 데이터 전처리 모듈 기능	72
<표 3-7> JSON 형식(예시)	73
<표 3-8> 데이터셋 형식 검증 코드	73
<표 3-9> Train/Validation set 분할 및 파일 형식 변환 코드	74
<표 3-10> 데이터셋 업로드 코드	74
<표 3-11> Fine-tuning 모듈(A-4) 코드	75

<표 3-12> 하이퍼파라미터의 주요 변수 및 정의	78
<표 3-13> 하이퍼파라미터 설정 코드	79
<표 3-14> Epoch 수와 Batch Size의 조합에 따른 성능	80
<표 3-15> Epoch 수와 Learning Rate Multiplier의 조합에 따른 성능	81
<표 3-16> Chunking(B-2) 코드 구성	86
<표 3-17> Embedding(B-3) 모듈 코드 구성	87
<표 3-18> Indexing(B-4) 코드 구성	88
<표 3-19> 검색(B-5) 구성 코드	90
<표 3-20> 벡터 DB 모듈(B-6) 구성 코드	91
<표 4-1> System Instruction 구성	99
<표 4-2> 성능 기준별 활용지표	100
<표 4-3> BLEU Score 결과	101
<표 4-4> ROUGE-1 Score 결과	102
<표 4-5> ROUGE-L Score 결과	103
<표 4-6> BERT Score 결과	104
<표 4-7> 콘크리트 타설 및 다짐/운반 작업(모범답안)	105
<표 4-8> 콘크리트 타설 및 다짐/운반 작업(범용 GPT)	105
<표 4-9> 콘크리트 타설 및 다짐/운반 작업(RAG-GPT)	106
<표 4-10> 콘크리트 타설 및 다짐/운반 작업(Finetuned-GPT)	107
<표 4-11> 콘크리트 타설 및 다짐/운반 작업(Finetuned-GPT+RAG)	107
<표 4-12> 콘크리트 타설 및 다짐/운반 작업(Finetuned-GPT+MM-RAG)	108
<표 4-13> 설문대상	109
<표 4-14> 설문 평가방법	109
<표 4-15> 설문평가 항목	110

제 1장 서론

1.1 연구의 배경 및 목적

1.1.1 연구의 배경

1) 안전 규정 강화로 인한 문제점

정부는 산업안전보건법 개정안 시행, 중대재해처벌법 시행 등 안전사고 예방을 목적으로 안전 규정을 강화하고 있다. 하지만 현장에서는 이로 인한 안전관리 인력문제와 서류업무 과다 문제가 발생하고 있다.

산업안전보건법 개정안 시행(2020년)으로 인해 건설업 안전관리자 선임 대상 사업장의 범위가 기존 120억 원 이상에서 50억 원 이상으로 확대되었으며, 의무적으로 안전관리자를 배치해야 할 대상 현장이 증가하였다. 또한, 중대재해처벌법 시행(2022년 1월)을 통해 안전·보건 관리체계 구축 및 이행 의무사항이 강화되었으며, 건설현장의 안전관리 인력 배치에 대한 의무가 더욱 강화되었다. 이처럼 정부의 안전 규정 강화로 인해 건설현장에서는 안전관리 전문인력 수요가 급격하게 증가하였다. 하지만, 건설 산업의 인력공급 여건상 이러한 수요를 충족시키기 어려운 실정이다. 특히 대규모 현장과 비교하여 인력확보 및 유지 경쟁력이 상대적으로 약한 중·소규모 건설현장을 중심으로 인력 수급 문제가 더욱 심화되고 있다 (최수영, 2022).

이와 더불어 안전 규정 강화로 인한 현장 안전관리자의 서류 업무과다 문제도 발생하고 있다. 기존 산업안전보건법에 근거하여 현장 안전관리자가 작성해야 할 서류는 약 180종에 이른다. 여기에 건설기술진흥법과 중대재해처벌법에 근거한 약 20종의 서류까지 추가로 포함하면 총 200종 이상의 많은 양의 서류가 요구된다. 이처럼 과다한 서류업무량은 현장 안전관리가 현장 점검 중심이 아닌 문서작업 중심으로 변질되는 결과를

초래하고 있으며, 안전관리자가 현장 점검에 투입 가능한 시간을 감소시키게 만든다.

이는 결국 현장의 형식적인 안전관리 업무 환경을 조성하며, 안전관리 업무의 핵심인 현장 순회점검 및 유해·위험요인 파악 과정에서 중요 정보의 누락과 같은 인적오류 발생 가능성을 증가시킨다.

2) LLM (Large Language Model)의 활성화

ChatGPT 등장 이후 우수한 텍스트 처리(NLP) 및 생성(NLG) 능력에 관심이 폭발적으로 증가했으며, 건설 분야에서 이러한 LLM을 활용하기 위한 연구가 활발하게 진행되고 있다. 특히 건설현장 안전관리 업무에 적용하는 방안도 주목받고 있다. 기존의 안전관리 업무는 서류작업, 현장 모니터링 등 반복적이고 인적오류 발생 확률이 높은 작업이 대부분이다. 많은 건설 분야의 연구에서 이렇게 반복적이고 인적오류 발생 확률이 높은 작업을 LLM을 활용하여 자동화하거나 보조하고자 하는 시도가 이루어지고 있다. 그러나 현재 일반적으로 활용되고 있는 LLM(GPT, Bard, PaLM 등)은 방대한 범용적 지식을 기반으로 학습된 모델이다. 이러한 범용 LLM이 초기에 학습되지 않은 전문 분야에서 활용될 경우, 모델이 사용자의 의도와 맞지 않는 결과나 부정확한 정보를 생성하는 환각 현상(Hallucination)이 발생하게 된다(Sammour et al., 2024). 따라서 범용 LLM을 건설 안전관리 업무와 같은 전문 지식을 요구하는 작업에 그대로 활용하기에는 다소 한계가 존재한다.

이러한 범용 LLM의 전문성 한계를 해결하는 방안으로 Fine-tuning과 RAG(Retrieval-Augmented Generation)와 같은 방법이 존재한다. Fine-tuning은 소량의 데이터셋을 기반으로 LLM을 추가 학습시키는 방법으로 LLM의 특정 분야에 대한 전문성을 강화할 수 있다. RAG는 답변 생성 과정에서 LLM이 외부 데이터베이스의 정보를 참조하여 답변하

는 과정으로 부정확한 정보의 생성을 방지할 수 있으며, 답변내용의 정확성을 향상시킬 수 있다.

이러한 기술적 접근방법은 의료, 금융 등의 전문 지식을 요구하는 분야에서 LLM 개발에 활용되고 있다. 건설 분야에서도 단순 반복 업무에서부터 전문 지식을 요구하는 업무까지 LLM 관련 연구가 광범위하게 이루어지고 있으며, 이를 활용한 전문인력 보조 및 대체를 통해 업무 효율성 향상에 대한 기대도 높아지고 있다 (Saka et al., 2023).

1.1.2 연구의 목적

건설현장에서 위험성 평가는 안전사고를 예방하기 위한 핵심적인 업무이다. 특히, 위험성 평가 절차의 2단계에 해당하는 유해·위험요인 식별 단계(2단계)는 안전사고 예방에 핵심적인 역할을 한다. 그러나 건설현장에서는 안전관리 전문인력 부족, 과도한 서류작업 등으로 인해 유해·위험요인 식별 단계에 투입하는 시간이 감소하고, 정보의 누락 가능성이 증대되는 문제가 발생하고 있다.


이와 같은 한계점들을 극복하기 위해 전문인력을 보조하거나 대체할 수 있는 LLM이 주목받고 있다. 그리고 이를 건설 안전 분야에서 활용하기 위해 Fine-tuning 및 RAG 등의 기술적 접근을 활용한 LLM 관련 연구도 활발히 진행되고 있으며, 이를 위험성 평가에 활용한 선행 연구 사례도 존재한다. 그러나, LLM을 전문 분야에서 활용하기 위한 기술적 접근방법 중 어떤 방법이 가장 효과적이고, 좋은 성능을 보이는지에 대한 연구는 부족한 실정이다. 이에 본 연구에서는 LLM의 성능향상 방법인 Fine-tuning과 RAG 프로세스를 기반으로 실험 시나리오를 설계하고, 각 방법에 대한 성능평가를 진행한다. 그리고 이를 통해 LLM의 성능향상에 가장 효과적인 방법론을 도출하고, 위험성평가 업무에서 LLM을 활용하기 위한 기술적 기반을 마련하는 것을 목적으로 한다.

1.2 연구의 범위

1) 공종의 범위

국토안전관리원 사고정보분석실(2024)에 따르면 건설사고 발생 주요 5대 공종으로 철근·콘크리트 공사, 철골 공사, 해체 및 철거공사, 토공사, 가설공사가 포함되는 것으로 나타났다. 또한, 주요 5대 공종의 총 사망 및 부상자 수는 2021년(2721명), 2022년(3362명), 2023년(3605명)으로 매년 증가하고 있다. 이중 철근·콘크리트 공사는 전체(21년~23년) 사망·부상자 수의 약 60%(5794명)를 차지하며 가장 많은 사망·부상자 수를 차지하고 있다. 철근·콘크리트 공사는 타워크레인, 콘크리트 펌프카, 거푸집과 같은 중장비 사용이 필수적이며, 중량물 취급, 고소작업 등 다양한 위험요인이 복합적으로 작용하는 공종이다. 특히, 작업 환경의 불안정성과 중장비 사용 과정에서 중대 재해로 이어질 수 있는 작업이 많아, 타 공종에 비해 사고 발생 위험이 상대적으로 크다.

따라서 본 연구에서는 사고 비중이 높고 위험 요소가 다양한 철근·콘크리트 공사를 연구범위로 선정하여 진행하고자 한다.



<그림 1-1> 공종별 사망자 수 및 부상자 수 (국토안전관리원, 2024)

2) 위험성 평가 단계의 범위

건설현장 위험성 평가는 사전준비(1단계), 유해·위험요인 파악(2단계), 위험성 결정(3단계), 감소대책 수립 및 실행(4단계), 결과공유(5단계), 기록 및 보존(6단계) 총 6가지 절차로 구성되어 있다. 이 중 유해·위험요인 파악(2단계)는 관련 작업에서 부상이나 질병을 유발할 수 있는 모든 요인을 파악하는 과정으로, 안전관리의 성공 여부를 결정짓는 핵심적인 절차이다 (국토안전관리원, 2023).

이에 본 연구에서는 공종의 범위에서 선정한 철근·콘크리트 공사와 위험성평가 과정의 핵심 절차인 유해·위험요인 파악(이하 위험요인 식별)을 연구의 범위로 선정하여 진행하였다.

<표 1-1> 연구의 범위

위험성평가의 범위	유해·위험요인 파악(2단계)		
	공종	세부공종	세부작업(12종류)
공종의 범위	철근·콘크리트 공사	콘크리트 공사	콘크리트 타설 및 다짐 작업
			콘크리트 운반 작업
			콘크리트 양생 작업
		철근 공사	철근 반입 작업
			철근 가공 및 운반 작업
			철근조립 작업
		거푸집 공사	자재 운반 작업
			자재 가공 작업
			자재 운반 작업
			거푸집 동바리 해체 작업
			거푸집 동바리 인양 작업
			거푸집 동바리 조립 작업

1.3 연구의 방법 및 절차

1.3.1 연구의 방법

2022년 11월 ChatGPT 출시 이후 GPT 모델의 발전이 가속화되었으며, 이후 OpenAI는 지속적으로 모델 성능을 향상시킨 후속 모델을 발표하고 있다. 2023년까지 GPT-3, GPT-3.5, GPT-4 모델이 출시되었으며, 2024년에는 멀티모달(Multi-Modal)을 지원하는 GPT-4o가 출시되었다. GPT 모델은 뛰어난 자연어 생성(NLG) 능력을 바탕으로 챗봇 개발, 콘텐츠 생성, 번역 등 다양한 분야에 활용되며, 넓은 적용 가능성을 갖추고 있다. 이러한 GPT 모델의 확장성을 기반으로 건설 분야에서도 다양한 연구가 이루어지고 있다.

Ghimire et al.(2023)의 연구에서는 건설 분야에서 GPT를 활용한 연구 동향을 고찰하였으며, OpenAI 사에서 제공하는 API를 활용한 다양한 연구가 진행되고 있음을 확인하였다. 특히, OpenAI의 API는 연구자들이 목적에 맞게 LLM을 구현할 수 있도록 Fine-tuning, 시스템 통합, 맞춤형 워크플로우 구성 등 다양한 기능을 제공한다. 이러한 OpenAI API는 업무 지원 도구의 개발, 자동화 시스템 구축 등 건설 안전관리 분야의 실무적 적용 사례로 이어지고 있다(Ghimire et al., 2023).

본 연구에서도 이러한 OpenAI API의 활용 가능성을 기반으로 GPT-4 모델을 활용하여 연구를 수행하였으며, 성능향상의 방법으로는 Fine-tuning(미세조정)과 RAG(Retrieval-Augmented Generation, 검색 증강 생성) 기법을 적용하였다.

Fine-tuning은 OpenAI API 기능을 활용하여 로컬 환경에서 프레임워크를 구성하고, 공종별 안전관리 지침과 KRAS 위험성 평가 사례 데이터를 바탕으로 질의응답(Q&A) 형태의 데이터셋을 구축하여 학습에 활용하였다. RAG 프로세스 및 시스템 구축과정에서는 LangChain 프레임워크를 활용하였으며, GPT 모델이 벡터 데이터베이스(Vector DB) 내부의 관련 정보를 참조하여 답변을 생성하는 방식으로 구성하였으며, Chroma Vector Database를 사용하였다.

1.3.2 연구의 절차

본 연구의 절차는 <그림 1-2>와 같으며, 세부 내용은 다음과 같다.

- 2장에서는 예비적 고찰을 진행하며, 2.1절에서는 건설 안전 분야의 LLM 활용 연구 동향 고찰을 진행하고, 2.2절에서는 Fine-tuning 및 RAG와 관련 연구 동향 고찰을 진행한다. 2.3절에서는 LLM의 성능을 평가하기 위한 평가지표에 대한 고찰을 진행하며, 2.4절에서는 2.1~2.3의 내용에 대한 소결로 2장을 마무리한다.
- 3장에서는 LLM의 성능평가를 위한 RAG와 Fine-tuning 프로세스 및 시스템 구축을 진행한다. 또한, 시스템 구축과정에서 활용되는 구체적인 성능향상 전략과 이에 대한 세부 모듈을 제시하며, 각 모듈의 데이터 처리 과정에 대하여 설명한다.
- 4장에서는 3장에서 구성한 RAG와 Fine-tuning 프로세스 및 시스템을 기반으로 시스템 구성 방법에 따른 실험 시나리오를 설계한다. 그리고 각 시나리오별 GPT 모델의 성능을 정량·정성적으로 평가한다.



<그림 1-2> 연구의 절차

제 2장 예비적 고찰

2장의 2.1절에서는 건설 안전 분야의 LLM 활용 연구 동향 고찰과 이에 대한 시사점을 도출하며, 2.2절에서는 Fine-tuning 및 RAG 방법과 관련된 연구 동향 고찰과 각 방법의 정의 및 기술적인 세부 내용에 대한 고찰을 진행한다. 2.3절에서는 LLM의 성능을 검증하기 위한 평가 지표에 대한 고찰을 진행하며, 2.4절 소결을 통해 고찰내용을 정리한다.

2.1 건설 안전 분야 LLM 연구 동향

1) LLM(Large Language Model)

LLM이란 Large Language Model의 약어로 자연어 처리(NLP) 및 생성(NLG) 분야에서 주로 활용되며, 인간의 언어를 이해하고 처리하는데 특화된 인공지능 모델이다. LLM은 Transformer 구조를 기반으로 설계되며, 언어 이해와 생성, 변환 작업에 특화된 다양한 모델로 구성된다. Transformer 구조는 인코더(Encoder)와 디코더(Decoder)로 구분할 수 있으며, 둘 중 어떤 구조를 기반으로 모델을 설계하는지에 따라 인코더 기반 모델과 디코더 기반 모델로 구분할 수 있다. 인코더 기반 모델은 입력된 텍스트의 문맥 정보를 학습하고 의미를 이해하는 데 중점을 두며, 주로 텍스트 분석, 정보 검색, 문장 분류 등의 작업에서 활용된다. 대표적으로 BERT, RoBERTa 등이 존재하며, 해당 모델은 양방향 문맥 학습을 통해 텍스트 이해 작업에서 뛰어난 성능을 발휘한다. 반면, 디코더 기반 모델은 텍스트 생성에 특화되어 입력 정보를 바탕으로 다음 단어를 예측하는 방식으로 작동하며, 문서 작성, 대화 생성, 질문 응답 시스템 등 텍스트 생성 작업에서 활용된다. 대표적인 모델로는 GPT와 Llama 등이 존재한다. 이러한 Transformer 기반 모델들은 각각 언어 이해와 생성 작업에서 높은 성능을 발휘하며, 자연어처리의 다양한 분야에 적용되고 있다.

2) 범용 LLM의 한계

범용 LLM을 추가적인 처리 과정 없이 건설 안전 분야에 활용할 경우, 전문성 측면에서 한계가 존재한다. 이러한 한계는 모델이 초기에 학습한 데이터셋의 분야, 종류, 품질과 모델이 답변을 생성하는 내부 작동 방식 등에 기인하여 발생한다.

범용 LLM은 대규모 데이터를 기반으로 학습하였기에 광범위한 지식을 보유하고 있지만, 학습한 대규모 데이터에는 전문 분야(Domain)의 데이터가 포함되어 있지 않아 전문 분야에 대한 지식(Domain-Knowledge)이 부족한 상황이다. 이런 상황에서 해당 분야의 깊은 지식을 요구하는 질문을 모델에 입력하면 맥락에 맞지 않는 답변을 생성하거나 정확한 용어를 적절히 사용하지 못하는 경우가 발생하며, 결국 부정확한 정보를 생성하는 결과를 초래한다(Burtsev et al., 2023). 또한, GPT와 같은 디코더 기반의 LLM은 문장을 생성할 때 확률적으로 다음 단어를 예측하는 방식으로 작동한다 (Deng et al., 2024). 이러한 내부 작동 방식은 학습되지 않은 내용에 대해서도 확률적으로 적합성이 높은 단어들을 조합하여 답변을 생성하여, 사실이 아닌 정보를 마치 사실인 것처럼 생성하는 환각(Hallucination) 현상을 발생시킨다(Rawte et al., 2023).

이러한 한계점들로 인해, 범용 LLM은 건설 안전 분야와 같은 전문 분야에서의 활용 가능성이 크게 제한된다. 또한, 이러한 범용 LLM을 건설현장의 위험요인 식별의 도구로 활용한다면, 사용자에게 잘못된 정보를 제공하고 현장의 안전관리 업무의 효율성을 저해할 수 있다. 따라서 범용 LLM을 건설 안전 분야에 활용하기 위한 추가적인 처리 과정이 필요하며, 기존 LLM이 가진 한계를 보완하고 전문성을 강화할 수 있도록 성능향상을 위한 기술적 접근이 필요하다.

3) LLM 성능향상 방법

범용 LLM의 성능적 한계를 극복하는 방법에는 대표적으로 Fine-tuning(미세조정), RAG(Retrieval Augmented Generation, 검색증강생성), 프롬프트 엔지니어링(Prompt Engineering)이 존재하며 각각의 장점 및 단점은 다음과 같다. Fine-tuning은 사전학습된 언어 모델(Pre-trained Language Model, PLM)을 특정 전문 분야와 업무에 맞게 조정하는 과정이다. 전문 지식 또는 특정 태스크에 대한 데이터셋을 활용하여 모델의 파라미터를 학습시킴으로써, 특정 작업에서의 성능을 극대화할 수 있다. 또한, Fine-tuning은 GPT와 같은 디코더 기반 모델뿐만 아니라 BERT와 같은 인코더 기반 모델의 성능 개선에도 유용한 방법이다. 하지만 학습에 비용과 시간이 소모되며 데이터셋의 품질에 따라 성능이 크게 좌우될 수 있다는 단점이 존재한다. RAG는 LLM의 기본적인 성능에 외부 데이터베이스나 검색 시스템의 정보를 통합하여 응답을 생성하는 방식으로 GPT와 같은 디코더 기반 모델의 성능향상에 효과적인 방법이다. RAG는 모델의 학습데이터에 포함되지 않은 내용을 최신 정보나 특정 전문 분야에 대한 정보를 검색하고 이를 바탕으로 답변을 생성한다. 이를 통해 답변의 정확성을 향상시키며, 효율적인 자원 활용과 확장성을 제공하는 강력한 기법이다. 하지만, RAG 기반의 LLM을 활용하게 되면 시스템의 복잡성이 증가하며 데이터베이스에 대한 의존도가 높다는 단점이 존재한다. Prompt Engineering은 모델의 내부 파라미터를 변경하지 않고, 입력(Prompt)을 설계하거나 조정하여 모델이 특정 작업에서 원하는 결과를 생성하도록 유도하는 기법이다. 사용자는 프롬프트에 예제, 명령, 또는 특정 지시에 관한 내용을 포함시켜, 모델의 응답 품질과 스타일을 최적화한다. 이 방법은 모델 내부의 업데이트나 기술적인 변경 없이 구현 가능하며, 다양한 태스크에 즉시 적용할 수 있는 장점이 있다. 하지만, 복잡한 작업이나 전문 분야에서는 성능 개선의 정도가 제한된다는 한계가 존재한다.

4) 국내 연구 동향

국내 및 해외 연구 동향 고찰은 2023년 이후의 건설 안전 분야에서 LLM을 활용한 연구사례를 국내와 해외로 나누어서 고찰하였으며, 고찰을 통해 시사점을 도출하였다. 고찰에 활용된 국내 문헌은 RISS 학술정보 사이트에서 “건설”&“LLM”, “건설 안전”&“LLM”, “건설”&“생성형 AI” 3가지 키워드를 기반으로 문헌을 검색하여 관련도 높은 순으로 연구를 선정하여 고찰을 진행했다. 고찰 결과, <표 2-1>과 같이 국내 건설 분야에서 LLM을 활용한 연구가 다양하게 진행되고 있음을 확인할 수 있었으며, 각 연구에 대한 주요 내용은 다음과 같다.

조민건 외 3인(2022)의 연구에서는 BERT와 Decision Forest 알고리즘을 활용하여 건설 재해예측 모델을 개발하였다. 건설공사 안전관리 종합정보망(CSI)에 등록된 3년간의 재해사례 데이터를 BERT 모델에 학습시켰으며, 이를 통해 재해예측 모델을 개발하였다. 개발된 예측 모델은 기존 모델과 비교하여 약 20% 향상된 95.41%의 예측 정확도를 달성하였다. 해당 연구에서는 재해예측을 목적으로, 재해 유형에 대한 정보를 생성하는 모델을 구현하였다. 또한, 기본 BERT 모델에 Fine-tuning 방법을 적용하여 성능을 향상시킬 수 있음을 입증하였다.

김재희 외 2인(2023)의 연구에서는 건설현장에서 발생한 사고 데이터를 기반으로 작업자의 부상 부위를 추출하고 이를 통해 사고의 특성과 부상 부위 간 관계를 분석하는 연구를 진행하였다. 형태소 분석을 통해 명사 데이터를 추출하고, 정해진 키워드로 1차 분류를 수행한 뒤, GPT-3.5 기반 LLM을 활용하여 ‘불분명’ 데이터를 2차 분류하였다. 해당 연구에서는 2차 분류에서 LLM 활용 시, Prompt Engineering 방법을 적용하여 LLM의 분류 성능을 향상시킬 수 있음을 입증하였다.

Muritala Adebayo Isah(2023)의 연구에서는 터널 공사에서 발생할 수 있는 위험을 효율적으로 식별하기 위해 질의응답 시스템(QAR-System)을 개발하는 연구를 진행하였다. Neo4j를 활용한 리스크 지식 그래프와 OpenAI의 GPT-3 모델을 통합하여 구축되었으며, 과거 프로젝트 데이터를 체계적으로 저장하고 분석함으로써 위험요인을 신속하고 정확하게 식별할 수 있도록 설계하였다. 해당 연구에서 구축한 시스템은 지식 그래프 기반의 RAG 방법을 적용하여 응답 정확도 96%의 성과를 달성하였다.

이원중(2023)의 연구에서는 BERT 모델 기반의 자연어처리(NLP) 기술과 그래프 기반 지식베이스(KB)를 활용하여 비정형 건설 데이터에서 위험성평가 관련 지식을 자동으로 추출하고 이를 효율적으로 관리할 수 있는 지식베이스를 구축하는 연구를 진행하였다. 안전 관련 비정형데이터에서, 사전에 정의한 위험성평가 지식을 추출할 수 있도록 BERT 모델을 Fine-tuning 하여 개체명 인식 및 키워드 추출 엔진을 개발하였으며, 추출된 지식을 개체-관계 기반으로 설계한 그래프 데이터를 위험성평가 지식베이스로 구축하였다. 해당 연구에서는 BERT 모델을 기반으로 지식추출에 활용하였으며, 이 과정에서 모델에 Fine-tuning 방법을 적용하여 지식추출에 대한 성능을 향상시켰다.

전아여(2024)의 연구에서는 LLM에 RAG방법을 적용하여 중소규모 현장을 위한 위험성평가 자동화 기술을 제안하였다. GPT와 Langchain 기반의 RAG 모델을 통합하여 위험성평가 자동화 방안을 제안하였으며, 데이터 수집·관리, 정보 추출, 유해·위험요인 생성, 안전대책 수립, UI 설계의 단계를 통해 기술을 개발하였다. 해당 연구에서는 RAG 방법을 적용하여 유해·위험요인 파악과 안전대책 수립 과정의 효율성을 향상시켰으며, 중·소규모 건설현장에서의 안전관리 한계를 개선하였다.

<표 2-1> 건설 안전 분야 LLM 활용 연구(국내)

연구자 (연도)	주요 내용	활용 목적	생성 정보
조민건 외 3인 (2022)	- BERT와 Decision Forest 알고리즘을 활용하여 건설 재해예측 모델을 개발한 연구. - 건설공사 안전관리 종합정보망(CSI)의 3년간 데이터를 활용하여 정형데이터와 비정형데이터를 함께 분석하고 예측 모델을 설계함. - 연구 결과, 기존 모델대비 약 20% 향상된 95.41%의 예측 정확도를 달성.	재해예측	재해유형
김재희 외 2인 (2023)	- 건설현장 사고 데이터를 활용하여 작업자의 부상 부위를 추출하고, 사고 특성과 부상 부위 간의 관계를 분석하는 연구 - 연구 결과, 분류 정확도가 크게 향상되었으며, 사고 원인 분석 및 안전대책 수립에 기여할 수 있는 데이터를 제공하였다는 점에서 의의가 있음.	데이터 분석 및 분류	부상부위
Muritala Adebayo Isah (2023)	- NATM 터널 공사에서 발생할 수 있는 위험을 효율적으로 식별하기 위해 질의응답 시스템(QAR-System)을 개발한 연구. - Neo4j 기반 리스크 지식 그래프(RisKG)와 OpenAI의 GPT-3 모델을 통합하여 위험요인을 신속하고 정확하게 식별할 수 있음. - 지식 그래프 기반의 RAG 방법을 적용한 결과 응답 정확도 96%를 달성하였으며, 기존 방식에 비해 효율성과 신뢰성을 크게 향상시킴.	Q&A 시스템 및 위험성 평가	위험요인
이원중 (2024)	- BERT를 활용하여 지식베이스를 구축하는 연구. - 비정형데이터에서 추출된 지식을 개체-관계 기반으로 설계하여 지식베이스를 구축하고, 기존 방식과 비교하여 효율성과 효과성을 검증.	위험성 평가	위험요인
전아여 (2024)	- GPT와 RAG 모델을 통합하여 중소규모 현장의 위험성평가를 자동화하는 방안을 제안. - 데이터수집, 정보추출, 유해-위험요인 생성, 안전 대책 수립, UI 설계 단계에 대한 모듈 개발을 통해 전체 자동화 기술을 개발함.	위험성 평가	위험요인, 예방대책

5) 국외 연구 동향

고찰에 활용된 국외 문헌은 Google Scholar에서 “Construction industry” & “Risk Identification”&“LLM”, “Construction industry”& “Risk Assessment”&“LLM”의 키워드를 기반으로 검색을 진행한 후, 관련도 높은 문헌을 중심으로 고찰을 진행하였다. 고찰 결과, <표2-2>와 같이 국외에서도 위험요인 식별을 위한 다수의 연구가 진행되었음을 확인할 수 있다.

(A) Lee et al.(2024)의 연구에서는 건설현장에서 기후 대비를 위해 대규모 언어 모델(LLM)을 활용한 관리 프레임워크를 제안하였다. 연구는 극한 기후 상황에서 건설 자재와 임시 구조물을 보호하기 위한 맞춤형 LLM을 설계하였으며, 데이터 수집, 데이터 준비, 모델 개발의 3단계로 구성된 프레임워크를 제안하였다. 프레임워크는 건설 현장에서 발생 가능한 자재 및 구조물의 취약점을 파악하고, 수집된 데이터를 바탕으로 LLM을 미세 조정하여 실시간으로 맥락에 맞는 대응 조치를 제공한다. 사례 연구를 통해 제안한 프레임워크의 효과성 검증하였으며, LLM에 Fine-tuning 방법을 적용하여 모델 성능의 향상을 입증하였다.

(B) Lee et al. (2024)의 연구에서는 건설 안전 관리에서 비정형 데이터를 활용한 지식검색 성능향상을 위해 RAG와 Fine-tuning 접근 방식을 활용한 LLM을 비교하였다. 해당 연구에서는 건설 안전 지침에서 파생된 지식 그래프 기반의 RAG 방법을 적용한 GPT-4 모델과 건설 안전 지침에서 생성된 질의응답 데이터 세트를 기반으로 Fine-tuning 방법을 적용한 Llama 모델을 설계하였다. 사례 연구에서는 사고 요약 데이터를 쿼리로 활용하여 두 모델의 예방대책 생성 성능을 평가하였다. 연구 결과 RAG 방법을 적용한 모델은 21.5%, Fine-tuning을 적용한 모델은 26% 성능향상을 보여줌으로써, 두 접근 방식이 기존 범용 GPT 대비 우수한 성능을 나타냄을 입증하였다.

Uddin et al. (2023)의 연구에서는 ChatGPT를 활용하여 건설 현장의 위험 인식을 지원하고 안전 교육 및 훈련의 효과를 강화하는 가능성을 조사하였다. 연구는 미국의 한 주요 대학 건설학과 학생 42명을 대상으로 실험적으로 진행되었으며, ChatGPT를 도입하기 전과 후의 위험 인식 능력을 비교하였다. 해당 연구에서는 범용 GPT인 ChatGPT를 활용하였으며, 이를 바탕으로 학생들에게 제공할 수 있는 구체적인 위험요인에 대한 정보를 제공할 수 있으며, 학생들의 위험 인식도가 향상됨을 입증하였다.

Hussain et al. (2024)의 연구에서는 iSafeCom이라는 AI 기반 가상현실(VR) 안전 교육 시스템을 개발하여 건설 현장에서의 이주 노동자 안전 교육을 개선하는 것을 목표로 하였다. iSafeCom 시스템에 ChatGPT 모델을 통합하여 가상 강사와의 실시간 대화를 가능하게 하며, 참가자들에게 개인 맞춤형 피드백이 가능하도록 시스템을 구현하였다. 해당 연구에서는 범용 GPT인 ChatGPT를 활용하였으며, 이를 기반으로 한 시스템의 효과성을 검증하였다. 사전 및 사후 테스트를 통한 검증 결과, ChatGPT를 활용한 지식 전달이 포함된 과정의 점수가 23% 향상되어 그 효과성을 입증하였다.

Smetana et al. (2024)의 연구에서는 고속도로 건설 산업에서의 안전사고 데이터를 분석하기 위해 대규모 언어 모델(LLM)을 활용한 접근법을 제안하였다. OSHA Severe Injury Reports (SIR) 데이터베이스에서 중증 부상 보고서를 활용하여, GPT-3.5 모델과 자연어 처리(NLP) 기법, 클러스터링 알고리즘을 통해 주요 사고 유형과 원인을 파악하고 분류하였다. 사고보고서의 텍스트 데이터를 임베딩 벡터로 변환하고 K-means 클러스터링 및 t-SNE 시각화를 통해 사고 패턴을 분석하였다. 이후, LLM을 활용하여 클러스터 요약 및 사고 원인을 식별하였으며, 이를 통해 주요 사고 유형과 관련 원인을 도출하였다. 해당 연구에서는 범용 GPT인 GPT-3.5 모델을 활용하였으며, 사고 유형과 원인을 파악하는 작업에 유용함을 입증하였다.

Uhm et al.(2024)의 연구에서는 GPT 모델에 RAG 프로세스를 통합하여 작업자에게 개인화된 안전정보를 제공하는 RAG-GPT 모델을 제안하였다. RAG-GPT 모델을 통해 기존 GPT 모델이 직면한 주요 한계인 부정확한 수치 응답, 세부 정보 부족, 그리고 환각(hallucination) 문제를 해결하고자 하였다. 연구 결과, RAG-GPT 모델은 정확성(Correctness), 적합성(Relevance), 완전성(Completeness) 등에서 범용 GPT와 비교하여 우수한 성능을 보였으며, 안전정보를 제공하는 도구로서의 유용성을 입증하였다.

Khan et al.(2023)의 연구에서는 건설 안전 문서에서 정보를 추출하고 작업 현장에서의 안전 규정 준수를 개선하기 위해 대규모 언어 모델(LLM)을 활용한 CSQA 시스템을 제안하였다. 해당 연구에서는 LLM 기반 시스템 프레임워크를 제안하였으며, 건설 안전 문서 내의 텍스트 데이터를 실시간으로 처리하고, 사용자의 질의에 정확한 응답을 제공하도록 구성하였다.

Chen et al.(2024)의 연구에서는 초대형 건설 프로젝트의 위험성 평가를 위해 대규모 언어 모델(LLM)과 Fine-tuning을 활용한 접근법을 제안하였다. 연구는 OpenAI의 GPT-3.5 모델을 사용하여 건설 프로젝트 일정의 작업 항목과 위험요인을 식별하였으며, Fine-Tuning 기법을 통해 모델의 성능을 실제 프로젝트 조건에 맞게 조정하였으며, 해당 방법을 통해 성능이 향상됨을 검증하였다.

Yoo et al.(2024)의 연구에서는 GPT 모델을 활용하여 건설 사고 데이터 사고 유형을 예측하는 접근 방식을 제안하였다. 이 연구에서는 15,000건의 실제 사고 데이터를 바탕으로 GPT 모델에 Fine-tuning 방법을 적용하여 총 6가지 사고 유형(끼임,절단,추락,맞음,걸림,기타)을 분류하는 모델을 개발하였다. 또한, 사고보고서 내 텍스트 데이터에서 사고 발생 요인을 시각적으로 확인할 수 있는 중요도 시각화(saliency

visualization) 방법을 도입하였다. 연구 결과, Fine-tuning 방법을 적용한 GPT 모델은 기존의 TF-IDF, CNN, BERT 모델을 포함한 모델과 비교하여 높은 정확도(82.33%)를 기록하였으며, 특히 GPT-3.0이 GPT-2.0에 비해 모든 사고 유형에서 더 우수한 성능을 보임을 입증하였다.

<표 2-2> 건설 안전 분야 LLM 활용 연구(국외)

연구자 (연도)	주요 내용	활용 목적	생성 정보
(A) Lee et al. (2024)	- LLM 기반 극한 기후 대비 관리 프레임워크 개발을 위한 연구 진행. - LLM을 활용해 건설 자재 및 임시 구조물의 취약점을 분석하고 맞춤형 대응 조치 제공. - 사례 연구를 통해 복구 속도와 준비성을 향상시키는 LLM의 실용성을 입증.	위험 모니터링	대응방안
(B) Lee et al. (2024)	- RAG와 미세 조정된 LLM을 비교하여 건설 안전 지식 검색 성능을 평가한 연구. - RAG는 지식 그래프와 GPT-4를 통합했고, LLM은 질의응답 데이터 세트를 사용해 미세 조정됨. - 사례 연구를 통해 성능평가 결과, RAG는 21.5%, Fine-tuning은 26%의 성능향상을 보여 안전관리 적용 가능성을 입증함.	Q&A 시스템	예방대책
Uddin et al. (2023)	- Chat GPT 기반 건설현장 위험정보를 제공하여 작업자 안전교육을 강화하기 위한 연구. - Chat GPT가 건설업 종사 예정인 학생들의 위험인식 향상에 기여한다는 것을 검증함.	안전 교육	위험요인
Hussain et al. (2024)	- GPT 기반 작업자 안전교육 시스템 개발에 관한 연구 진행. - ChatGPT를 통해 VR 환경에서 실시간 맞춤형 피드백 제공. - 시스템을 통해 교육받은 사람의 안전 지식 보유가 23% 증가함.	안전 교육	위험요인

Smetana et al. (2024)	- GPT-3.5 기반 LLM을 활용하여 고속도로 건설 산업의 사고 데이터를 분석하는 연구 진행. - OSHA 부상보고서 데이터베이스를 활용하여 보고서의 Text 데이터를 클러스터링하고 요약하여 주요 사고 원인과 패턴을 식별. - LLM이 기존 기술과 비교하여 사고 원인 분석 및 패턴식별 과정에서 높은 효율성과 정밀도를 보임. - 활용 데이터베이스의 확장성 한계로 모델 적용 범위에 한계가 존재함.	데이터 분석	위험요인 예방대책
Uhm et al. (2024)	- RAG 기반 GPT 모델을 활용하여 건설 안전 정보 제공 및 관리 효율성 개선 연구 수행. - 기존 GPT 모델과의 비교를 통해 정확성, 적합성, 완전성 등 주요 평가 지표에서 RAG-GPT 모델의 우수성 입증. - 건설 안전작업 지침에 기반한 정확한 데이터 제공 및 작업 환경에 맞춘 개인화된 안전 정보 생성. - 건설 근로자와 전문가로부터 실용성과 작업 효율성 향상 효과 검증.	Q&A 시스템	작업 안전정보
Khan et al. (2023)	- LLM 기반 CSQA 시스템을 활용하여 건설 안전 문서에서 필요한 정보를 효율적으로 추출하는 연구 수행. - 벡터 데이터베이스와 GPT 모델을 통합하여 안전 규정 데이터를 분석 및 검색하며, 사용자 질의에 실시간으로 정확하고 맥락에 맞는 응답 제공. - OSHA 규정 및 사례 연구를 통해 시스템의 효율성을 검증하고, 시스템 개발 과정에서 사용자 피드백 메커니즘을 도입하여 정확성과 신뢰성을 향상시킴. - 범용 GPT를 활용하였으며 LLM 모델의 성능에 관한 추가적인 연구가 필요함.	Q&A 시스템	작업 안전정보

Yoo et al. (2024)	- GPT 모델을 활용하여 15,000건의 실제 건설 사고 데이터를 분석하고 6가지 사고 유형(끼임, 절단, 추락, 맞음, 걸림, 기타)을 분류하는 모델 개발. - 미세 조정(fine-tuning) 및 중요도 시각화(saliency visualization) 기법을 도입하여 사고 보고서 내 텍스트 데이터에서 사고 발생 요인을 시각적으로 확인 및 분석. - GPT-3.0 모델이 기존의 TF-IDF, CNN, BERT, GPT-2.0 등 비교 모델 대비 높은 정확도(82.33%)를 기록하며 사고 유형 분류에서 우수한 성능 입증.	데이터 분석 및 분류	사고유형
Chen et al. (2024)	- GPT-3.5 모델을 기반으로 건설 프로젝트의 위험요인 식별을 자동화하는 시스템 개발에 관한 연구. - Baseline Schedule 데이터를 기반으로 작업 항목의 Work Breakdown Structure(WBS) 및 작업 명칭을 표준화하여, 데이터셋을 생성하고 OpenAI API를 사용해 모델을 Fine-Tuning. - Fine-tuning된 GPT-3.5 모델을 활용하여 작업 항목별 리스크 요인을 자동으로 식별하고, Python 기반 인터페이스를 통해 실시간으로 위험요인 식별 결과를 제공하는 시스템 구축. - 위험요인 식별의 범위가 국한되어 있으며, 다른 유형의 건축 프로젝트로의 확장성에 대한 고려가 부족함.	위험성 평가	위험요인

6) 시사점

건설 안전 분야 LLM 연구 동향을 살펴보기 위해 국내·외 문헌사이트를 검색한 결과, 안전 교육, Q&A 시스템, 데이터 분석 및 분류, 위험성 평가 등 다양한 목적으로 LLM을 활용한 연구가 진행되었다. 문헌에 대한 검색은 국내 연구논문 5건과 해외 연구논문 9건을 검색하여 고찰을 진행하였다. 고찰한 내용에 대한 시사점은 아래 내용과 같다.

① 건설 안전 분야의 LLM 연구

• LLM 활용 가능성

Uddin et al.(2023), Hussain et al.(2024), Smetana et al.(2024), Khan et al.(2023)의 연구를 통해서 추가적인 처리 과정을 적용하지 않은 범용 GPT도 다양한 작업에서 유용하게 활용될 수 있음을 확인할 수 있다. 해당 연구에서는 범용 GPT를 Q&A 시스템, 데이터 분석, 안전 교육에 활용하였으며 해당 작업에서 효율성을 높이는 데 기여할 수 있음을 검증하였다.

• Fine-tuning과 RAG의 필요성

조민건 외 3인(2022), 이원중(2024), [A] Lee et al.(2024), Yoo et al.(2024), Chen et al.(2024)의 연구에서는 LLM의 전문성과 특정 작업 능력을 향상시키기 위해 LLM에 Fine-tuning 방법을 적용하였으며, 그 효과성을 입증하였다. 이를 통해 Fine-tuning 방법이 LLM의 전문 지식과 작업에 대한 정확성을 향상시키기 위해 필수적이고 중요한 방법임을 확인할 수 있다.

Muritala Adebayo Isah(2023), 전아여(2024), Uhm et al.(2024)의 연구에서는 외부 데이터베이스를 활용하는 RAG(Retrieval-Augmented Generation) 방법을 적용하여 LLM의 답변 정확도를 높였다. 해당 연구들은 건설 지식을 포함한 외부 정보를 참조함으로써, 기존 GPT 모델이 보유하지 못한 지식을 보완하여, 모델의 성능을 향상시킬 수 있음을 보여주었다.

[B] Lee et al.(2024)의 연구에서는 RAG와 Fine-tuning 각각의 방법에 대한

성능향상 효과에 관한 연구를 진행하였다. 연구 결과, RAG와 Fine-tuning 기술 모두 LLM에 유의미한 성능향상 효과를 미친다는 것을 확인하였다. 또한, RAG와 Fine-tuning의 성능향상 효과를 비교한 결과 Fine-tuning의 성능향상 효과가 RAG와 비교했을 때 약 5% 더 큰 것으로 나타났다. 그러나 해당 연구에서는 LLM의 활용 목적에 따라 두 방법의 적용 효과가 달라질 수 있음을 강조하였으며, 활용 목적에 따라 효과적인 방법을 도출하는 연구의 필요성을 제시하였다.

- 프롬프트 엔지니어링(Prompt Engineering)

김재희 외 2인(2023)의 연구에서는 프롬프트 엔지니어링(Prompt Engineering)을 적용하여 GPT 모델의 분류 성능을 향상시켰다. Prompt Engineering은 별도의 Fine-tuning 없이도 적절한 프롬프트를 설정하여 모델의 성능을 향상시키는 방법으로, 상대적으로 비용과 컴퓨팅 자원이 적게 소요되는 장점이 있다. 하지만, 최적 Prompt라는 명확한 정답이 존재하지 않으며, 이를 찾아내기까지 상당한 시간과 노력이 투입된다는 한계가 존재한다. 그리고 본 연구의 목적인 위험요인 식별에 LLM을 활용하기 위해서는 모델의 근본적인 지식을 업데이트하는 과정이 필수적이다. 하지만 Prompt Engineering은 추가적인 학습 과정을 거치지 않기 때문에 근본적인 전문성을 향상시키기에 한계가 존재한다. 따라서 본 연구에서는 Prompt Engineering을 제외한 Fine-tuning과 RAG 방법에 대해서만 고려하여 연구를 진행한다.

② 위험성평가 LLM 관련 연구

국내·외 논문 중 위험성 평가(위험요인 식별)와 관련한 연구(이원종,2024; 전아여,2024; Muritala Adebayo Isah,2023; Chen et al.,2024)를 고찰한 결과, LLM을 활용하여 건설현장의 위험성평가와 관련된 다수의 연구를 확인할 수 있다. 이원종(2024)의 연구에서는 BERT 모델을 활용하여 비정형 데이터를 처리하고 정보를 추출하는 연구를 진행하였으며,

추출된 정보를 기반으로 지식베이스를 구축하는 데 성공하였다. 하지만, 해당 연구는 데이터를 기반으로 지식베이스를 구축하는 방법에 초점을 맞춘 연구이다. 또한, 해당 연구에서 활용한 BERT 모델은 비정형데이터에서 정보를 추출하는 용도로 활용되었으며, GPT와 같은 디코더 기반 모델의 텍스트 생성과 관련한 연구는 진행되지 않았다.

전아여(2024)의 연구에서는 GPT 모델에 RAG 방법을 적용하여 범용 GPT 모델의 전문성을 향상시켰으며, 위험요인 식별과 예방대책을 생성을 자동화하는 연구를 수행하였다. 또한, 현장관리자를 대상으로 설문조사를 진행하여 그 효율성을 입증하였다. 하지만, GPT 모델의 전문성을 향상을 위한 다양한 방법의 검증에 관한 연구는 진행되지 않았다.

Muritala Adebayo Isah(2023)의 연구에서는 터널 공사 위험요인을 식별하기 위해 RAG 방법을 적용한 GPT 기반 Q&A 시스템을 개발하였다. 해당 연구는 그래프 데이터베이스를 활용하여 위험요인 식별에 대한 정확도를 향상시켜 유의미한 성과를 거두었다. 또한, Chen et al. (2024)의 연구에서도 GPT-3.5 모델에 Fine-tuning 방법을 적용하여 위험요인 식별에 유의미한 성과를 거두었다. 하지만, 마찬가지로 두 연구 모두 각각 RAG와 Fine-tuning이라는 단일 접근 방식에 초점을 맞춘 연구로, 다양한 시나리오에 대한 평가는 진행되지 않았다.

③ 소결

고찰한 문헌에 따르면 건설 안전 분야에서 LLM을 활용한 연구들은 다양한 작업에서 유의미한 성과를 거두고 있다. 특히, Fine-tuning과 RAG 기술은 LLM의 전문성과 성능을 향상시키는 데 중요한 방법으로 활용되고 있다. 그러나 기존연구들은 주로 특정 한 가지 기술을 활용하는 단일 접근 방식을 채택하는 경우가 대부분이며, 두 가지 방법을 통합하거나 다양한 시나리오를 구성하여 성능을 체계적으로 실험한 연구는 제한적임을 확인할 수 있다.


2.2 RAG 및 Fine-tuning 연구 동향

2.2절에서는 본 연구의 실험 적용할 RAG와 Fine-tuning의 세부 기술에 대한 고찰을 진행한다.

2.2.1 RAG(Retrieval Augmented Generation)

1) 개요


RAG란 LLM의 성능향상을 위한 방법 중 하나로, 응답을 생성하기 전 신뢰할 수 있는 외부 데이터베이스를 참조하는 프로세스를 의미한다. 사람이 질문에 답변할 때 질문과 관련된 내용을 참고서나 웹사이트에서 검색하여 해당 정보를 근거로 답변을 하는 것과 유사한 원리이다. RAG의 작동 세부 모듈은 Retriever (검색기)와 Generator (생성기) 두 가지로 구성된다 (Patrick Lewis et al. 2021). Retriever는 사용자의 쿼리(Query)를 기반으로 외부 데이터베이스에서 관련 정보를 찾아오는 검색기능을 수행하며, Generator는 모델 내부의 지식과 Retriever 모듈로부터 참조된 정보를 통합하여 사용자 쿼리에 대한 응답을 생성하는 정보생성 기능을 수행한다. Retriever에는 Non-Parametric Memory가 내장되어 있으며, Generator에는 Parametric Memory가 내장되어 있다. 여기서 Non-Parametric Memory란 모델 외부에서 쿼리와 관련된 데이터를 검색하여 이를 정보생성에 활용하는 매커니즘을 뜻한다. Parametric Memory란 모델에 내장된 지식 또는 데이터 저장소를 의미한다. 이는 모델 내부에 저장된 매개변수를 뜻하며, 매개변수는 학습(Training)을 통해 업데이트된다. RAG는 이 두 가지 모듈 및 메모리의 결합을 통해 보다 정확한 정보를 생성할 수 있으며, LLM의 환각(Hallucination) 문제를 해결할 수 있다.



<그림 2-1> RAG 개요(Patrick Lewis et al. 2021)

2) RAG 프로세스

RAG 프로세스는 인덱싱(Indexing), 검색(Retrieval), 생성(Generation)의 과정으로 구성되며, (Gao et al. 2024) 세부 프로세스는 <그림2-2>과 같다.



<그림 2-2> RAG 프로세스

① 인덱싱(Indexing) : RAG의 인덱싱은 외부 데이터베이스에 저장할 문서를 준비하고, 검색을 빠르고 효율적으로 수행할 수 있도록 데이터를 전처리하여 외부 데이터베이스에 저장하는 과정을 의미한다. 인덱싱 과정은 세부적으로 텍스트 추출(Extracting), 문서 분할(Chunking), 임베딩(Embedding), 데이터베이스에 저장 총 4가지 단계로 구성된다.

첫 번째 단계인 텍스트 추출(Extracting)은 관련 데이터로부터 텍스트를 추출하여 정형화된 형태로 변환하는 것을 의미한다. PDF, HTML, Word 문서 등 다양한 형식의 데이터에서 텍스트를 추출하며, 필요에 따라 OCR(Optical Character Recognition) 및 Object Detection과 같은 추가적인 기술을 활용하기도 한다. 텍스트 추출 과정에서 데이터의 품질과 정확성은 이후 검색 및 생성 성능에 직접적인 영향을 미친다.

두 번째 단계는 문서 분할(Chunking)이다. 추출된 텍스트 데이터를 의미 단위

로 나누어 검색 효율성을 높이는 작업을 수행한다. 일반적으로 문장 단위나 단락 단위로 분할하며, 필요에 따라 특정 규칙에 따라 분할 하기도 한다. 분할 크기가 너무 크면 검색의 정밀도가 낮아질 수 있고, 반대로 너무 작으면 정보가 단편화되어 유용성이 감소할 수 있다. 따라서 적절한 기준을 설정하는 것이 중요하다. 예를 들어, LLM의 입력 제한을 고려하여 512~1024 토큰 단위로 분할하는 것이 일반적이다.

세 번째 단계는 임베딩(Embedding)이다. 분할된 청크를 벡터로 변환하여 벡터 공간에 매핑하는 작업을 의미한다. 이를 통해 텍스트 데이터의 의미를 보존하면서도 계산 효율성을 높일 수 있다. 일반적으로 OpenAI의 text-embedding-ada 모델이 임베딩 생성 모델로 활용되며, 한국어 임베딩 생성 모델에는 Bert 기반의 Roberta 모델이 대표적이다. 임베딩 모델 선택 시 속도, 정확도, 자원 소모 등을 고려해야 하며, 모델의 성능은 검색 결과의 품질에 영향을 미친다. 이렇게 임베딩 모델을 통해 생성된 벡터는 검색단계에서 유사도 계산에 사용된다.

마지막 단계는 데이터베이스 저장이다. 생성된 임베딩 벡터를 효율적으로 저장하기 위해 FAISS(Facebook AI Similarity Search), Milvus, Weaviate, Chroma와 같은 벡터 데이터베이스가 사용된다. 이러한 데이터베이스는 대규모 데이터에 대한 빠른 검색을 지원하며, 확장성과 실시간 동기화 메커니즘을 제공한다. 데이터 저장 과정에서는 검색 속도와 시스템 확장성을 고려해야 하기에 적절한 데이터베이스를 선택하는 것이 중요하다. 추가적으로, 인덱싱 과정에서는 데이터의 중복 제거, 정규화(Normalization), 노이즈 필터링과 같은 전처리 작업이 중요하다. 이러한 작업을 통해 데이터의 품질을 높이고, 검색 및 생성 단계에서 발생할 수 있는 오류를 최소화할 수 있다. 예를 들어, PDF 문서의 경우 중복된 내용이나 비정형데이터를 포함할 가능성이 크기에 이를 사전에 정제

하는 과정이 필요하다. 인덱싱은 단순히 데이터를 준비하는 단계를 넘어, 검색 시스템의 성능과 응답 정확성을 좌우하는 핵심적인 역할을 한다. 따라서 적절한 도구와 기술을 활용하여 효율적이고 정교하게 설계하는 것이 중요하다.

② 검색(Retrieval) : RAG의 검색은 사용자의 쿼리와 관련된 정보를 데이터베이스에서 찾아내는 과정을 의미한다. 검색의 세부적인 단계는 쿼리 벡터화(Vectorization), 유사도 계산(Similarity Calculation), Top-K 청크 검색 이렇게 총 3가지 단계로 구성된다.

첫 번째 단계인 쿼리 벡터화(Vectorization)는 사용자가 입력한 쿼리를 고차원 벡터로 변환하는 작업을 의미한다. 이 작업은 임베딩 모델(예: BERT, RoBERTa, text-embedding-ada 등)을 활용하여 쿼리를 벡터 형태로 표현하며, 이 벡터는 쿼리의 의미적 정보를 포함한다. 쿼리 벡터화의 품질은 검색 결과의 정확성과 직결되므로, 적합한 임베딩 모델을 선택하는 것이 중요하다.

두 번째 단계는 유사도 계산(Similarity Calculation)이다. 데이터베이스에 저장된 문서 청크의 임베딩 벡터와 쿼리 벡터 간의 유사도를 계산하여 관련성 높은 문서를 선별한다. 일반적으로 코사인 유사도(Cosine Similarity) 또는 유클리드 거리(Euclidean Distance)와 같은 수학적 척도가 사용된다. 이 단계에서 빠른 연산을 위해 벡터 데이터베이스(예: FAISS, Milvus)를 활용하며, 이들 데이터베이스는 고속 유사도 검색을 지원한다.

마지막 단계는 Top-K 청크 검색이다. 유사도 계산 결과 중 상위 K개의 관련 청크를 선택하여 검색 결과로 반환한다. Top-K 값은 사용 사례와 시스템 설계에 따라 조정할 수 있으며, 검색의 정확성과 속도 간의 균형을 고려하여 설정한다. 예를 들어, 너무 많은 청크를 반환하면 생성 단계의 과부하를 초래할 수 있고, 너무 적으면 필요한 정보를 놓칠 가능성이 있다. 검색단계는 RAG 전체 프로세스에서 생성 단계의 입력 데이터를 제공하는 역할을 하며, 검색 결과의 품

질이 최종 생성 결과의 정확성에 결정적인 영향을 미친다. 따라서 검색 과정에서는 임베딩 모델의 선정, 유사도 계산 방식 등의 요소를 신중히 고려해야 한다.

③ 생성(Generation) : RAG의 생성 프로세스는 사용자의 쿼리와 ②검색(Retrieval)단계의 결과물인 검색 정보(Retrieved Information)를 합쳐 최종 답변(Answer)을 생성하는 과정을 의미한다. 생성 단계는 대규모 언어 모델(LLM)을 기반으로 하며, 주어진 입력 데이터(검색 정보)를 활용하여 자연스럽고 일관성 있는 텍스트를 출력하는 역할을 한다. 생성 단계의 첫 번째 작업은 검색된 정보의 통합이다. 검색단계에서 반환된 Top-K 청크를 입력으로 받아 사용자의 쿼리와 함께 모델에 전달한다. 이 과정에서 검색된 정보가 단편적이거나 불완전한 경우, 모델 내부의 파라메트릭 메모리(Parametric Memory)가 이를 보완하여 최종 답변을 생성한다. 다음으로, 쿼리와 검색된 정보의 조합을 통해 답변을 생성한다. 생성 과정에서는 검색된 정보가 답변의 근거로 활용되며, 모델 내부에 저장된 사전학습 지식이 이를 보완한다. 이로 인해 RAG 프로세스를 통해 생성된 답변은 신뢰성을 갖추게 되고, LLM의 환각(Hallucination) 문제를 완화하여 정확성을 높일 수 있다. 생성 단계는 모델의 언어 생성 능력을 기반으로 하기때문에, 다양한 텍스트 응답 형식을 지원할 수 있다. 예를 들어, 요약(Summarization), 설명(Explanation), 질의응답(Question-Answering) 등이 가능하며, 사용자 요구에 따라 응답 형식을 조정할 수 있다. 또한, 생성된 텍스트는 정확성(Accuracy), 유용성(Usefulness) 등의 측면에서 검토가 필요하다. 생성 단계는 최종적으로 사용자가 이해할 수 있는 답변을 출력한다는 점에서 RAG 프로세스의 최종 단계로서 매우 중요한 역할을 한다. 검색단계와 달리, 생성 단계는 모델의 사전학습 지식과 외부 데이터베이스의 검색 정보를 바탕으로 결과물을 생성하므로, 모델의 품질과 학습데이터의 적합성이 결과에 직접적인 영향을 미친다.

3) 타 분야 RAG 연구 동향

건설 분야를 제외한 타 분야의 RAG 관련 연구 동향은 <표2-4>와 같다. 국내 문헌의 경우 RISS에서 “LLM”&“RAG” 키워드를 기반으로 검색한 최신연구 중 건설 분야를 제외한 연구를 고찰 대상 문헌으로 선별하였다. 해외 문헌의 경우 Google Scholar에서 “LLM”&“RAG” 키워드를 기반으로 최신연구 중 건설 분야를 제외한 연구를 고찰 대상 문헌으로 선별하였다.

박종진(2024)의 연구는 RAG를 활용하여 치과 상담용 챗봇을 개발하는 데 초점을 맞추었다. 연구는 OpenAI의 GPT-3.5를 기반으로 하여 LangChain 라이브러리를 이용한 RAG 시스템을 구현하였다. 이를 위해 국내 치과대학 병원 웹사이트 게시판의 데이터를 수집하고, 치과 전문의의 자문을 통해 데이터를 정제하여 상담 데이터셋을 구축하였다. 구축된 데이터는 적절한 크기의 청크로 분할되었으며, 청크 크기와 오버랩 크기는 각각 1001자와 100자로 설정되었다. 이러한 데이터 전처리를 통해 데이터 단절로 인한 부정확한 출력을 방지하였다. 챗봇은 사용자 입력과 가장 유사한 텍스트를 검색하여 GPT-3.5 모델에 전달함으로써 정확한 답변을 생성하였다. 연구 결과, 챗봇은 치과 상담과 관련된 질문에 대해 정확하고 신뢰성 있는 응답을 제공하였으며, 치과 상담의 접근성과 상담 내용의 정확도를 높이는 데 기여하였다. 연구는 치과 건강 관리를 위한 실질적인 AI 도구로서 챗봇의 활용 가능성을 입증하였으며, RAG 기반 LLM이 도메인 특화된 Q&A 시스템 개발에서 효과적임을 보여주었다.

안해연(2024)의 연구에서는 교원의 행정업무를 줄이기 위해 GPT-4와 RAG 기술을 활용한 생성형 AI 기반 질의응답 시스템을 개발하고 평가하였다. 교육법령과 업무지침을 벡터 데이터베이스로 구축하고, LangChain 프레임워크를 통해 GPT-4와 연결하여 시스템을 완성하였다. 자체 개발한 벤치

마크 테스트에서 100% 정확도를 기록하였으며, 사용자 경험 평가에서도 4점 이상의 높은 점수를 받아 실제 교육현장에서의 활용 가능성을 입증하였다. 시스템은 답변의 신뢰성 확보를 위해 RAG 기술을 사용하고, 프롬프트 엔지니어링을 통해 명확하고 공적인 어조로 답변을 제공하였다. 이를 통해 교원의 행정업무 부담을 줄이고, 교육 전문성을 강화할 가능성을 제시하였다.

한승헌 외(2024)의 연구에서는 축구 산업 데이터를 분석 지원하기 위해 RAG 기반의 FT-LLM 프레임워크를 개발하고 평가하였다. 435,599건의 축구 관련 뉴스를 데이터베이스로 구축하고, BM25 및 embedding 기반 retrieval 기법을 활용하여 질의와 연관성이 높은 데이터를 검색하는 프로세스를 구축하였다. 또한, Query Refinement와 Confidence Check라는 모듈을 통해 답변의 신뢰성을 강화하였으며, CoT 프롬프팅 전략으로 답변의 정확도를 향상시켰다. 검증 결과, FT-LLM 프레임워크는 범용 GPT 대비 객관적, 주관적 질문에서 높은 성능을 보이며, 축구 산업의 데이터 기반 의사결정 및 분석 작업 지원 가능성을 입증하였다.

Wang et al.(2024)의 연구에서는 생명과학 연구에서의 복잡한 질의응답 문제를 해결하기 위해 RAG 방법을 적용한 Bio-RAG 프레임워크를 개발하고 검증하였다. 연구에서 PubMed를 포함한 2,200만 건 이상의 생명과학 논문 데이터를 기반으로 내부 정보 소스를 구축하고, PubMedBERT를 활용해 도메인에 특화된 임베딩 모델을 설계하였다. 또한, 지식 계층화 기반 질의 전처리와 자체 평가(Self-Evaluation) 메커니즘을 통해 검색된 데이터의 적합성을 지속적으로 평가하며, 필요 시 외부 검색 엔진이나 생물학 데이터 허브를 활용하여 최신 정보를 통합하였다. BIORAG는 생물학 QA 데이터셋(GeneTuring, MedMCQA 등)에서 기존 Fine-Tuned LLM과 RAG 기반 LLM 대비 우수한 성능을 보

였으며, Gene 및 PubMed 데이터베이스와 통합 활용을 통해 생물 분야 질문에 대한 정밀한 추론능력과 답변 정확도 향상을 달성하였다. 해당 연구는 생명과학 분야의 복잡성과 지식 업데이트 문제를 해결할 수 있는 강력한 도구로 Bio-RAG의 유용성과 활용 가능성을 입증하였다.

Zhang et al.(2024) [31]의 연구에서는 금융 문서 기반의 질의응답 시스템의 성능을 개선하기 위해 RAG 기반 프레임워크를 개발하고 평가하였다. 연구는 10-K와 같은 금융 문서에서 관련 텍스트를 검색하기 위한 고도화된 chunking 기법, 쿼리 확장, 메타데이터 주석 및 Reranking 알고리즘을 활용하여 RAG의 검색 품질을 향상시키는 방법을 제안하였다. FinanceBench 데이터셋을 활용한 실험에서 제안된 기법은 기본 RAG 모델 대비 높은 정확도를 기록하며, 문서 기반 질의응답 시스템의 신뢰성과 정확도를 입증하였다. 이를 통해 금융 도메인의 복잡한 질문에 대한 답변 생성에 효과적인 개선 가능성을 보여주었다.

Ye et al.(2024)의 연구에서는 중국 의학 분야에 특화된 대규모 언어 모델 Qilin-Med를 개발하고 평가하였다. 연구는 Baichuan-7B를 기반으로 도메인 특화 사전 학습(CPT), 지도 학습(SFT), 직접 선호 최적화(DPO)를 통합한 멀티 단계 학습 방식을 제안하였다. ChiMed 데이터셋을 활용하여 의료 질문 응답, 텍스트 이해, 대화 생성 등 다양한 의료 응용 프로그램에서 성능을 개선하였으며, CMExam 데이터셋에서 42.8%의 정확도를 기록하였다. RAG 기술을 통해 관련성이 높은 데이터를 검색하고 답변의 품질을 강화하여 의료 LLM의 가능성을 입증하였다.

Kim et al.(2024)의 연구에서는 제약 산업의 규제 준수 과정을 지원하기 위해 QA-RAG(Question and Answer Retrieval-Augmented Generation) 모델을 개발하고 평가하였다. 연구는 FDA 및 ICH 가이드

라인 문서를 벡터 데이터베이스로 구축하고, 사용자 질문과 가상 답변을 결합한 이중 검색 방식으로 관련성을 높은 정보를 검색하였다. QA-RAG 모델은 재랭킹 기법과 few-shot 프롬프팅을 활용하여 문서 검색과 답변 생성을 최적화하였으며, 실험 결과 문맥 정밀도와 답변 생성의 F1 점수에서 기존 RAG 모델 대비 높은 성능을 기록하였다. 이를 통해 제약 산업의 복잡한 규제 준수 과정을 효율적으로 지원할 가능성을 입증하였다.

<표 2-3> 타 분야 RAG 연구사례

연구자 (연도)	분야	주요 내용
박종진 (2024)	의료	- GPT-3.5를 기반으로 LangChain 기반 RAG 기술을 활용한 치과 상담용 챗봇 시스템 개발. - RAG를 적용하여 사용자 입력과 가장 관련성 높은 데이터를 검색해 답변의 정확도와 신뢰성을 향상. - 치과 상담의 접근성과 상담 내용의 실질적 활용 가능성을 입증함.
안해연 (2024)	교육	- GPT-4와 LangChain 기반 RAG 기술을 활용한 교원 행정업무 경감용 생성형 AI 질의응답 시스템 개발. - RAG를 적용하여 사용자 질문과 관련성 높은 데이터를 검색해 답변의 정확도와 신뢰성을 향상. - 벤치마크 테스트에서 100%의 정확도와 사용자 경험 평가에서 높은 점수를 기록하며 실제 교육현장에서의 활용 가능성을 입증함.
한승현 외 3인 (2024)	스포츠	- BM25 및 embedding 기반 RAG 기술을 활용한 축구 산업 지원용 FT-LLM 프레임워크 개발. - Query Refinement와 Confidence Check 모듈을 통해 사용자 질의와 관련성 높은 데이터를 검색해 답변의 신뢰성과 정확도를 향상. - 객관적 및 주관적 질문에서 기존 GPT 모델 대비 높은 성능을 기록하며 축구 데이터 분석 및 의사결정 지원 가능성을 입증함.

Wang et al. (2024)	생명 과학	- PubMed 데이터를 기반으로 한 도메인 특화 RAG 프레임워크 BIORAG 개발. - 지식 계층화와 자체 평가 메커니즘을 통해 관련성 높은 데이터를 검색하고 답변의 신뢰성과 정확도 향상. - 생물학 QA 데이터셋에서 기존 모델 대비 우수한 성능을 기록하며 생명과학 질의응답 시스템으로 활용 가능성 입증.
Zhang et al. (2024) [31]	금융	- 금융 문서 기반 질의응답 시스템 성능향상을 위해 RAG 기반 프레임워크 개발. - Chunking 기법, 쿼리 확장, 메타데이터 주석, 재랭킹 알고리즘을 적용해 관련성 높은 데이터를 검색하고 답변의 정확도와 신뢰성을 개선. - FinanceBench 데이터셋 실험에서 높은 정확도를 기록하며 금융 도메인의 복잡한 질문 응답 가능성을 입증함.
Ye et al. (2024)	의료	- Baichuan-7B 모델을 기반으로 도메인 특화 사전 학습(CPT), 지도 학습(SFT), 직접 선호 최적화(DPO) 및 RAG 기술을 통합한 Qilin-Med 모델 개발. - RAG를 활용하여 사용자 질문과 관련성이 높은 데이터를 검색하고 답변의 정확도와 신뢰성을 개선함. - CMExam 및 Huatuo-26M 데이터셋에서 높은 성능을 기록하며 의료 질문 응답 및 텍스트 이해 응용에서 활용 가능성을 입증함.
Kim et al. 2024	제약	- QA-RAG 모델을 활용하여 제약 산업의 규제 준수 지원 시스템 개발. - FDA 및 ICH 가이드라인 데이터를 기반으로 사용자 질문과 가상 답변을 결합한 이중 검색방식을 적용해 문서 검색의 정확도와 신뢰성을 향상. - 문맥 정밀도와 답변 생성 성능에서 기존 RAG 모델 대비 높은 성과를 기록하며 제약 규제 준수 지원 가능성을 입증함.

4) 건설 분야 RAG 연구 동향

건설 분야에서의 RAG 연구 동향은 <표 2-4>와 같다.

Uhm et al.(2024)의 연구에서는 건설 안전 정보를 효과적으로 생성하기 위해 RAG-GPT 모델을 개발하고 평가하였다. 연구 결과, RAG 기술을 통해 기존 Base 모델대비 성능이 향상된 결과를 얻었으며, 정확도 80%를 달성하였다. 해당 연구에서는 RAG에는 안전 지침 문서데이터를 벡터 데이터베이스로 구축하여 활용하였다. 벡터 데이터베이스는 텍스트 데이터를 벡터로 변환하고, 이를 기반으로 유사도를 계산하여 사용자 질의와 가장 관련성 높은 데이터를 빠르고 정확하게 검색할 수 있으며, 향후 대량의 데이터셋을 다루어야 할 때 이를 효율적으로 처리할 수 있어 확장성이 높다는 장점이 존재한다.

Li et al.(2024)의 연구에서는 건축 계획 검토의 효율성과 정확성을 높이기 위해 지식 그래프와 LLM을 융합한 지능형 검토 시스템을 개발하였다. 해당 연구는 건축 계획 규정에 대하여 다차원적이고 다계층적인 지식 그래프를 구축하고, 텍스트 분류 및 엔티티 추출을 기반으로 한 분석 모듈을 통해 건설 계획 문서 검토를 자동으로 처리할 수 있는 시스템을 구축하였다. 해당 연구에서 적용한 지식 그래프는 데이터를 개체(entity)와 관계(relation) 간의 삼중(triple) 구조(주어-서술어-목적어)로 표현하여 의미론적 정보를 체계적으로 관리하는 도구이다. 이러한 지식 그래프는 규정과 지침의 의미를 구조적으로 표현함으로써 관련 정보를 보다 정확하게 검색하고, LLM에 활용하기 용이한 정보를 제공할 수 있다. 하지만, 지식 그래프는 초기 단계에서 데이터의 정형화와 관계 정의가 요구되며, 이 과정은 많은 시간과 자원이 소요된다. 특히 대규모 규정 데이터를 구조화하는 과정에서 높은 기술적 역량이 필요하며, 데

이터베이스의 크기가 확장됨에 따라 검색 및 추론 성능이 저하될 가능성이 존재한다는 단점이 존재한다.

최지원(2024)의 연구는 ChatGPT-3.5와 GPT-4의 BIM관련 지식수준을 평가하고, RAG를 활용하여 GPT-4의 성능을 개선하는 방법을 제안하였다. 연구는 최근 5년간 BIM 전문가 1급 시험 문항과 문제은행에서 수집한 총 238개의 문항을 활용하여 GPT 모델의 성능을 유형별로 분석하였다. 그 결과, ChatGPT-4는 평균 77%의 정답률로 BIM 전문가 1급 시험을 통과했지만, ChatGPT-3.5는 61%의 정답률로 기준에 미달하였다. 특히, 'BIM 지침' 유형 문항에서 가장 낮은 정답률인 41%를 기록하며, GPT-4의 부정확하거나 다의적인 답변 생성이 주요 한계로 나타났다. 이러한 한계를 극복하기 위해 연구에서는 RAG 기법을 적용하였다. BIM 지침 문항에 대한 성능을 향상시키기 위해 국토교통부 및 기타 공공기관에서 제공하는 BIM 관련 지침서 13개를 PDF 형태로 수집하여 Chroma DB 벡터 데이터베이스로 구축하였다. 검색 성능을 극대화하기 위해 BM25 기반 검색과 벡터 임베딩 검색을 결합한 Ensemble Retriever를 사용하였으며, OpenAI의 GPT-4-turbo 모델과 LangChain 프레임워크를 통해 RAG 기법을 통합하였다. 이를 통해 GPT-4가 사용자 질의와 관련성 높은 데이터를 검색하고, 보다 정확하고 신뢰성 높은 답변을 생성할 수 있도록 개선하였다.

이규은(2024)의 연구에서는 교량 유지관리를 위한 지식 기반 및 질의응답 시스템을 개발하고 이를 평가하였다. 연구는 교량 관리 시스템(BMS)과 관련 플랫폼에서 데이터를 통합하여 포괄적인 지식 기반을 생성하고, GPT-4 모델을 활용하여 자연어 질문을 구조화된 질의로 변환하여 데이터를 검색하고 예측 추론 기능을 제공하는 시스템을 구축하였

다. 사용자 테스트에서 개발된 시스템은 85.7%의 정확도와 4.57/7의 사용자 만족도를 기록하며, 교량 유지관리 의사결정을 지원하는 데이터 기반 도구로서의 가능성을 입증하였다. 하지만 해당 연구에서 지식그래프와 관련한 한계점도 존재하였다. 지식그래프는 이질적이고 단편화된 데이터를 통합관리하는 데 효과적이지만, 데이터를 통합하고 관계를 모델링하는 과정에서 높은 복잡성과 비용이 요구된다. 해당 연구에서 활용한 교량 유지관리 데이터는 구조화된 데이터와 비구조화된 데이터가 혼재되어 있어, 이를 통합하여 지식그래프로 변환하는 과정에서 특히 많은 노동과 시간을 투입했다는 한계가 존재한다.

전아여(2024)의 연구에서는 중·소규모 건설현장의 위험성평가 자동화를 목표로 RAG 기반의 모델을 설계하고 평가하였다. 연구는 건설공사 안전관리 정보망(CSI)의 사고사례와 산업안전보건법 가이드라인 등을 수집하여 벡터 데이터베이스를 구축하고, 이를 통해 유해·위험요인 도출 및 안전대책 수립 작업을 자동화하였다. 검증은 전문가 평가를 기반으로 모델의 효과성을 검증하였다.

Muritala Adebayo Isah(2023)의 연구에서는 NATM 터널 건설 프로젝트의 위험 식별을 지원하기 위해 GPT-3와 지식 그래프 기반의 QAR-System(Question-Answering Risk Identification System)을 개발하고 평가하였다. 연구는 NATM 터널 데이터에서 위험 지식 그래프(RisKG)를 생성하고 Neo4j를 사용하여 관계형 데이터를 구축하였다. GPT-3 모델은 자연어 질문을 Cypher 쿼리로 변환하여 사용자의 질의와 가장 관련성 높은 데이터를 검색하도록 설계되었다. QAR-System은 Streamlit 기반 사용자 인터페이스(UI)를 통해 빠르고 효율적인 위험 정보를 제공하며, 사례 연구를 통해 기존 위험 식별 방식 대비 시간 효율

성과 정확도가 향상된 것으로 나타났다. 하지만 위험요인을 추출할 수 있는 범위가 터널 프로젝트에 국한되며, 그래프 데이터베이스를 활용하여 복잡한 질문에 대한 추론에는 한계가 존재한다.

<표 2-4> 건설 분야 RAG 기술 활용 연구

연구자 (연도)	주요 내용 및 적용 방법	활용 데이터베이스
Uhm et al. (2024)	- 건설현장 작업자에게 안전 정보 제공을 위한 RAG-GPT 프로세스 제안. - RAG 기술을 통해 기존 Base모델 대비 성능이 향상되었으며, 정확도 80%를 달성함.	벡터 데이터베이스 (Chroma)
Li et al. (2024)	- 건축 계획에 대한 법규 준수 여부 검사 방법론 제시. - 지식그래프 데이터베이스 기반 RAG 기술을 통해 답변 정확도 72% 달성.	지식 그래프 데이터베이스 (Neo4j)
최 지원 (2024)	- ChatGPT의 BIM 지식수준을 평가하는 연구 진행. - RAG 기술을 통해 범용 GPT 대비 41% 높은 정확도 달성.	벡터 데이터베이스 (Chroma)
이 규은 (2024)	- 교량 유지관리 분야의 의사결정을 지원하는 질의응답 시스템 개발 - RAG 기술을 통해 답변 정확도 85.7% 성능 달성- RAG	지식 그래프 데이터베이스 (Neo4j)
전아여 (2024)	- LLM 기반 위험성평가 자동화를 위한 시스템 개발에 관한 연구. - GPT-3.5와 벡터 데이터베이스 기반 RAG 프로세스 제안.	벡터 데이터베이스 (Chroma)
Muritala Adebayo Isah (2023)	- GPT-3 모델을 기반으로 터널 시공위험요인 식별을 위한 Q&A 시스템 개발에 관한 연구 - GPT-3 모델에 지식그래프를 결합하여 시스템 개발.	지식 그래프 데이터베이스 (Neo4j)

건설 분야에서 RAG 기반 연구는 벡터 데이터베이스와 지식 그래프 데이터베이스를 활용하여 각각의 특성을 살린 다양한 접근 방식으로 이루어지고 있다. 고찰한 연구들을 바탕으로 두 데이터베이스의 장단점을 비교해보면 <표 2-5>와 같다.

<표 2-5> 데이터베이스 장·단점

	벡터 데이터베이스	그래프 데이터베이스
장점	- 확장성이 뛰어나며 데이터 처리의 효율성이 우수함. - 비정형데이터를 처리하는 데 적합하며, RAG와 같은 기술에서 검색 성능을 극대화할 수 있음. - 실시간 검색과 통합 작업에 강점을 가진다. - 대규모 데이터에서도 높은 검색 속도와 효율성을 제공함.	- 데이터의 관계와 구조를 시각적으로 표현하고 의미론적 정보를 체계적으로 관리할 수 있음. - 복잡한 질의나 관계 기반의 데이터를 추론하는 데 적합함. - 사용자가 질문한 내용에 대해 더 심층적인 답변을 생성할 수 있음.
단점	- 데이터 간의 관계를 명확히 표현하거나 추론하기 어려움 - 복잡한 질문이나 의미론적 관계 분석에는 한계가 있음.	- 데이터 검색 및 확장성에서 한계가 있음. - 초기 구축과정에서 많은 시간과 자원이 소요된다. - 대규모 데이터를 다룰 때 성능이 저하됨.

건설 분야에서 RAG 기반 연구를 수행함에 있어 데이터베이스 선택은 매우 중요한 요소이다. 특히 본 연구에서는 벡터 데이터베이스를 활용하는 것이 지식 그래프 데이터베이스를 활용하는 것보다 적합하다고 판단된다. 이러한 판단의 근거는 다음과 같다.

첫째, 지식 그래프 데이터베이스는 데이터를 개체(Entity)와 관계

(Relation)로 구조화하여 의미론적 정보를 체계적으로 관리할 수 있는 장점을 가지고 있다. 그러나 이러한 데이터베이스를 구축하기 위해서는 데이터 정형화와 관계 정의가 필요하며, 이 과정에서 많은 시간과 자원이 소요된다. 또한, 대규모의 비정형데이터를 다루는 상황에서는 데이터 관계를 명확히 정의하지 않으면 그래프의 활용도가 떨어지며, 구조화되지 않은 데이터를 처리하기 어렵다. 본 연구와 같이 다양한 비정형 데이터를 활용해야 하는 경우, 이러한 번거로움은 큰 제약으로 작용할 수 있다.

둘째, 지식 그래프 데이터베이스는 대규모 데이터셋을 처리할 때 확장성이 제한된다는 단점이 있다. 데이터 크기가 증가함에 따라 검색 속도와 추론 성능이 저하될 가능성이 있으며, 특히 건설 지침서나 안전 문서와 같은 비정형데이터를 포함하는 연구에서는 효율적으로 대응하기 어렵다. 반면, 벡터 데이터베이스는 대규모 데이터에 대한 처리 효율성과 확장성이 뛰어나며, 문맥적 유사성을 기반으로 신속하게 데이터를 검색할 수 있는 장점을 제공한다.

셋째, 지식 그래프 데이터베이스는 복잡한 관계 기반 분석에는 적합하지만, 실무적 관점에서 활용하기에는 제약이 있다. 초기 단계에서 데이터 관계를 정의하고 이를 그래프 형식으로 변환하는 데 전문적인 기술 역량이 요구되며, 실시간 검색과 신속한 데이터 처리가 필요한 작업 환경에서는 적용하기 어렵다. 반면, 벡터 데이터베이스는 데이터를 임베딩하여 문맥적 유사성을 기반으로 직관적이고 빠른 검색 결과를 제공할 수 있어 실무적으로 활용하기에 더 적합하다.

따라서 본 연구에서는 건설 지침서와 안전 문서와 같은 비정형데이터를 다루고, 신속하고 효율적인 검색이 중요한 요구 사항이라는 관점에서, 벡터 데이터베이스를 활용하는 것이 지식 그래프 데이터베이스보다 적합하다고 판단하였다.

2.2.2 Fine-tuning

1) 개요


Fine-tuning이란 사전학습 언어 모델(Pre-trained Language Model, PLM)을 특정 도메인이나 작업에 맞게 조정하는 방법을 의미한다. 사전 학습 언어 모델은 대규모 데이터셋을 기반으로 비지도 학습(Unsupervised Learning)¹⁾이나 자기 지도 학습(Self-Supervised Learning)²⁾을 통해 범용적인 지식을 학습한다. 이러한 모델은 자연어 처리(NLP) 분야에서 다양한 태스크를 수행할 수 있는 강력한 도구로 활용될 수 있으며, OpenAI의 GPT 모델은 그 중에서도 대표적인 모델이다. 그러나 사전학습 모델이 범용적인 지식을 학습한 상태에서 특정 도메인 지식이나 특화된 태스크를 처리하려면 한계가 발생할 수 있다. 이는 모델이 특정 목적으로 활용하기 어렵고, 전문 분야에서 전문성을 보이지 못하거나, 응답의 스타일과 형식이 태스크의 요구 사항과 일치하지 않는 경우를 의미한다. 이러한 한계를 극복하기 위해 사전학습 모델을 Fine-tuning 하며, 대표적인 세부 방법에는 Supervised Fine-tuning (SFT)이 존재한다. Supervised Fine-tuning은 사전 학습된 모델이 이미 학습한 범용적인 지식을 바탕으로 특정 태스크에 맞는 레이블 데이터셋(Labeled Dataset)을 사용해 모델을 조정하는 과정이다. 여기서 레이블 데이터셋은 “콘크리트 공사에서 펌프카를 이용해 콘크리트 타설 작업 시 위험요인은?”이라는 질문과 “콘크리트 펌프카 작업반경 내 근로자 접근에 의한 부딪힘 위험”라는 답변 쌍과 같은 형식으로 구성된다. 즉, 질문과 그에 대한 정답으로 구성된 데이터셋을 의미한다. 이러한 데이터셋을 기반으로 사전학습 모델에 전문 분야의 지식을 학습시키고, 특정 목적에 활용할 수 있도록 사전학습 모델을 훈련 시킬 수 있다.

1) 비지도 학습(Unsupervised Learning) : 레이블이 없는 데이터를 사용하여 데이터의 패턴, 구조, 또는 군집을 학습하고 이해하는 기계 학습 방법

2) 자기 지도 학습(Self-Supervised Learning) : 데이터의 일부를 숨기고 이를 예측하도록 학습하여, 레이블 없이도 모델이 데이터를 스스로 학습하는 기계 학습 방법


2) GPT Fine-tuning

Open AI사에서는 사용자가 다양한 모델을 쉽고 빠르게 조정할 수 있도록 API(Application Programming Interface) 기능을 제공하고 있다. 이 API 기능을 통해서 GPT 모델을 사용자의 목적에 맞게 Fine-tuning 할 수 있으며, Fine-tuning에 필요한 단계적 프로세스를 구축할 수 있다. 또한, Playground 플랫폼을 통해 Fine-tuning의 진행 상황을 확인할 수 있다. <그림 2-3>은 Fine-tuning 진행 상황을 확인할 수 OPEN AI Playground 플랫폼 화면이다.



<그림 2-3> Playground 플랫폼 내 Fine-tuning 확인 기능

사용자는 API를 활용하여 로컬 환경에서 단계적인 Fine-tuning 프로세스를 구축하여 LLM을 구현할 수 있다. Fine-tuning 프로세스는 <그림 2-4>와 같이 데이터 수집 및 생성, 데이터 전처리, 데이터셋 검증 및 분할, Fine-tuning 진행 이렇게 크게 4가지 단계로 구성된다.



<그림 2-4> Fine-tuning 프로세스

1단계는 데이터수집 및 생성 단계이다. 사용자는 Fine-tuning을 위한 데이터들을 수집하여 GPT 모델을 Fine-tuning 하기 위한 레이블링 데이터를 생성해야 한다. 예를 들어, 수집된 데이터가 사고사례 보고서이고 Fine-tuning의 목적이 위험요인에 대한 정보를 생성하기 위한 GPT 모델을 만드는 것이라면 <표 2-6>과 같이 Question-Answering의 형태로 데이터를 생성해야 한다.

<표 2-6> 1단계 데이터 생성 (예시)

Question	Answering
콘크리트 공사에서 펌프카를 이용해 콘크리트 타설 작업 시 위험요인은?	콘크리트 펌프카 작업반경 내 근로자 접근에 의한 부딪힘 위험

2단계는 데이터 전처리 단계이다. 데이터 전처리 단계에서는 1단계에서 생성된 데이터에서 불필요한 특수문자, 기호, 내용 등을 제거한다. 그리고 <표 2-7>과 같은 형식(JSON)으로 변환하는 과정을 거친다. JSON 데이터셋의 구성은 모델의 역할을 지정해주는 “system”, 질문(Question)에 해당하는 “user”, 답변(Answering)에 해당하는 “assistant”로 구성된다. 그 후 JSON 파일 형식을 JSONL 파일로 변환하는 과정을 통해 최종적인 Fine-tuning 데이터셋을 생성하게 된다.

<표 2-7> 2단계 데이터 형식

<pre> {"messages": [{"role": "system", "content": "Marv is a factual chatbot that is also sarcastic."}, {"role": "user", "content": "What's the capital of France?"}, {"role": "assistant", "content": "Paris, as if everyone doesn't know that already."}]}</pre>
--

3단계는 데이터셋 검증 및 분할과정으로 Fine-tuning 데이터셋 형식의 적합성 검토와 데이터셋을 검증 할 수 있도록 Train set과 Validation set으로 분할하는 과정을 포함한다.

4단계에서는 3단계를 마친 데이터셋을 기반으로 Fine-tuning을 진행한다. 해당 단계에서는 Hyper parameter 조정을 통해 모델의 성능을 최적화 할 수 있다.

3) 타 분야 Fine-tuning 연구 동향

정천수(2024)의 연구에서는 금융 분야의 도메인에 특화된 LLM을 구축하기 위한 Fine-tuning 방법과 절차에 관한 연구를 진행하였다. 해당 연구에서는 금융 문서와 용어 등을 바탕으로 데이터셋을 기반으로 LLM을 Fine-tuning하여 금융 분야에 특화된 LLM을 구현하였다. Supervised Learning을 적용하였으며, Fine-tuning 과정에서 파라미터를 효율적으로 업데이트할 수 있는 PEFT 방법을 추가하여 적용하였다. 이를 통해 Fine-tuning 방법 적용의 가능성과 방법의 효과를 검증하였다.

Li et al.(2023)의 연구는 의료 분야에 특화된 LLM을 개발하기 위한 Fine-tuning 방법을 제시하였다. Meta의 LLaMA 모델을 기반으로 약 10만 건의 환자-의사 대화 데이터를 활용하여 Supervised Learning 방식으로 Fine-tuning을 수행하였다. 이 과정에서 최신 의료 정보를 실시간으로 검색하고 활용할 수 있는 외부 지식 기반(Self-directed Information Retrieval)을 통합하여 모델의 성능을 더욱 향상시켰다. 정량적 평가 결과, Fine-tuning된 ChatDoctor 모델은 ChatGPT 대비 정밀도, 재현율, F1 점수에서 모두 우수한 성능을 보였으며, 특히 최신 질병 및 신약 관련 질문에서 더욱 정확한 응답을 제공함으로써 의료 도메인에서의 활용 가능성을 입증하였다.

Latif & Zhai et al. (2023)의 연구에서는 교육 분야에서 자동 채점을 위한 GPT-3.5 모델의 활용 가능성을 탐구하였다. 해당 연구는 중학교 및 고등학교 학생의 서술형 답안 데이터를 기반으로 하여 GPT-3.5 모델을 Fine-tuning 하였다. 이를 통해 다중 라벨(multi-label) 및 다중 클래스(multi-class) 평가 작업에서 자동 채점 정확도를 향상시켰다. 특히, Fine-tuned GPT-3.5 모델은 Google BERT 모델 대비 평균 9.1% 높은

정확도를 보였으며, 다중 라벨 작업에서는 7.2%, 다중 클래스 작업에서는 10.6%의 정확도 향상을 달성하였다. 해당 연구에서는 Fine-tuning된 GPT-3.5 모델을 교육 분야의 자동 채점에 활용할 때 유용하며 높은 정확도를 가진다는 것을 입증하였다.

Li et al.(2023)의 연구는 Table-GPT 모델을 개발하기 위해 GPT-3.5와 ChatGPT 모델을 파인튜닝하는 "Table-Tuning" 기법을 제안하였다. 이 연구에서는 GPT 모델들이 주로 자연어 텍스트 데이터에 사전 훈련되었음에도 불구하고, 테이블과 관련된 작업에서 최적의 성능을 발휘하지 못한다는 점을 문제로 지적하였다. 이를 해결하기 위해 Table-Tuning이라는 새로운 접근 방식을 통해, 모델의 기본 가중치를 테이블 작업에 특화된 데이터셋으로 학습시킴으로써 성능을 향상시켰다. 연구는 테이블 데이터 이해와 관련된 18가지 주요 작업(결측값 식별, 데이터 변환, 테이블 질의 응답 등)을 포함하는 데이터셋을 설계하였으며, 이를 통해 GPT 모델의 테이블 이해 능력을 강화하였다. 파인튜닝 결과, Table-GPT는 기존 GPT-3.5 및 ChatGPT 모델 대비 다양한 테이블 작업에서 더 높은 정확도를 보였다. 특히, 새로운 작업 및 데이터셋에서도 뛰어난 성능을 유지하며 테이블 기반 작업에서의 활용 가능성을 입증하였다.

Pornprasit & Tantithamthavorn(2024)의 연구에서는 코드 리뷰 자동화를 위한 GPT-3.5 모델의 Fine-tuning 방법을 제시하였다. 이 연구에서는 Fine-tuning과 Prompt Engineering 두 가지 접근법을 비교하여, 특정 코드 리뷰 데이터셋을 활용하여 Fine-tuning한 모델이 Zero-shot 및 Few-shot 학습만으로 활용된 모델 대비 성능이 우수함을 보였다. Fine-tuned GPT-3.5 모델은 Zero-shot 학습을 통해 기존 제안된 방법

에 비해 73.17%에서 74.23% 더 높은 정확도를 기록하였다. 또한, Fine-tuning된 모델은 미세 조정되지 않은 모델과 비교해 EM에서 기존 63.91%보다 높은 성능을 보였으며, 코드 생성 품질 평가를 위한 Code BLEU 점수에서도 5.91%에서 63.9% 향상을 달성하였다.이 연구는 GPT-3.5를 Fine-tuning하여 코드 리뷰 프로세스에서 성능을 효과적으로 개선할 수 있음을 확인하였다. 또한, 데이터가 부족한 상황에서는 Few-shot 학습 전략이 대안적으로 유용함을 입증하였다. 결과적으로, Fine-tuning은 코드 리뷰 자동화 작업에서 GPT-3.5 모델의 잠재력을 최대한 활용할 수 있는 핵심 방법으로 평가되었다.

<표 2-8> 타 분야 Fine-tuning 관련 기존연구

연구자/ (연도)	분야	주요 내용	적용 모델	적용 방법
정천수 (2024)	금융	- 금융 분야의 도메인에 특화된 Llama 기반의 LLM 구축.	Llama	SFT (PEFT)
Li et al. (2023)	의료	- 의료분야에서 의사-환자 대화 데이터 10만 개를 기반으로 Llama 모델을 미세 조정하는 연구 진행. - 질병이나 치료에 대한 의학적 문의에 대한 응답 정밀도와 정확도를 향상시킴.	Llama	SFT
Latif & Zhai et al. (2023)	교육	- 교육 분야에서 GPT-3.5 모델을 Fine-tuning하여 자동 채점 모델을 개발. - Google BERT 대비 평균 9.1% 높은 정확도를 기록하며, 다중 라벨 작업에서 7.2%, 다중 클래스 작업에서 10.6% 성능 향상을 달성. - Fine-tuning된 GPT-3.5 모델이 교육 분야 자동 채점에 유용하고 높은 정확도를 가짐을 입증.	GPT-3.5	SFT

Li et al. (2023)	정보 처리	- GPT-3.5 모델을 파인튜닝하는 "Table-Tuning" 기법을 제안하여 Table-GPT 모델을 개발. - 테이블 데이터 이해와 관련된 18가지 주요 작업 (결측값 식별, 데이터 변환, 테이블 질의 응답 등)에서 기존 GPT-3.5 및 ChatGPT 대비 성능 향상을 달성. - 새로운 작업 및 데이터셋에서도 Fine-tuning을 통해 뛰어난 성능을 보여 테이블 기반 작업에서의 활용 가능성을 입증.	GPT-3.5	SFT
Pornprasit & Tantithamthavorn (2024)	컴퓨터 공학	- 컴퓨터 공학 분야에서 GPT-3.5 모델을 Fine-tuning 하여 코드 리뷰 자동화 작업의 성능을 개선. - Zero-shot 학습 대비 73.17%에서 74.23% 더 높은 정확도를 기록하며, EM 및 Code BLEU 점수에서도 각각 63.91% 이상의 성능향상을 달성함. - Few-shot 학습이 데이터 부족 상황에서 유용함을 입증하며, Fine-tuning이 코드 리뷰 자동화에서 핵심적인 방법으로 평가됨.	GPT-3.5	SFT

이처럼 기존연구 고찰을 통해 Llama, GPT와 같은 LLM에 Fine-tuning을 적용하여 특정 분야와 목적에 훈련하여 LLM의 성능을 향상시킨 타 분야 연구사례를 확인할 수 있다. 이를 통해 본 연구의 목적인 LLM 위협요인 식별 성능향상을 목적으로 Fine-tuning 방법이 적합할 것으로 판단할 수 있으며 또한, 추가적으로 GPT Fine-tuning 시 활용할 수 있는 최적의 하이퍼 파라미터를 조합하여 적용한다면 성능향상의 효과가 극대화될 것으로 판단된다.

4) 건설 분야 Fine-tuning 연구 동향

Yoo et al.(2024)의 연구에서는 건설현장에서 발생하는 사고를 예측하고 분류하기 위해 GPT-2와 GPT-3 모델을 Fine-tuning 하는 방법을 활용하여 도메인 특화된 사고 분류 시스템을 개발하였다. 연구는 비정형 텍스트로 작성된 건설 사고보고서 데이터를 기반으로 진행되었으며, 데이터 전처리, Fine-tuning, 그리고 모델 성능평가의 과정을 통해 사고 분류 정확도를 높이는 방법을 제안하였다. 연구는 우선 사고보고서 데이터를 정형화하는 단계로 시작되었다. 보고서에서 주요 정보를 추출하여 학습 가능한 형태로 구조화하고, 각 사고를 끼임, 절단, 추락, 부딪힘, 미끄러짐, 기타의 여섯 가지 유형으로 라벨링하였다. 이후 Fine-tuning 단계에서는 사고 데이터를 활용하여 GPT-2와 GPT-3 모델이 건설 도메인의 특수한 언어 패턴을 학습하도록 하였다. 마지막으로 Fine-tuned 모델의 성능을 기존 TF-IDF, CNN, BERT 모델과 비교 평가하여, 사고 데이터에 대한 예측 정확도를 분석하였다. Fine-tuned GPT 모델은 기존의 TF-IDF, CNN, BERT 모델 대비 평균 82.33%의 높은 정확도를 기록하며, 특히 GPT-3 모델은 GPT-2와 비교해 더 높은 정확도와 안정성을 보였다. 또한, 모델이 학습 과정에서 파악한 주요 사고 전조 단어를 시각화하여 예측 결과의 해석 가능성을 높였다. 이를 통해 안전관리자들이 사고 원인을 명확히 이해하고 적절한 예방조치를 설계할 수 있도록 지원하였다.

Yao & García de Soto (2024)의 연구는 건설 산업에서 발생하는 사이버 리스크를 효과적으로 식별하기 위해 언어 모델(LLM)을 활용하는 방법을 제시하였다. 연구는 건설 산업의 사이버 보안과 관련된 대규모 텍스트 데이터를 분석하고 이를 기반으로 사이버 리스크를 분류하기 위

해 Supervised Fine-Tuning(SFT) 및 Reinforcement Learning from Human Feedback(RLHF) 기술을 적용하여 모델을 개발하였다. 연구 결과, Fine-tuning된 모델은 기존의 수작업 기반 리스크 식별 방식 대비 더 높은 정확성과 효율성을 보였으며, RLHF를 통해 이전에 학습되지 않은 질문에 대해서도 더 일반화된 응답을 생성할 수 있음을 입증하였다.

Lee et al.(2024)의 연구는 건설 프로젝트에서 기술 명세서를 검토하고 조직 내 지식을 효과적으로 관리하기 위해 대규모 언어 모델(LLM)을 활용하는 방안을 제시하였다. 연구는 OpenAI의 GPT-3(Davinci-002)와 Meta의 LLaMA2-13B 모델을 Fine-tuning하여 기술 명세서와 같은 내부 문서를 기반으로 질문-응답(Q&A) 시스템을 개발하였다. 이 시스템은 기술 명세서와 관련된 질문에 대한 정확하고 신뢰성 있는 답변을 제공함으로써 조직 내 지식 관리 효율성을 높이는 데 초점을 맞췄다. Fine-tuning된 두 모델은 정확성, 신뢰성, 간결성을 기준으로 성능을 평가받았다. 연구결과, Fine-tuning된 LLaMA2 모델은 더 GPT-3보다 더 높은 정확성을 보여주었으며, Fine-tuning된 GPT-3 모델은 LLaMA2 모델보다 특정 요구 사항에 대한 응답에서 더 높은 신뢰성을 보여주었다.

Forth et al.(2024)의 연구는 건설 산업에서 BIM(Building Information Model) 요소와 환경 데이터셋 간의 재료 매칭을 개선하기 위해 대규모 언어 모델(LLM)을 도메인 특화 방식으로 Fine-tuning하는 방법을 제안하였다. 연구는 BIM 기반의 Material Passports 생성을 자동화하여 건축물의 순환 경제와 생애 주기 평가(LCA)를 지원하는 데 초점을 맞추었다. 연구 결과, 기존 모델의 정확도가 44.26%에 불과했던 것에 비해, Fine-tuning 전략과 필터링을 결합한 경우 정확도가 80.33%까지 향상되었다.

<표 2-9> 건설 분야 Fine-tuning 관련 기존연구

연구자 (연도)	주요 내용	적용모델	적용 방법
Yoo et al. (2024)	- GPT-2와 GPT-3 모델을 Fine-tuning하여 건설 사고 예측 시스템을 개발. - 사고 유형(끼임, 절단, 추락, 충돌, 걸림 등) 분류에서 기존 TF-IDF, CNN, BERT 모델 대비 평균 82.33%의 높은 정확도를 기록. - Fine-tuning을 통해 사고 전조 단어를 파악하고 예측 결과의 해석 가능성을 높여 안전 관리 시스템에서의 활용 가능성을 입증.	GPT-2 GPT-3	SFT
Yao & García de Soto (2024)	- GPT-3.5 모델을 Fine-tuning하여 건설 산업에서의 사이버 리스크 식별 모델을 개발. - Supervised Fine-Tuning(SFT)과 Reinforcement Learning from Human Feedback(RLHF)를 적용하여 기존 수작업 방식 대비 더 높은 정확성과 효율성을 달성. - Fine-tuning과 RLHF를 통해 학습되지 않은 질문에 대한 일반화된 응답 생성 능력을 입증하며, 사이버보안 분야에서 활용 가능성을 제시.	GPT-3.5	SFT RLHF
Lee et al. (2024)	- GPT-3(Davinci-002)와 LLaMA2-13B 모델을 Fine-tuning하여 기술 명세서 기반의 질문-응답(Q&A) 시스템 개발. - Fine-tuning된 LLaMA2 모델은 GPT-3 모델 대비 높은 정확성을 보였으며, GPT-3 모델은 특정 요구 사항에 대한 응답에서 더 높은 신뢰성을 기록. - 조직 내 기술 명세서 검토와 지식 관리 효율성을 높이는 데 있어 Fine-tuning된 LLM의 활용 가능성을 입증.	GPT-3 Llama2	SFT
Forth et al. (2024)	- BERT 기반 LLM을 Fine-tuning하여 BIM 요소와 환경 데이터셋 간의 재료 매칭 정확도 개선. - Fine-tuning 전략과 필터링 기술을 결합하여 기존 44.26%의 정확도를 80.33%까지 향상. - BIM 기반 Material Passports 자동화를 통해 건축물의 순환 경제와 생애 주기 평가(LCA)를 지원할 가능성을 입증.	BERT	SFT

2.2.3 Fine tuning과 RAG 통합 연구

Wilhelmsen (2024)의 연구에서는 사망 원인 보고서 데이터를 기반으로 질병 분류코드를 자동으로 분류하기 위해 LLM을 Fine-tuning 하는 방법에 관한 연구를 진행하였다. 연구는 Meta의 Llama3와 Mistral 모델을 사용하여 수행되었으며, 1830년부터 1920년까지의 노르웨이 트론헤임 지역 장례 기록 데이터를 활용하였다. 총 2,000개의 데이터로 Fine-tuning을 수행한 뒤, 추가 데이터를 통해 성능을 평가하였다. Fine-tuning만 적용했을 때, 질병 분류 코드의 일치율은 이전 연구에서 GPT-4가 기록한 58%에서 88%로 크게 향상되었다. 반면, RAG만 적용하거나 Fine-tuning과 RAG를 병합한 경우에는 성능이 감소하였다. 이를 통해 Fine-tuning이 역사적 데이터와 같은 도메인 특화 작업에 가장 효과적임을 보여주며, RAG는 추가적인 연구가 필요함을 시사하였다.

Gupta et al.(2024)의 연구에서는 농업 분야에 특화된 LLM의 성능을 개선하기 위해 RAG와 Fine-tuning의 비교와 통합을 중심으로 진행되었다. 연구는 LLaMA2-13B, GPT-3.5, GPT-4와 같은 여러 언어 모델을 대상으로 농업 데이터를 활용하여 질문과 답변(Q&A) 생성을 최적화하는 방법을 제안하고, 이를 통해 두 가지 접근 방식의 효과와 한계를 분석하였다. 이 연구는 LLM이 특정 산업에서 더 효율적으로 활용될 수 있도록 새로운 데이터 처리 파이프라인을 제안하였다. 이 파이프라인은 크게 다섯 단계로 나뉜다. 첫 번째 단계는 PDF 문서와 같은 비정형 데이터를 수집하여 정형데이터로 변환하는 과정이다. 이 과정에서는 농업과 관련된 문서에서 정보를 추출하고, 이를 질문 및 답변을 생성하기 위한 텍스트 데이터로 구조화한다. 두 번째 단계에서는 RAG를 활용하여 모델이 특정 질문과 관련된 정보를 데이터셋에서 검색하여 적절한

문맥 정보를 생성하도록 한다. 세 번째 단계는 모델 학습 단계로, Fine-tuning을 통해 농업 분야에 특화된 지식을 모델에 내재화한다. 네 번째 단계에서는 생성된 Q&A 데이터셋과 Fine-tuned 모델을 비교 평가하여 모델 성능을 분석한다. 마지막으로, 두 접근법을 통합하여 RAG와 Fine-tuning의 상호 보완적 성능을 검토한다. RAG는 질문에 대해 관련 문맥을 데이터셋에서 검색하여 추가적인 정보를 제공함으로써, 농업 데이터와 같은 도메인에서 더욱 정확하고 간결한 답변을 생성할 수 있도록 하였다. Fine-tuning은 모델 자체를 재학습시켜 도메인 특화 지식을 내재화하는 데 집중되었으며, 이를 통해 모델의 응답 정확도와 유사성을 크게 개선할 수 있었다. 연구 결과, Fine-tuning만 적용했을 때 모델의 정확도는 약 6% 향상되었으며, RAG를 통합하였을 때 추가적으로 약 5%의 성능향상이 나타났다. 그리고 Fine-tuning된 모델과 RAG를 통합한 모델은 답변 유사성을 47%에서 72%로 크게 개선하였다. 이는 모델이 단순히 학습된 데이터를 활용하는 것을 넘어, 추가적인 정보를 참조하였을 때, 더욱 정확한 응답을 생성할 수 있음을 보여준다.

Zhang et al.(2024)의 연구에서는 금융 분야에서 질문과 답변(Q&A) 작업의 정확도를 높이기 위해 RAG와 Fine-tuning 방법을 통합하는 접근법을 제시하였다. 연구에서는 GPT-3.5 Turbo, GPT4All, LLaMA2와 같은 모델을 사용하여 Fine-tuning을 수행하였으며, 금융 데이터셋(FinanceBench, RAG Instruct Benchmark)을 활용하여 모델의 성능을 평가하였다. Fine-tuning된 모델은 질문에 대해 더 높은 정확도를 제공하였으며, RAG를 통합한 경우 추가적인 문맥을 제공하여 더욱 정확하고 적절한 응답을 생성할 수 있음을 입증하였다. 특히, Fine-tuning과 RAG의 통합은 금융 문서와 같은 도메인 특화 데이터에서 모델의 답변

정확성과 유사성을 크게 향상시켰다. 연구는 Fine-tuning과 RAG가 상호 보완적인 성능을 가지며, 도메인 특화 작업에서 LLM의 응용 가능성을 극대화할 수 있음을 보여주었다.


<표 2-10> RAG와 Fine-tuning 통합 연구

연구자 (연도)	분야	주요 내용	적용 모델	적용 방법
Wilhelmsen (2024)	의료	- Llama3와 Mistral 모델을 Fine-tuning하여 사망 원인 보고서 데이터를 기반으로 질병 분류코드를 자동화. - Fine-tuning을 통해 GPT-4의 58% 대비 88%의 코드 일치율을 달성하며, RAG 적용 시 성능 감소를 확인. - Fine-tuning이 역사적 데이터와 같은 도메인 특화 작업에서 가장 효과적인 접근법임을 입증	Llama3 Mistral	RAG, SFT
Gupta et al. (2024)	농업	- LLaMA2-13B, GPT-3.5, GPT-4 모델을 활용하여 농업 분야에 특화된 Q&A 생성을 최적화하기 위해 RAG와 Fine-tuning을 비교 및 통합. - Fine-tuning으로 모델 정확도를 약 6% 향상시키고, RAG의 통합을 통해 추가적으로 5%의 성능 향상을 달성. 답변 유사성은 47%에서 72%로 크게 개선. - Fine-tuning과 RAG의 통합이 도메인 특화 데이터에서 정확하고 간결한 답변을 생성하는 데 효과적임을 입증.	LLaMA 2 GPT-3. 5, GPT-4	RAG, SFT
[31] Zhang et al. (2024)	금융	- GPT-3.5 Turbo, GPT4All, LLaMA2 모델을 활용하여 금융 분야에 특화된 Q&A 생성을 최적화하기 위해 RAG와 Fine-tuning을 비교 및 통합. - Fine-tuning으로 질문 응답 정확도를 향상시키고, RAG 통합으로 추가적인 문맥 제공을 통해 더 정확하고 적절한 응답을 생성. - Fine-tuning과 RAG 통합이 금융 문서와 같은 도메인 특화 데이터에서 답변 정확도와 유사성을 크게 향상시킴을 입증.	GPT-3. 5	RAG, SFT

2.3. LLM 성능 평가지표

LLM의 텍스트 생성(Text Generation) 결과물에 대한 평가는 주로 정확성(Accuracy)을 기반으로 품질을 평가한다. 정확성이 낮은 모델은 신뢰할 수 없으며, 잘못된 정보를 전달하기에 유용성도 떨어진다. 따라서 LLM의 성능을 평가하는 가장 중요한 척도 중 하나라고 볼 수 있다. LLM의 텍스트 생성 결과물의 정확성(Accuracy) 대한 평가방법은 1) ‘평가지표를 활용한 자동평가’(정량적) 2) ‘사람에 의한 수동평가’(정성적) 2가지로 구분할 수 있다.

‘평가지표를 활용한 자동평가’는 ‘정확한 단어 일치 여부에 따른 평가’, ‘문장 구조 일치에 따른 평가’, ‘의미적인 일치 여부에 따른 평가’로 구분할 수 있다. ‘정확한 단어 일치에 따른 평가’에 속하는 대표적인 지표에는 BLEU Score와 ROUGE - N gram Score가 있으며, ‘문장 구조 일치에 따른 평가’에는 ROUGE-L Score가 있다. ‘의미적인 일치 여부에 따른 평가’에 속하는 대표적인 지표에는 BERT Score가 있다. BLEU, ROUGE-N Score는 용어(Keyword)의 정확성을 평가할 수 있으며, ROUGE-L Score를 통해서 문장 구조 일치 여부와 BERT Score를 통해서 의미적인 유사성을 평가할 수 있어 내용(Contents)의 정확성을 평가할 수 있다.



<그림 2-5> LLM 정확도(Accuracy) 평가방법

2.3.1 BLEU

BLEU(Bilingual Evaluation Understudy) Score는 기계 번역(Machine Translation) 성능평가를 위해 개발된 지표로, 생성된 문장(Candidate Sentence)과 기준이 되는 정답문장(Reference Sentence) 간의 단어 수준의 유사성을 측정한다. <표 2-11>은 BLEU Score의 계산 원리를 적용한 2개의 예시이다. 예시 1을 보면 ‘고소작업으로 인한 추락 위험’이라는 정답문장과 ‘고층작업으로 인해 떨어짐 예상’이라는 LLM 답변문장이 있을 때 정확하게 일치하는 단어가 없기 때문에 BLEU Score는 0점이다. 예시 2를 보면 ‘고소작업으로 인한 추락 위험’이라는 정답문장과 ‘고소작업으로 인한 떨어짐 예상’이라는 LLM 답변 문장이 있을 때, {고소작업으로}, {인한}이라는 2가지 단어가 정확하게 일치한다. 이 때 정답문장이 총 4가지 단어로 구성되어 있고, LLM 답변문장 중에서 정답문장의 단어와 정확하게 일치하는 개수가 2개이므로 BLEU Score는 0.5(2/4)점이 된다. 이처럼 BLEU Score는 단어의 정확한 일치 여부를 기준으로 정답문장과 LLM 답변문장의 유사도를 계산한다. 하지만, 이는 문장의 의미론적인(Semantic) 측면을 고려하지 못하고 점수를 계산한다는 한계가 존재한다.

<표 2-11> BLEU Score 예시

예 시 1	정답문장 (Reference Sentence)	고소작업으로 인한 추락 위험
	LLM 답변문장	고층작업으로 인해 떨어짐 예상
	BLEU Score : 0	
예 시 2	정답문장	고소작업으로 인한 추락 위험
	LLM 답변문장	고소작업으로 인한 떨어짐 예상
	BLEU Score : 0.5 (2/4)	

2.3.2 ROUGE

ROUGE Score는 주로 요약된 문장의 성능을 평가하기 위해 널리 사용되는 정량적 평가지표로, 생성된 문장이 정답문장(참고 문장)과 얼마나 유사한지를 측정한다. ROUGE는 "Recall-Oriented Understudy for Gisting Evaluation"의 약자로, 생성된 문장이 정답문장에서 나타난 정보를 얼마나 잘 포함하고 있는지를 평가하는 데 중점을 둔다. 이 지표는 텍스트 생성 모델의 결과물을 평가할 때, 특히 기계 요약(Summarization) 모델의 성능을 비교하거나 검증하는 데 자주 활용된다. ROUGE Score의 하위유형에는 ROUGE N-gram($N=1,2,3$), ROUGE-S, ROUGE-SU, ROUGE-L이 있다. ROUGE-N은 N개의 연속된 단어(N-gram)의 일치율을 기반으로 평가하는 방식이다. <표 2-12>는 ROUGE Score N-gram의 계산 원리를 적용한 예시이다. 여기서 N-gram이란 N개의 연속된 단어의 개수를 의미한다. ‘고소작업대 작업자 안전고리 미체결로 인한 작업자 추락 위험’이라는 정답문장과 ‘고소작업대 작업자 추락 위험’이라는 LLM 답변문장이 있을 때, 각 문장을 2-gram으로 분할하여 일치하는 개수를 Count 한다. 이 경우 ‘고소 작업대 작업자 추락 위험’ LLM 답변 문장의 2-gram 개수는 총 6개이고 그 중 정답문장의 2-gram과 일치하는 개수가 3개이므로 ROUGE 2-gram Score는 0.5가 된다. 이처럼 ROUGE N-gram Score도 BLEU Score와 마찬가지로 단어의 정확한 일치 여부를 기준으로 정답문장과 LLM 답변문장의 유사도를 계산한다. 하지만, BLEU Score와 마찬가지로 문장의 의미론적인 측면을 고려하지 못한다는 한계가 존재한다. 이외에 ROUGE-S는 문장에서 단어의 순서를 유지하면서도 특정 단어를 건너뛸 수 있는 "Skip-Bigram"의 일치를 평가한다. ROUGE-SU는 ROUGE-S에 단어 단위의 일치를 추가한 방식이며, ROUGE-L은 두 문장의 최장 공통부분 문자열(Longest Common Subsequence, LCS)을 계

산하여 문장의 전체적인 구조와 순서 일치를 평가한다. 이는 ROUGE N-gram과 비교하여 내용적인 측면과 문장의 순서 정보에 대한 지표를 더 잘 나타낼 수 있다는 장점이 존재한다.


<표 2-12> ROUGE N-gram(N=1,2) 예시

정답문장	고소작업대 작업자 안전고리 미체결로 인한 작업자 추락 위험
정답문장의 1-gram	(고소작업대), (작업자), (안전고리), (미체결로), (인한), (작업자), (추락), (위험)
정답문장의 2-gram	(고소작업대, 작업자), (작업자, 안전고리) (안전고리, 미체결로), (미체결로, 인한), (인한, 작업자), (작업자, 추락), (추락, 위험)
LLM 답변문장	고소작업대 작업자 추락 위험
LLM 답변문장의 1-gram	(고소작업대), (작업자), (추락), (위험)
LLM 답변문장의 2-gram	(고소작업대, 작업자), (작업자, 추락), (추락, 위험)
ROUGE 1-gram Score : 0.5 (4/8) ROUGE 2-gram Score : 0.43 (3/7)	

2.3.3 Bert Score

BLUE Score와 ROUGE Score의 의미적인 내용을 반영하지 못한다는 한계점을 극복하고자 Embedding 기반의 평가방식이 등장하였다. 대표적인 예시로는 BertScore(Zhang et al. 2020)가 있다. Bert Score는 정답문장과 LLM의 답변문장이 유사도를 계산한다는 점에서 BLUE Score, ROUGE Score와 유사하다. 하지만 Bert Score는 Embedding model을 적용하여 단어들의 벡터값을 구한 후에 유사도를 계산한다는 점에서 차이가 있다. Embedding model은 대량의 데이터셋으로 사전학습된 모델이기에 의미를 반영한 벡터값을 도출할 수 있다. Bert score의 계산 원리는 <그림2-6>과 같다. 정답문장과 답변문장을 각각 Bert모델을 활용해서 Embedding한다. BERT 모델은 각각의 문장의 개별단어(n x m)에

대한 벡터값을 도출한다. 도출된 벡터값을 내적하여 코사인 유사도를 계산하여 $n \times m$ 행렬을 구성한다. 그리고 IDF를 활용하여 빈도수가 낮고, 일반적이지 않은 단어에 중요도를 더해주는 IDF 가중치 행렬을 구성한다. 그 후, $n \times m$ 행렬과 IDF 가중치 행렬을 계산하는 작업을 한다. 이때, $n \times m$ Matrix에서 정답문장 단어의 벡터 중에 가장 큰 값을 선택한 후, 해당 값에 가중치를 곱하여 Bert score-Recall, Bert score-F1, Bert score-Precision에 대한 계산을 진행한다.



<그림 2-6> Bert score 계산 원리(Zhang et al. 2020)

2.4 소결

2.1절에서는 국내외 건설 안전 분야에서 LLM을 활용한 기존연구를 고찰하였다. 이 과정에서 Fine-tuning과 RAG를 적용하여 LLM의 성능이 향상된 다양한 연구사례들이 확인되었다. 또한, 위험성 평가에 LLM을 활용한 연구사례를 통해 RAG와 Fine-tuning을 기반으로 유의미한 성과를 달성하였음을 확인할 수 있다. 그러나 대부분의 연구는 RAG나 Fine-tuning 중 하나의 방법에 초점을 맞춘 연구가 대부분이며, 두 방법을 통합하거나 다양한 시나리오에 대한 실험적 평가를 진행한 연구는 제한적임을 확인할 수 있었다.

2.2절에서는 RAG와 Fine-tuning 기술의 정의와 세부 기술적 내용을 탐색하였다. RAG 관련 연구고찰을 통하여, 데이터베이스가 RAG 연구에서 중요한 요소로 구분되는 것을 확인할 수 있었으며, 연구에서 주로 활

용되는 데이터베이스는 벡터 기반의 데이터베이스와 지식 그래프 기반의 데이터베이스로 구분되는 것을 확인하였다. 그리고 이를 바탕으로 연구에 적합한 데이터베이스를 선정하기 위해 두 데이터베이스의 장·단점을 분석한 결과, 비정형데이터 처리의 효율성과 확장성을 고려하여 벡터 데이터베이스를 활용하는 것이 적합하다는 것을 결론을 도출하였다.

Fine-tuning 관련 고찰 결과, Supervised Fine-tuning(SFT)을 통해 특정 작업 내에서 모델 성능을 효과적으로 향상시킬 수 있음을 확인하였다. 최근 Fine-Tuning의 세부 방법론으로 PEFT(Parameter-Efficient Fine-tuning)를 활용하여 Llama 모델의 성능을 개선한 연구사례도 확인할 수 있었다. 그러나 본 연구에서 활용하는 GPT 모델의 Fine-tuning 환경은 PEFT 기법과 관련된 하이퍼파라미터 설정을 지원하지 않는다. 이러한 기술적 제한으로 인해 본 연구에서는 PEFT 방법론을 적용하는 대신, 기존의 Supervised Fine-Tuning(SFT)만을 활용하고자 한다.

Fine-tuning과 RAG 통합에 관한 연구고찰 결과, 의료·농업·금융 등의 분야에서 두 방법의 통합 구성이 LLM의 성능향상에 효과적임을 확인하였다. 그러나 건설 분야에서는 이러한 통합 구성의 연구사례가 상대적으로 부족하며, 다양한 시나리오에 대한 성능을 실험적으로 평가한 연구는 제한적임을 확인할 수 있었다.

따라서 본 연구에서는 벡터 데이터베이스 기반의 RAG와 SFT 방법 기반의 Fine-tuning을 활용하고자 한다. 그리고 이를 통해 RAG와 Fine-tuning의 통합 구성 및 다양한 시나리오를 설계하여 실험적 평가를 진행하고자 한다.

이에 따라 3장에서는 실험적 평가를 위한 RAG와 Fine-tuning 프로세스 및 시스템 구축을 진행하고, 4장에서는 2.3절에서 고찰한 LLM 성능 평가지표를 바탕으로 시스템 구성 시나리오별 성능평가를 진행한다.

제 3장 RAG와 Fine-tuning 프로세스 및 시스템 구축

3장에서는 실험적 평가를 위해 사용되는 성능향상 전략에 대하여 설명하며, 이를 바탕으로 RAG와 Fine-tuning 각각의 프로세스 설계를 진행한다. 그리고 이를 통합하는 시스템 구축 내용에 대하여 설명한다.

3.1 성능향상 전략

3.1.1 성능평가를 위한 모범답안 구성(벤치마크 데이터셋)

본 연구에서 성능평가에 활용하기 위한 모범답안(벤치마크 데이터셋)은 ‘규정 및 지침에 근거한 위험요인’과 ‘사고사례에 기반한 위험요인’ 2가지로 구분하여 구성하였다. 모범답안의 구성과정에서 안전보건공단의 위험성평가 지원시스템(KRAS)과 건설업 사고사망 핵심위험요인(SIF)평가표가 활용되었다. 위험성평가 지원시스템(KRAS)에서는 다양한 기법의 위험성평가 사례를 제공하고 있으며, 각각의 기법에 대하여 산업안전보건 규정에 근거한 유해·위험요인 예시를 제공하고 있다. 본 연구에서는 다양한 기법 중 빈도·강도법에 해당하는 유해·위험요인 예시를 활용하여 모범답안을 구성하였다. 그리고 추가적으로 사고사례에 기반한 모범답안을 추가하기 위해 안전보건공단에서 제공하는 건설업 사고사망 핵심위험요인(SIF)평가표 데이터를 활용하였다. <표 3-1>은 앞서 설명한 내용과 같이 <그림 3-1> 유해·위험요인 예시 데이터(KRAS)와 <그림 3-2> 핵심위험요인(SIF) 평가표 예시 데이터를 통해 최종적으로 구성된 모범답안의 일부 예시이다. 이외에도 연구의 범위에서 언급한 3가지 공종 및 12가지 세부작업에 대한 위험요인 모범답안도 동일한 방식으로 구성하였다.

<표 3-1> 모범답안 일부 예시(콘크리트 공사- 콘크리트 운반 작업)

모 범 답 안	[규정 및 지침에 근거한 위험요인] 출처:a.유해·위험요인 예시 데이터	1. 개인보호구 미착용하고 작업 중 부딪히거나 쥘 위험. 2. 콘크리트 펌프카 유압장치 점검 중 붐이 낙하하여 근로자 맞음 위험. 3. 펌프카 붐 설치 중 주변 고압선에 접촉으로 인한 감전 위험. 4. 작업반경 내 접근에 의한 부딪힘 위험. 5. 펌프카 장비 사용방법 미숙지에 의한 오작동 사고 위험. 6. 레미콘 운반 트럭 후진 시 유도자 미배치로 인한 근로자 부딪힘 위험. 7. 레미콘 운반 트럭 상부에서 작업 중 안전장비 미착용으로 인한 추락 위험.
	[사고사례에 기반한 위험요인] 출처:b. 핵심위험요인(SIF) 평가표	8. 콘크리트 믹서트럭의 채동장치 이상으로 미끄러지며 근로자 깔림 위험. 9. 콘크리트 믹서트럭이 경사로에서 오르지 못하고 미끄러지며 주변 근로자 깔림 위험.

공정명	세부작업명	유해위험요인 파악	관련근거
콘크리트 작업	콘크리트 반입, 운반	기계적 요인 개인보호구 미착용하고 작업중 부딪히거나 쥘 위험	안전보건규칙 제32조 [보호구 급 등]
콘크리트 작업	콘크리트 반입, 운반	기계적 요인 콘크리트 펌프카 유압장치 점검 중 붐이 낙하하여 근로자 맞음 위험	안전보건규칙 제205조 [붐 등 하에 의한 위험 방지]
콘크리트 작업	콘크리트 반입, 운반	기계적 요인 콘크리트 펌프카 유압장치 점검 중 붐이 낙하하여 근로자 맞음 위험	안전보건규칙 제38조 [사전조작업계획서의 작성 등]
콘크리트 작업	콘크리트 반입, 운반	기계적 요인 레미콘 운반트럭 후진시 유도자 미배치로 인한 근로자 부딪힘 위험	안전보건규칙 제172조 [접촉 지]
콘크리트 작업	콘크리트 반입, 운반	기계적 요인 레미콘 운반트럭 상부에서 작업 중 보호구 미착용으로 인한 떨어짐 위험	안전보건규칙 제32조 [보호구 급 등]

<그림 3-1> a. 유해·위험요인 예시 데이터(KRAS)

고위험작업/상황(Potential)		재해유발요인(Precursor)				해당여부 및 등급		위험성 감소대책										
작업명	단위작업명	기인물	재해 종류	사고사양 건수 (16~21년)	재해 상세	해당여부 (○, □)	위험등급											
2.4 콘크리트 작업 단위작업 별 사고 발생 현황 <table><tr><td>소계</td><td>17</td></tr><tr><td>주막</td><td>4</td></tr><tr><td>끼임</td><td>5</td></tr><tr><td>부딪힘</td><td>5</td></tr><tr><td>기타</td><td>3</td></tr></table> ※ 기타: 낙하 1, 전도 1, 이상운도 접촉 1	소계	17	주막	4	끼임	5	부딪힘	5	기타	3	2.4.1 콘크리트 반입, 운반	콘크리트 믹서	부딪힘	2	콘크리트 타설을 위해 대기 중인 콘크리트 믹서트럭이 채동장치 이상으로 미끄러지며 근로자 깔림	☐	중	▶ 차량계 건설기계를 사용하여 작업 시 작업 전 관리감독자가 브레이크 및 클러치 등의 기능 점검 ▶ 경사로에서 차량계 건설기계에 탑승하여 대기 시 사이드브레이크 체결 및 고임목 설치 등 미끄러짐 방지
	소계	17																
	주막	4																
	끼임	5																
부딪힘	5																	
기타	3																	
	콘크리트 믹서	부딪힘	1	레미콘 트럭이 이동 중 경사로를 오르지 못하고 뒤로 밀리며 주변에서 작업중이던 근로자 깔림	☐	중	▶ 레미콘 트럭 등 비탈길에서 차량계 건설기계 정차 시 밀린 방지를 위해 쏜, 사이드브레이크 체결 및 고임목 설치 ▶ 차량계 건설기계를 이용한 작업 시 접촉 및 부딪힘 위험이 있는 장소에 근로자 출입 금지 및 유도자 배치 ▶ 도로와 작업장이 겹쳐있을시 방책 등 근로자 보호조치 실시											
	콘크리트 믹서	전도	1	배수로 관보호공 콘크리트 타설을 위해 콘크리트 믹서 트럭을 운전하던 중 비가 내려 지표면이 미끄러운 상태의 경사로에서 전복되어 운전석 내부에서 출혈함	☐	중	▶ 차량계건설기계 상시 점검 및 정비 실시 ▶ 경우 및 악천후 등으로 차량계건설기계 운행을 불안전한 경우 즉시 중지											
	콘크리트 펌프카	끼임	1	펌프카 콘크리트 타설 위해 펌프카 사전 점검중 콤포레와 샤프트에 이상이 생겨 피팅오를 수리하던 중 채동장치의 공압호스가 빠져 차량 채동장치가 돌리면서 움직이는 펌프카에 걸림	☐	중	▶ 펌프카 등 차량계 건설기계의 수리나 부속장치의 장착 및 제거작업을 하는 경우 그 작업을 지휘하는 사람을 지정하여 해당 작업을 지휘하고 작업순서를 결정하는 작업지휘자 배치											

<그림 3-2> b. 핵심위험요인(SIF) 평가표 예시(안전보건공단, 2023)

3.1.2 범용 GPT의 한계

본 연구의 3.1.2절에서는 범용 GPT의 한계를 확인하기 위한 테스트를 진행하였다. 테스트는 공중, 작업, 사용 장비와 관련된 위험요인의 출력을 범용 GPT에 요청한 후, 이에 대한 답변을 모범답안과 연구자가 육안으로 직접 비교·분석하는 방식으로 진행하였다. <표 3-2>과 <표 3-3>은 콘크리트 공사와 거푸집 공사에 대한 범용 모범답안과 GPT 답변 결과를 비교한 표이다.

① 내용 정확도(Content Accuracy)의 한계

<표 3-2>에서 범용 GPT 답변내용을 살펴보면, “콘크리트 펌프카 작동 중의 전기 충격”, “콘크리트 펌프카 운전 중의 교통사고”와 같이 포괄적이고 일반적인 표현을 활용하며, 답변내용에 구체적인 상황과 작업 맥락을 충분히 반영하지 못한다는 것을 확인할 수 있다.

또한, 답변 형식 측면에서도 모범답안은 [{구체적인 상황}으로 인한 {재해유형}]과 같이 일관된 형식을 유지하며 구체적 작업조건과 위험요인으로 구성되어 있지만, 범용 GPT의 답변은 형식적 일관성과 구체성이 부족하다는 것을 확인할 수 있다. 예를 들어, “부주의로 인한 동바리 부품의 잘못된 조립”과 같은 답변은 재해 유형에 대한 명확한 정보를 제공하지 않으며, “작업 중 미끄러짐 및 넘어짐”과 같은 표현은 작업조건과 위험요인에 대한 설명이 부족한 추상적인 표현으로 건설현장의 위험요인에 대한 범용 GPT의 지식적인 한계를 확인할 수 있다.

② 용어 사용 정확도(Keyword Accuracy)의 한계

또한, 범용 GPT의 답변에서 전문용어 활용에 한계가 있음을 확인할 수 있다. 모범답안은 “유압장치”, “붐”, “철근 도막”, “후크 해지장치” 등과 같이 현장에서 사용하는 전문용어를 포함하고 있지만, 범용 GPT의 답변은 “작업 중 장비 손상”, “근육통 및 피로 위험” 등과 같이 일반적인 표현으로 구성되어 있다.


<표 3-2> 콘크리트 공사 답변 비교

Question	• 공종 : 콘크리트 공사 • 작업 : 콘크리트 운반 작업 • 사용장비 : 콘크리트 펌프카 일 때, 관련 위험요인은?
모범답안	1. 개인보호구 미착용하고 작업 중 부딪히거나 찰림 위험. 2. 콘크리트 펌프카 유압장치 점검 중 붐이 낙하하여 근로자 맞음 위험. 3. 레미콘 운반트럭 후진 시 유도자 미배치로 인한 근로자 부딪힘 위험. 4. 레미콘 운반트럭 상부에서 작업 중 보호구 미착용으로 인한 떨어짐 위험. 5. 펌프카 붐 설치 중 주변 고압선에 접촉으로 인한 감전 위험. 6. 작업반경 내 접근에 의한 부딪힘 위험. 7. 펌프카 장비 사용방법 미숙지에 의한 오작동 사고 위험.
범용 GPT 답변	1. 무거운 콘크리트 재료로 인한 등포 및 근육 부상 2. 콘크리트 펌프카 운전 중의 교통사고 3. 콘크리트 펌프카 작동 중의 기계적 결함으로 인한 사고 4. 콘크리트 반입 작업 중의 낙하 사고 5. 콘크리트 펌프카 작동 중의 전기 충격 사고 6. 콘크리트 반입 작업 중의 작업자 간의 충돌 사고 7. 콘크리트 펌프카 작동 중의 잘못된 조작으로 인한 사고

<표 3-3> 거푸집 공사 답변 비교

Question	• 공종 : 거푸집 공사 • 작업 : 거푸집 동바리 조립 작업 • 사용장비 : X 일 때, 관련 위험요인은?
모범답안	1. 동바리 높이 조절용 핀을 철근 도막으로 사용함으로 인한 철근에 찰림 위험 2. 가조립된 보판, 슬라브판 낙하로 인한 하부 작업 근로자 맞음 위험 3. 거푸집 동바리 구조가 2단 설치로 인한 콘크리트 타설중 무너짐 위험 4. 거푸집 자재 인양 시 양중기의 후크 해지장치 미설치로 인한 자재 에 맞음 위험 5. 동바리 간격이 구조 허용간격 이상으로 설치되어 내력 저하로 무너짐 위험 6. 동바리 미검정품 사용으로 내력 감소, 조립 불량으로 인한 무너짐 위험 7. 동바리 상하부 미고정으로 인한 동바리 무너짐 위험
범용 GPT 답변	1. 높은 고도에서의 작업으로 인한 떨어짐 위험 2. 부주의로 인한 동바리 부품의 잘못된 조립으로 인한 안전 문제 3. 작업 중에 발생할 수 있는 근육통 및 피로로 인한 안전 문제 4. 작업 중에 발생할 수 있는 미끄러짐 및 넘어짐으로 인한 안전 문제 5. 거푸집 부품의 불안정한 상태로 인한 안전 문제 6. 작업 중에 발생할 수 있는 장비 손상으로 인한 안전 문제 7. 작업장 내 환경 요인으로 인한 안전 문제 (예: 충분한 조명 부족, 충분한 통풍 부족)

3.1.3 범용 GPT의 한계 해결전략



<그림 3-3> 위험요인 정보생성 시스템 개요

3.1.2절에서 범용 GPT가 생성한 답변이 건설현장의 위험 정보를 충분히 반영하지 못하는 한계를 확인하였다. 특히 작업의 위험요인을 제시하는 과정에서 내용의 구체성이 부족하고, 건설현장에서 사용하는 전문 용어의 활용이 미흡한 문제가 드러났다. 이는 범용 GPT의 위험요인에 대한 학습이 부족하다는 점에서 기인한 한계로 볼 수 있다. 이를 해결하기 위해 3.1.2절에서는 LLM의 성능향상을 위한 전략을 제안한다. 제안하는 전략은 Fine-tuning과 RAG를 핵심기술로 활용하는 접근법을 적용한다. 제안하는 성능향상 전략을 바탕으로 구축된 시스템의 개요는 <그림 3-3>에 제시되어 있으며, 성능향상을 위한 세부전략은 <그림 3-4>와 같다. <그림 3-3>은 시스템의 전체 개요를 보여주며, 사용자가 입력한 프롬프트를 GPT-4와 RAG를 활용해 처리하고, 최종적으로 공중, 작업, 사용 장비(도구)별 위험요인을 도출하는 과정을 나타낸다. <그림 3-4>는 범용 GPT의 한계점을 해결하기 위해 적용된 성능향상(문제 해결) 전략의 구체적인 내용을 나타낸다.

1) 핵심기술(1)-A: Fine-tuning

Fine-tuning 기술을 활용하기 위해 위험성 평가와 관련된 데이터셋을 수집하고, 이를 바탕으로 학습 데이터셋을 구축한다. Fine-tuning 과정에서 모델 최적화를 위해 최적 하이퍼파라미터 조합을 도출하는 과정을 수행한다. 이를 통해 위험요인 식별에 특화된 GPT 모델을 구축하였다.


2) 핵심기술(2)-B: RAG

RAG 기술의 적용을 위해 벡터 데이터베이스를 활용한다. 이를 통해 GPT-4 모델이 작업과 관련된 정보를 검색하고, 이를 참조하여 정확한 답변을 생성할 수 있다.

3) 핵심기술(3)-C: MM-RAG(Multimodal-RAG)

MM-RAG를 활용하기 위해 문서 전처리 및 청킹 전략을 구성하였으며, 표나 이미지와 같은 비정형 데이터를 효율적으로 활용할 수 있는 시스템을 구현하였다. 비정형 데이터에서 추출된 정보를 기반으로 GPT-4 모델이 구체적이고 다양한 위험요인 정보를 생성할 수 있다.

이와 같은 전략을 활용하여 GPT-4 모델은 구체적인 내용과 전문적인 용어를 활용한 공중 관련 위험요인을 도출할 수 있다.



<그림 3-4> 성능향상 전략(해결전략)

3.1.4 성능향상 전략 기반 시스템 구축

1) Fine-tuning 및 RAG 프로세스 통합시스템

본 연구에서 제안하는 전략을 기반으로 한 Fine-tuning 및 RAG 프로세스 기반 통합시스템 구성도는 <그림 3-5>과 같으며, 세부 모듈은 Fine-Tuning(A), RAG(B), Input 모듈(C), Output 모듈(D)로 구성된다.

① Fine-tuning(A) 프로세스

KRAS 시스템의 위험성평가 사례데이터와 안전보건공단의 핵심위험요인(SIF)를 기반으로 Q&A 데이터셋을 구성하여 Fine-tuning 학습데이터셋으로 활용하였다. Fine-Tuning 모듈(A)는 총 4가지 세부 모듈로 구성된다.

- 데이터 수집 및 생성 모듈(A-1)

해당 모듈에서는 수집한 데이터셋[위험성평가 사례데이터, 핵심위험요인(SIF) 데이터]을 바탕으로 Question & Answering형식의 데이터셋을 생성한다.

- 데이터 전처리 모듈(A-2)

해당 모듈에서는 수집된 데이터를 JSONL 형식으로 변환하고, 위험요인을 줄바꿈 기호(/n)를 활용하는 과정을 포함한다. 이를 통해 문장을 체계적으로 구분하여 학습 효율성을 높일 수 있다.

- 데이터셋 검증 및 분할 모듈(A-3)

해당 모듈에서는 데이터셋의 형식을 검증하고, 학습 및 검증 데이터셋을 일정 비율로 분할하며, 이를 Fine-Tuning API에 업로드하는 과정을 포함한다.

- Fine-Tuning 모듈(A-4)

해당 모듈에서는 하이퍼파라미터(Epoch, Batch Size, Learning Rate 등)를 설정하여 모델을 학습시키고, 학습 과정을 모니터링 할 수 있는 기능을 포함한다.

② RAG(B) 프로세스

RAG(B) 총 6개의 세부 모듈로 구성된다.

- 데이터 전처리 모듈(B-1)

해당 모듈에서는 비정형데이터인 콘크리트 공사의 안전보건 작업지침서(Kosha Guide, C-43-2023)에서 공중 및 작업별 안전 지침사항을 텍스트로 추출한다. 이후, 추출된 텍스트에서 특수문자와 불필요한 정보를 제거하는 정제 과정이 수행된다.

- 청크 모듈(B-2)

데이터 전처리 모듈(B-1)에서 전처리된 텍스트는 청크 모듈(B-2)에서 Langchain 라이브러리에서 제공하는 Character Text Splitter(텍스트 분리 도구)를 활용하여 문서를 일정 단위로 분할한다. 이 과정을 통해 문서에서 추출된 텍스트를 검색 가능한 형태로 분리하며, 검색 속도와 정확도를 향상시킬 수 있다.

- 임베딩 모듈(B-3)

해당 모듈에서는 Chunking된 텍스트 데이터를 ko-sroberta 모델을 사용하여 벡터화하는 과정을 수행한다. 벡터화된 데이터는 텍스트의 의미적 유사성을 벡터 공간에 표현함으로써, 추후 검색 과정에서 유사도를 기반으로 검색에 활용된다.

- 인덱싱 모듈(B-4)

임베딩 모듈(B-3)을 통해 벡터화된 데이터는 해당 모듈을 통해 Chroma 벡터 데이터베이스에 저장된다. 이때 저장하는 과정에서 HNSW 알고리즘을 활용하여 인덱스 구조를 만들고, 해당 구조 내에 임베딩된 벡터 데이터를 저장한다.

- 검색 모듈(B-5)

저장된 벡터 데이터는 검색 모듈(B-5)을 통해 질문에 대한 응답 시 활용된다. 사용자의 질문(Embedded Query)과 비교하여, 가장 유사한 벡터 데이터를 벡터 데이터베이스 내에서 검색하고 검색된 결과를 반환하는 역할을 수행한다.

- 벡터 데이터베이스(B-6)

본 연구에서는 벡터 데이터베이스(B-6)로 Chroma 벡터 데이터베이스를 활용하였다. 벡터화된 데이터를 체계적으로 관리하여 검색과 처리를 지원한다.


③ Input 모듈(D) / Output 모듈(E)

- Input 모듈(D)

Input 모듈(C)은 사용자가 시스템과 상호작용할 수 있는 입력 인터페이스를 제공하며, System Instruction Prompt, Format Instruction Prompt, User Prompt로 구성된다. System Instruction Prompt를 통해서 GPT 모델에게 역할을 설정할 수 있다. Format Instruction Prompt를 통해서 모델에게 간단한 지침이나 예제를 제시할 수 있다. User Prompt는 시스템 사용자가 직접 Prompt를 입력하는 모듈로, 공중, 작업, 장비 등의 정보를 입력할 수 있다.

- Output 모듈(E)

Output 모듈(D)은 GPT 모델이 생성한 답변과 사용자가 입력한 Prompt와 관련된 참조 정보(검색 정보)를 사용자가 확인할 수 있는 모듈이다. 해당 모듈을 통해 RAG 결과물의 확인이 가능하다. Output 모듈(D)은 위험요인 모듈(D-1)과 참조 정보 모듈(D-2)의 세부 모듈로 구성된다. 위험요인 모듈(D-1) 도출된 위험요인을 출력하며, 참조 정보 모듈(D-2)를 통해 벡터 데이터 내부에서 검색된 결과를 확인할 수 있다.



<그림 3-5> Fine-tuning 및 RAG 프로세스 기반 통합시스템 구성도

2) Fine-tuning 및 MM-RAG 프로세스 통합시스템

성능향상 전략(2)에서는 성능향상 전략 모듈(1)의 RAG 프로세스에 표와 이미지를 처리할 수 있는 멀티모달 RAG(MM-RAG)를 적용하였다. Fine-tuning 및 MM-RAG 프로세스 통합시스템의 모듈 구성은 <그림 3-6>과 같으며, 크게 Table & Image 처리 모듈과 텍스트 처리 모듈로 구성되며 각 모듈의 세부 모듈은 다음과 같다.


① Table & Image 처리 모듈(i)

MM-RAG 시스템의 Table & Image 처리 모듈은 PDF와 같이 비정형 문서데이터에서 위험요인과 관련된 정보를 효과적으로 추출하는 역할을 수행한다. 해당 모듈의 세부 모듈은 다음과 같이 구성되어 있다.

- Table Detection 모듈(C-1)
 - 표 영역을 인식하고 해당 표 영역의 좌표값을 설정한다.
- Image Crop 모듈(C-2)
 - Table Detection 모듈(C-1)으로부터 설정된 좌표값을 기준으로 표에 해당하는 이미지 영역을 추출한다.
- 정보 추출 (C-3)
 - 표 이미지의 텍스트를 GPT-4o 모델의 OCR 기능을 활용하여 추출한다.
- Chunking (C-4)
 - 1개의 표 이미지를 기준으로 추출된 정보를 청킹(Chunking)한다.

② 텍스트 처리 모듈(ii)


- 텍스트 추출 (C-5)
 - 문서 내 구조를 바탕으로 정규식을 적용하여 PDF 문서 내에서 섹션 별로 구분하여 텍스트를 추출한다.
- Chunking (C-6)
 - 섹션 별로 추출된 텍스트 데이터를 다시 섹션 별로 청킹(Chunking)하여 벡터 데이터베이스에 저장한다.



<그림 3-6> Fine-tuning 및 MM-RAG 프로세스 기반 통합시스템 구성도

3.2 Fine-tuning(A)

Fine-tuning(A)에는 학습데이터의 구조화, 하이퍼파라미터 최적화 등을 통해 모델의 성능을 극대화할 수 있다. Fine-tuning(A)은 <그림 3-7>과 같이 데이터 수집 및 생성 모듈(A-1), 데이터 전처리 모듈(A-2), 데이터셋 검증 및 분할 모듈(A-3), Fine-tuning 모듈(A-4) 4가지 모듈로 구성되며 본 연구에서는 A-2, A-3, A-4 모듈을 Fine-tuning Framework로 구현하여 Fine-tuning을 진행하였다.



<그림 3-7> Fine-tuning(A) 프로세스 세부 모듈 구성도

3.2.1 데이터수집 및 생성(A-1)

A-1 모듈에서는 데이터수집 작업과 데이터 생성 작업을 진행한다. 본 연구의 데이터셋은 <그림 3-1> a. 위험성평가 예시 데이터(KRAS)와 <그림 3-2> b. 핵심위험요인 평가표로부터 공중별 위험요인 데이터를 활용하였다. 수집된 데이터를 Q&A 형태로 가공하여 모델 학습에 적합한 형식으로 변환하였다. 데이터셋의 형식은 아래 <표3-4>과 같이 구성하였으며, 학습 및 Fine-tuning을 위한 Q&A 학습데이터셋 총 491쌍을 생성하였다.

<표 3-4> Fine-tuning 학습용 데이터셋 생성(일부 예시)

<pre> {"messages": [{"role": "system", "content": "당신은 건설현장에서 근무하는 안전관리자입니다."}, {"role": "user", "content": "건설공사에서 공중은 {콘크리트 공사}, 작업은 {콘크리트 반입 및 운반 작업}, 사용도구 및 장비는 {콘크리트 펌프카}일 때의 위험요인."}, {"role": "assistant", "content": "작업반경 내 접근에 의한 부딪힘 위험.\n\n펌프카 장비 사용방법 미숙지에 의한 오작동 사고 위험.\n"}]] </pre>

3.2.2 Fine-tuning Framework 구축

본 연구에서는 GPT-4 모델의 Fine-tuning을 위한 프레임워크를 구현하였다. 로컬 환경에서 API를 연동하여 진행할 수 있도록 <표 3-5>와 같이 5가지 세부 모듈을 구성하였으며, Visual Studio Code 프로그램과 Python 언어를 활용하였다. Fine-tuning Framework에 해당하는 세부 모듈은 A-2, A-3, A-4 총 3가지이며, 학습 정보 확인과 작동점검을 위한 X, Y 모듈을 추가로 구현하였다.

<표 3-5> Fine-tuning Framework 세부 모듈

기호	세부 모듈명	코드명	기능
A-2	데이터 전처리 모듈	change_format.py	- 파일형식 변환 (CSV->JSON) - 전처리
A-3	데이터셋 검증 및 분할 모듈	gpt_upload_file.py	- 데이터셋 형식 검증 - Train/Validation set 분할-파일형식 변환 (JSON->JSONL) - 데이터셋 업로드
A-4	Fine-tuning 모듈	gpt_finetuning.py	- Fine-tuning 실행 - 하이퍼파라미터 설정
X	학습 정보 확인 모듈	Check Fine-tuning.py	- 학습 완료된 모델 정보 확인 - 학습 진행정보 확인 및 수정
Y	작동점검 모듈	gpt_use_finetuning.py	- 학습 완료된 모델 점검

1) 데이터 전처리 모듈 - (A-2)

Fine-tuning을 성공적으로 수행하기 위해서는 고품질의 Question & Answering 데이터셋이 필수적이며, 이를 위해 데이터셋은 철저한 전처리 과정을 통해 모델이 이해할 수 있는 형식으로 구조화되어야 한다. 데이터 전처리 과정은 크게 두 가지 단계로 나눌 수 있다. 첫째, 정제 과정에서는 수집된 CSV 파일 내의 특수문자와 불필요한 기호를 제거하여 데이터를 깨끗하고 일관된 형태로 정리하여야 한다. 해당 과정을 통해 데이터셋의 품질을 높이고 모델이 학습하는 과정에서 오류를 방지할 수 있다. 둘째, 형식 변환 과정에서는 정제된 CSV 파일을 JSON 형식으로 변환한다. 이때 {Prompt} 열에 해당하는 데이터는 {"role": "user", "content"} 형식으로 변환되며, {Completion} 열에 해당하는 데이터는 {"role": "assistant", "content"} 형식으로 변환된다. 또한, "\n" 기호를 활용하여 복수의 위험요인을 줄바꿈 형태로 구분해 입력한다. "\n" 기호의 사용은 데이터셋의 구조화 과정에서 중요한 역할을 한다. 이를 통해 Completion(답변) 내에 존재하는 여러 작업 위험요인이 명확하게 분리되어 모델이 각 위험요인을 독립된 항목으로 인식할 수 있다. 이렇게 구조화된 데이터셋은 모델이 학습 과정에서 일관된 형식과 구조를 효과적으로 학습하는 데 기여할 수 있다.

<표 3-6> 데이터 전처리 모듈 기능

[illegible]

<표 3-7> JSON 형식(예시)

<pre>{ "messages": [{ "role": "user", "content": "건설공사에서 공중은 {콘크리트 공사}, 작업은 {콘크리트 타설 및 다짐 작업}, 사용도구 및 장비 및 장비는 {콘크리트 펌프카}일 때의 위험요인", }] }</pre>
a. JSON(CSV의 Prompt 부분)
<pre>{ "role": "assistant", "content": "콘크리트 타설 중 펌프카 붐 파단에 의한 근로자 부딪힘 위험.\n 레미콘 타설장소 주변 개구부, 슬라브 단부에 개구부 미표시로 인 한 추락 위험.\n 유해 물질 피부접촉에 의한 질환 발생 위험.\n 철근 배근 상부 이동 시 안전 통로 미설치로 인한 추락 위험.\n"} </pre>
b. JSON(CSV의 Completion 부분)

2) 데이터셋 검증 및 분할 모듈 - (A-3)

데이터셋 검증 및 분할 모듈(A-3)은 데이터셋 형식 검증 기능, Train/Validation set 분할 기능, 파일형식 변환 기능(JSON -> JSONL), 데이터셋 업로드 기능을 포함한다. 데이터셋 형식 검증 기능은 <표 3-8>의 코드로 구성할 수 있다. A-2 모듈에서 변환된 JSON 파일을 불러와 validate_data_format 함수를 활용하여 데이터셋의 검증을 진행하며, 데이터셋의 형식이 [{user}, {assistant}]의 구성을 따르는지 여부를 점검한다. Train/Validation set 분할 기능, 파일형식 변환 기능은 <표 3-9>과 같으며, <표 3-10>의 코드를 통해 Fine-tuning API에 Train/Validation set 데이터셋 업로드가 가능하다.

<표 3-8> 데이터셋 형식 검증 코드

```
# JSON 파일 로드
with open(json_filename, "r", encoding="utf-8") as file:
    data = json.load(file)
# 데이터 형식 검증
is_valid, message = validate_data_format(data)
if not is_valid:
    print(f"Data format error: {message}")
else:
    print("Data format is valid.")
```

<표 3-9> Train/Validation set 분할 및 파일형식 변환 코드

```
# 데이터셋 분할(Train/Validation)
def split_and_save_jsonl(data, jsonl_filename_train, jsonl_filename_val, train_ratio=0.8)
    # Train/Validation 분할
    split_index = int(len(data) * train_ratio)
    train_data = data[:split_index]
    val_data = data[split_index:]

# Train 데이터 JSONL 파일로 저장
    with open(jsonl_filename_train, "w", encoding="utf-8") as train_file:
        for item in data:
            train_file.write(json.dumps(item, ensure_ascii=False) + "\n")

# Validation 데이터 JSONL 파일로 저장
    with open(jsonl_filename_val, "w", encoding="utf-8") as val_file:
        for item in data:
            val_file.write(json.dumps(item, ensure_ascii=False) + "\n")
```

<표 3-10> 데이터셋 업로드 코드

```
# 파일 업로드
response_train = openai.File.create(
    file=open(jsonl_filename_train, "rb"),
    purpose="fine-tune"
)
response_val = openai.File.create(
    file=open(jsonl_filename_val, "rb"),
    purpose="fine-tune"
)
```



```
{
  "messages": [
    {
      "role": "user",
      "content": "건설공사에서 공종은 콘크리트 공사, 작업은 타설 및 다짐 작업시 위험요인.",
      "role": "assistant",
      "content": "건설공사에서 공종은 콘크리트 공사, 작업은 타설 및 다짐 작업, 사용도구는 호퍼일 때의 위험요인."
    },
    {
      "role": "user",
      "content": "건설공사에서 공종은 콘크리트 공사, 작업은 타설 및 다짐 작업, 사용도구는 피니셔를 사용할 때의 위험요인.",
      "role": "assistant",
      "content": "건설공사에서 공종은 콘크리트 공사, 작업은 타설 및 다짐 작업, 사용도구는 진동기일 때의 위험요인."
    },
    {
      "role": "user",
      "content": "건설공사에서 공종은 콘크리트 공사, 작업은 콘크리트 반입 및 운반 작업 작업, 사용장비는 콘크리트 양생 작업일 때의 위험요인.",
      "role": "assistant",
      "content": "건설공사에서 공종은 콘크리트 공사, 작업은 콘크리트 반입 및 운반 작업 작업, 사용장비는 레미콘."
    },
    {
      "role": "user",
      "content": "건설공사에서 공종은 콘크리트 공사, 작업은 콘크리트 양생 작업일 때의 위험요인.",
      "role": "assistant",
      "content": "건설공사에서 공종은 콘크리트 공사, 작업은 콘크리트 양생 작업, 사용도구는 양생기일 때의 위험요인."
    }
  ]
}
```

<그림 3-8> d. JSONL 파일 예시

3) Fine-tuning 모듈 - (A-4)

Fine-tuning 모듈(A-4)은 Fine-tuning 실행기능과 하이퍼파라미터 입력 기능을 포함하며, 모델 학습 프로세스의 핵심적인 역할을 수행한다. 먼저, A-3 모듈을 통해 업로드된 Training 파일과 Validation 파일의 고유 ID를 입력함으로써 학습에 필요한 데이터셋을 지정한다. 이후 학습에 사용할 모델(예: GPT-4)과 학습 완료 후 생성될 모델의 이름(Suffix)을 입력하여 Fine-Tuning 실행이 가능하다. 하이퍼파라미터는 모델 학습의 효율성을 높이고 최적의 성능을 도출하기 위해 중요한 조정 변수로, Fine-tuning 모듈(A-4)에서는 Epoch 수, Batch Size, Learning Rate Multiplier의 값을 사용자 지정 방식으로 설정할 수 있다. Fine-tuning 실행 과정은 Training 파일과 Validation 파일의 ID 입력, 모델 및 Suffix 설정, 하이퍼파라미터 설정의 단계를 거쳐 이루어진다. Training 파일 ID와 Validation 파일 ID를 입력하고, GPT-4 모델을 선택한 뒤 Suffix를 설정하면 Fine-Tuning이 실행된다. 이 과정에서 모델은 학습데이터의 패턴을 파악하고, Validation 데이터를 기반으로 성능을 검증하며, 과적합(Overfitting)을 방지하기 위한 균형 잡힌 학습을 수행한다.

<표 3-11> Fine-tuning 모듈(A-4) 코드

```
# file_id = "id 입력"
training_file_id = input("training file_id : ")
validation_file_id = input("validation file_id : ")
model = input("사용 모델 (ex. gpt-3.5 turbo/ft-model.) : ")
suffix = input("사용자 지정 이름 : ")
# Fine-tuning
response = openai.FineTuningJob.create(
    training_file="file name",
    validation_file="file name",
    model="gpt-4",      # model명
    suffix=suffix, # suffix 이름
    hyperparameters={}
```

4) 학습 정보 확인 모듈 - (X)

학습이 완료된 후에는 학습 정보 확인 모듈(X)을 통해 모델의 상태와 학습 결과를 점검할 수 있다. 학습 완료된 모델에 대한 정보는 모델 리스트 및 상태 정보로 확인 가능하며, 학습이 진행 중인 모델은 학습 종료, 진행내용 수정, 또는 삭제 등의 기능을 통해 관리할 수 있다. 이러한 확인 과정을 통해 학습 과정에서 발생할 수 있는 오류를 사전에 발견하고, 학습의 효율성을 높일 수 있다.

5) 작동점검 모듈 - (Y)

작동점검 모듈(Y)은 학습이 완료된 모델의 작동 상태와 성능을 검증하는 기능을 수행한다. 이 모듈은 <그림 3-9>와 같이 Fine-tuning된 모델이 사용자 질의에 대해 정확한 답변을 생성하는지 확인하고, 모델이 예상대로 작동하는지 점검한다. 예를 들어, "철근콘크리트 공사에서 위험요인은?"이라는 질의에 대해 학습된 모델이 정확한 답변을 생성하는지 평가한다. 작동 점검을 통해 학습 결과를 확인하고, 모델의 활용 가능성을 실질적으로 검증할 수 있다.

[query] (공백 입력 시 종료): 철근콘크리트 공사에서 위험요인
철근콘크리트 공사에서의 위험요인은 다양하며, 주요하게 고려해야 할 몇 가지는 다음과 같습니다.

1. **낙하 위험**: 상부 작업 중 공구나 자재가 낙하하여 지상 근로자를 가림.
2. **추락 위험**: 안전대 부착 설비 미설치 상태 등에서 외부 작업발판 작업 중 추락.
3. **감전 위험**: 전기기계(타설 펌프카 집진기)에 전선이 깔려지면서 감전.
4. **무너짐 위험**: 철근조립 미숙과정에서 단부가 풀리거나 탈락하면서 작업자 근처 철근, 콘크리트 더미에 깔림.
5. **개입 위험**: 지상철근 조립중 철근 단부에 의한 찰림, 벽체 등 철근조립시 상부 장선으로 철근 접하면서 철근이 펼쳐질 위험에서 다른 작업자를 철근에 부딪힘.
6. **자격상의 위험**: 근로자들이 안전교육을 이수하지 못해서 위험한 행동을 자초.
7. **과로 위험**: 무리하게 근로를 감행하여 장시간 고열에서 작업하여 탈진.

이 외에도 현직마다 작업 환경과 조건이 다르므로, 현장 여건에 맞는 추가적인 안전 조치를 실시하고 정기적인 안전 점검을 구현하여 위험을 적극적으로 관리해야 합니다.

<그림 3-9> 작동점검 모듈 활용 예시

3.2.3 하이퍼파라미터 설정

1) 하이퍼파라미터

GPT API를 활용한 Fine-tuning 과정에서는 Epoch, Batch Size, Learning Rate Multiplier와 같은 주요 하이퍼파라미터를 설정하여 모델 학습의 효율성과 성능을 최적화할 수 있다. 각 하이퍼파라미터는 모델이 학습데이터를 처리하고 학습 결과를 도출하는 데 있어 중요한 역할을 수행한다.

먼저, Epoch는 모델이 전체 데이터셋을 학습하는 반복 횟수를 의미한다. 예를 들어, 데이터셋에 100개의 Q&A 데이터 쌍이 있을 때 Epoch 수를 3으로 설정하면, 모델은 전체 데이터셋을 3번 반복 학습하게 된다. Epoch 수를 적절히 설정하면 모델이 데이터의 패턴을 충분히 학습할 수 있지만, 과도하게 높은 Epoch 수는 과적합(Overfitting)을 발생시킬 수 있으므로 주의가 필요하다.

Batch Size는 모델이 1회 Epoch에서 학습에 사용하는 데이터 샘플의 수를 나타낸다. 예를 들어, 데이터셋이 100개이고 Batch Size를 25로 설정하면, 모델은 1 Epoch 동안 데이터를 4회($100/25$)로 나누어 학습하게 된다. Batch Size는 학습 속도와 GPU 메모리 사용에 직접적인 영향을 미치며, 값이 너무 크거나 작을 경우 학습의 안정성과 성능에 부정적인 영향을 줄 수 있다.

Learning Rate Multiplier는 모델 학습 중 가중치(Weights)가 업데이트되는 크기를 조정하는 변수로, 학습 과정의 효율성을 결정짓는 중요한 요소다. Learning Rate 자체는 모델의 전체 레이어에 적용되는 학습률을 의미하며, Multiplier는 이에 곱해지는 상수로, 특정 레이어의 학습 속도를 조절하는 데 사용된다. Learning Rate가 지나치게 낮으면 학습

속도가 느려지고 최적화가 어려워질 수 있으며, 반대로 지나치게 높으면 학습 과정이 불안정해질 가능성이 있다.

이와 같은 하이퍼파라미터들은 Fine-Tuning 과정에서 최적의 조합을 설정하기 위해 다양한 실험과 테스트를 통해 결정된다. 각 하이퍼파라미터의 설정은 모델의 학습 속도, 안정성, 성능에 직접적인 영향을 미치므로, 학습 데이터의 특성과 목적을 고려한 신중한 조정이 필요하다. 이를 통해 Fine-tuning된 모델은 높은 학습 효율성과 도메인 특화된 성능을 발휘할 수 있게 된다.

<표 3-12> 하이퍼파라미터의 주요 변수 및 정의

주요 변수	정의
Epoch 수	- 전체 데이터셋을 모델이 학습(신경망을 통과)하는 횟수.
Batch Size	- 모델이 1 Epoch을 수행할 때 사용되는 데이터의 샘플 수. - 전체 데이터셋을 여러 작은 그룹으로 나누었을 때 하나의 소그룹에 속하는 데이터 수
Learning Rate	- 모델 전체 레이어가 업데이트되는 가중치(Weights)의 크기
Learning Rate Multiplier	- Learning Rate에 대한 곱셈 상수를 의미. - 모델의 특정 레이어에 대한 학습률을 조정하는 변수.

2) 최적 하이퍼파라미터 설정

하이퍼파라미터 설정은 <표 3-13>의 hyperparameters={} 개체를 통해 변수 설정과 변수값 입력이 가능하다. 본 연구에서는 최적의 하이퍼파라미터 조합을 찾기 위해 여러 가지 조합에 대한 테스트를 진행하였다. 실험을 통해 본 연구에서 Fine-tuning에 활용할 최적 하이퍼파라미터 조합은 Epoch : 3, Batch Size : 1, Learning rate multiplier : 1이라는 결론을 도출하였으며, 해당 하이퍼파라미터 조합을 적용하여 Fine-tuning을 진행하였다.

<표 3-13> 하이퍼파라미터 설정 코드

```
# file_id = "id 입력"
training_file_id = input("training file_id : ")
validation_file_id = input("validation file_id : ")
model = input("사용 모델 (ex. gpt-4/ft-model.) : ")
suffix = input("사용자 지정 이름 : ")
# Fine-tuning
response = openai.FineTuningJob.create(
    training_file="file name",
    validation_file="file name",
    model="gpt-4", # model명
    suffix=suffix, # suffix 이름
    hyperparameters={
        "n_epochs":3,
        "learning_rate_multiplier": 1, # 학습률 배수
        "batch_size": 1
```

• 최적 하이퍼파라미터 조합 실험

본 연구에서는 Epoch 수, Batch Size, Learning Rate Multiplier를 주요 변수로 설정하고, 각각의 조합에 대해 Bert Score 평가지표를 기반으로 Fine-tuning 모델의 성능을 평가하였다. 그리고 하이퍼파라미터 설정 과정에서 Epoch 수를 기준으로 Batch Size와 Learning Rate Multiplier를 조합하여 최적의 하이퍼파라미터 설정을 도출하였다. 본 연구의 실험에서 최적 하이퍼파라미터 조합의 첫 번째 기준 변수를 Epoch 수를

기준으로 한 이유는 해당 변수는 모델이 전체 데이터셋을 학습하는 반복 횟수를 의미하며, 모델의 과적합(Overfitting) 여부를 결정짓는 핵심 변수이기 때문에 기준 변수로 설정하였다.

(1) Epoch 수와 Batch Size의 조합에 따른 성능 분석

Epoch 수에 따라 Batch Size를 변경하면서 Bert Score를 비교하여, 모델의 성능을 분석하였다. 분석 결과 Epoch = 3, Batch Size = 1에서 가장 높은 Bert Score(0.9122)를 기록하였으며, Batch Size가 증가할수록 Bert Score가 전반적으로 감소하였다. Epoch 수 5 이상에서는 Batch Size = 8~32 구간에서도 높은 성능을 나타냈으나, 학습 효율성을 고려할 때 Epoch = 3, Batch Size = 1이 최적의 조합으로 판단된다.

<표 3-14> Epoch 수와 Batch Size의 조합에 따른 성능

Epoch 수	Batch Size				
3Epoch	1	4	8	16	32
Bertscore	0.9122	0.868433333	0.8571	0.8614	0.8805
4Epoch	1	4	8	16	32
Bertscore	0.9088	0.905433333	0.888866667	0.904733333	0.894166667
5Epoch	1	4	8	16	32
Bertscore	0.902166667	0.9023	0.9061	0.902966667	0.905066667

(2) Epoch 수와 Learning Rate Multiplier의 조합에 따른 성능 분석

Epoch 수와 Learning Rate Multiplier를 조합하여 Bert Score를 비교하고, 모델의 성능을 분석하였다. 분석 결과 3 Epoch, Learning Rate Multiplier = 1에서 Bert Score(0.8830)가 가장 높게 나타났으며, 학습의 안정성과 성능을 동시에 확보할 수 있었다. 5 Epoch에서도 Learning Rate Multiplier = 1에서 가장 높은 Bert Score(0.9083)를 기록하였으나, Epoch 증가로 인한 학습 비용을 고려했을 때 Epoch = 3, Learning Rate Multiplier = 1이 최적의 선택으로 판단된다.


<표 3-15> Epoch 수와 Learning Rate Multiplier의 조합에 따른 성능

Epoch 수	Learning rate multiplier		
3Epoch	0.1	0.2	1
Bertscore	0.8724	0.87238	0.883
4Epoch	0.1	0.2	1
Bertscore	0.90118	0.90016	0.89986
5Epoch	0.1	0.2	1
Bertscore	0.90362	0.89924	0.9083

실험 결과, 본 연구에서는 Epoch = 3, Batch Size = 1, Learning Rate Multiplier = 1이 최적의 하이퍼파라미터 조합임을 확인할 수 있다.

3.3 RAG(B)


RAG(B) 프로세스의 세부 모듈 구성도는 <그림 3-10>과 같으며, 세부 모듈은 데이터 전처리 모듈(B-1), Chunking 모듈(B-2), Embedding 모듈(B-3), Indexing 모듈(B-4), 검색 모듈(B-5), 벡터 DB (B-6)으로 구성된다.




<그림 3-10> RAG(B) 프로세스 세부 모듈 구성도

3.3.1 데이터 전처리 및 Chunking - (B-1, B-2)

1) 데이터 전처리 모듈 - (B-1)



=>



<그림 3-11>

콘크리트공사의 안전보건작업 지침.pdf

<그림 3-12>

전처리 된 Text

데이터 전처리 모듈(B-1)에서는 [건설 안전 보건 작업지침서-콘크리트 공사.pdf] 문서로부터 텍스트 데이터를 추출하기 위해 pdf2txt 알고리즘을 사용하였다. 본 연구에서는 fitz 라이브러리를 활용하여 PDF 파일의 텍스트를 추출하였다. 이 과정에서 문서의 각 페이지를 순회하며 텍스트 데이터를 읽어들이고, 이를 하나의 문자열로 병합하여 반환하는 프로세스를 구현하였다. 추출된 텍스트는 특수문자 제거, 중복 공백 삭제, 메타데이터 제거와 같은 정제 작업을 거쳐 데이터의 품질을 높였다. 이러한 전처리 과정을 통해 추출된 텍스트 데이터의 품질은 B-2 Chunking 단계의 효율성과 추후 검색단계(B-5)에서 검색의 정확성에 큰 영향을 미치게 된다.



2) Chunking - (B-2)

Chunking은 전체 텍스트 데이터를 의미가 유지되는 작은 단위로 분할하는 작업으로, LLM과 벡터 데이터베이스를 활용하는 시스템에서 중요한 과정이다. 이 과정은 LLM이 긴 문서를 처리할 수 있도록 입력 데이터를 적절히 나누고, 검색 효율성과 응답 품질을 향상시키는데 기여한다. LLM은 입력 가능한 토큰 수에 제한이 있으므로, 긴 문서를 처리할 때 텍스트를 적절히 분할하지 않으면 모델이 모든 정보를 수용하지 못하거나 효율성이 저하될 수 있다. 또한, Chunking은 벡터 데이터베이스에서 관련 정보를 검색할 때 정밀도를 높이는 데 기여한다. 텍스트를 의미 단위로 나누면 불필요한 정보를 줄이고, 정확한 참조 정보를 제공할 수 있기 때문이다. 이와 함께 Chunking은 모델이 입력 데이터를 이해하기 쉽도록 구조화하여 응답 품질을 높이는 역할을 한다.

Chunking 작업을 진행할 때에는 다음과 같은 사항을 고려해야 한다.

첫째, 텍스트는 의미가 유지될 수 있는 자연스러운 경계에서 분할(Split)해야 한다. 일반적으로 단락(Paragraph), 문장(Sentence), 혹은 특정 토큰 수를 기준으로 Chunk를 생성하며, 이 과정에서 문맥이 단절되지 않도록 적절한 분할 기준을 설정해야 한다. 자연스러운 경계에서의 분할은 각 Chunk가 독립적으로 의미를 가질 수 있도록 하며, 이는 검색 및 모델 사용 과정에서의 효율성을 높이는데 기여한다.

둘째, Chunk 크기(Chunk Size)는 LLM의 입력 토큰 제한과 벡터 데이터베이스의 검색 효율성을 동시에 고려하여 설정해야 한다. Chunk 크기가 지나치게 작으면 문맥이 단절되거나 의미 전달이 부족할 수 있고, 반대로 너무 크면 LLM이 텍스트를 처리하기 어려워지며 검색 효율성 또한 저하될 수 있다. 따라서 적절한 Chunk 크기를 설정하는 것이 중요

하며, 일반적으로 GPT 모델의 입력 토큰 수를 고려했을 때, 512~1024 값 사이에서 Chunk 크기를 결정하는 것이 바람직하다.


셋째, Chunk는 벡터화(Embedding) 과정에서 정보의 중복(Overlap)을 최소화하면서도 중요한 내용을 유지할 수 있도록 구성해야 한다. 이를 위해 Chunk Overlap을 설정하여 인접한 Chunk 간의 의미 연속성을 보장해야 한다. Chunk Overlap 크기가 지나치게 작을 경우 문맥 연속성이 손실될 수 있으며, 반대로 지나치게 클 경우 중복 데이터로 인해 검색 성능이 저하될 가능성이 있다. 따라서 적절한 Overlap 크기를 설정하는 것이 Chunking 작업에서 매우 중요하다.

본 연구에서 사용된 [콘크리트공사의 안전보건 작업지침.pdf]은 각 공종 별(거푸집 공사, 철근 공사, 콘크리트 공사) 세부 작업지침으로 구분된 내용을 포함하여 구성되어 있다. 문서의 구성은 크게 1. 목적, 2. 적용범위, 3. 용어의 정의, 4. 거푸집 공사, 5. 철근 공사, 6. 콘크리트 공사로 이루어져 있으며, 4. 거푸집 공사는 ① 거푸집 조립작업, ② 거푸집 해체 작업 등으로 나뉘어 구성되어 있다.

Chunk 크기(Chunk Size) 및 중복 범위(Chunk Overlap)는 긴 텍스트의 문맥과 의미를 유지하기 위해 설정되었다. 본 연구에서는 Chunk 크기를 1000으로 설정하여 LLM의 입력 토큰 수 제한을 고려하면서도 각 Chunk가 세부작업 지침의 내용을 충분히 포함하도록 하였다. 또한, 인접한 Chunk 간 50자의 중복 범위(Chunk Overlap)를 두어 작업 간 의미적 연속성을 유지하도록 하였다. 이를 통해 Chunking 과정에서 정보 손실을 최소화하고, 공종의 작업별 안전 지침 간의 의미론적 관계를 효과적으로 유지할 수 있도록 하였다.

<그림 3-13>은 앞서 설명한 Split, Chunk Size, Chunk Overlap의 적

용을 통해 <그림 3-12>으로부터 Chunking 된 결과물(Chunked Text)이다.



<그림 3-13> Chunked Text

<표 3-16> Chunking(B-2) 코드 구성

```
# 텍스트를 청크로 분할
splitter = Character Text Splitter.from_tiktoken_encoder(
    separator="\n", "\n\n"
    chunk_size=1000,
    chunk_overlap=50
)
texts = splitter.split_text(file_text)
```

3.3.2 Embedding 및 Indexing - (B-3, B-4)


1) Embedding - (B-3)

Embedding은 텍스트 데이터를 숫자 벡터로 변환하는 작업으로, 모델이 텍스트의 의미와 관계를 이해할 수 있도록 돕는 핵심 과정이다. 특히, RAG 프로세스에서는 임베딩된 벡터를 활용하여 벡터 데이터베이스에서 관련 정보를 검색하고, 이를 기반으로 LLM이 Prompt에 응답하기 때문에, Embedding 품질이 시스템 성능에 직접적인 영향을 미친다.

본 연구에서는 Embedding 작업을 수행하기 위해 ko-sroberta 모델을 활용하였다. ko-sroberta는 Hugging Face에서 제공하는 사전 학습된 RoBERTa 기반의 모델로, 한국어 텍스트 데이터에 최적화된 특성을 가지고 있다. 이 모델은 텍스트의 의미를 효과적으로 표현할 수 있어 한국어 분석에서 우수한 성능을 발휘한다. 특히 건설 안전과 같은 특화된 도메인의 텍스트에서 단어와 문장의 맥락적 의미를 잘 반영할 수 있어, RAG 프로세스의 Embedding 모듈(B-3)로 적합하다고 판단되었다. 이렇게 Embedding 모듈(B-3)에서는 Chunked된 Text를 ko-sroberta 모델에 입력하여 벡터 형식으로 변환하는 과정이 포함된다.

<표 3-17> Embedding(B-3) 모듈 코드 구성

```
# Embedding 설정
hf = HuggingFaceEmbeddings(model_name='jhgan/ko-sroberta-multitask')
# Chroma 데이터베이스 설정
db = Chroma(persist_directory='./db_4', collection_name='risk_eval', embedding_function=hf)
```



<그림 3-14> Embedding 결과물

2) Indexing - (B-4)

Indexing은 임베딩된 벡터(Vectorized Text)를 데이터베이스에 저장하고 효율적인 검색이 가능하도록 구조화하는 과정이다. 본 연구에서는 Chroma 데이터베이스를 활용해 데이터를 관리하였으며, Indexing 과정에서 HNSW 알고리즘을 적용하였다. HNSW는 대규모 벡터 데이터에서 빠르고 정확한 검색을 가능하게 하는 계층적 그래프 기반 알고리즘이다. 이 알고리즘은 벡터 데이터를 저장할 때, 데이터 간의 유사도를 계산하여 유사성이 높은 데이터를 가까운 저장공간에 위치시킨다. 이는 추후 검색 과정에서 데이터셋 내에서 가장 가까운(유사한) 벡터를 찾는 근사 근접 탐색(Approximate Nearest Neighbor Search)을 수행하여 신속하고 정확한 결과를 제공할 수 있다.

Indexing 구현 과정에서는 벡터 데이터를 risk_eval 이라는 컬렉션에 저장하여 위험성 평가와 관련된 데이터를 독립적으로 관리할 수 있도록 구성하였다. 또한, 데이터베이스의 지속성을 확보하기 위해 저장 디렉토리를 지정하여, 시스템 재가동 시에도 데이터가 유지되고 추가적인 데이터 입력 및 업데이트 작업에 유연하게 대응할 수 있도록 설계하였다.

<표 3-18> Indexing(B-4) 코드 구성

```
db = Chroma.from_texts(  
    texts,  
    hf,  
    collection_name='risk_eval',  
    persist_directory='경로',  
    collection_metadata={'hnsw:space': 'cosine'}, # l2 is the default  
)
```

3.3.3 검색 및 벡터 DB(1) - (B-5, B-6)

1) 검색(B-5)

검색 모듈(B-5)은 Embedded Query(A모듈)와 유사한 데이터를 벡터 데이터베이스(Vector DB)에서 찾아 반환하는 역할을 수행한다. 해당 모듈은 Prompt를 벡터화한 후, 데이터베이스 내에서 유사도를 계산해 가장 적합한 데이터를 선별하고, 이를 답변 생성에 활용할 수 있도록 정제된 형태로 제공해야 한다. 유사도 계산에는 벡터 데이터베이스에 활용할 수 있는 코사인 유사도 계산 기반의 `db.similarity_search` 함수를 활용한다. 검색 모듈의 과정은 다음과 같다.

검색 모듈의 첫 번째 단계는 Embedded Query를 데이터베이스에 전달하여 유사도 기반 검색을 수행하는 것이다. 이 과정에서 `db.similarity_search` 함수를 활용하여 다음과 같은 작업을 수행한다.

- ① Prompt를 Embedded Query로 변환하여 데이터베이스에 전달.
- ② 데이터베이스는 저장된 벡터 데이터와 입력된 벡터 간의 유사도를 계산.
- ③ 유사도가 높은 순서대로 데이터를 정렬한 검색 결과 리스트를 반환.

두 번째 단계에서는 “`selected_docs = rag_result[:3]`”를 활용하여 다음과 같은 작업을 수행한다.

- ④ 검색된 데이터의 양을 제한하여 검색 효율성을 높이고, 관련성이 낮거나 불필요한 데이터를 배제하기 위해 검색된 결과 리스트 중 상위 3개의 문서를 선별.

이후, ④의 결과물은 사용자 UI에 참조 정보(E-2)에 표시된다.

세 번째 단계에서는, “`rag_ans = format_docs(selected_docs)`”를 활용하여 다음 작업을 수행한다.

- ⑤ 검색된 문서를 정제하고, 모델이 이해할 수 있는 형태로 포매팅

이후, ⑤의 결과물은 Fine-tuned GPT Model(A-4)의 입력 데이터로 처리된다.

<표 3-19> 검색(B-5) 구성 코드

```
from langchain_community.embeddings import HuggingFaceEmbeddings
from langchain.vectorstores import Chroma
if USE_RAG :
    print("[RAG] : ")
    rag_result = db.similarity_search(query)
    # RAG 결과 중 관련 문서 선별
    selected_docs = rag_result[:3] # 3개 문서 선별
    rag_ans = format_docs(selected_docs) # 문서 내용을 포맷팅
    print(rag_ans)
def format_docs(ans_li):
    # Filter out any empty strings or None values from ans_li
    filtered_content = [ans.page_content for ans in ans_li if ans.page_content.strip()]
    return "\n\n".join(filtered_content)
```

2) 벡터 DB(B-6)

본 연구의 벡터 DB 모듈(B-6)에서는 Chroma 벡터 데이터베이스를 활용하여 의미 기반 검색(Semantic Search)이 가능하도록 설계하였다.

구성된 데이터베이스 내부 구조는 <그림3-13>과 같으며, 각 벡터 데이터베이스란 텍스트, 이미지 등이 Embedding 모델을 통해 생성된 숫자 벡터 데이터를 처리하도록 설계된 특수 데이터베이스를 의미한다.


기존의 데이터베이스는 텍스트, 숫자 등의 데이터를 저장하여, 키워드 검색 기반의 방식을 주로 적용한다. 키워드 검색 기반의 방식은 검색 속도가 빠르고 안정적이라는 장점이 있지만, 데이터베이스 구축과 쿼리문 작성 등으로 인해 많은 시간과 노동을 필요로 하며, 쿼리의 의미와 의도에 대한 고려가 불가하다는 단점이 존재한다.

벡터 데이터베이스는 쿼리 관련된 문맥적 의미를 이해하고 이에 대한 검색 결과를 제공하는 의미(Semantic) 기반의 검색방식을 적용한다. 의미(Semantic) 기반의 검색방식은 키워드 검색방식과 비교하여 연산량이 많다는 단점이 존재하지만, 사용자의 의도를 정확하게 이해하여 관련

정보를 검색할 수 있다는 장점이 존재한다. 이는 LLM에 RAG 프로세스를 적용할 때 검색 결과로 질문과 의미적으로 관련도 높은 정보를 도출할 수 있는 장점이 있다.

<표 3-20> 벡터 DB 모듈(B-6) 구성 코드


```
# Embedding 설정
hf = HuggingFaceEmbeddings(model_name='jhgan/ko-sroberta-multitask')
# 데이터베이스 생성
db_dir = './db_5'
if not os.path.exists(db_dir):
    os.makedirs(db_dir)
db = Chroma(persist_directory=db_dir, collection_name='risk_eval',
embedding_function=hf)
```



<그림 3-15> Chroma DB 내부

3.4 MM-RAG(C)

RAG의 성능을 극대화하기 위해서는 양질의 데이터 확보가 필수적이다. 특히 건설 분야에서 RAG를 활용할 때, GPT 모델에 제공되는 참조 정보는 시스템의 답변 정확도와 신뢰성에 직접적인 영향을 미친다. 현장 위험성평가 문서나 사고사례집과 같은 데이터는 양질의 참조 데이터로 분류될 수 있으며, 대부분 PDF 형태로 관리되고 표와 이미지 같은 비정형데이터를 포함한다. 그러나 기존 텍스트 기반 RAG 프로세스는 PDF 문서에 포함된 비정형데이터를 효과적으로 활용하지 못하며, 표내 텍스트를 추출하더라도 정보 손상이나 누락의 가능성이 크다. 이러한 한계를 극복하기 위해 본 연구에서는 멀티모달 기반의 MM-RAG(C) 접근법을 제안하였다. 제안하는 MM-RAG(C)는 PDF 문서에서 표의 정보를 이미지 형태로 추출하고, 이를 GPT-4o 모델의 OCR 처리 기능을 통해 분석하여 유용한 정보를 추출한다. 추출된 데이터는 벡터 데이터베이스에 저장되어 참조 정보로 활용된다. 이 시스템은 비정형데이터를 포함한 문서를 효율적으로 처리함으로써 RAG 성능향상에 기여할 수 있다. MM-RAG(C)의 세부 모듈 구성은 <그림 3-16>과 같다.



<그림 3-16> MM-RAG(C) 세부 모듈 구성도

3.4.1 Table & Image 처리 모듈(i)

1) 표 인식(C-1)

표 인식(C-1) 모듈은 PDF 문서 내에서 표의 위치를 인식(Detection)하여 좌표값을 추출하는 과정을 수행한다. 본 연구에서는 [안전보건공단-핵심위험요인.pdf] 문서 내의 위험요인 평가표 데이터를 활용하였으며, 해당 표 내에서 [재해유발요인]-[재해 상세]항목의 정보를 추출하여 활용하였다. 표 내에서 표를 인식하는 과정에서 사용된 모델은 객체 인식(Object Detection)에 특화된 Yolo v8 모델을 사용하였다. Yolo v8 모델은 PDF 문서 내의 표 영역을 객체로 인식한 후 바운딩박스의 좌표값을 결과물로 도출한다. 모델이 표 영역을 인식한 결과 및 바운딩박스 결과물은 <그림 3-17>과 같다.

2.1 거꾸집 작업

건설업 사고사망 핵심위험요인(SIF) 평가표

※ 최근 6년간('16~'21년) 건설업에서 발생한 사망재해를 분석하여, 중상해 이상 재해를 일으킬 수 있는 고위험작업/상황 및 재해유발요인 도출

bordered 0.70

으로, 체크리스트를 참고하여 사업장 환경 및 작업특성을 고려한 고위험작업, 재해유발요인을 전체적으로 파악·추가하기가 바람

고위험작업/상황(Potential)		재해유발요인(Precursor)				해당여부 및 등급		위험성 감소대책										
작업명	단위작업명	기인율	재해 종류	사고사망 건수 ('16~'21년)	재해 상세	해당여부 (○, □)	위험등급											
2.1 거꾸집 작업 단위작업 별 사고사망 위험도 <table> <tr> <td>소계</td> <td>49</td> </tr> <tr> <td>추락</td> <td>35</td> </tr> <tr> <td>끼임</td> <td>2</td> </tr> <tr> <td>부딪힘</td> <td>-</td> </tr> <tr> <td>기타</td> <td>12</td> </tr> </table> ※ 기타: 낙하 5, 전도 3, 깔림 1, 절단 1, 기타 1	소계	49	추락	35	끼임	2	부딪힘	-	기타	12	2.1.1 거꾸집 재채반입, 기공, 운반	비계	추락	3	비계 위에서 상부층으로 거꾸집 재채를 옮기기 위해 받아치기 방법으로 작업 중, 거꾸집의 무게를 이기지 못하고 몸의 중심을 잃어 계구부로 추락	☐	상 중 하	▶거꾸집 재채 양중 시 자재에 따라 알맞은 결속과 도르래 및 양중장비를 사용하여 작업 ▶추락위험이 있는 장소에서 작업 시 단부에 안전난간 설치 등 추락방호조치 실시
	소계	49																
	추락	35																
	끼임	2																
부딪힘	-																	
기타	12																	
		비계	추락	1	작업자 승하강 통로가 설치되어 있지 않은 시스템 부재(비계, 동바리)에서, 자재 운반 중 시스템 부재를 밟고 몸의 중심을 잃고 추락	☐	상 중 하	▶거꾸집동바리 등의 가설재 내부에서 이동가능한 승·하강설비 설치 ▶고소작업 장소에서 이동 및 작업 중 추락방지를 위해 추락방지망 설치 ▶2m 이상의 추락위험이 있는 장소에서 작업 시 안전대 부착설비 설치 및 안전대 착용										
		비계	추락	1	비계와 작업발판 간 고정이 불량하여 거꾸집 운반 중 작업발판 돌림으로 비계에서 근로자 추락	☐	상 중 하	▶외부비계 등 2m 이상의 추락위험장소에 설치되는 작업발판에 대해 둘 이상의 지지물에 고정 및 앞단 결림고리 체결 확인 ▶외부비계 위에서 이동·작업 시 추락방지조치 실시										
		비계	추락	1	승강통로가 미설치된 상태에서 외부비계 바깥으로 이동 중 실족하여 추락	☐	상 중 하	▶비계 상하단 작업발판 사이에는 사다리, 계단 등의 승하강 통로 설치 ▶추락 위험이 있는 작업발판, 통로 끝 및 계구부에는 안전난간 또는 덮개 등 설치 ▶계구부 덮개 설치 시 계구부임을 표기하여 추락 위험 방지										

<그림 3-17> 문서 내 표 인식 결과

2) 이미지 추출(C-2)

이미지 추출(C-2) 모듈은 (C-1)에서 인식한 표 영역의 바운딩 박스를 기준으로 이미지를 자르는 과정을 수행한다. 수행 결과물은 <그림 3-18>과 같다.

고위험작업/상황(Potential)		재해유발요인(Precursor)				해당여부 및 위험등급		위험성 감소대책
작업명	단위작업명	기인물	재해 종류	사고사양 간수 (16~21년)	재해 상세	해당여부 (○, □)	위험등급	
2.4 콘크리트 작업	2.4.2 콘크리트 타설 및 다짐	콘크리트 펌프카 (국립안전연구원)	전도	9	콘크리트 타설 작업 중 펌프카 아웃트리거 하부 지반이 침하되어 펌프카가 기울어지며 펌프카 몸대가 근로자 가격	☐	☐ 상 중 하	▶ 콘크리트 펌프카를 이용한 타설 작업 시 지반·지층 상태 사전조사 및 다짐 등의 방법으로 지지력 확보 ▶ 콘크리트 펌프카를 이용한 타설 작업 시 아웃트리거 손상 등에 의한 전도방지를 위해 아웃트리거 접지부 방형대 설치 등 실시 ▶ 차량계 건설기계 사용 시 유도자를 배치하여 작업반경 내 근로자 접근 통제 실시
단위작업 별 사고 사례 유형 사 소 계 주 학 49 고 대 2 사 기 입 14 유 기 입 2 형 부 입 7 기타 26 ※ 기타: 전도 10, 붕괴 9, 발동 3, 파열 2, 기타 2								
		콘크리트 펌프카 (국립안전연구원)	파열	1	콘크리트 타설 작업 준비 중 콘크리트 펌프카의 압송관이 막혀 압송관 교체작업을 위해 굴림의 롤트를 배치하는 순간 막혀있던 콘크리트가 분출하여 근로자 가격	☐	☐ 상 중 하	▶ 콘크리트 펌프용 압송관에 막혀 콘크리트 타설작업 중지 시 작업 중단 및 보수 실시 ▶ 분출되는 콘크리트에 맞을 위험이 있는 장소에서는 작업내용에 적절한 개인 보호구 지급 및 착용
		각재 (B이브,강관, 합판)	추락 (국립안전연구원)	1	콘크리트 타설 장소로 이동하던 중 이동중로가 확보되지 않은 상태에서 슬래브에 기대어 세운 목재각재를 밟고 올라가던 중 목재각재가 무너지며 근로자 낙상을 강타	☐	☐ 상 중 하	▶ 작업장 주변 통하는 장소 또는 작업장내에 통로의 주요 부분에 통로표시로 안전한 통행 보장 ▶ 작업여건에 의해 추락작업이 영향을 받은 경우 무리한 작업진행 지양
		기타계구부	추락 (국립안전연구원)	1	무근콘크리트 타설을 위해 도구(갈고리)를 사용하여 콘크리트 타설용 주름관들 이동시키는 작업 중 갈고리가 주름관에서 빠지는 순간 몸의 중심을 잃고 위로 날아지면서 떨어짐	☐	☐ 상 중 하	▶ 추락 및 낙하 방지 조치 철저 ▶ 작업장 사전정리 등 관리 감독 철저 ▶ 안전모 등 개인보호구 착용에 대한 관리 철저

<그림 3-18> 문서 내 표 이미지 추출 결과

3) 정보 추출(C-3)

정보 추출(C-3)은 (C-2)를 통해 추출된 이미지 데이터를 처리하는 과정을 수행한다. 본 연구에서 공중 및 작업과 연관된 위험요인과 연관된 데이터를 활용해야 하므로, 표 내에서 [작업명], [단위작업명], [재해상세]에 해당하는 데이터를 추출한다. 정보 추출(C-3)과정에서 사용되는 모델은 GPT-4o 모델이다. 해당 모델은 멀티모달 데이터의 분석과 처리가 가능하다. GPT-4o 모델은 표 이미지 데이터를 입력데이터로 받아 표 내에서 [작업명], [단위작업명], [재해상세]에 해당하는 정보를 추출한다. 추출된 결과물은 <그림 3-19>과 같다. <그림 3-19> 표 이미지에 대한 정보 추출 결과를 보면 <그림 3-18> 표 내의 [재해 상세] 항목에 해당하는 정보들이 모두 추출된 것을 확인해 볼 수 있다.

```

\1. page_10_표_1.png_processed.txt
- page_10_표_1.png
- 공통 : 콘크리트 공사
- 작업 : 콘크리트 타설 및 다짐
- 사용도구 : 콘크리트 펌프카
- 유형 : 전도
- 내용 : 콘크리트 타설 작업 중 펌프카 아웃렛이 허부 지면에 삽입되어 펌프카 기울어지며 펌프카 몸체가 근로자 가격
- 위험요인 : 펌프카 지면 삽입으로 인한 기울어짐과 몸대 가격 위험

- 공통 : 콘크리트 공사
- 작업 : 콘크리트 타설 및 다짐
- 사용도구 : 콘크리트 펌프카
- 유형 : 파굴
- 내용 : 콘크리트 타설 작업 준비 중 콘크리트 펌프카의 안전관이 막혀 압송관 교체작업을 위해 클램프 볼트를 해지하는 순간 얹어있던 콘크리트가 분출하여 근로자 가격
- 위험요인 : 압송관 막힘으로 인한 분출과 근로자 가격 위험

- 공통 : 콘크리트 공사
- 작업 : 콘크리트 타설 및 다짐
- 사용도구 : -
- 유형 : 추락
- 내용 : 콘크리트 타설 장소로 이동하던 중 이동통로가 확보되지 않은 상태에서 슬래브에 기대어 세운 목재각재를 밟고 올라가던 중 목재각재가 부러지며 근로자 목부를 갈라
- 위험요인 : 이동 중로 불안정으로 인한 추락 및 목부 갈라 위험

- 공통 : 콘크리트 공사
- 작업 : 콘크리트 타설 및 다짐
- 사용도구 : -
- 유형 : 추락
- 내용 : 유관콘크리트 타설을 위해 도구(갈고리)를 사용하여 콘크리트 타설용 주동관을 이동시키는 작업 중 갈고리가 주동관에 빠지는 순간 몸의 중심을 잃고 뒤로 넘어지면서 떨어짐
- 위험요인 : 작업 중 중심 잃고 추락 위험

```

<그림 3-19> 표 이미지의 정보추출 결과

3) Chunking(C-4)

Chunking(C-4) 모듈은 추출된 정보들을 표 단위로 분할하는 작업을 수행한다. 건설공사 위험성평가 관련 문서의 경우 작업단위로 하나의 표에 관련 내용을 작성하는 경우가 많기에 이와 같이 표 단위로 분할을 진행하였다. 이후 Chunked된 Text는 인덱싱(Indexing) 과정을 거쳐 벡터 데이터베이스에 저장된다. 해당 모듈을 통해 완료된 결과물은 <그림 3-20>과 같다.

id	embedding_value
1	1. page_10_표_1.png_processed.txt
2	2. page_10_표_1.png
3	3. 공통 : 콘크리트 공사
4	4. 작업 : 콘크리트 타설 및 다짐
5	5. 사용도구 : 콘크리트 펌프카
6	6. 유형 : 전도
7	7. 내용 : 콘크리트 타설 작업 중 펌프카 아웃렛이 허부 지면에 삽입되어 펌프카 기울어지며 펌프카 몸체가 근로자 가격
8	8. 위험요인 : 펌프카 지면 삽입으로 인한 기울어짐과 몸대 가격 위험
9	9. 공통 : 콘크리트 공사
10	10. 작업 : 콘크리트 타설 및 다짐
11	11. 사용도구 : 콘크리트 펌프카
12	12. 유형 : 파굴
13	13. 내용 : 콘크리트 타설 작업 준비 중 콘크리트 펌프카의 안전관이 막혀 압송관 교체작업을 위해 클램프 볼트를 해지하는 순간 얹어있던 콘크리트가 분출하여 근로자 가격
14	14. 위험요인 : 압송관 막힘으로 인한 분출과 근로자 가격 위험
15	15. 공통 : 콘크리트 공사
16	16. 작업 : 콘크리트 타설 및 다짐
17	17. 사용도구 : -
18	18. 유형 : 추락
19	19. 내용 : 콘크리트 타설 장소로 이동하던 중 이동통로가 확보되지 않은 상태에서 슬래브에 기대어 세운 목재각재를 밟고 올라가던 중 목재각재가 부러지며 근로자 목부를 갈라
20	20. 위험요인 : 이동 중로 불안정으로 인한 추락 및 목부 갈라 위험
21	21. 공통 : 콘크리트 공사
22	22. 작업 : 콘크리트 타설 및 다짐
23	23. 사용도구 : -
24	24. 유형 : 추락
25	25. 내용 : 유관콘크리트 타설을 위해 도구(갈고리)를 사용하여 콘크리트 타설용 주동관을 이동시키는 작업 중 갈고리가 주동관에 빠지는 순간 몸의 중심을 잃고 뒤로 넘어지면서 떨어짐
26	26. 위험요인 : 작업 중 중심 잃고 추락 위험
27	27. 공통 : 콘크리트 공사
28	28. 작업 : 콘크리트 타설 및 다짐

<그림 3-20> 표 단위별 Chunking 결과

3.4.2 텍스트 처리 모듈(ii)

MM-RAG(C)의 텍스트 처리 모듈은 Extracting (C-5)와 Chunking (C-6)로 구성된다. 해당 모듈의 (C-5)와 (C-6) 세부 모듈의 처리 방식은 RAG(B)의 텍스트 처리 방식과 다르게 구성하였다. RAG(B)의 텍스트 처리 방식은 적절한 Chunking 단위를 연구자가 문서의 구조를 파악하고 임의로 적절한 수치를 선택해야 한다. 이는 문서 내의 의미론적인 사항을 고려하지 못하고 문서를 분할하게 되어 정보의 손실 가능성이 크다는 한계가 존재한다. 따라서 텍스트 처리 모듈(ii)에서는 문서의 구조를 바탕으로 Rule을 기준으로 분할하는 정규식 기반의 방법을 적용하였다. 그 이후의 과정은 RAG(B)와 동일하게 처리 및 작동된다.

1) Extracting (C-5)

Extracting (C-5) 모듈에서는 PDF 문서 내에서 Text 데이터를 추출한다. 추출하는 방법으로는 정규식 기반의 Text 추출 기술을 활용하였다. 여기서 정규식이란 특정 규칙을 적용하여 데이터를 추출하는데 활용되는 식을 의미한다. RAG(B) 모듈에서는 전체 문서의 Text를 한 번에 모두 추출한 후 Chunking을 진행하였다. 반면, Extracting (C-5) 모듈에서는 [콘크리트공사의 안전보건 작업지침.pdf] 내에서 <그림 3-21>과 같이 섹션 별로 데이터를 추출할 수 있도록 “^\\d+\\.\\s.*” 정규식을 활용하였다. 여기서 해당 정규식은 (숫자)+(.)+(공백)으로 시작하는 문자열을 의미하며, 문서에 따라 변경할 수 있다. 이와 같은 처리를 통해 “거푸집공사”, “콘크리트공사”, “철근공사”와 같이 공종을 기준으로 문서 내에서 정보를 누락 없이 추출할 수 있다.

2) Chunking (C-6)

Chunking (C-6) 모듈의 Chunking은 별도의 설정 없이 Extracting (C-5)모듈에서 추출한 공종 섹션에 따라 Chunking 과정을 수행하였다. 이후, 인덱싱(Indexing) 과정을 거쳐 <그림 3-22>과 같이 벡터 데이터 베이스에 저장된다.

4. 거꾸집 및 거꾸집동바리 공사

41 일반

- 1 -

KOSHA Guide C-43-2003

거꾸집 및 거꾸집동바리는 소정의 강도와 강성을 가지는 동시에 완성된 구조물의 위치, 형상, 치수가 정확하게 확보되어 안전한 콘크리트 구조물이 되도록 설계도에 의해 시공하여야 한다.

42 재료

(1) 거꾸집은 다음사항을 고려하여 선정하여야 한다.

(가) 목적 거꾸집은 흙집 및 용이가 많거나 할면의 질과부분이 떨어져 구조적으로 약한 것을 사용해서는 아니 된다.

(나) 목적 거꾸집의 떠받치는 부리되거나 군열이 있는 것을 사용해서는 아니 된다.

(8) 해체된 거꾸집이나 각종 등에 막혀있는 못 또는 날카로운แหล은물은 즉시 제거하여야 한다.

(9) 해체된 거꾸집이나 각종은 재사용 가능한 것과 보수하여야 할 것을 선별, 분리하여 적지하고 정리정돈을 하여야 한다.

(10) 강줄, 록두 등 악원후 시에는 작업을 금지하여야 한다.

5. 철근공사

51 운반

(1) 원칙으로 철근을 운반할 때에는 다음사항을 준수하여야 한다.

(가) 1인당 무게는 25kg이하로 제한하여 무리한 운반을 피하여야 한다.

(나) 2인 이상일 1조가 되어 어깨케기로 운반하여 안전을 도모하여야 한다.

(다) 긴 철근을 부딪히 한 사람이 운반할 때에는 한쪽을 어깨에 끼고 한쪽 손을 앞면에서 운반하여야 한다.

(라) 운반할 때에는 양끝을 묶어 운반하여야 한다.

(마) 내려놓을 때는 천천히 내려놓고 던지지 않아야 한다.

(2) 철근조립시 철근 이동위치에 대하여 충분한 검토하고 철근의 도괴방지를 위하여 강관과피로, 와이어로프, 각종 등으로 일정 간격마다 버팀계를 설치하여야 한다.

(3) 캐체릴린 조립작업은 도괴방지를 위해 2인 1조로 실시하여야 한다.

(4) 구조물의 형상 및 높이에 따라 말비계, 이동식비계 등 적절한 구조의 작업발판을 설치하여야 한다.

6. 콘크리트 타설공사

61 타설

(1) 콘크리트 타설은 계획에 의하여 순서대로 실시하여야 한다.




(2) 콘크리트를 타설하는 도중에는 거꾸집 및 거꾸집동바리의 이상 유무를 확인하여야 하고 담당자를 배치하여 이상이 발생된 때에는 신속히 안전조치를 하여야 한다.

(3) 타설속도는 국토교통부 제정 "콘크리트공사 표준시방서"에 따른다.

(4) 손수레를 이용하여 콘크리트를 운반할 때에는 다음사항을 준수하여야 한다.

(가) 손수레를 타설하는 위치까지 천천히 운반하여 거꾸집에 충격을 주지 아니 하도록 하여야 하며 적량의 간격을 유지하여야 한다.

<그림 3-21> PDF 문서 내부




<그림 3-22> 벡터 데이터베이스 내부

제 4장 GPT 성능평가

4장에서는 3장에서 구성한 프로세스와 시스템을 기반으로 GPT 모델의 성능평가를 진행한다. 성능평가는 3.1.1절에서 구성한 모범답안(벤치마크 데이터셋)을 기준으로 ‘RAG’, ‘Fine-tuning’, ‘RAG와 Fine-tuning의 통합 구성’, ‘MM-RAG와 Fine-tuning의 통합 구성’ 방법별 GPT 모델의 답변을 정량·정성적으로 평가한다.

1) 구성 방법에 따른 실험 시나리오 설계

본 연구에서는 실험을 위해 구성 방법에 따른 실험 시나리오를 <그림 4-1>과 같이 설계하였다. 구체적인 실험 시나리오는 시스템 구성 방법에 따라 ‘범용 GPT’, ‘RAG-GPT’, ‘Fine-tuned GPT’, ‘Fine-tuned GPT + RAG’, ‘Fine-tuned GPT + MM-RAG’로 구분하여 설계하였다. 이와 같은 실험 시나리오를 구성을 통해 Fine-tuning의 적용 효과와 RAG의 적용 효과 그리고 RAG와 Fine-tuning의 통합 구성에 따른 GPT 모델의 적용 효과를 평가하고 분석할 수 있다.



<그림 4-1> 구성 방법에 따른 실험 시나리오

2) Prompt 구성

평가에 활용하기 위한 Prompt는 <표 4-1>의 내용과 같이 ①System Prompt, ② Instruction Prompt, ③ User Prompt 이렇게 총 3가지로 구성된다.

① System Prompt

System Prompt는 GPT 모델이 어떻게 행동해야 하는지 역할(Role)을 정의하는 부분이다. 본 연구에서는 GPT 모델에게 안전관리자라는 역할을 지정해주고, 사용자의 입력 정보를 바탕으로 관련된 위험요인을 식별하라는 구체적인 역할을 지정해주었다.

② Instruction Prompt

Instruction Prompt는 ① System Prompt를 통해 역할을 부여받은 GPT 모델에게 구체적으로 역할을 어떻게 수행할지 지시하는 부분이다. 본 연구에서는 "[공종], [작업]과 관련된 위험요인을 목록화합니다. 만약, [사용도구]가 있다면, [사용도구]와 관련된 위험요인을 목록화합니다."라는 Instruction Prompt를 활용하였다.

③ User Prompt

User Prompt는 사용자가 직접 입력하는 질문과 요청사항을 의미한다. 사용자는 User Prompt 부분에 공종, 작업, 사용 도구에 대한 정보를 입력하면 관련된 위험요인을 답변으로 출력할 수 있다.

<표 4-1> System Instruction 구성

```
# System_Prompt = "당신은 건설현장의 안전을 책임지는 안전관리자입니다. 사용자가 입력한 정보를 기반으로 관련된 위험요인들을 식별해야 합니다."
# Instruction_Prompt = "[공종], [작업]과 관련된 위험요인을 목록화합니다. 만약, [사용도구]가 있다면, [사용도구]와 관련된 위험요인을 목록화합니다."
# User Prompt = ""
[공종] :
[작업] :
[사용도구] : ""
```

3) 성능 평가방법

구성 방법별 GPT 모델의 성능평가는 정량적 평가와 정성적 평가로 구분하여 진행하였다.

- 정량적 평가 : 정량적 평가에서는 ‘1) 구성 방법에 따른 시나리오 설계’에서 설계한 구성 방법별 모델의 답변과 모범답안을 비교하는 방식으로 정확성(Accuracy)을 평가하였다. 정확성(Accuracy)은 3.1.2 범용 GPT의 한계를 분석한 결과에 근거하여 내용적 정확성(Contextual Accuracy)과 용어의 정확성(Keyword Accuracy)으로 구분하여 성능을 평가하였다. 내용적 정확성 평가에는 Bert Score, ROUGE-L 지표를 활용하며, 용어의 정확성 평가에는 BLEU, ROUGE-1 지표를 활용하였다. 평가에 활용되는 모범답안(벤치마크 데이터셋)은 3.1.1에서 언급한 과정 및 내용과 동일하게 a. 위험성평가 예시(KRAS)와 b.핵심위험요인(안전보건공단) 자료를 통해 연구자가 직접 구성하였다. 그리고 구성된 모범답안과 각각의 5가지 구성 방법별 모델에 대하여 <표 4-2>에 명시된 평가지표를 활용하여 성능을 평가한다.
- 정성적 평가 : 모델에 대한 정성적 평가는 설문평가를 활용하여 진행하였다. 5가지 구성 방법별 모델의 답변내용을 확인하고 평가자들은 해당 내용이 모범답안보다 우수한지, 해당 모델 활용을 통해 업무의 효율성 향상 가능 여부에 대한 평가를 진행한다.

<표 4-2> 성능 기준별 활용지표


	정량적 평가(4.1)		정성적 평가(4.2)
평가기준	정확성(Accuracy)		효율성 및 효과성
세부기준	내용(Content)	용어(Keyword)	-
평가지표	Bert Score / ROUGE-L	BLEU / ROUGE-1	설문평가

4.1 정량적 평가

정량적 평가에서는 총 4가지의 지표를 활용하여 구성 방법별 GPT 모델의 성능을 평가한다. 또한, 각 지표의 점수 결과와 답변내용에 대한 분석을 진행하였다. 답변내용에 대한 분석은 1.2절 연구의 범위에서 언급한 12가지 세부작업 중 콘크리트 타설 및 다짐 작업과 콘크리트 운반 작업의 답변을 예시로 활용하여 진행하였다.

4.1.1 BLEU Score

BLEU Score는 생성된 텍스트와 모범답안 간의 단어 일치도를 평가하는 지표로, 각 모델이 응답한 12가지 세부작업에 대한 위험요인과 모범답안의 BLEU Score 평균 점수는 <그림 4-2> 및 <표 4-3>과 같다.



<그림 4-2> BLEU Score 결과

<표 4-3> BLEU Score 결과


모델	범용 GPT	Only B	Only A	A+B	A+C
BLEU Score	16%	15%	20%	23%	25%

4.1.2 ROUGE Score

ROUGE Score는 생성된 텍스트와 모범답안 간의 단어 유사도 및 문장 구조적 유사도를 평가하는 지표로, 본 연구에서는 ROUGE-1 Score와 ROUGE-L Score 평가지표를 활용하였다.

1) ROUGE-1

ROUGE-1은 단어 수준에서 모범답안과 생성된 텍스트 간의 유사도를 평가하며, BLEU Score와 유사하게 단어 일치율에 중점을 둔다. 각 모델이 응답한 12가지 세부작업에 대한 위험요인과 모범답안의 ROUGE-1 Score의 평균 점수는 <그림 4-3> 및 <표 4-4>와 같다.




<그림 4-3> ROUGE-1 Score 결과

<표 4-4> ROUGE-1 Score 결과

모델	범용 GPT	Only B	Only A	A+B	A+C
ROUGE-1 Score	34%	33%	39%	39%	54%

2) ROUGE-L

ROUGE-L은 생성된 텍스트와 모범답안 간의 문장 구조적 유사성을 평가하며, BLEU나 ROUGE-1에 비해 문맥적 연속성과 구조적 유사성을 평가하기에 적합하다. 각 모델이 응답한 12가지 세부작업에 대한 위험요인과 모범답안의 ROUGE-L의 평균 점수는 <그림 4-4>와 <표 4-5>과 같다.



<그림 4-4> ROUGE-L Score 결과


<표 4-5> ROUGE-L Score 결과

모델	범용 GPT	Only B	Only A	A+B	A+C
BLEU Score	23%	22%	24%	27%	37%

Fine-Tuned GPT + MM-RAG 모델(A+C)은 ROUGE-L Score에서 37%로, 모든 실험 모델 중 가장 높은 성능을 기록하였다. 이는 Fine-Tuned GPT + MM-RAG 모델(A+C)의 답변이 모범답안의 문장 구조와 가장 유사함을 의미한다. 또한, Fine-Tuned GPT / Fine-Tuned GPT + RAG / Fine-Tuned GPT + MM-RAG 순으로 ROUGE-L Score가 높아지는 것으로 확인할 수 있다. 이를 통해, RAG의 적용이 ROUGE-L Score에 영향을 미치며, 답변의 구조와 문맥적 연속성에도 큰 영향을 미친다고 해석할 수 있다.

4.1.3 BERT Score

BERT Score는 생성된 텍스트와 모범답안 간의 의미론적 유사성을 평가하여 BLEU와 ROUGE와 달리 내용적 정확도를 평가하기에 적합하다. 각 모델이 응답한 12가지 세부작업에 대한 위험요인과 모범답안의 BERT Score의 평균 점수는 <그림 4-5>와 <표 4-6>과 같다.



<그림 4-5> BERT Score 결과

<표 4-6> BERT Score 결과

모델	범용 GPT	Only B	Only A	A+B	A+C
BLEU Score	85.71%	85.85%	86.12%	86.32%	86.81%

Fine-Tuned GPT + MM-RAG 모델(A+C)의 BERT Score는 86.81%로, 실험된 모든 모델 중 가장 높은 수치를 기록하였다. 이는 Fine-Tuned GPT + MM-RAG 모델이 모범답안의 의미적 연관성과 문맥적 유사성을 가장 충실히 반영했음을 의미한다. Fine-tuning 방법과 비정형데이터 (표 데이터) 기반의 MM-RAG 활용의 시너지 효과로, 생성된 텍스트가 타 모델과 비교하여 해당 공중, 작업, 도구에 해당하는 위험요인 생성능력이 일정 정도 이상 우수하다고 해석할 수 있다.

범용 GPT 모델의 BLEU Score는 16%, ROUGE-1 34%, ROUGE-L 23%, BERT Score 85.7%로 용어의 정확성과 내용의 정확성 측면에서 타 모델과 비교하여 낮은 점수를 기록하였다. <표 4-8>은 범용 GPT 모델의 콘크리트 운반 작업에 대한 위험요인 답변내용이다. <표 4-7>의 모범답안과 비교했을 때 답변한 위험요인 내용의 구체성이 떨어지며 건설현장의 전문 용어 활용도가 낮아 비교적 낮은 점수를 기록한 것으로 해석할 수 있다.

<표 4-7> 콘크리트 타설 및 다짐/운반 작업(모범답안)

규정 및 지침에 근거한 위험요인	비계와 벽체 사이로 추락 위험. 시스템 비계 가설 계단에서 미끄러짐 위험. 타워크레인을 이용하여 호퍼로 타설시 호퍼가 인양로프에서 탈락되어 근로자 부딪힘 위험. 콘크리트 피니셔 회전부에 안전덮개 미설치로 인한 근로자 신체 일부가 끼임 위험. 충전부 노출된 진동기에 의한 감전 위험. 개인보호구 미착용하고 작업 중 부딪히거나 찢림 위험. 콘크리트 펌프카 유압장치 점검 중 붐이 낙하하여 근로자 맞음 위험. 펌프카 붐 설치 중 주변 고압선에 접촉으로 인한 감전 위험. 작업반경 내 접근에 의한 부딪힘 위험. 펌프카 장비 사용방법 미숙지에 의한 오작동 사고 위험. 펌프카 아웃트리거 미설치로 인한 전도 위험.
사고사례에 기반한 위험요인	레미콘 운반 작업트럭 후진 시 유도자 미배치로 인한 근로자 부딪힘 위험. 레미콘 운반 작업트럭 상부에서 작업 중 안전장비 미착용으로 인한 추락 위험. 제동장치 이상으로 미끄러지며 근로자 깔림 위험. 경사로에서 오르지 못하여 주변 근로자 깔림 위험.

<표 4-8> 콘크리트 타설 및 다짐/운반 작업(범용 GPT)

비계의 불안정한 설치로 인한 추락 위험 콘크리트 타설 중 장비와 작업자 간의 충돌로 인한 근로자 부상 위험 콘크리트 타설 및 다짐 작업 중 호퍼 사용으로 인한 추락 위험 콘크리트 타설 및 다짐 작업 중 피니셔 사용으로 인한 넘어짐 위험 진동기 사용으로 인한 근로자 부상 위험 콘크리트 펌프카의 이동 경로에서의 넘어짐 위험 콘크리트 펌프카 붐의 불안정한 위치로 인한 추락 위험 콘크리트 운반 시 차량과의 충돌로 인한 근로자 부상 위험 펌프카 작동 중 압력 누출로 인한 화학적 위험 작업 중 장비 소음으로 인한 청력 손상 위험 장비 전원 케이블의 손상으로 인한 감전 위험 레미콘 운반 작업트럭으로 인한 충돌 위험 콘크리트 운반 중 불균형으로 인한 넘어짐 위험
--

RAG-GPT(Only B) 모델의 BLEU Score는 15%, ROUGE-1 33%, ROUGE-L 22%, BERT Score 85.85%로 범용 GPT 모델과 동등한 결과를 기록하였다. 이는 RAG-GPT(Only B) 모델이 벡터 데이터베이스로부터 정보를 검색하여 답변을 생성하였으나, 검색된 정보를 충분히 활용하지 못한 것으로 해석할 수 있다.

<표 4-9> 콘크리트 타설 및 다짐/운반 작업(RAG-GPT)

비계로 인한 추락 위험
 콘크리트 타설 중 구조물 붕괴 위험
 호퍼 사용으로 인한 콘크리트의 낙하 위험
 콘크리트 타설 및 다짐 작업 중 피니셔 사용으로 인한 근로자 부상 위험
 진동기 사용 시 진동으로 인해 근로자의 손목, 팔, 어깨 등에 무리가 갈 수 있으며, 장시간 사용 시 근골격계 질환이 발생
 콘크리트 펌프카의 붐대 조작 중 전선 접촉으로 인한 감전 위험
 콘크리트 펌프카의 불안정으로 인한 전도 위험
 콘크리트 타설 중 호스 요동으로 인한 근로자 부상 위험
 자재 운반 중 낙하로 인한 부상 위험
 지게차 사용 중 충돌 및 낙하물로 인한 부상 위험
 펌프카 작업반경 내 근로자 출입으로 인한 안전사고 위험
 레미콘 운반 작업트럭의 불안정한 적재로 인한 추락 위험
 철근콘크리트 공사 중 거푸집 및 동바리 조립 불량으로 인한 구조물 붕괴 위험
 콘크리트 믹서 트럭 운반 경로의 바닥면에 돌출물이나 미끄러운 표면으로 인한 넘어짐 위험
 작업자들이 높은 곳에서 작업할 경우 추락 위험

반면, Finetuned-GPT(Only A)는 BLEU Score는 20%, ROUGE-1 39%, ROUGE-L 24%, BERT Score 86.12%로 범용 GPT와 RAG-GPT에 비해 용어의 정확성 측면에서 크게 향상된 것을 확인할 수 있다. <표 4-7>은 Finetuned-GPT 모델의 콘크리트 운반 작업에 대한 위험 요인 답변내용이다. 답변내용을 살펴보면 사용도구 및 장비를 기준으로 구체적인 용어를 사용하여 상황을 표현하였으며, 이로 인한 발생 가능한 재해 유형까지 표현하였다. 이와 같은 답변으로 인해 높은 수치의 BLEU Score를 기록한 것으로 해석할 수 있다.

<표 4-10> 콘크리트 타설 및 다짐/운반 작업(Finetuned-GPT)

비계 상부에서 작업중 근로자 안전난간 미설치로 인한 추락 위험
 비계에 고정하여 설치한 작업발판이 탈락되면서 추락 위험
 호퍼 사용 중 부적절한 고정으로 인한 호퍼 전도 위험
 피니셔 회전부에 의한 근로자 부상 위험
 진동기 사용 중 전원 케이블 피복 손상으로 인한 감전 위험
 콘크리트 펌프카 붐대 파단으로 인한 근로자 부상 위험
 콘크리트 펌프카 전도에 의한 근로자 깔림 위험
 콘크리트 펌프카 작업 중 근로자 감전 위험
 콘크리트 펌프카 붐대 접힘에 의해 근로자 깔림 위험
 펌프카 붐대와 구조물의 접촉으로 인한 구조물 붕괴 위험
 콘크리트 펌프카 작업 중 불안정한 통로로 인한 근로자 추락 위험
 운반 작업트럭 후진 시 주변 근로자 부딪힘 위험
 콘크리트 반입 시 레미콘 트럭 호퍼에 신체 부딪힘 위험
 콘크리트 믹서 트럭 후진 중 후방에 근로자 깔림 위험
 콘크리트 믹서 트럭이 경사지에 주차 중 밀림으로 인한 근로자 깔림 위험

Finetuned-GPT+ RAG 모델(A+B)의 BLEU Score는 23%, ROUGE-1 39%, ROUGE-L 27%, BERT Score 86.32%로 Finetuned-GPT(Only A)보다 높은 수치를 기록하였다. <표 4-8>과 같이 “펌프카의 아웃트리거 미설치로 인한 전도 위험”, “펌프카 붐대가 전선과 접촉으로 인한 감전 위험”, “펌프카 붐대가 전선과 접촉으로 인한 감전 위험” 등과 같이 모범답안과 유사한 답변이 비교적 많은 것을 확인할 수 있다. 유사한 답변이 많기에 용어의 일치도와 내용의 유사도가 증가한 것으로 해석할 수 있다.

<표 4-11> 콘크리트 타설 및 다짐/운반 작업(Finetuned-GPT+RAG)

비계의 불안정한 설치로 인한 추락 위험
 작업 중 철근 또는 콘크리트에 걸려 넘어짐 위험
 호퍼 사용 중 이동식 크레인 와이어로프의 파단에 의한 호퍼의 추락 위험
 피니셔 사용 중 회전 날에 의한 부상 위험
 진동기 사용 중 전기 누전으로 인한 감전 위험
 펌프카 붐대가 전선과 접촉으로 인한 감전 위험
 콘크리트 호스 요동으로 인한 근로자 부상 위험
 펌프카의 아웃트리거 미설치로 인한 전도 위험
 크레인 사용 중 혹 해지장치 미설치로 인한 인양물 탈락 위험
 콘크리트 펌프카 주변에서 근로자 안전모 미착용으로 인한 추락물 부딪힘 위험
 펌프카 붐대 조작 중 근로자 접근으로 인한 부딪힘 위험
 레미콘 운반 작업트럭의 후진 중 근로자 부딪힘 위험
 레미콘 운반 작업트럭의 적재함에서 콘크리트가 낙하하여 근로자 부딪힘 위험
믹서 트럭 후진 시 작업자 부딪힘 위험
믹서 트럭의 경사로 주차 중 밀림으로 인한 전도 위험

Finetuned-GPT와 멀티모달 RAG(MM-RAG)의 통합 방법 [(A+C)]은 BLEU Score는 25%, ROUGE-1 54%, ROUGE-L 37%, BERT Score 86.81%을 기록하며, 평가대상 모델 중 모든 지표에서 가장 높은 성능을 보였다. 이는 해당 모델이 텍스트 데이터뿐만 아니라 표 이미지의 비정형데이터 까지 활용하여 사고사례에 기반한 세부적인 위험요인을 반영했기 때문으로 해석할 수 있다. 답변내용을 보면 “레미콘 트럭 후진 중 근로자와 부딪힘 위험.”, “레미콘 트럭이 도로 경사면에서 주차 브레이크 미체결로 인한 차량 전도 위험.” 등 사고사례에 기반한 세부적인 위험요인이 답변으로 출력된 것을 확인할 수 있다. 또한, 규정 및 지침에 근거한 위험요인도 모범답안의 위험요인과 유사한 것을 육안으로 확인할 수 있다. 이로 인해 Finetuned-GPT+MM-RAG(A+C) 모델의 답변내용이 모범답안과 비교하여 가장 높은 용어 일치율과 내용적 유사성을 가지는 것을 확인할 수 있다.

<표 4-12> 콘크리트 타설 및 다짐/운반 작업(Finetuned-GPT+MM-RAG)

규정 및 지침에 근거한 위험요인	피니셔의 회전부에 의한 근로자 끼임 위험. 진동기 전선 피복 손상으로 인한 감전 위험. 비계와 건물 사이의 틈새로 인한 추락 위험. 비계 상부 난간대 미설치로 인한 추락 위험. 펌프카의 붐대가 탈락하면서 레미콘 트럭과 부딪힘으로 인한 근로자 부딪힘 위험. 펌프카 붐대의 작동반경 내 근로자 출입으로 인한 근로자 부딪힘 위험. 펌프카 붐대가 전선에 접촉되어 감전 위험. 펌프카 운전원 미숙으로 인한 펌프카 붐대 탈락 위험. 펌프카 아웃리거 지반 침하로 인한 장비 전도 위험. 펌프카 붐대에 설치된 유도 호스가 탈락하면서 근로자 부딪힘 위험. 펌프카의 유압 호스 파손으로 인한 콘크리트 분출 위험 작업중 타설호스의 콘크리트가 근로자에게 부딪힘 위험 안전모, 안전화 등 개인보호구 미착용으로 인한 부딪힘 위험. 슬래브 타설 중 슬래브가 무너짐으로 인한 근로자 깔림 위험. 안전난간 미설치로 인한 근로자 추락 위험. 거푸집이 전도되면서 외부로 근로자 추락 위험. 콘크리트 타설중 근로자가 미끄러지면서 추락 위험. 콘크리트 다짐 작업 중 거푸집 붕괴로 인한 근로자 깔림 위험.
사고사례에 기반한 위험요인	레미콘 트럭 후진 중 근로자와 부딪힘 위험. 레미콘 트럭이 도로 경사면에서 주차 브레이크 미체결로 인한 차량 전도 위험. 레미콘 트럭의 회전드럼 구동부 덮개 미설치로 인한 회전체에 끼임 위험. 콘크리트 믹서트럭 운전 중 전도 방지를 위한 차량 주차브레이크 미체결로 인한 전도 위험. 콘크리트 믹서트럭 후방에 유도자 미배치로 인한 근로자와 충돌 위험.

4.2 정성적 평가

정성적 평가에서는 설문평가를 활용하여 GPT 모델의 을 평가한다.

4.2.1 설문평가

방법론에 따른 모델별 효율성과 효과성을 평가하기 위하여 현장 시공 관리자를 대상으로 설문 평가를 진행하였다.

1) 설문대상

설문은 시공경력 10년 이상의 건설 현장관리자 5명을 대상으로 진행 하였으며 과장급 이상의 인원을 대상으로 설문을 진행하였다.

<표 4-13> 설문 대상

직급	경력
과장	시공경력 10년
상무	시공경력 20년
팀장	시공경력 16년
차장	시공경력 12년
차장	시공경력 15년

2) 평가방법

평가방법은 <그림 4-1>과 같이 분류한 평가대상별로 분류된 답변내용을 설문대상자에게 제공한다. 설문대상자는 답변내용을 확인한 후 해당 답변내용을 바탕으로 설문항목에 응답하는 방식으로 진행하였으며, 설문은 5점 리커트 척도기반의 평가방법을 활용하였다.

<표 4-14> 설문 평가방법

답변 내용	공종	콘크리트 공사 / 철근 공사 / 거푸집 공사				
	세부 작업	- 콘크리트 공사 : 콘크리트 타설 및 다짐 작업,콘크리트 운반 작업 - 철근 공사 : 철근 반입 작업, 철근 가공 및 운반 작업, 철근 조립 작업 - 거푸집 공사 : 자재 운반 작업, 자재 가공 작업, 자재 인양 작업, 동바리 해체 작업, 동바리 인양 작업, 동바리 조립 작업				
설문 항목	평가척도					
항목 [1]~[6]	① 매우 아니다	② 아니다	③ 보통이다	④ 그렇다	⑤ 매우 그렇다	

3) 설문평가 문항

설문 문항은 GPT의 답변내용을 기반으로 효율성과 효과성을 평가하는 것을 목적으로 설문평가 문항을 구성하였다.


<표 4-15> 설문평가 항목

효율성	[1]	안전관리 전문인력의 서류작성 업무 시간을 단축할 수 있다고 생각하십니까?
	[2]	안전관리 전문인력의 의사결정을 효율적으로 지원할 수 있다고 생각하십니까?
	[3]	안전관리 전문인력이 수행하는 반복적이거나 단순한 수작업을 대체할 수 있다고 생각하십니까?
효과성	[4]	답변이 3년 이상의 안전관리 전문인력과 동일한 수준이라고 생각하십니까?
	[5]	답변이 건설현장의 작업과 관련하여 위험요인을 누락 없이 생성하였다고 생각하십니까?
	[6]	LLM을 활용하여 안전관리 전문인력을 대체하거나 보완할 수 있다고 생각하십니까?

4) 설문 결과

평가결과, 5가지 시나리오의 LLM 모두 5점 만점에 4점 이상을 기록하여, 위험요인 식별 과정에서 LLM이 업무의 효율성과 효과성을 크게 향상시킬 수 있음을 확인하였다.

효과성 항목에서는 Fine-tuned GPT + MM-RAG 모델이 4.2점으로 가장 높은 수치를 기록하였다. 반면, 효율성 항목에서는 Fine-tuned GPT 모델이 가장 높은 점수를 기록하였다.



<그림4-6> 효율성 설문 결과



<그림4-7> 효과성 설문 결과

4.3 결과분석

4장에서는 Fine-tuning과 RAG를 바탕으로 5가지 시나리오에 대한 설계를 진행한 후, 평가지표 기반의 실험적 성능평가를 진행하였다.

Finetuned GPT + MM-RAG 통합 방법[(A)+(C)]이 정량적 평가인 BLEU, ROUGE-1, ROUGE-L, BERT Score에서 모두 높은 성능을 보였으며, 정성적 평가의 효과성 설문항목에서도 4.3점으로 가장 높은 수치를 기록하였다.

Fine-Tuned GPT[Only A] 모델은 범용 GPT 대비 BLEU Score와 ROUGE Score에서 크게 향상된 결과를 기록하였으며, Fine-tuning(A) 방법을 통해 전문용어의 활용도가 크게 향상되었다고 해석할 수 있다.

반면, RAG-GPT[Only B]는 BLEU와 ROUGE 점수에서 범용 GPT와 동등 또는 이하의 점수를 기록하였다. 이는 RAG 단일 방법으로는 검색 정보 처리 능력의 한계 등으로 인해 성능향상이 제한적이라고 해석할 수 있다.

Fine-Tuned GPT+RAG 통합 방법[(A)+(B)]이 BLEU, ROUGE, BERT Score에서 [Only A]와 [Only B] 단일 방식보다 높은 점수를 기록하며, 두 방식의 통합이 성능향상에 효과적으로 기여했음을 보여준다. 또한, Fine-Tuned GPT[Only A] 모델대비 BLEU Score와 ROUGE-L Score, Bert Score에서 높은 정량적 평가결과를 보여주었으며, Fine-tuning과 RAG 프로세스의 통합이 성능향상에 효과적이라고 해석할 수 있다. 또한, 설문평가의 효율성 항목에서 4.3점으로 가장 높은 점수를 기록하였다.

Fine-Tuning과 MM-RAG를 통합 방법[(A)+(C)]은 모든 정량적 평가지표에서 가장 높은 성능을 기록하였다. 특히, ROUGE-L 37%와 BERT Score 86.81%로 의미적 유사성 평가에서 해당 모델이 모범답안의 문맥적 연관성과 의미적 일치성을 가장 잘 반영했음을 보여준다. 또한, BLEU Score 25%, ROUGE-1 Score 54%로 용어의 일치성 역시 모범답안의 용어와의 일치율이 가장 높은 것으로 나타났다. Fine-tuning의 학습효과에 표 이미지 기반의 비정형데이터를 통해 활용한 MM-RAG의 효과가 더해져 가장 높은 성능을 보인 것으로 해석할 수 있다.

제 5장 결론

5.1 연구의 결과

건설 안전 분야에서 위험요인 식별을 위한 LLM의 성능향상을 목적으로 Fine-tuning과 RAG 프로세스를 활용하여 5가지 실험 시나리오를 설계하고, 각 시나리오에 해당하는 모델의 성능에 대한 실험적 평가를 수행하였다. 본 연구에서는 건설현장의 위험요인 관련 정보는 위험성 평가표 형식의 비정형데이터(표, 이미지 등)로 존재하는 비중이 높다는 점을 고려하여 MM-RAG 방법을 포함한 실험을 진행하였다. 연구의 주요 결론은 다음과 같다.

Fine-tuning을 적용한 결과, 답변의 정확성이 향상되었으며 특히 전문 용어 활용도가 개선되었음을 확인하였다. 또한, 정성적 평가에서 모델의 위험요인 식별 결과가 현장 안전관리 업무의 효율성을 높이는 데 기여할 수 있음을 보여주었다.

RAG 방법의 적용 결과, Bert Score에서는 범용 LLM과 유사한 수치를 기록하였으나, BLEU와 ROUGE 점수에서는 범용 LLM과 비교하여 낮은 점수를 보여 정확한 용어 활용 측면에서 제한적임을 확인하였다.

Fine-tuning과 RAG를 통합한 방식은 개별적으로 적용했을 때보다 더 높은 성능향상 효과를 보였다. 두 가지 방법이 상호·보완적으로 작용하여 Fine-tuning을 통해 전문 지식 학습을 강화하고, RAG를 통해 외부 데이터베이스 정보를 효과적으로 검색 및 활용함으로써 성능이 향상된 것을 확인할 수 있다.

Fine-tuning과 MM-RAG(Multi-Modal RAG)의 통합 적용 방법은 BLEU, ROUGE, BERT Score의 정량적 평가에서 가장 높은 점수를 기

록하였으며, 나머지 4가지 시나리오와 비교했을 때 가장 우수한 성능을 기록하였다. 이는 Fine-tuning을 통해 전문성을 향상시키고, MM-RAG를 통해 비정형데이터를 효과적으로 활용한 결과로, 두 방법의 통합 구성이 성능을 크게 향상시킨 것으로 해석할 수 있다. 정성적 평가에서는 효과성과 효율성 측면에서 높은 점수를 얻었다. 특히, 효과성 항목에서 높은 점수를 기록하여 업무 지원 도구개발을 위한 LLM 구현에 효과적인 방법으로 활용될 수 있음을 확인하였다.



5.2 연구의 의의

본 연구를 통하여 LLM의 성능향상에 가장 효과적인 방법을 도출하였으며, 다음과 같은 학술 및 실무적 의의를 갖는다.

1) 학술적 의의

- 위험요인 식별을 위한 LLM 개발의 방향성

본 연구는 Fine-Tuning과 RAG, 그리고 MM-RAG(Multi-Modal RAG)와 같은 최신 기법을 적용하여 LLM의 전문성을 향상시키는 효과적인 방법을 도출하였다. 이를 통해 기존 범용 LLM이 가진 한계를 극복하고, 위험요인 식별에 적합한 LLM의 개발 방향성을 제시하였다는 점에서 학술적 의의가 있다.

- Multi Modal RAG(MM-RAG)의 활용 가능성

또한, 본 연구는 비정형데이터(표, 이미지 등)를 효과적으로 처리할 수 있는 MM-RAG 방법에 대한 성능평가도 진행하였다. 기존 건설 분야의 LLM 연구에서 확장된 접근법을 활용하였으며, 이를 바탕으로 LLM 연구의 새로운 가능성을 열었다는 점에서 학술적 의의가 있다.

2) 실무적 의의

본 연구에서는 설문평가를 통해 LLM의 활용이 건설현장 위험요인 식별에 실질적으로 활용하기 적합하다는 것을 확인하였다. 특히, Fine-tuning과 MM-RAG 통합 구성방식을 적용한 LLM은 전문인력을 가능한 수준임을 확인하였다.

이에 본 연구는 건설현장의 위험요인 식별 과정에서 전문인력을 대체하고 보조할 수 있는 LLM을 구현하였으며, 이를 바탕으로 한 도구개발의 기술적 기반을 마련하였다는 점에서 실무적 의의가 있다.

5.3 연구의 한계 및 향후 연구

본 연구는 위험요인 식별을 목적으로 하는 LLM의 성능향상을 위해 실험적 연구를 진행하였으며, 이를 기반으로 성능향상에 효과적인 방법을 도출하였다. 하지만, 연구범위, 적용 기술의 범위, 활용모델 등 다양한 측면에서 한계점이 존재하며, 추가적인 연구도 필요하다. 이에 대한 세부 내용은 다음과 같다.

- 연구범위의 한계

본 연구에서 철근콘크리트 공사와 관련된 콘크리트 공사, 철근 공사, 거푸집 공사로 범위를 한정하여 연구를 진행하였으며, 철근콘크리트 공사 이외의 공종 및 작업에 대해서는 다루지 않았다. 이로 인해 본 연구에서 도출된 방법을 LLM의 성능향상에 대한 일반적인 방법이라고 하기에 한계가 존재하며, 추후 연구의 범위를 확대한 추가 실험을 통해 일반화 가능성을 검토하는 연구가 필요하다.

- 적용 기술의 범위

LLM에 적용할 수 있는 기술에는 강화 학습(Reinforcement Learning), 지식 그래프(Knowledge Graph) 기반 RAG 등 다양한 방법이 존재한다. 본 연구에서는 Supervised Fine-tuning과 벡터 데이터베이스 기반 RAG 방법을 활용하여 실험적 연구를 진행하였지만, 향후 연구에서는 적용 기술의 범위를 확장한 추가연구가 필요할 것으로 판단된다.

또한, 텍스트뿐만 아니라 실시간 영상 및 이미지와 같은 데이터를 통합적으로 처리할 수 있는 거대 멀티모달 모델(LMM, Large Multimodal Model)로의 확장연구도 필요할 것으로 판단된다.

- 활용모델의 한계

본 연구에서는 GPT-4 모델 1가지 모델만 활용하여 실험을 진행하였으며 Bard, Llama, Palm 등 타 모델을 활용한 연구는 진행되지 않았다. 이에 따라 본 연구 결과를 다양한 모델에 일반화하는 데 한계가 존재한다. 또한, 본 연구에서 활용한 GPT-4 모델은 OpenAI의 유료 API를 기반으로 운영되기 때문에 구현 과정에서 상당한 비용적 부담이 발생하였다.

향후 연구에서는 타 LLM과의 성능 비교연구를 통해 연구 결과의 일반화 가능성을 강화할 필요가 있으며, 동시에 각 모델 활용 시 발생하는 비용 효율성에 대한 고려도 필요하다.

- 모범답안(벤치마크 데이터셋) 구성

본 연구에서는 실험에 활용 가능한 벤치마크 데이터셋의 부재로 인하여, 자체적으로 모범답안(벤치마크 데이터셋)을 구성하였다. 이러한 표준화된 벤치마크 데이터셋의 부재는 건설 LLM 연구에 객관성 확보와 일반화에 어려움을 발생시킨다. 이에 따라 향후 연구에서는 LLM과 더 나아가 LMM 연구를 위해 건설 안전 분야에 전문화된 벤치마크 데이터셋을 구축하기 위한 연구가 필요할 것으로 판단된다.

참 고 문 헌

- [1] 고용노동부, 안전보건공단, "새로운 위험성평가 안내서", p.2, 2023.
- [2] 김재희, 김준휘, & 김봉완. "형태소 분석, LLM 을 활용한 건설현장 사고 사례 데이터에서의 작업자 부상부위 파악 및 분석", 한국통신학회 학술대회논문집, pp.985-986, 2023.
- [3] 박종진., "검색 증강 LLM 을 이용한 치과 상담용 챗봇 개발", 한국인터넷방송통신학회 논문지, 24(2), pp. 87-92, 2024.
- [4] 안혜연, "교원 업무경감을 위한 생성형 AI 질의응답 시스템의 개발 및 평가", 한국교육공학회 논문집, 40(3), pp.719-751, 2024.
- [5] 이규은, "교량 유지관리 지식베이스와 거대언어모델을 활용한 전문 질의응답 시스템 개발", 서울대학교 건설환경공학부 대학원 박사학위 논문, 2024
- [6] 이원종, "BERT와 그래프 모델을 활용한 건설프로젝트 위험성평가 지식베이스 구축방안 ",광운대학교 석사학위 논문, 2024.
- [7] 전아여, "RAG 기반 중·소규모 건설현장 위험성평가 자동화", 광운대학교 석사학위 논문, 2024.
- [8] 정천수, "LLM 애플리케이션 아키텍처를 활용한 생성형 AI 서비스 구현 RAG모델과 LangChain",한국지능정보시스템학회 논문집, 29(4), pp.129-164, 2023.
- [9] 정천수, "도메인 특화 LLM Mistral 7B를 활용한 금융 업무분야 파인튜닝 및 활용 방법",지능정보연구,30(1) ,pp.93-120, 2024.
- [10] 조민건, 이동환, 박주영, & 박승희. "건설현장 정형·비정형데이터를 활용한 기계학습 기반의 건설재해 예측 모델 개발", 대한토목학회논문집, 42(1), pp. 127-134, 2022.
- [11] 최수영, 박희대, "건설업 안전관리자 수요 증가에 따른 안정적인 수급 확보 방안", 한국건설산업연구원, 2022.
- [12] 최지원, "RAG 기반 GPT 모델의 BIM 관련 지식 수준 평가에 대한 연구", 서울과학기술대학교 대학원 석사학위논문, 2024.
- [13] 한승현, 강민혁, 강필성, 황우현, "FT-LLM : 축구 산업의 데이터 분석 지원을

위한 Retrieval 증강 생성 기반의 언어 모델 프레임워크 개발”, 대한산업공학회 지,50(2), pp.97-108, 2024.

- [14] Chenrui Wang , Qingqing Long , Meng Xiao , Xunxin Cai , Chengjun Wu , Zhen Meng , Xuezhi Wang , Yuanchun Zhou, "BioRAG: A RAG-LLM Framework for Biological Question Reasoning", arxiv.org/abs/2408.01107, 2024.
- [15] CHEN, Y. T., & Chung, T. H., "Advancing Construction Risk Management: An Empirical Investigation of Gpt-3.5 and Supervised Learning Applications in Mega Project Risk Assessment", Available at SSRN 4953265, 2024.
- [16] Deng, J., Heybati, K., Park, Y. J., Zhou, F., & Bozzo, A. "Artificial intelligence in clinical practice: a look at ChatGPT.", *Cleve Clin J Med*, 91(3), pp.173-180, 2024.
- [17] Dongchi Yao, Borja, "Enhancing cyber risk identification in the construction industry using language models", *Automation in Construction*, 165, 105565, 2024.
- [18] Ghimire, P., Kim, K., & Acharya, M., "Generative ai in the construction industry: Opportunities & challenges". *arXiv preprint arXiv:2310.04427*, 2023.
- [19] Gupta, A., Shirgaonkar, A., Balaguer, A. D. L., Silva, B., Holstein, D., Li, D., ... & Benara, V., "RAG vs Fine-tuning: Pipelines, Tradeoffs, and a Case Study on Agriculture". *arXiv preprint arXiv:2401.08406*, 2024.
- [20] Hussain, R., Sabir, A., Lee, D. Y., Zaidi, S. F. A., Pedro, A., Abbas, M. S., & Park, C. "Conversational AI-based VR system to improve construction safety training of migrant workers", *Automation in Construction*, 160, 105315, 2024.
- [21] Lee, J., Jung, W., & Baek, S. "In-House Knowledge Management Using a Large Language Model: Focusing on Technical Specification Documents Review", *applied science*, 14(5), 2096, 2024.
- [22] Kasimir Forth, S.M.ASCE, Patrick Berggold, André Borrmann, Prof.

Dr.-Ing. "Domain-specific fine-tuning of LLM for material matching of BIM elements and Material Passports" , Proc. of 2024 ASCE International Conference on Computing in Civil Engineering, 2024.

- [23] Khan, N., Kimito, E. C., Tran, S., Pedro, A., Soltani, M., Hussain, R., ... & Park, C. "Chapter Extracting Information from Construction Safety Requirements Using Large Language Model", Proceedings e report, 137, pp.7, 2023.
- [24] Kim, J., & Min, M., "From rag to qa-rag: Integrating generative ai for pharmaceutical regulatory compliance process", arXiv preprint arXiv:2402.01717, 2024.
- [25] Latif, E., & Zhai, X. "Fine-tuning ChatGPT for automatic scoring", Computers and Education: Artificial Intelligence, 6, 2024.
- [26] Lee, J., Jang, K., Sparkling, A. E., & Kang, K. "Large Language Model-Based Construction Site Management for Severe Weather Preparedness", Available at SSRN 5033362, 2024.
- [27] Lee, J., Ahn, S., Kim, D., & Kim, D., "Performance comparison of retrieval-augmented generation and fine-tuned large language models for construction safety management knowledge retrieval", Automation in Construction, 168, 105846, 2024.
- [28] Li, H., Yang, R., Xu, S., Xiao, Y., & Zhao, H. "Intelligent Checking Method for Construction Schemes via Fusion of Knowledge Graph and Large Language Models", Buildings, 14(8), 2502, 2024.
- [29] Li, P., He, Y., Yashar, D., Cui, W., Ge, S., Zhang, H., ... & Chaudhuri, S. "Table-gpt: Table-tuned gpt for diverse table tasks", arXiv preprint arXiv:2310.09263, 2023.
- [30] Li, Y., Li, Z., Zhang, K., Dan, R., Jiang, S., & Zhang, Y. "Chatdoctor: A medical chat model fine-tuned on a large language model meta-ai (llama) using medical domain knowledge". Cureus, 15(6), 2023.

- [31] Liang Zhang, Katherine Jijo, Spurthi Setty, Eden Chung, Fatima Javid, Natan Vidra, Tommy Clifford, "Enhancing Large Language Model Performance To Answer Questions and Extract Information More Accurately", 2024.
- [32] Muritala Adebayo Isah, "Development of Question-Answering System to Improve Construction Risk Identification in NATM Tunnels", 경북대학교 석사학위논문, 2024.
- [33] Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., ... & Kiela, D. "Retrieval-augmented generation for knowledge-intensive nlp tasks", *Advances in Neural Information Processing Systems*, 33, pp. 9459-9474, 2020.
- [34] Mikhail Burtsev, Martin Reeves, & Adam Job, "The Working Limitations of Large Language Models : Overestimating the capabilities of AI models like ChatGPT can lead to unreliable applications.", *MIT Sloan Management Review*, pp. 2-4, 2024.
- [35] Pornprasit, C., & Tantithamthavorn, C., "Fine-tuning and prompt engineering for large language models-based code review automation. *Information and Software Technology*", 175, 107523, 2024.
- [36] Rawte, V., Chakraborty, S., Pathak, A., Sarkar, A., Tonmoy, S. M., Chadha, A., ... & Das, A. "The troubling emergence of hallucination in large language models--an extensive definition, quantification, and prescriptive remediations." *arXiv preprint arXiv:2310.04988*, 2023.
- [37] Saka, A., Taiwo, R., Saka, N., Salami, B. A., Ajayi, S., Akande, K., & Kazemi, H. "GPT models in construction industry: Opportunities, limitations, and a use case validation". *Developments in the Built Environment*, 17, 100300, 2024.
- [38] Sammour, F., Xu, J., Wang, X., Hu, M., & Zhang, Z., "Responsible AI in Construction Safety: Systematic Evaluation of Large Language Models and

Prompt Engineering”, arXiv preprint arXiv:2411.08320, 2024.

- [39] Smetana, M., Salles de Salles, L., Sukharev, I., & Khazanovich, L., "Highway Construction Safety Analysis Using Large Language Models", *Applied Sciences*, 14(4), 1352, 2024.
- [40] Spurthi Setty, Harsh Thakkar, Alyssa Lee, Eden Chung, Natan Vidra, "Improving Retrieval for RAG based Question Answering Models on Financial Documents", <https://doi.org/10.48550/arXiv.2404.07221>, 2024
- [41] Tianyi Zhang, Varsha Kishore ,Felix Wu, Kilian Q. Weinberger,Yoav Artzi, "BERTScore: Evaluating Text Generation with BERT", *ICLR*, <https://doi.org/10.48550/arXiv.1904.09675>, 2020.
- [42] Uddin, S. J., Albert, A., Ovid, A., & Alsharef, A. "Leveraging ChatGPT to Aid Construction Hazard Recognition and Support Safety Education and Training". *Sustainability*, 15(9), 7121, 2023.
- [43] Uhm, M., Kim, J., Ahn, S., Jeong, H., & Kim, H., "Efficacy of Retrieval Augmented Generation-Based Large Language Models for Generating Construction Safety Information". Available at SSRN 4819837, 2024.
- [44] Ye, Q., Liu, J., Chong, D., Zhou, P., Hua, Y., Liu, F., ... & Guo, Z. "Qilin-Med: Towards Advanced Chinese Medical Large Language Model", *JOURNAL OF LATEX CLASS FILES*, 14(8), 2024.
- [45] Yoo, B., Kim, J., Park, S., Ahn, C. R., & Oh, T. "Harnessing Generative Pre-Trained Transformers for Construction Accident Prediction with Saliency Visualization", *Applied Sciences*, 14(2), 664, 2024.
- [46] Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., ... & Wang, H. "Retrieval-augmented generation for large language models: A survey", arXiv preprint arXiv:2312.10997, 2023.
- [47] Wilhelmsen, K. B. "Fine-tuning Large Language Models on historical causes of death data", (Master's thesis, UiT Norges arktiske universitet), 2024.

부 록

[부록 1] Input(C) 모듈 / Output(D) 모듈

[부록 2] 5가지 방법론에 대한 세부작업(12가지)별 답변내용


[부록 3] 정성적 평가를 위한 설문지



[부록 1] Input(C) 모듈 / Output(D) 모듈

<부록-표1> Input(C) 모듈 구성 코드

```
def set_text():
    text = ""
    input_query.insert("current", text)
def generate_gpt_answer(prompt):
    # Ensure the API key is securely retrieved from an environment variable
    openai.api_key = ""
    # System_Prompt = "당신은 건설현장의 안전을 책임지는 안전관리자입니다. 사용자가 입력한 정보를 기반으로 관련된 위험요인들을 식별해야 합니다."
    # Instruction_Prompt = "[공중], [작업]과 관련된 위험요인을 목록화합니다. 만약, [사용도구]가 있다면, [사용도구]와 관련된 위험요인을 목록화합니다."
    # User Prompt = ""
    [공중] :
    [작업] :
    [사용도구] : ""
```



<부록-그림 1> Input 모듈(C) UI 화면

<부록-표2> Output(D) 모듈 구성 코드

```
# UI
if __name__ == '__main__':
    root = tk.Tk()
    root.title("건설공사 위험요인 식별")

    mainframe = ttk.Frame(root, padding="3 3 12 12")
    mainframe.grid(column=0, row=0, sticky=(tk.N, tk.W, tk.E, tk.S))
    root.columnconfigure(0, weight=1)
    root.rowconfigure(0, weight=1)

    label1 = ttk.Label(mainframe, text="Query : ")
    label1.grid(column=1, row=1, sticky=tk.W)
    input_query = tk.Text(mainframe, wrap="word")
    input_query.grid(column=2, row=1, columnspan=3, sticky=(tk.N, tk.S, tk.E,
tk.W))
    set_text()
    input_query.insert("1.0", initial_text)

    send_button = ttk.Button(mainframe, text="위험요인 도출",
command=send_message)
    send_button.grid(column=3, row=2, columnspan=4, sticky=tk.E)

    label2 = ttk.Label(mainframe, text="gpt Answer : ")
    label2.grid(column=1, row=3, sticky=tk.W)
    input_gpt_result = tk.Text(mainframe, wrap="word")
    input_gpt_result.grid(column=1, row=4, columnspan=4, sticky=(tk.N, tk.S,
tk.E, tk.W))

    label3 = ttk.Label(mainframe, text="RAG Answer : ")
    label3.grid(column=1, row=5, sticky=tk.W)
    input_rag_result = tk.Text(mainframe, wrap="word")
    input_rag_result.grid(column=1, row=6, columnspan=4, sticky=(tk.N, tk.S,
```

tk.E, tk.W))

```
for child in mainframe.winfo_children():
    child.grid_configure(padx=5, pady=5)
mainframe.columnconfigure(1, weight=1)
mainframe.rowconfigure(4, weight=1)
mainframe.rowconfigure(5, weight=0)

root.mainloop()
```

gpt Answer :

1. 본 문서를 읽고, 다음 질문에 답하십시오.
2. 본 문서를 읽고, 다음 질문에 답하십시오.
3. 본 문서를 읽고, 다음 질문에 답하십시오.
4. 본 문서를 읽고, 다음 질문에 답하십시오.
5. 본 문서를 읽고, 다음 질문에 답하십시오.
6. 본 문서를 읽고, 다음 질문에 답하십시오.
7. 본 문서를 읽고, 다음 질문에 답하십시오.

<부록-그림 2> 위험요인 모듈(D-1) UI 화면

RAG Answer :

(다) 무늬가 없는 경우를 제외하고는 절선 사용을 금하여야 한다.¶¶¶
단순 솔레노이드 밸브의 안전작업 지침
3. 밸브 정비 및 기계기구 사용작업 시 안전 준수사항
(가) 진동기(Vibrator), 밸브의 펌프, 압송관 등 밸브 기계기구의 안전점검을 실시하여야 한다.¶¶¶
(나) 진동기는 대기 저항이 100Ω이하(3중 접지)가 되도록 접지를 하고 분전반에서 인출하여야 하며, 분전반의 외함접지 및 누전차단기 작동 여부를 점검하여야 한다.¶¶¶
(다) 진동기의 지나친 진동은 축압이 증가하여 거푸집 붕괴의 원인이 될 수 있으므로 주의하여야 한다.¶¶¶
(라) 밸브 정비는 시공 장소에 근접하게 설치하되, 평탄하고 바닥이 단단하여 장비 전도의 위험이 없는 곳에 설치하여야 한다.¶¶¶
(마) 밸브의 펌프가 작동 시 물체의 급격한 이동 및 조작을 금지하여야 한다.¶¶¶
(바) 밸브의 펌프가 작동 시 고압 가공전선에 대한 감전예방 조치를 실시하여야 한다.¶¶¶
(사) 밸브의 펌프가 전도방지를 위해 견고한 지반위에 아웃트리거(Outrigger) 설치 등 침하 방지 조치를 하여야 한다.¶¶¶
(아) 밸브의 펌프가 설치지반의 상태가 연약지반인 경우에는 연약토사를 제거하고 밸브를 타설한 후 설치하거나, 충분한 강도와 접지 면적이 확보되는 철판 등을 지면에 깔아야 한다.¶¶¶
(자) 밸브의 펌프가 작업구역 내에 근로자의 출입을 제한하여야 한다.¶¶¶
(차) 밸브의 펌프의 유연성 호스(Flexible hose)는 이상 압력 발생방지를 위해 반경 1미터 이내로 두르지 않아야 한다.¶¶¶
(카) 호스는 솔레노이드 밸브 등 구조물의 끝에서 요동치지 않도록 손잡이를 설치하여 확실히 붙잡고 타설하여야 한다.¶¶¶

<부록-그림 3> 참조 정보(Retrieved Information) 모듈(D-2) UI 화면

[부록2] - 5가지 방법론에 대한 세부작업(12가지)별 답변내용

※ 범용 GPT의 답변내용

공종	콘크리트 공사	
세부작업	콘크리트 타설 및 다짐 작업	콘크리트 운반 작업
답변내용	[사용도구 : 비계, 호퍼, 피니셔, 진동기] 1. 비계의 불안정한 설치로 인한 추락 위험 2. 콘크리트 타설 중 장비와 작업자 간의 충돌로 인한 근로자 부상 위험 3. 콘크리트 타설 및 다짐 작업 중 호퍼 사용으로 인한 추락 위험 4. 콘크리트 타설 및 다짐 작업 중 피니셔 사용으로 인한 넘어짐 위험 5. 진동기 사용으로 인한 근로자 부상 위험	[사용도구 : 콘크리트 펌프카, 레미콘 운반 작업트럭, 콘크리트 믹서 트럭] 1. 개인보호구 미착용하고 작업 중 부딪히거나 찢림 위험. 2. 콘크리트 펌프카 유압장치 점검 중 붐이 낙하하여 근로자 맞음 위험. 3. 펌프카 붐 설치 중 주변 고압선에 접촉으로 인한 감전 위험. 4. 작업반경 내 접근에 의한 부딪힘 위험. 5. 펌프카 장비 사용방법 미숙지에 의한 오작동 사고 위험. 6. 레미콘 운반 작업트럭 후진 시 유도자 미배치로 인한 근로자 부딪힘 위험. 7. 레미콘 운반 작업트럭 상부에서 작업 중 안전장비 미착용으로 인한 추락 위험. 8. 제동장치 이상으로 미끄러지며 근로자 깔림 위험. 9. 경사로에서 오르지 못하여 주변 근로자 깔림 위험.
세부작업	콘크리트 양생 작업	
답변내용	[사용도구 : X, 열풍기] 1. 습기와 물기로 인한 미끄러짐 위험 2. 양생 중인 콘크리트의 부적절한 경계 조치로 인한 추락 위험 3. 화학물질(양생제 등) 사용으로 인한 근로자 부상 위험 4. 열풍기로 인한 화재 위험 5. 열풍기 전원 코드로 인한 넘어짐 위험 6. 콘크리트 양생 시 발생하는 유해가스로 인한 호흡기 질환 위험 7. 양생 작업 중 높은 곳에서의 추락 위험	

※ 범용 GPT의 답변내용

공종	철근 공사	
세부작업	철근 반입 작업	철근 가공 및 운반 작업
답변내용	[사용도구 : 굴삭기, 지게차, X] 1. 철근 반입 작업 중 굴삭기의 이동으로 인한 충돌 위험 2. 철근 적재 시 불안정한 적재로 인한 붕괴 위험 3. 철근 운반 중 지게차로 인한 충돌 위험 4. 철근 적재 불량으로 인한 붕괴 및 근로자 부상 위험 5. 철근 운반 중 부주의로 인한 넘어짐 위험 6. 철근 적재 불량으로 인한 근로자 부상 위험	[사용도구 : 비계, 고소작업차, 고정식 크레인, 굴삭기, 이동식 크레인, X] 1. 철근 가공 및 운반 작업 시 중량물 취급으로 인한 근로자 부상 위험 2. 철근 운반 중 전선과의 접촉으로 인한 감전 위험 3. 고정식 크레인을 사용한 철근 운반 작업 중 과다한 하중으로 인한 로프 파단 및 철근 낙하 위험 4. 철근 가공 및 운반 작업 중 철근의 불안정한 적재로 인한 넘어짐 위험 5. 크레인 작업 중 전도 위험 6. 철근 운반 시 추락 위험 7. 작업 중 장비 및 도구의 불안정한 상태로 인한 근로자 부상 위험 8. 작업장 주변 장애물로 인한 충돌 및 낙하물 위험 9. 장비 및 로프의 과다한 하중으로 인한 추락 위험 10. 와이어로프 및 섬유벨트슬링의 손상으로 인한 근로자 부상 위험 11. 철근 운반 중 감전사고 위험 12. 철근의 부적절한 적재로 인한 도괴 위험 13. 인력 운반 시 근골격계 부상 위험
세부작업	철근 조립 작업	
답변내용	[사용도구 : 비계, 사다리, 고소작업차, X] 1. 비계의 불안정한 설치로 인한 추락 위험 2. 철근조립 작업 중 철근의 미끄러짐으로 인한 넘어짐 위험 3. 철근 운반 시 근로자 간의 부주의로 인한 부상 위험 4. 사다리 사용 중 균형을 잃어 발생할 수 있는 넘어짐 위험 5. 고소작업차 사용으로 인한 추락 위험 6. 철근 운반 중 넘어짐 위험 7. 높은 곳에서의 철근 작업으로 인한 추락 위험 8. 철근 절단 시 발생하는 비산물로 인한 눈 부상 위험 9. 철근을 조립하는 과정에서 손가락 끼임 위험 10. 철근 끝부분에 의한 찔림 위험 11. 작업 공간 내 불규칙한 바닥으로 인한 발목 부상 위험	

※ 범용 GPT의 답변내용

공종	거푸집 공사	
세부작업	자재 운반 작업	자재 가공 작업
답변내용	[사용도구 : 비계] 1. 거푸집 자재반입 중 비계 위에서의 균형 상실로 인한 넘어짐 위험 2. 비계 사용 시 높은 곳에서의 작업으로 인한 추락 위험 3. 거푸집 자재 가공 및 운반 중 비계 구조물과의 충돌로 인한 근로자 부상 위험 4. 거푸집 자재반입 시 적재 불량으로 인한 넘어짐 위험 5. 거푸집 자재 가공 시 절단기 사용 부주의로 인한 근로자 부상 위험 6. 거푸집 자재 운반 중 낙하로 인한 추락 위험 7. 자재 운반 시 중량물 취급 부주의로 인한 근골격계 질환 위험 8. 가공 작업 중 소음으로 인한 청력 손상 위험 9. 거푸집 자재 적재 시 불안정한 적재로 인한 전도 위험 10. 자재 가공 중 비산물로 인한 안구 부상 위험 11. 자재반입 시 통로 확보 미비로 인한 충돌 위험	[사용도구 : 타워크레인, 톱] 1. 타워크레인 사용 중 자재 이동 시 충돌로 인한 근로자 부상 위험 2. 거푸집 공사 중 높은 곳에서 작업 시 추락 위험 3. 거푸집 자재 가공 작업 중 근로자 부상 위험. 4. 톱 사용 중 부주의로 인한 근로자 부상 위험 5. 자재 가공 작업 중 미끄러짐으로 인한 넘어짐 위험
세부작업	자재 인양 작업	동바리 해체 작업
답변내용	[사용도구 : 카고크레인] 1. 카고크레인 사용 시 자재 추락으로 인한 부상 위험 2. 거푸집 공사 시 고소 작업으로 인한 추락 위험 3. 자재 운반 중 미끄러짐으로 인한 넘어짐 위험 4. 크레인 작업 반경 내 근로자 접촉으로 인한 충돌 위험 5. 자재 운반 중 과적에 의한 장비 전도 위험 6. 크레인 작동 중 전선 접촉으로 인한 감전 위험 7. 거푸집 설치 중 부적절한 지지로 인한 붕괴 위험 8. 장비 점검 미흡으로 인한 기계 고장 및 사고 위험	[사용도구 : X] 1. 부적절한 거푸집동바리 사용으로 인한 구조 붕괴 위험 2. 손상된 동바리 및 연결재 사용으로 인한 작업자 부상 위험 3. 동바리 해체 시 추락 위험 4. 해체 작업 중 비산물로 인한 작업자 부상 위험 5. 안전모 및 안전대 미착용으로 인한 중상 위험 6. 동바리 해체 작업 중 장비 충돌로 인한 부상 위험 7. 동바리 해체 시 부적절한 장비 사용으로 인한 부상 위험 8. 해체 작업 시 주변 환경 미확보로 인한 작업자 간 충돌 위험

※ 범용 GPT의 답변내용

공종	거푸집 공사	
세부작업	동바리 인양 작업	동바리 조립 작업
답변내용	[사용도구 : 양중기] 1. 양중기 작동 중 안전장치 미작동으로 인한 추락 위험 2. 동바리 설치 불량으로 인한 붕괴 위험 3. 거푸집 해체 시 지지대 미흡으로 인한 근로자 부상 위험 4. 작업 공간 내 불안정한 발판으로 인한 넘어짐 위험 5. 작업자 부주의로 인한 양중기와의 충돌 위험 6. 양중기 사용 시 하중 초과로 인한 장비 전도 위험 7. 동바리 인양 중 적재물의 불균형으로 인한 낙하 위험 8. 작업장 내 불충분한 조명으로 인한 시야 확보 불량 위험 9. 기상 악화 시 작업 지속으로 인한 안전사고 위험 10. 작업자 개인 보호장구 미착용으로 인한 부상 위험 11. 장비의 정기적 점검 미비로 인한 고장 위험	[사용도구 : X, 이동식 크레인, 리프트] 1. 동바리의 불안정한 설치로 인한 넘어짐 위험 2. 높은 곳에서 작업 시 추락 위험 3. 거푸집의 붕괴로 인한 근로자 부상 위험 4. 작업 중 동바리의 변형으로 인한 구조물 붕괴 위험 5. 작업 공간 내 장애물로 인한 발목 뺨 및 넘어짐 위험 6. 동바리 조립 시 무거운 자재 취급으로 인한 근로자 부상 위험 7. 동바리 연결 부위의 불량으로 인한 구조물 불안정 위험 8. 조립 작업 중 공구의 미끄러짐으로 인한 손 부상 위험 9. 동바리 해체 시 잔존물로 인한 발 부상 위험 10. 작업자 간 의사소통 부족으로 인한 협업 실패 위험 11. 조립 작업 중 과도한 힘 사용으로 인한 근로자 근육 부상 위험 12. 작업 공간 내 조명 부족으로 인한 시야 확보 불량 위험 13. 날씨 변화에 따른 작업 환경 변화로 인한 안전 위험 1. 이동식 크레인 사용으로 인한 추락 위험 2. 리프트 사용 중 발생할 수 있는 균형 상실로 인한 추락 위험

※ Only B 방법론의 답변내용

공종	콘크리트 공사	
세부작업	콘크리트 타설 및 다짐 작업	콘크리트 운반 작업
답변내용	[사용도구 : 비계, 호퍼, 피니셔, 진동기] 1. 비계로 인한 추락 위험 2. 콘크리트 타설 중 구조물 붕괴 위험 3. 호퍼 사용으로 인한 콘크리트의 낙하 위험 4. 콘크리트 타설 및 다짐 작업 중 피니셔 사용으로 인한 근로자 부상 위험 5. 진동기 사용 시 진동으로 인해 근로자의 손목, 팔, 어깨 등에 무리가 갈 수 있으며, 장시간 사용 시 근골격계 질환이 발생	[사용도구 : 콘크리트 펌프카, 레미콘 운반 작업트럭, 콘크리트 믹서트럭] 1. 콘크리트 펌프카의 붐대 조작 중 전선 접촉으로 인한 감전 위험 2. 펌프카 아웃트리거의 부등침하로 인한 전도 위험 3. 콘크리트 타설 중 호스 요동으로 인한 근로자 부상 위험 4. 자재 운반 중 낙하로 인한 부상 위험 5. 지게차 사용 중 충돌 및 낙하물로 인한 부상 위험 6. 펌프카 작업반경 내 근로자 출입으로 인한 안전사고 위험 7. 레미콘 운반 작업트럭의 불안정한 적재로 인한 추락 위험 8. 철근콘크리트 공사 중 거푸집 및 동바리 조립 불량으로 인한 구조물 붕괴 위험 9. 콘크리트 믹서 트럭 운반 경로의 바닥면에 돌출물이나 미끄러운 표면으로 인한 넘어짐 위험 10. 작업자들이 높은 곳에서 작업할 경우 추락 위험
세부작업	콘크리트 양생 작업	
답변내용	[사용도구 : X, 열풍기] 1. 콘크리트 양생 작업 중 미끄러운 표면으로 인한 넘어짐 위험 2. 작업 중 높은 곳에서의 작업으로 인한 추락 위험 3. 양생 중인 콘크리트 위에 과도한 하중이 가해져 근로자 부상 위험 4. 밀폐된 공간에서 갈탄이나 열풍기를 사용하여 발생하는 유해 가스에 의한 질식 위험. 5. 콘크리트 양생 작업 중 열풍기 사용 시 발생할 수 있는 화재 위험. 6. 열풍기 등 전기 기계기구 사용 시 접지 불량이나 누전으로 인한 감전 위험. 7. 갬폼 해체 및 인양 작업 중 작업 발판에서의 추락 위험.	

※ Only B 방법론의 답변내용

공종	철근 공사	
세부작업	철근 반입 작업	철근 가공 및 운반 작업
답변내용	[사용도구 : 굴삭기, 지게차, X] 1. 철근 반입 작업 시 굴삭기로 인한 근로자 부상 위험 2. 철근 반입 시 철근의 낙하로 인한 부상 위험 3. 작업장 내 정리정돈 미흡으로 인한 넘어짐 위험 4. 지게차 사용 중 부딪힘 및 깔림 위험 5. 철근 적재 불안정으로 인한 추락 위험 6. 철근 운반 중 전선과의 접촉으로 인한 감전 위험 7. 철근 적재 부주의로 인한 구조물 붕괴 위험	[사용도구 : 비계, 고소작업차, 고정식 크레인, 굴삭기, 이동식 크레인, X] 1. 철근 가공 및 운반 작업 시 중량물 취급으로 인한 근로자 부상 위험 2. 철근 운반 중 전선과의 접촉으로 인한 감전 위험 3. 고정식 크레인을 사용한 철근 운반 작업 중 과도한 하중으로 인한 로프 파단 및 철근 낙하 위험 4. 철근 가공 및 운반 작업 중 철근의 불안정한 적재로 인한 넘어짐 위험 5. 크레인 작업 중 전도 위험 6. 철근 운반 시 추락 위험 7. 작업 중 장비 및 도구의 불안정한 상태로 인한 근로자 부상 위험 8. 작업장 주변 장애물로 인한 충돌 및 낙하물 위험 9. 장비 및 로프의 과도한 하중으로 인한 추락 위험 10. 와이어로프 및 섬유벨트슬링의 손상으로 인한 근로자 부상 위험 11. 철근 운반 중 감전사고 위험 12. 철근의 부적절한 적재로 인한 도괴 위험 13. 인력 운반 시 근골격계 부상 위험
세부작업	철근 조립 작업	
답변내용	[사용도구 : 비계, 사다리, 고소작업차, X] 1. 비계 및 철근 조립 작업 중 추락 위험 2. 철근 운반 및 조립 중 근로자 부상 위험 3. 강풍, 폭우 등의 악천후로 인한 작업 안전성 저하 4. 철근조립 작업 중 이동식비계의 불안정한 설치로 인한 추락 위험 5. 작업자가 안전대나 안전난간 없이 작업할 경우 추락할 위험 6. 철근 운반 중 무거운 하중으로 인한 근로자의 근골격계 부상 위험 7. 철근 운반 중 철근이 다른 물체에 부딪혀 발생할 수 있는 추락 위험 8. 철근 운반 작업 중 전선과의 접촉으로 인한 감전 위험 9. 철근을 비계나 거푸집 위에 과도하게 적재하여 발생할 수 있는 구조물 붕괴 위험 10. 철근 운반 중 부주의로 인한 장비 및 로프의 파손으로 인한 부상 위험 11. 거푸집 조립 시 고정 불량으로 인한 구조물 붕괴 위험 12. 동바리 조립 시 강관의 연결 불량으로 인한 전도 위험	

※ Only B 방법론의 답변내용

공종	거푸집 공사	
세부작업	자재 운반 작업	자재 가공 작업
답변내용	[사용도구 : 비계] 1. 비계 설치 및 사용 중 추락 위험 2. 거푸집 자재 운반 중 근로자 부상 위험 3. 거푸집 조립 시 구조적 불안정으로 인한 붕괴 위험 4. 자재반입 시 바닥면의 돌출물로 인한 넘어짐 위험 5. 거푸집 자재 운반 중 중량물 취급으로 인한 근로자 부상 위험 6. 작업발판의 불안정성으로 인한 추락 위험 7. 운반 중 자재의 낙하로 인한 근로자 부상 위험 8. 운반경로의 시야 방해로 인한 충돌 및 부상 위험 9. 자재 가공 시 발생할 수 있는 튀거나 이탈된 물체로 인한 부상 위험 10. 작업장 내 정리정돈 미흡으로 인한 작업 중 사고 위험	[사용도구 : 타워크레인, 톱] 1. 타워크레인을 이용한 자재 가공 작업 중 자재의 불안정한 적재로 인한 추락 위험 2. 자재 가공 작업 중 불필요한 자재로 인한 넘어짐 위험 3. 톱 사용 중 발생할 수 있는 절단 부상 위험 4. 자재 가공 작업 중 발생할 수 있는 넘어짐 위험
세부작업	자재 인양 작업	동바리 해체 작업
답변내용	[사용도구 : 카고크레인] 1. 카고크레인 사용 중 부적절한 조작으로 인한 추락 위험 2. 자재 운반 중 무거운 하중으로 인한 근골격계 부상 위험 3. 운반 경로에 돌출물로 인한 넘어짐 위험 4. 차량계하역운반기계 사용 중 기계와의 접촉으로 인한 깔림 위험 5. 적재된 자재가 불안정하게 쌓여 있을 경우의 붕괴 위험 6. 작업구역 내 근로자의 불필요한 출입으로 인한 사고 위험 7. 차량 적재함에서 자재 하역 시의 불안정한 행동으로 인한 추락 위험 8. 운반 도중 자재가 다른 물체에 부딪혀 발생할 수 있는 파손 및 부상 위험	[사용도구 : X] 1. 부적절한 해체 순서로 인한 넘어짐 위험 2. 작업 중 불안정한 자세로 인한 근로자 부상 위험 3. 동바리 해체 시 갑작스러운 붕괴로 인한 추락 위험 4. 인원 부족으로 인한 과도한 작업 부하로 인한 부상 위험 5. 해체 시 주변 물체와의 충돌로 인한 부상 위험 6. 날씨 변화로 인한 작업 환경 악화로 인한 부상 위험 7. 미끄러운 작업 표면으로 인한 넘어짐 위험 8. 보호 장비 미착용으로 인한 부상 위험 9. 해체 도중 도구의 미끄러짐으로 인한 부상 위험 10. 작업 구역 내 통제 부족으로 인한 외부인 접근 위험 11. 해체 작업 중 소음으로 인한 청력 손상 위험 12. 해체 시 비산물로 인한 안면 부상 위험 13. 비숙련 작업자의 부주의로 인한 부상 위험 14. 해체 중 불안정한 지지로 인한 붕괴 위험 15. 해체 작업 시 시야 확보 부족으로 인한 사고 위험 16. 조명 부족으로 인한 시야 확보 문제로 인한 사고 위험

※ Only B 방법론의 답변내용

공종	거푸집 공사
세부작업	동바리 인양 작업
답변내용	[사용도구 : 양중기] 1. 양중기 와이어로프 파단으로 인한 거푸집 부재에 맞음 위험 2. 양중기 훅 걸림식 미설치로 인한 거푸집 부재에 맞음 위험 3. 양중기 훅에 거푸집 부재 걸림상태 불량으로 인한 거푸집 부재에 맞음 위험 4. 양중기 운전원과 신호수간 신호불량으로 인한 거푸집 부재에 맞음 위험 5. 양중기 훅과 와이어로프 연결부 탈락으로 인한 거푸집 부재에 맞음 위험 6. 양중기 훅 파단으로 인한 자재 낙하 위험 7. 거푸집 동바리 인양중 동바리의 훅 이탈로 인한 자재 낙하 위험 8. 양중기 운전 미숙으로 인한 자재 낙하 위험 9. 양중기 운전중 인양중인 거푸집 동바리에 근로자 깔림 위험 10. 양중기 훅에 훅 마개 미설치로 인한 자재 낙하 위험 11. 양중기 훅에 와이어로프가 미체결된 상태로 인양중인 거푸집 동바리에 근로자 깔림 위험
세부작업	동바리 조립 작업
답변내용	[사용도구 : X, 이동식 크레인, 리프트] 1. 양중기 사용 중 장비의 고장으로 인한 넘어짐 위험 2. 양중기 사용 중 하중 불균형으로 인한 추락 위험 3. 거푸집 동바리 조립 중 근로자 부상 위험 4. 거푸집 해체 시 부재 낙하로 인한 부상 위험 5. 인양 작업 중 갯폼 출렁임으로 인한 추락 위험 6. 작업장 주변 개구부 및 슬래브 단부에서의 추락 위험 7. 작업장 주변 돌출물로 인한 부상 위험 8. 장비 작업 중 전기 누전으로 인한 감전 위험 9. 유류 연료 사용 장비의 화재 위험 10. 체인블록 훅 해지장치의 불량으로 인한 부상 위험 11. 데릭 인양 시 수평 불균형으로 인한 구조물 파손 위험 12. 와이어로프 고정 불량으로 인한 인양 실패 위험 13. 작업발판의 잔재물로 인한 미끄러짐 및 넘어짐 위험 14. 이동식 크레인의 부적절한 아웃트리거 설치로 인한 전도 위험 15. 거푸집 동바리 조립 작업 중 리프트 사용으로 인한 추락 위험

※ Only A 방법론의 답변내용

공종	콘크리트 공사	
세부작업	콘크리트 타설 및 다짐 작업	콘크리트 운반 작업
답변내용	[사용도구 : 비계, 호퍼, 피니셔, 진동기] 1. 비계 상부에서 작업중 근로자 안전난간 미설치로 인한 추락 위험 2. 비계에 고정하여 설치한 작업발판이 탈락되면서 추락 위험 3. 호퍼 사용 중 부적절한 고정으로 인한 호퍼 전도 위험 4. 피니셔 회전부에 의한 근로자 부상 위험 5. 진동기 사용 중 전원 케이블 피복 손상으로 인한 감전 위험	
세부작업	콘크리트 양생 작업	
답변내용	[사용도구 : X, 열풍기] 1. 콘크리트 양생 중 주변에 낙하물로 인한 근로자 부상 위험 2. 콘크리트 양생 중 작업발판이 파손되면서 추락 위험 3. 양생 중 콘크리트가 강도를 얻지 못해 붕괴 위험 4. 열풍기 과열로 인한 화재 위험 5. 전선 피복 손상으로 인한 감전 위험 6. 작업장 내 정리정돈 미흡으로 인한 넘어짐 위험 7. 열풍기에서 나오는 유해가스에 의한 질식 위험	

※ Only A 방법론의 답변내용

공종	철근 공사	
세부작업	철근 반입 작업	철근 가공 및 운반 작업
답변내용	[사용도구 : 굴삭기, 지게차, X] 1. 굴삭기 작업반경 내 근로자 출입으로 인한 부상 위험 2. 굴삭기 버킷에 고정된 철근다발 낙하로 인한 근로자 부상 위험 3. 지게차의 포크로 인한 근로자 부상 위험 4. 지게차의 포크에 적재된 철근 다발 무너짐에 의한 근로자 부상 위험 5. 철근 더미의 정리 미흡으로 인한 근로자 넘어짐 위험 6. 철근을 차량에서 내리는 중 낙하로 인한 근로자 부상 위험	[사용도구 : 비계, 고소작업차, 고정식 크레인, 굴삭기, 이동식 크레인, X] 1. 비계에 안전난간 미설치로 인한 근로자 추락 위험 2. 철근 운반시 고소작업차에 근로자 탑승 금지 조치 필요 3. 고정식 크레인 와이어로프 단선으로 인한 철근에 근로자 맞음 위험 4. 굴삭기 회전부와 근로자 간 충돌로 인한 근로자 부상 위험 5. 이동식크레인 작업반경 내 출입으로 인한 근로자 부상 위험 6. 이동식크레인에 의한 철근 운반중 슬링와이어 파단으로 인한 근로자 부상 위험 7. 철근 운반중에 운반용 장비와 접촉으로 인한 근로자 부상 위험 8. 이동식크레인으로 철근 운반중 근로자와 접촉으로 인한 부상 위험 9. 철근 단부에 의한 찢림 위험 10. 철근 운반 중 인력 과다 사용으로 인한 근로자 부상 위험 11. 철근 운반 중 발판 탈락에 의한 추락 위험 12. 철근 운반 중에 끈이 풀리면서 철근에 맞음 위험 13. 철근 운반 중 전도 위험
세부작업	철근 조립 작업	
답변내용	[사용도구 : 비계, 사다리, 고소작업차, X] 1. 비계의 불안정한 설치로 인한 넘어짐 위험 2. 철근 운반 시 안전모 미착용으로 인한 근로자 부상 위험 3. 비계 주변 추락 방호조치 미설치로 인한 추락 위험 4. 사다리 파손으로 인한 근로자 추락 위험 5. 고소작업차 바스켓 위 작업발판 고정 불량으로 인한 근로자 추락 위험 6. 철근 단부에 의한 찢림 위험 7. 철근 조립중 철근이 무너짐으로 인한 깔림 위험 8. 작업중 철근단부에 의한 찢림 위험 9. 철근조립 작업중 고소에서 추락 위험 10. 작업발판 미설치로 인한 추락 위험 11. 개인보호구 미착용으로 인한 부상 위험 12. 안전난간 미설치로 인한 추락 위험	

※ Only A 방법론의 답변내용

공종	거푸집 공사	
세부작업	자재 운반 작업	자재 가공 작업
답변내용	[사용도구 : 비계] 1. 비계 부실 설치로 인한 근로자 추락 위험 2. 비계 상부에서 작업 중 안전모 미착용으로 인한 근로자 부상 위험 3. 거푸집 자재 운반 중 적재불량으로 인한 근로자 부딪힘 위험" 4. 자재 적재 불량으로 인한 근로자 부상 위험 5. 자재 운반 중 근로자 맞음 위험 6. 거푸집 하부 미 고정으로 인한 자재 쓸림에 의한 근로자 부상 위험 7. 자재 운반 중 근로자 발 부딪힘 위험 8. 근로자 무리한 작업으로 인한 근골격계 질환 위험 9. 거푸집 자재 가공중 안전장구 미착용으로 인한 근로자 부상 위험 10. 지반 침하에 의한 적재된 자재 무너짐으로 인한 근로자 부상 위험	[사용도구 : 타워크레인, 톱] 1. 타워크레인 와이어로프 파단으로 인한 자재에 맞음 위험 2. 절단 작업 중 절단기 톱날에 손이 닿어 근로자 부상 위험 3. 톱 사용 중 보호구 미착용으로 인한 근로자 부상 위험 4. 작업 중 톱에 의해 손이 베이는 위험
세부작업	자재 인양 작업	동바리 해체 작업
답변내용	[사용도구 : 카고크레인] 1. 작업 반경 내 근로자 출입으로 인한 근로자 부상 위험 2. 근로자가 운전부 주의 없이 유도로 인한 근로자 부상 위험 3. 근로자가 신호수 없이 작업으로 인한 근로자 부상 위험 4. 운전부가 유도로만 믿고 작업으로 인한 근로자 부상 위험 5. 와이어로프의 탈락으로 인한 자재 낙하 위험 6. 자재를 한번에 많이 걸어 인양중 로프 파단으로 인한 자재 낙하 위험 7. 와이어로프가 훅에 제대로 체결되지 않아 자재 낙하 위험 8. 인양중에 자재가 무너져내리며 낙하 위험	[사용도구 : X] 1. 작업 중 불안정한 작업발판 사용으로 인한 추락 위험 2. 작업 중 무리한 동바리 해체로 인한 붕괴 위험 3. 해체된 동바리로 인한 자재 낙하 위험 4. 해체된 동바리 주변에서 작업으로 인한 부딪힘 위험 5. 거푸집 해체 시 잔여 부재에 걸려 넘어짐 위험 6. 작업장 주변에 정리되지 않은 자재로 인한 걸려 넘어짐 위험 7. 작업 중 개인보호구 미착용으로 인한 부상 위험 8. 동바리 해체 작업 중 근로자 간의 신호 불일치로 인한 부딪힘 위험 9. 해체된 자재를 무리하게 운반 중 근골격계 질환 위험 10. 해체된 자재를 적재 중 무너짐으로 인한 깔림 위험 11. 작업장 주변 개구부 미설치로 인한 추락 위험 12. 해체 작업 시 잔여 부재의 돌출로 인한 찰림 위험 13. 작업 중 불안정한 행동으로 인한 추락 위험 14. 작업장 주변 정리정돈 미흡으로 인한 자재에 걸려 넘어짐 위험 15. 작업 중 근로자간 의사소통 불량으로 인한 안전사고 위험 16. 동바리 해체 작업 중 인력 부족으로 인한 부상 위험

※ Only A 방법론의 답변내용

공종	거푸집 공사
세부작업	동바리 인양 작업
답변내용	[사용도구 : 양중기] 1. 양중기 혹에서 와이어로프 이탈로 인한 자재 낙하 위험 2. 와이어로프의 혹 걸림 불량으로 인한 자재 낙하 위험 3. 거푸집 동바리 인양중 혹에서 와이어로프 이탈로 인한 자재 낙하 위험 4. 거푸집 동바리 인양중 혹 파단으로 인한 자재 낙하 위험 5. 양중기 인양중 자재에 부딪힘 위험 6. 부재 인양 시 클램프의 부적절한 사용으로 인한 부재 손상 위험 7. 인양 중 부재의 흔들림으로 인한 충돌 위험 8. 장비 작동 중 근로자의 신체 일부가 휘니사 날에 접촉될 위험 9. 유류를 연료로 사용하는 장비에서의 화재 위험 10. 인양 작업 중 신호 불명확으로 인한 사고 위험 11. 작업장 내 전기 설비의 누전으로 인한 감전 위험
세부작업	동바리 조립 작업
답변내용	[사용도구 : X, 이동식 크레인, 리프트] 1. 안전난간 미설치로 인한 추락 위험 2. 개구부 미덮개 설치로 인한 추락 위험 3. 고정되지 않은 거푸집으로 인한 근로자 깔림 위험 4. 동바리의 강도부족으로 인한 붕괴 위험 5. 거푸집이 설계도와 다르게 조립되어 발생하는 붕괴 위험 6. 하단부 지지 불량으로 인한 동바리 붕괴 위험 7. 동바리부재 용접부 탈락으로 인한 근로자 부딪힘 위험 8. 작업중 안전모, 안전화 등 보호구 미착용으로 인한 부상 위험 9. 작업발판 미설치로 인한 추락 위험 10. 거푸집 부재 무리한 인력 운반중 부딪힘 위험 11. 거푸집 부재 인양중 결속상태 불량으로 인한 낙하 위험 12. 작업반경내 무단출입으로 인한 부딪힘 위험 13. 불안정한 사다리 사용으로 인한 추락 위험 14. 거푸집 동바리 조립 중 이동식 크레인 불대 하강으로 인한 근로자 부상 위험 15. 리프트의 이상으로 인한 근로자 부상 위험

※ A+B 방법론의 답변내용

공종	콘크리트 공사	
세부작업	콘크리트 타설 및 다짐 작업	콘크리트 운반 작업
답변내용	[사용도구 : 비계, 호퍼, 피니셔, 진동기] 1. 비계의 불안정한 설치로 인한 추락 위험 2. 작업 중 철근 또는 콘크리트에 걸려 넘어짐 위험 3. 호퍼 사용 중 이동식 크레인 와이어로프의 파단에 의한 호퍼의 추락 위험 4. 피니셔 사용 중 회전 날에 의한 부상 위험 5. 진동기 사용 중 전기 누전으로 인한 감전 위험	[사용도구 : 콘크리트 펌프카, 레미콘 운반 작업트럭, 콘크리트 믹서 트럭] 1. 펌프카 붐대가 전선과 접촉으로 인한 감전 위험 2. 콘크리트 호스 요동으로 인한 근로자 부상 위험 3. 펌프카의 아웃트리거 미설치로 인한 전도 위험 4. 크레인 사용 중 훅 해지장치 미설치로 인한 인양물 탈락 위험 5. 콘크리트 펌프카 주변에서 근로자 안전모 미착용으로 인한 추락물 부딪힘 위험 6. 펌프카 붐대 조작 중 근로자 접근으로 인한 부딪힘 위험 7. 레미콘 운반 작업트럭의 후진 중 근로자 부딪힘 위험 8. 레미콘 운반 작업트럭의 적재함에서 콘크리트가 낙하하여 근로자 부딪힘 위험 9. 믹서 트럭 후진 시 작업자 부딪힘 위험 10. 믹서 트럭의 경사로 인한 전도 위험
세부작업	콘크리트 양생 작업	
답변내용	[사용도구 : X, 열풍기] 1. 양생 중 콘크리트 강도 미달로 인한 구조물 붕괴 위험 2. 작업장 내 정리정돈 미흡으로 인한 근로자 부상 위험 3. 개구부, 슬래브 끝단 등 추락 위험 4. 열풍기 사용 중 전기 누전으로 인한 감전 위험 5. 밀폐공간에서 열풍기 사용으로 인한 질식 위험 6. 열풍기 주변 인화성 물질로 인한 화재 위험 7. 양생 작업 중 미끄러운 바닥으로 인한 넘어짐 위험	

※ A+B 방법론의 답변내용

공종	철근 공사	
세부작업	철근 반입 작업	철근 가공 및 운반 작업
답변내용	[사용도구 : 굴삭기, 지게차, X] 1. 굴삭기 작업 중 과부하로 인한 장비 전도 위험 2. 철근 반입 중 인력 운반으로 인한 근로자 부상 위험 3. 지게차 운행 중 전도 위험 4. 철근 운반 중 자재 낙하 위험 5. 철근 다발 무너짐으로 인한 깔림 위험 6. 철근 다발 운반 시 부딪힘 위험	[사용도구 : 비계, 고소작업차, 고정식 크레인, 굴삭기, 이동식 크레인, X] 1. 비계발판 끝단부에서 안전난간 미설치로 인한 추락 위험 2. 고소작업차의 아웃트리거 미설치로 인한 전도 위험 3. 로프 파단으로 인한 자재 낙하 위험 4. 굴삭기 혹은 탈락으로 인한 자재 낙하 위험 5. 슬링벨트의 결함으로 인한 철근 탈락 위험 6. 이동식 크레인의 보조 혹은 미사용으로 인한 철근망 이탈 위험 7. 철근 운반 중 자재 낙하 위험 8. 이동식 크레인 전도 위험 9. 개구부로 인한 추락 위험 10. 철근 운반 중 슬링벨트 불량 체결로 인한 자재 낙하 위험 11. 철근 운반 중 로프 결속 불량으로 인한 철근 근로자 강타 위험 12. 철근 운반 중 슬링벨트 불량 체결로 인한 철근 가격 위험 13. 철근 가공 중 가공기 회전부에 의한 끼임 위험 14. 철근 운반 중 이동로 상 장애물로 인한 넘어짐 위험
세부작업	철근 조립 작업	
답변내용	[사용도구 : 비계, 사다리, 고소작업차, X] 1. 비계 연결부의 파단으로 인한 추락 위험 2. 비계에 안전난간 미설치로 인한 추락 위험 3. 비계 발판 미설치로 인한 추락 위험 4. 사다리 사용 중 불안정한 설치로 인한 추락 위험 5. 고소작업차의 중량 초과로 인한 전도 위험 6. 철근의 고정 불량으로 인한 넘어짐 위험 7. 작업 발판 불안정으로 인한 추락 위험 8. 작업 중 철근의 이탈로 인한 자재 낙하 위험 9. 철근 묶음의 무너짐으로 인한 전도 위험 10. 작업 구역 주변에 개구부로 인한 추락 위험 11. 철근 운반 중 주변 장애물로 인한 넘어짐 위험 12. 개인 보호구 미착용으로 인한 상해 위험	

※ A+B 방법론의 답변내용

공종	거푸집 공사	
세부작업	자재 운반 작업	자재 가공 작업
답변내용	[사용도구 : 비계] 1. 비계의 작업발판 탈락으로 인한 추락 위험 2. 비계에 근로자 승강설비 미설치로 인한 추락 위험 3. 거푸집 해체시 잔존콘크리트 등 낙하로 인한 위험 1. 무리한 인력운반으로 인한 근골격계 부상 위험 2. 운반 경로의 돌출물로 인한 넘어짐 위험 3. 거푸집 자재가 운반 중 낙하로 인한 부상 위험 4. 가공 작업 중 자재에 부딪힘 위험 5. 운반 중 자재가 쓸림으로 인한 전도 위험 6. 작업장 주변 정리정돈 미비로 인한 걸림 위험 7. 개구부 주변 작업으로 인한 추락 위험	[사용도구 : 타워크레인, 톱] 1. 타워크레인에서의 자재 낙하 위험 1. 거푸집 무너짐으로 인한 근로자 깔림 위험 1. 톱 사용중 감전 위험. 2. 톱 사용중 톱날에 접촉으로 인한 베임 위험.
세부작업	자재 인양 작업	동바리 해체 작업
답변내용	[사용도구 : 카고크레인] 1. 카고크레인 붐대 파손으로 인한 자재 낙하 위험 2. 크레인 사용 중 붐대가 파손으로 인한 전도 위험 3. 자재 인양 중 와이어로프 풀림에 의한 자재 낙하 위험 4. 카고크레인 사용 중 붐대에 작업자 맞음 위험 5. 크레인 인양줄에 의한 자재 낙하 위험 6. 자재 인양중 와이어로프가 파단으로 인한 자재 낙하 위험 7. 크레인 인양줄에 의한 자재 낙하 위험 8. 운반 자재 무너짐으로 인한 맞음 위험	[사용도구 : X] 1. 작업발판 미설치하고 작업중 추락 위험. 2. 작업 발판 미설치로 인한 추락 위험 3. 해체 중 거푸집 무너짐으로 인한 근로자 깔림 위험 4. 개구부 또는 슬라브 단부로 이동중 추락 위험. 5. 무리한 작업으로 인한 근로자 근골격계 질환 위험 6. 근로자 개인보호구 미착용으로 인한 부상 위험 7. 해체된 거푸집에 근로자 부딪힘 위험 8. 무리한 작업 실시 중 해체 거푸집 및 동바리 낙하로 인한 근로자 깔림 위험. 9. 거푸집 해체 중 동바리 연결재 무너짐에 의한 근로자 깔림 위험 10. 해체된 거푸집을 지상으로 운반중 거푸집에 맞음 위험 11. 거푸집 해체 중 상부에서 낙하물에 맞음 위험 12. 지상으로 인양중 거푸집이 인양로프에서 빠짐에 맞음 위험 13. 동바리 해체 작업중 동바리 해체 순서 불량으로 인한 깔림 위험 14. 동바리 해체 작업중 인양로프 미결속으로 인한 거푸집 맞음 위험 15. 해체된 거푸집에 근로자 부딪힘 위험 16. 거푸집 해체 작업중 동바리 연결재가 빠지면서 깔림 위험

※ A+B 방법론의 답변내용

공종	거꾸집 공사
세부작업	동바리 인양 작업
답변내용	[사용도구 : 양중기] 1. 양중기 사용 시 장비의 불안정한 설치로 인한 넘어짐 위험 2. 거꾸집 동바리 인양 중 와이어로프 파손으로 인한 추락 위험 3. 인양 작업 중 장비의 균형 상실로 인한 근로자 부상 위험 4. 작업장 주변 개구부 및 슬래브 단부에서의 추락 위험 5. 인양 와이어로프의 부적절한 체결로 인한 부재 낙하 위험 6. 거꾸집 부재 인양중 주변 근로자 접근으로 인한 부딪힘 위험 7. 거꾸집 부재 인양중 와이어로프 끊어짐으로 인한 부딪힘 위험 8. 거꾸집 부재 인양중 와이어로프에서 거꾸집 부재가 탈락되면서 부딪힘 위험 9. 거꾸집 부재 인양중 양중기 후에서 와이어로프가 탈락되면서 부딪힘 위험 10. 거꾸집 부재 인양중 양중기 후에서 와이어로프가 탈락되면서 부딪힘 위험 11. 양중기 후과 와이어로프 연결부 탈락으로 인한 거꾸집 부재에 맞음 위험
세부작업	동바리 조립 작업
답변내용	[사용도구 : X, 이동식 크레인, 리프트] 1. 작업발판 미설치로 인한 추락 위험 2. 양중기 후크에 전대 부착설비 미설치로 인한 자재 낙하 위험 3. 양중기의 후크 해지장치 미설치로 인한 자재에 맞음 위험 4. 마리에 동바리 부딪힘 위험 5. 동바리 무너짐 위험 6. 동바리 조립불량으로 무너짐 위험 7. 동바리 상하부 미고정으로 인한 동바리 무너짐 위험. 8. 동바리 수평 내려저하로 인한 무너짐 위험. 9. 2단 설치로 인한 타설 중 무너짐 위험 10. 자재 낙하로 하부 작업근로자 맞음 위험 11. 안전대를 안전대 부착설비에 미체결로 인한 추락 위험. 12. 거꾸집 변형으로 인한 붕괴 위험 13. 거꾸집 이탈로 인한 추락 위험 1. 외줄달기로 인한 거꾸집 추락 위험 1. 리프트 운행 중 근로자 끼임 위험

※ A+C 방법론의 답변내용

공종	콘크리트 공사
세부작업	콘크리트 타설 및 다짐 작업
답변내용	[사용도구 : 비계, 호퍼, 피니셔, 진동기] 인양로프 점검 미흡으로 인해 작업 중 로프가 끊어져 호퍼가 낙하하여 작업자가 깔릴 위험. 피니셔의 회전부에 의한 근로자 끼임 위험. 진동기 전선 피복 손상으로 인한 감전 위험. 비계와 건물 사이의 틈새로 인한 추락 위험. 비계 상부 난간대 미설치로 인한 추락 위험. 비계 상부 난간대 미설치로 인한 추락 위험. 안전모, 안전화 등 개인보호구 미착용으로 인한 부딪힘 위험. 슬래브 타설중 슬래브가 무너짐으로 인한 근로자 깔림 위험. 안전난간 미설치로 인한 근로자 추락 위험. 거푸집이 전도되면서 외부로 근로자 추락 위험. 콘크리트 타설중 근로자가 미끄러지면서 추락 위험. 콘크리트 다짐 작업 중 거푸집 붕괴로 인한 근로자 깔림 위험.
세부작업	콘크리트 운반 작업
답변내용	[사용도구 : 콘크리트 펌프카, 레미콘 운반 작업트럭, 콘크리트 믹서트럭] 펌프카의 붐대가 탈락하면서 레미콘 트럭과 부딪힘으로 인한 근로자 부딪힘 위험. 펌프카 붐대의 작동반경 내 근로자 출입으로 인한 근로자 부딪힘 위험. 펌프카 붐대가 전선에 접촉되어 감전 위험. 펌프카 운전원 미숙으로 인한 펌프카 붐대 탈락 위험. 펌프카 아웃리거 지반 침하로 인한 장비 전도 위험. 펌프카 붐대에 설치된 유도 호스가 탈락하면서 근로자 부딪힘 위험. 펌프카의 유압 호스 파손으로 인한 콘크리트 분출 위험 작업중 타설호스의 콘크리트가 근로자에게 부딪힘 위험 레미콘 트럭 후진 중 근로자와 부딪힘 위험. 레미콘 트럭이 도로 경사면에서 주차 브레이크 미체결로 인한 차량 전도 위험. 레미콘 트럭의 회전드럼 구동부 덮개 미설치로 인한 회전체에 끼임 위험. 콘크리트 믹서트럭 운전 중 전도 방지를 위한 차량 주차브레이크 미체결로 인한 전도 위험. 콘크리트 믹서트럭 후방에 유도자 미배치로 인한 근로자와 충돌 위험.

※ A+C 방법론의 답변내용

공종	콘크리트 공사
세부작업	콘크리트 양생 작업
답변내용	[사용도구 : X, 열풍기] 열풍기 전원 연결부가 파손되어 감전 위험. 열풍기 전기 누전으로 인한 감전 위험. 열풍기 배기구로 유해가스 노출에 의한 질식 위험. 콘크리트 양생용 비닐 덮개 설치 중 추락 위험. 양생용 비닐 덮개 미설치로 인한 콘크리트 강도 부족 위험. 콘크리트 양생용 비닐 덮개 설치 중 작업발판 미설치로 인한 추락 위험. 콘크리트 양생 중 유해물질에 의한 질식 위험

※ A+C 방법론의 답변내용

공종	철근 공사
세부작업	철근 반입 작업
답변내용	[사용도구 : 굴삭기, 지게차, X] 굴삭기로 철근을 반입하던 중 철근이 무너짐에 따른 근로자 깔림 위험. 굴삭기로 철근을 반입하던 중 철근이 낙하에 따른 맞음 위험. 철근 반입 작업중 굴삭기 전도에 따른 근로자 깔림 위험. 굴삭기 운전원의 신호수와 신호 불일치로 인한 근로자 충돌 위험. 지게차로 철근을 반입하던 중 철근이 무너짐에 따른 근로자 깔림 위험.
공종	철근 공사
세부작업	철근 가공 및 운반 작업
답변내용	[사용도구 : 비계, 고소작업차, 고정식 크레인, 굴삭기, 이동식 크레인, X] 비계에서 철근을 가공하던 중 근로자가 추락 위험. 철근 운반 작업 중 무리한 인양으로 인한 인양줄 파단으로 철근 운반 중 고정식 크레인 와이어로프 파단으로 인한 낙하 위험. 고정식 크레인 설치 및 사용 부주의로 인해 크레인 자체 전도 위험. 고정식 크레인 사용 중 전선과의 접촉으로 인한 감전 위험. 철근 가공 및 운반 중 철근 끝단에 의해 근로자가 찔림 위험. 고정식 크레인 운전 중 작업 반경 내 근로자와 충돌 위험. 철근 운반 중 굴삭기 버킷에 적재된 철근이 불안정하게 고정되어 낙하 위험. 굴삭기 작업 반경 내 근로자와 굴삭기가 충돌 위험. 철근 운반 중 이동식 크레인 와이어로프 파단으로 인한 철근 낙하 위험.

	철근 운반 중 크레인 후의 미고정으로 철근 낙하 위험. 철근 적재 작업 중 적재물의 붕괴로 인해 근로자가 깔림 위험. 철근 운반 작업 중 크레인 붐대와 전선 접촉으로 인한 감전 위험. 철근 적재 작업 중 철근이 불안정하게 쌓여 낙하 위험. 철근을 적재하는 과정에서 불안정한 적재로 철근이 떨어져 작업자가 깔릴 위험. 철근 가공 중 절단기의 절연 파괴로 인한 감전 위험. 철근 운반 중 낙하물방지망이 접혀진 상태에서 각재가 낙하하여 근로자 위험. 철근 운반 중 타워크레인 슬링벨트 탈락으로 인한 강타 위험. 철근 운반 중 철근다발 한쪽 끝단 철선에 연결된 상태로 크레인 인양 중 근로자 낙하 위험. 철근 가공 작업 중 철근 절단기의 절단날 마모로 인한 미끄러짐 위험. 철근 운반 중 인력으로 운반 시 부주의로 인한 부상 위험. 철근 운반 시 전선과의 접촉으로 인한 감전 위험. 철근 운반 중 부적절한 하중 분배로 인한 인양 장비 전도 위험. 철근 운반 중 로프 및 슬링의 부적절한 사용으로 인한 철근 낙하 위험.
--	---

※ A+C 방법론의 답변내용

공종	철근 공사
세부작업	철근 조립 작업
답변내용	[사용도구 : 비계, 사다리, 고소작업차, Xi 비계의 안전난간 미설치로 인한 추락 위험. 비계의 발판이 탈락되어 근로자 추락 위험. 비계 연결부의 탈락으로 인한 근로자 추락 위험. 임의 제작한 목재 사다리 사용 중 부재 탈락으로 인한 추락 위험 고소작업차 작업 중 중심을 잃어 추락 위험. 철근 조립 중 수직 철근에 의해 찢림 위험. 고소작업차 이동 중 지반 침하로 인한 전도 위험 철근 조립 작업 중 주변 개구부에 안전난간 미설치로 인한 추락 위험. 철근 조립 중 근로자가 수직 철근에 걸려 넘어지면서 찢림 위험. 고소작업차의 작업대 미고정으로 인한 추락 위험. 대형축조블럭 붕괴로 인한 깔림 위험 안전난간 미설치된 바닥 개구부로 인한 추락 위험 바닥 슬래브 수직철근에 찢림 위험 및 추락 위험 수직철근 전도로 인한 깔림 위험 철근 붕괴로 인한 근로자 협착 위험

※ A+C 방법론의 답변내용

공종	거푸집 공사
세부작업	자재 운반 작업
답변내용	[사용도구 : 비계] 비계 위에서 거푸집 자재를 운반 중 작업자가 중심을 잃고 추락 위험. 승강통로가 미설치된 상태에서 비계 외부로 이동 중 실족하여 추락 위험. 거푸집 자재의 무게로 인해 작업자가 개구부로 추락할 위험. 작업 발판이 고정되지 않거나 불안정하여 작업 중 발판 탈락으로 추락 위험. 비계의 안전난간 미설치로 인해 자재 운반 중 작업자가 추락 위험. 작업자가 비계 이동 시 미끄러짐 방지 조치 미흡으로 실족 추락 위험 자재 운반 중 비계 주변에 작업 통로가 확보되지 않아 근로자 충돌 및 낙상 위험. 고정되지 않은 자재가 작업 중 전도되거나 떨어져 근로자 부상 위험 방호선반 고정 불량으로 인한 붕괴 및 추락 위험 구조검토를 수행하지 않은 자재 활용으로 인해 거푸집 붕괴 위험.
공종	거푸집 공사
세부작업	자재 가공 작업
답변내용	[사용도구 : 타워크레인, 톱] 거푸집 전도방지조치가 제대로 되지 않아 거푸집이 전도되어 근로자 깔림 위험. 자재 가공 중 톱날에 의한 베임 위험. 톱 사용 중 전원공급 장치의 불량이나 전선 손상으로 인한 감전 위험. 거푸집 동바리의 고정 불량으로 인해 동바리가 무너져 추락할 위험.

※ A+C 방법론의 답변내용

공종	거푸집 공사
세부작업	자재 인양 작업
답변내용	[사용도구 : 카고크레인] 양중기 조작 중 조작 미숙으로 인한 오작동으로 근로자가 자재에 부딪힘 위험. 관리감독자 미배치 상태에서 근로자가 무리하게 차량에 올라가다가 추락 위험. 양중기 기계장치 이상으로 조작 중 갑작스러운 회전으로 근로자가 부딪힘 위험. 후크 해지장치 미설치로 자재 인양 중 후크에서 로프 탈락으로 인한 자재에 맞음 위험. 거푸집 자재를 불안전하게 적재하여 외부 충격 또는 편심하중에 의해 무너짐 위험. 인양 중 양중기 와이어로프 파단으로 인한 자재에 맞음 위험. 인양 중 보조로프 절단으로 인해 인양 물체가 낙하하며 근로자가 맞음 위험. 자재 인양 중 카고크레인 붐대가 꺾이면서 자재에 깔림 위험. 자재를 1줄걸이로 결속하여 인양 중 갑작스러운 흔들림으로 근로자가 맞음 위험. 양중 로프를 이용해 인양 중 거푸집이 기울어져 근로자가 추락 위험. 보 거푸집 설치 작업 중 중심 상실로 인해 근로자가 추락 위험. 노후된 섬유로프 파단으로 인해 거푸집이 낙하하며 근로자가 깔림 위험. 불안정한 거푸집 상부층 인양으로 인해 근로자가 거푸집 철근에 찢림 위험. 상부 합판 주변 자재에 걸려 넘어지면서 근로자가 추락 위험. 타워크레인 메인지브 연결핀 탈락으로 인해 자재가 낙하하며 근로자가 타격 위험. 크레인 고정핀 불량 사용으로 인해 자재가 낙하하며 근로자가 맞음 위험.

※ A+C 방법론의 답변내용

공종	거푸집 공사
세부작업	동바리 해체 작업
답변내용	[사용도구 : X] 높은 장소에서 거푸집 해체 시 작업발판 미설치로 인한 근로자 추락 위험. 거푸집을 떼어내기 위해 무리한 힘을 가하다가 중심을 잃어 추락 위험. 해체된 자재 위를 지나던 중 걸려 넘어짐 위험. 개구부 또는 슬래브 단부로 이동 중 방호조치 미비로 인한 추락 위험. 해체 중인 거푸집을 받침대로 미지정한 상태에서 거푸집이 쓰러져 근로자 깔림 위험. 이동 중 불안정하게 적재된 자재가 무너져 근로자 부상 위험. 거푸집 해체 중 거푸집이 불안정하게 매달려 낙하로 인한 근로자 맞음 위험. 작업 중 거푸집 동바리 해체 절차를 무시한 무리한 작업으로 해체된 자재가 낙하하여 근로자 깔림 위험. 해체 작업 중 동바리 하부 받침판 이탈로 인해 동바리가 전도되어 근로자 깔림 위험. 해체된 거푸집 자재에 박혀 있는 못이나 날카로운 돌출물로 인한 근로자 부상 위험. 안전모, 안전화 등 개인 보호구 미착용으로 인한 부딪힘 및 찢림 위험. 비계 부재를 밟고 내려가다가 근로자가 추락할 위험. 외벽과 비계 사이 개구부로 근로자가 추락할 위험. 안전난간 해체 상태에서 작업 중 근로자 추락 위험. 비계 위에 거푸집 자재를 적재한 상태에서 불안정으로 인해 자재가 낙하하거나 근로자가 추락할 위험. 양생 기간 미준수로 인해 구조물이 붕괴되고 근로자가 깔릴 위험.

※ A+C 방법론의 답변내용

공종	거푸집 공사
세부작업	동바리 인양 작업
답변내용	[사용도구 : 양중기] 동바리 인양 중 양중기의 작업 반경 내 근로자 접근으로 인한 충돌 및 끼임 위험. 동바리 인양 작업 중 고정 불량으로 인해 동바리가 전도되거나 낙하하여 근로자 부상 위험. 양중기 사용 시 작업 반경 내 불안정한 자재 적치로 인해 자재 낙하 위험. 양중기 훅(Hook)과 와이어로프의 체결 불량으로 인해 동바리 낙하 위험. 인양 작업 중 작업자 중심을 잃고 동바리 또는 작업장 허부로 추락 위험. 동바리 인양 중 양중기의 과도한 하중 또는 불균형으로 인해 양중기 전도 위험. 작업 반경 내 작업자 보호구 미착용으로 인해 낙하물 충격 시 심각한 부상 위험. 동바리 인양 작업 중 강풍 등 악천후로 인해 동바리가 흔들리거나 전도될 위험. 양중기 운전자의 시야 제한으로 인해 작업 반경 내 근로자와 충돌 위험. 양중기 사용 전 장비 점검 미흡으로 인해 기계 결함 발생 시 작업자 안전 위험. 작업 반경 내 비계나 발판의 불안정한 설치로 인해 작업자 추락 위험. 인양 작업 중 동바리의 날카로운 부분이나 돌출물에 의해 작업자가 찔림 위험. 동바리 인양 작업 시 작업 구역 주변 통제 미흡으로 인해 외부인의 접근 및 사고 위험.

※ A+C 방법론의 답변내용

공종	거꾸집 공사
세부작업	동바리 조립 작업
답변내용	[사용도구 : X, 이동식 크레인, 리프트] 작업발판이 설치되지 않은 동바리 수평재에서 작업 중 근로자가 추락할 위험. 동바리 고정상태 불량으로 인해 자재가 낙하하여 근로자가 부상을 입을 위험. 동바리 조립 시 리프트 운반구와 안전난간 사이에서 끼임 사고 발생 위험. 슬링벨트 불안정으로 인해 동바리가 뒤집히며 근로자가 추락할 위험. 이동식 크레인으로 동바리 인양 시 혹에서 슬링 와이어 로프 빠짐으로 인한 자재 추락 위험. 리프트 운반구와 안전난간 사이에 근로자 끼임 위험. 시스템동바리 상부에서 비정상적인 이동 중 근로자가 추락할 위험. 자재반출구 난간대 제거 상태에서 작업 중 안전대 미착용으로 인한 추락 위험. 작업발판에서 긴결재 이송 중 실족하여 근로자가 추락할 위험. 임시설치된 작업보조대의 구조적 불안정으로 인해 근로자가 추락할 위험. 동바리 하부의 받침판 고정 불량으로 인해 동바리가 침하하거나 전도될 위험. 동바리 상·하부 접속부 및 교차부 연결 불량으로 인해 구조적 불안정 발생 위험. 경사진 곳에 동바리 설치 시 부적절한 고정으로 인해 동바리가 전도될 위험. 작업 중 동바리와 거꾸집 사이에 근로자가 끼일 위험.

[부록3] 정성적 평가를 위한 설문지

건설현장 위험요인 식별 LLM 성능평가를 위한 설문

귀하의 귀중한 시간을 허락해 주셔서 감사드립니다.

본 설문은 LLM 답변 품질을 평가하는 것에 목적이 있습니다.

본 설문을 통해 확보된 데이터와 응답 내용은 학문적 목적 이외로는 절대로 사용되지 않을 것이며, 외부로 공개되는 일이 없을 것을 약속드립니다.

협조에 감사드리며, 귀하와 귀사의 무궁한 발전을 기원합니다.

2024년 12월



광운대학교 건축공학과
왕인국 석사과정생

귀하의 부서를 작성해주시시오.	
귀하의 직위/직책을 작성해주시시오.	
귀하의 건설 관련 경력을 작성해주시시오.	① 5년 이하 ② 5년 이상 ③ 10년 이상 ④ 20년 이상 ⑤ 30년 이상

설문평가 일반사항

✓ 본 설문은 위험성평가의 위험요인 정보를 생성한 LLM의 성능을 평가하는 설문입니다.

※ 평가대상

- 평가대상은 성능향상을 위해 적용한 방법(4가지)와 범용 GPT의 응답(1가지)으로 총 5가지 모델에 대하여 평가를 진행합니다.
- 각각의 방식에 대해서는 (A) ~ (E) 알파벳으로 표현하였으며, 각 알파벳이 어떤 방법을 적용한 모델인지는 표기하지 않았습니다.
- (A) ~ (E) 답변내용 모두 LLM을 통해 자동으로 생성한 위험요인입니다.

※ 평가방법

- 5점 리커트 척도기반 평가방법을 활용하였습니다.
- PDF파일의 각 방식의 답변내용 (A) ~ (E)을 보고 구글 설문 Form의 설문항목에서 체크하여 주시면 됩니다.

공종	콘크리트 공사
세부작업	• 콘크리트 타설 및 다짐 작업 • 콘크리트 운반 작업 • 콘크리트 양생 작업
답변내용	[LLM 답변]

※ 설문구성

- 각 방식에 대한 설문 구성은 다음과 같습니다.

☞ LLM의 효율성 및 효과성 평가 : 문항 [1] ~ 문항[6]

설문 문항	평가척도				
항목 [1]	① 매우 아니다	② 아니다	③ 보통이다	④ 그렇다	⑤ 매우 그렇다
⋮					
항목 [6]	① 매우 아니다	② 아니다	③ 보통이다	④ 그렇다	⑤ 매우 그렇다

설문 항목			평가 척도				
			매우 아니다	←	보통	→	매우 그렇다
효 율 성	[1]	LLM을 활용하여 안전관리 전문인력의 서류작성 업무 시간을 단축할 수 있다고 생각하십니까?	①	②	③	④	⑤
	[2]	LLM을 활용하여 안전관리 전문인력의 의사결정을 효율적으로 지원할 수 있다고 생각하십니까?	①	②	③	④	⑤
	[3]	LLM을 활용하여 안전관리 전문인력이 수행하는 반복적이거나 단순한 수작업을 대체할 수 있다고 생각하십니까?	①	②	③	④	⑤
효 과 성	[4]	LLM의 답변이 3년 이상의 안전관리 전문인력과 동일한 수준이라고 생각하십니까?	①	②	③	④	⑤
	[5]	LLM의 답변이 건설현장의 공종과 관련된 위험요인을 누락 없이 생성하였다고 생각하십니까?	①	②	③	④	⑤
	[6]	LLM을 활용하여 안전관리 전문인력을 대체하거나 보완할 수 있다고 생각하십니까?	①	②	③	④	⑤