



## 저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

碩士學位 請求論文  
指導教授 鄭 鍾 筆

# 산업 안전 예방을 위한 이미지 처리 기반 실시간 객체 탐지 모델에 관한 연구

成均館大學校 一般大學院

스마트팩토리융합學科

具 炳 辰

碩士學位 請求論文

指導教授 鄭 鍾 筆

# 산업 안전 예방을 위한 이미지 처리 기반 실시간 객체 탐지 모델에 관한 연구

Research on Image Processing based Realtime Object  
Detection for Industrial Safety Prevention

成均館大學校 一般大學院

스마트팩토리융합學科

具 炳 辰

碩士學位 請求論文  
指導教授 鄭 鍾 筆

# 산업 안전 예방을 위한 이미지 처리 기반 실시간 객체 탐지 모델에 관한 연구

Research on Image Processing based Realtime Object  
Detection for Industrial Safety Prevention

이 論文을 工學 碩士學位請求論文으로 提出합니다.

2022 年 10 月 日

成均館大學校 一般大學院

스마트팩토리융합學科

具 炳 辰

이 論文을 具炳辰의 工學  
碩士學位 論文으로 認定함.

2022 年 12 月 日

審査委員長

---

審査委員

---

審査委員

---

## 목차

|                                       |    |
|---------------------------------------|----|
| 제1장 서론 .....                          | 1  |
| 1.1 연구 배경 및 목적 .....                  | 1  |
| 1.2 논문 구성 및 기여 .....                  | 4  |
| 제2장 관련연구 .....                        | 5  |
| 2.1 YOLO .....                        | 5  |
| 2.2 Vision Transformer .....          | 9  |
| 2.3 기존 헬멧 탐지 모델 연구 .....              | 12 |
| 제3장 YOLOv4 기반 실시간 작은 객체 탐지 모델 .....   | 14 |
| 3.1 헬멧 탐지 모델 구조 .....                 | 14 |
| 3.2 ISR(Image Super Resolution) ..... | 15 |
| 3.3 Backbone Network .....            | 18 |
| 3.4 Neck Network .....                | 20 |
| 3.5 이미지 타일링 기법 .....                  | 21 |
| 3.6 ISR-Yolov4 모델 아키텍처 .....          | 28 |
| 제4장 실험 및 평가 .....                     | 29 |
| 4.1 실험 환경 .....                       | 29 |
| 4.2 성능지표 .....                        | 31 |
| 4.3 모델의 초매개변수 .....                   | 33 |

|                         |        |
|-------------------------|--------|
| 4.4 모델 크기 및 학습시간 .....  | 34     |
| 4.5. Inference 시간 ..... | 35     |
| 4.6. 평균 정밀도 .....       | 36     |
| 4.7. 모델 이미지 샘플 .....    | 37     |
| <br><b>제5장 결론</b> ..... | <br>44 |
| 5.1 연구 결과 .....         | 44     |
| 5.2 향후 연구 계획 .....      | 45     |
| <br><b>참고문헌</b> .....   | <br>46 |
| <b>Abstract</b> .....   | 52     |

## 표 목차

|                                               |    |
|-----------------------------------------------|----|
| [표 3-1] 타일링 그리드에 따른 모델 정확도 .....              | 22 |
| [표 3-2] ISR 모듈만 적용 .....                      | 26 |
| [표 3-3] YOLO 모델에 2x2 타일링 기법 적용 .....          | 26 |
| [표 4-1] 하드웨어 및 소프트웨어 환경 .....                 | 29 |
| [표 4-2] 데이터 SET .....                         | 30 |
| [표 4-3] 모델의 초매개변수 .....                       | 33 |
| [표 4-4] 매개변수, 모델 크기 및 훈련 시간에서 다양한 모델 비교 ..... | 34 |
| [표 4-5] Inference 시간과 실시간 탐지 성능 비교 .....      | 35 |
| [표 4-6] 모델 평균 정밀도 비교 .....                    | 36 |

## 그림목차

|                                                         |    |
|---------------------------------------------------------|----|
| [그림 2-1] YOLO-v4 아키텍처 .....                             | 7  |
| [그림 2-2] Detr 아키텍처 .....                                | 10 |
| [그림 3-1] 제안된 헬멧 탐지 모델 .....                             | 14 |
| [그림 3-2] ISR 모듈 프레임워크 .....                             | 17 |
| [그림 3-3] CSPDarknet 네트워크 구조 .....                       | 18 |
| [그림 3-4] CSP1-N Network Structure .....                 | 19 |
| [그림 3-5] CSPN-2 네트워크 구조 .....                           | 20 |
| [그림 3-6] 타일링 기법 .....                                   | 21 |
| [그림 3-7] 타일링 프로세스 .....                                 | 23 |
| [그림 3-8] Training 이미지 타일링 헬멧 객체 탐지 결과 .....             | 24 |
| [그림 3-9] Training 및 Inference 이미지 타일링 헬멧 객체 탐지 결과 ..... | 25 |
| [그림 3-10] ISR-YOLOv4 네트워크 .....                         | 28 |
| [그림 4-1] 헬멧 착용자와 미착용자 샘플 .....                          | 37 |
| [그림 4-2] 소형 물체 탐지 샘플 .....                              | 38 |
| [그림 4-3] 드론 앵글 탐지 모델 샘플 .....                           | 39 |
| [그림 4-4] 헬멧 착용자 미착용자 분류 샘플 .....                        | 40 |
| [그림 4-5] 수직 앵글 샘플 모델 .....                              | 41 |
| [그림 4-6] 소방관 헬멧 탐지 샘플 모델 .....                          | 42 |
| [그림 4-7] 실내 탐지 모델 샘플 .....                              | 43 |

## 논문 요약

# 산업 안전 예방을 위한 이미지 처리 기반 실시간 객체 탐지 모델의 관한 연구

안전모를 착용하면 건설 현장에서 작업자의 안전을 효과적으로 향상시킬 수 있다. 그러나 작업자들은 작업에 불편함 때문에 헬멧을 벗는 경우가 많으며, 이는 큰 위험을 초래한다. 안전모를 착용하지 않은 작업자는 인명과 수직 낙하와 같은 사고에서 부상을 입을 가능성이 더 크다. 따라서 헬멧 착용 감지는 건설현장의 안전관리에 있어 중요한 단계이며, 신속하고 정확하게 헬멧을 감지하는 것이 시급하다. 그러나 기존의 수동 모니터는 상당한 노동력이 필요하고 헬멧에 센서를 장착하는 방식을 대중화하기 어렵다. 따라서 본 논문에서는 높은 탐지율로 만족할 만한 정확도로 헬멧 착용을 탐지하는 AI 기법을 제안한다. YOLO v4를 기반으로 입력 이미지의 초고해상도(ISR) 모듈을 추가하여 이미지 해상도를 높이고 이미지의 노이즈를 제거한 뒤, CSPDarknet53 프레임워크를 사용하여 백본 네트워크의 잔여 블록을 조밀한 블록으로 대체하여 불필요한 계산을 줄이고 네트워크 구조 매개변수의 수를 줄인다. 그런 다음 목은 SPPnet과 PANnet의 조합을 사용하여 이미지에서 작은 대상의 기능을 최대한 활용한다. 본 논문에서 이미지 배경 및 전경 불균형 문제를 해결하기 위해 YOLOv4 손실 기능 부분에 전경 및 배경 균형 손실 기능을 추가한다. 자체적으로 구축한 데이터 세트를 사용하여 수행한 실험은 제안된 방법이 기존 작은 표적 탐지 모델보다 더 효과적인 것으로 나타났다. 끝 우리 모델은 원래 알고리즘보다 7.8% 증가한 93.3%의 평균 정밀도를 달성했으며 416 x 416에서 이미지를 감지하는 데 3.0ms밖에 걸리지 않는다.

주제어 : small-object detection; helmet detection; image super resolution; YOLO; YOLOv4; safety

# 제1장 서론

## 1. 연구 배경 및 목적

산업이 활성화됨에 따라 점점 더 많은 인프라를 구축해야 하므로 건설 현장의 안전은 그 어느 때보다 중요하며, 개인 보호 장비를 사용하여 사고를 예방할 수 있다. 헬멧은 낙하물로부터 작업자를 보호하기 위한 가장 중요한 개인보호장비로서, 전 세계 건설현장에서는 반드시 착용을 의무화하고 있다. 그러나 안전모를 착용하는 것은 불편함과 성가시함으로 인해 소홀해지는 경향이 있다. 따라서 작업자의 안전을 위해 작업자의 헬멧 착용 여부를 확인하는 것이 매우 중요하며, 안전관리 수준을 높일 수 있다. 기존 건설현장 헬멧착용검사에서는 감시영상검사와 유인순찰을 하고 있다. 그러나 이 방법은 많은 시간과 노력이 필요하며, 수동 모니터링 검사자가 장시간 화면을 응시해야 하기 때문에 피로로 인한 오판을 유발할 수 있다. 이에 건설현장에서 헬멧을 감지하는 신기술과 센서 등의 도움으로 영상분석기법이 빠르게 발전하고 있다. 과거에 비해 산업재해로 인한 사망자는 줄었지만 여전히 건설업의 사망률이 높고 전체 사망자의 절반 이상이 건설업에서 발생하고 있다. 건설 현장에서 헬멧을 착용하지 않으면 치명적인 사고로 이어질 수 있다. 따라서 이러한 인명사고를 예방하기 위해서는 건설현장에서 헬멧 착용 여부를 인식하고 감지하는 시스템이 필요하며, 컴퓨터 기술의 발전으로 대규모 병렬 컴퓨팅에 GPU를 적용하여 대규모 심층 신경망을 훈련할 수 있게 되었다.

객체 탐지는 컴퓨터 비전 솔루션의 필수 기능이다. 기상 레이더 영상의 분류에 사용되는 병렬 자기 조직화 지도(parallel-Self-Organizing Map, SOM)의 핵심 구성요소를 사용하여 지난 몇 년 동안 주목을 받았다. 프로세스를 사용하여 이미지 데

이터에 대한 연속적인 변환 세트에 대해 합산된 구성 요소별(픽셀별) 엔트로피를 최소화하여 테스트 데이터를 생성된 데이터 정의 모델과 일치하도록 효과적으로 가져오는 절차를 보여준다. 객체 탐지 분야에서는 일련의 딥러닝 기반 방법이 개발되었으며, 고수준의 특징 추출에서 우수한 특성 때문에 CNN(Convolution Neural Networks)이 가장 많이 사용된다. 그러므로 이미지 분석에서 기존의 검출 방법을 점차 대체하고 있다. CNN 기반 객체 감지에는 두 가지 주요 방법이 있다. 첫 번째는 객체가 있을 수 있는 후보 영역 세트를 추출한 다음 CNN 감지기를 객체 분류 및 위치에 적용하는 two-stage 감지기입니다. 대표적으로 R-CNN(Region-Based Convolution Neural Network)과 Fast R-CNN 및 Faster R-CNN[12]과 같은 개선된 네트워크가 있다. 대표적으로 R-CNN(Region-Based Convolution Neural Network)과 Fast R-CNN 및 Faster R-CNN과 같은 개선된 네트워크가 있다. 반면, Single-stage 검출기는 객체 검출을 회귀 문제로 취급하여 CNN 기능에 따라 클래스 확률과 경계 상자 좌표를 직접 예측한다. 대표적인 네트워크는 SSD(Single-shot Multibox Detector), Look-at-Once(YOLO), 개선된 네트워크다. CNN 기반 탐지기의 개발은 딥러닝 기반 안전모 착용 탐지 방법에 적용했으며, 많은 연구자들은 딥러닝 기반 방법을 건설 안전 관리 문제를 해결하기 위한 필수 조치로 고려하고 있다.

한 연구 결과에 따르면 Faster R-CNN을 기반으로 한 헬멧 자동 감지기를 개발하여 다양한 환경에서 90.1%에서 98.4%의 정확도를 달성했다. 그러나 Faster R-CNN은 이미지를 감지하는 데 약 0.2초가 걸리므로 실시간으로 객체를 탐지하기에는 무리가 있다. 타 연구에서는 Faster R-CNN을 개선하기 위해 다중 규모 훈련, 증강 앵커 전략 및 온라인 하드 예제 마이닝을 사용했다. 안전모 감지 정확도는 최종적으로 기존 알고리즘 대비 7% 향상됐지만, 탐지 속도는 개선되지 않았다. 최근 많은 연구자들이 안전모 감지 작업을 위한 단일 단계 감지기에 대해 연구하고 있으며 S이미지 피라미드 구조를 사용하여 다중 스케일 특징 맵을 추출하고 YOLO-v3

와 결합하는 방법도 있으며, YOLO-v3의 기존 백본 대신에 조밀하게 연결된 컨볼루션 네트워크를 채택하여 동일한 탐지 시간으로 더 나은 탐지 결과를 얻었다. 또한 Single-Shot-Detector 얼굴 검출기를 기반으로 안전모를 검출한 후 얼굴-투-헬멧 회귀 모델을 개발하였으며, 실시간 요구 사항을 충족하기 위해 SSD 알고리즘을 선택하고 계산 부하를 줄이기 위해 MobileNet 을 추가했다.

YOLO-v3를 개선하기 위해 새로운 목적 함수를 제안하고 헬멧 감지에 적용하여, Single Stage detector는 일반적으로 Two-Stage-detector 검출기보다 정확도가 낮지만 속도 측면에서 더 우수하다. YOLO-v4는 객체 감지 모델 중 속도와 정확도를 모두 만족하여 실시간 객체 감지에 적합하며, 위의 모든 연구는 딥 러닝 기반의 안전모 착용 감지 방법을 개발하면 인적 및 물적 자원을 줄이고 인적 요인으로 인한 누락 및 오탐을 방지하고 다음 단계의 기반을 마련하는 데 도움이 될 수 있음을 보여준다.

## 1.2 논문 구성 및 기여

본 논문의 나머지 부분은 다음과 같이 구성되어 있다. 1장에서는 연구 배경 및 목적에 관해서 설명한다. 2장에서는 안전모 감지 관련 연구를 소개한다. 3장에서는 제안된 모델의 알고리즘을 소개하고 4장에서는 실험 환경, 훈련 내용, 결과 분석을 제시한다. 5장에서는 결론을 제시합니다.

본 연구의 기여는 건설현장 작업자들의 헬멧 착용 실제 이미지 데이터셋을 활용하여 작은 물체(헬멧) 감지 문제를 해결하기 위해 YOLOv4 기반의 향상된 이미지 네트워크를 제안한다.

## 제2장 관련연구

### 2.1 YOLO


객체 감지의 두 가지 주요 문제는 분류와 위치 지정이다. 이 두 문제가 별도로 해결될 때 우리는 그것을 two-stage 탐지기라고 부른다. RCNN은 전형적인 Two-stage 탐지 알고리즘입니다. Two-stage 탐지 알고리즘은 정확도 측면에서 장점이 있지만 처리 속도가 느리고 구조적 복잡하다. 반면에 single-stage 탐지기는 앞에서 언급한 두 가지 문제를 하나의 프로세스에서 해결합니다. YOLO는 그러한 프로세스 중 하나입니다. Single-stage 탐지기 YOLO는 종단간 학습 방법으로 사용할 수 있는 알고리즘이다. 단일 회귀 문제로 분류하고 찾는 문제에 접근한다. YOLO는 입력 이미지를  $S \times S$  그리드로 나누어, 물체의 중심이 특정 그리드 내에 있는 경우 그리드는 물체를 감지하는 역할을 합니다. 각 그리드에서 B 경계 상자가 예측되면, 각 B-Box에 대해 예측된 신뢰 점수는 0에서 1 사이의 값을 가지며 해당 경계 상자에 개체가 존재할 확률을 나타낸다. 또한 각 그리드는 클래스의 확률도 예측하며 최종 예측값은  $(S \times S \times (B*5 + C))$  크기의 데이터의 배열 값을 가집니다. 또한 non-max 억제를 통해 최종 바운딩 박스가 선택된다. 이 YOLO 방식은 빠른 처리 속도를 보이지만 한 영역에서 두 개의 상자와 하나의 범주만 예측할 수 있기 때문에 작은 물체나 가까운 물체를 감지하기 어렵다.

모델이 더 많은 상자를 예측하고 더 나은 성능을 보여주기 위해 YOLO-v2는 Faster-RCNN[10]에서 앵커 상자의 개념을 차용합니다. 앵커 박스를 사용할 때 앵커 박스와 객체의 차이만 예측하면 됩니다. 이렇게 하면 YOLO-v2가 문제를 더 쉽게 해결할 수 있어 성능이 향상됩니다. 모델이 더 많은 상자를 예측하고 더 나은

성능을 보여주기 위해 YOLO-v2는 Faster-RCNN에서 앵커 상자의 개념을 차용하여 앵커 박스를 사용할 때 앵커 박스와 객체의 차이만 예측하면 된다. 이렇게 하면 YOLO-v2가 문제를 더 쉽게 해결할 수 있어 성능이 향상된다. 또한 YOLO-v2는 입력 영상의 해상도를 416 x 416 픽셀로 변경하여 마지막으로 추출된 특징 맵이 13 x 13이 되도록 홀수인 앵커 박스가 중앙에 생성되도록 하였다. 이런 식으로 중앙에 있는 물체도 잘 예측할 수 있으며 YOLO-v2의 그리드는 5개의 앵커 박스를 제공하므로 앵커 박스의 크기 표준은 훈련 세트에 클러스터링된 앵커 박스를 기반으로 결정된다. 그러나 YOLO 계열의 알고리즘은 작은 물체 감지에서 약점을 보인다. 따라서 YOLO-v3는 세 가지 척도를 사용하여 이 문제를 해결하려고 했다.

세 가지 척도는 darknet-53에 convolutional layer를 추가하여 피라미드 수준에서 특징을 추출하여 추가된 컨볼루션 레이어는 피쳐 피라미드를 생성하는 데 사용된다. 업샘플링은 최종 피쳐 맵에 대해 2회 수행되며, 최종 피쳐 맵과 이전 두 개의 피쳐 맵이 업샘플링된 피쳐 맵과 결합된다. 그 후 병합된 특징 맵은 FCN(Fully Convolutional Networks)에 입력되고 다음 레벨의 특징 맵에도 동일한 과정이 적용된다. YOLO-v4는 최신 딥러닝 기술을 사용하여 모델을 설계하였다. 잘 짜여진 구조를 기반으로 훈련하면 속도와 정확도 면에서 매우 우수한 성능을 자랑한다. YOLO-v3와 비교할 때 가장 큰 차이점은 네트워크 구조를 감지하고 조정하는 몇 가지 추가 기술이다. 이 방법을 통해 AP의 성능은 이전 모델에 비해 10%, FPS는 12% 향상되어 YOLOv4에서는 Bag of Freebies(BoF)와 Bag of Special(BoS) 기술을 추가하여 정확도를 높였다. BoF는 데이터 증대, 손실 함수, 정규화 등 학습에 관여하는 요소로 훈련 비용을 높여 정확도를 높이는 방법을 말한다. BoS는 주로 후처리 및 추론 비용만 증가시켜 정확도를 높이는 기술을 포함하여 아키텍처 관점에서 기술이며 YOLOv4는 이전 버전에서 사용되었던 darknet-53에서 CSPDarknet을 활용하여 처리 속도를 높였다. CSPDarknet은 매우

무거운 추론 비용을 완화하고 정확도 손실을 최소화할 수 있는 교차 단계 부분 네트워크 구조를 제안하였다. 입력된 feature map을 두 부분으로 나눈 후 작업에 참여하지 않고 뒤에서 한 부분을 병합하여 이를 기반으로 추론 비용, 메모리 비용 등을 줄일 수 있다. 학습의 관점에서는 기울기 흐름을 나누어 학습에 좋은 영향을 미치기 때문에 정확도의 손실이 작다고 주장한다.



[그림 2-1] YOLO-v4 아키텍처

[그림2-1] YOLO-v4 아키텍처 구성이다. CSPDarknet 53이 있는 백본, Path Augmented Network가 있는 목 및 헤드로 구성되어있다. 백본은 입력 이미지에서 특징 맵을 추출한다. Neck은 백본과 헤드 사이에 위치하는 최근에 사용된 구조가

사용된다. Neck의 다양한 단계에서 특징을 수집하는 데 사용된다. 몇 가지 상향식, 하향식 경로를 사용하여 구축되며 헤드는 개체의 범주와 경계 상자를 예측한다.


## 2.2 Vision Transformer

자연어 처리 주로 사용되는 알고리즘이지만 최근들어 이미지 처리 학습에도 준수한 성능을 보여주는 모델로 사용되고 있다. DETR(End-to-End Object Detection with Transformers)는 decoder 를 통해서 단 한번의 패스로 고정된 개수인  $N$  개의 예측을 반환합니다. 이 때,  $N$  은 이미지내에 전형적인 이미지 객체 개수보다 훨씬 커야한다. 학습에서의 주된 어려움은, 학습하고자 하는 데이터 원본 또는 실제 값에 관련해 예측된 객체에 점수를 부여하는 데 있다(예를 들어, class, position, size). 여기서 손실률은 다중객체 관점에서 ground-truth 와 예측값 간에 이상적인 이분매칭을 생성하고, 그 후 객체 단위에서의 손실을 최적화합니다. 첫번째 과정으로,  $y$  를 set of object(객체 집합)의 ground truth 라 하고,  $\hat{y}=\{\hat{y}_i\}_{i=1}^N$  을 set of  $N$  예측값이라 하자. 보통  $N$  을 넉넉하게 설정하기 때문에,  $y$  는  $\phi$ (no object)로 패딩된  $N$  size 집합이라고 볼 수 있다. 그러면,  $N$  개의 ground truth 집합과  $N$  개의 prediction 집합 사이의 이분매칭을 찾기 위해서, 낮은 값을 갖는  $N$  개의 요소에 대한 순열을 탐색한다. 즉,  $L_{\text{match}}(y_i, \hat{y}_{\sigma(i)})$  를 ground truth  $y_i$  와 index  $\sigma(i)$  를 갖는 예측값  $\hat{y}_{\sigma(i)}$  사이의 pair-wise matching cost(양방매칭 비용)라 할 때, 아래와 같은 permutation(순열)을 찾을 수 있게 된다.

$$\hat{\sigma} = \arg \min_{\sigma \in \mathfrak{S}_N} \sum_i^N \mathcal{L}_{\text{match}}(y_i, \hat{y}_{\sigma(i)}) \quad \hat{\sigma} = \arg \min_{\sigma \in \mathfrak{S}_N} \sum_i^N \mathcal{L}_{\text{match}}(y_i, \hat{y}_{\sigma(i)})$$

Matching cost 는 class prediction 과 predicted  $\leftrightarrow$  ground truth boxes 간 similarity 두 가지 모두를 고려한다. ground truth set 의 각 요소  $i$  관점에서 살펴보자. 이 때,  $c_i$  를 target class label 이라하고,  $b_i \in [0,1]^4$  를 ground truth box 의 중심좌표 와 높이, 너비 에 해당하는 좌표라 할 때,  $y_i=(c_i, b_i)$  처럼 나타낼 수

있다. 트랜스포머는 attention 기반이기 때문에 permutation-invariant 하다. 즉, 순서를 무시한다는 것이다. 때문에, 순서를 부여하기 위해 fixed positional encoding 을 input of each attention layer 에 추가한다. (참고) x, y 축 따로  $d/2$  씩 해서 인코딩해서 concat 하는 식으로 positional encoding 을 해준다. [그림 2-2]는 Transformer 의 스탠다드 아키텍처를 따랐다고 개편된 Detr 아키텍처이다.



[그림2-2] Detr Architecture

다만 original 과의 차이점은 각 디코더 레이어에서  $N$  개의 객체를 평행하게 디코딩한다는 것이다. 디코더를 통과하게 되면  $N$  개의 오브젝트가 평행하게 나오는데, 이 때 디코더의 입력으로 들어가는 것은 object 쿼리이다.

디코더 역시 입력 벡터의 요소의 순서와 상관없이 같은 출력을 생성하기 때문에 일종의 포지셔널 인코딩이 필요하다. 여기서 object 쿼리가 포지셔널 인코딩 역할을 한다. 이 쿼리는 학습의 대상이 되며 each attention layer 의 인풋으로 추가된다. 이것들은 개별적으로 FFN(Feed Neural Network)을 지나 박스 좌표, 클래스 라벨로 디코드된다. End-to-End Vision Transformer 알고리즘을 사용하여 안전모 객체탐지를 하는 모델은 제안한다. Detr 알고리즘에 특성은 CNN 알고리즘에 비해 즉각 예측으로 아주 단순하게 만들어져 이용하기 편리하다. 하지만 Transformer 특성상 학습하는데 굉장히 많은 시간이 필요하고 작은 객체 탐지에 성능이 저조하여 아직까진 본 연구에서 사용하기 적합하지 못하다.

## 2.3 기존 헬멧 탐지 모델 연구

때문에 안전 헬멧을 감지하는 작업은 지난 몇 년 동안 진행되었다. 안전모 감지는 주로 헬멧의 색상과 모양 등 헬멧의 뛰어난 특징을 감지하려고 했다.

감시 카메라를 통해 안전모를 착용한 사람을 감지하려고 했다. 그들은 수정된 허프 변환에 기반한 원/원호 검출 방법을 적용하였으며 감시 카메라로 촬영한 물체를 원호/원 안에 배치하고 기하학적 특징을 사용하여 안전 헬멧이 원호 안에 있는지 여부를 감지했다. 타 연구에서는 잘 알려진 인간 탐지 알고리즘인 HOG(Histogram of Oriented Gradient) 접근 방식을 사용하여 건설 작업자를 탐지하였으며 작업자가 착용하는 안전모의 특징을 추출하기 위해 컬러와 함께 Circle Hough Transform(CHT)을 사용했다. 또한 색상 모델을 사용하여 피부색을 통해 사람의 얼굴을 감지하여 안전 헬멧을 찾으려고 했다. 이 목표를 달성하기 위해 웨이블릿 변환을 사용하여 이미지를 전처리하고 안전 헬멧의 특징을 추출했다. 타 논문 피부색 검출을 통해 얼굴 영역을 찾고, 얼굴 영역을 획득하여 얼굴 위의 영역 이미지를 획득할 수 있었다. 또한 모멘트를 사용하여 특징을 추출하고 신경망과 SVM(Support Vector Machine)을 사용하여 분류했다. DPM(Deformable Part Model)을 통한 안전모 알고리즘의 목적. 이 모델에서 SVM을 사용하여 안전 헬멧을 분류하고 감지하는 알고리즘을 훈련했다.

YOLO-v4는 우리 사회의 다양한 분야에서 사용될 수 있으며 Yu J. 및 Zhang W. YOLO-v4 네트워크를 재구축하여 개선된 YOLO-v4 기반 안면 마스크 착용 감지 알고리즘을 사용하였다. Li et al. Vibe 배경 모델링 알고리즘을 통해 변전소에서 움직이는 물체를 감지하는 알고리즘을 통해 획득한 모션 객체 분할을 통해 실시간 인간 분류 프레임워크인 C4로 처리했다. C4를 통해 작업자를 높은 정확도와 처리 속도로 감지할 수 있었고 데이터를 사용하여 작업자의 머리를 찾고 색상 변환과 색상

기능을 사용하였다.

## 제3장 ISR-Yolov4를 활용한 실시간 객체 탐지 모델

### 3.1 헬멧 탐지 모델 구조

Input, Backbone 네트워크, Neck 네트워크, 헤드로 구분하여 본 논문에서 제안하는 소형 물체 검출 알고리즘을 사용하였다. 작은 물체를 추출하기 위해 입력 부분에 이미지 초해상도 처리를 수행한 후, 척추 부분은 이미지에서 작은 물체의 특징을 추출하는 데 사용하고 목 부분은 다중 스케일 특징에 사용하고 머리 부분은 Multi-scale features 지도를 사용하여 탐지한 다음 대상을 지정하고 위치를 결정한다. 작은 물체 감지의 주요 구조는 크게 4가지로 구분되는데, 이 구조를 척추, 목, 예측 부분을 개선하여 안전모 감지에 사용하였다. 알고리즘의 구조는 [그림 3-1]에 나와 있다.




그림 3-1 제안된 모델 구조

## 3.2 Image Super Resolution(ISR)

입력 부분은 ISR 처리를 수행하고, Backbone 이미지에서 작은 개체 특징을 추출하고, 목은 다중 스케일 특징을 융합하고, 예측은 다중 스케일 특징 맵을 사용하여 탐지를 지정한다. ISR 모듈이 Input에 추가되어 작은 표적의 로컬 세부 정보를 캡처하여 추출된 주요 콘텐츠는 이미지 향상을 위한 텍스처 추출과 이미지 식별을 위한 텍스처 추출을 사용했다. 백본 네트워크에서 Darknet53의 블록은 DenseNet의 각 계층과 동일한 방식으로 연결된다. 더욱 세밀한 네트워크 구조를 훈련하고 다양한 수준에서 학습된 기능 맵의 뉴런 모드를 위해 이 특정 연관성을 사용한다. 이 연결 방법으로 더 적은 수의 매개변수로 인해 과적합을 피할 수 있다. Neck은 다른 네트워크보다 더 적은 매개변수가 필요하고 과적합을 방지한다. Neck 부분은 PAnet 구조와 원래의 공간 피라미드 풀링 구조를 유지함으로 PAnet은 이 부분의 기능적 융합 모듈로 서로 다른 스케일 기능을 결합한 것이다. 공간 피라미드 모듈은 네트워크의 사용 가능한 필드를 증폭하기 위해 Neck에 추가된 구조다. Head로 YOLO-v4를 선택하였고, 작은 물체 검출의 정확도를 향상시키기 위해 전경 및 배경 균형 손실, 신뢰도 손실, 경계 상자 회귀로 인한 분류 손실에 손실 함수를 추가하였다. ISR 모듈 Input은 [그림 3-2]와 같이 콘텐츠와 로컬 텍스처의 두 부분으로 나뉜다. 먼저 콘텐츠 추출기로 추출한 다음 하위 픽셀 컨볼루션을 사용하여 콘텐츠 기능의 해상도를 두 배로 늘려 텍스처 추출기는 기본 및 참조 및 기능에서 신뢰할 수 있는 로컬 텍스처를 선택하고 참조 기능을 잡음 제거하면서 두 부분을 출력 터미널에 연결한다. P0은 이미지 슈퍼 레졸루션 모듈의 출력을 나타내며 다음과 같이 정의된다.

$$P_0 = R_l(I_0 \otimes R_c(I_1) \uparrow_{2 \times}) + R_c(I_1) \uparrow_{2 \times}$$


$I_0$ 은 로컬 텍스처 입력,  $I_1$ 은 콘텐츠 입력,  $R_l()$ 은 텍스처 추출 요소,  $R_c()$ 는 콘텐츠 추출 요소,  $\uparrow_{2 \times}$ 는 하위 픽셀 컨볼루션을 통한 2차 업스케일링을 나타내고, (X)는 다음을 나타낸다. 기능 스티칭 콘텐츠 추출기와 텍스처 추출기는 모두 잔여 블록으로 구성되며 기본 방법은 하위 픽셀 컨볼루션을 사용하여 기본 입력의 콘텐츠 기능에 대한 공간 해상도 처리를 수행한다. 너비와 높이의 픽셀 값을 증가시키기 위해 서브픽셀 컨볼루션은 채널 차원의 픽셀을 전송한다. 컨볼루션 레이어에서 생성된 특징은 다음과 같이 표현된다.

$$F \in R^{H \times W \times C \cdot r^2}$$

서브픽셀 컨볼루션의 픽셀 서플링 작업은 특징을  $rH \times rW \times C$ 로 재배열한다. 이 수식은 다음과 같이 정의된다.

$$PS_{\square}(F)_{x,y,z} = F_{\lfloor x/\lambda \rfloor, \lfloor y/\lambda \rfloor, C \cdot \lambda \cdot \text{mod}(y,\lambda) + C \cdot \text{mod}(x,\lambda) + z}$$


출력 기능의 픽셀을 나타내는 부분은  $PS(F)_{x;y;z}$ 이고 픽셀 서플링 연산  $PS()$  후의 좌표( $x; y; z$ )  $r$ 은 업스케일링 인자이다. ISR은  $PS(F)_{x;y;z}$ 는 출력 특징 픽셀을 나타낸다. ISR 모듈에서 D2를 사용하여 공간의 크기를 두 배로 늘렸고 D 및 콘텐츠 입력 A는 텍스처 영역에서 텍스처 추출로 전송되어 작은 개체의 추출을 매우 안정적으로 만든다. 요소별로 텍스처와 콘텐츠를 추가하면 출력이 입력 및 참조의 의미 체계 및 로컬 정보를 통합할 수 있으며 따라서 P()는 피쳐 D와 레벨 I1에서 선택한 신뢰할 수 있는 텍스처와 비슷한 의미를 갖는다.



[그림 3-2] ISR 모듈 프레임워크

### 3.3 Backbone Network

나머지 모듈을 YOLO-v4에 추가하여 매개변수를 줄이고 네트워크 학습 능력을 향상시켰다. Yu와 Zjang은 CSPNDarkNet53을 안면 마스크 착용 감지 모듈로 사용했으며, 나머지 단위는 다음과 같이 표현할 수 있다. 우선,  $1 \times 1$  컨볼루션이 있었다. 그런 다음  $3 \times 3$  컨볼루션을 진행한 후 모듈의 두 출력에 가중치를 추가하여, 차원 정보를 유지하며 목표는 피쳐 레이어의 정보를 증가시키는 것이다. 이번 실험 헬멧 탐지에서는 다른 방법을 사용하였다. 각 추가 잔여 네트워크의 첫 번째 및 마지막 CSP 연결을 유지함으로써 경계 간은 모든 두 인접 추가 블록 사이에 추가되어 그라디언트의 교차층 흐름 분리를 제공하고 순방향 전파를 가속화하는 동시에 깊이 반복되는 추가 블록을 반복한다. 그 사이에 발생하는 낭비되고 사라지는 자원을 줄이게 한다. 이미지 피쳐 레이어 세트 CSPDarkNet53이 입력된 후 더 나은 정보를 얻기 위해 컨볼루션 다운샘플링을 계속 수행한다. 따라서 백본 끝에 있는 3개의 레이어가 최고의 의미 정보와 구성을 가지며 마지막 3개의 레이어가 SPPNet에 대한 입력으로 선택된다. CSPDarkNet53의 네트워크 구조는 [그림 3-3]과 같다.




[그림 3-3] CSPDarknet 네트워크 구조

본 논문에서는 성능 향상을 위해 YOLO-v4의 CSPDarknet53을 CSP1-N 모듈로 변경하여 YOLO-v4는 중복 네트워크를 사용하여 알고리즘에 대한 컴퓨팅 성능 요구 사항을 낮추지만 메모리 요구 사항은 CSP1-N 모듈로 부분적으로 개선된다. 그림 3-3 CSPDarkNet53와 비교하면 다음 식과 같이 H-Swish 기능을 사용하는 업스트림 네트워크이다.

$$h-swish(x) = x \frac{ReLU(6(x+3))}{6}$$


Swish 함수는 ReLU 함수에 비해 시그모이드 함수를 포함하기 때문에 Swish 함수는 더 높은 계산 성능 요구 사항을 갖지만 더 높은 정확도가 나온다. 또한 H-Swish 기능을 통해 모델 런타임 감소 기울기 오차 감쇠를 줄일 수 있었고 전 작업에서 감소되었다. CSP1-N에서 이미지 블록의 입력 레이어를 분할하여 모델 객체 감지 정확도 성능을 향상시켜 다음 [그림 3-4]와 같이 컨볼루션 연산의 잔차 예지로 사용된다.



[그림 3-4] CSP1-N Network Structure

### 3.4 Neck Network

컨볼루션 신경망은 입력 이미지의 크기가 동일해야 함으로 기존의 컨볼루션 신경망에서는 truncation 및 warping 연산을 통해 고정된 입력 값을 얻는다. YOLOv4가 SPPNet을 통해 고정 입력 크기에 대한 수요를 개선하기 위해 다중 스케일 로컬 기능을 사용하는 연구도 있다. PANnet 구조에 CSP2-N 모듈을 추가하여 전체 기능 정보와 다중 스케일을 결합함으로써 모델 성능 정확도와 기능을 향상시켰다. YOLO-v4의 Neck 네트워크는 common convolution 연산을 채택하고 있으며, CSPNet은 우수한 학습능력, 컴퓨팅 병목 현상, 메모리 비용 절감 등의 장점이 있다. YOLO-v4를 기반으로 CSPNet 네트워크 모듈을 개선함으로써 네트워크 기능 융합 기능을 더욱 강화할 수 있다. 그러나 본 논문에서는 Neck의 연결성을 최적화하기 위해 정보 전달 네트워크에 CBL-Resunit 구조를 추가하고 주요 역할은 ResNet의 교차 계층 연결 속성을 사용하여 정보 처리가 다음을 통해 분산되도록 하는 것이다. SPPNet 네트워크는 bottom-to-top deep positioning 기능을 결합하여 목에 있는 다른 백본 레이어 간의 기능적 융합을 구성하고, PANet에서는 이러한 융합 연산을 통해 세부 기능에 대한 top-to-bottom 계산 방법을 구현한다. 이 부분은 예측 네트워크에 더 유용한 기능을 제공한다. CSP2-N 네트워크는 [그림 3-5]에 나와 있다.



[그림 3-5] CSPN-2 네트워크 구조

### 3.5 이미지 타일링 기법

사람의 눈과 마찬가지로 컴퓨터 비전 모델 또한 거리가 떨어지면 작은 물체를 감지하는 데 어려움을 겪었다. 이 문제점을 극복하기 위해 이미지를 타일링하여 확대하는 방법을 진행 하였다. 타일링을 사용하면 이미지의 더 작은 부분을 확대하고 더 정확한 학습 및 추론을 수행하기 위해 각 이미지를 더 작고 관리하기 쉬운 타일로 나눌수 있다. 여기서 훈련 방법은 추론중에 타일링하고 사용된 타일의 크기가 비슷한지 확인해야한다. 타일링을 사용하여 학습한 다음 타일링 되지 않은 이미지에 대한 추론을 시도하면 모델이 잘못된 크기의 객체를 감지 할려고 시도하는 경우에 옳 잘못된 탐지가 발생되기 때문이다. [그림3-6] 과 같이 이미지를 2x2 로 잘라서 이미지의 작은 이미지를 확대하여 작은 물체 감지의 성능을 높일 수 있었다.



[그림 3-6] 타일링 기법

타일링은 이렇게 작은 물체 감지 및 장거리 사진의 대한 탐지능력을 높일수 있지만 몇가지 주의해야될 단점이 있다. 너무 많은 타일로 나누게 되면 학습시간이

길어지고 타일링 단계에서 감지할 개체가 반으로 잘려서 정확도를 떨어뜨리는 영향이 있다. 또한 추론하는 속도가 늦어지므로 가장 해당 모델에 적합한 타일링 횟수를 찾아야한다. 2x2 4등분으로 나누어 학습했을 때 [표 4-2]에서 가장 우수한 성능을 보였다.

[표 3-1] 타일링 그리드에 따른 모델 정확도

| 타일링 그리드 | mAP   | Precision | Recall |
|---------|-------|-----------|--------|
| 1x1     | 87.4% | 85.1%     | 90.2%  |
| 2x2     | 93.1% | 92.9%     | 91.6%  |
| 3x3     | 85.7% | 84.8%     | 88.7%  |
| 4x4     | 82.1% | 81.7%     | 87.4%  |
| 5x5     | 80.5% | 79.2%     | 82.3%  |
| 6x6     | 75.9% | 74.5%     | 81.1%  |

타일링 작업을 하고 난뒤에 반드시 이미지에 헬멧이 없는 조각난 이미지들이 생기게 됩니다. 이럴경우에 추가적으로 헬멧 탐지 되지 않는 이미지들을 필터링해주는 작업을 통해 탐지 모델 정확도 성능을 올릴수 있었다. 이미지 추론중 타일링으로 학습된 모델을 배포하면 추론중에도 타일링이 발생한다. 학습된 헬멧 탐지 값을 사용하여 추론 중에 타일을 생성한 뒤, 전체 이미지와 해당 타일이 모델을 통과하고 두 이미지가 병합되어 다음 그림과 같이 최종 예측 이미지가 출력된다. 아래는 타일링 프로세스 관한 그림이다.



[그림 3-7] 타일링 프로세스

학습과 추론중 모두 타일링하고 사용된 타일 크기가 비슷한지 확인하는 것이 중요합니다. 타일링을 사용하여 학습한뒤 다음 타일링 되지 않은 이미지에 대한 추론을 시도하면 모델이 잘못된 크기의 개체를 감지하려고 시도하는 경우 False Positive(거짓 양성)의 객체 탐지가 발생하기 때문이다. 다음 그림에서 학습중에서만 타일링 기법을 사용하면 객체 인식에 오류가 많이 나타나는 것을 확인할 수 있다.



[그림3-8] 학습중에만 이미지 타일링 헬멧 객체 탐지 결과



[그림3-9] Training 및 Inference 이미지 타일링 헬멧 객체 탐지 결과

본 연구에서는 전체적으로 ISR모듈과 타일링 기법을 같이 적용시켰다. 이유는 ISR 모듈로 인해 객체 이미지 측정 정확도를 높일 수 있었다. 다음 [표 3-2]는 ISR 모듈만 적용했을 때 성능 지표다.

| ISR 모듈  | mAP   | Frame time |
|---------|-------|------------|
| SSD     | 0.799 | 1041.6ms   |
| YOLO-v3 | 0.802 | 1025.72ms  |
| YOLO-v4 | 0.817 | 1025.56ms  |
| YOLO-v5 | 0.860 | 1025.00ms  |
| YOLO-v6 | 0.881 | 1023.92ms  |

[표 3-2] ISR 모듈만 적용

ISR 모듈만 적용을 하게되면 정확도 측면에서 객체를 인식하기 충분한 성능이 나오나 이미지 추론 속도 측면에서 실시간으로 객체를 검출하기엔 다소 느린 면이 있다. 추론속도의 시간은 해상도측면에서 용량이 커지기 때문에 추론하는 속도가 그만큼 올라가는 현상이다. 그렇기 때문에 실시간으로 객체 검출에 사용하기 위해 타일링 기법을 사용해야한다. 다음은 YOLO 알고리즘에 2x2 타일링 기법을 적용하였다. 다음 [표 3-3]은 YOLO모델에 2x2 타일링 기법을 적용한 성능 지표다.

| YOLO 모델 | mAP   | Frame time |
|---------|-------|------------|
| YOLO-v3 | 0.602 | 25.72ms    |
| YOLO-v4 | 0.617 | 25.56ms    |
| YOLO-v5 | 0.660 | 25.01ms    |
| YOLO-v6 | 0.681 | 24.27ms    |


[표 3-3] YOLO 모델에 2x2 타일링 기법 적용

YOLO모델에 2x2 타일링 기법을 적용했을 때 추론시간 측면에서 상당히 높은

속도를 보여주고 있지만, 정확도 측면에서는 객체를 검출하는데 낮은 성능을 보여주었다. 그리하여 ISR 모듈과 타일링 기법을 동시에 적용해야한다. 타일링 기법을 적용했을 때 옴로에 대비해서 추론시 결과적으로 4개의 이미지를 각각 계산함으로 추론 시간이 늘어날 것으로 보이나 오히려 더 빠른 시간에 객체를 검출할수 있었다. 이유는 이미지를 4등분으로 나누면 이미지가 컨볼루션 망을 통과 할 때 분할로 진행하여 그만큼 이미지의 용량이 줄어들기 때문에 객체 추론 속도를 오히려 줄일 수 있고, 작은 객체에 대해서 이미지가 확대되는 효과가 있기 때문에 탐지 능력 또한 증가 하게 된다.

### 3.6 ISR-Yolov4 네트워크 구조

개선된 네트워크 모델은 그림 3-8과 같이 백본에서 특이점 추출 네트워크에서 3개의 CSP1-N 네트워크를 사용하며 각 CSP1-N 네트워크에는 N개의 나머지 유닛이 있다. 본 논문에서는 계산 요구 사항을 줄이기 위해 N개의 잔여 단위 조합으로 잔여 모듈을 직렬로 연결한다. 이 방법은  $1 \times 1$ ,  $3 \times 3$ ,  $1 \times 1$  컨볼루션 모듈로 2개의  $3 \times 3$  컨볼루션 연산을 수정할 수 있다. 첫 번째  $1 \times 1$  컨볼루션 레이어는 채널 수를 약 50%로 줄이면서 매개변수를 줄일 수 있습니다.  $3 \times 3$  컨볼루션 레이어는 특징 추출을 개선하고 잔여 채널 수를 재사용할 수 있다. 마지막으로  $1 \times 1$  컨볼루션 연산은  $3 \times 3$  컨볼루션 레이어의 출력을 복구하므로 대체 컨볼루션 연산이 효율적이고 특징 추출에 대한 정확도가 높으며 컴퓨터 성능 요구 사항을 줄일 수 있다.



[그림 3-10] ISR-YOLOv4 네트워크

## 제4장 실험 및 평가

### 4.1 실험 환경

이 연구의 모든 실험과 평가는 52GB RAM과 NVIDIA Tesla V100 16GB GPU에서 수행되었다. 객체 탐지 모델은 PyTorch 버전 1.10.0 + cu111을 사용하여 구축되었다. 학습 하이퍼파라미터는 300 epoch, batch size 8, learning rate  $10^{-5}$ , patch size 64였다. H/W 및 S/W 사양은 [표4-1]과 같다.

[표 4-1] 하드웨어 및 소프트웨어 환경

| H/W & S/W 환경 | 사양                     |
|--------------|------------------------|
| 시스템 환경       | 윈도우 11                 |
| CPU          | Intel Core i9 11900k   |
| Memory       | 52GB                   |
| GPU          | Nvidia Tesla V100 16GB |
| OS 타입        | 64-bit                 |
| CUDA         | version 11.0           |
| Pytorch      | version 1.5.1          |

본 논문에서 건설 현장에 다양한 시나리오의 헬멧 및 머리 이미지를 객관적으로 수집하여 모델 성능을 향상시키기 위해 물체 감지 문제를 고려했다. 헬멧 데이터 셋은 AI HUB 사이트에서 사용하였고, 전문 데이터 수집 업체에서 헬멧 모델 탐지 연구를 위해 수집된 데이터이기 때문에 본 연구에 가장 적합한 데이터를 찾을 수 있었다. 데이터 세트는 제조 환경과 실외 및 실내 요소를 충분히 고려하여 학습

하였다. 또한 모델 정밀도를 높이기 위해 다양한 소형 헬멧과 머리 이미지를 수집했으며 모델 알고리즘은 제조 환경뿐만 아니라 다양한 환경에서도 우수한 헬멧 검출 능력을 갖는다. 이 실험에서 각 그림의 머리는 각 레이블이다. 라벨 0은 안전모가 없는 "머리"이다. 레이블 1은 "헬멧", 안전모가 있는 머리, 즉 두 가지 범주의 감지를 나타낸다. [표 4-2]는 실험에 사용된 데이터 세트를 이다.

[표 4-2] 데이터 Set

| 분류 | Train 세트 | Test 세트 | Validation 세트 |
|----|----------|---------|---------------|
| 헬멧 | 7185     | 1532    | 512           |
| 머리 | 7025     | 1512    | 645           |

## 4.2 성능 지표

정밀도(P) 및 재현율(R) 곡선은 다양한 확률 임계값에 대한 정밀도(y축) 및 재현율(x축)의 함수로 참조되었다. 단일 변수와의 비교 및 다른 모델의 비교를 통해 정밀도와 재현율 간의 관계를 보다 총체적으로 이해할 수 있었다. 정밀도와 재현율은 다음과 같이 표현된다.

$$\begin{aligned} precision &= \frac{TP}{TP+FP} \\ recall &= \frac{TP}{TP+FN} \end{aligned}$$

TP()는 각 클래스에 대해 참양성을 정확하게 예측한 개인의 수로 정의되고 FP()는 내용이 다르게 예측된 개인의 수로 정의된다. 가음성(FN)은 모델이 예측하지 못한 정답의 수를 나타낸다. 물체 감지 연구는 일반적으로 곡선이 오른쪽 상단 모서리에 가까울수록 모델의 성능이 더 우수함을 보여준다. 전체 클래스의 Average Precision의 평균값인 Mean Average Precision은 다음과 같다.

$$Mean\ Average\ Precision = \frac{\sum_{i=1}^n Average\ Precision_i}{n}$$

n은 클래스의 개수이고, 각 클래스의 평균 정밀도는 정밀도-재현율 곡선 아래의 면적에 해당한다. 일반적으로 평균 정밀도가 높을수록 모델의 성능이 향상된다. 그러나 정밀도와 재현율 사이에는 절충점이 있으므로 탐지 능력 평가 메트릭 F-Measure는 다음과 같이 표현된다.

$$F_{\alpha} = \frac{(\alpha^2 + 1) \times P \times R}{\alpha^2(P + R)}$$

정밀도 비율과 재현율 평균은 다음과 같은 경우 식 8에서 F1으로 표시된다.

$$F_1 = \frac{2 \times P \times R}{(P + R)}$$

### 4.3 모델의 초매개변수

모든 실험은 다음 매개변수 epoch 300, 배치 크기 8 및 입력 이미지 크기 416 x 416 x 3에서 수행되었고 매개변수 조정 프로세스는 [표 4-3]에 나와 있다.

[표 4-3] 모델의 초매개변수

| 초매개변수 | 설정 값    |
|-------|---------|
| 폭     | 416     |
| 높이    | 416     |
| 채널    | 3       |
| 운동량   | 0.949   |
| Decay | 0.0005  |
| 각도    | 0       |
| 채도    | 1.5     |
| 노출    | 1.5     |
| 색조    | 0.1     |
| 학습률   | 0.00261 |
| 최대 배치 | 500,500 |

## 4.4 모델크기 및 학습 시간

모델 크기는 YOLO-v4 및 YOLO-v3의 경우 0.371 및 0.387이다. 동일한 조건에서 이 모델의 훈련 시간은 2.945시간으로 실험에서 YOLO 및 SSD 모델 중 가장 낮았고 YOLO-v6이 그 뒤를 이었다. Faster R-CNN은 RPN(Region Proposal Network)을 사용하여  $W \times H \times K$  후보 영역을 생성하여 모델을 적용하기 때문에 많은 컴퓨팅 성능이 필요하다. 한편, Faster R-CNN은 ROI pooling layer를 동일하게 유지하면서 full connection layer를 ROI pooling layer에서 사용하며, 네트워크에서 많은 iteration이 발생하여 [표 4-4]와 같이 모델의 학습 속도를 감소시킨다.

[표 4-4] 매개변수, 모델 크기 및 훈련 시간에서 다양한 모델 비교

| 모델         | 파라미터    | 모델 크기  | 학습 시간    |
|------------|---------|--------|----------|
| SSD        | 25.4 MB | 92 MB  | 3.452 H  |
| YOLO-v3    | 59.9 MB | 198 MB | 7.951 H  |
| YOLO-v4    | 62.5 MB | 201 MB | 9.267 H  |
| YOLO-v5    | 65.3 MB | 213 MB | 10.152 H |
| YOLO-v6    | 47.3 MB | 132 MB | 3.012 H  |
| ISR-YOLOv4 | 46.8 MB | 120 MB | 2.945 H  |

## 4.5 Inference 시간

본 논문에서는 테스트의 실시간 성능을 검증하였다. FPS(초당 프레임 수)는 모델의 실시간 성능을 측정하는 데 자주 사용되므로 [표 4-5]에서 FPS가 높을수록 실시간 성능이 우수함을 알 수 있다.

[표 4-5] Inference 시간과 실시간 탐지 성능 비교.

| 모델         | Inference Time |
|------------|----------------|
| SSD        | 10.4 ms        |
| YOLO-v3    | 6.37 ms        |
| YOLO-v4    | 6.30 ms        |
| YOLO-v5    | 6.24 fps       |
| YOLO-v6    | 5.95 fps       |
| ISR-YOLOv4 | 6.05 fps       |

## 4.6 평균 정밀도

[표 4-6]에서 볼 수 있듯이 제안된 모델의 평균 정밀도(mAP)는 Faster R-CNN보다 0.15, SSD보다 0.118, YOLO-v3보다 0.107, YOLO-v4보다 0.078, YOLO-v5보다 0.039 높고, YOLO-v6보다 0.003 더 높은 mAP를 보여준다.

[표 4-6] 모델 평균 정밀도 비교

| 모델         | 헬멧 AP | 머리 AP | mAP   |
|------------|-------|-------|-------|
| SSD        | 0.819 | 0.811 | 0.815 |
| YOLO-v3    | 0.824 | 0.828 | 0.826 |
| YOLO-v4    | 0.858 | 0.853 | 0.855 |
| YOLO-v5    | 0.891 | 0.898 | 0.894 |
| YOLO-v6    | 0.928 | 0.932 | 0.930 |
| ISR-YOLOv4 | 0.932 | 0.935 | 0.933 |

이 실험을 통해 우리는 우리 모델이 포괄적인 성능에서 YOLO-v4 및 SSD를 능가하고 최근에 출시된 YOLO-v6을 약간 능가한다는 것을 보여준다. 그러나 추론 시간은 YOLO-v6보다 길었다. Faster R-CNN의 mAP는 YOLO-v4, YOLO-v3보다 높지만 FPS가 가장 낮아 정확도가 높지만 실시간 탐지로 사용하기 어려운 것이 two-step 알고리즘의 공통적인 특징이다.

#### 4.7 모델 이미지 샘플



[그림 4-1] 헬멧 착용자와 미착용자 샘플

[그림 4-1]과 같이 제안 모델은 안전모 착용자와 미착용자를 실시간으로 분류하여 감지했습니다.



[그림 4-2] 소형 물체 탐지 샘플.

[그림 4-2]와 같이 제안된 모델은 장거리에서 미착용 안전모 탐지의 우수한 성능을 보였다.



[그림 4-3] 드론각도 탐지 모델 샘플.

[그림 4-3]과 같이 제안된 모델은 원거리에서도 안전모를 잘 감지하였다.



[그림 4-4] 헬멧 착용자 미착용자 분류 샘플

[그림 4-4]와 같이 제안된 모델은 사람이 많더라도 안전모를 착용한 사람과 착용하지 않는 사람을 탐지하여 분류하였다.



[그림 4-5] 수직 앵글 샘플 모델

[그림 4-5]와 같이 제안된 모델은 장애물이 많은 분주한 건설현장에서 안전모를 탐지하였다.



[그림 4-6] 소방관 헬멧 탐지 샘플 모델

[그림 4-6]과 같이 제안된 모델은 장거리 소방관 헬멧 착용 여부를 탐지하였다.



[그림 4-7] 실내 탐지 모델 샘플

[그림 4-7]과 같이 제안된 모델은 다른 분야에서도 헬멧 미착용자를 잘 감지하였다.

## 제5장 결 론

### 5.1 연구 결과

본 논문에서 헬멧 탐지 문제를 해결하기 위해 YOLO-v4를 기반으로 개선된 네트워크를 제안한다. 객체 탐지 알고리즘에 대한 비교 연구를 통해 효율성 및 정확도가 높은 모델을 검증하였다. ISR 모듈을 통해 저해상도 사진의 해상도를 높여 물체 감지 정확도 성능을 향상시켰다. 또한 CSP-1N 모듈 특징 추출을 통해 백본 특징 추출 네트워크를 개선하였으며, Neck 부분에는 CSP2-N을 사용하여 모델이 병렬 프로세스 학습을 처리할 수 있도록 하였다. 다음으로 모델 학습 비선형 함수를 개선하기 위해 H-Swish 활성화 함수를 추가했다.

실험 결과, 본 논문에서 제안한 방법은 기존 연구된 알고리즘에 비해 안전모 탐지에서 최고의 성능 감지 정확도를 보였고 모델 학습 리소스 및 모델 복잡성에 대한 모델의 요구 사항을 줄여 모델을 중형 장치에 배포하고 헬멧 착용 식별이 필요한 다른 산업에서 사용할 수 있습니다.

## 5.2 향후 연구 계획

향후 연구에서는 본 연구에서는 여전히 탐지가 어려운 표본이나 누락 및 위양성 사례에 대한 특징 추출이 미흡한 문제가 있으므로, 개인정보 보호법에 따라 많은 양의 데이터를 수집하기 어렵웠다. 또한 헬멧의 종류를 식별할 수 없는 점도 여전히 존재한다. 따라서 다음 연구 단계에서는 데이터 세트를 헬멧 유형으로 확장하여 수집하고 현재 작업에서 모델에 대한 추가 개선을 얻어 더 많은 객체 감지 작업으로 확장되어야 한다.

## 참 고 문 헌

- [1] Di Benedetto, M.; Carrara, F.; Meloni, E.; Amato, G.; Falchi, F.; Gennaro, C. Learning accurate personal protective equipment detection from virtual worlds. *Multimed. Tools Appl.* 2021, 80, 23241 - 23253.
- [2] Li, Y.; Wei, H.; Han, Z.; Huang, J.; Wang, W. Deep learning-based safety helmet detection in engineering management based on convolutional neural networks. *Adv. Civ. Eng.* 2020, 3
- [3] Cabahug, R.R. A survey on the implementation of safety standards of on-going construction projects in Cagayan de Oro City, Philippines. *Mindanao J. Sci. Technol.* 2014, 12.
- [4] Wang, B.; Li, W.J.; Tang, H. Improved YOLOv3 algorithm and its application in helmet detection. *Comput. Eng. Appl.* 2020, 56, 33 - 40.
- [5] Han, K.; Yang, Q.; Huang, Z. A two-stage fall recognition algorithm based on human posture features. *Sensors* 2020, 20, 6966.
- [6] Han, K.; Peng, J.; Yang, Q.; Tian, W. An end-to-end dehazing Siamese region proposal network for high robustness object tracking. *IEEE Access* 2021, 9, 91983 - 91994.
- [7] Weigang, L.L.; da Silva, N.C. A study of parallel neural networks. In *Proceedings of the IJCNN'99 Proceedings of the International Joint Conference on Neural Networks, Proceedings (Cat. No. 99CH36339)*, Washington, DC, USA, 10 - 16 July 1999; Volume 2, pp. 1113 - 1116.
- [8] Miller, E.G.; Matsakis, N.E.; Viola, P.A. Learning from one example through shared densities on transforms. In *Proceedings of the IEEE Conference on*

- Computer Vision and Pattern Recognition. CVPR 2000 (Cat. No. PR00662), Hilton Head, SC, USA, 15 June 2000; Volume 1, pp. 464 - 471.
- [9] Li, M.; Zhang, Z.; Lei, L.; Wang, X.; Guo, X. Agricultural greenhouses detection in high-resolution satellite images based on convolutional neural networks: Comparison of faster R-CNN, YOLO v3 and SSD. *Sensors* 2020, 20, 4938.
  - [10] Girshick, R.; Donahue, J.; Darrell, T.; Malik, J. Rich feature hierarchies for accurate object detection and semantic segmentation. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, Columbus, OH, USA, 23 - 28 June 2014.
  - [11] Girshick, R. Fast r-cnn. In *Proceedings of the IEEE International Conference on Computer Vision*, Santiago, Chile, 7 - 13 December 2015.
  - [12] Ren, S.; He, K.; Girshick, R.; Sun, J. Faster r-cnn: Towards real-time object detection with region proposal networks. *Adv. Neural Inf. Process. Syst.* 2015, 28.
  - [13] Liu, W.; Anguelov, D.; Erhan, D.; Szegedy, C.; Reed, S.; Fu, C.; Berg, A.C. Ssd: Single Shot Multibox Detector; *European conference on computer vision*; Springer: Cham, Switzerland, 2016.
  - [14] Redmon, J.; Divvala, S.; Girshick, R.; Farhadi, A. You only look once: Unified, real-time object detection. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, Las Vegas, NV, USA, 27 - 30 June 2016.
  - [15] Redmon, J.; Farhadi, A. YOLO9000: Better, faster, stronger. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, Honolulu, HI, USA, 21 - 26 July 2017.

- [16] Zhou, Y.; Xue, H.; Jiang, X.; Sun, H.; Yanyan, X. Low-resolution safety helmet image recognition combining local binary pattern with statistical features. *Comput. Syst. Appl.* 2015, 24, 211 - 215
- [17] Mneymneh, B.E.; Abbas, M.; Khoury, H. Automated hardhat detection for construction safety applications. *Procedia Eng.* 2017, 196, 895 - 902.
- [18] Park, C.; Lee, D.; Khan, N. An analysis on safety risk judgment patterns towards computer vision based construction safety management. In *Creative Construction e-Conference 2020*; Budapest University of Technology and Economics: Budapest, Hungary, 2020.
- [19] Fang, Q.; Li, H.; Luo, X.; Ding, L.; Luo, H.; Rose, T.M.; An, W. Detecting non-hardhat-use by a deep learning method from far-field surveillance videos. *Autom. Constr.* 2018, 85, 1 - 9.
- [20] Gu, Y.; Xu, S.; Wang, Y.; Shi, L. An advanced deep learning approach for safety helmet wearing detection. In *Proceedings of the 2019 International Conference on Internet of Things (iThings) and IEEE Green Computing and Communications (GreenCom) and IEEE Cyber, Physical and Social Computing (CPSCom) and IEEE Smart Data (SmartData)*, Atlanta, GA, USA, 14 - 17 July 2019.
- [21] Shi, H.; Chen, X.; Yang, Y. Safety helmet wearing detection method of improved YOLOv3. *Comput. Eng. Appl.* 2019, 55, 213 - 220. 22. Wu, F.; Jin, G.; Gao, M.; He, Z.; Yang, Y. Helmet detection based on improved YOLO-V3 deep model. In *Proceedings of the 2019 IEEE 16th International Conference on Networking, Sensing and Control (ICNSC)*, Banff, AB, Canada, 9 - 11 May 2019.
- [23] Huang, G.; Liu, Z.; Van Der Maaten, L.; Weinberger, K.Q. Densely

connected convolutional networks. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, Honolulu, HI, USA, 21 - 26 July 2017.

- [24] Shen, J.; Xiong, X.; Li, Y.; He, W.; Li, P.; Zheng, X. Detecting safety helmet wearing on construction sites with bounding-box regression and deep transfer learning. *Comput. Civ. Infrastruct. Eng.* 2021, 36, 180-196.
- [25] Li, J.; Wang, Y.; Wang, C.; Tai, Y.; Qian, J.; Yang, J.; Wang, C.; Li, J.; Huang, F. DSFD: Dual shot face detector. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, Long Beach, CA, USA, 16 - 17 June 2019.
- [26] Howard, A.G.; Zhu, M.; Chen, B.; Kalenichenko, D.; Wang, W.; Wey, T.; Andreetto, M.; Adam, H. Mobilenets: Efficient convolutional neural networks for mobile vision applications. *arXiv* 2017, arXiv:1704.04861.
- [27] Soviany, P.; Ionescu, R.T. Optimizing the trade-off between single-stage and two-stage deep object detectors using image difficulty prediction. In Proceedings of the 2018 20th International Symposium on Symbolic and Numeric Algorithms for Scientific Computing (SYNASC), Timisoara, Romania, 20 - 23 September 2018.
- [28] Bochkovskiy, A.; Wang, C.Y.; Liao, H.Y.M. Yolov4: Optimal speed and accuracy of object detection. *arXiv* 2020, arXiv:2004.10934.
- [29] Redmon, J.; Farhadi, A. Yolov3: An incremental improvement. *arXiv* 2018, arXiv:1804.02767.
- [30] Wen, C.Y.; Chiu, S.H.; Liaw, J.J.; Lu, C.P. The safety helmet detection for ATM's surveillance system via the modified Hough transform. In Proceedings of the IEEE 37th Annual 2003 International Carnahan

- Conference on Security Technology, Taipei, Taiwan, 14 - 16 October 2003.
- [31] Rubaiyat, A.H.; Toma, T.T.; Kalantari-Kh, M.; Rahman, S.A.; Chen, L.; Ye, Y.; Pan, C.S. Automatic detection of helmet uses for construction safety. In Proceedings of the 2016 IEEE/WIC/ACM International Conference on Web Intelligence Workshops (WIW), Omaha, NE, USA, 13 - 16 October 2016.
- [32] Hu, T.; Wang, X. Analysis and design of helmet recognition system based on wavelet transform and neural network. *Softw. Guide* 2006, 23, 37 - 39.
- [33] Liu, X.-H.; Xi-Ning, Y.E. Skin color detection and hu moments in helmet recognition research. *Huadong Ligong Da Xue Xue Bao (Nat. Sci. Version)* 2014, 3, 365 - 370.
- [34] Li, K.; Zhao, X.; Bian, J.; Tan, M. Automatic safety helmet wearing detection. *arXiv* 2018, arXiv:1802.00264.
- [35] Yu, J.; Zhang, W. Face mask wearing detection algorithm based on improved YOLO-v4. *Sensors* 2021, 21, 3263.
- [36] Barnich, O.; Van Droogenbroeck, M. ViBe: A universal background subtraction algorithm for video sequences. *IEEE Trans. Image Process.* 2010, 20, 1709 - 1724.
- [37] Wang, Z.Z.; Xie, K.; Zhang, X.Y.; Chen, H.Q.; Wen, C.; He, J.B. Small-Object Detection Based on YOLO and Dense Block via Image Super-Resolution. *IEEE Access* 2021, 9, 56416 - 56429.
- [38] Avenash, R.; Viswanath, P. Semantic Segmentation of Satellite Images using a Modified CNN with Hard-Swish Activation Function. In Proceedings of the VISIGRAPP (4: VISAPP), Prague, Czech Republic, 25 - 27 February 2019.

- [39] Ramachandran, P.; Zoph, B.; Le, Q.V. Searching for activation functions. arXiv 2017, arXiv:1710.05941.
- [40] Howard, A.; Sandler, M.; Chu, G.; Chen, L.C.; Chen, B.; Tan, M.; Wang, W.; Zhu, Y.; Pang, R.; Vasudevan, V.; et al. Searching for mobilenetv3. In Proceedings of the IEEE/CVF International Conference on Computer Vision, Seoul, Korea, 27 - 28 October 2019.
- [41] Purkait, P.; Zhao, C.; Zach, C. SPP-Net: Deep absolute pose regression with synthetic views. arXiv 2017, arXiv:1712.03452.

## ABSTRACT

# Real-Time ISR-YOLOv4 Based Small Object Detection for SafeShop Floor in Smart Factories

Byungjin Ku

Department of Smart Factory Convergence

Sungkyunkwan University

Wearing a hard hat can effectively improve the safety of workers on a construction site. However, workers often take off their helmets because they have a weak sense of safety and are uncomfortable, and this action poses a large danger. Workers not wearing hard hats are more likely to be injured in accidents such as human falls and vertical falls. Therefore, the detection of wearing a helmet is an important step in the safety management of a construction site, and it is urgent to detect helmets quickly and accurately. However, the existing manual monitor is labor intensive, and it is difficult to popularize the method of mounting the sensor on the helmet. Thus, in this paper, we propose an AI method to detect the wearing of a helmet with satisfactory accuracy with a high detection rate. Our method selects based on YOLO v4 and adds an image super resolution (ISR) module at the end of the input. Afterward, the image resolution is increased, and the noise in the image

is removed. Then, dense blocks are used to replace residual blocks in the backbone network using the CSPDarknet53 framework to reduce unnecessary computation and reduce the number of network structure parameters. The neck then uses a combination of SPPnet and PANnet to take full advantage of the small target's capabilities in the image. We add foreground and background balance loss functions to the YOLOv4 loss function part to solve the image background and foreground imbalance problem. Experiments performed using self-constructed datasets show that the proposed method has more efficacy than the currently available small target detection methods. Finally, our model achieves an average precision of 93.3%, a 7.8% increase over the original algorithm, and it takes only 3.0 ms to detect an image at 416 x 416.

**Keywords:** Small-object detection; helmet detection; image super resolution; YOLO; YOLOv4; safety

碩士學位請求論文

산업 안전 예방을 위한  
기반 시설 간 객체 탐지  
모델의 이미지 처리  
관한

2  
0  
2  
3

具  
炳  
辰