



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

碩士學位 請求論文

指導教授 朴 承 熙

객체 감지 기술을 활용한 반도체 건설 현장의 작업자 사고 예방 기술 연구

成均館大學校 一般大學院

半導體디스플레이工學科

韓 東 燁

碩士學位 請求論文

指導教授 朴 承 熙

객체 감지 기술을 활용한 반도체 건설
현장의 작업자 사고 예방 기술 연구

A Study on the Technology to Prevent Accidents of
Semiconductor Workers Using Object Detection

成均館大學校 一般大學院

半導體디스플레이工學科

韓 東 燁

碩士學位 請求論文

指導教授 朴 承 熙

객체 감지 기술을 활용한 반도체 건설
현장의 작업자 사고 예방 기술 연구

A Study on the Technology to Prevent Accidents of
Semiconductor Workers Using Object Detection
이 論文을 工學 碩士學位請求論文으로 提出합니다.

2023 年 10 月 日

成均館大學校 一般大學院

半導體디스플레이工學科

韓 東 燁

이 論文을 韓東燁의 工學
碩士學位 論文으로 認定함.

2023 年 12 月 日

審査委員長

審査委員

審査委員

목차

제1장 연구 배경 및 목표	1
제2장 선행 연구	4
1. 반도체 현장의 안전 관리 현황	4
2. 건설 현장의 안전 관리 현황	6
1) 안전 보호구 감지 기술	6
2) 위험 구역 출입 방지 기술	8
3) 중장비 충돌 방지 기술	9
3. 반도체 현장의 특징 분석	10
제3장 이론적 배경	13
1. 객체 감지 기술의 개념	13
2. 객체 감지 기술 알고리즘의 구조	17
1) One-Stage Detector 구조	17
2) Two-Stage Detector 구조	19
3. 객체 감지 기술의 주요 알고리즘	21
1) YOLO	21
2) SSD	23
3) RetinaNet	25
4) R-CNN	27
5) Faster R-CNN	29

제4장 연구 방법 및 결과	32
1. 반도체 현장 작업자 사고 예방 컨셉	32
2. 데이터 셋 구축 및 객체 감지 알고리즘 선정	34
3. 알고리즘 적용 결과 및 분석	38
제5장 결론	42
참고 문헌	44

표 목차

표 1-1. 중대 재해 원인 분석 결과	3
표 4-1. Faster R-CNN 과 Faster R-CNN ConvNeXt 비교	37
표 4-2. Faster R-CNN ConvNeXt 학습 결과	39

그림 목차

그림 1-1. AI 반도체 시장 규모 전망	1
그림 1-2. 국내 반도체 메가 클러스터 구축 계획	2
그림 2-1. 반도체 현장 안전 관리 현황.....	4
그림 2-2. 작업자 안전모 착용 상태 감지 시스템	7
그림 2-3. 위험 구역 출입 방지 시스템	8
그림 2-4. 중장비 출동 방지 시스템	9
그림 2-5. 작업자 방진복 착용 모습 예시	10
그림 2-6. 임직원의 방진복 착용 모습	11
그림 2-7. 협력사 작업자의 방진복 착용 모습	11
그림 2-8. 안전 관리자의 방진복 착용 모습	12
그림 3-1. 객체 감지 기술 예시	13
그림 3-2. CNN 모델 구조	14
그림 3-3. 다중 출력 신경망 구조	16
그림 3-4. One-Stage Detector 구조	17

그림 3-5. 클래스 불균형 예시	18
그림 3-6. Two-Stage Detector 구조	19
그림 3-7. YOLO 객체 감지 과정	21
그림 3-8. Multi-Scale Feature Layer	23
그림 3-9. Non-Max Suppression 예시	24
그림 3-10. RetinaNet 동작 원리	25
그림 3-11. R-CNN 구조	27
그림 3-12. Faster R-CNN 구조	29
그림 3-13. Faster R-CNN 동작 원리	30
그림 4-1. 작업자 사고 예방 컨셉 도식화	33
그림 4-2. 데이터 셋 구성	34
그림 4-3. 학습 데이터 증강	35
그림 4-4. Faster R-CNN ConvNeXt 구조	36
그림 4-5. 안전모 착용 상태 감지 및 알람 기능 구현 결과	40
그림 4-6. 안전 관리자 존재 여부 확인 및 알람 기능 구현 결과	40
그림 4-7. Prompt Engineering 기반 자연어 생성 결과	41

논문요약

객체 감지 기술을 활용한 반도체 건설 현장의 작업자 사고 예방 기술 연구

최근 Chat GPT의 등장을 중심으로 전 세계 AI 시장의 규모가 급격히 성장함에 따라, AI 기술의 핵심 요소인 반도체의 수요가 전 세계적으로 빠르게 성장하고 있다. 이에 한국, 미국을 비롯한 세계 각국에서 반도체 시장 점유율을 늘리고자 생산 라인 증설 공사를 지속적으로 진행하고 있다. 그 결과, 국내에서도 반도체 라인 건설 현장의 작업자 수가 점차 증가하고 있는 추세이다.

이러한 상황 속에서, 우리나라의 경우 2022년도부터 50인 이상의 규모를 가진 전 사업장을 대상으로 중대재해처벌법이 시행됨에 따라 작업자의 안전 관리에 대한 경각심이 더욱 커진 상황이다. 그러나 2021년과 2022년의 중대재해로 인한 사망자 현황을 비교해 본 결과, 21년 사망자 수는 248명, 22년 사망자 수는 256명으로, 중대재해처벌법 시행에도 불구하고 중대재해로 인한 사망자 수는 오히려 증가했다는 사실을 확인하였다. 이는 법적 제재 강화만으로는 작업자의 사고 예방 효과를 기대하기 어렵다는 사실을 반증하는 결과이다. 따라서 실질적인 작업자 사고 예방 효과를 얻기 위해서는 법적 제재 강화보다 실제 현장에 도움을 줄 수 있는 시스템의 확보가 반드시 필요하다.

이어서 중대재해의 발생 원인을 분석한 결과, ‘근로자 부주의 및 안전 규칙 미준수’가 76.5%으로 가장 큰 비중을 차지하였는데, 이는 반도체 라인 현장에서도 매우 중요하게 관리해야 하는 사항이다. 특히 반도체 라인의 경우, 무색·무취의 화학 물질 누출 등 대형 사고를 유발할 수 있는 다양한 사고 위험 요소들이 존재하기 때문에, 본 연구에서는 반도체 건설 현장의 작업자를 대상으로 사고 예방 기술에 대한 연구를 진행하였다.

반도체 라인의 안전 관리는 주로 ‘안전 관리자’에 의해 이루어진다. 하지만 최근 건설 산업 현장의 경우, 대형 건설사들을 중심으로 ‘객체 감지 기술’을 활용한 사고 예방 시스템을 도입하고 그 적용 범위를 점차 넓혀가고 있는 추세이다. 해당 연구에서는 건설 산업 현장에서 적용되고 있는 ‘객체 감지 기술’을 활용하되, 반도체 현장의 특징인 ‘각자의 역할에 따라 서로 다른 색상의 방진복 착용’을 결합하여 반도체 라인 건설 현장 작업자에게 특화된 사고 예방 기술을 연구하였다.

해당 연구의 방향은 중대 재해의 주요 원인인 ‘근로자 부주의 및 안전 규칙 미준수’에 의한 사고 발생을 줄이는 것을 목표로 설정하여, ‘작업자의 안전모 착용 상태’와 ‘작업 현장 내 안전 관리자 존재 여부’를 확인하고, 이상 발생 시 알람을 표시하는 기능을 구상하였다. 이를 위해 먼저 반도체 라인 건설 현장의 영상 데이터를 수집하였고, 학습 성능 향상을 목적으로 데이터 증강을 통해 학습 데이터의 수를 늘렸다. 이후 안전모 착용 상태와 방진복 색상에 대한 Class 생성하였으며, 모든 영상 데이터를 대상으로 Bounding Box 형태의 라벨링을 진행하였다. 라벨링 완료 후에는 객체 감지 알고리즘 중 높은 정확도와 속도 및 안정성을 가진 ‘Faster R-CNN ConvNeXt’ 알고리즘을 활용하여 총 100회의 학습을 진행하였다. 학습 결과, 50회 이상 학습 시 정확도 및 재현성 성능이 포화되는 것을 확인하였으며, 안전모 미착용 및 안전 관리자의 부재 상황에 대한 감지 및 알람 표시 기능도 정상적으로 구현되는 것을 확인하였다.

향후 해당 연구 결과는 반도체 현장의 ‘작업자의 안전모 미착용’ 및 ‘비인가 작업’ 등 안전 관리 사각지대를 해소함으로써 사고를 예방하는 데에 도움을 줄 수 있을 것으로 예상된다. 장기적으로는, 현재 사람을 중심으로 이루어지고 있는 반도체 라인의 안전 관리의 주체를 사람에서 시스템으로 전환함으로써, 반도체 라인의 개수와 면적 증가에 따른 안전 관리 인력 부족 현상과 기술적 한계를 극복하는데 기반이 될 수 있을 것으로 기대한다.

주제어: 반도체 건설 현장, 객체 감지 기술, 방진복, 안전 관리 강화, 사고 예방

제1장 연구 배경 및 목표

최근 Chat GPT의 등장을 중심으로 전 세계 AI 시장의 규모가 급격히 성장함에 따라, AI 기술의 핵심 요소인 반도체에 대한 수요가 전 세계적으로 빠르게 성장하고 있다. 이에 한국과 미국을 비롯한 세계 각국에서 반도체 시장 점유율 경쟁에서 앞서 나가기 위하여, 기술 연구 개발에 대한 투자와 생산 라인 증설 공사를 지속적으로 진행하고 있는 상황이다. 미국의 기술 자문 회사인 Gartner의 조사 결과에 따르면, **그림 1-1**과 같이 2030년까지 AI 반도체 시장의 규모는 2020년 대비 3.6배 이상 증가할 것으로 전망하고 있다.




그림 1-1. AI 반도체 시장 규모 전망

특히 우리나라의 경우, 디지털 뉴딜 사업을 통한 국가 경쟁력 향상을 위하여 ‘반도체 기술력 초격차 확보 및 신격차 창출’이라는 목표를 앞세워 반도체 산업을 적극 육성하고 있다. 최근에는 평택 및 용인을 대상으로 **그림 1-2**와 같이 세계

최대 규모의 반도체 클러스터를 구축하는 계획을 발표하였으며, 평택에서는 이미 반도체 라인 신설 공사가 진행되고 있다. 평택의 경우, 반도체 라인 건설 현장에 매일 2만 명 이상의 작업자가 작업을 하고 있는 상황이다.



그림 1-2. 국내 반도체 메가 클러스터 구축 계획

이처럼 국내 반도체 라인 건설 현장 및 작업자 수가 지속 증가하고 있는 상황 속에서, 2022년 1월부터 50인 이상의 규모를 가진 전 사업장을 대상으로 중대재해처벌법이 시행됨에 따라 작업자의 안전 관리에 대한 경각심이 점차 고조되고 있다. 그러나 중대재해처벌법 시행 이후 고용노동부에서 발표한 ‘2022년 재해 조사 대상 사망 사고 발생 주요 현황’ 자료에 따르면, 21년의 사망자 수는 248명, 22년의 사망자 수는 256명으로, 중대재해처벌법 시행 이후 사망자 수가 오히려 증가했다는 사실을 확인할 수 있다. 이는 곧 중대재해처벌법의 시행

만으로는 작업자의 사고 예방 효과를 기대하기 어렵다는 사실을 반증하는 결과이다. 이어서 중대 재해의 발생 원인을 분석한 결과, 표 1-1과 같이 중대 재해의 76.5%가 ‘근로자 부주의 및 안전 규칙 미준수’에 의한 것임을 확인할 수 있었다.

표 1-1. 중대 재해 원인 분석 결과

중대 재해 원인	비율 (%)
근로자 부주의 및 안전 규칙 미준수	76.5
작업 SOP 부재	9.0
전문 인력 부족	8.2
시설 노후화	6.0

이러한 분석 결과는 현장의 작업자에 대한 안전 관리가 여전히 잘 이루어지지 않는다는 의미로 해석할 수 있다. 따라서 지금 현장에는 법적 제재 강화보다는 실제로 현장에서 근무하는 수많은 작업자들의 생명을 보호할 수 있는 사고 예방 시스템 도입이 반드시 필요한 상황이다. 게다가 반도체 건설 현장은 무색·무취의 화학 물질 등 대형 사고를 유발할 수 있는 다양한 잠재 위험 요소(hazard)들이 산재하고 있다. 이에 본 연구에서는 반도체 건설 현장 작업자들의 사고를 예방하기 위한 기술을 연구하였다.

제2장 선행 연구

1. 반도체 현장의 안전 관리 현황

반도체 현장의 안전 관리는 그림 2-1과 같이 크게 6가지(안전 교육, 사전 심의, 작업 관리 감독, 현장 점검, 시설 유지 및 보수 작업, 화학 물질 농도 상시 모니터링)으로 구분할 수 있다.




그림 2-1. 반도체 현장 안전 관리 현황

첫째로 안전 교육의 경우 모든 인원이 분기 별 1회 안전 교육을 의무적으로 받고 있으며, 안전 교육을 이수하지 못하는 인원에게는 라인 내 출입을 제한하고 있다. 또한 사고 발생에 대한 대피 훈련을 실시하며, 사고 상황을 가정한 비상소집을 통하여 각 부서가 실제 사고 상황과 동일한 대응 절차대로 움직이도록 연습하는 모의 사고 대응 훈련을 수행하기도 한다. 둘째, 사전 심의 과정의 경우 매주 위험 작업에 대한 허가 심의를 진행하는데, 각 작업의 책임자는 해당 작업에 대한 위험 요인을 사전 검토하여 안전 대책을 수립 후 심의를 받는다. 또한 작업일 하루 전에는 반드시 현장의 상태를 미리 확인하여 변경점이 있는지 검토해야 한다. 셋째 작업 관리 감독의 경우 각 작업 영역의 안전 관리자를 중심으로 진행되는데,

반도체 현장의 특성상 화학 물질 노출 위험성이 존재하기 때문에 모든 인원이 반드시 안전 보호구를 착용해야 한다. 적절한 보호구를 착용하지 않는 경우 페널티를 받게 된다. 그리고 작업 현장에는 사전 심의 서류, MSDS, 표준 작업 지침서(SOP) 등 필수 서류들을 반드시 비치해야 하며, 작업자가 표준 작업 지침서에 맞게 작업을 수행하는지 관리 및 감독한다. 넷째 현장 점검의 경우 매주 각 팀 별로 현장 점검을 실시하고 있으며, 안전 담당 부서의 직원들은 매일 현장을 순찰하며 사고 위험 요인을 수색한다. 그리고 현장의 모든 근무자들은 잠재 위험 요인 발굴 활동을 통해 현장의 불합리 개선 활동을 하고 있다. 다섯째 시설 유지 및 보수의 경우 노후화된 시설물에 대한 점검 및 보수를 상시로 수행하는 데, 라인 가동 중에는 시설물 보수에 한계가 있기 때문에 연 1~2회는 라인 가동을 멈추고 overhaul을 수행한다. 여기서 Overhaul 이란 최상위 개념의 정기 보전 활동을 의미한다. 마지막으로 화학 물질 농도 상시 모니터링을 진행하는데, 반도체 라인은 공정 특성상 다량의 Gas, Chemical을 사용하기 때문에 라인 내 화학 물질 농도 관리가 반드시 필요하다. 이에 라인 내 수많은 화학 물질 농도 감지 센서들이 설치되어 있으며, 농도가 허용치를 초과할 경우 즉각 알람이 발생하여 개선 활동이 이루어진다. 하지만 아직 반도체 현장의 안전 관리는 주로 시스템이 아닌 사람에 의해 진행되고 있기 때문에, 안전 관리 인력 부족 문제와 기술적 한계가 존재한다.

2. 건설 현장의 안전 관리 현황

1) 안전 보호구 감지 기술

최근 대형 건설사들의 경우, 일부 건설 현장을 대상으로 객체 감지 기술을 활용한 사고 예방 시스템을 개발 및 적용하고 있다(Jaekyu Lee, 2023; 강태욱, 2021). 그중 현재 가장 많이 사용되고 있는 기술은 작업자의 ‘안전모 착용 상태를 감지’하는 기술이다. 건설 현장에는 추락, 낙하물 등 다양한 사고 위험이 존재하므로 개인 보호구 착용이 의무화되어 있는데, 특히 두부 손상의 경우 생명과 직결될 수 있기 때문에 안전모 착용에 대한 중요성이 매우 높다. 따라서 현장의 안전 관리자는 순회 점검을 통해 작업자들의 안전모 착용을 독려하고 착용 상태를 직접 점검한다. 하지만 안전 관리자의 교육과 지시만으로 작업자의 안전모 착용을 100% 독려하는 것은 어렵기 때문에, 건설 현장의 CCTV 영상과 객체 감지 기술을 활용하여 안전모 착용 상태를 실시간으로 점검한다(김명호, 2019).

그림 2-2와 같이 CCTV 영상을 통해 작업자의 안전모 착용 상태를 감지하고, 만일 안전모를 착용하지 않은 경우 화면 상단에 주의 문구를 발생시키는 형태로 기술 개발 및 적용 진행되고 있다. 객체 감지 기술을 활용한 안전 관리 기술 수준은 지속적으로 고도화되고 있으며, 그에 따라 기술의 적용 범위도 점차 확대되고 있는 추세이다.




그림 2-2. 작업자 안전모 착용 상태 감지 시스템

2) 위험 구역 출입 방지 기술

건설 현장에는 작업자의 안전을 위하여 출입을 금지하는 구역이 존재한다. 2003년 한국산업안전보건공단(KOSHA)의 사망사고 보고서에 따르면, 건설 작업자의 사망 사고 원인 중 약 20%는 작업자가 현장 내에서 이동하는 중에 발생한다는 연구 결과가 있다(Hyunsoo Kim, 2016). 따라서 작업자가 위험 구역에 출입하는 것을 제한하는 것이 매우 중요한데, 이러한 구역들은 주로 사각지대이거나 고도가 높은 등 효율적인 안전 관리가 어려운 장소인 경우가 많다. 이에 최근 건설 현장에서는 객체 감지 기술을 활용한 위험 구역 출입 감지 기술을 개발하고 있는데, **그림 2-3**과 같이 작업 현장 내 위험 구역을 별도로 설정한 후 해당 구간에 작업자가 출입하는 경우에 작업자 및 안전 관리자에게 경고를 보내어 출입을 제한시키는 형태이다(Trevor Slaton, 2020; Xinyu Mei, 2023).



그림 2-3. 위험 구역 출입 방지 시스템

3) 중장비 충돌 방지 기술

건설 현장은 작업의 특성상 대형 중장비들과 수많은 작업자가 공존한다. 그 결과 깔림, 충돌, 끼임 등 수많은 사고의 위험성이 존재하며, 작업자의 사망 확률이 다른 분야의 작업자들보다 약 5배 높다(Meghana Nain, 2021). 특히 중장비의 경우 운전자 입장에서 시야 사각지대가 많이 존재하기 때문에, 작업자가 중장비와 일정 거리를 유지하지 않을 경우 사고 위험성이 매우 높다. 21년 안전보건공단 중대사고 이슈 리포트에 따르면 매년 60~70건의 사망사고가 중장비로 인해 발생하는데, 이는 건설 현장 사망 사고의 15.8%를 차지한다. 이러한 사고 위험성을 개선하기 위하여 그림 2-4와 같이 객체 감지 기술을 활용하여 중장비를 기준으로 거리에 따른 객체 존재 여부를 실시간으로 확인하고, 특정 거리 이내에 작업자가 인식될 경우 사고 위험성이 높다고 판단하여 알람을 발생시킨다.




그림 2-4. 중장비 충돌 방지 시스템

3. 반도체 현장의 특징 분석

반도체 라인 건설 현장의 경우, 일반 건설 현장들과는 달리 반도체 현장만의 특징이 존재한다. 바로 모든 작업자가 방진복을 착용한다는 점이다. 반도체 제작은 실리콘 웨이퍼 위에 여러 가지 공정을 거쳐 패턴을 그리는 형태로 진행되는데, 하나의 웨이퍼 위에 최대한 많은 반도체 chip을 생산하기 위하여 공정 미세화를 위한 기술의 발전이 지속되고 있다. 그 결과 최근에는 선폭이 3nm 수준인 반도체 chip을 생산하고 있으며, 25년에는 2nm chip을 양산하는 것을 목표로 하고 있는 상황이다. 특히 반도체 제품의 양산 과정에서 웨이퍼가 파티클에 노출될 경우 제품의 수율에 치명적인 타격을 받게 되는데, 공정 미세화가 진행될수록 그 피해 규모는 더욱 커진다. 따라서 반도체 라인 내 파티클 제어에 대한 중요성은 점차 커지고 있다. 이에 반도체 라인은 늘 class 1000 이하(파티클 1,000개/ft³ 이하)의 클린룸 환경을 유지해야 한다. 따라서 라인 내 모든 근무자들은 작업자에 의한 파티클의 발생을 방지하기 위하여 **그림 2-5**와 같이 방진복을 착용하는데, 눈을 제외한 모든 부분이 가려져 작업자 식별이 어렵다는 문제점이 존재한다.




그림 2-5. 작업자 방진복 착용 모습 예시

이러한 문제점을 보완하기 위하여 각자의 역할에 따라 서로 다른 색상의 방진복을 착용한다. 역할 별 방진복 색상은 각 회사마다 다르나, 본 연구에서는 임직원의 경우 **그림 2-6**과 같이 하얀색 방진복을 착용하고, 협력사 작업자는 **그림 2-7**과 같이 파란색 방진복을 착용하고, 안전 관리자는 **그림 2-8**과 같이 주황색 방진복을 착용하는 경우를 적용하였다.



그림 2-6. 임직원의 방진복 착용 모습



그림 2-7. 협력사 작업자의 방진복 착용 모습



그림 2-8. 안전 관리자의 방진복 착용 모습

이처럼 반도체 현장에서는 각자의 역할에 따라 서로 다른 색상의 방진복을 착용함으로써 작업자 식별이 어렵다는 문제점을 보완하고 있다. 해당 연구에서는 일반 건설 현장의 안전 관리에 활용되고 있는 객체 감지 기술을 활용하되, 이와 같은 반도체 현장만의 특징을 결합하여 반도체 라인 건설 현장에 특화된 작업자 사고 예방 기술을 확보하고자 연구를 진행하였다.

제3장 이론적 배경

1. 객체 감지 기술의 개념

객체 감지 기술(Object Detection)은 그림 3-1과 같이 이미지나 영상 데이터의 특정 개체를 인식하고 그 위치를 식별하는 기술이다. 해당 기술을 통해 사람, 동물, 자동차 등과 같은 다양한 객체를 감지할 수 있다.




그림 3-1. 객체 감지 기술 예시

객체를 감지하는 과정은 주로 딥러닝(Deep learning) 알고리즘을 사용하여 수행되는데, 대표적으로 CNN(Convolutional Neural Network) 알고리즘이 있다. CNN은 이미지 내에서 특징을 추출하는 데 높은 성능을 가진 신경망 구조로서, 이미지를 입력받은 후 해당 이미지에 CNN 모델을 적용하여 이미지 내에서 객체를 감지하는 과정을 거친다. 이는 그림 3-2와 같이 표현할 수 있다(Saily Shah, 2022).




그림 3-2. CNN 모델 구조 [7]

객체를 감지하는 과정은 크게 두 가지 작업을 통해 이루어진다. 하나는 입력 이미지에서 객체의 위치를 찾는 작업이고, 또 다른 작업은 찾은 객체를 적절한 클래스에 할당하는 작업이다(Ohay Angah, 2020). 객체의 클래스란 사람, 자동차, 자전거 등 해당 객체가 속하는 범주 또는 유형을 의미한다.

객체 위치 결정 작업에서 사용되는 기술은 경계 박스 추정(Bounding Box Regression)이 있다. 경계 박스 추정이란 객체의 위치를 정확하게 추정하는

과정으로서, 주로 RPN(Region Proposal Network)을 통해 생성된 앵커 박스(Anchor Box)와 정답 경계 박스 사이의 차이를 예측한다. 이는 식 (1)~(4)로 표현이 가능하다.

$$t_x = (x - x_a)/w_a \quad (1)$$

$$t_y = (y - y_a)/h_a \quad (2)$$

$$t_w = \log(w - w_a) \quad (3)$$

$$t_h = \log(h - h_a) \quad (4)$$

x, y, w, h 는 정답 경계 박스의 좌표와 크기를 나타내고, x_a, y_a, w_a, h_a 는 해당 앵커 박스의 좌표와 크기를 나타내며, t_x, t_y, t_w, t_h 는 예측된 bbox와 정답 경계 박스 사이의 차이를 나타내는 값이다. 이렇게 예측된 bbox를 사용하여 입력 이미지 내의 객체를 보다 정확하게 감지할 수 있게 된다. 즉, 경계 박스 추정 과정의 목적은 객체 감지의 정확도와 신뢰성을 높이는 것이다.

다음으로 클래스 분류(Classification)는 객체를 적절한 클래스에 할당하기 위하여, 주어진 Bounding Box 내 존재하는 객체가 어떤 클래스에 속하는지 분류하는 과정이다. 클래스 분류는 입력 이미지의 각 bbox마다 수행되는데, 이때 bbox를 RoI(Region on Interest)로 지정하여 CNN의 입력으로 사용한다. 여기서 RoI란 객체가 존재할 가능성이 높은 영역을 의미한다. CNN은 입력 이미지의 특징을 추출하고 이를 바탕으로 bbox 내의 객체의 클래스를 예측한다. 일반적으로 Softmax 함수를 사용하여 클래스 별 확률 값을 계산하는데, 입력 이미지의 각 bbox i에 대해 클래스 분류를 수행하는 과정은 식 (5)와 같이 도출할 수 있다.

$$p_{i,k} = \frac{\exp(s_{i,k})}{\sum_j \exp(s_{i,j})} \quad (5)$$

$s_{i,k}$ 는 RoI Pooling을 거친 CNN의 출력 벡터 중 k 번째 클래스에 대한 점수 (score)이며, $p_{i,k}$ 는 Softmax 함수를 통해 구한 $s_{i,k}$ 의 확률 값을 나타낸다. 이를 통해 bbox i 내의 객체가 k 번째 클래스에 속할 확률을 구할 수 있다.

이처럼 객체 감지 과정은 객체의 위치 결정과 클래스 분류 등 서로 다른 목적을 가진 다양한 작업들이 동시에 수행되어야 하기 때문에, 각 작업을 분리하여 수행하는 것이 유리하다(Chandrabhas Mishra, 2016). 따라서 객체 감지는 그림 3-3과 같이 주로 다중 출력 신경망(Multi-output neural network)을 사용하여 객체 위치 결정과 클래스 분류 작업을 별도의 출력층으로 분리하여 처리한다.




그림 3-3. 다중 출력 신경망 구조

2. 객체 감지 기술 알고리즘의 구조

1) One-Stage Detector 구조

One-Stage Detector 구조는 객체 감지 기술 알고리즘의 대표적인 구조로써 단일 신경망 Architecture로 구성되어 있으며, **그림 3-4**와 같이 입력 이미지에서 객체의 경계 박스 추정(Bounding Box Regression)과 클래스 추정(Classification) 작업을 동시에 수행한다. One-Stage Detector 구조를 가진 대표적인 알고리즘은 YOLO, SSD, RetinaNet 등이 있다.




그림 3-4. One-Stage Detector 구조

One-Stage Detector은 이미지를 입력으로 받은 다음 해당 이미지를 작은 영역으로 나눈다. 이후 각 영역에 대해 객체의 Bounding Box와 class를 예측하고,

예측한 객체의 위치와 class를 바탕으로 객체를 감지한다. One-Stage Detector 구조는 객체의 위치와 클래스를 한 번에 예측 및 학습하기 때문에 속도가 빠르고 메모리 사용량이 적다는 장점을 가진다. 하지만 객체 감지의 정확도가 낮은 편이고, 클래스 불균형 현상이 심하다는 단점이 존재한다.

클래스 불균형이란 그림 3-5와 같이 학습 이미지 속에서 찾고자 하는 객체보다 원치 않는 객체에 대한 감지가 더 쉬워서 발생하는 문제이다. 대부분의 영상 이미지에는 우리가 감지하고자 하는 객체보다 배경 부분이 훨씬 많은 공간을 차지하기 때문에, 배경을 감지하는 것이 훨씬 쉽다. 그 결과 배경의 객체들은 학습을 많이 하지 않더라도 상대적으로 더 많은 앵커 박스가 존재하게 된다. 이처럼 원하는 객체가 아닌 배경 영역의 객체를 Negative Example이라고 한다. 반대로 감지하고자 하는 객체는 Positive Example이라고 한다. 즉, Positive Example보다 Negative Example이 많은 현상을 클래스의 불균형이라고 한다.




그림 3-5. 클래스 불균형 예시

2) Two-Stage Detector 구조

Two-Stage Detector 구조는 그림 3-6과 같이 객체의 위치와 클래스를 예측하기 위하여 두 단계의 처리 과정을 거친다. 먼저 Region Proposal 단계를 통해 후보 영역을 생성한 후, Region Classification 단계를 통해 생성된 후보 영역을 분류 및 정제하여 최종 객체 감지까지 수행한다. Two-Stage Detector 구조를 가진 대표적인 알고리즘으로는 R-CNN, Faster R-CNN 등이 있다.




그림 3-6. Two-Stage Detector 구조

Two-Stage Detector 구조는 위치를 먼저 예측하고 그 위치를 바탕으로 객체의 클래스를 예측하는 작업을 나누어서 수행하기 때문에 상대적으로 객체 감지 속도가 느린 편이지만, 객체 감지 정확도가 더욱 높다는 장점이 있다. 또한 Two-

Stage Detector 구조의 경우 RPN 등 Region Proposal 단계를 통하여 입력된 이미지 속에서 객체가 있을만한 후보 영역들을 1차적으로 선별함으로써, One-Stage Detector 구조 대비 클래스 불균형 문제로부터 자유롭다는 장점도 존재한다. 따라서 구현하고자 하는 시스템의 목적에 따라 적절한 구조의 알고리즘을 선택해야 한다.

3. 객체 감지 기술의 주요 알고리즘

1) YOLO

YOLO(You Only Look Once)는 One-Stage Detector 구조를 기반으로 하며, 그림 3-7과 같이 입력 이미지를 그리드로 나누고 각 그리드 셀에서 Bounding Box와 클래스의 확률을 예측하여 객체를 감지하는 알고리즘이다.




그림 3-7. YOLO 객체 감지 과정

YOLO 알고리즘의 초기 버전은 Joseph Redmon에 의해 개발되었으며, 2015년 CVPR 학회에서 처음으로 소개된 이후 객체 감지 기술 분야에 범용적으로 사용되는 알고리즘으로 자리 잡았다. YOLO는 다른 객체 감지 알고리즘들과는 달리 한 번의 순전파(Forward pass)로 모든 객체의 클래스와 위치를 예측하기 때문에 빠른 객체 감지 속도를 가지며, 상대적으로 적은 bbox를 예측하기 때문에 false positive를 줄일 수 있다는 장점이 있다. 하지만 YOLO는 각 그리드 셀이 하나의 클래스만 가질 수 있다는 단점이 있어 작은 객체를 감지하는 능력이 상대적으로 낮은 편이며, 일반적이지 않은 형태나 중첩비를 가진 객체에 대하여 bbox의 위치가 정확하지 않은 경우가 많다는 한계점이 있다. 뿐만 아니라 YOLO는 실제 True값에 대해서도 True로 예측하는 비율이 낮아, 객체를 모두 감지하지 못하는 상황이 발생하기도 한다. 최근에는 다양한 개발자들에 의해 YOLO v8까지 출시되는 등 다양한 버전의 YOLO 알고리즘이 개발되고 있는데, 초창기 모델 대비 더 깊고 복잡한 Network Architecture와 더욱 발전된 Backbone 네트워크(Darknet-53)를 사용한다. 특히 YOLO v8은 객체의 중심을 직접 예측하는 Anchor-free detection 방법을 도입하여 Bounding Box 예측 수 자체를 줄여 동작 속도를 더욱 개선하였다.

2) SSD

SSD(Single Shot Detector)도 YOLO 와 마찬가지로 One-Stage Detector 구조를 가지는 객체 감지 알고리즘이다. One-Stage Detector 구조의 문제점은 Two-Stage Detector 구조 대비 객체 감지 정확도가 낮다는 것인데, 이러한 문제점을 개선하기 위하여 개발된 알고리즘이 SSD 이다. SSD 알고리즘은 크게 Multi-Scale Feature Layer 와 Anchor Box 로 구성된다. 먼저 Multi-Scale Feature Layer 는 다양한 크기의 객체들을 정확하게 감지할 수 있도록 객체의 다양한 크기에 대한 특징 맵을 생성한다. 즉, 서로 다른 크기의 특징 맵이 입력 이미지 내의 크기가 다른 객체들을 전담하여 감지하는 방식이다.

SSD 알고리즘의 구조는 일련의 Convolution layer 부터 시작되며, 이후 다양한 크기의 특징 맵을 생성할 수 있도록 하는 Multi-Scale Feature Layer 로 연결된다. 각각의 Multi-Scale Feature Layer 는 그림 3-8 과 같이 다양한 크기의 특징 맵과 앵커 박스(Anchor Box)를 통해 여러 스케일의 객체를 감지한다. 이때, Convolution 을 더 많이 거친 특징 맵일수록 이미지의 중심이 되는 객체를 잘 감지한다.




그림 3-8. Multi-Scale Feature Layer

앵커 박스는 Classification 과 경계 박스 추정을 수행하는 데, 이를 통해 생성된 Bounding Box 중 신뢰도가 높은 객체만 남기기 위하여 NMS(Non-Max Suppression) 후처리 기법을 사용한다. NMS 기법이란 객체를 보다 정확하게 예측할 수 있도록 도와주는 기술인데, **그림 3-9** 와 같이 여러 개의 Bounding Box 들 중에서 객체를 감지하는 데 가장 적합한 박스만 남기고 나머지 박스들은 삭제하는 방식이다.




그림 3-9. Non-Max Suppression 예시

SSD 알고리즘의 장점은 Multi-Scale Feature Layer 를 통해 이미지에서 다양한 크기와 중형비를 가진 객체를 동시에 감지할 수 있다는 것이 가장 큰 장점이며, 메모리 사용량도 낮은 편이다. 하지만 작은 객체에 대한 정확도는 다소 낮은 편이며, 겹쳐져 있는 객체에 대한 인식을 잘 못한다는 단점도 존재한다.

3) RetinaNet

RetinaNet 알고리즘은 FPN(Feature Pyramid Network)을 기반으로 한 One-Stage Detector 구조의 알고리즘이다. RetinaNet 알고리즘은 크게 2 가지 특징을 가진다. 첫 번째 특징은 Focal Loss 손실 함수를 사용한다는 점이다. Focal Loss 손실 함수란 손실의 가중치를 조정하는 것인데, 객체 감지 시 배경에 대해서는 낮은 가중치를 부여하고 목표하는 객체에 대해서는 높은 가중치를 부여하는 것이다. 이를 통해 클래스의 불균형 문제를 해소할 수 있으며, 결과적으로 작은 객체에 대한 감지 정확도까지 향상시킬 수 있다는 장점을 가진다.

RetinaNet 알고리즘의 두 번째 특징은 FPN 구조를 취한다는 점이다. FPN 은 피라미드 형태의 네트워크 구조를 가지며, 다양한 크기의 객체를 감지하기 위한 특징을 추출하는 역할을 수행한다. 특히 FPN 은 객체 감지 및 세분화 작업에서 다양한 크기의 객체를 감지하기 위하여 그림 3-10 과 같이 Bottom-Up 방향과 Top-Down 방향의 경로를 결합하여 특징 맵을 추출한다.




그림 3-10. RetinaNet 동작 원리

Bottom-Up 방향에서는 낮은 수준의 특징 맵에서 다운 샘플링을 수행하여 전반적인 정보를 얻고, Top-Down 방향에서는 높은 수준의 특징 맵에서 업 샘플링을 수행하여 상세한 정보를 얻는 방식이다. RetinaNet 알고리즘의 장점은 Focal Loss 를 사용함으로써 클래스 불균형 문제를 완화하고, 객체 감지 신뢰도가 높다는 점이다. 또한 FPN 을 통해 다양한 크기의 객체를 감지할 수 있다는 것도 장점이다. 하지만 다양한 객체를 감지하기 위하여 요구되는 학습 데이터의 양이 많은 편이며, 높은 사양의 GPU 를 사용해야 원하는 성능을 얻을 수 있다는 단점도 존재한다.

4) R-CNN

R-CNN(Region-based Convolutional Neural Network)은 Two-Stage Detector 구조를 가졌으며, 객체 감지 분야에 딥러닝을 최초로 적용시킨 알고리즘이다. R-CNN은 이미지의 모든 위치에서 객체를 찾는 Sliding window 방법 대신에 이미지에서 객체가 존재할 후보 영역을 먼저 찾는 Region proposal 방식을 사용함으로써 Sliding window 방식보다 속도와 정확도를 개선하였다. R-CNN 알고리즘은 그림 3-11과 같이 Region Proposal과 Region Classification 단계를 통해 객체를 감지한다.




그림 3-11. R-CNN 구조

Region Proposal 단계는 입력 이미지를 대상으로 객체가 존재하는 영역을 찾는 과정인데, selective search 알고리즘을 활용하여 임의의 작은 Bounding Box들을 생성한 후 이를 바탕으로 RoI를 제안하는 형태로 진행된다. 이후 해당 RoI로부터 각 영역들에 대한 고정 크기의 특성 벡터를 추출하여 CNN의 input으로 사용한다. CNN을 통해 나온 특징 맵은 선형 지도 학습 모델인 SVM(Support Vector Machine)을 통해 classification을 진행한다. 마지막으로 Bounding Box regression을 통해 객체 감지 정확도를 향상시킨다.

R-CNN 알고리즘은 높은 정확도와 뛰어난 성능을 가졌으며, 새로운 데이터셋에 대해서도 잘 동작하는 일반화 능력이 뛰어나다는 장점이 있다. 하지만 객체의 후보군을 독립적으로 처리하기 때문에 동작 속도가 상대적으로 느려 실시간 감지에 부적합한 편이며, 대규모의 Train Set을 사용하기 때문에 메모리 사용량이 높다는 단점이 있다.

5) Faster R-CNN

Faster R-CNN 알고리즘은 Two-Stage Detector 구조를 가지며 R-CNN 계열 알고리즘 중 가장 높은 정확도와 빠른 속도를 가진 알고리즘이다. Faster R-CNN 알고리즘은 **그림 3-12**와 같이 크게 세 가지 주요 구성 요소(CNN, RPN, Detector)로 이루어진다. 먼저 이미지가 입력되면 CNN(Convolutional Neural Network)을 통해 객체의 크기와 모양 정보를 포함한 특징 맵(Feature map)으로 변환되며, RPN(Region Proposal Network)은 해당 특징 맵들을 입력으로 받아 이미지 내에 객체가 있을 것으로 추정되는 후보 영역(Region proposal)을 생성하는 역할을 수행한다. 그리고 Detector는 특징 맵과 후보 영역을 입력으로 받아 객체의 클래스와 위치를 예측하는 역할을 수행한다.




그림 3-12. Faster R-CNN 구조

Faster R-CNN의 동작 과정은 **그림 3-13**과 같이 나타낼 수 있다. 우선 RPN을 사용하는데, 이는 입력된 특징 맵을 대상으로 convolution을 적용하여 Fully Convolutional Layer를 만드는 네트워크이다. 이후 추가로 convolution을 거쳐서 나오는 결과 값과 Ground Truth(실제 객체가 있는 영역) 간 IoU 값을 비교하여 positive anchor box와 negative anchor box를 분류한다. 이를 통해 RoI를 더욱 효율적으로 생성하며, Bounding Box regression을 별도의 모델이 아닌

하나의 통합된 모델로 처리한다. RPN을 통해 RoI 생성을 완료하면, RPN과 별개로 이미지를 Feature Extractor에 입력하여 나온 특징 맵과 RPN을 통해 나온 결과를 Mapping을 시킨 다음 RoI Pooling layer를 거친다. RoI Pooling layer는 특징 맵에서 해당 RoI에 해당되는 영역을 추출해 원하는 크기로 pooling 하여 고정된 크기의 특징 맵으로 결합하는 역할을 수행한다. RoI Pooling를 통과한 후에는 FC Layer(Fully Connected Layer)를 통해 RoI에 대한 객체의 클래스를 분류하며, 이후 softmax 등의 활성화 함수를 활용하여 클래스 별 확률을 계산하고 Bounding Box Regressor를 통해 Bounding Box의 좌표를 출력한다. 이러한 과정들을 통해 객체 감지 결과가 생성된다.




그림 3-13. Faster R-CNN 동작 원리

Faster R-CNN 알고리즘의 장점은 RPN을 이용함으로써 객체가 존재할 후보 영역을 더욱 효율적으로 생성하고, 통합 모델을 통해 후보 영역 생성과 객체의 클래스 및 위치 추론 과정을 간소화하여 빠른 속도로 객체 검출이 가능하다. 그리고 객체 인식에 대해 높은 정확도를 가진다는 장점이 있다(Wenyao Liu, 2021). 또한 RPN과 객체 분류 네트워크가 동시에 학습되는 end-to-end 방식으로 학습을 진행하기 때문에 모델 최적화에 용이하다. 하지만 학습에 장시간이 소요되며, 높은 객체 감지 성능을 구현하기 위하여 많은 리소스가 필요하다는 단점도 있다.

제4장 연구 방법 및 결과

1. 반도체 현장 작업자 사고 예방 컨셉

앞서 분석한 중대 재해의 주요 원인(‘근로자 부주의 및 안전 규칙 미준수’, 76.5%)에 의한 사고 발생률을 줄이기 위하여, 건설 현장에 적용되고 있는 ‘객체 감지 기술’과 반도체 현장의 특징인 ‘역할 별 방진복 색상 차이’를 결합한 사고 예방 기술을 연구하였다. 반도체 현장의 주요 사고 원인은 Gas, Chemical 등 화학 물질 누출에 의한 것인데, 이는 영상으로 감지가 어렵기 때문에 영상 감지 기술의 도입이 다른 현장 대비 지연된 경향이 있다. 하지만 화학 물질 관리 외에도 작업자의 표준 작업 지침서 이행 여부를 감독하는 것은 사고 예방 측면에서 매우 중요하다. 특히 ‘근로자 부주의 및 안전 규칙 미준수 문제’를 개선하기 위해서는, 현재 현장에서 그 역할을 수행하고 있는 안전 관리자에 대한 감리를 강화해야 한다.

따라서 객체 감지 기술을 통해 반도체 현장 작업자의 안전 보호구 착용 상태를 확인하고, 해당 현장의 안전 관리자 존재 여부를 확인함으로써 사고를 예방하는데 기여하고자 한다.

세부적인 기능은 **그림 4-1**과 같이 현장의 CCTV 영상을 3분 간격으로 샘플링하여, 샘플링 된 이미지를 대상으로 작업자의 안전모 착용 여부를 먼저 확인한다. 만일 안전모 미착용이 확인될 경우 화면의 좌측 상단에 ‘No Helmet’ 알람을 표시한다. 안전모 착용 상태가 이상이 없을 경우 해당 작업 현장 내 안전 관리자가 정상적으로 존재하는지 확인한다. 만일 안전 관리자가 3분 연속 부재 시 ‘주의 알람(Caution)’, 6분 연속 부재 시 ‘경고 알람(Danger)’을 화면 좌측 상단 표시하도록 구성하였다.

1) Check the Safety Rules



➤ Safety helmet



*No Helmet
alarm*



2) Check the Safety Manager



!

absence



➤ 3 mins. in a row



*Caution
alarm*

➤ 6 mins. in a row



*Danger
alarm*

그림 4-1. 작업자 사고 예방 컨셉 도식화

2. 데이터 셋 구축 및 객체 감지 알고리즘 선정

반도체 건설 현장 작업자의 사고 예방 기술을 개발하기 위하여, 반도체 현장에 대한 약 4,500개의 영상 데이터를 수집하였다. 데이터 셋의 경우, 그림 4-2와 같이 안전모 착용 상태를 판단할 수 있는 데이터와 작업자의 역할에 따른 방진복 색상 별 데이터로 구성하였다. 이러한 데이터들은 반도체 건설 현장에서 직접 획득하거나, AI Hub 등의 오픈 플랫폼에 업로드된 영상 이미지 등을 활용하였다.



그림 4-2. 데이터 셋 구성

또한 학습 성능의 향상을 위하여, 그림 4-3과 같이 이미지 회전(mirroring, rotation), 조도 변경(지하층 저조도 환경 반영) 등의 데이터 증강(Data augmentation)을 통해 학습용 데이터를 추가하였다. 학습 데이터와 평가 데이터의 비율은 약 8:2로 구성하였다. 데이터 학습을 위한 Class는 안전모 착용 상태(착용, 미착용)와 방진복 색상(흰색, 파란색, 주황색)에 따라 총 5개로 구성하였고, 이후 데이터 셋을 대상으로 Bounding Box 라벨링을 진행하였다.



✓ Original



✓ Mirroring



✓ Rotation



✓ Low-light

그림 4-3. 학습 데이터 증강

데이터 딥 러닝을 위해서는 객체 감지 알고리즘이 필요하다. 본 연구를 통한 사고 예방 시스템은 객체 감지에 대한 정확도가 가장 중요하기 때문에, Two-Stage Detector 구조를 채택하였으며, 여러 알고리즘 중 정확도가 높고 동작 속도가 빠른 ‘Faster R-CNN ConvNeXt’을 학습 알고리즘으로 선정하였다(Zhuang Liu, 2022). Faster R-CNN ConvNeXt 알고리즘의 구조는 그림 4-4와 같이 나타낼 수 있다(Qiuchi Xiang, 2023). DWConv는 Depthwise Convolution를 뜻하며, 입력 데이터의 채널을 유지하면서 각 채널에 대해 별도의 필터를 적용하는 역할을 수행한다. LN은 Layer Normalization을 의미하며, 각 채널의 분산을 0으로 맞추어 정규화를 통해 학습이 안정되도록 한다. GELU는 Gated Linear Unit 활성화 함수로써, sigmoid 함수를 사용하여 입력 데이터 중 필요한 데이터만 통과시키고 나머지 데이터는 차단시키는 역할을 수행하는 모듈이다. 동작 원리는, 먼저 이미지의 특징 맵이 입력되면 DWConv를 거쳐 C2 채널을 가진 출력을 생성한다. 이후 LN을 거치며 출력이 정규화되고, Conv를 거쳐 입력 데이터의 4배 크기의 채널을 가진 데이터가 출력된다. 해당 출력이 GELU를 거치며 필요 데이터만 통과되고, 마지막의 Conv를 거쳐 최종 특징 맵이 출력된다.

[ConvNeXt Block]




그림 4-4. Faster R-CNN ConvNeXt 구조 [14]

Faster R-CNN ConvNeXt 알고리즘은 Faster R-CNN 알고리즘과 마찬가지로 이미지에서 객체가 존재할 만한 후보 영역(RoI)을 생성한 후 각 RoI에 대한

클래스와 위치를 예측하는 방식으로 객체를 감지하지만, RoI 생성 단계에서 사용되는 네트워크가 서로 다르다. 우선 Faster R-CNN 알고리즘은 후보 영역 생성 시 RPN 네트워크를 사용한다. RPN 네트워크는 3x3 convolution을 사용하기 때문에, 이미지의 특성 맵에서 작은 영역만 볼 수 있다. 즉, RoI가 작거나 RoI가 이미지의 가장 자리에 위치하는 경우 성능이 저하될 수 있다. 반면 Faster R-CNN ConvNeXt 알고리즘은 후보 영역 생성 시 RPN 네트워크가 아닌 ConvNeXt-37 네트워크를 사용한다. ConvNeXt-37 네트워크란 37개의 레이어를 가지는 깊은 신경망으로써 각 레이어는 Transformer 블록을 사용하여 RoI를 생성한다. Transformer 블록은 3x3 convolution 대비 이미지의 특성 맵에서 더 긴 범위의 상호 작용 통해 학습할 수 있기 때문에 RoI의 크기나 위치에 덜 민감하여 상대적으로 높은 성능을 유지할 수 있다. 두 알고리즘 간 차이점은 표 4-1과 같이 나타낼 수 있다.

표 4-1. Faster R-CNN 과 Faster R-CNN ConvNeXt 비교

구분		Faster R-CNN	Faster R-CNN ConvNeXt
알고리즘 구조		Two-Stage Detector	
RoI 생성	생성 네트워크	RPN 네트워크	ConvNext-37 네트워크
	특징	3x3 convolution 사용	Transformer 블록 사용
	차이점	RoI 크기, 위치 민감 → 성능 저하 발생	RoI 크기, 위치 둔감 → 높은 성능 및 안정성

즉, Faster R-CNN ConvNeXt 알고리즘은 Faster R-CNN 알고리즘보다 정확도, 속도 및 안정성을 개선한 모델이라고 할 수 있다.

3. 알고리즘 적용 결과 및 분석

앞서 bbox 형태로 라벨링 한 데이터 셋을 대상으로 ‘Faster R-CNN ConvNeXt’ 알고리즘을 적용하여 학습 횟수를 100회로 설정 후 학습을 실시하였다. 학습 데이터와 평가 데이터의 비율은 약 8:2로 구성하였다. 학습 데이터는 모델을 학습시키는 데에 사용되고, 평가 데이터는 학습된 모델의 일반화 성능을 평가하는데 사용된다. 특히 평가 데이터의 경우 실제 적용할 환경에 가까워야 한다는 것에 주안점을 두고 데이터를 선별하였다. 학습 데이터와 평가 데이터의 비율을 8:2로 선택한 이유는, 딥러닝 시 과적합을 방지하고 통계적으로 가장 높은 신뢰성을 얻을 수 있는 비율이기 때문이다. 학습 환경의 경우, 하드웨어는 NVIDIA RTX A6000 GPU(48GB Graphic memory), Intel(R) Xeon(R) Silver 4215R CPU @ 3.20GHz(125GB RAM memory)였으며, 소프트웨어는 python 3.8.0, V11.7.99 Cuda Toolkit (pytorch 1.11.0 version, torchvision 0.12.0 version) 환경에서 학습을 진행하였다. 해당 환경에서 학습한 결과, 100회 학습을 하는 데에 약 46.5시간이 소요되었다.

최종 학습 결과, 정확도(mean Average Precision, mAP)는 약 75%였으며, 재현성(mean Average Recall, mAR)은 약 78%로 확인되었다. 학습 횟수 별 정확도 및 재현성의 경우, 표 4-2와 같이 50회 이상 학습 시 학습 성능이 거의 포화되는 것을 확인할 수 있었으며, 81회 학습 결과 가장 높은 성능을 나타내었다. 81회 학습 시 각 class 별 학습 성능을 살펴보면, 안전모 착용 상태에 대한 정확도는 안전모 착용(0.773), 안전모 미착용(0.735) 순으로 나타났고, 방진복 색상 별 감지 정확도의 경우 협력사 임직원(0.828), 작업자(0.736), 안전관리자(0.697) 순으로 나타났다.

표 4-2. Faster R-CNN ConvNeXt 학습 결과

학습 횟수(Epoch)	mAP (mean Avg. Precision)	mAR (mean Avg. Recall)
1	0.147	0.364
5	0.598	0.659
10	0.684	0.726
15	0.703	0.746
20	0.697	0.744
25	0.720	0.755
30	0.720	0.753
35	0.727	0.763
40	0.724	0.761
45	0.732	0.772
50	0.748	0.780
55	0.740	0.775
60	0.748	0.778
65	0.739	0.775
70	0.745	0.762
75	0.740	0.778
80	0.749	0.775
81	0.754	0.781
85	0.727	0.761
90	0.745	0.776
95	0.748	0.775
100	0.743	0.779

학습 성능뿐만 아니라 그림 4-5와 같이 안전모 착용 상태에 대한 감지 및 알람 표시 기능이 정상 구현됨을 확인하였고, 그림 4-6과 같이 안전 관리자의 부재 시 알람 표시 기능도 정상적으로 구현되는 것을 확인하였다.



그림 4-5. 안전모 착용 상태 감지 및 알람 기능 구현 결과



그림 4-6. 안전 관리자 존재 여부 확인 및 알람 기능 구현 결과

또한 안전 관리자의 부재에 따른 알람 발생 시, 각 상황에 적합한 자연어를 생성하기 위하여, Chat GPT 와 Prompt Engineering 기술을 활용하였다. Chat GPT 와 같은 자연어 생성 AI 는 사용에 편리함을 갖고 있지만, 워낙 방대한 양의

사전 학습 텍스트 데이터와 자율적인 판단을 통해 답변을 생성하기 때문에 매번 사용자가 원하는 답변을 얻는 것이 어렵다. 이러한 단점을 극복하기 위해 Prompt Engineering 을 활용할 수 있다. Prompt Engineering 이란 원하는 정보나 특정 작업을 수행하도록 모델을 조작하는 기술 또는 방법론을 의미하며, Chat GPT 등의 자연어 생성 AI 를 사용할 때에 더욱 효과적인 결과를 얻을 수 있다. 즉, Prompt Engineering 을 통해 구체적인 입력 프롬프트를 구성하여, 동일한 질문을 하더라도 본인이 원하는 형태의 결과를 생성할 수 있게 된다.

안전 관리자의 3 분 연속 부재로 Caution 알람이 발생한 경우에 대한 자연어 생성을 하기 위하여, **그림 4-7** 과 같이 Chat GPT 를 통해 질문을 하였다. 그 결과 ‘작업 중단, 안전 지역 이동, 안전장비 착용’ 등 다양한 답변을 얻을 수 있었다. 하지만 해당 연구에서 정의한 ‘Caution 알람’ 개념에 대해 명확한 답변이라고 보기에는 거리가 있었다. 이에 Prompt Engineering 기술을 적용하여 자연어를 생성해 본 결과, ‘모든 작업을 즉시 중단하고 안전 관리자를 찾아주세요.’라는 알람 상황에 가장 적합한 자연어를 생성할 수 있었다.




그림 4-7. Prompt Engineering 기반 자연어 생성 결과

제5장 결론

본 연구에서는 최근 글로벌 AI 반도체 시장 규모의 확대로 반도체 건설 현장 작업자가 지속 증가하는 상황 속에서, 중대재해처벌법의 시행에 따른 작업자 안전 관리에 대한 법적 제재 강화 추세에 대응하기 위하여 반도체 현장에 특화된 작업자의 사고 예방 기술을 개발하고자 하였다. 이에 건설 현장의 사고 예방 기술로써 적용 범위를 점차 넓혀가고 있는 ‘객체 감지 기술(Object Detection)’을 활용하면서 반도체 현장의 특징을 결합하여 반도체 작업자 맞춤형 사고 예방 기술 개발을 위한 연구를 진행하였다. 학습 알고리즘으로는, 여러 가지 객체 감지 기술 알고리즘 중 가장 높은 정확도와 빠른 속도를 가지며 Bounding Box 형태의 라벨링으로 학습이 가능한 Faster R-CNN ConvNeXt 알고리즘을 사용하였다.

연구 방법은 중대 재해의 주요 원인인 ‘근로자 부주의 및 안전 규칙 미준수’에 의한 사고 발생률을 줄이는 것을 목적으로, 먼저 작업자의 안전모 착용 상태를 확인하여 이상 유무를 확인하도록 구성하였다. 안전모 미착용이 감지될 경우 알람을 표시하는 기능을 구성하였으며, 안전모 착용 상태에 이상이 없을 경우에는 해당 작업 현장에 안전 관리자의 존재 여부를 확인하도록 구성하였다. 만일 안전 관리자가 일정 시간 이상 부재중인 경우 주의(Caution) 혹은 경고(Danger) 알람을 표시하는 기능으로 구성하였다.

이에 실제 반도체 현장 및 AI Hub 등의 오픈 플랫폼을 통해 수집한 영상 데이터들을 대상으로, 안전모(착용, 미착용) 및 방진복 색상(흰색, 파란색, 주황색)에 대한 Class 생성 후 Bounding Box 형태로 라벨링을 진행하였다. 이후 Faster R-CNN ConvNeXt 알고리즘을 사용하여 학습 횟수를 100회로 설정 후 학습을 실시하였다. 학습 결과, 50회 이상 학습 시 정확도 75%, 재현성 78% 수준으로 학습 성능이 거의 포화되는 것을 확인할 수 있었으며, 안전모 미착용 및 안전 관리자의 부재 시 알람 표시 기능도 정상 동작하는 것을 확인하였다. 이후

Chat GPT와 Prompt Engineering 기술을 활용하여 안전 관리자 부재 상황에 맞는 자연어를 생성하였는데, 향후 영상 감지 기술과 자연어 처리 기술 간 연계성을 높여 복합 적용한다면 보다 효과적인 사고 예방 시스템을 구축할 수 있을 것으로 예상된다.

해당 연구는 건설 현장에서 많이 사용되는 객체 감지 기술을 활용하되, 반도체 현장의 특징인 ‘라인 내 모든 작업자가 방진복을 착용한다’는 점과 ‘각 역할 별로 방진복의 색상이 다르다’는 점을 결합하여 반도체 현장 작업자 맞춤형 사고 예방 기술이라는 점에서 차별성이 있다.

해당 연구 결과는 현장의 안전 관리자가 놓칠 수 있는 ‘작업자 안전모 미착용’ 사례와 안전 관리자 없이 진행되는 ‘비인가 작업’에 대한 관리를 강화하여 안전 관리 사각지대를 해소함으로써 사고를 예방하는 데에 도움을 줄 수 있을 것으로 예상된다. 또한 현재 반도체 라인의 안전 관리는 주로 사람에 의해 수동으로 진행되고 있기 때문에, 반도체 라인의 개수와 면적이 점차 증가할수록 안전 관리 인력 부족 및 관리 능력 저하 문제에 직면할 우려가 존재한다. 이에 장기적으로는 현장 안전 관리의 주체를 사람에서 시스템으로 전환함으로써, 안전 관리 인력 부족과 안전 관리의 기술적 한계를 극복하는 데에 기반이 될 수 있을 것으로 기대된다.

참 고 문 헌

- [1] 고용노동부, 2022 재해조사 대상 사망 사고 발생 현황, 2021-2022
- [2] Jaekyu Lee, Sangyub Lee, Construction Site Safety Management: A Computer Vision and Deep Learning Approach, Sensors, 23(2): 944, 2023
- [3] 강태욱, 김병곤, 정유석, 이미지 기반 실시간 건설 현장 장비 및 작업자 모니터링을 위한 딥러닝 플랫폼 아키텍처 도출, 한국BIM학회 논문집, Vol.11, No.2, 2021, pp.24-32.
- [4] Meghana Nain, Shilpa Sharma, Sandeep Chaurasia, Safety and Compliance Management System Using Computer Vision and Deep Learning, IOP Conference Series: Materials Science and Engineering, 1099:012013, 2021
- [5] 김명호, 신성우, 서용윤, 건설현장 근로자의 안전모 착용 여부 검출을 위한 컴퓨터 비전 기반 딥러닝 알고리즘의 적용, 한국안전학회지, Vol.34, No.6, 2019, pp.29-37.
- [6] Trevor Slaton, Carlos Hernandez, Reza Akhavain, Construction activity recognition with convolutional recurrent networks, Automation in Construction, Vol.113, 2020: 103138
- [7] Saily Shah, Convolutional Neural Network: An Overview, Data Science Blogathon, 2022
- [8] Ohay Angah, Albert Y. Chen, Tracking multiple construction workers through deep learning and the gradient based method with re-matching based on multi-object tracking accuracy, Automation in Construction, Vol.119, 2020: 103308
- [9] Chandrahas Mishra, Dharmendra Lal Gupta, Deep Machine Learning and Neural Networks: An Overview, International Journal of Hybrid Information

Technology, Vol.9, No.11, 2016, pp.401–414.

[10] Wenyao Liu, Qingfeng Meng et al., Application of computer vision in monitoring the unsafe behavior of constructions workers, Buildings, 11:409, 2021

[11] 조영운, 강경수, 손보식, 류한국, 건설 현장 CCTV 영상을 이용한 작업자와 중장비 추출 및 다중 객체 추적, 한국건축시공학회지, Vol.21, No.5, 2021, pp.397–408.

[12] Zhiheng Li, Tongcheng Gu et al., ConvNeXt–Based Fine–Grained Image Classification and Bilinear Attention Mechanism Model, Applied Sciences, 12(18):9016, 2022

[13] Zhuang Liu et al., A ConvNet for the 2020s, arXiv:2201.03545, 2022

[14] Qiuchi Xiang et al., Yolo–Pest: An Insect Pest Object Detection Algorithm via CAC3 Module, Sensors, 23(6):3221, 2023

[15] Dingwen Zhang, Junwei Han et al., Weakly Supervised Object Localization and Detection: A Survey, IEEE Transactions on Pattern Analysis and Machine Intelligence, Vol.44, 2022, pp.5866–5885

[16] Bo Xiao, Qiang Lin, Yuan Chen, A Vision–Based Method for Automatic tracking of construction machines at nighttime based on deep learning illumination enhancement, Automation in Construction, Vol.127, 2021: 103721

[17] Qi Fang, Heng Li et al, A Deep Learning–based Method for Detecting Non–certified Work on Construction Sites, Advanced Engineering Informatics, Vol.35, 2018, pp.56–68.

[18] 김요한, 김주현, 김형관, 건설산업의 안전 및 재해 관련 인공지능, 한국건설관리학회, 제22권4호, 2021, pp.4–8

[19] Xinyu Mei, Xiaojing Zhou et al., Human Intrusion Detection in Static Hazardous Areas at Construction Sites: Deep Learning–Based Method, Journal

of Construction Engineering and Management 149(1):04022142, 2023

[20] Hyunsoo Kim et al., Automated hazardous identification using laborers' actual and optimal routes, Automation in Construction, Vol.65, 2016, pp.21–32

[21] 한국산업안전보건공단, 연례 보고서:사망 사고 사례, 2001–2003

[22] 안전보건공단, 이슈리포트, 2021

[23] Joseph Redmon et al., You Only Look Once: Unified, Real-Time Object Detection, Computer Vision and Pattern Recognition, v5, 2016

[24] Dang Thanh Vu, Gwanghyun Yu et al., Text Data Augmentation for the Korean Language, Applied Sciences, 12(7):3425, 2022

[25] Adam Marcus et al., Twitinfo: aggregating and visualizing microblogs for event exploration, Association for Computing Machinery, 2011, pp.227–236

[26] Jacob Devlin et al., BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding, arXiv:1810.04805v2, 2018

[27] Ashish Vaswani et al., Attention Is All You Need, arXiv:1706.03762v5, 2017

[28] Yiyi Zhang et al., ConvNeXt-based anchor-free object detection model for infrared image of power equipment, International Conference on Frontiers of Energy and Environment Engineering, 2022

[29] Shilin Wu et al., Improved Faster R-CNN for the Detection Method of Industrial Control Logic Graph Recognition, Front Bioeng Biotechnol, 2022 Aug 4;10:944944, 2022

[30] Qiguo Xu et al., A ConvNext-Based and Feature Enhancement Anchor-Free Siamese Network for Visual Tracking, Electronics, 11(15):2381, 2022

ABSTRACT

A Study on the Technology to Prevent Accidents of Semiconductor Workers Using Object Detection

Han Dong Yeop

Department of Semiconductor and Display Engineering

Sungkyunkwan University

As the global AI market has experienced rapidly growth, centered around the emergence of Chat GPT, the demand for semiconductors, a crucial element of AI technology, is also rapidly increasing worldwide. In response to this demand, countries like South Korea and the United States are continuously expanding their production lines to increase their market share in the semiconductor industry. As a result, the number of workers at semiconductor construction sites in South Korea is gradually increasing.

In this context, in South Korea, with the enforcement of the Serious Accident Punishment Act targeting all workplaces with 50 or more employees from 2022, the awareness of worker safety has increased even more. However, when comparing the number of fatalities due to serious accidents in 2021 and 2022, it has been observed that the number of fatalities increased despite the implementation of the Serious Accident Punishment Act. In 2021, there were 248 fatalities, and in 2022, there were 256. This observation indicates that relying solely on legal reinforcement might not effectively prevent accidents

among workers. Therefore, in order to achieve a substantial effect in preventing worker accidents, it is essential to secure systems that can provide practical assistance at the actual worksites rather than relying on legal sanctions alone.

Furthermore, an analysis of the causes of serious accidents revealed that 'worker carelessness and non-compliance with safety rules' accounted for the largest share at 76.5%. This is a matter that must be closely managed, especially in semiconductor construction sites. In the case of semiconductor production lines, various accident risks, such as the leakage of colorless and odorless chemical substances, which can lead to serious incidents, exist. In this regard, this study has conducted research on accident prevention techniques for workers in the semiconductor construction sites.

Safety management in semiconductor production lines is primarily carried out by 'safety managers.' However, in recent times, in the construction industry, there is a trend, particularly among large construction companies, to adopt accident prevention systems based on 'object detection technology' and gradually expand their application. In this study, the research focused on utilizing 'object detection technology' as applied in the construction industry while incorporating the unique characteristic of semiconductor production lines, such as the requirement for workers to wear different-colored protective clothing based on their roles. This approach aimed to develop specialized accident prevention techniques for workers in semiconductor construction sites.

The direction of this study is aimed at reducing accidents caused by the major cause of serious accidents, 'worker carelessness and non-compliance with safety rules'. The goal is to verify the 'safety helmet wearing status of workers' and the presence of 'safety managers at the work site', and devise a system that triggers an alarm in case of abnormalities. To accomplish this, I

collected video data from semiconductor construction sites, and in order to improve learning performance, I conducted data augmentation to increase the amount of the training data. Subsequently, I established classes for safety helmet wearing status and protective clothing colors. And I conducted labeling in the form of bounding box for all video data. Afterwards, the 'Faster R-CNN ConvNeXt' algorithm, known for its high accuracy, speed, and stability in object detection, was utilized for training through 100 epochs. The results of the training showed that accuracy and recall performance saturated after 50 iterations and that the detection and alarm system for the absence of safety helmets and safety managers was successfully implemented.

In the future, it is anticipated that the results of this study will be instrumental in preventing accidents by addressing safety management blind spots in semiconductor construction sites, such as 'safety helmet absences among workers' and 'unauthorized work.' In the long term, it is hoped that the transition from a human-centered safety management approach to a system-based approach in semiconductor construction sites will help overcome the shortage of safety management personnel and technological limitations associated with the increasing number and size of semiconductor production lines.

Keywords: Semiconductor construction site, Object Detection, Dust-proof suit, Enhanced safety management, Accident prevention