



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

석사학위논문

건설현장 ‘일일 위험성 평가서’

자동 생성 모델

– ‘Vision–Language Model (VLM)’ 을

활용하여 –



2026 년 02 월

인천대학교 대학원

건축학과

한소은

본 논문은 건축공학 석사학위논문임

건설현장 ‘일일 위험성 평가서’

자동 생성 모델

– ‘Vision-Language Model (VLM)’ 을

활용하여 –

지도교수 구충완, Ph.D.

이 논문을 건축공학 석사학위논문으로 제출함

2025 년 12 월

인천대학교 대학원

건축학과

한소은

이 논문을 한소은의 건축공학
석사학위논문으로 인준함

2025 년 12 월

심사위원장 김 태 완 (서명)

심 사 위 원 이 슬 비 (서명)

심 사 위 원 구 충 완 (서명)

국문초록

최근 「중대재해처벌법」 시행 등으로 인해 건설현장의 안전관리, 특히 위험성 평가 업무의 부담이 급격히 증가하고 있다. 현재 건설업에서는 위험성 평가를 통해 각 공종의 위험요인을 식별하고 안전관리대책을 수립하고 있다. 이에 대한 체계적인 관리를 위해, 건설현장에서의 안전관리대책 이행 사진을 촬영하고, 이를 본사에서 검토 및 관리하는 방식으로 ‘일일 위험성 평가서’를 작성하고 있다. 그런데, 현장에서 촬영된 사진의 품질이 안전관리 담당자의 이해도 및 태도에 따라 상당히 달라질 수 있고, 대규모 현장의 모든 이미지를 일일이 확인하기 어려운 상황이기 때문에, 안전관리대책 이행이 ‘미흡’한 경우에도, 이를 명확히 평가하지 못한 채 ‘이행’으로 처리되는 한계가 존재한다. 이와 같이, 안전관리대책 수립을 위해 많은 인력과 시간이 투입되고 있지만, 안전관리대책 ‘이행’ 여부에 대한 관리가 미흡한 실정이다.

이러한 한계를 극복하기 위하여, 본 연구에서는 'Vision-Language Model(VLM)'을 활용하여 '일일 위험성 평가서' 자동 생성 모델을 구축하였다. 제안모델에서는, 안전관리대책에 대한 이미지를 3가지 평가 기준 ((i) 핵심 객체 식별성, (ii) 상황 적합성, (iii) 실행 적정성)에 따라 분석할 수 있도록 ‘프롬프트 엔지니어링(Prompt Engineering)’ 기법을

적용하였다. 더불어, 각 평가 기준에 대한 분석 설명이 추출되면, 상용 LLM(GPT-4o) 모델을 통해 1~5점(소수점 1자리)의 점수 산출을 위한 루브릭 평가를 수행함으로써, 안전관리대학에 대한 ‘이행/미이행’을 자동 분류하도록 하였다.

본 연구에서는 일일 위험성 평가서의 분류체계 중 “골조공사 - 콘크리트 타설 - 슬라브 타설” 공종을 대상으로 구축한 1,146건의 ‘안전관리대책-이미지’ 1:1 매칭 데이터셋을 활용하였다. 분석 결과에 따르면, 기본 ‘상용 VLM’ 모델과 비교하여, 제안모델의 정확도 (Weighted Accuracy)가 74.77%에서 88.58%로 약 13.81%p 향상되었다. 이와 같이, ‘프롬프트 엔지니어링’ 기반의 제안 모델에 대한 타당성을 입증하였다. 본 연구는 ‘VLM과 같은 AI 기술’을 활용하여 건설현장 안전관리 자동화의 가능성을 검증하였다는 점에서 의의가 있다. 본 연구에서 제안한 모델을 ‘일일 위험성 평가 시스템’에 통합하여, 안전관리대책 이행 여부의 자동 판별 및 보고서 생성 자동화를 실현시킴으로써, 건설현장의 안전관리 효율성과 신뢰성을 동시에 향상시킬 수 있을 것으로 기대된다.

주제어: Vision-Language Model (VLM), 건설현장 안전관리, 일일 위험성 평가서, 프롬프트 엔지니어링, 이행 여부 평가

목 차

국 문 초 록.....	i
목 차.....	iii
표 목 차.....	v
그 립 목 차.....	vi
제 1장 서론.....	1
1.1. 연구 배경 및 목적.....	1
1.2. 기존 연구의 동향.....	4
1.3. 기존 연구의 한계.....	7
제 2장 연구 방법.....	10
2.1. 연구 범위 및 데이터 수집.....	11
2.2. 모델 개발.....	14
2.2.1. ‘상용 VLM’을 활용한 이행/미이행 분류 모델.....	14
2.2.2. ‘프롬프트 엔지니어링’ 기반 이행/미이행 분류 모델 ..	15
2.3. 모델 평가.....	23
2.3.1. Weighted Accuracy	24
2.3.2. 미이행 오답률(Type2).....	26
2.3.3. 이행 오답률(Type3).....	28
제 3장 분석 결과.....	30

3.1. 모델별 분류성능 비교.....	30
3.2. 모델별 현장 적용성 비교.....	33
3.3. 고찰.....	41
제 4장 결론.....	45
참고문헌.....	49
Abstract	54



표 목 차

표2.1. 검증 데이터 구성	13
표 2.2.2. (i) 핵심 객체 식별성 루브릭	20
표 2.2.3. (ii) 상황 적합성 루브릭	21
표 2.2.4. (iii) 실행 적정성 루브릭	22
표 3.1. 모델 성능(Accuracy 및 Weighted Accuracy).....	32
표 3.2. 미이행 오답률(Type2) 원인 분석 결과	35
표 3.3. 이행 오답률(Type3) 원인 분석 결과	36
표 3.4. 평가 기준별 참고 데이터	37
표 3.5. 안전관리대책 유형별 ‘미이행 오답률(Type2)’	40
표 3.6. 안전관리대책 유형별 ‘이행 오답률(Type3)’	40

그림 목 차

그림 2. 연구 구성	10
그림 2.3. 혼동행렬 기반 Type1-4 정의.....	24



제 1장

1.1. 연구 배경 및 목적

고용노동부(2023)에서 보고한 ‘2023년 전체 산업재해 발생 현황’에 따르면, 업종별로 재해 발생률을 분석한 결과, '건설업'(23.65%)에서 재해가 빈번하게 발생하였고, 사망자는 486명으로 가장 많이 발생하였다 [1]. 이에 정부는 「중대재해 처벌 등에 관한 법률」을 시행하여, 건설업에서 발생하는 중대 산업재해를 예방하고, 사업주 및 경영책임자의 안전보건 의무를 강화함으로써 현장의 안전관리체계를 근본적으로 개선하고자 하고 있다 [2].

이를 위해 건설현장에서는 ‘위험성 평가’ 시스템을 통해 공종별로 발생 가능한 위험요인을 사전에 식별하고, 이에 대한 안전관리대책을 수립·이행함으로써 위험요인을 체계적으로 관리하고 있다. ‘위험성 평가’란 사업주가 사업장의 유해·위험요인을 파악하고, 각 요인에 의한 부상 또는 질병의 발생 가능성(빈도)과 중대성(강도)을 추정·결정한 후, 그 결과를 바탕으로 ‘안전관리대책’을 수립하고 실행하는 일련의 관리 과정을 의미한다 [3,4]. 특히, 여러 건설현장에서는 ‘일일 위험성 평가서’를 통해 매일 작업별 안전관리대책의 이행 여부를 확인하고, 이행 완료 후 촬영한 현장 사진을 기반으로 평가서를 작성한다. 이렇게 작성된 평가서는 본사에서 검토·관리되어 최종 일일 위험성 평가서로 통합·관리되고 있으며, 안전관리대책의 이행 상태를 지속적으로 점검하기 위한 체계적

관리 도구로 활용되고 있다 [5].

이에 중대재해처벌법 시행 이후, 안전 관련 행정 업무의 급증과 인력 부족으로 인해 현장의 안전관리 업무 부담이 크게 가중되고 있다. 특히, 실무부서 담당자는 기존의 안전점검 및 유지보수 업무에 더하여 중대재해 대응 업무까지 병행해야 하는 상황으로, 이에 따라 일부 부서에서는 안전업무를 기피하는 현상이 나타나고 있다 [6]. 이러한 배경에서, ‘일일 위험성 평가서’에 업로드되는 이미지의 품질은 현장 담당자(사진 촬영자)의 이해도 및 숙련도와 촬영 태도 등에 따라 크게 좌우되며, 그 결과 이미지 품질의 일관성이 확보되지 못하는 한계가 존재한다. 또한, 본사에서는 매일 수백 건에 달하는 현장 이미지를 모두 검토하기 어려워, 사진이 단순히 촬영·업로드되었다는 이유만으로 자동 ‘이행’ 처리되는 한계가 존재한다. 이로 인해 실제로 ‘미이행’된 이미지가 업로드되더라도 ‘이행’으로 분류되는 사례가 발생하고 있다. 즉, 안전관리대책의 수립에는 많은 인력과 시간이 투입되고 있음에도 불구하고, 그 ‘이행’ 여부가 실질적으로 관리되지 않아 안전관리의 실효성과 신뢰성에 한계가 나타나고 있다.

최근 인공지능(AI) 기술의 발전으로 인해 건설현장의 안전관리 문제를 해결하기 위한 시각 정보 기반 자동 판별 기법에 대한 연구가 활발히 진행되고 있다 [7-9]. 특히, 이미지와 텍스트를 동시에 이해할 수 있는 ‘비전-언어 모델(Vision-Language Model, VLM)’은 건설현장에서 촬영된 시각 정보를 안전관리대책 문구와 연계하여 자동으로 분석하고, 이를 기반으로 일일 위험성 평가서와 같은 보고서를 자동 생성할 수 있는 잠재력을 지닌 기술로 주목받고 있다 [10-12]. 그러나 기존 ‘상용 VLM’은 일반적인 사물 인식이나 일상적 문맥 이해에는 우수한 성능을 보이지만, 건설 분야의 특수한 작업 환경과 안전관리 문맥에 대한 학습이 부족하여 ‘이행/미이행’과 같은 맥락적 판단에 한계가 존재한다. 또한, 대부분의 상용 모델은 단순히 분류 결과만 제시할 뿐, 모델이 어떤 근거로 판단을 내렸는지에 대한 설명이 부족하여 실무자가 결과를 신뢰하고 활용하기 어렵다는 한계가 있다.

이에 본 연구에서는 이러한 한계를 보완하기 위해 프롬프트 엔지니어링 기법을 적용하였다. 이를 통해 모델이 단순한 이행 여부 분류를 넘어, 사전에 정의된 평가 기준에 따라 정성적 설명을 생성하고, 이를 기반으로 ‘정량적 분석(루브릭 기반 평가)’이 가능한 구조를 제안하였다.

1.2. 기존 연구의 동향

최근 건설업에서는 인공지능(AI)을 활용한 안전관리 업무의 자동화와 디지털 전환이 빠르게 확산되고 있다. 이 가운데 LLM(Large Language Model)을 활용한 연구는 안전 관련 문서, 점검일지, 사고 보고서 등 텍스트 기반 데이터를 분석하여 위험요인을 자동 추출하거나 관리자 판단을 지원하는 방향으로 발전해 왔다. 특히 LLM 기반 연구들은 건설안전 도메인 정보를 적극적으로 활용하고 있으며, 프롬프트 엔지니어링이 체계적으로 확립되어 있다는 특징을 가진다. Ballal et al. (2024) 은 NLTK 를 활용한 규칙 기반 반복 접근법을 적용하여, 건설 관련 사고 서술로부터 위험요인을 효과적으로 추출하였다 [13]. Wang et al. (2024) 은 CV 기반 고밀도 이미지 캡처링과 NLP 를 결합한 멀티모달 프레임워크를 통해 건설 안전 위험요인을 자동으로 식별하고 추론하는 방법을 제안하였다 [14]. Ahmadi et al. (2024) 은 GPT-3.5, GPT-4.0, Gemini Pro, LLaMA 3.1 등 대형 언어모델 (LLM)을 활용하여 건설 사고보고서의 주요 속성(근본 원인, 부상 원인, 영향 부위, 심각도, 사고 시점) 을 자동 분류함으로써 건설 안전 분석의 정밀도를 향상시키는 방법을 제안하였다. [15]. Uhm et al. (2025) 은 RAG (Retrieval-Augmented Generation) 기반 프롬프트 구조를 적용하여 GPT 계열 모델의 평가 기준 기반 정확성, 정보 충실도 등을 크게 향상시켰다 [16].

이처럼 LLM 연구는 안전관리 문맥에서 도메인 정보를 체계적으로 반영하고 있으며, 프롬프트 엔지니어링을 활용한 모델 성능 향상 사례가 축적되고 있다.

그러나 비전-언어 모델(Vision-Language Model, VLM)을 활용한 연구는 건설안전 도메인을 충분히 반영하지 못한 초기 단계에 머물러 있다. 최근 VLM 을 사용하여 위험요인을 자동 식별하려는 시도가 증가하고 있으나, 대부분 이미지 기반 캡션 생성 또는 단순 분류 수준에 국한되어 있으며, 모델이 안전관리대책과 현장 상황을 연계하여 정교한 판단을 수행하기에는 한계가 있다. 무엇보다 LLM 과 달리 VLM 분야에서는 프롬프트 엔지니어링이 제대로 정립되어 있지 않아, 멀티모달 모델이 잠재적으로 보유한 장점이 충분히 활용되지 못하고 있다. Adil et al. (2025) 은 GPT-4o, Gemini, LLaMA 3.2 등을 활용하여 건설현장 위험요인을 자동 식별하는 프레임워크를 제안하였으며 [17], Chan et al. (2025) 은 CogVLM 기반 파인튜닝을 통해 고소작업 위반을 90% 이상 정확도로 분류하는 시스템을 개발하였다 [18]. 또한 Chen et al.(2025)은 Qwen2-VL-7B 를 파인튜닝하여 위험요인 자동 식별기(ChatCH)를 구축하고 정밀도 89.4%를 보고하였다 [19].

이러한 VLM 기반 연구들은 대부분 이미지 기반 텍스트 생성 또는 단순 위험요인 분류 수준에 국한되어 있어 건설업에서는 한계가 있다. 현재 건설업에서는 이미지 캡션을 활용해 점검 효율성을 높이려는 시도가 이루어지고 있으나, 이는 학습된 데이터에 기반한 일반적인

설명만 생성될 뿐, 건설업의 도메인과 직접 연계하여 안전관리대책의 이행 여부를 판단하기에는 한계가 있다.

반면, 타 분야에서는 도메인에 VLM을 활용하고 있다. 예를 들어, Zhou et al.(2024)에서는 자율주행 분야에서 운전면허 객관식 문항을 활용하여 VLM의 시각 판단 능력을 평가하였으나, 프롬프트 엔지니어링이 적용되지 않아 GPT와 Bard 모델은 60~70% 수준의 정확도에 머물렀다 [20]. McNulty et al. (2025) 와 Bereuter et al. (2025) 에서는 의료 분야에서 VLM을 신경외과·외과 관련 객관식 시험을 활용해 모델의 시각적 이해 능력을 검증하였으나, GPT, Gemini, Claude 등이 50~70% 수준의 정답률을 보이는 등 도메인 입력 구조와 프롬프트 설계가 부족하여 성능이 제한되었다 [21,22]. 이처럼 VLM은 도메인 지식을 충분히 반영하지 못하거나, 프롬프트 구조가 정교하게 설계되지 않은 경우 모델의 판단 근거가 불명확하고 성능 변동성이 크다는 한계가 지속적으로 보고되고 있다.

상기와 같이, LLM 기반 안전관리 연구는 도메인 정보의 체계적 활용과 프롬프트 엔지니어링을 통해 실질적인 성과를 도출해온 반면, VLM 기반 연구는 건설 안전관리 도메인의 활용이 미흡하고 프롬프트 설계가 부족하여 성능이 제한되는 초기 단계에 머물러 있다. 따라서 이미지와 안전관리대책 문구를 결합해 이행·미이행을 평가하고 설명까지 생성할 수 있는 VLM 기반 모델 개발을 위해서는, LLM 에서 축적된

프롬프트 엔지니어링 전략을 멀티모달 환경에 맞게 재구축하는 노력이 필요하다.

1.3. 기존 연구의 한계

건설현장 내 ‘일일 위험성 평가서’는 매일 수립되는 다양한 안전관리대책의 이행 여부를 평가해야 하며, 공종별로 상이한 안전관리대책이 적용되기 때문에 판단의 일관성을 확보하기 어렵다. 이에 따라, 이행/미이행 분류 모델을 구축할 때에는 다양한 안전관리대책 유형을 반영하여 범용성과 확장성을 확보하는 것이 중요하다. 그러나 기존 연구들은 주로 현장 이미지를 기반으로 미리 학습된 범위 내에서 위험요인을 추출하거나, 학습된 위반 사례를 근거로 위반된 사항을 식별하고 설명을 생성하는 수준에 머물러 있었다. 이러한 접근 방식은 모델이 학습된 데이터 범위 내에서만 판단이 가능하다는 한계가 있으며, 통합분류체계 하에서 안전관리대책 문구와 현장 이미지를 직접 매칭하여 실제 이행 여부를 종합적으로 판단하는 연구는 매우 제한적이었다. 즉, 다양한 공종과 안전관리대책을 포괄적으로 처리할 수 있는 범용적 모델의 도입이 필요한 상황이다.

한편, 객관식 형태의 시각적 판단을 수행하는 연구들을 분석한 결과, 이러한 연구들은 주로 의료 영상 진단이나 자율주행 분야에서 활용되며, 다양한 시각적 상황에 대해 모델이 정답을 선택하도록 유도함으로써 범용적 판단 능력을 검증하는 데 초점을 두었다. 그러나 이들 연구는 프롬프트 엔지니어링이나 평가 기준이 부재하여, 모델의 판단 근거가

불명확하고 평가의 신뢰성이 낮다는 한계가 있다. 또한, 단순 정확도 중심의 결과 산출로 인해 실제 안전관리 맥락에서의 정량적·정성적 판단 근거를 제시하기 어렵다.

따라서 본 연구는 이러한 기존 연구의 한계를 보완하기 위해, 프롬프트 엔지니어링을 기반으로 평가 기준을 적용하여 ‘일일 위험성 평가서’ 내 안전관리대책의 이행 여부를 자동 분류하는 모델을 구축하고, 그 성능을 검증하고자 한다. 이를 위해 골조공사 중 콘크리트 타설 및 슬라브 타설 공정을 대상으로 하였으며, 이행·미이행 데이터가 각각 30 개 이상 확보된 9 개 유형의 안전관리대책을 선정하여, 총 1,146 쌍의 안전관리대책-이미지 데이터를 분석하였다. 본 연구는 다음 두 가지 연구 목표를 중심으로 수행되었다:

- **연구목표 1:** 프롬프트 엔지니어링을 기반으로 한 이행·미이행 분류 모델의 유효성을 검증하고자 한다. 이를 위해 본 연구에서는 상용 비전-언어모델(VLM)의 단순 질의응답 방식 한계를 보완하여, Role(역할), Knowledge(배경지식), Task(작업), Rules(규칙), Format(형식), Examples(예시)로 구성된 체계적인 프롬프트 구조를 설계하였다. 이를 통해 모델이 건설 안전관리자의 관점에서 이미지를 분석하고 일관된 판단을 내릴 수 있도록 하였다. 모델은 프롬프트를 기반으로 안전관리대책별 세 가지 평가 기준인 (i)핵심 객체 식별성, (ii)상황 적합성, (iii)실행 적정성에 따라 설명을 생성하며, 이후 생성된 설명을

토대로 루브릭 기반 정량화를 수행하여 각 기준별 점수를 0~5 점 범위에서 산출한다. 일정 점수 이상을 충족하는 경우 ‘이행’으로 판정하도록 하였다. 이러한 과정을 통해 평가 기준별 정성적 설명과 정량적 점수를 함께 활용함으로써 모델의 판단 근거와 일관성을 확보하고, 프롬프트 구조와 평가 기준의 타당성을 검증하고자 한다.

- **연구목표 2:** 모델의 오답 데이터를 세부적으로 분석하여 ‘미이행 오답률(Type2)’과 ‘이행 오답률(Type3)’을 중심으로 안전관리대책별 특성을 파악하고자 한다. 특히, Type2 오류는 안전성 관점에서 실제 미이행된 안전관리대책을 이행으로 잘못 분류하는 ‘위험 간과형 오류’로, 현장의 사고 예방 신뢰도를 저하시킬 수 있다. 반면, Type3 오류는 안전관리의 효율성 관점에서 실제로 이행된 대책을 미이행으로 과잉 판정하는 ‘과잉 판단형 오류’로, 불필요한 검토와 행정적 부담을 초래할 수 있다. 따라서 본 연구는 Type2·Type3 오류를 중심으로 이를 평가 기준 분석 시 참고 데이터로 활용하여, 안전성 및 효율성 관점의 현장 적용 가능성을 평가하고, 이를 바탕으로 향후 이행/미이행 자동 분류 모델의 고도화 및 현장 적용 전략을 수립하기 위한 가이드라인을 제시하고자 한다.

제 2장 연구 방법

본 연구는 프롬프트 엔지니어링을 적용하여 ‘안전관리대책-이미지’ 기반의 이행/미이행 자동 분류 성능 향상을 분석하는 데 중점을 둔다. 본 연구의 전체 구성은 [그림 2]과 같다.




그림 2. 연구 구성

2.1. 연구 범위 및 데이터 수집

본 연구에서는 건설공사 중 ‘골조공사(대분류)’를 연구 범위로 선정하였다. 골조공사는 건축물의 주요 구조체를 형성하는 핵심 공종으로, 아파트 신축공사의 경우 전체 공정 중에서도 공사 기간에서 약 57%를 차지할 만큼 높은 비중을 보인다 [23]. 또한, 고소작업, 거푸집 설치, 콘크리트 타설 등 중장비와 인력이 동시에 투입되는 등 고위험 작업이 다수 포함되어 있어, 다양한 잠재적 위험요소가 내제되어 있다 [24]. 이러한 특성으로 인해 다른 공종에 비해 안전관리의 중요성이 특히 높은 핵심 단계로, 안전관리대책의 이행 여부에 따라 사고 예방 효과가 크게 달라질 수 있다. 또한, 골조공사 중에서도 ‘콘크리트 타설(중분류)’ 작업은 펌프카, 거푸집, 철근 등 여러 위험요소가 복합적으로 작용하는 고위험 공종으로 분류된다 [25]. 이에 따라 본 연구에서는 콘크리트 타설 공종을 중심으로 분석을 수행하였으며, 세부적으로는 ‘슬라브 타설(소분류)’ 작업을 대상으로 우선 검증을 실시하였다. 이는 골조공사 중에서도 데이터 축적이 용이하고, 동일 공종 내 작업환경의 변동성이 비교적 적어 모델 검증의 일관성을 확보하기에 적합하기 때문이다.

데이터 수집은 실제 건설현장에서 작성된 ‘일일 위험성 평가서’를 기반으로 수행하였다. 각 평가서에는 작업별 ‘안전관리대책’과 해당 대책의 ‘이행 사진’이 포함되어 있으며, 이를 바탕으로 안전관리대책-이미지 쌍을 구축하였다.

본 연구에서 선정한 안전관리대책 항목은 펌프카, 콘크리트 믹서트럭과 같이 건설현장에서 중대재해로 직결되는 중장비 작업을 중심으로 구성하였다. 중장비는 이동성, 작업 반경의 확대, 고하중 장비 구조적 특성으로 인해 작업자와의 충돌·협착, 장비 전도 등 치명적 사고를 유발할 가능성이 높은 위험요소로 알려져 있다 [26]. 실제로 건설 장비 관련 사고는 전체 사망사고에서 높은 비중을 차지하며, 특히 펌프카와 같은 대형 장비는 아웃트리거 미확장, 지반 지지력 부족 등으로 인해 전도 위험이 크게 증가한다고 보고하였다 [27,28]. 이러한 연구 결과에 따라, 본 연구에서는 신호수 배치, 작업계획서 비치, 장비 안정화 조치(스토퍼, 아웃트리거 설치), 작업구역 구획 설정 등 실제 현장에서 사고 예방에 직접적으로 기여하는 항목을 중심으로 안전관리대책 리스트를 구성하였다. 수집된 대책은 [표 2.1]에 제시하였다. 이후 모델 검증의 신뢰성을 확보하기 위해, 각 안전관리대책 유형별로 ‘이행’ 및 ‘미이행’ 데이터를 1:1 비율로 매칭하였다.

표 2.1. 검증 데이터 구성

번호	안전관리대책	전체 데이터	“이행” 데이터	“미이행” 데이터
1	신호수 배치 및 신호봉 소지 여부 확인	284	142	142
2	작업계획서 비치	96	48	48
3	장비 후면 스톱퍼 설치	60	30	30
4	콘크리트 믹서트럭 주변 신호수 배치	98	49	49
5	펌프카 아웃트리거 수평알림경보기 설치	106	53	53
6	펌프카 아웃트리거 최대 확장	96	48	48
7	펌프카 아웃트리거 하부 고임목 또는 철판 설치	78	39	39
8	펌프카 주변 구획 설정	240	120	120
9	펌프카 주변 신호수 배치	88	44	44

2.2. 모델 개발

2.2.1. ‘상용 VLM’ 을 활용한 이행/미이행 분류 모델

본 연구에서는 상용 VLM(Vision-Language Model)의 안전관리대책 이행·미이행 분류 성능을 검증하고자 하였으며, 이에 안정성과 범용성이 검증된 대표적 모델인 GPT-4o를 분석 대상으로 선정하였다. GPT-4o는 OpenAI에서 공개한 다중모달 기반 생성형 인공지능으로, 텍스트·이미지·음성 등 다양한 형태의 입력을 동시에 처리할 수 있는 모델이다 [29]. 특히 이미지 내 객체 인식, 작업 맥락 해석, 조치 실행 판단과 같은 고차원 시각 추론에서 기존 텍스트 기반 모델이나 단순 이미지 분류 모델 대비 우수한 성능을 보이는 것으로 알려져 있다 [30].

이러한 특성은 건설현장 안전관리대책 평가에서 요구되는 핵심 요소 즉, 핵심 객체 식별(예: 아웃트리거, 신호수, 접근 통제선), 작업 맥락 분석(예: 장비 주변 여부, 작업 시점), 실행 조건 충족 여부 판단(예: 설치·배치·확보 상태)을 통합적으로 판단해야 하는 과업의 특성과 부합한다. 또한 GPT-4o는 다양한 산업 분야에서 안정적 성능이 확인된 범용 모델로서, 프롬프트 기반 규칙 설정만으로도 비교적 일관된 판단 기준을 적용할 수 있어, 현장별·촬영별 편차가 큰 건설 안전 이미지 평가에 효과적으로 활용될 수 있다 [31,32]. 따라서, GPT-4o는 별도의 대규모 학습 없이도 안전관리대책의 시각적 이행 여부를 정교한 추론 방식으로 평가할 수 있는 실용적이고 신뢰성 높은 모델로 판단된다.

상용 VLM의 경우, 추가적인 프롬프트 엔지니어링이나 세부 파라미터 조정 없이 기본 입력 구조만으로도 일정 수준의 시각적 이해가 가능하다. 따라서 본 연구에서는 모델의 기본 인식 능력을 평가하기 위해, 안전관리대책 문장과 이미지를 쌍으로 입력하고, 다음과 같은 단일 프롬프트를 사용하였다: “입력된 이미지를 기반으로 주어진 ‘안전관리대책’의 이행 여부를 판단하세요.” 이 프롬프트는 모델이 별도의 사전지식 없이 시각적 단서를 중심으로 ‘이행’ 또는 ‘미이행’을 직접 판단하도록 설계되었다. 이를 통해 ‘상용 VLM’이 현장 이미지를 기반으로 안전관리대책의 이행 여부를 얼마나 정확히 분류할 수 있는지를 1차적으로 분석하고자 한다.

2.2.2. ‘프롬프트 엔지니어링’ 기반 이행/미이행 분류 모델

본 연구에서는 프롬프트 엔지니어링을 적용하여 ‘상용 VLM’ 모델의 성능을 개선하고자 하였다. 나아가 단순한 이행·미이행 분류뿐만 아니라, 각 평가 기준에 따른 정성적 설명을 함께 도출하여 모델의 판단 근거를 명확히 제시하는 것을 목표로 하였다. 프롬프트 엔지니어링이란, 인공지능 모델이 보다 정확하고 일관된 응답을 생성할 수 있도록 입력 문장(프롬프트)의 구조와 내용을 체계적으로 설계하는 기법을 의미한다 [33]. 즉, 단순한 질문 형태의 입력이 아닌, 모델이 수행해야 하는 역할(Role), 지식 수준(Knowledge), 규칙(Rule), 형식(Format) 등을 구체적으로 지정함으로써 모델의 사고 과정을 유도하는 방법이다. 본

연구에서는 기존 상용 VLM 모델의 입력 구조를 개선하기 위해, 프레임워크 요소를 7 가지 중 총 6 가지로 설정하였다 [34,35]. 각 요소는 Role(역할), Audience(대상), Knowledge(지식), Task(작업), Rule(규칙), Format(형식), Examples(예시)로 구성된다. 이 중 ‘Audience(대상)’은 실제 응답 생성에 미치는 영향이 제한적이므로 본 연구에서는 제외하였다. 이외의 6 개 요소는 모델이 건설 안전관리자의 시각에서 이미지를 분석하고, 정의된 평가 기준에 따라 일관된 판단을 내릴 수 있도록 프롬프트에 포함하였다:

- **Role (역할):** AI의 페르소나 또는 역할을 정의하는 요소로, 모델이 배경 지식을 갖고 답변을 제공하도록 유도
- **Audience (대상):** AI의 응답 대상이 되는 사용자나 그룹을 명시하는 요소로, 모델의 응답이 특정 대상에게 맞춰지도록 설정 (복잡성, 어조 등)
- **Knowledge(지식):** 질문과 관련해서 참고할 만한 지식과 정보를 DB 나 검색 엔진 등에서 가져와 삽입하는 요소로, 모델이 응답 제공 시 활용할 배경 지식이나 정보의 범위 지정
- **Task (작업):** 수행해야 하는 구체적인 작업이나 목표를 설정하는 요소로, 모델이 어떤 작업을 수행해야 하는지 명확히 이해하도록 함
- **Rule (규칙):** 응답을 만들 때 따라야 하는 특정 정책이나 규칙, 스타일 가이드, 제약사항을 설정하는 요소로, 응답의 톤, 내용 등

조절

- **Format (형식):** 응답이 따라야 하는 특정 형식이나 구조를 설정하는 요소로, 응답의 구조나 스타일을 명확히 하는 데 유용
- **Examples (예시):** 모델이 작업을 수행하는 데 참고할 수 있는 예시를 제공하는 요소로, 모델이 사용자가 원하는 형태의 응답을 제공

프롬프트의 구성 방식은 두 단계로 구분된다 [36,37]:

- **System Prompt:** 모델의 기본 성격과 배경지식을 설정하여 전체 응답의 방향성을 제어한다. 본 연구에서는 System Prompt 에 ‘Role(역할)’과 ‘Knowledge(배경지식)’ 요소를 포함하여, 모델이 건설 안전관리자의 관점에서 이미지를 평가하고, 평가 기준에 대한 사전 정의를 바탕으로 사고하도록 설정하였다.
- **User Prompt:** 실제 질의 수행에 필요한 세부 지시를 포함한다. 여기에는 ‘Task(작업)’, ‘Rule(규칙)’, ‘Format(형식)’, ‘Examples(예시)’ 요소가 포함되며, 모델이 구체적으로 어떤 평가를 수행하고 어떤 형태로 응답을 생성해야 하는지를 명시하였다.

본 연구에서 정의한 안전관리대책 평가 기준은 총 세 가지이다. 안전관리대책은 시각적 근거를 기반으로 ‘무엇이 존재하는가(객체)’, ‘어떤 상황에서 수행되는가(상황)’, ‘어떻게 실행되었는가(실행)’의 세 가지 요소가 종합적으로 고려되어야 한다. 이에 따라 본 연구에서는

평가 기준을 (i)핵심 객체 식별성, (ii)상황 적합성, (iii)실행 적정성의 세 가지로 설정하였다. 이 세 가지 평가 기준은 각각의 정의와 평가 문항이 프롬프트 설계 단계에서 반영되며, 모델이 정성적 서술과 정량적 판단을 동시에 수행할 수 있도록 유도하였다.

- **(i) 핵심 객체 식별성:** 이미지 내 안전관리대책과 관련된 주요 대상(객체)이 존재하고, 그 형태와 종류가 명확하게 식별되는지 평가한다.
- **(ii) 상황 적합성:** 이미지 내 주요 객체(대상)가 안전관리대책이 요구하는 작업 상황 및 환경에 정확히 놓여 있는지를 평가한다.
- **(iii) 실행 적정성:** 이미지 내 객체(대상)가 안전관리대책이 요구하는 작업 및 조치를 실질적으로 이행했는지를 평가하는 지표

각 평가 기준의 정의 및 지침과 함께, 상용 VLM 에서 발생한 오류의 원인을 분석하여 이를 평가 기준별 참고 데이터로 반영하였다. 이를 통해 상용 VLM 이 오판한 주요 요인을 보완하고, 평가 기준별로 필요한 데이터 항목을 체계적으로 선정하였다. 이후, 프롬프트를 통해 단순 분류 결과뿐 아니라 각 평가 기준에 대한 설명을 추출하고, 이 설명을 기반으로 ‘루브릭 기반 정량화’를 수행하였다. 즉, 모델은 이미지와 안전관리대책을 비교하여 세부 평가 항목별 서술형 설명을 먼저 생성한 뒤, 이후 리커트 척도에 기반하여 각 설명을 근거로 0~5 점 범위의 정량 점수를 부여하고 [38], 최종적으로 4 점 이상을 ‘이행’ 또는 ‘미이행’으로

분류하도록 설계하였다. 이때, LLM 의 대표적인 모델로 ‘GPT-4o’를 활용하였다. GPT-4o 는 텍스트와 이미지를 동시에 처리할 수 있는 다중모달 생성형 모델로, 각 평가 기준에 대해 0 점에서 5 점까지(소수점 1 자리 단위) 세밀한 점수 부여가 가능하였다. 평가 결과는 각 기준별 루브릭에 따라 산정되었으며, 해당 루브릭의 세부 내용은 [표 2.2.2-2.2.4]에 제시하였다.



표 2.2.2. (i) 핵심 객체 식별성 루브릭

점수	내용
4.1~5.0 점	안전관리대책에 언급된 핵심 객체가 이미지 내에 명확하게 존재하며, 그 형태와 종류가 선명하게 식별되어, 시야 제한(흐림, 가림 등) 없이 전체적으로 핵심 객체의 인식이 완전한 상태이다.
3.1~4.0 점	안전관리대책에 언급된 핵심 객체가 이미지 내에 존재하며, 그 형태와 종류는 대부분 식별 가능하나, 일부 시야 제한으로 인해 핵심 객체의 일부 인식이 불명확한 상태이다.
2.1~3.0 점	안전관리대책에 언급된 핵심 객체가 이미지 내에 존재하나, 비교적 넓은 범위의 시야 제한으로 인해 그 형태 또는 종류의 식별에 어려움이 있어, 핵심 객체로 추정 가능한 상태이다.
1.1~2.0 점	안전관리대책에 언급된 핵심 객체가 이미지 내에 존재하는 것으로 추정되지만, 상당히 넓은 범위의 시야 제한으로 인해 핵심 객체의 인식이 매우 제한적이거나 거의 불가능한 상태이다.
0.0~1.0 점	안전관리대책에 언급된 핵심 객체가 이미지 내에 전혀 존재하지 않고, 극심히 넓은 범위의 시야 제한으로 인해 핵심 객체의 인식이 사실상 불가능한 상태이다.

표 2.2.3. (ii) 상황 적합성 루브릭

점수	내용
4.1~5.0 점	안전관리대책에 언급된 작업 상황 및 환경이 명확히 드러나며 분명하게 확인된다.
3.1~4.0 점	안전관리대책에 언급된 작업 상황 및 환경이 대체로 충족되어 충분히 인지 가능하지만, 일부 요소에서 미미한 불확실성이 존재한다.
2.1~3.0 점	안전관리대책에 언급된 작업 상황 및 환경 중 일부가 부적절하거나 충족되지 않아, 확신이 낮은 상황이다.
1.1~2.0 점	안전관리대책에 언급된 작업 상황 및 환경 중 대부분이 부적절하거나 충족되지 않아, 연관성이 약한 상황이다.
0.0~1.0 점	안전관리대책에 언급된 작업 상황 및 환경이 전혀 충족되지 않아, 불필요하거나 명백히 부적절한 상황이다.

표 2.2.4. (iii) 실행 적정성 루브릭

점수	내용
4.1~5.0 점	핵심 객체가 안전관리대책의 언급된 요구사항에 따라 정확한 방식으로 완전히 실행되어 있으며, 기능을 안정적이고 적절하게 수행할 수 있는 상태이다.
3.1~4.0 점	핵심 객체가 안전관리대책의 언급된 요구사항에 따라 대부분 적절하게 실행되어 기능 수행에는 문제가 없으나, 일부 상태나 방식에서 미미한 보완이 필요한 상태이다.
2.1~3.0 점	핵심 객체가 안전관리대책의 언급된 요구사항에 따라 부분적으로만 실행되었거나 일부 차이가 있는 방식으로 실행되어, 기능 수행의 제한 또는 신뢰도 저하가 발생하는 상태이다.
1.1~2.0 점	핵심 객체가 안전관리대책의 언급된 요구사항에 따라 대부분이 실행되지 않았거나 형식적으로만 실행되어, 기능 수행이 어렵거나 부적절한 상태이다.
0.0~1.0 점	핵심 객체가 안전관리대책의 언급된 요구사항에 따라 전혀 실행되지 않았거나, 기능 수행이 불가능할 정도로 부적절한 상태이다.

2.3. 모델 평가

본 연구에서는 제안한 프롬프트 기반 VLM 모델의 성능을 정량적으로 평가하기 위해, 총 9 개 안전관리대책 유형에 대해 수집된 1,146 건의 ‘안전관리대책-이미지 쌍’을 대상으로 실험을 수행하였다.

모델이 예측한 ‘이행’ 및 ‘미이행’ 결과의 정확성을 검증하기 위해, OO 건설사의 안전관리 전문가 그룹에게 해당 데이터의 실제 이행 여부를 검토받았다. 전문가 검토는 각 이미지가 제시하는 시각적 근거를 바탕으로 이루어졌으며, 안전관리대책 문구에 명시된 요구사항을 충족했는지를 기준으로 판단하였다. 이를 통해 구축된 전문검토 결과는 모델 예측값과의 비교를 위한 ‘정답 레퍼런스(ground truth)’로 활용되었다. 즉, 각 이미지에 대해 전문가가 판단한 ‘이행’ 또는 ‘미이행’ 결과를 기준으로, 모델의 예측 결과(Type1~Type4)를 분류하고, 그에 따른 정확도(Accuracy), 가중정확도(Weighted Accuracy), 미이행 오답률(Type2), 이행 오답률(Type3) 등을 산출하였다.

이러한 전문가 기반 검증 절차를 거침으로써, 본 연구는 단순한 모델 예측 성능 비교를 넘어, 실제 현장 평가 기준에 부합하는 신뢰도 기반의 성능 검증 체계를 구축하였다. 이후 혼동행렬(Confusion Matrix)을 바탕으로 2.3.1.에서는 Accuracy 및 Weighted Accuracy, 2.3.2에서는 미이행 오답률(Type2), 2.3.3.에서는 이행 오답률(Type3)의 세부 지표에 대해 구체적으로 설명하고자 한다 [그림 2.3].

		Actual	
		Implementation	Non-implementation
Predict	Implementation	Correct Type1 (TP)	Incorrect Type2 (FP)
	Non-implementation	Incorrect Type3 (FN)	Correct Type4 (TN)

그림 2.3. 혼동행렬 기반 Type1-4 정의

2.3.1. Weighted Accuracy

본 연구에서는 제안한 프롬프트 기반 VLM 모델의 성능을 정량적으로 검증하기 위해, 안전관리대책 유형별 ‘정확도(Accuracy)’를 주요 평가 지표로 활용하였다. 정확도는 모델이 예측한 결과 중에서 실제 정답(전문가 검토 결과)과 일치하는 비율을 의미하며, 일반적으로 다음과 같이 정의된다 [39].

$$Accuracy = \frac{\text{맞춘 개수}}{\text{전체 데이터 수}} = \frac{TP + TN}{TP + TN + FP + FN} \quad (2-1)$$

(i) TP (True Positive): 실제 ‘이행’을 ‘이행’으로 올바르게 예측한 경우(Type1)

(ii) TN (True Negative): 실제 ‘미이행’을 ‘미이행’으로 올바르게 예측한 경우(Type4)

(iii) FP (False Positive): 실제 ‘미이행’을 잘못 ‘이행’으로 예측한 경우(Type2)

(iv) FN (False Negative): 실제 ‘이행’을 잘못 ‘미이행’으로 예측한 경우(Type3)

즉, Accuracy 는 모델이 전체 데이터 중에서 정확히 예측한 비율을 나타내며, 값이 1 에 가까울수록 모델의 예측이 정답과 잘 일치함을 의미한다. 또한, 본 연구에서는 단순히 전체 데이터에 대한 Accuracy 만으로는 충분하지 않다고 판단하였다. 그 이유는 ‘이행’과 ‘미이행’ 두 클래스 모두 안전관리 측면에서 동등하게 중요한 판단 대상이기 때문이다. 즉, ‘이행’을 정확히 판단하는 능력뿐 아니라, ‘미이행’을 정확히 감지하는 능력 역시 안전사고 예방의 핵심 요소이므로, Accuracy 는 두 범주를 모두 반영한 전반적 분류 성능의 개괄적 지표로 활용하였다. 다만, 본 연구에서 다루는 각 안전관리대책 유형별 데이터의 규모에는 차이가 존재한다. 이와 같이 데이터 편차가 존재하는 경우, 단순히 모든 유형의 Accuracy 를 평균하면 데이터 수가 적은 유형이 과도하게 반영되거나, 반대로 대규모 유형이 전체 성능을 왜곡할 가능성이 있다. 따라서 본 연구에서는 이러한 불균형을 보정하기 위해, 가중 정확도(Weighted Accuracy) 지표를 도입하였다 [40]. 가중

정확도는 각 안전관리대책 유형의 데이터 수를 가중치로 반영하여 계산되며, 다음 식으로 정의된다:

$$Weighted\ Accuracy = \frac{\sum_{i=1}^n (w_i \times A_i)}{\sum_{i=1}^n w_i} \quad (2-2)$$

(i) n : 안전관리대책 유형의 개수

(ii) N_i : i 번째 안전관리대책 유형의 전체 데이터 수

(iii) $Accuracy_i$: i 번째 안전관리대책 유형의 정확도

즉, 각 안전관리대책 유형의 $Accuracy$ 를 단순 평균하지 않고, 유형별 데이터 비중(N_i)을 고려해 가중 평균함으로써 모델의 전반적인 분류 성능을 보다 공정하게 평가할 수 있다.

2.3.2. 미이행 오답률

모델의 성능을 평가함에 있어, 단순한 정확도(Accuracy)만으로는 안전관리 측면의 실제 위험을 충분히 반영하기 어렵다. 특히 건설현장의 안전관리 업무에서는 ‘이행’과 ‘미이행’의 구분이 단순한 데이터 분류를 넘어 사고 예방의 직접적 판단 기준으로 작용한다. 따라서 본 연구에서는 $Accuracy$ 외에도, 모델이 실제 미이행된 안전관리대책을 놓치는 비율을 평가하기 위해 ‘미이행 오답률(Type2 Error Rate)’을 지표로 산정하였다.

Type2 는 실제로는 ‘미이행’ 상태임에도 불구하고, 모델이 이를 ‘이행’으로 잘못 판단한 경우를 의미한다. 즉, 현장에서 안전관리대책이 제대로 수행되지 않았음에도 불구하고, 모델이 이를 정상적으로 이행된 것으로 간주하는 ‘위험 간과형 오류’에 해당한다. 이러한 오류는 단순한 예측 실수 이상의 문제를 초래한다. 모델이 미이행된 상태를 올바르게 인식하지 못할 경우, 현장의 안전 담당자가 실제로 위험이 존재함에도 불구하고 이를 확인하거나 조치하지 않을 가능성이 높아진다. 결과적으로, Type2 의 발생은 안전사고로 직접 이어질 수 있는 잠재적 위험 요소로 간주된다. 본 연구에서는 Type2 오답률을 다음과 같은 식으로 정의하였다:

$$Type2\ Error\ Rate = \frac{Type2}{Type2+Type4} = \frac{FP}{FP+TN} \quad (2-3)$$

본 연구에서는 Type2 오답률을 중심으로 모델의 안전성을 분석하였다. Type2 가 높은 유형은 모델이 실제 위험 상황을 탐지하지 못하는 취약성을 지닌 것으로 해석하며, 이러한 유형을 식별함으로써 현장의 안전관리대책 중 모델이 상대적으로 취약하게 인식하는 유형을 도출할 수 있다. 이는 단순히 모델의 성능을 개선하기 위한 분석일 뿐 아니라, 실제 건설현장에서 시각정보 기반 위험 검출 시스템의 실무적 개선 방향을 제시하는 데에도 활용될 수 있다. 본 연구에서는 각 안전관리대책 유형별로 Type2 오답률을 산출하여, 모델이 안전조치 미이행 상황을 얼마나 정확히 감지할 수 있는지를 검증하였다. 이를

통해 ‘모델이 실제 위험을 놓치지 않는가(안전성)’를 중점적으로 평가하였으며, Type2 가 낮을수록 모델의 위험 식별 능력이 높다고 판단하였다. 결과적으로, 미이행 응답률은 단순한 분류 지표가 아니라, 모델의 실질적 안전관리 성능을 평가하는 핵심 지표로 활용되었다. 향후 모델 개선 시 Type2 가 높은 안전관리대책 유형을 중심으로 프롬프트 설계나 데이터 보강을 진행함으로써, 모델의 안전성 신뢰도를 지속적으로 향상시킬 수 있다.

2.3.3. 이행 응답률

Type3 은 실제로는 ‘이행’된 상태임에도 불구하고, 모델이 이를 ‘미이행’으로 잘못 판단한 경우를 의미한다. 즉, 현장에서 안전관리대책이 적절히 수행되었음에도 불구하고, 모델이 이를 미이행으로 분류하는 ‘과잉 판단형 오류’에 해당한다. 이러한 오류는 Type2(미이행 응답률)과는 반대되는 개념으로, 실제로는 안전조치가 완료된 상태를 불필요하게 위험 상황으로 간주하는 오류라고 할 수 있다.

건설현장의 안전관리 체계에서는 위험 요소의 누락(Type2)을 방지하는 것이 우선적이지만, 동시에 과잉 판단(Type3) 역시 중요한 관리 지표로 다루어진다. 그 이유는, 모델이 정상적으로 수행된 작업을 지속적으로 미이행으로 판정할 경우, 불필요한 행정 절차와 재점검이 반복되어 안전관리 인력의 업무 과중 및 비효율로 이어질 수 있기 때문이다. 또한, 이러한 과잉경고는 안전관리 시스템 전반의 신뢰도를

저하시켜, 사용자(안전관리자)가 모델의 결과를 신뢰하지 않게 되는 부작용을 초래할 수 있다. Type3 오답률은 다음과 같은 식으로 정의된다:

$$Type3\ Error\ Rate = \frac{Type3}{Type3 + Type1} = \frac{FN}{FN + TP} \quad (2-4)$$

본 연구에서는 Type3 오답률을 통해 모델의 안전관리 효율성 정도를 분석하였다. Type3 오답률이 낮을수록 모델이 실제 이행된 조치를 정확히 인식하며, 이는 안전관리대책 평가의 정확성과 실무 효율성이 높다는 것을 의미한다. 반대로 Type3 이 높게 나타나는 경우, 모델이 현장의 시각적 증거를 과도하게 엄격하게 해석하거나, 특정 조건(조명, 각도, 가림 등)에 취약함을 시사한다. 이러한 결과는 프롬프트 구성 또는 학습 데이터 보강을 통해 개선해야 할 항목으로 해석된다. 최종적으로 Type3 오답률은 단순한 분류 오류의 개념을 넘어, 모델의 실무 적용 가능성과 효율성 측면을 평가하는 핵심 지표로 활용된다.

제 3장 분석 결과

3.1. 모델별 분류성능 비교

본 절에서는 상용 비전-언어 모델(Vision-Language Model, VLM)과 프롬프트 엔지니어링 기반 제안모델 간의 이행/미이행 분류 성능을 정량적으로 비교하였다. 분석은 앞서 제시한 9 개 안전관리대책 유형의 총 1,146 쌍의 이미지-문장 데이터를 대상으로 수행하였으며, 각 모델의 Weighted Accuracy 를 주요 평가 지표로 사용하였다. Weighted Accuracy 는 안전관리대책 유형별 데이터 수가 상이한 점을 고려하여 각 유형의 정확도에 데이터 가중치를 부여한 평균값으로 산정하였다. 이는 개별 항목의 불균형이 전체 성능에 미치는 영향을 완화하고, 모델의 종합적 분류 성능을 객관적으로 평가하기 위한 지표로 활용되었다.

그 결과, 상용 VLM 의 Weighted Accuracy 는 ‘74.77%’로 나타나, 이행/미이행 분류 정확도가 전반적으로 낮은 수준이었다. 이는 단일 프롬프트 입력만으로 모델이 안전관리대책 문구의 세부 조건이나 현장 맥락을 충분히 반영하지 못한 데 기인한 것으로 분석된다. 특히, 프롬프트 엔지니어링 기반 제안모델의 Weighted Accuracy 는 ‘88.58%’로, 상용 VLM 대비 13.81%p 향상된 성능을 보였다 [표 3.1]. 이는 평가 기준(핵심 객체 식별성, 상황 적합성, 실행 적정성)을 명시적으로

프롬프트에 반영함으로써, 모델이 이미지 내 객체와 문맥적 조건을 보다 구체적으로 인식하고 정확한 판단을 수행할 수 있었기 때문에 판단된다. 또한, 제안모델은 단순한 분류 결과뿐 아니라, 평가 기준별 설명을 함께 생성하고 이를 ‘루브릭 기반으로 정량화(0~5 점)’함으로써 모델의 판단 근거를 명확히 제시하였다. 이 과정은 결과의 ‘설명 가능성’을 확보하여 실제 현장에서 결과를 해석하고 검증하는 데 있어 신뢰성을 향상시킨 것으로 나타났다. 따라서, 본 연구에서 제안한 프롬프트 엔지니어링 기반 모델은 상용 VLM 대비 이행/미이행 분류의 정확도 및 판단 근거의 명확성 측면에서 우수한 성능을 확인할 수 있었다.

표 3.1. 모델 성능(Accuracy 및 Weighted Accuracy)

번호	안전관리대책	전체 데이터	“이행 데이터”	“미이행” 데이터	Accuracy		
					상용 VLM	제안 모델	개선 정도
1	신호수 배치 및 신호봉 소지 여부 확인	284	142	142	0.827	0.972	14.50% ▲
2	작업계획서 비치	96	48	48	0.969	0.979	1.00% ▲
3	장비 후면 스톱퍼 설치	60	30	30	0.600	0.800	20.00% ▲
4	콘크리트 믹서트럭 주변 신호수 배치	98	49	49	0.551	0.684	13.30% ▲
5	펌프카 아웃트리거 수평알림 경보기 설치	106	53	53	0.726	0.792	6.60% ▲
6	펌프카 아웃트리거 최대 확장	96	48	48	0.594	0.740	14.60% ▲
7	펌프카 아웃트리거 하부 고임목 또는 철판 설치	78	39	39	0.731	0.987	25.60% ▲
8	펌프카 주변 구획 설정	240	120	120	0.683	0.892	20.90% ▲
9	펌프카 주변 신호수 배치	88	44	44	0.955	0.955	0.00%
-	모델 전체(Weighted Accuracy)	1,146	573	573	74.77%	88.58%	18.31 %▲

3.2. 모델별 현장 적용성 비교

본 절에서는 상용 VLM 과 프롬프트 엔지니어링 기반 제안모델 간의 현장 적용성을 비교·분석하였다. 현장 적용성은 단순한 분류 정확도 외에도, 모델이 실제 건설현장의 안전관리 상황을 얼마나 신뢰성 있게 반영하는가를 평가하기 위해 ‘미이행 응답률(Type2)’ 과 ‘이행 응답률(Type3)’을 중심으로 검토하였다.

‘미이행 응답률(Type2)’은 실제로 안전관리대책이 이행되지 않았음에도 불구하고 모델이 이를 ‘이행’으로 잘못 분류한 사례를 의미한다. 이는 현장의 사고 위험을 증가시킬 수 있어 안전성측면에서 매우 치명적인 문제로 간주된다. 특히, ‘콘크리트 믹서트럭 주변 신호수 배치’ 및 ‘펌프카 아웃트리거 최대 확장’과 같은 항목에서 안전관리대책에 언급된 상황을 제대로 반영하지 못해 미이행 상태를 이행으로 잘못 분류하는 경향이 뚜렷하게 나타났다. 분석 결과, 상용 VLM 의 경우 9 개 안전관리대책 중 4 개 유형에서 Type2 응답률이 높게 나타나, 실제 미이행 상태를 정확히 인식하지 못하는 한계가 확인되었다 [표 3.2].

‘이행 응답률(Type3)’은 실제로 안전관리대책이 이행되었음에도 불구하고 모델이 이를 ‘미이행’으로 잘못 분류한 사례를 의미한다. 이는 현장의 안전관리 효율성을 저하시킬 수 있어 효율성 측면에서 매우 치명적인 문제로 간주된다. 분석 결과, 상용 VLM 의 경우 9 개 안전관리대책 중 3 개 유형에서 Type3 응답률이 높게 나타나, 실제 이행

상태를 정확히 인식하지 못하는 한계가 확인되었다 [표 3.3].

Type2 와 Type3 의 발생 원인을 분석하고, 이를 평가 기준 분석 시 참고할 수 있도록 관련 데이터를 추가하였다. 핵심 객체 식별성 평가에서는 주요 객체 정보를, 상황 적합성 평가에서는 작업 환경 및 조건을, 실행 적정성 평가에서는 실행 상태와 관련된 요소를 각각 참고 데이터로 활용하였다. 이후 안전관리대책과 참고 데이터를 기반으로, 입력된 이미지를 각 평가 기준에 따라 분석하도록 하였다. 참고 데이터의 예시는 [표 3.4]에 제시하였다.

표 3.2. 미이행 응답률(Type2) 원인 분석 결과

번호	안전관리대책	Type1	Type2	Type3	Type4	“미이행” 응답률 (Type2)	Type2 CASE	필요 요소
1	신호수 배치 및 신호봉 소지 여부 확인	142	49	0	93	34.51%	신호수의 손이 가려져 있거나 보이지 않아 신호봉 소지 여부를 확인 할 수 없으나 ‘이행’ 으로 판정	객체 인식, 실행 조건 이해 필요
4	콘크리트 믹서트럭 주변 신호수 배치	49	44	0	5	89.80%	펌프카가 존재하거나 믹서트럭이 부분적으로만 도출되어 ‘믹서트럭 주변’ 으로 판단하기 어려우나 ‘이행’ 으로 판정	객체 인식, 실행 조건, 상황(환경) 이해 필요
6	펌프카 아웃트리거 최대 확장	48	39	0	9	81.25%	아웃트리거가 펌프카의 한쪽 면만 확장되어 양측면 확장 여부를 확인 할 수 없으나 ‘이행’ 으로 판정	객체 인식, 실행 조건 이해 필요
7	펌프카 아웃트리거 하부 고임목 또는 철판 설치	38	20	1	19	51.28%	아웃트리거 하부가 가려져 있어 고임목 및 철판 설치 여부를 확인할 수 없으나 ‘이행’ 으로 판정	객체 인식, 실행 조건 이해 필요

표 3.3. 이행 오답률(Type3) 원인 분석 결과

번호	안전관리대책	Type1	Type2	Type3	Type4	“이행” 오답률 (Type3)	Type3 CASE	필요 요소
3	장비 후면 스톱퍼 설치	13	7	17	23	56.67%	장비 후면에 스톱퍼가 설치 되어 있으나, '미이행'으로 판정	객체 인식, 실 행 조건 이해 필요
5	펌프카 아웃트리거 수평 알림 경보기 설치	30	6	23	47	43.40 %	아웃트리거 상단에 수평알림 경보기가 설치되어 있으나, '미이행'으로 판정	객체 인식, 실 행 조건 이해 필요
8	펌프카 주변 구획 설정	62	18	58	102	48.33 %	펌프카 주변에 라바콘 또는 위험테이프로 구획이 설정되어 있으나, '미이행' 으로 판정	객체 인식, 실 행 조건, 상황 (환경) 이해 필요

표 3.4. 평가 기준별 참고 데이터

번호	안전관리대책	핵심 객체 식별성		상황 적합성		실행 적정성	
		분석 여부	참고 데이터	분석	참고 데이터	분석	참고 데이터
1	신호수 배치 및 신호봉 소지 여부 확인	○	신호수, 신호봉	-	-	○	신호수가 현장에 배치되어 있으며, 손에 경광봉을 소지한 상태여야 함.
2	작업계획서 비치	○	작업계획서	-	-	○	작업계획서를 손에 들고 직접 촬영하거나 게시판에 비치되어 있어야 함.
3	장비 후면 스톱퍼 설치	○	스톱퍼	-	-	○	장비 후면에 스톱퍼가 설치되어 있어야 함.
4	콘크리트 믹서트럭 주변 신호수 배치	○	신호수	○	작업 환경은 콘크리트 믹서트럭 주변이며, 믹서드럼이 식별되어야 '콘크리트 믹서트럭 주변' 으로 판단함.	○	콘크리트 믹서트럭 주변에 신호수가 배치되어 있어야 함.

5	펌프카 아웃트리거 수평알림 경보기 설치	○	수평알림 경보기	-	-	○	펌프카 아웃트리거 상단에 수평알림 경보기가 설치되어 있어야 함.
6	펌프카 아웃트리거 최대 확장	○	펌프카 아웃트리거	-	-	○	펌프카의 양측면에 아웃트리거가 확장되어 있어야 함.
7	펌프카 아웃트리거 하부 고임목 또는 철판 설치	○	고임목 또는 철판	-	-	○	펌프카 아웃트리거 하부에 고임목 또는 철판이 설치되어 있어야 함.
8	펌프카 주변 구획 설정	○	구획설정 시설물 (라바콘 또는 위험테이프 등)	○	작업 환경은 펌프카 주변이어야 하며, 펌프카의 본체 또는 아웃트리거가 식별되어야 '펌프카 주변'으로 판단함.	○	펌프카 주변에 구획(위험테이프, 라바콘 등)이 연속적으로 설정되어 있어야 함.
9	펌프카 주변 신호수 배치	○	신호수	○	작업 환경은 펌프카 주변이어야 하며, 펌프카의 본체 또는 아웃트리거가 식별되어야 '펌프카 주변'으로 판단함.	○	펌프카 주변에 신호수가 배치되어 있어야 함.

이에 프롬프트 엔지니어링 기반 제안모델은 ‘미이행 응답률(Type2)’이 최대 51.28% 감소하여 안전성 측면에서 현저히 개선된 결과를 보였다 [표 3.5]. 이는 각 항목의 응답 원인을 분석하여 해당 근거를 평가 기준의 참고 데이터로 프롬프트에 입력한 결과이다. 특히 ‘상황 적합성’을 명시적으로 포함함으로써, 모델이 이미지 내 상황적 단서를 보다 정밀하게 인식할 수 있었던 것으로 해석된다.

또한, 제안모델은 ‘이행 응답률(Type3)’ 역시 최대 42.50% 감소하여 이행 상태를 불필요하게 ‘미이행’으로 분류하는 오류가 크게 줄어들었다 [표 3.6]. 이는 평가 기준별 설명(Description)을 통해 모델이 이행 근거를 명확히 파악하고, 그 판단을 루브릭 기반으로 정량화할 수 있었기 때문으로 분석된다. 종합적으로, 프롬프트 엔지니어링 기반 제안모델은 Type2 감소를 통해 안전성을 향상시키고, Type3 감소를 통해 안전관리 효율성을 개선한 것으로 나타났다. 따라서 본 모델은 단순 분류 정확도 향상을 넘어, 현장 중심의 안전관리 체계에서 신뢰성 있고 효율적인 의사결정을 지원할 수 있는 실질적 적용 가능성을 갖춘 것으로 판단된다.

표 3.5. 안전관리대책 유형별 ‘미이행 응답률(Type2)’

No.	안전관리대책	전체 데이터	“이행” 데이터	“미이행” 데이터	“미이행” 응답률 (Type2)		
					상용 VLM	제안 모델	개선 정도
1	신호수 배치 및 신호봉 소지 여부 확인	284	142	142	34.51%	0.00%	-34.51% ▼
4	콘크리트 믹서트럭 주변 신호수 배치	98	49	49	89.80%	63.27%	-26.53% ▼
6	펌프카 아웃트리거 최대 확장	96	48	48	81.25%	52.08%	-29.17% ▼
7	펌프카 아웃트리거 하부 고임목 또는 철판 설치	78	39	39	51.28%	0.00%	-51.28% ▼

표 3.6. 안전관리대책 유형별 ‘이행 응답률(Type3)’

No.	안전관리대책	전체 데이터	“이행” 데이터	“미이행” 데이터	“미이행” 응답률 (Type2)		
					상용 VLM	제안 모델	개선 정도
3	장비 후면 스톱퍼 설치	60	30	30	56.67 %	36.67%	- 20.00% ▼
5	펌프카 아웃트리거 수평알림 경보기 설치	106	53	53	43.40%	35.85%	-7.55% ▼
8	펌프카 주변 구획 설정	240	120	120	48.33%	5.83%	-42.50% ▼

3.3. 고찰

본 연구는 프롬프트 엔지니어링을 적용하여 제안된 이행/미이행 분류 모델의 정확성과 현장 적용 가능성을 향상시킬 수 있는지를 검증하였다. 제안모델은 평가 기준으로 (i) 핵심 객체 식별성, (ii) 상황 적합성, (iii) 실행 적정성을 적용하여, 모델이 단순 분류를 넘어 평가 근거를 설명할 수 있도록 설계되었다. 본 연구의 결과는 학문적 측면과 실무적 측면에서 다음과 같이 요약될 수 있다.

- **학문적 측면:** 본 연구는 ‘비전-언어 모델(VLM)’에 프롬프트 엔지니어링(Prompt Engineering) 기법을 적용하여, 건설 현장의 안전관리대책 이행 여부를 자동으로 분류하는 새로운 접근법을 제시하였다. 기존 상용 VLM 이 단순한 이미지-텍스트 매칭 수준에 머물렀던 것과 달리, 본 연구에서는 (i) 핵심 객체 식별성, (ii) 상황 적합성, (iii) 실행 적정성의 세 가지 평가 기준을 정의하고 이를 프롬프트 구조에 통합함으로써, 모델이 단순한 시각적 인식 단계를 넘어 맥락적 사고를 수행할 수 있도록 하였다. 그 결과, 제안모델은 상용 GPT-4o 기반 VLM 에 비해 가중정확도(Weighted Accuracy)가 13.81%p 향상되었으며, Type2(미이행을 이행으로 판단) 및 Type3(이행을 미이행으로 판단) 오류가 모두 감소하였다. 이는 프롬프트 구조화와 평가 기준 기반 정량화의 효과를 실증적으로 입증한 결과로, 건설안전 분야에서 설명 가능한 인공지능과 프롬프트 엔지니어링을 접목한

최초의 시도라는 점에서 학문적 의의가 있다. 또한, 본 연구는 ‘루브릭 기반 정량화’ 방식을 도입하여 VLM의 추론 결과를 정성적 서술과 정량적 점수(0~5 점)로 함께 제시함으로써, 향후 평가 자동화, AI 감사, 안전관리 보고 자동화 등으로 확장 가능한 정량·정성 통합형 프레임워크의 가능성을 제시하였다.

- **실무적 측면:** 본 연구의 결과는 실제 건설현장의 안전관리 효율성과 신뢰성 향상 측면에서 실질적인 적용 가치를 지닌다. 현재 다수의 현장에서는 ‘일일 위험성 평가서’를 수작업으로 작성하고 있으며, 담당자가 업로드한 이미지가 단순히 “이행”으로 처리되는 등 검증 절차의 신뢰성에 한계가 존재한다. 본 연구에서 제안한 프롬프트 엔지니어링 기반 VLM은 이행·미이행 자동 판별과 동시에 평가 기준별 설명을 제공함으로써, 현장-본사 간 안전관리 의사소통의 투명성과 효율성을 동시에 향상시킬 수 있다. 특히, Type2(미이행 오판) 감소를 통해 안전성 간과를 방지하고, Type3(이행 오판) 완화를 통해 불필요한 행정 업무를 줄임으로써 현장 관리자와 본사 담당자 모두의 업무 효율성을 향상시킬 수 있다. 이러한 결과는 프롬프트 엔지니어링이 단순한 모델 성능 개선 도구를 넘어, AI 기반 건설 안전관리 체계의 실질적 의사결정 지원 시스템으로 발전할 수 있음을 시사한다.

한편, 본 연구에서는 건설현장의 안전관리대책 이행 여부를 자동으로 분류하기 위한 ‘비전-언어 모델(VLM)’을 제안하였다. 제안된 VLM은 이미지와 텍스트 정보를 통합적으로 분석하여 이행 및 미이행을 판별함으로써, 건설현장의 안전관리 효율성과 신뢰성을 향상시킬 수 있는 가능성을 확인하였다. 향후 본 연구의 확장 방향은 다음과 같이 제시할 수 있다:

- **(i) 다양한 공종에 대한 확장성 확보:** 본 연구는 골조공사 중 콘크리트 타설-슬라브 타설 작업을 중심으로 검증을 수행하였다. 향후 연구에서는 토공, 마감, 기계·전기설비 등 다른 공종으로 적용 대상을 확대하여, 공종별 특성과 작업환경의 차이를 반영한 안전관리대책 자동 판별 모델로 발전시킬 필요가 있다.
- **(ii) 이행·미이행 오류율의 추가 개선:** 본 연구에서 확인된 Type2(미이행을 이행으로 판단)와 Type3(이행을 미이행으로 판단) 오류를 중심으로 세부 오류 원인을 분석하고, 이에 기반한 세분화된 Fine-tuning을 수행함으로써 안전관리대책 유형별로 특화된 개선 전략을 마련할 필요가 있다. 이를 통해, AI 기반 안전관리 체계가 단순 보조도구를 넘어 실질적인 의사결정 지원 시스템으로 발전할 수 있을 것으로 기대된다.
- **(iii) 데이터 다양성과 일반화 성능의 고도화:** 향후 연구에서는 이미지 데이터의 다양성을 확대하고, 조명, 거리, 가림, 기상 조건 등 다양한 현장 환경을 반영한 증강 데이터를 구축할 필요가

있다. 이를 통해 모델의 일반화 성능을 강화하고, 현장 여건의 변화에도 안정적으로 작동하는 신뢰성 높은 모델로 발전시킬 수 있을 것이다.



제 4장 결론

본 연구는 ‘프롬프트 엔지니어링’을 활용하여 ‘상용 VLM’의 이행/미이행 분류 성능을 향상시키고자 하였다. 이를 위해 골조공사 중 콘크리트 타설 공정의 슬라브 타설 작업을 대상으로 하였으며, 총 9 개 유형의 안전관리대책에 대한 1,146 쌍의 안전관리대책-이미지 데이터를 구축하여 검증을 수행하였다. 제안모델은 (i) 핵심 객체 식별성, (ii) 상황 적합성, (iii) 실행 적정성의 세 가지 평가 기준을 토대로 설명(Description)을 추출하고, 이후 대규모 언어모델(LLM, GPT-4o)을 활용하여 해당 설명을 루브릭 기반으로 0~5 점 범위에서 정량화하였다. 세 평가 기준 중 모든 항목이 4 점 이상인 경우 ‘이행’으로, 하나라도 4 점 미만인 경우 ‘미이행’으로 판단하였으며, 이를 전문가 검토 결과(정답)와 비교하여 이행/미이행 분류 성능을 분석하였다. 본 연구의 주요 결과는 모델 전체 분류 성능과 모델 별 현장 적용성(안전성 및 효율성) 측면의 분석 결과로 구분하여 제시할 수 있다.

- **모델별 이행/미이행 분류 성능:** ‘상용 VLM’을 활용한 이행/미이행 분류 성능과 ‘프롬프트 엔지니어링’ 기반 ‘제안모델’을 활용한 이행/미이행 분류 성능을 각각 평가한 결과, ‘상용 VLM’의 분류 성능(Weighted Accuracy)은 74.77%로 비교적 낮았다. 또한, 검증 시 이행/미이행 판단 기준을 신뢰할 수 없는 것으로 보였다.

이는 프롬프트 엔지니어링 없이 모델이 안전관리대책의 핵심 객체나 상황 및 실행 조건을 충분히 반영하지 못한 데 기인한 한계로 판단된다. 반면, 평가 기준 기반의 프롬프트 엔지니어링 기법을 활용한 ‘제안모델’은 88.58%로 ‘상용 VLM’ 모델에 비해 13.81% 증가하였다. 이에 현장에서 요구되는 기본적인 신뢰도 수준을 충분히 충족하는 결과를 보였으며, 실제 업무 적용 가능성을 실증적으로 확인하였다. 또한, 평가 기준별 설명(Description)을 루브릭 기반의 정량화 과정과 함께 추출함으로써, 모델의 판단 근거가 명확해지고 결과 해석의 신뢰성이 향상되었다. 이러한 결과를 통해, 프롬프트 엔지니어링 기반 구조가 이행/미이행 분류 성능 개선뿐 아니라, 설명 가능성과 신뢰성 향상에도 효과적임을 확인할 수 있었다. 후속 연구에서는 실제 건설현장 이미지 데이터를 추가 수집하고, Qwen · LLaMA · InternVL 등 다양한 VLM 에 대한 fine-tuning 을 적용하여 모델의 일반화 성능을 강화할 필요가 있다. 이를 통해 모델이 안전관리대책의 세부 표현, 장비 · 작업 조건의 다양성, 자연광 · 초점 · 노출 조건 변화 등 실제 현장의 변동성을 더욱 안정적으로 처리할 수 있을 것으로 기대된다.

- **모델별 현장 적용성(안전성 및 효율성):** 모델별 현장 적용성(안전성 및 효율성)을 비교한 결과, ‘상용 VLM’에 비해 프롬프트 엔지니어링 기반 ‘제안모델’의 분류 성능이 향상된

것으로 나타났다. 제안모델의 가중 정확도(Weighted Accuracy)는 ‘상용 VLM’ 대비 13.81% 증가하였으며, 이는 프롬프트 엔지니어링을 통해 평가 기준별 판단 근거를 명확히 제시할 수 있었기 때문으로 분석된다. 나아가 현장 적용성 즉, 안전성 및 효율성 측면에서 살펴보면, 두 모델 간 뚜렷한 차이가 확인되었다. ‘상용 VLM’의 경우, 안전관리대책 9 건 중 4 건에서 ‘미이행 오답률(Type2)’이 높게 나타나 안전성 확보 측면에서 한계가 있었으며, 9 건 중 3 건에서는 ‘이행 오답률(Type3)’이 높아 안전관리 효율성 측면에서 개선이 필요한 것으로 분석되었다. 반면, 프롬프트 엔지니어링 기반 제안모델은 이러한 오류가 큰 폭으로 감소하였다. 특히, ‘미이행 오답률(Type2)’은 최대 51.28% 감소, ‘이행 오답률(Type3)’은 최대 42.50% 감소하여 모델의 판단 신뢰도와 현장 적용성이 현저히 향상된 것을 확인할 수 있었다. 따라서, 프롬프트 엔지니어링을 적용한 모델이 현장 중심의 안전관리 자동화에 보다 합리적이고 효과적인 접근 방식임을 입증하였다.

본 연구에서 제안한 모델은 건설현장의 효율적인 안전관리를 지원함으로써, 현장에서 발생할 수 있는 다양한 안전사고를 예방하는 데 기여할 수 있다. 또한, 이행 및 미이행 분류 결과를 평가 기준별 설명과 함께 정량적으로 제시함으로써, ‘일일 위험성 평가서’의 자동 생성 및 검증 과정에 적용할 경우 현장 활용성이 더욱 높을 것으로 기대된다.

향후 연구에서는 본 모델을 다양한 공종으로 확대 적용하고, 공정별 특성을 반영한 세분화된 프롬프트 설계를 통해 모델의 일반화 성능과 적용 범위를 확장하고자 한다. 이를 통해, 건설현장의 안전관리 체계를 자동화하여 디지털 혁신을 실현함으로써, 건설 산업의 지속 가능한 발전에 기여할 수 있을 것으로 기대된다.



참 고 문 헌

- [1] Ministry of Employment and Labor (MOEL), "Status of fatal accidents subject to disaster investigation". MOEL, 2023.
- [2] Korea Industrial Safety Association (KISA), Understanding of the Serious Accidents Punishment Act (Industrial Accident Section), KISA General-51, 2024.
- [3] Korea Industrial Safety Association (KISA), "Risk Assessment in Construction Industry". KISA, 2025.
- [4] Korea Occupational Safety and Health Agency (KOSHA), 2023 Guide to the New Risk Assessment, KOSHA, May 2023.
- [5] Korea Occupational Safety and Health Agency (KOSHA), 2023 Excellent Cases of Risk Assessment and Occupational Safety and Health Management System, KOSHA, December 2023.
- [6] Park, N. K., and Chae, J. G., 2024, "A Study on the Current Status of Safety Management and Improvement Measures Following the Enforcement of the Serious Accidents Punishment Act," Journal of the Society of Disaster Information, 20(3), pp. 533–540.
- [7] Han, S., Park, W., Jeong, K., Hong, T. and Koo, C., 2024. Utilizing synthetic images to enhance the automated recognition of small-sized construction tools. Automation in Construction, 163, p.105415.
- [8] Han, S., Won, J., and Koo, C., 2025, "A Strategic Approach to Enhancing the Practical Applicability of Vision-based Detection and Classification Models for Construction Tools – Sensitivity Analysis of Model Performance Depending on

- Confidence Threshold,” *Korean Journal of Construction Engineering and Management*, 26(1), pp. 102–109.
- [9] Rabbi, A.B.K. and Jeelani, I., 2024. AI integration in construction safety: Current state, challenges, and future opportunities in text, vision, and audio based applications. *Automation in Construction*, 164, p.105443.
- [10] Adil, M., Lee, G., Gonzalez, V.A. and Mei, Q., 2025. Using Vision Language Models for Safety Hazard Identification in Construction. *arXiv preprint arXiv:2504.09083*.
- [11] Chen, Z., Chen, H., Imani, M., Chen, R. and Imani, F., 2025. Vision language model for interpretable and fine-grained detection of safety compliance in diverse workplaces. *Expert Systems with Applications*, 265, p.125769.
- [12] Kim, T., Kim, S., Chern, W.C., Park, S., Kim, D. and Kim, H., 2025. Optimizing large vision-language models for context-aware construction safety assessment. *Automation in Construction*, 180, p.106510.
- [13] Ballal, S., Patel, K.A. and Patel, D.A., 2024. Enhancing Construction Site Safety: Natural Language Processing for Hazards Identification and Prevention. *Journal of Engineering, Project, and Production Management*, 14(2), p.1.
- [14] Wang, Y., Xiao, B., Bouferguene, A. and Al-Hussein, M., 2024. Proactive safety hazard identification using visual–text semantic similarity for construction safety management. *Automation in Construction*, 166, p.105602.
- [15] Ahmadi, E., Muley, S. and Wang, C., 2025. Automatic construction accident report analysis using large language models (LLMs). *Journal of Intelligent Construction*, 3(1), pp.1-10.

- [16] Uhm, M., Kim, J., Ahn, S., Jeong, H., & Kim, H., 2025. Effectiveness of retrieval augmented generation-based large language models for generating construction safety information. *Automation in Construction*, 170, 105926.
- [17] Adil, M., Lee, G., Gonzalez, V.A. and Mei, Q., 2025. Using Vision Language Models for Safety Hazard Identification in Construction. *arXiv preprint arXiv:2504.09083*.
- [18] Chan, C.F., Wong, P.K.Y., Guo, X., Cheng, J.C., Chan, J.P.C., Leung, P.H. and Tao, X., 2025. Context-aware vision-language model agent enriched with domain-specific ontology for construction site safety monitoring. *Automation in Construction*, 177, p.106305.
- [19] Chen, Q. and Yin, X., 2025. Tailored vision-language framework for automated hazard identification and report generation in construction sites. *Advanced Engineering Informatics*, 66, p.103478.
- [20] Zhou, S., Li, J., Yamauchi, T., Cai, J. and Tei, K., 2024, June. Evaluating Vision-Language Models in Visual Comprehension for Autonomous Driving. In *2024 IEEE 4th International Conference on Software Engineering and Artificial Intelligence (SEAI)* (pp. 205-209). IEEE.
- [21] McNulty, A.M., Valluri, H., Gajjar, A.A., Custozzo, A., Field, N.C. and Paul, A.R., 2025. Performance evaluation of ChatGPT-4.0 and Gemini on image-based neurosurgery board practice questions: A comparative analysis. *Journal of Clinical Neuroscience*, 134, p.111097.
- [22] Bereuter, J.P., Geissler, M.E., Klimova, A., Steiner, R.P., Pfeiffer, K., Kolbinger, F.R., Wiest, I.C., Muti, H.S. and Kather, J.N., 2025. Benchmarking Vision Capabilities of Large Language Models in Surgical Examination

- Questions. *Journal of Surgical Education*, 82(4), p.103442.
- [23] Cho, T. J., and Choi, J. S., 2011, "Case Studies: Schedule Delay Factors and Delay Prevention Program for Concrete Frame Works in Apartment Construction Project," *Journal of the Korea Institute of Building Construction*, 11(1), pp. 9–17.
- [24] Construction Safety Management Integrated Information (CSI). "Status of Risk Factors Identified by Construction Work Type". CSI, 2025
- [25] Korea Land and Housing Corporation (LH), *Establishment of Safety Measures for 20 High-Risk Construction Work Types under 7 Major Categories at Construction Sites*, LH, 2022.
- [26] Kazan, E. and Usmen, M. A., 2018. Worker safety and injury severity analysis of earthmoving equipment accidents. *Journal of safety research*, 65, 73-81.
- [27] Wang, Y. and Zou, P. X., 2025. Decoding Construction Accident Causality: A Decade of Textual Reports Analyzed. *Buildings*, 15(21), 3859.
- [28] Cho, C. and Choi, J., 2025. 콘크리트 펌프카 Booms 파단사고 예방. *Journal of the Society of Disaster Information*, 21(1), 83-92.
- [29] OpenAI, "GPT-4o and More Tools to ChatGPT Free," OpenAI, 2024
- [30] Ramachandran, R., Garjani, A., Bachmann, R., Atanov, A., Kar, O. F., & Zamir, A., 2025. How Well Does GPT-4o Understand Vision? Evaluating Multimodal Foundation Models on Standard Computer Vision Tasks. *arXiv preprint arXiv:2507.01955*.
- [31] Bubeck, S., Chandrasekaran, V., Eldan, R., Gehrke, J., Horvitz, E., Kamar, E., Lee, P., Lee, Y. T., Li, Y., Lundberg, S., Nori, H., Palangi, H., Ribeiro, M. T. and Zhang, Y., 2023. Sparks of artificial general intelligence: early experiments with

- GPT-4. *arXiv preprint arXiv:2303.12712*, 1.
- [32] Achiam, J., Adler, S., Agarwal, S., Ahmad, L., Akkaya, I., Aleman, F. L., ... & McGrew, B., 2023. Gpt-4 technical report. *arXiv preprint arXiv:2303.08774*.
- [33] Chen, B., Zhang, Z., Langrené, N. and Zhu, S., 2025. Unleashing the potential of prompt engineering for large language models. *Patterns*.
- [34] Wang, K., Bukharin, A., Jiang, H., Yin, Q., Wang, Z., Zhao, T., Shang, J., Zhang, C., Yin, B., Li, X. and Chen, J., 2024. RNR: Teaching large language models to follow roles and rules. *arXiv preprint arXiv:2409.13733*.
- [35] Diallo, A., Bikakis, A., Dickens, L., Hunter, A. and Miller, R., 2025. IAO Prompting: Making Knowledge Flow Explicit in LLMs through Structured Reasoning Templates. *arXiv preprint arXiv:2502.03080*.
- [36] Zhang, L., Ergen, T., Logeswaran, L., Lee, M. and Jurgens, D., 2024. Sprig: Improving large language model performance by system prompt optimization. *arXiv preprint arXiv:2410.14826*.
- [37] Choi, Y., Baek, J. and Hwang, S.J., 2025. System Prompt Optimization with Meta-Learning. *arXiv preprint arXiv:2505.09666*.
- [38] Koo, M., and Yang, S.-W., 2025, "Likert-Type Scale," *Encyclopedia*, 5, p. 18.
- [39] Menditto, A., Patriarca, M. and Magnusson, B., 2007. Understanding the meaning of accuracy, trueness and precision. *Accreditation and quality assurance*, 12(1), pp.45-47.
- [40] Zeng, X., Wong, D.F. and Chao, L.S., 2014. Constructing better classifier ensemble based on weighted accuracy and diversity measure. *The Scientific World Journal*, 2014(1), p.961747.

Abstract

With the recent enforcement of the *Serious Accidents Punishment Act*, the burden of safety management at construction sites—particularly risk assessment tasks—has increased rapidly. In the construction industry, risk assessments are conducted to identify risk factors for each trade and to establish safety management measures. For systematic management, construction sites prepare “daily risk assessment reports” by taking photographs of the implementation of safety management measures on-site and having these reviewed and managed by the head office. However, the quality of photographs taken on-site can vary considerably depending on the safety manager’s level of understanding and attitude, and it is difficult to individually review all images from large-scale construction sites. As a result, even when the implementation of safety management measures is insufficient, there are limitations in that such cases may be recorded as “implemented” without being clearly evaluated. Although substantial manpower and time are invested in establishing safety management measures, the management of whether these measures are actually implemented remains insufficient.

To overcome these limitations, this study develops an automated daily risk assessment report generation model using a Vision-Language Model (VLM). In the proposed model, prompt engineering techniques are applied to analyze images related to safety management measures according to three evaluation criteria: (i) identifiability of key objects, (ii) contextual appropriateness, and (iii) adequacy of execution. In addition, once descriptive analyses for each evaluation criterion are

extracted, a commercial large language model (GPT-4o) is used to perform rubric-based scoring on a scale of 1 to 5 (to one decimal place), thereby automatically classifying the implementation status of safety management measures as “implemented” or “not implemented.”

In this study, a dataset of 1,146 one-to-one matched pairs of safety management measures and images was constructed for the work category of “structural work - concrete placement - slab pouring” within the classification system of daily risk assessment reports. The analysis results show that, compared with a baseline commercial VLM, the accuracy (weighted accuracy) of the proposed model improved from 74.77% to 88.58%, representing an increase of approximately 13.81 percentage points. These results demonstrate the validity of the proposed prompt-engineering-based model. This study is significant in that it verifies the potential of automating construction site safety management using AI technologies such as VLMs. By integrating the proposed model into a daily risk assessment system to enable automatic determination of safety management measure implementation and automated report generation, it is expected that both the efficiency and reliability of safety management at construction sites can be improved.

Keyword: Vision-Language Model (VLM), Construction Safety Management, Daily Risk Assessment Report, Prompt Engineering, Implementation Evaluation