



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

2024 학년도

석사학위논문

YOLO(You Only Look Once)

모델별 건설 현장

위험 상태 및 객체 인식 성능 비교

지도교수 : 문 유 미

경기대학교 공학대학원

건축 · 안전공학전공

박 중 학



YOLO(You Only Look Once)
모델별 건설 현장
위험 상태 및 객체 인식 성능 비교

이 논문을 석사학위논문으로 제출함

2025년 6월 일

경기대학교 공학대학원

건축·안전공학전공

박 중 학



박 종 학의 석사학위논문을 인준함

심 사 위 원 장	_____	인
심 사 위 원	_____	인
심 사 위 원	_____	인

2025년 6월 일

경기대학교 공학대학원




목 차

표 목 차	iv
그림목차	v
감사의 글	ix
논문개요	x
제 1 장 서 론	1
제 1 절 연구의 배경 및 필요성	1
제 2 절 연구의 목적	5
제 3 절 연구 가설 및 연구의 모형	5
제 2 장 이론적 배경 및 문헌 고찰	6
제 1 절 YOLO 알고리즘 개요 및 객체 탐지 기술의 발전	6
제 1 항 00~10년대 머신러닝 기술	6
제 2 항 10~년대 CNN 기반 딥러닝 기술	9
제 3 항 20~년대 Transfomer 기반 딥러닝 기술	14
제 2 절 건설 현장의 주요 위험 요소와 안전관리 선행 연구	15
제 1 항 건설 현장의 주요 위험 요소와 안전관리	15
제 2 항 YOLO 알고리즘 개요 및 객체 탐지 기술의 발전에 대한 선행 연구	18
제 3 항 국내 YOLO 알고리즘에 관한 선행 연구	21



제 3 장 연구설계와 분석 방법	24
제 1 절 YOLO 데이터 수집	24
제 2 절 수집 데이터 전처리	26
제 1 항 학습 데이터 선별	26
제 2 항 학습 데이터 클래스 선정	29
제 3 항 클래스 데이터 라벨링 구성	30
제 3 절 YOLO 모델별 구동	32
제 1 항 YOLO 모델 구조 분석	32
제 2 항 Google Colab을 활용한 YOLO 학습	32
제 4절 모델 성능 평가 및 검증 방법	34
제 1 항 정확도(Precision), 재현율(Recall), F1 Score	34
제 2 항 IOU(Intersection Over Union), FPS(Frame Per Second)	35
제 3 항 연구 방법 소결	35
제 4 장 YOLO 기반 AI 모델별 학습 결과 분석	37
제 1 절 YOLO 모델별 학습 성능 변화 분석	37
제 2 절 YOLO 모델별 학습 결과 분석	42
제 1 항 YOLO 모델별 학습 필요 시간 비교	42
제 2 항 YOLO 모델별 손실 함수(Loss Function) 변화 비교 ·	42
제 3 항 YOLO 모델별 성능 평가 지표(Matrics) 비교	44
제 4 항 YOLO 모델별 혼동 행렬(Confusion Matrix) 분석 ···	46
제 5 항 정규화 혼동 행렬 기반의 정밀 분석	48
제 6 항 소결	49
제 3 절 YOLOv8n, YOLOv11n 모델 기반 신뢰도-성능 곡선 분석	51



제 1 항 F1-Confidence Curve 분석	51
제 2 항 Precision-Confidence Curve 분석	53
제 3 항 Recall-Confidence Curve 분석	54
제 4 항 Precision-Recall Curve 분석	55
제 5 항 소결	57
제 4 절 YOLO 모델의 시각적 검증 결과 분석	58
제 1 항 Batch 0: Ground Truth 및 예측결과 비교 (val_batch0_labels vs. val_batch0_pred)	58
제 2 항 Batch 1: Ground Truth 및 예측결과 비교 (val_batch1_labels vs. val_batch1_pred)	61
제 3 항 Batch 2: Ground Truth 및 예측결과 비교 (val_batch2_labels vs. val_batch2_pred)	64
제 4 항 소결	67
제 5 항 YOLOv8n 기반 객체 탐지 성능에 대한 종합 분석	67
제 6 항 종합 소결	69
 제 5 장 결론 및 시사점	 71
제 1 절 결론	71
제 2 절 시사점	72
제 3 절 제언	73
 참고문헌	 74
부 록	78
Abstract	103



표 목 차

<표 2-1> YOLO 버전별 주요 특징	12
<표 2-2> 건설 현장의 주요 위험 요소와 안전 관리 선행 연구	17
<표 2-3> YOLO 알고리즘 및 객체 탐지 기술 선행 연구	19
<표 2-4> 국내 YOLO 알고리즘에 관한 선행 연구	22
<표 3-1> AI-HUB 데이터셋 구성	26
<표 3-2> AI-HUB 데이터셋 내 추락 시나리오 구성	27
<표 3-3> 연구 데이터셋 구성	28
<표 3-4> 클래스에 대한 세부 구성	29
<표 4-1> YOLO 모델별 학습 필요 시간	42
<표 4-2> YOLO 모델별 train/box_loss 변화	43
<표 4-3> YOLO 모델별 train/cls_loss 변화	43
<표 4-4> YOLO 모델별 train/dfL_loss 변화	44
<표 4-5> YOLO 모델별 모델별 Precision(정밀도) 변화	44
<표 4-6> YOLO 모델별 Recall(재현율) 변화	45
<표 4-7> YOLO 모델별 평균 정밀도 (IoU 0.5 기준) 변화	45
<표 4-8> YOLO 모델별 종합 평균 정밀도 (IoU 0.50-95 기준) 변화	46
<표 부록-1> YOLOv5n 결과 상세 값	82
<표 부록-2> YOLOv6n 결과 상세 값	87
<표 부록-3> YOLOv8n 결과 상세 값	92
<표 부록-4> YOLOv10n 결과 상세 값	97
<표 부록-5> YOLOv11n 결과 상세 값	102



그 립 목 차

<그림 1-1> 전체 업무상 사고 중 건설업 비중 추이	2
<그림 1-2> 전체 추락 재해 사고 중 건설업 비중 추이	2
<그림 2-1> HOG 예시	7
<그림 2-2> Haar cascade 예시	7
<그림 2-3> SHIFT 예시	8
<그림 2-4> DPM 예시	8
<그림 2-5> CNN 구성 방식	9
<그림 2-6> CNN stage별 역사	10
<그림 2-7> Vision Transformer(ViT)	14
<그림 3-1> Roboflow Universe	25
<그림 3-2> kaggle 데이터셋	25
<그림 3-3> 데이터셋 구성	30
<그림 3-4> 라벨링 전 데이터	31
<그림 3-5> 라벨링 후 데이터	31
<그림 3-6> 구글 코랩(Google Clab)	32
<그림 3-7> 구글 코랩(Google Clab) 내 YOLO 설치 코드	33
<그림 3-8> YOLO를 이용한 데이터셋 학습 코드	33
<그림 4-1> YOLOv5n 모델 학습 과정에서의 성능 변화와 손실 함수(loss)의 감소 추이	39
<그림 4-2> YOLOv6n 모델 학습 과정에서의 성능 변화와 손실 함수(loss)의 감소 추이	39
<그림 4-3> YOLOv8n 모델 학습 과정에서의 성능 변화와 손실 함수(loss)의 감소 추이	40



<그림 4-4> YOLOv10n 모델 학습 과정에서의 성능 변화와 손실 함수(loss)의 감소 추이	40
<그림 4-5> YOLOv11n 모델 학습 과정에서의 성능 변화와 손실 함수(loss)의 감소 추이	41
<그림 4-6> YOLOv8n 및 YOLOv11n 모델 F1-confidence Curve 곡선	51
<그림 4-7> YOLOv8n 및 YOLOv11n 모델 Precision-confidence Curve 곡선	53
<그림 4-8> YOLOv8n 및 YOLOv11n 모델 Recall-confidence Curve 곡선	54
<그림 4-9> YOLOv8n 및 YOLOv11n 모델 Precision-Recall Curve 곡선	55
<그림 4-10> YOLOv8n 예측 결과와 정답 라벨 비교 시각화 (val_batch0)	60
<그림 4-11> YOLOv8n 예측 결과와 정답 라벨 비교 시각화 (val_batch1)	63
<그림 4-12> YOLOv8n 예측 결과와 정답 라벨 비교 시각화 (val_batch2)	66
<그림 부록-1> YOLOv5n 최종 예측의 혼동 행렬	78
<그림 부록-2> YOLOv5n 예측 성능의 정규화 혼동 행렬	78
<그림 부록-3> YOLOv5n 신뢰도 변화에 따른 클래스별 F1 점수 변화 곡선	79
<그림 부록-4> YOLOv5n 학습 데이터의 클래스 분포 및 바운딩 박스 히트맵	79
<그림 부록-5> YOLOv5n 바운딩 박스 좌표 및 크기 간 분포 시각화	80
<그림 부록-6> YOLOv5n 정밀도-재현율(PR) 곡선	80



<그림 부록-7> YOLOv5n 클래스별 정밀도와 재현율 관계 분석 곡선	81
<그림 부록-8> YOLOv5n 정밀도-신뢰도 곡선	81
<그림 부록-9> YOLOv6n 최종 예측의 혼동 행렬	83
<그림 부록-10> YOLOv6n 예측 성능의 정규화 혼동 행렬	83
<그림 부록-11> YOLOv6n 신뢰도 변화에 따른 클래스별 F1 점수 변화 곡선	84
<그림 부록-12> YOLOv6n 학습 데이터의 클래스 분포 및 바운딩 박스 히트맵	84
<그림 부록-13> YOLOv6n 바운딩 박스 좌표 및 크기 분포 시각화	85
<그림 부록-14> YOLOv6n 정밀도-재현율(PR) 곡선	85
<그림 부록-15> YOLOv6n 클래스별 정밀도와 재현율 관계 분석 곡선	86
<그림 부록-16> YOLOv6n 정밀도-신뢰도 곡선	86
<그림 부록-17> YOLOv8n 최종 예측의 혼동 행렬	88
<그림 부록-18> YOLOv8n 예측 성능의 정규화 혼동 행렬	88
<그림 부록-19> YOLOv8n 신뢰도 변화에 따른 클래스별 F1 점수 변화 곡선	89
<그림 부록-20> YOLOv8n 학습 데이터의 클래스 분포 및 바운딩 박스 히트맵	89
<그림 부록-21> YOLOv8n 바운딩 박스 좌표 및 크기 간 분포 시각화	90
<그림 부록-22> YOLOv8n 정밀도-재현율(PR) 곡선	90
<그림 부록-23> YOLOv8n 클래스별 정밀도와 재현율 관계 분석 곡선	91
<그림 부록-24> YOLOv8n 정밀도-신뢰도 곡선	91



<그림 부록-25> YOLOv10n 최종 예측의 혼동 행렬	93
<그림 부록-26> YOLOv10n 예측 성능의 정규화 혼동 행렬	93
<그림 부록-27> YOLOv10n 신뢰도 변화에 따른 클래스별 F1 점수 변화 곡선	94
<그림 부록-28> YOLOv10n 학습 데이터의 클래스 분포 및 바운딩 박스 히트맵	94
<그림 부록-29> YOLOv10n 바운딩 박스 좌표 및 크기 간 분포 시각화	95
<그림 부록-30> YOLOv10n 정밀도-재현율(PR) 곡선	95
<그림 부록-31> YOLOv10n 클래스별 정밀도와 재현율 관계 분석 곡선	96
<그림 부록-32> YOLOv11n 정밀도-신뢰도 곡선	96
<그림 부록-33> YOLOv11n 최종 예측의 혼동 행렬	98
<그림 부록-34> YOLOv11n 예측 성능의 정규화 혼동 행렬	98
<그림 부록-35> YOLOv11n 신뢰도 변화에 따른 클래스별 F1 점수 변화 곡선	99
<그림 부록-36> YOLOv11n 학습 데이터의 클래스 분포 및 바운딩 박스 히트맵	99
<그림 부록-37> YOLOv11n 바운딩 박스 좌표 및 크기 간 분포 시각화	100
<그림 부록-38> YOLOv11n 정밀도-재현율(PR) 곡선	100
<그림 부록-39> YOLOv11n 클래스별 정밀도와 재현율 관계 분석 곡선	101
<그림 부록-40> YOLOv11n 정밀도-신뢰도 곡선	101



감사의 글

멀게만 느껴졌던 입학부터 논문 완성까지, 저 혼자였으면 하지 못 할 일을 수 많은 분들 덕분에 끝까지 해낼 수 있었습니다. 언제나 부족한 능력에 비해 운 좋게 인생에 도움되는 많은 분들이 만날 수 있었음에 감사드립니다.

먼저, 누구보다 저를 아껴주시고 언제나 열정적으로 지도해주신 문유미 교수님께 진심으로 감사드립니다. 아무것도 모르는 저에게 새로운 논문 방향성을 제시해주시고, 뛰어난 지식으로 논문 마무리까지 큰 힘이 되어주셨습니다. 언제나 마음 깊은 곳에 은혜를 세기고 있었습니다. 또한 대학원 과정에서 다양한 시야와 연구자로서의 마음가짐에 대해 가르침을 주신 박종용 교수님, 이성진 교수님, 하준태 교수님과 학사때부터 많은 도움을 주신 이병길 교수님이 주신 은혜도 잊지 않겠습니다.

배움의 길을 고민만 하고 있을 때, 석사의 길을 열어주시고 본인 일처럼 여러 방면에서 많은 도움을 주신 노희상 박사님께 감사합니다. 올해 하는 결혼 진심으로 축하드립니다.

석사 과정에서도 좋은 인연을 많이 만난 뜻 깊은 졸업이 되었습니다. 석사 수업 때 같이 의지하며 끝까지 함께한 장인석, 김병기, 오은준 님과 가장 일찍 오셔서 늦은 시간까지 논문 연구를 같이 한 이현숙 님께도 감사드립니다. 논문에 관해 많은 자료와 지도, 조언을 아끼지 않아 주신 대학원 선배님들께도 꼭 은혜 갚을 수 있도록 잊지 않겠습니다.

현장에서 석사를 다니느라 힘들 때 큰 힘이 되어준 이희태 소장님과 석사 여정을 진심으로 응원해주시고 배려해주신 평택~오송 3공구 팀들께 감사와 무재해를 기원합니다.

배움에는 끝이 없다는 것을 알려 준 김승권 님과 김영호 님, 본인 시간을 들여 코딩을 도와준 구병국 님께도 이 자리를 빌려 감사 말씀드립니다.

마지막으로, 전화할 때마다 손자 걱정만 하는 박금희, 손영자 할머니와 언제나 아들을 위해 희생하시는 어머니, 누구보다도 존경하며 닮고 싶은 사람이 되어주신 아버지께 감사의 말씀 올립니다.

2025년 05월
박 종 학 드림

논 문 개 요

건설업은 산업재해 중 사망사고 비중이 가장 높은 분야로, 특히 추락, 협착, 낙하물 등의 중대재해가 반복적으로 발생하고 있다. 이러한 재해는 주로 안전수칙 미준수, 보호구 미착용, 작업 환경 내 위험 요소 방치 등 실무적 요인에 의해 발생하며, 기존의 수동적 안전관리 방식으로는 실시간 대응과 위험예지에 한계가 있다. 이에 따라 객체 탐지 기반 인공지능 기술, 특히 YOLO(You Only Look Once) 알고리즘이 건설안전 분야에서 주목받고 있으며, 이는 영상 기반의 자동 탐지와 실시간 대응에 강점을 가진 기술로 평가된다.

본 연구는 YOLO 알고리즘의 다중 모델(YOLOv5n, v6n, v8n, v10n, v11n)을 적용하여, 실제 건설현장의 위험 객체 인식 성능을 정량적(mAP, Precision, Recall 등) 및 정성적(Ground Truth 시각화, Confusion Matrix 분석 등) 관점에서 종합적으로 비교·분석하였다. 학습 데이터는 AI-HUB의 건설안전 데이터셋 중 추락 사고와 관련된 주요 객체(People, Ladder, Scaffold 등)와 위험 상황(Unsafe Solo work, No Outrigger 등)을 중심으로 구성하였으며, 총 22,000장의 이미지에 대해 클래스 라벨링을 수행하였다.

학습 결과, YOLOv8n 모델은 전체 클래스 기준 mAP@0.5가 0.906, F1 Score 0.91로 가장 우수한 성능을 보였으며, 주요 위험 클래스의 탐지 정확도가 0.9 이상으로 나타나 실시간 경고 시스템 구현에 적합한 성능을 확보하였다. 특히 Confidence Threshold를 0.4~0.5 수준으로 설정할 경우 Precision과 Recall 간 균형이 최적으로 유지되는 경향이 확인되었으며, 이는 실무 적용을 위한 기준 수립에 활용될 수 있다. 반면, Forklift 및 Roller 클래스끼리의 오탐과 Scaffold 객체의 배경과의 시각적 유사성으로 인해 오탐이 발생하는 경향을 보였고, 이는 추가적인 데이터 보강과 클래스 구조 재정립의 필요성을 시사하였다.



결론적으로 본 연구는 YOLO 기반 객체 탐지 모델이 건설현장 내 복합적인 위험 상황에 대한 실시간 자동 탐지 시스템의 핵심 기술로서 활용 가능성을 실증적으로 검증하였으며, 향후 스마트 안전관리 체계 구축을 위한 기술적 토대로 활용될 수 있다.

Key words: 건설안전, 딥러닝, 실시간 객체 탐지, 인공지능, YOLO


제 1 장 서 론

제 1 절 연구의 배경 및 필요성


건설업은 산업 중에서도 가장 높은 사망률을 기록하는 분야로, 안전사고는 지속적인 관심과 개선이 필요한 중요한 문제로 대두되고 있다(윤영근 & 오태근, 2022). 건설 현장에서 발생하는 안전사고는 주로 추락, 충돌, 낙하물 등의 유형으로 나타나며, 이는 작업자의 부주의, 안전 장비의 미착용, 위험 요소가 포함된 작업 환경 등에 기인한다(Zhang, Y, 2021).

고용노동부의 최근 10년간 산업재해 현황 분석에 따르면, 건설업은 전 근로자 대비 업무상 사고 근로자 수가 23~30%라는 높은 비율을 유지하고 있다. 추락 사고의 경우 전체 사고 중 건설업 재해가 50~60%로 가장 높은 비율을 차지하고 있다. 이는 작업 고도, 안전시설 미비, 작업자의 안전의식 부족 등의 요인에 기인하며, 사고 발생 시 치명적인 인명 피해로 이어질 가능성이 크다(Qian, Y et al, 2023).

따라서 건설 현장에서 추락사고 예방을 위한 보다 체계적인 관리 방안이 요구된다. 특히 이러한 사고는 현장에서의 실시간 대응 부족으로 인해 더욱 심각해질 가능성이 높다. 따라서 건설 현장의 안전 문제를 체계적으로 해결하기 위한 새로운 접근법이 요구된다.



<그림 1-1> 전체 업무상 사고 중 건설업 비중 추이



<그림 1-2> 전체 추락재해 사고 중 건설업 비중 추이

전통적으로 건설 현장의 안전 관리는 현장 관리자의 점검이나 CCTV 모니터링과 같은 수동적인 방식에 의존해 왔다(윤영근 & 오테근, 2022). 이러한 방식은 사고 발생 이후의 대처에 초점이 맞추어져 있으며, 실시간으로 위험을 탐지하거나 데이터에 기반한 예방적 조치를 수행하는 데는 한계가 있다. 특히, 관리자와 모니터링 시스템의 한정된 역량은 현장의 복잡한 위험 상황을 효과적으로 통제하지 못하는 주요 원인으로 지적된다(Zhao, J et al, 2023). 이에 따라, 실시간 위험 탐지 및 자동화된 안전 관리 시스템의 필요성이 점점 증가하고 있다.

최근 인공지능(AI) 기술의 발전은 다양한 산업에서 안전 관리 시스템의 혁신을 가능하게 하고 있다(Zhang, Y, 2021). 특히 YOLO(You Only Look Once)와 같은 객체 탐지 알고리즘은 이미지 및 영상 데이터에서 사람, 장비, 위험 요소 등을 실시간으로 탐지하는 데 유용한 도구로 주목받고 있다. 이러한 기술은 잠재적인 위험 요소를 조기에 식별하고 작업자의 행동을 실시간으로 모니터링함으로써 신속하고 적절한 대응을 가능하게 한다(Liu, L et al, 2024). AI 기술을 활용한 위험 탐지 시스템은 기존 안전 관리의 한계를 극복할 수 있는 효과적인 대안으로 간주된다.

YOLO 및 기타 컴퓨터 비전 기술은 다양한 산업에서 안전 관리 개선을 위해 활발히 연구되고 있다. 예를 들어, 윤영근과 오테근(2022)은 YOLOv5와 OpenPose를 결합하여 건설 현장에서 근로자를 탐지하는 성능을 향상한 연구를 발표하였으며, 이는 안전한 작업 환경 조성에 기여할 가능성을 보여준다(윤영근 & 오테근, 2022). 또한, Zhao et al.(2023)은 CNN 모델을 활용하여 건설 현장에서 작업자의 침입 행동을 실시간으로 탐지하고, 조기 경고 시스템을 제안하였다(Zhao, J. et al, 2023). 이 외에도, 빅데이터 기술과 AI를 결합하여 건설 현장의 반복적인 사고 패턴을 이해하고 효과적인 예방 조치를 설계하는 연구들이 진행되고 있다(Meng, Q, et al. 2022). 이러한 연구들은 AI 기반 기술이 건설 현장의 안전 관리를 개선하는 데 실질적인 기여를 할 수 있음을 시사한다.



본 연구는 기존의 선행 연구를 기반으로 하여 YOLO(You Only Look Once)와 같은 첨단 객체 탐지 알고리즘을 활용해 건설 현장에서 발생할 수 있는 특정 위험 요소와 작업자의 행동을 실시간으로 모니터링하고 분석하는 AI 기반 시스템을 개발하는 데 초점을 둔다. 이를 통해, 작업자와 중장비 간 거리, 낙하물 위험, 접근 금지 구역 침범 등 다양한 위험 상태를 조기에 식별하고, 작업자의 안전모 미착용이나 추락 위험 지역에서의 부적절한 행동과 같은 위험 행동을 실시간으로 탐지하여 신속하게 대응할 수 있는 시스템을 구축하고자 한다.

또한, 본 연구는 기존의 수동적인 안전 관리 체계가 가진 실시간 대응 및 데이터 분석의 한계를 극복하고, 보다 효율적이고 디지털화된 안전 관리 방안을 제시하는 데 중점을 둔다. 이를 통해 건설 현장에서 반복적으로 발생하는 위험 상황과 행동 패턴을 체계적으로 분석하여 사고 발생 원인을 규명하고, 안전사고를 예방할 수 있는 선제적 대응 체계를 마련하고자 한다.

이러한 접근은 건설 현장의 안전 문화를 근본적으로 개선하고, 미래의 스마트 건설 현장을 위한 혁신적인 안전 관리 모델을 제시함으로써 디지털 전환을 가속화하고 사고 예방 효과를 극대화하는 데 중요한 역할을 할 것으로 기대된다.

제 2 절 연구의 목적

본 연구는 건설 현장에서 발생할 수 있는 위험 요소를 실시간으로 탐지하고 작업자의 위험 행동을 모니터링함으로써, 안전사고를 예방하고 보다 효과적인 안전 관리 체계를 구축하는 것을 목적으로 한다. 구체적으로, 본 연구는 건설 현장에서의 위험 상태를 식별하여 작업자와 중장비 간 거리, 낙하물 위험, 접근 금지 구역 침범과 같은 잠재적 위험 요인을 신속히 탐지하고 대응할 수 있는 시스템을 개발하는 데 중점을 둔다.


또한, 작업자의 안전모 미착용, 추락 위험 지역에서의 부적절한 행동 등과 같은 위험 행동을 실시간으로 모니터링하고 분석하여, 근본적인 안전 문제를 파악하고 해결 방안을 제시하고자 한다.

기존의 수동적인 안전 관리 시스템, 예를 들어 현장 관리자 점검이나 CCTV 모니터링 방식은 실시간 대응과 데이터 분석에 한계가 있다. 본 연구는 이러한 한계를 극복하기 위해 AI 기반 자동화 시스템을 도입하여 관리 효율성과 사고 예방 효과를 극대화하는 것을 목표로 한다.

이를 통해 건설 현장에서 수집된 데이터를 분석하고 반복적으로 발생하는 위험 상황과 행동 패턴을 도출하여, 사고 발생 원인을 체계적으로 이해하고 예방 방안을 제시하는 데 기여하고자 한다.

제 3 절 연구 가설 및 연구의 모형

본 연구는 건설 현장에서 발생하는 위험 요소와 작업자의 행동 데이터를 AI 기술을 활용하여 실시간으로 분석함으로써, 신속하고 정확한 대응이 가능한 모니터링 시스템을 구축하는 데 의의를 둔다. 패턴 인식과 데이터 기반 의사결정을 통해 건설 현장의 안전사고를 예방할 수 있는 선제적 대응 체계를 마련하고, 기존의 경험 중심적이고 비효율적인 안전 관리 체계를 혁신하는 데 기여하고자 한다. 본 연구 결과는 건설 현장의 안전 문화를 개선하고, 사고 예방을 위한 디지털 전환을 가속하는 데 중요한 역할을 할 것으로 기대된다.



제 2 장 이론적 배경 및 문헌 고찰


제 1 절 YOLO 알고리즘 개요 및 객체 탐지 기술의 발전

제 1 항 00~10년대 머신러닝 기술

HOG: HOG(Histogram of Oriented Gradients) 알고리즘이란 2005년 다탈(N. Dalal)과 트릭스(B. Triggs)가 발표한 알고리즘으로, 보행자 검출을 하기 위해 널리 사용되는 기법 중 하나이다. HOG은 이미지 내 각 픽셀에서 그래디언트(방향과 크기)를 나누어 픽셀 주변의 밝기가 어떻게 변하는지 측정한다. 그 이후 이미지를 여러 개의 작은 셀(Cell)로 나눈다. 각 셀은 보통 8x8, 16x16 같은 고정된 픽셀 크기를 가진다. 각 셀 내에서, 앞서 계산한 그래디언트를 이용하여 히스토그램을 생성한다. 이를 바탕으로 여러 개의 인접한 셀을 그룹화한 블록을 만들고 이를 블록으로 그룹화하고, 블록의 히스토그램을 연결하여 큰 벡터를 형성하는 정규화의 과정을 거친다.

Haar cascade: 2001년 Viola와 Jones가 개발한 물체 검출 알고리즘이다. 기본적으로는 영역과 영역의 밝기 차이를 이용하며, 검정 부분과 흰 부분으로 이뤄진 feature가 이미지 내에서 이동하며 인접한 feature 내의 픽셀값의 합끼리 비교하는 방식이다. 픽셀 값을 비교해 보았을 때, 0에 가까울수록 edge가 없는 영역으로 보고 이를 이용하여 물체의 형태를 얻어낸다. 단점으로는 연산량이 많고 밝기 차가 심하거나 거의 없는 부분은 검출이 힘들다.





<그림 2-1> HOG 예시¹⁾



<그림 2-2> Haar cascade 예시²⁾

SIFT:SIFT(Scale Invariant Feature Transform)는 2004년도 Lowe 교수가 발표한 알고리즘으로 이미지의 크기와 회전에 영향을 받지 않는 특징점을 추출하는 알고리즘이다. 이미지를 블러처리하면서 같은 옥타브 상에 있는 서로 다른 두 개의 이미지를 빼기 연산을 통해 DOG(Difference of Gaussian kernel)를 구한 뒤, 키포인트 후보를 찾는다. 키포인트의 정확한 위치를 테일러 전개를 이용하여 찾은 뒤 키포인트 주변 feature vector를 얻고 이를 정규화하여 SIFT로 만들어 이미지를 매칭한다.

1) Masked Autoencoders Are Scalable Vision Learners, Kaiming He et al (2021)

2) A comparative study between LBP and Haar-like features for Face Detection using OpenCV, K. Kadir. (2014)

DPM:DPM(Deformable Part Model)는 2008년도 Felzenswalb에 의해 발표된 알고리즘이다. HOG의 확장 개념이기 때문에 그 특징을 가진다. 특이점으로는 최초로 바운딩 박스라는 개념을 도입하였다. 바운딩 박스를 그려 일정 크기의 픽셀마다 이동하여 HOG feature를 비교하였기에 발표 당시에는 비교적 빠른 연산과 정확도를 가지고 있었다.



<그림 2-3> SHIFT 예시3)




<그림 2-4> DPM 예시4)

-
- 3) Lowe D G. Distinctive Image Features from Scale-Invariant Keypoints[M]. Kluwer Academic Publishers, (2004)
 - 4) Convolutional Random Walk Networks for Semantic Image Segmentation, Gedas Bertasius. (2017)

제 2 항 10~년대 CNN기반 딥러닝 기술

CNN: NN(Neural Network)란 우리 뇌가 수많은 뉴런으로 이루어져 있고 상당히 많은 양의 데이터를 빠르게 처리할 수 있다는 것에서 영감을 받아 생긴 모델이다. CNN(Convolutional Neural Network)은 이런 NN을 발전시켜 Input된 데이터를 Convolutional(합성곱)을 거쳐 원하는 Output을 만드는 방식이다[1].




<그림 2-5> CNN 구성방식⁵⁾

CNN의 최초 모델은 1990년 Yann LeCun이 발표한 LeNet-1이 있으며, 최종적으로 발표한 LeNet-5이 있다. CNN은 이후 컴퓨터 GPU와 데이터셋을 발전에 힘입어 2012년 AlexNet과 2014년 GoogleNet과 같이 꾸준히 발전을 하였다. CNN은 오브젝트가 있을 법한 후보를 뽑아내고 정확한 바운딩을 구하는 two stage detector 기법과, 객체 검출과 분류를 한번에 하는 one stage

5) Image Enhancement using Convolution Neural Networks. Hasan Ahmed Salman & Ali Kalakech(2024)

detector 기법이 있다. Two stage detector의 대표적인 기법으로는 R-CNN(2014), Fast R-CNN(2015), Faster R-CNN(2015) 등이 있다. One stage detector의 대표적인 기법으로는 YOLO(2015), SSD(2016) 등이 있다. one stage의 장점은 두 번의 단계를 거치기에 느리지만 정확하다는 장점이 있고, two stage는 반대로 빠르지만 정확도가 떨어진다는 단점이 있었다. 각 모델은 서로의 단점을 보완하는 식으로 발전해왔다.



<그림 2-6> CNN의 stage별 역사⁶⁾

R-CNN: 기존에 일정한 크기의 윈도우를 설정하고 하나씩 이동시키면서 데이터를 처리하는 기법인 슬라이딩 윈도우 방식의 비효율성을 극복하기 위해 오브젝트가 있을 법한 영역을 찾는 Region 모듈과 CNN을 활용한 방법이다 (Evelyn Clarke, 2024). 단점으로는 수행시간이 느리고 AlexNet을 그대로 사용하기 위한 이미지 왜곡과 정보 손실이 있었다. 이를 개선하기 위하여 ROI Pooling을 사용하여 2,000장의 모델 입력을 1장으로 줄인 Fast R-CNN과 또 다시 이를 개선하여 GPU 사용으로 End-to-End 학습을 가능하게 한 Faster R-CNN이 있다(Ross Girshick et al, 2014).

6) Deep Learning for Generic object Detection: A Survey, Li Liu(2019)

YOLO: YOLO: YOLO(You Only Look Once)는 실시간 객체 탐지를 위한 딥러닝 모델로, 단일 패스 방식을 활용하여 높은 속도와 정확도를 제공한다. 초기 버전에서는 CNN 기반의 단순한 구조를 따랐으나, 이후 앵커 박스, 다중 스케일 예측, 경량화된 백본, 앵커 프리 기법 등이 도입되며 지속적으로 성능이 향상되었다. YOLO4 이후부터는 연산 최적화에 적합한 구조로 개선되며 더욱 효율적인 모델로 발전하였다.

또한 YOLO v9~v11은 객체 탐지뿐만 아니라 인스턴스 분할, 포즈 추정, 이미지 분류 등 다양한 컴퓨터 비전 작업을 지원하도록 확장되었으며, 경량성과 실용성이 크게 강화되었다. 특히 YOLO 시리즈는 YOLOv5n, YOLOv8n, YOLOv11n과 같은 초경량 모델을 제공하여 모바일 및 엣지 디바이스에서도 실시간으로 작동 가능하며, ONNX, TFLite, CoreML 등 다양한 포맷으로 변환이 가능해 스마트폰 기반 응용 프로그램 개발에도 적합하다.



<표2-1> YOLO 버전별 주요 특징


YOLO 버전	발표 연도	특징
YOLOv1	2015	YOLO의 초기 버전으로 CNN기반의 단일 패스 방식이다. 이미지를 지정한 grid로 나누고, 각 grid cell이 한번에 바운딩박스과 클래스 정보라는 두가지 정답을 도출토록하였다.
YOLOv2	2016	9000종류의 객체를 찾아 낼 수 있다는 뜻의 YOLO9000으로 소개되었으며 Anchor Box를 도입하여 속도와 정확도를 향상시켰다
YOLOv3	2018	3개의 서로 다른 크기의 Feature Map을 활용한 다중스케일 예측과 Darknet-53을 활용하여 작은 객체의 탐지를 개선하였다.
YOLOv4	2020	CSPDarknet-53을 도입하여 연산량은 감소시키고 성능은 유지하였다.
YOLOv5	2020	YOLO4까지는 Darknet 기반이었지만 YOLO5는 PyTorch로 개발되어 속도가 대폭 향상되고 실용성이 증가되었다.
YOLOv6	2022	기존 앵커박스 기반 객체 검출을 앵커프리 방식으로 전환하여 연산량을 줄이고 속도를 개선했다.
YOLOv7	2022	기존 YOLO6까지는 단순한 예측 헤드를 사용했지만, YOLO7에서는 비선형 구조를 추가하여 객체 검출 정확도를 향상 시켰다.
YOLOv8	2023	더욱 가벼운 백본 구조와 최신 하드웨어 최적화로 더 적은 데이터로 높은 성능을 낼 수 있도록 하였다.

YOLOv9	2024	Transformer 기반 구조를 일부 도입하여 장거리 의존성 문제를 개선하고, 비전과 언어를 결합한 멀티모달 처리 가능성을 실험적으로 적용하였다.
YOLOv10	2024	다양한 환경(엣지 디바이스, 서버 등)에 유연하게 대응할 수 있도록 모듈화가 강화되었으며, AutoML 기능이 탑재되어 사용자 맞춤형 모델 설계가 보다 쉬워졌다.
YOLOv11	2024	초경량화된 구조를 바탕으로 모바일 및 IoT 환경에서도 실시간 처리가 가능하도록 최적화되었고, 클라우드 연동을 통해 학습과 추론 성능을 동적으로 조정할 수 있도록 개선되었다.

제 3 항 20~년대 Trasformer 기반 딥러닝 기술

2020년대 CNN없이도 강력한 성능을 내는 Transformer 기반 모델 등장하였다.(Vaswani, et al, 2017)

ViT(2020):ViT(Vision Transformer)은 기존 CNN방식처럼 이미지의 특징을 보는 것이 아니라 이미지를 패치로 분할하고 벡터로 정보를 변환한 이후에 Self-Attention을 거쳐 패치들의 관계를 학습하여 예측을 하는 모델이다. CNN 보다 귀납적 편향을 가지고 있지 않기 때문에 충분한 데이터 없이는 일반화 성능이 떨어지며 속도가 떨어지고 하드웨어 요구사항이 높은 단점이 있다. 다만 대규모데이터셋으로 훈련 될 경우 뛰어난 성능을 보인다(Yahui Liu et al, 2021). 위 단점들을 상쇄하기 위하여 CNN과 Transformer의 장점을 합친 Swin Transgormer(2021), ConvNeXt(2022)등이 나오고 있지만 아직까진 YOLO에 비해 실용성이 떨어지고 있다.



<그림 2-7> Vision Transformer(ViT) 구동 방식⁷⁾

7) AN IMAGE IS WORTH 16X16 WORDS:TRANSFORMERS FOR IMAGE RECOGNITION AT SCALE, Alexey Dosovitskiy(2021)

제 2 절 건설 현장의 주요 위험 요소와 안전관리 선행 연구

제 1 항 건설 현장의 주요 위험 요소와 안전관리

건설 현장은 다양한 위험 요소로 인해 안전사고 발생 가능성이 높은 작업 환경이다. 주요 위험 요소는 크게 낙하 위험, 중장비 관련 위험, 전기 관련 위험, 인체공학적 위험 등으로 구분할 수 있다.

첫째, 낙하 위험은 높은 곳에서 작업할 때 발생할 가능성이 높은 사고 유형으로, 물건이나 장비가 떨어짐으로 인해 작업자가 부상을 입을 수 있다. 이러한 사고를 예방하기 위해 최근 건설 현장에서는 CCTV 및 인공지능을 활용하여 실시간으로 위험 요소를 감지하는 기술이 도입되고 있다(윤영근 & 오태근, 2022).

둘째, 중장비 관련 위험은 건설 현장에서 이동 및 조작되는 대형 장비로 인해 발생할 수 있는 사고를 의미한다. 특히, 장비의 오작동이나 안전 절차 미준수는 치명적인 사고로 이어질 수 있다. 이에 따라, 개인보호구 착용 여부를 검출하는 인공지능 기반 모델이 적용되며, 이를 통해 중장비 사고를 효과적으로 예방하고자 하는 연구가 진행되고 있다(이기석 외, 2022).

셋째, 전기 관련 위험은 건설 현장에서 전기 작업 시 발생할 수 있는 감전 사고 및 전기 설비의 부주의한 취급으로 인해 발생하는 사고를 포함한다. 전기 안전 관리를 위해서는 정기적인 설비 점검과 안전 절차 준수가 필수적이다.

넷째, 인체공학적 위험은 작업자의 반복적인 동작, 무리한 힘 사용, 부적절한 작업 자세로 인해 발생하는 부상 위험을 의미한다. 특히, 장기간 작업 시 근골격계 질환이 발생할 가능성이 높으므로, 이를 예방하기 위한 작업 환경 개선이 필요하다.

이러한 위험 요소를 효과적으로 관리하기 위해 건설 현장에서는 안전 교육, 장비 점검, 개인 보호 장비 착용, 위험 평가 및 관리 계획 수립 등의 안전 관

리 조치가 시행된다.

첫째, 안전 교육은 건설 근로자들에게 정기적으로 실시되며, 이를 통해 근로자들은 위험 요소에 대한 인식을 제고하고 적절한 대응 방안을 습득할 수 있다(Zhang et al, 2021).

둘째, 장비 점검은 중장비 및 기타 작업 장비의 안전성을 보장하기 위한 필수적인 과정이다. 최근에는 무인항공기(UAV)와 인공지능 기술을 활용하여 건설 현장의 작업 환경을 모니터링하는 방법이 연구되고 있으며, 이를 통해 장비의 이상 여부를 신속하게 감지하고 대응할 수 있다(Jiao et al, 2025).

셋째, 개인 보호 장비 착용은 건설 현장 안전의 기본 요소로, 헬멧, 안전화, 안전대 등의 보호 장비 착용이 의무화되어야 한다. 특히, UAV 기반의 헬멧 착용 감지 시스템이 개발되어 건설 현장에서 실질적인 안전 관리를 지원하고 있다(Jiao et al, 2025).

넷째, 위험 평가 및 관리 계획은 건설 현장의 위험 요소를 사전에 평가하고 이를 관리하기 위한 체계적인 계획을 의미한다. 무작위 과정 및 마르코프 프로세스를 활용한 건설 안전 사고 확률 예측 연구가 진행되었으며, 이를 통해 보다 효과적인 안전 관리 전략을 수립할 수 있는 기반이 마련되었다(Zhang et al, 2021). 구체적인 내용은 <표2-2>과 같다.

<표2-2>건설 현장의 주요 위험 요소와 안전 관리선행 연구

행연구 주제	연도 및 저자	주요 내용
건설 현장의 낙하 위험 감지	2022(윤영근 & 오태근)	CCTV 및 인공지능을 활용한 실시간 낙하 위험 감지 기술 적용
중장비 관련 사고 예방	2022(이기석 외)	인공지능 기반 개인보호구 착용 감지 모델을 통한 중장비 사고 예방
Analysis of stochastic process to model safety risk in construction industrt Journal of Civil Engineering and Management	2021(Zhang 외)	정기적인 안전 교육을 통한 근로자의 위험 인식 제고 및 마르코프 프로세스를 이용한 건설 안전 사고 확률 예측 및 관리 전략
Detection Method for Safety Helmet Wearing on Construction Sites Based on UAV Images and YOLOv8. Buildings."	2025(Jiao 외)	무인항공기(UAV) 및 인공지능을 활용한 건설 장비 점검과 UAV 기반 헬멧 착용 감지 시스템을 통한 실질적 안전 관리

제 2 항 YOLO 알고리즘 개요 및 객체 탐지 기술의 발전에 대한 선행 연구

YOLO(You Only Look Once) 알고리즘은 객체 탐지를 위한 실시간 알고리즘으로, 이미지를 전체적으로 한 번에 분석하여 객체의 위치와 클래스를 동시에 예측하는 방식으로 동작한다. 기존의 객체 탐지 방법과 비교하여 YOLO는 낮은 계산 비용과 높은 속도를 갖추고 있으며, 바운딩 박스 예측 시 전체 이미지를 고려한다는 특징이 있다(Shen et al, 2023).


YOLO의 작동 원리는 이미지가 여러 개의 셀로 나뉘고, 각 셀에서 객체가 존재할 가능성을 예측하는 방식으로 진행된다. 이를 통해 객체의 경계 상자 및 클래스 확률을 동시에 예측하는 것이 가능하다.

객체 탐지 기술은 여러 단계의 발전을 거쳐 향상되었다. 초기 객체 탐지 기술은 이미지 필터 및 특징 추출 방법을 기반으로 하였으며, 대표적인 알고리즘으로는 SIFT (Scale-Invariant Feature Transform) 및 HOG (Histogram of Oriented Gradients)가 있다.

이후, 딥러닝 기반 객체 탐지 기술의 도입으로 탐지 정확도가 크게 향상되었다. 특히, CNN(Convolutional Neural Network)의 발전과 함께 R-CNN, Fast R-CNN, Faster R-CNN 등 Region Proposal 기반의 탐지 기법이 연구되었으며, 이를 통해 객체 탐지의 성능이 비약적으로 개선되었다(Qi 외, 2024). 최근에는 객체 탐지의 속도와 정확도를 동시에 높이기 위한 단일 단계 객체 탐지 모델(Single Shot Detector, SSD) 및 YOLO 시리즈가 등장하였다. YOLOv5, YOLOv8 등의 최신 버전이 지속적으로 개선되면서, 다양한 응용 분야에서 활용되고 있다(Qi et al, 2024).

또한, 최신 연구에서는 작은 객체 탐지 성능을 개선하기 위해 FFCA-YOLO 및 SOD-YOLO 모델이 개발되었으며, UAV(무인항공기) 기반 건설 현장 모니터링에서도 활용되고 있다(Zhang et al, 2024; Li et al, 2024).

이러한 객체 탐지 기술의 발전은 건설 현장의 실시간 안전 모니터링 및 위



협 감지 시스템 구축에 중요한 역할을 하고 있으며, 향후 인공지능과 결합된 건설 안전 관리 기술의 지속적인 발전이 예상된다. 구체적 내용은 <표2-3>과 같다.

<표2-3> YOLO 알고리즘 및 객체 탐지 기술 선행 연구

연구 주제	연도 및 저자	주요 내용
Monocular 3D object detection for construction scene analysis. Computer Aided Civil and Infrastructure Engineering,	2023 (Shen et al.)	건설 현장에서 단일 카메라 기반의 3D 객체 탐지 기법 적용
FFCA-YOLO for Small Object Detection in Remote Sensing Images. IEEE Transactions on Geoscience and Remote Sensing,	2024 (Zhang et al.)	FFCA-YOLO 모델을 활용하여 원격 감지 이미지에서 작은 객체 탐지 성능 향상
SOD-YOLO: Small-Object-Detection Algorithm Based on Improved YOLOv8 for UAV Images. Remote. Sens.	2024 (Li et al.)	SOD-YOLO 모델을 활용하여 UAV 기반의 작은 객체 탐지 정확도 개선



MSFE-YOLO: An Improved YOLOv8 Network for Object Detection on Drone View. IEEE Geoscience and Remote Sensing Letters,	2024 (Qi et al.)	MSFE-YOLO 모델을 통해 드론 영상에서 객체 탐지 성능 향상
Object Detection for Construction Waste Based on an Improved YOLOv5 Model. Sustainability.	2022 (Zhou et al.)	향상된 YOLOv5 모델을 활용하여 건설 폐기물 객체 탐지 개선

제 3 항 국내 YOLO 알고리즘에 관한 선행 연구

국내 YOLO알고리즘에 대한 연구는 YOLO버전별 객체인식 성능의 차이를 활용한 알고리즘 작성이 주를 이루고 있다.

최승훈(2022)는 YOLO5 모델별 드론영상 기반 보행장 추돌 경고시스템의 성능을 비교하였다.

유지희(2023)은 무인단속카메라를 활용하여 이륜차 후면 번호판 데이터를 수집 후, YOLO 번호판 내 문자에 대한 버전별 성능 실험 및 비교를 하여 최신 버전이 최선의 선택이 아닐 수 있음을 시사하였다.

김은정(2023)은 YOLOv8에서 CPR 이미지를 이용한 지하시설물 탐지 성능 향상을 위하여 Class 특징별로 Bounding box를 조절할 필요성을 확인하였다.

최병정(2023)은 PASCAL VOC 데이터를 COCO 데이터 형식과 YOLO 데이터 형식으로 변환 후, YOLOv5 모델을 활용하여 건설 현장 근로자 안전모 실시간 모니터링 기술 활성화 방안을 연구하였다.

오유나(2024)는 웹에서 이미지 크롤링으로 데이터 수집 후, YOLOv8를 활용하여 재활용 자원 자동분류 엔진을 구현 뒤 성능을 평가하였다.

김희범(2024)는 이차전지 제조에서 불량 검출 성능에 대하여 YOLOv5와 YOLOv8의 하이퍼 파라미터 설정 후 결과를 비교하였다.

손솔비(2024)는 YOLO11 모델을 활용하여 화재 시, 화재, 안개와 연기를 객체 인식하는 새로운 화재 객체 탐지 모델을 제안 하였다.

임새롬(2025)은 하수관로 내부결함 이미지를 이용한 하수관로 결함탐지 모델별 효과를 YOLO5~YOLO8까지 비교하였다.


최은주(2025)는 YOLO8 모델을 활용하여 다양한 버전별 YOLO8의 원통형 배터리의 외관 결함 검출 성능을 비교하였다.

오종호(2025)는 데이터 증강 모델과 YOLO8~10 모델을 결합하여 위험물 창고 환경 개선을 하기 위한 최적화 전략을 제안하였다.



<표2-4> 국내 YOLO 알고리즘에 관한 선행 연구

연구 주제	연도 및 저자	주요 내용
YOLO5 모델별 드론 데이터 분석 성능 비교	2022(최승훈)	YOLO 버전별 드론데이터 학습을 통한 보행자 추돌시스템 성능 비교
이륜차 후면 번호판 데이터 분석 성능 비교	2023(유지희)	YOLO 버전별 후면 번호판 문자 인식을 비교
CPR이미지를 이용한 지하 시설물 탐지 성능 향상	2023(김은정)	Bounding 크기 변화를 통한 YOLOv8 성능 향상
건설 현장 근로자 안전모 실시간 모니터링 기술 활성화	2023(이형도)	YOLOv5를 활용한 건설 현장 내 근로자 안전모 실시간 모니터링 기술 활성화 방안 연구
재활용 자원 자동분류 엔진 구현	2024(오유나)	YOLOv5를 활용한 재활용 자동 분류 엔진 구현
이차전지 제조 불량 검출	2024(김희범)	이차전지 제조 불량 검출에 대한 파라미터 설정 후 YOLOv5와 YOLOv8 성능 비교
YOLO11 모델을 활용한 화재 인식 모델 제안	2024(손솔비)	YOLO11 모델을 활용하여 기존 연구에 더해 안개 클래스를 추가하여 화재 초기 진압 가능성을 높이는 모델 제안
하수관로 결함탐지 모델별 효과 비교	2025(임새롬)	YOLO5~YOLO8 모델별 하수관로 결함탐지 모델별 효과 비교



YOLO8 버전별 원통형 배터리의 외관 결합 검출 성능 비교	2025(최은주)	YOLO8 모델별(N, S, M, L , X) 배터리의 외관 결합 검출 성능 비교하여 환경과 목적에 맞는 최적 모델 선정
데이터 증강 모델과 YOLO모델을 결합한 위험물 창고 환경 개선 전략 제안	2025(오종호)	데이털 증강 모델을 활용하여 학습데이터에 환경 요인을 추가하였으며,YOLO8~10 모델을 사용하여 위험물 창고 개선 최적화 전략을 제시하였다



제 3 장 연구설계와 분석 방법

제 1 절 YOLO 데이터 수집

본 연구에서는 YOLO 모델을 활용한 객체 탐지를 위해 다양한 데이터셋을 수집하고 전처리하였다. 수집된 데이터는 객체 인식 및 사고 유형 분류를 위한 학습 데이터로 구성되었으며, 주요 데이터셋 확보를 위하여 Roboflow Universe, Kaggle, COCO 그리고 AI-HUB를 비교 분석하였다.

1. Roboflow Universe


Roboflow Universe는 YOLO 학습을 위한 객체 탐지용 데이터셋을 제공하는 대표적인 공개 플랫폼이다. 사용자는 필요한 데이터의 범주 및 저장 형식, 키워드 등을 직접 지정하여 데이터를 수집할 수 있다. 본 연구에서는 근로자의 보호구 착용 및 건설 현장과 관련된 이미지들을 중심으로 데이터를 확보하였다. 그러나 사고 유형과 직접적으로 연계된 데이터는 제한적이었다.

2.Kaggle


Kaggle은 다양한 데이터셋을 제공하는 머신러닝 기반 통합 플랫폼으로, 데이터 분석, 비전 인식, 참여형 학습 등을 지원한다. 그러나 본 연구의 목적에 적합한 사고 유형 관련 데이터셋은 존재하지 않았으며, 주로 보호구 착용 여부에 관한 단순한 데이터에 국한되어 있었다.

3.COCO (Common Objects in Context)

COCO는 일반적인 객체 인식 및 분할을 위한 대규모 데이터셋으로, 약 80개의 객체 클래스와 91개의 세분화된 카테고리를 포함한다. 본 연구에서는 COCO에서 제공하는 객체 분류 정보를 참고하였으나, 건설 현장의 위험 상황을 명시적으로 포함한 데이터는 존재하지 않아 직접 활용에는 한계가 있었다.



<그림 3-1> Roboflow Universe⁸⁾



<그림 3-2> kaggle 데이터셋⁹⁾

AI-HUB 데이터셋

AI-HUB는 인공지능 학습을 위한 공개 데이터 플랫폼으로, 다양한 분야에 걸친 데이터셋을 보유하고 있다. 특히 재난·안전 환경 분야 중 건설 현장의 위험 상태 판단에 특화된 영상 데이터가 다수 구축되어 있어, 본 연구에서는 이를 주요 연구 데이터셋으로 활용하였다.

AI-HUB의 건설 현장 위험 상태 판단 데이터셋은 상위 범주로 정상(Y)과 비정상(N) 두 가지 상태로 분류되며, 중분류에는 추락, 낙하, 협착, 화재, 전도의 5대 사고 유형이 포함된다. 각 사고 유형은 10개의 시나리오로 구성되어 있으며, 개별 시나리오마다 2,000개의 영상 데이터가 구축되어 있다. 이에 따라 사고 유형별 데이터는 총 2(정상/비정상) × 5(사고 유형) × 10(시나리오) × 2,000(건)으로, 총 200,000건의 데이터가 수집되었다.

추가로, 주의 요망 작업(타워크레인, 롤러, 하역, 방수, 항타기 작업 등) 관련 영상 10,000건과, 안전 보조 장비 관련 영상 16,000건이 포함되어, 전체 데이터

출처

8) <https://universe.roboflow.com/>

9) <https://www.kaggle.com/datasets>

규모는 총 226,000건에 이른다. 본 데이터셋은 사고 예방을 위한 객체 탐지 및 위험 상황 분류 학습에 있어 높은 활용 가능성을 지닌다.

<표3-1> AI-HUB 데이터셋 구성

사고유형		구축량(개)	비율
5대사고유형	추락	40,000	17.70%
	낙하	40,000	17.70%
	협착	40,000	17.70%
	화재	40,000	17.70%
	전도	40,000	17.70%
주의요망작업		10,000	4.42%
안전보조장비		10,000	7.08%
총합계		226,000	100.00%

제 2 절 수집데이터 전처리

제 1 항 학습데이터 선별

AI-HUB에서 제공하는 5대 사고 유형별 시나리오 중 건설업 재해자 비중이 가장 높은 추락 사고 유형을 중심으로 한 시나리오 데이터를 기반으로 총 22,000장의 이미지가 수집되었으며, 추락 유형의 정상·비정상 데이터를 중심으로 학습 모델을 설계하였다. 특히, 비계공사, 개구부 공사, 외벽 공사, 족장 공사, 사다리 공사 등 총 5개의 공정에 대하여, 각각 정상 시나리오(안전 작업 상태)와 비정상 시나리오(위험 작업 상태)를 구분하여 총 20개의 세부 시나리오로 구성되었다. 이에 대한 세부 내역은 다음과 같다.

해당 <표3-2>는 사고유형, 공정, 시나리오 ID, 시나리오 명, 수량 등의 정보를 포함하며, 각각 2,000장의 이미지가 할당되었음을 나타낸다.



<표3-2> AI-HUB 데이터셋 내 추락 시나리오 구성

순번	사고유형	공정	시나리오ID	시나리오	수량
1	추락 (정상)	비계공사	Y-01	비계 작업 발판 설치	2,000
2			Y-02	개폐형 발판 단힘	2,000
3		개구부 공사	Y-03	개구부 덮개 설치	2,000
4			Y-04	개구부 난간 설치	2,000
5		외벽 공사	Y-05	단부 난간 설치	2,000
6			Y-06	단부 수직 방지망 설치	2,000
7		조적 공사	Y-07	이동식 비계 난간 설치	2,000
8			Y-08	상부 간이 사다리 미설치	2,000
9		사다리 공사	Y-09	사다리 정상 설치	2,000
10			Y-10	사다리 치상단 밑단 작업	2,000
11	추락 (비정상)	비계공사	N-01	비계 작업 발판 미설치	2,000
12			N-02	개폐형 발판 열림	2,000
13		개구부 공사	N-03	개구부 덮개 미설치	2,000
14			N-04	개구부 난간 설치 불량	2,000
15		외벽 공사	N-05	단부 난간 설치 불량	2,000
16			N-06	단부 수직 방지망 불량	2,000
17		조적 공사	N-07	이동식 비계 난간 불량	2,000
18			N-08	상부 간이 사다리 설치	2,000
19		사다리 공사	N-09	사다리 적재물 위 설치	2,000
20			N-10	사다리 최상단 작업	2,000

추락 시나리오 중 3대 사고 유형(추락, 끼임, 부딪힘) 8대 위험요인(비계, 지붕, 사다리, 고소작업대, 방호장치, 정비 중 운전 정지, 혼재 작업, 충돌 방지 장치)(Zhou, Q, et al, 2022)에 해당하는 비계공사(Y-01, Y-02, Y-03, Y-04) 및 사다리 공사(Y-09, Y-10, N-09, N-10)의 데이터 가공을 결정하였다.



객관적인 지표 비교를 위하여 주의요망 작업의 C-01(타워크레인 양중 작업), C-02(롤러 차량 작업), C-03(지게차 차량 작업)를 추가 가공하였다

<표3-3> 연구 데이터셋 구성

순번	공정	시나리오ID	시나리오	수량
1	비계 공사	Y-01	비계 작업 발판 설치	2,000
2		Y-02	개폐형 발판 닫힘	2,000
3		N-01	비계 작업 발판 미설치	2,000
4		N-02	개폐형 발판 열림	2,000
5	사다리 공사	Y-09	사다리 정상 설치	2,000
6		Y-10	사다리 치상단 밑단 작업	2,000
7		N-09	사다리 적재물 위 설치	2,000
8		N-10	사다리 최상단 작업	2,000
9	양중 작업	C-01	타워크레인 작업	2,000
10	토공사	C-02	롤러 차량 작업	2,000
11	화물 운반 공사	C-03	지게차 차량 작업	2,000
총합계				22,000

<표3-3>의 학습데이터셋의 구조를 Train, Valid, Test 데이터셋 구조로 나누었다. 학습 비율은 Train:Validation:Test를 각각 16,000:2,000:2,000 (비율 8:1:1)로 설정하였다. 각 데이터셋의 역할은 다음과 같다.

Train Dataset: 모델이 실제 학습하는 데 사용되는 데이터로, 객체 위치 정보를 포함한 이미지가 제공되어 모델이 패턴을 학습하고 가중치를 조정하는데 활용된다.

Validation Dataset: 학습 중 모델의 성능을 평가하고 과적합을 방지하기 위한 검증용 데이터로 사용된다. 모델이 직접 학습하지는 않지만 학습 조정에 중요한 역할을 한다.



Test Dataset: 최종 성능 평가를 위한 데이터로, 실제 환경에서의 예측 성능을 확인하기 위해 사용된다.

제 2 항 학습 데이터 클래스 선정

본 연구에서는 YOLO 기반 객체 탐지 모델 학습을 위하여, 라벨링(Classification)을 물리적 객체(Objects)와 위험 상황(Hazardous Situations)의 두 가지 범주로 나누어 정의하였다.

객체(Class)에는 건설 현장에서 주요하게 관찰되는 사람(People), 사다리(Ladder), 비계/발판(Scaffold), 타워크레인(Tower crane), 지게차(Forklift), 롤러(Roller) 등이 포함되며, 이는 작업자의 활동과 환경 구성 요소를 시각적으로 탐지하기 위한 기반으로 활용된다.

위험 상황은 실제 현장에서 빈번하게 발생하는 비정상 작업 행태를 중심으로 설정되었으며, 사다리 단독 작업(Unsafe: Solo work), 비계·발판 미설치(Unsafe: No platform), 사다리 하부 적재물 설치(Unsafe: No outrigger / Not secured) 등의 유형으로 구체화하였다. 라벨링 클래스에 대한 세부 구성은 다음 <표3-4>과 같다.

<표3-4> 클래스에 대한 세부 구성


순번	클래스 명칭	비고
1	People	
2	Ladder	아웃트리거 포함
3	Scaffold	
4	Unsafe (Solo work)	
5	Unsafe (No outrigger)	바운딩 박스 내 사다리 하부 2단 포함
6	Unsafe (No platform)	
7	Unsafe (Not secured)	바운딩 박스 내 사다리 최하단부 포함
8	Hazardous work (Tower crane)	



9	Hazardous work (Forklift)	
10	Hazardous work (Roller)	

제 3 항 클래스 데이터 라벨링 구성


YOLO 모델을 구동하기 위해선 데이터셋내에 데이터와 각 데이터 내 클래스 정보를 포함한 라벨링 텍스트가 필요하다. 이를 그림으로 나타내면 다음과 같다.




<그림 3-3> 데이터셋 구성

각 이미지에 라벨링을 하기 위하여 labellmg 프로그램을 활용하였다.
데이터셋의 이미지를 YOLO 구동을 편리한 640*640의 크기로 변환 후 각

데이터 내에 labelling 프로그램을 활용하여 해당 데이터에 포함된 클래스들을 각각 라벨링 해주었다. 그 후 해당 파일을 구글 코랩을 활용하기 위하여 구글 드라이브에 업로드하였다



<그림 3-4> 라벨링 전 데이터



<그림 3-5> 라벨링 후 데이터



제 3 절 YOLO 모델별 구동


제 1 항 YOLO 모델 구조 분석

본 연구에서는 건설 현장 데이터셋의 5대 사고 유형 중 재해자 발생 비중이 가장 높은 추락 데이터를 중심으로 YOLO 기반 객체 탐지 학습을 수행하였다. 이를 위해 Ultralytics에서 제공하는 YOLOv5, 6, 8, 10, 11의 구조를 비교 분석하고, 최종적으로 본 연구 목적에 가장 적합한 모델을 선정하여 적용하였다.

제 2 항 Google Colab을 활용한 YOLO 학습

22,000개의 데이터셋을 YOLO로 구동하려면 일반적인 그래픽 카드로는 메모리가 부족하기 때문에 Google Colab을 활용하였다.

구글 코랩(Google Colab)이란 구글에서 제공하는 클라우드 기반의 노트북 환경이다. 주로 Python 코드를 작성하고 실행하는데 사용되며, 데이터 분석, 기계 학습, 딥러닝 등의 작업에 유용하다.



<그림 3-6> 구글 코랩(Google Clab)¹⁰⁾

구글 코랩에서 Python을 이용해 드라이브의 데이터셋을 마운트하고, Ultralytics의 YOLO를 버전별로 받아 학습하였다. 버전별 모델은 용량이 작고 건설 현장 CCTV 객체 인식에 적합한 N 모델로 통일하였다. 학습 횟수는 대용량 데이터셋에 적합한 10회로 진행하였다. 사용된 코드는 그림과 같다.

<pre>from google.colab import drive drive.mount('/content/drive')</pre>	Google Drive를 Colab에 연결해서 파일을 읽을 수 있도록 마운트
<pre>import numpy as np import pandas as pd import os import torch</pre>	YOLO 학습을 위한 라이브러리 가져오기
<pre>!pip install ultralytics from ultralytics import YOLO</pre>	ultralytics에서 제공하는 YOLO 설치
<pre>model_ver = "yolov8n" model = YOLO(model_ver + ".pt") model.info()</pre>	설치된 YOLO내 특정 모델 로드

<그림 3-7> 구글 코랩(Google Clab) 내 YOLO 설치 코드

<pre>save_path = os.path.join("/content/drive/MyDrive/", model_ver, "now/runs/")</pre>	학습 결과 저장 경로 설정
<pre>if not os.path.exists(save_path): os.makedirs(save_path)</pre>	경로가 존재하지 않으면 새로 생성
<pre>data_path = "/content/drive/MyDrive/now/dataset/my_data_new.yaml"</pre>	데이터셋 경로 설정
<pre>model.train(data=data_path, epochs=10, imgsz=640, device="cuda", save=True, save_period=1, project=save_path, name="train_" + model_ver)</pre>	학습에 사용할 .yaml 파일 경로 지정 10번 반복하여 학습 지정 입력 이미지 크기(640·640) 학습 결과 저장 여부 매 에폭마다 저장 저장할 상위 폴더 경로 학습 결과 폴더명 지정

<그림 3-8> YOLO를 이용한 데이터셋 학습 코드

10) <https://colab.google/>

제 4 절 모델 성능 평가 및 검증 방법

모델의 정확성과 실시간 적용 가능성을 평가하기 위해, 본 연구에서는 정확도(Precision), 재현율(Recall), F1 Score, IoU(Intersection Over Union), FPS(Frame Per Second)를 주요 성능 지표로 사용하였다.

제 1 항 정확도(precision), 재현율(Recall), F1 Score

정확도(Precision)

모델이 검출한 객체 중 실제로 정답인 비율을 의미하며, 다음과 같이 계산된다.

$$Precision = \frac{TP}{TP + FP}$$

TP(True Positive):실제 객체가 있고 모델도 올바르게 검출

FP(False Positive): 실제 객체가 없는데 모델이 잘못 검출한 경우

재현율(Recall)

실제 객체 중 모델이 얼마나 정확히 검출했는지를 나타낸다.

$$Recall = \frac{TP}{TP + FN}$$

FN(False Negative):실제 객체가 있지만 모델이 검출하지 못한 경우

F1 Score

F1 Score는 정밀도(Precision)와 재현율(Recall)의 균형을 평가하는 지표이다. 두 값을 단순 평균으로 계산하면 중요한 정보가 손실될 수 있으므로, 조화 평균을 사용하여 F1 Score를 계산한다.F1 Score가 높을수록 모델의 정밀도와 재현율을 모두 잘 유지하고 있음을 나타낸다.

$$F1\ Score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$



제 2 항 IOU(Intersection Over Union), FPS(Frame Per Second)

IOU(Intersection Over Union)

IOU는 모델이 예측한 바운딩 박스와 실제 객체의 바운딩 박스가 얼마나 겹치는지를 평가하는 지표이다. IoU가 0.5 이상일 경우 TP, 0.5미만일 경우 FP로 간주한다.

$$IoU = \frac{Area\ of\ Overlap}{Area\ of\ Union}$$

분자: 예측한 박스와 실제 박스가 겹치는 영역

분모: 두박스를 합친 전체 영역

FPS(Frame Per Second)


FPS는 모델이 1초에 몇 개의 프레임을 처리할 수 있는지를 나타내는 지표로 높을수록 모델의 속도가 빠름을 의미한다

$$FPS = \frac{Total\ Processed\ Frames}{Total\ Time\ Taken(second)}$$

제 3 항 연구 방법 소결

본 연구는 건설현장의 위험 상태를 효과적으로 탐지하기 위한 YOLO 기반 객체 인식 모델의 성능을 비교·분석하고자 하였다. 이를 위하여 AI-HUB에서 제공하는 건설안전 데이터셋을 중심으로 5대 사고 유형(추락, 낙하, 협착, 화재, 전도)에 대한 총 226,000건의 이미지 데이터를 확보하고, 이 중 정상/비정상 시나리오에 기반한 20개의 상세 시나리오로 구성된 22,000장의 데이터를 선별하여 학습용(16,000장), 검증용(2,000장), 테스트용(2,000장)으로 분할하였다.

객체 분류는 물리적 객체(Class)와 위험 상황(Hazardous Situations)으로 구분되었으며, 총 10개의 라벨링 클래스(People, Ladder, Scaffold, Unsafe(Solo



work), Unsafe(No outrigger), Unsafe(No platform), Unsafe(Not secured), Hazardous work(Tower crane), Hazardous work(Forklift), Hazardous work(Roller))가 지정되었다. 데이터셋 라벨링은 labelImg 프로그램을 통해 YOLO 학습 형식(640×640)으로 변환 및 구성되었으며, Google Colab 환경에서 ultralytics의 YOLOv5n, YOLOv6n, YOLOv8n, YOLOv10n, YOLOv11n 모델을 동일 조건하에 학습하였다.

성능 평가는 정확도(Precision), 재현율(Recall), F1 Score, IoU, FPS(Frame Per Second) 등의 지표를 활용하여 수행되었으며, 각 모델의 객체 탐지 능력과 실시간 적용 가능성을 종합적으로 검증하였다. 특히 혼동행렬 분석과 신뢰도 기반 F1 - Confidence Curve를 도입하여 클래스별 탐지 안정성과 분류 정확도를 정량적으로 비교하였으며, 이를 통해 건설 현장에서 가장 우수한 결과를 나타낼 것으로 기대되는 모델을 선정하였다.

이상의 분석 결과는 건설 현장 내 주요 위험 요인의 자동 탐지를 위한 YOLO 모델의 실질적 적용 가능성을 입증하며, 향후 스마트 건설 안전관리 시스템 설계에 유용한 기초 자료로 활용될 수 있을 것으로 판단된다.



제 4 장 YOLO 기반 AI 모델별 학습 결과 분석

제 1 절 YOLO 모델별 학습 성능 변화 분석

YOLO 모델을 활용한 객체 탐지 학습 결과, 학습 및 검증 손실 함수의 지속적인 감소와 성능 지표의 점진적 향상이 관측되었다. 모델별 학습 과정에서의 성능 변화와 손실 함수의 감소 추이는 해당 그림과 같으며 자세한 결과값은 부록에 추가하였다.

YOLO 모델의 학습 과정에서 손실 함수(Loss Function)의 감소 추이와 주요 성능 지표의 변화를 분석한 결과, 각 모델은 전반적으로 학습이 진행됨에 따라 성능이 향상되고 손실 값이 안정적으로 감소하는 경향을 나타냈다.

우선, <그림 4-1>에 제시된 YOLOv5n 모델은 학습 초기에 train/val 손실 값이 빠르게 감소하면서도 mAP50 및 mAP50 - 95에서 점진적인 상승 곡선을 보였다. Precision과 Recall 지표는 약 10 epoch 내에서 안정적으로 수렴하였으며, 특히 precision은 빠르게 상승한 후 완만한 증가세를 유지하며 학습 안정성을 보여주었다.

<그림 4-2>의 YOLOv6n 모델은 YOLOv5n보다 손실 함수의 초기값이 다소 높았으나, 더 빠른 속도로 감소하며 10 epoch까지 꾸준한 개선 추이를 나타냈다. Precision과 Recall, mAP 지표는 모두 epoch 진행에 따라 점진적으로 향상되었으며, mAP50 - 95 기준에서 최종적으로 높은 정확도를 기록하였다. 이는 YOLOv6n 모델의 깊은 학습 구조와 파라미터 최적화가 보다 정교하게 이루어졌음을 시사한다.


<그림 4-3>의 YOLOv8n 모델은 학습 초기에 손실 함수가 일시적으로 증가하는 변동을 보였으나, 이후 빠르게 수렴하여 안정화되는 양상을 나타냈다. Precision과 Recall 지표는 YOLOv5n과 유사한 수준에서 수렴하였으며, 특히 mAP50 - 95는 다른 모델 대비 고르게 상승하여 전체 클래스에 대한 탐지 정밀도가 우수함을 확인할 수 있었다.

<그림 4-4>의 YOLOv10n 모델은 다른 모델에 비해 초기 손실값이 높은 편


이었으며, 전반적인 수렴 속도는 완만하게 나타났다. Precision과 Recall은 점진적으로 상승하였으나, mAP50과 mAP50 - 95는 후반부로 갈수록 불안정한 변동을 보이며 일부 과적합(overfitting)의 가능성을 내포하였다. 이는 YOLOv10n 모델의 구조적 복잡성과 계산량 증가로 인해 안정적인 학습 성능 확보에 시간이 더 필요함을 의미한다.

마지막으로 <그림 4-5>의 YOLOv11n 모델은 학습 초기에 손실 함수가 빠르게 감소하며 안정적인 수렴 양상을 보였다. Precision과 Recall 지표는 YOLOv5n 및 YOLOv8n과 유사한 수준에서 점진적으로 향상되었고, mAP50 및 mAP50 - 95에서도 비교적 고르게 상승하는 추이를 나타냈다. 특히 mAP 지표의 진동 폭이 제한적이었으며, 이는 모델의 일반화 성능이 개선되었음을 시사한다. 전반적으로 YOLOv11n 모델은 학습 안정성과 탐지 정밀도 측면에서 균형 잡힌 성능을 보여주었다.


결과적으로 YOLOv5n, YOLOv8n과 YOLOv11n 모델은 빠른 수렴성과 안정적인 성능을 나타내어 실시간 건설현장 위험 탐지에 실용성이 높은 것으로 분석되었으며, YOLOv6n은 정밀도 향상 측면에서 우수한 성능을 보였으나 상대적으로 긴 학습 시간이 요구되었다. 반면, YOLOv10n은 구조적 복잡성으로 인해 손실 수렴 및 정확도 측면에서 불안정한 양상을 보였다.




<그림 4-1> YOLOv5n 모델 학습 과정에서의 성능 변화와 손실 함수(loss)의 감소 추이




<그림 4-2> YOLOv6n 모델 학습 과정에서의 성능 변화와 손실 함수(loss)의 감소 추이



<그림 4-3> YOLOv8n 모델 학습 과정에서의 성능 변화와
손실 함수(loss)의 감소 추이



<그림 4-4> YOLOv10n 모델 학습 과정에서의 성능 변화와
손실 함수(loss)의 감소 추이



<그림 4-5> YOLOv11n 모델 학습 과정에서의 성능 변화와
손실 함수(loss)의 감소 추이

제 2 절 YOLO 모델별 학습 결과 분석

제 1 항 YOLO 모델별 학습 필요 시간 비교

각 모델별 학습 시간은 1epoch에서 10epoch로 증가하는 동안 모두 상승하는 수치를 보였으며 작게는 1.52배에서 크게는 9.55배의 크기 차이를 보였다. 모델별로 표로 정리하면 <표4-1>와 같다.

<표4-1> YOLO 모델별 학습 필요 시간

모델	1epoch 학습 시간(초)	10epoch 학습 시간(초)	특이사항
yolov5n	4637.27	7918.37	
yolov6n	5821.22	8830.85	최장 시간 소요
yolov8n	367.291	3509.01	최소 시간 소요
yolov10n	3304.22	6629.72	
yolov11n	3617.54	6900.81	

제 2 항 YOLO 모델별 손실 함수(Loss Function) 변화 비교

1) train/box_loss

학습 데이터에 대한 박스 손실(box loss)는 모든 모델들이 큰 격차를 보이며 감소하였다. 이는 상자 위치 예측의 정확도가 점진적으로 크게 향상되었음을 나타낸다. 10epoch를 기준으로 yolov8n과 yolov11n이 가장 낮은 수치를 보여주었고,, yolov10n이 가장 높은 수치를 보여주었다. 모델별로 표로 정리하면 <표4-2>과 같다.

<표4-2> YOLO 모델별 train/box_loss 변화

모델	1epoch train/box_loss	10epoch train/box_loss	특이사항
yolov5n	1.14515	0.66797	
yolov6n	2.80846	0.84561	
yolov8n	0.83125	0.64552	최솟값
yolov10n	2.08438	1.35784	최댓값
yolov11n	1.07539	0.6459	최솟값

2) train/cls_loss

클래스 손실(classification loss)은 yolov8n는 제외한 나머지 모델에서 초기 epoch에선 train/box_loss보다 큰 값을 보이지만 최종적으로는 train/box_loss 값을 보였다. yolov8n의 경우 처음부터 train/box_loss보다 작은 값을 보였다.

10epoch를 기준으로 yolov8n이 가장 낮은 수치를 보여주었고, yolov10n이 가장 높은 수치를 보여주었다. 모델별로 표로 정리하면 <표4-3>과 같다.

<표4-3> YOLO 모델별 train/cls_loss 변화

모델	1epoch train/cls_loss	10epoch train/cls_loss	특이사항
yolov5n	1.94346	0.39894	
yolov6n	3.98981	0.59502	
yolov8n	0.72265	0.35957	최솟값
yolov10n	6.56287	0.75909	최댓값
yolov11n	1.93497	0.36754	

3) train/dfl_loss

분포 중심 손실(Distribution Focal Loss) 역시 꾸준히 감소하며 모델이 객체 중심 좌표 예측을 안정적으로 수행하고 있음을 보여준다. 10epoch를 기준으로 yolov5n이 가장 낮은 수치를 보여주었고, yolov10n이 가장 높은 수치를 보여주었다. 모델별로 표로 정리하면 <표4-4>과 같다.

<표4-4> YOLO 모델별 train/df_loss 변화

모 델	1epoch train/cls_loss	10epoch train/cls_loss	특이사항
yolov5n	1.3091	0.92747	최솟값
yolov6n	3.98981	1.16436	
yolov8n	1.1036	0.974	
yolov10n	2.4204	1.9256	최댓값
yolov11n	1.24613	0.95596	

4) val/box_loss, val/cls_loss, val/df_loss

검증 데이터에서도 동일하게 손실 함수가 점진적으로 감소하여, 학습 과정에서 과적합 없이 모델이 일반화 능력을 유지하며 성능을 개선해 나가고 있음을 확인할 수 있다.

제 3 항 YOLO 모델별 성능 평가 지표(Matrics) 비교

1) Precision (정밀도)

정밀도의 값이 증가할수록 잘못된 객체 검출(False Positive)의 비율이 감소했음을 의미한다. 모든 모델들의 학습이 진행됨에 따라 정밀도가 점진적으로 상승하여 성능이 개선되고 있음을 확인할 수 있다. 10epoch를 기준으로 yolov10n이 가장 낮은 수치를 보여주었고, yolov8n이 가장 높은 수치를 보여주었지만 나머지 모델의 수치도 yolov8n과 비슷한 값을 보여주었다. 모델별로 표로 정리하면 <표4-5>과 같다.

<표4-5> YOLO 모델별 Precision(정밀도) 변화

모 델	1epoch train/cls_loss	10epoch train/cls_loss	특이사항
yolov5n	0.85504	0.92747	
yolov6n	0.40947	0.92805	
yolov8n	0.91643	0.92854	최댓값
yolov10n	0.662	0.90789	최솟값
yolov11n	0.88209	0.92797	



2) Recall (재현율)

재현율은 정밀도와 비슷한 수치와 양상을 유지하였다. 이 역시 모델들의 학습이 진행됨에 따라 재현율이 점진적으로 상승하여 성능이 개선되고 있음을 확인할 수 있다. Precision과 마찬가지로 10epoch를 기준으로 yolov10n이 가장 낮은 수치를 보여주었고, yolov8n이 가장 높은 수치를 보여주었다. 모델별로 표로 정리하면 <표4-6>과 같다.

<표4-6> YOLO 모델별 Recall(재현율) 변화

모델	1epoch train/cls_loss	10epoch train/cls_loss	특이사항
yolov5n	0.86509	0.93501	
yolov6n	0.44608	0.92037	
yolov8n	0.90288	0.93628	최댓값
yolov10n	0.67803	0.90421	최솟값
yolov11n	0.88292	0.93614	

3) 평균 정밀도 (IoU 0.5 기준)

IoU 0.5 기준 평균 정밀도(mAP50)란, 예측 박스와 정답 박스가 50% 이상 겹칠 경우에 정답으로 판정한 값이다. 모든 모델에서 중간 에폭에서 약간의 편차를 보였지만 10epoch 기준 0.89~0.91의 값을 보였다. 10epoch를 기준으로 yolov 6n이 가장 낮은 수치를 보여주었고, yolov5n이 가장 높은 수치를 보여주었다. 모델별로 표로 정리하면 <표4-7>와 같다.

<표4-7> YOLO 모델별 평균 정밀도 (IoU 0.5 기준) 변화

모델	1epoch maP50	10epoch maP50	특이사항
yolov5n	0.87476	0.91698	최댓값
yolov6n	0.37991	0.89618	최솟값
yolov8n	0.88563	0.90587	
yolov10n	0.7033	0.90961	
yolov11n	0.88926	0.91434	

4) 종합 평균 정밀도 (IoU 0.50-95기준)

IoU 0.5-0.95 기준 종합 평균 정밀도(mAP50-95)란, 예측 박스와 정답 박스가 50% 이상 겹치는 것을 기준으로 5% 간격으로 95%까지 10개의 값을 평균 낸 값이다. IOU 0.50기준과 마찬가지로 모든 모델에서 중간 예폭에서 약간의 편차를 보였지만 10epoch 기준 0.73~0.81의 값을 보였다. 종합 평균 정밀도가 더 정밀한 능력을 평가하기에 평균 정밀도에 비해 낮은 값을 보였다. 10epoch를 기준으로 yolov6n이 가장 낮은 수치를 보여주었고, yolov11n이 가장 높은 수치를 보여주었다. 모델별로 표로 정리하면 <표4-8>와 같다.

<표4-8> YOLO 모델별 종합 평균 정밀도 (IoU 0.50-95 기준) 변화

모델	1epoch maP50-0.95	10epoch maP50-0.95	특이사항
yolov5n	0.67811	0.80617	
yolov6n	0.14775	0.73766	최솟값
yolov8n	0.73561	0.80905	
yolov10n	0.55522	0.80787	
yolov11n	0.70754	0.81787	최댓값

제 4 장 YOLO 모델별 혼동 행렬(Confusion Matrix) 분석

모델의 다중 클래스 분류 성능을 보다 정밀하게 평가하기 위하여, 본 연구에서는 학습된 YOLO 모델의 예측 결과를 바탕으로 혼동 행렬(Confusion Matrix)을 도출하였다. 혼동 행렬은 실제 클래스와 예측 클래스 간의 일치 여부를 기반으로 모델의 정분류 및 오분류 경향을 시각적으로 보여준다. 각 모델별 분석은 다음과 같다.

1) YOLOv5n

YOLOv5n의 경우 Ladder, Unsafe(Not secured), Hazardous work(Tower crane), Hazardous work(Roller)에서 각각 627건, 140건, 163건, 160건이 정확히 분류되었다.



People, Unsafe(Solo work), Unsafe(No outrigger), Unsafe(No platform)의 경우 각각 601건, 165건, 110건, 325건이 정분류되었지만 6건, 1건, 1건이 오분류되어 99%의 정분류 비율을 보여주었다.

Unsafe(No platform)는 325건이 정분류되고, 25건이 오분류되어 92.9%의 정분류 비율을 보여주었다.

Scaffold, Hazardous work(Forklift)의 경우 1304건, 76건의 정분류 718건, 82건이 오분류되어 59.2%, 48.1%의 정분류 비율을 보여주었다.

2) YOLOv6n

YOLOv6n의 경우 Unsafe(Solo work)에서 165건의 정확한 정분류를 보여주었다.

People, Ladder, Unsafe(No outrigger), Unsafe(No platform), Unsafe(Not secured), Hazardous work(Tower crane), Hazardous work(Roller)의 경우 각각 601건, 627건, 110건, 325건, 140건, 163건, 159건이 정분류되었지만 29건, 2건, 9건, 28건, 14건, 8건, 2건이 오분류되어 95.4%, 95.8%, 92.4%, 92%, 90.9%, 95.3%, 98.8%의 정분류 비율을 보여주었다.

Scaffold, Hazardous work(Forklift)의 경우 1106건, 76건의 정분류에 1030건, 83건이 오분류되어 51.8%, 47.8%의 정분류 비율을 보여주었다.

3) YOLOv8n

YOLOv8n의 경우 Unsafe(Solo work), Unsafe(No outrigger), Hazardous work(Roller)에서 165건, 110건, 160건의 정확한 정분류를 보여주었다.

People, Ladder, Unsafe(No platform), Unsafe(Not secured), Hazardous work(Tower crane)의 경우 각각 601건, 627건, 325건, 140건, 163건이 정분류되었지만 4건, 1건, 8건, 4건, 5건이 오분류되어 99.3%, 99.8%, 97.6%, 97.2%, 97%의 정분류 비율을 보여주었다.

Scaffold, Hazardous work(Forklift)의 경우 1280건, 76건의 정분류에 690건, 82건이 오분류되어 65%, 48.1%의 정분류 비율을 보여주었다.



4) YOLOv10n

YOLOv10n의 경우 Ladder, Unsafe(Solo work), Hazardous work(Tower crane), Hazardous work(Roller)에서 627건, 162건, 161건, 160건이 정분류가 되었지만 22건, 15건, 6건, 4건이 오분류가 되어 96.1%, 91.5%, 96.4%, 98.2%의 정분류 비율을 보여주었다.

People, Scaffold, Unsafe(No outrigger), Unsafe(Not secured), Unsafe(No platform), Unsafe(Not secured), Hazardous work(Forklift)의 경우 589건, 1167건, 109건, 320건, 139건, 73건의 정분류에서 93건, 768건, 16건, 33건, 16건, 84건이 오분류되어 86.4%, 60.5%, 87.2%, 90.7%, 89.7%, 46.5%의 정분류 비율을 보여주었다.

4) YOLOv11n

YOLOv11n의 경우 Ladder, Unsafe(No outrigger), Unsafe(Not secured), Hazardous work(Roller)에서 627건, 110건, 140건, 160건의 정확한 정분류를 보여주었다.

People, Unsafe(Solo work), Unsafe(No platform), Hazardous work(Tower crane)의 경우 601건, 165건, 325건, 163건이 정분류되었지만 7건, 1건, 22건, 2건의 오분류되어 98.8%, 99.4%, 93.7%, 98.8%의 정분류 비율을 보여주었다.

Scaffold, Hazardous work(Forklift)의 경우 1294건, 76건의 정분류에 711건, 82건이 오분류되어 64.5%, 48.1%의 정분류 비율을 보여주었다.

제 5 항 정규화 혼동 행렬 기반의 정밀 분석

정량적인 성능 평가를 위해, 앞선 원시 혼동 행렬에 이어 정규화된 혼동 행렬(Normalized Confusion Matrix)을 분석하였다. 이 행렬은 각 클래스별 참값(True Label)에 대한 예측값의 정확도를 0~1 사이의 비율로 나타내며, 클래스별 탐지 정밀도를 직관적으로 확인할 수 있다.

분석 결과, 대부분의 클래스에서 정분류 비율이 0.98 이상으로 매우 우수하



게 나타났다. 특히 다음과 같은 성과가 주목된다.

첫째, Ladder의 경우 모든 모델에서 1.00의 정분류율을 보였으며, 이는 해당 클래스가 명확한 시각적 특징을 갖고 있으며 모델이 이를 효과적으로 학습했음을 나타낸다.

둘째, People, Unsafe (Solo work), Unsafe (No outrigger), Unsafe (No platform), Unsafe (Not secured), Tower crane, Hazardous work (Forklift) 작업 등은 정확도가 낮은 YOLOv10 모델을 제외하면 1.00~0.98의 높은 분류 정확도를 보여 안정적으로 인식한 것으로 해석된다. 다만 Hazardous work (Forklift)의 경우 0.33~0.34에 해당하는 비율이 Hazardous work (Roller)에서 오분류하는 원인이 되었기에 정확도가 낮은 것으로 해석된다.


셋째, Hazardous work (Roller)는 0.66~0.67의 정분류와 Hazardous work (Forklift)를 0.33~0.34를 오분류율을 기록하여, 다른 위험 작업 클래스에 비해 탐지 정확도가 낮은 것으로 분석되었다. 이는 해당 장비의 크기, 형태 다양성, 촬영 각도에 따른 특징 불분명성 등이 원인일 수 있으며, 후속 연구에서는 해당 클래스의 데이터 수 보완 및 주석 품질 개선이 요구된다.

또한, 일부 클래스는 background(배경)으로 잘못 예측된 경우가 확인되었다. 정확도가 낮은 YOLOv10 모델을 제외하면, 특히 Scaffold가 배경 오인의 89~97%에 해당되었으며, 이는 시야 가림, 배경과의 색상 유사성, 난간대를 오인 등 시각적 혼란 요소가 영향을 미친 것으로 판단된다. 나머지 클래스의 경우 0%~4%의 배경 오인 요소가 발생하였다.

제 6 항 소결

모델별 학습 필요 시간은 YOLOv8n가 다른 모델에 비해 절반에 가까운 학습 시간을 필요로 하였다.(2.1항) 이는 실시간으로 영상에서 결과값을 도출해 내야하는 건설 모델에 적합하다.

학습 데이터에 대한 YOLO 모델별 학습 및 평가 결과를 종합적으로 분석한 결과, 손실 함수는 모든 모델들이 지속적으로 감소하여 예측의 정확도가 증가



했으며, 특히 박스 손실과 데이터 손실의 경우에는 YOLOv8n과 YOLOv10n의 결과값이 낮은 손실 값을 보였고, 분포 중심 손실의 경우 YOLOv5n이 낮은 결과값을 보였다(2.2항).

정밀도(Precision), 재현율(Recall), mAP 등 다양한 성능 지표에서도 전반적으로 높은 수치를 기록하였다(2.3항). 정밀도의 경우 YOLOv10이 0.90의 비교적 낮은 정밀도값을 보였지만 나머지 모델은 0.927~0.928의 정밀도 값을 보였다. 재현율의 경우 YOLOv10이 0.90의 비교적 낮은 재현율 값을 보였고, YOLOv5n, YOLOv8n, YOLOv11n이 0.935~0.936의 재현율 값을 보였다. MaP의 경우 공통적으로 중간 에폭에서 약간의 편차를 보였다. IoU0.5는 YOLOv5n에서 최대 0.916989의 값을 보였고 IoU0.5~0.95는 YOLOv11n에서 0.81787의 값을 보였다.

모델별 혼동행렬의 경우에는 Scaffold를 background로 오인식하거나 background를 Scaffold로 오인식하는 경우가 압도적으로 많았다. 이는 Scaffold의 특성상 옆에서 봤을 경우 난간대와 비교가 힘들며, 안전망 설치에 따른 시야 가림과 배경과의 경계 모호 등의 환경적 요인이 탐지 정확도에 영향을 줄 수 있음을 시사한다. 두 번째로 오분류가 많은 Forklift를 Roller로 인식한 경우는 다양한 상황의 데이터를 학습시키지 못하여 Forklift의 마스트가 안보일 경우 Roller로 인식한 경우가 대부분이었다. 나머지 클래스의 경우 모델 중 오류 없이 정확하게 인식한 경우가 있으며, 이는 객체 인식이 잘 되었음을 나타낸다.


종합적으로 YOLOv8n의 경우 빠른 속도와 더불어 다양한 지표에서 우수한 수치를 보여주었고, YOLOv11n의 경우 인식을 했을 경우, 보다 정확하게 인식하는 평균 정확도에서 높은 값을 보여주었다. 두가지 모델을 정확하게 비교하기 위하여 후속절에서 두 모델에 대한 신뢰도-성능 곡선은 고찰하고자 한다.



제 3 절 YOLOv8n, YOLOv11n 모델 기반 신뢰도-성능 곡선 분석

YOLO 모델의 클래스별 객체 탐지 성능을 보다 정량적으로 분석하기 위해 Confidence score에 따른 정밀도(Precision), 재현율(Recall), 그리고 F1 Score 기반의 성능 곡선 및 정밀도 따른 재현율 곡선을 도출하였다. 이 세부 분석은 모델이 예측 신뢰도를 기준으로 실제 탐지 성능이 어떻게 변화하는지를 시각적으로 확인할 수 있도록 구성되었으며, 클래스별 탐지 안정성과 임계값 설정에 대한 근거를 제공한다.

제 1 항 F1-Confidence Curve 분석



<그림 4-6> YOLOv8n 및 YOLOv11n 모델 F1-confidence Curve 곡선

YOLOv8n 및 YOLOv11n 모델 F1-confidence Curve 곡선은 비슷한 패턴이 관찰되었다. 전체 클래스 평균 기준으로, YOLOv8n의 F1 Score는 confidence 0.444 지점에서 0.92로 최대치를 기록하였다. YOLOv11n의 F1 Score는 confidence 0.421 지점에서 0.92로 최대치를 기록하였다.

이는 YOLO 모델이 전체적으로 높은 균형 성능을 발휘하고 있음을 시사한다. 자세한 분석 결과는 다음과 같다.

첫째, 대부분의 클래스는 confidence 값이 0.3~0.7 구간에서 안정적인 F1 Score (0.9 이상)를 유지하였으며, 특히 Unsafe 관련 클래스(Solo work, No outrigger, No platform 등)는 거의 0.95 이상의 정점 성능을 보여 매우 높은 예측 신뢰도를 확인할 수 있었다. 반면, 일부 클래스에서는 낮은 성능이 관측되었다.

둘째, Scaffold 클래스는 평균적으로 F1 Score가 0.79 수준에 머물렀으며, 다른 클래스 대비 전체적인 곡선이 낮고 넓게 퍼져 있어 시각적 유사성에 따른 분류 혼란 가능성이 높음을 시사한다.

셋째, Hazardous work (Tower crane) 클래스는 YOLOv8n의 경우 0.95 이상의 성능을 보여주었지만, YOLOv11n의 경우 0.95 내외의 성능을 보여주었다.


넷째, Hazardous work (Forklift) 클래스는 F1 Score가 약 0.66 수준에서 최대에 도달하였으며, 신뢰도가 높을수록 급격한 성능 저하가 나타나 고신뢰 조건에서의 탐지 안정성이 낮음을 보여준다.

반면, Hazardous work (Roller)는 0.8 수준에서 안정된 곡선을 유지하며, 높은 신뢰 조건에서도 일정한 성능을 유지하였다.

클래스별로 성능 격차가 존재하므로, 향후 실제 시스템 적용 시에는 클래스별 threshold 조정(adaptive thresholding) 전략이 필요할 수 있다. 특히 Forklift 및 Scaffold와 같은 복잡 구조 클래스에 대한 별도 후처리 또는 데이터 증강이 요구된다.



제 2 항 Precision-Confidence Curve 분석



<그림 4-7> YOLOv8n 및 YOLOv11n 모델 Precision-confidence Curve 곡선

Precision-Confidence Curve는 각 클래스에 대한 예측 신뢰도(Confidence)에 따른 정밀도 변화를 나타낸다. 1항 F1-Confidence Curve 곡선과 같이 YOLOv8n과 YOLOv11n의 비슷한 패턴을 보였다.

전체 클래스 평균 기준으로 볼 때, 모델은 전반적으로 높은 정밀도를 유지하고 있으며, confidence가 증가함에 따라 대부분의 클래스에서 Precision 값이 0.9 이상을 안정적으로 나타내고 있다. 자세한 분석 결과는 다음과 같다.

첫째, Unsafe 관련 클래스들(Solo work, No outrigger, No platform 등)은 Confidence 0.1 이상부터 거의 0.95 이상의 정밀도를 유지하며, 예측의 정확성이 매우 우수함을 보여준다. 이는 해당 클래스들이 시각적으로 뚜렷한 특징을 지니고 있어 모델이 일관되게 정답을 예측하고 있음을 시사한다.


둘째, Scaffold 클래스는 전체 Confidence 구간에서 점진적으로 Precision이 상승하며, 약 0.98 수준까지 도달한다. 이는 탐지가 가능하지만 confidence가 높아질수록 오탐이 감소함을 보여준다.

셋째, Hazardous work (Forklift) 클래스는 전체적으로 낮은 수준의 Precision

을 기록하였으며, 거의 0.5 이하에서 평탄한 형태를 유지하고 있어 해당 클래스의 탐지에 대한 불확실성이 크고, 오탐 비율이 높은 것으로 판단된다.

넷째, Roller 클래스는 전반적으로 0.8 수준의 안정적인 정밀도를 유지하며, 고신뢰 조건에서도 예측의 정확성이 떨어지지 않는 특성을 나타냈다.

제 3 항 Recall-Confidence Curve 분석



<그림 4-8> YOLOv8n 및 YOLOv11n 모델 Recall-confidence Curve 곡선

Recall-Confidence Curve는 예측 신뢰도(Confidence)에 따른 재현율(Recall)의 변화를 나타낸다. 재현율은 실제 존재하는 객체를 모델이 얼마나 잘 검출하였는지를 의미하며, 객체 누락(false negative)에 민감한 지표이다.

해당 곡선도 앞선 곡선들과 같이 YOLOv8n과 YOLOv11n의 비슷한 패턴을 보였다. 전체 클래스 평균 기준으로 볼 때, 모델은 Confidence 값이 0에 가까운 구간에서 최대 재현율 0.95를 달성하였다. 이는 낮은 임계값에서도 객체를 넓게 포착할 수 있는 YOLO 모델의 탐지 특성을 반영한 결과이다. 클래스별 자세한 사항은 다음과 같다.

첫째, 대부분의 Unsafe 관련 클래스들(Solo work, No outrigger, No platform


등)은 Confidence 값이 0.8 이하 구간에서 0.95 이상의 재현율을 안정적으로 유지하였으며, 이는 해당 클래스가 탐지 누락 없이 일관되게 예측되고 있음을 의미한다.

둘째, Scaffold 클래스는 Confidence가 높아질수록 재현율이 급격히 감소하는 경향을 보였으며, Confidence 0.8 이상에서는 0.3 이하로 급락하였다. 이는 해당 클래스가 비교적 복잡한 형태이거나 다른 유사 객체와의 경계가 모호하여 높은 신뢰 조건에서는 탐지 누락이 빈번하게 발생함을 시사한다.

셋째, Hazardous work (Forklift) 클래스는 Confidence 값이 전 구간에 걸쳐 낮은 재현율(약 0.65 이하)을 유지하고 있으며, 이는 오탐과 더불어 탐지 누락 또한 동시에 존재하는 모델의 성능 한계를 보여준다.

넷째, Roller 클래스는 약 0.65 수준의 재현율을 유지하다가 Confidence 0.85 이상에서 급격히 하락하는 특성을 보였으며, 이는 고신뢰 조건에서 일부 객체를 놓치는 경우가 발생함을 의미한다.

제 4 항 Precision-Recall Curve 분석



<그림 4-9> YOLOv8n 및 YOLOv11n 모델 Precision-Recall Curve 곡선

Precision-Recall Curve는 각 클래스에 대한 정밀도(Precision)와 재현율(Recall) 간의 상호 관계를 나타낸다. 모델이 얼마나 정확하게 예측하면서도 실제 객체를 얼마나 많이 포착하는지를 동시에 평가할 수 있게 하며, 전체 모델의 mAP@0.5(mean Average Precision at IoU 0.5) 값을 도출하는 데 핵심적인 지표로 활용된다.

전체 클래스 평균 기준으로 YOLOv8n의 mAP@0.5는 0.906으로, YOLOv11n은 0.914로 나타났다. 이는 YOLO 모델이 실질적인 객체 탐지 성능에서 매우 우수한 결과를 보였음을 의미한다. 각 클래스별 자세한 사항은 다음과 같다.

첫째, People, Ladder, Unsafe (Solo work), Unsafe (No outrigger), Unsafe (Not secured), Hazardous work (Tower crane) 클래스는 모두 Precision 0.99, Recall 0.95 이상의 조합을 기록하며 매우 이상적인 곡선을 형성하였다. 이들은 높은 정확도와 탐지 완성도를 동시에 만족시켜, 해당 클래스에 대한 학습이 안정적으로 이루어졌음을 나타낸다.

둘째, Scaffold 클래스는 Precision 약 0.81, Recall 0.8 수준으로, 중상위권의 성능을 보였으나 앞선 그래프와 마찬가지로 시각적 복잡도 및 유사 객체와의 혼동 가능성으로 인해 탐지 신뢰도에서 제한이 있었다. 또 한 Recall 0.7 미만 구간에서 YOLOv11n의 Precision의 값보다 조금 더 큰 값이 나오는 경향이 있었다.

셋째, Hazardous work (Forklift) 클래스는 YOLOv8n에서 Precision 0.485로, 전체 클래스 중 가장 낮은 성능을 나타냈으며, Recall 역시 0.5 수준에 머물렀다. YOLOv11n에서 Precision은 0.564로, Recall은 초반 값은 YOLOv8n보다 높았지만 Precision이 0.5 이후부터는 YOLOv8n과 비슷한 0.5 수준에 머물렀다. 이는 해당 클래스에서 높은 비율의 오탐과 누락이 동시 발생했음을 보여주며, 학습 데이터의 품질 또는 수량의 한계, 객체의 시각적 다양성이 주된 원인일 가능성이 크다.

넷째, Hazardous work (Roller)는 Precision 0.81, Recall 0.9 수준에서 안정적인 곡선을 보였으며, 클래스 특성상 크기와 형상이 일정하여 모델이 탐지에 성공적으로 반응하고 있음을 의미한다.

종합적으로, Precision-Recall 곡선은 YOLO 모델이 대부분의 클래스에 대해 높은 신뢰성과 재현성을 보유하고 있음을 입증하였으며, 특히 mAP@0.5 기준에서 90%를 상회하는 성능은 모델의 실용 가능성을 뒷받침하는 결정적 근거로 작용한다.

제 5 항 소결

본 절에서는 YOLOv8n과 YOLOv11n을 비교하고, 모델의 예측 신뢰도 (Confidence score)에 따른 정밀도(Precision), 재현율(Recall), F1 Score, 그리고 Precision-Recall 관계를 시각화한 곡선을 바탕으로, 모델 성능의 임계값 설정 기준과 클래스별 탐지 특성을 종합적으로 분석하였다.


Precision-Confidence Curve 분석 결과, 대부분의 클래스는 Confidence 값이 0.3~0.8 구간에서 0.9 이상의 안정적인 정밀도를 유지하였으며, 특히 Unsafe 계열 클래스는 0.95 이상의 높은 정밀도를 지속적으로 기록하였다. 반면, Forklift 클래스는 평균 0.5 수준에 머무르며 낮은 탐지 정확도를 보였다.

Recall-Confidence Curve에서는 YOLO 모델이 낮은 Confidence 구간(0~0.2)에서도 평균 0.95 이상의 높은 재현율을 달성하였으며, 대부분의 클래스는 0.8 이하에서 안정적인 탐지 성능을 유지하였다. 그러나 Scaffold 및 Forklift 클래스는 Confidence가 높아질수록 재현율이 급감하는 경향을 보여 탐지 누락의 가능성이 높은 것으로 나타났다.

Precision-Recall Curve 분석을 통해 도출된 전체 클래스의 평균 mAP@0.5는 0.906으로, YOLO 모델이 실제 객체 탐지 과업에서 높은 정확도와 재현율의 균형을 유지하고 있음을 확인할 수 있었다. People, Ladder, Unsafe (No outrigger) 등은 Precision과 Recall 모두에서 0.99 이상의 값을 기록한 반면, Forklift 클래스는 Precision 0.485로 가장 낮은 성능을 보였다.

이러한 분석 결과는 클래스별 탐지 성능을 수치적으로 비교·판단할 수 있는 근거를 제공하며, Confidence threshold 설정 및 실무 적용 시의 전략 수립에 중요한 기준으로 활용될 수 있다.

실제 건설 현장에 YOLO 모델을 적용할 경우, Confidence Threshold를 0.4~0.5 수준으로 설정하는 것이 바람직하며, 이를 통해 F1 Score와 Recall 간의 균형을 효과적으로 달성할 수 있다. 다만, 클래스별 탐지 성능에는 차이가 존재하므로, 성능이 낮게 나타난 클래스, 특히 'Forklift'와 같은 장비 기반 객



체의 경우에는 다양한 각도와 배경 조건을 반영한 데이터 보강(Data Augmentation)과 하드 샘플 마이닝(Hard Negative Mining) 등의 기법을 활용하여 학습 성능을 향상시킬 필요가 있다. 또한, 모델 평가 시에는 정밀도나 재현율과 같은 단일 지표에 의존하기보다는 F1-Confidence Curve, Precision-Recall Curve 등 다양한 시각화 기반 지표를 종합적으로 고려해야 하며, 이는 클래스별 탐지 전략 수립과 최적 threshold 설정을 위한 실질적인 근거로 활용될 수 있다.

제 4 절 YOLO 모델의 시각적 검증 결과 분석

3절에서 나온 결과를 토대로 YOLOv8n와 YOLOv11n의 클래스별 신뢰도가 큰 차이가 없음을 확인하였다. 이를 토대로 스마트시대에 맞춰 용량이 작아 학습 시간이 빠른 YOLO8n 모델을 건설 현장 적합 모델로 선정하여, 실제 검증 데이터셋에 대해 수행한 객체 탐지 결과를 시각적으로 분석하였다. 각 결과는 라벨 이미지(val_batchX_labels.jpg)와 예측 이미지(val_batchX_pred.jpg)로 구성되어 있으며, 이를 통해 Ground Truth와 예측값 간의 일치 정도를 비교하여 모델의 실질적인 검출 능력을 정성적으로 평가하였다.

제 1 항 Batch 0: Ground Truth 및 예측 결과 비교 (val_batch0_labels vs. val_batch0_pred)

Batch 0은 건설 현장에서의 작업자('People' 클래스) 탐지를 중심으로 구성된 데이터셋으로, YOLO 모델이 사람 객체를 실제 환경에서 얼마나 정확하게 인식하는지를 평가하기 위한 시각적 비교 분석 대상이다. 본 절에서는 Ground Truth 라벨과 예측 결과를 정량적으로 비교하여 모델의 기본적인 객체 검출 성능을 평가하였다.

첫째, Ground Truth 시각화(val_batch0_labels.jpg)에서는 각 프레임에 대해 작업자가 명확하게 바운딩 박스로 지정되어 있으며, 모든 이미지에 걸쳐 People 클

래스가 일관성 있게 라벨링되어 있다. 객체 위치와 크기, 프레임 간 균형 등에서 정확성과 일관성이 확보되어 있어, 고품질 학습 데이터임을 확인 할 수 있다

둘째, 예측 결과 이미지(val_batch0_pred.jpg)에서는 YOLO 모델이 모든 이미지에서 People 클래스를 정확히 탐지하였으며, 신뢰도(Confidence Score)는 대부분 0.8~0.9 사이로 높은 수준을 기록하였다. 바운딩 박스의 위치와 크기 또한 Ground Truth와 매우 유사하게 출력되어, 실제 객체의 공간 정보와 시각적 특징을 정확히 인식하고 있음을 시사한다.

특히, 모델은 복잡한 배경(천장 구조물, 자재 더미, 조명 반사 등) 속에서도 People 객체를 안정적으로 인식하고 있으며, 이는 실제 건설 현장 환경에서도 높은 실용성과 적용 가능성을 확보하고 있다는 점에서 의의가 크다.

예측된 Confidence Score가 0.8 이하로 낮아진 일부 프레임에서도 탐지 실패는 발생하지 않았으며, 이는 신뢰도 변화에 관계없이 일관된 탐지 역량이 유지됨을 보여준다.





그림 4-10 YOLOv8n 예측 결과와 정답 라벨 비교 시각화 (val_batch0)

제 2 항 Batch 1: Ground Truth 및 예측 결과 비교 (val_batch1_labels vs. val_batch1_pred)

Batch 1은 사다리 작업 중 단독 작업(Unsafe (Solo work)), 아웃트리거 미설치(Unsafe (No outrigger)), 사다리 존재(Ladder) 등 복합적인 위험 상황이 포함된 장면으로 구성되어 있으며, YOLO 모델이 다중 위험 요소를 동시에 인식할 수 있는지에 대한 시각적 성능 평가를 목적으로 한다.

첫째, Ground Truth 분석 (val_batch1_labels.jpg) : Ground Truth 이미지에는 총 세 가지 주요 클래스가 일관되게 라벨링되어 있다

Unsafe (Solo work)는 작업자가 보조자 없이 사다리를 사용하는 단독 작업 상황을 의미하며,

Ladder는 물리적인 작업 장비로서의 사다리 자체를 지칭하고,

Unsafe (No outrigger)는 아웃트리거가 설치되지 않아 구조적 안전성이 확보되지 않은 상태를 나타낸다.

해당 데이터셋은 다양한 실내 구조, 카메라 시점, 사다리 배치, 조도 조건 등을 포함하고 있어 실제 건설 현장을 반영한 학습 환경으로 평가되며, 클래스 간 상호 작용이 명확하게 드러나도록 구성되어 있다.


둘째, 예측 결과 분석 (val_batch1_pred.jpg): YOLO 모델은 대부분의 이미지에서 세 가지 객체를 정확히 탐지하였으며, Confidence Score 또한 전반적으로 0.8~1.0 수준을 유지하였다.

Unsafe (Solo work) 클래스는 일부에서 "People 0.9 work", "People 1.0 work" 등으로 표현되었으나, 탐지 정확도와 바운딩 박스 위치 모두 Ground Truth와 유사하였다.

Ladder 클래스는 거의 모든 프레임에서 정확히 탐지되었으며, 대부분 Confidence Score가 0.9로 안정적으로 유지되었다.

Unsafe (No outrigger) 역시 일관된 탐지가 이루어졌으며, 바운딩 박스 위치와 크기, 신뢰도 면에서 Ground Truth와의 차이가 거의 없었다.

단, 일부 프레임에서는 텍스트 겹침, 클래스명 일부 누락 등의 시각화 오류가



있었으나, 이는 예측 성능 자체보다는 시각화 처리상의 제한에 따른 결과로 판단된다.

결과적으로, YOLO 모델은 복합 위험 상황에 대해 높은 정확도와 일관된 신뢰도를 기반으로 탐지 성능을 발휘하고 있으며, 단순 객체 인식을 넘어 실제 위험 요소 판단에도 활용 가능한 수준의 모델로 평가된다. 특히, Ground Truth와 예측 결과 간의 일치도는 정량적 지표(mAP, Recall)뿐 아니라 정성적 비교를 통해서도 높은 수준임이 확인되었다.





그림 4-11 YOLOv8n 예측 결과와 정답 라벨 비교 시각화 (val_batch1)

제 3 항 Batch 2: Ground Truth 및 예측 결과 비교 (val_batch2_labels vs. val_batch2_pred)

Batch 2는 건설 현장에서의 단독 사다리 작업 및 안전장치 미비 상황을 반영한 이미지들을 대상으로 하며, YOLO 모델의 예측 성능을 시각적으로 검토하기 위한 데이터셋이다. Ground Truth와 예측 결과를 비교함으로써 모델의 복합적 위험 탐지 역량을 정성적으로 평가하였다.

첫째, Ground Truth(val_batch2_labels.jpg)에는 다음과 같은 세 가지 주요 클래스가 반복적으로 라벨링되어 있다:

Unsafe (Solo work)는 작업자가 보조자 없이 사다리를 사용하는 위험한 상황을 의미하며, Ladder는 물리적 작업 장비인 사다리 자체를 나타낸다. Unsafe (No outrigger)는 아웃트리거(지지대)가 설치되지 않은 사다리를 의미하는데, 이는 구조적 불안정 상태를 나타내는 핵심 위험 요소이다.

이 세 가지 라벨은 대부분의 이미지에서 동시에 나타나며, 다양한 작업 자세, 배경 환경, 조명 조건 등을 포함하고 있어 복합적이고 현실적인 학습 상황을 구성하고 있다. 특히 모든 객체가 정밀한 위치와 크기로 표시되어 있어 학습용 Ground Truth로서 매우 적절하다.

둘째, YOLO 모델의 예측 결과(val_batch2_pred.jpg)는 Ground Truth와 높은 일치율을 보이며, 모델이 위험 요소를 효과적으로 학습했음을 시각적으로 입증한다.

대부분의 객체가 높은 신뢰도(Confidence Score 0.8~0.9)로 정확하게 탐지되었으며, Unsafe (Solo work)는 예측 결과에서 "People 0.9 work" 등의 형태로 출력되지만, 실제로는 단독 작업 상황을 정확히 인식하고 있는 것으로 해석된다.

Ladder 및 Unsafe (No outrigger) 클래스 또한 바운딩 박스의 위치와 신뢰도가 Ground Truth와 거의 일치하며, 복합적 위험 탐지 성능이 우수함을 보여준다. 다만, 일부 클래스명에서 텍스트가 누락되거나 축약되어 표시되는 사례가 관찰되었는데, 이는 시각화 처리 과정에서 발생한 라벨 출력상의 문제로, 모델 성능 자체에는 영향을 미치지 않는다.



종합적으로, YOLO 모델은 위험 행동(단독 작업), 위험 상태(지지대 미설치), 그리고 장비 객체(사다리)를 동시에 탐지할 수 있는 다중 객체 및 위험 상황 인지 능력을 보유하고 있으며, 실무 적용 가능성을 시각적으로 확인할 수 있다.





그림 4-12 YOLOv8n 예측 결과와 정답 라벨 비교 시각화 (val_batch2)

제 4 항 소결

본 절에서는 YOLO 모델이 학습한 객체 인식 성능을 정성적으로 검증하기 위하여, 실제 검증용 이미지(val_batch0~2)를 대상으로 정답 라벨(Ground Truth)과 예측 결과(Prediction)를 시각적으로 비교 분석하였다. 분석 결과, 모델은 대부분의 클래스에서 높은 탐지 정확도와 안정적인 신뢰도(Confidence Score)를 보였으며, 특히 People, Ladder, Unsafe (Solo work) 등 주요 객체에 대해 0.8~0.9 이상의 신뢰도로 정확하게 탐지하는 성능을 나타냈다.

단일 객체(People)를 중심으로 구성된 Batch 0에서는 모델이 복잡한 배경 환경에서도 일관된 탐지 성능을 발휘하는 것으로 나타났으며, 이는 기본적인 객체 검출 역량이 우수함을 입증하였다. 복합 위험 요소가 포함된 Batch 1과 2에서는 Unsafe (No outrigger)와 Solo work 등 다중 위험 상황에 대한 동시 탐지 성능이 확인되었으며, 예측 결과는 Ground Truth와 높은 일치도를 나타냈다.

또한 일부 시각화에서는 클래스 명칭의 누락 또는 표기 오류가 있었으나, 이는 탐지 성능과는 무관한 시각적 표출의 문제로 해석된다.

종합적으로, YOLO 모델은 건설 현장에서 발생할 수 있는 주요 위험 상황에 대한 정확한 객체 인식 및 다중 위험 탐지 역량을 보유하고 있으며, 이는 실제 현장 적용 시 안전 모니터링 및 자동 경고 시스템 구축에 활용 가능한 수준의 신뢰성을 확보하고 있는 것으로 평가된다.

제 5 항 YOLOv8n 기반 객체 탐지 성능에 대한 종합 분석

본 장에서는 건설 현장 객체인식 모델로 선정된 YOLOv8n 모델을 활용한 객체 탐지 성능을 정량적 지표와 시각적 분석을 통해 종합적으로 평가하였다. 모델의 학습 손실 감소 추이, 정밀도(Precision), 재현율(Recall), mAP 등 성능 지표와 더불어, 클래스별 혼동 행렬 및 Confidence 기반의 F1-Precision-Recall Curve 해석, 예측 시각화 분석을 통하여 학습 효과성과 적용 가능성을 다각적으로 검토하였다.



첫째, 손실 함수 분석 결과(4.2절), train 및 val 데이터셋에서 box, cls, dfl 손실 항목 모두가 학습 에폭(epoch)이 진행됨에 따라 꾸준히 감소하는 경향을 보였으며, 이는 모델이 과적합 없이 안정적인 방향으로 수렴하고 있음을 시사한다.


둘째, 정밀도 및 재현율, mAP 평가 지표 분석(4.2절)에서 Precision은 0.928 수준까지, Recall은 0.936 수준까지 점진적으로 향상되었으며, mAP@0.5는 0.906, mAP@0.5:0.95는 0.809로 나타나 전체적인 탐지 성능이 매우 우수한 수준임을 입증하였다.

셋째, 에폭별 성능 지표 변화 분석(4.2절)에서는 학습이 진행될수록 Precision, Recall, mAP 등의 주요 성능 지표가 지속적으로 향상되었으며, box/cls/dfl loss는 전반적으로 감소하였다. 학습률 역시 안정적인 학습 수렴과정에 따라 점진적으로 낮아지는 경향을 보이며, 모델의 수렴 안정성과 학습 효율성이 확보되었음을 입증하였다.

넷째, 혼동 행렬 기반 클래스별 탐지 정확도 분석(4.2절)에서는 대부분의 주요 클래스(People, Ladder, Unsafe 계열 등)가 0.9 이상의 높은 정분류율을 나타냈으나, 일부 장비 기반 클래스(Forklift, Roller)는 낮은 정확도 또는 background로 오인되는 사례가 관찰되었다. 이는 시야 조건, 클래스 간 시각 유사성 등에 기인한 것으로 판단된다.

다섯째, Confidence 기반 성능 곡선 분석(4.3절)을 통해 Confidence 값이 0.4~0.5일 때 F1 Score와 Recall의 균형이 가장 우수하게 나타났으며, 클래스별 성능 차이를 고려한 threshold 설정의 필요성이 제기되었다. 특히 Forklift 클래스는 낮은 Precision과 Recall을 보여, 추가적인 데이터 보강과 학습 전략 보완이 요구된다.

여섯째, 객체 인식 결과의 정성적 분석(4.3절)에서는 검증용 이미지(val_batch0~2)를 대상으로 Ground Truth와 Prediction을 비교한 결과, People, Ladder, Unsafe (Solo work) 등의 객체를 높은 신뢰도로 탐지하였으며, 다중 위험 요소가 포함된 이미지에서도 복합 객체를 동시에 정확하게 인식하는 성능을 보여주었다. 특히, 복잡한 배경이나 구조물 속에서도 일관된 객체 탐지가 이루어졌고, 시각적 표기 오류를 제외한 전반적인 탐지 정확도는 Ground Truth와의 일치율 측면에서도 우수한 성능을 나타냈다.



종합적으로, YOLO 모델은 정량적 성능 지표와 정성적 예측 결과 양 측면에서 모두 우수한 객체 탐지 능력을 입증하였다. 모델은 건설 현장의 다양한 위험 요소에 대해 안정적인 탐지 성능을 보여주었으며, 정밀도와 재현율 간의 균형을 바탕으로 실시간 경고 시스템, 작업자 안전 모니터링 등의 실제 적용 가능성도 높은 것으로 판단된다. 특히 클래스별 특성과 학습 데이터 조건을 고려한 threshold 조정 및 학습 전략의 최적화는 향후 실환경 도입 시 중요한 과제로 남으며, 본 연구 결과는 그에 대한 실증적 근거로 활용될 수 있을 것이다.

제 6 항 종합 소결

본 연구에서는 YOLOv8n 모델을 기반으로 건설현장 내 다양한 객체 및 위험요소에 대한 탐지 성능을 정량적 지표와 시각적 비교를 통해 종합적으로 평가하였다. 분석 결과, 전체 클래스에 대한 mAP@0.5는 0.906으로 매우 높은 수준의 탐지 정확도를 나타냈으며, Precision은 0.928, Recall은 0.936으로 안정적인 성능을 보였다. 특히 주요 클래스인 People, Ladder, Unsafe (No Outrigger, Solo work) 항목에서는 mAP 및 Recall 값이 모두 0.9 이상으로 나타나, 실제 건설현장과 유사한 환경에서도 높은 탐지 신뢰도를 확보함을 입증하였다.

YOLO 모델의 시각적 검증 결과, 대부분의 프레임에서 Ground Truth와 예측 결과 간의 일치도가 높게 나타났으며, Confidence Score 0.8 이상을 기준으로 주요 객체가 정확히 탐지되었다. 일부 Forklift 클래스의 경우 낮은 탐지율(Precision 0.485)로 인해 탐지 성능이 저하되었으나, 이는 Roller로 오탐 또는 객체의 크기, 시각적 노이즈 등에 기인한 것으로 분석된다.

또한, 클래스별 학습 편차를 고려한 threshold 설정의 중요성이 확인되었으며, Confidence 값을 0.4~0.75 범위 내에서 설정할 경우 F1 Score와 Recall 간 균형 있는 탐지 성능이 확보되었다. 데이터 보강(Augmentation) 기법과 Hard Negative Mining 전략 적용 시, 복잡한 객체 배경 속에서도 모델의 학습 효율성 및 탐지 정밀도가 향상됨을 확인하였다.



결과적으로, YOLOv8n 모델은 다중 객체 및 위험 상황 인식을 동시에 수행할 수 있는 실질적인 응용 가능성이 높은 탐지 프레임워크로 평가되며, 실제 건설현장의 안전관리 및 위험예지 시스템에 효과적으로 적용할 수 있음을 시각적 및 정량적 검증을 통해 실증하였다.

제 5 장 결론 및 시사점

제 1 절 결론

본 연구는 건설현장에서 반복적으로 발생하는 주요 위험요소를 실시간으로 탐지하고 자동 인식할 수 있는 YOLO(You Only Look Once) 기반 객체 탐지 모델의 실효성을 검증하고자 하였다. 이를 위하여 AI-HUB의 실제 건설현장 이미지를 바탕으로 11개 클래스(People, Ladder, Scaffold, Unsafe 계열, Forklift 등)를 정의하고, 다중 모델(YOLOv5n, v6n, v8n, v10n, v11n) 중 YOLOv8n을 중심으로 탐지 성능을 정량적·정성적으로 평가하였다.

모델 학습은 에폭 진행에 따라 box, cls, dfl 손실 함수가 안정적으로 수렴하였고, Precision 및 Recall 값은 동반 상승하는 경향을 보여 과적합 없이 안정적인 학습이 이루어졌음을 확인하였다. 정량적 평가 지표에서 YOLOv8n 모델은 전체 클래스 기준 mAP@0.5 0.906, mAP@0.5:0.95는 0.809로 측정되어 매우 우수한 탐지 성능을 확보하였다.

Confusion Matrix 분석 결과, People, Ladder, Unsafe (Solo work, No outrigger) 클래스에서는 0.9 이상의 높은 정확도를 기록하였으며, 이는 실제 건설현장에서의 위험 탐지 기능으로의 적용 가능성을 실증한 것이다. 반면, Forklift 및 Roller 클래스는 background와의 시각적 유사성으로 인해 오분류되는 경향이 일부 나타났으며, 데이터 불균형과 객체 특성이 그 원인으로 분석되었다.

Confidence Score 기반 F1 Score 및 Precision-Recall Curve 분석 결과, Confidence Threshold를 0.4~0.5 범위로 설정할 경우 Precision과 Recall 간 균형이 최적으로 유지됨이 확인되었고, 이는 실무 환경에서 threshold 기준 수립의 실증적 근거로 활용 가능하다.

시각화 기반 성능 평가(val_batch02)에서는 YOLOv8n이 단일 객체뿐 아니라 다중 위험 상황이 복합된 이미지에서도 Ground Truth와의 높은 일치도를 보였고, 주요 클래스들은 Confidence Score 0.80.9 수준을 안정적으로 유지하

였다. 특히, 복잡한 배경, 조명 변화, 작업자 크기 차이 등 다양한 현장 조건에서도 높은 탐지 일관성과 정밀도를 나타내며, 실제 적용에 필요한 신뢰성과 실용성을 함께 확보한 것으로 판단된다.

결과적으로 YOLOv8n 모델은 건설현장의 주요 위험 상황에 대해 정밀도와 재현율이 균형 있게 확보된 상태에서 높은 수준의 객체 인식 성능을 실현하였으며, 실제 안전관리 시스템에 적용 가능한 수준의 탐지 기술로 평가된다.

제 2 절 시사점

본 연구는 다음과 같은 시사점을 제시한다.

첫째, YOLOv8n 모델은 빠른 처리 속도와 높은 정확도를 바탕으로 건설현장 내 실시간 객체 인식 및 자동 경고 시스템 구현에 적합한 핵심 기술로 적용될 수 있으며, 스마트 안전관리 플랫폼의 기반 요소로 활용될 수 있다.

둘째, Forklift, Roller 등 탐지 성능이 상대적으로 낮게 나타난 클래스에 대해 데이터 보강(Data Augmentation), 하드 샘플 마이닝(Hard Negative Mining) 등 전략적 학습 개선이 요구되며, 향후 위험 객체별 탐지 취약 요인 분석을 통해 위험관리 우선순위 수립이 가능하다.

셋째, Confidence 기반의 F1 Score 및 Precision-Recall 분석을 통해 실무 환경에서 클래스별 탐지 민감도에 따라 threshold 값을 유연하게 설정할 수 있는 기준을 제공함으로써, 적용 환경에 따른 실효성 있는 운영 기준 수립이 가능함을 시사한다.

넷째, 시각화 기반 검증은 예측 결과의 신뢰도를 사용자가 직관적으로 이해할 수 있도록 함으로써, 설명 가능한 인공지능(Explainable AI)의 구현 및 현장 관리자와의 협업 효율성 향상에 기여할 수 있다.



제 3 절 제언

향후 연구 및 실무 적용을 위해 다음과 같은 사항을 제언한다.

첫째, 탐지 정확도가 낮게 나타난 클래스(Forklift, Roller 등)는 시각적 유사성 또는 데이터 편향의 가능성이 있는 만큼, 클래스 정제 기준 마련 및 균형 데이터 확보가 우선되어야 한다.

둘째, Scaffold 및 Unsafe 계열 클래스 간 의미 중복 또는 시각적 중첩 가능성을 고려하여, 세부 클래스 통합 또는 하위 분류 재정립을 통해 모델 탐지 혼선 요소를 제거할 필요가 있다.

셋째, YOLO 외에도 Faster R-CNN, RetinaNet, SSD 등 다양한 객체 탐지 모델과의 비교 분석을 통해, 작업 환경에 적합한 탐지 알고리즘 선별 기준을 마련할 필요가 있다.

넷째, 실제 건설현장을 대상으로 한 실증 테스트와 사용자 중심의 UI/UX 연계, 실시간 알림 기능을 포함한 종합적 안전관리 시스템으로의 통합 연구가 지속적으로 이루어져야 할 것이다.

참고문헌

[국내문헌]

- [1] 윤영근, & 오태근(2022), 『YOLOv5 및 OpenPose를 이용한 건설현장 근로자 탐지 성능 향상에 대한 연구』, 문화기술의 융합, 8(5), 735-740
- [2] 이기석, 강성원, & 신윤석(2017), 『사례분석을 통한 객체검출 기술의 건설현장 적용 방안에 관한 연구』, 한국재난정보학회 논문집, 18(2), 269-279
- [3] 최승훈(2022), 『드론 영상 기반 YOLO 객체 탐지 기술을 이용한 보행자 추돌 경고 시스템』, 한서대학교 일반대학원 석사논문
- [4] 유지희(2023), 『무인단속카메라를 활용한 이륜차 후면 한글번호판 YOLO 성능비교 연구』, 단국대학교 정보융합기술창업대학원 석사논문
- [5] 김은정(2023), 『YOLO v8에서 GPR 이미지를 이용한 지하시설물 탐지 성능향상을 위한 Bounding box 보정방법 연구』, 단국대학교 정보융합기술창업대학원 석사논문
- [6] 이형도(2023), 『객체탐지 알고리즘을 이용한 건설현장 근로자 안전모 실시간 모니터링 기술 활성화 방안 연구』, 경기대학교 박사논문
- [7] 오유나(2024), 『YOLOv8 기반의 영상인식 모델을 활용한 재활용 자원 자동분류 엔진의 구현』, 대구가톨릭대학교 대학원 석사논문
- [8] 김희범(2024), 『이차전지 제조에서 YOLO 기반의 불량 검출 시스템 개발』, 순천향대학교 석사논문
- [9] 손솔비(2024), 『YOLO기반 화재, 연기 그리고 안개 객체 탐지』, 강릉원주대학교 석사논문
- [10] 임새론(2025), 『딥러닝 기반 YOLO를 활용한 하수관로 결함탐지 모델에 관한 연구』, 서울시립대학교 도시과학대학원 석사논문
- [11] 최은주(2025), 『YOLOv8을 사용한 원통형 배터리 외관 품질 결함 검출』, 충북대학교 일반대학원 석사논문
- [12] 오종호(2025), 『위험물 창고 알고리즘 개선 연구 : 증강과 YOLO 버전을 중심으로』, 중앙대학교 석사논문



[사이트]

- [1] https://www.moel.go.kr/news/enews/report/enewsView.do?new_seq=16057 고용노동부<최근 5년간 발생한 사다리에서 발생한 중대재해자 200건 넘어>
- [2] Evelyn Clarke(2024) <https://www.guru99.com/convnet-tensorflow-image-classification.html> CNN Image Classification in TensorFlow with Steps&Examples
- [3] <https://universe.roboflow.com/> Roboflow Universe
- [4] <https://www.kaggle.com/datasets> Kaggle 데이터셋
- [5] <https://colab.google/> 구글코랩(Google Clab)

[해외문헌]

- [1] Zhang, Y. (2021). Safety Management of Civil Engineering Construction Based on Artificial Intelligence and Machine Vision Technology. *Advances in Civil Engineering*.
- [2] Qian, Y., Liu, H., Mao, P., & Zheng, X. (2023). Evaluation of Safety Management of Smart Construction Sites from the Perspective of Resilience. *Buildings*.
- [3] Zhao, J., Xu, Y., Zhu, W., Liu, M., & Zhao, J. (2023). Real-Time Early Safety Warning for Personnel Intrusion Behavior on Construction Sites Using a CNN Model. *Buildings*.
- [4] Liu, L., Guo, Z., Liu, Z., Zhang, Y., Cai, R., Hu, X., Yang, R., & Wang, G. (2024). Multi-Task Intelligent Monitoring of Construction Safety Based on Computer Vision. *Buildings*.
- [5] Dobrucali, E., Demirkesen, S., Sadikoglu, E., Zhang, C., & Damci, A. (2022). Investigating the impact of emerging technologies on construction safety performance. *Engineering, Construction and Architectural Management*.
- [6] Meng, Q., Peng, Q., Li, Z., & Hu, X. (2022). Big Data Technology in



Construction Safety Management: Application Status, Trend and Challenge. Buildings.

[7] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, Ross Girshick.(2021). Masked Autoencoders Are Scalable Vision Learners

[8] Kushsairy Kadir, Mohd Khairi Kamaruddin, .Haidawati Nasir, Sairul I Safie,Zulkifli Abdul Kadir Bakti.(2014).A Comparative Study between LBP and Haar-like features for Face Detection Using OpenCV

[9] David G. Lowe.(2004). Distinctive Image Features from Scale-Invariant Keypoints

[10] Gedas Bertasius, Lorenzo Torresani, Stella X. Yu, Jianbo Shi (2017). Convolutional Random Walk Networks for Semantic Image Segmentation

[11] Hasan Ahmed Salman & Ali Kalakech (2024) Image Enhancement using Convolution Neural Networks

[12] Liu, L., Ouyang, W., Wang, X., Fieguth, P., Chen, J., Liu, X., & Pietikäinen, M.(2018). Deep Learning for Generic Object Detection: A Survey


[13] Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., & Houlsby, N. (2021). AN IMAGE IS WORTH 16X16 WORDS: TRANSFORMERS FOR IMAGE RECOGNITION AT SCALE

[14] Ross Girshick, Jeff Donahue, Trevor Darrell, Jitendra Malik(2014). Rich feature hierarchies for accurate object detection and semantic segmentation

[15] Shaoqing Ren, Kaiming He, Ross Girshick(2015), Jian Sun, Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks

[16] Joseph Redmon, Santosh Divvala, Ross Girshick, Ali Farhadi(2016). You Only Look Once: Unified, Real-Time Object Detection

[17] Chien-Yao Wang, I-Hau Yeh, Hong-Yuan Mark Liao(2024). YOLOv9:



Learning What You Want to Learn Using Programmable Gradient Information

[18] Ao Wang, Hui Chen, Lihao Liu(2024). YOLOv10: Real-Time End-to-End Object DetectionAo Wang, Hui Chen, Lihao Liu(2024). YOLOv10: Real-Time End-to-End Object Detection

[19] J Vaswani, Ashish, et al(2017). Attention is all you need.

[20] JYahui Liu, Enver Sangineto, Wei Bi, et al(2021). Efficient Training of Visual Transformers with Small Datasets

[21] Zhang, Z., Li, W., & Yang, J. (2021). ANALYSIS OF STOCHASTIC PROCESS TO MODEL SAFETY RISK IN CONSTRUCTION INDUSTRY. Journal of Civil Engineering and Management, 27, 87-99.

[22] Shen, J., Jiao, L., Zhang, C., & Peng, K. (2023). Monocular 3D object detection for construction scene analysis. Computer Aided Civil and Infrastructure Engineering, 39, 1370-1389.

[23] Jiao, X., Li, C., Zhang, X., Fan, J., Cai, Z., Zhou, Z., & Wang, Y. (2025). Detection Method for Safety Helmet Wearing on Construction Sites Based on UAV Images and YOLOv8. Buildings.

[24] Zhang, Y., Ye, M., Zhu, G., Liu, Y., Guo, P., & Yan, J. (2024). FFCA-YOLO for Small Object Detection in Remote Sensing Images. IEEE Transactions on Geoscience and Remote Sensing, 62, 1-15.

[25] Li, Y., Li, Q., Pan, J., Zhou, Y., Zhu, H., Wei, H., & Liu, C. (2024). SOD-YOLO: Small-Object-Detection Algorithm Based on Improved YOLOv8 for UAV Images. Remote. Sens., 16, 3057.


[26] Qi, S., Song, X., Shang, T., Hu, X., & Han, K. (2024). MSFE-YOLO: An Improved YOLOv8 Network for Object Detection on Drone View. IEEE Geoscience and Remote Sensing Letters, 21, 1-5.

[27] Zhou, Q., Liu, H., Qiu, Y., & Zheng, W. (2022). Object Detection for Construction Waste Based on an Improved YOLOv5 Model. Sustainability.




부록


[YOLOv5n 학습 결과값]




<그림 부록-1> YOLOv5n 최종 예측의 혼동 행렬




<그림 부록-2> YOLOv5n 예측 성능의 정규화 혼동 행렬




<그림 부록-3> YOLOv5n 신뢰도 변화에 따른 클래스별 F1 점수 변화 곡선




<그림 부록-4> YOLOv5n 학습 데이터의 클래스 분포 및 바운딩 박스 히트맵




<그림 부록-5> YOLOv5n 바운딩 박스 좌표 및 크기 간 분포 시각화



<그림 부록-6> YOLOv5n 정밀도-재현율(PR) 곡선



<그림 부록-7> YOLOv5n 클래스별 정밀도와 재현율 관계 분석 곡선




<그림 부록-8> YOLOv5n 재현율-신뢰도 곡선


<표 부록-1> YOLOv5n 결과 상세값

epoch	time	train/ box_los	train/ cls_loss	train/ dfl_loss	metrics/ precision(B)	metrics/ recall(B)	metrics/ mAP50(B)	metrics/ mAP50-95(B)	val/ box_loss	val/ cls_loss	val/ dfl_loss	lr/pg 0	lr/pg 1
1	4637.2 7	1.1451 5	1.9434 6	1.3091	0.8550 4	0.8650 9	0.8747 6	0.6781 1	0.8939 2	0.9656 2	1.1351 1	0.0002 38	0.0002 38
2	5002.2 8	0.9441 1	0.9161 2	1.1474 7	0.8925 2	0.8908 3	0.8841 1	0.7093 5	0.8326 6	0.8632 2	1.1107 2	0.0004 29	0.0004 29
3	5360.9 5	0.8932 9	0.7060 4	1.1100 8	0.8982 9	0.8973 8	0.8776 2	0.6919	0.8643 4	0.8679 2	1.1202 5	0.0005 72	0.0005 72
4	5719.8 7	0.8578 8	0.6148 1	1.087	0.9136 7	0.9232	0.9070 3	0.7508 8	0.7901	0.7767 4	1.0755 9	0.0005 02	0.0005 02
5	6089.8 9	0.8094 8	0.5525 3	1.0562 1	0.9255 8	0.9254 2	0.9250 7	0.7738 5	0.7714 9	0.7298 9	1.0680 1	0.0004 31	0.0004 31
6	6457.0 2	0.7747 1	0.5042 1	1.0316 7	0.9287 1	0.9236	0.9079 1	0.7694 7	0.7255 8	0.7092 1	1.0321 9	0.0003 61	0.0003 61
7	6820.4 8	0.7466	0.4739 8	1.0141	0.9284 2	0.9260 2	0.9066 4	0.7752	0.7215 3	0.6925 1	1.0247 8	0.0002 9	0.0002 9
8	7182.7 9	0.7205 5	0.4458 6	1.0015 8	0.9303 9	0.9314 1	0.9052 8	0.7842 3	0.6823 7	0.6617 3	0.9991 4	0.0002 19	0.0002 19
9	7552.2 3	0.6912 7	0.4192 4	0.9863 2	0.9308	0.9325 9	0.9072 9	0.7903 5	0.6662 5	0.6480 4	0.9894 9	0.0001 49	0.0001 49
10	7918.3 7	0.6679 7	0.3989 4	0.9727 2	0.9274 7	0.9350 1	0.9169 8	0.8061 7	0.6487 1	0.6374 8	0.9806 7	7.7826 e-05	7.7826 e-05


[YOLOv6n 학습 결과값]




<그림 부록-9> YOLOv6n 최종 예측의 혼동 행렬




<그림 부록-10> YOLOv6n 예측 성능의 정규화 혼동 행렬




<그림 부록-11> YOLOv6n 신뢰도 변화에 따른 클래스별 F1 점수 변화 곡선




<그림 부록-12> YOLOv6n 학습 데이터의 클래스 분포 및 바운딩 박스 히트맵




<그림 부록-13> YOLOv6n 바운딩 박스 좌표 및 크기 간 분포 시각화



<그림 부록-14> YOLOv6n 정밀도-신뢰도 곡선



<그림 부록-15> YOLOv6n 클래스별 정밀도와 재현율 관계 분석 곡선




<그림 부록-16> YOLOv6n 재현율-신뢰도 곡선


<표 부록-2> YOLOv6n 결과 상세값

epoch	time	train/ box_loss	train/ cls_loss	train/ dfl_loss	metrics/ precision(B)	metrics/ recall(B)	metrics/ mAP50(B)	metrics/ mAP50-95(B)	val/ box_loss	val/ cls_loss	val/ dfl_loss	lr/pg 0	lr/pg 1
1	5821.22	2.80846	3.98981	3.30843	0.40947	0.44608	0.37991	0.14775	2.2684	2.39041	2.57068	0.000238	0.000238
2	6161.34	1.82419	1.96491	2.09458	0.66694	0.63984	0.67677	0.39321	1.65289	1.63144	1.88961	0.000429	0.000429
3	6495.47	1.46246	1.35686	1.71435	0.80199	0.75707	0.78178	0.51352	1.33726	1.43781	1.56684	0.000572	0.000572
4	6831.18	1.26658	1.08714	1.52138	0.87591	0.821	0.85701	0.60554	1.15344	1.16065	1.42841	0.000502	0.000502
5	7165.95	1.14719	0.92516	1.40745	0.87741	0.88495	0.87752	0.65307	1.05505	0.94203	1.32547	0.000431	0.000431
6	7497.74	1.05293	0.81204	1.32653	0.90558	0.88023	0.88717	0.67887	0.96523	0.90921	1.26887	0.000361	0.000361
7	7830.93	0.98748	0.73538	1.27077	0.91605	0.9017	0.8955	0.6981	0.93388	0.84839	1.23723	0.00029	0.00029
8	8161.98	0.93467	0.67845	1.23026	0.92301	0.90884	0.89302	0.71677	0.87306	0.81323	1.19935	0.000219	0.000219
9	8494.01	0.88396	0.63223	1.19619	0.92459	0.91611	0.89372	0.72361	0.86823	0.79673	1.18991	0.000149	0.000149
10	8830.85	0.84561	0.59502	1.16436	0.92805	0.92037	0.89618	0.73766	0.83138	0.77578	1.16062	7.7826e-05	7.7826e-05


[YOLOv8n 학습 결과값]




<그림 부록-17> YOLOv8n 최종 예측의 혼동 행렬




<그림 부록-18> YOLOv8n 예측 성능의 정규화 혼동 행렬




<그림 부록-19> YOLOv8n 신뢰도 변화에 따른 클래스별 F1 점수 변화 곡선




<그림 부록-20> YOLOv8n 학습 데이터의 클래스 분포 및 바운딩 박스 히트맵




<그림 부록-21> YOLOv8n 바운딩 박스 좌표 및 크기 간 분포 시각화



<그림 부록-22> YOLOv8n 정밀도-신뢰도 곡선



<그림 부록-23> YOLOv8n 클래스별 정밀도와 재현율 관계 분석 곡선




<그림 부록-24> YOLOv8n 클래스별 정밀도와 재현율 관계 분석 곡선


<도표 부록-3> YOLOv8n 결과 상세값

epoch	time	train/ box_loss	train/ cls_loss	train/ dfl_loss	metrics/ precision(B)	metrics/ recall(B)	metrics/ mAP50(B)	metrics/ mAP50-95(B)	val/ box_loss	val/ cls_loss	val/ dfl_loss	lr/pg 0	lr/pg 1
1	367.291	0.83125	0.72265	1.10363	0.91643	0.90288	0.88563	0.73561	0.73722	0.80121	1.06397	0.000238	0.000238
2	720.042	0.85788	0.64373	1.11222	0.89919	0.90659	0.89065	0.72261	0.79316	0.79557	1.10052	0.000429	0.000429
3	1074.42	0.84798	0.58856	1.10093	0.91738	0.91592	0.90327	0.74406	0.76374	0.76184	1.05935	0.000572	0.000572
4	1428.05	0.81277	0.53859	1.07808	0.91542	0.92429	0.90508	0.76431	0.72077	0.74932	1.03313	0.000502	0.000502
5	1780.95	0.77155	0.49187	1.0515	0.92513	0.91978	0.92183	0.78925	0.71974	0.71152	1.03492	0.000431	0.000431
6	2134.53	0.74116	0.45255	1.02961	0.91972	0.92976	0.90519	0.78658	0.69692	0.67044	1.02	0.000361	0.000361
7	2480.83	0.71696	0.42962	1.01509	0.93141	0.93124	0.91266	0.80321	0.66939	0.65156	0.99992	0.00029	0.00029
8	2825.56	0.69006	0.40201	1.00142	0.92978	0.93473	0.90511	0.80108	0.63877	0.63476	0.97796	0.000219	0.000219
9	3167.77	0.66817	0.37938	0.98989	0.93018	0.9332	0.90523	0.80746	0.62669	0.62705	0.97387	0.000149	0.000149
10	3509.01	0.64552	0.35957	0.97466	0.92854	0.93628	0.90587	0.80905	0.61317	0.62472	0.96461	7.7826e-05	7.7826e-05


[YOLOv10n 학습 결과값]




<그림 부록-25> YOLOv10n 최종 예측의 혼동 행렬




<그림 부록-26> YOLOv10n 예측 성능의 정규화 혼동 행렬




<그림 부록-27> YOLOv10n 신뢰도 변화에 따른 클래스별 F1 점수 변화 곡선




<그림 부록-28> YOLOv10n 학습 데이터의 클래스 분포 및 바운딩 박스 히트맵




<그림 부록-29> YOLOv10n 바운딩 박스 좌표 및 크기 간 분포 시각화



<그림 부록-30> YOLOv10n 정밀도-신뢰도 곡선



<그림 부록-31> YOLOv10n 클래스별 정밀도와 재현율 관계 분석 곡선




<그림 부록-32> YOLOv10n 클래스별 정밀도와 재현율 관계 분석 곡선


<도표 부록-4> YOLOv10n 결과 상세값

epoch	time	train/ box_loss	train/ cls_loss	train/ dfl_loss	metrics/ precision(B)	metrics/ recall(B)	metrics/ mAP50(B)	metrics/ mAP50-95(B)	val/ box_loss	val/ cls_loss	val/ dfl_loss	lr/pg 0	lr/pg 1
1	3304.2 2	2.0843 8	6.5628 7	2.4204 9	0.662	0.6780 3	0.7033	0.5522	1.7752 1	2.3088 2	2.2486 8	0.0002 38	0.0002 38
2	3680.1 8	1.9214 3	2.4193 2	2.2599 6	0.7644 9	0.7983 1	0.8006 7	0.6387	1.7497 6	1.9139 6	2.1892 9	0.0004 29	0.0004 29
3	4052.0 1	1.8535 8	1.5707 8	2.2050 2	0.8221 9	0.8405 5	0.8535 2	0.6992 8	1.6383 3	1.6078 6	2.1204 2	0.0005 72	0.0005 72
4	4423.4 3	1.7656 8	1.2901 5	2.1542 3	0.8494 5	0.8619 8	0.8706 5	0.7238 8	1.5724 9	1.5634 3	2.0872	0.0005 02	0.0005 02
5	4794.1 5	1.6621 6	1.1270 6	2.0917 5	0.8643 4	0.8578 3	0.892	0.7580 7	1.4645 9	1.5653 4	2.0190 9	0.0004 31	0.0004 31
6	5159.5 5	1.5835 7	1.0008 7	2.0412 1	0.8760 1	0.8888 1	0.885	0.7577 5	1.4121 5	1.4331 2	1.9941 2	0.0003 61	0.0003 61
7	5525.2 2	1.5315 1	0.9253 6	2.0100 4	0.8895 6	0.8752 1	0.8883 7	0.7649 9	1.3893 4	1.4128 9	1.9789 9	0.0002 9	0.0002 9
8	5894.3 3	1.4654 1	0.8578 2	1.9827 4	0.8963 9	0.8907 9	0.9032 9	0.7939 2	1.3146	1.3747 7	1.9321	0.0002 19	0.0002 19
9	6260.5 7	1.4073 2	0.8033 6	1.9549 2	0.8986 8	0.9046 6	0.9053	0.7967 5	1.3127 9	1.3347	1.939	0.0001 49	0.0001 49
10	6629.7 2	1.3578 4	0.7590 9	1.9256 1	0.9078 9	0.9042 1	0.9096 1	0.8078 7	1.247	1.3175 5	1.8984 3	7.78E -05	7.78E -05


[YOLOv11n 학습 결과값]




<그림 부록-33> YOLOv11n 최종 예측의 혼동 행렬




<그림 부록-34> YOLOv11n 예측 성능의 정규화 혼동 행렬




<그림 부록-35> YOLOv11n 신뢰도 변화에 따른 클래스별 F1 점수 변화 곡선




<그림 부록-36> YOLOv11n 학습 데이터의 클래스 분포 및 바운딩 박스 히트맵




<그림 부록-37> YOLOv11n 바운딩 박스 좌표 및 크기 간 분포 시각화



<그림 부록-38> YOLOv11n 정밀도-신뢰도 곡선



<그림 부록-39> YOLOv11n 클래스별 정밀도와 재현율 관계 분석 곡선



<그림 부록-40> YOLOv11n 클래스별 정밀도와 재현율 관계 분석 곡선

<도표 부록-5> YOLOv11n 결과 상세값

epoch	time	train/ box_loss	train/ cls_loss	train/ dfl_loss	metrics/ precision(B)	metrics/ recall(B)	metrics/ mAP50(B)	metrics/ mAP50-95(B)	val/ box_loss	val/ cls_loss	val/ dfl_loss	lr/pg 0	lr/pg 1
1	3617.54	1.07539	1.93497	1.24613	0.88209	0.88292	0.88926	0.70754	0.80746	0.93829	1.08166	0.000238	0.000238
2	3986.95	0.9163	0.87141	1.11582	0.88929	0.8952	0.9106	0.72831	0.82624	0.84326	1.0921	0.000429	0.000429
3	4351	0.87518	0.66679	1.08458	0.90793	0.90598	0.90443	0.72769	0.81024	0.78364	1.07	0.000572	0.000572
4	4714.02	0.82831	0.57493	1.0594	0.91846	0.91446	0.89224	0.74791	0.733	0.76839	1.03058	0.000502	0.000502
5	5076.4	0.78797	0.51777	1.03312	0.92514	0.92424	0.90131	0.76541	0.71208	0.70313	1.00746	0.000431	0.000431
6	5438.06	0.75041	0.4743	1.01111	0.92918	0.92547	0.91837	0.78947	0.68174	0.65213	0.98787	0.000361	0.000361
7	5802.5	0.72448	0.44318	0.99474	0.92924	0.92944	0.90632	0.78333	0.67311	0.64703	0.97648	0.00029	0.00029
8	6168.81	0.69557	0.41389	0.98275	0.92973	0.93156	0.90781	0.7974	0.63411	0.63431	0.95251	0.000219	0.000219
9	6533	0.66978	0.38948	0.96902	0.92687	0.93302	0.91061	0.80856	0.61317	0.63016	0.94325	0.000149	0.000149
10	6900.81	0.6459	0.36754	0.95596	0.92797	0.93614	0.91434	0.81787	0.59517	0.61775	0.93169	7.78E-05	7.78E-05

Abstract

MS.Thesis


Application of YOLO-Based Object Detection for Real-Time Hazard Recognition in Construction Sites

Park Jong Hag

Dept. of Architecture & Safety Engineering
Graduate School of Engineering
Kyonggi University

The construction industry accounts for the highest proportion of fatal industrial accidents, with recurrent cases of falls, entrapments, and falling objects. These incidents are often caused by practical safety violations, such as failure to comply with safety protocols, inadequate use of personal protective equipment (PPE), and the presence of unmanaged hazards in the work environment. Traditional passive safety management approaches have proven limited in anticipating risks and providing real-time responses.

In response to these limitations, artificial intelligence (AI)-based object detection technologies, particularly the YOLO (You Only Look Once) algorithm, have gained significant attention in the field of construction safety due to their strengths in visual-based automatic detection and real-time response capabilities. This study applies and evaluates five YOLO models (YOLOv5, v6, v8, v10, v11) to analyze their object recognition performance in actual construction site scenarios. The evaluation was conducted using both quantitative metrics (mAP,



Precision, Recall, F1 Score) and qualitative analyses (Ground Truth visualization and Confusion Matrix).

The training dataset comprised 22,000 labeled images from the AI-HUB Construction Safety Dataset, focusing on key objects associated with fall-related accidents, such as People, Ladders, Scaffolds, and hazard conditions including Unsafe Solo Work and No Outrigger. Among the models, YOLOv8n achieved the highest performance with an mAP@0.5 of 0.906 and an F1 Score of 0.91. For major hazard classes, the detection accuracy exceeded 0.9, demonstrating the model's suitability for real-time warning system implementation. Moreover, a Confidence Threshold of 0.4 to 0.5 was found to optimize the balance between Precision and Recall, suggesting practical applicability in field conditions. Conversely, object classes such as Forklift and Roller showed higher false detection rates due to visual similarity with the background, indicating a need for enhanced dataset augmentation and refinement of class definitions.

In conclusion, this study empirically validates the potential of YOLO-based object detection models as core technologies for automated real-time hazard recognition systems in construction sites. The results offer a technical foundation for the development of future smart safety management systems.

Keywords: construction safety, deep learning, real-time object detection, artificial intelligence, YOLO

