



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

碩士學位 請求論文
指導教授 尹 弘 植

재난 위험 예측 및 탐지를 위한
AI 활용 가능성 연구
- YOLOv8와 LightGBM을 중심으로 -

成均館大學校 一般大學院

防災安全工學協同課程

沈 유 리

碩士學位請求論文

재난

A I 위험

활용 예측

가능성 및

연구 탐지를

위한

2025

沈유리

碩士學位 請求論文
指導教授 尹 弘 植

재난 위험 예측 및 탐지를 위한 AI 활용 가능성 연구

- YOLOv8와 LightGBM을 중심으로 -

A Study on the Application of AI for
Disaster Prediction and Detection

- Focusing on YOLOv8 and LightGBM -

成均館大學校 一般大學院

防災安全工學協同課程

沈 유 리

碩士學位 請求論文

指導教授 尹 弘 植

재난 위험 예측 및 탐지를 위한 AI 활용 가능성 연구

- YOLOv8와 LightGBM을 중심으로 -

A Study on the Application of AI for
Disaster Prediction and Detection

- Focusing on YOLOv8 and LightGBM -

이 論文을 工學 碩士學位請求論文으로 提出합니다.

2025 年 4 月 日

成均館大學校 一般大學院

防災安全工學協同課程

沈 유 리

이 論文을 沈 유 리의 工學
碩士學位 論文으로 認定함.

2025 年 6 月 日

審査委員長

審査委員

審査委員

목차

제1장 서론	1
1.1 연구 배경 및 문제의식	1
1.2 연구 목적 및 의의	2
1.3 연구 방법	3
제2장 이론적 검토	5
2.1 재난관리의 체계와 한계	5
2.1.1 재난관리의 체계	5
2.1.2 한계 및 보완 필요성	6
2.2 AI와 재난관리	8
2.2.1 AI 발전 현황	8
2.2.2 재난관리 분야 AI 활용 현황	10
2.3 객체 탐지 및 데이터 예측 AI 기술 동향	12
2.3.1 객체 탐지 AI 기술	12
2.3.2 데이터 예측 AI 기술	13
제3장 객체 탐지 AI 기술(YOLOv8) 활용 연구	14
3.1 YOLOv8 개요	14
3.2 실험 설계	15
3.2.1 실험 설명	15
3.2.2 환경 설정	17
3.2.3 데이터 구성	18

3.3 Pre-trained 상태 실험	19
3.4 Fine-tuning 진행 실험	21
3.4.1 재난 상황(산사태) 소규모 Fine-tuning	21
3.4.2 재난 상황(산사태) 데이터 증가 Fine-tuning	27
3.4.3 재난 징후(균열) Fine-tuning	34
3.4.4 멀티클래스(산사태+균열) Fine-tuning	39
3.5 종합 검토 및 시사점	46
제4장 데이터 예측 AI 기술(LightGBM) 활용 연구	48
4.1 LightGBM 개요	48
4.2 실험 설계	49
4.2.1 실험 설명	49
4.2.2 환경 설정	51
4.2.3 데이터 구성	51
4.3 데이터 기반 위험 예측 실험	52
4.4 통합 분석 예측 모델(meta-GBM) 구상	56
4.4.1 배경 및 개념	56
4.4.2 작동 방식 및 효용성	57
4.5 종합 검토 및 시사점	58
제5장 결론	60
참고문헌	63
ABSTRACT	66

표목차

표 1. 연구절차 및 내용	4
표 3-1. 실험 별 주요 내용	16
표 3-2. YOLOv8 실험 수행 시 활용된 시스템 환경	17
표 3-3. 산사태 파인튜닝(99장) 성능지표	24
표 3-4. 산사태 파인튜닝(99장→1,623장) 성능지표 비교	29
표 3-5. 균열 파인튜닝(930장) 성능지표(산사태와 비교)	36
표 3-6. 멀티클래스(산사태+균열) 파인튜닝 성능지표	42
표 4-1. LightGBM 실험 수행 시 활용된 시스템 환경	51
표 4-2. LightGBM 전범위 대상 실험결과 성능지표	53
표 4-3. LightGBM 기준값 근처 대상 실험결과 성능지표	55

그림 목차

그림 3-1. 라벨링된 산사태, 균열 이미지 데이터(예시)	18
그림 3-2. pre-trained상태 산사태 탐지 실패(예시)	19
그림 3-3. pre-trained상태 균열 탐지 실패(예시)	20
그림 3-4. 산사태 파인튜닝(99장) 학습 손실함수	22
그림 3-5. 산사태 파인튜닝(99장) 전체 손실함수	23
그림 3-6. 파인튜닝(99장) 산사태 탐지 성공(예시)	25
그림 3-7. 파인튜닝(99장) 산사태 탐지 실패(예시)	26
그림 3-8. 산사태 파인튜닝(1,623장) 전체 손실함수	28
그림 3-9. 산사태 학습 데이터 증가에 따른 탐지 확신도 향상(예시)	31
그림 3-10. 산사태 학습 데이터 증가에 따른 탐지 정교화(예시)	31
그림 3-11. 산사태 학습 데이터 증가에 따른 미탐·오탐 결과 수정(예시)	32
그림 3-12. 균열 파인튜닝(930장) 학습 손실함수	34
그림 3-13. 균열 파인튜닝(930장) 전체 손실함수	35
그림 3-14. 파인튜닝(930장) 균열 탐지 성공(예시)	37
그림 3-15. 파인튜닝(930장) 균열 불완전한 탐지(예시)	38
그림 3-16. 파인튜닝(930장) 균열 오탐·미탐(예시)	38
그림 3-17. 산사태·균열 멀티클래스 파인튜닝 학습 손실함수	40
그림 3-18. 산사태·균열 멀티클래스 파인튜닝 전체 손실함수	41
그림 3-19. 멀티클래스(산사태+균열) 파인튜닝 산사태 탐지 성능 저하(예시) ·	43
그림 3-20. 멀티클래스(산사태+균열) 파인튜닝 균열 탐지 성능 저하(예시) ·	44
그림 3-21. 멀티클래스(산사태+균열) 파인튜닝 균열 탐지 성능 개선(예시) ·	45
그림 4-1. LightGBM Feature Importance	53
그림 4-2. LightGBM 전범위 실험 중 정답과 다른 예측 데이터	54

논문 요약

재난 위험 예측 및 탐지를 위한 AI 활용 가능성 연구

본 연구는 불확실성과 복잡성이 심화되는 재난 환경에 효과적으로 대응하기 위해 현재 우리나라 재난관리 체계 개선의 필요성을 검토하고, 그 대안으로 AI 기술을 제시하여 그 효용성과 정책적 활용 가능성을 도출하고자 하였다. 특히, 재난 발생 이전 단계에서의 예측 및 선제조치 역량 강화에 초점을 맞추어 이미지 기반 객체 탐지 모델인 YOLOv8과 데이터 기반 예측 모델인 LightGBM을 중심으로 실험적 연구를 수행하였다.

이미지 기반 재난 탐지 실험에서 YOLOv8의 사전학습(pre-trained) 모델은 재난 이미지를 탐지하지 못하고, 재난 이미지를 활용한 파인튜닝(fine-tuning) 과정을 통해 탐지 성능이 생성됨을 확인하였다. 또한, 파인튜닝 데이터 양을 적정 수준으로 증가시키면 탐지 정확도와 정밀도 등 모델의 전반적인 성능이 향상된다는 결과를 입증하였다. 다음으로, 산사태보다 미세하여 탐지 난이도가 높은 재난 징후(균열)에 대한 파인튜닝도 진행하였는데, 성능지표가 산사태 파인튜닝 시와 비슷하여 모델이 다양한 재난에 대한 탐지 역량을 갖출 수 있다는 것을 확인했다. 다만, 실제 사진으로 진행한 테스트에서 탐지 성능이 산사태 파인튜닝 시보다 저하된 점을 생각해 보면, 시각적으로 불분명하고 난해한 재난 징후 이미지 학습 시에는 학습 데이터 품질에 보다 주의를 기울여 구성해야 할 것으로 판단된다. 한편, 모델이 다중 재난 유형을 동시에 탐지할 수 있는지 알아보기 위하여 재난 상황(산사태)과 재난 징후(균

열)를 동시에 학습시키는 멀티클래스 파인튜닝도 진행하였는데, 단일클래스 모델 대비 전반적인 성능 저하 현상이 나타났으며, 특히 미세한 이미지인 균열 사진에서 성능 저하가 더욱 두드러졌다.

데이터 기반 재난 위험 예측 실험에서는 LightGBM 모델을 활용하여 고도, 경사도, 강수량 등 비시각적 데이터만으로 재난 위험도를 예측하는 모델 설계가 가능함을 확인하였다. 특히, AI 모델은 기존 규칙 기반 도구처럼 기준값에서 인위적으로 예측값을 단절시키지 않고, 기준값 부근의 모호함을 데이터 학습을 통해 스스로 익혀 유연하게 반응하기 때문에 이러한 특징을 활용하여 향후 정교하게 설계한 양질의 학습 데이터를 구축한다면, 현실적인 재난 예측이 가능한 모델을 설계할 수 있음을 제안하였다. 마지막으로, 시각 정보를 활용한 예측과 비시각 정보를 활용한 예측을 통합 분석하여 재난 위험을 종합적으로 판단하는 상위 모델인 meta-GBM을 구상하여 단일 예측 모델의 한계를 보완하고 보다 정확하며 신뢰도 높은 통합 위험 판단 시스템 구축의 가능성을 제시하였다.

본 연구는 재난관리의 패러다임을 사후 대응에서 사전 예방 중심으로 전환시킬 해법으로 AI 기술을 제시하였으며, 기존의 고비용·고성능 기술 연구와 차별화된 경량형 AI 기술의 활용 가능성을 검증함으로써 제한된 자원과 환경 하에서도 AI 기술을 도입할 수 있는 가능성을 제시하였다. 또한 기술 검증과 더불어 정책적 고려사항을 함께 제시하여 학계의 연구가 정책 현장에 적용되도록 하는 실용적 연구 방식에 초점을 맞췄으며, 단일 기술의 성능 평가를 넘어 향후 재난관리 시스템 전반에 활용 가능한 AI 기술들의 도입 필요성을 강조하고자 하였다. 본 연구가 AI 기반 재난관리 체계의 발전에 기여하여 보다 안전한 대한민국을 건설해 나가는 데 이바지할 수 있기를 기대한다.

주제어 : 재난관리, 인공지능(AI), 재난위험예측, YOLOv8, LightGBM

제1장 서론

1.1 연구 배경 및 문제의식

최근 기상 환경의 변화와 다양한 위험 요소의 등장으로 전 세계적으로 재난 예측의 불확실성이 심화되고 재난관리의 복잡성과 난이도도 높아지고 있다. 이제 재난은 더 이상 과거처럼 예상된 시나리오나 반복적인 패턴만으로 대비할 수 있는 단순한 현상이 아니며, 다양한 변수와 예측 불가능한 상황에 대한 복합적인 고려가 필요한 영역이 되었다. 우리나라의 재난관리를 책임지고 있는 정부는 이 같은 재난 환경의 변화에 대처하기 위해 현장 점검 확대, 예·경보 강화, 정보통신기술 도입 등 국가 재난관리 역량을 강화하기 위한 다양한 노력을 기울이고 있다. 재난관리 예산과 인력의 확대 등 자원적 기반 강화도 함께 이루어지고 있음은 물론이다. 그러나 현 체계는 여전히 사람의 경험과 직관, 전통 장비와 인력 투입 위주의 접근에 의존하고 있어 급변하는 현대 재난 환경에서 객관성, 정확성, 신속성, 효율성 측면에서 한계에 다다른 듯하다.

이러한 공감대 속에서 인공지능(Artificial Intelligence, AI) 기술이 돌파구가 되어 줄 대안으로 주목받고 있다. AI는 대규모 데이터를 실시간으로 분석하고 그 결과를 바탕으로 복잡한 위험 패턴을 빠르게 식별해 낼 수 있기 때문에 사람이 신속하고 정확하게 위험을 예측하고 대처하여 피해를 최소화할 수 있도록 도와줄 수 있는 도구이다. 이에 본 연구는 현 재난관리 체제의 한계를 보완할 새로운 재난관리 도구로서 AI 기술을 제시하고, 그 활용 방안을 모색하고자 한다.

1.2 연구 목적 및 의의

본 연구에서는 기존 연구와 달리 경량형 모델을 선택하여 재난분야에서도 적은 노력과 비용으로 신속하게 정책화할 수 있는 도구가 있는지 확인하기 위한 실용적인 실험을 설계했다. 재난은 국민의 생명과 관련이 깊어 기술 도입의 지연이 곧바로 인명 피해로 이어질 수도 있는 만큼 현장 투입의 신속성과 시의 적절성이 매우 중요한 분야이다. 그런데 지금까지의 재난분야 기술 연구는 기업이나 연구팀 단위로 진행되어 많은 비용과 오랜 시간이 필요한 고도화된 기술 위주였다. 물론, 비용과 시간을 투입해 만든 기술은 그만큼 성능이 뛰어날 수 있다. 그러나, 개발 과정 자체도 오래 걸리고, 비용이 많이 들어가는 만큼 정책화 과정에서도 법적·제도적 장벽에 부딪쳐 도입에 지연이 발생할 가능성이 높다. 이렇게 최종 승인되면 지연 때문에 적시성이 사라져 개발의 실효성이 저하될 수도 있다. 따라서 재난분야에서 기술 선택 시에는 정밀성이나 고도화도 중요하지만, 도입의 용이성, 현장 적용 시 효율성도 중시해야 한다고 판단된다. 그렇다고 하더라도 정확성이나 신뢰성을 포기할 수는 없는 일이다. 따라서 본 연구에서는 ‘경량형이되, 효율성이 높은 기술’을 찾아 검증함으로써 도입 부담은 낮고 정책 효과는 높은 도구를 제시하고자 했다.

앞서 언급한 바와 같이 본 연구에서는 경량형 AI 기술이 재난 위험 예측 및 탐지에 어떻게 활용될 수 있는지 실험적으로 검증하고 정책화 가능성을 확인하고자 했다. 이를 위하여 우선, 우리나라 재난관리의 체계와 작동 방식을 검토하고, 현 체계가 지닌 한계점을 진단해 보완 방안을 모색하였다. 특히, 재난 발생 이전의 선제 조치 단계에서 정책적·기술적 취약성이 드러난다는 점에 주목하여 이를 보완할 방안으로서 AI 기술을 제시하고, 그 중에서도 도입 효과성이 높은 기술 분야로 범위를 좁혀 나가며 이론적 검토를 진행하였다. 그 다음으로, 실험을 통해 재난 위험 예

측·탐지 분야에 AI 기술 도입의 실질적 가능성을 검증하고, 그 정책적 활용 방안을 제시하고자 하였다. 구체적으로는 타 분야에서 이미 상용화되어 안정성이 검증된 경량형 AI 기술인 YOLOv8과 LightGBM를 선택하여 실험을 통해 성능을 평가하고, 그 결과를 바탕으로 경량형 AI기술을 재난관리 정책 현장에 적용할 때의 유용성과 한계점, 보완 사항 등을 제시하였다.

본 연구는 단순히 한 가지 기술의 우수성을 검증하는 데에서 그치지 않고, 국가 재난관리 방식의 개선을 위한 실용적·전략적 방안을 모색하고자 하는 시도이다. 이를 통해 후속 연구의 활성화를 촉진하고, 미래 재난관리 정책 추진 전략 개선 논의의 출발점을 마련하고자 한다.

1.3 연구 방법

본 연구에서는 AI 기술이 재난관리의 전 과정 중 특히 예측과 예방, 조기 대응 등 재난 발생 이전 단계에 실질적으로 기여할 수 있는지 평가하기 위해 이론적 검토와 함께 실험에 기반한 기술 검증을 수행하였다.

2장에서는 이론적 검토를 통해 우리나라 재난관리 체계의 한계와 그 보완 방안으로서 AI 기술의 도입 필요성을 제시한다. 이어서 AI 기술의 동향을 정리하고, 특히 객체 탐지 기술과 데이터 예측 기술에 주목하여 실험에 활용하기 위한 기본 정보를 파악한다. 3장과 4장에서는 실험을 통해 경량형 AI 기술의 재난 예측·탐지 분야 적용 가능성을 평가한다. 실험 대상 재난 유형으로는 산사태(재난 상황)와 벽균열(재난 징후)을 선정하였는데, 이들은 시각적 특성이 뚜렷하여 객체 탐지 실험이 가능하고 기상·지형 등 수치 데이터 기반 실험도 가능한 유형의 재난이므로 본 연구의 실험 대상에 적합하다. 3장의 실험에서는 YOLOv8모델을 활용해 사전학습

(pre-trained)된 모델과 파인튜닝(fine-tuning)을 거친 모델의 재난 이미지(산사태, 균열)에 대한 탐지 성능을 비교 검증한다. 다음으로 4장에서는 LightGBM 모델을 활용해 기상·지형 등 비시각적 정보만으로 재난 위험 예측이 가능한지 실험한다. 마지막으로, YOLOv8에서 탐지한 위험도와 LightGBM에서 산정한 위험 예측 결과를 결합한 데이터를 종합적으로 판단하는 meta-GBM 구조를 설계하여 시각·비시각 정보 통합 분석으로 예측 성능을 향상시킬 수 있는 가능성을 제시한다. 각 장의 실험 후에는 종합 검토를 통해 실험 결과의 정책화를 위한 시사점을 제시한다.

<표 1> 연구 절차 및 내용

구분		연구 내용
1장	서론	연구 목적 및 방향 설정
2장	이론적 배경	- 국가 재난관리 체계 분석 및 한계 진단 - AI 기술 검토
3장	객체 탐지 실험	YOLOv8 활용 재난 이미지 탐지 실험 - 사전학습 모델 테스트 - 파인튜닝한 모델 성능 실험
4장	데이터 예측 및 통합 예측 실험	- LightGBM 활용 데이터 예측 실험 - meta-GBM 시각·비시각 정보 통합 분석 예측 모델 구상
5장	결론	-연구 내용 정리

제2장 이론적 검토

2.1 재난관리의 체계와 한계

2.1.1 재난관리의 체계

「재난 및 안전관리 기본법」에 따르면, 재난은 국민의 생명·신체·재산과 국가에 피해를 주거나 줄 수 있는 것으로서 자연재난과 사회재난으로 분류¹⁾한다. 재난은 사회 안전망을 위협하고 국민들의 일상 및 국가 기능의 지속을 어렵게 만든다는 점에서 체계적이고 통합적인 관리가 필요한 중요 분야이다.

재난관리는 재난 발생에 따르는 피해를 최소화하고 사회의 신속한 회복을 달성하기 위해 수행하는 모든 활동을 의미하며, 예방(Prevention), 대비(Preparedness), 대응(Response), 복구(Recovery)의 네 단계로 구분한다. 예방은 재난 발생을 차단하거나 재난으로 인한 피해를 최소화하기 위한 선제 조치를 이행하는 단계로, 대표적으로 시설물 점검과 보수·보강, 위험지역 지정 등 사전 조치들이 이에 해당한다. 대비는 효과적인 대응을 준비하는 단계로 경보체계 구축, 인력·장비 확보, 매뉴얼 작성, 훈련 등이 포함된다. 대응은 재난 발생 직후 인명 구조, 긴급 대피, 응급 복구 등 피해 확산 방지를 위한 현장 중심의 조치 및 통신·전력 등 핵심 인프라의 긴급 복구 조치가 포함된다. 복구 단계는 재난 상황 종료 후 피해 지역과 시스템을 정상화하는 단계로, 피해 조사, 인프라 복구, 심리상담 등 사회 기능의 전면적 회복과 재발 방지 대책이 병행된다.

1) 「재난 및 안전관리 기본법」 제3조 제1호

2.1.2 한계 및 보완 필요성

가. 재난 발생 이전 단계의 선제적 관리 강화 필요

재난관리의 각 단계 중 예방은 단순히 위험 요소가 재난으로 이어지지 않기를 바라기만 하는 정적인 단계가 아니라, 위험 요소의 적극적 발견, 재난 발생 가능성의 정확한 예측, 신속한 사전경보 발령, 위험 지역 통제 등 정확한 판단과 신속한 조치를 포함하는 역동적인 단계이다. 물론 이 단계는 그 범위가 막연하여 준비 시기와 조치 사항의 결정이 어렵고 상당한 비용이 소요될 수 있다. 그러나 재난관리의 각 단계가 긴밀하게 연계되어 순차적으로 진행되고, 한 단계의 실패가 다음 체계의 취약성으로 연결될 수 있다는 점을 고려해 본다면, 재난관리의 시작점인 예방 단계는 매우 중요하다. 이 단계에서 정확한 설계로 조치에 성공할 경우, 재난 발생이나 재난으로 인한 피해 발생이 사라질 수도 있기 때문에 재난 피해를 근본적으로 줄일 수 있는 단계라고 판단된다. 따라서 예방 단계에서 정확한 예측과 꼭 필요한 선제 조치로 전체 피해 규모를 줄이고, 다음 단계인 대응의 난이도를 낮출 수 있도록 선제적 관리 역량 강화를 위한 노력이 무엇보다 절실하다.

나. 국민이 제외된 국가 재난관리의 한계

현재 대한민국의 재난관리는 「재난 및 안전관리 기본법」을 근거로 정부가 재난관리의 모든 계획과 실행을 책임지는 체계로 설계되어 있다. 중앙정부는 평시에 행정안전부를 중심으로 각 부처가 재난 유형 별 소관 업무를 수행하고, 재난 발생 시에는 범정부적 통합 관리 체계를 가동한다. 지방정부는 지역 특성에 맞는 예방조치, 대응계획 수립, 응급 대응 등을 최일선의 현장에서 담당하고, 중앙과의 연계를

통해 국가 전체의 통합적 대응 체계를 유지한다. 이러한 체계는 국가 위기관리의 통합성과 일관성 유지에는 장점이 있으나, 민간 및 지역 사회의 책임있는 참여를 제한한다는 한계를 내포한다. 그러나 안전 사각지대 해소나 현장 정보 수집, 위험 신호 조기 인지를 통한 재난 예방을 위해서는 현장 거주민 및 민간의 역할이 매우 중요하다. 우리 집 근처의 불안정한 담벼락 상태의 변화는 우리 동네 주민이 가장 먼저 가장 확실하게 알 수 있다. 그리고 누구도 위험한 환경에서 살아가고 싶지 않다. 이 때문에 재난안전관리 분야에서 민간의 참여를 독려하는 것은 다른 정책 분야와 다르게 매우 필요하고 효과성이 높으며, 특별한 인센티브 없이도 참여를 쉽게 이끌어 낼 수 있다. 따라서 국가만 책임지는 재난관리가 아니라 국민의 책임 의식을 고취시키고 재난관리에 국민의 참여가 용이하도록 인프라를 구축하여 전 국민이 재난 예방을 위해 노력하도록 하는 것은 장기적으로 국가 재난관리 정책이 나아가야 할 방향이라고 생각된다.

다. 전통 도구와 인력 투입 중심 대처의 한계

변화하는 재난 환경과 복잡해지는 위험에 효과적으로 대응하기 위해 기존의 도구와 인력을 대체하거나 보완할 새로운 도구의 도입 필요성도 절실하다. 그간 정부는 재난관리의 실효성을 높이기 위해 다양한 노력을 기울여 왔으나, 여전히 현행 재난관리 시스템은 첨단 기술의 도입보다는 전통적 장비 사용, 수동적인 정보 수집과 분석, 그리고 대규모 인력 투입에 의존하고 있다. 재난 위험 예측과 탐지는 대부분 일부 데이터에 불과한 정보 수집과 담당 관료의 주관적 관찰 및 판단에 의존한다. 대응 역시 공무원, 소방·경찰 등 공공 인력이 현장에 직접 투입되는 방식으로 이루어지고 있어 더 나은 성과를 내려면 인력을 더 많이 투입하는 것 말고 달리 방법이 없는 실정이다. 이러한 전통적 방식은 일정 수준의 효과는 보장하지만, 변화하는 재난 양상에 신속하고 정밀하게 대응하는 데에 한계가 있으며, 특히, 예측의 정

확성, 실시간 위험 감지, 효율적 인적·물적 자원 운용 측면에서 한계가 크다.

이러한 배경에서 새로운 기술의 도입 필요성이 더욱 강조되고 있다. 특히, 최근 급속도로 발전하고 있는 AI 기술은 재난관리에 필요한 대규모의 복잡한 데이터를 객관적으로 수집·분석·적용할 수 있다는 점에서 기존 시스템이 가진 방대한 통계 분석과 정확한 결론 도출 어려움의 한계를 보완할 도구이다. 또한 실시간으로 신뢰성있는 결과값을 도출할 수 있다는 점은 사람이 신속하게 결정을 내릴 수 있도록 도와주므로 시기를 놓쳐서 피해가 확대될 가능성을 낮춰준다. 아울러 재난 대응 현장에서 하늘을 날거나 붕괴 구조물 더미에 갇힌 피해자를 탐지해 내는 등 사람을 뛰어넘는 기술로 인명구조에 기여할 수 있다는 점에서 AI는 기존의 인력 투입에만 의존하던 관리 방식의 한계를 극복할 수 있는 수단이 될 수 있다고 판단된다.

요약하면, 재난관리 환경이 빠르게 변화하는 현재, 향후 재난관리 체계는 재난 발생 이전 단계의 선제적 관리 강화, 국가와 국민이 함께하는 거버넌스형 재난관리, 그리고 AI 기술 등 새로운 도구의 적극적 도입을 통해 재난 예방 효과를 극대화하고 피해를 최소화하는 방향으로 발전해야 한다. 다음 절에서는 AI 기술의 개념과 재난관리 분야에서의 활용 현황을 살펴보고자 한다.

2.2 AI와 재난관리

2.2.1 AI 발전 현황

인공지능(Artificial Intelligence, AI)은 인간의 인지 능력을 모방해 데이터 기반으로 학습, 추론, 예측 등을 수행하는 기술이다. AI의 개발은 데이터(Data), 알고리즘(Algorithm), 연산 자원(Computational Resources)의 세 축을 중심으로 진행되어 왔으며, 데이터는 AI 학습의 기반, 알고리즘은 문제 해결 방식(예: 머신러닝, 딥러닝

등), 연산 자원은 이를 실현하는 인프라(GPU, 클라우드 등)의 역할을 한다.

AI는 1950년대 컴퓨터 과학의 태동기와 함께 개념적으로 등장했으며, 다트머스 회의를 통해 처음 학문적으로 정의되었다. 이후 1960~70년대 전문가 시스템과 논리 규칙 기반 추론에서 출발하여 1980년대부터 업계에 제한적으로 도입되기 시작했다. 2000년대 들어 인터넷의 확산으로 데이터가 증가하고 GPU, 병렬연산 등 인프라가 발전하면서 머신러닝(machine learning) 알고리즘이 본격적으로 부상하며 기술적 전환이 시작되었다. 인공신경망(ANN), Random Forest, Gradient Boosting 등 통계 기반 학습 알고리즘의 도입으로 이미지, 음성, 텍스트 등 비정형 데이터의 분석이 가능해졌으며, 현재 머신러닝은 지도학습, 비지도학습, 강화학습 등으로 발전하여 분류, 회귀, 최적화 등 다양한 실용적 문제 해결에 적용되고 있다. 2010년대는 딥러닝 알고리즘 중심의 AI 대전환기로, 기술적 혁신과 생태계 확장이 동시에 일어난 시기였다. 2012년 CNN(Convolutional Neural Network) 기반 이미지 인식 기술이 주류로 부상했고, VGGNet, ResNet 등 고도화된 모델들이 등장했다. 음성 인식과 자연어 처리 분야에서는 RNN, LSTM, 그리고 후반기에는 Transformer 구조가 등장하며 성능의 비약적 향상을 이끌었다. 이러한 기술 발전은 대규모 데이터 및 GPU, TensorFlow, PyTorch 등 오픈소스 프레임 워크의 확산과 맞물리며 AI의 적용 영역을 산업 전반으로 확대시켰다.

2020년대에는 Transformer 구조를 기반으로 한 초거대 언어모델(GPT, BERT 등)의 실용화가 가속화되며 범용 언어의 처리와 생성 역량을 갖춘 생성형 AI 시대로 진입했다. 그리고 최근에는 이미지 기반 객체 탐지 기술(예: YOLO, Faster-R-CNN), 트리 기반 데이터 예측 기술(예: LightGBM) 등 다양한 기술이 개발되며 AI는 단순 예측을 넘어 실시간으로 복잡한 문제를 처리할 수 있게 되었다. 이러한 기술적 진보에 따라 AI의 활용 범위는 의료, 교통, 공공행정 등 급속히 확대되고 있다. 특히, 재난관리 분야에서는 대규모 데이터 분석, 위험 예측, 신속한 의사결정 등 정확성·객관성·신속성이 동시에 요구되기 때문에 활용 가능성이 크게 주목받고 있다.

2.2.2 재난관리 분야 AI 활용 현황

AI 기술의 급속한 발전에 따라, 재난관리 분야에서도 AI의 활용이 시도되고 있다. 재난관리 분야에서 활용되고 있는 AI 기술의 역할을 다음과 같이 크게 세 가지 유형으로 정리해 보았다.

가. 위험 예측 및 조기경보

위험 예측 및 조기경보는 현장에서 수집된 대규모 데이터를 과학적으로 분석하여 재난 발생의 가능성을 예측하고, 위험 요소를 선제 조치하여 필요 시 조기경보를 제공하는 분야이다. 지금까지 위험 예측은 주로 과거 사례와 통계에 의존했으나, 이는 시시각각 상호작용하며 변화하는 다중 변수와 이전에 발생하지 않았던 신종 위험을 반영하지 못하는 한계가 있었다. 최근에는 LightGBM, XGBoost, LSTM 등 최신 머신러닝 및 딥러닝 기반 예측 모델이 도입되면서 기상·지형·토양 등 다양한 데이터의 시계열 패턴을 정밀하게 학습하고, 새로 출현한 위험 변수도 실시간으로 반영할 수 있는 기반을 갖추게 되었다. 현재 딥러닝 기반 강우 예측 연구(RainNet 등), AI기반 홍수 예측 기술 개발(HydroNets 등), 머신러닝 기반 태풍 경로 실시간 예측(Aurora 등), 시뮬레이션을 통한 산사태 위험 지역 예측 등 다양한 시도가 있다. 이러한 기술의 발전은 재난 발생 이전 단계에서 예측의 정확도와 신속성을 높여 선제적 위험 관리와 피해 저감에 중요한 역할을 수행할 수 있을 것으로 전망된다.

나. 현장 모니터링 및 실시간 대응 지원

AI 기술은 영상 기술과 접목하여 현장 감시 및 실시간 대응 체계 구축을 가능하

게 한다. 기존에는 순찰을 통한 현장 감시 및 수동적 정보 수집 등 인력에 의존한 현장 관리가 주를 이루었기 때문에 광범위한 지역이나 접근이 어려운 상황에 대한 실시간 모니터링과 조치에 한계가 있었다. 최근에는 컴퓨터 비전 및 딥러닝 기반 객체 탐지 모델(YOLO, Faster R-CNN, DETR 등)을 드론, CCTV, 위성영상 등 장비에 결합시켜 산사태, 붕괴, 침수, 구조물 균열 등 다양한 재난 상황을 실시간으로 자동 탐지하는 기술이 개발되고 있다. 위성 영상에 기반한 산사태·산불 등 감지, 드론을 활용한 교량 및 도로 붕괴 위험 탐지, 도시 내 지능형 CCTV를 활용한 재난 상황 실시간 감시 등이 이러한 사례에 해당한다. 향후 고정밀 위치 추적, 인공지능 로봇을 통한 원거리 현장조치 기능 등을 강화한다면, 광범위하고 위험한 재난 현장에서 보다 신속하고 효과적인 대응이 가능하게 될 것으로 기대된다.

다. 대피 및 복구 등 의사결정 보조

AI는 주민 대피와 피해 복구 분야에서 의사결정을 돕는 데에도 기여하고 있다. 재난 발생 직후에는 주민들이 얼마나 신속하게 대피하느냐가 인명 피해 규모를 결정짓는다. 이런 관점에서 운영 중인 클라우드 기반 AI 안전 내비게이션(울주군)은 재난 상황에서 주민들에게 사용자 위치 기반으로 가까운 대피소, 행동 요령 등 정보를 안내하여 재난 지역 주민들이 신속하게 대피 결정을 내릴 수 있게 한다. 한편, AI는 피해 정보를 종합 검토하여 보상 및 복구 금액 산정에 활용되는 등 재난 종료 이후 합리적인 복구 전략 수립에 기여할 수 있다. 예를 들어, 미국의 연방재난관리청(FEMA)은 AI 기반의 피해 추정 시스템인 Hazus를 운영하며 지역별 피해 범위, 복구 비용 등을 정량적으로 분석하여 재난 복구 계획 수립을 지원하고 있다. 이처럼 AI 기술은 대피의 신속성, 보상 및 복구의 공정성을 동시에 확보할 수 있도록 의사결정을 돕고, 정부의 대응 역량과 주민의 체감 안전도를 향상시키는 데에 기여하고 있다.

2.3 객체 탐지 및 데이터 예측 AI 기술 동향

앞서 살펴본 바와 같이, 재난관리 분야에서도 AI 기술 개발 및 활용을 위한 움직임이 활발하다. 이 절에서는 그 중 이미지 기반 객체 탐지 기술과 데이터 기반 예측 기술의 동향에 대해 검토하여 본 연구의 실험에서 사용한 YOLOv8과 LightGBM 모델에 대한 기초 지식을 정립하고자 한다.

2.3.1 객체 탐지 AI 기술

객체 탐지 기술은 이미지나 영상에서 객체를 자동으로 탐지하고 분류하는 컴퓨터 비전 분야의 핵심 AI 기술이다. 이 기술은 초기에 SIFT, HOG, SURF 등 사람이 지정한 특징을 추출하여 비교하는 특징 기반(feature-based) 알고리즘이 주를 이루었다. 이후 2012년 딥러닝 기반의 AlexNet 등장으로 특징을 자동 학습하여 객체를 탐지해 내는 합성곱신경망(CNN) 기반의 모델이 주류로 자리잡았다. 이에 따라 복잡한 이미지 내 패턴을 자동으로 추출·분석하는 것이 가능해졌고, 정확도와 유연성도 높아지면서 지속적인 기술 혁신이 일어나고 있다.

현재 대표적으로 활용되는 모델로는 YOLO, Faster R-CNN, DETR 등이 있다. YOLO 계열은 속도가 빠르고 정확도가 비교적 높다는 특징을 갖고 있다. Faster R-CNN은 객체 후보 영역을 제안하는 과정을 네트워크 내부로 통합한 영역 제안 네트워크(Region Proposal Network, RPN)를 도입함으로써 객체탐지의 end-to-end 학습²⁾이 가능하게 만들었다. DETR(Detection Transformer)은 트랜스포머 기반 모델로, 객체 간의 관계를 학습하여 정교하게 반영하는 등 기존 CNN 모델의 한계를 극복한 모델이다. YOLO보다 속도가 다소 느리지만, 일단 학습에 성공하면 다양한

2) 중간에 특징 추출 및 수작업 공정 없이 데이터 입력부터 최종 결과 출력까지 모델이 데이터로부터 자체적으로 학습하고 결과를 도출하는 기법

환경과 복잡한 구조 속에서 객체를 정밀하게 탐지할 수 있다는 강점을 가진다.

객체 탐지 기술은 재난관리 분야에서 활용도가 높다. 산사태, 붕괴, 홍수 등 재난 상황이나 재난 징후를 탐지하기 위해 드론, CCTV, 위성 영상 등 다양한 영상 데이터에 AI 기술을 적용하려는 시도가 활발히 진행되고 있다. 다만, 현장 적용을 위해서는 경량화, 데이터 품질 향상, 신뢰도 제고 등 추가 과제가 남아 있다.

2.3.2 데이터 예측 AI 기술

데이터 예측 기술은 데이터를 활용해 수치를 예측하는 AI 기술이다. 과거에는 통계와 전문가 분석에 기반한 방식이 주로 사용됐으나, 2010년대 이후 Random Forest, Gradient Boosting(GBM, LightGBM, XGBoost 등) 등 앙상블 머신러닝 기법이 도입되었고, 최근에는 LSTM, GRU와 같은 시계열 딥러닝 모델이 활용되며 AI를 활용한 데이터 예측 기술의 정확도와 적응성이 한층 높아졌다.

대표적인 데이터 예측 AI 모델은 Gradient Boosting 계열로, 이 중 LightGBM은 경량화와 고속 연산이 가능해 대규모 데이터에 대한 빠른 학습과 예측이 가능하며, 변수별 중요도를 반영할 수 있다는 장점이 있다. XGBoost는 분류·회귀 등 다양한 문제에 활용되며 과적합 방지와 결측치 처리, 병렬 학습 등에서 강점을 보인다. 또한, LSTM(Long Short-Term Memory), GRU(Gated Recurrent Unit)와 같은 딥러닝 기반 시계열 예측 모델은 시간에 따른 데이터의 연속성과 패턴, 장·단기 의존성을 효과적으로 반영할 수 있어 복잡한 재난 발생 양상이나 위험 변동성의 흐름을 다루는 데 유리하다.

재난관리 분야에서 데이터 예측 기술은 산사태, 홍수, 태풍 등 재난의 위험을 수치 기반으로 예측하는 방식으로 활용 가능한데, 기술의 활용을 위해서는 데이터 신뢰성 확보, 현실적인 데이터 셋 구성, 예측 과정 설명 등 해결해야 할 과제가 많다.

제3장 객체 탐지 AI 기술(YOLOv8) 활용 연구

3.1 YOLOv8³⁾ 개요

YOLOv8(You Only Look Once version8)은 Ultralytics에서 개발한 단일 신경망(single-stage)⁴⁾기반의 객체 탐지(Object Detection) 딥러닝 알고리즘으로, 이미지 내 객체의 빠르고 정확한 탐지와 경량화된 구조를 특징으로 한다. YOLOv8의 작동 방식(Architecture)은 기본적으로 백본(Backbone), 넥(Neck), 헤드(Head)의 세 부분으로 구성된다. 먼저, 백본 네트워크에서 C2f모듈⁵⁾을 사용해 입력 이미지의 특징을 추출한다. C2f는 전체 네트워크를 경량화하기 위해 도입한 백본 네트워크의 핵심 모듈로, 연산량을 줄이면서도 백본과 넥 간의 연산 흐름이 효율적으로 조정되게 하여 YOLOv8의 경량화와 빠른 속도를 가능하게 한다. 다음으로, PAN-FPN⁶⁾ 등 넥 구조를 통해 백본에서 추출한 다양한 크기의 특징 맵을 결합하여 의미론적으로 풍부한 특징을 생성한다. 마지막으로, 헤드 단계에서는 넥에서 전달받은 특징 맵을 기초로 최종 예측을 진행한다. 특히, YOLOv8에서는 Anchor-free 방식⁷⁾을 전면 채택하여 복잡한 설정과 불필요한 연산을 줄이고 다양한 객체에 유연하게 반응할 수 있

3) 출처: Ultralytics 홈페이지 (<https://github.com/ultralytics/ultralytics>)

4) 모든 연산 절차(객체 박스 생성, 클래스 분류, 중복 제거, 신뢰도 부여 등)를 통합하여 한 번에 처리할 수 있어 Faster R-CNN, DETR 등 2-stage나 Transformer 기반 모델에 비해 속도가 빠름.

5) C2f(CSP Bottleneck with 2 convolution): YOLOv5의 CSPNet 기반 C3모듈을 개선하여 설계한 모듈. 더 많은 분기(Branch)와 연결(connection)을 통해 풍부한 그래디언트 흐름(rich gradient flow)을 제공하면서도 연산 효율성을 최적화하여 특징 추출(feature extraction) 능력을 향상시킴.

6) PAN-FPN(Path Aggregation Network-Feature Pyramid Network): PAN과 FPN의 장점을 결합해 다양한 해상도의 맵을 효과적으로 통합(저해상도-의미정보, 고해상도-위치정보)하는 넥구조. 작은 객체도 정확히 탐지하게 함.

7) 사전에 정의된 앵커 박스 없이 객체의 중심 좌표를 직접 예측하고 해당 좌표에서 너비와 높이를 회귀(Regression)하는 방식. 기존 Anchor-based 방식은 사전에 앵커 박스를 정의하여 각 grid 셀이 이 앵커와 맞는지를 기준으로 학습했기 때문에 앵커 박스 최적화 과정이 필요해 튜닝이 복잡하고 다양성에 한계가 있었음.

게 되었다. 전체 구조는 end-to-end⁸⁾로 학습되며, 이 과정에서 사용되는 DFL, CIoU Loss 등 고도화된 손실 함수⁹⁾들이 위치 정밀도와 탐지 안정성을 높이고, 특히, 복잡한 배경에서의 탐지 성능을 강화한다.

재난관리 분야에서 YOLOv8의 활용 가능성은 매우 높다. 기본적으로 객체 탐지 기능으로 산사태, 홍수, 구조물 균열 등 시각적 특징이 명확한 재난의 탐지가 가능하다. 또한 경량성 덕분에 드론·CCTV·모바일 기기 등 제한된 환경에서도 작동이 용이하며, 적은 비용으로 정책에 도입할 수 있다. 속도도 빨라 대규모 데이터의 신속한 분석과 실시간 경보가 필요한 곳에 훌륭한 보조 도구로 활용할 수 있다.

본 연구에서는 YOLOv8의 빠른 속도, 경량성, 효율성, 정책화 가능성을 고려하여 산사태 및 균열 이미지 탐지 모델로 채택하였다. 실험에서는 파인튜닝 학습 내용 변화에 따른 성능을 평가하였으며, 종합 검토를 통해 정책화 가능성을 확인해 보았다.

3.2 실험 설계

3.2.1 실험 설명

가. 사전학습(pre-trained) 상태 실험

사전학습 실험을 통해 YOLOv8 모델이 기본 상태에서 재난 이미지(예: 산사태, 구조물 균열 등) 탐지에 활용 가능한지 확인하였다. 아울러, 모델의 기본 탐지 능력을 확인함으로써 향후 파인튜닝 데이터 셋 구성과 실험 방향 설정의 기준으로 삼았다.

8) 중간에 특징 추출 및 수작업 공정 없이 데이터 입력부터 최종 결과 출력까지 모델이 데이터로부터 자체적으로 학습하고 결과를 도출하는 기법.

9) 탐지 성능 향상을 위해 손실 함수 설계를 개선. 객체 위치 예측에 CIoU(Complete IoU) Loss를 사용하여 박스 크기, 중심 거리, 정렬 각도까지 고려하여 정확도를 높임. 클래스 예측에 DFL(Distribution Focal Loss)를 적용하여 경계가 모호한 경우에도 확률 분포를 반영하여 판단하도록 설계되어 오탐률을 낮춤.

나. 재난 이미지 파인튜닝 실험

파인튜닝 실험에서는 사전학습 모델에 산사태 이미지로 파인튜닝(fine-tuning)¹⁰⁾한 후 모델이 재난 상황을 학습하고 탐지해 낼 수 있는지 확인한다.

다. 확장된 파인튜닝 실험

확장된 파인튜닝 실험은 기존 파인튜닝 실험에서 발전한 단계로, 세 가지 하위 실험으로 구성된다. 첫째, 산사태 이미지 학습량을 확대(99장→1,623장)하여 학습량 증가에 따른 성능 변화를 비교하는 실험이다. 둘째, 균열과 같이 미세한 이미지를 학습시켜 재난 징후에 대한 탐지도 가능한지 확인하는 실험이다. 셋째, 산사태와 균열 데이터를 한 번에 하나의 모델에 학습시킴으로써 모델이 다중 재난 상황에 대해 동시 탐지 성능을 갖출 수 있는지 확인하는 실험이다.

<표 3-1> 실험 별 주요 내용

실험명	주요 내용
Pre-trained 상태 실험	사전학습(pre-trained) 모델로 재난 이미지 탐지 가능 여부 확인
Fine-tuning 모델 실험	산사태 이미지로 재난 상황 학습 후 탐지 성능 확인
확장된 Fine-tuning 모델 실험	산사태 이미지 학습량 증가(99장→1,623장)에 따른 탐지 성능 변화 확인
	산사태보다 미세한 이미지인 재난 징후(균열) 이미지 학습 후 탐지 성능 확인
	모델에 두 가지 클래스[재난 상황(산사태)+재난 징후(균열)]를 동시에 학습시켰을 때 성능 변화 확인

10) 사전학습 모델에 새로운 객체를 추가 학습시켜 해당 객체에 대한 탐지 성능을 개선하는 과정

3.2.2 환경 설정

YOLOv8 기반의 시각 정보 탐지 실험은 Google Colab Pro 환경에서 수행하였다. 본 실험에서 사용한 딥러닝 모델은 Ultralytics에서 제공하는 PyTorch 2.1 프레임워크를 기반으로 구현되었고, 라이브러리는 Ultralytics에서 제공하는 YOLOv8 라이브러리를 적용하였다. 학습 시에는 YOLOv8 모델의 기본 학습 설정을 사용¹¹⁾하였으며, Cosine learning rate scheduler(=0.01), optimizer(=기본 SGD), augmentation(=Mosaic) 등은 Ultralytics 라이브러리의 디폴트 값으로 적용되었다.

<표 3-2> YOLOv8 실험 수행 시 활용된 시스템 환경

실험 수행 플랫폼	Google Colab Pro (GPU: NVIDIA T4) ※Google이 제공하는 클라우드 기반의 고성능 연산 플랫폼으로, GPU(NVIDIA T4)를 활용하여 일반 CPU 환경에 비해 대규모 이미지 데이터의 처리 효율과 속도 면에서 강점을 가진다.
프로그래밍 언어	Python 3.10
주요 프레임워크	PyTorch 2.1 ※PyTorch는 동적 계산 그래프를 지원하는 딥러닝 프레임워크로서 실시간 객체 탐지를 위해 설정값 조정이 가능해 유연하며, 모델 정의, 학습, 추론 등의 과정을 효율적으로 수행할 수 있다는 장점을 가진다
주요 라이브러리	Ultralytics YOLOv8 라이브러리

11) Learning rate: 학습속도. 너무 크면 불안정하고, 너무 작으면 느림.

Optimizer(SGD, Adam): 최적화 방법. 학습 방법. SGD는 안정적이거나 단순, Adam은 빠름


Augmentation: 이미지 증강 기법. 회전, 밝기 변화 등 다양한 상황을 연출하여 이미지를 다변화하는 기술.

Batch size: 배치 크기. 한 번에 학습하는 이미지 수. 작을수록 메모리를 덜 사용하나, 클수록 속도가 느려짐

Epoch: 반복 학습 횟수. 전체 데이터를 반복 학습시키는 횟수.

3.2.3 데이터 구성

객체 탐지 실험은 모델을 재난 상황(산사태)과 재난 징후(균열) 사진으로 학습시켜서 진행하였다. 학습에 필요한 이미지는 로보플로우(Roboflow)¹²⁾의 오픈소스를 통해 획득하였고, 학습용 이미지는 <그림 3-1>과 같이 산사태와 균열 부분을 COCO(Common Objects in Context) 포맷에 따라 라벨링하였다. 학습이 끝난 후 성능 평가를 위한 데이터셋은 직접 촬영하거나 언론에 보도된 라벨 없는 실제 산사태와 균열 사진을 사용하였으며, 탐지 결과 표시 라벨은 인식된 객체의 위치를 나타내는 박스 좌표와 클래스 정보(landslide, crack)를 포함하는 형식으로 표기하였다.



<그림 3-1> 라벨링된 산사태, 균열 이미지 데이터(예시)

12) 웹 기반으로 이미지 데이터 셋을 제작하여 관리하거나 이를 오픈소스로 공유할 수 있도록 지원해 주는 플랫폼

3.3 Pre-trained 상태 실험

가. 실험 목표 및 내용

본 실험은 YOLOv8 모델이 사전학습(pre-trained)¹³⁾ 상태에서 재난 상황(산사태)과 재난 징후(균열)를 인식할 수 있는지 확인하기 위한 실험이다. 아울러, 사전학습 모델의 인식 능력을 확인하여 추후 YOLOv8을 재난관리 분야에 활용하려면 어떤 조치가 필요한지 알아보는 파인튜닝 실험(3.4)의 기준점으로 삼고자 했다. 실험에서는 특별한 라벨 없는 산사태 현장 및 구조물 균열 사진 30장을 인식시켜 모델이 생성한 객체 탐지 박스의 위치, 클래스, 신뢰도 등을 확인하였다.

나. 결과 도출 및 해석


YOLOv8은 사전학습 상태에서는 산사태 및 균열 이미지를 전혀 탐지하지 못했고, 사전학습된 COCO 클래스 객체만 인식하여 탐지 박스를 생성하였다. <그림 3-2>처럼 심각한 산사태 현장 이미지에서도 낙석과 토사 붕괴 영역은 전혀 인식하지 못하고, 주변의 차량이나 사람 등 사전학습된 객체는 높은 확신도로 인식하였다.



<그림 3-2> pre-trained상태 산사태 탐지 실패(예시)

13) 사전학습(pre-trained) 상태란, 객체 탐지 모델에 사람, 자동차, 동물 등 일상 이미지 80여 종에 대하여 대규모 데이터 셋을 기반으로 기본 학습이 되어 있는 상태의 모델을 의미한다.

균열 이미지 탐지 실험에서도 균열은 전혀 인식하지 못하고 오토바이, 사람, 의자 등 사전학습된 객체만 탐지해 냈다. 한편, <그림 3-3>의 둘째줄 사진들처럼 사전학습된 객체도 잘못 인식하거나 균열 이미지를 다른 객체로 잘못 인식하는 오탐 사례도 관찰되었다.



<그림 3-3> pre-trained상태 균열 탐지 실패(예시)

다. 분석 및 평가

YOLOv8 pre-trained 모델은 기존에 학습한 일반 객체 탐지에 대해서는 비교적 정확한 탐지 능력이 있었으나, 학습하지 않은 재난 이미지에 대한 탐지 능력은 없었다. 본 실험을 통해 모델이 재난 상황 및 재난 징후를 탐지하도록 하기 위해서는 이미지를 추가로 학습시키는 파인튜닝 과정이 필요하다는 것을 알 수 있었다. 다음 절에서는 파인튜닝을 통해 YOLOv8에 재난 이미지를 학습시키고 탐지 성능이 향상되는지 확인해 보고자 한다.

3.4 Fine-tuning 진행 실험

본 절에서는 재난 이미지를 인식하지 못하는 사전학습(pre-trained) 상태의 YOLOv8 모델에 재난 이미지를 파인튜닝한 후, 학습 내용에 따른 모델의 재난 탐지 성능을 확인하는 실험을 진행하였다. 파인튜닝이란, 기존의 사전학습 모델에 새로운 클래스(산사태, 벽균열 이미지 등)를 추가 학습시켜 해당 클래스에 대한 탐지 성능을 향상시키는 과정이다.

본 연구에서는 재난 상태(산사태) 소규모 학습 실행 후 학습 데이터 증량 실험, 재난 징후(균열) 학습 실험, 재난 상태와 재난 징후 복합 학습 실험을 순차적으로 진행하여 탐지 성능을 비교했다. 학습 상태는 라벨있는 검증용 사진을 넣어 손실함수와 성능지표 분석을 진행하여 확인하고, 라벨없는 사진으로 모델의 실제 탐지 성능을 테스트하는 순서로 실험을 진행하였다.

3.4.1 재난 상황(산사태) 소규모 Fine-tuning

가. 실험 목표 및 내용

본 실험에서는 YOLOv8 모델에 소량의 산사태 사진으로 파인튜닝을 진행하여 모델이 재난 상황에 대해 탐지 성능을 갖출 수 있는지 확인하였다. 실험을 위하여 로보플로우에서 산사태 부분이 라벨링된 사진 99장¹⁴⁾을 선별하여 파인튜닝을 진행하였고(epoch¹⁵⁾=50), 산사태 외 다른 객체는 탐지하지 않도록 설정하였다.


14) Roads Detection with Drones, landslide Detection Computer Vision Project
<https://universe.roboflow.com/roads-detection-with-drones/landslide-detection-2dme2/dataset/2>

15) epoch: 전체 데이터 셋을 한 번 완전히 학습시키는 과정. epoch=50은 데이터 셋을 50회 반복 학습했다는 의미. 반복 횟수를 늘릴수록 탐지 성능이 향상되는 경향이 있으나, 과다 반복 시 과적합(overfitting)위험도 있음

나. 결과 도출 및 해석

1) 손실함수¹⁶⁾ 분석을 통한 Fine-tuning 결과 확인


손실함수는 예측값과 실제 정답 간의 오차를 수치화한 함수로, 학습은 이 값을 최소화하는 방향으로 진행된다. 그래프의 감소 경향이 뚜렷할수록 학습이 잘 진행되었다고 볼 수 있다. 파인튜닝 진행 결과인 <그림 3-4> 학습 손실함수(train/box_loss, train/cls_loss, train/df_l_loss)는 전반적으로 크게 진동하며 감소하는 경향을 나타냈다. epoch=40수준에서 전체 손실값이 증가하여 과적합¹⁷⁾이 의심되나, 이후 다시 감소하여 최종 수렴한 것으로 보아 학습 효과가 어느 정도 확보되었다고 판단된다.



<그림 3-4> 산사태 파인튜닝(99장) 학습 손실함수

- 16) train/(box_loss, cls_loss, dfl_loss): 학습 중/(박스오차, 클래스 분류 오차, 박스경계 정밀도 오차)
val/(box_loss, cls_loss, dfl_loss): 정량평가 중/(박스오차, 클래스 분류 오차, 박스경계 정밀도 오차)
metrics/precision: 모델이 탐지한 것 중 정답 비율, metrics/recall: 전체 정답 중 모델이 탐지한 비율
metrics/mAP50: 실제 박스와 탐지 박스가 50%이상 겹친 것을 탐지 성공으로 간주할 때의 평균 정밀도.
metrics/mAP50-95: IoU(Intersection over Union)를 0.5에서 0.95까지 0.05단위로 증가시키며 각각의 평균 정밀도를 구한 후 이를 다시 평균하여 얻은 값. mAP@0.5보다 엄격한 기준으로 정확도와 정밀성을 평가
- 17) 훈련 데이터에 지나치게 적합하게 되어 새로운 데이터에 일반화되지 못하는 현상. 과적합 시 모델은 훈련 데이터의 노이즈나 불필요한 패턴까지 학습해 실제 데이터의 주요한 일반적 추세를 반영하지 못하는 오류 발생

<그림 3-5>에 따라 항목별로 살펴보면, 진동이 전체적으로 더 뚜렷하게 확인된다. train/box_loss는 1.7에서 1.1까지 수렴하는 과정에서 큰 진동을 보여 모델이 객체 위치 예측 정확도를 불안정하게 학습한 것을 알 수 있었다. train/cls_loss은 3.0에서 1.5까지 수렴하였으나, epoch=40부근에서 2.1까지 상승하여 모델의 클래스 식별 기능도 불안정하게 학습되었다고 판단된다. train/df_l_loss의 경우, 1.6~2.0사이에서 계속 진동을 보이다 epoch=40부근에서 2.2까지 오르는 모습을 보여 탐지 박스 경계에서 정밀도 조정 능력이 거의 학습되지 못했을 것으로 추측된다. 한편, 검증용 이미지로 진행한 검증 손실 함수(val/box_loss, val/cls_loss, val/df_l_loss)도 큰 진동을 보이다 epoch=20를 중심으로 손실값이 일시적으로 폭증하여 성능이 다소 불안정하게 확보되었을 것으로 예상된다. Precision(=0.790), Recall(=0.738), mAP50(=0.826), mAP50-95(=0.561)은 다음 절의 성능지표 분석 파트에서 검토하기로 한다.



<그림 3-5> 산사태 파인튜닝(99장) 전체 손실함수

손실 함수 양상으로 보아 소규모 파인튜닝 모델은 산사태 탐지 성능을 불안정하게 갖춘 듯하다. 다음으로 성능지표 분석을 통해 파인튜닝 결과를 확인해 보겠다.

2) 성능지표¹⁸⁾ 분석을 통한 Fine-tuning 결과 확인

Recall과 Precision은 Confusion Matrix¹⁹⁾에 따라 산정한다. Recall(=0.738)은 모델이 전체 산사태 중 약 73.8%를 탐지해 냈음을 의미하며, 탐지 누락률(미탐)은 26.2%이다. Precision(=0.790)은 탐지한 산사태 중 79.0%가 실제 산사태였고, 잘못 탐지한 비율(오탐)은 약 21.0%로 해석된다. 이 두 지표의 조화 평균인 F1-score(=0.763)로 모델이 비교적 균형잡힌 탐지 성능을 갖추었다고 판단할 수 있다. 한편, mAP@0.5(=0.826)은 모델이 생성한 탐지 박스와 실제 객체가 50%이상 일치하는 경우가 82.6%에 달한다는 것을 의미한다. mAP@0.5~0.95(=0.561)은 보다 엄격한 기준 하에서 객체 예측 정밀도는 56.1%라는 것을 의미한다. 이상의 수치로 볼 때 소 규모 파인튜닝 모델은 불안정하지만 탐지 성능은 발휘할 수 있을 것으로 보인다.

<표 3-3> 산사태 파인튜닝(99장) 성능지표

지표	결과값	의미 분석
Recall [=TP/(TP+TN)]	0.738	산사태 중 탐지해 낸 산사태
Precision [=TP/(TP+FP)]	0.790	탐지한 것 중 실제 산사태
F1-score [=2×(Recall×Precision)/(Recall+Precision)]	0.763	Recall과 Precision의 조화평균. 성능의 균형 판단 지표
mAP@0.5	0.826	탐지 위치 정밀도와 박스 품질.
mAP@0.5~0.95	0.561	엄격한 평가 시 품질 저하됨.

18) Recall(재현율): 실제 정답 중 모델이 탐지한 객체의 비율

Precision(정밀도): 모델이 탐지한 객체 중 실제 정답의 비율

F1-score(조화평균): Recall과 Precision의 조화평균으로, 전체 탐지 성능의 균형을 판단하는 지표

mAP@0.5: IoU(Intersection over Union)가 0.5이상일 때 평균 정밀도. 라벨링된 박스와 탐지해서 그려낸 박스가 50%이상 일치할 때 탐지 성공으로 판단하고, 이 성공한 경우들의 평균 정밀도를 의미


mAP@0.5~0.95: IoU 기준을 0.5에서 0.95까지 0.05단위로 증가시키며 각각의 평균 정밀도를 계산한 후 이를 다시 평균하여 얻은 값. mAP@0.5보다 엄격한 기준으로 탐지 정확도와 정밀성을 평가하는 지표

19)

실제 \ 예측	Positive	Negative
True	TP(산사태를 산사태로 탐지)	TN(산사태를 정상으로 탐지)
False	FP(정상을 산사태로 탐지)	FN(정상을 정상으로 탐지)

3) 사진을 활용한 탐지 성능 확인

사진을 활용한 탐지 성능 확인은 파인튜닝과 검증에 사용하지 않은 40장의 라벨 없는 산사태 사진으로 수행하였다. 총 23장(57.5%)에서 산사태를 탐지하였고, 대부분 1장 당 1건의 탐지 박스를 생성했으며, 2건을 생성하는 경우도 있었다.



<그림 3-6> 파인튜닝(99장) 산사태 탐지 성공(예시)

<그림 3-6>과 같이 탐지에 성공한 이미지들은 대부분 산사태가 시각적으로 뚜렷한 경우였으며, 박스 별 예측 확신도는 25~80%까지 다양하였으나, 대부분의 경우 40안팎으로 높지 않게 도출되었다. 예측 박스는 산사태 부위만 정교하게 그려내기 보다는 전체를 넓게 표기하는 경우가 대부분이었다.

한편, <그림 3-7>의 (a)처럼 명백한 산사태 이미지도 탐지에 실패하는 미탐 사례도 다수(42.5%) 존재하였다. 또한 (b)처럼 산사태 탐지는 실패하고 다른 부분을 산사태로 탐지하는 사례도 있었으며, (c)처럼 가장 큰 범위의 산사태는 놓치고, 산사태가 아닌 부분(우측 하단)을 산사태보다 더 높은 확신도로 탐지하는 오탐 사례도 발견되었다.



<그림 3-7> 파인튜닝(99장) 산사태 탐지 실패(예시)

다. 분석 및 평가

YOLOv8 모델을 소량(99장)의 데이터로 파인튜닝한 결과, 학습을 통해 재난 탐지 성능을 갖출 수 있다는 것을 확인하였다. 그러나 탐지에 성공한 사진이 전체 중 57.5%에 그치는 점, 탐지 확신도가 높지 않고 탐지 박스가 산사태 영역에 집중하지 못하고 광범위하게 그려지는 점을 고려해 볼 때 성능이 불안정하다는 것을 알 수 있었다. 재난 분야에서는 재난 영역을 놓치는 경우 피해 확대의 위험성이 크고, 재난이 아닌 것을 재난으로 오판할 경우 막대한 자원을 잘못 투입하여 낭비가 초래될 수 있기 때문에 미탐·오탐의 심각성은 중대하다. 따라서 정책 현장에 활용하기 위해서는 성능 향상이 반드시 필요할 것으로 판단된다. 다음 절(3.4.2)에서는 모델 성능 향상의 방법 중 하나로 학습 데이터량을 증가시켜 파인튜닝하는 실험을 진행해 보고, 이를 소량 데이터 파인튜닝 결과와 비교 분석하고자 한다.

3.4.2 재난 상황(산사태) 데이터 증가 Fine-tuning

앞선 3.4.1절에서는 소규모 데이터 셋(산사태 이미지 99장)으로 YOLOv8 모델을 학습시키고, 파인튜닝으로 산사태 탐지 능력이 생성됨을 확인하였다. 그러나 탐지 확신도 및 정확도가 떨어지고 오탐과 미탐의 가능성이 높아 성능을 향상시킬 필요가 있었다. 이에 학습 데이터를 증가시켜 학습량 증가 시 성능이 향상될 수 있는지 확인해 보았다.

가. 실험 목표 및 내용

본 실험에서는 산사태 이미지 학습 데이터 셋을 기존 99장에서 1,623장으로 확대하여 YOLOv8 모델을 파인튜닝하고, 소규모 파인튜닝 실험과의 비교를 통해 학습량 증가가 모델 성능에 미치는 영향을 확인하였다. 1,623장의 이미지는 로보플로우에서 산사태 부분이 라벨링된 사진으로 선별²⁰⁾하였으며, 소규모 파인튜닝에 사용한 이미지도 포함하여 구성했다. 이미지 수량 외에 모든 조건은 소규모 데이터 파인튜닝 실험과 동일하게 진행하여 실험 환경과 평가 기준의 일관성을 유지하고자 하였다.


나. 결과 도출 및 해석

1) 손실함수 분석을 통한 Fine-tuning 결과 확인

학습 손실 함수(train/box_loss, train/cls_loss, train/dfl_loss)는 소규모 학습 실험과 비교할 때 더 뚜렷하게 감소 및 수렴하였다. 모든 손실 함수가 감소세를 유지하

20) LANDSLIDE, Landslide Area Segmentation Computer Vision Project
<https://universe.roboflow.com/landslide-28gdu/landslide-area-segmentation>

면서 epoch 후반부까지 안정적으로 수렴하여 학습 데이터 증가 시 안정성이 확보된다는 것을 확인할 수 있다. 특히, train/box_loss, train/cls_loss의 경우, 학습 중후반 구간에서도 손실 값의 상승 없이 일정하게 감소세가 유지되었다는 점에서 과적합 없이 안정적인 학습이 이루어진 것으로 판단된다. 정량 지표인 Precision, Recall, mAP50도 90% 수준으로 높게 확보되는 모습을 보이며 학습 효과를 뒷받침하였다.



<그림 3-8> 산사태 파인튜닝(1,623장) 전체 손실함수

<그림 3-8>을 항목별로 분석해 보면, train/box_loss는 학습이 진행됨에 따라 감소하여 최종적으로 약 1.1에서 0.48 수준까지 수렴하였으며, 이는 객체 위치 예측의 정확도가 향상되었음을 의미한다. train/cls_loss 역시 과적합 현상 없이 1.8에서 0.53까지 꾸준히 수렴하며 모델의 클래스 구분 능력이 안정적으로 학습되었음을 보여주었다. train/df_l_loss의 경우 epoch=40부근에서 일시적인 증가가 관찰되었으나, 최종적으로 1.58에서 1.23 수준까지 수렴하여 탐지 박스 경계의 세부 정밀도 역시 비교적 안정적으로 확보된 것으로 판단된다.

한편, 검증 손실함수(val/box_loss, val/cls_loss, val/df_l_loss)는 다소 진동은 있으나 전반적으로 감소하는 모습을 보였다. 세 지표 모두 검증 초반에 손실값이 폭증하며 불안정한 모습을 보였으나, epoch을 진행하면서 점차 안정을 되찾아 수렴한 것으로 볼 때, 모델의 성능이 소규모 파인튜닝보다 안정적으로 확보되었음을 알 수 있었다.

손실함수 분석을 통해 학습 데이터 양을 증가시키면 모델이 더욱 정확하고 정밀한 객체 탐지 능력을 확보할 수 있음을 확인하였다. 다음 절에서는 성능지표를 통해 탐지 성능 향상 여부를 분석해 보도록 하겠다.

2) 성능지표 분석을 통한 Fine-tuning 결과 확인

평가 결과, Recall은 0.868, Precision은 0.915, F1-score는 0.889, mAP@0.5는 0.939, mAP@0.5~0.95는 0.808로 확인되었다.

<표 3-4> 산사태 파인튜닝(99장→1,623장) 성능지표 비교

지표	소규모 학습 시 (99장)	학습 데이터 증가 시 (1,623장)	데이터 증가 시 변화 분석
Recall	0.738	0.868	산사태 중 옳게 탐지한 비율 증가 (미탐 감소)
Precision	0.790	0.915	탐지한 것 중 산사태의 비율 증가 (오탐 감소)
F1-score	0.763	0.889	Recall과 Precision의 조화평균 상승 (전반적인 탐지 성능 개선)
mAP@0.5	0.826	0.939	산사태 위치 예측 정밀성과 박스
mAP@0.5~0.95	0.561	0.808	품질 개선

Recall(=0.868)은 전체 산사태 중 약 86.8%를 모델이 탐지해냈고, 탐지 누락률(미탐)이 13.2%임을 의미한다. 이는 소규모 파인튜닝 시 미탐율이 26.2%였던 것에

비해 크게 개선된 수치로, 학습 데이터의 확장이 객체 포착력 향상에 기여했음을 말해준다. Precision(=0.915)는 탐지된 객체 중 91.5%가 실제 산사태였음을 나타내며, 허위 탐지(오탐) 비율이 약 8.5%로 낮아졌음을 의미한다. 소규모 파인튜닝의 오탐률이 21%였던 것과 비교하면 정밀도가 크게 향상되었다는 것을 알 수 있다. Recall과 Precision의 조화 평균인 F1 score(=0.889)는 모델이 높은 재현율과 정밀도를 균형있게 확보하고 있음을 보여주며, 전반적인 탐지 성능이 개선되었음을 나타낸다. 한편, mAP@0.5(=0.939)로 모델의 탐지 정확도가 약 93.9%이며, 특히, mAP@0.5~0.95(=0.808)로 보다 엄격한 기준 하에서 예측된 탐지 정밀도가 80.8%까지 향상된 것을 확인하였다. 이는 소규모 파인튜닝 결과(=56.1%)와 비교할 때, 모델의 위치 예측 정밀성과 박스 품질 예측 성능이 큰 폭으로 개선되었음을 보여준다.

이로써 학습 데이터의 증가가 YOLOv8 모델의 학습 효과에 긍정적으로 작용하며, 모델의 성능을 향상시킬 수 있다는 것을 확인하였다. 향후 재난 분야에서 모델 활용 시 충분한 양의 학습 데이터를 확보해 적절한 수준으로 파인튜닝한다면, 탐지 성능을 높이고 신뢰도를 향상시킬 수 있을 것으로 판단된다.

3) 사진을 활용한 탐지 성능 확인

사진을 활용한 탐지 성능 확인은 소규모 파인튜닝 실험과의 비교를 위해 그 실험에서 사용한 40장의 라벨 없는 산사태 사진으로 동일하게 수행하였다. 총 39장(97.5%)에서 산사태를 성공적으로 탐지하였고, 평균적으로 1장 당 1~3건의 탐지 박스를 생성하였다. 손실함수와 성능지표에서 확인했던 바와 같이 실제 사진으로 테스트해 본 결과에서도 학습량 증가 시 향상된 정확도와 정밀도를 보여주었다.


소규모 파인튜닝 결과와 비교 분석한 결과 몇 가지 주목할 만한 차이점을 발견하였다. 첫째, <그림 3-9>처럼 전반적으로 탐지 확신도가 상승했다. 소규모 파인튜닝 시 탐지에 성공한 23장 중 20장(85%)²¹⁾에서 확신도가 1~50%p가량 높아졌다.

21) 나머지 3장은 탐지 박스 개수가 증가하며 정교해졌고, 평균 탐지 확신도가 소폭 하락하였음




<그림 3-9> 산사태 학습 데이터 증가에 따른 탐지 확신도 향상(예시)

둘째, 탐지 결과가 정교해졌다. <그림3-10>의 (a'')와 같이 산사태 영역에 맞게 탐지 박스를 세분화해서 여러 개 생성한 경우도 있고, (b'')와 같이 탐지 박스를 산사태 부분으로 집중하여 축소 제작함으로써 정교해진 경우도 있었다. 이런 경우들은 대부분 탐지 확신도도 상승하였다.



<그림 3-10> 산사태 학습 데이터 증가에 따른 탐지 정교화(예시)

셋째, 미탐·오탐이 수정되었다. 물론 소규모 데이터 파인튜닝 시와 동일하게 여전히 산사태를 탐지하지 못하는 경우도 있었으나, <그림3-11>의 (a')처럼 소규모 데이터 파인튜닝 시 탐지하지 못했던 객체를 (a')처럼 탐지해 내는 경우도 있었다. 또는 (b')와 (c')처럼 소규모 파인튜닝 시 산사태로 잘못 탐지했던 오탐 사례를 수정하여 (b'')와 (c'')처럼 올바르게 탐지해 내는 경우도 있었다는 점이 주목할 만하다.



<그림 3-11> 산사태 학습 데이터 증가에 따른 미탐·오탐 결과 수정(예시)

다. 분석 및 평가

산사태 이미지 데이터 셋을 99장에서 1,623장으로 증가시켜 파인튜닝한 결과, 학습 데이터량 증가는 YOLOv8 모델의 성능을 향상시키는 데에 효과적임을 확인하였다. 손실함수 분석 결과, 모든 손실 지표가 일정한 감소세를 유지하며 안정성을 보였으며, 성능 지표 분석 결과, 소규모 파인튜닝 시와 비교하여 전반적으로 큰 폭의 개선을 보여 90% 안팎의 높은 수치를 기록하였다. 이 결과는 학습 데이터 셋 규모를 적정 수준으로 확대 시 모델이 객체를 더욱 정밀하고 정확하게 탐지하게 할 수 있다는 것을 증명한다. 실제 사진을 활용한 테스트에서도 전반적으로 탐지 성공률과 탐지 확신도가 증가하였고, 탐지 박스를 더 정교하게 생성하거나 이전 실험에서 미탐·오탐이었던 부분을 올바르게 수정하는 등 성능 향상이 관찰되었다.

향후 객체 탐지 모델을 재난관리 현장에서 활용하기 위해서는 충분한 양의 학습 데이터로 파인튜닝을 거치는 과정이 필수적이며, 이를 통해 안정적이고 신뢰도 높은 객체 탐지 모델을 확보할 수 있을 것으로 판단된다. 다음 절(3.4.3)에서는 YOLOv8 모델에 다른 유형의 재난 징후(균열)를 학습시켜 재난 유형 별로 탐지 성능의 차이를 보이는지 비교·분석하고자 한다.

3.4.3 재난 징후(균열) Fine-tuning


가. 실험 목표 및 내용

본 실험은 YOLOv8가 산사태보다 미세한 붕괴 징후인 균열(crack)도 탐지할 수 있는지 확인하여 객체 탐지 모델을 재난 징후 감지에도 활용 가능한지 검토하기 위해 수행하였다. 파인튜닝은 로보플로우에서 선별하여 라벨링된 930장의 이미지²²⁾로 진행하였다(epoch=50).

나. 결과 도출 및 해석

1) 손실함수 분석을 통한 Fine-tuning 결과 확인

학습 과정에서 모든 손실함수(train/box_loss, train/cls_loss, train/dfl_loss)가 후반부까지 안정적으로 감소하며 수렴하는 모습을 보였다.




<그림 3-12> 균열 파인튜닝(930장) 학습 손실함수

22) cracks detection, Detecção de fissuras/rachaduras Computer Vision Project
<https://universe.roboflow.com/cracks-detection-nbicj/deteccao-de-fissuras-rachaduras/dataset/2>

<그림 3-13>의 구체적인 수치 분석 그래프를 보면, train/box_loss는 epoch=40 부근에서 일시적으로 손실값 증가를 보였으나, 전체적으로 약 1.8에서 1.3까지 꾸준히 감소하며 모델이 객체 위치 예측 정확도를 갖추었음을 보여주었다. train/cls_loss도 약 2.6에서 1.5까지 가파르게 수렴한 것으로 보아 모델이 클래스 식별 능력을 갖추었다고 판단된다. train/df_l_loss의 경우 epoch=40부근에서 일시적으로 증가했으나, 그 외 구간에서는 약 2.0에서 1.5수준까지 감소하였으므로 모델이 탐지 박스 경계에서 정밀도 조정 능력을 어느 정도 획득했을 것으로 보인다.

한편, 검증 손실함수(val/box_loss, val/cls_loss, val/df_l_loss)는 초반에는 시작점보다 손실값이 상승했으나, 전체적으로 안정적으로 감소하며 수렴하는 모습을 보여주어 성능의 안정성을 확인할 수 있었다. 정량 평가 지표인 Precision, Recall, mAP도 epoch가 진행됨에 따라 90%수준까지 상승하며 학습 효과를 뒷받침하였다.



<그림 3-13> 균열 파인튜닝(930장) 전체 손실함수

손실 함수의 양상으로 보아 모델이 균열에 대해서도 학습이 가능하다는 것을 확인하였다. 다음으로 성능지표를 통해 파인튜닝 결과를 분석해 보겠다.

2) 성능지표 분석을 통한 Fine-tuning 결과 확인

평가 결과, Recall은 0.867, Precision은 0.920, F1-score는 0.893, mAP@0.5는 0.938, mAP@0.5~0.95는 0.809로 확인되었다.

<표 3-5> 균열 파인튜닝(930장) 성능지표(산사태와 비교)


지표	균열 파인튜닝 (930장)	산사태 파인튜닝 (1,623장)	균열 학습 시 변화 분석
Recall	0.867	0.868	균열 중 옳게 탐지해 낸 균열의 비율
Precision	0.920	0.915	탐지한 것 중 실제 균열의 비율
F1-score	0.893	0.889	Recall과 Precision의 조화평균
mAP@0.5	0.938	0.939	우수한 위치 정밀도와 박스 품질 유지
mAP@0.5~0.95	0.809	0.808	

Recall(=0.867)은 산사태 파인튜닝의 Recall(=0.868)과 유사하게 높은 탐지율로, 균열 탐지의 난이도가 더 높을 것임에도 불구하고 미탐율이 비슷한 수준으로 낮게 유지되었음을 의미한다. Precision(=0.920)은 탐지한 객체 중 92%가 실제 균열로 확인되었음을 나타내며, 산사태 파인튜닝의 Precision(=0.915)과 비슷하게 높은 수준으로, 모델이 균열과 같이 미세한 객체를 탐지할 때에도 낮은 오탐율을 유지함을 보여준다. Recall과 Precision의 조화 평균인 F1-score(=0.893)은 모델이 균형있는 탐지율을 확보하여 전체적으로 탐지 성능이 우수함을 나타낸다. mAP@0.5(=0.938)와 mAP@0.5~0.95(=0.809)도 역시 모델이 산사태 파인튜닝때와 비슷한 수준의 정확도와 정밀도를 확보했음을 보여준다.

YOLOv8 모델이 산사태와 같은 재난 상황 뿐만 아니라 벽균열과 같은 재난 징후의 탐지 학습도 가능한 것으로 보아 향후 모델을 다양한 재난 유형을 대상으로 학습시켜 범용으로 활용할 수 있는 가능성이 있다고 판단된다.


3) 사진을 활용한 탐지 성능 확인

사진을 활용한 탐지 성능 확인은 파인튜닝과 검증에 사용하지 않은 균열 이미지 40장으로 진행했으며, 그 중 28장의 사진(70%)에서 올바르게 탐지 박스를 생성하였다. 성능 지표에서 확인한 수치(Recall=86%)에 비하면 실제 사진으로 확인한 재현율(70%)은 다소 낮다고 판단된다. 탐지 박스 생성 예를 사진을 통해 살펴보면, <그림 3-14>와 같이 균열 사진 전체에 광범위하게 박스를 생성하는 경우도 있었으나, 균열마다 정확하게 탐지 박스를 생성하여 정밀도 측면에서 높은 품질을 보이는 경우도 많았다.



<그림 3-14> 파인튜닝(930장) 균열 탐지 성공(예시)

한편, 탐지에 성공했으나 품질이 좋지 않은 경우도 있었다. <그림 3-15>의 (a)처럼 균열 중 일부만 탐지에 성공하고 나머지는 놓치거나, (b)처럼 균열을 잡아내면서 균열이 아닌 부분(좌측 박스)까지 오탐하여 탐지 박스를 생성하는 경우도 있었다. 또는 (c)처럼 균열에 비해 너무 큰 탐지 박스를 그리거나, 탐지는 했으나 확신도가 낮아 탐지 결과의 유용성이 낮은 경우도 있었다.



<그림 3-15> 파인튜닝(930장) 균열 불완전한 탐지(예시)

오탐과 미탐 사례도 다양했다. <그림 3-16>의 (a)처럼 균열과 비슷한 무늬나 그림자를 균열로 오탐하는 경우도 있었고, (b)처럼 선명한 균열임에도 인식하지 못하는 경우도 있었다. 그 밖에 미탐 사례는 (c)처럼 파인튜닝 시 학습 데이터에 없어 학습할 수 없었던 패턴인 경우가 대부분이었다. 이 결과로 볼 때, 균열 이미지는 패턴이 다양하고 경계가 불분명하여 탐지 난이도가 높으므로 파인튜닝 시 다양한 이미지를 활용하여 충분히 학습시켜야 정확도와 정밀도가 확보될 것이라고 판단된다.



<그림 3-16> 파인튜닝(930장) 균열 오탐·미탐(예시)

다. 분석 및 평가

균열 파인튜닝 실험 결과, 손실함수 결과와 성능평가 지표가 모두 대규모 산사태 파인튜닝 시와 비슷하게 90% 수준으로 나온 것으로 보아 YOLOv8이 산사태보다 미세하고 불규칙한 재난 징후인 균열에 대해서도 탐지 능력을 갖출 수 있다고 판단된다. 따라서 향후 다양한 재난 탐지가 가능한 범용 모델도 만들 수 있을 것으로 보인다. 다만, 실제 사진으로 테스트하였을 때에는 전체 이미지의 70%만 올바르게 탐지하는 불안정한 탐지 성능을 보였는데, 미탐 사례들은 대부분 화질이 좋지 않거나 파인튜닝 시 학습 데이터에 들어있지 않은 패턴이었으며, 오탐 사례들은 균열로 착각하기 쉬운 무늬나 그림자가 있는 경우들이었다. 따라서 모델의 정확도와 정밀도를 향상시키려면 파인튜닝 시 무조건 대량의 사진을 넣기보다는 양질의 다양한 데이터를 확보하여 학습시키는 것이 중요하다고 판단된다. 다음 절에서는 산사태와 균열을 동시에 학습시켜 서로 다른 유형의 재난을 한 번에 탐지하는 멀티클래스 모델을 제작하여 지금까지의 실험 결과들과 비교 평가를 통해 성능을 분석하고, 활용 가능성을 검토하고자 한다.

3.4.4 멀티클래스(산사태+균열) Fine-tuning

가. 실험 목표 및 내용

지금까지 산사태와 균열 이미지를 단독으로 학습한 모델의 성능을 확인해 보았다. 본 실험에서는 한 번에 두 가지 재난 유형(산사태, 균열)을 동시에 학습시키는 멀티클래스 모델 실험을 수행하였다. 이는 실제 재난 현장에서 하나의 통합된 모델로 다양한 재난 유형을 동시에 탐지하는 모델 제작이 가능한지 확인하기 위한 것으


로, 클래스 간 간섭이나 성능 저하·학습 불안정성이 발생하지 않는지, 혹은 긍정적인 영향이 발생하기도 하는지 검토하고자 하였다.

앞서 실험에서 사용했던 총 2,553장의 이미지(산사태 1,623장 + 균열 930장)를 모델에 동시에 파인튜닝하였으며(epoch=50), 기타 설정은 앞의 실험들과 동일하게 유지하여 실험 환경과 평가 기준의 일관성을 유지하고자 하였다.

나. 결과 도출 및 해석


1) 손실함수 분석을 통한 Fine-tuning 결과 확인

학습용 이미지로 파인튜닝한 손실 함수(train/box_loss, train/cls_loss, train/dfloss)는 모두 학습 후반부까지 안정적으로 감소하며 수렴하였다.



<그림 3-17> 산사태·균열 멀티클래스 파인튜닝 학습 손실함수

<그림 3-18>의 그래프를 살펴보면, train/box_loss는 epoch=40부근에서 일시적으로 증가하였으나, 전체적으로 1.2에서 0.85까지 안정적으로 수렴한 것으로 보아 모델이 객체의 위치 탐지 방법을 안정적으로 학습하였음을 알 수 있었다. train/cls_loss도 2.2에서 0.9까지 처음부터 일관성있게 가파르게 감소하며 수렴하였는데, 이는 모델이 두 클래스(산사태, 균열)를 구분할 수 있는 식별 능력 효과적으로 학습했음을 보여준다. train/dfl_loss의 경우 epoch=40 부근에서 일시적으로 증가했으나, 다시 가파르게 감소하여 모델이 탐지 박스 경계에서 어느 정도 정확도 조정 능력을 획득한 것으로 보인다. 세 손실 함수 모두 단일클래스 실험과 유사한 패턴을 보여주었으며, 두 개의 클래스가 동시에 학습되었음에도 불구하고 과적합이나 수렴 불안정성은 관찰되지 않았다. 정량 평가 지표인 Precision, Recall, mAP는 다음 절의 성능지표 분석을 통해 검토해 보겠다.



<그림 3-18> 산사태·균열 멀티클래스 파인튜닝 전체 손실함수

2) 성능지표 분석을 통한 Fine-tuning 결과 확인

산사태와 균열 모두에서 단일클래스 대비 멀티클래스 파인튜닝 시 전반적으로 성능 지표가 낮아졌다. 산사태의 Recall은 단일(0.868)에서 멀티(0.770)로, 균열은 단일(0.867)에서 멀티(0.660)로 각각 감소하였는데, 이는 멀티클래스 모델의 미탐율이 높아졌음을 의미한다. Precision 역시 산사태(0.915→0.810), 균열(0.920→0.720) 모두 감소한 것으로 나타나 오탐률도 높아졌음을 알 수 있다. mAP@0.5 역시 산사태(0.939→0.810), 균열(0.938→0.750) 모두 감소했으며, mAP@0.5~0.95도 산사태(0.808→0.611), 균열(0.809→0.547) 모두 낮아져 멀티클래스 모델의 탐지 정확도와 위치 예측 정밀도가 저하되었음을 보여준다.

이 결과를 통해 모델이 두 재난 유형을 동시에 탐지할 수 있는 가능성은 확인하였으나, 단일클래스 특화 모델에 비해 전반적인 탐지 능력(탐지율, 정확도, 정밀도, 박스 품질 등)에서 성능 저하가 발생하는 것을 알 수 있었다. 특히, 성능지표의 하락이 산사태보다 균열에서 더 크게 나타났다는 점이 주목할 만하다. 구체적인 성능 저하의 예시는 이어질 사진 활용 평가에서 확인해 보겠다.


<표 3-6> 멀티클래스(산사태+균열) 파인튜닝 성능지표

지표	산사태		균열		평균
	단일	멀티	단일	멀티	
Recall	0.868	0.770	0.867	0.660	0.715
Precision	0.915	0.810	0.920	0.720	0.771
F1-score	0.889	0.789	0.893	0.688	0.739
mAP@0.5	0.939	0.810	0.938	0.750	0.778
mAP@0.5~0.95	0.808	0.611	0.809	0.547	0.581

3) 사진을 활용한 탐지 성능 확인


사진 탐지 성능 확인은 각각의 단일클래스 파인튜닝에서 테스트용으로 사용했던 것과 동일한 이미지로 진행하였다.

산사태의 경우, 전체적으로 <그림 3-19>처럼 탐지 확신도가 저하되고 탐지 박스의 개수가 줄었다. 심지어 (c)처럼 단일클래스에서 높은 확신도로 탐지에 성공했던 산사태를 (c')처럼 미탐하는 사례도 발견되었다.




<그림 3-19> 멀티클래스(산사태+균열) 파인튜닝 산사태 탐지 성능 저하(예시)

균열의 경우, 성능 저하가 더욱 분명히 관찰되었다. 전체적으로 <그림 3-20>의 (a')처럼 탐지 확신도가 저하되고 박스 숫자가 줄었으며, (b)처럼 단일클래스에서 탐지에 성공했던 균열을 (b')처럼 미탐하는 경우도 많았다. 특히, (c)처럼 단일클래스에서 균열로 탐지했던 객체를 (c')처럼 멀티클래스 실험에서 산사태로 오탐하는 간섭 사례가 발생한 반면, 산사태를 균열로 오탐한 간섭 사례는 전혀 없었다는 점이 주목할 만하다.



<그림 3-20> 멀티클래스(산사태+균열) 파인튜닝 균열 탐지 성능 저하(예시)

한편, 성능 개선을 보이는 사례도 있었다. <그림 3-21>의 (a)처럼 단일클래스에서 전봇대의 전선을 균열로 오탐했던 사례를 수정하여 (a')처럼 오탐이 사라지는 경우도 있었고, (b)처럼 단일클래스 학습에서 놓쳤던 균열을 (b')처럼 멀티클래스에서 탐지해 내는 경우도 있었다.



<그림 3-21> 멀티클래스(산사태+균열) 파인튜닝 균열 탐지 성능 개선(예시)

다. 분석 및 평가

복수의 재난 유형을 동시에 학습시킨 결과, 기본적인 탐지 기능은 작동하였으나, 전반적으로 단일클래스 대비 탐지 성능 저하 현상이 관찰되었다. 이는 멀티클래스 학습 환경에서 발생할 수 있는 클래스 간 혼선으로 인해 객체 간 구분이 어려워지는 문제가 발생한 것으로 해석된다.

특히, 산사태보다 균열 탐지에서 성능 저하가 더 두드러졌으며, 산사태를 균열로 오탐한 사례는 확인되지 않은 반면, 균열을 산사태로 오탐한 사례는 발생하였다. 멀

티클래스 학습 시 상대적으로 크기가 작고 미세한 객체의 경우에 정보가 손실되거나 다른 클래스에 흡수되는 간섭 현상이 더 쉽게 발생하는 것으로 보인다. 후속 연구를 통해 확인해 봐야겠지만, 만약 이러한 현상이 일반화될 수 있다면, 작고 세밀한 객체를 포함하는 멀티클래스 모델 설계 시 성능 저하를 방지하기 위해 학습 데이터 비중 조절 등 보완책 마련이 필요해 보인다. 한편, 일부 사례에서는 단일클래스 학습 시 발생했던 오탐이 해소되거나, 미탐이었던 영역이 성공적으로 탐지되는 등 성능 개선 효과도 부분적으로 관찰되었다. 그러나 이와 같은 긍정적인 변화는 제한적인 수준이어서 보편적인 경향으로 일반화하기에는 추가 실험을 통한 근거 확보가 필요할 것으로 보인다.

결과적으로 본 실험은 모델 활용에 있어 멀티 탐지 모델의 효율성과 유형별 특화 모델의 정확성 사이에서 전략적 선택이 필요함을 시사한다. 특히, 미세한 징후를 조기에 탐지하여 심각한 재난 피해를 막아야 하는 경우에는 멀티 탐지 모델보다 단일클래스 모델을 활용하여 정확성을 높이는 방향을 검토해 볼 필요가 있다. 또한 멀티 모델 제작 시에는 미세한 클래스의 성능이 영향받지 않도록 주의하여 정교한 학습 데이터 구성, 클래스 간 경계 명확화, 데이터 균형 조정 등의 보완이 선행된 설계가 필수적일 것으로 판단된다.

3.5 종합 검토 및 시사점

본 장에서는 YOLOv8 모델을 활용하여 재난 유형에 대한 경량형 객체 탐지 모델의 성능을 실험적으로 검증하였다. 실험은 사전학습 모델의 탐지 가능성 평가를 시작으로 산사태와 균열에 대한 단일클래스 파인튜닝, 학습 데이터 규모 확대, 멀티클래스 파인튜닝까지 단계적으로 확장하였으며, 이를 통해 경량형 AI 객체 탐지 모델의 재난관리 분야 적용 가능성 및 활용 조건을 검토하고자 하였다. 실험 결과,

YOLOv8 모델은 일정 수준 이상의 탐지 능력을 보였으며, 특히, 학습 데이터를 증량시켰을 때 탐지 성능이 뚜렷이 향상되었다. 다만, 탐지 대상의 종류에 따라 성능 차이가 발생하였고, 두 가지 이상의 재난 유형을 학습시킨 멀티클래스 모델의 경우 단일클래스에 비해 성능 저하를 보였다. AI 기반 재난 탐지 기술을 실질적으로 정책에 도입하기 위해서는 다음과 같은 조건이 필요하다.

첫째, 모델 성능 확보를 위한 고품질·대규모 데이터셋의 구축이 가장 중요한 선행 과제이다. 특히, 재난은 지역별, 유형별로 다양한 양상을 보이므로 단순히 양적인 확대뿐만 아니라, 대표성을 반영한 다양한 데이터 구성이 필수적이다. 현재 국가 중심의 재난정보 관리 체계는 이러한 데이터를 중앙에서 효율적으로 수집·통합할 수 있는 인프라를 이미 보유하고 있으므로, 공공 주도의 체계적 데이터 생산 및 관리 시스템을 마련할 수 있다. 둘째, 성능 향상을 위한 기술적 접근의 다각화가 필요하다. 본 실험에서는 데이터 양 증가가 성능 개선에 효과적이었으나, 향후에는 전이 학습 기법, GAN²³⁾(Generative Adversarial Network) 기반 데이터 증강 등 다양한 기술을 병행해 모델을 고도화할 필요가 있다. 셋째, 정확도가 충분히 확보되기 전까지 AI는 보조적 도구로써만 활용하며 혼란을 최소화해야 한다. 시범 운영, 단계적 도입 등 점진적 도입 전략이 필요하며, 일정 수준 이상의 성능 기준을 충족한 모델만 현장에 적용하도록 하는 정책적 필터링 장치도 필요하다.

결론적으로, YOLOv8은 경량성과 신속성 측면에서 재난관리 분야에 유용하게 활용될 수 있는 가능성을 보여주었다. 그러나 AI 기술의 도입은 단순한 성능 검증만으로 결정할 것이 아니라, 데이터 인프라, 운영 체계, 정책 수용성까지 포괄하는 통합적 전략 속에서 추진되어야 한다. 특히, 재난이라는 고위험 분야에서 AI 기술이 실효성 있는 도구로 자리 잡기 위해서는 기술적 신뢰성과 정책적 책임성이 동시에 보장되는 정책 마련이 필요할 것으로 보인다.

23) 데이터 생성 모듈과 검증 모듈이 경쟁적으로 학습하는 구조로, 생성 모듈은 실제와 유사한 데이터를 만들어 내고, 검증 모듈은 해당 데이터의 진위 여부를 판단하는 과정을 반복함으로써 점점 더 실제와 비슷한 데이터를 만들어 고품질 데이터를 생성하는 딥러닝 기반 AI 생성 모델

제4장 데이터 예측 AI 기술(LightGBM) 활용 연구

4.1 LightGBM 개요

LightGBM(Light Gradient Boosting Machine)은 Microsoft에서 GB²⁴⁾(Gradient Boosting)알고리즘을 개선하여 변형한 모델로, 고차원 대용량 데이터셋에 대한 신속한 평가 및 반복 학습이 가능하도록 고안된 머신러닝 알고리즘이다(Jin, 2019). 이 모델은 정보량이 많은 부분을 우선적으로 세분화해서 최적화하는 리프 기반 트리 성장 전략(leaf-wise tree growth strategy)을 적용함으로써 대용량 데이터도 적은 연산을 통해 처리가 가능하다. 또한, 데이터를 구간별로 나눠서 각 구간의 요약 값만 사용해 처리하는 Histogram 기반으로 데이터를 처리하여 계산이 빠르고 메모리도 적게 든다. LightGBM은 기존 Gradient Boosting Decision Tree(GBDT) 구현체인 XGBoost 대비 최대 20배 이상의 학습 속도 향상을 보이면서도 정확도는 거의 동일하게 유지한다(Guolin, 2017).

LightGBM은 연산 효율성과 메모리 사용량을 크게 개선하여 다양한 분야에서 활용 가능성이 높는데, 특히, 신속성, 대용량 데이터 처리 가능성, 경량성 덕분에 실시간 의사결정이 요구되는 재난관리 분야에서 활용도가 높다. 빠른 추론 속도와 낮은 연산량은 실시간 기상 관측자료 분석, 이상징후 감지, 조기 경보 등 다양한 데이터 기반 의사결정 지원에 활용 가능하다. 또한 대량의 지형·기상 등 정보를 바탕으로 산사태, 침수 등 재난 위험을 수치화하고 피해 규모를 예측하는 등 재난 발생 이전 단계에서 유용하게 활용할 수 있을 것으로 판단된다.

24) 예측 오차를 줄이기 위해 예측력이 낮은 모델을 반복적으로 학습시키며 기존 모델이 틀린 부분(잔차)을 다음 모델이 보완하도록 순차적으로 정교화하는 앙상블 머신러닝 기법. 높은 예측 성능을 가진 모델을 생성할 수 있으나, 학습 시간이 길고 확장성이 낮음.

4.2 실험 설계

4.2.1 실험 설명

가. 실험 방법

본 연구에서는 시각 정보가 불충분할 때 LightGBM 모델이 수치 데이터만으로 산사태 등 재난 위험 예측을 보완하는 도구로서 기능할 수 있는지 확인하기 위한 실험을 진행하였다. 먼저, LightGBM 모델에 산사태 위험에 영향을 줄 수 있는 변수 몇 가지를 조합하여 위험(=1), 정상(=0)의 라벨을 붙인 가상 시뮬레이션 데이터셋을 학습시킨 후, 모델이 학습한 기준에 따라 위험 라벨을 정확하게 예측할 수 있는지 기본 성능을 확인하는 실험을 진행했다. 예측 성능 결과와 정책 활용 가능성은 테스트 데이터 결과값 원본과 변수 중요도²⁵⁾(Feature Importance) 그래프, Accuracy, F1-score, ROC-AUC 평가 지표²⁶⁾를 통해 분석한다. 그 다음으로 데이터 종합분석 모델인 meta-GBM을 구상한다. 이는 앞서 실험한 YOLOv8이 시각 자료를 활용해 도출한 위험도와 LightGBM이 데이터 분석을 통해 도출한 위험도를 추출해 하나의 데이터 셋으로 제작하여 재난 위험도를 종합 판단하는 모델로, 단일 데이터로 판단하는 모델이 가지는 불완전성을 보완하고자 하는 구상이다.

25) Feature Importance (변수 중요도 분석): 입력 변수 중 모델 예측에 가장 크게 기여한 요인을 수치화하여 시각적으로 제시함으로써, 특정 재난 유형에서 어떤 환경 요소가 핵심적 역할을 하는지를 판단하는 데 활용

26) Accuracy (정확도): 전체 예측 중 정답의 비율로, 기본적인 성능 수준을 나타낸다.

F1-score: 클래스 간 불균형을 고려하여 예측 성능을 종합적으로 측정하는 지표로, 특히 위험 사례가 소수인 경우 유용하다.

ROC-AUC (Receiver Operating Characteristic - Area Under Curve): 모델의 분류 임계값 변화에 따른 민감도(Sensitivity)와 특이도(Specificity)의 균형을 종합적으로 평가하는 지표로, 0.5에 가까울수록 무작위 추측과 같고, 1.0에 가까울수록 성능이 우수함을 의미한다.

나. AI 기술(LightGBM) 활용 시 유용성

수치 데이터에 기반한 위험 예측은 엑셀과 같은 기존의 규칙 기반 도구로도 가능하다. 그러나 이러한 도구는 기준값 부근에서 단절적이고 비현실적인 결과를 도출²⁷⁾하며, 변수 별 중요도나 예외 상황 반영 등을 하지 못한다. 실제 재난 환경은 불완전성과 복잡성을 지니기 때문에 현실을 보다 정교하게 반영할 수 있는 유연한 도구의 도입이 필요하다.

앞서 살펴본 바와 같이 LightGBM은 여러 결정 트리를 결합해 데이터의 특성을 학습하는 트리 기반 머신러닝 모델이다. 데이터 경험을 통해 기준값을 포함한 다양한 규칙을 학습하기 때문에 기준값 부근에서도 단절적 기준에 따르지 않고 연속적·확률적 예측을 할 수 있다. 또한, 변수별 중요도를 자동으로 산출하고 데이터 전처리와 과적합 방지 등 최신 머신러닝 기법을 적용하여 오류를 보정하므로 예측 정확도가 높다. 다만, 규칙을 스스로 생성하기 때문에 사람이 해석하기 어려운 부분이 발생할 수 있다. 해석 불가능성은 결과의 신뢰성을 약화시킬 수 있으며, 결국 일반화나 정책화가 어려워질 수 있다. 이를 보완하기 위해 학습 데이터의 품질 관리는 물론이고, 연산 과정과 판단 근거를 시각적으로 보여주는 설명형 AI 도구(XAI: SHAP, LIME 등)를 활용하여 판단 근거를 시각화하는 방안도 활용할 필요가 있다. 아울러, 불완전한 예측 결과는 보조 수단으로 활용하고 전문가 피드백 등을 병행함으로써 실효성과 신뢰성을 함께 확보하는 것이 바람직하다.

요약하면, LightGBM은 재난 위험 예측에 있어 높은 성능과 유연성을 제공하지만, 결과의 안정성, 신뢰성 등의 측면에서 한계가 존재한다. 이러한 한계를 인지하고 적절한 보완책을 병행한다면 현장에서 유용한 보조 수단으로 활용할 수 있을 것으로 판단된다.

27) 단순히 기준값(30°) 기준으로 분류할 경우, 경사도 29.9°와 30.1°처럼 실제 차이가 미미함에도 기준값 인근에서 위험/정상으로 극단적으로 나뉘는 왜곡이 발생할 수 있다.

4.2.2 환경 설정

데이터 기반 위험 예측 실험은 LightGBM 4.0.0 라이브러리를 활용하여 구성하였다. Google Colab Pro 환경에서 Python 3.10 기반으로 진행하였으며, Colab Pro의 CPU 환경을 활용하여 모델의 학습과 평가를 신속하게 처리하도록 하였다.

<표 4-1> LightGBM 실험 수행 시 활용된 시스템 환경

실험 수행 플랫폼	Google Colab Pro (CPU환경)
프로그래밍 언어	Python 3.10
주요 라이브러리	LightGBM 4.0.0, scikit-learn

4.2.3 데이터 구성

학습용 데이터는 재난 위험 예측과 관련된 주요 변수 및 위험 여부를 수치로 표현하여 표 형식의 데이터 셋을 제작하여 사용하였다. 아직 국내에는 산사태 위험 판단을 위한 공식화된 통일적 기준이 존재하지 않는다. 다만, 선행 연구에 따르면, 경사도, 지형 형태, 지하수위, 강수량 등이 산사태 발생 가능성을 높이는 핵심 요인으로 분석되었으며, 특히 지형 및 지질학적 요인과 기상 요인이 산사태 발생에 중요한 역할을 하는 것으로 확인되었다(김정흠, 2024). 고도가 높을수록, 경사가 급할수록, 일정 시간 내 강수량이 많을수록(집중호우) 산사태 발생 위험이 증가하는 경향이 있다. 이에 본 연구는 고도(m), 경사도(°), 12시간 누적 강수량(mm)을 변수로 정하고, 이와 관련된 실제 사례에서 자주 언급된 수치를 참조하여 다음과 같이 임의로 변수별 기준값을 설정하였다.

- 산사태 위험 판단 기준: 다음 중 2개 이상에 해당하면 ‘위험’으로 라벨링
 - 고도 기준(0~1000m): 300m 이상
 - 경사도 기준(0~45°): 30도 이상
 - 강수량 기준(12시간 누적, 0~100mm): 80mm 이상

각 변수 별로 해당 범위 내에서 균등 분포로 수치를 입력하고, 위험 여부를 라벨링(위험=1, 정상=0)하였다. 이렇게 세 가지 변수 조합에 라벨링한 데이터 총 1,000개로 가상 시뮬레이션 학습 데이터 셋을 제작하였다.


4.3 데이터 기반 위험 예측 실험

가. 전범위 데이터 셋 테스트

앞서 설정한 기준에 따라 세 가지 변수에 해당 범위 내에서 균등 분포로 랜덤 추출한 수치 데이터를 입력하고, 위험 여부를 라벨링하여 총 1,000개의 데이터 셋을 제작하여 모델을 학습시켰다. 이후 전 범위에서 랜덤 추출한 수치 데이터로 테스트용 데이터 셋 100개를 별도 제작하였는데, 특별히 기준값 부근에서 모델의 예측 패턴 변화를 놓치지 않기 위해 100개 중 10개의 데이터 셋은 다음과 같이 세팅하였다.

- 변수 중 2개 이상을 다음의 범위(기준값 근처) 안에서 입력
 - 고도(기준값: 300m) : 295~305m 수치 랜덤 입력
 - 경사도(기준값: 30°) : 25~35° 수치 랜덤 입력
 - 강수량(기준값: 80mm) : 75~85mm 수치 랜덤 입력

한편, LightGBM은 예측에 반영할 변수 별 중요도도 학습한다. 산사태 발생의 실제 환경을 고려하여 고도보다 강수량과 경사도에 비중을 두고 판단하도록 학습을 진행한 결과, 변수 별 중요도인 Feature Importance 그래프는 <그림 4-1>과 같다.



<그림 4-1> LightGBM Feature Importance

이렇게 학습한 모델로 실험한 결과, 모델이 예측해 낸 위험 예측의 정확도는 97%였다. 100개 중 3개에서 예상 정답과 모델 예측이 달랐다는 의미이다. 그 외 성능지표인 Accuracy, F1-score, ROC-AUC는 다음과 같다.

<표 4-2> LightGBM 전범위 대상 실험결과 성능지표

지표	결과값	의미 분석
Accuracy	0.970	전체 100개 중 97개 정답
F1-score	0.949	Precision(정밀도=0.966), Recall(재현율=0.933)의 조화평균
ROC-AUC	0.996	1.0에 가까우므로 성능이 우수함을 의미

<그림 4-2>는 모델이 결과값을 도출한 테스트 데이터 셋 100개 중 일부이다. 빨간 박스 안에 정답과 다른 예측을 한 데이터 셋 3개가 들어있다. 이 중 5번과 6번 세트는 의도적으로 기준값 부근의 값으로 세팅했던 10%에 포함되어 있던 데이터로, 세 가지 변수 모두 기준값 부근에 있었다. 나머지 1개는 고도(76.97m)가 기준값(300mm)보다 현저히 낮았으나, 경사도(29.99°)가 기준값(30°) 부근이었고 강수량(95.98mm)이 기준값(80mm)보다 매우 높았다. 앞서 <그림 4-1> Feature Importance 에서 확인한 바와 같이 이 모델은 고도보다는 강수량과 경사도에 중요도를 두고 예측하도록 학습시켰는데, 이 점 때문에 경사도를 고려하여 이 데이터 셋을 정상(0)이 아닌 위험(1)으로 예측한 것이 아닐까 추측된다. AI모델의 기준값 학습과 판단에 관한 의문에 관한 해답에 접근하기 위해 다음으로는 기준값 근처에만 집중된 데이터로 추가 실험을 진행하였다.

연번	고도	경사도	강수량	정답 라벨	예측 라벨
1	672.702994	20.2614411	11.04318634	0	0
2	796.681397	43.0911457	28.91874463	1	1
3	250.467899	17.9565893	30.98068753	0	0
4	624.8741	37.7910723	24.99569464	1	1
5	303.773505	28.8940494	80.41760964	1	0
6	304.680658	25.6656473	81.48318007	1	0
7	76.9794671	29.9908371	95.98628027	0	1
8	571.745983	8.48432726	51.50056597	0	0
9	832.830377	30.2607224	53.55538149	1	1
10	906.08706	43.9653129	35.68859752	1	1
11	12.1567715	4.58518954	35.37891587	0	0

<그림 4-2> LightGBM 전범위 실험 중 정답과 다른 예측 데이터

나. 기준값 근처에 집중된 데이터 셋 테스트

전범위 테스트 때 적용한 기준값 부근 데이터 입력 원칙²⁸⁾에 따라 기준값 부근 값으로만 테스트 데이터 셋 100개를 제작하여 모델의 기준값 민감도를 확인하였다. 실험 결과, 예측 정확도는 전범위 데이터 셋 실험(97%)보다 더 낮은 87%였다. 이 결과를 통해 모델이 기준값 부근에서 확실히 유연하게 반응하고 있다는 것을 알 수 있었다. Accuracy, F1-score, ROC-AUC는 다음과 같다.

<표 4-3> LightGBM 기준값 근처 대상 실험결과 성능지표

지표	결과값	의미 분석
Accuracy	0.870	전체 100개 중 87개 정답
F1-score	0.863	Precision(정밀도=1.000), Recall(재현율=0.759)의 조화평균
ROC-AUC	0.945	1.0에 가까우므로 성능이 우수함을 의미. 기준값 근처 데이터 실험이 전범위 데이터 실험보다 낮음.

F1-score에 따르면, 모델이 위험으로 예측한 것은 모두 실제 위험이었고(Precision=1), 실제 위험 중에서 모델이 예측한 위험은 75.9% (Recall=0.759)인 것으로 보아 모델은 기준값 근처에서 위험이라는 판단을 매우 소극적으로 하고 있다고 판단된다. 본 결과로만 본다면, 지금 이 모델은 실제 위험 케이스를 15% 정도 놓칠 정도로 위험 판단을 쉽게 내리지 않는지만, 위험이라고 판단했다면 그 판단이 맞다.

다. 분석 및 평가

총 2단계의 실험을 통해 LightGBM은 입력 변수와 위험 라벨 간의 기준이 명확하게 정의되어 있을 때에는 정확한 분류를 할 수 있으나, 기준값 근처에서는 다소 유연한 판단을 내린다는 것을 알 수 있었다. 엑셀과 같은 기존의 규칙 기반 도구와

28) 고도, 강수량, 경도 중 2개 이상의 변수를 기준값 근처 구간(± 5)에 분포시킴

달리 AI모델은 학습을 통해 규칙과 기준을 스스로 만들기 때문에 기준값에서 예측값을 단절시키지 않는 모습을 보인다. 기준값 근처 데이터에 대한 민감도 변화는 모델의 판단 기준이 유연하게 작동할 수 있음을 보여주는 한편, 해당 구간에서 오분류 가능성에 대한 주의가 필요함을 시사한다. 이러한 특징을 활용하여 현실의 모호성과 불확실성을 충분히 반영한 양질의 학습 데이터를 구축하고 보다 현실을 잘 반영하는 모델을 설계한다면, 지금까지의 기계가 도출했던 왜곡된 예측값이 아닌 현실을 반영하는 예측값을 도출하는 모델을 만들 수 있을 것으로 판단된다.

4.4 통합 분석 예측 모델(meta-GBM) 구상

4.4.1. 배경 및 개념

재난 현장에는 시각적 정보(예: 사진, 그림)와 비시각적 정보(예: 지형, 기후 데이터 등)가 동시에 존재하며, 이 두 정보는 위험 판단에 상호 보완적으로 기여할 수 있다. 기존의 재난 예측 연구는 대체로 한 종류의 데이터에 의존하는 경향이 있었으나, 다양한 데이터 소스를 통합 분석하는 통합적 예측 구조를 개발하면 재난 상황에서 판단의 불완전성을 보완하는 방안으로 활용할 수 있다.

본 연구에서 제안하는 meta-GBM은 이러한 정보 종합 판단의 필요성에 기반한 예측 모델로, 시각 기반 모델에서 도출한 위험도(confidence score²⁹⁾, box count³⁰⁾ 등)와 데이터 기반 모델의 위험 예측 결과를 상위 레벨에서 종합 분석하는 구조이다. 이와 같은 통합 구조는 단일 데이터 기반 모델의 한계를 보완하고, 복합적 위험요인 간의 상호작용을 반영함으로써 재난 위험 판단의 신뢰성과 정확성을 동시에 제고할 수 있다는 점에서 우월성을 지닌다.

29) 탐지 박스 별로 박스 안의 객체가 실제 해당 객체일 확률을 수치로 제시하는 신뢰도 점수

30) 탐지된 위험 박스 수

4.4.2 작동 방식 및 효용성

가. 작동 방식

meta-GBM은 다음의 3단계 계층적 분석 과정을 통해 종합 위험도를 산출한다. 첫째, 시각 정보 탐지 모델로부터 도출된 위험도 판단값³¹⁾을 추출한다. 둘째, 고도·경사도·강수량 등 데이터로 LightGBM과 같은 모델을 통해 위험 예측 확률값을 도출한다. 셋째, meta-GBM이 두 단계에서 생성된 값을 종합 판단하여 최종 위험도를 산출한다. 이때 단순히 평균 산출이나 규칙 결합만 하는 것이 아니라, 각 변수 조합이 위험도 예측에 미치는 영향과 중요도를 데이터로부터 학습하여 복수의 예측 변수가 결합될 때 나타나는 비선형적·복합적 효과까지 통계적으로 최적화하는 머신러닝 앙상블 구조를 활용한다.

나. 효용성

meta-GBM은 다음과 같은 이유로 효용성이 있다. 첫째, 사람이 여러 전문가의 의견을 종합하여 판단하듯이 상위 기계가 여러 기계의 판단을 종합하여 판단하는 계층적 구조를 통해 보다 거시적이고 균형있는 판단이 가능하여 예측의 품질을 높일 수 있다. 둘째, 불완전한 단일 모델 각각의 오탐·미탐 등 한계를 상호 보완적으로 보정할 수 있다. 예를 들어, 수치 데이터 상 위험도가 낮아도 시각적으로 뚜렷한 붕괴 징후가 감지될 경우 최종 위험 신호를 낼 수 있으며, 반대로 시각 모델의 오탐을 수치 데이터로 걸러낼 수도 있다. 셋째, 설명형 XAI와 함께 활용하면 판단에 활용된 정보 및 그것이 최종 판단에 미친 기여도와 함께 판단의 과정까지 해석할

31) confidence score, box count 등

수 있어 결과 도출의 신뢰도를 높일 수 있다. 요약하자면, meta-GBM은 단일 모델 기반 위험 예측의 한계를 극복하고, 복합적 위험요인을 통합 판단할 수 있는 차세대 융합형 예측 모델로서 AI 기반 재난 예측·탐지의 전략적 발전 방향을 제시하는 초석이 될 것으로 기대된다.

4.5 종합 검토 및 시사점

본 장에서는 데이터 예측 AI 모델인 LightGBM을 활용해 비시각적 정보만으로 재난 위험 예측 가능성을 평가하고, 나아가 시각·비시각 정보를 통합하여 판단하는 meta-GBM 모델 구상을 통해 통합적 재난 위험 분석의 가능성을 모색하였다.

실험 결과, LightGBM은 구조화된 수치 데이터만으로도 재난 위험도를 효과적으로 예측할 수 있음을 확인하였다. 특히, 명확한 기준이 데이터에 반영되어 있을 경우, 기준값과 멀리 떨어진 데이터에 대한 예측은 정확했다. 반면, 기준값 인근의 데이터에 대해서는 다소 모호한 판단을 내렸는데, 이는 기존의 규칙 기반 도구와 달리 AI모델은 학습을 통해 규칙과 기준을 스스로 만들기 때문에 기준값에서 인위적으로 예측값을 단절시키지 않는 모습을 보인 것으로 추측된다. 이러한 특징은 기준값 근처에서 모델의 판단 기준이 유연하게 작동할 수 있음을 보여주는 동시에, 해당 구간에서의 오분류 가능성에 대한 주의가 필요함을 시사한다. 이러한 특징을 잘 활용한다면, 기존의 규칙 기반 도구와 달리 현실을 잘 반영하는 도구를 만들 수 있을 것이라고 생각된다. 이를 위해서는 현실의 모호성과 불확실성을 충분히 반영한 양질의 학습 데이터 구축이라는 선결 과제를 해결해야 한다.

본 연구에서 개념적으로 제안한 meta-GBM 모델은 시각 정보와 비시각 정보를 통합하여 최종적인 재난 위험도를 판단하는 상위 모델이다. 실제 재난 현장에서는 다양한 형태의 정보가 복합적으로 존재하며 상호 작용한다. 이러한 정보들을 종합

적으로 판단하는 상위 모델이 있다면, 단일 정보원에 의존할 때의 한계를 극복하고 보다 거시적이고 균형있는 판단으로 예측의 신뢰성과 정확도를 향상시킬 수 있을 것이다. 향후 meta-GBM 모델의 현장 적용을 위해서는 국내 주요 위험 지역과 과거 재난 발생 지역에서 재난 직전 위험 징후 사진과 당시 지형·기상 데이터를 수집·연계하여 병합형 데이터 셋을 구축할 필요가 있다. 이러한 데이터 셋을 활용해 시각·비시각 자료 대규모 데이터 학습을 수행하고, 실시간 GIS·기상 API 연계 및 XAI(설명 가능한 인공지능) 기반 해석 기능을 강화한다면, 재난관리 현장 및 정책 설계에 적용 가능한 통합 예측 모델로 발전시킬 수 있을 것이다.

meta-GBM은 적은 비용으로 비교적 쉽게 제작이 가능한 경량형 AI 기술들의 조합이기 때문에 상대적으로 정책 도입이 용이하다. 예를 들어, 당장이라도 데이터 셋을 구축하여 과인튜닝을 진행하고 meta-GBM을 제작한 뒤, 국민참여형 플랫폼(예: 안전신문고)에 도입하여 신고자가 동네의 불안해 보이는 현장 사진을 찍고 주소를 입력할 수 있는 ‘신고 도우미’ 섹션을 만들 수 있다. 사진과 주소를 종합판단하여 위험 분석 결과를 실시간으로 제공해 주면, 국민은 전문가의 도움 없이도 신속·정확하게 신고 여부를 판단할 수 있고, 보다 적극적으로 신고할 수 있다. 국민들의 신고 활성화로 인해 안전 사각지대가 줄어들 것이며, 불필요한 신고는 1차적으로 필터링이 되기 때문에 재난 인력과 자원 배분의 효율성을 높일 수 있다. 또한, 드론 촬영 자료와 정밀안전진단 데이터를 연계하여 산사태 위험 지역의 실시간 위험 예측을 지원하는 보조 도구로 활용할 수도 있다.

결론적으로, 본 장의 연구는 LightGBM과 같은 데이터 예측 AI 기술이 시각 정보가 부재하거나 제한적인 상황에서 재난 위험을 예측하는 데 유용한 도구임을 실증하였으며, meta-GBM이라는 통합적 접근을 통해 향후 AI 기반 재난 예측 및 탐지 시스템이 나아가야 할 방향을 제시하였다. 향후 이러한 개념을 실증하기 위한 노력과 함께 데이터 품질 관리, 모델의 해석 가능성 증진, 그리고 실제 정책에 도입을 위한 후속 연구가 필요할 것이다.

제5장 결 론

본 연구는 현대 재난의 복잡성과 불확실성에 대응하기 위한 혁신적 방안으로서 경량형 AI 기술의 재난 예측 및 탐지 분야 적용 가능성을 모색하고, 기술적·정책적 활용 방향을 제시하고자 하였다. 이를 위해 객체 탐지 AI 기술인 YOLOv8과 데이터 예측 AI 기술인 LightGBM을 중심으로 실험을 설계하고 수행하였으며, 나아가 이들 기술을 융합하는 meta-GBM이라는 통합적 접근 방식을 제안하였다.

주요 연구 결과를 요약하면 다음과 같다.

- 1) YOLOv8 사전학습 모델만으로는 재난 관련 객체를 탐지할 수 없으며, 재난에 특화된 데이터로 파인튜닝하는 과정이 필수적임을 확인하였다.
- 2) YOLOv8은 학습된 데이터에 대한 탐지 능력이 뛰어나고, 파인튜닝 시 학습 데이터 양을 적정 수준으로 증가시키면 탐지 능력이 향상된다.
- 3) YOLOv8은 산사태와 같이 시각적 특징이 분명한 ‘재난상황’ 이미지 뿐만 아니라, 벽균열과 같이 미세한 ‘재난징후’ 이미지에 대해서도 산사태와 비슷한 수준의 성능 지표를 보여줬다. 다만, 실제 사진 평가 시 벽균열 이미지 탐지 성능이 낮게 나오는 것을 고려해 보면, 시각적으로 불분명하고 난해한 재난징후 이미지 파인튜닝 시에는 학습 데이터 구성에 주의를 기울여야 할 것으로 판단된다.
- 4) 다중 재난 유형을 동시에 탐지하는 멀티클래스 모델은 구현 가능성이 있었으나, 개별 유형에 특화된 단일클래스 모델 대비 전반적인 성능 저하가 나타났다. 실제 정책에 활용 시에는 이를 고려하여 학습 데이터 구성 전략을 세워야 할 것으로 보인다.

- 5) LightGBM을 활용한 데이터 예측 실험 결과, 비시각적 정보만으로도 재난 위험 예측이 가능함을 입증하였다. 특히, 이 모델은 학습을 통해 기준을 만들고, 기준 값에 가까워질수록 유연하게 반응하는데, 현실을 반영하는 양질의 학습 데이터 셋을 학습시킨다면, 모델의 이러한 특징을 활용하여 현실을 잘 반영하는 모델을 설계할 수 있을 것이라고 판단된다.
- 6) 시각·비시각 정보를 종합 판단하는 meta-GBM을 구상하여 계층적 판단 구조로 단일 정보원의 한계를 극복하고 보다 신뢰성 있는 종합 판단 역량의 실현 가능성을 제시하였다. 현실 재난 상황의 복잡성을 고려할 때, 다차원적 통합 접근은 향후 AI 기반 재난 예측 및 탐지 시스템이 지향해야 할 방향으로 판단된다.

본 연구의 정책적 시사점을 요약하면 다음과 같다. 첫째, 경량형 AI 기술의 재난 관리 분야 활용 가능성을 검증함으로써 기존의 고비용·고성능 기술 중심 연구와 차별화하여 제한된 자원과 인프라 환경에서도 AI 기술 도입을 고려할 수 있는 가능성을 제시하였다. 둘째, 재난 예측·탐지 분야의 AI 기술 역량 확인 실험을 진행함으로써 그 동안 범위가 막연하고 준비가 어려웠던 재난 발생 이전 예방·대비 단계 추진의 돌파구를 제시하여 재난 관리의 패러다임을 사후 대응에서 사전 예측 및 예방 중심으로 전환하고자 하였다. 셋째, 기술 검증과 더불어 정책적 시사점 및 도입 시 고려사항을 함께 제시함으로써 학계의 연구가 실제 정책 현장 적용으로 이어지도록 하는 실용적 연구 방식에 초점을 맞췄다. 넷째, 단일 기술의 성능 평가를 넘어 향후 재난 예측·탐지 시스템 전반에 AI 기술 도입 자체의 필요성을 강조하고자 하였다.

본 연구에서 제시한 향후 연구 과제를 요약하면 다음과 같다.

- 1) 다양한 유형의 방대한 고품질 재난 데이터 셋을 구축하고, 이를 활용하여 AI 모델의 성능과 일반화 역량을 지속적으로 향상시켜야 한다.

- 2) meta-GBM과 같은 통합 모델의 실증 연구 및 구현을 통해 계층적 구조의 종합 분석 모델 도입의 효과를 정량적으로 검증해야 한다.
- 3) 스스로 규칙을 도출하는 LightGBM 모델의 불확실성을 보완하기 위하여 설명 가능한 XAI 기법과 병행하여 연산 과정을 밝히는 등 기술의 신뢰성과 정책적 수용성 제고 방안을 모색해야 한다.
- 4) 개발된 AI 기술이 실제 재난관리 시스템 및 현장 업무 프로세스와 효과적으로 연동될 수 있도록 실시간 운영 환경, 사용자 인터페이스, 법·제도적 정비 방안 등에 대한 심층적인 연구가 병행되어야 한다.

본 연구가 향후 AI 기반 재난 예측·탐지 기술의 발전과 활용 확대에 기여하고, 나아가 재난관리 체계를 개선하는 동력이 되어 궁극적으로 보다 안전한 대한민국을 건설해 나가는 데 이바지할 수 있기를 기대한다.

참 고 문 헌

- A. Vaswani., N. Shazeer., N. Parmar., J. Uszkoreit., L. Jones., A. N. Gomez., L. Kaiser., I. Polosukhin. (2017). Attention is all you need. *the 31st International Conference on Neural Information Processing Systems* (NIPS'17). <https://doi.org/10.48550/arXiv.1706.03762>
- D. Reis., J. Kupec., J. Hong., A. Daoudi., (2023). Real-Time Flying Object Detection with YOLOv8. *arXiv:2305.09972v2*.
<https://doi.org/10.48550/arXiv.2305.09972>
- Guolin Ke., Qi Meng., Thomas Finley., Taifeng Wang., Wei Chen., Weidong Ma., Qiwei Ye., Tie-Yan Liu., (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *31st Conference on Neural Information Processing Systems (NIPS 2017)*, pp.3149-3157
- J. Redmon., S. Divvala., R. Girshick, A. Farhadi., (2015). You Only Look Once: Unified, Real-Time Object Detection. *IEEE Conference on Computer Vision and Pattern Recognition*, pp.779-788.
<https://doi.org/10.48550/arXiv.1506.02640>
- Jin Zhang., Daniel Mucs., Ulf Norinder., Fredrik Svensson. (2019). LightGBM: An Effective and Scalable Algorithm for Prediction of Chemical Toxicity - Application to the Tox21 and Mutagenicity Data Sets. *Journal of Chemical Information and Modeling* v59.
<https://doi.org/10.1021/acs.jcim.9b00633>

- M. N. Sadik., T. Hossain., F. Sayeed. (2024). Real-Time Detection and Analysis of Vehicles and Pedestrians Using Deep Learning. arXiv:2404.08081v1. <https://doi.org/10.48550/arXiv.2404.08081>
- Qi Zheng., Chang Yu., Jin Cao., Yongshun Xu., Qianwen Xing., Yinxin Jin., (2024). Advanced Payment Security System: XGBoost, LightGBM and SMOTE Integrated. arXiv:2406.04658v3. <https://doi.org/10.48550/arXiv.2406.04658>
- R. Raina., A. Madhavan., A. Y. Ng., (2009). Large-scale deep unsupervised learning using graphics processors. *the 26th Annual International Conference on Machine Learning*, pp.873 - 880. <https://doi.org/10.1145/1553374.1553486>
- S. Ren., K. He., R. Girshick., Jian Sun., (2016). Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks. arXiv:1506.01497v3. <https://doi.org/10.48550/arXiv.1506.01497>
- Tanu Gupta., Sudip Roy., (2024). Applications of Artificial Intelligence in Disaster Management. *Proceedings of the 2024 10th International Conference on Computing and Artificial Intelligence*, pp.313-318. <https://doi.org/10.1145/3669754.366980>
- Wenjuan Sun., Paolo Bocchini., Brian D. Davison., (2020). Applications of artificial intelligence for disaster management. *Springer Nature B.V. 2020*. <https://dx.doi.org/10.1007/s11069-020-04124-3>
- 김정흠. (2024). 산사태 위험도 분석을 위한 영향인자에 관한 연구. *한국지반신소재 학회논문집*(2024.12.), pp.31-39. <https://doi.org/10.12814/jkgss.2024.23.4.031>

- 김준용. (2023). 객체탐지모델 YOLO의 버전별 특성 비교 연구. *한국컴퓨터정보학회 하계학술대회 논문집*(2023.7.) 제31권 2호, pp.75-78.
<https://www.koreascience.kr/article/CFKO202323672006229.page>
- 민대홍, 윤형구. (2021). 딥러닝을 활용한 산사태 결정론 방법의 활용성 고찰. *한국방재학회 논문집* 제21권 제5호, pp.203-211. <https://doi.org/10.9798/KOSHAM.2021.21.5.203>
- 박기준, 한정수, 황세웅, 지승한. (2023). 실시간 객체 검출 성능 평가에 대한 연구. *한국정보기술학회 추계 종합학술대회 논문집*(2023), pp.910-914.
<https://www.dbpia.co.kr/journal/articleDetail?nodeId=NODE11652231>
- 이용환, 김홍준. (2024). YOLO시리즈(v1에서 v11까지)와 응용 애플리케이션 분석 비교. *반도체디스플레이기술학회지* 제23권 제4호, pp.190-198.
<https://www.koreascience.kr/article/JAKO202403543203466.pdf>
- 이용환, 김영섭. (2020). 객체 검출을 위한 CNN과 YOLO 성능 비교 실험. *반도체디스플레이기술학회지* 제19권 제1호, pp.85-92.
<https://koreascience.kr/article/JAKO202011161035249.page?&lang=ko>
- 이정호, 전동산. (2020). 재난 현장 맞춤형 상황인식 기술 및 적용방안 연구. *차세대컨버전스정보서비스기술논문지* 제9권 제1호, pp.11-19.
<http://dx.doi.org/10.29056/jncist.2020.03.02>
- 이진수, 이상광, 김대욱, 홍승진, 양성일. (2018). 딥러닝 기반 객체 인식 기술 동향. *전자통신동향분석* 제33권 제4호, pp.23-32.
<https://doi.org/10.22648/ETRI.2018.J.330403>
- 최원상. (2020). 인공지능 기반의 지능형 재난안전관리체계구축에 관한 연구. *한국방재학회 논문집* 제20권 제1호, pp.127-140.
<https://doi.org/10.9798/KOSHAM.2020.20.1.127>

ABSTRACT

A Study on the Application of AI for Disaster Prediction and Detection

Yuri, Shim

Interdisciplinary Program for Crisis, Disaster and Risk Management

Sungkyunkwan University

This study examines the necessity of improving the current disaster management system in South Korea to effectively respond to an increasingly uncertain and complex disaster environment. As a viable alternative, this research proposes the application of Artificial Intelligence (AI) and aims to derive its practical effectiveness and policy implications. The study places a particular focus on enhancing prediction and pre-emptive response capabilities in the pre-disaster phase, conducting an experimental investigation centered on YOLOv8, an image-based object detection model, and LightGBM, a data-based prediction model.

In the image-based disaster detection experiments, it was confirmed that the pre-trained YOLOv8 model failed to detect disaster-related images, whereas detection capabilities were successfully generated through a fine-tuning process using disaster situation (landslide) images. The results also demonstrated that

increasing the fine-tuning data to an appropriate level enhances the model's overall performance, including detection accuracy and precision. Furthermore, fine-tuning was conducted for disaster signs (cracks), which are more minute and difficult to detect than landslides. The performance metrics were comparable to those of the landslide fine-tuning, indicating that the model can acquire detection capabilities for various disaster types. However, considering the performance degradation observed in tests with actual photographs compared to the landslide fine-tuning, it is judged that constructing high-quality training data with greater attention to detail is crucial when learning from visually ambiguous and complex disaster sign images. Additionally, a multi-class fine-tuning experiment, which involved simultaneously training on disaster situations (landslides) and disaster signs (cracks) to assess the model's ability to detect multiple disaster types concurrently, revealed a general degradation in performance compared to single-class models, with a more pronounced decline in the detection of minute crack images.

In the data-based disaster risk prediction experiments, it was confirmed that it is feasible to design a model that predicts disaster risk levels using only non-visual data such as altitude, slope, and precipitation with the LightGBM model. Notably, unlike conventional rule-based tools that artificially truncate predictions at threshold values, the AI model learns to flexibly handle ambiguity near these thresholds through data learning. It is therefore proposed that by leveraging this characteristic to build high-quality training data that reflects real-world conditions, it is possible to design a model capable of realistic disaster prediction. Finally, this study conceptually proposes meta-GBM, a higher-level model that comprehensively assesses disaster risk by integrating

predictions from both visual and non-visual information. This approach presents the potential for establishing a more sophisticated and reliable integrated risk assessment system that overcomes the limitations of single prediction models.

This research presents AI technology as a solution to shift the disaster management paradigm from post-disaster response to pre-disaster prevention. By verifying the applicability of lightweight AI technologies, which differentiates it from existing research focused on high-cost, high-performance technologies, this study suggests the feasibility of introducing AI even under limited resources and environmental constraints. In addition to technical verification, this work emphasizes a practical research approach that links academic findings to policy implementation by presenting policy considerations. Ultimately, it underscores the necessity of leveraging various AI technologies that can be introduced across the entire disaster management system, moving beyond the performance evaluation of a single technology. It is hoped that this study will contribute to the advancement of AI-based disaster management systems, thereby contributing to the construction of a safer Republic of Korea.

Keywords: Disaster Management, Artificial Intelligence(AI), Disaster Hazard Prediction, YOLOv8, LightGBM