



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

박사학위 논문

건설현장의 안전 확보를 위한 딥러닝
기반의 시스템비계 설치 이상감지 연구

A Study on the Deep Learning-Based Integrity
Assessment of System Scaffold Installations Ensuring
Safety at Construction Sites

명지대학교 대학원

재난안전학과학과간협동과정

이 기 수

지도교수 신 동 일

2024년 8월

건설현장의 안전 확보를 위한 딥러닝 기반의 시스템비계 설치 이상감지 연구

A Study on the Deep Learning-Based Integrity
Assessment of System Scaffold Installations Ensuring
Safety at Construction Sites

이 논문을 박사학위 논문으로 제출함.

2024년 8월

명지대학교 대학원
재난안전학과협동과정
이 기 수

건설현장의 안전 확보를 위한 딥러닝 기반의 시스템비계 설치 이상감지 연구

A Study on the Deep Learning-Based Integrity
Assessment of System Scaffold Installations Ensuring
Safety at Construction Sites

명지대학교 대학원
재난안전학과학과간협동과정
이 기 수

상기자의 재난안전학박사 학위논문을 인준함.

심사위원장 _____ 윤 현 덕 (인)

심 사 위 원 _____ 최 달 수 (인)

심 사 위 원 _____ 이 정 우 (인)

심 사 위 원 _____ 김 태 옥 (인)

심 사 위 원 _____ 신 동 일 (인)

2024년 8월

목 차

그림목차.....	iv
표 목 차.....	vii
국문초록.....	xi
제1장 서론	1
1.1. 연구배경	1
1.2. 연구 내용 및 목적	4
제2장 이론적 고찰	6
2.1 시스템비계	6
2.1.1 시스템비계의 특성	6
2.1.2 비계 관련 국내·외 기준	8
2.2 인공지능의 정의 및 분류	16
2.3.1 인공지능의 정의	16
2.3.2 기계학습의 종류	16
2.3.3 딥러닝의 종류	19
2.3 AI 기반의 객체 탐지	24
2.3.1 AI 기반의 객체 탐지 종류	24
2.3.2 YOLOv5의 구조	26
2.3.3 객체탐지 성능평가지표	31
2.4 선행연구와의 차별성	34
제3장 비계 설치의 적정성 판단 기준 분석	36
3.1 문제 정의	36

3.2 시스템비계의 재해사례 분석	36
3.2.1. 주요 사례	36
3.2.2. 시스템비계 이상감지 요구사항 분석	59
3.3 시스템비계 설치 관련 기준 분석	59
3.4 AI 판정 모델 개발을 위한 비계 설치의 적정성 판단 기준 선정	65
3.4.1 시스템비계 재해 유형 및 원인 분석에 바탕한 개발 시스템의 범위	65
3.4.2 설치 기준 분석에 바탕한 이미지 수집의 범위	65
제4장 비계 설치 적정성 판단 AI 시스템 설계 및 구현	69
4.1 이미지 분류 기반의 비계 설치 적정성 판단 모델 선정	69
4.1.1. 촬영 이미지의 지도학습 기반 분류	69
4.1.2. 객체 탐지 기반의 설치 적정성 판정	69
4.1.3. YOLO 기반 개발	71
4.2 시스템비계 설치 적정성 판단을 위한 YOLOv5 기반 모델링	73
4.2.1 데이터 수집 및 전처리	73
4.2.2 이미지 수집 및 크기 조정	75
4.2.3 데이터 labeling	75
4.2.4 학습 및 평가 데이터 분할	78
4.2.5 사용 데이터 및 YOLOv5 모델 학습 조건	78
4.3 모델 설계 및 개선	82
4.3.1 학습 데이터 양에 따른 성능 변화	82
4.3.2 YOLOv5 중 적정 모델 크기의 선정	85
4.3.3 모델 입력 이미지 크기의 설계	86
4.3.4 컬러 vs. 흑백 이미지에 따른 성능 검토	87
4.3.5 군집화 분석 및 편향 제거	90
4.3.6 데이터 증강	90
4.3.7 증강 이후의 데이터 분포	94
4.4 결과: 개발 SSCARF 시스템의 성능 평가 및 해석	97
4.4.1 사용 데이터 양에 따른 성능 변화	97

4.4.2 학습 횟수에 따른 성능 변화	98
4.4.3 분류 클래스별 성능 평가	100
4.5 개선사항 및 토의	103
4.6 객체탐지 기반의 시스템 건전성 판별 AI 구축 가이드라인	105
제5장 결론	110
참 고 문 헌	113
부 록	119
Abstract	131

그림 목 차

Fig. 1-1	Number of accidents and fatalities by industry.	1
Fig. 1-2	Status of construction industry accidents by specific causes related to buildings and structures	3
Fig. 2-1	System scaffolding	7
Fig. 2-2	BS EN 12811-1	9
Fig. 2-3	Angle of inclination between tubular standards and angle of inclination between a base jack and a tubular standard	10
Fig. 2-4	AS/NZS 1576	11
Fig. 2-5	OSHA 29 CFR Part 1926 Subpart L	13
Fig. 2-6	JIS A 8951	14
Fig. 2-7	Machine learning classification.	17
Fig. 2-8	Supervised learning.	18
Fig. 2-9	Unsupervised learning - clustering.	18
Fig. 2-10	Reinforcement learning	19
Fig. 2-11	Artificial neural network.	20
Fig. 2-12	Feedforward neural network.	21
Fig. 2-13	Recurrent neural network.	22
Fig. 2-14	Convolutional neural network.	22
Fig. 2-15	Flowchart of SIFT.	24
Fig. 2-16	Difference of gaussian(DOG)	25
Fig. 2-17	YOLOv5 architecture.	27
Fig. 2-18	Spatial pyramid pooling.	28
Fig. 2-19	PANet architecture.	29
Fig. 2-20	NMS(Non-maximum Suppression).	31
Fig. 2-21	Intersection over union (IoU).	33
Fig. 3-1	Construction Site Fall Hazard Inspection Results	65

Fig. 4-1	Classification/Classification+Localization/Object detection.	71
Fig. 4-2	A series of images capturing the same object from various perspectives.	74
Fig. 4-3	Labeling example.	76
Fig. 4-4	Distribution of data by class.	77
Fig. 4-5	Splitting data sets for deep learning model training.	78
Fig. 4-6	Design flowchart of SSCARF AI model	78
Fig. 4-7	Performance metrics of the first model.	80
Fig. 4-8	The results of training YOLOv5 with 461 images.	82
Fig. 4-9	YOLOv5 performance by size	84
Fig. 4-10	Performance by input data size.	85
Fig. 4-11	Comparison between gray-scale and color.	86
Fig. 4-12	The results of K-means clustering.	87
Fig. 4-13	Original image and rotated image.	89
Fig. 4-14	Original image and flipped image.	91
Fig. 4-15	Original image and noised image.	91
Fig. 4-16	Original image and gray scaled image.	92
Fig. 4-17	Original image and bounding box rotated image.	92
Fig. 4-18	Original image and image with noise added to bounding box.	93
Fig. 4-19	Original image and gray scale + noise insertion.	93
Fig. 4-20	Rotation of the entire image and bounding box, grayscale, noise insertion	95
Fig. 4-21	Rotation of the entire image and bounding box, grayscale, noise insertion.	95
Fig. 4-22	Distribution of YOLO data by label after augmentation.	96
Fig. 4-23	Performance by epoch	98
Fig. 4-24	Example of labeling data	99
Fig. 4-25	The prediction results of SSCARF	100
Fig. 4-26	Performance using the test dataset.	101
Fig. 4-27	Final results by class.	102
Fig. 4-28	Case of properly installed scaffolding platform connector.	102

Fig. 4-29 AI development guidelines for fault detection at construction sites. 106

표 목 차

Table 3-1 Case of scaffolding accident in Gangdong-gu, Seoul	38
Table 3-2 Case of scaffolding accident in Muan-gun, Jeollanam-do.	39
Table 3-3 Case of scaffolding accident in Yeongyang-gun, Gyeongsangbuk-do.	40
Table 3-4 Case of scaffolding accident in Seo-gu, Incheon.	41
Table 3-5 Case of scaffolding accident in Gwangsan-gu, Gwangju.	42
Table 3-6 Case of scaffolding accident in Haeundae-gu, Busan.	43
Table 3-7 Case of scaffolding accident in Boryeong-si, Chungcheongnam-do.	44
Table 3-8 Case of scaffolding accident in Jeju.	45
Table 3-9 Case of scaffolding accident in Anyang-si, Gyeonggi-do.	46
Table 3-10 Case of scaffolding accident in Mokpo-si, Jeollanam-do.	47
Table 3-11 Case of scaffolding accident in Dongjak-gu, Seoul.	48
Table 3-12 Case of scaffolding accident in Gyeyang-gu, Incheon.	49
Table 3-13 Case of scaffolding accident in Sasang-gu, Busan.	49
Table 3-14 Case of scaffolding accident in Namhae-gun, Gyeongsangnam-do.	50
Table 3-15 Case of scaffolding accident in Changwon-si, Gyeongsangnam-do.	51
Table 3-16 Case of scaffolding accident in Paju-si, Gyeonggi-do.	52
Table 3-17 Case of scaffolding accident in Cheongju-si, Chungcheongbuk-do.	53
Table 3-18 Case of scaffolding accident in Gyeongju-si, Gyeongsangbuk-do.	54
Table 3-19 Case of scaffolding accident in Guri-si, Gyeonggi-do.	55
Table 3-20 Case of scaffolding accident in Jungnang-gu, Seoul.	56
Table 3-21 Case of scaffolding accident in Gumi-si, Gyeongsangbuk-do.	57
Table 3-22 Case of scaffolding accident in Pyeongtaek-si, Gyeonggi-do.	58
Table 3-23 Key inspection points for system scaffolding.	62
Table 3-24 System scaffolding installation inspection checklist [53].	64
Table 3-25 Examples of problem causes and classification for system scaffolding.	68
Table 4-1 Comparison of object detection algorithms.	72
Table 4-2 Collection of image data by picture taking at construction sites.	74

Table 4-3 Data label for AI model development: 6 normals and 8 abnormals.	75
Table 4-4 The performance of the model according to the amount of data.	97
Table 4-5 Additional possible cases.	103
Table 4-6 Advantages and disadvantages of image collection methods	108

약 어 설 명

AI	Artificial Intelligenc
ANN	Artificial Neural Network
AP	Average Precision
AUC	Area Under the Curve
CNN	Convolutioncal Neural Network
CSPN	Cross Statge Partial Network
DNN	Deep Neural Network
FN	False Negatives
FNN	Feedforward Neural Network
FP	False Positives
GRU	Gated Recurrent Unit
HOG	Histogram of Oriented Gradients
IoU	Intersection over Union
LSTM	Long Short-Term Memory
MAP	Mean Average Precision
MSE	Mean Squared Error
NLP	Natural Language Process
NMS	Non-maximum Suppression
OSHA	Occupational Safety and Health Administration
PAN	Path Aggregation Network
R-CNN	Region-based convolution neural networ
ReLU	Rectified linear unit
RNN	Recurrent Neural Network
RPN	Region Proposal Network

SIFT	Scale-Invariant Feature Transform
SPP	Spatial Pyramid Pooling
SSCARF	System SCaffold AI for Risk Forecasting
SVM	Support Vector Machine
TP	True Positives
YOLO	You Only Look Once

건설현장의 안전 확보를 위한 딥러닝 기반의 시스템비계 설치 이상감지 연구

이 기 수

명지대학교 대학원 재난안전학과간협동과정

지도교수 신 동 일

건설현장에서의 안전은 작업자들의 생명과 건설 프로젝트의 성공에 직접적으로 영향을 미치는 중요한 요소이다. 따라서 지속적 모니터링을 통해 안전한 작업환경을 보장하는 것은 건설업에서 발생하는 사고로 인한 인적·물적 피해를 감소시키는 것뿐 아니라 작업자들의 생산성을 향상시킬 수 있기 때문에 건설현장에서의 안전에 대한 중요성은 더욱 중대되고 있다. 건설업 현장에서 시스템비계는 고소공간에서의 안전한 작업환경을 조성하기 위한 필수적인 가설재로, 적절하게 설치되면 작업자들이 안전하게 이동하며 효율적으로 작업할 수 있으나, 정상적으로 설치되지 않거나 유지되지 않는 경우에는 추락과 같은 위험이 발생할 가능성이 높다.

본 연구는 AI 기반의 시스템비계의 설치 적정성 판단 시스템 SSCARF를 설계하고 구현해, 설치의 무결성 관리 측면에서 발생하는 인적 오류를 줄이고, 궁극적으로 사고 발생을 감소시켜 건설현장에서의 안전을 확보하고자 하였다. 이를 위해서 여러 시스템비계 가설재 중에서 고정핀, 밀받침철물, 벽이음, 수평재, 발판의 5종 자재에 대해 설치 적정성을 판단하고자 하였다. 이때, 각각의 자재는 정상적으로 설치된 경우, 정확히 설치되어있지 않은 경우, 연결되지 않은 경우, 겹쳐서 설치된 경우 등 14개로 분류하여 라벨링을 수행하였으며, 건설현장에서 직접 촬영한 데이터를 활용하였다. AI 모델은 자재가 정확하게 설치되었는가를 분류하기 위하여 객체탐지 알고리즘인 YOLOv5를 채택하였다.

모델링 과정에서는 YOLO 기반 모델에서 많이 사용되는 mAP를 성능평가지표로 채택하였으며, 라벨링은 Roboflow의 라벨링 툴을 활용하여 수행하였다. 최초의 모델은 200장의 비계 이미지 데이터를 사용하였으며, 그 결과, 정확도가 mAP 18.6%로 낮은 성능을 보였다. 따라서 모델의 성능을 개선시키기 위해 데이터의 수를 461장으로 증가

시켰으며 그 결과 mAP 60.4%로 성능이 개선됨을 확인하였으나, 역시 현장에 적용하기에는 적합하지 않음을 확인하였다. 따라서 최종 모델에서는 데이터를 증강하였으며, 후백 처리, 좌우 반전 등 다양한 방식을 적용하여 411장의 학습 데이터를 1,233장으로 증가시켜 모델을 학습시킨 결과 80.8%의 우수한 성능을 보였으며, 이를 통해 설치된 학습 데이터를 적절히 보완할 경우 모델의 정확도도 향상되는 것을 확인할 수 있었다.

본 연구에서는 개발 모델을 5종의 자재에 대해서만 설치 적정성을 판단하였으나, 더 많은 자재와 다양한 형태에 대한 설치 적정성을 판단하기 위한 추가 연구가 필요할 것으로 보인다. 또한 발판, 수평재 등이 설치가 되어있지 않은 경우에는 학습이 이루어지지 않는 경향이 있어 이에 대한 데이터의 보완 또는 모델의 수정이 필요할 것으로 판단된다.

본 연구에서는 사람이 직접 관리하여 인적 오류가 발생하기 쉬운 비계의 설치 및 유지관리 과정에 이미지 감지 및 분류 AI 모델을 적용하여 인적오류를 감소시키고 최종적으로 건설현장의 안정성을 확보할 수 있는 딥러닝 기반의 비계 설치 적정성 판단 시스템을 제안하였다. 모델 개발과정에서 데이터가 추가될수록 모델의 성능이 향상됨을 확인하였으며, 라벨링 되어있지 않은 데이터 역시 비교적 정확하게 감지해낼 수 있었다. 따라서 추후 보완을 통해 실질적으로 현장에 적용할 경우에는 비계를 사용하는 건설현장의 안전을 확보할 수 있을 것으로 기대된다.

주제어(키워드)

건설안전, 이상감지, 머신러닝, 시스템비계, 가설구조물, 설치 적정성, 이미지 분류

제1장 서론

1.1. 연구배경

어떤 산업현장보다 시공간적 변화가 심한 건설현장에서의 안전은 작업자들의 직접적인 안전은 물론이고 주변 환경에의 영향과 더불어 건설 프로젝트의 성공을 좌우한다. 특히, 시간에 따라 변화하는 복잡한 건설현장은 높은 곳에서의 작업이 또한 잦기 때문에, 추락사고 및 다른 위험에 노출될 수 있는 위험성이 높다. 실제로 Fig. 1-1과 같이 2022년 기준 국내 산업현장에서 발생한 사고사망자 중 53%가 건설업 종사자였으며, 이 중 대다수는 추락이 그 원인이었다[46].




Fig. 1-1 Number of accidents and fatalities by industry [46].

건설현장에는 안전한 작업환경을 조성하고 작업자들의 안전을 보장하기 위한 다양한 시설 및 장치가 필요하다. 특히 비계는 건설현장에서 안전한 작업 플랫폼을 제공하여 낙하사고를 예방하고 작업자의 이동을 용이하게 하는 등 고소공간에서의 작업을 보다 안전하게 수행할 수 있도록 돕는 장치로 이러한 안전문제에 대한 해결책의 핵심 중 하나이다. 그러나, 현재 비계의 설치(설치상 오류는 대형사고로 이어질 수 있으나 이상 빈도는 상대적으로 낮음) 및 사용중 이상의 감지나 건전성(integrity) 확보는 사람

이 수작업으로 수행하고 있으며, 이에 따라 관련자의 숙련도에 따라 필연적인 인적 오류가 발생하고 있다.

인적오류 및 사용중 변형으로 인해 부적절하게 설치되거나 유지되고 있는 비계는 오히려 작업환경을 위험하게 만들 수 있으며, 이로 인해 작업자들의 안전을 위협할 뿐만 아니라 건설 프로젝트를 방해하는 중대 요소가 될 수 있다. 실제로 3년 동안(2020~2022년) 발생한 추락사고 사망자 중 36.3%가 비계 등 가시설과 관련된 사고에서 발생하였으며, Fig. 1-2에서 확인할 수 있듯이 건축·구조물 관련 사고 중 비계 관련 비율이 가장 높음을 확인할 수 있다. 이를 통해 건설현장에서 비계의 건전성 상실로 인해 발생할 수 있는 안전문제의 심각성을 확인할 수 있다[47].

건설현장에 설치되어 사용중인 비계의 적절성을 판단하는 것은 다음의 여러 가지 요인으로 인해 어려울 수 있다:

- 다양한 비계 유형 및 용도: 건설현장에서는 종종 다양한 유형의 비계를 사용하며, 각 비계는 고유한 설계, 용도 및 최대 하중 용량을 가지고 있다. 이러한 다양성으로 인해 적절성 평가에 대한 일률적인 접근 방식을 확립하기가 어렵다.
- 현장별 특정 조건: 건설현장은 비계 안전에 영향을 미치는 독특한 환경 및 운영 조건을 제공할 수 있다. 불평坦한 지형, 장애물 또는 악천후 노출과 같은 요인은 특정 비계의 안정성 및 적합성에 영향을 미칠 수 있다.
- 동적 하중 및 가변적인 사용: 건설현장의 비계는 종종 동적 하중을 받게 되는데, 이는 작업자가 상하 이동하거나 자재를 운반할 때 비계에 가해지는 무게 분포와 힘이 지속적으로 변하는 것을 의미한다. 이러한 동적인 특성으로 인해 실제 현장 조건에서 비계의 적절성을 정확하게 평가하기 어려울 수 있다.
- 제한된 검사 도구 및 절차: 비계에 대한 표준화된 검사 지침과 체크리스트가 있지만, 이러한 방법은 건설현장 사용의 복잡성과 발생 가능한 위험을 완전히 파악하지 못할 수도 있다.
- 인적 요인 및 비규정 준수: 인적 오류 및 안전 절차 불이행은 비계 안전에 큰 영향을 미칠 수 있다. 비계를 잘못 배치하거나 최대 하중을 초과하거나 잘못된 유형의 비계를 사용하면 비계 자체가 적절하더라도 사고로 이어질 수 있다.
- 위험 평가 정량화의 어려움: 비계의 적절성을 평가하는 데는 종종 주관적인 판단과 불확실성이 따른다. 특정 맥락에서 특정 비계와 관련된 위험을 정량화하는

것은 특히 건설 작업의 동적인 특성을 고려할 때 어려울 수 있다.

- 규제 격차 및 집행: 비계 안전을 규제하는 규정과 표준이 있지만, 집행 및 준수는 다를 수 있으며 잠재적인 위험이 발견되지 않을 수 있는 여지를 남긴다.




Fig. 1-2 Status of construction industry accidents by specific causes related to buildings and structures [47]

작업자들에게 안전한 작업현장을 마련해 주기 위해 비계를 사용하지만 적절하게 설치되지 않은 비계는 추락사고 등 작업자의 생명과 직결되는 문제의 원인이 되기도 한다. 따라서 이러한 안전문제를 예방하기 위해 국내에서는 산업안전보건기준에 관한 규칙으로 비계 설치에 관해 규정하고 있으며[65], 가설공사 표준안전 작업지침을 통해 작업상의 안전에 관하여 규정하고 있다. 또한, 유해위험작업 취업제한에 관한 규칙, 국가기술자격법, 근로자직업능력 개발법 등을 통해 안전한 비계 설치, 해체 및 운용을 목표로 하고 있다.

하지만 인적 오류와 더불어 현장 및 기상환경에 따른 실시간 이상감지의 어려움으로 인해 이러한 규정이 있음에도 불구하고 비계 관련 사고는 끊임없이 발생하고 있기에, 본 연구에서는 작업시간의 제약과 환경의 영향에서 자유로우며, 향후 쌓여져가는 현장 빅데이터의 지속적 학습을 통해 성능 개선이 가능한 AI 기반의 시스템비계 설치

적정성 판단 시스템을 제안 및 구축하고자 한다. 이를 통해 시스템비계의 설치 또는 설치된 비계의 운용 단계에서의 다양한 오류로 인한 비정상 설치를 감지하여, 건설현장에서 비계의 안전성 제고는 물론이고 현장의 안전토대 강화를 지원하고자 한다.

1.2. 연구 내용 및 목적

본 연구에서는 건설현장에서 실제 적용되고 있는 시스템비계를 대상으로 설치 적정성을 실시간으로 판단해주는 AI 시스템을 개발하고자 한다. 이를 통해 건설현장에서 시스템비계 설치 및 운용시 발생할 수 있는 인적 오류를 포함한 다양한 오류나 이상 발생의 조기 감지를 통해 사고를 줄이고자 하며, 궁극적으로 건설현장에서 비계가 원인이 되어 발생하는 추락사고 등의 인적 피해와 건설 프로젝트의 중단 등으로 발생할 수 있는 물적 피해를 감소시키고자 한다.

AI 기반 설치적정성 판단 시스템을 개발하기 위해 관련 사례 및 규정 연구와 더불어 시스템을 설계, 구현, 검증하는 실증연구를 수행하였다. 시스템비계 관련 법령과 설치기준, 작업자들이 안전하게 작업하기 위한 작업환경에 관련한 자료를 분석하였으며, 이를 본 연구의 이론적 배경으로 삼았다. 실증연구 단계에서는 문헌기반 연구에서 성립된 비계 설치의 적정성에 대한 기준을 이용하여 AI 모델 개발을 수행하며, 1) 적정성 판정을 위한 직접 데이터 측정방법과 간접 이미지 기반 판정의 비교분석을 통해 이미지 분류 기반의 AI 시스템 개발로 연구의 방향을 설정한다. 시스템 설계 및 구현 과정에서는 2) 현장 수집 이미지의 라벨링과 더불어 이미지 데이터의 체계적 확보 방법을 검토하고, 3) 분류 방법 등 적절한 기계학습 방법의 선정, 4) 그리고 구현 측면에서 이미지 분류를 지원하는 다양한 모델의 장단점 분석을 통해 YOLOv5 기반의 시스템 개발 등을 분석한다. 5) 이후 개발 시스템의 성능 평가 및 현장 활용 방안 등을 제시한다.

실시간 시스템비계 설치 이상감지 및 건전성 판별 AI 모델의 개발을 위해 실제 건설현장에서 시스템비계를 촬영하여 (빅)데이터를 확보하며, 비계 설치의 적정성 기준에 따라 정상 설치와 비정상 설치에 대한 라벨링 방법을 제안한다. 라벨링 단계에서는 Roboflow 등을 활용해, 전체 이미지 중 판단의 기준이 되는 부분을 박스 형태로 지정하여, 정상, 비정상 등 어떤 라벨에 속하는지 정의한다. YOLOv5 모델링 과정에서는 데이터의 전처리를 수행하며, 모델의 학습단계에서는 학습 횟수, 해상도, 모델 복잡도 등 최

적 파라미터 설정을 제안하고, 학습 결과를 이용하여 파라미터의 최적화를 진행한다. 특히 모델 개발 과정에서 데이터 수량이 부족하다 판단되어 추가적인 데이터 확보와 데이터 증강을 통해 학습 데이터를 충분한 양으로 증가시켜 최종 모델의 성능 개선을 제안한다.

본 연구의 개발 시스템은 연구 과정에서 선택한 수작업 기반의 이미지 수집에 그치지 않고, 개발 이후에는 드론 및 로봇에 탑재해 운용도 가능한 형태이다. 따라서 향후 무인 자율 기반 건설현장의 스마트안전 체계로의 발전에 대해서도 그 단초를 제공하고자 한다. 이를 통해 현장의 안전 토대를 보장하는 비계를 포함한 설비들의 실시간 자동 이상감지와 건전성 판별에 기초해, 보다 안전하고 효율적인 건설현장의 확보와 더불어 건설산업의 지속가능성 향상에도 기여할 수 있을 것으로 기대된다.

제2장 이론적 고찰

2.1 시스템비계

2.1.1 시스템비계의 특성

비계는 건설현장에서 지상 혹은 바닥에서 작업자의 손이 닿지 않는 곳의 작업을 지원하기 위해 설치되는 것으로, 작업대와 작업통로 두 가지를 주된 목적으로 하는 건설 현장 내 가설구조물을 의미한다[43]. 이러한 비계는 고소작업 중 안전을 보장하기 위하여 설치되는 구조물이므로 안전성뿐만 아니라 작업성, 경제성 또한 중요한 요건이다.

비계의 안전성은 파괴, 도괴, 흔들림, 추락, 낙하물에 대한 안전성을 의미하며, 작업성은 작업자가 현장에서 작업하는 도중 방해가 없음을 의미한다. 작업성을 확보하기 위해서는 작업대의 넓이, 작업 및 통행에 방해가 없는 구조로 이루어져야 하며, 작업 시 피로가 누적될 수 있는 무리한 자세가 유지되지 않도록 하여야 한다. 경제성은 설치와 철거가 신속, 용이하며 현장에서의 추가가공이 불필요하고, 내용 연수가 높은 재료의 사용하는 것을 의미한다.

건설현장에서 사용되는 비계는 크게 조립식 비계와 이동식 비계로 분류할 수 있는데, 조립식 비계에는 강관비계와 시스템비계가 포함되며, 이동식 비계는 틀비계, 말비계, 달비계, 달대비계 등으로 구분할 수 있다[3]. 이 중 본 연구는 설치 적정성을 판단할 수 있는 조립식 비계에 관해 집중하였으며, 조립식 비계 중에서도 구조적으로 안전성이 확보될 수 있어 최근 현장에서 널리 사용되는 시스템비계에 대해 연구를 수행하였다.

시스템비계는 Fig. 2-1과 같이 각각의 부자재를 공장에서 제작한 후 현장에서 직접 조립하는 조립식 비계를 의미하며, 강관비계와 비교했을 때 비계의 설치와 해체가 용이하고, 강도가 높아 안전성 측면에서 우수하다고 평가된다. 시스템비계는 표준화된 부품으로 구성되어, 설치 및 해체가 간편하다[22]. 시스템비계는 각각의 부자재를 공장에서 제작한 후 현장에서 직접 조립하는 조립식 비계로 각 자재가 모듈화되어 설치 및 해체가 용이하다는 장점을 갖고 있다[34]. 이러한 모듈성은 비계를 다양한 구조와 크기로 조립할 수 있게 해주어, 사용자의 요구에 유연하게 대응할 수 있다. 또한, 시스

템비계는 강철, 알루미늄과 같은 재료로 제작되었고, 미리 설계되어 제작되기 때문에 특정 하중과 환경을 견딜 수 있어 보다 더 높은 하중에도 견딜 수 있는 안정성과 안전성을 확보하고 있으며, 이는 작업자에게 안전한 작업환경을 제공하는데 기여한다.



Fig. 2-1 System scaffolding.

시스템비계의 유연성은 다양한 높이와 너비 조정을 가능하게 하여 복잡한 건축 환경에 적합하며, 이는 특히 기존 구조물의 보수 작업에 유용하다. 경제적인 측면에서도 시스템비계는 재사용 가능한 부품을 사용함으로써 여러 프로젝트에 걸쳐 장기간 사용할 수 있으며, 이는 비용 절감에 크게 기여한다. 마지막으로, 표준화된 부품과 간단한 조립 방식은 건설현장에서의 작업 속도를 향상시키고 프로젝트의 전반적인 효율성을 증가시키는 데 도움을 준다. 이러한 특성들은 시스템비계를 많은 건설 프로젝트에서 선호되는 선택지로 만든다.

시스템비계는 수직재, 수평재, 연결 조인트, 받침철물, 가새, 벽 연결철물 등 다양한 자재로 구성되기 때문에 설치과정에서 가장 먼저 설치 전 구조 안전성에 대한 검토를 진행하여야 하며, 이후 조립도를 따라 설치하여야 한다. 또한 조립시 작업발판, 가설통로 및 안전난간 등을 한번에 설치할 수 있고, 안전대 또한 착용한 후 작업할 수 있기

에 기존 지주식 비계인 강관비계에 비하여 추락재해의 가능성을 감소시킬 수 있다. 시스템비계는 강관비계보다 단가가 약간 높으나 설치가 편리하고 강도가 높으며 안전성이 우수하다고 판단되어 최근에 건설현장에서 많이 사용되고 있다.

2.1.2 비계 관련 국내·외 기준

시스템비계 관련 기준으로는 산업안전보건기준에 관한 규칙에 규정되어있으며, 구체적으로 제69조에 ‘비계 밑단의 수직재와 받침철물은 밀착되도록 설치’, ‘수평재는 수직재와 직각으로 설치하여야 하며, 체결 후 흔들림이 없도록 견고하게 설치할 것’으로 정의되어 있으며, ‘수직재와 수직재의 연결철물은 이탈되지 않도록 견고한 구조로 할 것’으로 규정되어있다[65]. 또한, 밑받침철물 사용 시, 시스템비계가 항상 수평 및 수직을 유지하여야 한다. 그 외에 KOSHA Guide 시스템비계 안전작업 지침에서 받침철물, 가새, 수평재, 작업발판, 수직재, 벽이음, 접합부, 연결조인트, 방호망에 대해 규정하고 있다[52]. 또한, 작업발판의 경우 KOSHA GUIDE C-08-2015 작업발판설치 및 사용안전 지침에서 추가로 준수사항을 제시하고 있으며[50], 벽이음, 철물 매립 방법은 KOSHA GUIDE C-69-2012 이동식 크레인 안전보건 작업지침을 따르도록 한다[53].

건설기술 진흥법 제55조(건설공사의 품질관리)[61], 건설기술 진흥법 시행령 제89조(품질관리계획 등의 수립 대상 공사)[59], 건설공사 품질관리 업무지침에서 품질시험 가설 기자재로 조립형 비계에 대해 품질시험 및 검사를 시행할 것을 규정하고 있다. 또한 가설구조물 설계 관련 법령으로 건설기술 진흥법 제48조(설계도서의 작성 등) 제5항[60], 건설기술 진흥법 시행령 제75조의2(설계의 안전성 검토)[58], 건설기술 진흥법 시행령 제101조의29 가설구조물의 구조적 안전성 검토)가 있으며[57], 상세하게는 KDS 21 60 00에서 비계 및 안전시설물 설계기준이 있다[63]. 가설구조물의 시공 관련 규정은 가설공사 표준시방서(KCS 21 00 00)가 있으며[70], KCS 21 60 05에서 비계공사 일반사항, KCS 21 60 10에서 비계, KCS 21 60 15에서 작업발판 및 통로에 관해 규정하고 있다. 가설구조물 점검은 건설기술 진흥법 제62조 제1항에서 건설공사의 안전관리에 관해 규정하고 있으며[62], 그 시기와 방법은 건설기술 진흥법 시행령 제100조 제1항에서 규정하고 있다[56].

비계 관련한 해외의 표준으로는 Fig. 2-2의 유럽의 BS EN 12811-1이 있다[6]. 건설

현장에서의 임시 작업용 구조물, 특히 비계에 관한 유럽 표준으로 비계 시스템의 설계, 설치 및 안전성에 관한 기준을 정하며, 비계가 설치되고 사용되는 동안의 최소 안전 요구사항과 성능 기준을 제시하고 있다. 특히 시스템비계 관련하여, 특정한 하중 조건 하에서의 성능 기준을 충족해야 하며, 사람과 장비의 무게를 포함하여 최대 하중에 관해 규정하고 있다. 비계의 각 부분에 대하여 강도, 안정성 및 견고성에 관한 규정과 모든 연결부위가 단단하게 고정되어 있어야 한다고 요구하고 있다.

또한 설치 전, 사용 중, 해체 전의 안전 검사에 대한 절차와 시스템비계의 구조 및 설계에 대한 상세한 지침을 제공하고 있다. BS EN 12811-1에 따르면 모든 수직 구조물들이 수직으로 설치되었는지 확인하여야 하며, 받침철물이 제대로 하중을 받고 있으며, 압력이 균등하게 분포될 수 있는지 즉, 사각형 형태의 받침철물이 바닥에 밀착되어 있는지를 확인하여야 한다. 또한 바닥판의 면적이 150 cm^2 이상이어야 하며, 폭은 120 mm 이상이어야 한다. 또한 베이스잭(Base Jacks)은 수직 조정이 가능하며, 중앙에 위치한 조정 스피들(spindle)을 포함하여야 한다. 베이스잭의 중첩 길이는 Fig. 2-3와 같이 조정 위치에서 최소 25% 또는 150 mm를 유지해야하며, 끝판의 두께는 최소 6 mm 이상이어야 한다.

비계의 안전난간은 작업면으로부터 최소 1미터 높이에 설치되어야 하며, 발판은 최소 150 mm의 높이여야 한다. 발판과 안전난간 사이 또는 안전난간 간 간격은 최대 470 mm 이하여야 하며, 이를 통해 작업자나 도구가 빠져나가는 것을 방지한다. 발판과 안전난간은 모두 갑작스러운 충격에 의해 분리되지 않도록 확실히 고정되어야 함을 규정하고 있다.



Fig. 2-2 BS EN 12811-1




Fig. 2-3 Angle of inclination between tubular standards and angle of inclination between a base jack and a tubular standard [6].

Fig. 2-4의 AS/NZS 1576은 호주와 뉴질랜드에서의 비계의 설계, 설치 및 해체 작업에 대한 요구사항을 정의하고 있으며, 비계의 구조적 안전성과 안전 작업 실행을 보장하기 위한 기준을 제시하고 있다[2]. AS/NZS 1576 역시 설계 및 세부 사항에 대한 지침을 설정하고 있으며, 비계의 재료와 부품에 대해 강도 및 내구성 기준을 제시하고 있다. 또한 설치, 해체 관련 프로세스에 대해 안전하게 수행할 수 있도록 가이드라인을 제시하고 있다.

세부 부품에 관한 규정을 살펴보자면 AS/NZS 1576에서는 수직 구조물(standards)와 수평재(transoms, ledgers)가 정확하게 수직 및 수평으로 설치될 것을 요구하며, 이를 통해 수직재, 수평재의 설치 적정성을 판단한다. 연결부에 해당하는 핀, 클립, 볼트 등의 모든 결합요소가 느슨하지 않게 제 위치에 있는지 확인할 것을 요구한다. 또한 비계의 기반인 기초판(base plates)과 조절나사(adjustable base jacks)가 제대로 설치되어 하중을 균등하게 분배받을 수 있도록 해야 AS/NZS 1576의 기준을 준수할 수 있다. 또한 비계 주변의 장애물이 없도록 불필요한 재료나 도구를 정리하여야 하며, 부식 및 손상에 대한 점검 역시 강조하고 있다.



Fig. 2-4 AS/NZS 1576

Fig. 2-5의 미국 Occupational Safety and Health Administration (OSHA)의 비계 관련 규정은 주로 29 CFR Part 1926 Subpart L에 명시되어 있으며, 설계, 설치 및 사용 중인 비계에 대한 요구사항을 정의한다[1]. 일반 요구사항(1926.451)에서 비계가 최소하중의

4배 이상을 견딜 수 있도록 요구하고 있다. 또한 설치, 조정, 해체 과정에서 전문적인 감독하에 작업이 수행되어야 하며, 해당 작업에 관련한 전문적인 교육과 지침을 제공할 것을 규정하고 있다. 접근 및 이용 (1926.452)에서는 비계에 안전하게 접근할 수 있는 계단 또는 사다리의 사용에 관해 규정하고 있다.

하중 요구사항 (1926.453)에서는 설계 시 고려된 최대하중을 견뎌야 하며, 최대하중은 사용 중인 재료뿐만 아니라 장비 및 인원의 무게까지 포함하는 것을 의미한다. 또한 비계에 가해지는 하중 분포는 균일해야 하며, 과적하에 대한 안전 조치가 마련할 것을 규정한다. 낙하 방지 및 보호 장비 (1926.454)에서는 작업 고도가 일정 높이 이상일 경우 낙하 방지 시스템이나 안전벨트와 같은 개인 보호 장비를 사용을 요구하고 있다. 또한 비계 주변에 낙하 물질을 막을 수 있는 가드레일, 안전망 등의 안전 설비가 설치에 관해 규정하고 있다. 훈련 요구사항 (1926.454)에는 비계를 사용하는 모든 작업자에 비계 설치, 조작, 유지 보수 및 해체 작업에 대해 적절한 훈련을 제공할 것을 요구하며, 이 훈련은 비계의 종류, 예상되는 위험, 조작 절차 등을 포괄해야 한다.

세부 부품에 대한 29 CFR Part 1926 Subpart L의 규정에는 수직재, 수평재, 가새재가 안정적으로 흔들리지 않게 고정되어야 함을 요구하고 있다. 또한 가드레일과 발판을 갖추고 있을 것을 요구하며, 가드레일은 최소 25 cm에서 최대 114 cm 사이로 설치되어야 하며, 발판은 반드시 플랫폼 길이 전체를 덮어야 함을 강조한다. 위의 기준들과 마찬가지로 비계의 기초는 평평한 표면에 견고하게 설치되며, 설치 시 최대하중을 넘지 않고 하중이 고루 분산될 수 있도록 하여야 한다고 규정한다. 또한 부식 및 손상, 작업환경의 청결 및 정리 상태 등 눈으로 알아보기 쉬운 것을 정기적으로 검사할 것을 요구하고 있다.



Fig. 2-5 OSHA 29 CFR Part 1926 Subpart L

일본에서는 주로 일본산업규격(JIS: Japanese Industrial Standards)에서 비계 관련 표준을 규정하고 있다[18]. Fig. 2-6의 JIS A 8951: "Scaffolds - Performance requirements and general design"에서는 비계의 성능 요구사항과 일반 설계원칙을 다루고 있다. 비계가 지탱할 수 있는 최대 하중, 강도, 내구성 등에 대해 규정하고 있으며 환경적 요인에 따른 영향을 최소화하도록 하고 있다. 또한 연결 부위에 대해 언급한다.




Fig. 2-6 JIS A 8951

JIS A 8952: "Temporary works equipment - Load bearing towers of prefabricated components - Particular methods of structural design"에서는 임시 구조물인 비계에 사용되는 사전 제작된 부품으로 구성된 하중 지지 타워의 구조 설계에 대해 설계, 제조, 설치 및 안전성 평가에 대한 구체적인 지침을 제공한다. JIS A 8953: "Temporary works equipment - Part 1: Scaffolds - Performance requirements and general design"은 임시 작업 설비 중 특히 비계의 성능 요구사항과 일반적인 설계원칙에 대해 자세히 설명한다. 또한 문서화와 작업자 교육까지 포괄적인 지침을 제공하고 있다.

JIS A 8953은 하중 용량, 안전성, 내구성과 관련된 성능 기준에 대해 언급하고 있으며, 내후성, 부식 저항성 등의 특성을 요구한다. 또한 일반 설계원칙으로 비계 설계 시 고려해야 하는 안전성, 접근성 및 사용 편의성에 대해 언급하고 있으며, 모든 설계가 사용될 환경과 작업 조건에 적합하여 가능한 모든 위험을 최소화하는 것을 목적으로

한다. 비계의 구성 요소 간 호환성을 보장하고, 쉬운 조립 및 해체를 가능하게 하는 설계를 요구한다.

JIS 8951에서는 비계의 각 부품에 대한 기준이 있으며, 구조적 안정성, 기초 안전성, 안전장치, 부하 용량, 손상 및 부식, 청결 및 정리상태에 관해 규정하고 있다. 구조적 안정성에서는 수직 및 수평재가 수직으로 잘 설치되어있는지를 확인할 것을 요구한다. 또한 연결부의 모든 부품이 안전하게 체결되었는지를 확인하여야 한다. 기초 안정성에서는 기초가 단단하고 평평한 표면에 단단히 고정되어야 하며, base jack이 적절하게 조절되어 모든 부하가 고르게 분포할 수 있도록 하여야 한다. 가드레일 높이는 최소 1m 이상을 요구하며, 발판은 최소 150 mm 이상일 것을 요구하고 있다.

2.2 인공지능의 정의 및 분류

기존 전문가의 지식과 수작업에 의존해온 설치 비계의 적절성 판정을 많은 비계 설치 및 운용 사례를 학습한 AI로 대체하려는 것이 본 연구의 목적이다. 따라서 본 절에서는 관련 AI 기술에 대해 분석하였다.

2.3.1 인공지능의 정의

인공지능(artificial intelligence, AI)은 인간의 지능적인 행위를 모방할 수 있는 시스템 또는 기계를 만드는 기술 분야로, 1956년 존 매카시에 의해 처음 소개된 이래, 전통적인 symbolic AI 중 하나인 규칙기반 시스템에서부터 데이터 기반의 학습 능력을 갖춘 machine learning 시스템까지 발전해왔다[31]. 초기 인공지능은 단순한 패턴 인식과 논리 기반의 추론에 초점을 맞췄으나 현재 다양한 분야에서 적용되고 있다[21].

자연어처리(natural language process, NLP)는 텍스트와 음성 데이터를 처리하여 기계가 사람의 언어를 이해할 수 있게 만드는 기술이며, 기계 번역, 감정 분석, 음성 인식, 챗봇 등의 형태로 응용되고 있다. 기계학습은 데이터로부터 패턴을 학습하여 예측이나 결정을 내릴 수 있는 모델을 생성할 수 있으며, 금융분야의 사기탐지, 의료 분야의 질병 진단, 추천시스템, 이미지 분류 등의 형태로 응용되고 있다.

본 연구의 바탕이 되는 컴퓨터 비전은 이미지나 비디오에서 유용한 정보를 자동으로 추출하고 해석하는 기술로, 안면 인식, 객체탐지, 자율주행 차량, 감시 카메라 등의 분야에 응용되고 있다. 본 연구 제안 시스템이 현장 활용 측면에서 향후 확대될 로봇틱스 분야는 물리적 로봇을 설계, 구성, 운영하여 인간을 대신해 작업할 수 있도록 만드는 것이며 제조업, 의료, 탐사 등의 분야에서 응용되고 있다.

2.3.2 기계학습의 종류

기계학습(Machine Learning)은 AI의 한 분야로 컴퓨터가 입력된 데이터를 학습하거나, 패턴을 인식하는 경험을 통해 성능이 개선될 수 있는 알고리즘, 기술을 연구한다 [14]. 기존 전문가의 직접 개발에 의존한 규칙기반의 프로그래밍 방식이 아닌 데이터 기반의 모델링이 가능해졌으며, Fig. 2-7과 같이 크게 지도학습, 비지도 학습, 강화학습으로 구분할 수 있다.




Fig. 2-7 Machine learning classification.

지도학습은 입력과 입력에 상응하는 출력 예시를 통해 함수를 학습하는 형태(universal function approximator)이다[4]. 즉, Fig. 2-8와 같이 학습 단계에서 문제와 답을 알려주어 문제에 맞는 함수를 도출하고, 학습하지 않은 새로운 문제가 주어졌을 때 답을 맞히는 형태이다. 지도학습의 대표적인 알고리즘으로 선형/로지스틱 회귀, Decision tree, Random forest, Gradient boosting, Support Vector Machine 등이 있다.

지도학습 방식으로는 보통 회귀와 분류 문제를 해결할 수 있으며, 회귀는 변수들 사이의 관계를 수량화하고, 새로운 데이터에 대해 예측을 가능하게 하는 모델링 기법이고, 분류는 데이터를 미리 정의된 범주로 나누는 것을 가능하게 하는 모델링 기법이다. 회귀는 연속적인 값을 예측하며, 주로 실수 형태로 출력하며, 분류는 이산적인 클래스 레이블을 예측하며, 카테고리형의 변수를 출력한다: 시스템 설계 단계에서 논의되듯이 본 연구의 제안시스템은 분류를 기반으로 한다. 회귀는 결정 계수 (R^2) 또는 평균 제곱 오차(MSE: Mean Squared Error)형태로 그 성능을 평가하며, 분류는 정확도, 정밀도, 재현율, F1 score 등의 지표를 사용하여 성능을 평가한다[45].




Fig. 2-8 Supervised learning.

비지도 학습은 Fig. 2-9과 같이 레이블이 지정되지 않은 입력 데이터로부터 데이터의 구조 또는 패턴을 발견하거나 유용한 정보를 추출하는 학습 방법이다[16]. 이때 지도학습과는 달리 입력 데이터만 주어지고 정답이나 레이블이 주어지지 않아, 라벨링이 어려운 대규모 데이터셋에 유용한 방식이다.




Fig. 2-9 Unsupervised learning - clustering.

K-means, 계층적 군집화, DBSCAN 등 군집화 알고리즘과 주성분분석, t-SNE, 오토 인코더 등 차원축소 알고리즘이 대표적인 비지도학습 알고리즘으로, 군집화는 비슷한 특성을 가진 데이터를 그룹화하는 알고리즘으로, 고객 세분화, 유전자 분류, 소셜 네트워크 분석 등에 응용되고 있다. 차원축소는 데이터의 중요 특징은 유지하면서 변수의 수를 줄이는 방식으로, 고차원 데이터를 처리할 때 차원의 저주를 완화하고 데이터 시각화가 필요한 경우에 사용되고 있다. 데이터의 시각화, 센서 등에서 입력되는 데이터

의 노이즈 제거, 데이터 저장 및 계산 분야에서 널리 사용되고 있다.

강화학습은 Fig. 2-10과 같이 에이전트, 환경, 상태, 행동, 보상, 정책의 기본 요소가 있으며, 에이전트가 환경과 상호작용하며 보상을 최대화하는 방법을 학습하는 방식이다[24]. 에이전트는 학습을 수행하는 주체로 행동을 결정하고 실행하며, 환경은 에이전트가 상호작용하는 가상의 세계로 에이전트의 행동에 반응하여 상태를 변경하고 보상을 제공한다. 상태는 환경의 현재 상태를 의미하며, 에이전트가 의사 결정을 하기 위해 참고할 수 있는 정보를 제공하며, 행동은 에이전트가 선택할 수 있는 모든 가능한 행동의 집합이다. 보상은 에이전트의 특정 행동에 대한 환경의 피드백으로 에이전트는 이 보상을 최대화하고자 하며, 정책은 에이전트의 의사결정 전략을 의미한다. 즉, 주어진 상태에서 어떤 행동을 취할지를 결정하는 규칙이다. 강화학습은 게임, 로봇틱스, 자동화, 금융, 자율주행차 제어 시스템 등의 분야에서 널리 사용된다.




Fig. 2-10 Reinforcement learning.

2.3.3 딥러닝의 종류

딥러닝(deep learning)은 기계학습의 한 분야이며, 인간의 뇌가 정보를 처리하는 방식을 모방하여 설계되었다[14]. 딥러닝 모델은 여러 개의 층(layer)을 통해 데이터에서 고차원의 복잡한 패턴을 학습할 수 있으며, 이를 통해 이미지 인식, 음성처리, 자연어처리 등 다양하고 복잡한 문제를 해결할 수 있다.

딥러닝의 핵심 구조는 다층 퍼셉트론으로 데이터를 입력하는 입력층, 입력층이나 또 다른 은닉층에서 받은 입력에 대해 가중치를 곱하고 편향을 더한 후 활성화 함수

를 적용하는 연산을 수행하는 여러 층의 은닉층, 최종 결과를 도출하는 출력층으로 구성된다[15]. 여기서 여러 층의 은닉층을 쌓는 것을 심층신경망(deep neural network, DNN)라고 부르며, 이를 통해 복잡한 데이터 형태나 비선형 문제의 해결이 가능하게 된다.

ANN(artificial neural network)는 Fig. 2-11와 같이 딥러닝의 가장 기초적인 구조로 모든 형태의 인공신경망을 포괄하는 개념이다. 뉴런이라 불리는 여러 노드들이 연결된 다양한 계층(Layer)이 존재하며, 계층의 여러 노드들에서 데이터를 입력받아 처리하여 출력을 생성할 수 있다[26]. 각 계층은 서로 연결되어 있으며, 연결에는 가중치가 부여되는데, 신경망의 학습과정은 이 가중치를 조정할 수 있으며, 이 과정에서 역전파(backpropagation)과 경사하강법(gradient descent) 등의 알고리즘이 사용된다[26]. ANN은 이 학습과정을 통해 복잡한 함수를 모델링하거나 패턴을 학습할 수 있도록 설계되었다.




Fig. 2-11 Artificial neural network.

Feedforward neural network (FNN)는 간단한 형태의 인공신경망으로 Fig. 2-12와 같이 데이터가 입력층에서 출력층으로 단방향으로만 전달되는 구조이다[13]. 일반적으로 하나 이상의 은닉층을 포함하고 있으며, 각 층은 fully connected layer 또는 dense layer로 구성된다. 대부분의 FNN은 지도학습 기법을 사용하며, 역전파 알고리즘을 사용하여 가중치를 최적화한다.




Fig. 2-12 Feedforward neural network.

Recurrent neural network (RNN)는 시간적 연속성을 지닌 데이터를 다루는데 적합한 구조로, 자연어처리, 음성 인식, 시계열 예측 분야에 널리 사용된다[8]. FNN과 달리 RNN은 Fig. 2-13과 같이 신경망 구조 내부에서 루프를 포함하여 과거의 정보를 저장하고, 이를 새로운 입력 데이터와 결합하여, 시간에 따라 변화하는 데이터의 패턴을 인식하고 예측할 수 있다. RNN은 시퀀스 데이터가 입력되는 입력층, 이전 시간 단계의 출력과 현재 시간 단계의 입력을 처리하는 순환 층, 순환 층의 출력을 바탕으로 최종 결과를 생성하는 출력층으로 구성되어있다.

RNN은 장기 의존성이 가장 큰 한계점으로 여겨지는데, 장기 의존성은 순환 층의 연산이 반복되면서 초기 시간 단계의 중요정보가 손실되는 경우를 의미한다. 이러한 장기 의존성 문제를 해결하기 위해 등장한 것이 long short-term memory (LSTM)과

gated recurrent unit (GRU)이다. 두 모델은 게이트 메커니즘을 도입하여 각 시간 스텝에서 어떤 정보를 유지하고 버릴지를 결정하여, 중요한 정보는 여러 시간 스텝을 거치더라도 유지할 수 있도록 하여 장기 의존성 문제를 해소하였다.




Fig. 2-13 Recurrent neural network.

Convolutional neural network (CNN)는 주로 이미지, 비디오 인식, 분류, 객체탐지 등의 분야에서 사용되며, 시각적인 데이터에서 유용한 특징을 추출할 수 있다[26]. Fig. 2-14에서 확인할 수 있듯이 CNN은 합성곱 계층에서의 연산 고정을 통해 이미지를 처리하는데 입력 이미지의 작은 영역을 슬라이딩 윈도우 방식으로 처리한다.




Fig. 2-14 Convolutional neural network.

이 계층에서는 여러 개의 필터를 이용하여 이미지의 지역적 특징을 감지하고 입력 데이터에 대해 합성곱 연산을 수행하여 입력 이미지의 특징을 활성화하는 특징 맵

(feature map)을 생성한다. 이후 풀링 계층(pooling layer)에서 특징 맵의 크기를 줄이면서 주요 특징을 유지한다. 이를 통해 계산량을 줄이고 과적합을 방지할 수 있다. 마지막으로 fully connected layer에서 모든 특징 맵을 평탄화하여 단일 벡터로 변환한다. 이 벡터는 최종적으로 분류 또는 회귀 결과값을 생성하게 된다.

CNN은 입력 이미지를 받아 각 합성곱 및 풀링 레이어를 통과시키면서 점점 더 추상적인 이미지 표현을 생성한다. 각 레이어는 학습 가능한 필터와 활성화 함수를 사용하여 이미지에서 유의미한 특징을 추출하고, 이러한 특징은 최종적으로 분류 또는 회귀 결과를 출력하기 위해 사용된다. CNN은 뛰어난 성능과 범용성으로 현대 컴퓨터 비전 연구와 응용의 핵심요소로 여겨지고 있다.

2.3 AI 기반의 객체 탐지

2.3.1 AI 기반의 객체 탐지 종류

본 연구 제안시스템이 입력값으로 사용하고자 하는 정지된 이미지 또는 동영상에서 객체의 위치를 식별하고 분류하는 객체 탐지는 컴퓨터 비전 분야에서 가장 중요한 문제 중 하나로 2010년대 초반 컴퓨터 비전 분야의 급격한 발전을 했다. 2010년 이전에는 전통적인 컴퓨터 비전 기법인 Fig. 2-15의 Scale-Invariant Feature Transform (SIFT), Histogram of Oriented Gradients (HOG)와 같은 feature extraction 또는 Support Vector Machine (SVM)과 같은 머신러닝 분류기가 주로 사용되었다.




Fig. 2-15 Flowchart of SIFT.

SIFT는 이미지에서 특징점(feature points)을 추출하여, 이미지의 크기(scale), 회전(rotation), 조명 변화에도 불구하고 일관된 방식으로 해당 특징점을 인식할 수 있게 하는 알고리즘으로, SIFT는 객체 인식, 이미지 스티칭, 3D 모델링, 모션 추적 등 다양한 컴퓨터 비전 응용 분야에서 널리 사용된다. SIFT는 다음과 같은 주요 단계를 통해 이미지의 특징을 추출한다[30]:

- Scale-space Extrema Detection : Fig. 2-16과 같이 이미지에서 다양한 스케일에서 특징점 후보를 찾기 위해 가우시안 차이(Difference of Gaussian, DoG)를 이용하여 스케일 공간을 생성
- Keypoint Localization : 후보들 중에서 불안정한 저대비 특징점이나 엣지에 위치한 특징점을 제거하여 정확한 특징점의 위치를 결정
- Orientation Assignment : 각 특징점에 방향을 할당하여, 이미지의 회전에 대해 불변인 특성을 부여

- **Keypoint Descriptor** : 각 특징점 주변의 이미지 영역의 방향 히스토그램을 사용하여, 특징점을 설명하는 벡터를 생성. 이 벡터는 변환에 대해 불변이며, 이미지 간의 매칭에 사용




Fig. 2-16 Difference of Gaussian.

HOG는 이미지의 지역적인 그래디언트 방향과 크기 정보를 이용하여 이미지의 특징을 기술하는 방법으로 주로 사람이나 차량 같은 객체의 검출에 사용된다. HOG는 다음과 같은 과정을 통해 특징을 추출한다[10]:

- **Gradient Computation** : 이미지의 각 픽셀에서 X와 Y 방향의 그래디언트를 계산하는데, 이는 이미지의 지역적인 구조 정보를 포착하는데 사용
- **Orientation Binning** : 계산된 그래디언트를 기반으로, 이미지를 작은 지역(셀)로 나누고, 각 셀에 대해 그래디언트 방향의 히스토그램을 계산함. 각 히스토그램은 해당 셀의 그래디언트 구조를 기술
- **Normalization** : 셀의 히스토그램을 블록(여러 셀의 그룹) 단위로 정규화하여 조명 변화에 대한 강인성을 확보
- **Feature Descriptor** : 모든 블록의 정규화된 히스토그램을 연결하여, 이미지 전체의 HOG 특징 기술자를 형성

2012년 이후 CNN 기반의 모델인 AlexNet의 등장으로 딥러닝 모델이 이미지 분류에

서 큰 성공을 거두게 되었고, 이로 인해 컴퓨터 비전 분야에서 딥러닝 알고리즘이 널리 사용되기 시작했다[25]. CNN은 1980년대부터 제안되었던 개념으로 이미지에서 특징을 추출하는 합성곱 층에서 필터를 사용하여 이미지를 작은 영역별로 구분하고, 합성곱 연산을 수행하여 이를 이용해 특징 맵(feature map)을 생성한다. 이후 ReLU (Rectified linear unit) 등의 활성화 함수 단계를 거쳐 비선형성을 도입하고 복잡한 패턴을 학습할 수 있도록 한 다음, 풀링층을 통해 특징 맵의 크기를 줄여 데이터의 공간적 크기를 감소시키면서 동시에 중요한 정보(feature)를 유지할 수 있도록한다. 이 과정을 통해 이미지에서 가장 중요한 정보를 추출할 수 있으며, 마지막 완전연결층(Fully connected layer)에서 추출된 특징을 이용하여 분류 또는 예측을 수행한다. AlexNet은 이러한 CNN 기반의 모델로 1998년에 개발된 LeNet 등 기존의 CNN 모델보다 훨씬 깊은 구조로 구성되어 있으며, ReLU, 드롭아웃, GPU를 이용한 훈련 등 혁신적인 기술을 도입하여 이미지 분류 문제에 뛰어난 성능을 보였다.

이후 CNN 기반의 객체탐지 알고리즘이 꾸준히 개발되었고 R-CNN이 2014년에 등장했다[11]. Region-based convolution neural network의 줄임말로, 이미지 내에서 객체의 위치를 탐지하고 분류하는데 사용된다. R-CNN은 이미지의 특정 영역을 후보 영역으로 제안하고, 해당 영역에서 CNN을 사용하여 객체를 탐지하고 분류하는 방식으로 기존의 객체탐지 기법보다 훨씬 좋은 성능을 보였으나, 계산비용이 높다는 단점 또한 존재했다. 이를 보완하기 위해 2015년 Fast R-CNN이 등장하였으며, ROI 풀링 기법을 통해 후보 영역을 보다 효율적으로 생성하였다[12]. 같은 해 Faster R-CNN이 Region proposal network (RPN) 방식을 사용하여 네트워크 내에서 객체 후보 영역을 생성하는 보다 효율적인 방식을 도입해 R-CNN의 단점인 계산비용을 단축할 수 있었다[39].

2016년 You only look once (YOLO)가 소개되었으며, 이전의 R-CNN 계열의 알고리즘보다 빠른 연산속도를 보여 실시간 객체 탐지를 가능하게 했다. YOLO는 전체 이미지를 나누어, 이미지의 각 부분에서 특정 객체의 경계 및 클래스를 동시에 예측할 수 있게 하였다[38]. 즉, YOLO는 R-CNN 계열 알고리즘이 수행했었던 객체 후보 영역을 지정하지 않고 한 번에 전체 이미지를 처리하기 때문에, 기존 방식보다 연산과정을 줄일 수 있었고 이를 통해 계산 속도 면에서 매우 효율적인 알고리즘이다[36].

2.3.2 YOLOv5의 구조

YOLOv5의 구조는 Fig. 2-17과 같다[21]. 객체 탐지를 위한 이미지는 백본 네트워크로 입력되며, 이 단계에서는 특징(feature)을 추출하는 데 사용된다. Bottleneck CSP는 병목(Bottleneck) 구조를 가진 블록들과 CSPNet (Cross Stage Partial Network)의 아이디어를 결합한 것이다. 병목 구조는 적은 수의 필터를 사용하여 정보를 압축하고 확장하는 것을 반복함으로써, 모델의 용량을 효율적으로 사용하면서도 중요한 특징을 추출한다. 이러한 구조는 더 깊고 복잡한 모델을 가능하게 하면서도, 모델의 크기를 불필요하게 늘리지 않아 필요한 계산량을 감소시켜 효율적인 모델 설계가 가능하도록 한다.

CSP는 네트워크의 일부분을 두 경로로 분할한 다음, 하나의 경로에서 특징을 추출하고 다른 경로를 통해 원래의 특징을 유지한다. 이렇게 함으로써, 두 경로 간의 그래디언트 흐름과 특징의 전파를 최적화하여, 효율적으로 신경망을 훈련시킬 수 있도록 한다: 깊은 층으로 그래디언트 값을 효과적으로 전달하여, 그래디언트 소실(gradient vanishing) 또는 그래디언트 폭발(gradient exploding) 문제를 완화시킨다. (그래디언트 소실은 오류 신호가 네트워크의 층을 거슬러 올라갈수록 점차 약해져, 입력층에 가까운 층의 가중치가 충분히 업데이트되지 않는 문제이며, 그래디언트 폭발은 그래디언트가 네트워크를 거슬러 올라갈수록 값이 기하급수적으로 커지는 현상을 말한다.)




Fig. 2-17 YOLOv5 architecture.

CSPNet은 앞서 언급하였듯이 네트워크를 부분적으로 분할하여 각 경로에서 특징을

별도로 처리한 뒤 다시 합치는 방식을 채택하였기에, 각 레이어에서의 특징 추출 및 통합 과정에서 발생할 수 있는 그래디언트 관련 문제를 완화할 수 있다. 즉 Bottleneck CSP 구조는 병목 구조를 통해 계산량을 감소시키고, CSP 구조를 통해 네트워크의 깊은 부분으로의 그래디언트 흐름을 개선하여 더 깊은 계층을 쌓아 효과적인 학습을 가능하게 한다. 이러한 구조를 통해 YOLOv5는 빠른 속도로 고해상도의 입력 이미지를 처리할 수 있으면서도 높은 정확도를 유지할 수 있게 한다.

백본 단계의 끝에서는 Fig. 2-18과 같은 Spatial Pyramid Pooling (SPP)을 사용하여 고정된 크기의 출력을 생성하여 신경망이 다양한 크기의 입력 이미지를 처리할 수 있도록 해주는 역할을 한다. 따라서 입력 이미지의 크기와 관계없이 신경망의 나머지 부분이 일관된 형식의 데이터를 받을 수 있으며, 학습 및 추론 과정에서 유연성이 증가하게 한다. 또한 여러 크기의 풀링 윈도우를 사용함으로써, 작은 물체부터 큰 물체에 이르기까지 다양한 스케일의 컨텍스트 정보를 추출하고 보존할 수 있으며, 입력 이미지의 크기에 상관없이 고정된 크기의 특징 벡터를 출력하기 때문에, 신경망의 뒤쪽 계층으로 들어가는 데이터의 크기를 예측할 수 있어 효율적인 연산이 가능하다.




Fig. 2-18 Spatial pyramid pooling.

YOLOv5에서 SPP 레이어는 백본 네트워크의 뒤쪽에 배치되어, 최종적으로 다양한 크기와 비율의 객체를 포함하는 이미지에 대한 높은 수준의 추상화를 달성할 수 있도록 하여, 모델이 크기 변화에 강건하게 만들어주고, 특히 다양한 스케일의 객체를 포

합하는 복잡한 장면에서 객체를 정확하게 탐지하게 한다. 즉, SPP는 고정된 차원의 출력을 보장하고 다양한 스케일의 정보를 포착할 수 있게 하여, 신경망이 더욱 다양한 시나리오와 환경에서 효과적으로 작동할 수 있도록 도와주는 도구이다. YOLOv5의 두 번째 단계 Neck에서는 Fig. 2-19와 같이 Path aggregation network (PANet) 구조가 적용된다. PANet은 백본 단계에서 추출된 다양한 수준의 특징을 통합하는데 사용된다[29].




Fig. 2-19 PANet architecture.

YOLOv5에서 PANet은 다운샘플링된 특징 맵에서 정보를 업샘플링하고 이전 레이어의 특징 맵과 결합하는데 이 과정을 통해 네트워크의 다른 깊이에서 온 정보를 통합하여, 물체의 고해상도 특징을 보존할 수 있다. BottleneckCSP 블록은 백본 단계와 마찬가지로 깊은 특징과 얕은 특징을 모두 포함하며, 통합된 특징 맵은 공간적 정확도와 컨텍스트 정보를 결합한다. 또한 PANet은 네트워크 내에서 여러 단계에 걸쳐 Skip Connection을 사용하여 정보의 손실을 최소화하고, 특징 맵의 정보를 최대한 활용하여 더 깊은 층으로부터의 정보와 얕은 층의 위치 정보를 결합할 수 있게 한다.

위와 같은 과정을 통해 여러 스케일에서의 특징을 통합함으로써 모델이 다양한 크기의 객체를 효과적으로 탐지할 수 있게 하며, 이미지 내에서 서로 다른 크기로 존재하는 객체들을 인식할 수 있도록 한다. 또한 특징 맵의 통합은 모델이 위치와 맞추고자 하는 클래스에 대한 예측 성능을 향상시킬 수 있으며, 각 스케일에서 특징을 통합하면서 세부적인 정보를 최대한 보존하여 미세한 패턴까지 인식하고, 작은 객체까지 탐지할 수 있게 한다. YOLOv5 네트워크의 Neck의 PANet은 모델이 고성능을 유지할 수 있도록 하는 핵심요소이며, 다양한 크기의 객체를 정확하고 빠르게 탐지할 수 있도록 한다.

최종 단계인 탐지 레이어는 이미지 내의 객체들에 대한 구체적인 예측을 수행하며, 모델이 다양한 크기의 객체를 탐지할 수 있도록 여러 스케일에서 작동한다. 이 단계는 PANet 단계에서 통합된 특징 맵을 받아, 각 객체의 위치(bounding boxes), 클래스(class probabilities), 그리고 객체 존재 확률(objectness score)에 대한 최종 예측결과를 생성한다. 최종 결과물은 각 스케일에서의 BottleneckCSP에 연결된 탐지 레이어의 1x1 convolution을 통해 생성되며, 이 컨볼루션 레이어는 특징 맵을 분석하여, 객체의 클래스, 위치, 그리고 신뢰도 점수를 예측결과를 출력한다.

각 탐지 레이어에는 1x1 컨볼루션 레이어가 포함되어 있어, 각각의 특징 맵을 채널 단위로 압축하고, 필요한 출력 차원으로 조절한다. 모델은 여러 anchor boxes를 사용하여 각각의 객체에 대한 예측을 수행하는데, 앵커 박스는 훈련 데이터에 기반하여 사전에 정의되며, 다양한 형태와 크기의 객체를 탐지할 수 있도록 최적화된다. 각 앵커 박스에 대해 모델은 해당 위치에 객체가 존재할 확률을 예측하고, 그 객체가 어떤 클래스에 속하는지에 대한 확률을 출력한다. 이후 모델은 또한 앵커 박스의 크기와 위치를 조정하여, 실제 객체에 더 정확하게 설정한다.

최종 출력에는 각 객체에 대한 클래스 확률과 경계 박스의 네 가지 좌표(x, y, width, height), 각 객체의 신뢰도 점수가 포함되며, 이러한 정보는 실시간으로 이미지 내의 여러 객체를 정확하게 탐지, 분류 및 추적하는 데 사용된다. 후처리 과정에서는 Fig. 2-20과 같이 중복된 결과물을 출력하지 않기 위해 NMS (Non-maximum Suppression) 단계를 거치는데, 이 과정에서 모델이 생성할 수 있는 겹친 박스 형태의 결과물에서 가장 높은 점수의 박스를 선택하여 출력한다. 이 과정에서 임계값을 적용하여, 높은 신뢰도의 탐지만을 최종 결과로 제공한다.

YOLO는 실시간 다중 객체 탐지에도 적용되며 단일 네트워크에서 한 번의 이미지 처리만으로 여러 객체를 감지할 수 있는 효율적인 방식이다. 입력 이미지를 $S \times S$ 격자로 분할하며, 각 격자의 셀은 이미지 내 객체의 중심이 될 수 있는 부분을 담당한다. 각 셀에서 B개의 경계 상자와 각 상자에 대한 객체 존재 확률을 예측한다. 상자의 중심 위치, 너비, 높이뿐만 아니라 해당 상자가 객체를 포함할 가능성을 나타내는 객체 존재 확률을 포함한다. 또한, 각 격자 셀은 C개의 클래스에 대한 조건부 확률을 예측하여, 특정 클래스의 객체가 해당 셀에 있을 확률을 계산한다. 이렇게 예측된 점수는

객체 존재 확률과 조건부 클래스 확률의 곱으로 결정되며, 이 점수는 해당 상자가 특정 클래스의 객체를 포함할 가능성을 나타낸다. 이 과정에서 NMS를 통해 중복 탐지를 방지하여 신뢰도 높은 결과를 출력한다.




Fig. 2-20 Non-maximum Suppression.

2.3.3 객체탐지 성능평가지표

객체탐지의 성능평가는 다양한 지표를 통해 이루어질 수 있다[7]. 일반적으로 정확도(Precision)과 재현율(Recall)이 분류 모델에서 널리 사용된다. 정확도는 모델이 참으로 판정한 것 중 실제로 참인 데이터의 비율을 나타내는 것으로, 다음의 식 (1)과 같이 계산된다:

$$Precision = \frac{TP}{TP + FP} \quad (1)$$

위 식에서 TP (true positives)가 정확하게 예측한 것이고, FP (false positives)는 잘못 예측된 경우이다.

재현율은 실제 참인 데이터 중 모델이 참으로 판정한 데이터의 비율을 나타낸다. 즉, 모델이 실제 참인 데이터를 얼마나 참으로 판정했는지 그 재현율을 측정하는 것이다. 재현율은 다음의 식 (2)와 같이 계산된다:

$$Recall = \frac{TP}{TP + FN} \quad (2)$$

여기서 FN (False negatives)은 모델이 참인 데이터를 거짓으로 예측한 경우를 의미한다.

F1 Score는 정밀도와 재현율의 조화평균을 나타내며, 두 지표를 동시에 고려할 때 유용하다. F1 score는 다음의 식 (3)과 같이 정의된다:

$$F1\ Score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (3)$$

여기서 F1 Score는 불균형 데이터 세트를 다룰 때 중요한 지표로 사용할 수 있으나, 두 지표중 하나가 크게 차이가 나는 경우 전체 점수에 큰 영향을 미친다는 한계가 있다.

정확도(Accuracy)는 분류 모델에서 널리 사용되는 지표로 모델이 예측한 결과가 실제 값과 얼마나 일치하는지를 나타내는 비율이다. 전체 데이터 샘플 중 올바르게 예측된 샘플의 비율을 나타내며, 다음 식 (4)와 같이 표현된다:

$$Accuracy = \frac{TP + TN}{TP + FP + TN + FN} \quad (4)$$

정확도는 클래스 분포가 균일한 데이터 셋에서 성능을 잘 나타낼 수 있으나, 불균형 데이터 셋에 적용할 경우 모델 성능을 제대로 반영할 수 없다는 한계가 있다.

Average precision (AP)은 객체탐지에서 널리 사용되는 지표로, 특정 클래스에 대한 정밀도-재현율 곡선(precision-recall curve) 아래의 면적을 의미하며 곡선 아래의 면적(area under the curve, AUC)은 모델의 전반적인 성능을 나타낸다. AUC는 0에서 1 사이의 값으로 나타나며, 높을수록 모델의 성능이 우수함을 나타낸다. 각 객체에 대한 AUC 값을 해당 객체의 평균 정확도 AP로 정의하며, 모든 객체에 대한 AP 값을 평균을 낸 것이 mean average precision (mAP)이다.

mAP는 객체 탐지작업에서 모델이 얼마나 정확하게 객체를 탐지하는지를 평가하는 것으로 널리 사용되고 있으며, 이 값이 높을수록 우수한 모델이라고 평가할 수 있다. 완벽한 모델은 재현율이 1일 때 정밀도도 1인 점에 해당한다. 즉, 곡선의 우측 상단 모서리에 도달하는 것이 가장 이상적인 모델이라고 볼 수 있다. 이 precision-recall curve는 AP를 도출하여 각 클래스에 대한 모델 성능을 종합적으로 평가하기 위한

mAP를 계산할 수 있어 다중 객체탐지 작업에서의 모델의 정확성을 평가하게 된다.

Intersection over union (IoU)는 Fig. 2-21와 같이 예측된 바운딩 박스와 실제 바운딩 박스의 교집합과 합집합의 비율을 나타낸다[20]. 객체탐지에서 모델이 얼마나 정확하게 객체의 위치를 예측했는지를 평가하는 데 사용되며, 특정 임계값(예: $\text{IoU} \geq 0.5$) 이상 일 때 탐지를 정확하게 했다고 판단하게 된다. IoU의 계산 공식은 식 (5)와 같다:

$$\text{IoU} = \frac{\text{Area of Intersection}}{\text{Area of Union}} \quad (5)$$

여기서 Area of Intersection은 두 바운딩 박스가 겹치는 영역의 면적이며, Area of Union은 두 바운딩 박스에 의해 커버되는 전체 면적을 의미한다. IoU는 중복탐지를 방지하는데 큰 역할을 할 수 있으나, 객체의 크기가 작을 경우 작은 위치의 오차로도 성능이 크게 좌우될 수 있다.




Fig. 2-21 Intersection over union.

YOLO의 경우 보통 mAP@50 을 성능지표로 사용한다. mAP@50 은 IoU가 50% 이상인 경우를 정확한 예측으로 간주하는 경우를 의미한다. 또 다른 지표로 사용되는 mAP@50-95 는 IoU가 50%부터 95%까지 5% 단위로 변화하는 경우에 대해 평균 정밀도를 계산한다. mAP@50-95 은 상대적으로 높은 정확도를 요구하기 때문에 약간의 위치 오차나 경계 상자의 크기 차이도 큰 영향을 미칠 수 있다. 높은 IoU 임계값을 요구하는 경우 모델이 실제로는 유용한 탐지를 제공했음에도 불구하고 성능이 지나치게 낮게 나오는 경우가 있어서 응용분야와 데이터셋의 특성을 고려하여 적절하게 설정하여야 한다[40].

2.4 선행연구와의 차별성

본 연구는 현장에서 실시간으로 촬영한 이미지 대상의 AI 판별을 통해 조기 이상감지에 기반한 시스템비계의 안전한 운용을 목적으로 한다. 관련된 연구의 하나로 김정룡 등[23]의 F-scan을 활용한 작업자 자세 안정도 평가에 관련한 연구가 있다. 이동식 틀비계를 사용하는 건설현장에서 숙련된 작업자와 비숙련된 작업자 그룹을 대상으로, 작업대의 높이, 안전난간 유무, 숙련도가 자세 안정성에 미치는 영향에 대해 실험을 진행하였다. 해당 연구는 작업자에 초점을 맞췄으며, 이동식 틀비계에 관해 연구를 수행했다는 점에서 본 연구와 차이가 있다.

민승남 등[32]의 이동식 틀비계 사용 작업 시에 따른 척추 안정성 분석 연구는 작업 경력에 따라 허리 안정성 차이에 대해 실험하였다. 실험결과, 안전난간이 없고, 작업대가 높을수록, 초보자일수록 허리 근육의 사용량이 증가하는 것으로 나타났다. 허리 근육을 많이 사용할수록 허리의 안정성을 유지하기 쉽지만 이와 동시에 근육이 쉽게 피로해져 안전문제의 원인이 될 수 있어, 작업시간의 조절이 중요하다는 결론을 내렸다. 해당 연구는 작업현장의 조건과 숙련도에 따른 허리 근육의 사용량을 비교하여 허리 근육의 안정성을 확인하였기에, 본 연구와 달리 틀비계 작업자를 대상으로 하였으며, 작업자에 초점을 맞췄다는 것을 알 수 있다.

이정석 등[28]은 조립식 가설기자재의 완성품에 대한 안전인증 타당성 연구에서 비계, 동바리 등 국내외 가설기자재의 안전인증제도에 대해 비교 분석하였으며, 가설 기자재 완성품에 대해 성능시험을 수행하였다. 또한 이를 통해 안전인증 타당성을 제시하였으며, 제도적인 측면에서 연구를 수행했다는 점에서 본 연구와의 차이가 있다.

유현동[44]은 소규모 건설현장에서 추락으로 인한 사망 재해를 저감할 수 있는 방안에 관해 연구하였으며, 이 과정에서 당시 건설업 현장에서 발생하는 재해에 대한 실태 조사를 기반으로 개선방안을 도출하였다.

2009년 한국산업안전보건공단의 제조업에서의 추락재해 원인 분석 및 예방대책 연구보고서[66]는 이동식 사다리를 중심으로 국내외 관련 기준과 재해사례 분석을 통해 선진국 수준의 재해 발생률을 목표로 설문조사와 안전모델을 제시하였다. 해당 연구는 제조업 현황에 대한 조사와 정부 정책 방안을 제시하고 있어 시스템비계 표준안전작업지침 제정 시 근거자료로 활용할 수 있도록 하였다. 따라서 본 연구에서는 해당 보

고서의 내용을 비계 설치 적정성에 대한 기준 설정에 참고하였다.

박주동 등[63]의 산업안전보건연구원의 2021년 보고서는 이동식 비계의 안전성과 현장 적용성의 개선에 관한 연구를 수행하였으며, 실태조사와 구조 안전성 평가를 수행하고 이동식 비계의 개선 모델을 제안하였다.

문성오 등[40]의 2019년 산업안전보건연구원 보고서에는 추락재해예방을 위해 국내 건설현장에서 비계 안전난간에 관련한 선행공법 적용방안에 관한 연구를 수행하였다. 이 과정에서 해외 기준에 대한 문헌 조사와 개별 제품의 실태조사, 우수사례 조사 등 문헌 및 현장 조사뿐만 아니라 설치 기준 개정 방안에 대한 의견 또한 제시하였다.

이동건 등[27]은 딥러닝 기반으로 LNGC 화물창의 관리를 위해 스캐닝 점군 데이터를 이용해 비계 시스템의 객체 탐지와 후처리에 관한 연구를 수행하였다. PointNet을 활용하였으며, 3차원 객체를 점군 데이터 형태로 객체를 인식하는 방식을 사용하였다. 장지영 등[17]은 강관비계, 시스템비계 등이 포함되는 조립 가설 기자재의 품질평가에 관한 이론적 고찰과 품질평가 및 관리 시스템(T-QEMS)의 개발에 관련한 연구를 수행하였다. 이동건 등과 장지영 등의 연구는 비계 관련한 연구를 수행하였을 뿐만 아니라 딥러닝 등의 기술을 접목하여 하나의 시스템을 개발한 연구이다.

이 외에 이명구 등[67]은 동바리 구조의 안전작업절차를 개발하였으며, 이영섭[67]은 건설공사의 종류별 표준화된 안전시설에 관한 제안을 하였다.

관련 선행연구를 살펴보았을 때, 다수의 연구에서 현장에서 근무하는 작업자에 초점을 맞추어 연구를 수행하는 것을 확인할 수 있었다. 또한 비계 설치의 적정성에 대한 기준을 분석한 연구가 있었으나, 실제 현장에서 적용되는 비계 설치의 적정성을 판단하는 연구 특히 AI 기반의 자동화 연구는 없었음을 확인할 수 있었다. 이에 본 연구에서는 현장에 설치된 시스템비계의 설치 적정성 판단을 지원 또는 자동화하고자 하였으며, 이 과정에서 인적 오류를 감소시키기 위한 AI 기반의 시스템 개발에 집중하고자 한다.

제3장 비계 설치의 적정성 판단 기준 분석

3.1 문제 정의

본 연구에서 제안하는 AI 시스템은 기계학습 중 지도학습의 분류에 기반한 구현을 하게 된다. 따라서 판정하게 되는 시스템비계의 설치 적정성에 대한 정의가 요구되고, 이를 위해 KOSHA Guide, 산업안전보건기준을 참고하였으며, 재해사례를 통해 우선으로 판단해야 할 자재를 선정하였다.

본 연구에서의 설치 적정성이란 KOSHA Guide, 산업안전 보건기준에서 규정된 기준을 준수하며, 비계가 안전하게 설치되어 작업자가 안전하게 작업할 수 있는 환경이 조성되어 있는 상태를 의미한다. 또한 AI를 이용한 설치 적정성 판단 시스템을 개발하기 위해 시스템비계 중 재해사례를 참고하여 가장 많은 피해자가 발생한 자재, 현장에서 가장 많이 사용되는 자재, 설치기준이 명확한 자재를 포함하여 총 5가지 시스템비계 자재를 연구대상으로 선정하였다.

3.2 시스템비계의 재해사례 분석

시스템비계는 건설현장의 안전을 확보하기 위한 중요한 요소 중 하나이다. 하지만 설치 및 관리가 부적절한 경우에는 추락사고 등 안전사고의 원인이 될 수 있다. 국내에서 다양한 재해사례가 보고되었으며, 이런 사례를 분석하여 시스템비계의 안전성에 영향을 미치는 주요 요인들을 식별하고 사고 예방을 위한 설치 적정성 판단 기준의 근거를 마련하고자 한다.

3.2.1. 주요 사례

비계의 잘못된 설치가 원인이 된 사고 경우를 건설공사 안전관리 종합정보망(CSI), 산업안전보건공단 재해사례 등에서 조사하였다[69]. 각 재해사례는 아래의 표들과 같다.

첫 번째 재해는 Table 3-1과 같으며, 서울 강동구 근린생활시설 신축현장에서 발생하

였다. 외부비계를 해체하기 위해 비계 상부로 이동하던 중 추락하여 사망한 사례이며, 비계 설치 시 작업 통로 미확보가 그 원인으로 추정되었다.

Table 3-1 Case of scaffolding accident in Gangdong-gu, Seoul

구분	내 용	비 고
장소	서울 강동구 근린생활시설, 공동주택 신축현장	
재해 개요	외부비계 해체작업을 위해 비계 상부로 이동 중 추락	
사고원인(추정)	작업통로 미확보, 무자격자에 의한 비계해체작업 진행	
재해 정도	사망 1명	
안전대책	해체 작업절차 수립 및 준수, 유자격자에 의한 비계해체작업 진행	



두 번째 재해는 Table 3-2와 같으며, 전남 무안군 공사현장에서 발생하였다. 시스템 비계 2단에서 미장면 바탕 정리작업 중 추락하여 사망한 사례이며, 작업 발판 설치 불량 그 원인으로 추정되었다.

Table 3-2 Case of scaffolding accident in Muan-gun, Jeollanam-do.

구분	내 용	비 고
장소	전남 무안군 공사현장	
재해 개요	부속동 시스템비계 2단 작업 발판 위에서 미장면 바탕 정리작업 중 추락	
사고원인(추정)	작업 발판 설치 불량, 추락방지조치 미실시	
재해 정도	사망 1명	
안전대책	안전한 작업발판 설치, 추락방지조치 실시	



세 번째 재해사례는 Table 3-3과 같으며, 경북 영양군 증축공사 현장에서 발생하였다. 작업발판에 위치한 개구부에서 자재를 옮기던 중 중심을 잃고 추락하여 사망한 사례이며, 개구부 주위 추락 방호조치가 미흡한 것이 그 원인으로 추정되었다.

Table 3-3 Case of scaffolding accident in Yeongyang-gun, Gyeongsangbuk-do.

구분	내 용	비 고
장소	경북 영양군 증축공사 현장	
재해 개요	작업발판에서 개구부를 통해 자재를 옮기던 중 중심을 잃고 추락	
사고원인(추정)	자재인양구 미확보, 개구부 주위 추락 방호조치 미흡	
재해 정도	사망 1명	
안전대책	자재인양구 설치, 자재인양구 주변 추락방지조치, 중량물 취급 작업계획의 수립 및 준수	



네 번째 재해사례는 Table 3-4와 같으며, 인천광역시 공사 현장에서 발생하였다. 비계 조립과정에서 수평재를 밟으며 내려오던 중, 실족하여 사망한 사례이며, 이동통로 미확보, 개구부 추락방호 조치 미흡이 그 원인으로 추정되었다.

Table 3-4 Case of scaffolding accident in Seo-gu, Incheon.

구분	내 용	비 고
장소	인천광역시 서구	
재해 개요	엘리베이터실 비계 조립 과정에서 수평재를 밟고 내려오던 중 실족	
사고원인(추정)	이동통로 미확보, 개구부 추락방호 미조치, 작업관리 소홀	
재해 정도	사망 1명	
안전대책	이동통로 확보, 추락방호 조치, 작업관리 철저	



다섯번째 재해사례는 Table 3-5와 같으며, 광주시 근린생활시설 공사 현장에서 발생하였다. 작업발판 미설치, 안전방망 등 추락 방호조치가 미흡하여 발생한 사고이다. 발판이 없어 비계 띠장에서 외벽 거푸집 해체작업 중 실족하여 사망한 사례이다.

Table 3-5 Case of scaffolding accident in Gwangsan-gu, Gwangju.

구분	내 용	비 고
장소	광주광역시 광산구 근린생활시설	
재해 개요	비계 띠장에서 외벽 거푸집 해체작업 중 발이 미끄러지면서 실족	
사고원인(추정)	작업발판 미설치, 추락 방호조치 미흡	
재해 정도	사망 1명	
안전대책	작업발판 설치, 안전대 착용, 안전방망 설치	



여섯번째 사례는 Table 3-6과 같으며, 부산광역시 교회 증축공사 현장에서 발생하였다. 외부비계로 이동 중 벽체와 비계사이로 추락하여 발생한 재해이다. 사고의 원인은 작업발판 설치, 추락 방호조치 미흡이었으며, 벽면과 밀접하게 발판 또는 추락방지망이 설치되었을 경우에 예방할 수 있을 것으로 추정되었다.

Table 3-6 Case of scaffolding accident in Haeundae-gu, Busan.


구분	내 용	비 고
장소	부산광역시 해운대구 교회 증축공사	
재해 개요	외부비계로 이동 중 벽체와 비계사이로 추락	
사고원인(추정)	작업발판 설치 미흡, 추락 방호조치 미흡	
재해 정도	사망 1명	
안전대책	벽면과 밀실하게 발판 설치, 추락방지망 설치	



일곱번째 사례는 Table 3-7과 같으며, 충남 보령시 설비 정비 공사 현장에서 발생하였다. 발전용 설비 내부에서 작업 발판용 비계가 도괴하여 발생한 사망사고로, 가설재 설치 이상, 최대하중 초과로 인해 벌어진 사고이다.

Table 3-7 Case of scaffolding accident in Boryeong-si, Chungcheongnam-do.


구분	내 용	비 고
장소	충남 보령시 설비 정비 공사	
재해 개요	발전용 설비 내부에서 이동통로 및 작업 발판용 비계가 도괴	
사고원인(추정)	가설재 설치 이상, 최대하중	
재해 정도	사망 1명	
안전대책	자재인양구 설치, 자재인양구 주변 추락방지조치, 중량물 취급 작업계획의 수립 및 준수	



여덟번째 사례는 Table 3-8과 같으며, 제주시 신축공사 현장에서 발생하였다. 비계 안전난간을 잡고 올라가다 클램프 파단으로 인해 추락하여 사망한 사고이며, 비계 조립상태 미흡이 그 원인으로 추정되었다.

Table 3-8 Case of scaffolding accident in Jeju.

구분	내 용	비 고
장소	제주시 신축공사 현장	
재해 개요	비계 안전난간을 잡고 올라가다 클램프 파단으로 추락	
사고원인(추정)	통로설치 미흡, 안전난간 구조 미준수, 비계 조립상태 미흡	
재해 정도	사망 1명	
안전대책	안전통로 설치, 안전난간 구조 및 설치기준 준수, 비계 조립상태 점검	



아홉번째 사례는 Table 3-9와 같으며, 안양시 다목적 체육관 증축공사 현장에서 발생하였으며, 시스템비계 자재를 전달받던 중 추락하여 사망한 사례이다. 안전난간이 미설치 된 구간에서 안전대까지 미체결 상태로 작업한 것이 원인이며, 작업발판, 추락 방호조치가 미흡하여 발생한 재해이다. 비계 작업발판과 추락방호조치를 제대로 설치 하거나 점검 및 보수를 철저히 할 때 유사한 사고를 예방할 수 있을 것이다.

Table 3-9 Case of scaffolding accident in Anyang-si, Gyeonggi-do.

구분	내 용	비 고
장소	안양시 다목적 체육관 증축공사 현장	
재해 개요	양중된 시스템비계 부재를 받던 중 추락	
사고원인(추정)	안전난간 미설치 구간에서 안전대 미체결 상태로 작업, 관리감독 미흡, 보수보강 미흡	
재해 정도	사망 1명	
안전대책	비계 작업발판 추락방호조치 철저, 중량물 취급 작업계획서 작성/이행, 작업지휘자 지정, 점검 및 보수	



열번째 사례는 Table 3-10과 같으며, 전남 목포시 신축공사 현장에서 외부 비계에서 이동 중 바닥으로 추락하여 사망한 사고이다. 개구부 덮개 미설치가 그 원인으로 추정된다.

Table 3-10 Case of scaffolding accident in Mokpo-si, Jeollanam-do.

구분	내 용	비 고
장소	전남 목포시 신축공사 현장	
재해 개요	외부비계에서 이동 중 바닥으로 추락	
사고원인(추정)	개구부 덮개 미설치, 현장관리 미흡	
재해 정도	사망 1명	
안전대책	주차타워 환기창 방호조치 실시, 콘크리트 타설 순서 계획 수립	



11번째 사례는 Table 3-11처럼 서울 동작구에서 발생하였다. 현장 내 상부 이동을 위한 가설통로를 설치한 후 가설통로 아래쪽에 앉아 휴식을 취하던 중, 가설통로 상부 발판의 클램프가 아래로 떨어져 휴식을 취하던 비계공의 우측 팔 부위에 떨어져 부상을 입었다.

Table 3-11 Case of scaffolding accident in Dongjak-gu, Seoul.

구분	내 용	비 고
장소	서울특별시 동작구 가설공사 현장	
재해 개요	클램프가 하부로 떨어져 휴식을 취하던 비계공 아래팔에 떨어진 사고	
사고원인(추정)	낙하위험물 방치	
재해 정도	3일 이상 휴업이 필요한 부상 1명	
안전대책	낙하 위험이 있는 곳에 자재 및 부재 방치 금지, 작업 중 휴식 시 안전이 확보된 곳에서 휴식하도록 교육	



Table 3-12의 사고사례는 인천 계양구에서 발생하였으며, 건물의 상층부로 이동하던 중 외부비계가 기울어져 고압선과 접촉되어 그 여파로 감전되어 아래로 추락한 것으로 추정된다. 목격자는 없으나, 약 8-9 m 높이에서 추락한 것으로 추정되며, 사고발생 약 8분 후 119가 도착하여 응급조치를 취했으나 수술 중 사망한 재해이다.

Table 3-12 Case of scaffolding accident in Gyeyang-gu, Incheon.

구분	내 용	비 고
장소	인천광역시 계양구	
재해 개요	내부 건물 상층부 철거 이후 외부비계 및 분진망 해체를 위해 상부로 이동 중 외부비계가 기울어지며, 고압선에 접촉, 감전되어 2~3층 높이에서 추락한 것으로 추정	
사고원인(추정)	작업자 통제 미흡	
재해 정도	사망 1명	
안전대책	위험노출 구간에 대한 고압선 방호커버 작업 이행을 요청	

Table 3-13의 재해사례는 부산광역시 사상구에서 발생하였으며, 작업자가 비계 위에서 자재를 들고 이동하던 중 비계발판 사이의 틈에 발이 빠져 넘어지면서 부상당한 사고이다. 발이 빠져 균형을 잃었으며, 이로 인해 넘어지다 난간대에 부딪혀 가슴과 손가락 부위에 3일 이상 휴업이 필요한 부상을 당했다.



Table 3-13 Case of scaffolding accident in Sasang-gu, Busan.

구분	내 용	비 고
장소	부산광역시 사상구 수장공사 현장	
재해 개요	비계 위에서 자재를 들고있어 이동 경로를 제대로 보지 못하고 비계 발판 사이 공간에 발이 빠짐. 그로 인하여 균형을 잃고 넘어지다 난간대 등에 부딪혀 가슴 및 손가락 부상	
사고원인(추정)	작업자 부주의, 발판 간격	
재해 정도	3일 이상 휴업이 필요한 부상 1명	
안전대책	관리감독자에 의한 작업 지시 전 사전 점검 철저 및 TBM시 사고 사례 공유 등으로 안전 의식 고취 실시	

14번째 재해사례는 Table 3-14와 같이 경남 남해군에서 발생하였다. 카자흐스탄 국적의 작업자가 외부 시스템비계 설치작업을 위해 수평연결재를 운반하던 중 자재를 넣어둔 마대 인양고리에 발이 걸려 넘어지면서 방수터 모서리에 우측 무릎을 부딪친 사고이다. 현장 정리가 부족해 작업발판위 장애물에 걸려 넘어진 사고이다. 이로 인해 우측 무릎 슬개골 골절 판정을 받고 입원 및 수술을 받았으며, 사고 이후, 시스템비계 설치 및 해체팀에 안전교육을 실시하였다.

Table 3-14 Case of scaffolding accident in Namhae-gun, Gyeongsangnam-do.

구분	내 용	비 고
장소	경남 남해군 숙박시설 공사현장	
재해 개요	자재를 넣어 둔 톤백마대 인양고리에 발이 걸려 넘어지면서 부딪힌 사고	
사고원인(추정)	불량자재 관리 미흡	
재해 정도	3일 이상 휴업이 필요한 부상 1명	
안전대책	시스템비계 설치 및 해체팀 안전교육 실시	

사고 관련 사진(그림) 1. 사고현장 (사고지점 및 위치 표시)   사진설명 사고발생 장소 (호텔동 8층 옥상 외부) 사진설명 호텔동 8층 외부 톤백마대 인양고리		2. 사고발생 상세도   사진설명 재해발생 재현 사진 (톤백마대 인양고리에 발이 걸림) 사진설명 재해발생 재현 사진 (콘크리트 방수터에 무릎 부딪힘)	
--	--	---	--

15번째 사고사례는 경남 창원시에서 발생하였으며, 재해 개요는 Table 3-15와 같다. 작업자가 지하 1층 선큰구간 계단쪽 시스템비계 횡대 설치 후 이동을 위해 계단 난간대를 넘어 내려오던 중 선큰계단 가설 난간대 브라켓에 안전대 다리 벨트가 걸려 넘어져 왼발 3번째 발가락이 골절되는 사고이다.

Table 3-15 Case of scaffolding accident in Changwon-si, Gyeongsangnam-do.

구분	내 용	비 고
장소	경남 창원시 신축현장 공사	
재해 개요	가설 난간대 브라켓에 안전대 다리벨트가 걸려 넘어짐	
사고원인(추정)	작업자 부주의	
재해 정도	3일 이상 휴업이 필요한 부상 1명	
안전대책	관리감독자 상주 관리 및 근로자 불안정한 행동 감시, TBM 시 작업방법 및 작업순서 교육 시행, 사고사례 전파를 통한 유사재해 예방활동 시행	

16번째 사례는 Table 3-16과 같으며, 미장 작업자가 수영장동에 설치된 시스템비계 내부에서 이동 중 탈락된 발판에 발이 걸려 넘어진 사고이다. 타 작업자가 시스템비계를 수정 행위 후 복구를 미흡하게 한 것이 주요 원인이며, 해당 구간을 사고피해자가 지나가다 부분 탈락되었던 발판에 발이 걸려 넘어진 사고이다. 이 사고 이후 시스템비계 전수조사를 수행하였으며, 특별안전 보건교육을 실시하고 일일 안전점검을 강화하여 사고를 예방하고자 하였다.

Table 3-16 Case of scaffolding accident in Paju-si, Gyeonggi-do.

구분	내 용	비 고
장소	경기도 파주시 운동시설 미장공사현장	
재해 개요	시스템비계 내부에서 이동 중 탈락된 발판에 걸려 넘어짐	
사고원인(추정)	시방기준 등 미준수	
재해 정도	3일 이상 휴업이 필요한 부상 1명	
안전대책	시스템비계 전수조사, 비계 및 안전가시설 임의해체 행위 단절을 위한 특별안전보건교육 실시, 일일 안전점검 강화	
		

17번째 사고사례는 Table 3-17과 같다. 수직재 간격을 맞추기 위해 수직재의 다른 부위를 잡을 수 있었음에도, 손가락 협착 가능성이 있는 수평재 고정핀 부위를 파지한 상태에서 발끝으로 일시적으로 강하게 수직재를 밀침으로써 수직재 간격을 맞추려고 하다가 왼손 약지가 수평재 고정핀과 수직재 사이에 협착된 사고이다.

Table 3-17 Case of scaffolding accident in Cheongju-si, Chungcheongbuk-do.

구분	내 용	비 고
장소	충청북도 청주시 교육 운동시설 가설공사 현장	
재해 개요	시스템비계 설치작업에서 수평재 조정작업 중 수평재 고정못치에 왼손 약지가 끼어 인대파열	
사고원인(추정)	작업자의 불안정한 행동	
재해 정도	3일 이상 휴업이 필요한 부상 1명	
안전대책	손가락 협착 방지를 위해 개인보호구(안전장갑) 착용여부 작업 전 확인 지시, 동종재해 재발방지를 위한 재해발생 사례 전파 및 작업자 안전교육 실시	

내 용 사고부위 전경 (의생명동 2층 시스템동바리 설치 작업) 	내 용 수직재 간격을 맞추기 위해 수직재를 발로 차던 중 수평재 홈에 손가락 협착 
---	---

다음 사례는 Table 3-18과 같이, 거푸집 해체 작업 중 해체된 거푸집을 주점검로 슬라브 위로 옮기던 과정에서 발생하였다. 거푸집을 잡고 있던 왼손이 시스템비계 수평재에 부딪혀 왼손 손가락 끝마디가 골절되는 부상사고 발생한 사례이다.

Table 3-18 Case of scaffolding accident in Gyeongju-si, Gyeongsangbuk-do.

구분	내 용	비 고
장소	경상북도 경주시 방사성폐기물 처분시설 공사현장	
재해 개요	거푸집 해체 작업 중 거푸집을 잡은 왼손이 수평재에 부딪혀 골절되는 사고	
사고원인(추정)	작업자 부주의	
재해 정도	3일 이상 휴업이 필요한 부상 1명	
안전대책	거푸집 해체 작업시 받아 치기 작업 실시/ 혼자서 작업 금지, 근로자 특별안전교육 실시	



Table 3-19의 재해사례는 경기도 구리시에서 발생했다. 체육관 및 급식소 증축공사 현장 지상 3층 외부 시스템비계에서 작업자가 낙하물 방지망 해체작업을 하는 도중 상부 미고정을 확인하지 못하고 하부 클립을 해체하여 파이프가 낙하하면서 가슴을 타격한 사고이다.

Table 3-19 Case of scaffolding accident in Guri-si, Gyeonggi-do.

구분	내 용	비 고
장소	경기도 구리시 교육시설 증축공사 현장	
재해 개요	2인 1조 작업 중 파트너 작업 분량 및 작업순서 미확인으로 인한 물체에 맞는 사고 발생	
사고원인(추정)	작업자 부주의	
재해 정도	3일 이상 휴업이 필요한 부상 1명	
안전대책	사고 재발 방지를 위해 현장 근로자 특별교육 진행, 사고 예방을 위한 작업 전 현장주변 정리정돈 및 현장 내 수시 안전점검 진행	



20번째 재해사례는 서울특별시 중랑구에서 발생하였으며, 재해개요는 Table 3-20과 같다. 지상 2층에서 시스템비계 설치작업 중 안전고리를 체결하였지만 최하사점 높이를 미확보하여 바닥으로 넘어지면서 발생한 사고로, 사고 작업자의 뒷머리 부분에 2cm 가량의 열상 피해가 발생하였다.

Table 3-20 Case of scaffolding accident in Jungnang-gu, Seoul.

구분	내 용	비 고
장소	서울특별시 중랑구 공동주택 가설공사 현장	
재해 개요	지상 2층에서 시스템비계 설치 작업중 높이 1.8m 작업발판에서 발을 헛디뎈 바닥으로 넘어짐	
사고원인(추정)	작업자 부주의	
재해 정도	3일 이상 휴업이 필요한 부상 1명	
안전대책	고소작업 시 그네식 안전벨트 착용 및 생명줄 선을 설치하여 안전고리를 체결하여 작업, TBM 실시 시 위험작업에 대한 가상교육을 통해 사전위험 숙지 및 제거	

Table 3-21의 재해사례는 경상북도 구미에서 발생하였으며, 내부 수평비계를 해체하던 중 비계 파이프가 떨어지면서 작업자의 이마에 부딪힌 사건이다. 작업순서 미흡으로 비계 파이프가 떨어진 것으로 주원인은 적정 공법의 검토가 미흡한 것으로 밝혀졌다.

Table 3-21 Case of scaffolding accident in Gumi-si, Gyeongsangbuk-do.

구분	내 용	비 고
장소	경상북도 구미시 교육 연구시설 공사 현장	
재해 개요	내부 수평비계 해체중 비계파이프가 떨어지면서 이마에 부딪힘	
사고원인(추정)	적정 공법검토 미흡	
재해 정도	3일 이상 휴업이 필요한 부상 1명	
안전대책	작업시 안전교육과 작업방법 및 작업계획서 토대로 교육 후 작업실시	



22번째 사례는 Table 3-22와 같으며, 시공사가 따로 없는 현장에서 엘리베이터 공사 중 비계설치를 하다 실수로 인하여 낙사한 사고이며, 사망자 한 명이 발생하였다. 주된 원인은 개인 안전보호구 착용 불량이며, 작업자의 불안정한 행동 역시 사고 보조 원인이었다.

Table 3-22 Case of scaffolding accident in Pyeongtaek-si, Gyeonggi-do.

구분	내 용	비 고
장소	경기도 평택시 근생 증축공사	
재해 개요	엘리베이터 비계 설치작업 중 실수로 인한 낙사	
사고원인(추정)	개인 안전보호구 착용 불량, 작업자의 불안정한 행동	
재해 정도	사망 1명	
안전대책	작업자 안전교육 및 EV 층별 안전발판 및 작업장 입구 안전난간 설치	



3.2.2. 시스템비계 이상감지 요구사항 분석

2000.01.01.~2024.07.03. 기간을 통해 CSI에 등록된 비계 관련 사고 1,409건 중 562건이 추락사고였다. 또한 사망사고는 68건 이었다. 공중에 따라 분류하면 건축 (1,097건) > 토목 (105건) > 기계설비 (74건) 순으로 나타났다. 작업 프로세스로 분류하면 설치작업 (330건) > 해체작업 (293건) > 운반작업 (79건) > 정리작업 (69건) 등의 순으로 나타났다.

또한 2023년 12월부터 2024년 4월까지 최근 5개월간의 시스템비계 관련 사고 자료를 검토하였을 때, 총 21건의 사고 중 작업자 부주의가 아닌 시공품질 미확보, 불량자재 관리 미흡 등 설치 관련 원인으로 인한 사고는 5건으로 이 중 3건이 발판 관련 사고였으며, 연결부분 관련 사고 또한 3건이었다. 재해사례를 참고하였을 때, 시스템비계에서 발판, 연결부가 사고가 가장 많이 발생하는 자재임을 확인할 수 있었다.

3.3 시스템비계 설치 관련 기준 분석

산업안전보건기준에 관한 규칙 제69조에서는 시스템비계의 구조에 대해 준수하여야 하는 사항을 나열하고 있다[65]. 각 부품별로 자세하게 살펴보면, 첫 번째 밀받침철물의 경우 제69조의 2에서 비계 가장 밑단의 수직재, 받침철물이 밀착되도록 설치할 것을 이야기하고 있다. 제70조에서도 비계 기둥 밑동에 밀받침철물을 사용하며, 높이차가 있는 경우에 조절형 밀받침철물을 사용할 것을 요구하고 있다. 또한 경사진 바닥의 경우 췌기 등을 이용하여 밀받침철물의 바닥면이 수평을 유지할 것을 요구한다. 그 다음 수평재와 수직재의 경우 제69조 3과 4에서 서로 수직으로 설치하도록 규정하고 있고, 체결 후 흔들림이 없을 것을 요구하고 있다. 또한 수직재 간 연결철물이 이탈되지 않도록 견고한 구조를 유지하도록 규정하고 있다.

산업안전보건기준에 관한 규칙에서 벽이음재의 경우 설치 간격에 대해 제조사의 기준을 따를 것을 요구하지만, 이 외 구체적인 규정으로 언급하고 있지는 않다. 또한 동 규칙 제70조에서는 가공 전로에 근접하여 비계가 설치되는 경우 절연용 방호구 설치 등 가공 전로와의 접촉을 피하기 위한 조치가 필요함을 언급하고 있고, 근로자가 이동하는 경우 지정된 통로를 사용할 수 있도록 주지시킬 것을 요구하고 있다. 또한 작업


자가 수직면 상의 위 아래 동시 작업을 금지하며, 작업발판의 경우 제조사의 매뉴얼에 따라 최대 적재하중을 설정하고 근로자에게 주지시켜야 함을 언급하고 있다.

KOSHA Guide 시스템비계 안전작업 지침에서 4.3.2 받침철물, 벽이음 및 가새의 설치 준수사항에 대해 설명하고 있으며, 지반의 침하를 방지하기 위하여, 깔판, 깔목의 설치 또는 콘크리트를 타설하여 조치할 수 있음을 언급하고 있다[52]. 또한 산업안전보건기준에 관한 규칙에서 언급하였듯이 높이차가 있는 경우 조절형 받침철물을 사용할 것을 권장하고 있으며, 시스템비계가 항상 수평 및 수직을 유지할 것을 요구하고 있다. 이외 KOSHA Guide에서 추가로 추락방호망을 10미터 마다 설치할 것을 권장하고 있으며, 가새에 대한 설치 준수사항도 언급하였다. 다만, 보다 추락방호망의 경우 구체적인 사례가 없으며, 가새의 경우 전문가의 검토 또는 제조사의 매뉴얼을 따를 것을 권장하고 있다.

KOSHA Guide에서 수직재와 수평재의 설치 준수사항으로는 산업안전보건기준과 마찬가지로 수직으로 설치할 것, 연결철물이 이탈하지 않도록 설치할 것을 요구하며, 추가로 연결핀을 견고하게 설치할 것을 요구하고 있다. 또한 가설 계단의 사용과 안전대 부착용 로프를 우선 설치하고 안전대를 걸고 작업할 것을 언급하고 있다. 4.4 안전시설 설치에서는 통로, 안전방망 등 안전시설의 설치 시 준수해야 할 사항을 언급하고 있다:

- 작업발판의 설치 시 제조사의 최대 적재하중 설계를 근로자에게 고지해야 하며, 작업 발판의 폭은 40 cm, 두 개 이상을 설치할 경우 틈은 3 cm 이하로 설치해야 한다.
- 또한 작업발판은 둘 이상의 지지물에 고정하고, 하중에 의하여 파괴되어선 안된다.
- 가설계단의 설치 후에 근로자의 추락을 방지하기 위해 안전난간의 설치가 필요하며, 발판 위에 장애물이 비치되어서는 안 된다.

Table 3-23 Key inspection points for system scaffolding.

항목	중간점검 확인사항	사진
지반상태	연약지반에 비계기둥 설치 시 지반 다짐 및 깔목(두께 45 mm 이상) 설치 또는 콘크리트, 강재표면 등의 침하방지 조치 여부	
받침철물	수직재와 받침철물의 겹침길이는 받침철물 전체길이(일반적으로 600 mm)의 3분의 1 이상이 준수 여부	
수직재	수직재는 받침철물의 조절너트와 밀착 여부 및 수직재와 수직재의 밀착 상태	
연결부	수직재와 수평재 직교설치 여부 및 연결핀체결 상태	
가새재	가새재 설치각도(40~60°) 준수 및 수평재 및 수직재 결속상태	
벽이음	- 시스템비계의 붕괴와 전도방지를 위한 벽이음 설치간격(제조사(구	

항목	중간점검 확인사항	사진
	조검토 결과)가 정한 간격), 위치 및 체결상태 - 수직재와 수평재(띠장) 결합 부분에 설치 여부 - 비계 최상단 및 가장자리 끝 설치 여부	
작업발판	- 작업발판은 폭 40 cm 이상, 발판 간의 틈 3 cm 이하 준수 여부 - 작업대 설치 시 걸침고리 및 이탈 방지 장치 작동상태	
안전난간	- 작업발판 단부 추락방지조치 (안전난간) 여부	
안전시설	추락재해 방지시설 설치상태(추락방호망 등)	

시스템비계의 중점점검 사항은 Table 3-23과 같으며, 각 자재 또는 설치 환경에 대해서 집중적으로 점검해야 한다[49]. 각 자재별로 살펴보면 다음과 같다:

- 받침철물의 경우에는 수직재와 받침철물의 겹침 길이가 받침철물 전체 길이의 3분의 1이상을 차지해야 하며, 받침철물을 설치하는 지반에 깔목 등을 설치하여 평평한 상태를 유지해야 한다. 또한 지반이 침하하지 않도록 콘크리트 등으로 지지상태를 보강하여야 한다.
- 수직재의 경우에는 받침철물의 조절너트와 밀착되어야 하며, 수직재 간의 밀착상태를 확인하여야 한다.

- 연결부는 연결핀의 체결상태를 확인하여야 하며, 수직재와 수평재는 직교하도록 설치하여야 한다.
- 연결핀의 체결상태는 연결핀이 흔들리는지 또는 돌출 여부로써 확인할 수 있다.
- 가새재의 경우에는 설치각도가 40~60°를 준수하여야 하며, 수평재, 수직재와의 결속상태를 확인하여야 한다.
- 벽이음재의 경우에는 수직재와 수평재 결합부분 또는 비계 최상단 및 가장자리 끝에 설치되었는지 여부를 확인하여야 하며, 벽이음 설치간격, 위치 및 체결상태에 대해 점검하여야 한다.
- 작업발판은 폭 40 cm 이상, 발판간의 틈이 3 cm 이하를 준수하여야 하며, 작업대 설치 시 걸침고리 및 이탈방지 장치의 상태를 확인하여야 한다.
- 안전난간은 바닥면에서 상부난간대 상단까지 간격이 90 cm 이상이어야 하며, 난간대 간 간격은 60 cm 이하여야 한다.
- 추락방호망 등 추락재해를 방지하기 위한 안전시설의 경우 중앙부 처짐이 짧은 변의 12%이상, 내민길이는 3 m 이상이어야 하며, 망의 겹침길이는 0.75 m 이상, 망과 구조체 사이 간격은 100 mm 이하이어야 한다.
- 낙하물재해를 방지하기 위한 낙하물 방지망 설치기준은 수평면과의 설치각도는 20 - 30° 이하를 유지하여야 하며, 내민 길이가 2 m 이상, 망의 겹침길이가 150 mm 이상, 수직보호망 체결간격은 350 mm 이하, 수직보호망 지지재 수평간격은 1.85 m 이하이어야 한다[51].

Table 3-24는 2023년 국토교통부에서 작성한 가설구조물 종류에 따른 설치 기준 및 점검 가이드에서 제안한 시스템비계 체크리스트 이다[54]. 이 중 설치상태에서 각 자재별 설치 점검사항을 확인할 수 있다. 받침철물과 관련된 사항으로는 지반 다짐 및 평탄도 상태와 경사지에서 경사각에 맞는 췌기 설치 여부에 대한 항목과 내민 길이 준수 여부, 조절 나사와 수직재 밀착상태가 있으며, 벽이음재 관련 사항으로는 경사 버팀대 설치 여부, 설치간격 및 앵커 고정상태 등 벽이음재 설치 상태가 있다. 연결부 점검사항은 전용 클램프 사용 여부가 포함되었으며, 수직재는 밀착 설치상태, 수직재와 수평재의 공통 점검사항으로 결합부 연결핀 체결상태가 포함되었다. 작업 발판은 이탈방지조치 여부와 최대 적재하중 표시 여부가 점검사항에 포함되었다.

Table 3-24 System scaffolding installation inspection checklist [53].

구분		점검사항	점검결과	비고	
설계도서		관계전문가 확인			
		시공상세도구와 구조검토결과 일치 여부			
		안전관리계획서 및 시공계획서 비치 여부			
성적서		품질시험성적서			
		비계 각 부재별 안전인증서			
설치상태	공통사항	설치도면과 설치상태 일치 여부			
		구조검토서 상의 사용자재와 반입된 자재 일치 여부			
		사용자재 손상 및 결함 유무			
	시스템비계	지반 다짐 및 평탄도 상태			
		경사지에 설치 시 경사각에 맞는 뺨기 설치 여부			
		구조검토 결과에 따른 경사버팀대 설치 여부			
		구조검토결과에 따른 벽이음 철물 설치상태			
		수직 및 수평도 적정 여부			
		연결부 전용클램프 사용여부			
		받침철물 및 유헤드 내면 길이 준수 여부			
		받침철물의 조절나사와 수직재 밀착상태			
		수직재와 수평재 결합부의 연결핀 체결 상태			
		상하 이동통로 설치상태			
		수평개구부 구간 지지부재의 보강 여부			
		출입구 및 자재 반입구 주변 트러스 구조물 설치상태			
		안전시설	안전난간 설치 여부		
			가설계단 또는 승강 사다리 설치상태		
			발끝막이판 설치 상태		
작업발판 설치 시 이탈방지조치 여부					
작업발판의 최대적재하중 표시 여부					
추락재해방지시설 설치상태					
낙하물재해 방지시설 설치상태					
안전표지판 설치상태					

3.4 AI 판정 모델 개발을 위한 비계 설치의 적정성 판단 기준 선정

3.4.1 시스템비계 재해 유형 및 원인 분석에 바탕한 개발 시스템의 범위

2021년 고용노동부 발표에 따르면 Fig. 3-1와 같이 안전난간 미설치가 가장 큰 사고 발생 요인이었으며, 개별 설비로는 작업 발판에서 사고가 가장 자주 발생하였음을 확인하였다[48]. 또한 3.2절에서 최근 5개월간 발생 사고를 확인하였을 때, 연결부와 작업 발판이 자주 발생하는 사고요인임을 확인하였다. 관련 기준으로는 KOSHA Guide에서는 개별 설비로 받침철물, 수직재, 연결부, 가새재, 벽이음, 작업발판, 안전난간, 안전시설에 대해 규정하고 있었음을 확인하였다.

따라서 본 연구에서는 사고가 가장 많이 발생하며 시각적으로 판단할 수 있는 안전난간에 해당하는 수평재, 수직재와 작업발판, 연결부를 개발 시스템의 대상 범위에 포함하였다. 추가로 시각적으로 판단하기 적합하며, 잘못 설치될 경우 붕괴, 무너짐의 원인이 될 수 있는 받침철물 또한 범위에 포함하였다.




Fig. 3-1 Construction Site Fall Hazard Inspection Results [48]

3.4.2 설치 기준 분석에 바탕한 이미지 수집의 범위

본 절에서는 3.3의 시스템비계 설치 기준을 참고하여 모델의 입력으로 사용되는 이



미지에서 시각적으로 명확하게 설치 적정성을 파악할 수 있는 자재들을 대상으로 데이터의 세부 사항을 정의하였다. 확보된 데이터 중 작업발판과 연결부의 경우 가장 많은 재해가 발생하였기에 최대한 많은 데이터를 확보하고자 하였다. 추가로 연구 날씨, 시간 등의 변수는 제외하고 비슷한 시간대에 촬영한 이미지를 활용하였다:

- 받침철물의 경우: 지반상태를 핵심기준으로 삼았다. 기울어진 곳이 있거나, 평평하지 않은 곳에 설치를 하는 경우에는 기반 다짐 또는 깔목을 설치하였는지를 파악하였다. 수직재와 받침철물의 겹침 길이에 대한 규정이 있으나, 이미지 형태에서 길이를 추정하는 과정이 포함되어야 하기에, 본 연구에서는 제외하였다.
- 수직재의 경우: 수평재와 직교설치 여부를 핵심기준으로 분석하였다. 이 과정에서 연결편을 사용하는 경우가 대다수이기 때문에 연결편의 체결상태 역시 동시에 파악이 가능하도록 하였다. 수직재와 수평재가 직교하고 있으며, 연결편이 일자로 고정되어 아래 돌출부가 튀어나온 경우를 정상 설치로 규정하였다.
- 가새재의 경우: 수평재 또는 수직재와의 연결상태를 파악하기는 쉬우나, 사진을 찍는 각도에 따라 설치각도가 다르게 나올 수 있기에, 연결편에 대한 항목에는 포함되었으나, 가새재 자체 설치 적정성은 제외하였다.
- 벽이음재의 경우: 이미지 형태에서 설치 간격을 명확하게 파악하기 어려우며, 현장마다 다른 비계를 사용하는 경우 제조사의 규격을 확인할 수 없었기에 해당 기준은 제외하였다. 수직재, 수평재의 결합 부분에 명확히 설치하였는가를 핵심기준으로 삼아 설치 적정성을 판단하였다.
- 작업발판의 경우: 이미지 형태에서 발판의 폭, 발판 사이의 틈 간격을 명확히 파악하기 어려워 해당 기준은 제외하였다. 발판 걸침 고리와 이탈방지 조치가 정확히 설치되었는가를 핵심기준으로 삼았으며, 추가로 고리로 연결되지 않고 겹쳐서 설치된 경우가 많아 해당 사항을 비정상 설치로 추가하였다.
- 추락 방호망 등 안전시설의 경우: 길이나 폭을 사진에서 추정하는 과정이 포함되어야 하기 때문에 본 연구에서는 제외하였다.

위의 사항을 모두 고려하였을 때, 이미지 형태에서 분석하기 어려운 추락 방호망, 낙하물 방지시설은 제외하였다. 받침철물, 수평재, 벽이음재, 작업발판, 연결편 5개 자재를 분석 대상으로 선정하였으며, Table 3-25와 같이 정상과 비정상 설치를 구분하였

다. 직접적으로 포함되지 않는 수직재, 가새재의 경우 연결핀 모델링 시 간접적으로 파악할 수 있도록 하였다.

Table 3-25 Examples of problem causes and classification for system scaffolding.

문제점	정상 설치	비정상 설치
고정핀		
밑받침철물		
벽이음재		
수평재		
발판		

제4장 비계 설치 적정성 판단 AI 시스템 설계 및 구현

4.1 이미지 분류 기반의 비계 설치 적정성 판단 모델 선정

4.1.1. 촬영 이미지의 지도학습 기반 분류

앞서 3장에서는 국내외 기준 및 전문가 지식을 통해 시스템비계 설치의 적정성 기준을 마련하였다. 각 자재별 올바른 설치 형태와 잘못된 설치 형태에 대한 기준을 설정하였으며, 해당 기준을 AI 기반 판정 모델의 판단 기준으로 삼았다. 설치 기준의 만족 여부 판정에 있어서는 시각 정보, 음향, 측정 정보 등이 사용될 수 있으나, 정보 수집의 편리성 측면에서 촬영 이미지만 학습만을 대상으로 하였다.

기계학습 모델은 문제와 정답을 같이 학습시키는 지도학습 방식을 채택하였다. 즉, 비계의 이미지와 비계가 설치 적정성 여부를 같이 제공하여 모델을 학습시켜 새로운 비계 이미지가 입력되었을 때 설치 적정성 여부를 출력하는 형태이다. 모델 학습에 사용되는 비계 이미지는 건설현장에서 설치된 비계를 직접 촬영하여 사용하였다.

4.1.2. 객체 탐지 기반의 설치 적정성 판정

데이터 기계학습 기반으로 시스템비계 설치 적정성 판단을 위해서는 크게 두 가지 방식으로 접근이 가능하다. 첫 번째는 이상감지 방식으로 일반적으로 이미지 데이터 기반의 이상 감지를 위한 딥러닝 모델은 이미지의 비정상적인 패턴이나 변화를 감지하는 데 사용되는데, 오토인코더, CNN 등을 통해 정상적인 데이터를 학습한다. 주어진 데이터 셋에서 정상적인 패턴과 이상한 패턴을 식별하는 것으로 명확하게 라벨링을 하기 어려운 문제에 적합하며, 정상 데이터만으로 학습이 가능하다. 두 번째는 객체 탐지 방식을 통한 설치 적정성 판단은 이미지 내 특정 객체의 위치와 클래스를 식별하는 과정으로 정상 설치와 비정상 설치의 정확한 라벨링이 필요하다. 객체의 위치와 상태를 명확하게 파악하여 설치 오류의 유형이 정해진 경우 적용해야 유리하다.

본 연구에서 해결하고자 하는 비계 설치 적정성 여부는 정상 범주에 속하는지 아닌지를 판단하거나 비정상적인 패턴을 파악하는 것이 아니라, 설치된 것 중에서 기준이 명확히 세워진 정상 설치와 비정상 설치를 분류하는 문제이므로 객체 탐지 방식을 채

택해야 한다. 또한 정상 설치의 경우 일정하고 단순한 패턴을 파악하는 것이 아니라 자재별로 다양한 설치 조건을 만족해야 하는데, 이러한 조건을 오토인코더와 같은 이상감지 모델로 판단하기 위해서는 훨씬 더 많은 양의 데이터가 필요하고 복잡한 구조의 모델을 설계해야 한다. 따라서 본 연구에서는 비계가 설치된 이미지 데이터를 이용하여, 명확한 기준을 세워 정상적으로 설치된 것과 제대로 설치되지 않은 것으로 분류하기 위해 객체 탐지 알고리즘인 YOLOv5 모델을 선택하여 연구를 수행하였다.

객체 탐지는 일반적으로 분류(classification), 위치검출(localization), 객체탐지(object detection) 세 가지 주요작업으로 나눌 수 있다[37]. 분류는 이미지가 주어졌을 때 그 이미지 내의 객체의 종류를 식별하는 과정이다. 분류는 가장 기본적인 형태에서 이미지 전체에 하나의 레이블을 할당하는 형태이다. 하나의 이미지에 있는 객체의 특징을 학습하고, 해당 객체가 어떤 클래스 해당하는지 확률 분포를 계산하는 것으로, 그중 가장 높은 확률의 클래스를 이미지에 해당하는 객체로 판단한다. 분류는 여러 객체 탐지 기법 중 가장 기초적인 부분으로 다른 작업과 함께 사용되는 경우가 많다.

위치검출은 이미지 내에서 특정 객체의 위치를 정확하게 지정하는 작업이다. 이 과정에서 바운딩 박스를 이용하며, 특정 객체를 둘러싸는 박스로 객체의 위치와 크기를 나타낸다. 위치검출은 분류와 결합하여 해당 객체가 무엇인지 그 위치가 어디인지를 동시에 알려줄 수 있으며, 이러한 과정을 통해 추가적으로 객체 분류, 객체 추적 등에 적용할 수 있다.

객체탐지는 분류와 위치검출을 통합한 과정으로 이미지 내의 여러 객체를 식별하고, 각 객체에 대한 바운딩 박스를 생성하여 위치를 찾아낼 수 있다. 객체 탐지는 동시에 여러 객체의 종류와 위치를 알아내야 할 때 사용한다. 예를 들어 Fig. 4-1과 같이 고양이의 이미지가 있는 경우 이미지 전체에 대한 라벨링을 수행하는 것이 분류, 고양이의 위치를 파악하는 것이 위치검출이며, 분류와 결합되어 고양이의 위치를 정확하게 파악할 수 있다. 객체탐지는 고양이와 개와 같은 객체가 여럿이 있는 경우에는 어떤 것이 고양이고 개인지 명확하게 구분하는 단계를 의미한다[5].



Fig. 4-1 Classification, Classification+Localization and Object detection.

4.1.3. YOLO 기반 개발

현재 널리 사용되는 객체 탐지 알고리즘은 YOLO와 R-CNN 계열의 알고리즘이 있으며, SSD 또한 자주 사용된다. 각 알고리즘을 비교한 내용은 Table 4-1과 같다. YOLO와 SSD는 실시간 처리가 가능할 정도로 빠르고, 객체의 위치와 분류를 단일 네트워크로 처리하는 단일 단계 처리 방식을 채택하여 병목 현상이 없다. 이를 통해 실시간 처리에 매우 적합한 구조로, 전체 이미지를 통합적으로 분석하여 높은 속도를 제공할 수 있다.

반면, R-CNN과 그의 변형인 Fast R-CNN 및 Faster R-CNN은 여러 단계를 거쳐 이미지를 분석한다. R-CNN은 가장 느린 속도를 보이며, 복잡한 계산 과정으로 인해 실시간 처리에는 적합하지 않고, Fast R-CNN은 이를 개선하기 위해 ROI Pooling을 도입하여 효율성을 향상시켰지만 여전히 처리 속도가 느리다는 문제가 있다. Faster R-CNN은 RPN (Region proposal network)를 사용하여 영역 제안 과정을 더욱 효율적으로 처리하며, 상대적으로 빠른 속도를 보인다. R-CNN 계열의 알고리즘은 높은 정확도를 제공하지만 속도 측면에서는 떨어지지만, YOLO와 SSD는 속도와 정확도의 균형을 잘 유지하며, 실시간 비디오 처리와 같은 응용 분야에 유용하게 적용되고 있다.

YOLO와 SSD 모두 처리속도가 빠르고 구현이 쉬워, 모바일 또는 웹 형태로 실시간 응답이 가능한 서비스 개발에 유용하지만 YOLO의 경우 관련 연구 커뮤니티가 활성화되어 있어서 지속적으로 개선된 버전이 개발되고 있어 다양한 분야에 적용되고 있어 SSD에 비해 더 널리 사용되고 있다. 본 연구의 개발 시스템은 모바일 기기를 통해 실시간으로 비계의 이미지를 입력받아 처리하는 것이 최종 목표이기 때문에 지속적인 서비스 개선과 제한된 자원에서 실시간으로 데이터를 처리하기 쉽다는 장점이 있는 YOLO를 선택하였다.

Table 4-1 Comparison of object detection algorithms.

특징	YOLO	R-CNN	Fast R-CNN	Faster R-CNN	SSD (Single Shot MultiBox Detector)
속도	매우 빠름 (real-time 가능)	느림	중간	빠름	매우 빠름
정확도	높음	매우 높음	높음	매우 높음	높음
처리 단계	단일 단계 (end-to-end)	다단계 (region proposal, classification, etc.)	다단계 (region proposal, classification, etc.)	다단계 (region proposal, classification, etc.)	단일 단계 (end-to-end)
실시간 처리 가능 여부	가능	불가능	제한적 가능	제한적 가능	가능
복잡도	낮음	높음	높음	높음	낮음
알고리즘 구조	단일 네트워크	다중 네트워크	단일 네트워크	단일 네트워크	단일 네트워크
주요 특징	전역 컨텍스트를 사용한 객체 감지	선택적 검색을 통한 region proposal	ROI Pooling 사용	Region Proposal Network (RPN) 사용	멀티 박스 객체 감지
장점	속도가 매우 빠르고, 실시간 처리가 가능	높은 정확도와 세밀한 객체 감지 가능	빠른 처리 속도와 높은 정확도	R-CNN 계열 중 가장 빠른 처리 속도	빠른 처리 속도와 좋은 정확도
단점	작은 객체 감지에 약함	느린 속도	구현 복잡도가 높음	구현 복잡도가 높음	작은 객체 감지에 약함

4.2 시스템비계 설치 적정성 판단을 위한 YOLOv5 기반 모델링

YOLOv5 기반의 모델 설계를 위해서는 데이터 수집부터 모델 평가까지 전과정에 대한 검토가 요구되며, 본 절에서는 각각에 대한 성능 개선 정도를 평가해 본 연구의 System SCaffold AI for Risk Forecasting (SSCARF) 최적 구조를 도출한 과정에 대해 설명한다. 즉 각 비계의 설치 적정성 판정 결과에 따라 빨강 또는 녹색 스카프를 매어 구분해준다는 의미이다.

4.2.1 데이터 수집 및 전처리

Table 4-2에서 보듯이, 아파트, 빌라, 근린생활시설 등 다양한 현장에서 스마트폰 (Galaxy S20+5G, 모델명 SM-G986N, 후면 카메라 12.0 MP + 12.0 MP + 64.0 MP + VGA, 사진 모드, 오토포커스)을 이용해 연구자가 직접 촬영한 비계의 이미지를 토대로 데이터 셋을 구성하였다. 3개월의 시간이 소요되었으며, 3.4에서 세운 기준에 따라 5가지 자재의 설치 적정성을 판단할 수 있는 이미지를 확보하였다.

각 자재별 기준에 따라 정상설치와 비정상 설치를 나누었으며, 같은 자재이더라도 다른 양상을 보이는 경우에는 더 세분화하여 총 14가지로 분류하였다:

- 받침철물 (2): 바닥면과 밀착된 상태로 설치되지 않았을 경우 비정상 설치로 판단하였다.
- 벽이음재 (3): 벽에 제대로 밀착되어 있지 않은 경우를 비정상 설치로 판단하였으며, 나무 자재로 된 경우에는 나무 재질로 설치된 벽이음재로 따로 분류하였다.
- 고정핀 (2): 핀의 끝부분이 아래로 튀어나와 단단하게 연결된 경우를 정상으로 가정하였으며, 핀이 수직이 아닌 경우나 끝까지 단단히 고정하지 않은 경우를 비정상으로 분류하였다. 또한, 전문가의 의견에 따라 핀이 애매하게 위치한 경우에 대해 정상과 비정상을 분류하였다.
- 발판 (5): 발판과 연결 고리의 두 가지 케이스로 나누어 분류하였는데, 발판이 한쪽이라도 연결되어있지 않은 경우 또는 겹쳐져 설치된 경우를 비정상의 두 가지로 나누어 분류하였다.
- 수평재 (2): 수직으로 설치되어있지 않은 경우, 고정핀이 아닌 번선으로 묶어놓

은 경우를 비정상으로 분류하였다.

Table 4-2 Collection of image data by picture taking at construction sites.

	공사명	지역	공사종류(규모)	수집기간	이미지 갯수
초기 수집 200장	오산세교2지 구 18블럭 공동주택 신축공사	경기	공동주택 골조공사 (380세대)	2023.08.04~08 .05	60
	OO건설 이O동 OO파크	서울	공동주택 석공사 (4,321세대)	2023.08.14~08 .17	50
	인덕원 자이 SK VIEW	경기	공동주택 골조 (994세대)	2023.08.23~08 .24	40
	연희동 400-O 현장	서울	근린생활시설 골조 (지상5층)	2023.09.09	50
추가 수집 261장	OO빌라 재건축 현장	서울	공동주택 골조 (지하1층~지상9층)	2023.10.10.~1 0.11	90
	연희동 400-O 현장	서울	근린생활시설 골조 (지상5층)	2023.10.07~10 .09	171

라벨링의 기준은 Table 4-3과 같으며, 5개 자재를 총 14개의 라벨로 분류하였다. 이를 라벨링 수행 결과 데이터 분포는 또한 Fig. 4.2와 같다.



Fig. 4-2 Labeling distribution of 200 image data by class.

Table 4-3 Data label for AI model development: 6 normals and 8 abnormals.

라벨명	해당 자재	라벨 의미
AbnormalBase	반침철물	잘못 설치된 반침철물
AbnormalConnector	벽이음재	잘못 설치된 벽이음재
AbnormalPin	고정핀	잘못 설치된 고정핀
AbnormalRing	발판 연결 고리	잘못 설치된 발판 연결 고리
Base	반침철물	제대로 설치된 반침철물
Connector	벽이음재	제대로 설치된 벽이음재
Horizon	수평재	제대로 설치된 수평재
NoneConnectHorizon	수평재	연결되지 않은 수평재
NoneConnectWalkboard	발판	연결되지 않은 발판
Pin	고정핀	제대로 설치된 고정핀
Walkboard	발판	제대로 설치된 발판
WalkboardClash	발판	겹쳐서 설치된 발판
WellconnectedWalkboard	발판 연결 고리	제대로 설치된 발판 연결 고리
WoodConnector	벽이음재	나무 재질로 설치된 벽이음재
합계	5	14

4.2.2 이미지 수집 및 크기 조정

초기 개발단계에서는 200장의 비계 이미지를 사용하였으나, 모델 개발과정에서 데이터의 수가 부족하여 추가 수집(Table 4-2 참고)을 통해 총 461장으로 확보하였다. 데이터를 추가하는 과정에서 Fig. 4-3과 같이 똑같은 자재에 대해 다양한 각도로 촬영하여 데이터를 확보하였으며, 전처리 단계에서는 모델의 개발 전 각 이미지의 크기를 모두 640x640으로 동일하게 설정하여 모델이 학습할 수 있도록 하였다.

4.2.3 데이터 labeling

이미지 크기를 통일한 이후, 각 자재별 정상과 비정상으로 분류하여 앞 절에서 언급

한 바와 같이 라벨링을 진행하였으며, 라벨링된 데이터를 활용한 지도학습 방식을 채택하였다. 즉, 하나의 이미지와 해당 이미지에 대한 명확한 정의를 내린 라벨로 구성되는 데이터 세트를 생성하였으며, 라벨링 과정에서는 Roboflow annotate를 사용하였다. Roboflow는 그림과 같이 동시에 서로 다른 여러 객체를 라벨링 할 수 있으며, 바운딩 박스를 사용자가 그리는 형태로 라벨링을 수행하게 된다. 또한 라벨링한 데이터를 손쉽게 찾아보고 확인할 수 있어 라벨링을 보다 수월하게 수행할 수 있다.

라벨링 결과는 Fig. 4-4과 같이 이미지와 라벨로 나타난다. 각 자재를 사각형 모양으로 표시하였으며, 해당 자재가 정상적으로 설치되어있는지에 대한 라벨링을 수행한 결과이다. Fig. 4-4의 라벨에서 나타난 숫자가 의미하는 것은 각각 객체의 클래스 ID, 이미지 너비 기준으로 한 경계상자 중심의 x 좌표, 이미지 높이를 기준으로 한 경계상자 중심의 y 좌표, 이미지 너비에 대한 경계 상자의 너비, 이미지 높이를 기준으로 한 경계 상자의 높이를 나타낸다.




Fig. 4-3 A series of images capturing the same object from various perspectives.




Fig. 4-4 Labeling example.

라벨링 수행 결과는 Fig. 4-5과 같으며, 가장 많이 등장한 것은 연결용 고정핀이었다. 총 461장의 이미지에서 315번 등장하였으며, 제대로 설치된 수평재가 172번, 제대로 설치되지 않은 수평재가 121번 등장하였다.

5가지 자재 중 고정핀과 수평재가 충분한 데이터 양을 확보할 수 있었던 것에 비해, 가장 데이터가 부족했던 것은 벽이음재였다. 정상 설치된 벽이음재가 58번, 비정상 벽이음재가 14번, 나무 재질 벽이음재가 8번 등장하여 관련 데이터가 부족함을 확인하였다.

또한 받침철물의 경우 명확하게 두 가지 라벨로 분류되었기 때문에 확보된 데이터보다 모델링 과정에서 성능이 우수하게 나올 수 있음을 확인하였다. 다만 발판의 경우 정상설치된 발판, 발판의 연결고리, 겹쳐서 설치된 발판 등 여러 라벨로 분류되어 실제 확보된 데이터만큼의 성능을 보이기 어려울 수 있음을 확인하였다.

Fig. 4-2 및 Fig. 4-5과 같이 데이터의 분포가 불균형하기 때문에 모델의 전체 성능이 고르게 우수하기 어려울 수 있지만, 고정핀 수평재와 같은 데이터 양이 충분한 개별 클래스의 모델 성능은 높을 수 있을 것으로 판단되었다.

Class Balance

all train valid test



Fig. 4-5 Labeling distribution of 461 image data by class.

4.2.4 학습 및 평가 데이터 분할

본 연구에서는 Fig. 4-6과 같이 461장의 이미지 중 411장을 학습용으로, 30장을 validation 평가, 20장을 테스트로 이용하여, 약 90%의 데이터를 학습에 사용하였고 나머지 10%를 모델 성능평가에 사용하였다. 모델 성능평가에 사용되는 평가와 테스트 데이터 셋에 가장 데이터가 적은 발판이 연결되지 않은 경우와 나무로 된 벽이음재를 제외하였으며, 나머지 12개 라벨은 모두 포함될 수 있도록 하였다. 평가 데이터 셋은 학습을 마친 모델을 이용해 최종적으로 가중치를 조정하는 단계이며, 테스트 데이터 셋은 모델의 최종 성능을 평가하기 위한 데이터 셋이다.




Fig. 4-6 Splitting data sets for machine learning model training.

4.2.5 사용 데이터 및 YOLOv5 모델 학습 조건

본 연구의 개발 시스템 System SCaffold AI for Risk Forecasting (SSCARF)는 시스템

비계 설치의 적정성을 판정하기 위해 크게 5가지 자재에 대해 14가지 case로 정상 설치와 비정상 설치에 대해 분류하였다.

SSCARF모델의 성능평가지표는 다양한 성능평가지표 중 mAP를 사용하였다. mAP는 객체 탐지에서 가장 널리 사용되는 지표이며, 다중 클래스 객체를 탐지하는데 매우 유용하며, 모델이 객체를 얼마나 잘 찾아내는지, 탐지된 객체가 정확하게 맞는지를 모두 고려할 수 있다. mAP를 계산하기 위해, 예측된 경계상자와 실제 경계 상자 간의 겹침 정도를 다양하게 설정하여, 다양한 IoU에서 성능평가가 가능하다는 장점이 있으며, 개발된 다수의 객체 탐지 모델의 성능평가가 mAP 기반으로 수행되었기에, 벤치마킹 및 비교 평가에서도 유리하다는 장점이 있다.

이와 반대로 accuracy의 경우 단일 클래스 감지에 특화되어 있어서 다수의 클래스를 탐지하는 본 연구의 문제와 맞지 않아 제외하였다. F1 Score의 경우 불균형 데이터 셋에 대해 소수 클래스를 얼마나 잘 처리하는가에 대한 평가에 유리하며, 오류 비용이 높은 경우에 적합하다. 하지만 본 연구에서는 가장 수가 적은 2가지의 클래스를 제외하고 학습하였으며, 잘못된 탐지에 대한 높은 성능이 요구되지는 않아, F1 Score를 사용하지 않았다. 따라서 다중 클래스 감지에 적합하며, 실제로 객체의 위치와 정확한 탐지에 적합한 mAP를 성능평가지표로 사용하였다.




Fig. 4-7 Design flowchart of SSCARF AI model.

개발과정은 Fig. 4-7과 같이 수행되었으며, 건설 현장에서 촬영된 이미지를 확보하여, 데이터 전처리 과정을 거쳤다. 이후 데이터 셋을 분류하고 학습데이터에 데이터 증강 기법을 통해 부족한 데이터 양을 보충하였으며, 최종적으로 YOLOv5 모델을 활용하여 각 클래스 별 분류를 수행하였다. 연구의 초기단계에서는 200장의 비계 이미지를 확보할 수 있었으며, 이를 이용해 초기 모델을 개발하였다. 이후 앞의 200장을 포함한 총 461장의 비계 이미지를 사용하여 연구를 수행하였다.

학습된 모델은 precision-recall curve를 통해 도출된 mAP를 이용하여 성능을 평가하였으며, 4.1.2에서 수행한 라벨링된 데이터를 이용하여, YOLOv5 모델을 학습시켰다. 총 5가지 자재에 대한 정상, 비정상 분류를 위해 local 환경에서 학습을 수행하였으며, Ultralytics의 사전학습된 YOLOv5 중간 크기 모델을 선택하여 속도와 정확도의 균형을 고려하였다. RTX 4070 GPU를 활용하여 학습시켰으며, 학습에 대략 10분이 소요되었다.

4.3 모델 설계 및 개선

4.3.1 학습 데이터 양에 따른 성능 변화

(1) 200장의 이미지 학습

첫번째 개발 모델은 200장의 데이터를 학습하였고, 성능평가지표인 mAP 기준 18.6%의 성능을 보였다. 제대로 객체를 탐지하지 못하였기에, 데이터의 수가 절대적으로 부족함을 확인하였다. Fig. 4-8과 같이 mAP는 18.6%, recall 값이 14.4%로 낮은 값을 보였지만, precision 값이 82.3%로 비교적 높은 성능을 보였다.




Fig. 4-8 Performance metrics of the first model.

Recall 값은 모델이 실제 객체 중 얼마나 많은 객체를 감지하는지를 측정하는 것으로 14.4%라는 것은 대부분의 객체를 감지하지 못하고 있음을 의미한다. Precision 값은 모델이 감지한 객체 중 실제로 정확한 개체의 비율을 의미하는 것으로 값이 82.3%로 비교적 높다는 것은 모델이 한 번 특정 객체를 감지했을 때, 정확하게 감지하고 있음을 의미한다.

따라서 mAP가 18.8%인 초기 모델의 경우 총 12개의 예측해야 하는 라벨 중 대부분을 감지하지 못했지만 감지가 가능한 특정 라벨 몇 개의 경우는 정확하게 예측할 수 있음을 의미한다. 이를 통해 모델이 전체 클래스에 대한 탐지가 정확하지 않지만, 특정 클래스의 경우 비교적 정확하게 잡아낼 수 있으며, 4.1.3의 데이터 분포를 확인하였을 때, 감지하지 못한 클래스의 데이터 양이 부족하다는 것을 추론할 수 있었다.

(2) 추가 이미지 확보 및 학습

초기 개발 모델의 결과를 반영하여 추가로 데이터를 확보해 기존 200장을 포함한 총 461장의 데이터를 사용하였다. 두 번째 개발 모델의 결과 mAP 기준 60.4%로 성능 향상을 확인할 수 있었으나, 여전히 그 성능이 실사용하기에는 부족함을 확인하였다. 다만 데이터의 수가 증가할수록 모델의 성능이 개선됨을 확인하였기에, 부족한 데이터를 보충하기 위해 데이터 증강을 시도하여 최종적으로 모델을 개선하였다.

Fig. 4-9에서 461장의 이미지를 학습시킨 모델의 경우에는 epoch 200-250회까지 성능이 개선되며, 200회 이후 성능 향상율이 둔화되는 것을 확인하였다. 또한 epoch 400회까지 train loss가 꾸준히 감소하는 것에 비해, mAP 성능이 개선되지 않고 수렴하는 것을 확인할 수 있었다. 이러한 결과는 모델의 과적합 또는 데이터 품질 또는 데이터의 불균형 때문에 발생한 문제일 확률이 높은 경우이며, 따라서 데이터 양의 문제보다 확보된 데이터에 대한 추가적인 분석이 필요함을 확인하였다.




Fig. 4-9 The results of training YOLOv5 with 461 images.

4.3.2 YOLOv5 중 적정 모델 크기의 선정

YOLOv5 모델링 과정에서 데이터 셋을 증강하는 것 이외에도 모델의 파라미터를 수정하여, 성능이 어느 정도 개선되는지를 확인하였다. 가장 첫 번째 파라미터는 학습된 모델의 크기를 달리 시도하였으며, 461장의 이미지에 작은 모델인 YOLOv5s, 중간 크기의 YOLOv5m, 큰 모델인 YOLOv5l을 각각 적용하여 비교하였다.

YOLOv5s의 경우 파라미터는 약 720만개이며, depth multiple이 0.33, width multiple이 0.50이며; YOLOv5m은 파라미터 약 2,120만개, depth multiple이 0.67, width multiple이 0.75이다. YOLOv5l의 경우 파라미터 약 4,700만개, depth multiple과 width multiple은 1.0이다[19]. 여기서 depth multiple과 width multiple은 기본 YOLO 구조의 레이어 깊이와 너비에 비례하는 값을 의미하며, 기존 레이어 개수에 각 multiple을 곱하여 그 개수를 결정하는 방식이다. 단순히 학습된 데이터 수의 차이가 있을 뿐만 아니라 레이어의 깊이와 너비 역시 다르기에 그 성능의 차이가 더욱 크다.




Fig. 4-10 YOLOv5 performance by model size

모델 크기에 따른 성능 비교 결과는 Fig. 4-10과 같으며, 각 성능은 작은 모델이 58.7, 중간 모델은 60.4, 큰 모델은 61.0으로 나타났다. 모델의 크기에 따른 성능은 약

간의 변화만 있을 뿐 크게 변화하지 않았는데, 학습시간은 작은 모델이 약 7분, 중간 모델이 약 10분, 큰 모델이 약 12분 정도가 소요되었다. 학습시간의 변화에 비해, 모델 성능은 크게 향상되지 않았기에 중간 크기의 모델을 선택하는 것이 합리적이라 판단되어 중간 크기의 모델을 선택하여 연구를 수행하였다.

4.3.3 모델 입력 이미지 크기의 설계

다음은 입력 이미지의 크기를 다르게 하였으며, 마찬가지로 작은 크기의 이미지, 중간 크기의 이미지, 큰 크기의 이미지를 활용하여 학습시켰다. 마찬가지로 461장의 이미지를 사용하였으며, 작은 크기는 440x440, 중간 크기는 640x640, 큰 크기는 840x840으로 이용하였으며, 모델의 결과는 Fig. 4-11와 같았다.

이미지 확대는 Roboflow를 통해 수행하였으며, 보간법을 통해 이미지를 확대하더라도 해상도에 변화가 없도록 하였다. 640x640 크기의 이미지를 학습시킨 경우가 가장 성능이 좋았다. 보통 이미지의 크기가 작아지는 경우 작거나 미세한 특징을 잘 학습하지 못하기 때문에 440x440 크기의 이미지를 사용할 때, 감지 성능이 크게 떨어지는 것




Fig. 4-11 Performance by input data size.

을 확인하였다. 더 큰 이미지를 이용하면 연산시간이 크게 늘어날 수 있으나 미세한

특징은 잘 감지할 수 있을 것으로 판단하였으나, 결과는 이와 달리 오히려 성능이 떨어짐을 확인할 수 있었다.

YOLOv5는 기본적으로 640x640 픽셀의 입력 크기로 훈련되기 때문에 640x640 크기의 이미지를 사용했을 때, 모델에 최적화되어 비교적 성능이 높았다고 볼 수 있다. 모델이 학습하는 동안 보지 못한 크기의 객체를 처리했기 때문에 큰 이미지를 사용하더라도 비교적 좋은 성능을 보이지 못했다고 추론할 수 있다. YOLOv5가 다양한 크기의 객체를 인식하여 강건한 성능을 낼 수 있도록 설계되었으나, 640x640 이미지를 미리 학습한 모델을 사용하였기에 중간 크기의 이미지를 사용하였을 때 성능이 우수함을 확인하였다.

4.3.4 컬러 vs. 흑백 이미지에 따른 성능 검토

다음은 학습 이미지를 흑백 또는 컬러 두 가지로 학습시켰다. 두 경우 모두 461장의 이미지를 사용하여 학습시켰으며, 앞서 데이터 분석과정에서 배경색이 크게 영향을 미칠 수 있음을 확인하였기에 두 경우로 나누어 학습시킨 결과는 Fig. 4-12와 같았다.




Fig. 4-12 Comparison between gray-scale and color.

기존 색깔이 들어간 이미지를 학습시킨 경우는 60.4였으며, 흑백처리를 한 이후의

성능이 64.7로 향상되는 것을 확인하였다. 다만 여전히 유의미한 정도의 향상을 보이지는 않았으며, 추가적인 데이터 전처리 및 증강을 통해 성능을 향상시켜야 함을 확인하였다. 모델의 파라미터를 수정하여 640x640 크기의 이미지를 입력값으로 사용하였으며, 연산시간과 성능을 모두 적절히 보장하는 YOLOv5m을 선택하여 모델을 개발하였다. 흑백처리를 하는 경우 성능이 향상되는 것을 확인하였기에, 데이터 증강 과정에서 흑백처리를 포함하였다.




Fig. 4-13 The results of K-means clustering.

4.3.5 군집화 분석 및 편향 제거

기존의 데이터와 추가 확보된 데이터를 모두 분석하기 위해 k-means 알고리즘을 활용하여 군집화를 수행하였다. 총 5개의 군집으로 분류하였으며, 그 결과 이미지의 배경색이 이미지를 인식할 때 크게 영향을 끼칠 수 있음을 확인하였다. Fig. 4-13에서 확인할 수 있듯이, (A) 이미지 군집은 배경이 파란색이며, (B) 군집의 경우 비교적 배경이 회색인 이미지가 포함되고 있음을 확인하였다.

이와 같은 군집화 결과를 고려하였을 때 YOLOv5 모델 역시 입력된 데이터의 배경색에 큰 가중치를 부여할 수 있을 것으로 판단되며, 이러한 편향을 제거하기 위해, 데이터를 흑백처리 하였다.

4.3.6 데이터 증강

현재 클래스 별 데이터의 수가 크게 차이나기 때문에 데이터의 불균형을 방지하기 위한 다양한 방법의 데이터 증강 방식을 적용하여, 총 411장의 이미지를 1,233장으로 세 배 증가시켰다: 흑백처리, 노이즈 삽입, 이미지 좌우반전, 다양한 각도로 회전, 이미지 중간에 경계상자를 삽입하거나 회전시키는 방식의 데이터 증강을 수행하였다. 데이터 증강은 전체 이미지를 각도를 비틀었으며, 이미지 중간에 회전된 이미지를 추가하였고, 검정색과 하얀색의 노이즈를 섞었다.

이미지 회전은 Fig. 4-14처럼 모델이 다양한 각도에서 객체를 인식할 수 있도록 하며, 회전된 객체를 감지할 수 있도록 학습을 개선시킬 수 있다. 이미지 회전 기법은 카메라 각도가 변동되기 쉬운 모바일 또는 드론 기반의 시스템에서 특히 유용하다[35].




Fig. 4-14 Original image and rotated image.

이미지 반전은 Fig. 4-15과 같이 이미지를 수평 또는 수직으로 반전시키는 것인데, 모델이 다른 방향성을 가진 이미지, 좌우대칭인 이미지를 일반화하는 것을 도와준다. 본 연구에서는 좌우대칭 형태인 받침철물, 서로 다른 방향으로 자주 설치되는 수평재 등에 효율적일 것으로 판단하여 증강과정에 포함하였다.




Fig. 4-15 Original image and flipped image.

임의의 노이즈를 이미지에 추가하는 노이즈 삽입 기법은 Fig. 4-16처럼 노이즈가 많은 환경에서 객체를 안정적으로 감지할 수 있게 한다. 이는 실제 환경에서 발생하는 이미지 해상도 저하나 왜곡에 대한 강건성을 확보하는 데 큰 도움이 된다[42].




Fig. 4-16 Original image and noised image.

흑백처리는 모델이 색상정보에 의존하지 않고 형태와 질감 등의 다른 시각적 특성만을 사용하여 객체를 인식할 수 있게 한다. 본 연구에서는 이미지를 감지하는 과정에 색상이 큰 영향을 미칠 수 있을 것으로 판단하여 Fig. 4-17과 같이 데이터 증강에 포함하였다.




Fig. 4-17 Original image and gray scaled image.

바운딩 박스의 회전은 Fig. 4-18와 같이 기존의 축에 평행한 형태인 사각형의 바운딩 박스가 제공하기 어려운 회전한 객체의 정보를 인식할 수 있도록 도움을 준다. 특

히 경사진 도로, 기울어진 글씨가 적힌 간판 등 다양한 각도의 객체 탐지에 효과적이다. 본 연구에서는 설치된 비계가 사선으로 설치된 경우 또는 실제 이미지를 촬영할 때 회전된 형태가 다수 포함되었기에 해당 기법을 통해 데이터를 증강시켰다.




Fig. 4-18 Original image and bounding box rotated image.

Fig. 4-19과 같이 노이즈 삽입을 통해 바운딩 박스 안의 객체가 일부만 보이거나 부분적으로 가려진 경우에도 적용할 수 있도록 한다[9]. 각 객체의 바운딩 박스에 무작위로 노이즈 삽입하는 것은 특정 훈련 샘플의 바운딩 박스에 과적합되는 것을 방지한다.




Fig. 4-19 Original image and image with noise added to bounding box.



Fig. 4-20 Images of (A) original and (B) processed by gray scale + noise insertion.

본 연구에서는 위에서 언급한 6가지의 데이터 증강기법을 단일 또는 여러 가지를 동시에 적용하여 데이터 증강을 수행하였다. Fig. 4-20의 (A)는 원본 이미지이며, (B)는 흑백처리와 노이즈를 삽입한 이미지이다. 수평재가 비정상 설치된 사례이며, 데이터 전처리 과정을 통해 (A)의 이미지를 (B)로 변환시켜 학습에 이용하였다.

Fig. 4-21는 동일한 이미지에 대한 서로 다른 전처리 사례이다. (A)는 원본 이미지를 회전시키고 추가로 감지해야 할 객체가 있는 바운딩박스를 같이 좌우 반전한 사례이다. Fig. 4-21의 (B)는 (A)의 전처리과정에 추가로 흑백처리와 노이즈까지 삽입한 사례이다. 본 연구에서는 Fig. 4-20, 4-21와 같은 전처리를 통해 데이터 증강을 수행하였다.

4.3.7 증강 이후의 데이터 분포

이러한 데이터 증강을 통해 다양한 데이터 패턴을 학습함으로써 훈련 데이터에 대한 모델의 과적합을 감소시킬 수 있으며, 데이터의 다양성을 증가시켜 같은 객체에 대해 조명, 회전, 크기, 배경 등에 대해 크게 영향을 받지 않고 감지하도록 만들 수 있었다. 또한 초기 모델 개발에서 발생한 불균형 데이터를 증가시켜, 해당 클래스의 감지 정확도를 개선시킬 수 있었다.

데이터 증강 이후 데이터의 분포는 Fig. 4-22과 같으며, 가장 많은 연결핀의 사례를 확인하였을 때 증강 전 대비 2배 정도 증가되었으며, 비교적 적은 데이터인 벽이음재

관련 데이터의 경우 약 3배 정도 증가하였으며, 각 클래스별로 50개 이상의 데이터를 확보하여 학습시킬 수 있었다.



(A)



(B)

Fig. 4-21 Rotation of the entire image and bounding box, grayscale, noise insertion.




Fig. 4-22 Distribution of YOLO data by label after augmentation.

4.4 결과: 개발 SSCARF 시스템의 성능 평가 및 해석

4.4.1 사용 데이터 양에 따른 성능 변화

YOLOv5를 이용한 학습 결과는 Table 4-4와 같으며, 앞 절에서 논의된 바와 같이 사용된 데이터가 늘어날수록 그 성능이 향상됨을 확인할 수 있었다. 첫 번째 200여 장의 데이터를 200번 학습한 case에서는 mAP가 18.6%으로 상당히 낮았으나, 데이터를 추가 확보하여 461장으로 늘린 결과, 60.4%까지 성능이 개선되었다.

최종적으로 데이터 증강을 수행하여 데이터의 편향과 과적합을 제거하고 두 번째 모델 대비 3배까지 학습량을 늘렸을 때 80.8%로 성능이 대폭 개선됨을 확인할 수 있었다: 다양한 전처리와 데이터의 추가 확보를 통해 모델의 성능을 높일 수 있었다.

Table 4-4 The performance of the model according to the amount of data.

사용 데이터 수	성능 (mAP@50)
200	18.6%
461	60.4%
1,283	80.8%




Fig. 4-23 Performance by epoch

4.4.2 학습 횟수에 따른 성능 변화

증강한 데이터를 활용한 학습 횟수에 따른 성능 비교는 Fig. 4-23와 같다. 학습과정 중 가장 최고성능으로 비교하였을 때, epoch 200일 때 80.8, 400과 600일 때는 81.2로 동일한 성능을 보였다. epoch 200 이후로는 성능의 개선이 거의 이루어지지 않았음을 확인하였으며, 계산시간은 배 이상으로 증가했기에, 계산시간과 성능을 고려해야 하는 객체탐지가 목표인 본 연구에서는 200회를 기준으로 하여 성능을 평가하였다.

Fig. 4-24과 4-25을 확인해보았을 때, 단순 수치로 보이는 성능 이외의 모델의 감지 능력을 확인할 수 있었다. 그림은 라벨링이 완료된 테스트 데이터 셋으로 모델의 입력으로 사용되었으며, Fig. 4-25은 모델의 예측결과로 Fig. 4-24의 데이터를 입력으로 사용하였을 때의 결과가 Fig. 4-25이다. Fig. 4-24의 입력과 Fig. 4-25의 결과를 확인하였을 때, 왼쪽 가장 위의 사진을 확인해보면 입력 데이터에 발판이 없음에도 발판을 감지하는 것을 확인할 수 있다. 또한 가장 위 왼쪽에서 세 번째 사진에서 입력 데이터에 라벨링이 되어있지 않음에도 불구하고, 모델이 연결핀을 정확히 예측하고 있음을 확인할 수 있었다. 이러한 경향은 연결핀과 수평재와 같이 라벨링 된 학습 데이터가 많았던 경우에 자주 발생하였으며, 이를 통해 데이터가 충분한 상황에서는 클래스 별 성능




Fig. 4-25 The prediction results of SSCARF

4.4.3 분류 클래스별 성능 평가

Fig. 4-26과 같이 평가 데이터 셋을 이용한 결과를 확인하였을 때, Precision-Recall Curve를 통해 각 클래스별 성능과 전체 모델 성능을 확인할 수 있었다.




Fig. 4-26 Performance using the test dataset.

가장 성능이 높았던 것은 비정상적으로 설치된 받침철물, 비정상 설치된 벽이음재, 비정상적으로 설치된 연결핀, 비정상적으로 설치된 발판 고리였다. 이와 반대로 정상 설치된 발판의 경우 0.086으로 전혀 감지하지 못하였으며, 정상설치된 수평재의 경우 0.477, 정상설치된 연결핀이 0.797, 연결되지 않은 수평재가 0.742로 상대적으로 낮은 성능을 보였다. 다만, 수평재와 연결핀의 경우 학습된 데이터가 가장 많았기 때문에, Fig. 4-24과 4-25에서 확인했듯이 라벨링이 되어있지 않은 데이터에 대해 정확한 답을 제시했으므로 수치적으로 보이는 성능보다 더 정확하게 감지하고 있음을 확인할 수 있었다. 즉, 라벨링 자체가 잘못되었음에도 불구하고 감지해낸 경우가 있었기 때문에 보다 정확한 데이터 셋을 활용할 경우에는 그 성능을 정확히 판정할 수 있을 것이다.

마지막 테스트 데이터 셋을 이용한 클래스 별 최종 결과는 Fig. 4-27과 같으며, 전체 모델의 성능은 0.808로 비교적 우수한 성능을 보였다. 모델의 출력 결과 역시, 평가와 비슷한 결과를 확인할 수 있었으며, 테스트 결과와 마찬가지로 정상설치된 발판고리에 대해 명확히 잡아내지 못함을 확인하였다. 또한 수평재와 연결핀 관련 성능이 비교적 낮게 나와 평가 결과와 비슷함을 확인하였다.

Class	Images	Instances	P	R	mAP50	mAP50-95:
all	30	79	0.692	0.704	0.808	0.465
AbnormalBase	30	1	1	0	0.995	0.597
AbnormalConnector	30	1	0.635	1	0.995	0.398
AbnormalPin	30	1	0.45	1	0.995	0.697
AbnormalRing	30	4	1	0.921	0.995	0.681
Base	30	4	0.802	0.75	0.912	0.631
Connector	30	7	0.836	0.857	0.84	0.355
Horizon	30	14	0.634	0.571	0.479	0.282
NoneConnectHorizon	30	6	0.69	0.747	0.742	0.373
Pin	30	35	0.632	0.8	0.829	0.415
Walkboard	30	2	0.63	0.891	0.828	0.663
WalkboardClash	30	2	1	0.911	0.995	0.457
WellconnectedWalkboard	30	2	0	0	0.0859	0.0344

Fig. 4-27 Final results by class.

테스트와 평가 모두에서 가장 성능이 낮았던 정상설치된 발판에 대해 확인했을 때, Fig. 4-28과 같이 연결고리를 중심으로 정상설치를 라벨링 했음을 확인할 수 있었다. 다만, 연결고리를 바라보는 시점과 각도가 지나치게 달랐기 때문에, 학습과정에서 문제가 생겼음을 유추해볼 수 있었다. 따라서 해당 데이터 셋은 정상, 비정상 설치의 기준을 더 세분화하여 라벨링을 수행하거나, 더욱 많은 데이터를 확보하는 방식을 통해 성능을 개선시킬 수 있을 것으로 보인다.



Fig. 4-28 Case of properly installed scaffolding platform connector.

4.5 개선사항 및 토의

본 연구에서는 시스템비계의 설치 적정성 판단을 위한 이미지 분류 기반의 기계학습 모델을 YOLOv5를 활용해 개발하였다. 여러 자재 중 작업발판, 받침철물, 수평재, 연결핀, 벽이음재 다섯가지 자재에 대해 설치 적정성 판단을 진행하였으며, 총 14가지 라벨로 정상과 비정상으로 분류하여 연구를 수행하였다. 14가지 라벨 중 특히 작업발판과 관련하여 성능이 비교적 떨어지는 것을 확인할 수 있었으며, 입력 데이터를 검토한 결과 더 많은 데이터를 확보하거나 정상 및 비정상 데이터를 더 세분화할 필요가 있음을 확인하였다.

현재 SSCARF ver. 1은 보다 간단한 라벨에 대해 분류하여 탐지하고 있으며, YOLOv5 기반이기에 이미지로 판단하기 어려운 각 자재의 길이, 각도에 대한 규정은 제외하고 있다. 따라서 YOLO 이외에도 여러 추가적인 처리 과정과 기술을 통해 가새의 각도 등에 대한 규정 역시 반영할 수 있도록 개발할 필요성이 있다. 이 과정에서 컴퓨터 비전 분야에서 널리 사용되는 카메라 캘리브레이션 등의 기술을 통해 추가 보정을 통해 보다 복잡한 모델을 개발할 수 있다. 이 과정을 통해 현재 개발 모델에서 추가로 감지 가능한 사례로 Table 4-5와 같이 수직재, 가새재, 벽이음재, 추락 방호망, 작업발판에 관련한 규정을 향후 반영하고자 한다.

Table 4-5 Additional possible cases.

추가 가능한 목표	적정성 확인
수직재, 받침철물	겹침길이 (1/3)준수여부
가새재	설치 각도 규정
벽이음재	설치간격. 고정상태
작업발판	발판 폭. 틈 간격. 겹침부 고정상태
추락 방호망 길이/폭	겹침길이/설치 폭

현재 개발 모델은 이미지를 기반으로 하여 현장에서 적용 시, 현장의 사진을 촬영한 이후 또는 edge에서 즉시 판별하는 방식이다. 연구 과정중 수집 이미지는 동일 기기로 촬영되어 다양성 및 강건성이 부족한 측면이 있으나, 다양한 현장 데이터의 수집과 학

습이 이루어지면 드론이나 로봇 탑재 방식으로든 운영이 가능할 것으로 기대된다.

4.6 객체탐지 기반의 시스템 건전성 판별 AI 구축 가이드라인

본 연구는 건설현장에서 시스템비계의 설치 적정성 판정에 집중하였으나, 촬영 이미지의 기계학습을 기반으로 이외 적정성 판정 기법은 설계 및 계획, 시공관리, 안전관리, 품질관리 등 여러 공종분야에서 다양한 형태로 AI의 적용이 가능하다. 본 연구에서는 다음과 같이 개발 절차 및 가이드라인을 제안하며, 이를 활용하면 건설현장에서 안전을 확보하기 위한 다양한 건전성 판별 AI 시스템 구축이 용이할 것으로 보인다 (Fig. 4-29 참고):

- 1) 이상 종류, 기준 설정
- 2) 이미지를 포함한 센싱 정보 및 수집 H/W의 선정
- 3) (이미지) 데이터 수집: 현장 직접 수집, 공개 DB 활용 등
- 4) 데이터의 양, 품질, 현장 다양성 확보
- 5) 데이터 전처리 및 전문가 지식을 활용한 labeling
- 6) 데이터 부족시 증강: 흑백 처리, 노이즈 삽입, 이미지 좌우 반전, 다양한 각도로 회전, 이미지 중간에 경계상자를 삽입하거나 회전시키는 방식 등
- 7) 기계학습 방법의 선정
- 8) 필요시 객체 감지 병행
- 9) 구축을 용이하게 하는 pretrained, foundation model 등 활용 결정
- 10) 모델 학습, 성능 평가 및 개선
- 11) 현장 적용: 수동/자동 및 이동형/고정형
- 12) 지속적 모델 갱신 (MLOps)




Fig. 4-29 AI development guidelines for fault detection at construction sites.

본 연구에서는 제안된 가이드라인을 따라 시스템 비계를 분석 대상으로 선정하였으며, 데이터 수집 과정에서 법적 기준, 재해사례 등을 고려하여 시스템 비계의 특정 자재에 초점을 맞춰 데이터를 수집하였다. 데이터 라벨링 과정에서 건설현장 경력이 풍부한 전문가의 자문을 받아 라벨링을 수행하였으며, 활용도를 고려하여 실시간성이 우수한 YOLOv5 모델을 선정하여 연구를 수행하였다. 모델 개발과정에서는 학습을 반복하여 여러 파라미터를 수정해나가 모델의 성능을 개선할 수 있었다. 더 나아가 개발 시스템을 현장에 적용하고 지속적인 유지보수를 통해 시스템 비계 관련 안전문제를 해결하고자 하였다.

본 연구 이외의 건설현장의 다양한 분야에도 제안 가이드라인의 적용이 가능할 것으로 보이며, 아래는 건설현장의 각 분야별 적용 가능할 것으로 보이는 구체 영역이다:

1. 시공관리

- 공사 진척도 확인: 이미지에서 시공된 부분, 사용된 자재 등을 파악하여 전체 공사 진행 상황을 확인할 수 있다.
- 작업자 및 자재 추적: 작업자의 위치 및 자세, 작업 공간, 자재 등을 파악하여 현장 안전관리 효율성을 높일 수 있다. 구체적으로는 작업자의 안전을 위해 위험 지역을 구분하고 해당 구역에서 작업 중인 작업자를 파악하여 관리자에게 알람 등으로 경고하는 시스템 등이 개발 가능하다.

2. 품질관리

- 자재 품질 확인: 비계 등의 자재에 생긴 흠집, 부서짐, 굽힘 등을 감지하여 건설 현장에 사용될 장비 및 자재에 대한 품질관리 수행이 가능하다.
- 시공 불량 감지: 벽돌 쌓기의 균일도, 콘크리트 마감 상태, 용접 품질, 도색 불량 등을 분석하여 시공 불량상태를 자동으로 감지해낼 수 있다.

3. 안전관리

- 안전 위험 요소 감지: 작업현장 위험 요소 존재 여부, 기계 및 장비의 상태 등을 감지하여 현장의 위험 요소를 미리 감지하여, 사고 예방 및 안전관리 수준을 높일 수 있다.
- 개인 보호 장비 착용 확인: 건설 현장의 작업자를 촬영하여 작업자의 개인 보호 장비(PPE) 착용 여부를 확인할 수 있다. 구체적으로는, 안전모, 안전대, 마스크 등 PPE 착용 규정 위반 사항을 파악할 수 있으며, 추가로 작업자에게 올바른 장비 착용 교육 및 훈련도 제공이 가능하다.

4. 토목 현장

- 시설 관리: 도로, 교량, 터널 등 토목 시설의 상태 점검 및 균열 등 결함 감지가 가능하다.

- 재해 예방: 지반 침하, 붕괴 위험 등 잠재적 위험의 조기 감지가 가능하다.

또한, AI 시스템을 구축하기 위해 가장 중요한 구성요소는 데이터이다. AI 시스템의 성능은 데이터의 신뢰도와 양에 의해 결정되는 경우가 많으며, 이를 위해 현장에 인허가를 얻어 방문하는 등 다양한 소스에서 데이터를 수집하여야 한다. Table 4-6는 이미지 수집 방식에 따른 장단점을 비교한 표이며, 개발 목적을 달성하기 위해 적합한 방식을 선택하여 최대한 많은 양의 데이터를 확보하여야 한다.

Table 4-6 Advantages and disadvantages of image collection methods

수집방법	장점	단점
직접 촬영	원하는 이미지 수집, 이미지의 품질 및 해상도의 제어 가능	시간, 노력, 안전사고, 현장 출입의 제한
인터넷 검색	빠르고 다양한 이미지 수집 특정 키워드 검색	원하는 이미지 확인 시간 소요, 저작권의 문제
이미지 데이터베이스 활용	고품질의 이미지 다양하게 수집이 가능하고 이미지의 분류 및 검색 용이함	원하는 이미지 찾기의 어려움. 제공 이미지의 메타 정보 결여 가능성
드론 활용	광범위한 영역 빠르게 이미지의 수집 가능, 위험작업의 회피 가능	항공규제준수, 현장 드론사용 불가능
건설회사 또는 정부기관 문의	특정 현장의 이미지 확보 가능	이미지 제공 거부 가능성, 이미지의 사용 제한 가능성

그러나 충분한 데이터를 수집하지 못한 경우, 데이터 증강 또는 모델 개선을 통해 성능을 향상시킬 수 있어야 한다. 또한 건설현장에 적용되는 AI의 경우, 현장의 이미지를 적절한 해상도로 확보하여야 하며, 감지하고자 하는 정상 또는 비정상의 객체를 전문가의 지식에 근거해 명확하게 라벨링 하여야 AI 시스템의 성능을 확보할 수 있다.

데이터를 충분히 수집한 경우, 연구목적에 적합한 모델을 선정하여야 한다. 본 연구와 같이 건설현장에 적용할 수 있는 객체탐지 기술을 적용할 경우, 선택할 수 있는 모델은 YOLO, R-CNN 계열 등 다양한 모델이 있으며, 해결하고자 하는 문제의 형태에 맞춰 적합한 모델을 선정하여야 한다. 현장에서 즉시 사용할 수 있도록 모바일로 개발될 경우, YOLO 등 속도 측면에서 우수한 모델을 선정하여야 하며, 벽에 생긴 균열 등 미세한 것을 감지해야 하는 경우, R-CNN 계열의 모델로 보다 명확하게 이상을 잡아낼 수 있다.

개발된 AI 모델은 반드시 지속적인 업데이트를 수행하여야 한다. 업데이트가 되지 않는 모델은 새로운 자재, 새로운 형태의 결함에 대해 취약해지게 되며, 보안 측면에서도 위험도가 증가하게 된다. 특히 산업현장에 적용되는 AI는 법률 및 규제의 변경 시 전면적인 업데이트가 필수적이다.

제안한 가이드라인을 따라 건설현장에 객체탐지 AI 기술을 도입할 경우, 건설현장의 생산성, 안전성, 지속가능성을 향상시킬 수 있을 것이다. 이를 통해 개발된 우수한 AI를 꾸준히 업데이트하여 건설산업 전반에 걸쳐 혁신을 가져올 것으로 기대하며, 더욱 다양한 활용 사례를 통해 건설산업의 효율성과 안전에 크게 기여할 것으로 기대된다.

제5장 결론

본 연구에서는 현장 기술자가 직접 설치하고 설치의 적정성을 판단하여 인적 오류가 발생하기 쉬운 시스템비계에 대해, 실시간 현장 촬영 이미지를 기반으로 설치의 적정성을 판단하는 AI인 SSCARF를 개발하였으며, 이를 이용해 현장에서 비계 설치의 적정성 판단과정을 가속화 및 자동화하고자 하였다. 이를 위해 본 연구는 두 단계로 나누어 수행되었으며, 개발 AI 모델에 적용할 설치 적정성 판단의 기준을 마련하고자 국내·외 관련 기준을 검토하였고, 5조의 가설재에 대해 재해사례를 분석하고 가장 많은 사고가 발생하는 자재에 대해 살펴보았다. 두 번째 단계에서는 설정한 판단 기준에 따라 실제 현장에서 확보한 이미지 데이터를 이용하여 CNN 딥러닝 모델을 기반으로 특징을 추출해 실시간으로 객체를 감지하는 YOLO architecture에 바탕한 판정 모델을 설계하고 구현하였다. 입력 데이터에 대한 전처리 및 데이터 증강을 제안하였으며, 이 과정을 통해 모델의 성능을 크게 향상시킬 수 있었다.

1. 연구를 통해 비계 설치의 적정성 판단기준을 생성하여 총 5개 가설재에 대해 14개 기준을 마련할 수 있었다. 판단기준은 재해사례가 많았던 발판, 연결부와 시각적으로 판단할 수 있는 경우를 포함하였으며, 자세한 설치 적정성 기준은 KOSHA Guide와 산업안전보건기준을 참고하였다. 이를 이용하여 입력 데이터를 정상, 비정상으로 분류 라벨링을 수행하였고(라벨링 툴인 Roboflow를 활용하여 바운딩 박스로 라벨을 지정), 총 461장의 이미지를 건설현장에서 확보하여 모델 개발에 활용하였다. 모델 개발과정에서 적정성 판단 시스템이 모바일 형태로 개발되는 것이 활용도가 높다고 판단하였으며, 이에 따라 실시간성의 중요도가 높아 속도가 빠른 객체탐지 모델인 YOLOv5를 채택하였다. YOLOv5를 이용하여 올바른 설치와 비정상 설치의 객체를 분류하는 형태로 SSCARF 모델을 개발하였다.

2. 모델의 파라미터를 수정하여 어떤 형태의 모델이 성능이 우수한지를 비교하였으며, 모델의 크기, 입력 이미지의 크기, 색깔 변화 효과를 분석하였다. 모델의 크기가 클수록 성능이 향상되는 경향은 있었으나 큰 변화는 없어, 중간 크기의 모델로 선정하여 적절한 성능과 계산시간을 확보하고자 하였다. 이미 학습된 모델을 사용하였기에,

YOLOv5 모델을 학습할 때 쓰인 640x640 크기의 이미지를 사용하였을 때가 가장 성능이 우수하였다. 또한 입력 데이터 분석을 통해 분류 과정에서 배경색이 중요한 역할을 할 수 있음을 확인하였으며, 흑백 처리한 이미지와 색깔이 들어간 이미지를 각각 학습시킨 결과를 비교하였을 때 흑백 처리한 경우가 보다 성능이 높음을 확인하였다.

다만 모델의 변화를 주더라도 성능이 필요한 만큼 크게 개선되지는 않음을 확인하였으며, train loss가 꾸준히 감소함에도 불구하고 성능지표인 mAP가 크게 변하지 않아 데이터의 절대적인 양이 부족함을 확인하였다. 이러한 문제를 해결하기 위해, 데이터 증강과정을 통해 더욱 높은 성능을 확보하고자 하였다. 이때, 데이터 증강은 흑백 처리, 노이즈 삽입, 이미지 좌우반전, 다양한 각도로 회전, 이미지 중간에 경계상자를 삽입하거나 회전시키는 방식을 수행하였다. 이를 통해 배경색의 영향을 줄이고, 불균형 데이터에서 생길 수 있는 문제를 제거하였다. 데이터 증강을 통해 학습 데이터의 양을 3배로 증가시켰으며, 학습 데이터로 1,233장을 확보할 수 있었다.

3. SSCARF 시스템은 연결핀, 받침철물, 벽이음재, 수평재, 작업발판의 다섯 가지 자재에 대해 설치 적정성을 판단하였으며, 총 1,283장의 이미지를 활용하여 모델을 개발한 결과 mAP 기준 80.8%의 우수한 성능을 기록하였다. 테스트 결과를 확인하였을 때 라벨링이 되어있지 않았던 데이터 역시 비교적 정확히 감지하고 있어서 단순 수치로 평가한 결과보다 더욱 우수한 성능을 보이고 있음을 확인할 수 있었다.

다만, 현재 개발된 SSCARF의 경우 시스템비계의 5개 자재에 대한 설치 적정성을 판단하고 있기 때문에 추락 방호망 등의 자재의 적정성을 판단하기 위해 추가적인 모델 개발이 필요하다. 특히, 발판의 틈 등 거리나 각도를 정확히 해야 하는 경우의 탐지가 어렵기 때문에 카메라 캘리브레이션 등의 기법을 이용하여 모델을 추가 개발할 수 있을 것으로 판단된다. 또한 데이터가 추가될수록 모델의 성능이 향상되는 경향이 있어서 현재 정확히 감지하지 못하는 자재가 설치되지 않은 경우에 대해 지속적인 데이터 수집을 통해 성능을 더욱 향상시킬 수 있을 것으로 보이며, 단일 이미지가 아닌 영상 형태의 데이터를 입력하여 현장에서의 적용성을 확보할 수도 있을 것으로 판단된다.

4. 촬영 이미지의 기계학습을 기반으로 이외 적정성 판정 기법은 설계 및 계획, 시

공관리, 안전관리, 품질관리 등 여러 공중분야에서 다양한 형태로 AI의 적용이 가능하다. 본 연구에서는 이상 분석 대상 선정, 데이터 수집, 데이터 무결성 확인 및 라벨링, 데이터 증강, 적합 기계학습 모델 선정, 학습 및 모델 개선, 현장 적용, 모델 갱신 및 재배포로 구성된 개발 절차 및 가이드라인을 제안하였으며, 이를 활용하면 건설현장에서 안전을 확보하기 위한 다양한 건전성 판별 AI 시스템 구축이 용이할 것으로 판단한다.

이상의 연구결과와 같이 본 연구에서 개발한 시스템 SSCARF는 실제 건설현장에 설치된 시스템비계의 사진을 직접 촬영하여 개발되었고, 설치 적정성 판정 결과 및 작동 속도 역시 우수하였기 때문에 해당 시스템을 실제 건설현장에 적용할 수 있을 것으로 판단된다. 또한 추가적인 개발을 통해 실제로 현장의 적정성 판단에 적용한다면 건설현장의 안정성을 확보할 수 있으며, 이를 통해 재해를 감소에 크게 기여할 수 있을 것으로 판단된다.

참 고 문 헌

- [1] American National Standards Institute, *ANSI/ASSE A10.8-2011, Scaffolding Safety Requirements*, American National Standards Institute, (2011)
- [2] Australian/New Zealand Standards, *AS/NZS 1576.1:2010, Scaffolding - General requirements*. Standards Australia/Standards New Zealand, (2010)
- [3] Baek, S. W. and Song, I. Y., “A Study on the Buckling Characteristics of Steel Pipe Scaffold”, *Journal of the Korean society of safety*, 25(1), 57-61, (2009)
- [4] Bishop, C.M., *Pattern Recognition and Machine Learning*, Springer, (2006)
- [5] Bochkovskiy, A., Wang, C.Y., and Liao, H.Y.M., YOLOv4: Optimal Speed and Accuracy of Object Detection, arXiv preprint arXiv:2004.10934, (2020)
- [6] British Standards Institution, *BS EN 12811-1: Temporary works equipment - Part 1: Scaffolds - Performance requirements and general design*, British Standards Institution, (2003)
- [7] Chen, W., Luo, J., Zhang, F., and Tian, Z., “A review of object detection: Datasets, performance evaluation, architecture, applications and current trends”, *Journal of Computer Vision and Pattern Recognition*, 37(2), 145-172, (2023)
- [8] Cho, K., Van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., and Bengio, Y., “Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation”, *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 1724-1734, (2014)
- [9] Cubuk, E. D., Zoph, B., Mane, D., Vasudevan, V., and Le, Q.V., “AutoAugment: Learning Augmentation Strategies from Data”, *2019 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 113-123, (2019)
- [10] Felzenszwalb, P.F., Girshick, R.B., McAllester, D., and Ramanan, D., “Object Detection with Discriminatively Trained Part-Based Models”, *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 32(9), 1627-1645, (2010)
- [11] Girshick, R., Donahue, J., Darrell, T., and Malik, J., “Rich Feature Hierarchies for

- Accurate Object Detection and Semantic Segmentation”, *Proceedings of the 2014 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 580-587, (2014)
- [12] Girshick, R., “Fast R-CNN”, *Proceedings of the 2015 IEEE International Conference on Computer Vision (ICCV)*, 1440-1448, (2015)
- [13] Glorot, X., Bordes, A., and Bengio, Y., “Deep Sparse Rectifier Neural Networks”, *Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics*, 315-323, (2011)
- [14] Goodfellow, I., Bengio, Y., and Courville, A., *Deep Learning*, MIT Press, (2016)
- [15] Haykin, S., *Neural Networks and Learning Machines* (3rd ed.), Pearson, (2009)
- [16] Hinton, G.E., and Sejnowski, T.J., *Unsupervised Learning: Foundations of Neural Computation*, MIT Press, (1999)
- [17] Jang, J. Y., Lee, J. Y., Kim, H. Y., Lee, J. H., Kim, J. S., Kim, J. Y., and Kim, Y. S., “Development of Quality Evaluation and Management System for Assembled Temporary Equipment- Focused on Steel Pipe Scaffolding, System Scaffolding and Support”, *Korean Journal of Construction Engineering and Management (KJCEM)*, 23(5), 43-55, (2022)
- [18] Japanese Standards Association, *JIS A 8951: Scaffolds - Performance requirements for scaffolds*, Japanese Standards Association, (2017)
- [19] Jocher, G., Stoken, A., Borovec, J., NanoCode012, ChristopherSTAN, et al., *YOLOv5: A Family of Object Detection Architectures*, GitHub repository, YOLOv5, (2020)
- [20] Johnson, R., and Gupta, A., “Intersection over Union: A Critical Metric for Object Detection Accuracy”, *Journal of Machine Learning Research*, 34(7), 1123-1142, (2023)
- [21] Jordan, M.I., and Mitchell, T.M., “Machine Learning: Trends, Perspectives, and Prospects”, *Science*, 349(6245), 255-260, (2015)
- [22] Kim, H. G., *The Actual Conditions and Improvement Plans of Safety Culture in Construction Sites*, Ph.D. Thesis, Graduate School, Seoul National University of Science and Technology, (2023)

- [23] Kim, J. R., Min, S. N., Lee, M. H., and Jung, J. H., “Evaluation of Factors Influencing posture stability when Using Unsafe Movable Scaffolding in Construction Sites using F-scan”, *Ergonomics Society of Korea (ESK) Conference*, (2010)
- [24] Kober, J., Bagnell, J.A., and Peters, J., “Reinforcement Learning in Robotics: A Survey”, *The International Journal of Robotics Research*, 32(11), 1238-1274, (2013)
- [25] Krizhevsky, A., Sutskever, I., and Hinton, G.E., “ImageNet Classification with Deep Convolutional Neural Networks”, *Advances in Neural Information Processing Systems 25 (NIPS 2012)*, 1097-1105, (2012)
- [26] LeCun, Y., Bottou, L., Bengio, Y., and Haffner, P., “Gradient-Based Learning Applied to Document Recognition”, *Proceedings of the IEEE*, 86(11), 2278-2324, (1998)
- [27] Lee, D. K., Ji, S. H. and Park B. Y., “Object Detection and Post-processing of LNGC CCS Scaffolding System using 3D Point Cloud Based on Deep Learning”. *Journal of the Society of Naval Architects of Korea*, 58(5), 303-313, (2021)
- [28] Lee, J. S., and Choe, J. U., “A Feasibility Study of Safety Cetification for Finished Product of Febricated Temporary”, *Korea Safety Management & Science Conference*, 39-48, (2013)
- [29] Liu, S., Qi, X., Shi, J., and Jia, J., “Path Aggregation Network for Instance Segmentation”, *2018 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 8759-8768, (2018)
- [30] Lowe, D.G., “Distinctive Image Features from Scale-Invariant Keypoints”, *International Journal of Computer Vision*, 60(2), 91-110, (2004)
- [31] McCarthy, J., “Programs with Common Sense”, *Proceedings of the Teddington Conference on the Mechanization of Thought Processes*, 75-91, (1958)
- [32] Min, S. N., Lee, M. H., Jeong, J. H. and Kim, J. R., “Analysis of Spinal Stability Affected by working on Scaffold”, *Ergonomics Society of Korea (ESK) Conference*, (2010)
- [33] Moon, S. O., Oh, T. K., Lee, J. S., Mo, S. E., and Yoon, Y. B., *A Study on the*

- Application of Pre-Construction Method of Safety Railings on Scaffolding for Fall Prevention in Domestic Construction Sites*, Occupational Safety and Health Research Institute, (2019)
- [34] Park. J. K. and Jeong, S. K., “The Survey of the Current Situation for System Scaffolding in the Domestic Construction Site”, *Journal of the Korean Society of Safety*, 25(3), 107-111, (2010)
- [35] Perez, L., and Wang, J., The Effectiveness of Data Augmentation in Image Classification using Deep Learning, arXiv preprint arXiv:1712.04621, (2017)
- [36] Redmon, J., and Farhadi, A., “YOLO9000: Better, Faster, Stronger”, *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 6517-6525, (2017)
- [37] Redmon, J., and Farhadi, A., YOLOv3: An Incremental Improvement, arXiv preprint arXiv:1804.02767, (2018)
- [38] Redmon, J., Divvala, S., Girshick, R., and Farhadi, A., “You Only Look Once: Unified, Real-Time Object Detection”, *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 779-788, (2015)
- [39] Ren, S., He, K., Girshick, R., and Sun, J., “Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks”, *Advances in Neural Information Processing Systems 28 (NIPS 2015)*, 91-99, (2015)
- [40] Rezatofighi, H., Tsoi, N., Gwak, J.Y., Sadeghian, A., Reid, I., and Savarese, S., “Generalized Intersection over Union: A Metric and A Loss for Bounding Box Regression”, *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 658-666, (2019)
- [41] Schmidhuber, J., “Deep Learning in Neural Networks: An Overview”, *Neural Networks*, 61, 85-117, (2015)
- [42] Shorten, C., and Khoshgoftaar, T.M., “A survey on Image Data Augmentation for Deep Learning”, *Journal of Big Data*, 6(60), 1-48, (2019)
- [43] The Constructor, *Types of Scaffolding in Construction*, The Constructor, (2023)

- [44] Yoo, H. D., *An Empirical Study on Prevention of Fall Accidents Using Accidents Statistics : Focused on Scaffold and Walk Plate of Small Scale Construction Site*, Ph.D. Thesis, Graduate School, Myongji University, (2015)
- [45] Zhang, H., Cisse, M., Dauphin, Y.N., and Lopez-Paz, D., “MixUp: Beyond Empirical Risk Minimization”, *ICLR 2018 Conference*, (2018)
- [46] 2022. 12 월말 산업재해 발생 현황, 고용노동부 정책자료실, (2023)
- [47] 2022년 재해조사 대상 사망사고 발생 현황 결과 발표, 고용노동부 보도자료, (2023)
- [48] 3대 안전 조치 현장점검의 날 건설현장 추락위험 일제 점검 결과 발표, 고용노동부 보도자료, (2021)
- [49] KOSHA GUIDE C-08-2015, *건설현장 안전 기준집*, 한국산업안전보건공단, (2019)
- [50] KOSHA GUIDE C-08-2015, *작업발판 설치 및 사용 안전 지침*, 한국산업안전보건공단, (2015)
- [51] KOSHA GUIDE C-30-2020, *강관비계 안전작업 지침*, 한국산업안전보건공단, (2020)
- [52] KOSHA GUIDE C-32-2020, *시스템비계 안전작업 지침*, 한국산업안전보건공단, (2020)
- [53] KOSHA GUIDE C-69-2012, *이동식 크레인 안전보건작업 지침*, 한국산업안전보건공단, (2012)
- [54] *가설공사 표준안전 작업지침*, 고용노동부, (2020)
- [55] *건설공사품질관리업무지침*, 제2장, 국토교통부, (2022)
- [56] *건설기술 진흥법 시행령 제100조의1, 가설구조물의 구조적 안전성 검토*, 국토교통부, (2024)
- [57] *건설기술 진흥법 시행령 제101조의29, 가설구조물의 구조적 안전성 검토*, 국토교통부, (2024)
- [58] *건설기술 진흥법 시행령 제75조의2, 설계의 안전성 검토*, 국토교통부, (2024)
- [59] *건설기술 진흥법 시행령 제89조, 품질관리계획 등의 수립 대상 공사*, 국토교통부,

(2024)

- [60] 건설기술 진흥법 제48조(설계도서의 작성 등) 제5항, 국토교통부, (2022)
- [61] 건설기술 진흥법 제55조(건설공사의 품질관리), 국토교통부, (2022)
- [62] 건설기술 진흥법 제62조의1(건설공사의 품질관리), 국토교통부, (2022)
- [63] 박주동, 강성윤, 건설현장 이동식 비계의 안전성과 현장 적용성 개선 연구. 한국산업안전보건공단 산업안전보건연구원, (2021)
- [64] 비계 및 안전시설물 설계기준, KDS 21 60 00, 국토교통부, (2020)
- [65] 산업안전보건기준에 관한 규칙 제7장, 고용노동부, (2024)
- [66] 안홍섭. 추락재해 원인 분석 및 효과적인 예방대책 연구. 한국산업안전보건공단 산업안전보건연구원, (2009)
- [67] 이명구, 정명진. RC 교량의 동바리 안전작업절차서 개발에 관한 연구. 한국산업안전보건공단, (1999)
- [68] 이영섭. 건설공사 종류별 표준안전 시설기준 제정 연구. 한국산업안전보건공단, (1997)
- [69] 이지혜, 손태홍. CSI 자료를 활용한 국내 건설업 사망사고 심층분석. 한국건설산업연구원, (2023)
- [70] 한국산업표준(KS), KS D 8701: 시스템비계, 대한민국 산업통상자원부, (2017)

부 록

부록 1. Data.yaml

```
train: C:/Users/1/Downloads/Scaffoldingyolov8/train/images
validation: C:/Users/1/Downloads/Scaffoldingyolov8/valid/images
test: C:/Users/1/Downloads/Scaffoldingyolov8/test/images
nc: 14
names: ['AbnormalBase', 'AbnormalConnector', 'AbnormalPin', 'AbnormalRing', 'Base',
'Connector', 'Horizon', 'NoneConnectHorizon', 'NoneConnectWalkboard', 'Pin', 'Walkboard',
'WalkboardClash', 'WellconnectedWalkboard', 'WoodConnector']
roboflow:
  workspace: isel
  project: scaffolding-9uzsy
  version: 7
  license: CC BY 4.0
  url: https://universe.roboflow.com/isel/scaffolding-9uzsy/dataset/7
```

부록 2. Local 모델 학습

CMD console 명령어:

```
python train.py --img 640 --batch 16 --epochs 200 --data  
C:\Users\pon01\Downloads\Scaffoldingyolov8\data.yaml --weights yolov5s.pt
```

Spyder IDE 명령어:

```
from ultralytics import YOLO
```

```
# 모델 로드
```

```
model = YOLO('yolov5m.yaml') # YAML에서 새 모델 구축
```

```
model = YOLO('yolov5m.pt') # 사전 훈련된 모델 로드 (훈련을 위해 권장됨)
```

```
model = YOLO('data.yaml').load('yolov5m.pt') # YAML에서 구축 및 가중치 전달
```

```
# 모델 훈련
```

```
results = model.train(data='C:/Users/pon01/Downloads/Scaffoldingyolov5/data.yaml',  
epochs=100, imgsz=640)
```

부록 3. 데이터 전처리 코드

이미지 변경, 분류, 특징 추출, 흑백 이미지 특징 추출, 흑백 전환, 이미지 bounding box 회전, 노이즈 삽입, 이미지 회전 등의 7개 파일로 구성된다.

(1) 이미지 이름 변경

```
import os

# 이미지 파일이 들어 있는 폴더 경로 설정
folder_path = "D:/scaffolding_images/Total_resize/train/images"

# 폴더 내의 이미지 파일 목록 가져오기
image_files = [f for f in os.listdir(folder_path) if f.endswith(('jpg', 'png', 'jpeg', 'gif'))]

# 이미지 파일 목록 정렬
image_files.sort()

# 이미지 파일 이름을 1부터 차례대로 정렬하면서 변경
for i, old_name in enumerate(image_files, start=1):
    file_extension = os.path.splitext(old_name)[1]
    new_name = f"{i}{file_extension}"
    old_path = os.path.join(folder_path, old_name)
    new_path = os.path.join(folder_path, new_name)

    os.rename(old_path, new_path)
    print(f"Renamed: {old_name} -> {new_name}")
```

(2) 이미지 분류

```
import os
import cv2
import numpy as np
from sklearn.cluster import KMeans
from collections import defaultdict
import shutil

# 이미지가 있는 폴더 경로 설정
image_folder = "D:/scaffolding_images/GRAY"
```

```
# 이미지 파일 목록 가져오기
image_files = [f for f in os.listdir(image_folder) if f.endswith((''.jpg', '.png', '.jpeg', '.gif'))]

# 이미지 로드 및 특징 추출
image_data = []
for image_file in image_files:
    image_path = os.path.join(image_folder, image_file)
    image = cv2.imread(image_path, cv2.IMREAD_COLOR)
    image_data.append(image.flatten()) # 이미지 데이터를 1차원 벡터로 변환하여 사용

# 클러스터 수 설정
num_clusters = 5

# K-Means 클러스터링 수행
kmeans = KMeans(n_clusters=num_clusters)
kmeans.fit(image_data)
cluster_labels = kmeans.labels_

# 클러스터별 이미지 그룹화
clustered_images = defaultdict(list)
for i, image_file in enumerate(image_files):
    cluster = cluster_labels[i]
    clustered_images[cluster].append(image_file)

# 결과 폴더 생성 및 이미지 복사
result_folder = 'C:/Users/pon01/OneDrive/바탕 화면/비개/'
os.makedirs(result_folder, exist_ok=True)

for cluster, image_files in clustered_images.items():
    cluster_folder = os.path.join(result_folder, f'Cluster_{cluster}')
    os.makedirs(cluster_folder, exist_ok=True)

    for image_file in image_files:
        source_path = os.path.join(image_folder, image_file)
        destination_path = os.path.join(cluster_folder, image_file)
```

```
shutil.copy(source_path, destination_path)

print(f'Clustering complete. {num_clusters} clusters created in {result_folder}.')

(3) 이미지 특징 추출
import os
import cv2
import numpy as np
import matplotlib.pyplot as plt

folder_path = "D:/scaffolding_images/GRAY"
image_files = [f for f in os.listdir(folder_path) if f.endswith(('jpg', 'png', 'jpeg', 'gif'))]

# 데이터베이스 이미지 로드 및 특징 추출
database_images = []

for i in image_files:
    img = cv2.imread(f'{folder_path}/{i}')
    sift = cv2.SIFT_create(nfeatures=500)
    kp, des = sift.detectAndCompute(img, None)
    database_images.append((f'{folder_path}/{i}', kp, des))

# 쿼리 이미지 로드 및 특징 추출
query_image = cv2.imread('D:/scaffolding_images/gray/gray_1.jpg')
sift = cv2.SIFT_create(nfeatures=500)
kp_query, des_query = sift.detectAndCompute(query_image, None)

# 유사도 측정을 위한 비교 함수 정의 (유클리드 거리)
def compare_images(des1, des2):
    return np.linalg.norm(des1 - des2)

# 데이터베이스 이미지와 쿼리 이미지 간의 유사도 측정
similar_images = []
for name, kp_db, des_db in database_images:
    try:
        distance = compare_images(des_query, des_db)
```

```
        similar_images.append((name, distance))
    except:
        pass

# 유사도에 따라 이미지 정렬
similar_images.sort(key=lambda x: x[1])

# 상위 N개의 가장 유사한 이미지를 추출
top_N = 5 # 상위 N개 이미지 추출
top_similar_images = similar_images[:top_N]

# 결과 출력
for name, distance in top_similar_images:
    print(f"The image {name} is similar with distance {distance:.2f}")

# 상위 N개 이미지를 플롯
plt.imshow(query_image)
for name, _ in top_similar_images:
    image_path = os.path.join(folder_path, name)
    similar_image = cv2.imread(image_path, cv2.IMREAD_COLOR)

    # 이미지 플롯
    plt.figure()
    plt.imshow(cv2.cvtColor(similar_image, cv2.COLOR_BGR2RGB)) # BGR을 RGB로 변
    환하여 플롯
    plt.title(f'Similar Image: {name}')
    plt.axis('off') # 축 숨김
    plt.show()

(4) 흑백 이미지 특징 추출
import cv2
import numpy as np
import matplotlib.pyplot as plt
import os

folder_path = 'D:/scaffolding_images/GRAY'
```

```
# 이미지 로드
```

```
image_files = [f for f in os.listdir(folder_path) if f.endswith((''.jpg', '.png', '.jpeg', '.gif'))]
```

```
for i in image_files:
```

```
    image = cv2.imread(f'{folder_path}/{i}', cv2.IMREAD_COLOR)
```

```
    gray_image = cv2.cvtColor(image, cv2.COLOR_BGR2GRAY)
```

```
    # SIFT 특징 추출
```

```
    sift = cv2.SIFT_create(nfeatures=500)
```

```
    keypoints, descriptors = sift.detectAndCompute(gray_image, None)
```

```
    # 이미지에 특징 그리기
```

```
    image_with_keypoints = cv2.drawKeypoints(image, keypoints, None)
```

```
    # 결과 시각화
```

```
    plt.figure(figsize=(10, 6))
```

```
    plt.imshow(cv2.cvtColor(image_with_keypoints, cv2.COLOR_BGR2RGB))
```

```
    plt.title('Image with Keypoints')
```

```
    plt.axis('off')
```

```
    plt.show()
```

(5) 흑백 전환

```
import os
```

```
import cv2
```

```
# 이미지가 있는 폴더 경로 설정
```

```
image_folder = 'D:/scaffolding_images/Total_resize/train/images'
```

```
result_folder = 'D:/scaffolding_images/GRAY'
```

```
# 이미지 파일 목록 가져오기
```

```
image_files = [f for f in os.listdir(image_folder) if f.endswith((''.jpg', '.png', '.jpeg', '.gif'))]
```

```
# 흑백으로 변환하여 저장
```

```
for image_file in image_files:
```

```
    image_path = os.path.join(image_folder, image_file)
```

```
    image = cv2.imread(image_path, cv2.IMREAD_COLOR)
```

```
# 이미지를 흑백으로 변환
gray_image = cv2.cvtColor(image, cv2.COLOR_BGR2GRAY)
gray_image = cv2.resize(gray_image, (640, 640))
# 흑백 이미지를 저장
output_path = os.path.join(result_folder, f'gray_{image_file}')
cv2.imwrite(output_path, gray_image)

print(f'Conversion complete. Gray images saved in {output_path}.')
```

(6) 이미지 bounding box 회전

```
import cv2
import numpy as np

def rotate_image_and_boxes(image, boxes, angle):
    # 이미지 차원
    (h, w) = image.shape[:2]

    # 이미지 중심 계산
    center = (w / 2, h / 2)

    # 회전
    M = cv2.getRotationMatrix2D(center, angle, 1.0)
    cos = np.abs(M[0, 0])
    sin = np.abs(M[0, 1])
    nW = int((h * sin) + (w * cos))
    nH = int((h * cos) + (w * sin))
    M[0, 2] += (nW / 2) - center[0]
    M[1, 2] += (nH / 2) - center[1]
    rotated_image = cv2.warpAffine(image, M, (nW, nH))

    rotated_boxes = []
    for box in boxes:
        # box 좌표
        x_min, y_min, x_max, y_max = box
        box_points = np.array([
```

```

        [x_min, y_min],
        [x_max, y_min],
        [x_max, y_max],
        [x_min, y_max]
    ])

    ones = np.ones(shape=(len(box_points), 1))
    points_ones = np.hstack([box_points, ones])
    rotated_points = M.dot(points_ones.T).T

    # 새로운 박스 생성
    x_coords = rotated_points[:, 0]
    y_coords = rotated_points[:, 1]
    new_x_min = int(x_coords.min())
    new_y_min = int(y_coords.min())
    new_x_max = int(x_coords.max())
    new_y_max = int(y_coords.max())

    rotated_boxes.append((new_x_min, new_y_min, new_x_max, new_y_max))

    return rotated_image, rotated_boxes

image = cv2.imread('path_to_image.jpg')
boxes = [(50, 50, 100, 100), (150, 150, 200, 200)] # Example bounding boxes
angle = 45 # Example rotation angle
rotated_image, rotated_boxes = rotate_image_and_boxes(image, boxes, angle)

# 출력
for box in rotated_boxes:
    cv2.rectangle(rotated_image, (box[0], box[1]), (box[2], box[3]), (0, 255, 0), 2)
cv2.imshow('Rotated Image', rotated_image)
cv2.waitKey(0)
cv2.destroyAllWindows()

(7) 노이즈 삽입
import cv2

```

```
import numpy as np
# 가우시안 노이즈 삽입
def add_gaussian_noise(image, mean=0, std=25):
    gaussian_noise = np.random.normal(mean, std, image.shape).astype(np.float32)
    noisy_image = cv2.add(image.astype(np.float32), gaussian_noise)
    noisy_image = np.clip(noisy_image, 0, 255).astype(np.uint8)
    return noisy_image

image = cv2.imread('path_to_image.jpg')
noisy_image = add_gaussian_noise(image)
cv2.imshow('Noisy Image', noisy_image)
cv2.waitKey(0)
cv2.destroyAllWindows()
```

(8) 이미지 회전

```
import cv2
# 이미지 불러오기
image = cv2.imread(image_path)

# Check if the image is loaded successfully
if image is None:
    print(f'Error: Unable to load image at {image_path}')
    return

# flip 함수 사용
flipped_image = cv2.flip(image, 1)

# 저장
cv2.imwrite(output_path, flipped_image)
```

부록 4. 결과 출력 코드

```
import torch
import cv2
import numpy as np

def load_yolov5_model(model_path='yolov5s.pt'):
    model = torch.hub.load('ultralytics/yolov5', 'custom', path=model_path)
    return model

def draw_predictions(image, results, classes, colors):
    for result in results:
        x1, y1, x2, y2, conf, cls_id = result
        x1, y1, x2, y2 = int(x1), int(y1), int(x2), int(y2)
        color = colors[int(cls_id)]
        label = f"{classes[int(cls_id)]}: {conf:.2f}"

        # 박스
        cv2.rectangle(image, (x1, y1), (x2, y2), color, 2)

        # 라벨
        label_size, base_line = cv2.getTextSize(label, cv2.FONT_HERSHEY_SIMPLEX,
0.5, 1)
        top = max(y1, label_size[1])
        cv2.rectangle(image, (x1, top - label_size[1]), (x1 + label_size[0], top + base_line),
color, cv2.FILLED)

        # 합치기
        cv2.putText(image, label, (x1, top), cv2.FONT_HERSHEY_SIMPLEX, 0.5, (0, 0,
0), 1)

    return image

def get_colors(classes):
    np.random.seed(42)
    return np.random.uniform(0, 255, size=(len(classes), 3))
```

```
def yolo_detect(image_path, model, classes, colors):
    image = cv2.imread(image_path)
    results = model(image) # Inference
    predictions = results.xyxy[0].cpu().numpy() # Bounding boxes with format (x1, y1, x2,
y2, confidence, class)

    return draw_predictions(image, predictions, classes, colors)

# YOLOv5 모델 불러오기
model = load_yolov5_model()

with open('coco.names', 'r') as f:
    classes = [line.strip() for line in f.readlines()]

colors = get_colors(classes)

# 예측/시각화
image_path = 'image30.jpg'
output_image = yolo_detect(image_path, model, classes, colors)

# Display the output image
cv2.imshow('YOLOv5 Predictions', output_image)
cv2.waitKey(0)
cv2.destroyAllWindows()
```

A Study on the Deep Learning-Based Integrity Assessment of System Scaffold Installations Ensuring Safety at Construction Sites

Lee Kisoo

Department of Disaster and Safety

Graduate School, Myongji University

Directed by Professor Shin Dongil

Safety on construction sites is a critical factor that directly affects the lives of workers and the success of construction projects. As a result, the importance of safety in construction is increasingly emphasized not only to reduce human and material damages caused by accidents but also to enhance worker productivity through a safe working environment. In construction sites, system scaffolding is essential equipment for creating a safe working environment in elevated spaces. Properly installed scaffolding allows workers to move safely and work efficiently. However, if not installed correctly, the risk of falling accidents increases significantly.

This study has developed an AI-based system SSCARF to assess the appropriateness of system scaffolding installations, aiming to reduce human errors in installation integrity management and ultimately decrease accident occurrences to ensure safety on construction sites. The study evaluated the installation appropriateness of five types of scaffolding materials: locking pins, support metal, wall ties, ledgers, and platforms. Each material was labeled as one of 14 cases based on its installation status: correctly installed, incorrectly installed, unconnected, or overlapping, using data directly captured on construction sites. The AI model adopted the YOLOv5 object detection algorithm to classify whether the five types of materials were correctly installed.

During the model development process, mAP was used as a performance metric, and labeling was conducted using Roboflow's labeling tool. The initial model used approximately 200 images of scaffolding and showed a low accuracy with an mAP of 18.6%. To improve the model's performance, the data amount was increased to 461 images, resulting in an improved mAP of 60.4%. However, it was still not suitable for practical use. Thus, in the final model, data augmentation was applied, and various techniques such as grayscale conversion and horizontal flipping were used to increase the training data from 411 to 1,233 images. The result showed excellent performance with an mAP of 80.8%, confirming that augmenting the training data can significantly enhance the model's accuracy.

The current model assesses the installation appropriateness of only five materials, and further research is needed to evaluate more materials and various installation forms. Additionally, there is a tendency for the model not to learn when components such as platforms and ledgers are completely missing, suggesting a need for data supplementation or model modification.

This study proposes a deep learning-based system to assess the appropriateness of scaffold installations, applying an image-based detection and classification AI model to the scaffold installation process, which is prone to human error, thereby securing the stability of construction sites. As data was added, the model's performance improved, and it was also able to detect relatively accurately unlabelled data. With some refinements, the proposed SSCARF system could be effectively applied on-site to ensure the safety of construction sites using scaffolding.

Keywords

Construction safety, abnormality detection, machine learning, system scaffolding, temporary structures, installation integrity, image classification