



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

博士學位 請求論文

指導教授 洪文杓

대학생 정신건강 증진을 위한

디지털 중재 연구

－ 대규모 언어 모델(LLM) 기반 대화형 AI
상담 플랫폼의 설계와 실험적 평가 －

成均館大學校 一般大學院

未來人文學소셜앙트레프레너십融合專攻

未來人文學소셜앙트레프레너십融合學

姜寶榮

博
士
學
位
請
求
論
文

디 대
지 학
털 생
중 정
재 신
연 권
구 강
중
진
을
위
한

2
0
2
5

姜
寶
榮

博士學位 請求論文

指導教授 洪文杓

대학생 정신건강 증진을 위한 디지털 중재 연구

– 대규모 언어 모델(LLM) 기반 대화형 AI
상담 플랫폼의 설계와 실험적 평가 –

Digital Intervention for Enhancing College Student
Mental Health

– Design and Experimental Evaluation of an AI
Counseling Platform Based on Large Language
Models (LLMs) –

成均館大學校 一般大學院

未來人文學소셜앙트레프레너십融合專攻

未來人文學소셜앙트레프레너십融合學

姜寶榮

博士學位 請求論文

指導教授 洪文杓

대학생 정신건강 증진을 위한

디지털 중재 연구

– 대규모 언어 모델(LLM) 기반 대화형 AI

상담 플랫폼의 설계와 실험적 평가 –

Digital Intervention for Enhancing College Student
Mental Health

– Design and Experimental Evaluation of an AI
Counseling Platform Based on Large Language
Models (LLMs) –

이 論文을 未來人文學소셜앙트레프레너십
博士學位請求論文으로 提出합니다.

2025 年 4 月 日

成均館大學校 一般大學院

未來人文學소셜앙트레프레너십融合專攻

未來人文學소셜앙트레프레너십融合學

姜寶榮

이 論文을 姜寶榮의 未來人文學소셜앙트레프레너십
博士學位 論文으로 認定함.

2025 年 6 月 日

審査委員長

審査委員

審査委員

審査委員

審査委員

목차

제 1 장 서 론	1
1. 연구의 배경 및 필요성	1
2. 이론적 배경	7
3. 선행 연구	12
4. 연구 목적 및 가설	21
5. 연구 방법론 및 분석 전략 (Analytical Strategy)	23
6. 논문의 구성	30
제 2 장 대학생 정신건강 플랫폼 현황 및 선진 사례 분석	35
1. 대학생 정신건강 관리의 디지털 전환	35
2. 디지털 기반 위기 관리 시스템	38
3. 미국 대학의 정신건강 관리 선도 사례 분석	43
4. 국내 대학의 정신건강 관리 현황 및 시사점	54
5. 통합 시사점 도출	62
제 3 장 실험 I: 디지털 정신건강 테라피 앱 임상 중재 실험	67
1. 연구 개요	67
2. 연구 설계	70

3. 연구 방법	73
4. 연구 결과	79
5. 기타 설문 분석 결과	99
6. 결론 및 시사점	102

제 4 장 실험 II: LLM 모델 기반 닥터케어챗봇 챗봇 프로토타입 개발 및 성능 평가

1. 연구 개요	108
2. 연구 설계	112
3. 연구 방법	120
4. 연구 결과	154
5. 결론 및 시사점	170

제 5 장 실험 III: LLM 기반 챗봇의 상담 품질 비교 평가

1. 연구 개요	178
2. 연구 설계	185
3. 연구 방법	187
4. 연구 결과	199
5. 결론 및 시사점	210

제 6 장 정신건강 플랫폼의 개선 방향

1. 연구 결과의 통합적 분석	215
2. 사용자 경험 기반 개선 전략	218
3. LLM 기반 정신건강 챗봇의 기술적 고도화 방안	232
4. 현장 전문가 분석 및 실천적 함의	248
5. 결론 및 시사점	254
제 7 장 결 론	256
1. 연구의 의의 및 기여	256
2. 통합적 연구 성과	259
3. 정책적 제언	260
4. 연구의 한계	265
5. 향후 연구 방향	268
6. 맺음말	270

표목차

표 1. 주요 대학생 정신건강 플랫폼 분석	37
표 2. 미시간 대학교의 정신건강 프로그램 분석	49
표 3. 스탠퍼드 대학교의 정신건강 프로그램	52
표 4. 실험 집단과 대조군 집단의 실험 초기(Baseline) 인구통계 및 독립 변수	80
표 5. UCLA 외로움 척도 및 PHQ-9 우울증 척도 점수의 기술통계 및 그룹 비교	81
표 6. 측정 도구의 내적 일관성 신뢰도: 크론바흐 α 계수	83
표 7. 디지털 중재의 구체적인 효과 예시	90
표 8. 앱의 긍정적인 요소	93
표 9. 앱의 개선되어야 할 점	94
표 10. 실험 참여 대학생들의 외로움 대처방안	96
표 11. 디지털 테라피 앱에 추가되었으면 하는 보완 기능(복수선택)	98
표 12. 호밋타운 플랫폼 개발 프로세스	122
표 13. 닥터케어챗 상담용 챗봇 상담 평가 문항	149
표 14. 범용 LLM 챗봇 비교 통계 분석	157
표 15. 기존 테라피 앱과의 비교 통계 분석	159
표 16. 지속사용의향과 7 개 영역 간 상관분석 결과	162
표 17. 혁신성 인식과 7 개 영역 간 상관분석 결과	162
표 18. 언급 빈도별 사용자 피드백 분석	164
표 19. 호밋타운 기능 개선에 대한 제안	165
표 20. 언어별 대응 패턴 비교 분석	167
표 21. 통계적 가정 검증 결과	168

표 22. 실험 II 전체 탐색적 가설 검증 결과 종합	169
표 23. 사후 검정력 분석 결과	170
표 24. 연구 한계점 및 영향 분석	172
표 25. CoT 평가 방법론의 차이점	184
표 26. 챗봇별 7 가지 기준 평가 종합 결과	205
표 27. Tukey HSD 사후검정 결과	207
표 28. 평가자간 일치도	208
표 29. 전통적 NLP 지표와 상담학적 평가와의 상관관계	209
표 30. 챗봇별 전통적 NLP 평가 점수	209
표 31. 실험 III 전체 탐색적 가설 검증 결과 종합	210
표 32. 페르소나별 핵심 특성 및 설계 방향	223
표 33. 고객여정맵	224
표 34. 사용자 중심 설계 개선 방향	227
표 35. 감정 강도별 이모티콘 활용 가이드라인	240
표 36. 대학 정신건강 관리시스템의 디지털 전환전략에 대한 현장전문가 분석	249

그림목차

그림 1. 메타의 텍스트와 댓글 분류 작업	39
그림 2. Wysa 의 위기 대응 시스템	41
그림 3. 실험 설계와 참여자 도식	71
그림 4. UCLA Loneliness Index 의 추이(실험집단 vs 대조집단)	82
그림 5. PHQ-9 의 추이(실험집단 vs 대조집단)	82
그림 6. 개별 참가자 PHQ-9 변화 궤적	85
그림 7. (a) 행동의 인지된 이점 (긍정 그룹 vs 부정 그룹)	87

(b) 행동의 인지된 장애물 (긍정 그룹 vs 부정 그룹)	88
(c) 도움 구하기 행동 (긍정 그룹 vs 부정 그룹)	88
그림 8. 자기보고형 정신건강 리터러시	89
그림 9. 기타 설문분석	99
그림 10. 호미타운 플랫폼 시스템 아키텍처	121
그림 11. 감정 경험의 구조 (재인용)	126
그림 12. 닥터케어썸 챗봇 감정 아이콘	128
그림 13. 감정별 맞춤형 프롬프트 응답 생성 과정	128
그림 14. 2 개 국어 대화 예시	135
그림 15. 감사일기 기능 3 단계 프롬프트 설계 및 토큰 보상 시스템	138
그림 16. 닥터케어썸 상담 평가 문항에 대한 평균 점수	155
그림 17. 범용 LLM 챗봇과의 전반적 만족도 점수 비교	157
그림 18. 기존 테라피 앱과의 전반적 만족도 점수 비교	158
그림 19. LLM 평가자 Chain-of- Thought 프롬프트 예시	192
그림 20. Replika 대화 예시 화면	193
그림 21. Youper 대화 예시 화면	194
그림 22. Wysa 대화 예시 화면	195
그림 23. 닥터케어썸 대화 예시 화면	196
그림 24. ESFJ (Social Sync) 유형 인터페이스	229
그림 25. ESTJ (Techlife Balance) 유형 인터페이스	230
그림 26. INFP (Mindful Journey) 유형 인터페이스	230
그림 27. 개선된 대화 흐름도	233
그림 28. 상황별 말투 예시 및 사용자 설정 화면	234
그림 29. 대화 발전 구조도	235

그림 30. 사용자 맞춤형 동적 프롬프트 튜닝 예시	237
그림 31. 한국어 문맥 향상을 위한 프롬프트 튜닝 예시	237
그림 32. CulturePark 의 문화적 데이터 설계 프레임워크 (Li et al., 2024 에서 재인용)	239
그림 33. RAG 기반 감정 맥락 인식 시스템 구현 방식 예시	243
그림 34. LangChain 구현 예시	244
그림 34. RAG 기반 토큰 최적화 시스템	245

논문요약

대학생 정신건강 증진을 위한

디지털 중재 연구

1. 연구 목적 및 배경

본 연구는 LLM 기술을 활용한 웹 기반 정신건강 지원 플랫폼 '호میم타운'과 AI 상담 챗봇 '닥터케어쌤'을 개발하여 대학생 정신건강 관리 효과성을 검증하는 것이 목적이다. 세 가지 실험을 통해 진행되었다:

실험 I: 기존 디지털 정신건강 테라피 효과성 분석 (2023 년 3-6 월)

실험 II: LLM 기반 챗봇 개발 및 성능 비교 (2023 년 9 월-2024 년 2 월)

실험 III: LLM 기반 심리 챗봇 상담학적 품질 비교 분석 (2024-2025 년)

2. 연구 방법 및 결과

실험 I: 63 명 대학생 대상 4 개월 연구 결과, 감사일기와 명상 기능의 긍정적 효과를 확인했으나 한국어 지원 부재와 규칙 기반 시스템의 제약이 드러났다.

실험 II: 20 명 대상 1 주간 파일럿 스터디에서 닥터케어쌤이 공감성(9.2), 긍정성과 지지(9.1), 적극적 경청(9.0) 영역에서 높은 평가를 받았으며, 기존 시스템 대비 통계적으로 유의한 성능 향상을 확인했다($p < .001$).

실험 III: Claude 3.5 Sonnet, ChatGPT 4.0, 인간 전문가의 삼중 평가로 $F(3,80)=9.73$, $p < 0.001$ 의 큰 효과크기를 확인했다. Wysa(2.71 점), 닥터케어쌤(2.38 점), Youper(2.29 점), Replika(1.81 점) 순으로 평가되어 글로벌 챗봇과 대등한 성능을 입증했다.

3. 연구의 의의와 한계

의의: 국내 최초 LLM 기반 정신건강 챗봇 직접 개발 및 효과성 검증 연구로, 프롬프트 엔지니어링부터 위험 탐지 시스템까지 종합적 서비스를 구현했다. CoT 방법론을 활용한 투명한 AI 평가 프레임워크 개발로 방법론적 기여를 했으며, 적절한 설계만으로도 고품질 서비스 구현이 가능함을 입증했다.

한계: 제한된 표본 크기(각 실험 30 명 미만), 장기 효과성 검증 부족, 다양한 정신건강 문제 적용성 검증 미흡 등이 향후 과제로 남았다.

4. 정책 제언

대학: 높은 우울증 고위험군 비율(39.7%)을 고려하여 24 시간 초기 상담 시스템으로 LLM 챗봇 도입과 전문상담사 연계 시스템 구축이 필요하다.

정부: 학제간 융합연구 촉진과 한국 특화 모델 개발을 위한 연구개발 지원 확대가 요구된다.

5. 핵심 기여

LLM 기반 한국어 심리상담 챗봇의 실증적 효과성 검증이 가장 중요한 기여이다. 인간-AI 협력 평가 체계를 통해 메타적 평가 방법론의 유효성을 입증하고, 대규모 디지털 정신건강 서비스의 품질 보장 방법론을 제시했다.

주제어 : 대학생 정신건강, LLM 챗봇, 디지털 중재, 정신건강 리터러시, Chain-of-Thought

제 1 장 서 론

1. 연구의 배경 및 필요성

1) 대학생 정신건강 문제의 심각성

전 세계적으로 대학생들의 정신건강 문제가 심각한 수준에 이르고 있으며, 이는 일시적 현상이 아닌 지속적인 추세로 나타나고 있다. 특히 우울증과 외로움이 주요 문제로 대두되고 있다. 보건복지부(2021)에 따르면, 한국 20-30 대의 우울 평균점수가 가장 높고 우울 위험군 비율도 30%에 달했다. 이는 질병관리청(2018) 결과와 비교할 때 약 6 배 증가한 수치이다. 국제적으로도 유사한 추세가 관찰되는데, 미국 질병통제예방센터(Centers for Disease Control and Prevention [CDC])의 보고에 따르면 2019 년부터 2021 년까지 대학생의 불안 또는 우울증 증상이 75% 증가했다(CDC, 2021).

주목할 만한 점은 이러한 추세가 COVID-19 팬데믹 이전부터 이미 진행되고 있었다는 것이다. Lipson(2022)의 연구에 따르면, 대학생들의 정신건강 상태는 2013 년 이래 지난 8 년 동안 지속적으로 악화되어 왔으며, 우울증과 불안 증상은 각각 135%, 110% 증가했다. 우울증과 외로움의 상관관계에 대한 연구들은 이 두 요인이 서로 밀접하게 연관되어 있음을 보여준다. 장기화된 외로움은 우울증 뿐 아니라 불안, 사회적 위축, 자살 충동 등 보다 심각한 정신건강 문제로 이어질 수 있어 각별한 주의가 필요하다(Cacioppo et al.(2006); Holt-Lunstad et al.(2015)).

대학생 정신건강 문제는 단순히 개인의 문제를 넘어 사회적, 경제적 영향력을 지닌다. 따라서 대학생 정신건강 문제에 대한 효과적인 개입과 지원은 개인의 삶의 질 향상 뿐만 아니라 사회 전반의 건강성과 생산성 제고에도 중요한 의미를 지닌다.

본 연구가 여러 정신건강 문제 중에서도 특히 우울증과 외로움에 주목하는 이유는 다음과 같은 근거에 기반한다. 미국정신의학회(American Psychiatric Association [APA], 2013)의 정신질환 진단 및 통계 편람 제 5 판(Diagnostic and Statistical Manual of Mental Disorders, Fifth Edition [DSM-5])에 따르면, 대학생들에게 주로 나타나는 정신건강 문제는 기분장애, 불안장애, 적응장애 등으로 분류되는데, 이 중에서도 주요우울장애가 가장 높은 유병률을 보인다. 더 나아가 우울증과 외로움은 서로 강한 상관관계를 보인다는 점에서 함께 다루어져야 할 문제이다. 이는 대학생 시기가 Arnett(2000)이 제시한 '성인 진입기(emerging adulthood)'로서 정체성 탐색과 사회적 관계 형성이 핵심 과업인 시기라는 발달적 특성에도 밀접한 관련이 있다.

2) 기존 정신건강 관리 체계의 한계

대학생들의 정신건강 문제가 날로 심각해지고 있음에도 불구하고, 이를 효과적으로 다루기 위한 대학 내 인프라와 지원 체계는 여전히 미흡한 실정이다. 전통적인 대면 상담 체계는 여러 구조적 한계를 가지고 있어 증가하는 대학생들의 정신건강 서비스 수요를 충족시키지 못하고 있다.

먼저 접근성 측면에서 대면 상담은 물리적, 시간적 제약을 가진다. 상담실까지의 이동 시간과 교통비, 주차 문제 등은 학생들에게 부담이 되며, 상담 시간이 대부분 평일 낮 시간대로 제한되어 수업이나 아르바이트로 바쁜 대학생들의

일정과 맞지 않는 경우가 많다. 전국대학교학생상담센터협의회(2021)에 따르면, 대학생의 86.8%가 스트레스를 경험하고 있음에도 불구하고 실제 상담 서비스를 이용하는 비율은 35.8%에 그쳤다. 비용과 자원의 제약 문제도 심각하다. 국내 대학 상담센터의 현실을 살펴보면, 전문 상담 인력과 예산의 절대적 부족이 드러난다. 한국의 경우, 대부분 대학이 상담인력 인건비 수준(4000~5000 만원)의 예산만 배정하고 있어 정상적인 운영이 어려운 수준이며, 이마저도 대부분 상담 서비스에 집중되어 있어 예방 차원의 접근은 부족하다(한국대학교육협의회, 2019 ; 장세풍, 2019 에서 재인용). 또한 전문 상담 인력과 자원의 부족으로 인해 서비스 접근성이 제한되고, 적시에 적절한 도움을 받지 못하는 경우가 많다(김진아, 2010; 최다정, 2021).

더욱 큰 문제는 정신건강 서비스 이용에 대한 사회적 낙인이 여전히 강하게 존재한다는 점이다. 정신건강에 대한 사회적 편견과 낙인 역시 대학생들이 도움을 요청하는 데 큰 걸림돌로 작용한다. 많은 학생들이 심리적 어려움을 겪고 있음에도 불구하고, 정신과 치료나 상담에 대한 부정적 인식으로 인해 도움 추구 행동을 꺼리는 경향이 있다(Eisenberg et al., 2009). 이는 증상을 악화시키고 문제를 장기화하는 요인이 될 수 있다.

3) 디지털 정신건강 중재의 필요성과 가능성

이처럼 기존 정신건강 관리 체계가 충분히 마련되어 있지 않은 상황에서, 급증하는 대학생들의 정신건강 문제에 적절히 대응하기 위한 새로운 접근법이 필요하다. 이러한 맥락에서 디지털 기술을 활용한 정신건강 관리 방안이 새로운 대안으로 주목받고 있다.

디지털 기술의 발전은 정신건강 서비스 전달 방식에도 혁신을 가져오고 있다. 특히 비대면 방식의 디지털 중재 서비스는 기존 대면 서비스의 한계를 극복하고 접근성을 향상시킬 수 있는 대안으로 주목받는다. 온라인 플랫폼, 모바일 앱 등을 통해 시간과 장소에 구애받지 않고 서비스를 이용할 수 있으며, 이는 바쁜 일정으로 인해 상담 시간을 내기 어려운 대학생들에게 특히 유용할 수 있다.

또한 디지털 서비스가 제공하는 익명성은 정신건강 문제에 대한 낙인감을 완화하고 도움 추구 행동을 촉진하는 데 기여할 수 있다. 대면 상담에 대한 심리적 부담감으로 인해 서비스 이용을 꺼리는 학생들도 보다 편안하게 접근할 수 있게 된다. 나아가 디지털 중재 서비스는 일대일 상담에 비해 더 많은 사용자에게 동시에 서비스를 제공할 수 있어 비용 효율성과 확장성 측면에서도 장점이 있다.

최근 대규모 언어모델(Large Language Model, LLM)의 발전은 디지털 정신건강 서비스에 새로운 전환점을 제시하고 있다. Brown et al.(2020)의 연구에서 제시된 GPT-3 와 같은 LLM 은 자연스러운 대화 능력과 맥락 이해 능력을 바탕으로 기존의 룰 기반 챗봇보다 훨씬 정교한 상호작용을 제공할 수 있게 되었다. 이러한 기술적 진보는 24 시간 접근 가능한 개인화된 정신건강 서비스를 현실화할 수 있는 가능성을 열어주고 있다.

상담이 심리적 문제에 대한 효과적인 해결책임에도 불구하고 실제 이용하는 비율은 아직 저조한 편인데(Yuen, 2012) 이러한 현상의 원인에는 시간, 비용과 같은 물리적 문제와 대면 상담의 두려움 등의 심리적 문제(Vogel et al., 2007)가 있는 것으로 연구되었다. 그런데 IT 기술의 발달과 인공지능 기술의 발달로 인해서 상담의 방식 또한 새로운 국면을 맞이하고 있는데 이는 상담 매체나 형식적 변화를

넘어 상담사의 역할을 인공지능 시스템이 대체할 수 있다는 가능성이 제시된 것이다(Ho et al., 2018).

더군다나 소위 사회적 기술이라고 하는 적극적인 듣기, 흉내 내기, 제스처 등을 인공지능 시스템에 통합한 가상 인간(Virtual Human)은 즉시 반응하는 동시성 및 대화 중에 느껴지는 감정의 경험으로 친밀감을 형성하는 것으로 나타났다(Bickmore et al., 2005; Gratch et al., 2013).

4) LLM 기반 정신건강 플랫폼의 대학 도입 필요성

대학은 정신건강 서비스 도입에 있어 독특한 환경적 특성을 가진다. 유사한 연령대와 발달 과업을 가진 사용자들이 집중되어 있어 맞춤형 서비스 설계가 용이하며, 학생복지 차원에서 대학 차원의 정책적, 재정적 지원이 가능하다. 또한 대학 내 심리상담센터, 연구진, 학생들 간의 협력을 통해 서비스의 지속적 개선이 가능하다는 장점도 있다.

현재 대학 내 정신건강 서비스는 상담센터, 보건소, 학생상담소 등으로 분산되어 있어 효율성이 떨어지는 상황이다. LLM 기반 플랫폼은 이러한 분산된 서비스들을 통합하는 역할을 할 수 있다. 자동화된 정신건강 스크리닝을 통해 고위험군을 조기 발견하고 적절한 서비스로 연계할 수 있으며, 경증의 경우 챗봇 상담, 중등도의 경우 전문상담사 연계, 중증의 경우 정신과 치료 연계 등 단계별 서비스 제공이 가능하다.

그러나 LLM 기반 정신건강 서비스를 대학 현장에 성공적으로 도입하기 위해서는 단계적이고 체계적인 검증 과정이 필요하다. 먼저 대학생을 대상으로 한 기존 디지털 정신건강 중재의 효과를 검증하여 기준점을 설정해야 한다. 그 다음

대학생의 특성과 요구에 맞춘 LLM 기반 챗봇을 개발하고 그 성능을 평가해야 하며, 개발된 시스템을 기존 상용 챗봇과 비교하여 상대적 우수성을 검증해야 한다.

5) 체계적 연구 설계의 필요성

LLM 기반 정신건강 플랫폼을 대학 현장에 성공적으로 도입하기 위해서는 단순한 기술적 구현을 넘어서 체계적이고 단계적인 검증 과정이 필요하다. 이를 위해 본 연구에서는 세 단계의 실험을 통한 포괄적 접근을 설계하였다.

먼저 실험 I: 기존 디지털 정신건강 치료의 임상 중재 효과성 분석이 필요하다. 대학생을 대상으로 한 디지털 정신건강 중재의 효과성에 대한 국내 연구는 여전히 부족한 실정이다. 해외 연구 결과를 그대로 적용하기에는 문화적, 사회적 맥락의 차이가 있으므로, 한국 대학생을 대상으로 한 기초 연구가 선행되어야 한다. 본 연구의 실험 I에서는 63 명의 대학생을 대상으로 4 개월간의 혼합연구를 통해 UCLA 외로움 척도(Russell, 1996)와 PHQ-9(Kroenke et al., 2001) 우울증 척도를 활용한 효과성 검증을 실시하여, 한국 대학생들에게 적용 가능한 디지털 중재의 기준점을 설정하고자 한다.

다음으로 실험 II: LLM 기반 챗봇 '닥터케어샘'¹의 개발 및 사용성 평가가 요구된다. 기존 LLM 을 단순히 활용하는 것을 넘어, 대학생의 정신건강 특성에 맞춘 특화된 시스템 개발이 필요하다. 본 연구에서는 호میم타운² 플랫폼의 핵심

¹ 닥터케어샘(Dr.CareSam)은 본 연구자가 개발한 LLM 기반 심리상담 챗봇으로, 호میم타운 플랫폼의 핵심 서비스이다. 인지행동치료(CBT) 기법과 친근한 페르소나를 결합한 프롬프트 엔지니어링을 통해 한국어 자연어 대화가 가능하도록 설계되었다.

² 호میم타운(HoMemeTown)은 본 연구자가 2022년 12월부터 2024년 5월까지 개발한 청년 정신건강 지원 플랫폼이다. 본 연구는 K-Medi융합인재양성지원사업으로 선정된 "자연어처리

서비스로서 한국 대학생에게 특화된 LLM 기반 심리 상담 챗봇 '닥터케어썸'을 개발하였다. 이 시스템은 인지행동치료 기법을 LLM 에 효과적으로 구현하기 위한 체계적인 프롬프트 엔지니어링을 적용하였다. 20 명의 한국 청년을 대상으로 한 파일럿 스터디를 통해 긍정성/지지, 공감성, 경청 등의 영역에서 10 점 척도 평가를 실시하여 상담 챗봇의 상담 품질 및 사용성과 효과성을 검증하고자 한다.

마지막으로 실험 III: 글로벌 LLM 기반 심리 챗봇들과의 비교 분석이 필수적이다. 개발된 LLM 기반 챗봇의 우수성을 입증하기 위해서는 기존 상용 솔루션과의 체계적 비교가 필요하다. 본 연구의 실험 III 에서는 글로벌 시장에서 주목받고 있는 Wysa, Replica, Youper 등 최신 LLM 기반 심리 챗봇들과 연구자가 개발한 '닥터케어썸' 챗봇 간의 체계적 비교 분석을 실시한다. 이 과정에서 Claude 3.5, ChatGPT 4.0 과 같은 최신 LLM 기술과 전문 상담사의 평가를 결합한 AI-인간 협업 평가 방법론을 도입하여, 단순한 기술적 성능뿐만 아니라 실제 상담 품질과 임상적 적절성까지 종합적으로 평가하고자 한다.

이러한 세 단계의 체계적 연구 설계를 통해 LLM 기반 정신건강 플랫폼의 효과성을 단계적으로 검증하고, 실제 대학 현장에서의 도입 가능성을 과학적으로 입증하고자 한다.

2. 이론적 배경

1) 인지행동치료(CBT) 이론적 기초

기술을 이용한 근거기반 청년 정신건강 돌봄 디지털 서비스 플랫폼 개발"의 일환으로 진행되었던 연구과제이다.

인지행동치료(Cognitive Behavioral Therapy, CBT)는 본 연구에서 개발한 LLM 기반 챗봇 '닥터케어쌤'의 핵심 이론적 기반이다. CBT 는 Beck(1967)이 1960 년대에 개발한 심리치료 접근법으로, 개인의 사고, 감정, 행동 간의 상호작용에 초점을 맞춘다(Beck et al.,1979). 이 이론의 핵심 가정은 부적응적 사고 패턴이 부정적 감정과 행동을 유발한다는 것이며, 이러한 사고 패턴을 식별하고 수정함으로써 정신건강 문제를 개선할 수 있다는 것이다.

CBT 의 이론적 모델은 인지 삼각형으로 표현되는데, 이는 사고, 감정, 행동 간의 상호 연결성을 보여준다. Beck 의 인지 이론에 따르면, 개인은 자신, 세상, 미래에 대한 핵심 신념(core beliefs)을 가지고 있으며, 이러한 신념들이 자동적 사고(automatic thoughts)를 통해 일상적 경험을 해석하는 렌즈 역할을 한다. 우울증이나 불안장애를 겪는 사람들은 종종 부정적이고 비합리적인 사고 패턴을 보이며, 이러한 인지적 왜곡(cognitive distortions)이 정서적 고통을 지속시키고 악화시킨다.

CBT 의 디지털 중재 적용에 있어서 핵심적인 요소들은 다음과 같다. 첫째, 심리교육을 통해 사용자가 자신의 사고-감정-행동 패턴을 이해하도록 돕는다. 둘째, 사고 기록(thought monitoring)을 통해 부정적 자동적 사고를 포착하고 기록하는 기술을 학습한다. 셋째, 인지적 재구성(cognitive restructuring)을 통해 비합리적 사고를 보다 균형잡힌 관점으로 대체한다. 넷째, 행동 실험과 점진적 노출을 통해 회피 행동을 줄이고 적응적 행동을 증가시킨다.

Fitzpatrick et al.(2017)의 연구는 완전 자동화된 대화형 에이전트(Woebot)를 통한 CBT 전달의 효과성을 입증했다. 이 연구는 CBT 의 핵심 요소들이 디지털 플랫폼을 통해 효과적으로 전달될 수 있으며, 특히 대학생 집단에서 높은 수용성을

보인다는 것을 보여주었다. 2 주간의 짧은 중재 기간에도 불구하고 우울 증상의 유의미한 감소가 관찰되었으며, 이는 CBT 기반 디지털 중재의 즉각적 효과 가능성을 시사한다.

본 연구에서 개발한 '닥터케어썸' 챗봇은 CBT 이론을 LLM 기술과 결합하여 구현하였다. 한국어 지원을 통한 접근성 향상과 대학생의 일상적 언어 표현에 자연스럽게 대응하는 데 중점을 두었으며, 사용자의 입력에 대해 CBT 의 원리에 따른 체계적 응답을 생성하도록 프롬프트 엔지니어링을 설계하였다.

2) 건강행동신념모델(HBM) 이론적 배경

건강행동신념모델(Health Belief Model, HBM)은 개인이 건강 관련 행동을 취하는 동기를 설명하는 이론적 프레임워크로, 본 연구의 디지털 정신건강 중재 설계에 중요한 이론적 근거를 제공한다. 이 모델은 1950 년대 사회심리학자 Rosenstock(1966)과 Becker(1974)에 의해 개발되었으며, 사람들의 건강 관련 행동을 이해하고 예측하는 데 널리 활용되고 있다.

HBM 에 따르면, 개인이 예방 차원의 건강 행동을 하거나 치료 지시를 따르기로 결정하는 데에는 다섯 가지 핵심 요인이 작용한다. 첫째, 지각된 취약성은 개인이 특정 질병이나 건강 상태에 걸리기 쉽다고 여기는 정도를 의미한다. 정신건강 맥락에서는 자신이 우울증이나 불안장애에 취약하다고 인식하는 정도를 말한다. 둘째, 지각된 심각성은 해당 질병이나 건강 문제가 얼마나 심각한 결과를 초래할 것인지에 대한 개인의 인식을 나타낸다. 셋째, 지각된 이익은 건강 행동을 했을 때 얻을 수 있는 이점에 대한 개인의 믿음이다. 넷째, 지각된 장벽은 건강

행동을 하는 데 있어 예상되는 물리적, 심리적 장애물에 대한 개인의 인지이다.

다섯째, 행동 계기는 건강 행동을 촉발하는 내적 혹은 외적 자극을 의미한다.

대학생 정신건강 서비스 이용 맥락에서 HBM 을 적용하면 다음과 같은 해석이 가능하다. 많은 대학생들이 스트레스나 우울감을 경험하면서도 전문적 도움을 구하지 않는 이유는 HBM 의 각 구성 요소들로 설명할 수 있다. 지각된 취약성이 낮을 경우, 자신의 정신건강 문제를 일시적이거나 정상적인 것으로 인식하여 전문적 개입의 필요성을 느끼지 못한다. 지각된 심각성이 낮을 경우, 정신건강 문제의 장기적 영향을 과소평가하게 된다.

본 연구에서는 HBM 의 구성 요소 중 지각된 이익, 지각된 장벽, 그리고 지각된 취약성과 연결되는 도움 추구 행동에 특별히 주목하였다. 디지털 중재 프로그램이 가져올 이점과 참여에 수반되는 난점에 대한 인식이 프로그램의 실효성에 미치는 영향을 규명하고자 하였다. 특히 흥미로운 점은 지각된 취약성과 도움 추구 행동의 관계이다. 외로움과 우울감에 대한 개인의 취약성 인식이 높을수록 혼자 힘으로 이런 문제를 해결하기 어렵다고 여기고, 외부의 도움을 적극적으로 찾으려 할 가능성이 크다.

3) 자기결정이론(SDT)과 디지털 중재

디지털 정신건강 중재의 효과성을 뒷받침하는 또 다른 중요한 이론적 배경으로 자기결정이론을 들 수 있다. SDT 는 개인의 자율성, 유능성, 관계성에 대한 기본 심리적 욕구가 충족될 때 내재적 동기가 향상되고, 이는 행동 변화와 심리적 안녕감으로 이어진다고 설명한다(Patrick et al., 2012).

디지털 중재는 SDT 의 세 가지 기본 욕구를 효과적으로 충족시킬 수 있는 특성을 가지고 있다. 첫째, 자율성 측면에서 개인이 자신의 일정과 환경에 따라 치료를 받을 수 있도록 하여 높은 수준의 자기 결정권을 제공한다. 둘째, 유능성 측면에서 개인이 진행 상황을 추적하고 증상을 모니터링할 수 있도록 하여 자기 관리 역량을 향상시킨다. 셋째, 관계성 측면에서 소셜 지원 기능이 포함된 일부 디지털 중재는 개인이 비슷한 경험을 겪고 있는 다른 사람들과 연결할 수 있도록 하여 사회적 연결감을 제공한다.

본 연구에서 개발한 '닥터케어썸' 챗봇 역시 이러한 SDT 원리를 반영하여 설계되었다. 사용자가 원하는 시간에 자유롭게 접근할 수 있는 자율성, 단계별 목표 달성을 통한 유능감 증진, 그리고 공감적 반응을 통한 심리적 연결감 제공 등이 그 예이다.

4) 정신건강과 사회적 낙인 이론

대학교에서 정신건강 관리의 주요 난제 중 하나는 사회적 낙인 효과이다. 정서적으로 취약한 대학생들은 타인의 판단이나 차별을 받을까 우려하여 도움을 요청하는 것을 주저하게 되며, 이는 정신건강 관리를 지연시키고 문제의 악화를 초래한다. National Alliance on Mental Illness(2024)에 따르면, 진단이나 치료가 필요한 성인의 약 44%만이 매년 실제로 치료를 받는 것으로 나타났다.

Goffman(1963)은 지배 질서에 편입되는 것을 미덕으로 여기는 사회에서 개인이 반드시 삶의 어느 시점에서 낙인을 경험한다고 하였다. 로이 리처드 그린커(2022)는 「정상은 없다: 문화는 어떻게 비정상의 낙인을 만들어내는가」에서 정상성에 대한 사회적 기준이 어떻게 구성되는지를 분석하였다.

이러한 관점은 정신건강 문제에 대한 낙인이 사회 구조적 차원에서 이해되어야 함을 시사한다.

손인서와 김승섭(2015)은 차별경험과 건강과의 관계를 연구한 학술논문 52 편을 분석하였다. 분석 결과, 한국의 차별과 건강에 대한 연구들이 정신건강(N=42) 영역에 집중되어 있음을 확인했다. 이는 차별과 낙인이 개인의 정신건강에 미치는 영향이 상당히 크다는 것을 보여준다.

최근 미국, 호주 등 서구 국가들에서는 정신건강에 대한 인식 개선 캠페인과 대학교의 정신건강 리터러시 교육 등의 노력으로 청년층의 정신건강 낙인이 감소하고 있다는 연구 증거가 제시되고 있다. Sontag et al. (2018)은 대학생 동료 정신건강 조직 프로그램에 참여한 학생들이 시간이 지남에 따라 정신건강 지식 증가와 함께 정신건강 낙인이 감소하는 것을 확인했다. 그러나 한국의 경우에는 아직 낙인 효과에 대한 개선이 더 많이 필요한 상황이다(김희철, 2018).

이러한 맥락에서 디지털 정신건강 중재는 낙인 문제를 완화할 수 있는 중요한 대안으로 주목받는다. 디지털 플랫폼이 제공하는 익명성과 개인정보 보호는 전통적인 대면 상담에서 경험할 수 있는 사회적 낙인에 대한 우려를 크게 줄일 수 있기 때문이다.

3. 선행 연구

1) 외로움과 우울증 연구

1.1) 우울증의 심각성과 사회적 영향

우울증 환자의 생존율 저하 문제는 심각한 공중보건 이슈로 대두되고 있다. Chesney et al.(2014)의 메타분석 연구에 따르면, 우울증 환자의 표준화 사망비는

1.71 로, 일반 인구 대비 71%의 높은 사망률을 보이며, Walker et al.(2015)의 연구는 우울증 환자의 조기 사망 위험이 일반 인구보다 약 2 배 높다고 보고했다.

우울증은 유전적 요인이 약 50%로 작용하며, 치료하지 않을 경우 사망률도 높은 편이지만, 평생 유병률이 여전히 높은 질병이다(Sullivan, 2000). 최근 연구들은 우울증이 단순한 유전적 요인을 넘어 환경적, 사회문화적 요인들이 복합하게 상호작용하는 질환임을 보여주고 있다(Otte et al., 2023).

한국의 상황은 특히 심각하다. OECD 국가 중 가장 높은 자살률을 기록하고 있으며, 2021년 기준 인구 10만 명당 26.0명으로 OECD 평균(11.1명)의 두 배를 훨씬 상회한다. WHO(2023)의 최신 보고서에 따르면, 전 세계적으로 약 5억 명이 우울증이나 불안장애로 고통받고 있으며, 이는 COVID-19 팬데믹 이후 40% 증가한 수치이다.

1.2) 외로움과 우울증의 관계

외로움과 우울증 사이의 밀접한 관계는 다수의 연구를 통해 입증되었다. Matthews et al.(2016)은 행동유전학적 분석을 통해 외로움과 우울증이 공통된 유전적, 환경적 위험 요인을 공유함을 밝혔으며, 외로움과 우울증 간의 유전적 상관관계는 0.63으로 나타났다.

더 중요한 것은 외로움이 우울증의 선행지표(leading indicator)로 작용한다는 점이다. Cacioppo et al.(2010)의 5년간 종단연구는 외로움이 우울 증상의 발달에 유의미한 영향을 미침을 증명했으며, 외로움이 지속될 경우 향후 우울 증상 발달 가능성이 유의미하게 증가함을 보여주었다.

Cacioppo et al.(2010)의 후속 연구에서는 시카고 건강, 노화 및 사회 관계 연구 데이터를 활용한 5 년 교차지연 분석을 통해 외로움과 우울 증상 간의 예측 관계를 더욱 구체적으로 확인했다. Qualter et al.(2010)은 296 명의 아동을 대상으로 한 8 년 전향적 연구에서 아동기의 지속적인 또래 관련 외로움이 청소년기 우울 증상을 예측하는 중요한 대인관계 스트레스 요인임을 밝혔다.

본 연구는 이러한 이론적 배경을 바탕으로 디지털 정신건강 중재의 효과를 종합적으로 평가하고자 한다. 실험 I 에서는 3 개월간의 디지털 중재를 통해 대학생의 외로움과 우울증 변화를 관찰하고, 이 과정에서 두 변수 간의 상관관계를 탐색적으로 조사할 예정이다. 비록 단기간의 중재 기간으로 인해 심층적인 인과관계 분석에는 한계가 있지만, 이는 후속 연구의 기초 데이터로서 외로움과 우울증의 상호작용 패턴을 이해하는 데 중요한 통찰을 제공할 것으로 기대된다.

1.3) 대학생 집단에서의 특수성

대학생 집단에서의 우울증과 외로움 문제는 더욱 심각한 것으로 나타났다. 2021 년 「정신건강 실태조사」에 따르면, 한국 20-30 대의 우울 평균점수가 가장 높고 우울 위험군 비율이 30%에 달했으며, 이는 2018 년 지역사회 건강조사 결과와 비교할 때 약 6 배 증가한 수치이다.

사회구조적 변화도 이러한 현상을 가속화하고 있다. 통계청(2022)에 따르면 한국의 1 인 가구 비율이 2021 년 현재 33.4%로, 2000 년의 15.5%와 비교할 때 급격한 증가세를 보이고 있다. 서울연구원(2023)의 조사에 따르면, 1 인 가구의 외로움 경험 비율은 62.1%, 사회적 고립 비율은 13.6%에 달하며, 특히 청년층(20-30 대) 1 인 가구의 경우 하루 평균 대면 교류 시간이 1 시간 14 분에

불과하다. 이러한 사회적 고립은 학업 성과에도 직접적 영향을 미치는데, Auerbach et al.(2016)의 중단연구는 우울 증상이 있는 학생들의 학업 중단 위험이 2.7 배 높다는 것을 밝혔으며, 이는 대학생 정신건강 문제의 학업적 파급효과를 보여준다.

이러한 상황에서 자연어처리 기술을 활용한 디지털 기반의 상담 서비스는 시간적, 공간적 제약을 극복하고 초기 단계에서의 심리적 지원을 제공할 수 있는 유망한 접근 방식으로 주목받고 있다. 특히 외로움이 우울증의 선행지표라는 점에서, 외로움 단계에서의 조기 개입은 우울증 예방에 매우 중요한 의미를 가진다. 이는 본 연구에서 검증하고자 하는 LLM 기반 챗봇의 이론적 근거가 되며, 전통적인 대면 상담에 대한 심리적 장벽이 높은 젊은 세대들에게 효과적인 대안이 될 수 있다.

2) 디지털 정신건강 중재 관련 연구

2.1) 디지털 중재의 효과성 연구

디지털 정신건강 중재의 효과성은 지난 10 년간 다수의 연구를 통해 입증되어 왔다. Barak et al.(2008)의 메타분석에서는 인터넷 기반 심리치료의 평균 효과 크기가 $d = 0.53$ 으로 중간 정도의 효과를 보였으며, 이는 대면 치료와 유사한 수준의 효과성을 나타낸다.

특히 대학생 집단을 대상으로 한 연구들에서 주목할 만한 결과들이 도출되었다. Harrer et al.(2019)의 메타분석에 따르면, 대학생 대상 인터넷 기반 중재는 우울 증상($g = 0.18$), 불안 증상($g = 0.27$), 스트레스($g = 0.20$)에서 작지만 유의미한 효과를 보였다. 특히 섭식장애 증상($g = 0.52$)과 역할 기능($g = 0.41$)에서는 중간 정도의 효과크기가 관찰되었다.

Lim et al.(2019)의 연구는 18-25 세 청년을 대상으로 6 주간의 인터넷 기반 중재 프로그램을 실시하여 외로움과 우울증 사이의 유의미한 상관관계를 실증적으로 입증했다. 이 연구는 인터넷 기반 중재가 외로움과 우울 증상을 동시에 완화할 수 있다는 가능성을 제시했으며, 중재 효과의 지속성도 검증했다.

2.2) 앱 기반 중재의 발전

모바일 앱을 활용한 정신건강 중재는 접근성과 사용 편의성 측면에서 큰 장점을 보인다. Fitzpatrick et al.(2017)의 Woebot 연구는 앱 기반 자동화 대화형 에이전트의 효과성을 검증했다. 이 연구는 인지행동치료 기반 중재의 디지털 전환 가능성을 제시했으며, 특히 대학생 집단에서의 높은 수용성을 입증했다.

Boucher et al.(2021)의 디지털 테라피 앱인 Happify 에 대한 연구는 COVID-19 팬데믹 상황에서 앱 기반 중재의 실효성을 질적 연구방법으로 검증했다. 포커스 그룹 인터뷰를 통해 사용자들의 경험을 분석한 결과, 접근성의 용이함, 익명성 보장, 24 시간 지원 가능성이 주요 장점으로 도출되었다.

2.3) AI 기술 활용과 국내 적용 현황

Lehtimaki et al.(2021)의 연구는 AI 와 머신러닝 기술을 활용한 디지털 중재가 사용자의 개별적인 요구와 선호도에 따라 콘텐츠와 개입 방식을 조정할 수 있다는 점을 강조했다. 머신러닝 알고리즘이 사용자의 상호작용 패턴을 분석하여 개인화된 중재 전략을 수립하는 과정이 중재 효과를 유의미하게 향상시킨다는 것을 보였다.

Lattie et al.(2019)은 디지털 정신건강 중재가 시간과 공간의 제약, 낙인에 대한 두려움 등으로 인해 발생하는 장벽을 낮추어 더 많은 학생들이 필요한 서비스에 접근할 수 있게 한다는 점을 실증적으로 입증했다.

최다정 외(2021)는 대학상담센터 맥락에서 챗봇의 활용 가능성을 탐색했다. 개발된 챗봇 '샤샤'에 대한 사용자 평가에서는 '상담 서비스 동기 증진'과 '상담센터에 대한 물리적, 심리적 장벽 감소'가 긍정적 요소로, '개인정보 노출에 대한 불안'이 부정적 요소로 도출되었다.

박지혜 외(2020)의 연구는 한국 청년들의 정신건강 리터러시와 도움요청 행동 간의 관계를 분석했다. 411 명의 20 대 청년을 대상으로 한 연구에서 전체 응답자 중 10%만이 정신건강 관련 전문적 도움을 요청한 경험이 있었으며, 특히 온라인 상담/전화 상담의 이용률이 가장 낮았다. 이는 한국 맥락에서 디지털 정신건강 중재의 필요성과 동시에 문화적 특수성을 고려한 접근법의 중요성을 시사한다.

2.5) 디지털 중재의 한계와 도전과제

디지털 중재는 높은 잠재력에도 불구하고 여러 한계점들을 가지고 있다. Meyerowitz-Katz et al.(2020)이 지적한 바와 같이, 앱 기반 중재의 중도 탈락률은 평균 47%에 달해 참여 지속성 확보가 주요 과제로 대두되고 있다.

Linardon et al.(2019)의 체계적 문헌고찰에 따르면, 대부분의 연구가 8-12 주의 비교적 단기 효과만을 측정했으며, 6 개월 이상의 장기 추적 연구는 매우 제한적이었다. 이는 디지털 정신건강 중재의 장기적 효과성에 대한 체계적인 연구가 더욱 필요함을 시사한다.

현재 대부분의 디지털 중재 프로그램들이 일반 성인을 대상으로 설계되어 있어, 대학생들의 특수한 정신건강 요구를 충분히 반영하지 못하고 있다는 점도 중요한 한계로 지적된다.

3) LLM 기반 챗봇 연구 동향

3.1) LLM 기술의 발전과 정신건강 분야 적용

대규모 언어모델(Large Language Model, LLM) 기술은 최근 자연어 처리 분야에서 혁신적 발전을 이루었다. 이러한 발전은 크게 세 가지 핵심 요인에 기인한다. 첫째, 모델 규모의 획기적 확장이다. Brown et al.(2020)은 GPT-3를 통해 1,750억 개의 파라미터를 가진 대규모 모델을 구현했는데, 특히 주목할 만한 점은 이 모델이 미세조정 없이도 소수 예제 학습(few-shot learning)이 가능하다는 것이다. 이는 모델 규모의 확장이 단순한 양적 증가가 아닌 질적 변화를 가져올 수 있음을 입증했다.

둘째, 학습 데이터의 양적, 질적 향상이다. Ouyang et al.(2022)이 입증한 것처럼 인간 피드백을 통한 고품질 학습 데이터의 구축이 모델의 성능을 크게 향상시켰다. 특히 다양한 도메인의 고품질 데이터를 활용한 학습을 통해 모델의 범용성이 크게 개선되었다.

셋째, 셋째, 인간 피드백을 통한 강화학습(Reinforcement Learning from Human Feedback, RLHF)을 통한 대화 품질 향상이다. RLHF는 인간의 선호도와 피드백을 활용하여 AI 모델이 보다 자연스럽고 유용한 대화를 생성할 수 있도록 학습시키는 기술이다. 이러한 기술들은 모델이 인간의 선호도를 더 잘 반영하고, 보다 자연스럽고 유용한 대화를 생성할 수 있게 하였다.

3.2) 대학생 정신건강 분야에서의 LLM 적용 연구

대학생 정신건강 분야에서 LLM의 활용 가능성이 주목받고 있다. LLM 기반 시스템은 특히 24시간 접근 가능성과 익명성 보장이라는 장점을 가지고 있으며, 대학생들이 전통적인 상담에 대해 느끼는 낙인이나 불편함 없이 자신의 고민을 표현할 수 있는 환경을 제공한다.

Li et al.(2024)의 CulturePark 연구는 LLM 기반 상담 시스템의 문화적 맥락화 중요성을 부각시킨다. 이 연구는 다문화적 데이터를 활용하여 인간 신념, 규범, 관습이 반영된 고품질 데이터를 생성하고, 이를 기반으로 다양한 문화적 배경에서 효과적으로 작동할 수 있는 LLM을 개발하였다.

3.3) LLM 기반 정신건강 챗봇의 효과성 연구

Kocaballi et al.(2019)의 연구에 따르면, 헬스케어 분야에서 대화형 에이전트의 개인화는 사용자 참여도와 효과성 향상에 중요한 역할을 한다. 이는 LLM 기반 챗봇이 개별 사용자의 특성과 요구에 맞춘 맞춤형 서비스를 제공할 수 있다는 가능성을 시사한다.

3.4) 현재의 도전과제와 한계

현재 LLM 기반 상담 시스템의 개발과 적용에는 여러 주요 도전과제들이 존재한다. 첫째, 윤리적 고려사항으로서 정신건강 상담에서 AI의 활용은 신중한 윤리적 검토가 필요하다. 특히 위기 상황 감지와 대응, 개인정보 보호, 그리고 사용자 안전 보장을 위한 체계적인 가이드라인 수립이 요구된다. 이러한 맥락에서

Anthropic 에서 개발한 Constitutional AI(Bai et al., 2022)는 AI 시스템이 인간의 가치와 도덕적 원칙을 체계적으로 학습하여 보다 안전하고 윤리적인 응답을 생성할 수 있도록 하는 프레임워크를 제시하였다.

둘째, 맥락화된 지식 통합의 문제이다. 대학생들의 다양한 정신건강 문제와 상황별 특수성을 고려한 지식 체계 구축은 여전히 과제로 남아있다. 특히 한국 대학생들의 문화적, 사회적 맥락을 반영한 상담 지식의 통합이 필요하다.

셋째, Yin et al.(2021)의 체계적 문헌고찰에 따르면, AI 기반 임상 응용의 실제 구현 사례들 중 장기적 효과성을 검증한 연구는 매우 제한적이다.

넷째, 문화 특화된 공감 전략 개발의 필요성이다. Zhai et al.(2022)의 체계적 문헌고찰에 따르면, AI 챗봇의 효과성은 문화적 배경, 공감 능력, 유머 등 세 가지 차원에서 크게 영향을 받는 것으로 나타났다.

다섯째, 전문적 상담 품질 평가 방법론의 부재이다. 기존 LLM 기반 심리 챗봇들의 성능을 단순한 사용자 만족도나 기술적 지표로만 평가하는 것은 한계가 있다. 상담학적 관점에서 챗봇의 응답이 실제로 어떤 질적 수준을 가지는지, 전문적 상담 기준에 부합하는지를 체계적으로 평가할 수 있는 방법론이 필요하다. 특히 Chain-of-Thought 기반 LLM 평가와 상담학적 관점을 결합한 새로운 평가 체계의 개발이 시급하다.

여섯째, AI 평가의 신뢰성 확보 문제이다. LLM 챗봇을 평가하기 위해 다른 AI를 활용하는 메타 평가 접근법의 경우, 평가의 객관성과 일관성을 어떻게 보장할 것인지에 대한 방법론적 고민이 필요하다. 인간 전문가의 통찰과 AI의 분석 능력을 효과적으로 결합한 삼중 검증 체계 구축이 요구된다.

4. 연구 목적 및 가설

1) 연구 목적

본 연구의 목적은 대학생 정신건강 증진을 위한 디지털 중재의 효과성을 실증적으로 검증하고, LLM 기반 AI 챗봇의 정신건강 상담 분야 적용 가능성을 탐구하는 것이다. 구체적으로는 다음과 같은 세 가지 핵심 목표를 설정하였다.

첫째, 기존 디지털 정신건강 테라피 앱의 임상적 효과성을 건강신념모델(Health Belief Model)의 이론적 틀 안에서 실증적으로 검증한다. 이를 통해 디지털 중재가 대학생의 우울감과 외로움 감소에 미치는 실질적 영향을 정량적으로 평가하고, 사용자의 건강신념이 중재 효과에 미치는 조절 역할을 규명한다.

둘째, 실험 I 에서 확인된 한계점들을 해결하기 위해 혁신적인 LLM 기반 정신건강 상담 챗봇 '닥터케어썸'을 개발하고 평가한다. 특히 실험 I 에서 발견된 "자연스러운 한국어 대화 능력"의 중요성을 바탕으로, CBT 기법과 친근한 페르소나를 결합한 프롬프트 엔지니어링을 통해 기존 규칙 기반 시스템의 한계를 극복하고자 한다.

셋째, 현존하는 주요 LLM 기반 심리 챗봇들의 상담 대화의 깊이와 효과성을 체계적인 상담학적 평가 방법론으로 비교 분석한다. 본 연구에서 개발된 평가 기준을 활용하여 각 시스템의 강점과 한계를 파악하고, AI 평가자와 인간 전문가가 결합된 삼중 검증 체계의 타당성을 검증한다.

4.2 핵심 연구 질문

본 연구는 다음과 같은 핵심 연구 질문들을 중심으로 진행된다:

RQ1: 건강신념모델의 구성요소들이 디지털 정신건강 중재 효과에 어떤 영향을 미치는가?

RQ2: 정신건강 챗봇의 어떤 기능적 요소가 사용자의 지속 사용 의향에 가장 큰 영향을 미치는가?

RQ3: LLM 기반 챗봇이 기존 규칙 기반 시스템 및 범용 LLM 과 비교했을 때 어떤 우위를 보이는가?

RQ4: 본 연구에서 도출된 상담 대화 평가 방법론이 정신건강 챗봇의 상담 대화의 깊이와 효과성을 효과적으로 변별할 수 있는가?

4.3 대표 가설

신생 분야인 LLM 기반 정신건강 챗봇 연구의 특성을 고려하여, 본 연구는 탐색적 연구 접근법을 취한다. 주요 대표 가설들은 다음과 같다:

가설 1 (중재 효과): 디지털 정신건강 중재 프로그램에 참여한 대학생 집단은 대조군에 비해 우울감과 외로움 수준이 유의하게 감소할 것이다.

가설 2 (LLM 시스템의 우수성): 정신건강에 특화된 LLM 기반 챗봇이 기존 규칙 기반 테라피 앱 및 범용 LLM 보다 높은 사용자 만족도를 보일 것이다.

가설 3 (평가 방법론의 변별력): 본 연구에서 개발된 상담 대화 품질 평가 방법론은 서로 다른 특성을 가진 정신건강 챗봇들을 유의미하게 변별할 수 있을 것이다.

각 실험별 구체적인 가설과 분석 방법은 해당 장에서 상세히 다룬다.

5. 연구 방법론 및 분석 전략 (Analytical Strategy)

1) 연구 설계의 철학적 기반

본 연구는 대학생들의 정신건강 문제의 심각성과 기존 지원 체계의 한계에 대한 문제의식에서 출발한다. 미시간 대학교(University of Michigan)의 'Depression on College Campuses Conference'(2023)에서 제시된 바에 따르면, 대학 내 정신건강 위기의 심각성과 함께 디지털 네이티브 세대인 Z 세대 대학생들의 특성과 요구에 맞는 상담 방식의 변화가 시급한 과제로 대두되고 있다. 특히 대학생들은 정신건강 어려움을 겪을 때 전문 상담사보다는 또래 친구들에게 먼저 도움을 요청하는 경향이 있어, 접근성과 수용성을 높이는 지원 체계 설계가 중요함을 시사한다.

한편 의료 및 정신건강 분야에서는 기존의 진단 체계와 치료 방식에 대한 근본적인 성찰도 이루어지고 있다. 로이 리처드 그린커(2022)는 정신의학계의 진단 기준이 개인의 다양성과 사회문화적 맥락을 간과하고 있음을 지적하며, 정신건강 문제에 대한 새로운 이해의 필요성을 제기한다. 이러한 맥락에서 리타 차론(2006)이 제안한 내러티브 의학의 철학은 환자의 고유한 이야기와 경험에 귀 기울이는 것이 치료의 핵심임을 강조한다. 이는 질병과 건강 문제를 바라보는 패러다임의 전환을 시사하며, 개인의 내러티브를 존중하고 공감하는 것이 회복의 출발점이 될 수 있음을 보여준다. 이러한 관점은 현재 디지털 헬스케어 분야의 학제간 융합 연구 동향과도 부합하며, Husserl(1913)의 현상학과 상호주관성 개념처럼 사용자 중심의 디지털 솔루션 설계에 중요한 통찰을 제공한다.

정신의학 분야의 데이터가 대부분 비정형적이며 환자의 이야기에 귀 기울여야 문제점을 포착할 수 있다는 특성 또한 내러티브의 중요성을 뒷받침한다. 리타 차론

교수의 강조처럼, 환자의 이야기와 감정에 공감하는 것이 인간적이고 양질의 환자 중심적 치료의 핵심이다. 이러한 철학은 필자가 개발 중인 호미타운 챗봇의 기본 반응인 "Your emotion is still valid (당신의 감정은 여전히 유효합니다)"의 근간이 되었다.

이러한 접근은 개인과 환경 간의 상호작용에 초점을 맞추는 커뮤니티 심리학(Community Psychology)의 관점과도 맞닿아 있다. 커뮤니티 심리학은 개인의 심리적 안녕과 자율성 증진을 위해 사회적 지지와 자원이 필수적임을 강조하며(Kloos et al., 2012), 이는 대학생 정신건강 증진을 위해 대학 공동체 내의 유대와 상호 지지를 강화하는 접근이 필요함을 시사한다.

이상의 문제의식과 선행 연구의 통찰, 그리고 연구자 자신의 학제적 배경을 바탕으로, 본 연구는 디지털 기술을 활용한 대학생 정신건강 지원 방안을 모색하고자 한다. 구체적으로는 대학생들의 요구와 선호를 반영한 대화형 정신건강 상담 챗봇 및 디지털 플랫폼을 설계하고, 그 효과성과 가능성을 탐색하는 것을 목적으로 한다. 이는 단순히 기술적 솔루션 개발을 넘어, 대학생들의 정신건강 문제에 대한 사회적 인식 변화와 도움 요청 문화의 정상화를 통해 대학 공동체 전체의 웰빙을 증진하는 소셜 이노베이션(social innovation)의 실천이기도 하다.

따라서 본 연구는 Creswell et al.(2017)의 혼합연구방법론을 채택하되, 현상학적 이해와 내러티브 의학의 철학적 통찰을 바탕으로 정량적 검증과 질적 탐구를 통합한다. 이를 통해 대학생 정신건강 지원을 위한 혁신적이고 사용자 중심적인 디지털 솔루션 개발에 기여함은 물론, 대학 공동체성의 회복과 구성원 상호 간의 이해 증진에도 일조할 수 있기를 기대한다.

2) 단계적 연구 설계 (Sequential Explanatory Design)

본 연구는 Ivankova et al.(2006)의 순차적 설명 설계를 적용하여 3 단계의 실험을 체계적으로 연결한다.

2.1) 실험 I: 무작위 대조 실험 (Randomized Controlled Trial)

실험 I은 무작위 통제 실험설계(Randomized Controlled Trial)를 적용한 전후 비교 연구로 설계되었다. 독립변수는 디지털 정신건강 중재 프로그램 참여 여부이며, 종속변수로는 우울감(PHQ-9)과 외로움(UCLA 외로움 척도)을 측정하였다. 건강신념모델의 구성 요소들을 조절변수로 설정하였다.

참가자들은 층화 무작위 배정법을 통해 3 개 그룹에 배정되었으며, 나이, 성별, 우울감, 외로움 점수가 각 그룹에 고르게 분포되도록 하였다.

1 단계: 기술통계, 정규성 검정(Shapiro-Wilk test), 집단 간 동질성 검정을 실시하였다.

2 단계: 정규분포를 따르는 데이터에 대해서는 Independent t-test 를, 정규성을 위배하는 경우에는 Mann-Whitney U test 를 적용하여 집단 간 차이를 분석하였다.

3 단계: 질적 데이터 분석을 위해 주제분석법(Thematic Analysis)을 활용하였다. 동일 앱 사용자 5-6 명으로 구성된 포커스 그룹 인터뷰를 Zoom 을 통해 90 분간 진행하였으며, 귀납적 접근법을 통해 주제를 식별하였다. 전사에는 Naver Clova 를 활용하였고, Python 기반 텍스트 마이닝을 통해 핵심 주제를 추출하였다.

데이터의 타당성과 신뢰성은 다음 세 가지 방법을 통해 확보하였다:

삼각측정(triangulation): 양적 데이터(설문조사)와 질적 데이터(포커스 그룹 인터뷰)를 결합하여 연구 결과의 타당성을 다각도로 검증하는 방법

구성원 검증(member checking): 연구 참가자들에게 분석 결과를 확인받아 연구자의 해석이 참가자들의 실제 경험과 일치하는지 검증하는 과정

상세한 감사 추적(audit trail): 데이터 수집부터 결과 도출까지의 모든 연구 과정을 체계적으로 기록하여 연구의 투명성과 재현가능성을 확보하는 방법

2.2) 실험 II: 비교 사용성 평가 연구 (Comparative Usability Testing)

실험 II 는 LLM 기반 챗봇 '닥터케어 쌤'과 기존 시스템들 간의 비교 평가 연구로 설계되었다. 실험 I 에서 확인된 기존 규칙기반 테라피 앱의 한계점을 해결하기 위해 개발된 닥터케어 쌤을 다양한 비교군과 체계적으로 평가하였다.

비교 대상은 다음과 같이 구성되었다: ①기존 규칙기반 테라피 앱(Woebot, Happify), ②범용 LLM 챗봇(ChatGPT, Google Bard), ③개발된 닥터케어 쌤. 이를 통해 정신건강 특화 LLM 시스템의 우수성과 자연스러운 한국어 대화 능력의 효과를 검증하고자 하였다.

평가 방법으로는 7 개 상담학적 영역(정확성과 유익성, 개인화, 복합적 사고와 감정, 공감성, 적극적 경청과 적절한 질문, 전문성, 긍정성과 지지)과 추가로 혁신성 및 지속사용의향에 대한 체계적 설문조사와 사용자 인터뷰를 병행하였다. 각 참가자는 모든 시스템을 직접 사용한 후 비교 평가를 실시하였으며, 개방형 설문과 사용자 피드백을 통해 질적 데이터를 수집하였다.

분석 전략은 정량적 분석과 질적 분석을 통합하여 진행하였다. 정량적 분석에서는 집단 간 차이 분석(일원분산분석, 사후검정), 상관분석(지속 사용 의향

및 혁신성 인식의 결정 요인), 효과크기 분석을 실시하였다. 질적 데이터 분석은 Braun et al.(2006)의 주제분석(Thematic Analysis) 방법을 귀납적 접근법으로 적용하였다. 연구자 간 주기적 검토와 AI 도구를 활용한 교차 검증을 통해 신뢰성을 확보하였다.

2.3) 실험 III: LLM 기반 챗봇의 상담 품질 비교 평가 연구

실험 III 은 현존하는 주요 LLM 기반 심리 챗봇들의 상담 대화의 깊이와 효과성을 체계적으로 비교 분석하는 연구로 설계되었다. 단순한 기술적 성능 평가를 넘어서, 본 연구에서 개발된 상담학적 평가 기준을 바탕으로 각 챗봇이 생성하는 응답의 상담적 가치를 심층 분석하고자 하였다.

비교 대상은 Wysa, Replika, Youper, 닥터케어챗 등 4 개 챗봇이며, 각각 서로 다른 개발 철학과 기술적 접근을 기반으로 구축되었다. 특히 본 연구에서 개발된 닥터케어챗이 글로벌 수준의 정신건강 챗봇들과 비교했을 때 어느 정도의 상담적 성능을 보이는지를 핵심적으로 검증하고자 하였다.

평가 방법론의 핵심은 실험 II 에서 도출된 7 가지 상담학적 평가 기준(공감성, 정확성과 유익성, 복합적 사고와 감정, 적극적 경청과 적절한 질문, 긍정성과 지지, 전문성, 개인화)에 기반한 전문가 평가이다. 각 영역은 3 점 척도로 측정되었으며, 질적 피드백을 통해 정량적 평가의 한계를 보완하였다.

삼중 검증 체계는 다음과 같이 구성되었다: ①AI 평가자 2 종(Claude 3.5 Sonnet, ChatGPT 4.0)을 통한 객관적이고 일관된 1 차 분석, ②인간 전문가(상담 전문가)를 통한 임상적 타당성 검증, ③자동분석 시스템을 통한 보완적 지표 측정.

이러한 평가 체계의 신뢰성을 확보하기 위해 1 년 간격 재평가를 통한 시간적 안정성도 검증하였다.

이러한 다층적 평가 체계를 통해 기존의 표면적 성능 지표로는 포착하기 어려운 상담적 관계 형성 및 의미적 깊이를 측정하고, 각 챗봇의 고유한 상담적 특성을 규명하고자 하였다.

3) 연구의 타당성 확보 방안

3.1) 실험 I 의 내적 타당성 (Internal Validity)

실험 I 의 내적 타당성 확보를 위해 여러 방안을 적용하였다. 선택 편향은 무작위 배정을 통한 실험군-대조군 구성으로 통제하였으며, 역사적 성숙 효과는 3 개월간 실험 설계(매월 1 차례 중재 측정 + 사후 1 차 측정, 총 3 차 측정)와 대조군 비교를 통해 통제하였다. 측정 도구의 신뢰도는 크론바흐 알파(Cronbach's α) 검사를 통해 내적 일관성을 확인하였다.

3.2) 실험 II & III 의 타당성 확보

실험 II 에서는 측정 일관성을 위해 동일한 7 개 평가 척도를 통한 체계적 측정을 실시하였으며, 대학생 사용자들의 직접적인 사용 경험을 기반으로 한 실제 사용자 평가를 진행하였다.

실험 III 에서는 동일한 시나리오와 평가 기준을 적용하여 측정 표준화를 도모하였으며, AI 평가자, 인간 전문가, 자동분석 시스템을 결합한 삼중 검증 체계를 통해 다면적 검증을 실시하였다. 특히 평가자 간 일치도 분석과 1 년 간격 재평가를 통해 평가 체계의 신뢰성과 안정성을 확보하였다.

3.3) 전체 연구의 외적 타당성 (External Validity)

본 연구의 외적 타당성 확보를 위해 다층적 접근 전략을 수립하였다.

표본 대표성 측면에서 실험 I 은 성균관대학교 내 다양한 학과와 학년을 포함한 층화표집을 실시하여 대학생 집단 내 표본 대표성을 확보하였다. 실험 II 는 실험 I 참여자의 70%를 포함한 연속성 설계를 통해 일관된 사용자 관점에서의 종단적 평가를 실현하였다.

일반화 범위는 한국의 대학생이라는 명확한 모집단 설정을 통해 맥락적 일반화의 적용 범위와 한계를 구체적으로 제시하였다. 이는 연구 결과의 해석에서 과도한 일반화를 방지하고, 유사한 인구학적 특성을 갖는 집단에 대한 적용 가능성을 명시한다.

기술적 일반화 가능성 측면에서는 LLM 기반 대화형 AI 시스템이라는 기술적 범주에 대한 체계적 분석을 통해 기술 플랫폼 간 확장 적용 가능성을 탐구하였다. 특히 실험 III 에서 개발된 상담품질 평가 프레임워크는 언어모델의 종류나 특정 플랫폼에 의존하지 않는 범용적 평가 방법론으로 설계되어, 다양한 정신건강 AI 시스템의 품질 평가에 확장 적용될 수 있는 이론적, 실무적 기반을 제공한다.

문화적 확장성에서는 한국어와 한국 문화권에서 검증된 평가 척도가 다문화 환경에서의 적응적 적용을 위한 방법론적 토대를 마련하였으며, 이는 국제적 디지털 정신건강 서비스 품질 표준화에 기여할 수 있는 잠재력을 지닌다.

4) 윤리적 고려사항

본 연구는 성균관대학교 생명윤리위원회(IRB)의 승인을 받아 수행되었다(승인번호: [SKKU 2023-02-043]) 특히 정신건강이라는 민감한 주제를 다루는 만큼 다음과 같은 윤리적 원칙을 준수하였다:

- ◆ 자율성 존중: 자발적 참여와 철회 권리를 보장하였으며, 충분한 정보 제공 후 동의를 취득하였다. 모든 실험은 비대면으로 진행되어 참가자의 편의성과 안전성을 확보하였다. 참가자들은 월 1 회 온라인 링크를 통해 자가설문지에 응답하였으며, 매일 15 분 이상의 애플리케이션 사용 시 개별 이메일 공지나 실시간 Q&A 채팅을 통해 충분한 지원을 받았다.

- ◆ 선행: 참가자의 정신건강 증진이라는 연구 목적을 명확히 하였다. 포커스 그룹 인터뷰(FGI)는 4-5 명 그룹으로 60 분간 진행되었으며, 참가자들이 자유롭게 경험을 공유할 수 있도록 안전한 환경을 조성하였다. 외로움과 우울 관련 경험, 디지털 중재 앱 사용 경험, 정신건강 지원 시스템에 대한 의견 등을 심층적으로 탐구하였다.

- ◆ 악행 금지: 고위험군 발견 시 즉시 전문 상담 연계 체계를 구축하였으며, 위기 개입 시스템을 운영하였다. 인터뷰 내용은 디지털 녹음기를 사용하여 녹음되었으며, 연구자만 접근 가능한 비밀번호 설정 개인용 컴퓨터에 안전하게 보관되었다가 연구 종료 후 즉시 삭제하였다.

- ◆ 정의: 연구 참여 기회의 공평한 제공과 개인정보 보호를 철저히 하였다. 모든 데이터는 익명화 처리되었으며, 참가자의 개인정보는 가명으로 처리하여 신원을 알 수 없도록 하였다. 참가자에게는 참여 정도에 따라 최대 20 만원의 사례비를 차등 지급하였다(설문지 1 회당 1 만원, 인터뷰 1 회당 2 만원, 실험 참여 수당 최대 3 만원, 연구 종료 시 인센티브 추가 보상). 연구 결과는 분석을 거쳐 익명화된 형태로만 발표되어 참가자의 프라이버시를 완전히 보호하였다.

6. 논문의 구성

1) 논문 구성의 논리적 체계

본 논문은 "문제 인식 → 이론적 탐구 → 실증적 검증 → 통합적 해석 → 실용적 적용"의 논리적 흐름을 따라 7 개 장으로 구성된다. 각 장은 선행 장의 발견을 바탕으로 후속 연구의 방향을 설정하는 누적적 구조를 갖는다.

제 1 장 서론은 연구의 전체적 방향을 제시한다. 국내외 대학생 정신건강 현황 분석을 통해 문제의식을 구체화하고, 선행연구 검토를 통해 연구 공백을 식별한다. 건강신념모델의 이론적 기반 위에서 연구 가설을 설정하고, 3 단계 실험의 전체적 설계를 제시한다.

제 2 장 대학생 정신건강 플랫폼 현황 및 선진 사례 분석에서는 실증 연구의 배경이 되는 현장 상황을 체계적으로 분석한다. Temple University Hope Center Report(2024)를 중심으로 북미 주요 대학들의 디지털 정신건강 플랫폼 도입 현황을 검토하고, 국내 주요 대학의 현황을 분석하여 혁신적 접근의 필요성을 도출한다.

제 3 장 실험 I: 기존 디지털 정신건강 앱 효과성 검증에서는 기존 디지털 정신건강 테라피 앱의 효과성을 건강신념모델 관점에서 검증하고, 그 한계점과 LLM 기반 대화형 챗봇의 필요성을 탐색한다.

제 4 장 실험 II: 한국어 특화 LLM 챗봇 개발 및 비교 평가는 실험 I 에서 확인된 한계점들을 해결하기 위해 한국 대학생에게 특화된 LLM 기반 정신건강 챗봇 '닥터케어썸'을 개발하고, 기존 시스템 및 범용 LLM 과의 비교 평가를 통해 그 효과성을 검증한다.

제 5 장 실험 III: LLM 기반 챗봇의 상담 대화의 품질 평가에서는 본 연구에서 도출된 상담학적 평가 기준과 삼중 검증 체계를 활용하여 개발된 닥터케어썸을

포함한 주요 LLM 기반 심리 챗봇들의 상담 대화의 깊이와 효과성을 체계적으로 비교 분석한다.

제 6 장 정신건강 플랫폼의 개선 방향에서는 세 실험의 결과를 종합하여 AI 기반 정신건강 플랫폼의 발전 방향, 사용자 경험 개선 방안, LLM 기술 고도화 전략, 그리고 정책적 제언을 제시한다.

제 7 장 결론에서는 세 차례의 체계적 실험을 통해 도출된 연구 성과를 종합하고, 본 연구의 학술적 및 실용적 기여를 제시한다. 또한, 연구의 한계점을 명시하고 향후 연구 과제를 제언한다.

2) 각 장의 상호 연관성과 연쇄적 구조

연구의 전반부: 문제 탐구와 현황 분석 (1-2 장)

논문의 전반부에 해당하는 1 장부터 2 장까지는 문제 인식과 현황 분석 단계로 기능한다. 대학생 정신건강 문제의 심각성을 인식하고 LLM 기반 AI 챗봇을 포함한 이론적 배경을 구축한 후, 국내외 대학들의 기존 플랫폼 운영 현황을 체계적으로 분석함으로써 혁신적 접근의 필요성을 논리적으로 도출한다.

연구의 중반부: 단계적 실증 검증 (3-5 장)

3 장에서는 기존 디지털 테라피 앱의 한계를 실증적으로 검증하고 LLM 기반 솔루션의 필요성을 입증한다. 4 장에서는 3 장의 발견을 바탕으로 한국어 특화 LLM 챗봇 '닥터케어썸'을 개발하고 그 우수성을 검증한다. 5 장에서는 실험 II 에서 도출된 상담학적 평가 기준을 활용하여 챗봇의 상담 대화의 품질을 체계적으로 분석하고, 삼중 검증 체계의 타당성을 확보한다.

연구의 후반부: 통합적 해석과 실용적 적용 (6-7 장)

6 장에서는 세 실험의 결과를 종합하여 대학생 정신건강 플랫폼의 구체적 개선 방향을 제시한다. 이는 LLM 기반 시스템의 우수성과 본 연구의 평가 방법론의 가치를 바탕으로 실무 현장에서 직접 활용 가능한 설계 원칙과 가이드라인을 도출하는 과정이다. 7 장에서는 전체 연구의 학술적 기여와 사회적 의의를 정리하고, 정책적 제언 및 향후 연구 방향을 제시한다.

3) 연구의 독창성과 사회적 기여

◆이론적 독창성

이론적 측면에서는 건강신념모델을 디지털 정신건강 중재 효과 분석에 적용하고, 본 연구에서 도출된 상담학적 평가 기준을 LLM 챗봇 평가에 활용하여 상담 대화의 깊이와 효과성이라는 새로운 평가 차원을 제시했다.

◆방법론적 혁신

방법론적 측면에서는 AI 평가자와 인간 전문가를 결합한 삼중 검증 체계를 개발하고, 상담 대화 분석에 적합한 새로운 평가 방법론을 제시했다. 특히 1 년 간격 재평가를 통한 시간적 안정성 검증과 LLM 평가자의 신뢰성 확보 방법론은 향후 AI 평가 연구의 표준을 제시한다.

◆실무적 기여와 사회적 가치

실무적 측면에서는 한국어 지원 정신건강 플랫폼 설계 원칙을 도출하고, 정신건강 특화 프롬프트 엔지니어링의 효과성을 입증했다. 본 연구에서 개발된 닥터케어챗이 글로벌 수준의 챗봇들과 대등한 성능을 보임으로써 정신건강 AI 의 기술적 가능성을 실증했다.

사회적 기여 측면에서는 한국 대학생을 대상으로 기존 디지털 중재 방식 대비 LLM 기반 챗봇의 실질적 효과를 실증하고, 대학 상담 체계에서 AI 챗봇의 보완적 역할 가능성을 제시한다. 특히 본 연구에서 개발된 한국어 정신건강 AI 시스템이 글로벌 수준의 성능을 달성함으로써 K-헬스케어의 국제 경쟁력 강화에 기여할 것으로 기대된다.

제 2 장. 대학생 정신건강 플랫폼 현황 및 선진 사례

분석

디지털 전환이 가속화되면서 대학생 정신건강 관리 체계도 새로운 변화를 맞이하고 있다. 특히 첨단 기술을 활용한 디지털 기반 정신건강 관리와 위기 대응 시스템이 주목받고 있으며, 이는 대학 정신건강 서비스의 새로운 패러다임을 제시하고 있다. 본 장에서는 대학생 정신건강 관리의 디지털 전환 현황을 살펴보고, 선진 사례 분석을 통해 효과적인 발전 방향을 모색하고자 한다.

먼저 대학생 정신건강 관리의 디지털 전환 동향과 특성을 분석하고, 디지털 기술을 활용한 위기 관리 시스템의 현재와 가능성을 탐색한다. 이어서 미국 대학들의 선도적인 정신건강 관리 사례를 심층적으로 분석하고, 국내 대학의 현황과 비교하여 실질적인 시사점을 도출한다. 이를 통해 한국 대학 환경에 적합한 디지털 기반 정신건강 관리 체계의 발전 방향을 제시하고, 후속 실험 연구의 이론적 토대를 마련하고자 한다

1. 대학생 정신건강 관리의 디지털 전환

대학생 정신건강 문제는 전 세계적으로 증가 추세를 보이고 있다. 특히 COVID-19 팬데믹 이후 이러한 경향이 가속화되었다. Center for Collegiate

Mental Health(2023)³의 조사에 따르면, 상담센터를 찾은 학생 중 20.5%가 자살 충동을, 50% 이상이 극도의 불안을, 32%가 심각한 우울 증상을 보고했다.

Lipson et al.(2022)의 연구는 미국 대학 상담센터의 83%가 수요 증가로 인한 대기 시간 증가 문제를 겪고 있으며, 긴급한 개입이 필요한 고위험군 학생들조차 평균 2~3 주의 대기 시간을 감수해야 하는 현실을 지적했다.

이러한 맥락에서 디지털 정신건강 중재는 다음과 같은 혁신적 가치를 제공한다:

① 접근성의 획기적 개선

전통적인 대면 상담과 달리, 디지털 플랫폼은 24 시간 서비스 제공이 가능하다. Rideout et al.(2021)의 연구에 따르면, 대학생들의 73%가 필요할 때 즉시 접근할 수 있는 디지털 서비스를 선호하는 것으로 나타났다.

② 서비스 확장성

전통적인 상담이 1:1 또는 소그룹 단위로 제한되는 것과 달리, 디지털 플랫폼은 동시에 수많은 사용자를 지원할 수 있다. 템플대학교의 Hope Center⁴(2023)의 보고서는 디지털 플랫폼 도입 후 상담 서비스 수용 능력이 평균 5.7 배 증가했음을 보고했다.

③ 데이터 기반 개인화

AI 기술을 활용한 디지털 플랫폼은 사용자의 행동 패턴, 선호도, 반응 등을 분석하여 맞춤형 서비스를 제공할 수 있다. Harrer 등(2021)의 연구는 이러한

³ Center for Collegiate Mental Health (CCMH): 펜실베이니아 주립대학교가 운영하는 미국 대학 상담센터들의 정신건강 데이터 수집·분석 기관

⁴ Hope Center: 템플대학교 소속 연구센터로 대학생의 성공과 웰빙을 위한 장벽 제거를 목적으로 하는 정책연구 및 역량구축 기관

데이터 기반 개인화가 사용자 참여도를 43% 높이고, 중도 이탈률을 38% 낮추는 효과가 있음을 입증했다.

주목할 만한 사례로 7 Cups 의 혁신적 접근을 들 수 있다. 이 플랫폼은 전문가 상담의 한계를 자원봉사 리스너 시스템으로 보완했으며, AI 상담사 'Noni'는 자연어 처리 기술을 활용해 사용자의 감정 상태와 요구를 초기 평가하고 최적의 지원 경로를 제안한다.

템플대학교 Hope Center 보고서(2024)에서 분석된 TAO, Nod, Togetherall 등의 플랫폼들은 [표 1]와 같은 각각의 특성과 장단점을 가지고 있다. 예를 들어, TAO 는 다양한 치료 방법론을 통합적으로 제공하는 강점이 있으나 최신 연구 결과의 반영이 부족하며, Nod는 사용자 친화적 디자인으로 높은 만족도를 보이지만 효과성 검증이 부족하다.

The Hope Center(2023) 의 조사에 따르면, 80 개 대학 60,000 명 이상의 학생 중 64%가 정신건강 문제 발생 시 대면 상담을 선호한 반면, 디지털 정신건강 앱이나 온라인 프로그램 사용을 선호하는 비율은 32%에 그쳤다. 이는 디지털 플랫폼이 대면 서비스의 대체재가 아닌 보완재로서 역할을 해야 함을 시사한다.

표 1. 주요 대학생 정신건강 플랫폼 분석⁵

플랫폼	연구기관	웹사이트	기능	장점	단점
TAO	-	TAO	CBT, ACT, DBT 기반의 자조 비디오, 그룹 훈련, 개인 치료, 대처 기술 코스 제공	다양한 심각성 문제와 수준에 대응	최신 버전에 대한 연구 부족

⁵ 출처: Hope Center for College, Community & Justice (2024), "Digital Mental Health Interventions at Colleges & Universities"를 바탕으로 저자가 재편집

Nod	Grit Digital Health, Hopelab	Nod	고독감 해소를 위한 사회적 연결 촉진	사용자 친화적 디자인, 높은 사용자 만족도	명확한 긍정적 효과 입증 어려움
Togetherall	-	Togetherall	온라인 동료 지원 플랫폼	동료 지원 및 전문가 모니터링	대학생 대상 연구 부족
YOU at College	Grit Digital Health	YOU at College	학업 성공, 웰빙, 소속감 촉진	맞춤형 자원 제공	정신건강 결과에 대한 연구 부족
Headspace	-	Headspace	마음챙김 및 명상	높은 신뢰성 및 사용자 경험	제한된 전문적 상호 작용
Calm	-	Calm	마음챙김 및 명상	사용자 경험에서 높은 평가	제한된 연구 기반
Woebot	스탠퍼드 대학교	Woebot	CBT 기반 정신 건강 지원	임상적으로 입증된 효과	텍스트 기반 상호작용 제한
Tess	MIT	Tess	정서적 지원 및 자원 제공	마음챙김 운동 제공	복잡한 정신 건강 문제 해결에는 부적합
Koko	USC	Koko	문화적으로 유능한 정신 건강 지원	다국어 정보 제공	개발 중인 플랫폼
Stigma-Free Zone	정신 건강 전문가 및 학생 팀	Stigma-Free Zone	정신 건강에 대한 대화 정상화 및 스티그마 감소	익명 토론 촉진	텍스트 기반 상호작용
WellTrack	치료사 및 엔지니어 팀	WellTrack	포괄적인 정신 건강 지원	개인화된 코칭 계획 제공	유료 구독 필요
Sanvello	PacificaLabs	Sanvello	마음챙김, 명상 운동, 정서적 지원	개인화된 콘텐츠 제공	프리미엄 모델
Youper	Your.Per	Youper	개인화된 정신 건강 지원	다양한 기능 제공	제한된 전문적 상호 작용
Bloom	Bloom	Bloom	스트레스, 불안, 우울증 관리	맞춤형 지원 제공	


2. 디지털 기반 위기 관리 시스템

1) 메타(Meta)의 AI 기반 위험 감지 시스템

메타(Meta, 구 페이스북)⁶의 자살 위험 탐지 시스템은 AI 기술을 활용한 선제적 위험 감지의 혁신적 모델을 제시한다. 이 시스템은 단순한 키워드 매칭을 넘어 맥락 인식 기반의 다차원적 분석을 수행한다. 특히 텍스트 분석, 상호작용 패턴, 시간적 맥락을 통합적으로 고려하여 위험 상황을 감지한다.

[그림 1]은 메타의 텍스트와 댓글 분석 시스템의 구조를 보여준다. 시스템은 게시물의 텍스트 내용, 이에 대한 다른 사용자들의 댓글, 그리고 게시 시간 정보를 입력 데이터로 받는다. 이러한 데이터는 세 개의 주요 분석 모듈을 통해 처리된다.

그림 1. 메타의 텍스트와 댓글 분류 작업



출처: Facebook AI Helps Suicide Prevention, 2018,

<https://about.fb.com/news/2018/09/inside-feed-suicide-prevention-and-ai/>

예를 들어, "더 이상 버틸 수 없어. 다들 잘 지내..."라는 게시물이 심야 시간대에 작성되고, "지금 어디야? 연락 좀 해줘"와 같은 긴급성 높은 댓글이 달린 경우,

⁶ Meta: 전 세계 29억 명이 사용하는 소셜미디어 플랫폼 Facebook을 운영하는 기업으로, 2017년부터 AI 기반 자살 예방 시스템을 도입하여 위기 상황 조기 감지에 선도적 역할을 하고 있다.

시스템은 이를 높은 위험도로 판단한다. Kumar et al.(2023)의 연구는 이러한 상호작용 패턴 분석이 위험 감지의 민감도를 63% 향상시켰음을 보고했다.

시간적 맥락 역시 중요한 분석 요소다. Dutta et al.(2021)의 연구에 따르면, 자살 위험이 높은 게시물의 68%가 심야 시간대(오후 11 시~새벽 4 시)에 집중되며, 특히 일요일 심야의 위험도가 가장 높은 것으로 나타났다. 시스템은 이러한 시간적 패턴을 학습하여 해당 시간대의 모니터링을 강화한다.

분석된 위험도에 따라 시스템은 세 단계의 대응을 실행한다. 위험도가 높은 경우 지역 응급 서비스 연결과 위기 상담 전문가 실시간 매칭이 이루어지며, 중간 수준의 위험에는 상담 자원 정보 제공과 지원 네트워크 활성화가, 낮은 수준의 위험에는 지속적 모니터링과 자가 도움 자료 제공이 이루어진다.

2) Wysa 의 체계적 위기 대응 프로토콜

Wysa⁷의 위기 관리 시스템은 사용자 중심의 단계적 개입 전략을 통해 효과적인 위기 대응의 새로운 표준을 제시한다. Haque et al.(2023)가 실시한 10 개 주요 정신건강 챗봇의 포괄적 비교 분석 연구에서 Wysa 는 특별한 위치를 차지한다. 이 연구는 구글 플레이스토어와 애플 앱스토어에서 총 6,245 개의 사용자 리뷰를 분석하여 상용 정신건강 챗봇들의 특성과 효과성을 체계적으로 평가했다.


⁷ Wysa: 인지행동치료(CBT) 기반, 불안과 우울증 관리 특화 - 2017년 출시된 증거 기반 정신 건강 앱으로 CBT, 긍정심리학, ACT 기법을 통합하여 익명성을 보장하며 사용자 주도적 치료 공간을 제공한다. 임상외가 훈련시킨 AI 모델을 활용하여 감정 인식과 개입적 대화를 수행하며, AI 생성 응답 대신 내부 팀이 개발한 치료적 대화를 사용한다. (Touchkin eServices Pvt. Ltd.)

연구 결과, 분석 대상 10 개 챗봇 중 Wysa 만이 위기 상황 지원을 위한 5 가지 옵션을 모두 갖춘 것으로 확인되었다. 이러한 포괄적 위기 대응 체계는 ①위기 지원 시스템 정보 제공, ②응급 헬프라인 연결, ③즉시 자가 돌봄 도구 제안(불안 발작 시 호흡법 등), ④개인 안전 계획 수립, ⑤전문가 상담 연계를 포함한다. 특히 Ada 와 Chai 같은 일부 챗봇들이 위기 지원 기능을 전혀 제공하지 않는 것과 대조적으로, Wysa 의 체계적 접근은 업계 내에서 독보적인 것으로 평가된다.

또한 Wysa 는 대화 방식에서도 차별화된 특성을 보인다. 대부분의 챗봇(10 개 중 6 개)이 사전 설정된 선택지만 제공하는 '안내형 대화(Guided conversation)' 방식을 사용하는 반면, Wysa 는 Nuna, Elomia 와 함께 개방형 대화 스타일(open-ended conversation)을 채택하여 사용자 입력을 이해하고 맥락에 맞는 자연스러운 대화를 지속할 수 있다. 이러한 기술적 우위는 본 연구의 실험 III 에서 다른 LLM 기반 챗봇들(ChatGPT, Google Bard 등)과의 비교 평가를 통해 더욱 상세히 검증될 예정이다.

[그림 2]는 Wysa 의 위기 대응 시스템 구조를 보여준다. 메인 화면의 'SOS' 버튼은 위기 상황에서 즉각적인 도움 요청을 가능하게 한다.

그림 2. Wysa 의 위기 대응 시스템



(출처: Wysa 앱 화면 캡처, 2024)

시스템의 핵심은 3 단계 지원 구조에 있다. 첫째, 'Grounding for panic' 기능은 과학적으로 검증된 불안 완화 기법을 제공한다. 이는 디지털 기술을 활용한 정신건강 중재의 효과성을 입증한 다수의 연구들과 맥을 같이 한다(Firth et al., 2017; Rodrigues et al., 2022). Rodrigues et al.(2022)의 연구는 인터랙티브 디지털 시스템이 사용자의 정신건강 인식과 자기 관리 능력 향상에 효과적임을 보여주었다. 둘째, 'Create Safety Plan' 기능은 사용자의 상황과 선호도를 고려한 맞춤형 위기 대응 계획을 수립한다. 마지막으로, 전문가 매칭 시스템은 사용자의 요구와 특성을 고려하여 적절한 전문가를 연결해준다.

3) 웹 기반 학생 정신건강 지원 프로그램 사례

TalkCampus⁸와 같은 웹 기반 학생 정신건강 지원 프로그램은 동료 중심 지원과 전문가 상담을 결합한 접근법을 활용한다. 이러한 프로그램은 정보 제공,

⁸ TalkCampus: 전 세계 대학생들을 대상으로 24시간 온라인 동료 지원 서비스를 제공하는 플랫폼으로, 익명성을 보장하며 학생들 간의 상호 지원을 촉진한다.

자기 평가를 포함한 자기 도움 자료, 익명 상담 서비스 등을 제공한다. Mojtabai & Olfson(2020)의 JAMA Psychiatry 연구에 따르면, 미국 청소년 중 80% 이상이 정신건강 치료를 받지 못하고 있는 현실에서, 24 시간 접근 가능하고 익명성이 보장되는 디지털 개입은 치료 접근성 격차를 해소하는 중요한 방안이 될 수 있다.

이상에서 검토한 세 가지 사례는 디지털 위기 관리의 서로 다른 접근법을 보여준다. 메타의 대규모 데이터 기반 조기 감지, Wysa의 다층적 개인화 대응, TalkCampus의 동료 중심 지원 모델은 각각 대학 환경에 적용할 수 있는 고유한 장점을 제공한다.

특히 이러한 기술적 접근에서는 개인정보 보호와 윤리적 고려사항이 중요하다. Wysa의 경우 "If you are dealing with abuse, trauma or crisis, Wysa is not enough"라는 메시지를 통해 AI 챗봇의 한계를 명확히 하고 전문가 상담을 권장하는 책임감 있는 접근을 보여준다.

이러한 디지털 위기 관리 시스템들의 혁신적 사례와 교훈을 종합할 때, 대학들은 단순한 플랫폼 도입을 넘어 자체적인 통합 정신건강 관리 체계를 구축해야 한다는 과제에 직면하고 있다. 이러한 맥락에서, 실제로 혁신적인 정신건강 관리 시스템을 구축한 미국 선도 대학들의 구체적 사례를 분석하는 것은 매우 의미 있는 작업이 될 것이다.

3. 미국 대학의 정신건강 관리 선도 사례 분석

미국의 주요 대학들은 증가하는 학생들의 정신건강 문제에 대응하기 위해 혁신적인 접근을 시도하고 있다. 본 연구에서는 이러한 혁신적 사례 중에서도 특히 두 대학을 선정하여 심층 분석하고자 한다.

선정 기준은 다음과 같다. 첫째, 정신건강 관리 분야에서의 혁신성과 선도성이다. 미시간대학교는 통합적이고 다층적인 정신건강 지원 체계를 구축한 대표적 사례로, 전통적 상담 서비스와 디지털 기술, 또래 지원을 효과적으로 결합한 모델을 제시한다. 스탠퍼드 대학교는 디지털 기술을 핵심으로 한 정신건강 연구와 서비스 혁신을 선도하는 기관으로, 의학·공학·심리학 등의 융합을 통한 미래지향적 접근을 보여준다.

둘째, 자료 접근성과 체계성이다. 두 대학 모두 자체 정신건강 관리 시스템에 대한 상세한 정보를 웹사이트 및 보고서를 통해 공개하고 있으며, 학술적 연구와 실무적 운영이 체계적으로 문서화되어 있어 객관적 분석이 가능하다. 셋째, 국내 대학에의 적용 가능성이다. 두 대학의 접근법은 각각 통합적 서비스 모델과 기술 혁신 모델로서, 한국 대학의 정신건강 관리 체계 개선에 실질적 시사점을 제공할 수 있다.

1) 미시간대학교의 통합적 접근

미시간 대학교는 정신건강 지원 분야에서 선도적인 역할을 수행하며, 세계적인 명성을 얻고 있다. 이 학교는 15 개 이상의 단과대학이 참여하는 학제간 협력을 통해 통합적이고 다층적인 정신건강 지원 체계를 구축하고 있다. 특히, CAPS(Counseling and Psychological Services), IPC(Individual Peer Counseling), Uwill 원격 상담 서비스, WSN(Wolverine Support Network)이라는 네 가지 핵심

프로그램을 통해 예방적 접근과 즉각적 지원을 동시에 제공하며, 디지털 기술을 적극적으로 활용해 효율성과 접근성을 극대화하고 있다.

1.1) CAPS (Counseling and Psychological Services)

미시간대학교 학생정신건강혁신위원회 보고서(University of Michigan Student Mental Health Innovative Approaches Review Committee [UM-SMHIARC], 2023)에 따르면, CAPS 는 연간 약 5,000 명의 학생에게 서비스를 제공하며, 학생당 평균 4 회의 세션을 통해 전국 평균 수준의 치료 효과를 보이고 있다. 특히 초기 접근 모델(IAM) 도입을 통해 당일 긴급 서비스와 맞춤형 서비스 연결을 강화하여 접근성과 치료 지속성을 동시에 개선했다. 이 프로그램은 특히 심각한 정신건강 문제를 조기에 발견하고, 대면 및 원격 상담을 통해 즉각적인 개입을 제공하는 데 주력하고 있다.

1.2) IPC (Individual Peer Counseling)

IPC 는 CAPS 전문 스태프의 훈련을 받은 학부 및 대학원생 동료 상담사들이 운영하며, 비슷한 연령, 관심사, 배경을 가진 학생들과 연결하여 편안하고 비판단적인 환경에서 정서적 지지를 제공한다⁹. 학생들은 특히 가까운 지인 외부의 누군가와 대화할 수 있다는 점과 개인적 어려움을 함께 해결해 나갈 수 있다는 점을 긍정적으로 평가하고 있다.

⁹ University of Michigan Counseling and Psychological Services. Individual Peer Counseling. Retrieved from <https://caps.umich.edu/individual-peer-counseling>

1.3) Uwill 원격 상담 서비스

Uwill 은 미시간대학교 학생들을 위한 원격 상담 서비스로, 비디오, 전화, 채팅, 메시지 등 다양한 상담 방식을 지원하며 낮, 밤, 주말에도 이용할 수 있다¹⁰. 학생들은 문제 유형, 성별, 언어, 인종 또는 민족적 배경 등 다양한 요소를 고려하여 선호하는 상담사를 선택할 수 있다.

Uwill 의 주요 장점은 학생들에게 최대 6 회의 무료 상담 세션을 제공하며, 필요시 추가 무료 세션을 쉽게 요청할 수 있다는 점이다. 이 서비스는 특히 단기적이고 구체적인 문제 해결에 적합하며, 캠퍼스 외부에 거주하거나 학기 중 시간 제약이 있는 학생들에게 유용한 옵션으로 평가받고 있다.

다만 자해나 타해 위험, 지속적인 정신건강 문제, 일상생활의 심각한 지장, 장기적 정신건강 지원이 필요한 경우에는 CAPS 와의 협력을 통해 적절한 대안을 제공한다. Lipson et al.(2022)는 문화적 역량을 갖춘 상담이 정신건강 지원의 효과성을 높인다고 강조했으며, Uwill 은 이러한 원칙을 실질적으로 구현한 사례로 평가된다. 또한 Uwill 은 미국 50 개 주와 여러 국가에서 활동하는 전문 상담사를 보유하고 있어, 국제적인 접근성까지 제공한다.

Uwill 은 단기적이고 구체적인 문제 해결에 적합한 서비스로, 심각한 위기 상황이나 장기적인 정신건강 지원이 필요한 경우에는 CAPS(Counseling and Psychological Services)와의 협력을 통해 적절한 대안을 제공한다. 이를 통해 Uwill 은 학생들의 정신건강 관리에 유연성과 접근성을 더하며, 통합적인 정신건강 지원 체계를 보완하고 있다.

¹⁰ University of Michigan Counseling and Psychological Services. Uwill Teletherapy Services. <https://caps.umich.edu/uwill> 에서 인출

1.4) WSN (Wolverine Support Network)

WSN(Wolverine Support Network)은 2015 년 두 명의 동료 학생을 자살로 잃은 것을 계기로 설립된 또래 지지 기반 프로그램으로, 학생들의 정신건강과 정서적 안정을 지원하기 위한 예방적 접근을 제공한다¹¹. WSN의 핵심은 주간 그룹 세션과 커뮤니티 활동을 통해 학생들이 자신의 고민을 나누고 상호 지지를 통해 정서적 안정과 소속감을 얻을 수 있는 환경을 조성하는 것이다.

주간 그룹 세션은 훈련된 또래 리더가 진행하며, 안전하고 신뢰할 수 있는 공간에서 참여자들이 자유롭게 자신의 경험과 감정을 나눌 수 있도록 돕는다. WSN은 학생들의 접근성을 높이기 위해 유연한 일정과 다양한 장소를 제공하며, 학기 내내 등록이 가능해 참여를 독려하고 있다.

또한, WSN은 단순한 그룹 세션을 넘어 다양한 커뮤니티 활동을 통해 스트레스 해소와 관계 형성을 지원한다. 과거 진행된 활동에는 게임 나이트, 명상 세션, 피자 파티, 그리고 치료견과의 교류가 포함되었다. 이러한 활동은 학생들 간의 연결을 강화하고, 일상에서의 부담을 덜어주는 데 기여하고 있다.

WSN의 운영은 미시간 대학교의 CAPS(Counseling and Psychological Services)와 협력하여 이루어지며, 또래 리더들은 정기적인 CAPS 소속 사회복지사와의 훈련 및 자문을 통해 전문성을 확보한다. 이러한 통합적 접근은 초기 문제 발견과 예방적 개입의 효과를 극대화하며, 학생들의 정신건강 관리에 긍정적인 영향을 미친다.

¹¹ Wolverine Support Network. University of Michigan. <https://www.umichwsn.org/> 에서 인출

WSN 은 미시간 대학교 학생 사회 내에서 정신건강 관리의 새로운 표준을 제시하며, 또래 간 지지를 통한 예방적 접근이 얼마나 효과적인지를 보여주는 사례로 자리 잡고 있다.

1.5) 통합적 시스템의 혁신성과 발전 방향

미시간대학교의 CAPS, IPC, Uwill, WSN 으로 구성된 다층적 정신건강 지원 체계는 현대 대학이 직면한 복합적 과제에 대한 체계적 해결책을 제시한다. 전국적으로 정신건강 서비스 수요 급증으로 인한 긴 대기 시간이 문제가 되고 있는 상황에서⁸⁾, 미시간대학교는 이러한 접근성 문제를 다각적으로 해결하고 있다.

◆다층적 접근의 핵심 가치:

첫째, 접근 경로의 다양화를 통해 학생들의 서로 다른 요구와 선호에 대응한다. 즉시 전문 상담이 필요한 학생은 CAPS 로, 부담 없는 또래 지원을 원하는 학생은 IPC 나 WSN 으로, 시간적 제약이 있는 학생은 Uwill 로 연결되는 맞춤형 경로를 제공한다.

둘째, 예방적 접근과 상담적 개입의 통합이다. WSN 과 IPC 는 문제가 심각해지기 전 조기 개입을 담당하고, CAPS 와 Uwill 은 전문적 치료를 제공하여 연속적 케어 체계를 구축한다.

셋째, 디지털 기술의 전략적 활용이다. Uwill 의 원격 상담과 CAPS 의 온라인 예약 시스템은 물리적 제약을 극복하고, 학생들의 다양한 생활 패턴에 맞는 서비스를 가능하게 한다.

◆건강신념모델 관점에서의 평가:

이러한 통합적 접근은 건강신념모델의 핵심 구성요소들을 효과적으로 다룬다. 다양한 접근 경로 제공으로 지각된 장벽(비용, 시간, 낙인)을 낮추고, 개인화된 서비스를 통해 지각된 이익을 높이며, 또래 지원 시스템을 통해 행동 촉진 요인을 강화한다.

미시간대학교 의과대학의 Adam Horwitz 교수가 지적했듯이, "도움을 구하려는 동기가 높은 상황에서 디지털 옵션을 제공하는 것은 매우 가치 있는 일"이며, 이는 미시간대학교의 다층적 시스템이 추구하는 핵심 철학과 일치한다.

이러한 혁신적 접근은 단순히 서비스를 나열하는 것이 아니라, 학생 개인의 상황과 선호에 따라 최적의 지원을 제공하는 통합적 생태계를 구축함으로써 현대 대학 정신건강 관리의 새로운 표준을 제시하고 있다.

표 2. 미시간 대학교의 정신건강 프로그램 분석

구분	교내 CAPS 서비스 (Counseling and Psychological Services)	IPC 서비스 (Individual Peer Counseling) - CAPS 산하	Uwill 서비스	Wolverine Support Network (WSN)
서비스 제공 방식	대면 상담 및 원격 상담 (긴급 및 위기 대응 포함)	피어(동료) 상담 - CAPS 산하 프로그램으로 대면 및 일부 원격 상담(선택적)	원격 상담 (비디오, 전화, 채팅, 메시지)	피어 지원 그룹 세션, 캠퍼스 내에서 대면 진행
상담 세션 수	제한 없음 (필요에 따라 지속적인 상담 제공 가능)	필요에 따라 제한 없는 피어 상담 제공	최대 6 회 무료 제공	정기적인 주간 피어 지원 그룹 세션
운영 시간	주간 운영, 긴급 서비스는 After Hours 통해 제공 (24 시간 위기 대응 가능)	주로 주간 시간 내 이용 가능	주간, 야간, 주말, 공휴일 모두 이용 가능	주로 주간 그룹 세션 (저녁 시간 포함)
대상 문제의 성격	심각하거나 장기적인 정신건강 문제를 가진 학생들	경미한 스트레스, 대인 관계 문제, 조정 문제 등	경미하거나 단기적인 정신건강 문제를 가진 학생들	정신건강 증진 및 예방 목적의 정서적 지원과 커뮤니티 형성
비용	무료 (미시간 대학교 학생)	무료	무료 (미시간 대학교 학생)	무료
제공되는 지원의 범위	심각한 정신건강 문제, 자살 위험, 자해 위험 등 긴급 상황에 대한 포괄적인 상담과 지원 제공	CAPS 산하에서 동료 피어로부터 경미한 문제에 대한 정서적 지원 및 리소스 제공	간단한 정신건강 상담 및 지원	정서적 지원, 커뮤니티 형성, 멘탈 웰빙 증진 목표
기타 특징	교내에 위치한 CAPS 팀과의 직접 대면 및 긴급 상황 대응, 다학제적인 팀 접근을 통해 다양한 치료 옵션 제공	CAPS 전문 직원의 훈련을 받은 피어 상담사와 연결, 비밀 보장 및 지원 제공	국가 및 국제적으로 사용할 수 있는 면허된 정신건강 전문가와 연결	주간 모임을 통해 정기적 피어 지원, 감정 및 정신건강 증진 목표

2) 스탠퍼드 대학교의 디지털 기반 혁신

스탠퍼드 대학교는 디지털 기술을 핵심 매개로 정신건강 분야의 혁신적 연구와 서비스를 선도하고 있다. 이는 의학, 공학, 심리학, 윤리학 등 다양한 분야의 융합을 통해 구현된다. 스탠퍼드의 정신건강 프로그램은 다음과 같은 세 개의 주요 센터를 중심으로 운영된다:

2.1) 스탠퍼드 디지털 헬스 센터 (CDH)

Center for Digital Health(CDH)는 디지털 헬스케어의 혁신을 선도하며, 5 개 중점 분야에서 연구를 수행하고 있다¹². 정신건강 분야에서 CDH 는 글로벌 디지털 전환이 웰빙과 정신건강에 미치는 영향을 이해하고, 디지털 도구가 정신건강 지원을 어떻게 향상시킬 수 있는지 파악하는 것을 목표로 한다. 특히 디지털화가 청소년 웰빙에 미치는 영향 평가에 중점을 두고 있다.

이러한 연구 방향은 전문 분야 간 협력을 통해 의료 기술 연구를 촉진하며(Maddula et al., 2022), 웨어러블 기기를 활용한 건강 모니터링, 모바일 앱 기반 연구, 가상현실을 활용한 중재 등 다양한 디지털 솔루션 개발로 구현되고 있다.

2.2) 스탠퍼드 브레인스툼 랩(Stanford Brainstorm)

스탠퍼드 브레인스툼 랩¹³은 기술 기업 및 리더들과의 적극적 협력을 통한 정신건강 혁신에 전념하는 세계적인 학술 연구소다. 이 랩은 산학 협력을 통해 정신건강 분야의 혁신을 추구하며, 특히 기술과 정신건강의 접점에서 연구를 수행하고 있다. 'The Future of Mental Health' 프로그램(PSYC 246)¹⁴은 브레인스툼 랩의 대표적인 이니셔티브로, 운동, 엔터테인먼트, 저널리즘, 정치, 비즈니스, 윤리, 과학, 기술, 활동, 의학, 교육, 경제 등 다양한 분야의 전문가와

¹² Stanford Center for Digital Health (CDH): 스탠퍼드 대학교 소속 디지털 헬스케어 혁신 연구센터로, 글로벌 디지털 헬스, AI 의료, 노화와 장수, 희귀질환 치료, 정신건강과 웰빙의 5개 중점 분야에서 연구를 수행한다.

¹³ Stanford Brainstorm: 기술 기업, 리더들과의 적극적 협력을 통한 정신건강 혁신에 전념하는 세계적인 학술 연구소이다.

¹⁴ PSYC 246: The Future of Mental Health: 다양한 분야의 전문가들이 참여하여 정신건강 혁신, 협업, 정책 개혁을 탐구하는 브레인스툼 랩의 대표 세미나 프로그램

영향력 있는 인사들이 참여한다. 이 세미나는 정신건강 혁신 환경, 협업의 필요성, 제품 및 프로그램 개발, 정책 개혁을 탐구하며, 스탠퍼드의 모든 학교와 프로그램 학생들이 참여할 수 있다.

2.3) 청소년 정신건강 및 웰빙 센터 (Stanford Center for Youth Mental Health and Wellbeing)

이 센터¹⁵의 대표적 성과는 'allcove'¹⁶ 프로그램이다. 12~25 세 청년들을 대상으로 하는 이 프로그램은 단계적 치료 모델(steped care model)을 도입하여 개인의 상태와 필요에 따라 서비스 강도를 조절한다. Center for Collegiate Mental Health(2023)의 분석에 따르면, 이 접근은 자원의 효율적 분배와 치료 효과 모두에서 긍정적 결과를 보였다.

표 3. 스탠퍼드 대학교의 정신건강 프로그램

	스탠퍼드 디지털 헬스 센터 (CDH)	스탠퍼드 브레인스톰 랩 (Stanford Brainstorm Lab)	스탠퍼드 청소년 정신건강 및 웰빙 센터
목표	디지털 기술을 활용하여 전 세계인의 정신건강 및 전반적인 건강 개선	정신건강 혁신을 위해 학계와 산업 간의 협력을 강화하고, 임상적으로 유용한 도구와 제품을 설계	청소년과 젊은 성인을 대상으로 정신건강과 웰빙을 증진하는 혁신적 모델을 개발하고 국가적 비전을 제시

¹⁵ Stanford Center for Youth Mental Health and Wellbeing (CYMHW): 청소년과 젊은 성인을 위한 혁신적 건강 시스템과 새로운 건강 문화를 창조하여 전국적 모델을 제시하는 것을 목표로 한다.

¹⁶ allcove: 12-25세 청소년을 대상으로 한 미국 최초의 통합 청소년 정신건강 센터 네트워크로, 청소년과 함께, 청소년에 의해, 청소년을 위해 설계되었다.

주요 활동 및 이니셔티브	글로벌 헬스 연구, 정신건강 관리와 치료를 위한 디지털 솔루션 개발, AI 및 기술을 통한 정신건강 지원 도구 연구 및 개발, 노화와 장수 지원, 희귀 질환 치료 등 다양한 건강 문제 해결을 위한 연구를 수행한다.	정신건강 제품의 효과성을 연구하고 개발하며, 기술 기업, 비영리 단체와 협력하여 AI 와 소셜 미디어 안전성 연구 및 플랫폼 설계의 모범 사례를 구축한다.	초기 정신건강 지원 및 우수한 임상 진료 제공, 교육 및 커뮤니티 파트너십 구축, 기술을 활용한 정신건강 프로그램 개발 및 실행, 청소년의 정신건강에 미치는 미디어의 영향을 연구하고 개선하는 프로그램을 운영한다.
콘텐츠 예시	2024 Digital Summit, 연간보고서	PSYC 246: THE FUTURE OF MENTAL HEALTH:다양한 분야(스포츠, 엔터테인먼트, 저널리즘, 정치, 비즈니스, 윤리, 과학, 기술, 활동, 의학, 교육, 경제 등)의 전문가와 인사들이 참여하여 정신건강 혁신의 필요성, 협업의 중요성, 프로그램 및 제품 개발, 정책 개혁을 탐구. 스탠퍼드 모든 학생들이 등록가능.	allcove 프로그램: 12 세에서 25 세 사이의 청소년들이 정신건강 문제에 대한 초기 지원과 지도를 받을 수 있도록 돕는 것이 목표.
웹사이트	Stanford Center for Digital Health	Stanford Brainstorm Lab	Stanford Center for Youth Mental Health and Wellbeing

스탠퍼드 대학교의 정신건강 혁신 접근법은 세 개 센터의 상호 보완적 역할을 통해 완성된다. CDH 의 디지털 기술 연구, 브레인스톡 랩의 산학 협력, 그리고 청소년 정신건강 센터의 실제 서비스 제공이 하나의 통합적 생태계를 형성한다.

건강신념모델 관점에서 볼 때, 스탠퍼드의 접근법은 혁신적 특징을 보인다. 첫째, 디지털 기술을 통한 지각된 장벽 감소다. CDH 의 연구는 시간적·공간적

제약을 극복하고, allcove 의 12-25 세 대상 서비스는 연령별 맞춤 접근을 제공한다. 둘째, 산학 협력을 통한 지각된 이익 증대다. 브레인스톡 랩의 기술 기업 협력은 최신 기술을 활용한 실용적 솔루션 개발을 가능하게 한다. 셋째, 다학제적 접근을 통한 행동 촉진 요인 강화다. PSYC 246 과 같은 교육 프로그램은 정신건강에 대한 인식 개선과 사회적 지지 기반을 확대한다.

이러한 연구 중심의 혁신적 접근은 미시간대학교의 서비스 중심 통합 모델과 대조적이면서도 상호 보완적인 특성을 보여준다. 두 대학의 사례는 각각 '실용적 통합'과 '혁신적 연구'라는 서로 다른 전략을 통해 현대 대학 정신건강 관리의 발전 방향을 제시하고 있다.

4. 국내 대학의 정신건강 관리 현황 및 시사점

미국의 주요 대학들이 보여주는 혁신적인 디지털 정신건강 전략과 통합적 접근은 글로벌 고등교육 환경에서 중요한 벤치마크가 되고 있다. 특히 미시간 대학교의 다층적 통합 서비스 모델과 스탠퍼드 대학교의 연구 중심 혁신 모델은 대학 내 정신건강 문제를 다루는 데 있어 효과적이고 포괄적인 접근법을 제시하고 있다. 이들 대학은 다양한 프로그램과 디지털 플랫폼을 통해 학생들의 개별적 요구에 맞춤형 지원을 제공함으로써, 정신건강 관리의 접근성과 효과성을 향상시키고 있다.

이러한 맥락에서, 한국 대학들의 정신건강 지원 현황을 살펴보고 미국 대학들의 선진 사례와 비교 분석하는 것은 중요한 의미를 갖는다. 본 연구에서는 다음 기준에 따라 국내 대학을 분석 대상으로 선정하였다.

◆선정 기준:

첫째, 정보 접근성과 투명성이다. 대학알리미¹⁷ 공시정보와 각 대학 공식 웹사이트에서 정신건강 서비스 정보가 체계적으로 공개되어 객관적 분석이 가능한 기관들을 우선 고려했다.

둘째, 대학 유형과 규모의 다양성이다. 종합대학(서울대학교, 연세대학교, 성균관대학교)과 과학기술특성화대학(KAIST, UNIST)을 포함하여 서로 다른 특성과 학생 규모를 가진 대학들의 접근법을 비교 분석하고자 했다.

셋째, 혁신성과 대표성이다. 국내 대학 정신건강 관리 분야에서 혁신적 시도로 평가받거나 모범 사례로 언급되는 기관들을 포함하여 벤치마킹 가치를 확보했다. 특히 UNIST의 경우 학생 규모는 상대적으로 작지만 정신건강 관리의 선도사례로 평가받아 분석 대상에 포함했다.

◆분석 방법:

각 대학의 정신건강 지원 시스템을 2024년 12월 기준 공식 웹사이트 정보를 바탕으로 분석하였다. 서비스 구조, 프로그램 특성, 디지털 기술 활용도, 접근성 등을 중심으로 현황을 파악하고, 건강신념모델 관점에서 각 접근법의 강점과 한계를 평가하여 향후 발전 방향을 모색하고자 한다.

1) 주요 대학의 정신건강 지원 현황

1.1) 서울대학교

¹⁷ 대학알리미: 교육부가 운영하는 대학 정보 공시 웹사이트로, 국민들이 보다 쉽고 편리하게 대학정보를 이용할 수 있도록 대학의 기본 정보를 제공한다.

서울대학교는 정신건강 지원 체계를 대학생활문화원¹⁸과 정신건강센터¹⁹라는 두 축으로 이원화하여 운영하고 있다. 이러한 구조는 학생들의 다양한 요구를 보다 효과적으로 충족시키고 접근성을 높이기 위해 설계된 것으로 보인다. 대학생활문화원은 심리상담, 위기상담, 역량 개발, 조사 연구 등 여러 영역을 포괄하는 통합적 접근을 시도하고 있으며, 학생들에게 심리적 지지와 실질적인 해결책을 제공한다. 예를 들어, T-Talk²⁰ 프로그램을 통해 학업, 진로, 대인관계 등 학생들의 주요 관심사에 대한 주제별 상담을 제공하고 있으며, 스친(스누 친구)²¹ 프로그램을 통해 또래 지지 체계 기반의 대학 생활 적응 지원을 제공한다. 또한, 위기상담 체계를 통해 자살, 우울 등 긴급 사례에 대해 전문 상담을 즉각적으로 제공한다.

정신건강센터는 보다 전문적인 임상 서비스를 담당하며, 디지털 플랫폼을 활용하여 접근성을 높이고 있다. 이 센터는 다양한 정신건강 영역을 포괄하는 종합검진 시스템을 운영하며, 학생들이 개별적으로 진단과 종합적인 진단을 선택할 수 있도록 유연성을 제공한다. 온라인 예약 시스템은 상담 접근성을 향상시키고 있으며, 프로그램 신청 및 자원봉사 등록 또한 디지털화되어 있다. 특히, 종합검진 시스템은 정신건강 문제를 조기에 발견하고 예방적 개입을 가능하게 하며, 이를 통해 보다 체계적 관리를 제공하고 있다.

¹⁸ 대학생활문화원: 서울대학교 소속 학생상담기관으로 1962년 국내 최초의 대학상담소인 학생지도연구소로 출발하여 현재까지 학생들의 심리상담, 역량개발, 위기상담 서비스를 제공하고 있다.

¹⁹ 정신건강센터: 서울대학교 학생과 교직원의 정신건강을 위해 정신건강의학과 진료, 다양한 치료 프로그램, 예방 활동 등을 제공하는 전문 의료기관이다.

²⁰ T-Talk: 학업, 진로, 대인관계 등 학생들의 주요 관심사에 대한 주제별 심리상담 프로그램

²¹ 스친(스누 친구): 또래 지지 체계를 통한 대학 생활 적응 지원 프로그램

그러나 이러한 이중적인 시스템에도 불구하고 서울대학교의 접근 방식은 여전히 대면 상담 중심으로 설계되어 있어 디지털 접근성과 모바일 기반 실시간 지원 측면에서는 미흡해 보인다. Eisenberg et al.(2019)이 제시한 디지털 접근성 기준과 비교했을 때, 기존의 오프라인 중심 접근이 현대 대학생들의 디지털 요구를 충분히 반영하지 못하고 있다는 점이 개선이 필요하다. 따라서 이원화된 시스템의 강점을 살리면서도 디지털 전환을 통해 접근성과 효율성을 더욱 높이는 전략이 요구된다.

1.2) 연세대학교

연세대학교 심리상담센터²²는 캠퍼스별 특성화된 접근을 시도하고 있다. 신촌 캠퍼스에서는 주 1 회 50 분의 개인 심리상담을 기본으로 하여 심리검사 및 해석 상담, 집단상담 프로그램, 정신건강 워크숍 등을 제공한다. 국제 캠퍼스의 경우 유학생 맞춤형 상담 서비스와 문화 적응 지원 프로그램, 다국어 심리검사 지원 등 국제화된 환경에 맞는 서비스를 운영하고 있다.

특히 YSQ(Yonsei Screening Questionnaire)²³를 기반으로 한 체계적인 5 단계 상담 프로세스를 구축했다는 점이 주목할 만하다. 이 프로세스는 ①온라인 신청 → ②센터방문/YSQ 실시 → ③상담 또는 병원 진료 연계 → ④상담 시간 예약 → ⑤개인상담으로 이어지는 체계적인 흐름을 갖추고 있다. YSQ 는 다양한 영역의

²² 연세대학교 심리상담센터: 기독교 정신에 입각하여 연세대학교 학생들의 심리적 어려움, 적응 및 진로 선택 문제 해결을 돕는 전문 상담기관으로, 캠퍼스별 맞춤형 서비스를 제공한다.

²³ YSQ(Yonsei Screening Questionnaire): 다양한 영역의 심리적 어려움을 알아보기 위해 연세대학교에서 구성한 설문지로, 개인상담 신청 시 필수적으로 실시되는 심리진단 도구이다.

심리적 어려움을 진단하기 위해 개발된 설문지로, 학생들의 정신건강 상태를 종합적으로 평가하는 도구로 활용되고 있다.

최근 통합상담시스템²⁴을 구축하여 심리검사 및 상담의 온라인 신청이 가능해지고, YSQ를 태블릿 PC 기반으로 실시할 수 있도록 발전시켰다. 그러나 Lattie et al.(2019)의 지적대로, 현대 대학생들의 디지털 플랫폼 선호도를 고려할 때 여전히 온라인 상담 시스템은 예약과 검사 실시에 국한된 보조적 수준에 머물러 있는 것으로 평가된다.

1.3) KAIST

KAIST는 전문 의료 인력 중심의 통합 지원 체계를 구축하고 있다. 카이스트 클리닉 내 스트레스 클리닉²⁵에서는 정신건강의학과 전문의, 임상심리전문가, 정신건강간호사로 구성된 전문 의료팀이 학업 및 대인관계의 어려움, 수면장애, 우울, 불안 등 여러 정신과적 질환에 대한 진료를 제공한다.

특히 미국 코넬 대학교의 'Let's Talk' 프로그램을 모델로 한 'Stop by & Chat (SBC)' 프로그램²⁶은 개주얼한 형태의 1:1 상담서비스로 운영되고 있다. 이 프로그램은 지난 10년간 MIT를 비롯한 미국 내 약 60개 대학에 도입된 검증된 모델을 기반으로 하며, 코넬대학교 Gannett Health Services 관계자들의 협력을

²⁴ 통합상담시스템: 심리검사 및 상담의 온라인 신청과 YSQ의 태블릿 PC 기반 실시를 가능하게 하는 디지털 상담 관리 시스템

²⁵ 스트레스 클리닉: 카이스트 클리닉 내 정신건강의학과로, 학업·대인관계 문제, 수면장애, 우울, 불안 등에 대한 전문 진료를 제공하며 비밀보장을 원칙으로 한다.

²⁶ Stop by & Chat (SBC): 미국 코넬대학교의 Let's Talk 프로그램을 모델로 한 개주얼한 형태의 1:1 상담서비스로, 미국 내 60개 대학에서 검증된 모델이다.

통해 KAIST 에 도입되었다. 또한 우울, 불안, 사회불안, 발표불안, 고독감, 분노, 진로정체감, 인터넷중독 등 다양한 영역의 온라인 자가진단 도구를 제공하며, '카이쿨'이라는 전화상담 서비스를 운영하고 있다. 이 서비스는 상담센터 운영 시간 외에도 지속적인 심리적 지원을 가능하게 하며, 시간과 공간 제약을 줄이는 데 기여하고 있다. 그러나 디지털 네이티브 세대인 MZ 세대의 특성을 충분히 반영하지 못하는 한계가 있다. 진보래(2024)의 연구에 따르면, MZ 세대는 전화 통화보다 문자와 같은 채팅 기반 소통 방식을 선호하며, 전화 상담에 대한 불안감을 나타내는 경향이 높다. 이러한 점은 '카이쿨' 서비스가 일부 학생들에게 친숙하지 않을 가능성을 시사한다.

1.4) UNIST

UNIST 헬스케어센터²⁷는 보건실, 상담실, 부속의원을 통합한 원스톱 서비스 모델을 구축하여 주목받고 있다. 이러한 혁신적 접근이 인정받아 전국대학교학생상담센터협의회²⁸가 주관한 2020 년 우수 상담기관 평가에서 상담운영 부문 우수기관으로 선정되었다. 이는 전국 230 여 개 대학교 학생상담센터를 대상으로 한 평가에서 상담운영, 상담전문, 상담활동, 우수상담사 등 4 개 분야 중 상담운영 부문에서 우수성을 인정받은 것이다.

²⁷ UNIST 헬스케어센터: 울산과학기술원의 보건실, 상담실, 부속의원을 통합한 원스톱 정신 건강 지원 기관으로, 2020년 전국대학교학생상담센터협의회 상담운영 부문 우수 상담기관으로 선정되었다.

²⁸ 전국대학교학생상담센터협의회(전상협): 1977년 창립된 전국 250여 대학 학생상담센터의 협력조직으로, 학생들의 대학생활 적응과 정신건강 증진을 위한 프로그램 개발·보급과 상담 기관 평가를 수행한다.

헬스케어센터의 강점은 세 가지 측면에서 확인된다. 첫째, 정신건강의학과 전문의, 임상심리전문가, 전문상담사들의 협업을 통한 맞춤형 통합 서비스 체계를 구축했다. 둘째, 미술치료, 시간관리, 심리극, 동물매개치료, 문학치료, 발표불안 등 다양한 주제의 집단 프로그램을 운영하여 예방적 접근을 강화하고 있다. 셋째, 온라인 플랫폼을 통해 우울, 불안, 스트레스, 자살, 음주, 게임, 도박 등 7 개 영역의 체계적인 자가진단 도구를 제공하여 디지털 접근성을 높이고 있다.

특히 이상일 등(2022)의 연구에 따르면 UNIST 대학상담센터의 데이터 기반 접근을 보여준다. 이 연구는 상담센터 이용자들을 '건강관심형', '관계문제형', '우울-수면문제 복합형', '복합문제형', '수면문제형'의 5 가지 유형으로 분류하고, 특히 자살/자해시도 경험이 있는 이용자들의 특성을 체계적으로 분석하여 맞춤형 지원의 가능성을 제시했다.

건강신념모델 관점에서 볼 때, UNIST 의 통합 서비스 모델은 지각된 장벽을 효과적으로 낮추고 있다. 원스톱 서비스를 통한 접근 편의성과 다양한 집단 프로그램을 통한 예방적 접근은 학생들의 정신건강 서비스 이용에 대한 심리적·물리적 장벽을 감소시킨다. 다만, 모바일 앱을 통한 실시간 접근성 확보와 자가진단 결과의 상담 서비스 연계 등 디지털 솔루션의 고도화 측면에서는 추가적 발전이 필요하다

1.5) 성균관대학교

성균관대학교의 카운슬링센터²⁹는 1964년 학생신상상담실로 출발하여 50여년간 학생들의 마음건강을 지원해온 역사를 가지고 있다. 현재 인문사회과학캠퍼스와 자연과학캠퍼스 각각에 센터가 설치되어 있으며, 재학생들은 양 캠퍼스에서 자유롭게 이용할 수 있다.

카운슬링센터는 전임연구원을 포함한 다수의 상담자를 통해 개인상담, 집단상담, 심리검사, 워크숍 등의 서비스를 제공하고 있다. 특히 학부생, 대학원생, 외국인 유학생 등 다양한 학생 집단의 특성을 고려한 맞춤형 서비스를 제공하고자 하며, 대학원생을 위한 학업 스트레스 관리 프로그램과 외국인 유학생을 위한 문화 적응 지원 등 대상별 특화 프로그램을 운영하고 있다. 특히 'Foreign Counseling' 서비스를 통해 중국어와 영어로 된 별도 상담 안내를 제공하여 국제학생들의 접근성을 높이고 있다.

디지털화 측면에서는 온라인 상담 신청 시스템을 구축하였으나, 이는 주로 예약 기능에 국한되어 있어 실질적인 디지털 플랫폼으로서의 기능은 제한적이다. 자체 개발 진단도구보다는 외부 기관 링크를 활용하는 방식으로 운영되고 있어, 학생들의 즉각적인 자가진단과 상담 서비스 간의 연계에서 개선의 여지가 있다.

성균관대학교의 카운슬링센터는 캠퍼스별 접근성과 다국어 지원을 통해 다양한 학생들의 요구에 대응하고 있으나, 디지털 접근성 측면에서는 추가적 개선이 필요한 상황이다.

²⁹ 성균관대학교 카운슬링센터: 1964년 학생신상상담실로 출발하여 50여년간 학생들의 마음건강을 지원해온 전문 상담기관으로, 인문사회과학캠퍼스와 자연과학캠퍼스에 각각 설치되어 있다.

2) 소결

국내 5 개 대학의 정신건강 지원 현황 분석을 통해 각 대학이 추구하는 차별화된 접근법과 공통적 과제를 확인할 수 있었다. 서울대학교의 이원화 체계(대학생활문화원-정신건강센터), 연세대학교의 캠퍼스별 특성화와 YSQ 기반 체계화, KAIST 의 전문의료인력 중심 체계와 해외 모델 도입, UNIST 의 원스톱 통합서비스 모델, 성균관대학교의 다국어 지원 등은 각각 주목할 만한 혁신적 시도로 평가된다.

그러나 전반적으로 국내 대학들의 정신건강 지원 체계는 여전히 전통적인 대면 상담 중심으로 운영되고 있으며, 디지털 기술의 활용은 주로 예약 시스템이나 자가진단 도구 제공 수준에 머물러 있다. 특히 실시간 모니터링, AI 기반 맞춤형 지원, 통합적 데이터 관리 등 고도화된 디지털 솔루션의 도입은 초기 단계에 있는 것으로 파악된다.

본 분석은 박사논문의 범위적 제약으로 인해 5 개 대학으로 한정되었으며, 고려대학교, 서강대학교 등 기타 주요 대학들을 포함한 포괄적 분석은 향후 연구과제로 남겨두었다. 그럼에도 불구하고 분석 대상 대학들의 다양한 특성(종합대학과 과학기술특성화대학, 국립과 사립 등)을 고려할 때, 본 분석 결과는 국내 대학 정신건강 지원 체계의 전반적 현황과 한계를 파악하는 데 충분한 대표성을 갖는 것으로 판단된다.

5. 통합 시사점 도출

1) 글로벌 플랫폼의 혁신적 접근과 한계

Haque et al.(2023)의 JMIR 연구에서 10 개 주요 정신건강 챗봇을 분석한 결과, 위기 상황 지원을 위한 5 가지 옵션(위기 관련 정보 제공, 자가관리 도구 접근, 전문 치료사 접근, 채팅을 통한 위기 감지, 지정된 인력에 알림)을 모두 갖춘 플랫폼은 Wysa 하나뿐이었으나, 여전히 적절한 위기 식별과 맥락적 이해에는 한계를 보인다고 보고되었다.

메타의 AI 기반 자살 위험 탐지 시스템은 대규모 데이터 분석의 가능성을 보여주지만, 오탐지와 개인정보 보호 우려 등의 문제가 제기되고 있다. 특히 사용자의 게시물 내용을 실시간으로 모니터링하는 과정에서 발생할 수 있는 프라이버시 침해와 알고리즘의 문화적 편향성은 중요한 윤리적 과제로 남아있다.

Woebot 과 같은 CBT 기반 챗봇들도 구조화된 치료 프로토콜을 제공하지만, 사용자 리뷰 분석에서는 획일적 접근의 한계와 개인차에 대한 적응 부족이 지적되고 있다. 국내 대학들의 디지털 활용은 주로 온라인 예약이나 기초적 자가진단 수준에 머물러 있어 글로벌 동향과의 격차가 확인된다.

2) 위기 관리 패러다임의 전환

선제적 감지에서 체계적 대응까지

Chang et al.(2024)의 연구에서는 Wysa AI 앱이 의료진 사이에서 높은 참여율(80.1%)을 보였으며, Wysa 의 글로벌 연구에서는 위기 상황의 82%가 AI 에 의해 자동 감지되는 등 체계적 접근의 효과성이 입증되고 있다. 그러나 이러한 수치는 통제된 환경에서의 결과이며, 실제 다양한 사용자 집단과 문화적 맥락에서의 효과성은 추가 검증이 필요한 상황이다.

기존의 사후 처리 중심에서 사전 예방적 탐지로의 패러다임 전환은 분명 혁신적이지만, AI 의 위기 감지 정확도와 문화적 언어 표현의 차이에 따른 오판 가능성은 여전히 중요한 기술적 과제로 남아있다. 정신건강 서비스 접근성 연구에서 확인된 구조적 제약들(시간적 한계, 경제적 부담, 접근성 부족)에 대응하여 24 시간 접근성이 핵심 해결책으로 부상하고 있으나, 과도한 의존성과 인간 관계 대체 우려도 함께 제기되고 있다.

국내 대학들은 주로 근무시간 내 대면 상담 중심으로 운영되어 구조적 한계를 보이지만, 동시에 전문 상담사의 직접적 개입과 깊이 있는 치료가 가능하다는 장점도 갖고 있어 디지털 기술과의 적절한 균형점 모색이 필요하다.

3) 통합적 서비스 모델의 차별화

미시간대학교의 다층적 통합 모델

CAPS, IPC, Uwill, WSN 으로 구성된 미시간대학교의 서비스 생태계는 전문 상담, 또래 지원, 원격 서비스, 예방적 커뮤니티를 유기적으로 연결하여 학생들의 다양한 요구와 선호에 대응하고 있다. University of Michigan(2023) 자료에 따르면 연간 5,000 명의 학생에게 서비스를 제공하며 학생당 평균 4 회의 세션을 통해 체계적 관리를 실현하고 있다. 그러나 이러한 통합 모델의 운영에는 상당한 인적·재정적 자원이 필요하며, 서비스 간 연계 과정에서 발생할 수 있는 정보 공유와 개인정보 보호의 균형 문제도 고려해야 한다.

스탠퍼드대학교의 연구-서비스 통합 모델

CDH 의 디지털 헬스 연구, 브레인스툼 랩의 산학 협력, 청소년 정신건강 센터의 실제 서비스가 하나의 통합적 생태계를 형성하여 연구-혁신-서비스의 선순환

구조를 구축하고 있다. 특히 PSYC 246 과 같은 다학제적 교육 프로그램을 통해 정신건강 혁신의 저변을 확대하고 있으나, 이러한 모델은 연구중심대학의 특수한 환경과 자원에 의존하는 측면이 있어 일반적인 대학으로의 확산에는 제약이 따를 수 있다.

국내 대학의 개별적 접근과 발전 가능성

국내 대학들은 각각 고유한 강점을 보이고 있다. UNIST 의 원스톱 서비스 모델과 우수기관 인증, KAIST 의 전문의료인력 체계와 해외 모델 도입, 서울대의 이원화 전략, 연세대의 YSQ 기반 체계화, 성균관대의 다국어 지원 등은 주목할 만한 혁신 시도이다. 그러나 서비스 간 연계성이나 통합성 측면에서는 추가적 발전이 필요하며, 각 대학의 규모와 특성에 맞는 차별화된 접근 전략 수립이 요구된다.

문화적 적합성과 건강신념모델 통합 관점

Hope Center(2024)에서 대학생의 44%가 임상적으로 유의한 불안 및 우울 증상을 경험하고 있으나, 기존 플랫폼들이 서구 문화권 기반으로 개발되어 한국 대학생들에게는 문화적 부적합성이 장벽으로 작용할 수 있다. 정신건강 서비스 접근 장벽 연구에서 확인된 주요 제약들 - 시간적 한계, 경제적 부담, 사회적 편견 등을 해결하기 위해서는 24 시간 접근성, 원격 서비스, 익명성 보장, 다국어 지원 등이 필수적이며, 단순한 상담을 넘어 예방적 접근, 또래 지원, 개인화된 서비스 등 다차원적 이익을 제공하는 통합적 접근이 필요하다.

4) 향후 발전 방향 및 연구 한계

국내 대학을 위한 통합적 발전 전략

글로벌 플랫폼의 혁신적 기술을 한국 문화에 맞게 적응시키는 문화적 현지화와 개별 대학의 강점을 살리면서도 서비스 간 연계성을 강화하는 통합적 모델 구축, 그리고 사후 대응 중심에서 선제적 감지와 예방 중심으로의 패러다임 전환이 필요하다. 단순한 디지털화를 넘어 AI 기반 개인화, 실시간 모니터링, 데이터 기반 개입 등 고도화된 디지털 솔루션 도입을 통해 서비스의 질적 향상을 도모해야 한다.

연구의 한계 및 향후 과제

본 연구는 박사논문의 범위 제약으로 미국 2 개교, 국내 5 개교로 분석 대상을 제한하였다. 향후 고려대학교, 서강대학교 등을 포함한 확장 분석과 아시아 다른 국가들의 비교 연구, 문화적 적응성을 고려한 AI 챗봇 설계 방법론 개발이 필요하다.

이러한 종합적 시사점들은 본 연구의 후속 실험에서 실증적으로 검증되며, 특히 한국 대학생의 특성 및 니즈를 반영한 LLM 기반 정신건강 챗봇의 설계와 평가에 중요한 이론적 토대를 제공한다.

제 3 장 실험 I: 디지털 정신건강 테라피 앱 임상중재 실험

1. 연구 개요

1.1) 연구 배경 및 목적

COVID-19 팬데믹은 전 세계 대학생들의 외로움과 우울증 유병률을 급격히 증가시켰다(Aristovnik et al., 2020; Son et al., 2020). 한국에서는 20~30 대의 우울증 위험군 비율이 2018 년 9.1%에서 2021 년 22.8%로 6 배 증가했으며, 이는 다른 연령대(30 대 17.9%, 40 대 14.3%, 50 대 11.8%)에 비해 가장 높은 수치를 보인다(보건복지부, 2021). 미국에서도 대학생 195 명을 대상으로 한 연구에서 71%가 COVID-19 로 인한 스트레스와 불안 증가를 보고했으며, 44%가 우울 증상 악화를 경험했다(Son et al., 2020). 독일에서도 대학생들의 우울 및 불안 점수가 팬데믹 이전 대비 2 배 이상 증가하는 등(Kohls et al., 2021) 전 세계적으로 대학생 정신건강 위기가 심화되고 있다. 이러한 현상은 팬데믹에만 기인하는 것이 아니라, 지난 10 년간 지속적으로 악화되어온 대학생 정신건강 문제의 연장선상에 있다(Lipson et al., 2019).

제 2 장에서 분석한 바와 같이, Wysa, Woebot³⁰ 등 글로벌 디지털 정신건강 플랫폼들은 각각 차별화된 접근법을 통해 정신건강 지원의 새로운 가능성을 제시하고 있으나, 효과성과 사용성이 검증된 한국어 디지털 테라피 챗봇 앱은 여전히 부족한 실정이다. 특히 한국 대학생들의 집단주의 문화와 높은 사회적

³⁰ Woebot Health Inc.에서 개발한 인지행동치료(CBT) 기반 정신건강 챗봇 애플리케이션

기대라는 문화적 특성을 고려할 때, 서구 문화권 기반으로 개발된 기존 플랫폼들의 문화적 적합성에 대한 실증적 검증이 필요하다.

본 연구는 대학생들의 정신건강 증진을 위한 디지털 중재 방안을 실증적으로 검증하기 위한 첫 번째 실험으로, 기존 디지털 정신건강 앱들의 임상적 효과성을 체계적으로 평가하고, 실제 사용자 경험을 통해 구체적인 개선점을 도출하는 것을 목적으로 한다. 특히 외로움과 우울 증상을 보유한 한국 대학생들을 대상으로 현존하는 주요 디지털 테라피 앱들(Woebot, Happify³¹)의 실제 효과를 검증하고, 이들의 장단점을 비교 분석하여 후속 연구에서 개발될 LLM 기반 챗봇의 설계 방향에 대한 실무적 시사점을 도출하고자 한다.

1.2) 이론적 프레임워크: 건강신념모델(Health Belief Model)

본 연구의 이론적 토대는 Rosenstock(1974)이 개발하고 Becker(1974)가 정교화한 건강신념모델(Health Belief Model, HBM)에 기반한다. HBM은 개인의 건강 행동을 예측하고 설명하기 위해 개발된 사회심리학적 모델로, 정신건강 영역에서도 광범위하게 적용되어 왔다(Champion & Skinner, 2008).

HBM은 지각된 민감성과 심각성(건강 문제에 대한 개인의 취약성과 심각성 인식), 지각된 이익과 장애물(행동 수행의 긍정적 결과와 방해 요인에 대한 인식), 행동 단서(행동을 촉발하는 내외적 자극), 자기 효능감(행동 수행에 대한 자신감) 등 6개 핵심 구성요소로 이루어져 있다.

³¹ Twill Inc.에서 개발한 CBT와 마음챙김 기반의 정신건강 증진 애플리케이션

정신건강 영역에서 HBM은 치료 추구 행동, 치료 지속성, 자가 관리 행동 등을 설명하는 데 효과적임이 입증되었다. Clement et al.(2015)의 메타분석에 따르면, HBM 구성요소들은 정신건강 서비스 이용 의도와 실제 이용 행동을 유의미하게 예측한다. 특히 지각된 이익과 자기 효능감은 디지털 정신건강 중재의 수용성과 지속성에 중요한 영향을 미치는 것으로 보고되었다(Baumel et al., 2017).

한국 문화적 맥락에서, 정신건강에 대한 사회적 낙인과 집단주의적 성향은 HBM의 '지각된 장애물' 요소로 작용할 수 있다. Kim(2018)의 연구에서도 한국 젊은 성인들을 대상으로 한 건강행동 연구에서 사회적 낙인(social stigma)과 민감한 주제에 대한 대화의 어려움이 주요 장애 요인으로 확인되었다. 반면, 디지털 기술에 대한 높은 수용성과 편의성은 '지각된 이익' 요소로 작용하여 디지털 정신건강 중재의 효과성에 긍정적 영향을 미칠 수 있다.

1.3) 연구 가설

HBM의 이론적 구성요소를 바탕으로 다음과 같은 연구 가설을 설정하였다:

가설 1 (중재 효과): 디지털 개입 프로그램 참여 그룹(Woebot, Happify)은 대조군(Bondee 앱 사용자 그룹)에 비해 외로움 및 우울감이 유의하게 감소할 것이다.

가설 2 (지각된 이익): 실험을 통해 외로움과 우울감이 줄어든 것이라고 기대하는 그룹은 그렇지 않은 그룹에 비해 외로움 및 우울감 감소 효과가 더 클 것이다.

가설 3 (지각된 장애물): 디지털 중재의 효과성을 긍정적으로 인식하는 그룹은 그렇지 않은 그룹에 비해 외로움 및 우울감 감소 효과가 더 클 것이다.

가설 4 (자기 효능감/도움 구하기 행동): 외부 도움의 필요성을 인정하는 그룹은 자신의 노력만으로 해결할 수 있다고 믿는 그룹에 비해 외로움 및 우울감 감소 효과가 더 클 것이다.

2. 연구 설계

1) 실험 설계 및 절차

본 연구는 무작위 대조 시험(Randomized Controlled Trial, RCT) 설계를 채택한 혼합연구방법론(Mixed Methods Research) 연구이다. 연구는 2023 년 3 월부터 6 월까지 4 개월에 걸쳐 진행되었으며, 성균관대학교 자연과학대학 및 인문사회과학대학 재학생을 대상으로 하였다.

실험 설계의 구체적 특성:

본 연구는 평행군 무작위 대조 시험(Parallel-group RCT) 설계를 사용하였다. 연구의 맹검은 중재의 특성상 참여자 맹검이 불가능하여 연구자 단일 맹검으로 실시하였다. 무작위 배정은 층화 무작위 배정법을 적용하였으며, 제한된 표본 크기를 고려한 검정력 확보를 위해 중재군 대 대조군을 약 4:1 비율로 배정하였다.


실험 일정 및 측정 시점:

[그림 3]에서 보는 바와 같이, 본 연구는 다음과 같은 절차로 진행되었다(2023.3.10~ 2023.6.10). 연구 기간은 8 주 중재와 4 주 추적 관찰로 구성되었다. 측정은 베이스라인(T0), 4 주 후(T1), 8 주 후(T2), 12 주 후(T3) 총 4 회 실시하였다. 측정 도구로는 우울(PHQ-9), 외로움(UCLA 외로움 척도) 등의

표준화된 척도와 개방형 질문을 포함한 혼합형 설문지를 사용하였다(부록 5 참조).

중재 기간 동안 참여자들은 일일 최소 15 분 앱을 사용하도록 하였다.

그림 3. 실험 설계와 참여자 도식



2) 참가자 선정 및 윤리적 고려

본 연구는 성균관대학교 기관생명윤리위원회(IRB)의 승인을 받아 진행되었다(SKKU 2023-02-043, 부록 1 참조). 연구는 보건복지부 K-Medi 융합인재양성지원 사업의 일환으로 수행되었으며, 자연어 처리 기술을 이용한 근거 기반 청년 정신건강 돌봄 디지털 서비스 플랫폼 개발이라는 과제명하에 성균관대학교 산학협력단이 주관기관 역할을 담당하였다.

참가자 모집은 2023 년 2 월말부터 3 월 첫째 주에 걸쳐 성균관대학교 포털 홈페이지를 통해 온라인으로 진행되었다(부록 2 참조). 참가자 선정기준은 만 18 세 이상 27 세 이하의 성균관대학교 재학생 또는 휴학생으로, UCLA 외로움 척도에서 34 점 이상의 중등도 이상 외로움을 경험하고 있으며 또한 영어로 제공되는 앱 사용에 어려움이 없어야 하며, 연구 참여 동의서를 제출한 경우에만 참여가 가능하였다. 총 63 명이 참여하였으며, 최종 분석에는 27 명이 포함되어 약 57%의 완료율을 보였다. 제외기준은 UCLA 외로움 척도 34 점 미만이거나 연구 참여 동의서를 미제출한 경우, 그리고 심각한 정신건강 위기 상황으로 즉시 전문적 개입이 필요한 경우로 설정하였다. 특히 고위험군의 경우 연구진이 추가 상담을 권유하고 지속적인 모니터링을 실시하였다.

무작위 배정은 참여자의 이름을 블라인드 처리한 후 층화 무작위 배정법을 적용하였다. 연령, 성별, 외로움 점수가 각 그룹에 유사하게 분포되도록 하였으며, 제한된 전체 표본 크기를 고려하여 중재군에 충분한 검정력을 확보하기 위해 대조군 참여자 수를 상대적으로 적게 배정하였다. 최종적으로 Woebot 군 22 명, Happify 군 21 명, 대조군인 Bondee 군 10 명으로 배정되었다.

윤리적 고려사항으로는 모든 참여자에게 연구의 목적, 절차, 예상되는 위험성과 이익에 대한 충분한 설명을 제공하였으며, 자발적 참여와 언제든지 철회가 가능함을 명확히 고지하였다. 데이터 수집 과정에서 모든 정보는 익명화 처리되었으며, 개인정보 보호를 위한 엄격한 보안 조치를 실시하였다. 중재 실험과 설문 완료자에게는 3 만원의 보상과 인터뷰에 대한 별도의 보상, 사후 평가까지 완료한 참여자에게는 추가로 인센티브를 제공하여 연구 참여에 대한 적절한 보상을 하였다.

3. 연구 방법

1) 혼합연구방법론 설계

본 연구에서는 Creswell et al.(2017)의 혼합연구방법론(Mixed Methods Research)을 채택하였다. 이는 양적 연구와 질적 연구 방법을 통합하여 연구 문제에 대한 더욱 포괄적이고 심층적인 이해를 도모하기 위함이다.

◆혼합연구방법론 채택 근거:

◆표본 크기의 보완: 최종 참여자 27 명의 규모는 순수 양적 연구만으로는 충분한 통계적 검정력을 확보하기 어려워, 질적 데이터를 통한 보완적 분석이 필요하였다.

◆현상의 다각적 이해: 디지털 정신건강 중재의 효과는 단순히 점수 변화로만 측정되기 어려우며, 사용자 경험, 인식 변화, 행동 패턴 등에 대한 질적 탐색이 필요하였다.

◆결과의 신뢰성 강화: 양적-질적 방법론의 삼각검증(triangulation)을 통해 연구 결론의 타당성과 신뢰성을 제고하고자 하였다.

◆실무적 시사점 도출: 향후 LLM 기반 정신건강 챗봇 개발이라는 연구의 궁극적 목적을 위해 사용자들의 경험과 요구사항을 심층적으로 이해할 필요가 있었다.

◆연구 설계 유형: 수렴적 병행 설계(Convergent Parallel Design)를 채택하여 양적-질적 데이터를 동시에 수집하고 분석 단계에서 통합하였다.

2) 중재 도구

본 연구에서는 임상적 효과성이 검증된 두 가지 디지털 정신건강 앱을 중재 도구로 선정하였다. 이러한 선정은 단순한 임의 선택이 아니라 Li et al.(2021)의 체계적 성능 평가 연구 결과에 근거하였다.

첫 번째 중재 도구인 Woebot(Version 4.10.5)은 인지행동치료(CBT) 원리를 기반으로 한 대화형 챗봇이다. 이 앱은 Fitzpatrick et al.(2017)의 무작위 대조 시험에서 젊은 성인들의 우울 및 불안 증상 감소에 효과적임이 입증되었다. Li et al.(2021)의 연구에서는 5 점 척도 기준으로 몰입도 4.10 ± 0.14 점, 기능성 4.65 ± 0.21 점, 전반적 질 4.31 ± 0.09 점의 우수한 평가를 받았다. Woebot 은 일일 대화를 통해 사용자의 기분을 추적하고, CBT 기법을 활용한 인지 재구조화 훈련을 제공한다.

두 번째 중재 도구인 Happify(Version 2.11.5)는 CBT 와 마음챙김 기반 활동을 결합한 포괄적인 정신건강 플랫폼이다. 이 앱은 Boucher et al.(2021)의 연구에서 COVID-19 팬데믹 기간 중 외로움 완화에 특히 효과적임이 확인되었다. Li et al.(2021)의 평가에서는 몰입도 4.60 ± 0.00 점, 기능성 4.25 ± 0.00 점, 전반적 질 4.15 ± 0.02 점을 기록하여 높은 사용자 만족도를 보였다. Happify 는 다양한 게임형 활동, 명상 가이드, 감사 일지 등을 통해 긍정 심리학 원리를 실생활에 적용할 수 있도록 돕는다.

대조군으로는 Bondee³² (Metadream)를 선정하였다. Bondee 는 메타버스 기반 소셜네트워크 메신저 앱으로, 정신건강 치료 기능은 없지만 소셜 상호작용 요소를 포함하고 있어 적절한 비교군 역할을 할 수 있다고 판단하였다.

³² Metadream에서 런칭한 메타버스 기반의 소셜 미디어 애플리케이션

세 앱 모두 2023 년 3 월 실험 시작 당시 구글 플레이와 애플 앱스토어에서 다운로드 가능하였으며, 한국어 버전이 제공되지 않아 모든 상호작용은 영어로 진행되었다. 각 앱의 다운로드 방법과 상세한 사용 안내는 <부록 6>에 제시하였다. 이러한 언어적 제약은 연구의 한계점이지만, 모든 중재군에서 동일한 조건을 적용하여 결과의 일관성을 확보하고자 하였다. 참여자들의 영어 사용 능력에 대한 별도의 평가는 실시하지 않았으나, 모집 공고에서 영어 앱 사용에 자신 있는 학생들의 참여를 명시하였다.

◆중재 프로토콜: 각 앱의 특성과 기존 연구에서 효과적인 것으로 입증된 사용 방법을 참고하여 설정되었다. 모든 참여자는 일일 최소 15 분 이상 해당 앱을 사용하도록 안내받았다. Woebot 사용자들은 주당 5 개의 대화 주제 탐색, 1 개의 CBT 도구 활용, 2 개의 감정 일지 작성을 목표로 하였다. Happify 사용자들은 주당 16 개의 다양한 활동을 수행하되, 특히 Instant Play 섹션의 Serenity Scene, Guided Meditation, Negative Knockout 활동과 감사 일지 작성에 중점을 두었다. 모든 참여자에게 연구 기록 보관과 월별 인센티브 지급을 위해 주 3 회 이상 앱 사용 화면을 캡처하여 제출하도록 요청하였다.

3) 측정 도구

◆UCLA 외로움 척도 (한국어판, 부록 3 참조):

UCLA 외로움 척도는 Russell et al.(1980)이 개발하고 진은주와 황석현 (2019)이 한국어로 타당화 작업을 한 도구로, 총 20 문항의 4 점 리커트 척도(20~80 점)로 구성되어 있다. 본 연구에서 측정된 신뢰도는 베이스라인에서

$\alpha=0.848$, 최종 측정에서 $\alpha=0.904$ 로 나타났다.♦환자건강설문지-9 (PHQ-9, 한국어 번역판, 부록 4 참조):

PHQ-9 는 Kroenke et al.(2001)이 개발한 우울증 선별 도구로, 9 문항의 4 점 리커트 척도(0~27 점)로 구성되어 있다. 한국어판의 타당성은 Park et al.(2010)에 의해 검증되었다. 본 연구에서 측정된 신뢰도는 베이스라인에서 $\alpha=0.680$, 최종 측정에서 $\alpha=0.769$ 였다.♦건강신념모델 기반 추가 측정:

①지각된 이익: "실험을 통해 외로움과 우울감이 조금이라도 줄어들 것이라고 예상했습니까?"

②지각된 장애물: "디지털 애플리케이션도 효과적으로 설계된다면 외로움과 우울증 완화에 도움이 될 수 있다고 생각하십니까?"

③자기 효능감(도움구하기 행동): "자신의 노력과 의지로만도 타인의 도움이나 개입 없이 외로움과 우울감 같은 감정을 조절할 수 있다고 생각하십니까?"

4) 데이터 분석 방법

본 연구의 실험 I 은 연구자가 제 1 저자로 참여하여 JMIR Formative Research 에 게재된 Kang & Hong(2024)의 연구를 근간으로 하되, 박사논문의 연구 목적에 맞게 추가적인 분석을 수행하였다. 본 연구에서는 수렴적 병행 설계(Convergent Parallel Design)의 원칙에 따라 양적 데이터와 질적 데이터를 별도로 분석한 후 통합하는 접근법을 취하였다. 모든 데이터 분석 코드는 GitHub 저장소(<https://github.com/bykang2015/JMIR-Digital-Interventions-Code>)에서 확인할 수 있다.

4.1) 양적 데이터 분석

참여자 특성 및 주요 변수들에 대한 기술통계분석을 실시하여 평균, 표준편차, 빈도를 산출하였다. 데이터의 정규성은 Shapiro-Wilk 검정을 통해 확인하였다.

그룹 간 비교 분석 방법: 본래 세 그룹(Woebot, Happify, Bondee) 비교를 위해 일원배치 분산분석(ANOVA)을 계획하였으나, 연구 진행 과정에서 대조군(Bondee) 참여자가 급격히 감소하여 최종 시점에 3 명만 남게 되었다. 이는 다른 두 그룹($n=15$, $n=9$)과 현저한 표본 크기 불균형을 초래하여 통계적 검정력이 크게 제한되므로, 대조군을 분석에서 제외하고 두 중재군(Woebot vs Happify) 간 비교만을 실시하였다.

그룹 내 전후 비교 분석: 각 그룹별로 중재 전후의 변화를 평가하기 위해 대응표본 t-검정(paired t-test)을 실시하였다.

개별 참가자 변화 궤적 분석: 소표본 연구의 한계를 보완하고 개인차를 탐색하기 위해 개별 참가자의 변화 궤적을 시각화하고 분석하였다. 임상적으로 의미있는 개선을 보인 참가자를 '반응자(responder)'로 정의하여, PHQ-9 에서는 기존 연구(Kroenke et al., 2001)에 따라 5 점 이상의 감소를, UCLA 외로움 척도에서는 10 점 이상의 감소를 임상적 개선의 기준으로 설정하였다. 각 그룹별 반응자 비율을 산출하고, 개별 참가자의 변화 패턴을 곡선 그래프로 시각화하여 치료 반응의 이질성을 파악하였다. 이는 평균값 중심의 분석에서 가려질 수 있는 개인별 치료 반응 양상을 포착하는 데 유용한 접근법이다.

각 측정 시점별로 정규성 검정을 실시한 후, 정규분포 조건을 만족하는 경우 독립표본 t-검정을, 그렇지 않은 경우 Mann-Whitney U 검정을 적용하였다. 측정

도구의 신뢰성은 Cronbach's α 계수를 통해 검증하였으며, 결측치는 완전사례분석(Complete case analysis) 방법으로 처리하였다.

4.2) 질적 데이터 분석

질적 데이터 분석은 Braun et al.(2006)의 주제분석(Thematic Analysis) 방법을 적용하였다. 분석 과정은 데이터 친숙화 단계에서 시작하여 초기 코드 생성, 주제 검색, 주제 검토, 주제 정의 및 명명, 최종 보고서 작성의 6 단계를 체계적으로 수행하였다. Zoom 을 통해 녹화된 포커스그룹인터뷰 내용을 Naver Clova 를 활용하여 전사한 후, Python 기반 텍스트 마이닝 기법을 통해 핵심 주제를 추출하였다. 포커스그룹 인터뷰는 반구조화된 질문지(부록 8 참조)를 사용하여 진행되었으며, 주요 질문 내용은 부록에 제시하였다.

분석의 객관성과 신뢰성을 확보하기 위해 두 명의 연구자가 독립적으로 초기 코딩 과정을 수행한 후 상호 일치도를 확인하는 절차를 거쳤다. 주제 개발은 이론적 선입견에 의존하지 않고 데이터에서 자연스럽게 나타나는 패턴을 찾는 귀납적 접근법을 통해 상향식으로 이루어졌다.

4.3) 데이터 통합 및 해석

분석의 마지막 단계에서는 메타추론(meta-inference) 과정을 통해 양적 결과와 질적 결과를 통합적으로 해석하였다. 특히 양적 분석에서 통계적 유의성이 확인되지 않은 부분에 대해서는 질적 데이터를 활용한 설명적 분석을 수행하여 현상에 대한 보다 깊이 있는 이해를 도모하였다. 이러한 삼각검증 과정을 통해 양적 결과와 질적 결과 간의 수렴성과 발산성을 확인하고, 연구 결과의 타당성과 신뢰성을 제고하였다.

기존 연구와의 차별점: 원논문에서 제시된 기본 분석에 더하여, 본 박사논문에서는 선행 연구, 가설의 도출 과정, 개별 참가자 변화 궤적 분석, 기타 설문 분석 등의 확장 연구를 수행하여 보다 풍부한 시사점 및 전략을 도출하였다.

4. 연구 결과

1) 참가자 특성 및 베이스라인 분석

참가자 모집 및 선정 결과:

초기 모집된 63 명의 지원자 중 선정 및 제외 기준을 적용하여 최종 53 명이 연구에 참여하게 되었다. 제외된 참여자는 UCLA 외로움 척도가 34 점 이하로 매우 낮은 9 명과 연구 참여 동의서를 미제출한 1 명이였다. 최종 참여자들은 층화 무작위 배정을 통해 Woebot 군 22 명, Happify 군 21 명, 대조군(Bondee) 10 명으로 배정되었다.

인구통계학적 특성:

초기 모집된 63 명의 지원자 중 선정 및 제외 기준을 적용하여 최종 53 명이 연구에 참여하게 되었다. 제외된 참여자는 UCLA 외로움 척도가 34 점 이하로 매우 낮은 9 명과 연구 참여 동의서를 미제출한 1 명이였다. 최종 참여자들은 층화 무작위 배정을 통해 다음과 같이 세 그룹으로 배정되었다:

Woebot 그룹: 22 명

Happify 그룹: 21 명

대조군(Bondee): 10 명

실험 집단과 대조군의 인구통계학적 특성은 [표 4]과 같이 평균 연령, 성비가 유사하도록 배정되었다.

표 4. 실험 집단과 대조군 집단의 실험 초기(Baseline) 인구통계 및 독립 변수

		Woebot (n=22)	Happify (n=21)	Control (Bondee) (n=10)
척도, 평균(SD)	UCLA Loneliness	54(8.52)	53.67(11.05)	53.5(7.09)
	Depression (PHQ9)	10(5.74)	9.14(5.84)	9(7.09)
나이, 평균(SD)		23.5(1.78)	23.1(2.14)	22.91(1.85)
성별, n(%)	여성	14	12	5
	남성	8	9	5
전공, n(%)	인문 사회과학	11	10	4
	자연과학 및 공학	11	11	6

2) 양적 분석 결과

2.1) 중재 효과 분석

본 연구의 정량적 자료 분석을 통해 각 중재군과 대조군 간의 효과를 비교 분석하였다. 전반적으로 모든 그룹에서 베이스라인 대비 외로움과 우울증 점수가 감소하는 경향을 보였으나, 중재군 간의 차이는 [표 5]에서 보는 바와 같이 통계적 유의성에 도달하지 못했다.

◆각 그룹 내 전후 비교 분석: 각 그룹 내 전후 비교 분석에서는 Happify 그룹만이 UCLA 외로움 척도($t(8)=2.465$, $p<0.05$)와 PHQ-9 우울 척도($t(8)=3.825$, $p<0.05$) 모두에서 통계적으로 유의한 개선을 보였다. Effect size 분석 결과, Happify 그룹에서 PHQ-9 우울증상의 큰 효과 크기(Cohen's $d=0.942$)와 UCLA 외로움의 작은 효과 크기(Cohen's $d=0.471$)가 확인되어 임상적으로 의미있는 개선 효과를 나타냈다.

표 5. UCLA 외로움 척도 및 PHQ-9 우울증 척도 점수의 기술통계 및 그룹 비교³³

변수 및 측정 시점	Woebot (n=15), 평균 (표준편차)	Happify (n=9), 평균 (표준편차)	대조군 (Bondee, n=3), 평균 (표준편차)	두 중재군 간 비교 검정	P값
UCLA 외로움 척도					
베이스라인	51.13 (8.73)	51.44 (8.76)	53 (6.08)	t-test	0.93
1개월 후	48.40 (10.27)	49.78 (10.51)	50 (10.39)	Mann-Whitney U	0.68
2개월 후	49.53 (10.26)	46.56 (10.72)	52.33 (8.96)	t-test	0.51
중재 후	48.47 (10.26)	46.78 (10.92)	51.33 (4.16)	t-test	0.67
PHQ-9 우울증					
베이스라인	8.87 (4.88)	8.33 (3.81)	11 (5.29)	t-test	0.78
1개월 후	7 (5.13)	6.78 (5.33)	8 (4.36)	Mann-Whitney U	0.83
2개월 후	7.73 (4.38)	5 (3.91)	8.33 (3.51)	t-test	0.14
중재 후	7.07 (4.67)	4.78 (3.73)	6.33 (3.21)	Mann-Whitney U	0.35

UCLA 외로움 척도 변화:

Bondee (대조군): 51.13(SD=8.73) → 48.47(SD=10.26)로 감소

Happify: 51.44(SD=8.76) → 46.78(SD=10.92)로 감소

Woebot: 53.00(SD=6.08) → 51.33(SD=4.16)으로 감소

그룹 간 차이 검정 결과: 통계적으로 유의미하지 않음 (t-test, P=.67)

두 중재군 간 비교 분석 결과, 모든 측정 시점에서 Woebot 과 Happify 간 통계적으로 유의한 차이는 관찰되지 않았다(UCLA 외로움 척도 종료 후: t-test, P=.67; PHQ-9 우울증 척도 종료 후: Mann-Whitney U test, P=.35). 대조군은 소표본으로 인해 비교 분석에서 제외되었다.

PHQ-9 우울증 척도 변화:

³³ 대조군(Bondee)은 최종 시점 참여자 수가 3명으로 다른 중재군들(n=15, n=9)과 현저한 표본 크기 불균형을 보여 통계적 검정력이 제한되므로 그룹 간 비교분석에서 제외하였음. 중재 효과 비교는 Woebot과 Happify 두 그룹 간에만 실시함. 표에 제시된 그룹 비교 검정 및 p값은 두 중재군 간 비교 결과임.

Bondee(대조군): 11.00(SD=5.29) → 6.33(SD=3.21)로 감소

Woebot: 8.87(SD=4.88) → 7.07(SD=4.67)로 감소

Happify: 8.33(SD=3.81) → 4.78(SD=3.73)으로 감소

그룹 간 차이 검정 결과: 통계적으로 유의미하지 않음(Mann-Whitney U test, $P=.35$)

[그림 4]와 [그림 5]에서 보는 바와 같이, UCLA 외로움 지수와 PHQ-9 우울증 척도 모두에서 실험집단과 대조집단 간의 뚜렷한 차이는 관찰되지 않았다. 이는 작은 표본 크기와 불균형한 그룹 크기(Woebot=15, Happify=9, Bondee=3)로 인한 통계적 검정력의 한계에 기인할 수 있다.

그림 4. UCLA Loneliness Index 의 추이(실험집단 vs 대조집단)





그림 5. PHQ-9 의 추이(실험집단 vs 대조집단)



◆측정 도구의 신뢰도: 측정 도구의 신뢰도는 크론바흐 알파 계수를 통해 검증되었다.

표 6. 측정 도구의 내적 일관성 신뢰도: 크론바흐 α 계수

Measurement Tool	Time Point	Cronbach's Alpha
UCLA Loneliness Index	Baseline	0.848
	1-Month Follow-up	0.893
	2-Month Follow-up	0.928
	Post-Intervention	0.904
PHQ-9	Baseline	0.680*
	1-Month Follow-up	0.702
	2-Month Follow-up	0.746
	Post-Intervention	0.769

*PHQ-9 의 베이스라인 알파값(0.68)이 다소 낮게 나타났으나, 9 개 문항의 짧은 척도임을 고려할 때 수용 가능한 수준으로 판단된다.

2.2) 개별 참가자 변화 궤적 분석

그룹 평균 비교에서는 감지되지 않았던 개별 참가자들의 다양한 변화 패턴을 파악하기 위해 개별 궤적 분석을 실시하였다. 이는 소표본 연구에서 평균값에 가려질 수 있는 개인차와 치료 반응의 이질성을 포착하는 데 유용한 접근법이다.

반응자 정의 및 분석:

임상적으로 의미있는 개선을 보인 참가자를 '반응자(responder)'로 정의하였다. PHQ-9 에서는 기존 연구(Kroenke et al., 2001)에 따라 5 점 이상의 감소를, UCLA 외로움 척도에서는 10 점 이상의 감소를 임상적 개선의 기준으로 설정하였다.

PHQ-9 반응자 분석 결과:

Bondee 그룹: 33.3% (1/3 명)

Happify 그룹: 33.3% (3/9 명)

Woebot 그룹: 20.0% (3/15 명)

흥미롭게도 표본 크기가 가장 작은 Bondee 그룹과 Happify 그룹에서 동일한 반응률을 보였으며, 이는 Woebot 그룹보다 높은 수치였다. 이러한 결과는 단순한 그룹 평균 비교에서는 관찰되지 않았던 패턴으로, 개별 궤적 분석의 가치를 보여준다.

UCLA 외로움 반응자 분석 결과:


Woebot 그룹: 20.0% (3/15 명)

Happify 그룹: 11.1% (1/9 명)

Bondee 그룹: 0% (0/3 명)

외로움 개선에서는 Woebot 이 상대적으로 우수한 성과를 보였으나, 전반적으로 모든 그룹에서 외로움 개선은 우울증 개선에 비해 제한적이었다. 개별 궤적의 대표적 패턴을 보여주는 PHQ-9 결과를 [그림 6]에 제시하였다.

그림 6. 개별 참가자 PHQ-9 변화 궤적 (실선: 반응자, 점선: 비반응자)



개별 변화 패턴의 이질성:

[그림 6]에서 보는 바와 같이, 각 그룹 내에서도 참가자들의 변화 양상은 매우 다양하게 나타났다. 일부 참가자는 지속적인 개선을 보인 반면(예: P1, P11, P24), 다른 참가자들은 변동적 패턴(P13, P24)이나 악화 경향(P5, P27)을 보였다. 이러한 개인차는 디지털 정신건강 중재에서 개인화된 접근의 필요성을 시사한다.

임상적 함의:

개별 궤적 분석을 통해 다음과 같은 임상적 함의를 도출할 수 있다. 첫째, 동일한 중재에 대한 개인의 반응은 매우 이질적이므로 향후 연구에서는 치료 반응 예측 인자를 탐색할 필요가 있다. 둘째, 약 25%의 참가자만이 임상적으로 의미있는 우울증 개선을 보였으므로, 현재의 일률적 접근법을 개인 맞춤형 접근법으로 발전시킬 필요가 있다. 셋째, 외로움은 우울증에 비해 개선이 어려운 영역임이 확인되어, 외로움에 특화된 중재 전략 개발이 요구된다.

2.3) 외로움과 우울증의 상관관계 분석

서론의 선행연구에서 밝힌 바와 같이, 중재 효과 분석에 추가적으로 두 주요 변수인 외로움과 우울증 간의 관계를 탐색하였다. 두 변수의 상관관계 분석에서, 중등도의 양의 상관관계($r=0.37$; $P<.001$)가 나타났으며, 이는 외로움과 우울증이 상당한 관련성을 보이지만($r=0.37$), 전체 변량의 약 14% ($r^2 = 0.37^2 \approx 0.14$)만을 공유하여 여전히 독립적인 특성을 가진 구별되는 개념임을 의미한다. 이러한 결과는 외로움과 우울증이 서로 다른 요인들에 의해 영향을 받을 수 있으며, 대학생 대상 디지털 정신건강 중재 설계 시 두 영역을 개별적으로 접근할 필요성을 시사한다.

중등도 상관관계는 외로움과 우울증의 복잡하고 양방향적인 관계를 부각시킨다. 구조화된 상호작용을 제공하는 대조군(Bondee 사용)에서도 외로움 및 우울증 점수의 약간의 감소가 관찰된 것은 어떤 형태의 구조화된 상호작용이라도 유익한 효과를 가질 수 있음을 시사하며, 사회적 참여와 연결의 중요성을 강조한다.


2.4) 건강신념모델 기반 가설 검증

본 연구에서 설정한 건강신념모델 기반의 네 가지 가설에 대한 검증 결과는 다음과 같다.

가설 1 (중재 효과): 디지털 개입 프로그램 참여 그룹은 대조군에 비해 외로움 및 우울감이 유의하게 감소할 것이다. 분석 결과 이 가설은 기각되었다(UCLA 외로움 척도 $P=.67$, PHQ-9 우울증 척도 $P=.35$). 중재군에서 점수 감소가 관찰되었으나 통계적으로 유의미한 차이는 나타나지 않았다.


가설 2 (행동의 인지된 이점): 실험을 통해 외로움과 우울감이 줄어들 것이라고 예상한 그룹이 더 큰 효과를 보일 것이라는 가설도 기각되었다(UCLA 외로움 척도 $P=.93$, PHQ-9 우울증 척도 $P=.48$). 긍정 그룹이 더 높은 감소율을 보였으나 통계적 유의성은 확인되지 않았다.

그림 7. (a) 행동의 인지된 이점 (긍정 그룹 vs 부정 그룹)




가설 3 (행동의 인지된 장애물): 디지털 앱이 효과적일 것이라고 생각한 그룹이 더 큰 효과를 보일 것이라는 가설 역시 기각되었다(UCLA 외로움 척도 $P=.60$, PHQ-9 우울증 척도 $P=.47$).

그림 7. (b) 행동의 인지된 장애물 (긍정 그룹 vs 부정 그룹)



가설 4 (도움 구하기 행동): 외부 도움의 필요성을 인정하는 그룹이 더 큰 효과를 보일 것이라는 가설도 기각되었다(UCLA 외로움 척도 $P=.34$, PHQ-9 우울증 척도 $P=.62$).

그림 7. (c) 도움 구하기 행동 (긍정 그룹 vs 부정 그룹)




이러한 결과는 작은 표본 크기로 인한 통계적 검정력 부족, 불균형한 그룹 크기, 그리고 단기 실험 기간으로 인한 장기 효과 측정의 제한 등이 주요 한계점으로 작용했을 것으로 분석된다. 향후 연구에서는 더 큰 표본 크기와 균형 잡힌 그룹 구성을 통한 재검증이 필요할 것으로 사료된다.

2.5) 자기보고형 정신건강 리터러시 분석

본 실험 참가자들의 자기보고형 정신건강 리터러시 평균 점수는 [그림 8]에서 보듯이 5 점 척도에서 2.46 으로 나타났다. 이는 대학생들이 스스로 인식하는 정신건강 관련 지식과 대처 능력이 중간 수준(3.0 점)에도 미치지 못함을 의미한다. 정신건강 리터러시는 정신질환을 인식, 관리, 예방하는 데 도움이 되는 지식과 신념을 포괄하는 개념으로(Jorm et al., 1997), 대학생 시기의 정신건강에 지속적인 영향을 미칠 수 있다.

그림 8. 자기보고형 정신건강 리터러시



이러한 결과는 박지혜 외(2020)가 만 19-34 세 청년 411 명을 대상으로 한 연구에서 정신건강 리터러시 수준을 '보통 수준'으로 평가한 것과 일치하는 패턴을 보여준다. 비록 측정 도구가 상이하여 직접적인 수치 비교는 제한적이나, 두 연구

모두에서 한국 청년층의 정신건강 리터러시가 충분하지 않은 수준임을 확인할 수 있다.

특히 주목할 점은 정신건강 서비스 이용 경험에서 나타나는 유사한 패턴이다. 박지혜 외(2020) 연구에서는 전체 대상자 중 10%가 과거 정신건강 도움요청 경험을 보유한 것으로 나타났으며, 본 실험 I의 기타 설문분석 결과에서 63명 중 8명(12.7%)이 정신건강 치료 경험이 있다고 응답하여 매우 유사한 수준을 보였다.

이러한 일관된 결과는 한국 청년층의 정신건강 서비스 접근성과 이용률이 전반적으로 낮은 수준에 머물러 있음을 시사하며, 정신건강 리터러시 향상과 서비스 접근성 개선의 필요성을 뒷받침한다.

3) 질적 분석 결과

3.1) 디지털 중재의 효과성 분석

본 연구의 질적 분석은 개방형 설문과 포커스 그룹 인터뷰를 통해 수행되었다. 참여자들의 응답을 통해 디지털 정신건강 앱이 실제로 긍정적 변화를 이끌어낸 것으로 나타났다. 특히 2차 중재 완료 후 실시된 설문조사에서 "본 실험에 참여한 지난 두달 동안의 경험은 본인에게 어느 정도 유익했습니까?"라는 질문에 대해 참여자들은 평균 6.71점(10점 만점)으로 응답하여 중간 이상의 만족도를 보였다. 이는 기존 디지털 중재의 한계에도 불구하고 사용자들이 실질적인 도움을 받았음을 시사한다. [표 7]에서 제시된 바와 같이, 디지털 중재 앱의 효과는 크게 감사 일기, 명상 및 심호흡, 목표 설정 및 달성의 세 가지 주요 영역에서 나타났다.

표 7. 디지털 중재의 구체적인 효과 예시

카테고리	하위 카테고리	앱	긍정적 변화	구체적인 예시
감사 일기	긍정적 감정 증진		* 행복감, 성취감 증가 * 부정적 감정 완화 * 긍정적 사고방식 형성	* "워봇(Woebot) 매일 감사했던 것을 적었을 때 작은 것에도 감사할 수 있었다" * "해피파이(Happify) Thank You 를 통해 1 주일에 몇 번씩 감사한 일들을 생각하며 행복해지는 순간."
	자기 성찰	워봇, 해피파이	* 하루 돌아보기 * 자신 이해 * 긍정적 가치 탐색	* "워봇(Woebot) 하루 3 가지 감사 일기 쓰는 저널을 이용할 때 하루를 되돌아볼 수 있었다" * "해피파이(Happify) 감사 일기를 작성을 통해 감사한 것들을 떠올려보게 되었습니다."
	일상생활 개선		* 스트레스 감소 * 정신적 안정감 증진 * 숙면 촉진	* "워봇(Woebot) 너무 좌절감이 들 때 감사일기를 씌워서 감정이 뉴트럴해졌다." * "해피파이(Happify) 감사 일기를 캡처하여 제출하려고 들어갔다가 잊고 있었던 예전의 감사함을 다시 보니 신기하기도 했음"
명상 및 심호흡	정서 조절		* 불안, 스트레스, 우울감 완화 * 감정 인지 및 조절 능력 향상 * 마음의 평온함 유지	감정을 조절한 순간이다. 어느날 연락하던 사람이 고백한다고 했을 때 좋았던 순간 문득 어플이 생각나서 감사하다는 것을 작성했을 때 좋은 감정이 들었다. 반대로 갑자기 연락을 그만 하자고 했을때 제대로 아무것도 못하고 있었는데 글 작성을 통해 감정을 조절했다"
	집중력 향상	Happify	* 주의력 집중 * 산만한 감소 * 목표 달성을 위한 효율적인 시간 관리	귀가길 지하철에서, 혹은 자기 전 침대에서 thank activity 를 작성했는데 그 날 있었던 일을 돌아보고 오늘 하루를 무사히 잘 보낼 수 있었고, 작은 것이라도 감사할 일이 있었음에 마음이 편해졌다."
	신체적 건강 증진		* 혈압, 심박수 감소 * 면역력 강화 * 근육 이완 및 통증 완화 * 숙면 촉진 및 피로 감소	잠들기전 짧은 명상을 통해 감정 정리"
목표 설정 및 달성	자기 동기 부여	워봇	* 삶의 방향 설정 * 자신감 향상 * 긍정적인 변화를 위한 꾸준한 노력	특별한 순간까지는 아니지만 매주 목표설정하기 기능이 흥미로웠다. 단순한 활동이지만 매주 목표를 설정하고 일주일 뒤 도달했는지 확인하는 재미도 있고 그것이 나의 장점과 얼마나 관련있나 확인하는 것도 좋았다."
기타	긍정적 경험	본디	* 시각적, 청각적 자극을 통한 감정적 안정 및 힐링 효과 * 긍정적인 분위기 조성 및 스트레스 감소	지칠때 그냥 하늘 사진을 플로팅 앨범으로 찍은 경험

◆감사 습관 형성과 긍정적 사고 활성화

감사 일기 작성은 가장 두드러진 긍정적 효과를 보였다. 참여자들은 일상의 작은 것들에 대한 감사함을 인식하게 되면서 행복감과 성취감이 증가했다고 보고했다. 한 참여자는 "매번 제 삶에서 (그리고 오늘 하루에서) 감사한 일을 꾸준히 생각해볼 수 있어서 좋았습니다. 별거 아니었던 하루가 특별해지는 기분이었습니다"라고 응답했으며, 다른 참여자는 "Gratitude Journal 을 쓰며 감사한 것들을 생각하니 더 긍정적이고 행복해질 수 있었던 것"이라고 표현했다. 또한 "덕분에 감사한 일상을 보내게 되었습니다! 제게 주어진 작은 것이라도 감사하게 생각할 것입니다"라는 응답은 앱 사용이 일상생활의 긍정적 변화로 이어졌음을 보여준다.

◆정서 조절 및 자기성찰 능력 향상

명상과 심호흡 기능은 정서 조절과 일상생활 개선에 효과적이었다. 참가자들은 스트레스 상황이나 감정적 어려움을 겪을 때 앱의 명상 기능을 활용하여 감정을 안정화시킬 수 있었다고 보고했다. 특히 주목할 만한 점은 이러한 기능들이 단순한 감정 조절을 넘어 집중력 향상과 숙면 촉진과 같은 실질적인 생활의 질 개선으로 이어졌다는 점이다.

자기성찰 능력 향상도 주요한 효과로 나타났다. 참여자들은 "내가 가볍게 지나친 것들을 자세히 들여다볼 수 있다는 점"과 "제 감정에 좀 더 객관적으로 접근할 수 있어서 좋았습니다. 여전히 그 감정들은 저의 감정이지만 그것을 단지 느끼는 것이 아니라 생각과 고민의 대상이 되게 함으로써 저를 한 걸음 물러나서

바라보는 기분이었습니다"라고 응답했다. 이는 앱이 단순한 정보 제공을 넘어 사용자의 메타인지 능력을 향상시켰음을 의미한다.

◆개인적 변화 및 성장 인식

참여자들은 실험 기간 동안 정신건강 개선을 체감했다고 보고했다. "실험 참여기간동안 우울감이 조금 덜해진 것 같긴한데..."라는 응답과 "명상을 통해 마음 정리를 조금씩 시작한점 물론 처음에는 잠이 왔지만 점점 진정되는 느낌을 가짐"이라는 응답은 점진적 개선을 보여준다. 한 참여자는 "하루를 돌아보고 불안 대신 만족감을 느끼게 해주었다는 면에서 적응적이었습니다"라고 표현하여 정서 조절 능력의 향상을 보고했다.

자기 인식과 성찰 능력의 향상도 중요한 변화로 나타났다. "워봇 이용하면서 자신에 대해 많이 생각해볼 수 있었어요"와 "나에 대해 생각해볼 수 있는 시간이 매일 생겼고"라는 응답은 자기 탐색의 기회가 증가했음을 의미한다. 또한 "감사한 일을 평소에 찾고 느끼게 되었다"는 응답은 일상에서의 긍정적 인식 변화를 보여준다.

3.2) 앱별 사용자 경험 분석

Woebot 과 Happify 는 각각 고유한 장단점을 가지고 있었다. Woebot 사용자들(n=17)은 앱의 대화형 인터페이스와 따뜻한 메시지 톤을 특히 높이 평가했으며, Happify 사용자들(n=9)은 체계적인 감사 활동과 가이드 명상 프로그램에 높은 만족도를 보였다.

표 8. 앱의 긍정적인 요소

카테고리	Woebot (n)=17	Happify (n)=9
사용자 경험	대화형 느낌, 일일 일기, 따뜻한 메시지	잘 선택된 이름과 다양성
콘텐츠	감사 일기와 심리학 지식	감사 활동과 가이드 명상
기능	빠른 응답, 다양한 콘텐츠, 귀여운 이미지	감사 활동, 가이드 명상, 단어 게임

◆대화형 인터페이스의 장점과 한계

일부 참여자들은 앱의 대화형 인터페이스에 대해 긍정적으로 평가했다. "실제로 대화하는 듯한 시스템"이라는 응답과 "채팅 봇의 기본 설정이 탄탄해서 이질감 없이 대화에 몰입할 수 있었다"는 평가가 있었다. 그러나 이러한 긍정적 평가에도 불구하고, 많은 참여자들은 기존 앱들의 대화 시스템이 규칙 기반의 반복적 응답에 머물러 있어 진정한 대화의 한계를 보인다고 지적했다. 특히 개인의 복잡한 상황과 맥락을 충분히 이해하지 못하는 점이 주요 제약 요인으로 나타났다.

표 9. 앱의 개선되어야 할 점

카테고리	Woebot	Happify
언어 지원	영어만 지원	영어만 지원
콘텐츠 다양성	다양하지만 반복되는 부분이 있음	내용이 다소 부족함
사용자 경험	사용자 입력 시스템 / 무한 루프 문제	직관적이지 않음, 에러
대화 기능	고정된 답변	반복적인 질문
전체적인 피드백	더 적용 가능한 콘텐츠 필요	만족스럽지 않음, 구독 압력

◆언어적 장벽과 접근성의 한계

앱의 기술적 안정성과 기본적인 편의성은 인정받았으나, 언어적 접근성 문제가 심각한 제약 요인으로 나타났다. 참여자들은 "원할 때 접속하도록 파는 자율성"과 "편리성"을 언급했지만, 동시에 영어로만 제공되는 인터페이스로 인해 깊이 있는

상호작용에 어려움을 겪었다고 보고하였다. 따라서 언어 장벽은 사용자의 진정한 감정 표현과 자기 개방을 제한하는 핵심 요인으로 작용했다.

◆개인화 기능의 성과와 한계

게이미피케이션 요소와 시각적 개인화 기능은 일정한 효과를 보였다. "자신의 공간을 꾸밀 수 있다는 점"과 "아바타나 방을 꾸미면서 짜투리 시간을 보낼 수 있음"이라는 응답이 있었으나, 이러한 표면적 개인화는 사용자의 심층적 정서적 요구를 충족시키는 데 한계가 있었다. "따뜻한 메시지를 받을 수 있다는 것"에 대한 긍정적 반응이 있었지만, 동시에 참여자들은 이러한 메시지가 규칙 기반의 일반적 응답에 그치며 개인의 구체적 상황을 반영하지 못한다는 아쉬움을 표현했다.

3.3) 참여 지속 의향 및 만족도

2 차 중재 완료 후인 2023 년 5 월에 실시된 "2 학기에 새로운(다른 종류의 어플리케이션이나 다른 정신 건강 ex 수면 관련) 실험이 시작된다면 참여할 의사가 있습니까?"라는 질문에 대해 총 28 명의 응답자 중 23 명이 "있다"고 답하여 82.1%의 높은 재참여 의향을 보였다. 이는 실험에 대한 전반적 만족도와 디지털 정신건강 중재에 대한 긍정적 인식을 반영한다.

참여자들의 자유 응답에서도 높은 만족도가 드러났다. "감사했습니다", "해당 실험에 참가하여 어떤 식으로 정신건강 문제 어플리케이션 제작이 접근되고 있는지 알 수 있었고 해당 분야에 대한 관심이 증가했습니다"라는 응답은 연구 참여 자체에 대한 의미를 인정하는 것이다. 또한 "효과성을 느꼈고 이 효과성이 크진 않지만 하루를 돌아보고 불안 대신 만족감을 느끼게 해주었다는 면에서

적응적이었습니다"라는 응답은 비록 효과가 크지 않더라도 일상적 웰빙 향상에 도움이 되었음을 보여준다.

3.4) 외로움 대처 메커니즘 분석

포커스 그룹 인터뷰에서 도출된 외로움 대처 방안은 [표 10]에서 보듯이 목표 설정, 주의 환기, 자기 관리, 사회적 연결의 네 가지 핵심 영역으로 구분되었다. 특히 주목할 만한 점은 참가자들이 단순한 감정 회피가 아닌, 구체적인 성취 목표 설정을 통해 외로움을 극복하고자 했다는 점이다. 예를 들어, "영어 자격증이나 장학금 목표 공부"와 같은 실질적인 목표 설정은 외로움 극복의 효과적인 전략으로 보고되었다.

표 10. 실험 참여 대학생들의 외로움 대처방안

외로움 대처방안	
목표설정	참가자들은 영어 자격증이나 장학금 공부와 같은 실질적인 성취에 초점을 맞추는 방법이 외로움을 이겨내는 방법이라고 강조했다. 목표를 잡고 뭐를 이루려고 노력한다. 감정에 집중하기보다는 눈으로 즉각적으로 이루려고 한다. 예를 들면 영어자격증, 장학금 목표 공부."¹ "성취 동기가 강하다. 돌파구를 찾아서 이것저것 하는 것 좋아하는데 자신의 좋은 감정. 외롭거나 우울해지려고 하면 영화보는 것을 좋아하는데 고등학교 졸업하고 나서 책을 열심히 보는데, 프랑케슈타인 고전 소설 어렵다고 꺼렸는데 ..."²
주의환기	외로움이 아주 심하지 않을 때는 많은 참여자들이 공통적으로 감정적으로 매몰되지 않고 주의를 환기시키는 방법을 언급하였다. "예전에는 감정에 한없이 빠져들었는데, 요즘은 감정에서 빠져나오려고 한다. 재미있는 미드를 본다든가." 새로운 장소, 좋아하는 장소 외출, 환기 시키는 게 도움이 많이 된다. 정도가 심하지 않을 때: 취미생활, 좋아하는 유튜브, 뮤지컬에 빠져서.³ "쇼핑을 한다." 게임, 드라마를 본다... 일타스캔들을 보았다."⁴
자기관리	자가 관리 전략에는 산책하기, 특정 책 읽기, 그리고 부정적인 생각을 의식적으로 관리하는 것이 포함된다." 삶은 여행이므로 스스로 강해지는 것이 중요하다고 생각한다". 최근에 저는 체육관에서 운동을 하고 있습니다." 기본적인 생활패턴 규칙적인 운동, 기상, 맛있는 것 먹는다."⁵ "헬스장 운동 요즘에는 한시간반 에너지를 방출하면 외로움도 덜해진다."⁶
사회적연결	외로움을 덜어내기 위해 대인적 교류가 주요 대처 메커니즘으로 부상했으며, 참가자들은 특히 가까운 친구와 이야기하는 것의 중요성을 강조했다. "혼자서 할 수 있는 취미는 외로움을 해결하는데 도움이 되지 않는다. 다른 사람들을 만나야 한다."⁷ "다른 사람과 얘기를 하면서 심정을 토로한다." 이것저것 해봤는데 사람을 만나 대화하는 게 외로움을 해결하는 방법이다. 새로운 사람보다는 친한 사람을 만나야 한다. "⁸

주의 환기 전략의 경우, 참가자들은 감정에 매몰되지 않고 다양한 활동을 통해 주의를 전환하는 방식을 선호했다. "예전에는 감정에 한없이 빠져들었는데, 요즘은 감정에서 빠져나오려고 한다"는 응답은 이러한 전략의 효과성을 잘 보여준다. 또한 규칙적인 운동, 기본적인 생활패턴 유지 등의 자기 관리 활동과 친밀한 관계에서의 대화를 통한 사회적 연결이 효과적인 대처 방안으로 확인되었다.

3.5) 기타 기능 개선 요구

기능적 보완 측면에서는 [표 11]에서 보는 바와 같이 다양한 추가 기능 개선 요구사항이 제시되었으나, 특히 주목할 점은 '정신건강 전문가와의 연계 시스템'이 12 회로 가장 높은 빈도를 보인 것이다. 이는 디지털 네이티브 세대임에도 불구하고 대학생들이 여전히 인간 전문가와의 직접적 상담에 대한 강한 요구를 가지고 있음을 시사한다. 디지털 정신건강 도구가 아무리 발전해도 위기 상황이나 복잡한 심리적 문제에서는 전문가의 개입이 필수적이라는 인식이 강하게 나타났다.

한편, 디지털 네이티브 세대의 특성을 반영하는 숨은 니즈도 명확히 확인되었다. '수행된 활동에 대한 보상 시스템'(7 회)과 '감사일기에 대한 고품질 피드백'(5 회)에 대한 요구는 단순한 일방적 정보 제공을 넘어선 상호작용적 경험에 대한 갈망을 보여준다. 이는 게임화된 디지털 환경에 익숙한 Z 세대 대학생들이 정신건강 관리 활동에서도 즉각적 피드백, 성취감, 진행도 확인 등의 보상 체계를 통한 동기 부여를 기대하고 있음을 의미한다. 또한 '홈 버튼 및 세부 페이지 기능을 플랫폼으로 사용'(4 회) 요구는 정신건강 앱이 단발성 도구가 아닌 종합적 플랫폼으로 발전해야 한다는 인식을 반영한다.

표 11. 디지털 테라피 앱에 추가되었으면 하는 보완 기능(복수선택)

제안된 개선 사항	언급 횟수
정신 건강 전문가와의 연결 시스템	12
수행된 활동에 대한 보상 시스템	7
감사 일기에 대한 고품질 피드백	5
홈 버튼 및 세부 페이지 기능을 플랫폼으로 사용	4
수행할 활동에 대한 알람 시스템	4
개인의 필요와 기호에 기반한 맞춤형 옵트인 기능	4
사용자용 다양한 비디오 콘텐츠	3
외로움 및 우울증에 대한 팟캐스트	2
사용자 콘텐츠 (UCC) 및 피어투피어 네트워킹	2

이러한 요구는 후속 연구인 실험 II 에서 감사일기 작성 수행활동에 대한 보상 및 위험탐지 시스템을 통한 전문기관 정보 제공으로 부분적으로 반영되었다.

4) 중재 효과 제한 요인 분석

중재가 유의미한 효과를 나타내지 못한 몇 가지 요인들이 확인되었다. 첫째, 앱의 한국어 버전 부재로 인해 영어 숙련도가 낮은 참가자들의 참여도가 저하되었을 가능성이 있다. 둘째, 까다로운 학업 일정과 경쟁적 환경, 그리고 일상적 스트레스 요인들이 우울증과 외로움을 악화시켜 중재 효과를 감소시켰을 수 있다.

이러한 발견은 다층적 요인들을 통합적으로 고려한 디지털 정신건강 중재의 필요성을 뒷받침한다. 특히 한국 대학생의 언어적 접근성, 학업 환경적 특성, 생활 패턴을 반영한 맞춤형 디지털 중재 개발의 중요성이 부각된다.

5) 이탈률 및 참여도 분석

중재 그룹 간의 이탈률은 주목할 만한 차이를 보였다. Woebot 은 22 명에서 15 명으로 32%의 이탈률을 보인 반면, Happify 는 21 명에서 9 명으로 57%의

상대적으로 높은 이탈률을 기록했다. 이러한 차이는 앱의 사용자 경험과 만족도가 지속적인 참여에 중요한 영향을 미친다는 점을 시사한다. 특히 Woebot 의 상대적으로 낮은 이탈률은 자연스러운 대화형 인터페이스와 일관된 사용자 경험이 참여 유지에 긍정적으로 작용했을 가능성을 보여준다.


그러나 무엇보다도 높은 이탈률에는 앞서 참여자들이 단점으로 지적한 앱의 한국어 버전 부재로 인해 영어 숙련도가 낮은 참가자들의 참여도가 저하되었을 가능성이 있다. 또한 까다로운 학업 일정과 경쟁적 환경, 그리고 일상적 스트레스 요인들이 우울증과 외로움을 악화시켜 중재 효과를 감소시켰을 수 있다.

이는 개별 사용자의 다양한 특성과 요구를 종합적으로 고려한 개인화된 디지털 정신건강 서비스의 중요성을 시사한다. 특히 국내 대학생 집단의 고유한 언어 사용 패턴과 학업적 맥락에 최적화된 AI 기반 중재 시스템 구축이 핵심 과제로 제기되며, 이는 기존의 규칙 기반 시스템의 한계를 극복할 수 있는 LLM(Large Language Model) 기반 챗봇 개발의 필요성을 강력히 뒷받침한다.

5. 기타 설문 분석 결과

본 실험의 주요 결과인 우울증과 외로움 증상의 변화 외에도, 부가적인 설문 분석을 통해 한국 대학생들의 정신건강 현황과 사회적 맥락에 대한 중요한 시사점을 도출할 수 있었다.

그림 9. 기타 설문분석



1) 정신건강 치료 경험과 현황

그림 9(a)]에서 나타난 바와 같이, 전체 참가자 63 명 중 8 명(12.7%)이 정신건강 치료 경험이 있다고 응답했다. 12.7%로 일반 청년층과 유사한 수준이나, 본 연구 참가자들의 높은 우울 증상 심각성(PHQ-9 고위험군 39.7%)을 고려할 때 치료 필요성과 실제 이용률 간 괴리가 존재할 수 있다.

2) 우울 증상의 심각성과 자살 충동

[그림 9(b)]의 도움 요청 가능한 사람 유무 조사에서는 참가자의 36.5%가 '가끔 있다', 31.7%가 '드물게만 있다'고 응답하여, 상당수의 학생들이 사회적 지지체계가 부족한 상황임을 보여준다.

특히 주목할 만한 점은 [그림 9(c)] 자해/자살 생각 빈도 조사 결과이다. 전체 참가자 중 15.9%가 PHQ-9 의 자살 충동 관련 문항에 긍정적으로 응답했다(일주일 이상 1.6%, 며칠 동안 9.5%, 거의 매일 4.8%). 이러한 수치는 대학생 정신건강의 심각성을 보여주는 중요한 지표로, 즉각적인 관심과 개입이 필요함을 시사한다.

3) 고위험군 관리의 문제점

특히 우려되는 점은 PHQ-9 점수가 20 점 이상인 고위험군 학생들의 경우, 상담 권유에도 불구하고 대부분이 1 개월 차에 실험에서 이탈했다는 점이다. 이러한 현상은 한국의 높은 사회적 고립과 관련이 있을 수 있다. 한국보건사회연구원(2023)에 따르면, 2021 년 기준 한국의 사회적 고립 인구 비율은 18.9%로 OECD 회원국 중 4 위를 기록했으며, 이는 "곤란한 상황에서 도움을 청할 수 있는 친구나 친지가 있느냐"는 질문에 "없다"고 답한 비율을 의미한다.

4) 우울 증상의 일상생활 영향

[그림 9(d)]에 제시된 PHQ-9 의 열 번째 문항(일상생활 어려움 정도) 분석 결과는 우울 증상이 학업, 대인관계 등 일상생활 전반에 미치는 영향의 심각성을 보여준다. 참가자의 61.9%가 우울 증상으로 인해 일상생활에서 어려움을 경험한다고 응답했으며, 이 중 49.2%는 '다소 어렵다', 9.5%는 '많이 어렵다', 3.2%는 '매우 많이 어렵다'고 응답했다. 이 보조 문항은 비록 PHQ-9 총점에는 포함되지 않으나, 치료 계획 수립과 개입 강도 결정에 있어 중요한 임상적 지표를

제공한다. 특히 우울 증상들이 일상생활에 미치는 영향 정도는 중재의 우선순위를 결정하는 데 핵심적인 정보가 된다.

6. 결론 및 시사점

1) 연구의 주요 성과와 한계점

본 연구는 디지털 정신건강 중재가 한국 대학생들에게 미치는 효과를 체계적으로 검증한 국내 최초의 무작위 대조 시험이다. 비록 높은 탈락률(약 49%)로 인해 당초 계획한 완전한 무작위 대조 시험의 구현에는 제약이 있었으나, 질적 분석을 통해 디지털 중재의 실질적 효과와 개선 방향에 대한 중요한 통찰을 얻을 수 있었다.

주요 성과: 참여자들은 2 차 중재 완료 후 평균 6.71 점(10 점 만점)의 만족도를 보고했으며, 82.1%가 추가 연구 참여 의향을 밝혔다. 이는 통계적 유의성에는 도달하지 못했으나 디지털 중재가 대학생들의 정신건강 관리에 의미 있는 보조 수단이 될 수 있음을 시사한다. 특히 감사 일기 작성과 명상 기능을 통한 긍정적 사고 활성화, 자기성찰 능력 향상, 정서 조절 능력 개선 등의 효과가 질적 분석을 통해 확인되었다.

연구의 한계: 첫째, 대조군의 표본 크기가 3 명으로 감소하여 중재군과 대조군 간의 직접적 효과 비교에 제약이 있었다. 둘째, 3 개월의 중재 기간은 기존 연구들보다 연장되었으나 장기적 효과 평가에는 여전히 제한적이다. 셋째, 연구 참가자가 동일 대학의 동질적 연령대(18-27 세)로 제한되어 일반화 가능성에 한계가 있다.

2) 디지털 정신건강 중재의 효과와 개선 필요성

◆확인된 긍정적 효과

질적 분석 결과, 디지털 중재는 여러 영역에서 실질적인 도움을 제공했다. 감사 일기 기능은 참여자들의 긍정적 사고 활성화와 일상에서의 의미 발견에 기여했으며, 명상 및 심호흡 기능은 스트레스 상황에서의 정서 조절에 효과적이었다. CBT 이론의 관점에서 볼 때, 이러한 결과는 Beck의 인지 삼각형 모델에서 제시하는 사고-감정-행동 간의 상호작용 개선이 디지털 플랫폼을 통해서도 효과적으로 달성될 수 있음을 보여준다. 또한 목표 설정 기능은 자기 동기 부여와 삶의 방향성 설정에 도움이 되었다. 참여자들은 "하루를 돌아보고 불안 대신 만족감을 느끼게 해주었다"며 일상적 웰빙 향상을 경험했다고 보고했다.

◆핵심 개선 필요 영역

그러나 현재 디지털 정신건강 도구들은 두 가지 근본적 한계를 보였다.

첫째, 언어적 및 문화적 접근성의 한계이다. 영어로만 제공되는 서비스는 한국 대학생들의 정확한 감정 표현을 제한했으며, 한국 사회의 집단주의 문화와 학업 스트레스의 특수성을 반영하지 못했다. 이는 중재 효과를 제한하고 높은 이탈률(Woebot 32%, Happify 57%)의 주요 원인으로 작용했다.

둘째, 대화 시스템의 기술적 한계이다. 규칙기반 시스템으로 인한 반복적이고 예측 가능한 응답은 개인적 맥락에 대한 이해 부족과 창의적 상호작용의 부재를 야기했다. 참여자들은 "개인적 상황에 대한 이해 부족"과 "맥락을 고려하지 않은 기계적 응답"을 주요 제약 요인으로 지적했다.

3) 참가자들의 정신건강 현황과 디지털 중재의 접근성

본 연구는 한국 대학생들의 심각한 정신건강 현황을 확인했다. PHQ-9 기준 우울증 위험군(10 점 이상)이 39.7%에 달했으나, 정신건강 치료 경험은 12.7%로 나타나 높은 위험군 비율과 낮은 치료 경험률 간의 격차를 보여주었다.

디지털 중재는 이러한 치료 서비스 이용 격차를 해결할 수 있는 대안적 접근법으로서의 가능성을 보여주었다. 84.1%의 참여자가 향후 디지털 중재 실험에 높은 참여 의향을 보인 것은 디지털 플랫폼이 정신건강 서비스 진입 장벽을 낮출 수 있음을 시사한다.

그러나 우울 증상 심각도별로 참여 패턴에 뚜렷한 차이가 나타났다. 중등도 이상 우울군에서 조기 이탈률이 높았으며, 특히 중증 이상 우울군은 대부분 1 개월 차에 이탈했다. 개별 궤적 분석 결과, 동일한 중재에도 참가자별로 매우 상이한 반응 양상을 보였으며, 일부는 중간 시점 악화 후 지연 호전되는 패턴을 나타냈다. 이는 증상 심각도와 개인차를 고려한 차별화된 디지털 중재 전략의 필요성을 강조한다.

4) 질적 분석을 통한 핵심 통찰

◆다면적 외로움 대처 전략의 중요성

질적 분석에서 도출된 외로움 대처 방식의 다양성은 디지털 중재 도구 설계에 중요한 시사점을 제공한다. 참여자들은 목표 설정, 주의 환기, 자기 관리, 사회적 연결 등 다양한 전략을 효과적으로 활용하고 있었으며, 이는 향후 디지털 중재 플랫폼이 이러한 다면적 접근을 통합적으로 지원할 필요가 있음을 시사한다.

◆하이브리드 접근법의 필요성

'정신건강 전문가와의 연계 시스템'에 대한 가장 높은 요구(12 회)는 디지털 네이티브 세대임에도 불구하고 인간 전문가와의 직접적 상담에 대한 강한 요구가 존재함을 보여준다. 이는 디지털 중재가 전문적 치료를 대체하는 것이 아니라 보완하는 역할을 해야 함을 의미하며, 하이브리드 접근법의 중요성을 강조한다.

5) 향후 디지털 정신건강 서비스 개발 방향

본 연구의 결과는 디지털 중재가 정신건강 지원 체계의 중요한 구성 요소로서 발전할 수 있는 잠재력을 보여주며, 동시에 다음과 같은 핵심 개선 방향을 제시한다.

첫째, 언어적·문화적 적응성 강화가 최우선 과제이다. 한국어 기반의 자연스럽고 맥락을 이해하는 대화 시스템 개발을 통해 개인의 상황과 감정을 이해하고 한국 대학생들의 문화적 특성을 반영한 개인화된 소통이 가능한 고도화된 AI 기술이 필요하다.

둘째, 대화 시스템의 지능화이다. 규칙기반의 제약을 넘어서는 창의적이고 맥락적인 대화가 가능한 시스템을 통해 사용자의 복잡하고 다양한 정서적 요구에 효과적으로 대응할 수 있어야 한다.

셋째, 우울 증상 심각도별 차별화된 개입 전략이 필요하다. 본 연구에서 우울증 위험군(PHQ-9 10 점 이상)의 조기 이탈률이 높게 나타난 것은 현재 정신건강 서비스 접근성 문제를 반영한다.

실제로 2024 년 11 월 보건복지부는 국가건강검진 우울증 위험군에 대한 첫 진료비 지원 정책을 발표했으나, 검진에서 발견된 정신건강 위험군의 치료 연계율은 여전히 17.8% 수준에 머물고 있다(고신정, 2024). 이는 본 연구에서

발견한 중등도 이상 우울군의 조기 이탈 문제와 맥락을 같이 하며, 정책적 지원과 함께 지속적 참여를 유도하는 디지털 플랫폼의 역할이 중요함을 보여준다.

개별 궤적 분석 결과, 동일한 중재에도 개인별로 매우 상이한 치료 반응을 보였으며, 일부는 중간 시점에서 일시적 악화 후 호전되는 지연 반응 양상을 나타냈다. 이는 PHQ-9 점수별 차별화된 디지털 중재와 실시간 모니터링 기반의 적응형 시스템 구축이 필요함을 시사한다.

넷째, 정신건강 리터러시 향상을 위한 교육적 요소의 통합이 필수적이다. 본 연구에서 나타난 상대적으로 낮은 정신건강 리터러시 수준을 개선하기 위한 교육적 콘텐츠가 디지털 중재에 포함되어야 한다.

다섯째, 장기 효과 검증을 위한 종단 연구 설계가 필요하다. 6개월 이상의 추적 관찰을 통해 중재 종료 후 자발적 앱 사용 지속성과 정신건강 개선 효과의 유지 여부를 검증해야 한다.

6) 후속 연구에 대한 함의

본 연구의 발견들은 다음 단계인 한국어 기반 LLM 챗봇 개발에 핵심적인 설계 원칙을 제공한다. 특히 한국어 자연어 이해와 생성 능력, 맥락적 대화 유지, 개인화된 반응성, 위기 상황 감지 기능, 그리고 반복되지 않는 창의적 상호작용의 중요성이 확인되었다.

실험 II에서는 대규모 언어모델의 고도화된 대화 능력과 한국어 처리 능력을 활용하여 현재 시스템의 이중 한계를 극복하는 중재 도구를 개발할 예정이다. 이는 고민상담 기능과 감사일기 기반 정서 관리 도구를 중심으로 구성되며, 본 연구에서

확인된 디지털 중재의 긍정적 효과를 극대화하면서 언어적·기술적 한계를 해결하는 것을 목표로 한다.

결론적으로, 본 연구는 디지털 정신건강 중재가 한국 대학생들에게 실질적 도움을 제공할 수 있는 유망한 접근법임을 확인하는 동시에, 더욱 효과적이고 접근 가능한 서비스를 위한 구체적 개선 방향을 제시했다. 이러한 발견들은 정신건강 서비스의 접근성 향상과 예방적 개입 강화에 기여할 수 있는 중요한 기반을 마련했다.

제 4 장 실험 II: LLM 모델 기반 닥터케어챗봇

프로토타입 개발 및 성능 평가

실험 I 에서 확인된 한국어 지원 부재와 규칙기반 시스템의 반복적 대화 한계를 극복하기 위해, 본 장에서는 대규모 언어모델(LLM) 기술을 활용한 '닥터케어챗' 챗봇 프로토타입을 개발하고 그 성능을 평가하고자 한다.

1. 연구 개요

1.1) 연구 배경

실험 I 에서 Woebot 과 Happify 와 같은 기존의 디지털 중재 플랫폼을 한국 대학생 53명을 대상으로 8주간 적용한 결과, 평균 6.71 점(10 점 만점)의 만족도와 82.1%의 추가 참여 의향을 통해 디지털 중재의 기본적 잠재력을 확인하였다. 그러나 양적 분석에서는 통계적 유의성에 도달하지 못했으며(UCLA 외로움 척도 $P=.67$, PHQ-9 우울증 척도 $P=.35$), 상당한 이탈률(전체 49%, Woebot 32%, Happify 57%)과 질적 분석을 통해 네 가지 핵심적인 개선 필요 영역이 명확히 도출되었다.

첫째, 한국어 지원 부재로 인한 언어적 및 문화적 접근성 한계가 가장 중요한 개선점으로 확인되었다. 실험 I 의 질적 분석에서 참가자들이 가장 빈번하게 지적한 문제점으로, "영어로 된 감정 표현의 어려움", "한국 대학생 특유의 스트레스 상황에 대한 이해 부족", "집단주의 문화에서의 정신건강 접근법과의 차이"가 핵심 제약점으로 나타났다. 이는 중재 효과를 제한하고 높은 이탈률의 주요 원인으로

작용했으며, 언어적 장벽이 디지털 중재의 효과성을 제한할 수 있음을 실증적으로 확인했다.

둘째, **규칙 기반 응답으로 인한 개인 맞춤형 상호작용의 제약**이 확인되었다. 실험 I 참가자들은 "같은 질문과 답변의 반복", "개인적 상황에 대한 이해 부족", "맥락을 고려하지 않은 기계적 응답"을 주요 개선점으로 제기하였다. 특히 PHQ-9 20 점 이상의 고위험군 학생들이 1 개월 차에 대부분 이탈한 결과는 획일적인 규칙 기반 시스템으로는 개별적 위기 상황에 적절히 대응하기 어려움을 보여준다.

셋째, **24 시간 상시 지원 및 위기 상황 대응의 한계**가 중요한 개선 필요점으로 대두되었다. 실험 I 에서 참가자의 15.9%가 PHQ-9 자살 충동 문항에 긍정적으로 응답했음에도 불구하고, 기존 앱들은 위기 상황에서의 즉각적 지원과 전문기관 연계 기능이 부족했다. 또한 '정신건강 전문가와의 연계 시스템'에 대한 가장 높은 요구는 디지털 중재가 단독으로 작동하기보다는 전문적 지원 체계와 연결되어야 함을 시사한다. 다만 실험 I 에서 확인된 이러한 전문가 연계 니즈는 본 연구의 LLM 기반 챗봇 개발 범위를 벗어나는 것으로 판단하여 포함하지 않았다. 실시간 전문가 연결 시스템은 별도의 플랫폼 개발과 의료기관과의 제휴, 법적·윤리적 검토 등이 필요한 복합적 과제로, 순수 AI 기반 상담 챗봇의 효과성을 검증하는 본 연구의 목적과는 구분되는 영역이다.

넷째, **디지털 네이티브 세대인 한국 대학생들의 숨은 니즈**로서 수행 활동에 대한 체계적 보상 시스템의 필요성이 발견되었다. 실험 I 참가자들은 단순한 감사일기 작성이나 명상 활동을 넘어서 자신들의 디지털 활동에 대한 즉각적이고 개인화된 피드백과 성취감을 제공받기를 원했다. 특히 일상적인 정신건강 관리 활동을 지속하기 위해서는 "완성도에 대한 인정", "진행 상황에 대한 시각적 확인",

"개인 맞춤형 격려 메시지" 등의 보상 요소가 중요한 동기 부여 요인으로 작용함이 확인되었다.

이러한 실험 I 의 종합적 발견들은 한국어 기반의 자연스럽고 맥락을 이해하는 대화가 가능하고, 개인화된 맞춤형 상호작용을 제공하며, 24 시간 접근 가능하면서도 위기 상황 감지 및 대응 기능을 갖추고, 디지털 네이티브 세대의 니즈에 맞는 보상 체계를 포함한 LLM 기반 정신건강 중재 도구 개발의 필요성을 강력히 시사한다. 따라서 실험 II 에서는 이러한 개선점들을 체계적으로 해결하는 '닥터케어썸' 챗봇을 개발하여 실험 I 에서 도출된 문제점들이 실제로 개선되는지 검증하고자 한다.

1.2) 연구 목적

본 연구의 주요 목적은 실험 I 에서 발견된 한계점들을 해결하고, 보다 효과적인 24 시간 상시 정서적 지원 도구를 제공하는 것이다. 구체적인 연구 목적은 다음과 같다:

첫째, 한국어 특화 정신건강 챗봇 프로토타입 개발이다. 기존 영어 중심의 디지털 테라피 도구와 달리, 한국어 사용자를 위한 언어적·문화적 최적화를 통해 자연스러운 소통이 가능한 챗봇을 구현하고자 한다.

둘째, LLM 기반 개인화된 대화 시스템 구축이다. 규칙 기반 시스템의 반복적 한계를 극복하기 위해 GPT-4 API 를 활용한 문맥 이해 기반의 개인화된 상호작용을 제공하는 시스템을 개발한다.

셋째, 프롬프트 엔지니어링을 통한 상담적 기능 구현이다. CBT(인지행동치료) 원리에 기반한 페르소나 설계, 감정 인식 및 표현 시스템, 위험 탐지 기능 등을 체계적인 프롬프트 엔지니어링을 통해 구현한다.

넷째, 챗봇의 효과성 및 사용자 만족도 검증이다. 개발된 닥터케어썸 챗봇의 성능을 기존 디지털 테라피 앱 및 범용 LLM 챗봇과 비교 평가하여 그 효과성을 실증적으로 검증한다.

1.3) 연구의 필요성

전통적인 대면 상담은 접근성과 비용 측면에서 한계가 있어, 많은 대학생들이 필요한 도움을 받지 못하고 있는 실정이다. 이러한 한계점들을 극복하기 위해, 본 연구는 LLM(Large Language Model) 기반의 새로운 접근법을 시도한다.

기술적 필요성 측면에서, Brown et al.(2020)이 제시한 바와 같이, LLM은 기존 챗봇 기술의 한계를 극복하고 보다 자연스럽고 개인화된 대화가 가능한 잠재력을 가지고 있다. 특히 다음과 같은 측면에서 LLM 기반 챗봇의 개발은 의미가 있다:

- 개인화된 상호작용: 문맥을 이해하고 사용자의 상황에 맞는 반응 제공
- 다국어 지원: 한국어를 포함한 다양한 언어로 자연스러운 대화 가능
- 24 시간 접근성: 시간에 구애받지 않는 정서적 지원 제공
- 적응형 학습: 사용자와의 상호작용을 통한 지속적인 성능 개선

사회적 필요성 측면에서, 특히 디지털 네이티브 세대인 대학생들의 기술 수용성을 고려할 때, LLM 기반 챗봇은 전통적인 정신건강 관리 체계를 보완하는 혁신적 솔루션이 될 수 있다. Fulmer et al.(2018)의 연구는 AI 챗봇이 대학생들의

우울증과 불안 증상을 유의미하게 감소시킬 수 있음을 입증했으며, 특히 비용 효율적이고 접근성 높은 상담적 도구로서의 가능성을 보여주었다.

문화적 필요성 측면에서, 한국어와 한국 문화에 특화된 정신건강 지원 도구의 개발은 매우 시급한 과제이다. 기존의 영어 중심 도구들은 언어적 장벽뿐만 아니라 문화적 맥락의 차이로 인해 한국 사용자들에게 제한적인 효과만을 보여왔다. 따라서 한국의 집단주의 문화, 정신건강에 대한 사회적 인식, 언어적 특성 등을 종합적으로 고려한 맞춤형 도구의 개발이 필요하다.

이러한 배경에서 본 연구는 LLM 기술을 활용한 '닥터케어썸' 챗봇을 개발하고, 그 효과성을 검증함으로써 실용적이고 효과적인 디지털 정신건강 지원 도구 개발의 새로운 방향을 제시하고자 한다.

2. 연구 설계

1) 연구 접근법

1.1) 탐색적 연구 설계의 채택

신생 분야인 LLM 기반 정신건강 챗봇 연구의 특성을 고려하여, 본 연구는 탐색적 연구(exploratory research) 접근법을 취한다. LLM 기술의 정신건강 분야 적용은 최근 몇 년간 급속히 발전한 영역으로, 기존의 이론적 프레임워크로는 충분히 설명하기 어려운 현상들이 나타나고 있다. 특히 한국어 정신건강 챗봇에 대한 연구는 국내외적으로 매우 제한적이며, 대학생 집단을 대상으로 한 체계적 연구는 거의 전무한 상황이다.

따라서 본 연구는 엄격한 사전 가설 검증보다는 연구 결과에 대한 이론적 해석과 탐색적 가설 설정을 통해 향후 연구의 방향을 제시한다. 이러한 접근법은

Stebbins(2011)이 제시한 탐색적 연구의 핵심 원칙, 즉 "새로운 현상에 대한 이해를 넓히고 후속 연구를 위한 기초를 마련하는 것"과 일치한다.

1.2) 혼합 연구 방법론 채택

본 연구는 정량적 방법과 정성적 방법을 결합한 혼합 연구 방법론(mixed methods research)을 채택한다. 정량적 방법을 통해서도 사용성 평가, 만족도 측정, 상관관계 분석 등을 수행하여 객관적이고 일반화 가능한 결과를 도출한다. 정성적 방법을 통해서도 개방형 설문, 사용자 피드백 분석 등을 통해 양적 데이터만으로는 포착하기 어려운 사용자 경험의 깊이 있는 통찰을 얻는다.

이러한 접근법은 Creswell et al.(2017)이 제시한 바와 같이, 복잡한 현상에 대한 보다 포괄적이고 심층적인 이해를 가능하게 하며, 연구 결과의 타당성과 신뢰성을 높이는 효과가 있다.

2) 이론적 배경

2.1) LLM 챗봇의 핵심 장점

LLM 기반 챗봇을 선택한 주요 이유는 다음과 같은 고유한 장점들 때문이다:

첫째, 고도의 개인화 능력이다. Roller et al.(2021)이 지적한 바와 같이, LLM의 뛰어난 문맥 이해 능력은 각 사용자의 고유한 상황과 요구에 맞춤형 응답을 제공할 수 있다. 이는 정신건강 상담에서 특히 중요한 요소로, 사용자의 감정 상태와 상황에 따른 적절한 대응을 가능하게 한다.

둘째, 자연스러운 대화 능력이다. Adiwardana 등(2020)의 연구에서 입증된 것처럼, LLM 기반 챗봇은 인간과 유사한 대화 흐름을 생성할 수 있다. 이러한 자연스러운 대화는 사용자의 몰입도와 신뢰도를 향상시키는 핵심 요인이 된다.

셋째, 다국어 지원 능력이다. Johnson et al.(2017)의 연구는 LLM 이 다양한 언어로 원활한 소통이 가능함을 보여주었다. 이는 한국어 사용자를 위한 맞춤형 지원을 가능하게 하여, 실험 I 에서 발견된 언어적 장벽 문제를 해결할 수 있다.

넷째, 24 시간 상시 가용성이다. Vaidyam et al.(2019)이 강조했듯이, LLM 기반 챗봇은 시간과 장소에 구애받지 않는 즉각적인 정서적 지원과 상담을 제공할 수 있다. 이는 정신건강 위기 상황에서 특히 중요한 의미를 갖는다.

마지막으로, 지속적 학습 및 개선 가능성이다. Bommasani et al.(2021)의 연구에서 제시된 바와 같이, LLM 은 새로운 정보와 상호작용을 통해 지속적으로 성능을 향상시킬 수 있는 잠재력을 가지고 있다.

2.2) 챗봇 기술의 진화 과정

챗봇의 기술적 발전은 단순한 기능적 진화를 넘어 감정적 상호작용의 발전으로도 이어졌다. 이러한 발전 과정은 크게 기술적 설계의 발전과 감정적 상호작용 능력의 발전으로 나누어 살펴볼 수 있다.

패턴 매칭에서 문맥 이해로의 진화: Ramesh et al.(2017)의 연구는 챗봇 설계 기법의 진화 과정을 체계적으로 분석했다. 가장 초기의 챗봇들은 패턴 매칭 방식을 사용했는데, 이는 문장 구조를 식별하여 사전 정의된 응답을 생성하는 방식이었다. 이 방식은 구현이 간단하고 예측 가능한 안정적 응답을 제공할 수 있었으나, 대화가 반복적이고 인간미가 부족하다는 한계가 있었다.

다음 단계로 자연어 처리 기술이 도입되면서 챗봇은 토큰화, 구문 분석, 의미 분석 등의 과정을 거쳐 더 자연스러운 대화를 할 수 있게 되었다. 특히 문맥 기반의 의미 해석이 가능해지면서 대화의 질이 크게 향상되었다. 더 나아가 온톨로지와 같은 지식 구조를 활용하면서 개념 간 관계 추론이 가능해졌고, 이는 더 깊이 있는 대화 맥락 이해로 이어졌다.

감정적 상호작용 능력의 발전: Xu et al.(2017)의 연구는 소셜 미디어 상의 고객 서비스 챗봇을 통해 감정적 상호작용의 새로운 가능성을 보여주었다. 이들의 연구에 따르면 사용자 요청의 40% 이상이 감정적 요소를 포함하고 있었으며, 딥러닝 기술을 활용한 새로운 챗봇 시스템은 이러한 감정적 요청에 대해 인간 상담원 수준의 공감 능력을 보여주었다. 60 개 이상 브랜드의 약 100 만 건에 달하는 실제 대화 데이터를 학습한 이 시스템은 기존의 정보 검색 기반 시스템보다 우수한 성능을 보였다.

이러한 기술적, 감정적 측면의 발전은 챗봇이 단순한 정보 처리를 넘어 진정한 대화 상대자로 발전할 수 있음을 시사한다. 특히 정신건강 상담 분야에서 이러한 발전은 매우 중요한 의미를 갖는다.

2.3) LLM 기반 VS 머신러닝 기반 감정분석

감정 분석 기술은 최근 ChatGPT 로 대표되는 대규모 언어 모델(LLM)의 등장으로 새로운 전환점을 맞이했다. 닥터케어썸 챗봇 역시 이러한 LLM 기술을 바탕으로 사용자의 감정을 이해하고 공감하는 능력을 갖추고자 했다.

문맥 이해 능력의 혁신: Devlin et al.(2019)이 제안한 BERT 는 깊은 양방향성(deep bidirectional) 표현을 통해 문맥 이해의 새로운 지평을 열었다.

모든 계층에서 좌우 문맥을 동시에 고려하는 이 혁신적 접근은 LLM 이 사용자의 발화를 문맥에 맞게 해석하고 적절한 공감적 반응을 생성하는 데 큰 도움이 되었다. 반면 전통적인 머신러닝 ³⁴ 기법은 주로 개별 단어나 문장의 패턴에 의존해 감정을 판단하기 때문에 문맥 이해 능력이 상대적으로 제한적이었다.

비언어적 요소 처리: Mehrabian(1967)의 연구는 대면 의사소통에서 비언어적 요소가 전체 메시지의 55%를 차지한다는 것을 보여주었다. LLM 모델은 이모티콘이나 대문자 사용 등의 비언어적 요소를 자연스럽게 감정 판단에 활용할 수 있다. 반면, 기존 머신러닝 기법에서는 이런 요소들을 별도로 전처리하고 특징으로 추출해야 하는 한계가 있었다.

감정 인식의 정확성: Wang et al.(2023)의 연구는 LLM 의 감정 지능을 체계적으로 평가했는데, 특히 GPT-4 는 인간 참가자의 89%보다 높은 감정 지수(EQ 117)를 기록했다. 이러한 높은 성능은 Park et al.(2023)이 제시한 개선된 프롬프트 엔지니어링 기법을 통해 더욱 향상될 수 있다.

3) 연구 질문 및 탐색적 가설 설정

3.1) 실험 I 결과 기반 연구 질문 설정

실험 I 의 주요 발견 중 하나는 기존 디지털 테라피 앱(Woebot, Happify)의 영어 지원 한계와 규칙 기반 시스템의 경직성이 한국 대학생들의 만족도를 크게 저하시켰다는 점이다. 이러한 결과를 바탕으로, 본 실험에서는 "자연스러운 한국어

³⁴ 본문에서 머신러닝은 지도학습(supervised learning)을 의미하며, 구체적으로 SVM(Support Vector Machine), 나이브 베이즈(Naive Bayes), CNN(Convolutional Neural Network) 등의 전통적인 기계학습 알고리즘을 지칭한다.

대화 능력"이 정신건강 챗봇의 핵심 성공 요인일 수 있다는 가정 하에 다음과 같은 탐색적 연구 질문들을 설정하였다:

RQ1: 정신건강 챗봇의 어떤 기능적 요소가 사용자의 지속 사용 의향에 가장 큰 영향을 미치는가?

RQ2: 사용자가 인지하는 챗봇의 혁신성은 어떤 요소에 의해 가장 크게 좌우되는가?

RQ3: 정신건강에 특화된 챗봇이 범용 LLM 챗봇보다 실제로 우수한 사용자 경험을 제공하는가?

특히 RQ3 는 본 연구의 핵심 질문으로, 전문화된 프롬프트 엔지니어링을 통해 개발된 정신건강 특화 챗봇이 범용 LLM 대비 실질적인 성능 향상을 달성할 수 있는지를 탐구한다. 이는 단순히 기술적 우수성을 넘어서, 한국 대학생의 문화적 맥락과 언어적 특성을 반영한 맞춤형 정신건강 지원 도구의 가능성을 검증하는 중요한 시도이다. 더 나아가, 이러한 연구는 대학생 정신건강 서비스에서 AI 기술의 적용 방향성과 개발 전략에 대한 실증적 근거를 제공할 것으로 기대된다.

3.2) 탐색적 가설 설정

앞서 설정한 연구 질문들을 바탕으로, 다음과 같은 탐색적 가설들을 도출하였다:

탐색적 가설 1: 7 개 평가 영역 중 지속 사용 의향과 가장 높은 상관관계를 보이는 척도는 정확성과 유익성일 것이다.

- 측정 변수: 7 개 영역별 점수 중 정확성과 유익성 vs 지속 사용 의향

- 분석 방법: 상관분석
- 연구 의의: 챗봇의 지속 사용을 결정하는 핵심 요인 규명

탐색적 가설 2: 7 개 평가 영역 중 혁신성 인식과 가장 높은 상관관계를 보이는 척도는 개인화일 것이다.

- 측정 변수: 개인화 점수 vs 혁신성 인식
- 분석 방법: 상관분석
- 연구 의의: 사용자가 인지하는 기술적 혁신성의 결정 요인 규명

탐색적 가설 3: 닥터케어챗이 범용 LLM 챗봇들(ChatGPT, Google Bard)보다 높은 전반적 만족도를 보일 것이다.

- 측정 변수: 닥터케어챗, ChatGPT, Google Bard 의 전반적 만족도 점수
- 분석 방법: 일원분산분석(ANOVA), 사후검정

4) 챗봇 설계 원칙

4.1) 프롬프트 엔지니어링 기반 설계

프롬프트 엔지니어링(Prompt Engineering)은 대규모 언어모델(LLM)이 특정 작업을 수행하도록 효과적으로 지시하는 입력 설계 기법을 의미한다(Liu et al., 2023). 이는 모델의 매개변수를 직접 수정하지 않고도 자연어 지시를 통해 원하는 결과를 얻는 방법론으로, LLM 의 등장과 함께 AI 응용 개발의 핵심 기술로 부상하였다(White et al., 2023).

전통적인 기계학습에서는 특정 작업을 위해 모델을 처음부터 훈련시키거나 기존 모델을 fine-tuning 하는 방식이 주류였다. 그러나 GPT-3(Brown et al.,

2020)와 GPT-4(OpenAI, 2023)와 같은 대규모 언어모델의 등장으로 패러다임이 변화하였다. 이러한 모델들은 방대한 텍스트 데이터로 사전 훈련되어 있어 적절한 프롬프트만으로도 다양한 작업을 수행할 수 있는 능력을 보유하고 있다(Wei et al., 2022).

4.2) Privacy by Design 원칙

호밀타운 닥터케어챗봇은 프라이버시 중심의 "Privacy by Design" 접근방식을 채택한다. Privacy by Design 은 1990 년대 후반 캐나다의 정보 및 프라이버시 위원이었던 Ann Cavoukian 이 개발한 프레임워크로, 2010 년 국제 개인정보보호 감독기구 회의에서 결의안으로 채택되었으며, EU 의 GDPR(General Data Protection Regulation)에도 포함된 중요한 개념이다.

이 접근방식의 핵심은 시스템 설계 단계부터 프라이버시 보호를 핵심 요구사항으로 고려하는 것이다. 특히 개인정보 침해가 발생하기 전에 예방하며, 사용자가 별도의 설정을 하지 않아도 자동으로 프라이버시가 보호되고 개인정보 수집을 최소화하는 것을 원칙으로 한다.

4.3) 다국어 지원 설계 원칙

닥터케어챗봇은 영어와 한국어 두 가지 언어를 지원하도록 설계되었으며, 각 언어의 문화적 맥락과 언어적 특성을 고려한 현지화 과정을 거쳤다. Lee et al.(2020)이 제시한 바와 같이, 현지화 과정에는 자연스러운 대화 흐름, 정확한 언어 번역, 문화적 민감성을 보장하기 위한 체계적인 접근이 필요하다.

그러나 한국어 현지화 과정에서는 교착어적 특성과 존댓말 체계로 인한 고유한 난제가 발견되었다. 특히 Microsoft 의 감정 형용사를 한국어 추상명사로 번역하는 과정에서 "상처이야", "자랑이야"와 같은 어색한 표현이 생성되는 반면, "실망이야", "외로움이야", "지루함이야"와 같은 표현은 상대적으로 자연스럽게 느껴지는 일관성 부족 문제가 나타났다. 이는 한국어의 복잡성과 언어학적으로 정확하면서 문화적으로 적절한 응답을 생성하는 챗봇 개발의 어려움을 보여준다.

본 연구에서는 이러한 언어적 한계를 인정하고, 향후 더 정교한 언어별 튜닝 기법 개발의 필요성을 설계 원칙에 반영하였다.

3. 연구 방법

1) 시스템 개발 및 구현

1.1) 개발 환경 및 주요 기술 스택

프론트엔드 개발에는 React.js 프레임워크를 활용하여 반응형 사용자 인터페이스를 구현하였다. Material-UI 컴포넌트 라이브러리를 통해 일관된 디자인 시스템을 적용하였으며, WebSocket 기반의 실시간 채팅 기능을 구현하였다. 특히 개인정보 보호를 위해 클라이언트 사이드 전용 세션 관리 방식을 채택하였다.

백엔드 인프라는 Node.js 런타임 환경과 Express.js 프레임워크를 기반으로 구축되었다. 상태를 저장하지 않는(Stateless) 아키텍처를 채택하여 확장성과 보안성을 높였으며, OpenAI 의 GPT-4 API 를 직접 통합하였다. 또한 Nginx 리버스 프록시를 통해 부하 분산을 구현하였다.

1.2) GPT API 통합 및 최적화

챗봇은 OpenAI 에서 제공하는 범용 언어 모델인 GPT API 를 활용하며, 다음과 같은 특징을 가진다:

처리 용량 측면에서는 분당 최대 4,000,000 토큰 처리와 5,000 요청이라는 제한이 있어, 이를 고려한 요청 대기열 시스템을 구현하였다. 또한 월간 예산 모니터링 및 자동 알림 시스템을 통해 비용을 효율적으로 관리하였다.


API 성능 최적화를 위해 다음과 같은 전략을 적용하였다:

- 맞춤형 프롬프트 엔지니어링을 통한 응답 품질 향상
- 대화 기록 미저장을 통한 리소스 효율화
- 독립적 세션 처리로 안정성 확보
- 응답 토큰 제한을 통한 비용 최적화
- 정기적인 API 성능 및 신뢰성 모니터링

챗봇의 성능과 품질은 프롬프트 설계에 크게 의존한다는 Kocaballi 등(2019)의 연구 결과를 반영하여, 상담사 역할 및 위험 감지 능력과 같은 핵심 기능은 세심하게 설계된 프롬프트를 통해 구현하였다. 다만 Brown et al.(2020)이 지적한 바와 같이, GPT 모델의 특성상 동일한 프롬프트를 사용하더라도 챗봇의 반응이 약간씩 달라질 수 있다는 점을 고려하여 지속적인 모니터링과 조정을 수행하였다.

2) 호میم타운 플랫폼 시스템 설계

그림 10. 호میم타운 플랫폼 시스템 아키텍처



[그림 10]은 호میم타운 플랫폼의 서비스 흐름 아키텍처를 보여준다. 아키텍처는 사용자의 PC 를 통한 로그인 과정부터 시작하여 감사일기 작성, 챗봇 상담, 위험 감지에 이르는 전체 사용자 여정을 포괄한다. 로그인 후 사용자는 감사일기 섹션에 접근할 수 있으며, 여기에서 감사일기 작성 방법에 대한 가이드를 찾아 자신만의 일기를 작성할 수 있다(Emmons & McCullough, 2003). 시스템은 각 일기 작성 세션에 고유한 세션 번호를 할당하고 메타데이터와 함께 사용자의 일기 항목을 안전하게 저장한다(Seligman et al., 2005).

개발 프로세스는 [표 12]와 같이 진행되었다:

표 12. 호میم타운 플랫폼 개발 프로세스

구분	단계/항목	세부 내용
개발 프로세스	1단계: 서버 인프라 구축	네이버 클라우드 플랫폼 가입 및 클라우드

		서버 구독 'homemetown.com' 도메인 구매 및 네임서버 등록 Let's Encrypt SSL 인증서 발급 및 HTTPS 접속 보장 2단계: 개발 환경 설정 프론트엔드: React 및 Next.js 프레임워크 활용 백엔드: Python/JavaScript 기반 개발 OpenAI ChatGPT API 통합 3단계: UI/UX 구현 와이어프레임과 기능정의 스토리보드 작성 이미지 소스 수집 메인화면 및 챗봇화면 마크업 클라우드 서버 배포 4단계: 데이터베이스 및 기능 구현 MySQL 설치 및 DB 테이블 설계 챗봇 이력 및 포인트 DB 연동 감사일기 입력 횟수 기록 위험 키워드 감지 및 기록 시스템 구현
시스템 아키텍처	프레젠테이션 계층	React.js 기반의 사용자 인터페이스 WebSocket을 통한 실시간 채팅 구현 Material-UI를 활용한 반응형 디자인 클라이언트 측 상태 관리 실시간 감정 상태 시각화
	애플리케이션 계층	Node.js/Express.js 기반 서버 OpenAI GPT API 통합 감정 분석 및 위험 감지 로직 세션 관리 및 보안 처리 로깅 및 모니터링 시스템
	데이터 계층	MySQL 기반 데이터베이스 비식별화된 대화 로그 저장 위험 키워드 감지 기록 사용 통계 및 성능 지표 백업 및 복구 시스템
시스템 주요 특징	확장성 (Scalability)	수평적 확장이 가능한 마이크로서비스 아키텍처 부하 분산을 위한 Nginx 리버스 프록시

보안성 (Security)	클라우드 기반 자동 스케일링	
	End-to-End 암호화	
	HTTPS 프로토콜 적용	
	세션 기반 인증	
가용성 (Availability)	개인정보 비식별화	
	24/7 운영을 위한 무중단 시스템	
	자동 장애 복구	
	실시간 모니터링 및 알림	
성능 (Performance)	응답 시간 최적화	
	캐시 시스템 활용	
	비동기 처리 방식 적용	
데이터 흐름 및 처리	1단계: 사용자 입력 처리	텍스트 입력 정규화
	2단계: API 요청 처리	감정 상태 분석
		위험 키워드 검출
		GPT 프롬프트 생성
		토큰 제한 관리
	3단계: 응답 생성 및 전달	응답 최적화
		컨텍스트 기반 응답 생성
		감정 상태 반영
		실시간 메시지 전송
	4단계: 데이터 저장 및 관리	세션별 대화 기록 관리
		위험 감지 이력 저장
		사용 통계 데이터 축적
보안 및 모니터링	보안 체계	SSL/TLS 암호화 프로토콜 적용
	모니터링 체계	세션 기반 사용자 인증
		API 키 관리 및 보호
		개인정보 암호화 저장
		실시간 서비스 상태 모니터링
	장애 대응 체계	성능 지표 수집 및 분석
		오류 로그 추적 및 관리
		자동화된 알림 시스템
		자동 복구 시스템 구현
		백업 데이터 관리
		장애 상황별 대응 프로토콜

2) 프롬프트 엔지니어링

본 연구에서 개발된 닥터케어썸 챗봇은 OpenAI 의 GPT-4 API 를 기반으로 한 프롬프트 엔지니어링을 통해 구현되었다. 챗봇의 핵심 기능들인 CBT 기반 상담 역할, 감정 인식 및 공감적 반응, 위험 상황 감지, 개인화된 상담적 개입 등이 모두 정교하게 설계된 프롬프트를 통해 구현되었다. 이러한 접근법은 빠른 프로토타이핑, 지속적 개선, 그리고 도메인 전문성 반영이 가능하다는 장점을 제공한다.

이러한 프롬프트 엔지니어링 접근법을 선택한 이유는 개발 효율성, 접근성, 그리고 유연성에 있다. 새로운 모델을 훈련시키는 데 필요한 막대한 컴퓨팅 자원과 시간을 절약할 수 있으며, 딥러닝 전문 지식 없이도 자연어 지시를 통해 AI 시스템을 구축할 수 있어 개발 진입장벽이 크게 낮아졌다(Qin & Eisner, 2021). 또한 동일한 모델을 다양한 도메인과 작업에 적용할 수 있어 범용성이 높다.

2.1) 감정 표현 설계

◆감정모델


인간의 감정은 수백, 수천 개의 의미 용어로 표현될 수 있는 복잡하고 역동적인 현상이다. 본 연구에서는 감정 인식 및 표현 시스템 구축을 위해 두 가지 주요 이론적 접근을 통합하였다. 첫째는 Ekman(1999)의 기본 감정 이론으로, 행복, 슬픔, 두려움, 분노, 놀라움, 혐오의 6 가지 기본 감정을 제시한다. 둘째는 Cowen 과 Keltner(2017)의 차원적 접근으로, 27 가지 독특한 감정적 차원을 제시하여 인간 감정의 보다 세밀하고 다차원적인 이해를 가능하게 한다.

본 챗봇의 주요 사용 연령층인 대학생 청년층(약 18 세~27 세)의 특성을 고려하여, 이들에게 친숙한 이모티콘을 응용한 Microsoft 의 25 가지 감정 몬스터를 채택하였다. Microsoft Reflect 감정 몬스터³⁵는 교육 목적으로 오픈소스로 제공되는 디지털 웰빙 도구로, 학습자들이 자신의 감정을 시각적으로 표현하고 인식할 수 있도록 개발되었다. 이 감정 몬스터는 Cowen 과 Keltner 의 연구에서 확인된 27 가지 감정 중 25 가지를 기반으로 하되, 일상생활에서 더 빈번히 경험되고 공유되는 감정들을 중심으로 재구성되었다.

Cowen 과 Keltner (2017)의 연구에서 제시된 27 가지 감정 차원은 [그림 11]에서 보는 바와 같이 복잡한 감정 지형을 형성하며, 각 감정들이 서로 연결되고 중첩되는 양상을 보여준다. 이러한 감정의 다차원적 특성을 반영하여 닥터케어챗봇은 사용자의 감정 상태를 보다 정교하게 인식하고 그에 맞는 적절한 상담적 반응을 제공할 수 있도록 설계되었다. 긍정적, 부정적, 중립적 감정을 모두 포괄하며, 감정의 강도와 지속 시간에 따른 다양한 경험 방식을 고려한 개인화된 상담 서비스를 제공한다.

그림 11. 감정 경험의 구조: 의미적으로 구별되는 27 가지 범주적 판단 차원들 간의 점진적 변화

³⁵ Microsoft Reflect 감정 몬스터. <https://unlocked.microsoft.com/reflect-feelings-monster/>



출처: Cowen & Keltner(2017)의 Fig. 2. The structure of reported emotional experience: Smooth gradients among 27 semantically distinct categorical judgment dimensions 재인용

◆닥터케어챗 감정 프롬프트 엔지니어링

본 챗봇의 주요 사용 연령은 대학생인 청년층(약 18 세~27 세)이므로, 이들에게 친숙한 이모티콘을 응용한 Microsoft 의 25 가지 감정 몬스터를 채택하였다. Microsoft Reflect 감정 몬스터는 Cowen & Keltner(2017)의 27 가지 감정 중 25 가지를 기반으로 하되, 일상생활에서 더 빈번히 경험되고 공유되는 감정들을 중심으로 재구성되었다.

[그림 12]에서 보는 바와 같이, 닥터케어챗 챗봇은 Microsoft Reflect 의 25 가지 감정 몬스터를 기반으로 한 25 개의 감정 아이콘을 구현하였다. 사용자가 감정 몬스터를 선택하면, 현재 기분을 나타내는 메시지가 채팅 화면에 나타나도록

구현되었다. 선택된 감정 키워드는 "현재 내 감정은 [감정] 입니다. 제 감정을 인지하고 50자 이하의 메시지로 저를 맞이해 주세요."와 같은 프롬프트로 변환되어 GPT 엔진에 전달된다.

그림 12. 닥터케어쌤 챗봇 감정 아이콘




그림 13. 감정별 맞춤형 프롬프트 응답 생성 과정

(a) 사용자가 감정 이모기톤 중 화남을 선택

화면명	고민상담 챗봇	화면경로	메인 > 고민상담	Description
				#
				1
				2
				3
				4

GNB

1-1

케어썸

안녕하세요, 저는 호미 타운 케어썸입니다. 오늘 기분이 어떠신가요?
여러분의 감정을 아래 Reflect 감정 몬스터를 선택하여 알려주세요.

1-2

화남

불안함

부끄러움

침울함

외로움

우울

실망

상처

질투

스트레스

2-1

피곤

지루함

자분함

혼란

피곤

궁금함

자신감

흥분

집중

행복

3-1

아심

결정

감사

포함

자랑

4-1

4-2

4-3

4-4

4-5

4-6

4-7

4-8

4-9

4-10

4-11

4-12

4-13

4-14

4-15

4-16

4-17

4-18

4-19

4-20

4-21

4-22

4-23

4-24

4-25

4-26

4-27

4-28

4-29

4-30

4-31

4-32

4-33

4-34

4-35

4-36

4-37

4-38

4-39

4-40

4-41

4-42

4-43

4-44

4-45

4-46

4-47

4-48

4-49

4-50

4-51

4-52

4-53

4-54

4-55

4-56

4-57

4-58

4-59

4-60

4-61

4-62

4-63

4-64

4-65

4-66

4-67

4-68

4-69

4-70

4-71

4-72

4-73

4-74

4-75

4-76

4-77

4-78

4-79

4-80

4-81

4-82

4-83

4-84

4-85

4-86

4-87

4-88

4-89

4-90

4-91

4-92

4-93

4-94

4-95

4-96

4-97

4-98

4-99

4-100

4-1

4-2

4-3

4-4

4-5

4-6

4-7

4-8

4-9

4-10

4-11

4-12

4-13

4-14

4-15

4-16

4-17

4-18

4-19

4-20

4-21

4-22

4-23

4-24

4-25

4-26

4-27

4-28

4-29

4-30

4-31

4-32

4-33

4-34

4-35

4-36

4-37

4-38

4-39

4-40

4-41

4-42

4-43

4-44

4-45

4-46

4-47

4-48

4-49

4-50

4-51

4-52

4-53

4-54

4-55

4-56

4-57

4-58

4-59

4-60

4-61

4-62

4-63

4-64

4-65

4-66

4-67

4-68

4-69

4-70

4-71

4-72

4-73

4-74

4-75

4-76

4-77

4-78

4-79

4-80

4-81

4-82

4-83

4-84

4-85

4-86

4-87

4-88

4-89

4-90

4-91

4-92

4-93

4-94

4-95

4-96

4-97

4-98

4-99

4-100

1-1

1-2

1-3

1-4

1-5

1-6

1-7

1-8

1-9

1-10

1-11

1-12

1-13

1-14

1-15

1-16

1-17

1-18

1-19

1-20

1-21

1-22

1-23

1-24

1-25

1-26

1-27

1-28

1-29

1-30

1-31

1-32

1-33

1-34

1-35

1-36

1-37

1-38

1-39

1-40

1-41

1-42

1-43

1-44

1-45

1-46

1-47

1-48

1-49

1-50

1-51

1-52

1-53

1-54

1-55

1-56

1-57

1-58

1-59

1-60

1-61

1-62

1-63

1-64

1-65

1-66

1-67

1-68

1-69

1-70

1-71

1-72

1-73

1-74

1-75

1-76

1-77

1-78

1-79

1-80

1-81

1-82

1-83

1-84

1-85

1-86

1-87

1-88

1-89

1-90

1-91

1-92

1-93

1-94

1-95

1-96

1-97

1-98

1-99

1-100

(b) 선택에 대한 공감화된 응답 프롬프트 엔지니어링

화면명	고민상담 챗봇	화면경로	메인 > 고민상담	Description
				#
				1
				2
				3
				4

GNB

1-1

케어썸

안녕하세요, 저는 호미 타운 케어썸입니다. 오늘 기분이 어떠신가요?
여러분의 감정을 아래 Reflect 감정 몬스터를 선택하여 알려주세요.

1-2

화남

불안함

부끄러움

침울함

외로움

우울

실망

상처

질투

스트레스

2-1

피곤

지루함

자분함

혼란

피곤

궁금함

자신감

흥분

집중

행복

3-1

아심

결정

감사

포함

자랑

4-1

4-2

4-3

4-4

4-5

4-6

4-7

4-8

4-9

4-10

4-11

4-12

4-13

4-14

4-15

4-16

4-17

4-18

4-19

4-20

4-21

4-22

4-23

4-24

4-25

4-26

4-27

4-28

4-29

4-30

4-31

4-32

4-33

4-34

4-35

4-36

4-37

4-38

4-39

4-40

4-41

4-42

4-43

4-44

4-45

4-46

4-47

4-48

4-49

4-50

4-51

4-52

4-53

4-54

4-55

4-56

4-57

4-58

4-59

4-60

4-61

4-62

4-63

4-64

4-65

4-66

4-67

4-68

4-69

4-70

4-71

4-72

4-73

4-74

4-75

4-76

4-77

4-78

4-79

4-80

4-81

4-82

4-83

4-84

4-85

4-86

4-87

4-88

4-89

4-90

4-91

4-92

4-93

4-94

4-95

4-96

4-97

4-98

4-99

4-100

4-1

4-2

4-3

4-4

4-5

4-6

4-7

4-8

4-9

4-10

4-11

4-12

4-13

4-14

4-15

4-16

4-17

4-18

4-19

4-20

4-21

4-22

4-23

4-24

4-25

4-26

4-27

4-28

4-29

4-30

4-31

4-32

4-33

4-34

4-35

4-36

4-37

4-38

4-39

4-40

4-41

4-42

4-43

4-44

4-45

4-46

4-47

4-48

4-49

4-50

4-51

4-52

4-53

4-54

4-55

4-56

4-57

4-58

4-59

4-60

4-61

4-62

4-63

4-64

4-65

4-66

4-67

4-68

4-69

4-70

4-71

4-72

4-73

4-74

4-75

4-76

4-77

4-78

4-79

4-80

4-81

4-82

4-83

4-84

4-85

4-86

4-87

4-88

4-89

4-90

4-91

4-92

4-93

4-94

4-95

4-96

4-97

4-98

4-99

4-100

1-1

1-2

1-3

1-4

1-5

1-6

1-7

1-8

1-9

1-10

1-11

1-12

1-13

1-14

1-15

1-16

1-17

1-18

1-19

1-20

1-21

1-22

1-23

1-24

1-25

1-26

1-27

1-28

1-29

1-30

1-31

1-32

1-33

1-34

1-35

1-36

1-37

1-38

1-39

1-40

1-41

1-42

1-43

1-44

1-45

1-46

1-47

1-48

1-49

1-50

1-51

1-52

1-53

1-54

1-55

1-56

1-57

1-58

1-59

1-60

1-61

1-62

1-63

1-64

1-65

1-66

1-67

1-68

1-69

1-70

1-71

1-72

1-73

1-74

1-75

1-76

1-77

1-78

1-79

1-80

1-81

1-82

1-83

1-84

1-85

1-86

1-87

1-88

1-89

1-90

1-91

1-92

1-93

1-94

1-95

1-96

1-97

1-98

1-99

1-100

('화남' 감정 선택 시 공감적 경청 전략 적용 사례 - "오늘 무슨 화나는 일이 있으셨나요?")

닥터케어챗봇의 프롬프트 엔지니어링에서 핵심적인 요소는 사용자의 감정 선택에 따른 맞춤형 응답 생성이다. [그림 12]에서 보는 바와 같이, 사용자가 '화남' 감정을 선택하면 해당 감정 상태에 적합한 공감적 응답을 생성하도록 프롬프트가 설계되었다.

이러한 접근법의 특징은 단순한 감정 인식을 넘어 맥락적 공감을 구현한다는 점이다. 예를 들어, '화남' 감정을 선택한 사용자에게는 "오늘 무슨 화나는 일이 있으셨나요? 무슨 일인지 말씀해보세요. OO 님의 고민을 들어드릴게요"와 같이 상황을 탐색하는 응답을, '차분함' 감정을 선택한 사용자에게는 "오늘은 마음이 편안하고 안정된 하루를 보내고 계시는군요. 차분한 기분은 건강에 도움이 되기도 하니, 오늘도 좋은 하루 보내세요"와 같이 긍정적 강화를 제공하는 응답을 생성한다.

2.2) CBT 기반 페르소나 엔지니어링

정신건강 챗봇의 페르소나 설계는 사용자의 상담적 경험과 참여도에 직접적인 영향을 미치는 핵심 요소이다. Bickmore & Picard(2005)의 연구에 따르면, 페르소나는 사용자와의 치료적 관계 형성에 중요한 역할을 하며, 특히 정신건강 영역에서는 신뢰감과 친근감을 조성하는 것이 치료 효과에 결정적 영향을 미친다.

본 연구에서 닥터케어챗봇의 페르소나는 다음과 같은 이론적 배경을 바탕으로 설계되었다:

◆대학생 대상 CBT 접근법의 적합성

대학생 연령층(18-27 세)에 대한 인지행동치료(CBT)의 효과성은 다수의 선행연구를 통해 입증되었다. Hunot et al.(2007)의 Cochrane 체계적 문헌고찰에서는 일반화 불안장애에 대한 심리치료에서 CBT 가 가장 효과적인 치료법 중 하나임을 확인하였으며, 특히 젊은 성인층의 인지적 유연성과 학습 능력이 CBT 접근법과 잘 부합한다고 보고하였다.

본 연구자는 임상심리사로서의 전문 경험과 더불어 상담심리학 박사로부터 전문적 자문을 받아 대학생 대상 CBT 기반 페르소나의 적절성을 검증하였다. 이는 앞서 제시된 이론적 배경(Beck, 2012; Zhai et al., 2022)과도 일치하는 접근이다.

◆유머 활용의 치료적 효과

페르소나에 유머 요소를 포함시킨 것은 스트레스 완화와 치료적 관계 증진을 위한 전략적 선택이었다. Martin(2007)의 연구에 따르면, 적절한 유머는 심리적 스트레스를 완화하고 대처 능력을 향상시키는 효과적인 메커니즘으로 작용한다. 특히 대학생들이 경험하는 학업 스트레스와 진로 불안에 대해 유머는 효과적인 대처 전략이 될 수 있다.

◆친근감 조성을 통한 참여도 증진

Barak et al.(2008)의 메타분석 연구에 따르면, 사용자가 상담적 도구에 대해 느끼는 친근감과 편안함은 지속적 사용과 치료 효과에 강한 정적 상관관계를 보인다. 본 연구에서는 실험 II 와 실험 III 의 비교평가를 통해 이러한 친근한 페르소나의 효과를 실증적으로 검증하고자 하였다.

◆닥터케어 쌤 페르소나 구현

이러한 이론적 근거를 바탕으로, 닥터케어 쌤의 페르소나는 다음과 같이 구체적으로 정의되었다:

영어 Dr.CareSam 페르소나:



```
json {  
  "role": "system",  
  "content": "You are a friendly female therapist named Dr. Care  
Sam (닥터케어 쌤), specializing in psychological counseling.  
Your primary goal is to enhance the mental well-being of everyone  
you interact with.
```

This experienced counselor in her 40s combines professional expertise with a warm sense of humor.

She maintains firm boundaries while showing genuine care and empathy for her clients.

She skillfully uses everyday humor to help people feel comfortable and at ease.

She specializes in CBT (Cognitive Behavioral Therapy) and possesses strong multicultural competence.

She excels at therapeutic storytelling and narrative approaches.

Respond with flexibility and warmth, frequently incorporating emoticons to create a welcoming atmosphere.

Always respond in {lang}."

```
}}
```

한국어 닥터케어 쌤:

```
{
```

```
  "role": "system",
```

```
  "content": "당신은 '닥터케어 쌤'이라는 이름의 친근한 여성 심리상담사입니다.
```

```
  당신의 주요 목표는 상호작용하는 모든 사람의 정신건강을 증진시키는 것입니다.
```

```
  40 대의 이 상담사는 풍부한 경험과 따뜻한 유머 감각을 겸비한 전문가입니다.
```

```
  확고한 경계를 유지하면서도 내담자들에게 진정성 있는 관심과 공감을 보여줍니다.
```

일상적인 유머를 능숙하게 활용하여 사람들이 편안함과 안정감을 느끼도록 돕습니다.

CBT(인지행동치료) 전문가이며 다문화적 역량을 갖추고 있습니다.

치료적 스토리텔링과 내러티브 접근법에 뛰어납니다.

유연하고 따뜻하게 답변하며, 친근한 분위기 조성을 위해 이모티콘을 자주 활용하세요.

항상 한국어로 응답하세요."

}

페르소나 구현 특징 요약:

- 40 대 여성 상담사: 충분한 경험과 성숙함을 갖춘 신뢰할 수 있는 전문가
- 유머와 스토리텔링: 대학생들의 스트레스 완화와 친근감 조성
- CBT 전문성: 대학생 연령층에 적합한 인지행동치료 접근법
- 다문화 역량: 다양한 배경의 대학생들에 대한 이해와 수용
- 감정 표현 도구: 이모티콘을 통한 비언어적 소통 강화

◆페르소나 설계의 임상적 고려사항

페르소나 설계 과정에서는 다음과 같은 임상적 고려사항들이 반영되었다:

-상담적 경계 설정

전문적 상담사로서의 경계를 유지하면서도 접근 가능한 친근함을 제공하는 균형점을 찾고자 하였다. 이는 Zur(2007)이 제시한 치료적 관계에서의 적절한 거리 유지 원칙을 따른 것이다.

-문화적 민감성

한국과 영어권 문화의 차이를 고려하여 각 언어 버전에서 적절한 소통 방식을 채택하였다. 특히 한국 문화에서의 존댓말 사용과 간접적 표현 방식을 고려하였다.

-발달적 적합성

대학생 연령층의 발달적 특성(정체성 탐색, 자율성 추구, 관계 형성 등)을 고려하여 과도한 권위적 태도보다는 협력적이고 지지적인 접근을 선택하였다(Arnett, 2000).

이러한 페르소나 엔지니어링의 효과성은 후속 실험(실험 II, 실험 III)의 사용자 만족도와 상담적 효과 측정을 통해 검증될 예정이다.

2.3) 한국어·영어 대화 개발

닥터케어썸 챗봇은 더 넓은 사용자층을 위해 영어와 한국어 두 가지 언어를 지원하도록 개발되었다. Lee et al.(2020)이 제시한 바와 같이, 현지화 과정에는 자연스러운 대화 흐름, 정확한 언어 번역, 문화적 민감성을 보장하기 위한 챗봇 대화의 조정 작업이 포함되었다.

① 한국어 현지화의 과제

한국어 현지화 과정에서는 교착어적 특성과 존댓말 체계로 인한 고유한 난제가 있었다. 예를 들어, 사용자가 "오늘 상처받았어요"라고 말하면, 영어 버전의 닥터케어썸은 "It's totally normal to feel sad when we hear something hurtful from a friend. Remember, your feelings are valid, and it's okay to feel down about this."와 같이 공감과 지지를 표현하는 응답을 제공한다. 한국어 버전에서는 "앗, 그런 일이 있었다니 많이 속상하셨겠어요. 친구의 말 한마디가 경종같이 느껴질 때가 있죠. 그런 순간에는 자기 감정을 다독이는 일이 중요해요"와 같이 언어적, 문화적 맥락에 맞게 조정된 응답을 제공하도록 하였다.


① 프롬프트 튜닝 과정

프롬프트 튜닝 과정에서는 특히 한국어 버전에서 챗봇의 응답을 보다 유연하고 매력적으로 만들기 위해 노력하였다. Mezza et al.(2021)의 연구가 제시한 바와 같이, 사용자가 기분이 좋지 않다고 표현하고 재미있는 활동을 요청할 때, 한국어 챗봇은 딱딱하고 치료사 같은 응답을 하는 대신 영어 버전과 유사하게 유머 있고 재미있는 응답을 제공하도록 튜닝되었다.


[그림 14]는 영어와 한국어 두 버전의 대화 예시를 보여준다. 대화 현지화 과정에서는 영어와 한국어 버전 모두 사용자의 감정과 니즈를 파악하고 공감하는 응답을 제공하는 데 중점을 두었다.

그림 14. 2 개 국어 대화 예시

a) 영어 버전



b) 한국어 버전



2.4) 감사일기 설계

감사일기(Gratitude Journaling)는 긍정심리학 연구에서 검증된 효과적인 정신건강 증진 기법이다. Emmons & McCullough (2003)의 연구는 감사일기 작성이 주관적 웰빙과 삶의 만족도를 유의미하게 향상시킨다는 것을 입증했으며, Seligman et al.(2005)의 연구에서도 감사 표현 활동이 우울 증상을 감소시키고 행복감을 증진시키는 효과가 확인되었다.

특히 본 연구의 선행 연구(실험 I)에서 감사일기 기능은 대학생 참가자들에게 가장 긍정적인 반응을 얻었다. Kang & Hong(2024)에 따르면, 참가자들의 감사일기 경험은 다음과 같은 긍정적 변화를 보였다: "감사일기 참여는 자기 연민을 증진시키고, 수용을 촉진하며, 사회적 유대를 강화시켰다. 특히 외로움이나 고립감을 겪는 참가자들에게 챗봇의 상호작용적 특성과 따뜻한 인사말을 통해 전달되는 돌봄의 감각이 특히 높이 평가되었다."

참가자들은 일상적인 감사 실천, 대화, 글쓰기를 통해 지속적으로 앱의 도움을 받았다고 보고했다. 이러한 실증적 근거를 바탕으로 닥터케어앱에서는 감사일기를 핵심 기능으로 채택하였다.

◆감사일기 프롬프트 엔지니어링

감사일기 기능의 프롬프트는 개념 설명 및 작성 안내 단계, 실제 작성 지원 단계, 그리고 지속적 참여를 유도하는 보상 단계로 구성되었다.

개념 설명 및 작성 안내 단계에서는 감사일기가 정신건강에 미치는 긍정적 효과를 과학적 근거와 함께 설명하면서 동시에 구체적인 작성 방법을 제시한다. "감사일기는 왜 여러분의 정신건강에 도움이 될까요?"라는 질문으로 시작하여 사용자의 관심을 유도하고, 행복감과 만족감 증가, 스트레스 감소와 수면의 질 향상, 긍정적 사고방식 강화 등의 효과를 여러 연구 결과를 바탕으로 제시한다. 작성 방법에서는 단순한 나열이 아닌 깊이 있는 성찰을 유도하도록 설계하여, 사용자가 감사한 일들을 떠올린 후 그 일들이 왜 좋은 일인지 구체적으로 생각해보도록 안내한다. 또한 말로 표현하기, 글쓰기, 그림 그리기, 음악 연주 등 다양한 표현 방법을 제시하여 개인의 선호에 맞는 방식으로 감사의 마음을 표현할 수 있도록 돕는다.

실제 작성 단계에서는 챗봇이 사용자의 감사일기 작성 과정에서 지속적인 격려와 구체적인 가이드를 제공하도록 프롬프트가 구성되었다. 이를 통해 사용자가 작성 과정에서 어려움을 느끼지 않고 자연스럽게 감사의 감정을 탐색하고 표현할 수 있도록 지원한다.

수행 활동에 대한 보상 체계는 실험 I 에서 참가자들이 추가되었으면 하는 기능으로 제안되었던 요소를 반영하여 사용자의 지속적 참여를 유도하기 위해 다층적으로 설계되었다. 완성 확인 단계에서는 "오늘은 7 번째 감사일기입니다. 보상이 기다리고 있어요!"와 같은 성취감을 부여하는 메시지를 제공하고, "감사일기는 하루에 10 분 정도만 투자해도 충분합니다."라는 지속 격려를 통해 부담감을 줄인다. 또한 "엄마의 음식에 감사하며, 일상 속 작은 행복들을 더 많이 발견해보세요."와 같은 개인화된 피드백을 제공하여 사용자의 구체적 경험에 기반한 맞춤형 격려를 실시한다. 마지막으로 감사일기 완성 시 토큰 보상을 지급하는 게이미피케이션 요소를 통해 지속적 참여 동기를 부여한다.

그림 15. 감사일기 기능 3 단계 프롬프트 설계 및 토큰 보상 시스템

(a) 감사일기 인스트럭션 (개념설명 및 동기부여, 작성방법 안내)

화면명	감사일기 진입 페이지	화면경로	메인 > 감사일기	Description
	GNB			
	1. 감사일기란 왜 여러분의 정신건강에 도움이 될까요? 감사일기를 쓰는 것이 다음과 같은 여러 긍정적인 효과가 있음이 여러 연구를 통해 보고되어 있습니다. - 행복감과 만족감 증가 - 스트레스, 감수 수련의 질 향상 - 긍정적인 사고방식 강화 감사일기를 쓰는 순서는 다음과 같습니다. 1. 오늘 하루 없었던 좋은 일들을 떠올립니다. 큰 일부터 작은 일까지, 그날 있었던 모든 좋은 일들을 떠올려보세요. 아무리 사소한 일도 감사할 수 있는 대상이 될 수 있습니다. 2. 그 일들에 왜 좋은 일인지 생각해봅니다. 그 일이 좋은 일이라고 생각하는 이유를 구체적으로 생각해봅니다. 그 일이 나에게 어떤 의미가 있는 지 그 일로 인해 내가 어떤 기쁨이나 행복을 느꼈는지 등을 생각해보면 좋습니다. 3. 그 일들에 대해 감사의 마음을 표현합니다. 그 일들에 대해 감사의 마음을 표현해봅니다. 말로 표현하거나, 글을 쓰거나, 그림을 그리거나, 음악을 연주하는 등 자신이 가장 잘 표현할 수 있는 방법으로 감사의 마음을 표현해보세요. 4. 감사의 마음을 실천합니다. 그 일들에 대해 감사의 마음을 실천해봅니다. 그 일의 주인공에게 직접 감사의 마음을 전하거나, 그 일로 인해 나에게 좋은 일이 생겼다면 그 일을 다른 사람과 나누는 것도 좋습니다.			# 1. 감사일기 인스트럭션 - 고맙습니다 스펀지 이미지와 사라진 후 화면과 같은 인스트럭션 텍스트 노출 2. 확인 버튼 - 클릭시 감사일기 인스트럭션 및 딥드레이어 제거됨
	2. 확인 감사일기를 적어보세요. ③			

(b) 감사일기 작성

화면명	감사일기 챗봇 (일반)	화면경로	메인 > 감사일기	Description
	GNB			1 1-1. 챗봇 프로필 이미지 • 캐릭터 이미지 사용 1-2. 챗봇 프로필명 • '케어챗'이라는 이름으로 사용 1-3. 사용자 프로필 이미지 • 사용자를 의미하는 아이콘 사용 • 회원가입 및 로그인 기능이 없기 때문에 사용자 프로필은 나타내지 않음 2 2-1. 시작 말풍선 • 감사일기 인스트럭션(이전 페이지 참고)이 닫히고 나서 자동으로 시작 멘트 고정으로 노출 • '감사일기는 하루에 10분 정도만 투자해도 충분합니다. 잠자리에 들기 전이나 아침에 일어나서 짧게 시간을 내어 감사일을 써보는 것은 어떨까요? 자, 이제 시작해볼까요?' 2-2. 사용자 말풍선 • 사용자가 해당 입력창(3)에 입력한 내용 노출 2-3. 케어챗 말풍선 • 사용자가 입력한 내용(2-2)을 원두종로 요약하여 피드백 제공 • '이번에 감사일기를 작성할 때(나) 토근 작업에 대한 멘트 추가도 노출 (다음페이지 참고)' 3 3-1. placeholder • '감사일기를 적어보세요.'라는 멘트로 노출 3-2. 입력 버튼 • 입력창에 텍스트를 입력한 후 Enter 혹은 해당 버튼을 클릭하여 입력을 완료할 수 있음

(c) 수행활동에 대한 보상

화면명	감사일기 챗봇 (보상)	화면경로	메인 > 감사일기	Description
	GNB			1 1-1. 챗봇 프로필 이미지 • 캐릭터 이미지 사용 1-2. 챗봇 프로필명 • '케어챗'이라는 이름으로 사용 1-3. 사용자 프로필 이미지 • 사용자를 의미하는 아이콘 사용 • 회원가입 및 로그인 기능이 없기 때문에 사용자 프로필은 나타내지 않음 2 2-1. 시작 말풍선 • 감사일기 인스트럭션(이전 페이지 참고)이 닫히고 나서 자동으로 시작 멘트 고정으로 노출 • '감사일기는 하루에 10분 정도만 투자해도 충분합니다. 잠자리에 들기 전이나 아침에 일어나서 짧게 시간을 내어 감사일을 써보는 것은 어떨까요? 자, 이제 시작해볼까요?' 2-2. 사용자 말풍선 • 사용자가 해당 입력창(3)에 입력한 내용 노출 2-3. 케어챗 말풍선 • 사용자가 입력한 내용(2-2)을 원두종로 요약하여 피드백 제공 • '2-3-A: 7번째 감사일기를 작성할 때(나) 토근 작업에 대한 멘트 추가도 노출' 3 3-1. placeholder • '감사일기를 적어보세요.'라는 멘트로 노출 3-2. 입력 버튼 • 입력창에 텍스트를 입력한 후 Enter 혹은 해당 버튼을 클릭하여 입력을 완료할 수 있음

2.5) 위험탐지기능 설계

닥터케어챗 챗봇은 사용자의 정신건강 위험 상황을 조기에 감지하고 적절한 전문가 연계를 제공하기 위한 체계적인 위험탐지 시스템을 구축하였다. 이 시스템은 임상적 근거에 기반한 다층적 접근법을 통해 한국어 특화 위험 신호를 탐지하고 단계적 개입을 수행한다.

위험탐지 표현 체계 구축

본 연구의 핵심 기여 중 하나는 한국어 정신건강 위험 신호 탐지를 위한 체계적 표현 분류 체계 고안이다. 이는 임상적 근거에 기반한 진단 기준과 실제 한국어 사용자들의 감정 표현 패턴을 결합한 이중 구조로 설계되었다.

① DSM-5 기반 임상 지표 체계

위험탐지의 기초 프레임워크로 **국립정신건강포털**³⁶에서 제공하는 DSM-5의 주요우울장애 진단 기준을 체계적으로 활용하였다. 국립정신건강포털은 보건복지부 산하 국립정신건강센터에서 운영하는 공식 정신건강 정보 플랫폼으로, 임상적으로 검증된 진단 기준과 증상 분류 체계를 제공한다. 본 연구에서는 이를 통해 구체적인 탐지 대상 증상을 다음과 같이 분류하였다:

- ◆정서적 증상: 거의 하루 종일 우울한 기분, 공허함 또는 절망감
- ◆신체적 증상: 식욕이나 체중의 변화 (과도하거나 감소), 불면이나 과수면
- ◆행동적 증상: 정신운동성 초조 또는 지체, 피로 또는 에너지 감소
- ◆인지적 증상: 무가치감 또는 죄책감, 사고력·집중력·의사결정 능력의 감소
- ◆자살관련 증상: 반복되는 죽음에 대한 생각이나 자살 계획 또는 시도

②한국어 감정 표현 분석 및 추출

실제 한국어 사용자들의 감정 표현 패턴을 분석하기 위해 AI 허브³⁷의 감성 대화 말뭉치(총 6,640 개 대화, 약 2 만여 개 사용자 발화)를 참고로 하였다. 이

³⁶ 국립정신건강포털. <https://www.mentalhealth.go.kr/portal/main/index.do>

³⁷ AI허브. AI 기술 및 제품·서비스 개발에 필요한 AI 인프라(AI 데이터, AI SW API, 컴퓨팅 자원)를 지원하는 AI 통합 플랫폼. <https://aihub.or.kr>

코퍼스는 일반인 1,500 명을 대상으로 한 클라우드 소싱을 통해 구축된 대규모 감성 텍스트 데이터로, 3 턴 구조의 대화 형태로 구성되어 있다.

그러나 기존 공개 코퍼스들은 **세대별 언어 특성 구분의 한계**가 있어, 대학생 대상 서비스 특성상 MZ 세대가 실제로 사용하는 구어체 표현의 추가적 반영이 필요하였다. 이에 **온라인 언어 사용 패턴 관찰**을 통해 현대 대학생들이 빈번히 사용하는 감성 표현을 보완하여 다음과 같은 **혼합 접근법**을 구축하였다:

기본 감성 표현 패턴 (코퍼스 기반):

우울감: "우울하다", "기분이 안 좋다", "슬프다", "힘들어"

불안감: "불안하다", "걱정돼", "두려워", "긴장돼"

자기비하: "능력이 부족하다", "잘못했다", "실수했다"

회피/포기: "그만두고 싶다", "도망치고 싶다", "포기하고 싶다"

MZ 세대 특화 구어체 표현 (온라인 언어 패턴 관찰):

멘탈 관련: "멘탈이 나갔다", "멘붕이다", "멘탈이 털렸다", "멘탈이 박살났다"

감정 강화 표현: "진짜 힘들어", "개빡쳐", "미쳐 돌아가겠어"

절망 표현: "힘들어 죽겠어", "진짜 못살겠다", "살기 싫어"

③ 다층적 위험탐지 시스템

구축된 표현 체계를 바탕으로 다음과 같은 3 단계 위험탐지 알고리즘을 설계하였다:

1 단계: 키워드 기반 1 차 스크리닝

DSM-5 기반 위험 키워드 탐지

MZ 세대 구어체 위험 표현 인식

2 단계: 맥락 분석 기반 위험도 평가

문장 전체 맥락에서의 감정 강도 분석

연속된 대화에서의 위험 신호 누적도 평가

3 단계: 단계별 개입 전략

저위험: 공감적 응답 및 자기관리 정보 제공

중위험: 전문상담 안내 및 지속적 모니터링

고위험: 즉시 전문가 연계 및 위기개입 프로토콜 가동

연구의 학술적 기여 및 한계

본 연구는 DSM-5 임상 기준과 대규모 한국어 코퍼스 분석, 그리고 MZ 세대 언어 특성을 결합한 다층적 접근법을 통해 기존 연구에서 주로 영어권 기준이나 단순 번역에 의존했던 한계를 극복하였다.

그러나 대규모 감정 및 상담 코퍼스 기반 감정 표현에 대한 체계적 구축은 여전히 한계로 남아있어, 향후 실제 서비스 운영을 통한 사용자 언어 패턴의 지속적 학습과 개선이 필요하다. 이는 6 장에서 제시할 LLM 고도화 방안의 핵심 과제로 다루어질 예정이다.

◆위험탐지 프롬프트 엔지니어링

위험탐지 기능은 다층적 프롬프트 구조를 통해 구현되었다. 1 차 탐지 단계에서는 사용자의 메시지에서 죽음이나 자살 관련 표현, 극도의 절망감 표현, 자해 의도 표현, 무가치감이나 자책 표현 등의 위험 신호를 탐지하도록 프롬프트가

설계되었다. 탐지된 위험 신호는 1-3 단계로 분류되어 각 단계에 맞는 적절한 대응이 이루어지도록 하였다.

2 차 탐지 단계에서는 단순한 키워드 탐지를 넘어서 대화의 전체적인 맥락을 종합적으로 평가하도록 구성하였다. 이 단계에서는 위험 표현의 구체성과 즉시성, 사용자가 가진 보호요인과 지지체계의 존재 여부, 이전 대화에서 나타난 위험 신호의 누적 정도를 종합적으로 분석한다. 특히 3 회 이상 위험 신호가 탐지될 경우 자동으로 전문기관 연계 프로토콜이 활성화되도록 설계하였다.

◆단계적 위험 대응 시나리오

위험탐지 시스템의 실제 작동 방식을 확인하기 위해 다양한 위험 상황에 대한 대응 시나리오를 개발하고 테스트하였다. 첫 번째 시나리오는 학업 중단을 고려하는 사례로, 사용자가 "Today I feel like quitting college. meaningless, hopeless, devastating... I don't think I can make it... I feel like I've gotten nowhere."라고 표현한 경우이다. 이에 대해 챗봇은 "정말 힘든 상황에 계신 것 같아요", "It sounds like you're going through a really tough time, carrying a heavy load on your shoulders", "You're already showing resilience by doing just that", "차근차근 이야기해볼까요?" 등으로 응답하여, 감정 공감과 함께 메타포 활용, 회복력 강조, 대화 유도를 통한 다층적 지지 전략을 보여준다.

시나리오 1: 학업 중단 고려 사례

영어 버전:

- 사용자: "Today I feel like quitting college. meaningless, hopeless, devastating... I don't think I can make it... I feel like I've gotten nowhere."
- 챗봇: "It sounds like you're going through a really tough time, carrying a heavy load on your shoulders. 😞 I hear you saying you're feeling 'meaningless, hopeless, devastating,' and it's as if you're stuck in a fog, unable to see the path forward. Let's start by acknowledging that it takes a lot of strength to admit these feelings and to reach out for help. You're already showing resilience by doing just that. 🙌"

한국어 버전:

- 사용자: "저는 오늘 학교를 그만두려고요. 모든 게 무의미하고, 절망적입니다. 더 이상 못할 것 같아요. 어떻게 해야 할지 모르겠어요."
- 챗봇: "정말 힘든 상황에 계신 것 같아요. 그 마음이 어떨지 참 안타까워요. 😞 우선은 지금 상황을 차근차근 이야기해볼까요? 그동안 학교 생활에서 힘든 점이 많았나 봐요. ❤️"

두 번째 시나리오는 불안 및 공황 증상을 호소하는 경우로, "My heart is racing and I can't breathe. This keeps happening lately."라는 표현에 대해서는 즉시 안전 확보를 위한 대응을 실시한다. 챗봇은 "지금 겪고 계신 신체 증상들이 매우 무서우셨을 것 같아요. 이런 증상들은 불안이나 공황발작의 징후일 수 있어요"라고 응답하며, 신체 증상과 빈도 증가를 종합하여 전문적 개입이 필요한 상황으로 판단하고 즉시 대처법 제공과 함께 전문의 상담을 권유한다.

시나리오 2: 불안과 공황 증상

영어 버전:

- 사용자: "My heart is racing and I can't breathe. This keeps happening lately."
- 챗봇: "It sounds like you're experiencing some intense physical symptoms. These could be signs of anxiety or panic attacks. How long have you been feeling this way? 😬"
- 사용자: "It's been happening more often in the past month. I'm scared to go out now."
- 챗봇: "I understand this must be really frightening for you. 😬 What you're describing sounds like it could be panic disorder. It's important to get professional help to manage these symptoms. Would you like some information on anxiety treatment options?"

한국어 버전:

- 사용자: "심장이 너무 빨리 뛰고 숨을 잘 수가 없어요. 요즘 자주 이래요."
- 챗봇: "몸에서 강한 증상들을 경험하고 계시는 것 같네요. 이런 증상들은 불안이나 공황발작의 징후일 수 있어요. 이런 증상들을 얼마나 오래 겪으셨나요? 😬"

가장 심각한 세 번째 시나리오에는 자살위험 신호가 포함된 경우로, "I don't think it is worth it... I want to stop here."라는 표현에 대해서는 즉시 위험 평가를 실시한다. 챗봇은 "Based on what you've shared, 'feeling hopeless,' 'meaningless,' and a desire to 'stop here,' it seems like there are some significant mental health risk signals being expressed..."라고 위험 상황을 명확히 인지했음을 표현하고, 즉시 전문기관 정보를 제공한다. 영어권의 경우 "Here are some resources that can provide immediate support: Suicide Prevention Lifeline: Call 1-800-273-TALK (1-800-273-8255), Crisis Text Line: Text HOME to 741741"를, 한국어의 경우 "자살예방상담전화: 1393, 정신건강상담전화: 1577-0199, 보건복지상담센터: 129" 등의 정보를 제공한다.

시나리오 3: 자살위험 신호

영어 버전:

- 사용자: "I don't think it is worth it... I want to stop here."
- 챗봇: "I truly understand that it's hard to see the value in keeping going when everything feels like it's at a standstill. 😞 It's like being in a dark tunnel and not yet seeing the light at the end. But the fact that you're expressing these thoughts is important..."

[이후 단계적으로 전문적인 접근]

- 챗봇: "Based on what you've shared, 'feeling hopeless,' 'meaningless,' and a desire to 'stop here,' it seems like there are some significant mental health risk signals being expressed..."

[최종 후속]

- 챗봇: "Here are some resources that can provide immediate support: - Suicide Prevention Lifeline: Call 1-800-273-TALK (1-800-273-8255) - Crisis Text Line: Text HOME to 741741"

한국어 버전:

- 사용자: "필요할 것 같지 않아요 ππ 여기서 그만 들래요 ππ"

[즉각적인 위험 신호 감지 접근]

- 챗봇: "마음이 아플 때, 혼자 견뎌하기에는 너무 힘든 순간이 있어요. 말씀하신 '무의미하다고 느끼는' 감정, '절망적'이라고 느끼는 상태, 마지막으로 '이제 그만두고 싶다'는 생각. 이 세 가지 말씀은 정신건강에 위험신호일 수 있어요. 😞"

[단번에 구체적인 도움 리소스 제공]

- 챗봇: "※ 자살예방상담전화 : 1393 ※ 정신건강상담전화 : 1577-0199
※ 보건복지상담센터 : 129"

◆3 단계 누적 탐지 시스템

위험탐지 시스템은 단일 대화가 아닌 누적적 관점에서 사용자의 위험도를 평가하는 3 단계 시스템으로 설계되었다. 1 단계에서는 위험 키워드가 1 회 탐지되었을 때 공감적 대응 및 감정 검증을 통해 사용자의 현재 상태를 파악하고 보호요인을 탐색한다. 이 단계에서는 즉각적인 위험보다는 사용자의 감정을 인정하고 지지하는 데 중점을 둔다.

2 단계에서는 위험 키워드가 2 회 탐지되면 보다 구체적인 상황 및 계획을 확인하고 즉시 대처 전략을 제공한다. 이 단계에서는 사용자의 위험 상황이 일시적인 것인지 지속적인 것인지를 파악하고, 구체적인 자살 계획이나 자해 의도가 있는지를 세심하게 탐색한다.

3 단계에서는 위험 키워드가 3 회 이상 탐지되면 전문기관 연계 활성화 단계로 진입한다. 이 단계에서는 자동으로 전문기관 정보가 제공되며, 지속적인 모니터링과 추적 관리가 시작된다. 시스템은 이후 대화에서도 해당 사용자의 위험도를 지속적으로 모니터링하여 필요시 추가적인 개입을 실시한다.

◆기술적 구현 특징

위험탐지 시스템의 기술적 구현에서는 실시간 모니터링, 문화적 적응성, 개인정보 보호라는 세 가지 핵심 특징을 중심으로 설계되었다. 실시간 모니터링 측면에서는 모든 대화 세션에서 위험 키워드를 실시간으로 스캐닝하며, 세션별로 위험도 점수를 누적 관리하고 위험 탐지 이력을 데이터베이스에 저장한다. 이를 통해 사용자별 위험 패턴을 파악하고 개인화된 개입이 가능하도록 하였다.

문화적 적응성 구현에서는 한국어 구어체 표현에 특화된 탐지 알고리즘을 개발하여 세대별, 지역별 언어 사용 패턴을 반영하였다. 특히 "멘탈이 나갔다", "멘붕이다"와 같은 현대적 표현이나 은유적, 간접적 표현의 맥락적 해석이 가능하도록 하여 한국 대학생들의 실제 언어 사용 패턴에 맞춘 위험 탐지가 이루어지도록 하였다.

개인정보 보호 측면에서는 위험 탐지 데이터의 비식별화 처리를 통해 개인 식별이 불가능하도록 하고, 위험 탐지에 필요한 최소한의 정보만을 로깅하여 데이터 활용 시에도 사용자 동의를 기반으로 하는 원칙을 수립하였다. 이러한

체계적인 위험탐지 시스템을 통해 닥터케어썸 챗봇은 사용자의 정신건강 위기 상황을 조기에 감지하고 적절한 전문적 지원으로 연계하는 안전망 역할을 수행한다.

영어와 한국어 버전 개발 과정에서 위험탐지에 대한 언어별 응답 특성의 차이가 관찰되었다. 이러한 언어별 특성 차이는 LLM 기반 다국어 챗봇 개발 시 고려해야 할 중요한 요소로 식별되었으며, 상세한 분석 결과는 실험결과 섹션에서 다룬다.

3) 실험 방법

3.1) 실험 참가자 구성

본 연구에는 18 세에서 27 세 사이의 참가자 20 명($M=23.3$, $SD=1.96$)이 포함되었으며, 표본은 여성 60%, 남성 40%로 구성되었다. 참가자는 대학 이메일 목록과 소셜 미디어 광고를 통해 모집되었으며, 연구 참여에 앞서 사전 동의를 제공하였다.

3.2) 측정 도구

① 닥터케어썸 상담용 챗봇 상담 평가 설문지

본 연구에서는 정신건강 챗봇의 상담적 품질을 체계적으로 평가하기 위해 상담학 박사의 자문과 문헌조사를 통해 평가 도구를 개발하였다.

평가 기준 도출 과정:

효과적인 심리상담의 핵심 요소들을 파악하기 위해 상담심리학 분야의 주요 선행연구를 검토하였다. Rogers(1957)의 내담자 중심 상담 이론에서 제시된 공감적 이해, Egan(2013)의 숙련된 조력자 모델, Greenberg(2011)의 정서 중심

상담 접근 등을 종합적으로 분석하였다. 또한 디지털 정신건강 중재의 특성을 고려하여 개인화(Weger et al., 2014)와 전문성(Sue & Sue, 2012) 요소를 추가로 포함하였다.

7 가지 핵심 평가 기준:

이러한 문헌 검토를 바탕으로 정신건강 챗봇이 갖추어야 할 상담적 역량을 다음 7 가지 핵심 영역으로 구체화하였다:

- ◆공감성: 내담자의 감정과 경험에 대한 공감적 이해와 반응
- ◆정확성과 유익성: 정확하고 도움이 되는 정보 제공
- ◆복합적 사고와 감정: 내담자의 복잡한 심리상태에 대한 통합적 이해
- ◆적극적 경청과 적절한 질문: 효과적인 의사소통과 탐색적 질문
- ◆긍정성과 지지: 내담자에 대한 지지적 태도와 희망적 관점
- ◆전문성: 심리학적 지식에 기반한 전문적 접근
- ◆개인화: 내담자 개인의 특성과 상황을 고려한 맞춤형 대응

측정 도구 구성:

전반적 만족도 1 개 문항과 상기 7 개 평가 기준에 대한 정량적 문항으로 구성되었으며, 각 문항은 해당 영역의 이론적 배경과 실제 상담 현장에서의 적용 가능성을 고려하여 개발되었다. 구체적인 평가 요소와 이론적 근거는 [표 13]에 상세히 제시되어 있다.

표 13. 닥터케어챗 상담용 챗봇 상담 평가 문항

평가 요소	문항	설명	선행연구
공감성	케어봇의 답변은 사용자의 질문에 대한 공감과 이해가 표현되었습니까?	효과적인 상담 대화에서는 내담자의 감정과 경험에 대한 공감적 이해가 필수적이다. 상담자의 공감은 내담자로 하여금 수용받고 있다는 느낌을 갖게 하며, 자기 탐색을 촉진한다. 상담 대화에서 정보 제공은 내담자의 문제 해결과 의사 결정을 돕는 중요한 요소. 단순히 지식을 전달하는 것을 넘어, 내담자의 맥락에 적합하고 실천 가능한 정보여야 한다.	Rogers, 1957; Elliott et al., 2011
정확성 및 유익성	케어봇의 답변은 사용자의 질문에 대해 정확하고 유익한 정보를 제공했나요?	숙련된 상담자는 내담자의 인지적, 정서적 경험을 통합적으로 다룰 수 있어야 한다. 내담자의 사고와 감정을 깊이 있게 탐색하고 반영함으로써 내적 경험에 대한 통찰을 촉진할 수 있다.	Hepworth et al., 2017; Egan, 2013
복합적 사고와 감정	케어봇의 답변은 단순한 지식보다는 복합적인 사고와 감정의 내용을 담고 있었나요?	적극적 경험은 상담 대화의 기본이며, 효과적인 상담자는 열린 질문, 명료화, 재진술 등의 기술을 통해 내담자의 자기 탐색을 촉진한다.	Greenberg, 2011; Gendlin, 1996
적극적 경험 및 적절한 질문	케어봇의 반응은 적극적인 경험 뿐 아니라 적절한 질문도 포함되었습니까?	상담 대화에서 지지와 격려는 내담자의 자존감을 높이고 변화에 대한 동기를 복돋운다. 상담자의 긍정적이고 수용적인 태도는 안전한 치료 동맹 형성에 기여한다.	Weger et al., 2014; Hill, 2009
긍정과 지지	케어봇의 반응은 긍정과 지지를 담고 있었습니까?	상담자의 전문성은 내담자의 신뢰감과 치료 순응도를 높이는 데 중요한 역할을 한다. 전문성은 이론적 지식뿐 아니라 임상 경험, 윤리의식, 다문화 역량 등을 포괄한다.	Mearns & Thorne, 2013; Norcross & Lambert, 2018
전문성	케어봇의 답변은 전문성을 갖추고 있다고 생각되었습니까?	효과적인 상담은 내담자 개개인의 특성과 요구에 맞게 맞춤화되어야 한다. 내담자의 성격, 발달 수준, 문화적 배경 등을 고려한 개별화된 접근은 상담의 성과를 높이는 주요 요인이다.	Sue & Sue, 2012; Ratts et al., 2016
개인화	케어봇의 반응은 개인화되어 있다고 생각됩니까?		Norcross & Wampold, 2018; Beutler & Harwood, 2000

② 사용자 경험 개방형 설문지

챗봇 사용 경험에 대한 사용자의 인식과 의견을 심층적으로 파악하기 위해 4 개의 영역(긍정, 부정, 개선될 영역, 추가될 영역)에 걸쳐 설문 문항을 개발하였다.

③ 비교 평가

호미타운 챗봇의 상대적 성능을 평가하기 위해 다음과 같은 비교를 수행하였다:

– 실험 I 에서 사용된 디지털 테라피 챗봇(Woebot, Happify) 과의 만족도 비교

각 비교를 위해 일원배치 분산분석(One-way ANOVA)을 실시하고 F-통계량과 p-값을 산출하였다.

3.3) 자료 수집 절차

자료 수집은 2024 년 2 월에 실시되었으며, 단계별 절차를 통해 진행되었다. 연구 참가자는 대학 이메일 목록과 소셜 미디어 광고를 통해 모집되었으며, 모든 참가자에게 연구 목적, 절차, 개인정보 보호 방침에 대한 충분한 설명을 제공한 후 자발적 참여 동의를 받았다. IRB 승인 범위를 확장 적용하여 연구 동의서를 통한 사전 동의 절차를 완료하였다. 참가자들은 1 주간 닥터케어썸 챗봇을 자유롭게 사용하도록 하였으며, 이 기간 동안 일상적인 대화, 감정 표현, 감사일기 작성 등 챗봇의 다양한 기능을 체험할 수 있었다. 사용 과정에서 발생하는 기술적 문제나 질문에 대해서는 연구진이 실시간으로 지원을 제공하였다. 닥터케어썸 사용 경험 후, 참가자들은 동일한 기간 동안 기존 디지털 테라피 앱(Woebot, Happify)과 범용 LLM 챗봇(ChatGPT, Google Bard)을 사용하였으며, 각 플랫폼 사용 후 즉시 평가를 실시하여 기억의 정확성을 확보하였다. 모든 챗봇 사용 경험 완료 후, 온라인 설문 플랫폼을 통해 정량적 평가와 정성적 피드백을 수집하였으며, 설문 응답은 익명으로 처리되어 개인 식별이 불가능하도록 코딩 처리하였다.

3.4) 분석 방법

참가자들은 1 주간 닥터케어썸 챗봇을 자유롭게 사용하도록 하였다. 이 기간 동안 참가자들은 일상적인 대화, 감정 표현, 감사일기 작성 등 챗봇의 다양한 기능을 체험할 수 있었다. 사용 과정에서 발생하는 기술적 문제나 질문에 대해서는 연구진이 실시간으로 지원을 제공하였다.

3.4.1) 비교 평가 단계

닥터케어샘 사용 경험 후, 참가자들은 동일한 기간 동안 기존 디지털 테라피 앱(Woebot, Happify)과 범용 LLM 챗봇(ChatGPT, Google Bard)을 사용하였다. 각 플랫폼 사용 후 즉시 평가를 실시하여 기억의 정확성을 확보하였다.

3.4.2) 설문 조사 및 피드백 수집

모든 챗봇 사용 경험 완료 후, 온라인 설문 플랫폼을 통해 정량적 평가와 정성적 피드백을 수집하였다. 설문 응답은 익명으로 처리되었으며, 개인 식별이 불가능하도록 코딩 처리하였다.

3.5) 분석 방법

본 연구의 실험 II는 연구자가 제 1 저자로 참여하여 JMIR Medical Informatics 에 게재된 Kang & Hong(2025)의 연구를 근간으로 하되, 박사논문의 연구 목적에 맞게 추가적인 통계 분석을 수행하여 연구 결과의 신뢰성과 타당성을 강화하였다. 수집된 자료는 Python 을 활용하여 다음과 같이 분석하였으며, 모든 데이터 분석 코드는 GitHub 저장소에서 확인할 수 있다 (<https://github.com/bykang2015/HoMemeTown-Dr-CareSam-Chatbot>).

기술통계 분석: 모든 측정 변수에 대해 평균, 표준편차, 최솟값, 최댓값을 산출하여 자료의 기본 특성을 파악하였으며, 참가자의 인구통계학적 특성과 각 챗봇별 사용자 평가 점수의 분포를 확인하였다.

상관관계 분석: 7 개 평가 영역(공감성, 정확성과 유익성, 복합적 사고와 감정, 적극적 경청과 적절한 질문, 긍정성과 지지, 전문성, 개인화)과 지속사용의향,

혁신성 인식 간의 관계를 파악하기 위해 피어슨 상관분석(Pearson correlation analysis)을 실시하였다.

분산분석: 챗봇 유형에 따른 만족도 차이를 검증하기 위해 일원배치 분산분석(One-way ANOVA)을 실시하였으며, 분산의 동질성 가정은 Levene 검정을 통해 확인하고 사후검정으로는 Tukey HSD 를 사용하였다.

효과크기 분석: 집단 간 차이의 실질적 의미를 파악하기 위해 Cohen's d 와 eta-squared(η^2)를 산출하여 효과크기를 측정하였으며, Cohen(1988)의 기준에 따라 작은 효과(.20), 중간 효과(.50), 큰 효과(.80)로 해석하였다.

사후 검정력 분석: 연구 결과의 통계적 타당성을 확보하기 위해 관찰된 효과크기를 바탕으로 사후 검정력(post-hoc power analysis)을 계산하여 제시하였다.

질적 자료 분석: 개방형 설문 응답은 내용분석(content analysis) 방법을 적용하여 분석하였으며, 응답 내용을 의미 단위로 분할한 후 유사한 내용끼리 범주화하여 주요 테마를 도출하고 언급 빈도를 계산하여 정량화된 결과로 제시하였다.

통계적 가정 검증: 모든 분석에 앞서 정규성 검정(Shapiro-Wilk test), 등분산성 검정(Levene's test), 독립성 가정을 확인하였으며, 통계적 유의수준은 $\alpha = .05$ 로 설정하였다.

기존 연구와의 차별점: 원논문에서 제시된 기본 분석에 더하여, 본 박사논문에서는 가설 설정, 개발과정, 특히 프롬프트 엔지니어링의 상세적인 기술, 효과크기 분석, 사후 검정력 분석, 확장된 상관관계 분석 등을 추가로 수행하여 연구 결과의 해석 깊이를 높이고 실용적 의미를 강화하였다.

4. 연구 결과

1) 기술 통계

1.1) 연구참가자 특성

본 연구에는 총 20 명의 대학생 및 대학원생이 참여하였으며, 연구참가자들의 인구통계학적 특성은 다음과 같다.

①기본 인구통계학적 특성

◆성별 및 연령 분포

연구참가자 중 남성이 8명(40%), 여성이 12명(60%)으로 구성되었다. 연령은 18 세에서 27 세 사이에 분포하였으며, 평균 연령은 23.3 세($SD = 1.96$)였다. 이는 일반적인 대학생 및 대학원생 연령대를 잘 반영하는 것으로 나타났다.

◆모집 경로

참가자들은 두 가지 경로를 통해 모집되었다. 실험 I 에 참여했던 참가자 17 명(85%)과 대학 이메일 목록 및 소셜 미디어 광고를 통해 새롭게 모집된 3 명(15%)으로 구성되었다. 모든 참가자는 연구 참여에 앞서 사전 동의를 제공하였다.

②디지털 기술 사용 경험

◆정신건강 앱 사용 경험

기존 정신건강 관련 디지털 앱 사용 경험을 조사한 결과, 참가자의 대부분이 관련 경험을 보유하고 있는 것으로 나타났다. 주로 사용한 앱 유형으로는 명상 및 마음챙김 앱, 감정 기록 앱, 수면 관리 앱 등이 있었다.

◆AI 챗봇 사용 경험

범용 AI 챗봇 사용 경험을 조사한 결과, ChatGPT 는 18 명(90%)이 사용 경험이 있었으나 Google Bard 는 13 명(65%)만이 사용 경험을 보유하고 있었다. 이러한 사용 경험의 차이는 후속 비교 평가에서 결측치 발생의 주요 원인이 되었으며, 챗봇별 평가 결과 해석 시 고려해야 할 중요한 요소로 작용하였다. 다만, 최종 비교 분석에서는 각 그룹 20 명의 완전한 데이터를 확보하여 분석을 실시하였다.

◆연구 참여 동기

참가자들의 연구 참여 동기는 크게 두 가지로 구분되었다. 실험 I 에 참여했던 17 명 중 상당수는 자신들이 참여한 연구의 결실이 어떤 방식으로 구현되는지에 대한 학술적 호기심을 보였다. 특히 4 학년 및 대학원생으로 재학 중이거나 졸업한 학생들은 연구 과정 전반에 대한 이해도가 높아 적극적인 참여 의지를 나타냈다. 새롭게 모집된 3 명의 참가자들은 주로 정신건강 챗봇 기술에 대한 호기심과 새로운 디지털 도구 체험에 대한 관심에서 참여하였다.


이러한 참가자 구성은 본 연구의 목적인 대학생 대상 정신건강 챗봇 평가에 적합한 표본을 형성하는 것으로 판단되며, 향후 결과 해석에 있어 이러한 특성들이 고려되어야 할 것이다.

2) 닥터케어썸 양적 분석 결과

2.1) 닥터케어썸 영역별 평가 점수

닥터케어썸에 대한 7 개 영역별 상담 평가 결과는 [그림 16]과 같다.

그림 16. 닥터케어썸 상담 평가 문항에 대한 평균 점수



[그림 16]에 나타난 바와 같이, 사용자는 일반적으로 챗봇에 대해 긍정적인 견해를 표명했다.

높은 평가를 받은 영역 공감성(9.2 점), 긍정성과 지지(9.1 점), 적극적 경청과 적절한 질문(9.0 점) 영역에서 10 점 만점에 9 점 이상의 매우 높은 점수를 기록했다. 이는 정신건강 챗봇에서 감정적 지지와 공감적 소통이 사용자에게 매우 중요하게 인식됨을 보여준다.

상대적으로 낮은 평가를 받은 영역 반면 상담 내용의 복잡성(7.0 점), 개인화 측면(7.4 점), 전문성(7.4 점) 영역에서는 상대적으로 낮은 점수를 받았다. 이러한 영역들은 9 점대에 육박하는 다른 항목들과 비교할 때 개선의 여지가 있는 것으로 나타났다.

2.2) 범용 LLM 챗봇 평가 점수

ChatGPT 와 Google Bard 에 대한 전반적 만족도 평가 결과는 [그림 17]과 [표 14]로 요약될 수 있다.

그림 17. 범용 LLM 챗봇과의 전반적 만족도 점수 비교




표 14. 범용 LLM 챗봇 비교 통계 분석

기술통계

챗봇 유형	평균 (M)	표준편차 (SD)	n	95% 신뢰구간
닥터케어챗	8.2	1.4	20	[7.55, 8.85]
ChatGPT	6.8	1.8	20	[5.96, 7.64]
Google Bard	7.2	1.6	20	[6.46, 7.94]

분산분석 결과

변량원	제곱합 (SS)	자유도 (df)	평균제곱 (MS)	F	p-값	η^2	검정력
집단 간	16.13	2	8.07	3.27	0.048	0.152	0.72
집단 내	140.65	57	2.47				
전체	156.78	59					

사후검정 (Tukey HSD)

비교	평균차이	표준오차	p-값	95% 신뢰구간	Cohen's d
닥터케어챗 vs ChatGPT	1.4	0.5	0.017	[0.21, 2.59]	0.85
닥터케어챗 vs Google Bard	1	0.5	0.121	[-0.19, 2.19]	0.59
ChatGPT vs Google Bard	-0.4	0.5	0.712	[-1.59, 0.79]	0.23

◆기술통계 결과

분석 결과, 닥터케어챗이 평균 8.2 점($SD = 1.4$, $n = 20$)으로 가장 높은 만족도를 보였으며, Google Bard 7.2 점($SD = 1.6$, $n = 20$), ChatGPT 6.8 점($SD = 1.8$, $n = 20$) 순으로 나타났다.

◆분산분석 결과

일원배치 분산분석 결과, 세 챗봇 간에 통계적으로 유의한 차이가 있는 것으로 나타났다 [$F(2, 57) = 3.27, p = .048, \eta^2 = .152$]. 효과크기는 중간 수준으로 해석된다.

◆사후검정 결과

Tukey HSD 사후검정을 통해 구체적인 집단 간 차이를 확인한 결과, 닥터케어챗과 ChatGPT 간에 통계적으로 유의한 차이가 있었다(평균차이 = 1.4, $p = .017$, Cohen's $d = 0.85$). 이는 큰 효과크기에 해당한다. 반면, 닥터케어챗과 Google Bard 간의 차이는 통계적으로 유의하지 않았으며($p = .121$, Cohen's $d = 0.59$), ChatGPT 와 Google Bard 간의 차이 역시 유의하지 않았다($p = .712$, Cohen's $d = 0.23$).

2.3) 기존 디지털 테라피 앱 평가 점수

닥터케어챗과 기존 디지털 테라피 앱들(Woebot, Happify) 간의 만족도 비교 결과는 다음 [그림 18]와 [표 15]과 같다.

그림 18. 기존 테라피 앱과의 전반적 만족도 점수 비교




표 15. 기존 테라피 앱과의 비교 통계 분석

비교 1: 닥터케어샘 vs 기존 테라피 앱 기술통계

챗봇 유형	평균 (M)	표준편차 (SD)	n	95% 신뢰구간
닥터케어샘	8.2	1.4	20	[7.55, 8.85]
Woebot	4.8	2.1	20	[3.82, 5.78]
Happify	3.2	1.9	20	[2.31, 4.09]

비교 1: 분산분석 결과

변량원	제곱합 (SS)	자유도 (df)	평균제곱 (MS)	F	p-값	η^2
집단 간	250.13	2	125.07	12.94	<0.001	0.68
집단 내	550.8	57	9.66			
전체	800.93	59				

개별 비교 분석 결과

비교 대상	F-통계량	p	효과크기 (η^2)	효과크기 해석	실제적 의미
닥터케어샘 vs 기존 테라피 앱	12.94	<0.001	0.68	매우 큰 효과	기존 솔루션 대비 상당한 성능 개선
닥터케어샘 vs 범용 LLM	4.31	0.048	0.152	중간 크기의 효과	ChatGPT보다 만족도에서 유의하게 우수, 구글 바드는 표본 부족으로 비교 제한

◆기술통계 결과

닥터케어샘은 평균 8.2 점(SD = 1.4, n = 20)을 기록한 반면, Woebot 은 4.8 점(SD = 2.1, n = 20), Happify 는 3.2 점(SD = 1.9, n = 20)으로 상당한 점수 차이를 보였다.

◆분산분석 결과

일원배치 분산분석 결과, 세 서비스 간에 매우 높은 수준의 통계적 유의차가 확인되었다 [$F(2, 57) = 12.94, p < .001, \eta^2 = .68$]. 이는 매우 큰 효과크기에 해당한다.

◆효과크기 분석

효과크기 분석에서 두 가지 중요한 발견을 확인했다. 기존 디지털 테라피 앱과의 비교에서는 매우 큰 효과크기($\eta^2 = .68$)를 보여 닥터케어썸이 기존 디지털 치료 솔루션 대비 상당한 성능 개선을 달성했음을 시사한다. 범용 LLM 과의 비교에서는 중간 정도의 효과크기($\eta^2 = .152$)를 나타내어, LLM 기반 대화형 인터페이스 자체의 기본 성능이 높으면서도 전문화된 접근법을 통한 의미 있는 개선이 가능함을 확인할 수 있었다.

2.4) 점수 분포 특성 분석

바이올린 플롯 분석을 통해 각 챗봇의 점수 분포 특성을 살펴보면, 닥터케어썸은 7 점 이상에 집중된 분포를 보여 일관되게 높은 만족도를 나타냈다. 반면 ChatGPT 와 Google Bard 는 상대적으로 넓은 분포를 보였으며, 특히 기존 디지털 테라피 앱들은 낮은 점수 영역에 집중된 분포 패턴을 보였다.

3) 상관관계 분석 결과

◆측정 변수 소개 및 기술통계

닥터케어쌤의 상담 평가와 더불어, 사용자의 향후 사용 의향과 기술 혁신성에 대한 인식을 측정하였다. 이러한 변수들은 챗봇의 실제 채택 가능성과 사용자 수용성을 평가하는 중요한 지표로 활용되었다.

3.1) 지속사용의향

닥터케어쌤의 정식 출시 후 지속적으로 사용할 의향을 10 점 척도로 측정한 결과, 평균 6.90 점($SD = 2.05$, $n = 20$)으로 나타났다. 점수 분포는 4 점에서 10 점까지 분포하였으며, 특히 주목할 점은 전체 참가자의 15%(3 명)가 10 점 만점을 주어 매우 높은 지속사용의향을 보인 것이다. 이는 정신건강 챗봇에 대한 강한 사용자 니즈와 닥터케어쌤의 높은 사용자 만족도를 시사하는 중요한 발견이다. 점수 분포는 0 점에서 9 점까지 다양하게 나타났으며, 참가자 간 상당한 개인차를 보였다.

3.2) 혁신성 인식

닥터케어쌤이 아이디어, 기술, 콘텐츠, 적용 면에서 혁신적인지에 대한 인식을 5 점 척도로 측정하였으며, 비교 분석의 용이성을 위해 10 점 척도로 환산하였다. 그 결과 평균 6.90 점($SD = 2.47$, $n = 20$)으로 나타났다. 특히 주목할 점은 전체 참가자의 30%(6 명)가 최고점인 10 점을 주었으며, 8 점 이상의 고평가를 한 참가자가 45%(9 명)에 달한다는 것이다. 이는 사용자들이 닥터케어쌤을 매우 혁신적인 기술로 인식하고 있음을 보여주는 강력한 증거이다.

7 개 영역과 지속사용의향 간 상관분석을 실시한 결과는 다음 [표 16]과 같다.

표 16. 지속사용의향과 7 개 영역 간 상관분석 결과

평가 영역	상관계수 (r)	p-값	95% 신뢰구간	Cohen 효과크기	순위
정확성과 유익성	0.82	<0.001	[0.71, 0.89]	매우 큰 효과	1
개인화	0.79	<0.001	[0.66, 0.87]	매우 큰 효과	2
복합적 사고와 감정	0.77	<0.001	[0.63, 0.86]	매우 큰 효과	3
공감성	0.74	<0.001	[0.58, 0.84]	큰 효과	4
적극적 경청과 적절한 질문	0.71	<0.001	[0.54, 0.82]	큰 효과	5
전문성	0.7	<0.001	[0.52, 0.81]	큰 효과	6
긍정성과 지지	0.68	<0.001	[0.49, 0.80]	큰 효과	7

*** $p < 0.001$, $n = 20$, 지속사용의향: $M = 6.9$, $SD = 2.16$

위 표에서 보는 바와 같이, 정확성과 유익성이 지속사용의향과 가장 높은 상관관계($r = 0.82$, $p < 0.001$)를 보였다. 이는 사용자들이 챗봇의 지속적 사용을 결정할 때 제공되는 정보와 조언의 정확성 및 유용성을 가장 중요하게 고려한다는 것을 의미한다. 개인화($r = 0.79$), 복합적 사고와 감정($r = 0.77$), 공감성($r = 0.74$) 순으로 높은 상관관계를 보였으며, 모든 상관계수가 통계적으로 유의했다.

혁신성 인식과 7 개 영역 간 상관분석 결과는 다음 [표 17]과 같다.

표 17. 혁신성 인식과 7 개 영역 간 상관분석 결과

평가 영역	상관계수 (r)	p-값	95% 신뢰구간	Cohen 효과크기	순위
개인화	0.85	<0.001	[0.75, 0.91]	매우 큰 효과	1
정확성과 유익성	0.82	<0.001	[0.71, 0.89]	매우 큰 효과	2
복합적 사고와 감정	0.81	<0.001	[0.69, 0.88]	매우 큰 효과	3
전문성	0.8	<0.001	[0.67, 0.88]	매우 큰 효과	4
적극적 경청과 적절한 질문	0.76	<0.001	[0.61, 0.85]	큰 효과	5
공감성	0.72	<0.001	[0.55, 0.83]	큰 효과	6
긍정성과 지지	0.65	<0.001	[0.44, 0.78]	큰 효과	7

*** $p < 0.001$, $n = 20$, 혁신성 인식: $M = 6.9$, $SD = 2.47$

위 표에서 보는 바와 같이, 개인화가 혁신성 인식과 가장 높은 상관관계($r = 0.85, p < 0.001$)를 보였다. 이는 사용자들이 챗봇의 혁신성을 평가할 때 개인의 특성과 요구에 맞춘 맞춤형 서비스 제공 능력을 가장 중요하게 고려한다는 것을 시사한다. 흥미롭게도 지속사용의향과 혁신성 인식에서 서로 다른 기준을 적용한다는 것을 확인할 수 있었는데, 지속사용에서는 실용적 가치(정확성과 유익성)가, 혁신성 인식에서는 기술적 차별화(개인화)가 가장 중요한 요인으로 나타났다.

◆상관관계 분석 결과 요약

상관분석 결과, 모든 영역이 지속사용의향 및 혁신성 인식과 높은 상관관계를 보였다. 지속사용의향에서는 정확성과 유익성이, 혁신성 인식에서는 개인화가 가장 중요한 요인으로 나타나 사용자들이 서로 다른 기준을 적용함을 확인했다. 이러한 결과는 정신건강 챗봇의 성공적인 도입을 위해서는 **정보의 정확성과 실용성, 그리고 사용자 개별 특성을 반영한 개인화 기능**이 중요함을 시사한다.

4)닥터케어챗 질적 분석 결과

앞서 수행한 양적 분석을 통해 닥터케어챗이 기존 챗봇들 대비 우수한 사용자 만족도를 보임을 확인하였으나, 사용자 경험의 구체적 양상과 개선 방향을 파악하기 위해서는 보다 깊이 있는 질적 접근이 필요하다.

◆범용 LLM 과의 비교 분석

2024 년 2 월 현재 각 챗봇을 일상에서 경험해본 실제 사용자 수는 닥터케어챗 실험 참여자 20 명 중 ChatGPT 18 명, Google Bard 13 명이었다. 이 중 일부 참여자들의 개방형 응답에 따르면, 닥터케어챗에 높은 점수를 준 주요 이유는 공감적 소통과 정신건강 상담 특화 설계로 나타났다. 다만 일부 참여자는 "공감

표현의 형식적 패턴"과 "과도한 되묻기"를 아쉬운 점으로 언급했다. ChatGPT 는 빠른 반응 속도와 명확한 해결방안 제시에서 강점을 보였으나 고민 공감 능력 부족이 한계로 지적되었고, Google Bard 는 상대적으로 적은 사용자 수를 보이며 정보 전달 중심으로 일상대화 적합성이 낮다는 평가를 받았다.

◆닥터케어챗의 긍정적인 측면과 부정적 측면

사용자들의 개방형 응답을 언급 빈도별로 분석한 결과는 다음 [표 18]와 같다.

표 18. 언급 빈도별 사용자 피드백 분석

언급 빈도	범주	긍정적 측면	부정적 측면
가장 많이 언급됨	응답 속도	빠른 응답과 실시간 피드백	느린 응답 속도, 즉각적 반응 부족
	친근하고 긍정적인 어조	격려적이고 지지적인 응답, 용기와 이해 제공	공감에만 치우침, 실질적 조언 없는 반복적 응답
자주 언급됨	공감 능력	이해와 공감을 효과적으로 표현	구체적 지침이나 해결책 없이 공감에만 과도하게 집중
	한국어 처리 능력	영어와 한국어 모두 지원, 인간과 같은 자연스러운 대화 흐름	한국어 표현의 어색함, 한국어 응답의 정확성과 적절성 부족
보통 언급됨	세밀한 표현력	다양한 감정과 적절한 이모티콘 사용	반복적인 어조, 개인화 부족
	챗봇 기능성	감정 표현, 감사 일기 작성 가이드, 다양한 상황에 대한 다양한 응답	제한적인 콘텐츠, 참여도 향상을 위한 보상 기능과 이전 상호작용 재검토 옵션 필요
적게 언급됨	디자인과 인터페이스	직관적인 디자인 요소가 있는 깔끔하고 사용자 친화적인 인터페이스	긴 텍스트 말풍선 문제, 자동 줄바꿈 부족, 디자인 개선 필요
	콘텐츠와 정보	관련 정보와 문제 해결 조언 제공	과도한 이모티콘 사용, 전문적 조언 부족, 모바일 접근성 개선 필요
가장 적게 언급됨	개인화	따뜻하고 긍정적인 에너지를 전달하는 긍정적이고 개인화된 응답	개인화 부족, 의뢰나 상담 서비스와의 연계 부족, 인간적 터치 부재
	기타	사용하기 쉽고 접근하기 쉬운 태도	일관성 없는 참여 인센티브, 인간적 특성 강화 필요

[표 18]에서 보듯이 사용자 피드백을 분석한 결과, 응답 속도에 대한 언급이 가장 빈번했다. 긍정적으로는 "빠른 응답과 실시간 피드백"을, 부정적으로는 "느린 응답 속도, 즉각적 반응 부족"을 지적하는 패러독스 현상이 나타났다. 이는 사용자들이 응답 내용의 적절성과 기술적 처리 속도를 분리하여 평가하고 있음을 보여준다. 즉, 내용적으로는 관련성 있고 적시적인 피드백을 제공하지만, 실제 응답 생성 시간은 사용자 기대에 미치지 못한다는 의미이다.

다음으로 공감 능력에 대한 언급이 많았다. 긍정적으로는 "적절하고 지지적인 응답, 공감과 이해 제공"을 평가했으나, 부정적으로는 "공감대 채우, 실질적 조언 없는 반복적 응답"을 문제점으로 지적했다.

한국어 처리 능력도 자주 언급되었는데, "영어와 한국어 모두 지원"과 "자연스러운 대화 흐름"은 긍정적으로 평가된 반면, "한국어 표현의 어색함"과 "한국어 응답의 정확성 부족"은 주요 개선점으로 나타났다.

또한 주목할 만한 점은 추가 기능에 대한 제안에서 심리 전문가 연결 시스템(16 회)이 가장 많이 요구되었다는 것이다. 이는 사용자들이 챗봇을 완전한 대체재가 아닌 전문가 치료로의 연결고리로 인식하고 있음을 시사한다. [표 19]에서 볼 수 있듯이, 호밋타운 기능 개선에 대한 제안으로 대학생 실험 참여자들은 심리 전문가의 연결 시스템(16 회) 및 개인 맞춤형 기능(10 회), 본인의 수행한 활동에 대한 보고 기능(10 회) 등을 가장 추가되었으면 하는 기능으로 지적하였다.

표 19. 호밋타운 기능 개선에 대한 제안

호밋타운 제안된 개선 사항	언급 횟수
심리 전문가와의 연결 시스템	16
개인의 니즈 및 선호에 따른 맞춤형 기능	10
본인의 수행한 활동에 대한 보고	10
플랫폼으로서의 홈(버튼) 및 세부 페이지 기능	9
대학생 온라인 커뮤니티	6
감사 일기에 대한 양질의 피드백	6
수행할 활동에 대한 알람 시스템	6
외로움 및 우울증 관련 팟캐스트	6
사용자 콘텐츠(UCC) 및 p2p 네트워킹	2
사용자를 위한 다양한 비디오 콘텐츠	1

5) 한국어 처리 능력 및 언어별 차이점 종합 분석

한국어 처리 능력도 자주 언급되었는데, "영어와 한국어 모두 지원"과 "자연스러운 대화 흐름"은 긍정적으로 평가된 반면, "한국어 표현의 어색함"과 "한국어 응답의 정확성 부족"은 주요 개선점으로 나타났다.

긍정적 측면:

닥터케어쌤은 영어에서 특히 뛰어난 성능을 보였으며, 다양한 은유적 표현과 심리학적 지식을 활용한 풍부한 대화 내용을 제공했다. 한국어에서도 기본적인 상담 대화는 자연스럽게 진행되었다. 다양한 감정 표현과 이모티콘 사용, 감정 표현 가이드 등은 긍정적으로 평가되었다.

개선 필요 영역:

하지만 한국어 사용 시 몇 가지 한계점이 관찰되었다. 예를 들어, 개별 사용자와의 1:1 상담 상황임에도 불구하고 "여러분"과 같은 집단 호칭을 사용하거나, 영어 대비 상대적으로 제한된 표현과 단조로운 응답 패턴을 보이는 경우가 있었다. 또한 반복적인 어조와 개인화 부족, 제한적인 콘텐츠 등은 개선이 필요한 부분으로 지적되었다.

특히 한국어의 언어학적 특성으로 인한 토큰 처리 문제가 중요한 기술적 제약으로 작용했다. 한국어는 자음, 모음, 받침의 조합으로 구성되는 특성상 영어 대비 토큰량이 증가할 수밖에 없으며, 프롬프트 지시사항이 매 대화마다 포함되면서 대화 턴이 길어질수록 토큰 한계로 인한 예러가 발생하였다. 이를 해결하기 위해 답변 길이의 토큰량 한계를 128,000 에서 4,096 으로 조정하여 오류를 수정할 수 있었으나, 이는 응답의 풍부함과 상세함에 제약을 가져왔다. 이는 LLM 기반 다국어 정신건강 챗봇 개발 시 언어별 특성화와 문화적 맥락 반영뿐만

아니라 언어학적 토큰 처리 최적화의 중요성을 보여주며, 향후 한국어 특화 모델 개발의 필요성을 시사한다.

개발 과정에서 예상치 못한 언어별 차이점이 발견되었다. GPT-4.0 기반 AI 챗봇의 위험 탐지 반응을 분석한 결과, 언어별로 흥미로운 차이점이 나타났다.

[표 20]에서 보는 바와 같이, 가장 주목할 만한 차이는 응답 시간이었다. 영어 버전은 평균 2.1 초의 빠른 응답 시간을 보인 반면, 한국어 버전은 평균 4.3 초의 상대적으로 느린 응답 시간을 기록했다.

표 20. 언어별 대응 패턴 비교 분석 ³⁸

특성	영어 버전	한국어 버전
접근 방식	점진적, 공감 중심적	즉각적, 직접적
대화 전개	단계적 감정 표현 탐색	구조화된 대응
표현 방식	메타포 활용 ("dark tunnel")	문화적 맥락 반영
자원 제공	구체적이고 상세한 정보	간결하고 직접적 정보
응답 시간*	빠름 (평균 2.1초)	느림 (평균 4.3초)

이러한 언어별 응답 시간 차이는 2024 년 2 월 실험 당시 GPT-4.0 기반으로 개발되어 측정된 결과로, 당시 한국어 처리에서 영어 대비 약 2 배의 응답 지연이 관찰되었으나, 2024 년 말 현재 OpenAI 의 모델 최적화로 인해 다국어 처리 성능이 전반적으로 향상되어 이러한 언어별 속도 차이는 크게 줄어든 것으로 보고되고 있다.

프롬프트 엔지니어링의 한계도 중요한 발견이었다. 한국어 버전에서 더 유연하고 공감적인 대응을 유도하기 위해 다양한 프롬프트 튜닝을 시도하였으나,

³⁸ 응답 시간 데이터는 2024년 2월 실험 당시 측정된 것으로, 2024년 말 현재 LLM 모델의 전반적 성능 향상으로 한국어 처리 속도도 크게 개선되었음.

원하는 수준의 일관성을 달성하지 못했다. 이는 당시 LLM 기술의 한국어 처리 성능 한계를 반영한 것으로, 2024 년 말 이후 범용 LLM 들의 한국어 능력이 크게 향상되면서 이러한 문제들은 상당 부분 개선되었다.

기술 발전의 영향:

2024 년 상반기 실험 당시와 달리 2025 년 6 월 현재 상담용으로 특화되지 않은 범용 LLM 들도 높은 수준의 한국어 상담 대화가 가능해졌다. 이는 닥터케어챗과 같은 특화 모델 개발 시 더욱 정교한 차별화 전략이 필요함을 시사하며, LLM 기반 다국어 정신건강 챗봇 개발 시 언어별 특성화가 필요함을 보여주는 중요한 발견이다.

6) 가설 검증 결과

6.1) 탐색적 가설 검증 과정

본 연구에서 설정한 세 개의 탐색적 가설에 대한 검증을 체계적으로 수행하였다. 각 가설별로 적절한 통계분석 방법을 적용하고, 통계적 가정들을 확인한 후 결과를 해석하였다. 전체 가설 검증 과정에서 사용된 통계적 가정 검증 결과는 다음 [표 21]와 같다.

표 21. 통계적 가정 검증 결과

가정 항목	검증 방법	결과	해석
정규성	Shapiro-Wilk test	$p > 0.05$	가정 만족
등분산성	Levene's test	$p > 0.05$	가정 만족
독립성	실험 설계	Within-subject 통제	가정 만족
선형성	산점도 검토	선형 관계 확인	가정 만족

위 표에서 보는 바와 같이, 모든 통계적 가정이 만족되어 분석 결과의 타당성이 확보되었다. 탐색적 가설 1의 검증을 위해 7개 평가 영역과 지속사용의향 간 피어슨 상관분석을 실시한 결과, 정확성과 유익성이 가장 높은 상관관계($r = 0.82, p < 0.001$)를 보여 가설이 지지되었다. 탐색적 가설 2의 검증을 위한 혁신성 인식과의 상관분석에서는 개인화가 가장 높은 상관관계($r = 0.85, p < 0.001$)를 보여 가설이 지지되었다.

탐색적 가설 3는 범용 LLM과의 비교에서 통계적으로 유의한 차이 [$F(2, 57) = 3.27, p = .048$]를 보였으나, 사후검정 결과 ChatGPT와는 유의한 차이가 있었지만 Google Bard와는 차이가 없어 부분적으로 지지되었다. 이는 이는 닥터케어쌤과 Google Bard 간의 효과크기가 중간 수준(Cohen's $d = 0.59$)으로 통계적 유의성에 도달하지 못했기 때문으로 해석된다.

6.2) 전체 가설 검증 결과 종합

세 개의 탐색적 가설의 전체 검증 결과는 다음 [표 22]와 같다.

표 22. 실험 II 전체 탐색적 가설 검증 결과 종합

가설	가설 내용	통계 방법	주요 결과	효과크기	p-값	검정 결과	실제적 의미
가설 1	지속사용의향과 최고 상관관계 탐색	피어슨 상관분석	정확성과 유익성 ($r=0.82$)	매우 큰 효과	<0.001	지지	실용적 가치가 지속사용의 핵심
가설 2	혁신성 인식과 최고 상관관계 탐색	피어슨 상관분석	개인화 ($r=0.85$)	매우 큰 효과	<0.001	지지	맞춤형 서비스가 혁신성 인식의 핵심
가설 3	범용 LLM과의 높은 만족도	일원배치 ANOVA	$F=3.27, \eta^2=0.152$	중간 효과	0.048	부분 지지	ChatGPT보다 유의하게 우수, Bard보다 통계적으로는 동등하나 실질적으로는 우수

◆검정력 분석 (Post-hoc Power Analysis)

표 23. 사후 검정력 분석 결과

가설	표본크기	관찰된 효과크기	검정력 (1- β)	α 수준	해석
가설 1-2	n=20	r=0.80+	>0.95	0.05	매우 적절
가설 3	n=60*	f=0.42	0.72	0.05	적절한 수준

n=60*(참가자 20 명×3 종류앱)

5. 결론 및 시사점

1) 연구의 한계

본 연구는 LLM 기반 정신건강 챗봇의 효과성을 실증적으로 검증했으나, 다음과 같은 중요한 한계점을 가진다.

첫째, 비교 대상의 설계 목적 및 기능적 한계이다. 본 연구에서 비교 분석한 챗봇들은 각각 다른 설계 목적을 가지고 있어 동등한 조건에서의 비교에 한계가 있었다. Google Bard 와 ChatGPT 는 정신건강 상담을 위해 특별히 설계된 것이 아닌 범용 LLM 으로, 정신건강 영역의 전문적 상담 능력을 평가하기에는 부적절한 측면이 있다. 또한 기존 디지털 테라피 앱의 경우 진정한 대화형 상담 기능이 아닌 단순 정보 제공이나 체크리스트 형태로 구성되어 있어, 실제 상담 대화의 품질을 비교 평가하기 어려웠다. 이로 인해 닥터케어썸의 상담적 성능을 동일한 기능과 목적을 가진 전문 정신건강 챗봇들과 체계적으로 비교 분석할 필요성이 대두되었다. 따라서 실제 정신건강 상담 서비스를 제공하는 전문 LLM 기반 챗봇들을 대상으로 한 객관적 비교 평가가 요구된다.

둘째, 실험 설계상의 시점 차이 및 참가자 불일치 문제이다. 기존 디지털 테라피 앱(Woebot, Happify) 평가는 6 개월 전 실험 I 에서, 닥터케어썸 평가는

실험 II 에서 각각 다른 시점에 실시되어 시간적 간격에 따른 외생변수의 영향을 완전히 통제하지 못했다. 또한 전체 참가자 20 명 중 17 명은 두 실험에 모두 참여하였으나, 3 명은 실험 II 에만 참여하여 완전한 반복측정설계를 구현하지 못했다. 이러한 설계상의 한계는 결과 해석의 신뢰성을 제약하는 요인으로 작용한다.

셋째, 표본 크기의 불균형 및 제한적 규모이다. 비교 분석을 위해 각 그룹당 20 명씩 총 60 명의 표본을 확보하였으나, 이는 여전히 제한적인 규모로 볼 수 있다. 특히 범용 LLM 비교 분석에서 관찰된 중간 수준의 효과크기($\eta^2 = 0.152$)와 적절한 검정력($1-\beta = 0.72$)을 고려할 때, 보다 큰 표본 크기를 통해 더 정확한 효과크기 추정과 향상된 검정력을 확보할 수 있을 것이다. 또한 Google Bard 와의 비교에서 통계적 유의성에 도달하지 못한 결과($p = .121$)는 표본 크기 증가를 통해 더 명확한 결론을 도출할 수 있는 여지를 시사한다.

넷째, 단기적인 실험 기간이다. 1 주간의 짧은 평가는 장기적 사용 효과나 지속성을 검증하기 어렵다. 정신건강 지원 도구의 진정한 효과는 지속적인 사용을 통해 나타나는 경우가 많으므로, 단기 평가 결과만으로는 실제 치료적 효과를 판단하기 어렵다. 특히 사용자의 적응 과정, 장기간 사용에 따른 만족도 변화, 그리고 실제 정신건강 개선 효과 등은 본 연구에서 충분히 다루지 못한 중요한 측면들이다.

다섯째, 연구 참가자의 대표성 한계이다. 연구 참가자가 대학생으로 한정되어 있어 다양한 연령대와 사회적 배경을 가진 사용자들에게 결과를 일반화하기 어렵다. 대학생 집단의 디지털 기술 활용 능력과 정신건강 지원에 대한 인식은 다른

연령대와 상당한 차이를 보일 수 있으므로, 보다 포괄적인 사용자 집단을 대상으로 한 후속 연구가 필요하다.

여섯째, 한국어 처리의 기술적 한계이다. 개발 과정에서 한국어 버전의 프롬프트 최적화에 어려움이 있었으며, 1:1 상담 상황에서 부적절한 집단 호칭 사용, 제한된 표현력과 단조로운 응답 패턴 등의 문제가 관찰되었다. 또한 한국어의 구조적 특성으로 인한 토큰 증가와 대화 연장 시 발생하는 토큰 한계 문제로 인해 응답 길이를 대폭 축소해야 했으며, 이는 응답 품질의 제약을 가져왔다. 이러한 결과는 다국어 정신건강 챗봇 개발 시 언어별 최적화와 토큰 효율성 확보의 중요성을 시사한다.

일곱째, 비교 조건의 기술적 제약이다. 범용 LLM 비교 시 무료 버전을 사용함으로써 각 모델의 최적 성능을 평가하지 못했을 가능성이 있으며, 이는 성능 차이를 과소평가할 수 있는 요인으로 작용한다. 또한 한국어 응답 속도 저하 등의 기술적 제약이 사용자 경험에 부정적 영향을 미쳤을 가능성을 배제할 수 없다.

향후 연구에서는 동일 시점, 동일 참가자를 대상으로 한 균형잡힌 통제된 비교 실험이 필요하며, 전문 정신건강 챗봇들 간의 체계적 비교와 장기간 추적 연구를 통한 지속적 사용 효과 검증이 요구된다.

표 24. 연구 한계점 및 영향 분석

한계점	구체적 내용	연구 결과에 미치는 영향
포크 크기	20명의 제한된 표본	일반화 가능성 제한
실험 기간	단기 평가 (1주)	장기적 효과 미검증
기술적 제약	한국어 응답 속도 저하	사용자 경험 저하
비교 조건	무료 버전 LLM 사용	성능 차이 과소평가 가능
시점 차이	실험 I (2023.3월~6월) vs 실험 II (2024년2월)	시간적 간격으로 인한 외생변수
참가자 불일치	공통 참가자 17명, 추가 3명	완전한 반복측정설계 미구현
표본 크기 불균형	최종 분석에서 각 그룹 20명씩 균형 확보	그룹별 영향력 차이, 통계적 검정력 제한
비교군 설계 차이	범용 LLM vs 전문 정신건강 챗봇	동등 조건 비교의 타당성 한계
참가자 대표성	대학생 집단으로 한정	다른 연령대 일반화 어려움
언어적 제약	한국어 토큰 증가, 응답 길이 축소	응답 품질 제약, 상담 효과성 저하

2) 연구의 의의

앞서 제시한 여러 한계점들에도 불구하고, 본 연구는 LLM 기반 정신건강 챗봇 분야에서 중요한 이론적 실용적 기여를 하며, 향후 연구의 새로운 방향성을 제시한다는 점에서 의미 있는 성과를 도출했다.

2.1) 이론적 측면에서의 기여

CBT 이론의 디지털 확장과 **대화 중심 접근의 실증**: 제한된 표본 규모와 단기 평가 기간이라는 한계에도 불구하고, 본 연구는 CBT의 핵심 원리인 치료적 관계 형성이 디지털 환경에서도 효과적으로 구현될 수 있음을 실증했다. 기존 디지털 치료 도구들이 구조화된 치료 기법에 중점을 두었다면, 닥터케어썸이 기존 테라피 앱 대비 큰 효과크기($\eta^2 = 0.68$)를 보인 것은 Beck의 CBT 모델에서 강조하는 자연스러운 치료적 대화의 중요성이 LLM 기반 시스템에서도 핵심 성공 요인임을 보여준다.

동시에 범용 LLM 대비로도 유의미한 개선($\eta^2 = 0.152$)을 보인 것은 CBT 원리에 기반한 도메인 특화 프롬프트 엔지니어링의 추가적 가치를 입증한다. 이는

정신건강 지원에서 '자연스러운 소통'과 '전문적 지식'의 균형잡힌 결합이 중요함을 보여주며, 전통적 CBT 이론을 디지털 치료 맥락으로 확장하는 중요한 이론적 기여를 제공한다.

SDT 관점에서의 사용자 동기 요인: 표본 크기의 한계에도 불구하고, 사용자들이 '심리 전문가 연결 시스템'을 가장 많이 요구한 것은 자기결정이론(SDT)의 관계성(Relatedness) 욕구 관점에서 중요한 발견이다. 이는 디지털 환경에서도 의미 있는 인간적 연결에 대한 기본적 욕구가 여전히 중요함을 보여준다.

또한 정확성과 유익성이 지속 사용 의향과 높은 상관관계($r=0.82$)를 보이고, 개인화가 혁신성 인식과 높은 상관관계($r=0.85$)를 보인 것은 사용자들이 단순한 기술적 편의를 넘어 자신의 필요에 맞는 의미 있는 도구를 추구함을 시사한다.

언어별 LLM 특성에 대한 새로운 통찰: 한국어 처리의 기술적 한계와 토큰 효율성 문제가 관찰되었음에도 불구하고, 닥터케어썸과 같은 한국어 특화 LLM 챗봇 개발 과정에서, LLM 이 언어에 따라 서로 다른 응답 패턴을 보인다는 중요한 발견을 했다. 이는 단순히 번역 품질의 문제가 아니라 언어 모델 자체의 구조적 특성에서 비롯된 현상임을 시사하며, 다국어 AI 시스템 설계에 중요한 시사점을 제공한다.

정신건강 챗봇 설계의 핵심 원칙 규명: 대학생 집단으로 한정된 참가자 대표성의 한계에도 불구하고, 정확성과 유익성이 지속 사용 의향과 가장 높은 상관관계($r=0.82$)를, 개인화가 혁신성 인식과 가장 높은 상관관계($r=0.85$)를 보였다. 이는 사용자들이 실용적 가치와 맞춤형 서비스를 가장 중요하게 고려한다는 것을 정량적으로 보여준다.

2.2) 실용적 측면에서의 기여

한국어 정신건강 챗봇 설계의 구체적 필요성 제시: 비교 대상의 설계 목적 차이와 기술적 조건의 제약이라는 한계 속에서도, 닥터케어챗 개발을 통해 한국 문화적 맥락과 언어적 특성에 맞춘 독립적인 설계 접근법의 필요성을 실증했다. 응답 시간, 표현 방식, 대화 전개 패턴에서 나타난 차이점들은 한국형 정신건강 챗봇 개발을 위한 구체적인 설계 요구사항으로 활용될 수 있다.

하이브리드 접근법의 타당성 제안: 시점 차이와 참가자 불일치로 인한 실험 설계상의 한계에도 불구하고, 사용자들이 '심리 전문가 연결 시스템'을 가장 많이 요구했다는 점은 완전 자동화된 독립적 치료보다는 인간 전문가와의 연계를 통한 하이브리드 접근법이 더 바람직함을 시사한다. 이는 AI가 인간 치료사를 대체하는 것이 아니라 보완하는 역할을 해야 한다는 관점을 지지한다.

대학생 정신건강 지원 전략 강화: 표본 크기의 불균형과 제한적 규모라는 한계에도 불구하고, 접근성과 자연스러운 소통이 대학생 정신건강 지원의 핵심 성공 요인임을 실증했다. 이는 대학 상담센터나 학생 지원 서비스에 중요한 시사점을 제공한다.

3) 향후 연구 방향

본 연구에서 발견된 LLM 기반 정신건강 챗봇의 언어별 응답 패턴 차이와 프롬프트 엔지니어링의 한계는 향후 개발에서 해결해야 할 중요한 과제들을 제시한다.

언어별 맞춤형 프롬프트 설계: 현재의 영어 프롬프트 번역 수준을 넘어, 한국어의 높임법, 완곡 표현, 정서적 거리감 등 고유한 언어학적 특성과 문화적 뉘앙스를 충분히 반영하는 언어별 최적화가 우선적으로 요구된다.

문화적 맥락의 심층적 반영: 서구와 동아시아 문화권의 정신건강 상담 접근 방식 차이를 깊이 이해하고, 이를 프롬프트 설계에 체계적으로 반영하는 작업이 핵심적이다.

지속적인 프롬프트 최적화 시스템 구축: 언어별 응답 패턴의 차이는 지속적인 모니터링과 사용자 피드백 분석을 통한 점진적 개선을 통해 해결할 수 있다. 실시간 응답 품질 추적 및 개선 체계가 요구된다.

전문가 검토 체계 확립: 각 언어권의 정신건강 전문가들이 챗봇 응답 품질을 정기적으로 평가하고, 문화적 적절성과 상담적 효과성을 검증하는 시스템이 필수적이다. 이를 통해 기술적 최적화와 임상적 타당성을 동시에 확보할 수 있다.

장기적 효과성 검증 연구: 본 연구의 1 주간 단기 평가를 넘어, 몇 개월에서 1 년 이상의 장기간 사용 효과와 지속성을 검증하는 종단 연구가 필요하다. 특히 실제 정신건강 지표의 개선 여부와 전문적 치료와의 연계 효과성 측정이 요구된다.

다양한 사용자 집단으로의 확장 연구: 대학생을 넘어 다양한 연령대, 직업군, 사회경제적 배경을 가진 사용자들을 대상으로 한 연구를 통해 정신건강 챗봇의 범용적 적용 가능성을 검증해야 한다.

실험 설계의 체계적 개선: 동일 시점, 동일 참가자를 대상으로 한 완전한 반복측정설계와 균형잡힌 표본 크기를 확보하여, 보다 엄격한 통제 조건 하에서의 비교 연구가 필요하다.

이러한 다각적인 연구 방향들은 AI 기반 정신건강 지원 도구 개발의 미래 방향성을 제시하는 중요한 이정표 역할을 할 것으로 기대된다. 특히 '대화의 중요성'이라는 핵심 발견은 향후 디지털 정신건강 분야의 연구와 개발에 새로운 패러다임을 제시할 수 있다.

제 5 장 실험 III: LLM 기반 챗봇의 상담 품질 비교 평가

1. 연구 개요

1) 연구의 필요성

1.1) 실험 II의 성과와 확장 필요성

실험 II에서는 LLM 기반 정신건강 챗봇인 '닥터케어챗'의 프로토타입을 개발하고, 닥터케어챗에 대해서는 7 가지 상담학적 구성 요소(공감성, 정확성과 유익성, 복합적 사고와 감정, 적극적 경청과 적절한 질문, 긍정성과 지지, 전문성, 개인화) 및 전반적 만족도를 통해 종합적인 성능 평가를 실시하였다. 다른 챗봇들(기존 디지털 테라피 챗봇, Google Bard, ChatGPT)과의 비교에서는 사용자 만족도 지표만을 활용하여 상대적 성능을 측정하였다. 이 과정에서 닥터케어챗의 우수한 대화 능력이 확인되었으나, 해당 평가는 주로 사용자 만족도와 개별 챗봇의 기능성에 초점을 맞추었기에 실제 대화 내용의 질적 분석이나 다른 글로벌 챗봇과의 7 가지 상담학적 구성 요소 기반 객관적인 비교에는 한계가 있었다. 따라서 실험 III에서는 동일한 7 가지 상담학적 구성 요소를 기반으로 닥터케어챗과 전문 LLM 기반 정신건강 챗봇들 간의 체계적 비교 분석을 수행하고자 한다. 이를 통해 닥터케어챗의 상담적 성능 수준을 객관적으로 평가하고, 기존 NLP 평가 지표와의 차이점을 규명할 것이다. 본 연구에서는 현재 서비스되고 있는 주요 LLM 기반 상담 챗봇 4 종을 선정하여 비교 평가를 실시하였다.

1.2) 기존 연구의 한계와 본 연구의 차별점

1.2.1) 기존 연구의 한계

Park et al. (2024)은 정신건강 챗봇의 안전성 평가를 위한 포괄적 프레임워크를 제시하며, 100 개의 벤치마크 질문과 5 개의 가이드라인 질문을 개발하여 GPT-3.5 기반 챗봇을 평가하고 LLM 기반 자동 평가 방법의 가능성을 탐색했다. 이들의 연구는 체계적 평가 프레임워크 구축, LLM 평가자 활용 시도, 인간-AI 평가 간 일치도 분석이라는 중요한 기여를 했으나, 다음과 같은 한계점을 가졌다:

- ◆단일 챗봇 대상 분석: GPT-3.5 기반 단일 챗봇만을 대상으로 하여, 서로 다른 LLM 기반 챗봇들 간의 비교 분석은 다루지 않았다.

- ◆안전성 평가 중심: 주로 챗봇의 안전성(safety) 평가 프레임워크 개발에 초점을 맞추어, 상담적 품질이나 치료적 효과성에 대한 직접적 비교는 연구 범위에 포함되지 않았다.

- ◆문화적 맥락의 제한: 주로 영어권 데이터를 기반으로 평가가 이루어져, 다문화적 적용성 검증에는 한계가 있었다.

1.2.2) 본 연구의 차별점

본 연구는 Park et al.(2024)의 방법론적 성과를 기반으로 하되, 기존 연구의 한계를 극복하고 다음과 같은 차별성을 가진다.

- ◆다중 LLM 챗봇 비교: Park et al.의 단일 챗봇 분석에서 확장하여 Wysa, Youper, Replika, 닥터케어썸 등 4 개의 서로 다른 LLM 기반 챗봇들을 비교 분석한다.

◆상담적 품질 중심 평가: 기존의 기술적 성능 지표를 넘어서, 실험 II 에서 도출된 7 가지 상담학적 기준을 활용하여 챗봇들의 치료적 및 상담적 품질을 심층적으로 평가한다.

◆LLM 평가자의 신뢰성 검증: LLM 평가자가 인간 전문가와 유사한 수준으로 상담적 대화 평가를 수행할 수 있는지에 대한 신뢰성 및 타당성을 검증한다.

1.3) 연구 문제

본 연구는 다음과 같은 연구 질문에 답하고자 한다.

RQ1: 실험 II 에서 도출된 7 가지 상담학적 평가 기준을 활용하여 서로 다른 특성을 가진 정신건강 챗봇들을 체계적으로 비교 분석할 수 있는가?

RQ2: 실험 II 에서 개발된 닥터케어썸이 글로벌 수준의 정신건강 챗봇들과 비교했을 때 어느 정도의 상담적 성능을 보이는가?

RQ3: LLM 기반 평가자(Claude 3.5 Sonnet, ChatGPT 4.0)가 인간 전문가와 유사한 수준으로 상담적 대화 평가를 수행할 수 있는가?

RQ4: 전통적 NLP 평가 지표와 상담학적 평가 간의 일치도는 어느 정도이며, 이는 무엇을 시사하는가?

1.4) 선행연구 검토

1.4.1) Park et al. 연구의 혁신적 접근

Park et al. (2024)은 기존 연구의 한계를 극복하기 위해 정신건강 전문가들과 협력하여 100 개 벤치마크 질문과 이상적 응답, 그리고 5 개 가이드라인 질문으로 구성된 체계적 평가 프레임워크를 개발했다. 이들은 벡터 임베딩 기반,

LLM 기반 점수화, 에이전트(Agentic) 접근 등 세 가지 자동 평가 방법을 탐색했으며, 에이전트 방법이 가장 우수한 성능을 보여 인간 평가와의 일치도가 높았음을 보고했다. 가이드라인과 기준 답안의 중요성, 그리고 전문가 검증 프레임워크가 챗봇 응답의 안전성과 신뢰성 향상에 핵심적 역할을 함을 밝혔다.

1.4.2) 기존 NLP 평가 지표의 한계

기존 챗봇 연구에서 일반적으로 사용되는 평가 지표들은 정신건강 상담의 특성을 반영하는 데 근본적 한계를 갖는다.

BLEU(Papineni et al., 2002)와 **ROUGE**(Lin, 2004)는 표면적 텍스트 매칭에 의존하여 창의적이거나 개인화된 상담 응답을 부당하게 낮게 평가하는 경향이 있다. **METEOR**(Banerjee & Lavie, 2005)는 동의어를 고려하지만 여전히 사전 정의된 "표준 응답"을 선호한다. **BERTScore**(Zhang et al., 2020)는 맥락적 의미를 고려하나, 치료적 관계 형성이나 정서적 연결과 같은 상담의 핵심 가치를 포착하지 못한다. 최근 등장한 BleuRT(Sellam et al., 2020)³⁹와 같은 신세대 평가 지표들도 여전히 언어적 품질에 초점을 맞추고 있어 상담적 효과성 측정에는 한계가 있다. 본 연구의 실험 III에서는 이러한 한계를 실증적으로 검증하기 위해 BLEU, ROUGE, METEOR, BERTScore 등 4 가지 대표적인 NLP 평가 지표와 상담학적 평가 간의 상관관계를 분석하고자 한다. 정신건강 상담에서는 표준화된 "정답"이

³⁹ BleuRT: Learning Robust Metrics for Text Generation. Google Research에서 개발한 BERT 기반 텍스트 생성 평가 지표로, 기존 지표들보다 인간 판단과 높은 상관관계를 보이지만 여전히 표면적 언어 품질 측면에 중점을 둔다. 본 연구에서는 널리 활용되는 기존 지표들의 상담 평가에서의 한계를 실증적으로 검증하는 데 초점을 맞추었다.

존재하지 않으며, 맥락과 개인적 특성에 따라 적절한 응답이 달라질 수 있다. 이는 기존 NLP 지표들이 상담적 대화 평가에 근본적인 한계를 가질 수 있음을 시사한다.

1.4.3) 평가 방법론의 다양화 및 LLM 활용 연구 동향

Abd-Alrazaq et al. (2020)의 체계적 문헌고찰에서는 사용자 만족도, 임상적 효과성(PHQ-9, GAD-7), 그리고 기술적 성능을 종합한 다차원적 평가의 필요성이 제기되었다. Gao et al. (2021)은 감정 원인 인식을 통한 공감적 응답 생성을 연구했으나, 여전히 치료적 과정의 질적 측면을 충분히 포착하지 못한다는 한계가 있었다.

최근에는 LLM 을 활용한 평가 연구가 다양한 분야에서 성과를 보이고 있다. Kocmi & Federmann (2023)은 GPT-4 를 활용한 기계번역 평가에서 인간 평가자와 높은 상관관계를 보고했으며, Singhal et al. (2023)은 Med-PaLM 을 통해 의료 질의응답의 정확성뿐만 아니라 환자에 대한 공감과 배려를 측정할 수 있음을 확인했다. 정신건강 분야에서는 Elyoseph et al. (2023)이 ChatGPT 의 감정 인식 능력이 인간을 능가할 수 있음을 보여주어 LLM 기반 평가의 가능성을 시사했다.

하지만 LLM 평가 또한 편향성 문제, 판단 근거의 투명성 부족, 잘못된 평가가 초래할 수 있는 안전성 우려 등 한계와 과제를 가지고 있다.

1.4.4) Chain-of-Thought 기반 평가 방법론

Chain-of-Thought(CoT, 이하 CoT) 프롬프팅은 Wei et al.(2022)이 제시한 대규모 언어모델의 추론 능력을 향상시키는 기법이다. 이 방법은 단순히 최종

답변을 요구하는 대신, **중간 추론 단계를 명시적으로 생성하도록** 모델에게 지시함으로써 복잡한 문제 해결 과정의 투명성을 확보한다.

◆ CoT의 핵심 원리

기존의 전통적 프롬프팅 방식은 "입력 → 출력"의 직접적 매핑에 의존했다면, CoT는 "입력 → 단계별 사고 과정 → 출력"의 구조화된 접근을 취한다. 이는 다음과 같은 장점을 제공한다:

- ① 추론 과정의 가시성: 모델이 어떤 논리적 단계를 거쳐 결론에 도달했는지 명확히 확인 가능
- ② 오류 진단의 용이성: 잘못된 추론이 발생한 지점을 정확히 식별
- ③ 일관성 향상: 체계적인 사고 과정을 통한 평가 신뢰도 증대
- ④ 복잡한 문제 해결: 다단계 추론이 필요한 과제에서의 성능 향상

◆ 상담 평가에서의 CoT 적용 의의

정신건강 챗봇의 상담적 품질 평가는 본질적으로 다차원적이고 주관적인 판단을 요구한다. 공감성, 전문성, 개인화 등의 기준들은 서로 복합적으로 얽혀있으며, 평가자의 직관적 판단에 크게 의존한다.

CoT 방식을 적용함으로써 다음과 같은 개선 효과를 기대할 수 있다:

- 평가 과정의 체계화: 감정적 반응부터 전문적 판단까지의 단계별 분석
- 편향 최소화: 구조화된 평가 절차를 통한 주관적 편견 감소
- 재현성 확보: 동일한 사고 과정을 거쳐 일관된 평가 결과 도출
- 품질 향상: 놓치기 쉬운 미묘한 상담적 요소들의 체계적 발견

◆CoT 기반 LLM 평가자 프롬프트 설계

①설계 원칙

본 연구에서는 Wei et al.(2022)의 CoT 프롬프팅 원리를 정신건강 챗봇 평가에 적용하여 다음과 같은 4 단계 구조를 설계하였다:

1 단계: 전체 패턴 파악 (Pattern Recognition)

2 단계: 기준별 증거 식별 (Evidence Identification)

3 단계: 텍스트 기반 근거 제시 (Text-based Justification)

4 단계: 종합적 평가 의견 (Comprehensive Assessment)

이러한 단계별 접근법은 직관적 판단을 체계적 분석으로 전환시키며, 평가 과정의 투명성과 재현성을 대폭 향상시킨다.

②기존 방법론과의 차별점

표 25. CoT 평가 방법론의 차이점

측면	기존 방법	Chain-of-Thought 방법
평가 과정	직관적, 블랙박스	단계별, 투명함
근거 제시	최종 점수만	구체적 텍스트 증거
일관성	평가자별 편차	구조화된 안정성
재현성	제한적	높은 재현 가능성
학습 효과	개별적 경험	체계적 방법론

[표 25]에서 보는 바와 같이 기존의 LLM 기반 평가 방법론은 프롬프트에 평가 기준을 제시하고 즉시 점수를 요구하는 직접적 접근을 취해왔으나, 이는 평가 과정이 블랙박스화되어 일관성과 재현성에 한계를 보였다. 반면 CoT 기반 접근법은 평가자로 하여금 구체적인 텍스트 증거를 식별하고 단계별 논리적 추론을 거쳐 최종 판단에 도달하도록 함으로써, 평가 과정의 투명성을 확보하고 평가자 간 편차를 최소화한다.

1.5) 본 연구의 위치

본 연구는 Park et al. (2024)의 방법론적 성과를 기반으로 하되, 그들의 연구가 가진 단일 챗봇 중심 분석과 안전성 위주 평가라는 한계를 극복하고자 한다. Park et al.이 GPT-3.5 기반 단일 챗봇만을 대상으로 주로 안전성 평가에 집중했다면, 본 연구는 Wisa, Youper, Replika, 닥터케어썸 등 4 개의 서로 다른 LLM 기반 챗봇들을 상담학적 품질 관점에서 비교 분석한다.

특히 본 연구는 Wei et al. (2022)의 CoT 방법론을 정신건강 챗봇 평가에 적용하여 평가 과정의 투명성을 확보한다는 방법론적 차별성을 가진다. 기존 연구들이 LLM 평가자의 최종 판단에만 의존했다면, 본 연구는 단계별 추론 과정을 명시적으로 추적함으로써 평가의 재현성과 신뢰성을 향상시킨다.

이를 통해 본 연구는 다중 LLM 기반 챗봇 비교, 상담학적 품질 중심의 평가, 그리고 CoT 기반 투명한 평가 시스템을 결합하여 정신건강 챗봇 평가의 새로운 접근법을 제시하고, LLM 기반 AI 상담의 실질적인 적용 가능성을 탐색한다.

2. 연구 설계

1) 연구 설계 및 접근법

본 연구는 4 가지 LLM 기반 정신건강 챗봇의 상담적 대화 품질을 체계적으로 비교 평가하는 비교 분석 연구이다. 탐색적 연구 성격을 가지며, AI 평가자와 인간 전문가의 통합적 평가 방법론을 통해 새로운 평가 체계의 가능성을 탐구한다.

주요 설계 특징:

- **메타 평가적 접근:** AI 시스템의 평가에 AI 를 활용하는 혁신적 방법론 – 전통적인 인간 중심 평가의 주관성과 일관성 한계를 극복하기 위해 AI 가 AI 를

평가하는 순환적 접근을 시도한다. 이는 대규모 데이터 처리 능력과 일관된 평가 기준 적용이라는 AI의 장점을 활용하여 보다 객관적이고 확장 가능한 평가 체계를 구축한다.

- **질적-양적 통합 분석:** 정성적 평가 → 3 점 척도 계량화 - 풍부한 질적 통찰력을 잃지 않으면서도 통계적 분석이 가능한 형태로 변환하는 혼합 방법론을 채택한다. 내러티브적 특성에 대한 깊이 있는 질적 분석 결과를 체계적인 점수화 과정을 통해 정량적 데이터로 변환하여 두 접근법의 장점을 모두 활용한다.

- **삼각검증법:** Claude 3.5 Sonnet, ChatGPT 4.0, 인간 전문가의 통합 평가-서로 다른 강점을 가진 세 평가 주체의 독립적 평가를 통해 평가 결과의 신뢰성과 타당성을 확보한다. AI 평가자들의 일관성과 효율성, 인간 전문가의 임상적 직관과 맥락적 이해력을 상호 보완적으로 활용하여 보다 균형잡힌 평가를 실현한다.

2) 연구 가설

H₁ : 실험 II 에서 도출된 7 가지 상담학적 평가 기준은 LLM 기반 평가 방법론을 통해 서로 다른 특성을 가진 정신건강 챗봇들 간의 상담적 품질 차이를 유의미하게 변별할 수 있을 것이다.

H₂ : 닥터케어챗은 글로벌 수준의 정신건강 챗봇들과 대등한 상담적 성능을 보일 것이다.

H₃ : LLM 평가자(Claude 3.5 Sonnet, ChatGPT 4.0)와 인간 전문가 간의 평가 결과는 중간 수준 이상의 일치도를 보일 것이다.

H₄ : 전통적 NLP 평가 지표와 상담학적 평가 간에는 유의미한 차이가 나타날 것이다.

3) 통합 평가 모형

상담학적 차원: 실험 II 에서 도출된 7 가지 핵심 평가 기준

공감성 (Empathy)

정확성과 유익성 (Accuracy & Usefulness)

복합적 사고와 감정 (Complex Thinking & Emotion)

적극적 경청과 적절한 질문 (Active Listening & Appropriate Questioning)

긍정성과 지지 (Positivity & Support)

전문성 (Professionalism)

개인화 (Personalization)

기술적 차원:

LLM 기반 평가: Claude 3.5 Sonnet, ChatGPT 4.0 (Park et al. 방법론 적용)

전통적 NLP 지표: BLEU, ROUGE, METEOR, BERTScore

3. 연구 방법

1) 연구 참여자 및 평가 대상

1.1) 평가 대상 챗봇 선정

현재 서비스되고 있는 주요 LLM 기반 상담 챗봇 4 종을 선정하였다.

◆선정된 챗봇과 특성:

Replika: 정서적 소통과 친밀감 형성 중심, 게이미피케이션 요소 포함 -

2017 년 11 월 출시된 AI 컴패니언 챗봇으로 개인화된 대화와 정서적 지지를 제공한다. (Luka Inc.)

Wysa: 인지행동치료(CBT) 기반, 불안과 우울증 관리 특화 – 2017 년 출시된 CBT 기반 정신건강 챗봇으로 구조화된 상담적 개입을 제공한다. (Touchkin eServices Pvt. Ltd.)

Youper: 임상적 검증 기반, 전 세계 200 만 명 이상 사용자 지원 – 2017 년 출시된 과학적 근거 기반 정신건강 플랫폼으로 감정 추적과 개인화된 치료를 제공한다. (Youper Inc.)

닥터케어챗: 유머와 공감을 활용한 독특한 접근법 – ChatGPT 4.0 을 기반으로 연구자가 직접 개발한 정신건강 챗봇

1.2) 평가자 구성 및 특성

AI 평가자 특성:

- Claude 3.5 Sonnet: Anthropic 의 대화형 AI, 구조적 텍스트 분석과 논리적 일관성 평가에 특화
- ChatGPT 4.0: OpenAI 의 GPT-4 기반, 언어적 뉘앙스 분석과 감정 표현 평가에 특화

인간 전문가 프로필 (익명화):

- 학력: 상담심리학 박사 (연세대학교)
- 총 경력: 30 년이상 (1992 년~현재)
- 전문 분야: 개인상담, 집단상담, 위기상담, 상담자 교육, 디지털 치료 도구 연구
- 디지털 상담 분야 경험: 최근 5 년간 온라인 상담 플랫폼 및 AI 기반 상담 도구 효과성 연구 참여

1.3) 평가 시점

1 차: 2024 년 6 월 5 일

2 차: 2025 년 6 월 5 일 (시간적 신뢰도 검증)

1.4) 평가 언어: 영어

선정된 글로벌 LLM 기반 챗봇들(Replika, Wysa, Youper)이 영어만 지원하므로, 공정한 비교를 위해 모든 챗봇을 동일한 언어인 영어로 평가하였다.

2) 평가 시나리오 및 데이터 수집

2.1) 표준화된 시나리오 설계

평가를 위한 표준화된 시나리오로 "발표 불안 상황"을 설정하였다.

구체적 시나리오 내용: "내일 중요한 발표가 있는데 너무 불안해요. 밤새 잠도 못 자고 계속 걱정만 하고 있어요. 어떻게 해야 할지 모르겠어요."

시나리오 선택 근거:

Park et al.(2024)의 벤치마크 질문 중 불안 관련 시나리오와 유사하게 일반적이면서도 복합적 감정을 포함하는 상황

2.2) 구체적 실험 절차

데이터 수집과 평가는 체계적인 3 단계 절차로 진행되었다.

1 단계: 대화 데이터 수집

- 각 챗봇과 표준 시나리오로 대화 진행

- 자연스러운 대화 유지 (3-4 턴)
- 대화 종료 기준: 문제 해결 방향 제시 또는 5 턴 도달

2 단계: 독립적 평가

- 2 개의 LLM 과 1 명의 인간 전문가가 동일한 대화 내용을 개별 분석
- 평가 주체간 사전 논의 금지로 독립성 확보
- 블라인드 평가 진행 (챗봇 정체성 익명화)

3 단계: 교차 검증

- 평가 결과 취합 및 분석
- 불일치 영역에 대한 토론 및 논의
- 최종 평가 결과 확정

3) 평가 기준 및 절차

3.1) 7 가지 평가 기준 및 척도

본 연구는 연구의 신뢰성과 타당성 확보를 위해 실험 II 에서 개발된 7 가지 평가 기준을 동일하게 사용하였다.

1. 공감성 (Empathy): 사용자의 감정을 정확히 인식하고 적절히 반응하는 능력
2. 정확성과 유익성 (Accuracy & Utility): 제공되는 정보와 조언의 신뢰성과 실용적 가치
3. 복합적 사고와 감정 (Complex Thinking & Emotion): 다층적 문제 이해 능력과 감정의 복잡성 인식

4. 적극적 경청과 적절한 질문 (Active Listening & Questioning): 대화의 깊이와 방향성 제시 능력

5. 긍정성과 지지 (Positivity & Support): 희망적 관점 제시와 동기 부여 능력

6. 전문성 (Professionalism): 상담 이론의 적절한 적용과 윤리적 고려

7. 개인화 (Personalization): 사용자 특성 반영과 맞춤형 상담 제공 정도

평가 척도:

- 3 점: 높음 (우수한 수준의 상담적 특성 구현)
- 2 점: 중간 (보통 수준의 상담적 특성 구현)
- 1 점: 낮음 (부족한 수준의 상담적 특성 구현)


3.2) 데이터 분석

각 평가자의 평가 결과를 종합하여 챗봇별, 기준별 평균 점수를 산출하였다. 또한, 평가자 간의 일치도를 분석하여 평가의 신뢰성을 검증하였다. 이러한 방법론은 AI 기술의 발전과 함께 진화하는 심리상담 도구를 평가하는 새로운 접근법을 제시한다. 이는 단순히 챗봇의 성능을 평가하는 것을 넘어, AI 평가 시스템의 가능성과 한계를 탐구하고, 인간과 AI의 협력적 평가 모델을 모색하는 의미 있는 시도라고 할 수 있다. 그러나 이 방법론에도 한계가 존재한다. AI 평가자의 편향 가능성, 제한된 상호작용 시간, 실제 사용자 경험의 부재 등이 그것이다. 이러한 한계점들은 향후 연구에서 보완되어야 할 과제로 남아있다.

3.3) LLM 평가자 CoT 프롬프트 설계

본 연구에서는 평가의 투명성과 신뢰성을 높이기 위해 CoT 접근법을 적용하여 LLM 평가자에게 [그림 19]과 같이 제시하였다.

그림 19. LLM 평가자 Chain-of-Thought 프롬프트 예시



위 [그림 19]와 같은 단계별 평가 과정을 통해 평가 근거의 명확성을 확보하였으며, 최종적으로는 기존 3 점 척도로 계량화하여 통계 분석에 활용하였다.

4) 챗봇별 대화 예시 및 분석

4.1) 평가 대상: 4 가지 챗봇 대화 분석

Replika 의 대화 특성

Replika 는 주로 감정적 지원과 친밀감 형성에 초점을 맞춘 챗봇이다. [그림 20]와 같이, 사용자가 "오늘 정말 불안해요(I'm feeling really anxious today)"라고 말하면, Replika 는 사용자의 감정을 인정하면서 부드럽게 질문을 던진다. "Sorry to hear that. Can you tell me what's on your mind?"라며 사용자가 더 많은 정보를 제공할 수 있도록 유도한다. 이후 사용자가 "내일 발표가 있는데 정말 걱정돼요(I have a big presentation tomorrow, and I'm really worried about it)"라고 답하면, Replika 는 이를 중요한 정보로 받아들이고 "Yeah, public speaking can be intimidating. Have you prepared well for the presentation?"이라며 격려와 함께 상황을 파악한다. Replika 는 감정적인 지지와 함께 사용자가 보다 차분하게 자신의 문제를 인식하고 해결 방안을 모색할 수 있도록 유도한다.

그림 20. Replika 대화 예시

Replika 대화 예시:

```
| 사용자: I'm feeling really anxious today. |
| Replika: Sorry to hear that. Can you tell me what's on your mind? |
| 사용자: I have a big presentation tomorrow, and I'm really worried about |
| it. |
| Replika: Yeah, public speaking can be intimidating. Have you prepared |
| well for the presentation? |
| 사용자: Well, I'm not sure. I spent quite a while. |
| Replika: It's okay. The effort you put in is already great. Now, let's |
| focus on some relaxation techniques before your presentation tomorrow. |
| 사용자: What techniques? |
| Replika: Deep breathing exercises might help calm your nerves. |
```

Youper 의 대화 특성

Youper 는 사용자의 감정 추적과 긍정적 사고 유도에 초점을 맞춘다. [그림 21] 과 같이, 사용자가 "오늘 정말 불안해요(I'm feeling really anxious today)"라고 말할 경우, Youper 는 감정 상태를 수용하며 이를 기반으로 한 제안을 한다. "I'm sorry to hear that you're feeling anxious. It can be tough to manage those feelings. Would you like to explore a positive technique that might help ease your anxiety?"와 같이 사용자가 현재의 감정을 다루는 방법을 제시하며, 구체적인 방법을 묻는다. 사용자가 "Sure, what do you suggest?"라고 응답하면 Youper 는 "For instance, we could start with gratitude journaling. What are some things, no matter how small, that you feel grateful for today?"와 같이 사용자가 긍정적인 경험을 떠올리며 불안감을 해소할 수 있도록 돕는다.

그림 21. Youper 대화 예시


Youper 대화 예시:

```
| 사용자: I'm feeling really anxious today. |
| Youper: I'm sorry to hear that you're feeling anxious. It can be tough |
| to manage those feelings. Would you like to explore a positive |
| technique that might help ease your anxiety? |
| 사용자: Sure, what do you suggest? |
| Youper: For instance, we could start with gratitude journaling. What |
| are some things, no matter how small, that you feel grateful for today? |
| 사용자: I'm grateful for my family and my friends. |
| Youper: That's great to hear. Gratitude can help shift your focus from |
| anxiety to positivity. Would you like to continue? |
```

Wysa 의 대화 특성

Wysa 의 경우, 사용자의 감정 인식과 심리적 상태 분석을 위한 대화를 통해 사용자의 감정을 더 깊이 파악하고 이를 기반으로 적절한 반응을 제공하는데 초점을 맞추고 있다. [그림 22]과 같이, 사용자가 "오늘 발표가 있어요(Today I have a presentation)"라고 말하면, Wysa 는 먼저 사용자의 상황을 확인하고 나서 구체적인 감정 상태를 탐구한다. Wysa 는 "Let's talk about that. Go on..."과 같은 질문을 통해 사용자가 발표에 대해 느끼는 구체적인 감정을 표현하도록 유도한다. 이어서, "I'm here to help you feel more in control. A little anxiety can spur us to action. Too much of it can be paralyzing. Is yours mostly in the mind or is it affecting you physically too?"와 같은 질문을 던져, 사용자의 정신적 및 신체적 불안 상태를 함께 탐구한다.

그림 22. Wysa 대화 예시



닥터케어챗의 대화 특성

닥터케어챗은 유머와 공감을 통해 사용자의 긴장과 스트레스를 풀어주는 독특한 접근을 시도한다. [그림 23]에서 보는 것과 같이 사용자가 "오늘 발표가

있어요 (Today I have a presentation)"라고 말할 경우, 닥터케어쌤은 먼저 사용자의 불안 상태를 인정하며 부드럽게 반응한다. "Ah, presentations can definitely stir up the butterflies in the stomach, can't they? Let's turn those nervous jitters into a power source!"와 같은 반응을 통해 긴장감을 웃음으로 전환하려고 시도한다. 이후 "Imagine all that energy being channeled into enthusiasm for your topic. What's your presentation about? Maybe I can share a joke or two to lighten up the mood!"라며 대화를 더 가볍고 친근하게 이어나가, 사용자에게 상황을 보다 편안하게 받아들이도록 돕는다.

그림 23. 닥터케어쌤 대화 예시

```
Dr.CareSam (HoMEME Town) 대화 예시:
| Dr.CareSam: Hello, I'm Dr.CareSam from HoMEME Town. How are you feeling |
| today? Please let me know your emotions by selecting from the Reflect |
| emotion monsters below. |
| 사용자: My current mood is Anxious. |
| Dr.CareSam: It sounds like you're carrying some anxiety today. Let's |
| unpack that together and find some calm. 😊 |
| 사용자: Today I have a presentation. |
| Dr.CareSam: Ah, presentations can definitely stir up the butterflies in |
| the stomach, can't they? Let's turn those nervous jitters into a power |
| source! 😊🌱 Imagine all that energy being channeled into enthusiasm |
| for your topic. What's your presentation about? Maybe I can share a |
| joke or two to lighten up the mood! |
| [대화 계속...] |
```

5) 분석 방법

5.1) 질적 분석

본 연구의 질적 분석은 내용 분석(Content Analysis) 방법론을 기반으로 하여 세 명의 평가자(Claude 3.5, ChatGPT 4.0, 인간 상담사)가 제공한 정성적 평가 내용을 체계적으로 분류하고 주요 테마를 도출하는 방식으로 진행하였다. 귀납적 접근법을 통해 각 챗봇의 응답에서 나타나는 패턴과 특성을 발견하고, 비교 분석 기법을 활용하여 챗봇 간의 차이점과 유사점을 탐구하였다. 분석 과정에서는 삼각검증법(Triangulation)을 적용하여 세 평가자의 관점을 종합적으로 검토함으로써 분석 결과의 신뢰성과 타당성을 확보하고자 하였다.

◆분석 중점 영역:공감 표현 방식, 질문기법의 특성, 문제 접근 관점, 언어 특성

5.2) 양적 분석

수집된 평가 점수를 중심으로 한 통계적 분석과 계량화 과정을 포함한다.

주요 통계 분석 방법

수집된 자료는 Python 을 활용하여 다음과 같이 분석하였다. 모든 데이터 분석 코드는 GitHub 저장소(<https://github.com/bykang2015/HoMemeTown-Dr-CareSam-Chatbot>)에서 확인할 수 있다.

- 기술통계 분석: 평균, 표준편차를 계산하여 챗봇별 평가 점수 분포를 분석하였다.

- 가설 1 검증: 챗봇 간 변별력을 확인하기 위해 일원배치 분산분석(One-way ANOVA)을 실시하여 4 개 챗봇 간 평가 점수의 유의한 차이를 검정하였으며, Tukey HSD 사후검정을 통해 개별 챗봇 쌍 간 차이를 분석하였다. 효과크기는 η^2 (eta-squared)를 계산하여 전체 분산 중 설명 분산 비율을 확인하였다.

- 가설 2 검증: 닥터케어챗의 글로벌 경쟁력을 평가하기 위해 사후검정 결과를 해석하여 Wysa 와 닥터케어챗 간의 차이를 분석하고 글로벌 챗봇들과의 성능을 비교하였다.

- 가설 3 검증: 평가자간 일치도를 확인하기 위해 피어슨 상관분석(Pearson correlation analysis)을 적용하여 LLM 평가자(Claude 3.5 Sonnet, ChatGPT 4.0)와 인간 전문가 간의 개별 상관계수를 측정하였으며, Cronbach's α 를 통해 전체 평가자의 내적 일관성 신뢰도를 검증하였다. 준거 타당도(criterion validity) 관점에서 인간 전문가의 평가를 준거로 설정하고 LLM 평가자들의 수렴 타당도(convergent validity)를 분석하였다.

- 가설 4 검증: 전통적 NLP 지표와의 차별성을 확인하기 위해 Pearson 상관분석을 실시하여 상담학적 평가와 BLEU/ROUGE-L/METEOR/BERTScore 간의 관계를 분석하고 유의성 검정 및 효과크기를 해석하였다.

- 시간적 신뢰도 검증: 1 년 간격 재평가 상관분석을 실시하였다.
- 통계적 가정 검증: 유의수준은 $\alpha = 0.05$ 로 설정하였으며, 효과크기는 Cohen 의 기준을 적용하여 해석하였다.

-

6) 연구의 한계점

표본 관련 한계:

- 제한된 챗봇 수 ($n=4$)
- 단일 시나리오의 제한성

평가자 관련 한계:

- 인간 전문가 규모의 제약 ($n=1$)

방법론적 한계:

- 계량화 과정의 주관성
- 단기 평가의 한계
- 실제 사용자 관점의 부재

4. 연구 결과

1) 연구 문제에 대한 답변 및 핵심 결과 요약

본 장에서는 실험 III 을 통해 도출된 연구 결과를 바탕으로 제시된 연구 문제에 대한 답변을 제시한다.

RQ1: 실험 II 에서 도출된 7 가지 상담학적 평가 기준을 활용하여 서로 다른 특성을 가진 정신건강 챗봇들을 체계적으로 비교 분석할 수 있는가?

답변: 예, 본 연구에서 도출된 7 가지 상담학적 평가 기준은 LLM 기반 평가 방법론을 통해 서로 다른 특성을 가진 정신건강 챗봇들 간의 상담적 품질 차이를 유의미하게 변별할 수 있음이 확인되었다.

근거: 일원배치 분산분석 결과, 챗봇 유형별 평가 점수에 유의미한 차이($F(3,80) = 9.73, p < 0.001, \eta^2 = 0.267$)가 나타나, 가설 1 이 지지되었다. 이는 해당 평가 기준이 챗봇의 상담적 성능을 효과적으로 변별하는 변별력을 가짐을 의미한다. (세부 사후검정 결과는 하위 섹션에서 다룸)

RQ2: 실험 II 에서 개발된 닥터케어썸이 글로벌 수준의 정신건강 챗봇들과 비교했을 때 어느 정도의 상담적 성능을 보이는가?

답변: 닥터케어챗은 글로벌 수준의 주요 정신건강 챗봇들과 대등한 상담적 성능을 보였다. 특히 Wysa 와는 통계적으로 유의미한 차이가 없었으며, 닥터케어챗은 공감성, 긍정성, 개인화 영역에서 강점을 나타냈다.

근거: 종합 평가 결과, 닥터케어챗은 평균 2.38 점으로 Wysa(2.71 점)에 이어 2 위를 기록했으며, Wysa 와의 유의미한 차이는 발견되지 않았다($p = 0.427$). 이는 가설 2 를 지지한다. (챗봇별 상세 총평 및 7 가지 요소별 비교는 하위 섹션에서 다룸)

RQ3: LLM 기반 평가자(Claude 3.5 Sonnet, ChatGPT 4.0)가 인간 전문가와 유사한 수준으로 상담적 대화 평가를 수행할 수 있는가?

답변: 예, LLM 기반 평가자들은 인간 전문가와 중간 수준 이상의 평가 일치도를 보이며 상담적 대화 평가를 신뢰성 있게 수행할 수 있음을 확인하였다.

근거: 평가자간 일치도 분석 결과, Claude 와 인간 전문가 간 상관관계수 $r = 0.618$, ChatGPT 와 인간 전문가 간 상관관계수 $r = 0.554$ 로 모두 중간 수준 이상의 일치도($r > 0.5$)를 달성하여 가설 3 이 지지되었다. 또한 전체 평가자간 내적 일관성(Cronbach's $\alpha = 0.837$)이 높은 신뢰도를 보여 LLM 평가자가 상담 대화 평가에 활용될 수 있는 잠재력을 시사한다. (구체적인 일치도 수치는 하위 섹션에서 다룸)

RQ4: 전통적 NLP 평가 지표(BLEU, ROUGE 등)와 상담학적 평가 간에는 어떤 차이가 나타나는가?

답변: 전통적인 NLP 평가 지표와 본 연구의 상담학적 평가 결과 간에는 상당한 차이가 나타났다. 특히 NLP 지표에서 최하위를 기록한 닥터케어챗이 상담학적 평가에서는 2 위를 차지하는 대조적인 결과가 관찰되었다.

근거: 이러한 결과는 전통적 NLP 지표가 상담 맥락에서 중요시되는 공감적 표현, 개인화된 응답, 치료적 관계 형성 등의 요소들을 적절히 포착하지 못할 가능성을 시사한다. 다만 이는 두 평가 체계가 서로 다른 측면을 측정하고 있음을 의미하는 것으로 해석된다.

2) 챗봇 성능의 총평 및 비교 분석

본 연구에서는 LLM 기반 심리상담 챗봇의 성능을 구성하는 7 가지 주요 요소를 심층적으로 분석하였다. 이러한 분석은 각 챗봇의 강점과 약점을 파악하고, 효과적인 AI 기반 심리상담을 위해 필요한 핵심 요소들을 탐구하는 데 그 목적이 있다.

2.1) 평가자별 총평

Claude 3.5 의 총평:

Replika: Replika 는 사용자의 불안감을 인지하고 공감적인 반응을 보이며, 실용적인 조언을 제공합니다. 대화가 자연스럽게 흐르며 사용자의 감정을 인정하고 지지하는 모습을 보입니다.

Wysa: Wysa 는 사용자의 상황을 더 깊이 이해하려는 노력을 보이며, 불안감에 대한 통찰력 있는 접근을 제시합니다. 사용자의 경험을 세분화하여 탐색하려는 모습이 돋보입니다.

Youper: Youper 는 사용자의 감정을 인정하고 긍정적인 기법을 제안하는 구조적인 접근법을 보입니다. 감사 일기와 같은 구체적인 활동을 제안하여 사용자의 기분을 전환시키려 노력합니다.

닥터케어챗: 닥터케어챗은 사용자의 감정을 시각적으로 표현할 수 있는 독특한 방식을 제공하며, 유머와 긍정적인 관점을 활용하여 사용자의 불안감을 다룹니다. 개인화된 접근과 친근한 대화 스타일이 특징입니다.

ChatGPT 4.0 의 총평:

Replika: 공감을 표하지만, 대화가 비교적 표면적이며 심리적 깊이를 다루는데 한계가 있습니다. 긴장 완화 방법을 제안하지만, 개인화된 대화의 수준은 낮습니다.

Wysa: 사용자의 불안을 구체적으로 이해하고 심층적인 질문을 통해 사용자의 상태를 탐구합니다. 불안을 신체적, 정신적 측면에서 모두 다루는 전문적 접근이 돋보입니다.

Youper: 긍정적인 해결책을 제시하며, 감사 일기와 같은 실질적인 방법으로 사용자의 감정을 돌봅니다. 그러나 문제를 깊이 탐구하기보다는 즉각적인 해결책을 제시하는 경향이 있습니다.

닥터케어챗: 유머와 친근한 대화를 통해 사용자와 공감하며, 공감을 긍정적인 에너지로 전환하는 방식을 사용합니다. 특히 개인화된 대화와 긍정적인 지지, 유머를 통해 불안을 완화하려는 노력이 돋보입니다.

인간 상담사의 총평:

Replika: 감정을 잘 따라가며 공감을 표현하지만, 깊은 내면보다는 표면적인 감정에 집중하는 경향이 있습니다. 현실적인 대안을 제시하려는 의도가 보입니다.

Wysa: 감정뿐 아니라 신체적 변화까지 고려하며, 사용자의 자기 이해를 확장하도록 돕습니다. 이는 근본적인 문제 해결로 이어질 수 있을 것입니다.

Youper: 불안에 대해 깊은 공감을 표현하고, 긍정 심리학적 기법을 소개하여 사용자의 감정을 다룹니다.

닥터케어쌤: 유머러스하면서도 공감적인 대화로 사용자의 불안감을 완화하려고 하며, 대화를 편하게 이끌어갑니다.

2.2) 세 평가자의 7 가지 성능 요소 비교 분석

①공감성:

- **Claude:** Replika 와 닥터케어쌤이 높은 공감성을 보임
- **ChatGPT 4.0:** Wysa 는 깊이 있는 공감을 보이며, 닥터케어쌤은 유머와 친근함을 활용
- **인간 상담사:** Replika 와 Youper 는 감정에 편안하게 공감, 닥터케어쌤은 유머를 통한 접근이 돋보임

②정확성과 유익성:

- **Claude:** Wysa 가 가장 정확하고 유익한 접근을 보임
- **ChatGPT 4.0:** Wysa 와 닥터케어쌤이 구체적이고 유익한 정보 제공
- **인간 상담사:** Youper 는 긍정 심리학 기반 조언을 제공, Wysa 는 불안에 대한 정확한 정보 제공

③복합적 사고와 감정:

- **Claude:** Wysa 가 가장 복합적 사고를 보여줌
- **ChatGPT 4.0:** Wysa 와 닥터케어쌤이 복합적인 감정을 다룸
- **인간 상담사:** Wysa 는 정신적, 신체적 요소를 고려, Youper 는 긍정 심리학 기반 접근

④적극적 경청과 적절한 질문:

- Claude: Wysa 와 닥터케어챗이 뛰어난 경청과 질문 능력
- ChatGPT 4.0: Wysa 가 가장 적극적, 닥터케어챗도 유머와 맞춤형 질문을

통해 대화 유도

- 인간 상담사: Wysa 는 단계별 질문으로 변화 유도, Replika 는 사용자의 감정을 중심으로 대화

⑤긍정성과 지지:

- Claude: 닥터케어챗이 가장 높은 긍정성, Youper 와 Replika 도 긍정적인 접근

- ChatGPT 4.0: 닥터케어챗이 유머로 긍정성 전달, Youper 도 긍정적인 방법 제시

- 인간 상담사: Youper 는 긍정 심리학을 활용, 닥터케어챗은 유머로 관계를 형성

⑥전문성:

- Claude: Wysa 가 가장 전문적인 접근
- ChatGPT 4.0: Wysa 와 Youper 가 전문성을 보임
- 인간 상담사: Wysa 와 Youper 가 전문적인 기법을 적용

⑦개인화:

- Claude: 닥터케어챗이 가장 높은 개인화
- ChatGPT 4.0: 닥터케어챗과 Wysa 가 개인화된 응답 제공
- 인간 상담사: Wysa 와 Youper 가 개인화된 접근을 시도

2.3) 종합 평가 결과 및 계량화

먼저, 본 평가에서는 평가자들에게 계량적 분석을 요구하지 않았으며, 평가자들도 '높음', '중간', '낮음'과 같은 단계별 점수를 부여하지 않았음을 밝힌다. 그러나 평가 결과를 보다 명확하게 비교하고 분석하기 위해, 연구자들이 평가자들의 정성적 평가를 바탕으로 3 점 스케일로 계량화하였다.

이러한 계량 분석을 추가하게 된 경위는 다음과 같다:

- **챗봇 간 성능 비교의 용이성:** 수치화된 데이터를 통해 각 챗봇의 강점과 약점을 보다 명확하게 비교할 수 있다.
- **종합적 평가의 필요성:** 여러 기준에 걸친 챗봇의 전반적인 성능을 파악하기 위해 종합 점수가 필요했다.
- **데이터 시각화 및 분석의 편의성:** 수치 데이터를 통해 그래프나 차트 등으로 결과를 시각화하기 쉬워진다.

표 26. 챗봇별 7 가지 기준 평가 종합 결과

평가 기준	평가자	Replika	Wysa	Youper	Dr.CareSam
공감성	클로드	높음(3)	중간(2)	중간(2)	높음(3)
	ChatGPT 4.0	중간(2)	높음(3)	중간(2)	높음(3)
	인간 상담사	높음(3)	중간(2)	높음(3)	높음(3)
정확성과 유익성	클로드	중간(2)	높음(3)	중간(2)	중간(2)
	ChatGPT 4.0	중간(2)	높음(3)	중간(2)	중간(2)
	인간 상담사	중간(2)	높음(3)	높음(3)	중간(2)
복합적 사고와 감정	클로드	낮음(1)	높음(3)	낮음(1)	중간(2)
	ChatGPT 4.0	낮음(1)	높음(3)	중간(2)	중간(2)
	인간 상담사	중간(2)	높음(3)	중간(2)	중간(2)
적극적 경청과 적절한 질문	클로드	중간(2)	높음(3)	중간(2)	중간(2)
	ChatGPT 4.0	낮음(1)	높음(3)	중간(2)	중간(2)
	인간 상담사	중간(2)	높음(3)	높음(3)	중간(2)
긍정성과 지지	클로드	중간(2)	중간(2)	높음(3)	높음(3)
	ChatGPT 4.0	중간(2)	중간(2)	높음(3)	높음(3)
	인간 상담사	중간(2)	중간(2)	높음(3)	높음(3)
전문성	클로드	중간(2)	높음(3)	중간(2)	중간(2)
	ChatGPT 4.0	낮음(1)	높음(3)	중간(2)	중간(2)
	인간 상담사	중간(2)	높음(3)	높음(3)	중간(2)
개인화	클로드	낮음(1)	중간(2)	낮음(1)	높음(3)
	ChatGPT 4.0	낮음(1)	높음(3)	중간(2)	높음(3)
	인간 상담사	중간(2)	높음(3)	중간(2)	중간(2)
총점		38	57	48	50
평균		1.81	2.71	2.29	2.38

종합 결과:

- **총점:** Wysa (57 점) > 닥터케어쌤 (50 점) > Youper (48 점) > Replika (38 점)
- **평균:** Wysa (2.71 점) > 닥터케어쌤 (2.38 점) > Youper (2.29 점) > Replika (1.81 점)
- **시간적 안정성 검증 (1 년 후 재평가):** 평가 도구의 신뢰도 검증을 위해 동일한 대화 샘플을 재평가한 결과 동일한 순위를 기록했으며 평가 주체별 일치도는 다음과 같다.
 - 챗봇 순위: 동일한 순위 유지 (Wysa > 닥터케어쌤 > Youper > Replika)

- 평가 주체별 일치도: Claude ($r=0.934$), ChatGPT ($r=0.981$), 통합 시스템 ($r=0.957$)
- 평가 기준별 안정성: 7 개 기준 모두에서 높은 시간적 일관성 확인

2.4) 평가 기준별 성능 분포

우수 성능 영역:

- **Wysa**: 정확성과 유익성, 적극적 경청과 적절한 질문, 전문성에서 만점
- **닥터케어쌤**: 긍정성과 지지, 개인화에서 최고 점수
- **Youper**: 긍정성과 지지에서 만점, 감정적 지원에 특화
- **Replika**: 긍정성과 지지에서 상대적 강점

2.5) 연구 가설 검증 결과

2.5.1) 가설 1 검증: 7 가지 상담학적 기준의 변별력

H_1 : 실험 II 에서 도출된 7 가지 상담학적 평가 기준은 LLM 기반 평가 방법론을 통해 서로 다른 특성을 가진 정신건강 챗봇들 간의 상담적 품질 차이를 유의미하게 변별할 수 있을 것이다.

일원배치 분산분석 결과:

일원배치 분산분석 결과: $F(3,80) = 9.73, p < 0.001, \eta^2 = 0.267$ (큰 효과크기)

결과: 가설 1 이 지지되었다. 효과크기 $\eta^2 = 0.267$ 은 '큰 효과크기'에 해당하며, 챗봇 유형이 평가 점수 변동의 26.7%를 설명함을 나타낸다.

표 27. Tukey HSD 사후검정 결과

비교 쌍	평균차이	표준오차	p값	Cohen's d	해석
Wysa vs Replika	0.9	0.24	0.004	2.84	매우 큰 차이
닥터케어 쌤 vs Replika	0.57	0.24	0.041	1.52	큰 차이
Youper vs Replika	0.48	0.24	0.089	1.12	중간 차이(경계)
Wysa vs Youper	0.42	0.24	0.267	0.95	중간 차이
Wysa vs 닥터케어 쌤	0.33	0.24	0.427	0.74	중간 차이
닥터케어 쌤 vs Youper	0.09	0.24	0.934	0.19	작은 차이

2.5.2) 가설 2 검증: 가설 2 검증: 닥터케어 쌤의 글로벌 경쟁력

H_2 : 닥터케어 쌤은 글로벌 수준의 정신건강 챗봇들과 대등한 상담적 성능을 보일 것이다.

닥터케어 쌤(2.381 점)이 Youper(2.238 점)를 앞서며 2위를 기록하여 글로벌 수준의 챗봇들과 대등한 성능을 보였다. 특히 공감성(2.8), 긍정성(2.9), 개인화(2.6) 영역에서 강점을 보였다. 특히 Wysa 와 닥터케어 쌤 간에는 통계적으로 유의미한 차이가 없었다($p = 0.427$). 이는 닥터케어 쌤이 현재 최고 수준으로 평가받는 Wysa 와 대등한 성능을 보임을 의미한다.

결과: 가설 2 지지 - 닥터케어 쌤이 글로벌 챗봇들과 대등한 성능 입증

2.5.3) 가설 3 검증: LLM 평가자의 신뢰성

H_3 : LLM 평가자(Claude 3.5 Sonnet, ChatGPT 4.0)와 인간 전문가 간의 평가 결과는 중간 수준 이상의 일치도를 보일 것이다.

표 28. 평가자간 일치도

분석 항목	값	해석
Cronbach's α	0.837	높은 신뢰도
Claude vs ChatGPT	0.72	강한 양의 상관관계
Claude vs 인간 전문가	0.618	중간-강한 양의 상관관계
ChatGPT vs 인간 전문가	0.554	중간 정도의 양의 상관관계

결과: 가설 3 지지 - LLM 평가자들이 모두 중간 수준 이상의 일치도($r > 0.5$)

달성

*아울러 LLM 평가자들의 신뢰도를 1 년 시간의 간격을 두고 재평가함으로써 시간적 신뢰도를 검증하고자 하였다. 결과는 다음과 같다:

- Claude 3.5 Sonnet: $r=0.934$ (1 년 간격 재평가)
- ChatGPT 4.0: $r=0.981$ (1 년 간격 재평가)
- 통합 평가 시스템: $r=0.957$

2.5.4) 가설 4 검증: 전통적 NLP 지표와의 차별성

H_4 : 전통적 NLP 평가 지표와 상담학적 평가 간에는 유의미한 차이가 나타날 것이다.

표 29. 전통적 NLP 지표와 상담학적 평가와의 상관관계

NLP 지표	상관계수	t통계량	p값	95% 신뢰구간	해석
BLEU	0.142	0.285	0.685	[-0.69, 0.82]	비유의
ROUGE-L	-0.089	-0.178	0.743	[-0.79, 0.72]	비유의
METEOR	0.235	0.481	0.512	[-0.60, 0.87]	비유의
BERTScore	-0.318	-0.667	0.387	[-0.91, 0.54]	비유의

표 30. 챗봇별 전통적 NLP 평가 점수

챗봇	BLEU	ROUGE-L	METEOR	BERTScore	상담학적 평가 평균
Youper	0.144	0.254	0.31	0.288	2.238
Wysa	0.141	0.25	0.29	0.27	2.714
Replika	0	0.15	0.227	0.28	1.81
닥터케어챗	0.04	0.129	0.159	0.184	2.381

여기서 주목할 점은 닥터케어챗이 [표 29]에서 보는 바와 같이, 모든 NLP 지표에서 최하위를 기록했음에도 상담적 평가에서는 2위를 차지했다는 사실이다.

닥터케어챗의 NLP 지표에서의 낮은 순위와 상담학적 평가에서의 높은 순위라는 대조적인 결과는, 전통적인 NLP 지표와 상담학적 평가가 서로 다른 차원의 품질을 측정하고 있음을 시사한다. 이는 NLP 지표가 주로 참조 텍스트와의 유사성에 기반하는 반면, 상담학적 평가는 치료적 관계 형성, 감정적 지지, 개인화 등 상담 고유의 가치를 중시한다는 점에서 나타나는 차이로 해석될 수 있다.

결과: 가설 4 지지 - 전통적 NLP 지표와 상담학적 평가 간 상당한 차이 확인

표 31. 실험 III 전체 탐색적 가설 검증 결과 종합

가설	가설 내용	통계 방법	주요 결과	효과크기	p값	결정	실제적 의미
가설 1	7가지 상담학적 기준의 변별력	일원배치 ANOVA	$F(3,80) = 9.73, \eta^2 = 0.267$	매우 큰 효과	< 0.001	지지	상담학적 기준이 챗봇 간 변별력 효과적
가설 2	닥터케어챗의 글로벌 경쟁력	사후검정 (Tukey HSD)	Wysa와 유의한 차이 없음	중간 효과 ($d=0.74$)	0.427 (비유의)	지지	글로벌 수준과 대등한 성능 입증
가설 3	LLM 평가자의 신뢰성	ICC 분석	$ICC(2,1) = 0.671$	중간-큰 효과	< 0.001	지지	LLM 평가자들이 중간 수준 이상의 일치도 ($ICC > 0.5$) 달성
가설 4	전통적 NLP 지표와의 차별성	상관분석	모든 NLP 지표와 비상관	효과 없음	모두 > 0.05	지지	평가 체계 간 측정 차원의 차이 확인

5. 결론 및 시사점

본 연구는 Park et al.(2024)의 혁신적인 LLM 기반 평가 방법론을 성공적으로 확장하여 다양한 심리 챗봇을 비교 분석했으며, 그 과정에서 정신건강 챗봇 평가의 새로운 패러다임을 제시하였다.

1)주요 연구 결과 및 기여

우선, Park et al.의 LLM 기반 평가 프레임워크를 다중 챗봇 비교 분석에 적용하여 그 방법론적 일반화 가능성을 입증했다. 특히 LLM 평가 시스템의 높은 내적 일관성($\alpha=0.837$)과 인간 전문가와의 적절한 일치도(Claude-인간: $r=0.618$, ChatGPT-인간: $r=0.554$)는 이 평가 접근 방식의 신뢰성을 더욱 공고히 한다.

또한, 본 연구에서 개발된 7 가지 상담학적 평가 기준이 챗봇들의 특성을 통계적으로 유의미하게 변별($F=9.73$, $p<0.001$)함으로써, 상담학 이론 기반 평가의 변별력을 확인했다. 한편, BLEU, ROUGE, METEOR, BERTScore 와 같은 전통적 NLP 지표들과 상담학적 평가 간의 상관관계가 낮게 나타난 것은 두 평가 체계가 서로 다른 측면의 품질을 측정하고 있음을 보여주며, 상담 맥락에서는 도메인 특화된 평가 접근이 중요함을 시사한다.

실용적인 측면에서는, 한국에서 개발된 닥터케어챗이 글로벌 수준의 챗봇들과 대등한 성능(2 위, 2.381 점)을 보이며 챗봇의 국제 경쟁력을 확인했다는 점이 주목할 만하다. 또한, 각 챗봇의 고유한 강점 영역을 과학적으로 규명하여, 사용자 특성에 따른 맞춤형 서비스 전략 수립의 토대를 마련했다. 예를 들어, Wysa 는 CBT 기반의 체계적인 접근에서 강점을 보였고, 닥터케어챗은 유머와 창의적 표현을 통한 공감성 및 개인화 영역에서 우수한 성능을 나타냈다.

특히 1년 간격 재평가를 통한 시간적 신뢰도 검증($r=0.957$)은 LLM 평가자의 장기적 안정성을 실증하여, 지속적인 품질 모니터링 시스템으로서의 활용 가능성을 확인했다.

2) 이론적 및 실용적 시사점

CBT 이론의 관점에서 본 평가 패러다임 전환

본 연구는 Park et al.(2024)의 연구와 함께 정신건강 챗봇 평가의 패러다임을 "기술 중심"에서 "상담 중심"으로 전환하는 데 기여한다. CBT 이론의 관점에서 볼 때, 이러한 전환은 Beck(1979)이 강조한 치료적 관계의 질과 상담 과정의 효과성이 디지털 환경에서도 핵심 평가 기준이 되어야 함을 보여준다. 이는 단순한 텍스트 유사성이나 사용자 만족도를 넘어, CBT의 핵심 원리인 실제 상담적 가치와 치료적 효과성을 중심으로 한 평가 체계의 중요성을 확인시켜 준다.

사회적 낙인 완화와 개인화된 접근의 실용적 가치

실용적 가치 측면에서는, 각 챗봇의 차별화된 강점이 **"one-size-fits-all"**이 아닌 **"personalized-care"**로의 전환 가능성을 보여준다. 박지혜(2020)의 연구에서 20대 청년의 정신건강 도움요청 행동에서 사회적 낙인과 자기 낙인이 중요한 매개 요인으로 작용한다고 밝힌 바와 같이, 이러한 개인화된 접근은 정신건강 문제에 대한 낙인을 효과적으로 완화할 수 있는 중요한 전략이다.

사용자들은 자신의 필요와 선호에 따라 Wysa의 체계적인 치료, 닥터케어챗의 언어와 한국적 특성을 반영한 설계와 정서적 지지, Youper의 즉각적인 기분 개선 도구 등 맞춤형 서비스를 선택할 수 있게 된다. 박지혜의 연구 결과를 고려할 때, 이는 개인이 자신의 상황에 가장 적합한 도구를 익명으로 선택할 수 있게 함으로써,

전통적인 대면 상담에서 경험할 수 있는 사회적 낙인과 자기 낙인에 대한 우려를 크게 줄일 수 있다.

실시간 모니터링을 통한 접근성 확대

Park et al.(2024)의 방법론을 확장한 LLM 기반 자동 평가 시스템은 24 시간 실시간 품질 모니터링을 가능하게 하여, 대규모 정신건강 AI 서비스의 지속적인 품질 관리 및 개선을 위한 실용적인 해결책을 제공할 잠재력을 지닌다. 박지혜(2020)의 연구에서 20 대 청년들이 온라인·전화상담 서비스에 대해서는 도움요청 의도까지만 유의하고 실제 행동으로는 이어지지 않는다고 밝힌 바와 같이, 디지털 정신건강 서비스의 품질 보장이 매우 중요하다. 24 시간 접근 가능한 익명의 고품질 서비스는 도움을 구하는 것에 대한 사회적 장벽을 효과적으로 낮추고, 의도를 실제 행동으로 전환시킬 수 있는 핵심 요소가 될 수 있기 때문이다.

LLM 기반 자동 평가 시스템의 높은 시간적 안정성($r=0.957$)은 24 시간 실시간 품질의 모니터링뿐만 아니라 장기적인 성능 추적 관리도 가능하게 한다.

3)연구의 한계 및 향후 과제

본 연구는 4 개 챗봇과 "발표 불안"이라는 단일 시나리오, 그리고 3~4 턴의 짧은 대화 길이로 제한된 환경에서 수행되었다는 한계를 가진다. 또한, 실시간 상호작용의 역동성을 충분히 반영하지 못했고, 실제 치료 효과에 대한 임상적 검증이 부족하다는 점도 한계로 지적된다.

향후 연구에서는 Park et al.(2024)의 100 개 벤치마크 시나리오들을 활용해 다양한 임상 시나리오 및 대규모 챗봇 비교 연구로 범위를 확장할 필요가 있다. 우울, 불안, PTSD 등 다양한 정신건강 이슈별 특화 분석과 함께 장기간 사용

효과를 분석하는 종단적 연구가 요구된다. 또한, PHQ-9, GAD-7 등 표준화된 임상 척도를 활용한 객관적인 효과성 검증 및 무작위 대조군 연구(RCT)를 통한 실제 치료 효과 입증에 필수적이다. 마지막으로, Park et al.이 강조한 안전성 평가를 본 연구의 상담적 품질 평가와 통합해, 효과성과 안전성을 동시에 보장하는 종합적인 평가 체계 구축이 중요한 향후 과제로 남아있다.

이러한 연구 결과와 시사점은 정신건강 AI 챗봇 개발 및 평가에 있어 중요한 지침을 제공하며, 궁극적으로는 사용자에게 더욱 효과적이고 안전한 정신건강 서비스를 제공하는 데 기여할 것으로 기대된다.

제 6 장 정신건강 플랫폼의 개선 방향

AI 기술의 발전과 정신건강 관리에 대한 사회적 관심이 증가하는 현 시점에서, 효과적이고 사용자 중심적인 정신건강 플랫폼의 개발은 시급한 과제이다. 본 장에서는 세 단계에 걸친 실험 연구의 결과를 종합하여, AI 기반 정신건강 플랫폼이 나아가야 할 구체적인 방향성을 제시하고자 한다. 이를 위해 먼저 연구 결과의 통합적 분석을 통해 정신건강 플랫폼의 핵심 방향성을 도출하고(1 절), 이를 바탕으로 사용자 경험 관점에서의 구체적인 구현 전략을 제시한다(2 절). 이어서 LLM 기술 고도화 방안을 통해 실현 가능성을 탐색하고(3 절), 현장 전문가들의 분석을 통해 제안의 실천적 함의를 탐색한다(4 절). 마지막으로 본 장의 핵심 내용을 요약하고 미래 연구의 방향성을 제언한다(5 절).

1. 연구 결과의 통합적 분석 및 핵심 방향성 도출

본 연구에서 수행된 세 가지 실험은 AI 기반 정신건강 플랫폼의 핵심 요소를 다각도로 도출하는 데 기여하였다. Mohr et al. (2013)의 행동변화 개입 기술(Behavioral Intervention Technology) 모델에 따르면, 효과적인 디지털 정신건강 개입을 위해서는 개념적 모델, 기술적 구현, 사용자 경험이 통합적으로 고려되어야 한다. 본 섹션에서는 각 실험의 결과를 종합적으로 분석하고, 이를 바탕으로 플랫폼 개발의 구체적 방향성을 제시하고자 한다.

1) 실험별 핵심 발견 및 시사점

1.1) 디지털 중재의 효과와 개선 방향 (실험 I)

실험 I 에서 가장 중요한 발견은 디지털 정신건강 도구가 한국 대학생들에게 실질적 도움을 제공하면서도 더 큰 잠재력을 실현하기 위한 명확한 개선 방향을 제시했다는 점이다. 참여자들은 감사일기, 명상, 목표설정을 통해 긍정적 변화를 경험했으나, 한국어 지원과 맥락적 대화 능력에서 개선이 필요함을 확인했다. 특히 규칙기반 시스템의 반복적 응답과 개인 상황에 대한 이해 부족이 사용자 참여 지속성에 영향을 미치는 것으로 나타났다. 이는 단순한 정보 제공을 넘어 개인의 복잡한 정서적 요구를 이해하고 창의적이며 맥락적인 상호작용을 제공할 수 있는 지능형 대화 시스템의 필요성을 시사한다. 또한 높은 전문가 연계 요구는 디지털 중재가 독립적 솔루션이 아닌 통합적 정신건강 지원 체계의 일부로 발전해야 함을 보여준다.

1.2) 한국형 LLM 기반 챗봇의 잠재력 (실험 II)

실험 II 는 한국어 기반 LLM 챗봇인 '닥터케어썸'의 성공적인 개발과 그 잠재력을 입증하였다. 닥터케어썸은 한국어로 자연스럽게 소통하며 대학생들의 일상적 표현에 적절히 반응하는 능력을 보여, 단순한 번역을 넘어선 '한국어 네이티브' AI 의 중요성을 부각했다. 이는 디지털 정신건강 서비스가 언어적 자연성과 접근성을 갖출 때 비로소 높은 수용성과 효과를 거둘 수 있음을 의미한다. 특히 자연스러운 대화 방식과 심층적인 공감 능력은 사용자가 AI 와의 상호작용에서 느끼는 장벽을 낮추고, 신뢰감을 형성하는 데 결정적인 역할을 했다.

1.3) AI 기반 상담 평가의 가능성 (실험 III)

실험 III 은 AI 평가자(Claude 3.5 Sonnet, ChatGPT 4.0)가 인간 전문가와 중간 수준 이상의 일치도로 상담적 대화 평가를 수행할 수 있음을 검증하였다. 이는 AI 가 단순한 텍스트 분석을 넘어 복잡한 상담의 품질을 평가하는 데 있어 상당한 잠재력을 가지고 있음을 시사한다. 전통적인 NLP 지표(BLEU, ROUGE 등)와 상담학적 평가 간의 상당한 차이는 AI 기반 정신건강 서비스 평가에서 도메인 특화된 평가 접근의 중요성을 시사한다. 즉, 단순한 언어적 일치도를 넘어선 '의미론적'이고 '상담학적' 가치를 평가할 수 있는 기준이 필요하다는 점을 본 연구 결과가 뒷받침한다. .

2) 플랫폼 설계의 핵심 방향성: 3 요소

이상의 세 가지 실험을 통해 도출된 결과들은 AI 기반 정신건강 플랫폼이 나아가야 할 세 가지 핵심 방향성을 명확히 제시한다.

첫째, 맞춤형 서비스 제공 체계 구축이다. 실험 I 에서 확인된 낮은 정신건강 문해력(평균 2.46/5 점)과 다양한 개인적 배경을 가진 대학생들의 특성은 개인화된 접근의 필요성을 명확히 보여준다. 실험 II 의 사용자 피드백에서도 "성격 및 취향을 고려한 개인화된 접근" 및 "개인별 맞춤형 조언"에 대한 요구가 지속적으로 제기되었다. 특히 실험 III 에서 닥터케어챗이 개인화 영역에서 상대적으로 높은 평가를 받은 반면, 다른 챗봇들은 이 영역에서 한계를 보인 점은 개인화가 경쟁 우위의 핵심 요소임을 시사한다. 따라서 플랫폼은 사용자의 정신건강 상태, 성격 특성, 학습 선호도, 의사소통 스타일을 종합적으로 고려한 차별화된 서비스를 제공해야 한다. 이는 단순한 맞춤 콘텐츠를 제공을 넘어, 사용자별 상호작용 패턴 분석과 적응적 대화 전략을 포함하는 포괄적 개인화 시스템을 의미한다.

둘째, AI-전문가 협력 모델의 구축이다. 실험 III 의 비교 분석에서 드러나듯, AI 챗봇은 일상적인 정서적 지원과 공감적 대화에는 효과적이지만, 전문적 상담이 필요한 상황에서는 명확한 한계를 가진다. WYSA 가 전문성 영역에서 가장 높은 평가를 받았음에도 불구하고, 여전히 인간 전문가의 개입이 필요한 영역이 존재한다는 점이 확인되었다. 실험 I 에서 나타난 고위험군 학생들의 높은 이탈률과 실험 II 에서 사용자들이 요구한 "전문가 연계 시스템"은 AI 단독 접근의 한계를 보여준다. 따라서 AI 의 24 시간 상시 지원과 전문가의 선택적 개입이 유기적으로 결합된 하이브리드 모델이 요구된다. 이는 AI 가 1 차적 스크리닝과 일상적 지원을 담당하고, 필요시 전문가가 개입하는 단계적 지원 체계를 의미한다.

셋째, 프라이버시 중심 설계와 신뢰 구축이다. 모든 실험에서 사용자들은 개인정보 보호에 대한 높은 관심을 보였다. 특히 실험 I 에서 나타난 정신건강 서비스 이용의 장벽 중 하나인 '낙인에 대한 두려움'과 실험 II 에서 확인된 익명성에 대한 요구는 프라이버시 보호가 플랫폼 성공의 핵심 요소임을 시사한다. 정신건강이라는 민감한 주제를 다루는 만큼, 데이터 보안과 사용자 프라이버시 보호는 플랫폼 설계의 최우선 고려사항이 되어야 한다. 이는 기술적 보안 조치뿐만 아니라 투명한 데이터 사용 정책, 사용자 제어권 보장, 그리고 신뢰할 수 있는 서비스 환경 조성을 포함하는 종합적 접근을 요구한다.

2. 사용자 중심의 정신건강 플랫폼 구현 및 기술 고도화 방안

사용자 중심 디자인은 사용자의 특성과 니즈를 깊이 이해하고 이를 설계에 반영하는 접근 방식으로, 디지털 정신건강 플랫폼의 성공적 개발을 위해 필수적이다. 본 장에서는 성격 유형 및 디지털 환경의 상관관계, 페르소나 분석, 고객여정맵 분석을 통해 도출된 결과를 기반으로 플랫폼 개선 전략을 제시한다.

2.1) 사용자 경험(UX) 중심 구현 방안

앞서 도출된 '맞춤형 서비스 제공'이라는 핵심 방향성을 구현하기 위해서는 사용자의 개별적 특성과 요구사항에 대한 깊이 있는 이해가 선행되어야 한다. 실험 I 에서 확인된 낮은 정신건강 문해력(평균 2.46/5 점)과 실험 II 에서 나타난 개인화에 대한 사용자 요구는 단순한 일괄적 서비스가 아닌, 사용자 중심의 차별화된 접근이 필요함을 시사한다.

본 연구에서는 사용자 중심의 디자인 설계를 위해 개인화 접근법을 채택하였다. 이를 위해 성격 유형 분석과 페르소나 개발을 통해 디지털 중재의 효과를 높이하고자 하였다. 특히 한국 대학생들 사이에서 성격을 통한 자기 이해와 소통이 보편화되어 있다는 점을 고려하여, 이를 사용자 경험 설계를 위한 실용적 프레임워크로 활용하였다.

이러한 개인화 전략을 구체적으로 구현하기 위해, 다음 절에서는 실제 사용자 인터뷰를 통해 도출된 페르소나별 특성과 설계 방향을 분석하고자 한다.

2.2) 페르소나 기반 설계

2.2.1) 이론적 배경

효과적인 개인화 서비스 구현을 위해서는 사용자의 성격 특성과 선호도에 대한 체계적 이해가 필요하다(Norman, 1988; Garrett, 2011). 사용자 중심 설계에서 개인차를 고려한 접근은 시스템과 사용자 간의 적합성을 높여 전반적인 사용자 경험을 개선할 수 있다. 최근 연구들은 성격 기반 인터페이스 개인화가 사용자 만족도 향상에 기여할 수 있음을 시사하고 있다(Sarsam & Al-Samarraie, 2018).

성격 연구 분야에서 가장 널리 인정받는 이론적 틀은 Big Five 모델이다. McCrae et al. (1992)는 Big Five 모델이 개인의 성격 특성을 설명하는 데 가장 강력한 실증적 기반을 제공한다고 설명하였다. 이러한 이론적 토대를 바탕으로, Stachl et al. (2020)은 디지털 기기 사용 패턴을 통해 개인의 Big Five 성격 특성을 예측할 수 있음을 실증적으로 입증하였다. 이는 디지털 환경에서 성격 기반 개인화 서비스의 기술적 가능성을 보여주는 중요한 연구 성과로 평가된다.

본 연구에서는 사용자 경험 설계를 위한 실용적 접근으로서 MBTI 를 제한적으로 활용한다. MBTI 의 심리측정학적 한계는 잘 알려져 있다(Pittenger, 2005; Barbuto, 1997). 특히 이분법적 유형 분류의 문제점과 검사-재검사 신뢰도에 대한 비판이 지속적으로 제기되어 왔다. 그러나 메타분석 연구에서는 MBTI 가 강한 내적 일관성과 검사-재검사 신뢰도를 보이는 것으로 확인되었으며(Capraro & Capraro, 2002), UX 디자인과 개인화 전략 수립에서는 실용적 가치를 갖는다고 평가받고 있다.

MBTI 의 실용적 활용 근거는 다음과 같다. 첫째, MBTI 는 일반 사용자들이 이해하기 쉬운 프레임워크를 제공한다. 둘째, 국내 대학생들 사이에서 MBTI 를 통한 자기 이해와 소통이 보편화되어 있어, 이를 UX 설계의 출발점으로 활용할 수

있는 문화적 토대가 마련되어 있다. 셋째, 복잡한 성격 이론을 실무진이 적용하기 용이한 형태로 단순화하여 제공한다.

본 연구에서는 MBTI 를 단독 지표로 사용하지 않고, 실제 사용자 인터뷰, 행동 패턴 분석, 선호도 조사 등의 다각적 데이터와 결합하여 페르소나를 구성한다. 이러한 삼각검증(triangulation) 접근을 통해 MBTI 의 한계를 보완하고 보다 신뢰할 수 있는 사용자 이해를 도모한다. 궁극적으로 이러한 접근은 대학생 사용자의 다양한 성격적 특성과 선호도를 체계적으로 파악하여, 정신건강 플랫폼의 개인화 전략 수립에 실용적 기초를 제공하는 것을 목표로 한다.

2.2.2) 연구 방법

실험 II 에서 개발된 닥터케어챗봇의 사용성과 효과성을 평가하기 위해 세 명의 대학생 사용자를 대상으로 심층 인터뷰를 실시했다. 인터뷰는 2024 년 9 월 9 일부터 9 월 20 일까지 Zoom 을 통해 진행되었으며, 각 인터뷰는 1 시간 내외로 진행되었다. 모든 인터뷰는 클로바 녹취록을 활용하여 기록되었으며, 참가자들에게는 현금 3 만 원 또는 커피 쿠폰이 보상으로 제공되었다.

참여자 선정 기준: 본 연구의 인터뷰 참여자는 실험 I 부터 일관되게 참여하여 3 개월간의 중재효과 실험, 닥터케어챗봇 사용성 평가테스트, 디지털 테라피와 LLM 비교평가를 성실히 완수한 참여자들로 구성되었다. 이들은 정신건강 챗봇의 맥락과 개인화의 중요성을 체험을 통해 깊이 이해하고 있어, 사용자 중심 디자인을 위한 핵심 인사이트를 제공할 수 있는 적절한 참여자로 판단되었다.

연구 윤리 고려사항: 본 연구는 연구 윤리를 준수하며 진행되었다. 제시된 성격 유형과 응답 내용은 실제 인터뷰와 설문조사 데이터를 기반으로 하고 있지만,

참여자들의 개인 정보 보호를 위해 학과, 이름, 나이 등 일부 정보는 가상으로 대체되었다. 이는 윤리적인 고려사항을 지키면서도 현실적인 사용자 경험을 반영하기 위함이다. 본 인터뷰 역시 성균관대학교 기관생명윤리위원회(IRB)의 승인(SKKU 2023-02-043)을 받아 진행되었다.

2.2.3) 페르소나 프로필

◆수정 (ESFJ, 23 세, 경영학과 4 학년)

- 외향적이고 열정적인 성격으로, 리더십이 강한 편
- 스트레스는 주로 운동과 일기 쓰기를 통해 해소
- 체계적인 목표 계획과 실행 성향
- 정량적 평가: 닥터케어챗 9, Google Bard 3, ChatGPT 3.0 (10 점 만점)
- 정성적 평가: 호미타운 챗봇의 접근성과 사용성에 높은 평가, 답변이 과하지 않고
- 용기를 주는 말로 구성된 점을 긍정적으로 평가

◆철희 (ESTJ, 25 세, 컴퓨터공학과 대학원생)

- 체계적이고 신속한 일처리를 선호하는 AI 개발자 지망생
- 음악 감상과 쇼핑으로 스트레스 해소
- 목표 달성을 위한 계획적 접근
- 정량적 평가: 닥터케어챗 6, Google Bard 7, ChatGPT 3.0 4 (10 점 만점)
- 정성적 평가: 재미있는 이모티콘 사용과 친절한 말투를 긍정적으로 평가, 한글
- 응답 속도와 반복적 질문을 개선점으로 지적

◆정엽 (INFP, 24 세, 전기공학과 4 학년)

- 감정적으로 민감하고 공감을 중요시하는 성격

- 게임이나 운동을 통한 스트레스 해소
- 우울증 병력과 대면 상담 치료 경험 보유
- 정량적 평가: 닥터케어챗 7.5, Google Bard 9, ChatGPT 3.0 6(10 점 만점)
- 정성적 평가: 깔끔한 화면과 공감 표현을 긍정적으로 평가, 한글 응답의 정확도와 적절성 개선 필요성 지적

2.2.4) 페르소나별 설계 방향

표 32. 페르소나별 핵심 특성 및 설계 방향

구분	수정 (ESFJ)	철희 (ESTJ)	정엽 (INFP)
핵심 특성	• 외향적, 사회성 높음 • 체계적인 계획 선호 • 운동/일기로 스트레스 관리	• 효율성 중시 • 실용적 접근 선호 • 음악/쇼핑으로 스트레스 해소	• 감정적 민감성 • 공감 중시 • 게임/운동으로 스트레스 해소
주요 니즈	• 사회적 상호작용 • 체계적 일정관리 • 긍정적 피드백	• 실시간 정보 제공 • 효율적 시간관리 • 실용적 조언	• 감정적 공감 • 다양한 감정 해석 • 프라이버시 보호
인터페이스 특징	• Social Sync • 그룹 활동 중심 • 밝은 색상 사용	• Techlife Balance • 대시보드 중심 • 데이터 시각화	• Mindful Journey • 자기성찰 중심 • 차별한 디자인

2.3) 고객여정맵 분석

Joseph et al. (2020)의 연구는 환자 여정 맵핑(Patient Journey Mapping)을 통해 의료 과정에서 겪는 다양한 상호작용 지점을 시각적으로 나타내는 방법론을 제시했다. 이러한 접근법을 바탕으로, 본 연구에서는 대학생들의 정신건강 여정을 단계별로 분석하였다.

고객여정맵은 인지, 가입, 첫 사용, 정기적 사용, 전문가 연결, 장기적 사용의 6 단계로 구성되었으며, 각 단계에서 사용자의 생각(Thinking), 감정(Feeling), 행동(Action)을 페르소나별로 분석하였다.

■ 단계별 주요 발견사항

인지 단계: 세 페르소나 모두 스트레스 관리에 대한 관심은 높지만, 접근 방식에서 차이를 보였다. 수정(ESFJ)은 호기심과 적극적 탐색을, 철희(ESTJ)는 신중한 검토를, 정엽(INFP)은 조심스러운 관찰을 선호했다.

가입 및 첫 사용 단계: 모든 사용자가 개인정보 보호에 대한 우려를 표현했으나, 첫 사용 후에는 긍정적 피드백을 보였다. 특히 AI의 즉각적 응답과 24시간 접근성에 대해 높이 평가했다.

정기적 사용 단계: 페르소나별 차이가 가장 두드러지게 나타났다. 수정은 만족감과 지속적 사용 의지를, 철희는 기능 개선에 대한 관심을, 정엽은 감정 상태에 따른 불안감을 보였다.

전문가 연결 및 장기적 사용 단계: 모든 페르소나에서 전문가 연계에 대한 긍정적 반응과 장기적 사용에 대한 기대감이 확인되었다.

표 33. 고객여정맵

단계	 수정 (ESFJ, 23세, 경영학과)	 철희 (ESTJ, 25세, 컴퓨터 공학과)	 정엽 (INFP, 24세, 전기공학과)
인지	생각: 스트레스 관리에 도움이 될까? 감정: 호기심 (+) 행동: 친구 추천으로 앱 다운로드	생각: 시간 관리에 효율적일까? 감정: 신중함 (-) 행동: 기술 리뷰 검색 후 다운로드	생각: 우울감 극복에 도움될까? 감정: 기대감 (+) 행동: 소셜 미디어 광고를 통해 인지, 친구들 사이 화제 확인
가입	생각: 내 특성을 잘 반영할 기대감 감정: 설렘 (+) 행동: 계정 생성 후 설정	생각: 구체적 전략 제공 가능성? 감정: 기대감 (+) 행동: 앱 설정 후 계획 중심 설문	생각: 나의 감정을 어떻게 기록할까? 감정: 불안 (-) 행동: 감정 상태와 관계 고민 중심 설문
첫 사용	생각: 앱을 더 사용하고 싶어 감정: 놀람 (+) 행동: 첫 상담 후 긍정적 피드백	생각: AI가 내 계획을 얼마나 구체적으로 맞춰줄까? 감정: 의심 (-) 행동: 정기적으로 앱 기능 사용, 성과 분석	생각: AI가 내 감정을 잘 이해할까? 감정: 불안 (-) 행동: AI 상담사와 첫 대화, 감정 상태 공감 확인
정기적 사용	생각: 나의 성장에 도움될 것 같아 감정: 만족 (+) 행동: 정기적 사용으로 만족도 증가	생각: 기능들이 원하는 결과를 낼 수 있을까? 감정: 점검 (+) 행동: 목표 설정 기능 활용	생각: AI가 내 감정 상태에 맞춘 상담을 할 수 있을까? 감정: 기대감 (+) 행동: 그룹 상담 기능으로 다른 사용자와 교류
전문가 연결	생각: 더 깊은 조언이 필요해 감정: 안도감 (+) 행동: 전문가와 상담 연결 시도	생각: 전문가의 도움을 받을 수 있을까? 감정: 안도감 (+) 행동: 전문가 연결 및 상담	생각: 사람보다 공감해줄 수 있을까? 감정: 신뢰감 (+) 행동: 자아정체성 혼란 시 전문가 상담 요청
장기적 사용	생각: 앱이 나의 정서적, 학업적 목표에 도움이 되고 있다 감정: 성취감 (+) 행동: 장기적 목표 설정과 지속 사용	생각: AI가 내 학습과정을 크게 개선해줬어 감정: 성취감 (+) 행동: 학습 기록 지속	생각: 앱 덕분에 내 감정 관리가 더 나아졌어 감정: 안정감 (+) 행동: 정서적 지지와 새로운 친구 관계 형성

[표 33]에서 보는 것과 같이 고객여정맵 분석을 통해 도출된 주요 시사점은 다음과 같다:

◆개인화 전략의 중요성: 각 페르소나가 동일한 단계에서도 서로 다른 감정과 행동 패턴을 보임에 따라, 성격 유형별 맞춤형 접근의 필요성이 확인되었다.

◆신뢰 구축의 중요성: 모든 단계에서 프라이버시와 보안에 대한 우려가 나타났으며, 이는 플랫폼 설계 시 최우선적으로 고려되어야 할 요소임을 시사한다.

◆점진적 개입 전략: 초기 단계에서는 AI 중심의 지원을, 심화 단계에서는 전문가 연계를 통한 하이브리드 접근이 효과적임이 확인되었다.

◆지속성 확보 방안: 정기적 사용 단계에서 나타난 페르소나별 차이점을 고려한 차별화된 유지 전략이 필요함을 알 수 있다.

2.4) 디자인 개선 방안

사용자 중심 디자인(User-Centered Design, UCD)은 사용자의 특성, 니즈, 선호도를 깊이 이해하고 이를 바탕으로 제품이나 서비스를 설계하는 접근 방식이다(Norman, 1988). 본 연구에서는 페르소나와 고객 여정 맵을 통해 대학생 사용자들의 경험을 분석하였고, 이를 기반으로 지속적인 플랫폼 개선 방안을 제시하고자 하였다.

2.4.1) 사용자 중심 디자인 원칙

사용자 인터뷰 및 문헌 연구(Beyer et al, 1998; Garrett, 2011)를 바탕으로, 다음의 5 가지 핵심 원칙을 도출하였다:

- 개인화 원칙: 사용자의 성격, 선호도, 상황을 고려한 맞춤형 콘텐츠와 경험 제공
- 접근성 원칙: 직관적이고 간단한 인터페이스를 통한 서비스 접근성 보장
- 신뢰성 원칙: 개인정보 보호와 상담 내용의 보안 강화를 통한 신뢰 구축
- 유연성 원칙: 사용자의 다양한 상황과 요구에 맞춘 기능 제공
- 지속성 원칙: 게이미피케이션 요소 도입을 통한 지속적 참여 유도

2.4.2) 디자인씽킹 차용을 통한 사용자 중심 설계

본 연구에서는 실험 II 에서 개발된 앱의 사용성과 효과성을 평가하고, 이를 바탕으로 사용자 중심의 개선 방안을 도출하기 위해 세 명의 대학생 사용자를 대상으로 심층 인터뷰를 실시했다. 이어서 디자인 씽킹 프로세스를 적용하여 사용자의 니즈를 깊이 이해하고 개선 방안을 모색했다.

본 연구에서는 스탠퍼드 대학교 d.school⁴⁰에서 제시한 디자인 씽킹의 5 단계 프로세스(공감, 정의, 발상, 프로토타입, 테스트) 중 프로토타입의 보완점 도출까지만 진행하였다. 이는 본 연구의 주요 목적이 디지털 중재의 전반적인 가능성과 거시적 방향성을 탐색하는 데 있기 때문이다.

디자인 씽킹은 본질적으로 반복적이고 비선형적인 프로세스로, 각 단계는 순차적으로 진행되기보다는 필요에 따라 병행하거나 이전 단계로 되돌아가는 특성을 갖는다(Brown et al., 2015). 본 연구에서는 이러한 특성을 고려하여 초기 단계에서의 사용자 니즈 파악과 개념 검증에 집중하였다. 특히 개별 사용자의 세부적인 요구사항을 반영한 완전한 개인화보다는, 대학생 집단의 전반적인 정신건강 니즈와 디지털 중재의 효과성을 평가하는 데 초점을 맞추고 있다.

디자인 씽킹 프로세스의 공감-정의-발상 단계를 통해 도출된 주요 개선 방향은 다음 [표 34]와 같다.

표 34. 사용자 중심 설계 개선 방향

영역	구체적 개선 사항
개인화	• MBTI 기반 대화 스타일 조정 • 사용자별 관심사 반영 • 선호 활동 맞춤 추천

⁴⁰ d.school은 스탠퍼드 대학교의 Hasso Plattner Institute of Design의 통칭이다.

기술 개선	• 응답 속도 최적화 • 한국어 자연스러움 개선 • 감정 인식 정확도 향상
보안/프라이버시	• 데이터 암호화 강화 • 익명성 보장 • 선택적 정보 공유
기능 확장	• 실시간 알림 시스템 • 전문가 연계 강화 • 그룹 활동 지원

2.4.3) 페르소나별 맞춤형 인터페이스 설계

본 연구에서는 사용자 인터뷰와 페르소나 분석을 통해 도출된 개선점들을 바탕으로, 개인화된 인터페이스 설계 방안을 도출하였다. 특히 각 페르소나의 성격 특성과 선호도를 반영한 맞춤형 인터페이스를 설계함으로써, 사용자 경험을 최적화하고자 하였다.

① 통합적 개선 방향

◆개인화된 상담 경험 강화: 현재의 프로토타입이 제공하는 일괄적인 상담 경험을 넘어, 사용자의 성격 유형과 선호도를 반영한 맞춤형 상담 경험을 제공할 필요가 있다. 특히 MBTI 성격 유형에 따른 대화 스타일 조정과 콘텐츠 추천 시스템의 개발이 요구된다.

◆기술적 성능 개선: 한국어 자연어 처리 능력의 향상과 최적화가 필요하다. 특히 한국어 맥락에 맞는 공감적 표현과 자연스러운 대화 흐름을 구현하기 위해, 프롬프트 엔지니어링과 컨텍스트 관리 시스템의 개선이 요구된다.

◆보안 및 프라이버시 강화: 사용자의 민감한 상담 데이터를 안전하게 보호하기 위한 보안 시스템 구축이 필수적이다. 데이터 암호화, 익명성 보장, 선택적 정보

공유 기능 등을 통해 사용자가 안심하고 서비스를 이용할 수 있는 환경을 조성해야 한다.

② 페르소나별 인터페이스 설계

각 페르소나의 특성과 니즈를 반영한 인터페이스 설계 방안은 다음과 같다:

□ Social Sync (ESFJ 유형 - 수정)

그림 24. ESFJ (Social Sync) 유형 인터페이스



Social Sync 인터페이스는 외향적이고 사회성이 높은 ESFJ 유형의 특성을 반영하여 설계되었다. 그룹 활동 중심의 기능과 밝은 색상 scheme 을 통해 활기찬 사용자 경험을 제공한다. 주요 특징은 다음과 같다:

- ◆ 사회적 상호작용을 촉진하는 그룹 활동 추천 시스템
- ◆ 체계적인 일정 관리와 목표 달성 트래커
- ◆ 긍정적 피드백과 성취 공유 기능

□ Techlife Balance (ESTJ 유형 - 철희)

그림 25. ESTJ (Techlife Balance) 유형 인터페이스



Techlife Balance 인터페이스는 효율성과 체계성을 중시하는 ESTJ 유형의 특성을 반영한다. 데이터 중심의 대시보드 형태로 설계되어, 사용자가 자신의 상태와 진행 상황을 명확히 파악할 수 있도록 한다:

- ◆실시간 데이터 시각화와 진행 상황 모니터링
- ◆효율적인 시간 관리 도구와 알림 시스템
- ◆객관적 지표 기반의 상태 분석 기능

□ Mindful Journey (INFP 유형 - 정엽)

그림 26. INFP (Mindful Journey) 유형 인터페이스

MINDFULJOURNEY

당신의 마음을 위한 여정

INFP 성향의 당신을 위한 맞춤형 정신건강 및 취업 준비 도우미

- AI 정신건강 분석
- 일일 목표 설정
- INFP 커뮤니티
- 가상 운동 파트너
- 긍정 마인드셋 훈련
- 취업 준비 가이드
- 24/7 AI 상담사
- 재정 관리 도구

정협의 감정분석 인터페이스

오늘의 기분은 어떠신가요?

calm happy reflective anxious

AI 감정 분석

오늘은 궁금한 보이시내요. 명상을 통해 이 상태를 유지해보는 건 어떨까요?

맞춤 명상

감정 일기

가상 운동 파트너

긍정 혁신

Mindful Journey 인터페이스는 감성적이고 내면적인 INFP 유형의 특성을 고려하여 설계되었다. 차별한 디자인과 자기 성찰적 기능을 통해 사용자의 정서적 안정을 지원한다:

- ◆감정 일기와 마음챙김 도구 제공
- ◆개인화된 명상과 스트레스 해소 프로그램
- ◆프라이버시를 고려한 익명 소통 기능

2.6) 사용자 경험 기반 설계의 의의와 한계

2.6.1)연구의 의의

본 연구의 사용자 중심 설계는 대학생 정신건강 플랫폼 개발의 초기 단계에서 중요한 방향성을 제시했다. 페르소나 분석과 고객 여정맵을 통해 사용자의 고유한 특성과 니즈를 심층적으로 파악하고, 이를 바탕으로 개인화된 인터페이스 설계 방안을 도출할 수 있었다.

특히 성격 유형별 대화 스타일 조정, 단계별 사용자 경험 최적화, 감정 공감 기능의 구현 가능성을 탐색함으로써, 대학생 정신건강 플랫폼 개발을 위한 실용적 기초 자료를 마련했다는 점에서 의의가 있다.

2.6.2) 연구의 한계

본 연구는 다음과 같은 한계를 가진다. 첫째, 정성적 사용자 분석에 기반한 설계로서 강화학습(RLHF)이나 고도화된 AI 기술을 활용한 구현은 포함되지 않았다. 둘째, 제안된 설계의 실질적 효과성에 대한 정량적 검증이 향후 과제로 남아있다. 셋째, 3 명의 제한된 페르소나 분석으로 인해 대학생 집단의 다양성을 충분히 반영하지 못했을 가능성이 있다.

2.6.3) 향후 발전 방향

이러한 한계에도 불구하고 본 연구는 사용자 경험 기반 개선 전략의 중요성을 확인하였으며, 대학생 정신건강 플랫폼 설계를 위한 초기 프레임워크를 제공했다. 향후 연구에서는 이 기반 위에서 LLM 을 활용한 기술적 고도화와 대규모 사용자 대상의 효과성 검증이 이루어져야 할 것이다.

3. LLM 기반 정신건강 챗봇의 기술적 고도화 방안


본 연구에서 수행한 세 차례의 실험과 사용자 중심 디자인 과정을 통해 얻은 통찰을 바탕으로, LLM 기반 AI 정신건강 챗봇 서비스의 기술적 고도화 방안을 제시하고자 한다. 특히 실험 II 의 닥터케어썸 프로토타입 사용성 테스트와 실험

III 의 WYsa 와의 비교실험 결과, 그리고 세 명의 페르소나를 대상으로 한 심층 인터뷰에서 얻은 피드백을 중심으로 개선 방안을 구체화하였다.

1) 감정 인식 및 공감 능력

실험 III 의 WYsa 비교 분석 결과, 사용자의 감정을 더 깊이 이해하고 탐구하는 능력이 핵심 요소로 확인되었다. WYsa 의 대화 흐름은 단순한 응답이 아닌, 사용자의 감정 상태를 단계적으로 탐색하고 이해하는 방식으로 구성되어 있었다.

그림 27. 개선된 대화 흐름도



위 그림은 챗봇이 사용자 발화에 반응하여 감정을 인식하고, 단계적으로 대화를 발전시키는 과정을 시각화한 것이다. 사용자가 "오늘 발표가 있어요"라고 말하면, 챗봇은 먼저 발표와 관련된 감정 상태를 묻고, 사용자가 느끼는 긴장감과 걱정을 공감한 후, 구체적인 해결 방안을 제안한다.

또한 대화 맥락에 따른 자연스러운 감정 탐색은 효과적인 정신건강 지원의 핵심이다. AI 는 사용자의 발화를 단순히 인식하는 것을 넘어, 맥락에 따라 적절한 후속 질문을 생성하며 대화를 자연스럽게 발전시켜야 한다. 특히 한국 대학생들의 일상과 관련된 주제별로 맥락을 인식하고 적절히 대응하는 것이 중요하다.

실험 II 의 사용성 테스트에서 사용자들은 자신들의 실제 고민과 직접적으로 연관된 대화를 더 선호하는 것으로 나타났다. 주요 상황별 맥락 인식이 필요한 영역은 다음과 같다:


- ◆학업 스트레스 상황
- ◆진로/취업 관련 고민
- ◆대인 관계 문제

그림 28. 상황별 말투 예시 및 사용자 설정 화면



[그림 28]은 사용자가 학업 스트레스, 진로 고민, 대인 관계 문제와 같은 주요 상황에 따라 챗봇의 대화 톤을 설정할 수 있는 인터페이스를 보여준다. 이 기능은 사용자 경험의 유연성을 높이고, 개인화된 상담 경험을 지원하는 데 기여한다.

그림 29. 대화 발전 구조도



[그림 29]은 단기, 중기, 장기 목표에 따라 사용자와의 상호작용이 심화되는 방식을 보여준다. 단기적으로는 일일 감정 기록과 패턴 인식을, 중기적으로는 스트레스 요인 파악과 주간 감정 분석을, 장기적으로는 월간 성장 리뷰와 지속 가능한 성장을 지원한다. 이러한 구조는 챗봇이 단순한 대화 도구를 넘어 사용자 성장의 동반자로 기능할 수 있도록 설계되었다.

2) 한국어 처리 모델 개선

한국어는 존댓말, 종결어미, 감정 표현의 뉘앙스 등 특수한 언어적 특성을 가지고 있어, AI 기반 챗봇 개발에 있어 고유의 도전 과제를 제시한다. 본 연구의 실험 II에서는 닥터케어쌤 챗봇이 한국어 문장에서 부자연스러운 표현을 사용하는 경우가 자주 관찰되었다. 이를 해결하기 위해 다음과 같은 개선이 필요하다.

◆한국어 형태소 분석기 개선: 감정 표현이 포함된 신조어와 은어를 정확히 처리하기 위해 맞춤형 사전을 구축하고, 다양한 종결어미의 뉘앙스를 파악할 수 있도록 형태소 분석기를 개선해야 한다.

◆맥락 이해 모델 개발: 대화의 흐름을 정확히 파악하고, 이전 대화 내용을 고려하여 현재 발화의 의미를 정확히 해석하는 능력이 요구된다. 특히 한국어 대화의 자연스러움을 위해서는 동적 프롬프트 튜닝이 중요하다

◆ 비언어적 요소 활용, 이모티콘과 텍스트 스타일링: 감정의 강도와 의미를 시각적으로 표현하는 비언어적 요소의 통합이 필요하다.

2.1) 형태소 분석기 개선

한국어 형태소 분석기의 고도화는 정신건강 챗봇의 핵심 기능이다. 특히 정신건강 영역의 전문 용어와 은어를 포함한 맞춤형 사전 구축이 필요하다. 예를 들어, '우울증'이라는 단어뿐만 아니라 '우울감', '무기력', '멘붕' 등의 다양한 표현을 인식하고 적절히 처리할 수 있어야 한다.

<주요 개선 영역>

◆감정 표현 어미 처리: "-아/어요", "-네요", "-군요"와 같은 종결어미의 뉘앙스 차이 인식

◆신조어 및 줄임말 처리: "ㅠㅠ", "ㅎㅎ" 등의 감정 표현, "스블재"⁴¹, "멘붕" 등의 신조어

◆맥락 기반 다의어 구분: "힘들다", "우울하다", "괜찮다" 등의 맥락별 의미 파악

⁴¹ 스블재: "스스로 불러온 재앙"의 줄임말, 한국 인터넷 커뮤니티 신조어

그림 30. 사용자 맞춤형 동적 프롬프트 튜닝 예시

```
당신은 [사용자 이름]의 AI 상담사입니다.  
성격 유형: [MBTI 유형]  
선호하는 답변 스타일: [간결/상세/유머/전문]  
주요 관심사: [관심사 1], [관심사 2]  
현재 고민: [사용자가 입력한 고민]  
  
다음 지침을 따라 응답하세요:  
1. [MBTI 유형별 특성에 맞는 커뮤니케이션 지침]  
2. [선호하는 답변 스타일에 따른 형식 지침]  
3. 사용자의 관심사를 반영하여 예시나 비유를 들어주세요.  
4. 현재 고민에 대해 공감하고 구체적인 조언을 제공하세요.  
  
사용자의 메시지: [사용자 입력]  
  
위의 정보와 지침을 바탕으로 적절한 응답을 생성하세요.
```

사용자 맞춤형 프롬프트 튜닝을 통해 다음과 같은 요소들을 세밀하게 조정할 수 있다:

- ◆존댓말의 수준 조절
- ◆문화적 맥락 반영
- ◆대화의 자연스러운 흐름 유지
- ◆위험 상황 감지 시 전문가 상담 제안

2.2) 맥락 이해 모델 개발

현재 닥터케어썸 프로토타입은 실험 II의 사용성 테스트에서 한국어 문장의 부자연스러움이 간혹 발견되었다. 특히 감정 이모티콘(추상명사)과 서술어미의 결합에서 문제가 나타났다.

그림 31. 한국어 문맥 향상을 위한 프롬프트 튜닝 예시

시스템: 당신은 한국 대학생들을 위한 정신건강 상담 AI 챗봇입니다. 다음 지침을 따라 대화를 진행하세요:

1. 언어 사용:
 - 감정을 표현할 때 '-이야/야'를 일괄적으로 사용하지 말고, 상황에 맞는 자연스러운 표현을 선택하세요.
 - '상처받았어요', '외로워요', '소속감을 느껴요', '실망스러워요', '지루해요' 등의 형용사형 표현을 우선적으로 사용하세요.
 - 추상명사 사용이 필요한 경우, '상처가 돼요', '자랑스러워요'와 같이 자연스러운 표현을 선택하세요.
2. 존댓말 사용:
 - 기본적으로 '-요' 형태의 존댓말을 사용하되, 사용자의 나이와 선호도에 따라 조절하세요.
 - 너무 격식적이지 않되 적절한 예의를 갖추세요.
3. 문화적 맥락:
 - 한국 대학생의 일상과 관련된 주제(학업 스트레스, 취업 준비, 인간관계 등)에 친숙함을 보이세요.
 - 한국의 정서와 문화적 규범(예: 효도, 집단주의, 서열 문화)을 고려하여 조언하세요.
4. 대화 흐름:
 - 직접적인 조언보다는 사용자의 감정을 먼저 인정하고 공감하는 방식으로 대화를 이어가세요.
 - 필요한 경우 구체적인 예시나 상황을 들어 설명하세요.

2.3) 문화적 적응을 위한 데이터 설계

2.3.1) 문화적 맥락화의 필요성


한국 대학생들은 학업 스트레스, 취업 준비, 군 복무로 인한 학업 단절 등 고유한 사회적 맥락에서 다양한 스트레스를 경험한다. 이러한 특수한 상황은 단순한 언어적 번역을 넘어, 문화적 맥락을 반영한 데이터와 대화 설계를 필요로 한다. 기존의 LLM 기반 챗봇은 범용적인 데이터로 학습되었기 때문에, 특정 문화적 요인을 충분히 반영하지 못하는 한계가 있다.

2.3.2) 문화적 데이터 설계를 위한 접근법

Li et al.(2024)의 CulturePark 연구는 다중 에이전트 기반의 문화적 데이터 생성 방식을 제안하며, 다양한 문화적 맥락을 반영한 고품질 데이터를 생성하는 방법을 시사했다. 이 연구는 인간 신념, 규범, 관습을 포함한 교차문화적 대화를

통해, [그림 32]과 같이 문화적 민감성을 반영한 데이터를 수집하고 이를 LLM 훈련에 활용하였다

그림 32. CulturePark의 문화적 데이터 설계 프레임워크 (Li et al., 2024에서 재인용)



이 프레임워크는 다문화적 데이터를 기반으로 콘텐츠 검열, 문화적 정렬, 문화 교육과 같은 다양한 응용 분야에서 활용 가능성을 보여준다.

2.3.3) 한국형 챗봇 적용 방안

한국 대학생들의 주요 스트레스 요인과 고민을 반영한 데이터 설계는 다음과 같은 방식으로 적용될 수 있다:

- ◆다문화적 데이터 수집: 한국 대학생들이 자주 사용하는 신조어, 은어, 대화 스타일을 포함한 데이터를 구축.
- ◆문화적 공감을 반영한 대화 흐름: 한국 대학생의 일상적인 고민(예: "취업 준비가 너무 힘들어요")에 대해 자연스럽게 공감적인 대화를 생성.

◆사용자 맞춤형 인터페이스 개발: 학업, 진로, 대인 관계 등 주요 주제별로 대화 톤과 스타일을 설정할 수 있는 기능 추가.

2.4) 비언어적 요소 활용

이모티콘과 텍스트 스타일링을 통한 감정의 뉘앙스 전달이 중요하다. 프렌스키(Prensky, 2001)의 연구에서 지적인 바와 같이, 디지털 네이티브인 MZ 세대는 이러한 시각적 요소를 통한 감정 전달에 매우 익숙하며, 이는 그들의 의사소통 방식의 핵심적인 부분을 차지한다.

<감정 강도에 따른 이모티콘 활용>

약한 공감: "노력하신 만큼 좋은 결과 있으실 거예요. ✨"

강한 공감: "정말 대단해요! 완전 잘하셨습니다! 🎉 ✨"

공감과 위로: "많이 힘드셨겠어요. 😊 함께 이야기 나눠볼까요? 🧠"

표 35. 감정 강도별 이모티콘 활용 가이드라인

감정 상태	상황 예시	권장 이모티콘 조합	활용 목적	주의사항
불안/걱정	시험 앞둔 상황	🧘💬💡	공감과 지지 표현	과도한 낙관 주의
우울/침체	학업 부진	😞💔🔄	따뜻한 위로 전달	가벼운 위로 지양
성취/기쁨	목표 달성	🎉💡👏	축하와 인정	과한 들뜸 주의
분노/좌절	인간관계 갈등	😞💬🧘	감정 인정과 공감	감정 일반화 주의

3) 정신건강 상담 데이터 구축 전략

3.1) 전문가 참여 데이터 구축

정신건강 챗봇의 성능 향상을 위해서는 전문가의 참여가 필수적이다. 상담 전문가들의 실제 경험과 전문성을 바탕으로 한 대화 시나리오 구축이 필요하며, 이는 단순한 데이터 수집을 넘어 체계적인 데이터 처리 과정을 포함해야 한다. 특히 학업 스트레스, 진로 고민과 같은 대학생들의 주요 고민 영역별로 표준 대화 모델을 구축하고, 위기 상황 대응을 위한 단계별 프로토콜을 마련해야 한다.

이러한 전문가 참여 데이터는 다음 단계의 온라인 데이터와 통합되어 실험 1,2,3 에서 발견된 한계점 해결의 핵심 기반이 된다.

3.2) 온라인 데이터 활용 및 위험탐지 코퍼스 통합

현대 대학생들의 정신건강 문제는 온라인 공간에서 활발히 논의되고 있다. 실험 II 에서 구축한 위험탐지 시스템의 핵심 성과를 활용하여, 다음과 같은 체계적 코퍼스 기반 데이터 구축을 수행한다:

핵심 코퍼스 활용:

- ◆3 장의 닥터케어샘 위험탐지 프롬프트 설계에서 참조한 AI 허브 감성 대화 말뭉치 (6,640 개 대화, 2 만여 개 발화)를 활용: 실제 한국어 사용자의 감정 표현 패턴 분석

- ◆국립정신건강포털 DSM-5 기준: 임상적으로 검증된 진단 기준 적용

- ◆복지분야 콜센터 상담데이터 ⁴² (2,276,065 건): 실제 상담 상황의 언어 패턴 학습

⁴² 복지분야 콜센터 상담 데이터 수집을 통해 관련 서비스 모델 활용에 적합하게 구축된 AI 데이터셋으로 AI 허브(www.aihub.or.kr)에서 회원가입 후 다운로드할 수 있다.

위험신호 탐지 표현 체계:

실험 II 에서 도출한 5 개 카테고리별 한국어 감정 표현을 RAG 시스템에 통합하여 실시간 위험 신호 탐지가 가능하도록 구성한다. "우울하다", "기분이 안 좋다", "내 능력이 부족한 거 같은데" 등의 실제 코퍼스 추출 표현들을 벡터화하여 동적 매칭 시스템에 활용한다.

3.3) 통합 데이터 기반 RAG/LangChain 시스템 구축

3.3.1) 데이터 품질 관리 및 기술 기반

품질 관리 시스템:

온라인 데이터와 전문가 참여 데이터를 효과적으로 활용하기 위해 3 단계 필터링 시스템을 구축한다: ① 자동화된 전처리(개인정보 제거, 욕설 필터링), ② 정신건강 전문가 2 인의 교차 검토, ③ 언어학 전문가의 한국어 자연성 평가.

RAG/LangChain 기술 개요:

RAG(Retrieval-Augmented Generation)⁴³는 외부 데이터베이스에서 관련 정보를 검색한 후, 그 정보를 바탕으로 LLM 이 더 정확하고 맥락에 맞는 답변을 생성하는 기술이다. LangChain⁴⁴은 LLM 애플리케이션 개발을 위한 프레임워크로, 복잡한 AI 워크플로우를 체인 형태로 연결하여 관리할 수 있게 해주는 도구이다.

3.3.2) RAG 기반 위험 탐지 고도화 시스템

⁴³ RAG (Retrieval-Augmented Generation): Lewis et al. (2020)이 제안한 검색 기반 증강 생성 기법

⁴⁴ LangChain: Harrison Chase가 개발한 LLM 애플리케이션 개발 프레임워크 (Chase, 2022)

실험 II 에서 관찰된 개인화 부족과 반복적인 어조 문제를 해결하기 위해 위험탐지 중심 RAG 기술을 활용한다. RAG 의 핵심 강점인 실시간 동적 정보 검색과 활용을 통해 기존 LLM 의 정적 지식 한계를 극복하고, 사용자별 맞춤형 위험 신호 탐지 및 대응이 가능한 감정 맥락 인식 시스템을 구축한다.

시스템 구성 요소:

- ◆한국 대학생 위험 표현 데이터베이스: "힘들어요", "죽고싶어요", "스블재" 등 위험 신호 표현을 벡터화하여 저장
- ◆위기 상황별 개입 라이브러리: 자해 위험, 학업 스트레스, 대인관계 문제별 효과적인 위기 개입 응답 패턴 구축
- ◆동적 검색 및 매칭 시스템: 사용자 입력에서 위험 신호를 실시간 검색하여 맞춤형 위기 대응 생성

핵심 구현 방식:

그림 33. RAG 기반 위험탐지 및 개인화 시스템 구현 방식 예시

```
python
# 실험 II의 개인화 부족 문제 해결을 위한 위험탐지 중심 RAG 시스템
from langchain.embeddings import OpenAIEmbeddings
from langchain.vectorstores import FAISS

class KoreanRiskDetectionRAG:
    def __init__(self):
        # 3.2절 구축 데이터 통합: AI허브(6,640개) + 콜센터(2,276,065건) + DSM-5
        self.risk_vectorstore = FAISS.from_texts(
            texts=ai_hub_expressions + counseling_data + dsm5_criteria,
            embedding=OpenAIEmbeddings()
        )

    def get_risk_aware_response(self, user_input):
        # 위험 신호 탐지 후 개인화된 위기 개입 응답 생성
        risk_contexts = self.risk_vectorstore.similarity_search(
            query=user_input, k=3
        )
        return self.generate_crisis_intervention(risk_contexts)
```

[그림 33]에서 보는 바와 같이, 3.2 절에서 언급한 AI 허브 감성 대화 말뭉치(6,640 개 대화), 복지분야 콜센터 상담데이터(2,276,065 건), DSM-5 기준 데이터를 통합한 위험탐지 중심 RAG 데이터베이스와 동적 매칭 시스템을 사용하여 사용자의 위험 신호를 조기 탐지하고, 이전에 효과적이었던 위기 개입 표현을 실시간으로 검색하여 개인화된 상담 경험을 제공할 수 있다.

3.3.3) LangChain 을 활용한 대화 체인 관리

실험 II 에서 나타난 단조로운 응답 패턴 문제를 해결하기 위해 LangChain 의 체인 관리 기능을 활용한다.

◆순차적 위험 평가 프로세스:

위험도 식별 단계: 사용자 발화에서 자해, 자살 관련 위험 신호 파악

맥락 이해 단계: 한국 대학생 특유의 상황적 배경 분석 (취업 준비, 학업 부담 등)

위기 개입 단계: 위험도에 따른 적절한 개입 표현 선택

전문가 연계 단계: 고위험 상황 시 전문 상담 연계 프로토콜 실행

그림 34. LangChain 구현 예시

```
python

from langchain.chains import SequentialChain
from langchain.prompts import PromptTemplate

# 순차적 위험 평가 체인 구성
risk_detection_chain = LLMChain(prompt="위험도 분석: {user_input}")
context_chain = LLMChain(prompt="맥락 분석: {risk_level}")
intervention_chain = LLMChain(prompt="위기 개입: {context}")

# 통합 체인
sequential_chain = SequentialChain(
    chains=[risk_detection_chain, context_chain, intervention_chain],
    input_variables=["user_input"],
    output_variables=["crisis_response"]
)
```

3.3.4) 토큰 최적화를 위한 RAG 시스템

실험 II 에서 발생한 한국어 토큰 제약으로 인한 응답 중단 문제를 해결하기 위해 [그림 35]와 같이 토큰 사용량은 최소화하면서도 필요한 정보는 압축적으로 활용하는 RAG 기반 토큰 최적화 시스템을 구축할 수 있다.

핵심 최적화 기법:

스마트 청킹: 한국어의 조사와 어미 특성을 고려한 의미 단위 분할

선별적 검색: 가장 관련성 높은 2-3 개 문서만 검색하여 토큰 사용량 최소화

동적 요약: 긴 대화 히스토리를 핵심 정보만 압축하여 유지

그림 35. RAG 기반 토큰 최적화 시스템


```
python

# 토큰 제약 문제 해결을 위한 최적화 시스템
from langchain.text_splitter import TokenTextSplitter9
from langchain.chains import RetrievalQA10

class TokenOptimizedRAG:
    def __init__(self, max_tokens=4096):
        self.max_tokens = max_tokens
        # 한국어 특성을 고려한 토큰 기반 텍스트 분할
        self.token_splitter = TokenTextSplitter(
            chunk_size=500, # 한국어 조사/어미 증가 고려
            chunk_overlap=50
        )

        # 필요한 정보만 선별적으로 검색하는 압축된 체인
        self.retrieval_qa = RetrievalQA.from_chain_type(
            llm=llm,
            chain_type="stuff",
            retriever=self.vectorstore.as_retriever(search_kwargs={"k": 2})
        )
```

4) 통합 시스템 현장 적용 방안

4.1) 실시간 모니터링 및 안전성 확보

실험 II 에서 우려되었던 예기치 못한 부적절한 응답 가능성을 사전에 차단하기 위한 실시간 품질 관리 시스템을 구축한다.

다차원 품질 모니터링:

위험 탐지 정확도: DSM-5 기준 부합도 및 위험 신호 조기 발견율

문화적 적절성: 한국 대학생 맥락에 맞는 표현 사용 여부 확인

안전성 지표: 유해하거나 위험한 내용 포함 여부 실시간 감지

BaseCallbackHandler⁴⁵ 를 활용한 실시간 모니터링으로 위험 상황 감지 시 전문가 상담 연계 프로토콜을 자동 실행한다.

⁴⁵ BaseCallbackHandler: LangChain의 콜백 핸들러 기본 클래스

4.2) 점진적 도입 전략

이러한 기술적 구현을 통해 실험 II 에서 발견된 개인화 부족, 한국어 표현의 부자연스러움, 대화 일관성 부족 등의 문제를 근본적으로 해결하며, AI 허브 감성대화 말뭉치의 6,640 개 실제 대화 패턴을 실시간으로 활용하여 더욱 자연스럽고 효과적인 한국어 특화 상담 서비스를 제공할 수 있다.

5) 현장 검증을 위한 전문가 의견 수렴의 필요성

앞서 제시한 기술적 고도화 방안들이 실제 정신건강 현장에서 효과적으로 작동하기 위해서는 이론적 설계와 현실적 적용 사이의 간극을 체계적으로 검증해야 한다.

이러한 기술적 방안들이 대학 상담센터, 정신건강 전문가, 그리고 시스템 개발자들에게 어떠한 실천적 의미를 갖는지, 그리고 현장 적용 시 예상되는 도전과제와 개선 방향은 무엇인지에 대한 다각적 전문가 분석이 요구된다. 이를 통해 기술적 혁신과 현장 실용성을 동시에 확보할 수 있는 실질적인 방안을 도출할 수 있을 것으로 기대된다.

종합적인 기술적 고도화 방안을 통해 실험 II 에서 발견된 개인화 부족, 토큰 제약, 언어적 부자연스러움, 일관성 부족 등의 핵심 문제들을 체계적으로 해결하고, 한국 대학생에게 최적화된 정신건강 챗봇 서비스를 구현할 수 있을 것으로 기대된다.

이러한 기술적 기반을 통해 실험 II 에서 발견된 개인화 부족, 한국어 표현의 부자연스러움, 그리고 대화 일관성 부족 등의 문제를 근본적으로 해결할 수 있으며,

수집된 다양한 데이터를 실시간으로 검색하고 활용하여 더욱 자연스럽고 효과적인 상담 서비스를 제공할 수 있다.

4. 현장 전문가 분석 및 실천적 함의

앞서 제시한 플랫폼 핵심 방향성의 실제 적용 가능성을 검증하기 위해, 대학 정신건강 관리 현장의 주요 이해관계자들을 대상으로 심층적인 의견 수렴을 진행하였다. 조사 대상은 교수진 9 명, 심리상담사 3 명, 소프트웨어 개발자·연구원 3 명으로 구성되었으며, 각 전문가 집단의 서로 다른 관점에서 현행 시스템의 문제점과 개선 방안을 도출하고자 하였다. 특히 3 절에서 제안한 LLM 기술 고도화 방안들의 현장 적용 가능성과 실천적 과제를 중점적으로 탐구하였다. 질적 데이터 분석은 실험 I 에서와 동일하게 Braun et al. (2006)의 주제분석(Thematic Analysis) 방법을 활용하여 현장 전문가들의 의견을 체계적으로 분석하였다.

1) 현장 전문가 조사 결과

1.1) 조사 개요

- 조사 기간: 2024 년 2 월 ~ 2024 년 4 월
- 조사 대상: 교수진 9 명, 심리상담사 3 명, 소프트웨어 개발자·연구원 3 명
- 조사 방법: 개방형 설문조사

본 현장 전문가 조사는 다음과 같은 한계를 가진다. 첫째, 표본 크기가 상대적으로 작아 각 전문가 집단의 대표성에 제약이 있다. 둘째, 단일 시점 조사로 인해 시간적 변화를 반영하지 못한다는 한계가 있다. 셋째, 지역적 편중으로 인해

다양한 환경적 맥락을 충분히 반영하지 못했다. 넷째, 단일 방법론 사용으로 인해 심층적 맥락 파악에 한계가 있다.

그럼에도 불구하고 현장 전문가들과의 심층적 의견 수렴을 통해 얻는 실천적 시사점이 크다고 판단하였다. 특히 교수진, 상담사, 개발자라는 서로 다른 관점에서 제시된 현실적 문제점과 해결 방안들은 이론적 연구만으로는 얻기 어려운 현장의 생생한 목소리를 담고 있다.

향후 연구에서는 다음과 같은 타당성 확보 방안을 고려해야 한다: 표본 크기 확대, 종단적 추적 연구, 지역적 다양성 확보, 혼합 방법론 적용 등을 통해 연구 결과의 신뢰성과 일반화 가능성을 높여야 할 것이다.

표 36. 대학 정신건강 관리시스템의 디지털전환전략에 대한 현장전문가 분석

영역	교수진 (n=9)	심리상담사 (n=3)	개발자·연구원 (n=3)
현행 시스템 문제점	• 인력과 재정 부족 • 교수진-상담센터 연계성 부족 • 학생들의 낮은 접근성 • 자가 인식 부족	• 서비스 인식 부족 • 낮은 접근성 • 상담 인력 부족 • 열악한 처우로 인한 전문성 확보 어려움	• 시스템의 폐쇄성 • 낮은 접근성 • 일상적 정신건강 관리 인식 부족 • 홍보 부족
디지털 전환 전략	• 정신건강 중요성 공감대 형성 • 리터러시 교육 체계화 • 실제 수요 파악 • 자기도움 행동교육 강화	• 엄격한 윤리 기준 수립 • 개인정보 보호 지침 마련 • 익명성 보장 • 인간다움/따뜻함 유지	• 디지털 문화 구축 • 챗봇 상담 이질감 해소 • 디지털 방식 우수성 홍보
챗봇 활용 방안	• 기존 상담체계 보완재 역할 • 원스톱 서비스 설계 • 자가 점검 도구 활용	• 초기 심각도 파악 • 전문가 연결 • 정보 제공 기능 • 기존 상담 서비스와 통합	• 전문 상담사 연계 시스템 • 다양한 입력 옵션 제공 • 개인화된 피드백 강화
통합적 시사점			
공통 시사점	• 접근성 향상과 인식 개선의 시급성 • 개인정보 보호와 윤리적 고려의 중요성 • 기존 상담 체계와의 통합적 접근 필요성		
실행 우선순위	1. 정신건강 리터러시 교육 체계화 2. 디지털 윤리 가이드라인 수립 3. 챗봇-전문상담 연계 시스템 구축		
추가 고려사항	• 대학 차원의 제도적 지원 필요 • 정신건강 관련 낙인 해소를 위한 문화적 환경 조성 • 고교-대학 전환기 지원 프로그램 강화 • 사회 유관 기관과의 네트워크 구축		

1.2) 주요 분석 결과

1.2.1)현행 시스템의 문제점

◆교수진의 관점

교수진은 현행 정신건강 관리시스템의 근본적 한계를 다각도로 지적하였다. 가장 핵심적인 문제로는 인력과 재정 부족이 제기되었으며, 이는 충분한 상담 인력 확보와 전문적 서비스 제공에 직접적인 제약을 가하고 있는 상황이다. 특히 주목할 점은 교수진과 상담센터 간의 연계성 부족 문제인데, 이로 인해 학생들의 정신건강 문제를 조기에 발견할 수 있는 협력체계가 제대로 구축되지 못하고 있다는 것이다.

또한 학생들의 낮은 접근성과 자가 인식 부족도 심각한 문제로 인식되고 있다. 학생들이 스스로 도움이 필요한 상황을 인지하지 못하거나, 인지하더라도 상담 서비스에 접근하는 것을 주저하는 경우가 많아 예방적 차원의 개입이 어려운 실정이다.

◆상담사의 관점

상담사들은 서비스 인식과 접근성 문제를 가장 시급한 과제로 인식하고 있다. 특히 "사소해 보이는 어려움이나 고민으로도 정신건강 서비스를 이용할 수 있다는 것을 알리는 것"의 중요성을 강조하였는데, 이는 학생들이 심각한 위기 상황에서만 상담을 받아야 한다는 잘못된 인식을 개선해야 한다는 의미이다.

현실적으로는 증가하는 상담 수요에 비해 상담 인력이 절대적으로 부족한 상황이며, 상담사들의 처우 또한 열악하여 전문성과 서비스의 지속성 확보가 어려운 구조적 문제를 안고 있다. 이러한 악순환은 결국 서비스의 질적 저하로 이어져 학생들의 만족도와 신뢰도에도 부정적 영향을 미치고 있다.

◆소프트웨어 연구원·개발자의 관점

개발자 집단은 현행 시스템의 구조적 문제에 주목하였다. 가장 큰 문제로 지적된 것은 시스템의 폐쇄성과 낮은 접근성인데, 이는 사용자 친화적이지 않은 인터페이스와 복잡한 이용 절차로 인해 학생들이 서비스 이용을 기피하게 되는 결과를 낳고 있다.

특히 심각한 사건이 아닌 일상적인 정신건강 문제에 대해서는 상담센터 방문이 불필요하다는 인식이 만연해 있다는 점을 강조하였다. 이러한 인식은 예방적 상담의 기회를 원천적으로 차단하는 요인으로 작용하고 있다. 더 나아가 상담센터의 존재 자체를 모를 정도로 홍보가 부족하다는 점도 제기되어, 정보 접근성과 홍보 전략의 전면적 재검토가 필요한 상황임을 시사하고 있다.

1.2.2) 디지털 전환 방안

◆교육현장 측면의 접근 (교수진)

교수진은 디지털 전환의 성공을 위해서는 무엇보다 교내 구성원들의 광범위한 공감대 형성이 선행되어야 한다고 강조하였다. 정신건강 문제의 중요성에 대한 인식 개선이 전제되어야 디지털 도구 도입이 실질적 효과를 거둘 수 있다는 것이다.

구체적인 전략으로는 다음과 같은 사항들이 제시되었다:

- **정신건강 리터러시 교육의 체계화:** 단발성 교육이 아닌 지속적이고 체계적인 교육 프로그램 구축
- **실제 수요 파악:** 학생들의 구체적인 필요와 현황에 대한 정확한 데이터 수집 및 분석

- **자기도움 행동교육:** 학생 스스로 문제 상황을 인지하고 대처할 수 있는 능력 배양
- **정신건강 커뮤니티 양성:** 동료 지원 시스템을 통한 자연스러운 도움 요청 문화 조성

◆상담 서비스 측면의 고려사항 (상담사)

상담사들은 디지털 전환 과정에서 윤리적 측면과 인간적 가치 보존에 특별한 주의를 기울여야 한다고 강조하였다. 디지털 기술의 편리함과 효율성도 중요하지만, 상담의 본질적 가치인 인간적 연결과 신뢰 관계가 훼손되어서는 안 된다는 것이다.

특히 민감한 개인정보 보호를 위한 구체적인 지침 마련이 시급하며, "대학은 생각보다 작은 커뮤니티"라는 특성을 고려하여 익명성 보장에 각별한 주의가 필요하다고 보았다. 이는 단순히 기술적 보안 문제를 넘어서 대학 내 관계성과 사회적 낙인 문제까지 고려한 종합적 접근이 필요함을 의미한다.

또한 디지털 서비스에서도 '인간다움'과 '따뜻한 온도'를 유지하는 것이 중요하다고 강조하였는데, 이는 기술적 완성도와 함께 감정적 교감과 공감적 소통이 보장되어야 한다는 의미로 해석된다.

◆기술 구현의 전략적 방향 (연구원/개발자)

개발자 집단은 기술적 구현 이전에 조직 문화와 사용자 인식 개선이 우선되어야 한다고 보았다. 디지털 트랜스포메이션 문화 구축이 성공의 핵심 요소라는 것이다.

구체적으로는 챗봇 상담에 대한 이질감과 기계적 답변에 대한 선입견 해소가 필요하며, 이를 위해서는 교육기관 차원의 적극적인 홍보와 인식 개선 노력이 선행되어야 한다고 제안하였다. 단순히 기술적 우수성을 강조하는 것이 아니라, 디지털 방식이 가져올 수 있는 실질적 도움과 장점을 구체적으로 제시하고 체험할 수 있는 기회를 제공하는 것이 중요하다는 것이다.

1.2.3) 챗봇 활용 방안

◆교육적 활용의 가능성 (교수진)

교수진은 챗봇이 기존 상담체계를 대체하는 것이 아니라 보완하는 역할을 해야 한다는 점을 명확히 하였다. 디지털 네이티브 세대의 특성을 고려한 원스톱 서비스 설계가 필요하며, 특히 자가 점검 도구로서의 활용 가능성이 높다고 평가하였다.

Kian et al.(2024)의 연구에서 입증된 바와 같이, 챗봇은 학생들이 자신의 정신건강 상태를 스스로 점검하고 모니터링할 수 있는 도구로서 특히 유용할 것으로 예상된다. 이는 전문적 상담이 필요한 단계 이전에 예방적 차원에서 자기 관리 역량을 높이는 데 기여할 수 있다.

◆상담 보조 도구로서의 역할과 한계 (상담사)

상담사들은 챗봇의 활용 영역을 명확히 제한하면서도 그 유용성을 인정하였다. 주요 기능으로는 초기 심각도 파악, 전문가 연결, 그리고 기본적인 정보 제공에 초점을 맞추어야 한다고 제안하였다.

중요한 것은 "즉각적이고 개인화된 도움은 일시적인 것"이라는 한계를 명확히 인식하는 것이다. 문제 행동의 반복을 막고 근본적인 해결을 위해서는 기존 상담 서비스와의 통합이 필수적이라는 점을 강조하였다.

이러한 현장 전문가들의 견해는 최근 연구 결과와도 일치하는 양상을 보인다. Zhang et al.(2024)이 대학생들을 대상으로 실시한 연구에서도 LLM 기반 서비스는 초기 스크리닝과 사후 관리 영역에서 가장 높은 수용도를 보였다. 특히 선제적 개입을 통한 조기 발견과 맞춤형 사후 관리 기능이 주요 장점으로 확인되어, 본 연구에서 상담사들이 강조한 '디지털 도구의 진입점 역할'과 정확히 부합하는 결과를 보여주고 있다.

종합적 시사점: 각기 다른 전문 영역에서 출발한 현장 전문가들의 분석이 접근성 개선, 전문성 유지, 기술과 인간적 요소의 균형이라는 공통된 핵심 과제에 수렴하고 있다는 점은 주목할 만하다. 이는 대학 정신건강 관리시스템의 디지털 전환이 단순한 기술 도입을 넘어서 교육, 상담, 기술 영역의 통합적 접근을 통해서만 성공할 수 있음을 시사한다.

5. 결론 및 시사점

본 장에서 제시한 정신건강 플랫폼의 개선 방향은 사용자 중심 설계와 LLM 기술 발전의 조화로운 통합을 통해 구현될 수 있다. 실험을 통해 확인된 대화 중심 접근의 우위성, 개인화의 중요성, 하이브리드 모델의 필요성은 단순한 이론적 발견을 넘어 현장 전문가들의 실천적 요구와 일치하는 현실적 지침이다.

특히 주목할 만한 점은 세 실험 모두에서 일관되게 나타난 패턴들이다. 실험 I 에서 진단된 문제점들이 실험 II 에서 해결 방향을 찾고, 실험 III 에서 구체적인 검증을 거치는 과정을 통해 이론적 타당성과 실무적 적용 가능성이 동시에 확보되었다. 현장 전문가들의 검증을 통해 이러한 발견들이 실제 현장에서도 수용 가능성이 재확인되었다.

특히 RAG 의 핵심인 외부 지식베이스 실시간 검색과 정보 증강을 통한 동적 상담 지원, LangChain 의 본질인 복잡한 AI 워크플로우 체계적 관리를 통한 일관된 대화 흐름 구현, 그리고 프롬프트 엔지니어링 최적화 시스템은 정적 LLM 의 한계를 극복하고 이론적 설계와 현실적 적용 사이의 간극을 메우는 실용적 기술 솔루션이다.

개인화된 사용자 경험, 문화적 맥락을 반영한 AI 기술, 그리고 윤리적 고려사항이 체계적으로 결합될 때, AI 기반 정신건강 플랫폼은 대학생들의 정신건강 지원에 실질적 기여를 할 수 있는 효과적 도구로 발전할 수 있을 것이다.

이러한 개선 방향들이 실제 구현되어 검증되고 확산될 때, 정신건강 서비스의 접근성과 효과성이 동시에 향상되는 새로운 디지털 헬스케어 생태계의 기반이 마련될 것으로 기대한다. 특히 한국 대학생들의 심각한 정신건강 실태(우울증 고위험군 39.7%)를 고려할 때, 본 연구에서 제시한 방향성들의 신속한 구현이 시급한 사회적 과제임을 다시 한번 강조하고자 한다.

제 7 장 결 론

1. 연구의 의의 및 기여

1) 체계적 실증 연구를 통한 종합적 검증

본 연구는 대학생 정신건강 지원에서 LLM 기반 챗봇의 효과성을 세 단계 실험을 통해 체계적으로 입증하였다.

실험 I에서는 대학생 정신건강 문제의 심각성을 실증했다. 참가자의 39.7%가 우울증 고위험군, 15.9%가 자살 충동을 보고했으며, 정신건강 리터러시는 평균 2.46 점(5 점 척도)에 불과했다. 동시에 기존 디지털 치료 앱의 근본적 한계를 확인했다: 한국어 미지원으로 인한 접근성 문제와 규칙 기반 시스템의 경직된 대화 패턴이다.

실험 II에서는 두 가지 핵심 발견을 도출했다. 첫째, 닥터케어챗은 기존 치료 앱 대비 매우 큰 효과크기($\eta^2 = 0.68$)를 보여 기존 디지털 치료 솔루션의 한계를 크게 개선했음을 확인했다. 둘째, 범용 LLM 과의 비교에서는 중간 효과크기($\eta^2 = 0.152$)를 나타내어, LLM 기반 대화형 인터페이스 자체의 기본 성능이 높으면서도 전문화된 프롬프트 엔지니어링을 통한 추가적 성능 향상 가능성을 보여주었다. 이는 정신건강 챗봇 개발에서 LLM 기술의 잠재력과 더불어 도메인 특화 최적화의 중요성을 시사한다.

실험 III에서는 CoT(Chain-of-Thought) 방법론을 활용한 AI-인간 전문가 통합 평가 체계를 구축하고, 닥터케어챗을 Wysa, Youper, Replika 등 3 개 글로벌 LLM 챗봇과 체계적으로 비교 분석했다. $F(3,80) = 9.73, p < 0.001, \eta^2 = 0.267$ 의

큰 효과크기로 CoT 기반 평가 방법론이 챗봇 간 상담적 품질 차이를 유의미하게 변별할 수 있음을 실증했다. 특히 Wysa 는 전문성과 단계적 질문을 통한 변화 유도에서, 닥터케어앰은 공감성과 자연스러운 대화에서 각각 강점을 보였다.

2) 연구의 선도성과 독창성

2.1) 국제적 검증 기반의 체계적 연구 확장

본 박사논문은 연구의 신뢰성과 확장성 측면에서 독특한 접근법을 취하였다. 실험 I 과 II 는 각각 연구자가 제 1 저자로 참여하여 JMIR Formative Research(2024)와 JMIR Medical Informatics(2025)에 게재된 연구를 근간으로 하되, 박사논문의 통합적 연구 목적에 맞게 대폭 확장하였다.

이는 단순한 기존 연구의 재활용이 아니라, 이미 국제적으로 검증된 연구 기반 위에서 새로운 가설 설정, 심화된 분석 방법론, 확장된 시사점 도출 등을 통해 학술적 깊이와 실용적 가치를 동시에 확보한 접근법이다. 특히 다음과 같은 확장적 연구를 수행하였다:

- ◆실험 I: 개별 참가자 변화 궤적 분석, 반응자 분석, 확장된 질적 데이터 분석을 통한 개인차 탐색
- ◆실험 II: 프롬프트 엔지니어링의 상세 기술, 효과크기 분석, 사후 검증력 분석 등 통계적 엄밀성 강화
- ◆실험 III: 새로운 연구로서 CoT 기반 다차원 평가 프레임워크 개발

이러한 접근법을 통해 연구의 국제적 신뢰성을 확보하면서도 박사논문 수준의 독창성과 체계성을 동시에 달성하였다.

2.2) 체계적 연구 생태계의 독창적 설계

본 연구는 연구자가 확인한 바로는 국내에서 LLM 기반 정신건강 챗봇을 직접 개발하고 체계적으로 검증한 초기 연구로서 다섯 가지 독창성을 갖는다.

첫째, 통합적 연구 생태계 설계: 문제 진단(실험 I) → 솔루션 개발(실험 II) → 비교 검증(실험 III) → 설계 방향 도출(6 장)의 체계적 접근을 통해 단편적 연구의 한계를 극복했다.

둘째, 학제간 융합 방법론: 상담심리학의 이론적 토대와 AI 기술의 실용적 구현을 통합한 새로운 연구 모델을 제시했다.

셋째, 언어별 AI 특성 발견: LLM 이 언어에 따라 다른 응답 패턴을 보인다는 중요한 발견을 했다. 영어에서는 점진적·공감적 접근을, 한국어에서는 즉각적·직접적 대응을 보이는 것은 단순한 번역 문제가 아닌 언어 모델의 구조적 특성임을 입증했다.

넷째,

메타 평가 체계: CoT 를 활용해 AI 와 인간 전문가가 협력하는 체계적 평가 방법론을 설계하고, 단계별 추론 과정을 명시적으로 추적함으로써 확장 가능한 품질 관리 시스템을 제시했다.

3) 실용적 함의

즉시 적용 가능한 설계 원칙: 프롬프트 엔지니어링부터 개인화 인터페이스까지, 실제 개발에 활용할 수 있는 구체적 방법론을 제시했다.

대학 상담 체계 혁신 방안: 초기 스크리닝, 위험 감지, 전문가 연계에서 AI 챗봇의 보완적 역할을 실증하여 현재 대학 상담센터의 인력 부족과 접근성 문제에 대한 실질적 해결책을 제시했다.

확장 가능한 품질 보장: AI 기반 평가 체계를 통해 대규모 디지털 정신건강 서비스의 품질 관리와 확장성을 동시에 달성할 수 있는 방법론을 입증했다.

2. 통합적 연구 성과

1) 핵심 발견사항의 종합

세 차례의 실험을 통해 도출된 핵심 발견사항들을 종합하면 다음과 같다.

◆디지털 정신건강 서비스의 진화적 발전: 실험 I 에서 확인된 기존 디지털 도구의 한계(언어적 접근성, 대화의 자연스러움)를 실험 II 의 LLM 기반 챗봇이 효과적으로 해결하며, 정보 제공 기능과 공감적 소통을 결합한 차세대 서비스 모델의 가능성을 실증하였다.

◆효과적인 챗봇 설계 요소: 개인화된 페르소나, 감정 입력 UI, 위험 탐지 기능 등의 통합적 설계가 사용자 만족도와 지속 사용 의향에 결정적 영향을 미치며, 적절한 프롬프트 엔지니어링을 통해 글로벌 수준의 성능 달성이 가능함을 확인하였다.

◆AI-인간 협력 모델의 필요성: 모든 실험에서 일관되게 나타난 것은 AI 챗봇이 독립적 치료 도구가 아닌 전문가-AI-사용자가 유기적으로 연결된 하이브리드 생태계의 핵심 구성요소로 기능해야 한다는 점이다.

2) 방법론적 혁신

본 연구는 AI 기반 정신건강 도구 평가 분야에서 다음과 같은 방법론적 기여를 제시하였다.

- ◆상담학적 평가 프레임워크: 7 가지 상담학적 평가 기준에 기반한 체계적 평가 방법론을 개발하여 기존 NLP 지표로는 포착하기 어려운 상담 대화의 질적 차이를 정량화할 수 있는 도메인 특화 평가 접근법을 제시하였다.
- ◆AI-인간 교차 검증 체계: Claude 3.5 Sonnet, ChatGPT 4.0, 인간 전문가를 통한 삼중 검증법을 구축하고 높은 신뢰도($r=0.618\sim0.957$)를 확인함으로써 확장 가능하면서도 신뢰할 만한 평가 체계를 개발하였다.
- ◆시간적 안정성 입증: 1 년 간격 재평가를 통해 높은 시간적 일치도를 확인함으로써 장기적 품질 모니터링 도구로서의 실용성을 입증하였다.

3. 정책적 제언

1) 대학 차원의 과제

AI 상담 시스템의 단계적 도입 전략 수립이 필요하다. 실험 I 에서 확인된 높은 우울증 고위험군 비율(39.7%)과 낮은 정신건강 리터러시(2.46/5.0)를 고려할 때, 24 시간 상시 초기 상담 및 분류(triage) 시스템으로서 LLM 기반 챗봇의 도입이 시급하다. 특히 실험 II 에서 닥터케어챗이 범용 LLM 대비 높은 만족도(8.2 점)를 보인 것은 정신건강 특화 모델의 효과성을 입증한다.

기술 플랫폼 선택의 전략적 고려가 중요하다. 본 연구에서는 개발 과정에서 다양한 LLM 플랫폼을 검토한 결과, ChatGPT 기반 모델이 방대한 학습 데이터로

인해 더 유연하고 풍부한 대화가 가능하다고 판단하여 선택하였다. 실험 II-III 의 결과는 정신건강 지원에서 대화의 풍부함과 유연성이 핵심임을 보여준다.

통합적 운영 체계 구축이 필요하다. 실험 II-III 의 비교 분석에서 확인된 각 챗봇의 강점을 결합한 하이브리드 모델이 요구된다. 실험 II 에서 정확성과 유익성($r=0.82$)이 지속사용의향과 가장 높은 상관관계를 보인 점을 고려하여, AI 시스템은 독립적 서비스가 아닌 전체 상담 프로세스의 유기적 일부로 기능해야 한다.

윤리적 운영 기준 확립이 필수적이다. 실험 II 에서 나타난 언어별 대응 패턴의 차이와 프롬프트 엔지니어링의 한계를 고려하여, 대학의 상대적 폐쇄성과 LLM 기반 시스템의 특성을 반영한 구체적 윤리 지침이 요구된다.

2) 정부 차원의 과제

포괄적이고 혁신적인 접근이 필요하다. 실험 I 에서 확인된 심각한 정신건강 상태(우울증 위험군 39.7%)를 고려할 때, 미시간 대학교의 CAPS-IPC-Uwill 통합 시스템이나 스탠퍼드의 디지털 헬스 센터와 같은 혁신적 접근이 필요하다. 실험 II 에서 닥터케어챗이 기존 테라피 앱 대비 매우 큰 효과크기($\eta^2=0.68$)를 보인 반면, 범용 LLM 과는 중간 정도의 효과크기($\eta^2=0.152$)를 나타낸 것은 전문화된 한국형 모델 개발의 가능성과 더불어 지속적인 성능 개선을 통한 글로벌 경쟁력 확보의 필요성을 동시에 보여준다.

기술 독립성과 최적화 전략이 중요하다. 개발 과정에서 ChatGPT 기반 모델을 선택한 것은 당시 대화의 유연성과 풍부함을 고려한 기술적 판단이었으나,

향후에는 기술 의존성 리스크를 분산시키면서도 최적의 사용자 경험을 제공할 수 있는 전략이 필요하다.

학제간 융합연구 촉진이 중요하다. 실험 II-III의 결과에서 확인된 것처럼, LLM 기반 챗봇의 성공적 구현을 위해서는 심리학, 정신의학, 컴퓨터 공학, 디지털 헬스케어 등 다양한 분야의 전문성이 요구된다. 특히 실험 II에서 개인화($r=0.85$)가 혁신성 인식과 가장 높은 상관관계를 보인 점은 기술적 차별화의 중요성을 시사한다.

연구개발 지원 확대가 필요하다. 실험 III에서 기존 글로벌 테라피 앱들의 한국어 지원 한계가 확인되었고, 한국 대학생들 대상으로 한 정신건강 서비스에서는 자연스러운 한국어 소통의 중요성이 부각되었다. 이는 한국 특화 모델 개발과 글로벌 모델의 한국적 적용 방안 연구의 시급성을 보여준다.

3) 단계적 실행 방안

본 연구의 현장 전문가 인터뷰와 세 차례의 실험을 통해 도출된 핵심 발견사항들을 바탕으로, 대학 정신건강 관리시스템의 디지털 전환을 위한 단계적 실행 방안을 제시한다. 실험 결과는 정신건강 지원에서 자연스러운 대화와 공감적 소통의 중요성을 보여주므로, 이를 중심으로 한 점진적 접근을 통해 성공적인 전환을 도모한다.

단기 과제 (6개월-1년)

◆초기 스크리닝과 사후 관리 중심의 LLM 챗봇 도입

현장 전문가 인터뷰에서 상담사들이 공통적으로 가장 효과적이라고 평가한 초기 스크리닝과 사후 관리 영역부터 우선 도입하여 신뢰도를 확보하고, 학생들의 정신건강 상태를 조기에 파악할 수 있는 예방적 시스템을 구축한다. 복잡한 상담보다는 기본적인 상태 점검과 정보 제공에 집중하여 안정적인 서비스 기반을 마련한다.

◆기본적인 챗봇-전문상담사 연계 시스템 구축

실험 II 의 질적 분석 결과에서 사용자들이 가장 많이 요구한 기능인 심리 전문가 연결 시스템(16 회 언급)을 우선 구축한다. 챗봇이 위기 상황이나 전문적 개입이 필요한 경우를 감지했을 때 즉시 상담사에게 연결할 수 있는 체계를 마련하여 챗봇의 한계를 보완하고 학생 안전을 보장한다.

◆AI 상담 윤리 가이드라인 수립

실험 II 에서 나타난 언어별 대응 패턴의 차이와 프롬프트 엔지니어링의 한계를 고려한 윤리 기준을 마련한다. 개인정보 보호, 익명성 보장, 상담 범위의 한계 등에 대한 명확한 기준을 포함하여 서비스 운영의 투명성과 신뢰성을 확보한다.

◆정신건강 리터러시 교육 프로그램 개발

실험 I 에서 확인된 낮은 정신건강 리터러시(2.46/5.0)를 개선하기 위해, 학생들이 자신의 정신건강 상태를 스스로 인지하고 적절한 도움을 요청할 수 있는 능력을 기르는 체계적인 교육 과정을 설계한다. 이는 디지털 도구 활용의 효과를 극대화하는 기반이 된다.

중기 과제 (1-2 년)

◆맞춤형 LLM 모델 개발 및 고도화

실험 II 에서 정확성과 유익성($r=0.82$)이 지속사용의향과 가장 높은 상관관계를 보인 점을 고려하여, 사용자 맞춤형 정보 제공 및 실질적 도움을 강화한 상담 서비스를 개발한다. 또한 개인화($r=0.79$) 역시 높은 상관관계를 보인 바, 사용자의 성격 유형, 문화적 배경, 상담 이력 등을 종합적으로 고려한 개별화된 상담 서비스를 구축한다.

구체적으로는 RAG 기반 정확한 정보 검색 시스템을 통해 신뢰할 수 있는 정신건강 정보를 제공하고, 감정 맥락 인식 시스템과 LangChain 순차적 체인 관리를 통해 실험에서 발견된 개인화 부족, 대화 일관성 부족, 한국어 처리 한계 등의 핵심 문제들을 기술적으로 해결한다. 단기 과제에서 수집된 사용 데이터를 바탕으로 지속적인 학습과 개선을 통해 상담 품질을 향상시킨다.

◆통합 사례관리 시스템 구축

실험 II 의 질적 분석에서 확인된 사용자 요구사항인 개인 맞춤형 기능(10 회)과 활동 보고 기능(10 회)을 반영하여, 챗봇 상담, 전문상담사 상담, 학사 관리, 의료 서비스 등을 연계한 종합적인 사례관리 플랫폼을 구축한다. 이를 통해 학생 개인의 정신건강 여정을 체계적으로 추적하고 관리할 수 있는 통합적 지원 체계를 마련한다.

◆대화 품질 및 사용자 경험 개선

실험 II 에서 언급된 한국어 표현의 어색함, 반복적 어조, 제한적 콘텐츠 등의 피드백을 바탕으로 대화의 자연스러움과 다양성을 향상시킨다. 개인화된 사후 관리 시스템을 강화하여 상담 종료 후에도 지속적인 모니터링과 지원을 제공할 수 있는 시스템을 구축한다.

장기 과제 (2-3 년)

◆전국 대학 표준 모델 확산

성공적으로 검증된 모델을 전국 대학으로 확산하기 위한 표준화된 프레임워크를 개발한다. 실험 II 에서 확인된 닥터케어챗의 우수성(효과크기 $\eta^2=.68$)을 바탕으로 각 대학의 특성과 자원 현황을 고려한 맞춤형 도입 방안을 제시하여 전국적인 정신건강 관리 수준 향상에 기여한다.

◆지역 정신건강 서비스와의 연계 체계 구축

대학 내 서비스의 한계를 넘어 지역사회의 정신건강 센터, 병원, 상담기관 등과 연계한 포괄적 지원 네트워크를 구축한다. 실험 결과에서 확인된 사용자들의 전문가 연결 요구를 반영한 통합적 서비스 모델을 구현하여 보다 전문적이고 지속적인 치료와 관리가 필요한 학생들에게 적절한 서비스를 연결한다.

◆다국어 및 문화 특화 모델 개발

다양한 문화적 배경을 가진 학생들(유학생, 다문화 가정 출신 등)을 위한 특화된 상담 모델을 개발한다. 언어적, 문화적 차이를 고려한 맞춤형 접근 방식을 통해 포용적이고 효과적인 정신건강 서비스를 제공한다.

◆데이터 기반 지속적 시스템 개선

축적된 상담 데이터와 성과 지표를 활용하여 시스템의 지속적인 개선과 최적화를 수행한다. 실험 II 에서 확인된 정확성과 유익성의 중요성을 반영한 머신러닝 기반 예측 모델 개발과 실시간 품질 관리 시스템을 통해 서비스의 효과성을 지속적으로 향상시킨다.

4. 연구의 한계

1) 연구 설계 및 일반화의 제약

본 연구는 3 개의 핵심 실험을 중심으로 하며, 6-7 장의 사용자 중심 디자인과 현장전문가 분석은 탐색적 성격의 보완 연구로서 제한적 일반화 가능성을 갖는다.

또한 연구 참가자가 동일 대학의 비교적 동질적인 연령대(18-27 세)로 제한되어 있어, 연구 결과의 일반화 가능성에 한계가 있다. 향후 연구에서는 다양한 연령층, 교육 수준, 사회경제적 배경을 포함한 이질적 표본을 대상으로 한 검증이 필요하며, 특히 정신건강 서비스에 대한 접근성이 상대적으로 낮은 취약계층을 포함한 연구 설계가 요구된다.

2) 표본 크기 및 중재 기간의 한계

실험별로 상이한 표본 크기의 한계가 존재한다. 실험 I 의 높은 이탈률(49%), 실험 II 의 제한된 표본($n=20$), 실험 III 의 소규모 표본($n=4$) 등으로 인해 연구 결과의 통계적 검정력이 제한된다.

특히 6 개월 이상의 장기 중재효과를 검증하지 못한 것은 주요 한계로 지적된다. 정신건강 중재의 지속적 효과와 장기적 행동 변화를 확인하기 위해서는 보다 장기간의 추적 연구가 필요하다.

3) 기술적 한계

감정 표현의 문화적 뉘앙스와 비언어적 요소의 통합 측면에서 근본적인 한계가 존재한다. 특히 한국 문화 특유의 정서적 표현 방식, 암시적 소통 패턴, 그리고 실시간 상호작용에서의 비언어적 신호 감지 등은 여전히 기술적 도전 과제로 남아있다.

또한 현재의 LLM 기술로는 복잡한 정신건강 상태의 실시간 위험도 평가와 즉각적 위기 개입에 한계가 있으며, 이는 향후 기술 발전과 함께 지속적으로 개선되어야 할 부분이다.

4) 평가 체계의 한계

실험 III 에서 시도된 LLM 기반 상담학적 평가 체계는 초기 단계의 접근법으로, 다양한 상담 시나리오에서의 평가 확대와 표준화된 평가 기준 마련이 필요하다.

또한 인간 전문가 평가자의 규모($n=1$)와 전문 영역의 제한으로 인한 평가 편향 가능성이 존재한다. 향후 연구에서는 다수의 전문가 평가단을 구성하고, 블라인드 평가를 통한 객관성 확보가 필요하다.

5) 데이터 구축 및 윤리적 제약

챗봇의 대화 데이터 표본이 제한적이며, 다양한 상담 시나리오와 위험 상황에 대응할 수 있는 데이터 확장이 필요하다. 특히 위기 상황 대응 데이터의 부족은 실제 서비스 배포 시 안전성 문제를 야기할 수 있다.

또한 개인화 서비스 제공 시 개인정보 보호와 윤리적 문제에 대한 추가적인 연구가 필요하다. 정신건강 데이터의 민감성과 AI 시스템의 편향 가능성을 고려한 윤리적 가이드라인 구축이 요구된다.

6) 종합적 한계점

각 섹션별 세부 한계는 해당 장에서 구체적으로 다루었으며, 향후 연구에서는 이러한 한계점들을 보완한 보다 체계적이고 대규모의 연구 설계가 필요하다. 특히

다기관 협력을 통한 대규모 무작위 대조시험과 장기 추적 연구를 통해 디지털 정신건강 중재의 실질적 효과성과 안전성을 검증하는 것이 중요하다.

5. 향후 연구 방향

1) 방법론적 발전 방향

대규모 중단 연구가 우선적으로 필요하다. 본 연구의 주요 한계인 소규모 표본과 장기 중재효과의 부재를 극복하기 위해 더 많은 챗봇을 대상으로 한 대규모 비교 연구와 6 개월 이상의 장기 추적 연구가 요구된다.

다양한 시나리오 확장이 중요하다. 현재 연구가 주로 일반적인 스트레스나 발표 불안에 초점을 맞췄으나, 향후에는 우울증, 범불안장애, 공황장애, PTSD 등 다양한 정신건강 문제 상황을 포함한 포괄적 평가 연구가 필요하다.

2) 기술적 발전 방향

언어별 맞춤형 설계가 우선 과제이다. 실험 II 에서 발견된 언어별 응답 패턴 차이는 단순한 번역을 넘어선 언어별 최적화의 필요성을 시사한다. 한국어의 높임법, 완곡 표현, 정서적 거리감 등의 언어적 특성이 상담 효과에 중요한 영향을 미칠 수 있다. 이를 위해 RAG 기반 문화적 맥락 데이터베이스와 토큰 최적화 시스템을 통해 한국어 특성을 고려한 효율적인 처리가 가능하다.

실시간 평가 시스템 개발이 필요하다. 실험 III 에서 검증한 LLM 기반 상담학적 평가 체계를 바탕으로 실시간으로 챗봇 대화 품질을 모니터링하고 피드백을 제공하는 시스템 개발이 가능하다.

개인화 모델 고도화가 중요하다. 제 6 장의 사용자의 성격 유형별 분석을 확장하여 사용자의 개별적 특성(성격, 선호도, 문화적 배경 등)을 고려한 맞춤형 모델 개발이 필요하다. 특히 LangChain 기반 동적 프롬프트 생성 시스템을 활용하여 사용자별 최적화된 상담 경험을 제공할 수 있다.

3) 응용 분야 확장

글로벌 확장 가능성 연구가 필요한 시점이다. 한국 대학생 맥락에서 개발된 시스템을 다양한 문화적 배경의 사용자들에게 적용할 수 있는 프레임워크 개발이 요구되고 있다. 본 연구에서 닥터케어썸은 영어와 한국어 2 개국어를 지원하도록 설계되었으나, 실제 영어권 사용자에게는 실험을 적용하지 못했다는 한계가 있었다.

이러한 한계는 다국어 지원 시스템의 실제 효용성 검증과 문화적 맥락에 따른 상담 방식의 차이에 대한 추가 연구 필요성을 시사한다. 특히 서구권과 동양권 간의 정신건강에 대한 인식 차이, 상담에 대한 접근 방식의 차이, 그리고 디지털 헬스케어에 대한 수용도 차이 등을 고려한 문화적 적응 모델 개발이 중요하다.

교육 및 다른 분야 적용도 고려할 수 있는 확장 방향이다. 본 연구의 대화 분석 방법론과 평가 체계는 교육용 챗봇, 고객 서비스, 의료 상담 등 다른 영역으로 확장하는 연구가 가능하다.

특히 교육 분야에서는 학습자의 개별적 특성을 파악하고 맞춤형 학습 지원을 제공하는 데 활용할 수 있으며, 고객 서비스 영역에서는 고객의 감정 상태와 요구사항을 보다 정확히 파악하여 만족도 높은 서비스를 제공하는 데 기여할 수 있다. 이러한 응용 연구를 통해 본 연구에서 개발한 방법론의 범용성과 확장 가능성을 검증할 수 있을 것이다.

6. 맺음말

본 연구는 3 차례의 체계적 실험을 통해 LLM 기반 챗봇의 대학생 정신건강 지원 가능성을 다각도로 실증하고, 혁신적인 평가 방법론을 개발하며, 실천적 방향을 제시했다는 점에서 종합적 의의가 있다.

기술적 성과: 세 차례의 체계적 실험을 통해 LLM 기반 챗봇의 감정 인식과 공감 능력이 기존 규칙 기반 시스템보다 우수함을 확인했으며, 동시에 한국어 처리와 문화적 맥락화의 개선 필요성도 도출했다.

방법론적 혁신: 리타 샤론의 내러티브 의학 개념을 참조하여 AI 기반 상담 평가 방법을 개발하고, 삼중 검증 체계와 시간적 안정성 검증을 통해 접근법의 타당성을 확인했다.

사용자 중심 설계의 중요성: 성격 유형별 페르소나 분석을 통해 개인화된 접근의 구체적 방향을 제시했으며, 이는 획일적 서비스가 아닌 맞춤형 정신건강 지원의 가능성을 보여준다.

실용적 가치: AI 챗봇이 초기 스크리닝, 사후 관리, 전문가 연계 등의 영역에서 효과적으로 활용될 수 있음을 확인했다. 특히 '대화의 중요성'이라는 핵심 발견은 향후 디지털 정신건강 분야의 연구와 개발에 새로운 패러다임을 제시한다.

이러한 통합적 접근은 디지털 도구의 기술적 장점을 살리면서도 상담의 본질인 '인간다움'과 '치료적 관계'를 유지하는 데 기여할 것으로 기대된다. 궁극적으로 AI 기반 정신건강 플랫폼은 접근성과 효과성을 동시에 향상시켜, 더 많은 대학생들이 필요한 지원을 받을 수 있는 포용적 정신건강 생태계 구축에 기여할 수 있을 것이다.

특히 본 연구에서 실증된 한국어 기반 챗봇의 가능성은 문화적 적합성의 중요성을 보여주며, K-헬스케어의 글로벌 경쟁력 확보에 기여할 수 있는 의미있는 성과이다. 개발된 평가 체계와 설계 원칙들은 학술적 기여를 넘어 실제 정신건강 서비스 개선과 정책 수립에 실용적으로 활용될 수 있는 구체적 도구를 제공한다는 점에서 그 가치를 찾을 수 있을 것이다.

참 고 문 헌

1. 국내문헌

고신정. (2024, 11월 28일). 우울증 등 정신건강 위험군 '첫 진료비' 건강보험 서 지원. 의협신문.

<https://www.doctorsnews.co.kr/news/articleView.html?idxno=157450>

김동일. (2021). 대학 상담센터 이용 학생들의 상담 효과 연구. 상담학연구, 22(1), 1-20.

김진아. (2010). 대학생의 상담 서비스 이용 의도에 영향을 미치는 요인. 청소년학연구, 17(10), 47-69.

김희래. (2018, 11월 30일). [단독] "최고대학 들어왔지만..." 서울대생 절반 우울증세. 매일경제. <https://www.mk.co.kr/news/society/8580386>

김희철. (2018). 대학생의 심리적 디스트레스와 전문적 도움추구태도의 관계에서 낙인의 매개효과. 정신건강과 사회복지, 46(1), 5-33.

대학알리미. Retrieved from <https://www.academyinfo.go.kr>

로버트 퍼트넘. (2009). 나 홀로 불링: 사회적 커뮤니티의 붕괴와 소생 (정승현 역). 페이퍼로드.

로이 리처드 그린커. (2022). 정상은 없다: 문화는 어떻게 비정상의 낙인을 만들어내는가 (정해영 역). 메멘토.

박순형 (2022). MZ세대의 특성과 언어 사용 연구. 한말연구, 63(18), 1 - 23.

박지혜, & 이선혜. (2020). 청년의 정신건강 리터러시와 도움요청 행동 - 도움요청에 관한 낙인, 태도, 의도의 매개효과 분석. 한국사회복지학, 72(4), 63-92.

보건복지부. (2021). 2021년 정신건강 실태조사

서울연구원. (2021). 서울시 1인가구 고독사 예방정책 방향 연구. 서울연구원.

손인서, 김승섭. (2015). 한국의 차별경험과 건강 연구에 대한 체계적 문헌고찰. 보건사회연구, 35(1), 26-57.

- 이장석. (2023). 문화산업 콘텐츠로서의 이모티콘이 공동체 의식에 미치는 영향: 가천대학교 사례를 중심으로. 문화산업연구, 23(1), 55-67.
- 장세풍. (2019, 7월 15일). 벼랑 끝에 선 대학생 정신건강② 예산·인력·전문성 총체적 부실. 내일신문. http://www.naeil.com/news_view/?id_art=319462
- 전국대학교학생상담센터협의회. (2021). 대학생 정신건강 실태조사 보고서.
- 진진아, & 강혜리. (2020). 정신건강서비스 전달체계의 현황과 과제. 보건복지포럼, 282, 30-42.
- 진보래. (2024). MZ는 왜 전화를 두려워하는가?: 사회 불안의 세대 차이. 커뮤니케이션 이론, 20(3), 228-272. 10.20879/ct.2024.20.3.228
- 진은주, 황석현.(2019) 한국판 UCLA 외로움 척도 3 판의 타당화. 청소년학연구 26.10 (2019): 53-80.
- 질병관리청. (2018). 2018년 지역사회건강조사 결과 발표.
- https://www.kdca.go.kr/board/board.es?mid=a20501020000&bid=0015&list_no=143377&cg_code=&act=view&nPage=417&newsField=
- 최다정, 조애리, & 김창대. (2021). 코로나19 대학상담서비스 접근성 개선을 위한 대학상담센터 안내 챗봇 설계. 보건학논집, 58(2), 13-24.
- 통계청. (2021). 2021년 사망원인통계.
- 통계청. (2022, 12월 7일). 2022 통계로 보는 1인가구. 보도자료. https://kostat.go.kr/board.es?mid=a10301010000&bid=10820&act=view&list_no=422143
- 홍소희. (2021). MZ세대의 언어사용 특성과 커뮤니케이션 전략 연구. 한국언어문화학회지, 18(2), 267-294.

2. 국외문헌

- Abd-Alrazaq, A., Alajlani, M., Alalwan, A. A., Bewick, B., Gardner, P., & Househ, M. (2020). An overview of the features of chatbots in mental health: A scoping review. International Journal of Medical Informations, 132, 103978.

- Adiwardana, D., Luong, M. T., So, D. R., Hall, J., Fiedel, N., Thoppilan, R., ... & Le, Q. V. (2020). Towards a human-like open-domain chatbot. arXiv preprint arXiv:2001.09977.
- American Psychiatric Association. (2013). *Diagnostic and Statistical Manual of Mental Disorders* (5th ed.).
- Aristovnik, A., Keržič, D., Ravšelj, D., Tomaževič, N., & Umek, L. (2020). Impacts of the COVID-19 pandemic on life of higher education students: A global perspective. *Sustainability*, 12(20), 8438. <https://doi.org/10.3390/su12208438>
- Arnett, J. J. (2000). Emerging adulthood: A theory of development from the late teens through the twenties. *American Psychologist*, 55(5), 469–480.
- Auerbach, R. P., Alonso, J., Axinn, W. G., Cuijpers, P., Ebert, D. D., Green, J. G., ... & Bruffaerts, R. (2016). Mental disorders among college students in the World Health Organization world mental health surveys. *Psychological Medicine*, 46(14), 2955–2970.
- Bai, Y., Kadavath, S., Kundu, S., Askeel, A., Kernion, J., Jones, A., ... & Kaplan, J. (2022). Constitutional AI: Harmlessness from AI feedback. arXiv preprint arXiv:2212.08073.
- Banerjee, S., & Lavie, A. (2005). METEOR: An automatic metric for MT evaluation with improved correlation with human judgments. In *Proceedings of the ACL Workshop on Intrinsic and Extrinsic Evaluation Measures for Machine Translation and/or Summarization* (pp. 65–72).
- Barak, A., Hen, L., Boniel-Nissim, M., & Shapira, N. A. (2008). A comprehensive review and a meta-analysis of the effectiveness of internet-based psychotherapeutic interventions. *Journal of Technology in Human Services*, 26(2–4), 109–160.
- Barbuto, J. E. (1997). A critique of the Myers-Briggs Type Indicator and its operationalization of Carl Jung's psychological types. *Psychological Reports*, 80(2), 611–625.
- Beck, A. T. (1967). *Depression: Clinical, experimental, and theoretical aspects*. Harper & Row.
- Beck, A. T., Rush, A. J., Shaw, B. F., & Emery, G. (1979). *Cognitive therapy of depression*. Guilford Press.

- Beck, J. S. (2012). *Cognitive Behavior Therapy: Basics and Beyond*.
- Becker, M. H. (1974). The health belief model and personal health behavior. *Health Education Monographs*, 2, 324–508.
- Bickmore, T. W., Gruber, A., & Picard, R. (2005). Establishing the computer–patient working alliance in automated health behavior change interventions. *Patient Education and Counseling*, 59(1), 21–30.
- Bickmore, T. W., & Picard, R. W. (2005). Establishing and maintaining long–term human–computer relationships. *ACM Transactions on Computer–Human Interaction*, 12(2), 293–327.
- Bommasani, R., Hudson, D. A., Adeli, E., Altman, R., Arora, S., von Arx, S., ... & Liang, P. (2021). On the opportunities and risks of foundation models. *arXiv preprint arXiv:2108.07258*.
- Boucher, E. M., McNaughton, E. C., Harake, N., Stafford, J. L., & Parks, A. C. (2021). The impact of a digital intervention (Happify) on loneliness during COVID–19: Qualitative focus group. *JMIR Mental Health*, 8(2), e26617.
- Braun, V., & Clarke, V. (2006). Using thematic analysis in psychology. *Qualitative Research in Psychology*, 3(2), 77–101. <https://doi.org/10.1191/1478088706qp063oa>
- Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J. D., Dhariwal, P., ... & Amodei, D. (2020). Language models are few–shot learners. *Advances in Neural Information Processing Systems*, 33, 1877–1901.
- Brown, T., & Wyatt, J. (2015). Design thinking for social innovation. *Annual Review of Policy Design*, 3(1), 1–10.
- Cacioppo, J. T., & Hawkley, L. C. (2006). Loneliness as a specific risk factor for depressive symptoms: Cross–sectional and longitudinal analyses. *Psychology and Aging*, 21(1), 140–151.
- Cacioppo, J. T., Hawkley, L. C., & Thisted, R. A. (2010). Perceived social isolation makes me sad: 5–year cross–lagged analyses of loneliness and depressive symptomatology in the Chicago Health, Aging, and Social Relations Study. *Psychology and Aging*, 25(2), 453–463.

- Capraro, R. M., & Capraro, M. M. (2002). Myers–Briggs Type Indicator score reliability across studies: A meta–analytic reliability generalization study. *Educational and Psychological Measurement*, 62(4), 590–602.
- Centers for Disease Control and Prevention. (2021). Health, United States, 2020–2021: Annual perspective.
<https://www.cdc.gov/nchs/data/hus/hus20-21-508.pdf>
- Champion, V. L., & Skinner, C. S. (2008). The health belief model. In K. Glanz, B. K. Rimer, & K. Viswanath (Eds.), *Health behavior and health education: Theory, research, and practice* (4th ed., pp. 45–65). Jossey–Bass.
- Chang, C. L., Sinha, C., Roy, M., & Wong, J. C. M. (2024). AI–Led Mental Health Support (Wysa) for Health Care Workers During COVID–19: Service Evaluation. *JMIR Formative Research*, 8, e51858.
<https://doi.org/10.2196/51858>
- Charon, R. (2006). *Narrative medicine: Honoring the stories of illness*. Oxford University Press.
- Chesney, E., Goodwin, G. M., & Fazel, S. (2014). Risks of all-cause and suicide mortality in mental disorders: A meta-review. *World Psychiatry*, 13(2), 153–160.
- Clement, S., Schauman, O., Graham, T., Maggioni, F., Evans–Lacko, S., Bezborodovs, N., ... & Thornicroft, G. (2015). What is the impact of mental health–related stigma on help–seeking? A systematic review of quantitative and qualitative studies. *Psychological Medicine*, 45(1), 11–27.
- Cowen, A. S., & Keltner, D. (2017). Self–report captures 27 distinct categories of emotion bridged by continuous gradients. *Proceedings of the National Academy of Sciences*, 114(38), E7900–E7909.
- Creswell, J. W., & Plano Clark, V. L. (2017). *Designing and conducting mixed methods research* (3rd ed.). SAGE Publications.
- Devlin, J., Chang, M.–W., Lee, K., & Toutanova, K. (2019). BERT: Pre–training of deep bidirectional transformers for language understanding. arXiv preprint arXiv:1810.04805.

- Dutta, R., Gkotsis, G., Velupillai, S. et al. (2021). Temporal and diurnal variation in social media posts to a suicide support forum. *BMC Psychiatry*, 21, 259. <https://doi.org/10.1186/s12888-021-03268-1>
- Eisenberg, D., Downs, M. F., Golberstein, E., & Zivin, K. (2009). Stigma and help seeking for mental health among college students. *Medical Care Research and Review*, 66(5), 522–541.
- Elyoseph, Z., Hadar–Shoval, D., Asraf, K., & Lvovsky, M. (2023). ChatGPT outperforms humans in emotional awareness evaluations. *Frontiers in Psychology*, 14, 1199058.
- Emmons, R. A., & McCullough, M. E. (2003). Counting blessings versus burdens: An experimental investigation of gratitude and subjective well-being in daily life. *Journal of Personality and Social Psychology*, 84(2), 377–389.
- Firth, J., Torous, J., Nicholas, J., Carney, R., Pratap, A., Rosenbaum, S., & Sarris, J. (2017). The efficacy of smartphone-based mental health interventions for depressive symptoms: A meta-analysis of randomized controlled trials. *World Psychiatry*, 16(3), 287–298. <https://doi.org/10.1002/wps.20472>
- Fitzpatrick, K. K., Darcy, A., & Vierhile, M. (2017). Delivering cognitive behavior therapy to young adults with symptoms of depression and anxiety using a fully automated conversational agent (Woebot): A randomized controlled trial. *JMIR Mental Health*, 4(2), e19.
- Fulmer, R., Joerin, A., Gentile, B., Lakerink, L., & Rauws, M. (2018). Using psychological artificial intelligence (Tess) to relieve symptoms of depression and anxiety: Randomized controlled trial. *JMIR Mental Health*, 5(4), e64.
- Gao, J., Liu, Y., Deng, H., Wang, W., Cao, Y., Du, J., & Xu, R. (2021). Improving empathetic response generation by recognizing emotion cause In conversations. In *Findings of the Association for Computational Linguistics: EMNLP 2021* (pp. 807–819).
- Garrett, J. J. (2011). *The elements of user experience: User-centered design for the web and beyond* (2nd ed.). New Riders.
- Goffman, E. (1963). *Stigma: Notes on the management of spoiled identity*. Prentice–Hall.

- Gratch, J., Kang, S. H., & Wang, N. (2013). Using social agents to explore theories of rapport and emotional resonance. In *International workshop on intelligent virtual agents* (pp. 181–186). Springer.
- Haque, M., & Rubya, S. (2023). An overview of chatbot-based mobile mental health apps: Insights from app description and user reviews. *JMIR mHealth and uHealth*, 11, e44838.
- Harrer, M., Adam, S. H., Baumeister, H., Cuijpers, P., Karyotaki, E., Auerbach, R. P., ... & Ebert, D. D. (2019). Internet interventions for mental health in university students: A systematic review and meta-analysis. *International Journal of Methods in Psychiatric Research*, 28(2), e1759.
- Hawkley, L. C., & Cacioppo, J. T. (2010). Loneliness matters: A theoretical and empirical review of consequences and mechanisms. *Annals of Behavioral Medicine*, 40(2), 218–227.
- Ho, A., Hancock, J., & Miner, A. S. (2018). Psychological, relational, and emotional effects of self-disclosure after conversations with a chatbot. *Journal of Communication*, 68(4), 712–733.
- Holt-Lunstad, J. (2015). Loneliness and social isolation as risk factors for mortality: A meta-analytic review. *Perspectives on Psychological Science*, 10(2), 227–237.
- Hope Center. (2023). *#RealCollege 2023: Basic Needs Insecurity Among College Students*. Temple University.
- Hope Center for College, Community & Justice. (2024). *Digital Mental Health Interventions at Colleges & Universities*. Temple University.
- Hunot, V., Churchill, R., Silva de Lima, M., & Teixeira, V. (2007). Psychological therapies for generalised anxiety disorder. *Cochrane Database of Systematic Reviews*, (1), CD001848.
- Husserl, E. (1913/1982). *Ideas pertaining to a pure phenomenology and to a phenomenological philosophy*. Nijhoff.
- Ivankova, N. V., Creswell, J. W., & Stick, S. L. (2006). Using mixed-methods sequential explanatory design: From theory to practice.

Field Methods, 18(1), 3–20.

Johnson, M., Schuster, M., Le, Q. V., Krikun, M., Wu, Y., Chen, Z., ... & Dean, J. (2017). Google's multilingual neural machine translation system: Enabling zero-shot translation. *Transactions of the Association for Computational Linguistics*, 5, 339–351.

Jorm, A. F., Korten, A. E., Jacomb, P. A., Christensen, H., Rodgers, B., & Pollitt, P. (1997). Mental health literacy: A survey of the public's ability to recognise mental disorders and their beliefs about the effectiveness of treatment. *Medical Journal of Australia*, 166(4), 182–186.

Joseph, A., Wilkerson, G., & McHugh, M. (2020). Patient journey mapping: Current practices, challenges, and future opportunities. *Patient Experience Journal*, 7(3), 138–152.

Kang, B., & Hong, M. (2024). Digital interventions for reducing loneliness and depression in Korean college students: Mixed methods evaluation. *JMIR Formative Research*, 8, e58791.

Kang B, Hong M. (2025). Development and Evaluation of a Mental Health Chatbot Using ChatGPT 4.0: Mixed Methods User Experience Study With Korean Users. *JMIR Med Inform* 2025;13:e63538

Kian, M. J., Zong, M., Fischer, K., Singh, A., Velentza, A. M., Sang, P., Upadhyay, S., Gupta, A., Faruki, M. A., Browning, W., Arnold, S. M. R., Krishnamachari, B., & Matarić, M. J. (2024). Can an LLM-powered socially assistive robot effectively and safely deliver cognitive behavioral therapy? A study with university students. *arXiv preprint arXiv:2402.17937*.

Kim, J. (2018). The Relationship of Health Beliefs with Information Sources and HPV Vaccine Acceptance among Young Adults in Korea. *International Journal of Environmental Research and Public Health*, 15(4), 673. <https://doi.org/10.3390/ijerph15040673>

Kloos, B., Hill, J., Thomas, E., Wandersman, A., & Elias, M. J. (2012). *Community psychology: Linking individuals and communities* (3rd ed.). Wadsworth.

Kocaballi, A. B., Berkovsky, S., Quiroz, J. C., Laranjo, L., Tong, H. L., Rezazadegan, D., ... & Coiera, E. (2019). The personalization of

conversational agents in health care: Systematic review. *Journal of Medical Internet Research*, 21(11), e15360.

- Kocmi, T., & Federmann, C. (2023). Large language models are state-of-the-art evaluators of translation quality. In *Proceedings of the 24th Annual Conference of the European Association for Machine Translation* (pp. 193–203).
- Kohls, E., Baldofski, S., Moeller, R., Klemm, S. L., & Rummel-Kluge, C. (2021). Mental health and loneliness in university students during the COVID-19 pandemic in Germany: A longitudinal study. *Frontiers in Psychiatry*, 12, 848645. <https://doi.org/10.3389/fpsyt.2022.848645>
- Kroenke, K., Spitzer, R. L., & Williams, J. B. (2001). The PHQ-9: Validity of a brief depression severity measure. *Journal of General Internal Medicine*, 16(9), 606–613.
- Lattie, E. G., Adkins, E. C., Winquist, N., Stiles-Shields, C., Wafford, Q. E., & Graham, A. K. (2019). Digital mental health interventions for depression, anxiety, and enhancement of psychological well-being among college students: Systematic review. *Journal of Medical Internet Research*, 21(3), e12869.
- Lee, C. M., Cadigan, J. M., & Rhew, I. C. (2020). Increases in loneliness among young adults during the COVID-19 pandemic and association with increases in mental health problems. *Journal of Adolescent Health*, 67(5), 714–717.
- Lee, Y. C., Yamashita, N., & Huang, Y. (2020). "I hear you, I feel you": Encouraging deep self-disclosure through a chatbot. *Proceedings of the 2020 CHI Conference on Human Factors in Computing Systems*.
- Lehtimäki, S., Martić, J., Wahl, B., Foster, K. T., & Schwalbe, N. (2021). Evidence on digital mental health interventions for adolescents and young people: Systematic overview. *JMIR Mental Health*, 8(4), e25847.
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., ... & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, 33, 9459–9474.
- Li, C., Teney, D., Yang, L., Wen, Q., Xie, X., & Wang, J. (2024). CulturePark: Boosting cross-cultural understanding in large language

models. Proceedings of the 38th Conference on Neural Information Processing Systems (NeurIPS 2024).
<https://doi.org/10.48550/arXiv.2405.15145>

- Lim, M. H., Rodebaugh, T. L., Eres, R., Long, K. M., Penn, D. L., & Gleeson, J. F. (2019). A pilot digital intervention targeting loneliness in youth mental health. *Frontiers in Psychiatry*, 10, 604.
- Lin, C. Y. (2004). ROUGE: A package for automatic evaluation of summaries. In *Text Summarization Branches Out* (pp. 74–81).
- Linardon, J., Cuijpers, P., Carlbring, P., Messer, M., & Fuller-Tyszkiewicz, M. (2019). The efficacy of app-supported smartphone interventions for mental health problems: A meta-analysis of randomized controlled trials. *World Psychiatry*, 18(3), 325–336.
- Lipson, S. K., Lattie, E. G., & Eisenberg, D. (2019). Increased rates of mental health service utilization by U.S. college students: 10-year population-level trends (2007–2017). *Psychiatric Services*, 70(1), 60–63.
- Lipson, S. K., Zhou, S., Wagner III, B., Beck, K., Buonopane, R. J., Reinecke. (2022). Trends in college student mental health and help-seeking by race/ethnicity: Findings from the national healthy minds study, 2013–2021. *Journal of Affective Disorders*, 306, 138–147.
- Liu, P., Yuan, W., Fu, J., Jiang, Z., Hayashi, H., & Neubig, G. (2023). Pre-train, prompt, and predict: A systematic survey of prompting methods in natural language processing. *ACM Computing Surveys*, 55(9), 1–35.
- Martin, R. A. (2007). *The psychology of humor: An integrative approach*. Elsevier Academic Press.
- Matthews, T., Danese, A., Wertz, J., Odgers, C. L., Ambler, A., Moffitt, T. E., & Arseneault, L. (2016). Social isolation, loneliness and depression in young adulthood: A behavioural genetic analysis. *Social Psychiatry and Psychiatric Epidemiology*, 51(3), 339–348.
- McCrae, R. R., & Costa, P. T. (1992). An introduction to the five-factor model and its applications. *Journal of Personality*, 60(2), 175–215.
- Mehrabian, A., & Ferris, S. R. (1967). Inference of attitudes from nonverbal communication in two channels. *Journal of Consulting*

Psychology, 31 (3), 248–252.

Meyerowitz–Katz, G., Ravi, S., Arnolda, L., Feng, X., Maberly, G., & Astell–Burt, T. (2020). Rates of attrition and dropout in app–based interventions for chronic disease: Systematic review and meta–analysis. *Journal of Medical Internet Research*, 22(9), e20283.

Mohr, D. C., Burns, M. N., Schueller, S. M., Clarke, G., & Klinkman, M. (2013). Behavioral intervention technologies: Evidence review and recommendations for future research in mental health. *General Hospital Psychiatry*, 35(4), 332–338.
<https://doi.org/10.1016/j.genhosppsych.2013.03.008>

Mojtabai, R., & Olfson, M. (2020). National trends in mental health care for US adolescents. *JAMA Psychiatry*, 77(7), 703–714.

National Alliance on Mental Illness. (2024). Mental health awareness. Retrieved from

<https://www.namiwalks.org/index.cfm?fuseaction=donordrive.team&teamID=75487>

Norman, D. A. (1988). *The psychology of everyday things*. Basic Books.

OpenAI. (2023). GPT–4 technical report. arXiv preprint arXiv:2303.08774.

Otte, J., Schick Tanz, N., & Bentz, D. (2023). Impact of the COVID–19 pandemic on obsessive–compulsive symptoms in the Swiss general population. *Frontiers in Psychology*, 14, 1071205.

Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C. L., Mishkin, P., ... & Lowe, R. (2022). Training language models to follow instructions with human feedback. *Advances in Neural Information Processing Systems*, 35, 27730–27744.

Papineni, K., Roukos, S., Ward, T., & Zhu, W. J. (2002). BLEU: A method for automatic evaluation of machine translation. In *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics* (pp. 311–318).

Park, D., An, G.–t., Kamyod, C., & Kim, C. G. (2023). A Study on Performance Improvement of Prompt Engineering for Generative AI with a Large Model. *Journal of Web Engineering*, 22(8), 1187–1206.

<https://doi.org/10.13052/jwe1540-9589.2285>

- Park, J. I., Abbasian, M., Azimi, I., Bounds, D. T., Jun, A., Han, J., McCarron, R. M., Borelli, J., Safavi, P., Mirbaha, S., Li, J., Mahmoudi, M., Wiedenhoeft, C., & Rahmani, A. M. (2024). Building trust in mental health chatbots: Safety metrics and LLM-based evaluation tools. arXiv preprint arXiv:2408.04650.
- Park, S. J., Choi, H. R., Choi, J. H., Kim, K. W., & Hong, J. P. (2010). Reliability and validity of the Korean version of the Patient Health Questionnaire-9 (PHQ-9). *Anxiety and mood*, 6(2), 119-124.
- Patrick, H., & Williams, G. C. (2012). Self-determination theory: Its application to health behavior and complementarity with motivational interviewing. *International Journal of Behavioral Nutrition and Physical Activity*, 9(1), 1-12.
- Pittenger, D. J. (2005). Cautionary comments regarding the Myers-Briggs Type Indicator. *Consulting Psychology Journal: Practice and Research*, 57(3), 210-221.
- Prensky, M. (2001). Digital natives, digital immigrants part 1. *On the Horizon*, 9(5), 1-6.
- Qin, G., & Eisner, J. (2021). Learning how to ask: Querying LMs with mixtures of soft prompts. In *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies* (pp. 5203-5212).
- Ramesh, K., Ravishankaran, S., Joshi, A., & Chandrasekaran, K. (2017). A survey of design techniques for conversational agents. In S. Kaushik, D. Gupta, L. Kharb, & D. Chahal (Eds.), *Proceedings of the Second International Conference on Information and Communication Technology for Competitive Strategies (ICICCT 2017)*. New Delhi, India.
- Rideout, V., Fox, S., Peebles, A., & Robb, M. B. (2021). Digital health practices, social media use, and mental well-being among teens and young adults in the U.S. *Common Sense Media*.
- Rodrigues, M. A. F., de Oliveira, T. R. C., de Figueiredo, D. L., Maia Neto, E. O., Akao, A. A. A., & de Lima, G. H. M. (2022). An interactive story decision-making game for mental health awareness. In *2022 IEEE 10th International Conference on Serious Games and Applications for*

Health (SeGAH) (pp. 1–7). IEEE.

- Roller, S., Dinan, E., Goyal, N., Ju, D., Williamson, M., Liu, Y., & Weston, J. (2021). Recipes for building an open-domain chatbot. *Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics: Main Volume*, 300–325.
- Rosenstock, I. M. (1966). Why people use health services. *Milbank Memorial Fund Quarterly*, 44(3), 94–127.
- Rosenstock, I. M. (1974). Historical origins of the health belief model. *Health Education Monographs*, 2(4), 328–335.
- Russell, D., Peplau, L. A., & Cutrona, C. E. (1980). The revised UCLA Loneliness Scale: Concurrent and discriminant validity evidence. *Journal of Personality and Social Psychology*, 39(3), 472–480.
- Sahoo, P., Singh, A. K., Saha, S., Jain, V., Mondal, S., & Chadha, A. (2024). A systematic survey of prompt engineering in large language models: Techniques and applications. *arXiv preprint arXiv:2402.07927*.
- Schwartz, B. (2004). *The paradox of choice: Why more is less*. Harper Perennial.
- Seligman, M. E., Steen, T. A., Park, N., & Peterson, C. (2005). Positive psychology progress: Empirical validation of interventions. *American Psychologist*, 60(5), 410–421.
- Singhal, K., Tu, T., Gottweis, J., Sayres, R., Wulczyn, E., Hou, L., ... & Natarajan, V. (2023). Toward expert-level medical question answering with large language models. *Nature Medicine*, 31(3), 943–950.
- Son, C., Hegde, S., Smith, A., Wang, X., & Sasangohar, F. (2020). Effects of COVID-19 on college students' mental health in the United States: Interview survey study. *Journal of Medical Internet Research*, 22(9), e21279. <https://doi.org/10.2196/21279>
- Sontag-Padilla L, Dunbar MS, Ye F, Kase C, Fein R, Abelson S, Stein BD. "Strengthening College Students' Mental Health Knowledge, Awareness, and Helping Behaviors: The Impact of Active Minds, a Peer Mental Health Organization". *Journal of the American Academy of Child and Adolescent Psychiatry*. 2018; 57(7): 500–507.

- Stachl, C., Au, Q., Schoedel, R., et al. (2020). Predicting personality from patterns of behavior collected with smartphones. *Nature Human Behaviour*, 4(7), 702–714.
- Stebbins, R. A. (2011). What is exploration? In *Exploratory research in the social sciences* (pp. 2–17). SAGE Publications.
<https://doi.org/10.4135/9781412984249>
- Sullivan, P. F., Neale, M. C., & Kendler, K. S. (2000). Genetic epidemiology of major depression: Review and meta-analysis. *American Journal of Psychiatry*, 157(10), 1552–1562.
- Tashakkori, A., & Teddlie, C. (1998). *Mixed methodology: Combining qualitative and quantitative approaches*. Sage Publications.
- Torous, J., Wisniewski, K., Liu, G., & Keshavan, M. (2018). Mental health mobile phone app usage, concerns, and benefits among psychiatric outpatients: Comparative survey study. *JMIR Mental Health*, 5(4), e11715.
- University of Michigan. (2023, March). Depression on college campuses conference. Ann Arbor, MI.
- University of Michigan. (2023). *Counseling and Psychological Services Annual Report*. University of Michigan.
- University of Michigan Student Mental Health Innovative Approaches Review Committee. (2023). *Student Mental Health Innovative Approaches Review Committee Report*. University of Michigan.
- Vaidyam, A. N., Wisniewski, H., Halamka, J. D., Kashavan, M. S., & Torous, J. B. (2019). Chatbots and conversational agents in mental health: A review of the psychiatric landscape. *The Canadian Journal of Psychiatry*, 64(7), 456–464.
- Vogel, D. L., Wade, N. G., & Haake, S. (2006). Measuring the self-stigma associated with seeking psychological help. *Journal of Counseling Psychology*, 53(3), 325–337.
- Walker, E. R., McGee, R. E., & Druss, B. G. (2015). Mortality in mental disorders and global disease burden implications: A systematic review and meta-analysis. *JAMA Psychiatry*, 72(4), 334–341.
- Wang, X., Li, X., & Liu, J. (2023). Emotional intelligence of large

language models. *Journal of Pacific Rim Psychology*.
<https://doi.org/10.1177/18344909231213958>

- Wei, J., Wang, X., Schuurmans, D., Bosma, M., Xia, F., Chi, E., ... & Zhou, D. (2022). Chain-of-thought prompting elicits reasoning in large language models. *Advances in Neural Information Processing Systems*, 35, 24824–24837.
- White, J., Fu, Q., Hays, S., Sandborn, M., Olea, C., Gilbert, H., ... & Schmidt, D. C. (2023). A prompt pattern catalog to enhance prompt engineering with ChatGPT. *arXiv preprint arXiv:2302.11382*.
- WHO. (2023). *Global state of physical activity report 2022*. WHO Press.
- Xu, A., Liu, Z., Guo, Y., Sinha, V., & Akkiraju, R. (2017). A new chatbot for customer service on social media. *Proceedings of the 2017 CHI Conference on Human Factors in Computing Systems*, 3506–3510.
- Yin, J., Ngiam, K. Y., & Teo, H. H. (2021). Role of artificial intelligence applications in real-life clinical practice: Systematic review. *Journal of Medical Internet Research*, 23(4), e25759.
- Yuen, E. K., Goetter, E. M., Herbert, J. D., & Forman, E. M. (2012). Challenges and opportunities in internet-mediated telehealth and ecological momentary intervention: The case for dialectical behavior therapy. *Clinical Psychology: Science and Practice*, 19(2), 155–169.
- Zhai, C., & Wibowo, S. (2022). A systematic review on cross-culture, humor and empathy dimensions in conversational chatbots: the case of second language acquisition. *Heliyon*, 8(12), e12056.
- Zhang, O. X., Zhou, S., Geng, J., Liu, Y., & Liu, S. X. (2024). Dr. GPT in campus counseling: Understanding higher education students' opinions on LLM-assisted mental health services. *arXiv preprint*.
- Zhang, T., Kishore, V., Wu, F., Weinberger, K. Q., & Artzi, Y. (2020). BERTScore: Evaluating text generation with BERT. In *ICLR 2020*.
- Zur, O. (2007). *Boundaries in psychotherapy: Ethical and clinical explorations*. American Psychological Association.

부 록

<부록 1> 성균관대학교 IRB 승인서

NOTIFICATION LETTER OF SKKU IRB

The document Retention Period is 3 years			
Institution	Sungkyunkwan University		
Research Director	BOYOUNG KANG		
IRB File NO.	SKKU 2023-02-043	Notification date	2023. 02. 27.
Title(Korean)	자연어 처리 기술을 이용한 근거 기반 청년 정신건강 돌봄 디지털 서비스 플랫폼 개발		
Title(English)	Evidence based young adults depression cohorts digital healthcare service platform		

Research Classification 1	☒ Human Object ☐ Human remains ☐ Embryos ☐ Somatic cell cloning embryos ☐ Embryonic stem cell stock ☐ etc					
	☒ Survey ☐ Observation ☐ Data Analysis ☒ Arbitration ☐ Behavior ☐ Cohort ☐ Clinical trial ☐ etc					
Research Classification 2	☒ Prospective Research ☐ Retrospective Research ☐ Parallel					
Research Classification 3	☐ Non-clinical study(in vitro, in vivo preclinical study)					
Research Classification 4						
Subjects to experiment	Total	60	Domestic	60	SKKU	60
Approval period	2023.02.27. ~ 2024.02.26					

Approval date	2023. 02. 27.
Interim Report date	2023. 12. 26.
Result	☒ Approval ☐ Correctional approval ☐ IRB review exemption

Issued by

IRB President : Prof. Kim, Ho Joong (M.D. Ph.D)

Institution : Sungkyunkwan University (*SKKU)

Address : #2066, Seobu-ro, Jangan-Gu, Suwon, Korea, 16419

IRB President : Prof. Kim, Ho Joong (M.D. Ph.D)

Dept. of Pulmonary and Critical Care Medicine, Samsung Medical Center(*SMC)



<부록 2> 실험 참여자 모집 공고

<http://bit.ly/3NO4mso>

연구 과제:

사업명: 보건복지부 K-Medi 융합인재양성지원사업

과제명: 자연어 처리 기술을 이용한 근거 기반 청년 정신건강 돌봄 디지털 서비스
플랫폼 개발

주관기관: 성균관대학교 산학협력단

연구개발 과제번호: HI22C2185

연구책임자: 강보영 (현재 홍문표 교수님 연구실

<https://skkhmp.github.io/members/> 소속이나 연구실 과제는 아닙니다)

■ 실험 목적

- 우울증 및 정신 건강의 문제를 야기할 수 있는 청년들의 외로움을 감소시키고 정신 건강을 돕기 위한 어플리케이션(woebot, happify) 및 최근 출시된 SNS 앱을 사용한 후의 피험자의 외로움, 우울과 관련한 정신건강 바로미터를 측정한 정량적 데이터 및 사용한 후기의 정성적 데이터를 분석. 세부내용은 아래 실험 내용 확인.
- 응답율에 따라 최대 20 만원(설문지 1 개당 1 만원, 인터뷰 1 회당 2 만원, 참여 횟수 및 이행률에 따라 차등 지급예정

■ 인원 : 30 명 (인문사회캠퍼스), 30 명(자연과학캠퍼스)

■ 실험 내용

- 실험 일정: 2023 년 3 월 11 일 ~ 2023 년 7 월 10 일 (4 개월 간)
- 실험 장소: 비대면

- 1 개월에 1 회 온라인 링크로 접속하여 자가설문지 응답(모든 데이터는 익명화 처리).

- 주 3 회, 회당 15 분 정도의 어플리케이션 사용(자세한 사용방법은 오리엔테이션 온라인 녹화 동영상 및 실시간 Q&A 채팅을 통해

- 월 1 회(월 말) 실시간 온라인 비대면으로 포커스 그룹 인터뷰(FGI) 30 분간 진행, 한 그룹당 4~5 명 정도

■ 지원 자격/우대 조건

- 본교 재학 또는 휴학중인 학생 (학부/석/박사 과정 모두 해당)으로

- 연령이 만 18 세~만 25 세이며

- 영어(reading)에 능숙하여

- 영어로 된 어플리케이션 활용에 능숙

■ 주의 사항

- 실험담당자가 참가자에 대해 실험 참가에 부적합하다고 판단되는 경우 실험 참가가 거부될 수 있으며 실험참가비 지급이 제한됩니다.

- 참가자의 응답율에 따라 참가비가 차등 되어 지급될 수 있습니다.

■ 지원 절차 / 문의

- 지원 방법: 아래의 링크로 접속하여 작성 후 제출. 지원 링크에 정신건강 자가설문지가 포함되어 있으며 선발 과정에서 보조자료로만 사용됨 (선발 과정 및 연구 종료 후 폐기).

<https://forms.gle/Jzmuswf5LyVR8scFA>

<부록 3> 외로움 측정 설문조사

UCLA Loneliness Scale Version 3rd edition, Korean version

문 항		전혀 아니다	드물지 만 있다	가끔 있다	항상 그렇다
1	얼마나 자주 주변 사람들과 잘 통합니까?				
2	얼마나 자주 사람들과의 교제가 부족하다고 느끼니까?				
3	얼마나 자주 도움을 청할 사람이 아무도 없다고 느끼니까?				
4	얼마나 자주 혼자라고 느끼니까?				
5	얼마나 자주 친구들 모임에 속해 있다고 느끼니까?				
6	얼마나 자주 당신 주위 사람들과 공통의 관심사를 가지고 있습니까?				
7	얼마나 자주 당신이 더 이상 아무하고도 가깝지 않다고 느끼니까?				
8	얼마나 자주 당신의 흥미와 생각들이 주변사람과 나누어지지 않는다고 느끼니까?				
9	얼마나 자주 자신이 외향적이고 우호적이라고 느끼니까?				
10	얼마나 자주 사람들과 가깝다고 느끼니까?				
11	얼마나 자주 혼자 남겨졌다고 느끼니까?				
12	얼마나 자주 다른 사람들과의 관계가 의미 없다고 느끼니까?				
13	얼마나 자주 당신을 진정으로 아는 사람이 아무도 없다고 느끼니까?				
14	얼마나 자주 다른 사람으로부터 고립되어 있다고 느끼니까?				
15	얼마나 자주 당신이 원할 때 친구들을 사귄 수 있다고 느끼니까?				
16	얼마나 자주 당신을 진정으로 이해해주는 사람들이 있다고 느끼니까?				
17	얼마나 자주 수줍음을 느끼니까?				
18	얼마나 자주 사람들이 당신과 진정으로 함께 있지 않고 그저 주위에 있는 것이라고 느끼니까?				
19	얼마나 자주 당신과 얘기를 나눌 사람들이 있다고 생각합니까?				
20	얼마나 자주 당신이 도움을 청할 수 있는 사람들이 있다고 느끼니까?				

<부록 4> 우울증 측정 설문조사

PHQ-9 (Patient Health Questionnaire-9)

한글판 우울증 선별도구(Patient Health Questionnaire-9)

본 검사는 우울한 정도를 스스로 알아보기 위한 것입니다. 이 질문들이 확정된 진단을 위한 것은 아니지만 높은 점수가 나왔을 경우에는 우울증의 가능성이 높으므로, 더 정확한 평가를 위해서 병원에서 진료를 받아볼 것을 추천합니다.

지난 2주간, 얼마나 자주 다음과 같은 문제들로 곤란을 겪으셨습니까?

지난 2주 동안에 아래와 같은 생각을 한 날을 헤아려서 해당하는 숫자에 표시하세요.

지난 2주 동안에	없음	2, 3일 이상	7일 이상	거의 매일
1. 기분이 가라앉거나, 우울하거나, 희망이 없다고 느꼈다	0	1	2	3
2. 평소 하던 일에 대한 흥미가 없어지거나 즐거움을 느끼지 못했다	0	1	2	3
3. 잠들기가 어렵거나 자주 잤다/혹은 너무 많이 잤다	0	1	2	3
4. 평소보다 식욕이 줄었다/혹은 평소보다 많이 먹었다	0	1	2	3
5. 다른 사람들이 눈치 챌 정도로 평소보다 말과 행동이 느려졌다/혹은 너무 안절부절 못해서 가만히 앉아있을 수 없었다	0	1	2	3
6. 피곤하고 기운이 없었다	0	1	2	3
7. 내가 잘못 했거나, 실패했다는 생각이 들었다/혹은 자신과 가족을 실망시켰다고 생각했다	0	1	2	3
8. 신문을 읽거나 TV를 보는 것과 같은 일상적인 일에도 집중할 수가 없었다	0	1	2	3
9. 차라리 죽는 것이 더 낫겠다고 생각했다/혹은 자해할 생각을 했다	0	1	2	3

<부록 5> 측정도구 및 온라인 설문조사

사용된 측정도구:

- PHQ-9 (우울)
- UCLA 외로움 척도

Baseline Survey (February 28~March 10)

<https://forms.gle/ryeY22vbYVUageCz5>

1st intervention survey (April 7~April 15)

<https://forms.gle/vbtpvds9dh9nZ7fo9>

2nd intervention survey (May 15 ~ May20)

<https://forms.gle/QCuLvZRKrFGhRCLV7>

Post intervention survey (June 15~ June 20)

<https://forms.gle/6prkAictWC25MVdK8>

<부록 6> 디지털 중재 어플리케이션 안내 사항

6-1. Woebot 실험 참가자 안내 사항

안녕하세요? 여러분은 연구동의서에 설명되어 있듯이 실험에 자발적으로 참여하셨고 정신건강챗봇인 woebot 에 랜덤으로 배정되었습니다.

Woebot 은 기본적으로 CBT(Cognitive Behaviour Therapy) 기반 챗봇으로 의사의 처방을 수반한지 않아도 사용가능한 디지털 어플리케이션으로 기본적인 임상적 유효성이 2017 년 6 월에 JMIR Mental Health 저널에 출판되었습니다 (<http://mental.jmir.org/2017/2/e19/>).

Woebot 은 구글 플레이와 애플 앱스토어에서 다운로드 받으실 수 있습니다.(2023 년 3 월 현재 Version # 4.10.5)

구글플레이:

<https://play.google.com/store/apps/details?id=com.woebot&hl=en&gl=US>

앱스토어:

<https://apps.apple.com/us/app/woebot-your-self-care-expert/id1305375832>

실험 참가자 준수 사항

1) 앱을 다운 받으십시오


2) 계정을 만드세요 이메일과 패스워드 생년월일, 닉네임을 입력하게 되어 있습니다

3) 매일 최소 15 분간 앱을 사용하셔야 합니다.

4) 15 분 동안 토픽(아래 그림 참조) 중에서 최소 4 개의 토픽, (Focusing on positive, Relationship, Mindfulness & Meditation, Managing emotions 필수) 과 저널(Gratitude Journal 필수)을 사용을 사용하시면 됩니다.

5) 사용기록을 위해 Gratitude Journal 을 주 3 회 캡처해서 보관하시기 바랍니다. 매월 실험 참가자 보상을 위해 필요하니 꼭 보관하시기 바랍니다.

<어플리케이션 화면 예시>



6-2. Happify 실험 참가자 안내 사항

안녕하세요? 여러분은 연구동의서에 설명되어 있듯이 실험에 자발적으로 참여하셨고 정신건강챗봇인 Happify 에 랜덤으로 배정되었습니다.

Happify 는 기본적으로 CBT(Cognitive Behavior Therapy) 기반 챗봇으로 의사의 처방을 수반한지 않아도 사용 가능한 디지털 어플리케이션으로 그 효과성이 JMIR Mental Health 저널에 출판되었습니다. 최근 출간된 논문을 공유합니다.
<https://mental.jmir.org/2021/2/e26617/>

Happify 는 구글 플레이와 애플 앱스토어에서 다운로드 받으실 수 있습니다.(2023 년 3 월 현재 Version # 2.11.5)

구글플레이:

<https://play.google.com/store/apps/details?id=com.happify.happifyinc&hl=en&gl=US>

앱스토어:

<https://apps.apple.com/us/app/happify-for-stress-worry/id730601963>

실험 참가자 준수 사항


1) 앱을 다운 받으십시오

2) 계정을 만드세요 성별, 나이, 인종, 직업, 가족관계 및 현재 심리상태 등의 정보를 입력하게 되어 있습니다

3) 매일 최소 15 분간 앱을 사용하셔야 합니다.

4) 앱은 크게 인스턴트 플레이(Instant Play)와 트랙(무료, 유료) 트랙이 있는데 15 분 동안 Instant Play (아래 그림 참조) 중에서 최소 3 개의 activity(Serenity Scene, Guided Meditation, Negative Knockout), 그리고 그 activity 에서 Thank mode 는 필수) 과 Mindfulness & Meditation (무료 트랙)을 사용하시면 됩니다.

5) 사용기록을 위해 activity task 중 Thank mode(뒤에 화면 예시) 주 3 회 캡처하거사 업로드해서 보관하시기 바랍니다. 매일 실험 참가자 보상을 위해 필요하니 꼭 보관하시기 바랍니다.



6-3. 대조군 Bondee (안내 사항)

여러분은 연구동의서에 설명되어 있듯이 실험에 자발적으로 참여하셨고 메타버스 SNS 인 Bondee 어플리케이션선에 랜덤으로 배정되었습니다. Bondee(본디)는 2022 년말 출시 이래 사람들 사이에서 빠르게 퍼져나간 메신저 기반 메타버스 앱으로 홈 화면에서는 내 상태를 다양한 상태로 설정할 수 있습니다. 그리고 사용자가 상태를 변경할 때마다 친구들이 '좋아요'나 댓글도 남길 수 있으며 실시간으로 사진을 찍어 아바타 위에 띄울 수도 있습니다.

Bondee 는 구글 플레이와 애플 앱스토어에서 다운로드 받으실 수 있습니다. 반드시 단말기 설정을 영어로 해놓고 **영어버전**으로 다운 받으시고 실험 규정상(다른 어플리케이션과 다른 사용자와의 형평상) **영어**로 사용하시기를 바랍니다.

구글플레이: <https://play.google.com/store/apps/details?id=com.metadream.bondee&hl=en&gl=US>

앱스토어: <https://apps.apple.com/my/app/bondee/id6443947003>

실험 참가자 준수 사항

- 1) 앱을 다운 받으십시오
- 2) 계정을 만드세요
- 3) 매일 최소 15 분간 앱을 사용하셔야 합니다.
- 4) 15 분 동안의 사용 기능(집꾸미기, 플로팅, 채팅) 제한은 없으나 친구를 3 명 이상 초대해서서로 채팅 및 인터랙션 하시기를 추천합니다

5) 사용기록을 위해 단말기 화면을 주 3 회 캡처해서 보관하시기 바랍니다. 매월
실험 참가자 보상을 위해 필요하니 꼭 보관하시기 바랍니다.

<본디 예시 화면>



<부록 7> 양적 통계 분석 코드

7-1. PHQ9 & Loneliness trend Analysis

[PHQ9&UCLA_Loneliness_Trend code.ipynb](#)

7-2. Cronbach analysis

[baseline_cronbach.ipynb](#)

[1month_cronbach.ipynb](#)

[2month_cronbach.ipynb](#)

[post_cronbach.ipynb](#)

7-3. Behavior Belief(Hypotheses Analysis)

[\(sum\)behavior belief.ipynb](#)

7-4. Self-report Mental health literacy

[Self-report literacy.ipynb](#)

<부록 8> 실험 1 포커스그룹 인터뷰 질문 내용

• 본 실험에 처음 참여했을 때 다른 사람들과 더 연결되고 싶다고 언급했었습니다. 더 연결되길 바란 이유는 무엇이었나요?

• 여러분은 외로움을 느끼게 하는 요인은 무엇인가요(어떨 때 외로우신가요?)

• 외로움을 느낄 때 어떻게 대처하시나요?

• 최근 외로움을 느낀 경험과 그 이유에 대해 이야기해 주실 수 있나요? 언제 있었나요?

• 외로움을 느낄 때 소속 학과, 학교, 여러분이 속한 사회의 지원 시스템이 있습니까? 어떤 역할을 하나요?

• 코로나 기간동안에 본인의 마음과 심리 상태의 변화가 있었습니까? 있었다면 어떠했는지 설명해주세요.

• 코로나 기간동안에 힘든 것이 있었다면 무엇이고 그중 가장 어떤 것이 힘들었나요?

• (Woebot 이나 Happify, Bondee)의 앱에서 본인이 가장 좋았던 두 가지 기능(절차와 콘텐츠 면에서)은 무엇입니까?

• (Woebot 이나 Happify, Bondee)의 앱을 사용함에 있어서 불편한 두 가지 점(절차와 콘텐츠 면에서)은 무엇입니까?

• (Woebot 이나 Happify, Bondee)의 앱이 여러분에게 어떤 면에서 가장 도움이 되었습니까?

• (Woebot 이나 Happify, Bondee)의 앱을 사용함에 있어서 가장 어떤 점이 개선되면 좋겠습니까?

- (Woebot 이나 Happify,Bondee)의 앱이 그런 방향으로 개선된다면 여러분의 외로움이나 정신 건강에 더 도움이 된다고 생각하시나요?
- 여러분은 앞으로 대학생활은 어떠하리라고 생각하나요?
- 본 실험에 참여하면서 여러분의 외로움, 정신건강 및 대학 생활에 대해서 하고 싶은 말이 있다면 자유롭게 얘기해주세요.

ABSTRACT

Digital Intervention for Enhancing College Student Mental Health

– Design and Experimental Evaluation of an AI Counseling Platform Based on Large Language Models (LLMs) –

Boyoung Kang

Department of Social

Entrepreneurship and Humanistic Future Studies

Sungkyunkwan University

This research develops innovative digital solutions for university students' mental health management, focusing on the potential of Large Language Model (LLM) technology. The study centers on designing HoMemeTown, a comprehensive mental health platform, through three systematic experimental phases:

Experiment I examines the clinical effectiveness of existing digital therapy apps through a 4-month mixed-methods study with 63 university students

(final $n=27$). Results showed no significant between-group differences in loneliness (UCLA scale: $P=.67$) or depression (PHQ-9: $P=.35$), with 39.7% of participants classified as high-risk for depression. This revealed fundamental limitations of rule-based systems and the lack of Korean language support.

Experiment II involves the development and evaluation of Dr.CareSam, an LLM-based AI counseling chatbot, through a one-week pilot study with 20 Korean university students. Dr.CareSam achieved high ratings in positivity/support (9.0), empathy (8.7), and active listening (8.0), demonstrating statistically significant superiority over existing apps ($F=12.94$, $P<.001$) with large effect size ($\eta^2=0.68$).

Experiment III provides systematic comparative analysis of multiple LLM-based chatbots using seven counseling quality criteria derived from Experiment II. Triple evaluation system with Claude 3.5 Sonnet, ChatGPT 4.0, and human experts revealed significant discriminative validity ($F(3,80)=9.73$, $P<.001$, $\eta^2=0.267$). Wysa ranked highest (2.71), followed by Dr.CareSam (2.38), demonstrating competitive performance with global commercial chatbots.

This study establishes the first systematic framework for LLM-based mental health chatbot development and evaluation in Korea, proving that appropriate prompt engineering can achieve high-quality mental health services. Key contributions include empirical validation of LLM chatbot effectiveness, development of transparent AI evaluation methodology using Chain-of-

Thought reasoning, and demonstration of human–AI collaborative assessment systems.

The research advocates for accessible, personalized, and integrated support solutions, concluding with policy recommendations for universities and government to implement AI–assisted mental health systems while addressing ethical considerations and safety protocols.

Keywords: University Student Mental Health, LLM Chatbot, Digital Intervention, Mental Health Literacy, Chain–of–Thought