

중소규모 건설현장을 위한 YOLO-LLM 하이브리드 CCTV 안전관제 시스템 개발

A Development of a YOLO-LLM Hybrid CCTV Safety Monitoring System for
Small-and-Medium-Sized Construction Sites

ISSN: 2586-2685 안전문화연구 00호 0-0 접수일: 202□/00/00 수정일: 202□/00/00 확정일: 202□/00/00 발간일: 202□/00/00
<http://doi.org/10.52902/kjsc.202□.00.□> 논문투고: fpss.jams.or.kr 사무국연락처: 031-253-7776 사무국핸드폰: 010-2960-7797

윤 혁 (Yoon Hyuk) 주저자 : 한국농어촌공사, 경기대학교 건설안전학과 (석사과정), E-mail : yoonhyeok1@gmail.com
박 중 용 (Park Jong Yong) 교신저자 : 경기대학교 건설안전학과 교수, E-mail : jypicaso@kyonggi.ac.kr
김 미 소 (Kim Mi-Soh) 공동저자 : 태영건설, 경기대학교 건설안전공학과 (석사과정), E-mail : miucci0212@naver.com
☎ 사사표기

국 문 요 약

국내 건설업은 산업재해 사망사고의 약 절반을 점유하며 그 60% 이상이 50억 원 미만 중소규모 현장에서 발생하나, 전담 안전관리자 부재·예산 제약·노후 CCTV·라벨 데이터 부재로 스마트 안전관제 도입이 어렵고, 단일 AI 접근(YOLO 단독 또는 LLM 단독)은 오탐으로 인한 경보 피로와 현장 적응 비용 문제를 본질적으로 해결하지 못한다. 본 연구는 YOLO 1차 고민감도 검출(Confidence 0.3)과 LLM 2차 퓨샷(Few-shot) 문맥 검증을 결합하고, 신호감지이론(SDT)에 근거해 1차는 민감도, 2차는 특이도를 극대화하도록 역할을 분리한 이중 캐스케이드 시스템을 제안한다. 현장 적응은 퓨샷 학습과 사용자 교정 샘플로 미세조정 없이 달성한다. 00공사 산하 협력 현장에서 9일간(196.8시간) 수집한 운영 로그(분포·신뢰도 1,074건, 정밀도 878건·38대 카메라)를 사후 분석한 결과, 2단계 파이프라인은 1차 단독(Conf 0.3) 대비 시간당 오경보율(FAR)을 4.238→0.066건/시간으로 약 98.44% 감소시키면서 재현율은 1.000→0.886(-11.4%p)에 그쳤고, F1 0.095→0.813, 정밀도 0.050→0.750, 특이도 0.984, 정확도 0.980으로 향상되었다. RAG 기반 Few-shot 교정은 제로샷 대비 정밀도(0.320→0.462)·정확도(0.837→0.876)를 높이고 오경보를 17→7건(약 59%) 줄였다. 종단간 지연은 중위 약 6.0초, 도입 TCO는 상용 솔루션 대비 약 95% 절감되어 중소현장 적용 타당성을 확인하였다.

[주제어] 건설안전, YOLO, 대규모 언어모델(LLM), Few-shot Learning, 하이브리드 AI, 이중 캐스케이드, 알람 피로, 중소규모 건설현장

Abstract


The Korean construction industry accounts for about half of all industrial fatalities, over 60% at small-and-medium-sized sites under 5 billion KRW, where the absence of dedicated safety managers, budget constraints, aging CCTV, and lack of labeled data hinder smart safety monitoring; single-AI approaches (YOLO-only or LLM-only) cannot resolve the trade-off between false-alarm fatigue and site-adaptation cost. This study proposes a dual-cascade hybrid system combining high-sensitivity YOLO primary detection (Confidence 0.3) with LLM-based Few-shot contextual verification that, based on Signal Detection Theory, maximizes sensitivity in the first stage and specificity in the second, achieving site adaptation without fine-tuning via Few-shot Learning and user-correction samples. In a post-hoc analysis of nine-day operational logs (196.8 hours) from cooperative sites under the Korea Rural Community Corporation Gyeonggi Regional Headquarters (1,074 confidence-logged alerts for distribution/reliability; 878 alerts on 38 cameras for precision), the cascade pipeline reduced FAR from 4.238 to 0.066 alerts/hour ($\approx 98.44\%$) while recall dropped only from 1.000 to 0.886 (-11.4 pp), with F1 0.095→0.813, precision 0.050→0.750, specificity 0.984, and accuracy 0.980. RAG-based Few-shot correction raised precision (0.320→0.462) and accuracy (0.837→0.876) and cut false alarms from 17 to 7 ($\approx 59\%$) over zero-shot. End-to-end latency was a median of ≈ 6.0 seconds and TCO was reduced $\approx 95\%$ versus commercial solutions, demonstrating practical feasibility for small-and-medium-sized construction sites.

[Keywords] Construction Safety, YOLO, Large Language Model, Few-shot Learning, Hybrid AI, Dual Cascade, Alarm Fatigue, Small-and-Medium Construction Site

I. 서 론

국내 건설업 사고사망만인율은 1.59‰로 OECD 경제 10대국 평균(0.78‰)의 약 2배이며, 사망사고의 60% 이상이 50억 원 미만 소규모 현장에 집중된다(최수영, 2025; 조도빈, 2026). 산업안전보건법·중대재해처벌법 시행으로 안전관리 의무는 강화되었으나(류수영, 2023), 정작 의무 이행 주체인 중소현장은 전담 안전관리자 부재, 산업안전보건관리비 준수율 36.7%의 예산 제약(조도빈, 2026), 노후 CCTV·라벨 데이터 부재라는 구조적 취약성을 안고 있으며, 스마트 안전관제의 도입 비용마저 또 다른 장벽으로 작용한다.

그림 1. 2023년 국가별 건설산업 사망사고만인율(국제노동기구(ILO))



단일 AI 안전관제는 본질적 한계를 갖는다. 컴퓨터 비전 단독 시스템은 옷·적치물을 사람으로, 쪼그려 앉기를 낙상으로 오인식하며(Ryu & Park, 2025), 거짓경보가 80~99%에 달해 ECRI가 알람 피로를 2012년 No.1 위험으로 지정한 바 있다(Cvach, 2012). 임계값 상향은 미탐을 늘리는 민감도-특이도 상쇄로 단일 모델로는 해결이 불가능하고, 현장 적응을 위한 미세조정(fine-tuning)은 수천 장의 신규 라벨을 요구하여(Wu et al., 2025) 중소현장에는 비현실적이다. 선행 비전-언어 통합 접근 역시 계산 비용·규칙 한계·재학습/미세조정 의존의 제약을 공유하며, 접근별 비교는 표 1과 같다(Wang et al., 2025; Kim et al., 2025; Wu et al., 2025; 김윤현, 2025; 김현수, 2026). 특히 미세조정 없이 YOLO와 VLM을 결합한 DetVLM(Wang et al., 2025)도 2차 VLM을 검출기가 놓친 객체의 재현율(recall) 보강에 사용하여, 오탐 억제로 특이도를 회복하려는 본 연구와 목적이 상반된다. 결과적으로 라벨 부족 건설현장에서 미세조정 없이 신호감지이론에 근거해 민감도-특이도를 분리하여 오탐을 저감하는 구조는 보고된 바 없다.

본 연구는 YOLO 1차 고민감도 검출과 LLM 2차 문맥 검증을 결합한 이중 캐스케이드(dual cascade) 안전관제 시스템을 제안한다. 신호감지이론(Green & Swets, 1966)에 근거해 1차 YOLO 임계값을 통상값(0.4~0.5)보다 낮은 0.3으로 운영해 민감도를 극대화하고, 2차 LLM이 문맥 검증으로 특이도를 회복하도록 역할을 분담한다. 현장 적응은 미세조정이 아닌 맥락 내 학습(In-context Learning)과 사용자 교정 샘플로 달성하며, 클라우드 LLM API·사무용 PC·기존 ONVIF 카메라 재활용으로 GPU 서버를 요구하지 않는다. 본 연구의 기여는 ① 민감도-특이도의 명시적 분리 설계, ② 미세조정을 제거한 퓨샷(Few-shot) 기반 현장 적응, ③ 중소현장 부담 가능한 저비용 배포 모델이다.

표 1. 비전-언어 통합 접근 비교

접근 방식	실시간성	현장 적응	비용	본 연구 대비
YOLO 단독	우수	어려움(재학습)	중	오탐 다수
단일 VLM (GPT-4V 등)	낮음	용이	고	실시간 부적합
YOLO + 룰 후처리	우수	어려움	저	문맥 추론 부재
YOLO + 2차 CNN	중	어려움(재학습)	중	현장 적응 비용
YOLO + VLM 캐스케이드 (선행)	중~우수	일부 용이	중	Fine-tuning 의존
본 연구 (YOLO + LLM, Few-shot)	우수	용이(Few-shot)	저	-

본 논문은 II장에서 선행 연구를, III장에서 제안 시스템 아키텍처와 1·2차 모듈을, IV장에서 오탐률 감소와 퓨샷 학습 효과를 정량 분석하고, V장에서 결론과 향후 연구를 논의한다.

II. 문헌 고찰

2.1. 건설 안전 분야 컴퓨터 비전 연구

건설현장 컴퓨터 비전 연구는 PPE 착용 탐지, 위험행동·자세 인식, 작업자-중장비 근접 위반, 낙상 탐지로 발전해 왔다(이형도, 2023; 박종학, 2025; Mi, 2025). 영상 기반 낙상(쓰러짐) 탐지는 객체의 Bbox 형태를 활용한 객체탐지 방식으로 시도되었으나(임승진, 2023), 쪼그려 앉기 등 유사 자세를 위험 상황으로 오인식하는 오탐이 보고된다(Ryu & Park, 2025). 공통적 한계는 신뢰도 임계값 조정만으로 해결되지 않는 오탐, 현장 변경 시 재학습 비용, 객체 간 관계·상황 문맥 추론 부재로 요약된다(Ryu & Park, 2025; Wang et al., 2025).

2.2. 안전관리 분야 LLM 활용 연구

LLM은 보고서 자동 생성(한소은, 2026; 김윤현, 2025; 이호원, 2026)과 위험성 평가·의사결정 지원(왕인국, 2024; Wu et al., 2025; 김석기, 2026) 영역에서 채택되고 있다. 그러나 다수는 비전 입력이 부재하여 현장 영상 기반 위험을 직접 다루지 못하거나, 멀티모달이라도 미세조정·GPU 자원을 요구하거나 상용 클라우드 API에 의존하며, 적용 목적이 보고서 생성·특정 재난 대응에 한정되어 중소현장의 실시간 상시 관제에는 부적합하다.

표 2. 안전관리 분야 LLM 활용 선행연구 요약

연구자 (연도)	적용 영역	핵심 기법	비전 입력	한계
한소은 (2026)	보고서 자동생성	멀티모달 VLM + 3-루브릭 프롬프트, 이행/미이행 자동 분류	○	상용 클라우드 VLM(GPT-4o) API 의존(외부 비용); 보고서 생성 중심으로 실시간 현장 관제 부적합
김윤현 (2025)	보고서 자동생성	VLM 시각 묘사 + RAG 기반 종합 안전 리포트 생성 프레임워크	○	단일 GPU 처리량 한계로 대규모 현장 실시간 전수 분석 곤란
이호원 (2026)	보고서 자동생성	멀티모달 LLM + RAG(FIARE), 재난 이미지 상황 설명·대응 조언	○	화재 대응 조언에 특화, 건설현장 상시 관제와 목적 상이
왕인국 (2024)	위험성 평가	KRAS·SIF 컨텍스트 주입 JSA 자동화, RAG·미세조정-MM-RAG 통합	△	LLM 단독 적용, YOLO 1차 탐지 결함 부재
Wu et al. (2025)	위험성 평가	LoRA 미세조정 VLM(MonitorVLM), 상용 모델 대비 산업안전 성능 우위	○	미세조정 필수, 중소현장 배포 비용 부담
김석기 (2026)	사고 분석	BERTopic + GPT-4o 사고 패턴 분석	×	사후 분석 중심, 실시간 경보 생성 불가
본 연구	통합 관제	YOLO 1차 탐지 + LLM Few-shot 사후 검증, 프롬프트 기반 현장 적응	○	-

※ 비전 입력: ○ = 영상/이미지 입력 지원, △ = 부분 지원, × = 텍스트 전용

2.3. LLM Few-shot Learning과 현장 적응 연구

In-context Learning은 가중치 갱신 없이 프롬프트 예시만으로 과제를 학습하는 패러다임으로(Brown et al., 2020), 모델 재학습이나 기술적 변경 없이 프롬프트 수정만으로 새로운 과제에 즉시 적용할 수 있다는 이점을 제공한다(왕인국, 2024). 퓨샷 프롬프팅과 사고연쇄(Wei et al., 2022) 기법이 결합되며, 한소은(2026)은 3-루브릭 프롬프트 체계를 제시하였다. 분야 특화 적용에서는 왕인국(2024)이 RAG·미세조정·MM-RAG 통합을, Kim(2025)이 분야 지식베이스 방법론을 검증하였으나, YOLO 1차 결과를 LLM이 퓨샷으로 사후 검증하는 결합 구조는 보고된 바가 없다. 한편 In-context Learning의 효과는 예시의 선택에 민감하여 무관하거나 부적절하게 선택된 예시가 오히려 성능을 저하시킬 수 있으므로(Liu et al., 2022), 본 연구는 교정을 무차별 주입하지 않고 현재 알림과 같은 맥락의 교정만 선택적으로 검색·주입하는 RAG 기반 현장 적응 기법을 채택하며, 4.3절에서 이를 교정 미사용(제로샷)·고정 개수 주입(고정-k) 방식과 비교 검증한다.

Ⅲ. 제안시스템

3.1. 설계 목표와 이중 캐스케이드 아키텍처

중소규모 건설현장은 전담 안전관리자의 부재(김석기, 2026), 안전관리비 준수율 36.7%에 그치는 예산 제약(조도빈, 2026), 라벨 데이터 부족(Kim, 2025)이라는 구조적 제약을 가지며 기존 ONVIF 카메라 인프라의 재활용은 비용 제약을 해소하기 위한 핵심 전제이다. 본 연구는 이러한 제약을 충족하기 위해 다섯 가지 설계 요구사항을 도출하였다. 일반 사무용 PC에서 구동 가능할 것(R1), 기존 ONVIF IP 카메라와 호환되는 RTSP 스트림을 처리할 것(R2), 현장별 재학습 없이 현장 적응이 가능할 것(R3), 오탐률이 경보 피로를 유발하지 않는 임계치 이하로 유지될 것(R4), 영상 프레임 단위의 실시간 처리가 가능할 것(R5)이다. 본 연구에서 '실시간성(R5)'은 순간적 처리가 아니라 위험에 대응 가능한 시간 창(reaction window) 안에서 경보 도달, 즉 적시(right-time)로 정의한다(Teizer, 2016). 검출-알림 지연을 10초 미만으로 단축할 때 실시간 예방·시정 효과가 극대화됨을 보고한 대규모 실배치 연구(Zhang et al., 2026)에 근거하여, 본 연구는 검출부터 사용자 단말 알림 도달까지의 종단간 지연 10초 미만을 실시간성(R5)의 정량 기준으로 설정한다.


표 3. 중소현장 구조적 제약과 설계 요구사항 R1~R5 매핑

요구사항	대응 제약	제약이 야기하는 문제	본 시스템의 설계 대응	근거 절
R1 일반 사무용 PC 구동	예산 제약	고성능 GPU 서버·전용 워크스테이션 도입 불가	경량 YOLO 모델 + 클라우드 LLM API 호출 구조로 로컬 연산 부하 최소화	3.1, 3.2
R2 ONVIF/RTSP 호환	노후 인프라	신규 IP 카메라·네트워크 장비 전면 교체 부담	ONVIF 표준 RTSP 스트림 직접 수신, 기존 CCTV 자산 재활용	3.1
R3 현장별 재학습 불요	라벨 부족	현장 다양성 대비 라벨 데이터 확보 불가, 재학습 비용 과다	LLM Few-shot 프롬프트 예시 수정만으로 신규 현장·위험 규칙 반영	3.3.2
R4 오탐률 임계치 이하	안전관리자 부재	오탐 누적 시 경보 피로 유발, 진경보 무시·시스템 비활성화 위험	YOLO 1차 고민감도 탐지 + LLM 2차 특이도 검증의 캐스케이드로 오탐 억제	3.2, 3.3
R5 실시간 처리·경보 도달(종단간 <10초)	안전관리자 부재	사고 발생 시점과 인지·대응 지연이 인명피해로 직결	스트리밍 파이프라인 4단계 (수집→탐지→검증→경보) 비동기 처리, 종단간 중위 6초로 <10초 기준 충족	3.1, 3.4

본 시스템은 신호감지이론(Signal Detection Theory, SDT; Green & Swets, 1966)에 근거하여 1차는 민감도(sensitivity) 극대화, 2차는 특이도(specificity) 극대화로 역할을 분담하는 캐스케이드 구조를 채택

한다. SDT는 신호와 잡음이 중첩된 환경에서 결정 임계값(criterion)의 위치에 따라 적중(hit)과 오경보(false alarm)가 상쇄(trade-off) 관계를 이룬다고 본다. 단일 검출기로는 이 상쇄(trade-off)를 회피할 수 없으나, 서로 다른 기준값(criterion)을 가진 두 단계를 직렬 연결하면 1차의 높은 적중률(hit rate)과 2차의 낮은 오경보율(false alarm rate)을 동시에 확보할 수 있다. Cvach(2012)가 의료 알람 분야에서 권고한 지능형 알람(Smart alarms) 역시 동일한 원리에 기반한다. 본 시스템의 전체 처리 흐름은 ONVIF 카메라의 RTSP 스트림이 YOLO 1차 고민감도 검출 모듈로 입력되고, 검출 결과가 LLM 2차 퓨샷(Few-shot) 검증 모듈을 거쳐 알람 앱으로 전파되는 4단계 파이프라인으로 구성된다(그림 2).

그림 2. 제안 시스템의 4단계 처리 파이프라인



본 시스템은 일반 사무용 PC에서 동작하는 데스크톱 응용으로 구현되며, ONVIF 표준 카메라의 RTSP 스트림을 입력으로 받아 YOLO 객체 탐지와 멀티모달 LLM 검증을 수행한다. AI 추론은 가용 GPU 자원에 따라 가속 경로를 자동 선택하며, LLM은 상용 멀티모달 모델 다수에 대해 다중 프로바이더 폴백 구조를 적용해 가용성을 확보한다. 확정된 경보는 알람 앱으로 다중 수신자에게 동시 전파된다.

3.2. 1차 검출: 고민감도 YOLO 객체 탐지 모듈

기존 YOLO 기반 건설안전 연구는 오탐 우려로 신뢰도 임계값(confidence threshold)을 통상 0.4~0.5 수준에서 운용해 왔으며(박종학, 2025) 이로 인해 미탐(false negative)이 증가하는 한계를 보였다. 박종학(2025)은 통상 임계값에서 Forklift·Scaffold 등 일부 위험 클래스의 재현율(recall)이 낮아지는 한계를 보고하였다. 본 시스템은 SDT의 민감도-특이도(sensitivity-specificity) 분리 원칙에 따라 1차 단계에서는 재현율(recall) 극대화를 목표로 임계값을 0.3으로 하향한다. 이로 인해 발생하는 오탐은 2차 LLM 단계가 문맥 검증으로 필터링한다. Kim et al.(2025)은 임계값을 0.3으로 하향($\tau_{mod}=0.3$)하는 같은 방향의 전략으로 화재 검출 재현율(recall)을 0.904까지 끌어올리고 F1을 0.863에서 0.8895로 향상시킨 바 있어 본 연구 설계의 직접적 근거가 된다. 본 시스템은 YOLO26 계열의 중형(medium) 변형(YOLO26m, COCO val 기준 mAP50 0.651; Ultralytics, 2025)을 기반으로 작업자, 안전모·안전조끼 착용 여부, 중장비, 사다리, 비계, 낙상, 자유 객체 등을 검출하며 사전학습 가중치를 그대로 사용하고 추가 미세조정(fine-tuning)은 수행하지 않는다.

3.3. 2차 검증: LLM 기반 백업 검증 모듈

본 절은 본 연구의 핵심 기여를 다룬다. 본 모듈은 멀티모달 LLM이 1차 YOLO의 알람 메타데이터(카메라명·warning_key·warning_message)와 원본 프레임 이미지, 카메라별 사용자 교정 샘플을 입력받아 영

상·텍스트 통합 추론으로 정탐·오탐을 재판정하는 것을 골자로 한다. YOLO가 구조적으로 다룰 수 없는 객체 간 관계·상황 문맥·상식적 추론을 LLM이 보완함으로써 단일 모델로는 불가능한 특이도(specificity) 회복을 달성한다. 본 모듈의 두 가지 핵심 메커니즘은 LLM의 ① 멀티모달 문맥 추론에 의한 오탐 기각(3.3.1), ② 맥락 내 학습(In-context Learning) 특성을 활용한 퓨샷 기반 현장 적응(3.3.2)이며, 이를 통해 미세조정(fine-tuning) 없이도 현장별 적응이 가능하다.

3.3.1. 검증 필요성과 입출력 구조


1차 YOLO 검출은 자연 배경 오인식(나뭇가지를 사다리모), 작업복 패턴 오인식(줄무늬를 안전조끼로), 정상 자세 오인식(쪼그려 앉기를 낙상으로), 문맥 무관 오인식 등 네 가지 유형의 구조적 오탐을 발생시키며, 이러한 오탐은 임계값 상향만으로는 미탐 증가 없이 해결할 수 없다. 본 시스템은 이를 해결하기 위해 멀티모달 LLM을 2차 검증기로 도입한다. LLM은 1차 YOLO 검출 결과의 알람 메타데이터(카메라명·warning_key·warning_message)와 원본 프레임 이미지, 카메라별 사용자 교정 샘플(별도 user 메시지로 자동 주입)을 입력으로 받아 검출 영역을 자연어로 지목·해석하고, 정탐·오탐 판정(result: SEND/BLOCK)과 한국어 자연어 사유(reason: ≤80자) 두 필드만으로 구성된 JSON 스키마를 출력한다. reason 필드는 그대로 알림 앱 메시지로 활용되어 별도 요약 단계가 불필요하다. LLM이 2차 검증기로 적합한 이유는 ① 영상-언어 결합 추론으로 객체의 시각적 특성과 주변 맥락(예: 작업복 패턴 vs 반사 소재, 비계 위 자세 vs 사재 운반 자세)을 통합 판단할 수 있고, ② 사전 정의된 규칙 없이도 산업안전 분야의 상식적 지식을 활용할 수 있으며, ③ 판정 사유가 한국어 자연어로 출력되어 사용자가 결과를 검증·교정할 수 있고 알림 앱 메시지로 그대로 활용 가능하다는 세 가지 특성을 동시에 충족하기 때문이다.

3.3.2. Few-shot Learning 기반 현장 적응

본 시스템은 미세조정(fine-tuning) 없이 건설 현장용 시스템 프롬프트와 카메라별 사용자 교정 샘플을 결합하여 현장 적응을 달성한다. 이 접근은 라벨 데이터 구축 비용을 제거하고, 현장 규칙 변경 시 프롬프트 수정만으로 대응 가능하며, 사용자가 직접 오판 사례를 교정할 수 있다는 세 가지 이점을 가진다. 시스템 프롬프트는 건설안전 검토자 페르소나("You are a construction site safety officer")로 시작하여 출력 스키마(Output)·우선 규칙(Priority Rule)·SEND 조건·BLOCK 조건·핵심 원리(Key Principle)의 다섯 섹션으로 구성된다. LLM이 동일한 오판을 반복하는 경우 사용자는 알림 이력에서 우클릭으로 교정 샘플을 등록하며, 사유(10~80자)·교정 이미지와 함께 카메라별로 저장된다.

다만 누적된 교정을 매 호출에 무차별 주입하는 방식은, 관련 없는 교정이 끼어들어 새로운 오판을 유발하거나 동일 방향의 교정이 과다하게 쌓여 판정이 한쪽으로 쏠리는 부작용을 일으킨다(4.3절에서 실증). 본 시스템은 이를 방지하기 위해 현재 알림과 같은 맥락의 교정만 선택적으로 검색하여 주입하는 RAG(Retrieval-Augmented Generation) 방식을 채택한다. 구체적으로 교정 등록 시 현재 알림과 같은 맥락으로 분류하여 저장하고, 알림 발생 시 같은 맥락의 교정만 최대 3건까지 검색하여 본 검증 LLM의 프롬프트에 원본 프레임과 함께 주입한다. 같은 맥락의 교정이 없으면 주입하지 않는다(미주입 fallback). 이는 In-context Learning(Brown et al., 2020)을 검색 기반 예시 선택과 결합한 것으로, 관련성 높은 최소한의 교정만으로 운영 중 점진적 정확도 향상을 달성한다.

그림 3. 사용자 교정 샘플 등록 UI 스크린샷 - 알림 이력 우클릭으로 교정 샘플 등록·관리, 사유 입력(10~80자)



3.3.3. 통합 판정과 3단계 오탐 억제

본 시스템은 YOLO 1차 결과와 LLM 2차 결과를 결합하여 3단계 파이프라인으로 알림 여부를 결정한다. 1단계 1차 확인 필터는 단발성 오탐을 거르기 위해 일정 시간 창 내 재감지 또는 연속 프레임 감지를 요구한다. 2단계 LLM 문맥 검증에서는 `result=SEND`로 판정된 사건만 알림 단계로 진행되고 `BLOCK`으로 기각된 사건은 저장되어 추후 분석·교정에 활용된다. 3단계 쿨다운 필터는 동일 사건의 중복 알림을 억제한다. LLM API 장애 시에는 안전 폴백으로 1차 결과만 발송하되 "LLM 검증 실패" 태그를 부착하여 사용자가 결과의 신뢰 수준을 식별할 수 있도록 하며, LLM이 정탐을 오탐으로 잘못 기각한 사례는 사용자가 퓨샷(Few-shot) 교정 샘플로 등록 가능하다.


그림 4. 3단계 오탐 억제 파이프라인



3.4. 실시간 경보 전파

확정된 경보는 알림 앱을 통해 동시 전파된다. 메시지는 LLM이 출력한 자연어 사유(`reason` 필드)와 검출 프레임 이미지를 포함하며 다중 수신자에게 자동 분류 전송된다. 본 시스템의 위험알림 수신자 범위는 관련 법령에 근거하여 ① 「건설산업기본법」에 따른 현장대리인(현장배치 건설기술인), ② 「산업안전보건법」에 따른 안전보건관리책임자 및 안전관리자, ③ 「건설기술 진흥법」에 따른 발주청 소속 공사감독자 또는 지정 건설사업관리기술인(감리원)으로 정의한다. 알림 앱에 표시되는 위험 알림 예시는 그림 5와 같다.

그림 5. 위험 알림APP



IV. 실험 및 평가

4.1. 데이터셋 및 평가 지표

본 연구의 평가 데이터는 00공사 산하 중소규모 건설현장에서 2026년 5월 19일~27일 9일간(196.8시간) 운영된 현장 안전CCTV 카메라의 알림 로그(검출 유형: 중장비·차량 접근 위험 2종)로, YOLO confidence 와 LLM 판정 사유·스냅샷을 보유한 운영 산출물이다. 분석 목적에 따라 두 표본을 추출하여, 4.2.1~4.2.2 절(운영 분포·신뢰도 구간)에는 confidence가 기록된 1,074건을, 4.2.3절(정밀도 평가)에는 스냅샷 라벨링 이 가능한 878건(38대 카메라; 토목 25·건축 10·시설개보수 3, LLM 기준 오탐 826+정탐 52)을 사용한다. 라벨링은 연구자 1인이 LLM 판정의 정·오에 대한 이진 판단(O/X)으로 단독 수행하였다.

본 연구의 평가는 이기수(2024)의 객체탐지 성능평가지표 정의를 LLM 이진 판정 맥락에 적용하여, 사람 라벨링과 LLM 판정을 비교하는 네 사건 - 진양성(TP)·위양성(FP)·진음성(TN)·위음성(FN) - 으로 분류한다(표 4).

표 4. 본 연구의 혼동 행렬(Confusion Matrix) 정의 (이기수, 2024)

구 분	사람: 정탐 (실제 위험)	사람: 오탐 (실제 안전)
LLM: 정탐 (SEND)	TP - 진양성 (위험 알림 성공)	FP - 위양성 (오경보)
LLM: 오탐 (BLOCK)	FN - 위음성 (위험 누락)	TN - 진음성 (안전 차단 성공)

※ 사람 라벨(O/X)을 정답으로, LLM의 SEND/BLOCK 판정과 비교하여 네 사건(TP·FP·FN·TN)으로 분류함. 대각선(TP·TN)이 정확 판정, 비대각선(FP·FN)이 오판.

핵심 평가 지표는 표 4의 네 사건에 기반한 여섯 가지 - 정밀도, 재현율, F1, 시간당 오경보율(FAR), 특이도, 정확도 - 이며 정의와 목적은 표 5과 같다. 모든 비율 지표는 Wilson 95% 신뢰구간(Wilson, 1927)을 함께 보고하고, FAR은 196.8시간 기준으로 산출하며, YOLO 자체 검출 성능(mAP@0.5)은 선행 연

구(Ultralytics, 2025) 인용으로 대체한다.

표 5. 평가 지표 정의와 측정 목적

지표	정의	측정 목적
정밀도 (Precision)	$TP/(TP+FP)$	SEND로 통과시킨 알람 중 실제 위험의 비율로, 사용자가 받는 알람의 신뢰도와 알람 피로 감소 효과를 측정
재현율(Recall)	$TP/(TP+FN)$	실제 위험 사건 중 SEND된 비율로, 시스템이 안전사고를 놓치지 않는 능력을 측정
F1 점수	$2 \cdot P \cdot R / (P+R)$	정밀도와 재현율의 조화평균으로, 두 지표 간 상쇄 관계 속 균형 잡힌 종합 성능을 측정
시간당 오경보율(FAR)	$FP / \text{시간}$	단위 시간당 잘못된 알람 빈도로, 알람 피로(Cvach, 2012)의 정량 지표
특이도 (Specificity)	$TN/(TN+FP)$	실제 안전 상황 중 BLOCK된 비율로, LLM 백업 검증의 오탐 차단 능력을 측정
정확도 (Accuracy)	$(TP+TN)/N$	전체 판정의 정확률로, 시스템의 종합적 신뢰성을 측정

※ 모든 비율 지표는 Wilson 95% 신뢰구간(Wilson, 1927)을 함께 보고하며, FAR은 평가 기간 196.8시간 기준으로 산출. 핵심 가설("2단계가 1차 단독 대비 낮은 FAR 달성")상 FAR·정밀도가 1차 평가 대상.

핵심 가설은 "2단계 파이프라인이 1차 단독(Conf 0.3) 대비 낮은 FAR을 달성한다"이므로 FAR·정밀도를 1차 평가 대상으로 하고, 안전사고 방지 측면에서 재현율·특이도를 함께 보고한다.

4.2. LLM 백업 검증의 오탐률 감소 효과

4.2.1. 운영 알람 분포

평가 기간 9일간 1,074건의 알람 중 LLM이 SEND한 사건(정탐) 51건(4.75%), BLOCK한 사건(오탐) 1,023건(95.25%)이었고, 일평균 알람 119.3건·SEND 5.7건이었다. 이는 1차 YOLO(Conf 0.3)가 민감도를 높여 다수 알람을 발생시키고 2차 LLM이 약 95%를 추가 차단하는 캐스케이드 구조가 의도대로 작동함을 보여준다. Cvach(2012)가 보고한 알람 피로 유발 부하(환자 1인당 하루 약 700건, 시간당 약 29건)에 비해 본 시스템의 SEND 알람은 시간당 약 0.26건으로 과부하 수준을 크게 밑돈다.

4.2.2. YOLO confidence와 LLM 판정의 관계

본 절은 1차 confidence와 2차 LLM 판정의 관계로 캐스케이드 분업 원리를 정량 검증하고, YOLO 임계값 상향이라는 대안 설계의 타당성도 검토한다. 1,074건의 confidence 구간별 분포와 임계값 상향 시물레이션은 표 6과 같다.

표 6. YOLO confidence 구간별 LLM 판정 분포 및 임계값 상향 시물레이션 (n=1,074)

YOLO confidence	구간 알람	구간 SEND	구간 SEND율	임계값 ↑ 시 통과 알람	임계값 ↑ 시 누락 SEND
$0.30 \leq \text{conf} < 0.40$	452	9	1.99%	1,074 (100.0%)	0 (0.0%)
$0.40 \leq \text{conf} < 0.50$	224	11	4.91%	622 (57.9%)	9 (17.6%)
$0.50 \leq \text{conf} < 0.60$	130	9	6.92%	398 (37.1%)	20 (39.2%)
$0.60 \leq \text{conf} < 0.70$	101	8	7.92%	268 (24.9%)	29 (56.9%)
$0.70 \leq \text{conf} \leq 1.00$	167	14	8.38%	167 (15.5%)	37 (72.5%)
합계	1,074	51	4.75%	—	—

구간 경계는 [a, b) 방식으로 적용하였다. YOLO confidence가 높을수록 LLM의 SEND 비율이 단조 증

가(1.99% → 8.38%)하여 두 단계가 동일 방향의 위험 신호를 포착함을 보여주며, 특히 conf 0.30~0.40 구간(전체 42.1%)의 SEND율이 1.99%로 급락하는 점은 1차=민감도·2차=특이도라는 캐스케이드 설계 가정의 직접 증거다. 임계값을 0.40으로 올리면 FAR이 5.46→3.16건/시간(약 42.1% 감소)이나 SEND 51건 중 9건(17.6%)이 누락되고, 0.50에서는 FAR 2.02건/시간(62.9% 감소)에 SEND의 39.2%(20건)가 누락되어 손실이 급증한다. 따라서 conf 0.30을 유지하고 LLM이 잔여 오탐을 거르는 설계가 정당화되며, 이는 Kim et al.(2025)의 결과를 운영 데이터에서 재확인한 것이다.

4.2.3. 운영 정밀도 평가

본 절은 핵심 가설을 878건 전수 라벨링으로 검증한다. 사람 라벨링 결과 정탐 44건·오탐 834건이 확인되었으며, 1차 단독(Conf 0.3, 전 검출 통과)과 2단계(YOLO+LLM)의 성능 비교는 표 7 및 그림 6과 같다.

표 7. 1차 단독 시스템과 2단계 파이프라인의 성능 비교(n=878, 196.8시간, 38대 카메라)

지표	1차 단독 (Conf 0.3)	2단계 (0.3 + LLM)	변화
총 경보 건수	878	52	-94.1%
진경보(TP) / 오경보(FP)	44 / 834	39 / 13	-
진음성(TN) / 위음성(FN)	0 / 0	821 / 5	-
시간당 오경보율(FAR, 건/시간)	4.238	0.066	-98.44%
정밀도(Precision)	0.050	0.750[.618, .848]	+0.700
재현율(Recall)	1.000	0.886[.760, .951]	-0.114
F1 점수(F1)	0.095	0.813	+0.718
정확도(Accuracy)	0.050	0.980[.968, .987]	+0.930

그림 6. 1차 단독과 2단계 파이프라인의 성능 지표 비교



표 7의 '1차 단독(Conf 0.3)' 열은 878건 전체를 검증 없이 전달한다는 baseline 가정의 값으로, LLM

단계가 없어 정의상 $FN=0 \cdot TN=0$ 이 되므로 재현율 1.000·특이도 0.000은 산술적 귀결일 뿐 1차 모델의 실측 성능이 아니다. 본 비교의 목적은 동일 1차 입력에 LLM 2차 검증이 더하는 정밀도·특이도·FAR 개선분을 정량화하는 데 있으며, YOLO26m 자체 검출 성능은 선행 연구(Ultralytics, 2025) 인용으로 같음한다.

2단계 파이프라인은 1차 단독(Conf 0.3) 대비 FAR을 4.238→0.066건/시간으로 약 98.44% 감소시키면서 재현율은 1.000→0.886으로 11.4%p 하락에 그쳤고, F1은 0.095→0.813, 특히 특이도 0.984 [0.974, 0.991]로 안전 상황을 정확히 차단함을 보였다. 이는 김운현(2025)의 오알람 93.4% 필터링, Kim et al.(2025)의 F1 +0.0265, 한소은(2026)의 Weighted Accuracy +13.81%p와 같은 방향이며 FAR 감소율(98.44%)에서 더 큰 효과를 보였다. 정성 사례는 표 8에 정리하였다(사례 1·2 정확 판정, 사례 3·4 약점 노출).

표 8. LLM 2차 검증 정성 사례(실측 데이터에서 발췌)

사례	1차 YOLO 검출 (객체·conf)	LLM 판정	사람 검수	LLM 자연어 사유(요약)
1 TP	중장비 접근 (0.86)	정답	정답	굴착기 작업 반경 내에 작업자가 근접해 있어 충돌 위험이 있음
2 TN	중장비 접근 (0.33)	오탐	오탐	작업자가 중장비와 충분한 거리를 두고 통행로를 이동 중이며 직접적인 접촉 위험 없음
3 FP	중장비 접근 (0.66)	정답	오탐 (신호수 통제)	굴착기 작업 반경 내에 작업자가 근접해 있어 충돌 위험이 있음(신호수 미반영)
4 FN	중장비 접근 (0.85)	오탐	정답	빨간색 안전조끼를 착용한 신호수가 포함되어 있어 경보 차단(신호수 오인식)

사례 3·4는 "신호수(빨간·형광 안전조끼)" 인식 오판으로, 라벨링 X 사례 18건 중 16건(88.9%)이 신호수 인식 문제였다. 이는 프롬프트 교정·신호수 전용 검출 보조의 개선 여지를 시사한다(현장별 신호수 복장규정 상이). 위음성 5건은 안전사고 직결 사건이므로 5장 한계로 명시한다.

4.3. RAG 기반 Few-shot 교정의 성능 실험

본 시스템의 2차 검증은 카메라별 사용자 교정 샘플을 LLM에 주입해 동일 오판 반복을 억제하되, 무차별 주입이 아닌 현재 알림과 같은 맥락의 교정만 선택 검색·주입하는 RAG(Retrieval-Augmented Generation) 방식으로 구현된다. RAG는 현재 알림과 같은 맥락의 교정만 최대 3개 검색해 본 검증 LLM에 주입하며 없으면 미주입(fallback)한다. 본 절은 이를 제로샷·고정-k와 비교 검증한다.


검증 대상은 878건 중 교정 샘플을 등록한 6개 카메라이며, 각 알림을 실제 2차 파이프라인(temperature=0)으로 네 조건에서 재호출하였다. 교정-평가 중복 누수는 이미지 해시·사유 대조로 제외(평가 202건)하였고, 표본이 소수이므로 사례 분석으로 해석한다. 결과는 표 9, 그림 7과 같다.

표 9. 제로샷·고정-k·RAG의 성능 비교(알림=202건, 조건당1회, 총 808번 호출, 6개 카메라)

조건	정밀도(Precision)	재현율(Recall)	F1 점수(F1)	정확도(Accuracy)	오경보(FP)
제로샷(교정 미사용)	0.320	0.333	0.327	0.837	17
고정 k=3	0.389	0.292	0.333	0.861	11
고정 k=5	0.368	0.292	0.326	0.856	12
RAG 동적선택	0.462	0.250	0.324	0.876	7

그림 7-1. 제로샷·고정-k(k=3·k=5)·RAG의 정밀도·정확도·오경보 수 비교 막대그래프

그림 7-2. 무관 교정 주입의 역효과 - 단일 카메라 사례(00저수지현장·고정, n=30, 교정 3건)



결과는 세 가지다. 첫째, 교정 개수 증가(k)는 역효과로, 고정 k=5가 k=3보다 오경보가 늘어(11→12) 과 교정을 유발한다(그림 7). 둘째, 무관한 교정은 무익할 뿐 아니라 해로울 수 있다. 집계 정확도는 교정 주입으로 상승했으나(표 9), 제로샷에서 이미 정확도가 높던 카메라(00저수지현장, 0.967·오경보 0건)에서는 고정-k가 맥락과 무관한 교정까지 강제 주입해 없던 오경보 5건이 발생하여 정확도가 0.800으로 하락하였다. RAG의 선택적 주입에서 0.967로 회복되었다(그림 7-2). 셋째, RAG가 가장 효과적이어서 정밀도(0.462)·정확도(0.876)·오경보(FP 7)에서 제로샷과 두 고정-k를 모두 능가했고, 제로샷 대비 오경보를 17→7건(약 59%), 고정 k=5 대비 12→7건(약 42%) 줄였다.

이는 RAG가 상황에 맞는 선택성을 갖기 때문으로, 같은 맥락의 교정이 있을 때만 주입하고 무관하면 생략함으로써 고정-k의 과교정·무관 주입 부작용을 구조적으로 회피한다.

4.4. 적용 타당성

지연시간은 1,074건 실측 기준 LLM 2차 호출 중위 4.20초이며, 표준 사무용 PC(중급 GPU 12GB)에서 YOLO 1차 추론 45ms(720p, CPU 풀백 95ms)·1차 확인 윈도우 1.5초·모바일 알림 약 350ms를 포함한 검출→단말 도달 총 지연은 중위 약 6.0초로 측정되었다. 이는 1차 실시간·2차 비실시간 사후 검증의 분리 설계에 따른 것으로, 검출-경보 10초 미만을 실시간 기준으로 제시한 선행 실배치(Zhang et al., 2026)에 비추어 R5 기준을 충족한다. 도입 비용 비교(장비 단가는 국토안전관리원, 2024, pp.22-23)는 표 10과 같다.

표 10. 첫째 도입 비용(TCO) 비교(국토안전관리원 가이드라인 단가 기준, 단위: 만 원)

항목	상용 솔루션	본 시스템
AI CCTV (4채널)	2,000	0(ONVIF 재활용)
AI 분석 서버·SW	2,540	150(PC·오픈소스, 기존 자산 시 0)
LLM API 사용료	—	60 / 년(월 5만 원)
첫해 TCO	4,540	210(약 95% 절감)

상용 솔루션 첫째 약 4,540만 원은 조도빈(2026)이 보고한 50억 미만 현장 안전관리비 실행 규모(평균 준수율 36.7%)를 상회하여 부담 능력 밖이며, 이는 스마트 안전장비 비용 부담이 도입 장벽이라는 선행 분석(이준호, 2024)과 부합한다. 본 시스템은 이 격차를 약 95% 절감으로 해소한다.

V. 결론

중소규모 건설현장은 단일 AI의 높은 오탐과 라벨 데이터 부족이라는 이중 제약 아래 놓여 있고, 잦은 오경보는 경보 피로(Alarm Fatigue)를 누적시켜 위험 신호 대응 신뢰도를 잠식한다. 본 연구는 YOLO 1차 고민감도 검출(Conf 0.3)과 LLM 2차 퓨샷 검증을 결합하고 신호감지이론에 근거해 민감도·특이도 역할을 분리한 이중 캐스케이드 시스템을 제안하여, 00공사 산하 협력 현장 38대 카메라의 실제 운영 데이터로 실증하였다.

878건(196.8시간) 전수 라벨링 결과, 2단계 파이프라인은 1차 단독(Conf 0.3) 대비 FAR을 4.238→0.066건/시간으로 약 98.44% 감소시키면서 재현율은 1.000→0.886으로 11.4%p 하락에 그쳤고, F1 0.095→0.813, 특이도 0.984, 정확도 0.980으로 안전 상황을 정확히 차단함을 확인하였다. 종단간 지연은 중위 약 6.0초로 R5 실시간성을 충족하였고, 첫째 TCO는 상용 솔루션 4,540만 원 대비 210만 원으로 약 95% 절감되었다.

학술적으로 본 연구는 YOLO-LLM 이중 캐스케이드의 민감도·특이도 분리 설계가 단일 AI의 한계를 극복함을 정량 입증하였고, 이는 Cvach(2012)의 지능형 알람(Smart alarms) 권고에 부합한다. 실무적으로는 일반 PC와 기존 ONVIF 카메라 재활용, 다중 LLM 프로바이더 자동 폴백, 미세조정 없는 RAG 기반 교정 주입만으로 신규 현장에 적용 가능한, 중소현장이 부담 가능한 비용 수준의 도입 경로를 제시하였다.

본 연구는 검출 유형이 중장비·차량 접근 2종에 한정되어 다른 유형(낙상·안전모 미착용·제한구역 진입 등)으로의 일반화에 추가 검증이 필요하다는 한계를 가진다. 향후 2차 LLM 판정·교정 샘플을 1차 YOLO 학습에 활용하는 능동학습(Active Learning) 통합, 6개월 이상 장기 운영을 통한 사고 예방·지속성 평가, 사용자 설문 기반 실질 효과 검증, 그리고 터널·교량·플랜트 등 다양한 현장으로의 확장으로 연구 범위를 넓힐 필요가 있다.

참 고 문 헌

가. 학위논문

- [01] 김석기(2026), "소규모 건설현장 사망사고의 시스템적 원인 규명을 위한 BERTopic-LLM과 AcciMap 통합 분석 프레임워크 개발", 충북대학교 대학원 박사학위논문. [인용 페이지: pp.1-3, 39]
- [02] 김윤현(2025), "인공지능 기반 건설현장 안전인지 프레임워크 개발", 성균관대학교 대학원 박사학위논문. [인용 페이지: p.82]
- [03] 김현수(2026), "통합관제센터 운영을 위한 Vision AI - VLM 비교 및 하이브리드 연구", 중앙대학교 대학원 석사학위논문. [인용 페이지: pp.13, 31, 55-57]
- [04] 류수영(2023), "CCTV 기반 산업안전 관제 시스템에 관한 연구", 배재대학교 대학원 박사학위논문. [인용 페이지: p.1]

- [05] 박종학(2025), "YOLO(You Only Look Once) 모델별 건설 현장 위험 상태 및 객체 인식 성능 비교", 경기대학교 공학대학원 석사학위논문. (인용 페이지: pp.51, 56-57)
- [06] 왕인국(2024), "건설현장 위험요인 식별을 위한 RAG와 Fine-tuning 기반 LLM 성능향상에 관한 연구", 광운대학교 대학원 석사학위논문. (인용 페이지: pp.10, 62-63, 67-68)
- [07] 이기수(2024), "건설현장의 안전 확보를 위한 딥러닝 기반의 시스템비계 설치 이상감지 연구", 명지대학교 대학원 박사학위논문. (인용 페이지: pp.31-32)
- [08] 이준호(2024), "건설현장 중대재해 감소를 위한 스마트 안전장비의 지원방법 개선에 관한 연구", 한양대학교 융합산업대학원 석사학위논문. (인용 페이지: p.46)
- [09] 이형도(2023), "객체탐지 알고리즘을 이용한 건설현장 근로자 안전모 실시간 모니터링 기술 활성화 방안 연구", 경기대학교 대학원 박사학위논문. (인용 페이지: pp.27, 30)
- [10] 이호원(2026), "멀티모달 대규모 언어 모델과 검색 증강 생성을 결합한 실내 화재 대응 조연 시스템 개발에 관한 연구", 선문대학교 대학원 박사학위논문. (인용 페이지: pp.34-36, 43)
- [11] 임승진(2023), "도시철도 안전관리를 위한 딥러닝 기반 이상행동 감지", 경성대학교 대학원 철도시스템공학과 박사학위논문. (인용 페이지: pp.32, 34)
- [12] 조도빈(2026), "국내 소규모 민간 건설프로젝트의 산업안전보건관리비 준수 실태 분석 및 개선방안 제시연구", 울산대학교 대학원 박사학위논문. (인용 페이지: pp.20, 29-30)
- [13] 한소은(2026), "건설현장 '일일 위험성 평가서' 자동 생성 모델 - Vision-Language Model (VLM)을 활용하여", 인천대학교 대학원 석사학위논문. (인용 페이지: pp.17-18, 30)
- [14] Kim, E.W.(2025), "Development of an Automated Construction Contract Review Framework Using LLM and Domain Knowledge", Ph.D. Dissertation, Chung-Ang University. (인용 페이지: pp.27, 42)
- [15] Mi, Y.(2025), "Deep Learning-Based Safety Analysis for High-Altitude Construction Workers: PPE Detection and Posture Recognition Model Development", Ph.D. Dissertation, Kyungpook National University. (인용 페이지: pp.79-80, 111)

나. 학술지

- [16] Ryu, J., and Park, I.S.(2025), "건설현장의 스마트 안전장비 성능과 도입 효과 분석", *Crisisonomy*, 21(6), pp.125-135. DOI: 10.14251/crisisonomy.2025.21.6.125. (인용 페이지: pp.130-131, 133)
- [17] Brown, T.B., Mann, B., Ryder, N. et al.(2020), "Language Models are Few-Shot Learners", *Advances in Neural Information Processing Systems*, 33, pp.1877-1901. (인용 페이지: pp.1, 3)
- [18] Cvach, M.(2012), "Monitor Alarm Fatigue: An Integrative Review", *Biomedical Instrumentation & Technology*, 46(4), pp.268-277. (인용 페이지: pp.268, 271)
- [19] Kim, J., Lee, Y., Yoon, D., Jung, C., and Lee, G.(2025), "An Integrated YOLO and VLM System for Fire Detection in Enclosed Environments", *I Can't Believe It's Not Better (ICBINB) Workshop @ ICLR 2025*. (인용 페이지: pp.3-4)
- [20] Liu, J., Shen, D., Zhang, Y., Dolan, B., Carin, L., and Chen, W.(2022), "What Makes Good In-Context Examples for GPT-3?", *Proceedings of Deep Learning Inside Out (DeeLIO 2022): The 3rd Workshop on Knowledge Extraction and Integration for Deep Learning Architectures*, pp.100-114. (인용 페이지: pp.100-101)
- [21] Teizer, J.(2016), "Right-time vs Real-time Pro-active Construction Safety and Health System Architecture", *Construction Innovation*, 16(3), pp.253-280.
- [22] Wang, K., Cui, T., Zhang, Y., Chen, Y., Wu, S., and Li, Z.(2025), "Intelligent Image Search Algorithms Fusing Visual Large Models", *arXiv preprint*, arXiv:2511.19920. (인용 페이지: pp.2-3)
- [23] Wei, J., Wang, X., Schuurmans, D. et al.(2022), "Chain-of-Thought Prompting Elicits Reasoning in Large Language Models", *Advances in Neural Information Processing Systems*, 35, pp.24824-24837. (인용 페이지: p.2)

- [24] Wilson, E.B.(1927), "Probable Inference, the Law of Succession, and Statistical Inference", *Journal of the American Statistical Association*, 22(158), pp.209-212.
- [25] Zhang, G., Wang, W., Kong, T.L., Xing, K., Li, H., and Wang, Y.(2026), "ConstructAI: From Real-Time Safety Insight to Skill Growth in Deployed Construction AI Systems", *Proceedings of the 40th AAAI Conference on Artificial Intelligence (AAAI-26)*, pp.40167-40175. [인용 페이지: p.40173]

다. 보고서

- [26] 국토안전관리원(2024), "스마트 안전장비 활용 가이드라인", 국토교통부·국토안전관리원. [인용 페이지: pp.22-23]
- [27] 최수영(2025), "'23년 OECD 경제 10대국 건설업 사고사망만인을 비교", 건설동향브리핑 제1019호, 한국건설산업연구원. [인용 페이지: p.2]

라. 관련법

- [28] 산업안전보건법, 법률 제21065호, 2025. 10. 1. 타법개정(시행 2025. 10. 1.).
- [29] 중대재해 처벌 등에 관한 법률(중대재해처벌법), 법률 제17907호, 2021. 1. 26. 제정(시행 2022. 1. 27.).

마. 기타 (단행본·Preprint·웹자료)

- [30] Green, D.M., and Swets, J.A.(1966), *Signal Detection Theory and Psychophysics*, Wiley, New York.
- [31] Wu, J., Wu, S., Ma, Y., Yu, G., Xu, H., Zheng, L., and Duan, J.(2025), "MonitorVLM: A Vision-Language Framework for Safety Violation Detection in Mining Operations", *arXiv preprint*, arXiv:2510.03666. [인용 페이지: pp.1-2, 7-8]
- [32] Ultralytics(2025), *YOLO26 Model Documentation*, <https://docs.ultralytics.com> (최종 접속 2026-05-27).

저 자 소 개

윤 혁 (Yoon Hyuk)

주 저 자

- 공학학사(2013), 경기대학교 공학대학원 건설안전학과 석사과정
- 한국농어촌공사 경기지역본부 안전관리센터 재직 中

박 종 용 (Park Jong Yong)

교신저자

- 공학박사(2017)
- 안전의 4요소(4M)가 굴삭기 사고에 미치는 영향에 관한 연구(2023)
- 드론을 활용한 스마트 건설 안전기술 개발 및 실증연구(2023)
- 고령근로자의 만성질환과 건설현장 휴먼에러와의 상관성 연구(2023)
- 건설현장에서 건설기술진흥법상 안전관리비가 위험도에 미치는 영향 분석(2024)

김 미 소 (Kim Mi-Soh)

공동저자

- 공학학사(2023), 경기대학교 공학대학원 건설안전공학과 석사과정
- (주)태영건설 재직 中